

# 麦克风阵列信号处理教程

深入浅出 · 从阵列摆位到工程选型（合订本）

构建日期 2026-09-22 · 源文件 sha256 72736028564f · 共 14 篇：导读、11 章正文、2 篇附录

# 目录

---

- 导读与导航
  - 1. 这是一份什么样的教程
  - 2. 14 个文件一览
  - 3. 各篇内容学习目标
  - 4. 阅读顺序
  - 5. 三条阅读路径
  - 6. 插图地图：33 张图在哪篇
  - 7. 十处跨文档联系
  - 8. 动手复现
  - 9. 常见问题
  - 附录：下一步清单
- 第 1 章 · 问题定义与双耳启示
  - 1.1 双耳听觉的三类定位线索
- 第 2 章 · 声音到达阵列时发生了什么
  - 2.1 核心事实：同一声音，到达各麦克风有先有后
  - 2.2 近场与远场
  - 2.3 信号模型：把“声音有先有后”写成数学
  - 2.4 房间声学：混响到底是怎么来的
  - 2.5 数据怎么组织：STFT、快拍与协方差矩阵
  - 2.6 怎么衡量一个波束好不好：先学会读波束图
  - 2.7 小结：声源走近了，平面波不够用——近场要换的三样东西
  - 本章练习
- 第 3 章 · 阵列几何形态
  - 3.1 形态总览
  - 3.2 四条设计规律
  - 3.3 稀疏阵列与差分协同阵
  - 3.4 阵列校准：麦克风个个不一样时怎么办
  - 本章练习
- 第 4 章 · 声源定位（DOA 估计）
  - 4.1 总览：四大类思路
  - 4.2 GCC-PHAT：“对齐两段录音，找最吻合的错位”
  - 4.3 SRP-PHAT：跨麦对累积空间响应
  - 4.4 两阶段法的几何解算
  - 4.5 波束扫描类：Bartlett 与 Capon
  - 4.6 子空间类：MUSIC 与 ESPRIT
  - 4.7 稀疏重构与深度学习
  - 4.8 定位算法总对比
  - 4.9 本章练习
- 第 5 章 · 波束形成
  - 5.1 统一问题表述
  - 5.2 延迟求和波束形成器（Delay-and-Sum Beamformer，简称 DSB）：“合唱前先把大家对齐”
  - 5.3 超指向的白噪声增益—指向性权衡
  - 5.4 最小方差无失真响应
  - 5.5 线性约束最小方差（Linearly Constrained Minimum Variance，简称 LCMV）：多约束推广
  - 5.6 广义旁瓣对消器（Generalized Sidelobe Canceller，简称 GSC）：把约束改造成“噪声对消器”
  - 5.7 后置滤波
  - 5.8 球谐波波束形成（球阵专属）
  - 5.9 深度神经网络（Deep Neural Network，简称 DNN）波束形成
  - 5.10 波束形成算法总对比
  - 5.11 本章练习
- 第 6 章 · 声学回声消除（AEC）
  - 6.1 AEC 的模型、算法与实现
    - 6.1.1 回声从哪来：系统模型与四种场景
    - 6.1.2 线性自适应滤波：NLMS 回顾
    - 6.1.3 工程化自适应：频域、子带、比例、卡尔曼
    - 6.1.4 非线性回声：模型失配与处理方法
    - 6.1.5 双讲检测与自适应控制
    - 6.1.6 学习型 AEC
    - 6.1.7 阵列中的 AEC：与波束形成的三种顺序
    - 6.1.8 评测体系与工程验收清单
    - 6.1.9 WebRTC AEC3 的结构与排障
    - 6.1.10 多参考 AEC 模型与去相关选型
    - 6.1.11 播放链参考抽头位置及其对 ERLE 的影响
    - 6.1.12 测试覆盖与验收矩阵
    - 6.1.13 AEC 诊断方法与 NLP 工作点
    - 6.1.14 个性化 AEC 的合规检查
    - 6.1.15 研究方向
    - 6.1.16 可执行基线与开源实现边界
    - 6.1.17 常见误区与自测题
    - 6.1.18 延伸阅读
- 第 7 章 · 去混响（WPE）
  - 7.1 WPE 去混响
    - 7.1.1  $\Delta$  与  $K$  的参数换算
    - 7.1.2 常见错误与练习
    - 7.1.3 研究方向
- 第 8 章 · 语音分离
  - 8.1 多说话人语音分离：鸡尾酒会问题
  - 8.2 处理模块的顺序
- 第 9 章 · 声源追踪
  - 9.1 问题与声学特殊性
  - 9.2 单目标追踪
  - 9.3 多目标追踪
  - 9.4 定位、追踪与波束形成的接口
  - 本章练习
- 第 10 章 · 工程实现、评测与产业实践
  - 10.1 参考链路与端到端延迟
  - 10.2 拾音、同步与增益
  - 10.3 NS、控制信号与唤醒分支
  - 10.4 定点化、算力与功耗预算
  - 10.5 评测体系
  - 10.6 数据、仿真与复现
  - 10.7 分布式阵列
  - 10.8 阵列形态与场景约束
  - 10.9 从模型到设备
  - 10.10 联调与验收
  - 10.11 本章小结
- 第 11 章 · 总结与选型指南
  - 11.1 先回答六个问题
  - 11.2 按条件选择模块
  - 11.3 几何与算法要一起选
  - 11.4 四个场景怎样推导方案
  - 11.5 把候选方案写成可验证的规格
  - 11.6 练习
  - 11.7 后续阅读

- 附录 A · 符号术语数学
  - 12.1 符号表
  - 12.2 术语词典
  - 12.3 预备知识速览

- 附录 B · 路径地图与练习
  - 13.1 研究生学习路径
  - 13.2 领域地图：教材、会议、期刊与挑战赛
  - 13.3 研究前沿速览（2024—）
  - 13.4 常见问题与调试指南
  - 13.5 核心公式速查卡
  - 13.6 思考与练习
  - 13.7 复现说明

# 导读与导航

本页是全套教程的入口，一共 14 个文件：本页导读 + 11 章正文 + 2 篇附录。

11 章正文和 2 篇附录既可顺序阅读，也可按第 5 节的学习路径选读。每篇开头都列出上一篇、下一篇和首页链接。

全套教程配了 33 张图，图 18~20、图 26~32 在第 6 章。插图分为几何示意、指定条件下的仿真和系统框图，阅读时要同时核对图注中的参数。

## 1. 这是一份什么样的教程

这是一份讲麦克风阵列的教程。零基础可以从头读，读完还可以当手册查。文里配了 33 张图，先看图，再看公式。

教程从一个具体问题讲起：你站在 3 米外跟音箱说话，它怎样从噪声、混响和自身播放声中提取你的语音。全书依次讨论阵列几何、声源定位、定向拾音、回声与混响处理、重叠语音分离、移动声源追踪、系统评测和场景选型。

各章先建立直觉，再给出公式、符号、算例和适用边界。比较实验数字前，要先核对阵列几何、房间、数据集、实现和评测口径；条件不同的结果只能用于观察趋势。

## 2. 14 个文件一览

| 编号 | 文件                         | 配图                          | 难度 | 预计时间                       |
|----|----------------------------|-----------------------------|----|----------------------------|
| 00 | 00_overview.md（本页）         | 0 张专属图                      | 入门 | 15~20 分钟，先读本页              |
| 01 | 01_problem-definition.md   | 图1                          | 入门 | 10 分钟                      |
| 02 | 02_basics-signal-model.md  | 图2~图7，共 6 张                 | 进阶 | 45~60 分钟，建议完整读一遍           |
| 03 | 03_array-geometry.md       | 图8~图10，共 3 张                | 进阶 | 30 分钟                      |
| 04 | 04_doa-estimation.md       | 图11~图14、图33，共 5 张           | 较难 | 60~90 分钟，建议分两次读            |
| 05 | 05_beamforming.md          | 图15~图17，共 3 张               | 较难 | 60~90 分钟，跟着手算一遍            |
| 06 | 06_aec.md                  | 图18~20、图26~32，共 10 张，另引用图23 | 较难 | 60~80 分钟，建议分两次读            |
| 07 | 07_wpe-dereverberation.md  | 图21、图24，共 2 张               | 进阶 | 30~45 分钟                   |
| 08 | 08_speech-separation.md    | 0 张专属图，引用图23                | 进阶 | 30~45 分钟                   |
| 09 | 09_source-tracking.md      | 本章专属图22，另引用图23              | 进阶 | 30~40 分钟                   |
| 10 | 10_engineering-practice.md | 新图 1 张（图25），另引用图23          | 进阶 | 约 45~60 分钟                 |
| 11 | 11_selection-guide.md      | 0 张专属图                      | 入门 | 20~30 分钟；按任务、约束和场景条件形成候选方案 |

| 编号          | 文件                          | 配图     | 难度 | 预计时间              |
|-------------|-----------------------------|--------|----|-------------------|
| 附录 A（文件 12） | 12_appendix-symbols-math.md | 0 张专属图 | 查阅 | 通读约 25 分钟，也可以当词典查 |
| 附录 B（文件 13） | 13_appendix-guide.md        | 0 张专属图 | 查阅 | 通读约 40 分钟，也可以按需查  |

预计时间的算法：中文每分钟读 450 字，每张图多加 2~3 分钟，推导部分再加停留时间。按上表逐篇相加，全部精读约需 9~11 小时；练习和复现实验另计。按路径读见第 5 节。

时间有限时，可先读本页、01 和 11，明确问题与选型条件，再读 02 补齐信号模型。需要定位、波束、AEC、去混响或分离时，分别选读 04~08；工程实现配合第 10 章和附录 B 的排错部分，研究选题配合第 4、9 章和附录 B 的领域地图。

### 3. 各篇内容与学习目标

#### 01 · 问题定义与双耳启示

1 张图，入门。以智能音箱为例说明噪声、混响、干扰和麦克风自噪声，再区分定位、波束形成和追踪三项空间任务。阵列收益分三类度量：独立通道噪声看 WNG（白噪声增益），弥散场看 DI（指向性指数），定向干扰看零陷深度。三种指标的声场假设不同，不能直接互换。

人的听觉系统会利用双耳时间差、声级差和耳廓滤波线索。麦克风阵列也可利用通道间时延和幅相差，但需要显式的几何模型或实测阵列流形。细节见第 1 章。

学习目标：解释多麦克风相对单麦克风增加了哪些空间信息，复算理想白噪声模型下的阵列增益，并区分双耳线索与阵列观测。

#### 02 · 基础：声音到达阵列时发生了什么

6 张图，进阶。全书的符号和概念都在这章第一次出现。建议完整读一遍，后面看不懂时再回来查。

- 2.1 节讲时延：声音到达每个麦克风有先有后。采样率 16 kHz 时，一格是 62.5 微秒，约等于 2.1 厘米。时延估计要用到比采样间隔更细的插值，多路信号还必须用同一个时钟源。
- 2.2 节讲远场和近场：对中心对称孔径，常用相位曲率尺度是两倍孔径平方除以波长；其他几何要按参考点到最远阵元的距离推导。分界同时取决于孔径和频率。
- 2.3 节讲导向矢量：时域的移位变成频域的相位旋转。导向矢量就是每个方向对应的标准相位组合，后面定位和波束形成都要用它。
- 2.4 节讲房间混响：声音经反射形成拖尾， $T_{60}$  描述能量衰减 60 dB 所需时间，DRR（直达混响比）描述直达声与混响的相对能量。
- 2.5 节讲 STFT（短时傅里叶变换）：把波形分帧后得到复数时频表示，再由多通道快拍估计协方差矩阵。
- 2.6 节讲主瓣宽度、旁瓣、DI、WNG，还介绍分辨率尺度、栅瓣条件和 CRLB（克拉美 – 罗下界）。

本章结束时，读者应能从时延推到相位和导向矢量，解释协方差矩阵各元素的含义，并查清后续章节使用的基础符号。

#### 03 · 阵列几何形态

3 张图，进阶。讲麦克风怎么摆，以及摆法决定什么上限。

双麦只有一条物理基线，正横、端射和中间角度是相对该基线的连续工作方向。随后比较线阵、圆阵、方阵、球阵、螺旋阵和分布式阵列。

共线阵列无法分辨绕阵列轴的方位，继续在同一直线上增加麦克风也不能消除这种几何模糊。端射附近的时延对角度变化不敏感，同样的时延误差会对应更大的角度误差。

本章归纳四条设计规律：孔径和波长的比值影响分辨率；圆阵在水平面各方向都能利用孔径；挡板会改变阵列流形；增加麦数能改善白噪声增益和统计稳定性，但收益取决于几何、频段和噪声场。

稀疏阵只占用密集参考网格中的部分候选位置，再把麦对位置差组织成差分协同阵。例子中的 6 麦嵌套阵产生 23 个连续的有符号滞后；要把这些滞后用于 MUSIC，还需构造虚拟协方差并做空间平滑或等价重构。

读者可以据此说明阵列形态怎样限制可观测方向、孔径和无混叠频带，并按覆盖范围、同步条件和安装空间筛选几何方案。

#### 04 · 声源定位 DOA 估计

5 张图，较难。DOA 是波达方向（Direction of Arrival），也就是判断声音从哪来。本章算法种类多，建议分两次读。

本章把方法分为四类：两步法（互相关 + 几何解算）、扫描法、子空间法、稀疏重构与深度学习方法。

- GCC-PHAT（广义互相关相位变换）从相位随频率的变化估计时延，混响会拖宽或扰乱相关峰，时延估计还要做亚采样插值。图 13 用 16 kHz、64 ms 分析帧和 150 次固定种子试验构造随机衰减尾。它用于说明固定尾能量时  $T_{60}$  与 DRR 的联合作用，以及仿真参数口径可能改变趋势；该图不能当作“ $T_{60}$  越长性能越差”的单调证据，也不代表真实房间的通用正确率。
- SRP（可控响应功率）在每个候选位置累加各麦对的相关响应，再寻找最大值。算例里真点得分 6.0，偏 1.8 米的点 5.64，镜像点 2.08。粗到细两级搜索可减少需要评估的网格点；实际耗时取决于搜索范围、网格间距、麦对数、实现和硬件。
- 几何解算包括 Chan 算法和泰勒迭代。GDOP（精度稀释）描述几何摆位不好时误差怎样被放大。
- 扫描法包括 Bartlett 与 Capon（最小方差谱估计）。例子里二者的峰旁比分别为 1.8 和 5.0。

子空间法 MUSIC（多重信号分类）利用信号子空间与噪声子空间的正交关系寻找谱峰。相干信号会使源协方差秩下降，均匀线阵可在满足子阵条件时用空间平滑恢复可用秩。ESPRIT（旋转不变子空间法）利用阵列的平移结构直接解角度，不用逐格扫描。

DNN（深度神经网络）方法可用带方向标签的多通道数据学习定位特征，效果取决于训练数据是否覆盖测试阵列、房间、噪声和声源数。CRLB（克拉美 - 罗下界）用来分析指定观测模型下的方差下界；对已知波形的时延估计，有效带宽增大通常会增加 Fisher 信息，但具体幂次和系数取决于 SNR、频谱和参数定义。

完成本章后，读者应能按阵列几何、源数、混响和计算预算比较四类定位方法，并解释互相关峰受多径影响、MUSIC 在相干源下失效的原因。

#### 05 · 波束形成 Beamforming

3 张图，较难。波束形成对多通道信号加权求和，在保持目标方向响应的同时降低指定噪声场或干扰方向的输出功率。正文给出可复算的权重和响应例子。

三类噪声需要不同模型：麦克风自身噪声用 WNG 评价，延迟求和是解析基线；弥散场用 DI 评价，可比较超指向设计；定向干扰则检查零陷和 MVDR（最小方差无失真响应）的输出。

DSB（延迟求和波束形成）的权重是导向矢量除以麦克风数，理想独立白噪声下 WNG 等于麦克风数。超指向在低频提高 DI 时可能显著降低 WNG。两麦端射算例在指定间距和频率下得到约 -10 dB 的 WNG 与约 6 dB 的 DI；间距减半时，该算例的 WNG 再降低约 6 dB。

MVDR 分四步推导。算例中，噪声协方差所含的定向干扰信息使  $30^\circ$  处响应降至 -23.8 dB。LCMV（线性约束最小方差）加入多条约束，MWF（多通道维纳滤波）权衡降噪与失真。GSC（广义旁瓣对消器）分成固定波束、阻塞矩阵、自适应对消三路；在约束与实现一致时，它可表示 LCMV 解。

后置滤波调整时频增益，球谐方法用于球阵和球面声场表示。DNN 方法包括掩码估计、掩码结合 MVDR 和直接端到端映射。

本章要求读者能计算 WNG 与 DI，说明 MVDR 怎样利用协方差中的空间信息抑制定向干扰，并比较 GSC 与 LCMV 的约束表达。

#### 06 · 声学回声消除 AEC

10 张图（图 18~20、图 26~32，另引用图 23），较难。专讲回声消除这一件事，对照图 18、图 26~32 看收敛过程最直观。

AEC（声学回声消除）处理设备自己播放、又被自身麦克风收进来的声音。能预测回声波形时可估计后相减，这是本章区分减法处理与增益抑制的起点。

NLMS（归一化最小均方自适应滤波）给出基础更新式。PBFDAF（分块频域自适应滤波）、子带方法、IPNLMS 和 FDKF（频域卡尔曼滤波）用于降低长回声路径的计算量或改善收敛。扬声器非线性会限制线性 AEC，需根据失真来源增加非线性模型或神经网络。DTD（双讲检测）用于控制近端和远端同时活动时的自适应更新。

AEC 与其他模块的参考关系见 § 10.1 和图 23。评测要同时考虑远端单讲时的 ERLE、双讲稳定性、近端语音损伤和主观听测；ERLE 高并不能证明近端语音无损。WebRTC AEC3 可作为公开实现参考。

读者应能确定回声参考取点，解释 AEC 与波束顺序的条件，并为线性路径、非线性失真和双讲分别选择验证方法。

## 07 · 去混响 WPE

2 张图（图21、图24），进阶。讨论怎样利用跨帧预测估计并减弱晚期混响。

WPE（加权预测误差去混响）用历史帧预测晚期混响并相减，保护延迟用于避免直接预测当前直达声。正文算例在指定条件下展示混响能量变化；预测延迟和阶数要按帧长、混响与语音损伤验证。多人重叠语音在第 8 章讨论，模块启用条件和参考关系见 § 10.1。

本章给出保护延迟  $\Delta$  和预测阶数的选择依据，比较单通道与多通道 WPE，并说明 MINT、倒谱和谱方差方法各自依赖的假设。

## 08 · 语音分离

0 张专属图（引用全书链路总图23），进阶。讨论重叠语音的分离方法，以及时频掩码怎样连接分离、协方差估计和波束形成。

三条路线包括经典盲源分离（AuxIVA、ILRMA、MNMF、TRINICON）、GSS（引导源分离，用说话人活动标注处理输出排列）和深度分离（掩码估计、深度聚类、PIT、Conv-TasNet、状态空间模型及查询型分离）。§ 8.1 介绍方法，§ 8.2 与图 23 给出较完整前端的参考关系；实际顺序和模块启用条件以 § 10.1 为准。

读者应能按源数与麦克风数的关系区分 AuxIVA、ILRMA、MNMF 和 TRINICON 的模型条件，解释 GSS 使用活动信息的原因，并用分离掩码估计目标或干扰协方差。

## 09 · 声源追踪 Source Tracking

2 张图，进阶。讨论方向观测随目标运动、漏检和野点变化时，怎样估计连续轨迹。状态可以包括角度、角速度和角加速度。

声音观测有四类困难：

- 语音时断时续；
- 定位结果含有野点；
- 说话人数会变化；
- 角度观测与状态之间可能是非线性关系。

KF（卡尔曼滤波）由状态预测、观测更新和协方差递推组成，观测与预测的权重由噪声模型决定，不是固定比例。PF（粒子滤波）用带权粒子近似后验分布，并通过重采样缓解权重退化。

多人追踪还会用到 IMM（交互多模型）、PHD（概率假设密度）、LMB 和 TBD（检测前追踪）。§ 9.4 讨论定位与波束之间的反馈；更新限幅、静默保持和重置条件都应由目标运动与帧率确定。

完成本章后，读者应能说明追踪器在定位与波束之间传递什么状态，比较单目标与多目标方法，并设置方向更新、静默保持和重捕获条件。

## 10 · 工程实现、评测与产业实践

新图 1 张（图25），另引用图23，进阶。图 23 是参考依赖图，不表示每个项目都要启用全部模块。第 10 章按启用条件说明 AEC、WPE、定位、波束、NS 和后端的取点关系，并把延迟分为前瞻、缓冲、计算、调度和解码关键路径。

硬件部分区分数字样本格式、模拟动态范围、初始时差和 SRO（采样率偏移）。资源预算分别使用 MAC/s、MIPS、RTF、峰值内存和功耗，续航用 Wh 与整机平均功率计算。

评测部分说明 SI-SDR、STOI、PESQ/POLQA、WER/CER、OSPA 与主观听测各自回答什么问题。

本章结束时，读者应能编制延迟、同步和标定预算，选择与任务相符的评测指标，并列出版署时还需验证的资源与故障状态。

## 11 · 总结与选型指南

入门。11.1 从输出任务、覆盖区域、频带、干扰、目标运动和硬件边界六方面定义问题；11.2 给出不同模块的启用与替换条件；11.3 说明几何和算法怎样共同决定性能；11.4 用四类场景演示怎样从条件推导候选方案；11.5 把方案写成可验证规格；11.6 配有三道练习。

本章把任务和约束转成候选方案，给出 AEC、WPE 和分离的启用条件，并示范怎样把几何、WNG/DI 权衡和资源预算写成可测的验收规格。

## 12 · 附录 A：符号、术语、数学

查阅用。12.1 节是符号表。12.2 节是术语词典，按信号与数学基础、房间声学、自适应滤波与分离、波束形成与阵列度量、定位与追踪、系统与硬件分组。12.3 节介绍复数、分贝、卷积和相关、期望和协方差、最小二乘与特征分解。

遇到未定义符号、术语或数学步骤时，可按主题查阅，无需顺序通读。

## 13 · 附录 B：路径、地图、前沿、排错、练习、复现

查阅加动手。13.1 节是学习路径。13.2 节是教材、会议、期刊、挑战赛与历史地图。13.3 节介绍九个研究方向与泛化失配。13.4 节是排错指南，13.5 节是公式速查卡，13.6 节有 17 道练习题，13.7 节说明怎样复现 33 张图。

需要查学习资料、研究方向、排错方法、练习或复现步骤时，可直接进入对应小节。

---

## 4. 阅读顺序

1. 先读本页，再用约 10 分钟读第 1 章，建立问题意识。
2. 读第 2 章，补齐全书共用的信号模型。符号不懂时查附录 A。
3. 几何线从第 3 章开始，了解阵列形态怎样限制观测信息，再用 § 11.1 ~ § 11.3 形成候选几何。
4. 空间处理线依次关联第 4 章的定位、第 9 章的追踪和第 5 章的波束。第 2、5、8 章介绍的时频掩码可用于估计目标或噪声协方差，再交给 MVDR 或分离模块。
5. 干扰处理线包括第 6 章的回声消除、第 7 章的去混响和第 8 章的语音分离；启用条件和参考依赖见 § 10.1 与图 23。
6. 工程线用第 10 章核对链路、硬件、评测和芯片，再到第 11 章形成方案。

附录 A（文件 12）汇总符号、术语和数学。附录 B（文件 13）提供学习路径、领域地图、前沿、排错、练习和复现说明。

完成第 11 章后，工程读者可到 § 10.10 制定联调与验收计划，遇到问题查 § 13.4。研究读者可读 § 13.3，再做 § 13.6 的第 16、17 题，分别练习房间仿真和论文系统复核。两篇附录均可按需查阅。

---

## 5. 三条阅读路径

路径 A：零基础入门（能复现演示，约 2~3 周）

1. 先读本页和第 1 章，再读 § 11.1 ~ § 11.3，了解选型需要哪些输入条件。
2. 02 精读 60 分钟。推导可以先跳，重点是会读图 2~图 7。
3. 03 读表格 + 算例 30 分钟。04 读 4.2、4.3 节 + 算例 60 分钟，对照看图 12、图 14。05 读 5.1、5.2、5.4 节，跟着手算 60 分钟，对照看图 16。

4. 06 读 6.1.1、6.1.2、6.1.7（AEC 在阵列里放哪）、6.1.9 共 60 分钟，对照看图 18。07 读 7.1 节直觉部分和 7.1.1（ $\Delta$  与  $K$  的选择），对照看图 21、图 24。08 读 8.1 节三条路线和掩码用途 30 分钟。09 读 9.2 节卡尔曼滤波五步 30 分钟。
5. 阅读 § 10.1、§ 10.4 和 § 10.6，了解参考链路、资源口径与房间仿真。按需查附录 A，再做附录 B 的第 2、3、5、7、10、11、14 题，并用 § 13.4 检查常见问题。
6. 终点：重新生成并解释 33 张图，再在可用的多通道硬件上实现一个可测方向响应的基线系统。

路径 B：工程实现（形成可验证的前端方案，约 1 周精读）

1. 用 § 11.1~§ 11.5 写清任务、几何、场景、模块启用条件和验收指标。第 5 章重点读 MVDR、稳健化与后置滤波；第 6 章核对回声参考、双讲和与波束的顺序条件；第 7 章根据目标房间验证 WPE；第 8 章在确有重叠语音需求时选择分离方法。更换阵列前阅读 § 13.3 的泛化专栏。
2. 通读第 10 章，按关键路径核算延迟，区分多设备同步与 SRO，统一评测、算力和功耗口径。再查 § 13.4，完成 § 13.6 的第 7、8、9、11、14、15 题。
3. 终点：输出延迟、同步、标定三张预算表。对照 WebRTC AEC3 检查回声消除。用 ERLE 和 MOS 验收。

路径 C：研究复现与公开评测（长期）

1. 02 的 CRLB 给出指定观测模型和正则条件下无偏估计方差的下界。03 的稀疏阵列。04 的 4.6、4.7 节（空间平滑、宽带子空间方法、学习型定位、ACCCDOA 声事件定位表示）。05 的 RTF（相对传递函数）版 MVDR、球谐方法、掩码 + GEV（广义特征值波束形成）、端到端网络。
2. 06 的 FDKF、混合神经卡尔曼。07 的在线 WPE。08 的扩散模型、GSS 与掩码协方差估计。09 的 PHD、LMB、TBD。10 的指标口径（SI-SDR 和 BSS-eval 两套指标不能直接比数值）+ CHiME、LibriCSS、STARSS 数据集。
3. 用附录 B § 13.2 查领域资料，阅读 § 13.3 中与课题相关的方向和泛化专栏，再做 § 13.6 的第 6、8、12、13、16、17 题，分别覆盖定位分辨、稳健波束、分离、追踪、房间仿真和论文系统复核。阅读 CHiME-8 系统报告时，可把实际前端结构与图 23 对照。
4. 终点：在一个公开数据集上固定阵列、训练/测试划分和指标，分别实现一个解析基线与一个数据驱动基线，并记录模型版本、输入特征和推理资源。

6. 插图地图：33 张图在哪篇

| 图   | 文件                        | 所在文档 | 类型      | 内容                        |
|-----|---------------------------|------|---------|---------------------------|
| 图 1 | fig01_binaural            | 01   | 示意 + 曲线 | 双耳时间差和声级差，Rayleigh 双重理论   |
| 图 2 | fig02_dsin_geometry       | 02   | 示意      | 时延几何直角三角形                 |
| 图 3 | fig03_near_far_field      | 02   | 示意      | 球面波和平面波，远场判据              |
| 图 4 | fig04_delay_phase         | 02   | 示意 + 曲线 | 时延等于相位旋转，给互相关法铺垫          |
| 图 5 | fig05_room_acoustics      | 02   | 示意 + 曲线 | 房间脉冲响应三段、T60、直达临界距离、直达混响比 |
| 图 6 | fig06_stft_cov            | 02   | 仿真 + 矩阵 | 分帧语谱加协方差热图加特征谱            |
| 图 7 | fig07_beampattern_anatomy | 02   | 仿真教学    | 主瓣、旁瓣、零陷、主瓣宽度、栅瓣          |
| 图 8 | fig08_geometries          | 03   | 布局示意    | 线阵、圆阵、球阵、螺旋阵、分布式          |

| 图    | 文件                     | 所在文档     | 类型         | 内容                                                                                                                             |
|------|------------------------|----------|------------|--------------------------------------------------------------------------------------------------------------------------------|
| 图 9  | fig09_tradeoffs        | 03       | 公式计算, 分两幅看 | (a) 独立同方差白噪声下的理想 WNG 为 $10 \log_{10} M$ ; (b) 输入通道数 $M$ 、无序麦对数 $M(M-1)/2$ 和完整协方差元素数 $M^2$ , 不等于运行时间、功耗或价格                      |
| 图 10 | fig10_sparse_array     | 03       | 集合图解       | 所有有序麦对形成有符号差分位置; 图中 6 麦嵌套阵得到 23 个连续有符号滞后                                                                                       |
| 图 11 | fig11_doa_spectrum     | 04       | 仿真         | 指定高信噪比、充足快拍条件下的三种谱形; Capon 使用相对对角加载 $\eta = 10^{-6}$ ; 不检验分辨极限                                                                 |
| 图 12 | fig12_gcc_plot         | 04       | 示意 + 仿真    | 真值约 0.933 格; 固定噪声样例经 16 倍时延网格插值得 58.59375 $\mu\text{s}$ , 即 0.9375 格、约 $30.16^\circ$                                           |
| 图 13 | fig13_gcc_reverb       | 04       | 参数口径反例     | 在 16 kHz、64 ms 分析帧、无传感器噪声的随机衰减尾模型中, 每点 150 次固定种子试验; 正确率带 95% Wilson 区间, 峰对比度带四分位区间; 用于检查固定尾能量时 $T_{60}$ 与 DRR 的联合作用, 不支持单调退化结论 |
| 图 14 | fig14_srp_grid         | 04       | 仿真 + 几何    | 麦对相关响应的网格累加与双曲线交汇                                                                                                              |
| 图 15 | fig15_wng_di           | 05       | 指定模型仿真     | 半径 4 cm 的 6 元圆阵; 超指向使用相对对角加载 $10^{-6}$ , 两种方法均保持目标方向单位响应                                                                       |
| 图 16 | fig16_beampattern      | 05       | 指定模型仿真     | 三条曲线保持目标方向单位响应; DSB/MVDR 用 $d = \lambda/2$ , 超指向用 $d = 0.2\lambda$ , MVDR 干扰方向为 $20^\circ$                                     |
| 图 17 | fig17_gsc              | 05       | 系统框图       | 固定波束、阻塞矩阵、对消器三路                                                                                                                |
| 图 18 | fig18_aec              | 06       | 框图 + 本书仿真  | 固定随机种子样例在 $0.45 < t < 0.8 \text{ s}$ 窗口的 NLMS ERLE 均值约 29.23 dB (图中取整约 29 dB); 双讲区间冻结更新                                        |
| 图 19 | fig19_aec_landscape    | 06       | 仿真 + 方法分类  | (a) 指定未建模非线性条件下的线性 AEC 性能平台; (b) 按模型假设和处理对象区分四类方法, 横向位置不表示年代或性能排名                                                              |
| 图 20 | fig20_aec_pipeline     | 06       | 系统框图       | 经典链路与线性、神经网络混合链路对比                                                                                                             |
| 图 21 | fig21_wpe              | 07       | 仿真         | 共用谱幅参考值比较干净、混响和 WPE 输出; 统计量按 10 ms 直达延迟对齐干净参考, 再报告静音帧能量占比与活跃帧复增益对齐谱域 NMSE                                                      |
| 图 22 | fig22_tracking         | 09       | 仿真         | 单目标粒子滤波轨迹与两目标 PHD 强度示意                                                                                                         |
| 图 23 | fig23_pipeline         | 08、09、10 | 系统框图       | 较完整前端的参考依赖关系与方向反馈 (08、09 只引用)                                                                                                  |
| 图 24 | fig24_wpe_frames       | 07       | 示意         | WPE 帧结构: 只用过去历史预测当前帧, 保护延迟 $\Delta$ 的作用                                                                                        |
| 图 25 | fig25_latency_budget   | 10       | 瀑布条        | 一组旧设计的延迟拆分示意; 实际预算按 § 10.1 的关键路径重新测量                                                                                           |
| 图 26 | fig26_aec_problem      | 06       | 示意         | 回声怎么形成: 房间冲激响应、卷积拖尾、麦克风三者相加                                                                                                    |
| 图 27 | fig27_aec_concept      | 06       | 示意         | 估计回声路径并相减, DTD 控制自适应更新                                                                                                         |
| 图 28 | fig28_aec_nlms         | 06       | 仿真         | NLMS 自适应过程: 滤波器长成回声路径, 步长取舍                                                                                                    |
| 图 29 | fig29_aec_early_freeze | 06       | 仿真         | 收敛与冻结: 平时爬升, 双讲段定义失效必须冻结                                                                                                       |

| 图    | 文件                      | 所在文档 | 类型      | 内容                                  |
|------|-------------------------|------|---------|-------------------------------------|
| 图 30 | fig30_aec_delay_dtd     | 06   | 仿真      | 延迟对齐与双讲：不对齐掉几十分贝，对齐是第一要务            |
| 图 31 | fig31_aec_nonlinear     | 06   | 仿真      | 指定仿真条件下线性路径与 tanh 非线性路径的性能平台        |
| 图 32 | fig32_aec_hybrid_select | 06   | 框图 + 示意 | 线性与神经网络混合处理及条件化选型                   |
| 图 33 | fig33_gcc_two_paths     | 04   | 对照      | 时域滑动相加等于频域共轭相加 IFFT，两条路算出同一条曲线、同一个峰 |

示意图用于解释几何关系，曲线展示指定条件下的可复现结果，框图说明模块之间的信号与控制关系。

## 7. 十处跨文档联系

1. 定位连着追踪连着波束：04 找方向，09 跟轨迹，05 指波束，见 9.4 节和图 23。
2. 前端模块的参考依赖与启用条件见 § 10.1 和图 23。
3. 导向矢量：02 的 2.3 节定义，04、05、08、09 都要用。
4. 协方差矩阵：02 的 2.5 节定义，04、05、06 都要用。对角加载可改善条件数，但不能代替足够的独立观测。
5. WNG 和 DI 的权衡：02 的 2.6 节提出，05 详细计算，11 用于条件化选型。
6. 混响这条线：02 的 2.4 节讲混响是什么，04、05、06、07 讲各自怎么对付它。
7. 掩码估计：02 讲语音稀疏性，05 和 08 用掩码估计目标或噪声协方差，并把它们交给波束形成或导引分离。
8. 减法和乘法：06 的 6.1 节讲能预测波形就做减法，05 的 5.7 节讲只能估计幅度就做乘法。
9. 几何上限：03 讲摆位定的上限，04、09、10 都要回来看它。
10. 标定和同步：10 的 10.2 节讲标定同步，13 的附录 B 13.4 节讲排错时怎么查它。

## 8. 动手复现

`codes/` 先提供与公式相对应的小规模教学基线，`scripts/` 再生成书中的图。前者适合逐步检查时延、矩阵形状、约束残差和边界输入；后者适合复现正文的完整示意或仿真条件。算法覆盖状态见 `codes/COVERAGE.md`，第三方官方实现、固定提交和许可证边界见 `codes/THIRD_PARTY.md`。

在仓库根目录先运行三组章节例子：

```
.venv/bin/python codes/examples/ch02_05_baselines.py
.venv/bin/python codes/examples/ch06_09_baselines.py
.venv/bin/python codes/examples/ch10_engineering_baselines.py
.venv/bin/python -m unittest discover -s tests -p 'test_codes*.py' -v
```

再运行第 13.7 节列出的绘图命令，可重新生成 33 张图；运行时间取决于机器。具体构建步骤和错误处理见 `scripts/README.md`。Windows 上需把命令中的 `.venv/bin/python` 换成 `.venv\Scripts\python`。

这些 NumPy/标准库程序用于复算，不是产品实时前端。大型训练框架、WebRTC 和设备链路采用固定来源索引，默认不复制进仓库；代码、模型、数据和示例录音的许可证要分别核对。

## 9. 常见问题

---

### 图片看不到怎么办？

请保留仓库目录结构并从仓库中打开文档；图片使用相对路径，单独复制 Markdown 文件会使链接失效。

### 先读哪篇？

先读本页，再读 01 和 11，再读 02。之后按第 5 节的路径走。赶时间只读 11 也能得到选型结论。

### 公式看不懂怎么办？

先查第 2 章和附录 A 中的符号、术语与数学基础，再结合图 7、图 11、图 15、图 16 阅读第 4、5、7、8 章的推导。

### 想跑实验怎么办？

先按第 8 节运行章节教学基线，确认公式约定和边界输入，再重绘 33 张图。之后可按锁定版本用 pyroomacoustics 建立房间仿真基线。公开数据、模型和硬件实验应根据任务、许可证与设备条件选择，练习入口见附录 B 的 § 13.1、§ 13.6。

### 不同实验的绝对数值能比吗？

不能。阵列几何、房间、信噪比、数据集、实现和评测口径不同，绝对数值不能直接横向比较。先确认条件一致，再比较趋势和量级。

---

## 附录：下一步清单

---

- [ ] 15 分钟读完本页，选一条第 5 节的路径。
- [ ] 阅读第 1 章和第 11 章，分别明确问题定义与选型条件。
- [ ] 60 分钟读 02，学会读图 7（主瓣、旁瓣、零陷、主瓣宽度、栅瓣）。
- [ ] 按第 2 节的时间表读 04~08：04、05 各 60~90 分钟，06 约 60~80 分钟，07、08 各 30~45 分钟。
- [ ] 对照第 8 节画一遍 33 张图，打开 `figures/` 对照正文看图。
- [ ] 运行 `codes/examples/` 的三组基线，并从 `codes/COVERAGE.md` 选一个原理索引项目核对其官方实现边界。
- [ ] 做附录 B 的练习题（入门做 2、3、5、7、10、11、14 题，进阶再做 6、8、12、13、16、17 题）。
- [ ] 用附录 B § 13.4 排查常见问题，并按第 10 章编制延迟、同步和标定预算。
- 阵列几何决定可观测的空间信息，算法在给定数据和模型下利用这些信息。
- 房间混响是远场拾音的主要困难之一。
- 比较波束形成器时，应同时说明目标保持、干扰抑制和失配鲁棒性。

第 1 章 · 问题定义与双耳启示

本章从客厅里的远场语音交互出发，依次说明空间处理的三项任务、阵列增益的不同度量，以及双耳听觉为机器阵列提供的线索。

客厅里那句“今天天气怎么样”

想象你坐在客厅里，对 3 米外的智能音箱说“今天天气怎么样”。音箱要听清这句话，需要处理四类干扰：

- 1. 环境噪声：空调声、车声；
- 2. 房间混响：声音经墙壁、桌面、天花板反射形成“拖尾”，把音节糊在一起；
- 3. 干扰说话人：旁边有人在看电视或说话；
- 4. 麦克风自噪声：传感器自身的底噪，包括热噪声和电路噪声。普通环境里，它往往低于环境噪声；超指向波束形成依赖通道间的精确相消，可能显著放大大噪声，因此自噪声会限制阵列性能（见 § 2.6 的白噪声增益（White Noise Gain，WNG）和 § 5.3）。

人的听觉系统会合并双耳线索来定位和选择性聆听。机器可以用一组麦克风观测类似的空间差异：每个麦克风处于不同位置，同一声音到达它们的时间、强度略有不同。这些差异包含方向信息，也使系统能够优先保留某个方向的声音。

这些干扰的结构不同，不能用同一个“降噪增益”概括。先区分阵列空间处理承担的任务，再分别定义收益。

空间处理的三项任务

下面三项是阵列空间处理的核心任务：

| 任务   | 类比              | 回答的问题          |
|------|-----------------|----------------|
| 声源定位 | 你闭着眼判断声音从哪来     | “声音在哪个方向？”     |
| 波束形成 | 你扭头把耳朵和注意力转向说话人 | “怎么只听这个方向？”    |
| 声源追踪 | 你跟着走动的说话人持续转头   | “他动了，怎么一直盯着听？” |

它们没有覆盖开头的全部问题。设备自己的回声由声学回声消除（Acoustic Echo Cancellation，AEC）处理，房间拖尾由去混响处理，多人同时说话还需要语音分离；这些任务分别在第 6~8 章展开。

定位、波束形成和追踪回答的问题不同，对应的评价指标也不同。下面先计算最基础的白噪声阵列增益。

三类阵列收益

麦克风阵列最容易算清的一项理论收益，是对白噪声的阵列增益： $M$  元延迟求和阵列在理想条件下可得到  $10 \log_{10} M$  dB。功率 2 倍约为 3 dB，10 倍为 10 dB；4 麦约为 6 dB，8 麦约为 9 dB。

这个结果要求各通道噪声互不相关、目标可按远场平面波对齐，而且各麦克风的增益和相位一致。[Kumatani – McDonough – Raj 《Microphone Array Processing for Distant Speech Recognition》CMU 课程讲义，2012](#)

定向干扰、弥散混响和模型失配不能直接并入这一个数字。它们要分别检查零陷、DI 与稳健性，具体收益随场景变化。

三类声场对应三种不同收益：

- 对独立、等功率通道噪声，用 WNG 评价。延迟求和阵列在理想无失真归一化下达到  $10 \log_{10} M$ 。
- 对四面八方到来的弥散场，例如晚期混响，用指向性指数（Directivity Index，DI）评价。超指向设计可获得高于同麦数延迟求和阵列的 DI，但通常会牺牲 WNG（§ 5.3）。
- 对单个定向干扰，检查零陷深度。§ 5.4 的算例给出一个 -24 dB 零陷。

WNG、DI 和零陷深度的声场假设不同，不能用其中一个指标替代另外两个。

白噪声增益的推导（各麦噪声相互独立）：

1. 信号侧：各麦收到的是“同一个声音错开一点时间”，对齐后同相相加——幅度变成  $M$  倍，所以功率变成  $M^2$  倍（功率正比于幅度的平方）；
2. 噪声侧：各麦的噪声互相独立（不相关），相加时不会同相叠加而是“随机抵消一部分”——功率只变成  $M$  倍（独立随机变量的和的方差 = 方差的和）；
3. 相除：信噪比提升  $= M^2/M = M$ ，换成分贝就是  $10 \log_{10} M$ 。

以 4 只麦为例：信号幅度变为 4 倍，功率变为 16 倍；独立噪声的总功率变为 4 倍。因此信噪比提高 4 倍，约为 6 dB。满足上述条件时，麦数翻倍可增加约 3 dB。

对白噪声而言，信号同相相加，独立噪声只按功率相加。这给出延迟求和的 WNG 上限；它不是 DI、零陷深度或所有阵列算法的共同上限。

这个结果只依赖相干信号与独立噪声的叠加规律。真实系统还可利用双耳听觉中类似的时差、声级差和方向相关频谱线索。


## 1.1 双耳听觉的三类定位线索

---

从阵列模型看，双耳可以近似为带有头部散射的双传感器系统。人类主要利用三组线索判断声源方向，并在嘈杂环境中进行选择性地聆听：


图1 人类双耳定位线索：几何 ITD 与双重理论的适用边界

(a) 头 + 双耳 = 天然的 2 麦阵列（带挡板）




头影：远侧耳被头遮挡  
路程差 → 双耳时间差 ITD  
遮挡 → 双耳声级差 ILD

(b) 双耳时间差 ITD (Woodworth 模型)



(c) 双重理论的线索主导区 (理论示意, 不是人体响应曲线)



1. ITD (双耳时间差)：声音先到近耳、后到远耳，正侧面时两耳的时间差最大，量级约为数百微秒；按头部半径 8.75 cm、声速 343 m/s 的 Woodworth 刚性球模型计算，正侧面约为 656  $\mu$ s，即约 0.66 ms (图1(b))。

图中“正前方偏 1° 约对应 9  $\mu$ s”只是该几何模型的换算，不是普适的听觉阈值。实际可辨阈值随频率、声级、刺激类型和实验任务变化。Woodworth 模型是高频射线近似，低频窄带声还需考虑绕射模型。[Aaronsen 与 Hartmann 对 Woodworth 模型假设及适用范围的检验, JASA 2014](#)。频率升高后，相位会绕圈，听觉神经的波形锁相也逐渐减弱，因此纯相位 ITD 会出现歧义。

2. ILD（双耳声级差，Interaural Level Difference）：头颅遮挡使远耳听到的高频通常更弱，低频绕射则会减小两耳声级差。
- 瑞利双重理论（duplex theory）把低频细结构 ITD 和 高频 ILD 视为主要线索，但它不是互不重叠的硬分界。[Brughera、Dunai 与 Hartmann 的纯音实验](#)显示，细结构 ITD 的高频可辨上限因人而异，并在略高于 1.4 kHz 后消失；低频仍可能存在 ILD。[Bernstein 与 Trahiotis 的高频调制刺激实验](#)则说明，高频载波的包络 ITD 仍可影响侧向感知，不能与纯音相位 ITD 混为一谈。
- 图1(c)据此只画理论线索区和约 1.4 kHz 的非硬性边界，不画未经测量支持的人体 ILD 数值曲线。机器阵列也不能照搬这一频段划分：当均匀阵间距不满足半波长安全条件时，高频窄带相位会产生空间混叠，但非均匀几何、实测阵列流形和宽带融合仍可利用高频信息（§ 2.6、§ 3.2）。
3. HRTF（头相关传递函数，Head-Related Transfer Function）：耳廓的褶皱，加上头和肩膀的散射，对不同方向、尤其是不同俯仰角的声音产生不同的滤波（谱峰/谱谷位置变化）。
- 这种方向相关谱形是人类判断俯仰和减少前后混淆的重要线索之一。判断还会联合双耳时差、双耳声级差、头部运动和既有听觉经验，不能把 HRTF 写成唯一依据。经典综述可参见 [Middlebrooks 与 Green 1991](#)。

这些听觉线索在机器阵列中都有对应的观测量或处理方法。

双耳线索与阵列方法的对应关系

下表列出双耳听觉现象与阵列处理方法之间的联系：

| 人类的办法           | 机器阵列的对应技术（术语先不用记）                                                   | 章节           |
|-----------------|---------------------------------------------------------------------|--------------|
| ITD 双耳时间差       | GCC-PHAT 测 TDOA（§ 4.2）                                              | § 4          |
| 头颅当挡板           | 挡板效应放大麦间相位差（§ 3.2）                                                  | § 3          |
| ILD 与 HRTF 谱线索  | 测量每个方向的“标准答案”（导向矢量；全体方向的集合叫阵列流形，标定见 § 3.4、§ 10.2）、DNN 学习方向特征（§ 4.7） | § 3、§ 4、§ 10 |
| 优先效应（先到声主导方位感）  | 提醒算法区分直达声、早期反射与晚期混响；WPE 主要预测晚期混响，机制与听觉优先效应不同                        | § 2.4、§ 7.1  |
| 鸡尾酒会效应（多人里挑一个听） | 波束形成 + 语音分离                                                         | § 5、§ 8.1    |

人类用两只耳朵、头部与耳廓产生 ITD、ILD 和 HRTF，再由神经系统融合这些线索。硬件形态先提供可观测信息，后端算法再利用信息；机器阵列也是同一分工。

解析模型负责约束和可解释边界，数据驱动方法可补足难以精确建模的细节。

第 2 章将从传播时延出发，把这些空间差异写成阵列信号模型。

---

## 第 2 章 · 声音到达阵列时发生了什么

### 2.1 核心事实：同一声音，到达各麦克风有先有后

本书取声速  $c \approx 343 \text{ m/s}$ ，这是约  $20^\circ \text{ C}$  干空气中的常用近似；温度、湿度和气体成分改变时，声速也会改变。[Cramer 1993](#) 给出湿空气声速计算式及适用范围，[JASA 93\(5\)](#)。

两个相距  $4 \text{ cm}$  的麦克风，当声音沿两麦连线的方向传来时，先到近麦、后到远麦，时差幅值最大，约为  $0.04/343 \approx 0.116 \text{ ms}$ 。当声音垂直于连线传来时，两麦同时收到，时差为零。这个到达时间差称为到达时间差（Time Difference of Arrival, TDOA）。

坐标、方向和时差约定。把麦 1 放在  $x = 0$ ，麦 2 放在  $x = d > 0$ ；正横方向为  $\theta = 0^\circ$ ，正角朝  $+x$ 、即麦 2 一侧。单位向量  $\vec{u}(\theta)$  从阵列指向声源，声波实际传播方向为  $-\vec{u}$ 。到达时刻之差统一定义为  $\tau_{ij} = t_i - t_j$ 。因此正角时波前先到麦 2，有  $t_2 < t_1$ ，即  $\tau_{21} < 0$ 、 $\tau_{12} > 0$ 。

平面波下，麦 1 与麦 2 的路程差幅值为  $d \sin \theta$ （图2），所以带符号的麦对时差为

$$\tau_{12} = t_1 - t_2 = \frac{d \sin \theta}{c}, \quad \tau_{21} = -\frac{d \sin \theta}{c}。$$

其中  $d$  为两麦间距（m）， $\theta$  为声源方向角， $c$  为声速。只讨论大小时可写  $|\tau_{12}| = d |\sin \theta| / c$ ；不能把无符号“时差”直接代入需要方向的公式。

全书角度约定（后文凡涉角度一律沿用）： $\theta$  从正横方向（broadside，垂直于两麦连线的方向）起算。正横  $\theta = 0^\circ$  时两麦同时收到波前，时差为零；端射方向（endfire，沿两麦连线） $\theta = \pm 90^\circ$  时路程差幅值为  $d$ 、时差幅值最大。有些文献从阵列轴起算，此时关系写成  $\Delta \tau = d \cos \theta / c$ 。比较公式前应先统一角度零点和正方向；两种起算方式相差  $90^\circ$ 。

图2 时延的几何来源与角度约定（示意）




图 2 中麦 1 位于左侧、麦 2 位于右侧。正角声源位于麦 2 一侧，波前先到麦 2；直角三角形给出  $\tau_{12} = d \sin \theta / c > 0$ 。正横时差为零，端射时差幅值达到最大。

离散化。16 kHz 采样率下，采样间隔为  $1/16000 = 62.5 \mu\text{s}$ ，对应约  $343 \times 62.5 \mu\text{s} \approx 2.1 \text{ cm}$  的传播距离。4 cm 阵列的最大时差约为  $117 \mu\text{s}$ ，不到两个采样间隔。仅按整数采样点定位会得到很粗的方向，因此实际系统需要亚采样 TDOA 估计，例如对互相关峰插值、对相关函数上采样，或在频域拟合相位斜率（见 § 4.2）。

同步。多路信号必须同步采样。同一设备可让多通道模数转换器（ADC，Analog-to-Digital Converter）共享时钟；分布式设备则有独立晶振。相对偏移为 50 ppm 时，1 小时累积约  $50 \times 10^{-6} \times 3600 = 0.18 \text{ 秒}$ ，远大于阵列所测的微秒级时差，因此需要时钟同步或采样率偏移补偿（§ 10.2）。

声速失配会直接变成角度偏差。示意地，若真实声速为 331 m/s、真实方向为  $60^\circ$ ，系统却按 343 m/s 反算，则  $\hat{\theta} = \arcsin[(343/331) \sin 60^\circ] \approx 63.8^\circ$ ，偏差约  $3.8^\circ$ 。这不是“331 m/s 对应某一固定气温”的断言，只用于隔离声速参数失配；实际系统应按工作环境估计或校准  $c$ 。

上式是 § 2.3 远场向量模型的几何基础；式(2-1)将在那里给出。声源接近阵列时，波前曲率不能忽略，需要先区分近场与远场。

## 2.2 近场与远场

- 近场（声源很近）：波前（波阵面，即相位相同的面）是球面，各麦克风信号的时间和幅度都有差别；
- 远场（声源距离远大于阵列尺寸）：波前近似平面，各麦克风收到的是“同一个信号错开一些时间”，幅度几乎相同。

Fraunhofer 距离  $r_F = 2D^2/\lambda$ （ $D$  为阵列最大孔径、 $\lambda$  为波长）是常用的相位曲率尺度。这个等式针对以阵列中心对称的孔径：点声源位于中心法线上，最远阵元到中心的距离为半孔径  $a = D/2$ ，并以中心到该阵元的路程差不超过  $\lambda/16$  为容限。

非中心对称阵列应直接使用从选定参考点到最远阵元的距离  $a$ ，得到  $r_F = 8a^2/\lambda$ 。对其他方位，这个尺度只能作为起始检查，而不是精确边界。该  $\lambda/16$  口径及几何推导也见 ETSI ETR 273-1-1 条款 7.2.3.1 (p.76)。

当  $r$  大于该尺度，且同时满足下面展开所需的  $r \gg a$  时，可以把球面波的相位近似为平面波。对实际拾音距离，还应检查阵列到声源的距离比、各阵元的幅度差，以及最高使用频率。

例如，7 cm 中心对称阵列在 1 kHz ( $\lambda = 0.343 \text{ m}$ ) 时的公式值是  $2 \times 0.07^2/0.343 \approx 2.9 \text{ cm}$ ，但 2.9 cm 并不满足  $r \gg D$ ，不能据此宣称从 3 cm 开始整个房间都是远场。作为对照，1.26 m 的中心对称线阵在 1 kHz 下有  $r_F \approx 9.3 \text{ m}$ ，普通会议室内应核对球面波模型。

Fraunhofer 判据的推导：

1. 球面波到达阵列中心与到达最远阵元的路程不一样。把中心到最远阵元的距离记作  $a$ ；中心对称阵列有  $a = D/2$ 。由勾股定理，额外路程是  $\sqrt{r^2 + a^2} - r$ 。
2.  $r \gg a$  时用近似  $\sqrt{1+x} \approx 1 + x/2$  展开： $\sqrt{r^2 + a^2} - r \approx \frac{a^2}{2r}$ 。
3. 工程约定：只要这个“球面弯曲造成的误差”小于约十六分之一波长 ( $\lambda/16$ ，相位误差约  $22.5^\circ$ ，平面波假设就足够准)，就算远场： $\frac{a^2}{2r} \leq \frac{\lambda}{16} \Rightarrow r \geq \frac{8a^2}{\lambda}$ 。只有在  $a = D/2$  时，这才化为  $r \geq \frac{2D^2}{\lambda}$ 。

泰勒展开的中间步：先提出  $r^2$ ： $\sqrt{r^2 + a^2} - r = r \left[ \sqrt{1 + x} - 1 \right]$ ，其中  $x = (a/r)^2$ 。当  $x \ll 1$  时， $\sqrt{1+x} \approx 1 + x/2$ ，因此路程差近似为  $r \cdot x/2 = a^2/(2r)$ 。中心对称孔径代入  $a = D/2$  后才得到  $D^2/(8r)$ 。

所以 Fraunhofer 距离不是物理突变点，而是“相位误差还能忍”的约定线。

为何选  $\lambda/16$  ( $22.5^\circ$ ) 作为示例容限：路程误差  $\Delta$  对应相位误差  $2\pi\Delta/\lambda$ ；当  $\Delta = \lambda/16$  时，相位误差为  $22.5^\circ$ 。若只看两路等幅信号、其中一路存在这项相位误差，归一化相干和的幅度为  $|1 + e^{j\pi/8}|/2 = \cos(\pi/16) \approx 0.981$ ，即约 -0.17 dB。 $\lambda/16$  是本节为了说明数量级采用的工程容限，不是普适常数；要求更深零陷或更小相位误差时，所需距离会更大。

图3 近场与远场声场模型




图3 对比两种波前：近场采用球面波模型，各通道同时存在传播时延和幅度差；远场近似为平面波，传播模型主要由方向决定。这是下一节远场向量模型的前提。

确定远场条件后，可以把麦克风之间的传播时延写成导向矢量。

## 2.3 信号模型：把“声音有先有后”写成数学

符号约定（全书通用）：标量用普通斜体，如  $s$ 、 $\tau$ 、 $\theta$ 、 $\sigma^2$ ；向量用头顶箭头，如  $\vec{x}$ 、 $\vec{a}$ 、 $\vec{w}$ （默认列向量，零向量记  $\vec{0}$ ）；矩阵用加粗大写，如  $\mathbf{R}$ 、 $\mathbf{C}$ 、 $\mathbf{\Gamma}$ 、 $\mathbf{E}_n$ 。

再认几枚上标： $H$  是共轭转置（频域复数用）、 $\top$  是转置（时域实数用）、 $*$  是共轭、 $^{-1}$  是逆； $\hat{\cdot}$  表示估计值， $\|\cdot\|$  为范数、 $|\cdot|$  为幅度。

标量上标星号 vs 向量上标 H：单个复数取共轭用上标星号（如  $X_2^*$ ），整列向量转置再共轭用上标 H（如  $\vec{x}^H$ ）——后文凡见上标 H 都是向量/矩阵操作，凡见上标星号都是标量操作，对上号就不会认错。

大写谱值仍可为标量：语音文献习惯用  $X(f)$ 、 $X(f_k, \ell)$  这类大写字母表示某一物理频率或时频点上的复数谱值。它们是标量，不是矩阵；本书沿用这一惯例，并在首次出现处注明。

字母复用：受文献惯例所限， $k$  可表示频点索引、波数或 WPE 的滞后帧号； $D$  可表示阵列孔径或 PHD 强度函数； $\lambda$  可表示波长、WPE 功率谱或矩阵特征值； $K$  可表示声源数或 WPE 预测阶数； $s$  可表示源信号或追踪状态。每个符号以所在公式的定义为准。

频率与帧索引：本章的连续频率统一记作  $f$ ，单位 Hz；DFT/STFT 的频点索引记作  $k$ ，其物理频率为  $f_k = kf_s/N$ ；帧索引记作  $\ell$ 。文献中常见的  $\vec{x}(f, t)$  是简写，本书需要区分离散网格时写成  $\vec{x}(f_k, \ell)$ 。复指数  $e^{-j2\pi f\tau}$  中必须代入 Hz 频率  $f$  或  $f_k$ ，不能直接代入无量纲索引  $k$ 。

本节只做一件事：把 §2.1 那句“同一声音到达各麦有先有后”一步步写成可以计算的式子。分三步走，每一步都交代“为什么”。

第一步：时域模型——每个麦克风一个式子

远场、单声源时，先把各麦相对麦 1 的到达时延定义为  $\tau_{m1} = t_m - t_1$ 。由 § 2.1 的方向约定，

$$\tau_{m1} = -\frac{(\vec{r}_m - \vec{r}_1)^\top \vec{u}}{c}。$$

正角 ULA 上  $\vec{r}_m - \vec{r}_1$  的  $x$  分量为正，所以  $m > 1$  时  $\tau_{m1} < 0$ ：右侧麦更早收到。把麦 1 的到达时刻作为时间原点，第  $m$  个麦克风 ( $m = 1, 2, \dots, M$ ) 录到的信号为

$$x_m(t) = s(t - \tau_{m1}) + n_m(t)。$$

- $x_m(t)$ ：第  $m$  路录音波形——这是你实际拿到的数据；下标  $m$  表示“第几个麦克风”， $t$  是时间；
- $s(t)$ ：声源发出的原始信号——你想恢复的东西；注意它不带下标  $m$ ，因为远场平面波假设下各麦收到的是同一个  $s(t)$ ，只是时间有先后；
- $\tau_{m1}$ ：第  $m$  个麦相对麦 1 的带符号到达时延（秒），它由声源方向决定，可为负数；
- $n_m(t)$ ：第  $m$  路的噪声。

时移位于  $s(t - \tau_{m1})$  的自变量中。变换到频域后，它会成为可直接相乘的复相位因子。

第二步：搬到频率域——延迟从“移位”变成“转个角度”

本书采用前向傅里叶变换  $X(f) = \int x(t)e^{-j2\pi ft} dt$ 。在此约定下，时移性质为


$$s(t - \tau) \xrightarrow{\mathcal{F}} S(f)e^{-j2\pi f\tau}$$

箭头上的  $\mathcal{F}$  表示傅里叶变换。


左边表示时域延迟  $\tau$  秒，右边表示频域中乘以复相位因子。频域形式便于把宽带信号分频点处理，也便于将卷积近似为乘法，因此许多阵列算法采用 STFT 实现；这种近似的边界见 § 2.5。

这个  $e^{-j2\pi f\tau}$  到底是什么？它是复平面上一个长度为 1 的箭头，从正实轴出发顺时针转过角度  $2\pi f\tau$ （图 4(b)）。其中  $j$  是虚数单位 ( $j^2 = -1$ )； $e$  的复指数由欧拉公式定义： $e^{j\phi} = \cos \phi + j \sin \phi$ ；有些书把  $2\pi f$  写成  $\omega$ （角频率），两者是一回事。直觉检验：延迟恰好等于一个周期 ( $\tau = 1/f$ ) 时转过整整一圈  $2\pi$ ——波形平移一个周期后与原波形重合，箭头也转回原地，两边对上了  $\checkmark$ 。

图4 时延为什么变成  $e^{-j2\pi f\tau}$ ：几何直觉  
(4 cm 麦距；端射方向达到最大麦间时延  $\tau=d/c\approx 0.117$  ms)  
(a) 时域看延迟：整条波形向右平移



(b) 频域看延迟：复数相位转过一个角度  
延迟  $\tau$  等价于复平面上  
顺时针转  $2\pi f\tau$



(c) 同一延迟在不同频率：相位-频率是直线




图 4 的三幅子图采用同一组参数：4 cm 麦距、声速 343 m/s、端射方向，因此  $\tau = d/c \approx 0.1166$  ms。时域波形右移约 0.117 ms；1 kHz 复相量顺时针旋转约  $2\pi \times 1000 \times 0.1166$  ms  $\approx 42^\circ$ ；相位-频率图的斜率为  $-2\pi\tau$ ，2 kHz 处约为  $-84^\circ$ 。§ 4.2 的 GCC-PHAT 正是利用这项关系估计时延。

图 4 (c) 还说明，同一时延引起的相位旋转与频率成正比。相位展开后，直线斜率为  $-2\pi\tau$ ；实际数据中的相位缠绕、噪声和混响会使估计更复杂。

第三步：把  $M$  个式子擦起来，写成向量

对第  $m$  路、物理频率  $f$ ，时移性质给出：

$$X_m(f) = e^{-j2\pi f\tau_{m1}(\theta)} S(f) + N_m(f)。$$

- $X_m(f)$ 、 $S(f)$ 、 $N_m(f)$ ：第  $m$  路/声源在物理频率  $f$  处的复数谱值——都是标量（单个复数）；
- $e^{-j2\pi f\tau_{m1}(\theta)}$ ：相对时延造成的相位旋转因子，也是标量。

把  $M$  路的式子竖着擦起来。相对时延满足  $\tau_{m1} = -(\vec{r}_m - \vec{r}_1)^\top \vec{u}/c$ ，所以第  $m$  个导向分量也可写为

$$a_m(f, \theta) = e^{-j2\pi f\tau_{m1}} = e^{+j2\pi f(\vec{r}_m - \vec{r}_1)^\top \vec{u}/c}。$$

于是

$$\underbrace{\begin{bmatrix} X_1(f) \\ X_2(f) \\ \vdots \\ X_M(f) \end{bmatrix}}_{\vec{x}(f)} = \underbrace{\begin{bmatrix} e^{-j2\pi f\tau_{11}(\theta)} \\ e^{-j2\pi f\tau_{21}(\theta)} \\ \vdots \\ e^{-j2\pi f\tau_{M1}(\theta)} \end{bmatrix}}_{\vec{a}(f, \theta)} S(f) + \underbrace{\begin{bmatrix} N_1(f) \\ \vdots \\ N_M(f) \end{bmatrix}}_{\vec{n}(f)}。$$

每一行就是上面那个标量式子；把公共的  $S(f)$  提到列向量外面，就得到全书最常用的紧凑形式：

$$\vec{x} = \vec{a}(\theta) s + \vec{n}。 \quad (2-1)$$

- $\vec{x}$ ： $M$  路信号的列向量， $M$  为麦克风数量；
- $\vec{a}(\theta)$ ：导向矢量（steering vector），描述声源位于  $\theta$  方向时各麦克风相对麦 1 的相位；
- $\theta$ ：声源方向，也是定位时想求的量；
- $s$ ：该频点的声源谱，是标量，即上面逐行式子中的  $S(f)$ ；
- $\vec{n}$ ：噪声向量。

式(2-1)省略了频点自变量  $(f)$ ，下文沿用此简写。在本节的等幅远场模型中， $\vec{a}(\theta)$  每个分量的模长为 1，分量差异来自相对时延  $\tau_{m1}(\theta)$ 。定位算法可用候选方向的导向矢量解释观测，波束形成器则用它规定目标方向响应；近场或含散射时还要加入距离和幅度项。

手算一遍：3 麦 ULA 的麦 1、2、3 依次位于  $x = 0, 4, 8$  cm；声源位于正角  $30^\circ$ ， $f = 1$  kHz。

相邻麦的  $\tau_{m1}$  变化量为  $-d \sin 30^\circ / c \approx -58.3 \mu\text{s}$ ，所以相邻导向相位变化为  $-2\pi f(-58.3 \mu\text{s}) \approx +0.366 \text{ rad}$ ，即约  $+21^\circ$ 。因此

$$\vec{a} = [1, e^{+j0.366}, e^{+j0.733}]^\top。$$

时域解释是麦 2 比麦 1 早  $58.3 \mu\text{s}$ 。在本书的傅里叶约定下，较早到达对应相对麦 1 的正相位。

混响：实际房间中麦克风收到直达声与多条反射路径的叠加，即声源与房间脉冲响应（Room Impulse Response, RIR）的卷积。 $T_{60}$  描述混响尾的衰减时间；下一节给出定义、计算和适用边界。

直达声模型明确后，§ 2.4 再加入房间反射，说明混响会怎样改变观测。

## 2.4 房间声学：混响到底是怎么来的

房间脉冲响应（Room Impulse Response, RIR）：RIR 是房间和收发位置固定时，系统对理想单位冲激的响应。在线性、时不变近似下，麦克风信号等于声源信号与 RIR 的卷积。

拍手录音可以粗略显示直达声和衰减尾，却不是严格的 RIR：拍手本身有有限时长和频谱，麦克风响应也会进入录音。要得到可用于计算的 RIR，通常播放已知测试信号并反卷积，测量方法见本节末。

RIR 可按图5(a)作教学性分段：

1. 直达声：从声源直线到达，最干净、携带最准的方向信息；
2. 早期反射：直达声后较早到达、仍能分辨出路径结构的反射。图5(a)用 80 ms 作示意分界；80 ms 也是音乐清晰度指标  $C_{80}$  的积分分界，而语音清晰度常用 50 ms 的  $C_{50}$ 。这不是早、晚反射的普适物理边界，80 ms 内的反射次数也取决于房间尺度和路径。早期反射可能增加响度，也会模糊方向线索；
3. 晚期混响：经多次反射后形成的弥散尾音。统计建模时，常把充分弥散的晚期混响近似为各向同性声场；这个近似适合分析波束形成器的 DI（指向性指数，§ 2.6），但不表示混响在时间上就是独立白噪声。WPE（第 7 章）正是利用晚期混响仍有时间相关性来做预测消除。

图5 房间脉冲响应、能量衰减与直达混响比（本书仿真）




图 5 (a) 把房间脉冲响应分为直达声、早期反射和晚期混响；图 5 (b) 用能量衰减 60 dB 所需时间定义  $T_{60}$ ；图 5 (c) 固定  $d_c = 1.0$  m，展示直达声与混响声的相对声级怎样随声源—麦克风距离变化。该子图是归一化示例，不直接给出体积或混响时间不同的房间结果。

混响有多强： $T_{60}$  与赛宾公式。 $T_{60}$  是声能衰减 60 dB 所需的时间（图 5(b)），可用赛宾 (Sabine) 公式估算。原始理论可追溯到 Sabine 的声学论文集。实测时要按空间类型选标准：[ISO 3382-1:2009](#) 面向演出空间，[ISO 3382-2:2008](#) 面向普通房间：

$$T_{60} = \frac{0.161 V}{A}, \quad A = \sum_i S_i \alpha_i。$$

- $V$ : 房间体积 ( $\text{m}^3$ ) ;  $S_i$ 、 $\alpha_i$ : 第  $i$  个表面的面积与吸声系数 (0=全反射的光滑瓷砖, 1=全吸声的开放窗户) 。
- 算例 (本例是参数演示, 不代表某类房间的通用测量值): 房间尺寸取  $5\text{ m} \times 4\text{ m} \times 2.8\text{ m}$ , 故  $V = 56\text{ m}^3$ ; 再假设各表面的赛宾吸声量合计为  $A = 18\text{ m}^2$ , 则  $T_{60} = 0.161 \times 56/18 \approx 0.50\text{ s}$ 。改变表面材料或摆设会改变  $A$ , 因此同尺寸房间也可能得到不同结果。

这个公式怎么推出来的 (五步, 能量守恒 + 一个几何事实):

1. 模型: 混响期的声能在房间里近似均匀分布 (扩散场假设), 声线不断撞墙, 每撞一次被吸收掉一部分;
2. 几何事实: 声线在房间中平均飞行  $\ell_{\text{mfp}} = \frac{4V}{S}$  米撞一次墙 (统计几何的经典结果,  $S$  是所有墙面的总面积)。直觉检验: 房间越大飞得越远、墙越多撞得越勤, 都对得上;
3. 每秒能量损失率: 撞墙频率  $= \frac{c}{\ell_{\text{mfp}}} = \frac{cS}{4V}$  (次/秒), 每次损失能量比例  $\bar{\alpha}$  (平均吸声系数), 于是每秒损失率  $= \frac{cS\bar{\alpha}}{4V} = \frac{cA}{4V}$ ;
4. 列方程求解:  $\frac{dE}{dt} = -\frac{cA}{4V}E$ ——“损失率正比于当前能量”的方程, 解是指数衰减  $E(t) = E_0 e^{-\frac{cA}{4V}t}$ ;
5. 代入定义收尾:  $T_{60}$  是能量衰减 60 dB 的时间——注意 60 dB 是能量比  $10^6$  (不是  $10^3$ : 能量的 dB 用  $10\log_{10}$ ,  $10\log_{10} 10^6 = 60$ )。令  $e^{-\frac{cA}{4V}T_{60}} = 10^{-6}$ , 两边取对数:  $\frac{cA}{4V}T_{60} = 6\ln 10$ , 解出

$$T_{60} = \frac{24\ln 10}{c} \cdot \frac{V}{A} = \frac{55.3}{343} \cdot \frac{V}{A} \approx 0.161 \frac{V}{A} \checkmark。$$

平均自由程中的因子 4: 在声线方向各向同性、房间为凸体的假设下, 墙面对各方向的平均投影面积是总表面积的  $1/4$ 。因此单位体积内声线单位时间的墙面碰撞率为  $cS/(4V)$ , 两次碰撞间的平均距离为其传播距离形式的倒数  $\ell_{\text{mfp}} = 4V/S$ 。量纲检查:  $V/S$  是长度; 立方房间边长为  $L$  时,  $\ell_{\text{mfp}} = 4L^3/(6L^2) = 2L/3$ 。

常数 0.161 的来源:  $24\ln 10 \approx 55.26$ ; 取声速  $c = 343\text{ m/s}$ ,  $55.26/343 \approx 0.161$ 。其中  $6\ln 10$  来自 60 dB 的能量比, 几何平均路径项再带来因子 4。

适用边界: 推导用了“扩散场 + 弱吸收”假设。平均吸声系数不再很小时, 赛宾的一阶近似会逐渐偏离, 可改用 Eyring 公式

$$T_{60} = \frac{-0.161V}{S\ln(1-\bar{\alpha})} \quad (\text{极端检查: } \bar{\alpha} = 1 \text{ 时 Eyring 给出 } T_{60} = 0, \text{ 赛宾却给出非零值})。$$

这里不设一个适用于所有房间的硬阈值; 应按频带、声场扩散程度和测量标准核对。公式来源见 [Eyring 1930 原论文](#)。

直达混响比 DRR 与临界距离。直达声随距离按平方反比衰减 (每远一倍弱 6 dB), 而理想扩散场中的晚期混响能量密度近似不随位置变化。两者相等的位置称为临界距离  $d_c$ :

$$d_c \approx 0.057 \sqrt{\frac{V}{T_{60}}} \text{ (m)}。$$

(此式默认声源全向辐射, 即指向性因子  $Q = 1$ ; 若声源有指向性 (如人声朝前更响), 把  $Q$  乘进根号内的分子:

$$d_c \approx 0.057 \sqrt{QV/T_{60}}。)$$

临界距离公式的推导 (四步):

1. 直达声的声强与能量密度: 全向声源的功率  $W$  均匀分布在半径  $r$  的球面上, 声强为  $I_d = W/(4\pi r^2)$ , 单位是  $\text{W/m}^2$ 。对向外传播的平面波局部近似, 能量密度为  $E_d = I_d/c = W/(4\pi r^2 c)$ , 单位是  $\text{J/m}^3$ ;
2. 混响声能量密度: 房间里的混响能量不断被墙面吸收、又不断被声源补充, 稳态扩散场中的能量密度为  $E_r = 4W/(cA)$  ( $A$  是赛宾吸声量), 与位置无关;

3. 令两个能量密度相等（临界距离的定义）： $\frac{W}{4\pi r^2 c} = \frac{4W}{cA}$ ； $W$  和  $c$  消去后， $d_c = \sqrt{\frac{A}{16\pi}}$ ；
4. 代入赛宾公式  $A = \frac{0.161V}{T_{60}}$ ： $d_c = \sqrt{\frac{0.161V}{16\pi T_{60}}} = \sqrt{0.00321 \frac{V}{T_{60}}} \approx 0.057 \sqrt{\frac{V}{T_{60}}}$ 。

可跳过：弥散能量式中 4 从哪里来 ( $4W/(cA)$ )：稳态能量平衡是“注入功率 = 吸收功率”。墙面每秒吸收的功率 = 能量密度  $E \times$  声速  $c \times$  有效吸收面积。关键一步：各向同性声场中，只有面向墙面方向的能量流才会被吸收，对半球方向平均后有效因子恰为  $1/4$ （各向同性场向墙面投影平均带来的  $1/4$  因子，直觉版的严格说法见上），于是吸收功率 =  $E \cdot cA/4$ 。令它等于注入功率  $W$ ，解得  $E = 4W/(cA)$ 。与上一步平均自由程里的 4 是同一个几何根源：都是“各向同性场向一面墙投影”带来的  $1/4$ 。

常数 0.057 的来源： $0.161/(16\pi) \approx 0.003203$ ，再开平方得到  $0.0566 \approx 0.057$ 。因此该常数同时包含赛宾公式中的 0.161 和球面扩散项  $16\pi$ 。

图 5 (b) 的指数包络把名义  $T_{60}$  设为 0.5 s；加入固定随机尾和早期反射后，Schroeder 剩余能量积分曲线最接近 -60 dB 的位置约为 0.514 s。因此 0.5 s 是生成模型的名义参数，不表示该固定样例恰好在 0.500 s 穿过 -60 dB。

这里直接寻找 -60 dB 交点，只用于核对这条合成曲线。实测应按场所选择 ISO 3382 的相应分册，常对衰减曲线的 -5~-25 dB ( $T_{20}$ ) 或 -5~-35 dB ( $T_{30}$ ) 区间回归，再外推到 60 dB。

图 5 (c) 是设定  $d_c = 1.0$  m 的归一化示例。在该模型中，3 m 处的 DRR 为  $-20 \log_{10}(3/1) \approx -9.5$  dB，表示混响能量高于直达声；这个数不能外推到未测量的房间。实际  $d_c$  还随体积、吸声量和声源指向性变化。DRR 可作为距离估计的声学线索，但也会受房间和声源级别影响。

仿真怎么造混响：镜像法 (Image Method, 镜像声源法) 把墙面反射等效为镜像声源的叠加，算法定义见 Allen 与 Berkley 1979 原文。开源库 pyroomacoustics 可生成给定房间和阵列的 RIR；本书固定链接到 pyroomacoustics 0.10.0 的 PyPI 发布页，示例接口以该版本为准。不同版本的接口、默认值或依赖可能变化，复现时应记录实际安装版本。

反过来，怎么实测一个房间的混响：拍手或爆破气球后观察衰减只能作粗略估计。更可控的做法是指数正弦扫频 (Exponential Sine Sweep, ESS)：播放频率指数上升的已知扫频，录音后反卷积得到 RIR，方法见 Farina 2000, AES Convention Paper 5093。

在系统近似时不变、没有削波且扫频长度足够时，ESS 可将若干谐波失真成分与线性 RIR 在反卷积结果中分开。环境噪声、削波、时变非线性和播放/录音链路的频响仍会影响测量。

无法播放测试音的在线场景也可以用普通语音盲估  $T_{60}$  和 DRR，例如利用两麦相干函数估计直达 - 弥散比。

房间传播模型解释了麦克风信号的组成。算法实现还需要把连续波形组织成 STFT、快拍和协方差矩阵。

## 2.5 数据怎么组织：STFT、快拍与协方差矩阵

后面的算法反复出现三个词——STFT、快拍、协方差矩阵，先在这里一次讲清。

STFT (短时傅里叶变换, Short-Time Fourier Transform) 把波形切成重叠短帧，每帧加窗后做快速傅里叶变换 (Fast Fourier Transform, FFT)，得到时间-频率复数网格，即语谱图 (图 6 (a) (b))。每个时频点同时包含幅度与相位。

增强或波束示例可用 32 ms 窗、8 ms 帧移；自动语音识别 (Automatic Speech Recognition, ASR) 前端常见另一组设置为 25 ms/10 ms。比较文献时应核对采样率、窗函数、窗长和帧移。

为什么需要这张表？因为 STFT 把宽带语音分解为一组近似窄带问题。时延  $\tau$  对应的相位旋转  $2\pi f_k \tau$  随频率变化，因此第  $k$  个频点要使用自己的  $\vec{a}(f_k, \theta)$ 。

把卷积在每个时频点写成  $\vec{x}(f_k, \ell) \approx \vec{a}(f_k, \theta) s(f_k, \ell) + \vec{n}(f_k, \ell)$  仍是窄带近似。窗函数会使直线卷积在 STFT 中产生频带内和跨频带项，长房间响应、过短窗或频率变化过快时误差更大。第 4、5 章逐频点处理时，需把窗长与有效冲激响应长度纳入验证。

STFT 分帧数字例子：阵列配置为 4 麦常规小间距，采样率 16 kHz、窗长 32 ms、帧移 8 ms。

- 窗长为  $16000 \times 0.032 = 512$  点，FFT 常用 512 点。
- 帧移为  $16000 \times 0.008 = 128$  点，相邻帧重叠率为  $(512 - 128)/512 = 75\%$ 。
- 1 s 语音共有  $(1000 - 32)/8 + 1 \approx 122$  帧。
- 每帧 FFT 给出 257 个有效频点（0~8 kHz），相邻频点间隔为  $16000/512 = 31.25$  Hz。

这个 31.25 Hz 是 DFT 网格间隔，不等于能分开两条相邻谱线的频率分辨能力；后者还取决于窗函数的主瓣宽度等条件。[Harris 1978](#) 详细讨论了窗函数对谱分析的影响。

于是，1 s、4 麦录音展开为  $122 \times 257 = 31354$  个时频点，每个点上有一个 4 维快拍向量。这就是后文协方差矩阵  $\hat{\mathbf{R}}(f_k)$  在每个频点上平均的对象，每个频点约有 122 个快拍参与平均。

**快拍** (snapshot, 快照向量)：固定频点索引  $k$ 、取第  $\ell$  帧，把  $M$  个麦克风在该时频点  $(f_k, \ell)$  的复数谱排成列向量  $\vec{x}(f_k, \ell)$ ，就是一个快拍——相当于阵列在某一短帧拍下的一张“空间照片”（图6(b) 里标的那个格子就是它）。

**空间二阶矩**（阵列文献常称空间协方差矩阵）：单张快拍太噪，把几十到几百个快拍平均：

$$\hat{\mathbf{R}}(f_k) = \frac{1}{L} \sum_{\ell=1}^L \vec{x}(f_k, \ell) \vec{x}^H(f_k, \ell). \quad (2-2)$$

式(2-2)没有减去样本均值，严格说是未中心化的样本二阶矩；当 STFT 快拍在所用时间段内可视为零均值，或已经去均值时，它才等于样本协方差。阵列文献常把两者都简称为空间协方差，使用实现或论文时要核对其定义。

$\hat{\mathbf{R}}$  是  $M \times M$  的复数矩阵，第  $m, n$  个元素记录麦  $m$  与麦  $n$  在该频点上的相关幅度与相位差。Capon、MVDR、MUSIC 都以它为输入；MUSIC 再用特征分解把观测空间分成信号子空间和噪声子空间。

只有在窄带远场模型正确、 $K < M$ 、导向矩阵与源协方差均满秩、噪声为空间白噪声且快拍足够多时，才可把高于噪声底的  $K$  个特征值解释成  $K$  个声源。相干反射、彩色噪声、有限快拍和阵列失配都会破坏这种分组。

图6 从波形到协方差矩阵：阵列算法处理的数据形态（模拟）




图 6 (a) (b) 来自单通道示意语音，用来解释分帧和时频点。图 6 (c) (d) 是另一组独立的 8 麦、2 个互不相干窄带源加空间白噪声理论例，并非由 (a) (b) 的单通道波形累积得到。

图 6 (c) 只画  $|R_{ij}|$ ，相位仍包含在复数  $R_{ij}$  中但未在图上显示。图中  $(k, l)$  依次表示频点索引和帧索引；正文用  $\ell$  代替容易与数字 1 混淆的字母  $l$ ，对应物理频率为  $f_k$ 。

只有在源协方差满秩、噪声为空间白噪声、阵列模型正确且快拍充足等条件下，才能把较大特征值的个数与声源数联系起来。

协方差估计的两个细节：

1. 快拍数太少时， $\hat{\mathbf{R}}$  的估计方差增大，小特征值也会明显波动。这是 Capon/MVDR 使用对角加载（§ 5.4）的原因之一。
2. 帧移小、相邻帧高度重叠时，快拍间并不独立，有效快拍数会少于帧数。

其中  $L$  是参与平均的快拍数， $\ell$  是快拍（帧）索引。快拍不够时会发生什么（处理方法见 § 5.4、§ 8.1）：样本协方差是  $L$  个秩一外积之和，因此

$$\text{rank}(\hat{\mathbf{R}}(f_k)) \leq \min(M, L)。$$

若未去均值， $L < M$  时它必然奇异；若先用同一批样本估计并减去均值，秩至多为  $L - 1$ ，此时  $L \leq M$  就必然奇异。

即使  $L \geq M$ ，强相关快拍、很差的条件下数和估计误差仍可能让求逆不稳，所以不存在通用的“ $L \geq 2M$  就安全”门槛。

第一类处理是收缩估计：

$$\hat{\mathbf{R}}_{\text{shrink}}(f_k) = (1 - \rho)\hat{\mathbf{R}}(f_k) + \rho \frac{\text{tr} \hat{\mathbf{R}}(f_k)}{M} \mathbf{I},$$

其中  $0 \leq \rho \leq 1$ ，用于在样本统计量和各向同性先验之间折中；§ 5.4 的对角加载与它目标相近。

第二类处理是用时频掩码为快拍加权，分别估计目标或噪声协方差（§ 8.1）。掩码可以减少干扰泄漏，但也会减少有效样本数，仍须检查矩阵的条件数并配合加载。

本书代码采用的数组与流式约定。`spectral.py` 中的 STFT 固定输出 通道数  $\times$  频点数  $\times$  帧数，即  $M \times F \times L$ ；`covariance.py` 再把它变成  $F$  个  $M \times M$  空间二阶矩。示例使用前向变换  $e^{-j2\pi ft}$ 、周期 Hann 窗和加权重叠相加。`center=True` 会在两端补半窗，因此离线重构可对齐原波形；实时系统不能据此把延迟写成零，还要把首帧等待、窗长、帧移、分块缓存和可能的前瞻一并计入端到端延迟。

协方差实现同时给出批量估计和指数递归更新。掩码在某个频点的权重和为零时，代码会报错，而不是用  $\epsilon$  伪造一个无统计依据的矩阵；有限精度造成的非厄米残差会被对称化。需要加载时采用无量纲相对口径  $\alpha \text{tr}(\hat{\mathbf{R}})\mathbf{I}/M$ 。上线还应记录遗忘因子、VAD/SPP 更新门控、每频点有效权重、条件数以及回退方式；这些参数共同决定跟踪速度，不能只记录“用了 MVDR”。可运行的端到端小例见 `ch02_05_baselines.py`，解析边界测试见 `test_codes_doa_beam.py`。

语音信号对阵列处理的影响：

1. 语音既含低频基频及谐波，也含更高频的辅音和摩擦音；具体频带随说话人、发音和采集链路变化。谐波结构会让互相关出现周期性假峰，因此 TDOA 算法常做宽带加权（§ 4.2）。
2. 语音短时近似平稳、长时非平稳，所以常按几十毫秒分帧。
3. 多说话人语音在时频域常呈近似稀疏：不少时频点由某个声源占优，这是掩码类方法与聚类方法能工作的依据（§ 8.1），但混响和同频谐波会削弱这一近似。

阵列能否利用高频定位，还要同时检查混叠：4 cm 间距对应的全视场安全上限约 4.3 kHz，3 cm 间距约 5.7 kHz（§ 2.6）。超过上限并非一律不能用，而是必须结合转向范围、阵列几何和宽带融合处理歧义。

有了协方差和导向矢量，便可以定义波束图及其分辨率、旁瓣、WNG 和 DI。

## 2.6 怎么衡量一个波束好不好：先学会读波束图

本节路线图：四个度量回答四个问题——主瓣多窄（看得多细）？旁瓣多高（漏多少）？DI（抗混响/弥散噪声的能力）？WNG（抗自身底噪的能力）？

波束形成器让指定方向保持所需响应，同时改变其他方向的增益。把各方向的增益画出来就是波束图（beam pattern）；图 7(a) 标出本节使用的四个读图要素：

- 主瓣（main lobe）：想听的方向上拱起的那个高峰。峰顶增益 0 dB（无失真通过）；
- 旁瓣（side lobes）：主瓣两侧一连串越来越矮的小峰——它们在其他方向的声音漏进来的通道；
- 零点（nulls）：瓣与瓣之间的深谷——这些方向上各麦信号恰好相消干涉，几乎完全听不到；
- 为什么长这样：同相叠加形成峰、反相抵消形成谷——完整推导（等比数列求和）见 § 5.2，此处先会读图。

图7 波束图怎么读：主瓣 / HPBW / 旁瓣 / 零点 / 栅瓣（模拟）




图 7 (a) 标出主瓣、旁瓣、零点和半功率宽度；数值结果约为  $14.8^\circ$ ，离散 ULA 近似为  $14.7^\circ$ 。图 7 (b) 把间距增至  $\lambda$ ，在  $-7.7^\circ$  出现与主瓣等高的栅瓣。

度量一：主瓣宽度 HPBW（分辨率，Half-Power Beam Width）。主瓣两侧功率降到峰值一半的两个点之间的夹角，就是半功率波束宽度。

半功率点与  $-3\text{ dB}$  点：功率减半为  $10\log_{10} 0.5 = -3.01\text{ dB}$ 。波束图若按幅度绘制，半功率对应幅度  $1/\sqrt{2} \approx 0.707$ ，同样得到  $20\log_{10} 0.707 = -3.01\text{ dB}$ 。因此“半功率点”和“ $-3\text{ dB}$  点”指同一位置（图 7 (a) 的红色双箭头）。幅度减半则是  $-6\text{ dB}$ ，对应功率变为四分之一。

对常规波束扫描而言，HPBW 可用来估计角分辨率：两个源的间隔小于主瓣宽度时，扫描谱往往难以形成两个清楚峰值。对  $M$  元、等权、等间距 ULA，其离散阵因子给出的宽阵列近似为

$$\text{HPBW} \approx \frac{0.886 \lambda}{Md \cos \theta_0} \text{ rad.}$$

可跳过：系数 0.886 从哪里来：均匀线阵的归一化阵因子是 Dirichlet 核  $\frac{\sin(M\psi/2)}{M \sin(\psi/2)}$  (§ 5.2 的等比数列求和结果)，其中  $\psi = 2\pi d(\sin \theta - \sin \theta_0)/\lambda$ 。半功率点要求幅度  $= 1/\sqrt{2}$ ，即  $|\sin(M\psi/2)/(M\psi/2)| \approx 1/\sqrt{2}$ （大  $M$  时分母  $\sin(\psi/2) \approx \psi/2$ ）。

解  $\sin x/x = 1/\sqrt{2}$  得  $x \approx 1.3916$  ( $x = M\psi/2$ )，于是单边  $\psi_{3\text{dB}} = 2 \times 1.3916/M = 2.7832/M$ ；双边宽度换算到  $\sin \theta$  域再除以  $\cos \theta_0$  ( $d \sin \theta$  微分带来  $1/\cos \theta_0$ )，得  $\text{HPBW} = 2 \times 1.3916/(\pi) \times \lambda/(Md \cos \theta_0)$ ，而  $2 \times 1.3916/\pi = 0.8859 \approx 0.886$ 。

系数 0.886 来自方程  $\sin x/x = 1/\sqrt{2}$  的解。分母中的  $Md$  是离散阵因子近似产生的尺度，物理首末阵元跨度仍为  $D_{\text{phys}} = (M-1)d$ 。当  $M$  较大时两者接近； $\lambda/D_{\text{phys}}$  可用于孔径量级判断，但不是上述离散 ULA 公式的精确替换。

读法：阵列的电尺寸越大、频率越高（波长越短），主瓣越窄；转向接近端射时， $\cos \theta_0$  变小，主瓣变宽。

该式还用了主瓣附近的小角近似，因此主瓣很宽或转向接近端射时，应直接计算阵因子，而不是把公式外推到几百度。若只知道小阵列的物理跨度  $D_{\text{phys}} = 7\text{ cm}$ ，用  $\lambda/D_{\text{phys}}$  可看出：1 kHz 时比整个可视范围还宽，8 kHz 时进入几十度量级。这只是孔径尺度判

断。

图7(a)的条件是8麦、 $d = \lambda/2$ 、指向  $30^\circ$ 。代入离散 ULA 公式得  $0.886/(8 \times 0.5 \times \cos 30^\circ) \approx 0.256 \text{ rad} \approx 14.7^\circ$ ，与图中约  $14.8^\circ$  一致。

孔径尺度的明细： $0.886 \times 0.343/0.07 \approx 4.34 \text{ rad}$ 。这个量已超过线阵的  $180^\circ$  可视范围，说明窄主瓣近似不适用；正确结论是“该物理孔径在 1 kHz 几乎没有方向选择能力”，而不是把  $249^\circ$  当成可测的 HPBW。

度量二：旁瓣电平 SLL（泄漏）。最高旁瓣相对主瓣低多少 dB。均匀加权的 DSB（DSB = 延迟求和波束形成器，即“对齐后等权相加”，详见 § 5.2）约为  $-13 \text{ dB}$ ，对应最强旁瓣方向的功率约为主瓣方向的 5%（ $10^{-13/10}$ ）。定向干扰位于该方向时仍会进入输出；MVDR 可根据噪声协方差在干扰方向自适应形成零陷（§ 5.4）。加窗权重（例如汉明权重）可降低旁瓣，代价是主瓣变宽。

可跳过： $-13 \text{ dB}$  从哪里来：均匀加权阵因子近似为  $\sin x/x$  型（ $x$  正比于偏离指向的相位）。第一个旁瓣是该函数第一个负向极值点，位置约  $x \approx 4.4934$ （方程  $\tan x = x$  的首个非零解），函数值  $\sin(4.4934)/4.4934 \approx -0.2172$ 。幅度比  $0.2172$  折成功率  $0.2172^2 \approx 0.0472$ ，取  $10 \log_{10} 0.0472 \approx -13.26 \text{ dB}$ ——这就是“约  $-13 \text{ dB}$ ”的来历。

直觉上，等权矩形窗的傅里叶变换是 sinc，旁瓣是 sinc 振铃的第一个波峰，高度由 sinc 包络  $1/x$  决定。加窗（汉明等）相当于把矩形边沿削薄，振铃随之降低。

度量三：指向性指数 DI（抗混响/抗弥散噪声）。充分弥散的晚期混响常近似为从各方向入射的声场；实际风噪通常由局部湍流激发，不能无条件按弥散场处理。DI 表示在指定的各向同性弥散场模型下，波束对目标方向的信噪比改善。它由主瓣方向增益的平方除以全空间平均增益的平方，再取对数：

$$\text{DI} = 10 \log_{10} \frac{4\pi |B(\Omega_0)|^2}{\int_{4\pi} |B(\Omega)|^2 d\Omega}。$$

$\Omega = (\theta, \phi)$  表示三维方向， $B(\Omega)$  是该方向上的复响应， $\Omega_0$  是目标方向； $d\Omega$  是立体角微元，整个球面的立体角为  $4\pi$ 。分母对波束图在整个球面上积分，表示弥散场中各方向输入的总贡献。只有波束图轴对称时，才能把  $B(\Omega)$  简写为单角变量。

DI = 0 dB 表示没有方向选择性；DI 越大，能量越集中于目标方向。超指向波束形成（§ 5.3）的目标之一就是提高这一指标。

度量四：白噪增益 WNG（抗自身噪声/稳健性）。每个麦克风自己有底噪（热噪声），各通道互相独立。波束权重把它们合起来时会放大多少倍？这就是 WNG：

$$\text{WNG} = 10 \log_{10} \frac{|\vec{w}^H \vec{a}(\theta)|^2}{\|\vec{w}\|^2}。$$

分子是目标方向的增益平方，分母是权重自身的能量。无失真约束下，WNG 为负表示输出白噪声功率高于单通道参考。

超指向设计在低频可能产生较大的正负权重，使通道增益、相位和位置失配显著改变主瓣或零陷。单位幅度导向矢量下的 WNG 上限是  $10 \log_{10} M$ ，DSB 达到该上限（§ 5.2）。

DI 与 WNG 的定义及其在阵列设计中的用法可参见 Brandstein 与 Ward 编《Microphone Arrays》，第 2 章，2001。引用这些指标时仍须说明声场模型、导向归一化和积分范围。

DI 与 WNG 需要联合检查（详见 § 5.3、图 15）：在固定紧凑阵列上，超指向设计为提高弥散场 DI 往往会增大权重范数并降低 WNG，但变化幅度取决于频率、几何、对角加载和失配。不能只按其中一个指标选择权重。

常规波束的分辨率尺度。HPBW 的量级约为  $\lambda/D$ ，因此它常被用作常规波束扫描能否分开两个近邻源的经验尺度。

这不是所有估计器都不能越过的普适物理边界。MUSIC 等子空间方法在模型正确、信噪比和快拍数足够时可以得到窄于常规主瓣的谱峰，所以称为超分辨（super-resolution）；代价是对源相关性、阵列失配和有限样本更敏感。

空间混叠（栅瓣）：相邻麦间距超过半波长后，不同方向可能产生相同的离散空间相位。图 7（b）中，8 麦阵列指向  $60^\circ$ ，间距从  $\lambda/2$  增至  $\lambda$  后， $-7.7^\circ$  出现与主瓣等高的栅瓣，因而无法仅凭该频点区分两个方向。

这个  $-7.7^\circ$  可以手算验证：栅瓣条件  $\sin \theta - \sin \theta_0 = \pm \lambda/d$ ，取  $d = \lambda$ 、 $\theta_0 = 60^\circ$ ，得  $\sin \theta = \sin 60^\circ - 1 = 0.8660 - 1 = -0.1340$ ， $\theta = \arcsin(-0.1340) \approx -7.7^\circ$ 。这个结果与图7(b) 标注一致。

对麦距为 2~4 cm 的阵列，按上述半波长条件换算，无混叠带宽约为 4.3~8.6 kHz： $c/(2d) = 343/(2 \times 0.04) \approx 4.3$  kHz， $343/(2 \times 0.02) \approx 8.6$  kHz。

这与时间域奈奎斯特采样具有相似结构：时间采样要求  $f_s \geq 2f_{max}$  以避免频谱混叠；工程上常用  $d \leq \lambda/2$  作为均匀线阵的全视场安全线。

若把可视角写成闭区间  $[-90^\circ, 90^\circ]$ ，等号处仍有一个端点退化： $+90^\circ$  与  $-90^\circ$  的相邻相位分别为  $+\pi$  与  $-\pi$ ，两者相差  $2\pi$ ，无法仅凭该频点区分。要求闭区间内严格一一对应时应取  $d < \lambda/2$ 。

为什么  $d \leq \lambda/2$  是安全线（三步推导）：1. 相邻两麦对来自  $\theta$  方向的平面波，相位差为  $\psi = 2\pi d \sin \theta / \lambda$ （正横方向起算）；2. 相位以  $2\pi$  为周期，因此  $\psi$  与  $\psi + 2\pi$  不可区分。当  $\frac{2\pi d}{\lambda}(\sin \theta - \sin \theta_0) = 2\pi$ ，即  $\sin \theta - \sin \theta_0 = \frac{\lambda}{d}$  时，另一个方向与指向方向产生相同的阵元相位序列，波束图上出现等高栅瓣；3.  $\sin$  的取值范围是  $[-1, 1]$ ，所以  $|\sin \theta - \sin \theta_0| \leq 2$ 。当  $d < \lambda/2$  时， $\lambda/d > 2$ ，上式在可见范围内无解。反之， $d > \lambda/2$  只表示不再保证全视场无栅瓣；某个特定转向是否出现可见等高栅瓣，还要检查上式是否有可见解。

等号边界可直接代入核对： $d = \lambda/2$ 、 $\theta = +90^\circ$  与  $\theta_0 = -90^\circ$  时， $\sin \theta - \sin \theta_0 = 2 = \lambda/d$ 。因此“半波长安全线”包含端射两端重合这一边界例外。

精度理论下界（CRB）（统计内容较重，第一遍可跳过，§4 用到时再回）：克拉美-罗界（Cramér-Rao Bound）是在给定观测模型和正则条件下，对无偏波达方向（Direction of Arrival, DOA）估计器方差的下界。

下面的显式式子采用单源、窄带、确定性信号模型。每个快拍的未知复幅度作为干扰参数；阵列是  $M$  元均匀线阵（Uniform Linear Array, ULA）、间距为  $d$ ；共有  $T$  个独立快拍；噪声为各阵元方差均为  $\sigma^2$  的圆对称复白高斯噪声。

这里的单阵元线性 SNR 定义为  $\text{SNR} = \sum_{t=1}^T |s_t|^2 / (T\sigma^2)$ 。在这些约定下可得到下式。改变复/实噪声、已知/未知幅度或 SNR 定义会改变常数，推导口径见 [Stoica 与 Nehorai 1989](#)：

$$\text{CRB}(\theta) = \frac{6}{T \cdot \text{SNR} \cdot M(M^2 - 1) \cdot \left(\frac{2\pi d}{\lambda}\right)^2 \cos^2 \theta} \quad (\text{rad}^2)。$$

误差方差与 SNR、快拍数和阵元位置的二阶矩成反比，并在端射方向（ $\cos \theta \rightarrow 0$ ）发散。

- 固定间距  $d$  并增加阵元时， $M(M^2 - 1)d^2$  约按  $M^3 d^2$  增长。
- 固定物理孔径  $D = (M - 1)d$  时，同一项可写成  $M(M + 1)D^2 / (M - 1)$ ，约按  $MD^2$  增长，不能仍称为  $M^3$  标度。

公式里的  $M(M^2 - 1)$  来自各麦位置绕阵列中心的二阶矩  $\sum_m (m - \frac{M-1}{2})^2 = \frac{M(M^2-1)}{12}$ 。

算例 2-1：CRB 最小数值例

阵列配置——6 麦、间距 1.4 cm、孔径 7 cm；正横方向、 $f = 1$  kHz、 $T = 100$  快拍。

在上述模型内，任何满足正则条件的无偏估计器，其方差都不低于该 CRB。它不直接约束有偏估计器的均方误差，也不能脱离模型解释成所有算法的绝对极限。

本例取正横方向（ $\theta = 0^\circ$ ，即  $\cos \theta = 1$ ）、 $\lambda = 0.343$  m。SNR 要换成线性值再代入：SNR = 10 dB 对应 10，0 dB 对应 1。代入上式：

$$\text{CRB} = \frac{6}{100 \times 10 \times 6 \times 35 \times (2\pi \times 0.014/0.343)^2 \times 1} \approx 4.3 \times 10^{-4} \text{ rad}^2。$$

CRB 分母的五项因子： $T = 100$ （快拍数）； $\text{SNR} = 10$ （10 dB 的线性值）； $M(M^2 - 1) = 6 \times 35 = 210$ （麦克风位置方差项）； $(2\pi d/\lambda)^2 \approx 0.0658$ （电尺寸项）； $\cos^2 \theta = 1$ （正横方向）。分母乘积约为 13800，因此  $6/13800 \approx 4.3 \times 10^{-4} \text{ rad}^2$ 。改变阵列或频率时，应重新计算这五项。

开方得标准差  $\approx 0.021 \text{ rad} \approx 1.2^\circ$ ；SNR 降到 0 dB（线性值 1）时，标准差约为  $3.8^\circ$ 。

阵列的物理跨度为  $(M - 1)d = 5 \times 1.4 \text{ cm} = 7 \text{ cm}$ ；CRB 里的  $M(M^2 - 1)d^2$  则来自全部阵元位置的二阶矩，不能用一个 HPBW 孔径项代替。

这组数只说明：在本例的窄带、无偏估计和白噪声模型内，低信噪比会显著抬高方差下界。实际误差还受混响、失配、源相关性和估计器偏差影响。

**算例 2-2: DI 与 WNG 的数字感（4 元半波线阵，两个 6 dB）**

阵列配置——4 麦、间距  $\lambda/2$ 、孔径  $1.5\lambda$ ；延迟求和（DSB, Delay-and-Sum Beamforming）指向正横。

上面四个度量还只有公式没有数字，拿这个最小例子建立量级感：- WNG: DSB 恰好达到上限（§ 5.2 有证明）， $\text{WNG} = 10 \log_{10} M = 10 \log_{10} 4 \approx 6 \text{ dB}$ ；- DI: 把 DSB 波束图按定义式在整个球面上数值积分，得  $\text{DI} \approx 6 \text{ dB}$ ，这里采用 3D 各向同性弥散场口径。

对  $\lambda/2$  间距的线阵，DI 与 WNG 的数值恰好相等。原因是弥散场噪声在两麦间的相关系数正比于  $\text{sinc}(2\pi d/\lambda)$ ， $d = \lambda/2$  时恰好为 0，即各麦的弥散噪声互不相关，统计性质与自噪声一致。

口径注：此处  $\text{sinc}$  取  $\sin x/x$  定义；§ 5.1 用归一化定义  $\sin(\pi x)/(\pi x)$ ，同一物理量在该口径下写作  $\text{sinc}(1) = 0$ 。两种写法只差自变量里的  $\pi$ ，对照时应先换算。

量级结论：在本例的半波间距、空间白噪声近似下，4 元 DSB 的 WNG 和 DI 都是 6 dB。若针对某个弥散噪声模型提高 DI，权重通常会变得更敏感，WNG 可能下降；具体上限取决于阵列几何、频率、噪声相关矩阵和稳健性约束，不能只由麦克风数给出。

上述度量基于远场平面波模型。声源进入近场后，导向模型、搜索空间和定位参数都要加入距离维度。

## 2.7 小结：声源走近了，平面波不够用——近场要换的三样东西

远场模型把波前当平面，只剩方向一个未知数；声源走近后波前弯成球面，到达各麦的距离本身也携带信息。本小节把近场需要换掉的三样东西一次列清。

### ① 球面导向矢量

远场导向矢量的第  $m$  个分量只有相对相位旋转  $e^{-j2\pi f \tau_{ml}(\theta)}$ ，幅度视为相同。近场要写成球面波形式：声源在位置  $\vec{p}$  时，第  $m$  个麦克风位于  $\vec{r}_m$ ，它收到的复增益正比于

$$\frac{e^{-j2\pi f \|\vec{p} - \vec{r}_m\|/c}}{\|\vec{p} - \vec{r}_m\|}。$$

与远场相比，近场有两处变化：相位按真实距离  $\|\vec{p} - \vec{r}_m\|$  计算，不再是方向投影  $d \sin \theta$ ；幅度按距离的倒数衰减，各麦幅度不再相等。以表 1 归一化后得到近场导向矢量  $\vec{a}(\vec{p})$ ，其自变量从方向  $\theta$  变成位置  $\vec{p}$ ，定位输出也由角度扩展为角度和距离。

### ② 距离估计从哪里来

球面弯曲在阵列边缘相对中心造成的额外路程约为  $D^2/(8r)$ （§ 2.2 第 2 步），它同时改变相位曲率与幅度差。声源越近，波前越弯，边缘麦相对平面波预测的相位偏差越大；拟合这部分曲率可以估计距离  $r$ 。

距离是否可观测取决于  $D^2/(r\lambda)$ 、信噪比、带宽、麦数和几何形态。孔径很小或声源很远时，球面模型与平面模型几乎不可区分，此时距离估计会很不稳定。距离误差用米、角度误差用弧度，不能用“相差一个量级”直接比较。

### ③ 何时换球面模型

对中心对称孔径，Fraunhofer 距离  $r_F = 2D^2/\lambda$ ；一般应从选定参考点到最远阵元的距离  $a$  出发，用  $r_F = 8a^2/\lambda$  作相位曲率的起始检查。它不是跨过就立即从近场变为远场的物理分界。

使用平面波模型前，还要满足推导里的  $r \gg a$ ，并核对幅度差和允许的相位误差。条件不满足时，改用球面导向  $\vec{a}(\vec{p})$ ，SRP 搜索网格也从角度一维扩展为位置二维或三维（§ 4.3 的  $\tau_{ij}(\vec{r})$  已按距离差写出）。

7 cm 中心对称阵列在 1 kHz 下有  $r_F \approx 2.9$  cm，该数只表示相位曲率尺度，不能单独支持“整个房间都是远场”。1.26 m 中心对称线阵在同频率下有  $r_F \approx 9.3$  m，会议室内常需要球面波模型。频率越高、波长越短， $r_F$  越大；宽带系统应在目标频带内逐频检查建模误差。

本章从传播时延建立了远近场模型，并定义了 STFT、快拍、协方差及四项阵列度量。第 3 章将讨论麦克风几何如何限制这些观测与指标。

## 本章练习

1. STFT 分帧换算：采样率 8 kHz、窗长 32 ms、帧移 8 ms，求窗长采样点数、帧移采样点数、重叠率和 1 s 语音的帧数。

参考答案：窗长  $8000 \times 0.032 = 256$  点；帧移  $8000 \times 0.008 = 64$  点；重叠率  $(256 - 64)/256 = 75\%$ ；帧数  $(1000 - 32)/8 + 1 \approx 122$  帧。帧数与 16 kHz 时一样，因为只由窗长、帧移的时间值决定。

口径注：此处是无补零做法，即 FFT 点数等于窗长点数，256 点窗做 256 点 FFT。若补零到 512 点再做 FFT，频点数与频率分辨率另算，本题不按那个口径。

2. 协方差读数：2 麦在某频点上信号完全相干（互相关系数幅值为 1、相位差  $30^\circ$ ），各麦总功率都是 2，写出  $2 \times 2$  协方差矩阵  $\hat{\mathbf{R}}$ 。

参考答案： $\hat{\mathbf{R}} = \begin{bmatrix} 2 & 2e^{j\pi/6} \\ 2e^{-j\pi/6} & 2 \end{bmatrix}$ 。对角线是各麦功率，非对角线的模是相干强度，辐角是麦间相位差；矩阵应满足对角


元为实数且整体共轭对称。这里约定麦 1 相位超前  $30^\circ$ ；若采用相反的通道顺序，非对角元的相位符号也相反。

3. CRB 估算：阵列配置沿用算例 2-1（6 麦、间距 1.4 cm、孔径 7 cm）与 100 快拍，若 SNR 从 10 dB 提到 20 dB（线性值从 10 到 100），角度标准差从约  $1.2^\circ$  变成多少？再想想：快拍数翻 10 倍与 SNR 提 10 dB，哪个更划算？

参考答案：方差与 SNR 成反比，标准差缩小  $\sqrt{10} \approx 3.16$  倍，约为  $1.2^\circ/3.16 \approx 0.38^\circ$ 。快拍数与 SNR 在公式里是乘积关系，这两种变化的理论效果等价。实际中增加快拍只需多观察一段时间，提高 SNR 则可能需要改硬件或缩短拾音距离，前者通常成本更低。



图8 常见麦克风阵列几何形态示意



(a)(b) 平行线表示平面波波前，箭头表示传播方向；同一双麦基线只改变入射方向。其余平面子图为无量纲示意。

图8 画出八种常见形态。(a) (b) 使用完全相同的一条双麦基线，只把目标方向分别放在端射 (endfire) 和正横 (broadside) 两个极限；平行线表示平面波的波前，箭头表示传播方向。这说明“端射/正横”首先描述工作方向相对基线的关系，不是两套不同的双麦硬件。

其余子图依次为均匀线阵 (Uniform Linear Array, ULA)、方阵、均匀圆阵 (Uniform Circular Array, UCA) 加中心麦、按斐波那契球面规则确定性布置的 32 麦近均匀球阵、螺旋阵和分布式非规则阵。

裸露的全向麦克风只有几何位置，不会仅凭排列产生主瓣。(d) 的四只麦虽然也落在同一个圆周上，这里按方阵的平面几何分析。

两种基础双麦摆法（端射与正横是两个典型极限工作方向，中间角度同样有意义）：

- Endfire（前后排列）：配合延时和差分等处理后，目标主轴可沿连线方向，形成前方保留、后方抑制的响应。用于真无线立体声 (True Wireless Stereo, TWS) 耳机、手机；
- Broadside（左右排列）：配合相应波束形成器后，目标主轴可设为垂直于连线，用于笔记本、平板通话降噪。

### 算例 3-1 双麦耳机的差分——1 cm 间距怎么做心形指向

TWS 耳机上的双麦常采用端射 (endfire) 摆法：两个麦前后排列、间距  $d = 1\text{ cm}$ ，主轴沿两麦连线。它构成 § 5.3 所述的一阶差分麦克风阵列 (DMA, Differential Microphone Array)。

若只把两路信号乘实数增益后相减，即  $y = x_1 - g x_2$  ( $g$  为标量)，无法形成心形指向。纯实增益不改变相位；前方与后方来声的麦间相位差分别为  $-\Delta\phi$  和  $+\Delta\phi$ ，而前方  $|1 - g e^{-j\Delta\phi}|$  与后方  $|1 - g e^{+j\Delta\phi}|$  相等，结果是前后对称的 8 字形。

要打破这种对称性，需先引入时延再相减：把后路麦的信号延迟  $\tau_0 = d/c$ ，再从前路麦信号中减去：

$$y(t) = x_1(t) - x_2\left(t - \frac{d}{c}\right) \xrightarrow{\mathcal{F}} Y(f) = X_1(f) - e^{-j2\pi f d/c} X_2(f)$$

$\mathcal{F}$  表示傅里叶变换。

其中  $x_1$  是前路麦， $x_2$  是后路麦， $d/c$  是声音传播一个麦间距所需的时间。下面分别计算前方和后方来声的响应。

第 1 步：两麦之间的相位差。本算例用  $\Delta\tau$  表示时差的非负幅值；带符号的  $\tau_{ij} = t_i - t_j$  仍按 § 2.1 定义。声音沿连线方向传来时，两麦时差幅值最大：

$$\Delta\tau = \frac{d}{c} = \frac{0.01}{343} \approx 29.2\ \mu\text{s}$$

1 kHz 时对应的相位差（时延在频域就是相位旋转，§ 2.3）：

$$\Delta\phi = 2\pi f \Delta\tau = \frac{2\pi \times 1000 \times 0.01}{343} \approx 0.183\ \text{rad} \approx 10.5^\circ$$

第 2 步：后方来声——理想模型下抵消。后方的声音先到后路麦  $x_2$ 、晚  $\Delta\tau$  才到前路麦  $x_1$ ；给  $x_2$  补上的延迟  $\tau_0 = d/c$  正好等于自然时差，两路在减法器中对齐，理想等幅模型给出  $y = 0$ 。有限精度、通道失配和反射会使实际零陷保持有限深度。

第 3 步：前方来声——还剩多少。前方的声音先到  $x_1$ 、晚  $\Delta\tau$  到  $x_2$ ； $x_2$  又被电延迟推后  $\Delta\tau$ ，两路共错开  $2\Delta\tau$ ，即相位差  $2\Delta\phi \approx 21^\circ$ 。两路信号是复平面上两个长度相同、夹角  $21^\circ$  的箭头，相减得到连接两尖端的弦。剩余幅度（两路幅度归一化为 1）：

$$|Y| = |1 - e^{-j2\Delta\phi}| = 2 \sin \Delta\phi = 2 \sin 10.5^\circ \approx 0.365$$

换算成分贝： $20 \log_{10} 0.365 \approx -8.8\ \text{dB}$ 。前方保留而后方出现零陷，因此得到心形指向。低频近似下，只要电延迟与几何时差的关系保持不变，归一化波束形状随频率变化较小。

第 4 步：计算输出信噪比变化。与单个麦克风相比，前方信号幅度为 0.365，对应 -8.8 dB。两路独立自噪声相减后功率相加，噪声功率增加约 3 dB，因此输出信噪比降低约  $8.8 + 3 = 11.8\ \text{dB}$ 。这是一阶 DMA 在低频 WNG 较低的原因：间距越小、频率越低， $\Delta\phi$  越小，目标信号在相减中保留得越少。

第 5 步：失配最先伤害哪里。后方零陷靠的是“两路幅度精确相等、相减归零”。若麦 2 的增益是 1.01，后方响应的绝对幅度为  $|1 - 1.01| = 0.01$ ；相对单麦输入是  $20 \log_{10} 0.01 = -40 \text{ dB}$ 。波束图通常将目标方向归一化为 0 dB，这时还要除以失配后的前方响应：

$$|B_{\text{front}}| = |1 - 1.01e^{-j2\Delta\phi}| \approx 0.367, \quad 20 \log_{10} \frac{0.01}{0.367} \approx -31.3 \text{ dB}。$$

因此，“约 -40 dB” 是以单麦幅度为参考的绝对残差；本算例归一到前方主响应后，零陷约为 -31 dB。两个数的参考量不同，不能混用。增益失配主要限制后方零陷的深度，依赖精确相消的微型差分阵列因此需要通道配对和标定。

端射摆法利用延迟与相减形成前后不对称；正横摆法则把主轴放在麦克风连线的垂直方向。

双麦只有 1 个独立时延观测。在预先限定声源位于某个平面或半空间时，它可以估计一维入射角并形成固定波束；若要在三维空间同时求方位和俯仰，一个时延方程不够，同一时延对应绕阵列轴的一圈方向，形成锥面模糊。增加阵元并改变几何后，覆盖范围、歧义形式和端射灵敏度也会变化。

多麦形态对比：

| 形态         | 覆盖                 | 优点                                    | 缺点                                                      | 典型应用              |
|------------|--------------------|---------------------------------------|---------------------------------------------------------|-------------------|
| 均匀线阵 (ULA) | 一维 $\pm 90^\circ$  | 可直接利用平移不变结构；阵元集中在一条轴上，给定阵元数和间距时轴向孔径较大 | 不能由时延单独区分俯仰；靠近端射时 $d\tau/d\theta$ 趋近 0，角度误差被放大；还存在锥面模糊  | Soundbar、会议条      |
| 均匀圆阵 (UCA) | 水平 $360^\circ$     | 水平面基线方向较均衡，适合全方位扫描                    | 有限阵元只有离散旋转对称，波束仍随频率和转向变化；小半径在低频的电尺寸小，俯仰信息也有限            | 智能音箱、桌面会议设备       |
| 方阵/平面阵     | 单侧半空间；若两侧都开放则有镜像歧义 | 方位+俯仰都能测                              | 阵列平面两侧的镜像方向具有相同时延，需挡板或先验消歧                              | 视频会议一体机           |
| 球阵（刚性/开放球） | 全 $4\pi$ 立体角       | 三维覆盖较均匀，可录 3D 声场                      | 成本高、体积大；有限阵元下波束仍随频率和方向变化                                | 机器人听觉头、3D 录音、学术研究 |
| 螺旋阵/对数阵    | 宽频带                | 非均匀间距可打散周期性栅瓣                         | 设计与宽带优化较复杂；自由场导向矢量仍可按已知坐标计算                             | 高品质远场录音           |
| 分布式/随机阵    | 节点跨度可达房间尺度         | 长基线可提高部分方位的几何灵敏度；多位置观测可提供空间分集         | 节点常有独立时钟和不同声学路径；同步、位置标定、通信和缺包误差可能抵消长基线收益，空间分集也不保证抑制所有多径 | 多节点会议室、机器人网络      |

MUSIC 是多重信号分类 (Multiple Signal Classification)，ESPRIT 是借助旋转不变技术估计信号参数 (Estimation of Signal Parameters via Rotational Invariance Techniques)；本章只指出其几何前提，算法见 § 4.6。

读表时要区分两种几何歧义。线阵只有沿阵列轴的位置投影信息，因此同一组时延对应以阵列轴为轴的锥面；把麦继续加在同一直线上，能提高阵列增益和估计精度，却不能消除这类锥面模糊。非共线的平面阵能同时估计两个方向余弦，但若阵列两侧都开放，平面法向两侧的镜像方向仍可能产生相同时延，需要挡板、幅度模型或半空间先验消歧。

端射分辨率下降是另一类问题。若用  $\Delta\tau = d \sin \theta / c$  表示时差幅值随角度的局部关系，则  $\theta \rightarrow \pm 90^\circ$  时导数趋近于零，同样的时延误差会对应更大的角度区间；这与 § 2.6 CRB 中  $\cos \theta \rightarrow 0$  时下界发散一致。

算例 3-2 端射灵敏度——同一个 10 μs 误差在不同方向的影响

§ 3.1 所述端射附近灵敏度下降，根源是时延与角度的关系  $\Delta\tau = \frac{d}{c} \sin \theta$  ( $\theta$  从正横方向起算， $d$  为麦间距)。对  $\theta$  求导：

$$\frac{d\Delta\tau}{d\theta} = \frac{d}{c} \cos \theta \quad \Rightarrow \quad d\theta \approx \frac{c}{d \cos \theta} d\Delta\tau$$

即：同样的时延误差  $d\Delta\tau$ ，换算成角度误差时要除以  $\cos \theta$ 。

取  $d = 4 \text{ cm}$  的线阵（与 § 4.4 的例子一致）、时延误差  $d\Delta\tau = 10 \mu\text{s}$ （16 kHz 采样下不到 1/5 个采样点，是很容易残留的误差量级），算两个方向。

正横方向 ( $\theta = 0^\circ$ ) :  $\cos 0^\circ = 1$ ,

$$d\theta = \frac{343 \times 10 \times 10^{-6}}{0.04 \times 1} \approx 0.0858 \text{ rad} \approx 4.9^\circ$$

10  $\mu\text{s}$  误差对应约  $5^\circ$  的角度误差。这也复现了 § 4.4 “4 cm 间距下 10  $\mu\text{s}$  误差对应约  $5^\circ$ ” 的结论。

端射附近 ( $\theta = 85^\circ$ ) 不能继续把 10  $\mu\text{s}$  当作“小扰动”。本例最大物理时延是  $d/c \approx 116.6 \mu\text{s}$ ,  $85^\circ$  对应  $\tau \approx 116.2 \mu\text{s}$ 。若估计值增加 10  $\mu\text{s}$ , 便超过物理上限, 没有实数角度与之对应, 系统应当判为越界或把结果限制在端射。

若估计值减少 10  $\mu\text{s}$ , 则

$$\hat{\theta} = \arcsin\left(\frac{(116.2 - 10) \times 10^{-6} \times 343}{0.04}\right) \approx 65.6^\circ,$$

误差约  $19.4^\circ$ 。微分式在足够小的误差下仍说明灵敏度按  $1/\cos\theta$  增大, 但不能把  $85^\circ$  处的 10  $\mu\text{s}$  线性外推成  $56^\circ$  并当作精确误差。实际可用角域由允许误差、信噪比、快拍数和几何共同决定, 不存在统一的“端点扣掉  $30^\circ$ ”规则。

端射方向的非线性算例说明, 阵列灵敏度随入射角变化。下面把几何设计中最常用的四条规律集中列出。

## 3.2 四条设计规律

1. 常规波束的分辨率尺度由孔径与波长之比决定 (约  $\lambda/D$ ) : 7 cm 级圆阵在 1 kHz 的这个尺度已经超过线阵的整个可视角域, 方向选择性很弱; 到 4 kHz 才进入几十度量级 (见算例 3-3)。高频虽然能提供更大的电尺寸, 却也更容易遇到空间混叠、传播衰减和阵列失配。设计时必须把这些因素一起考虑。
2. 圆阵与线阵各有适用方向: 线阵在正横附近投影孔径最大, 转向端射时灵敏度下降; 圆阵在水平面各方位的几何更均衡。球阵还可提供俯仰信息。哪一种识别率更高, 取决于尺寸、挡板、房间、算法和评测方向分布, 不能只按阵形下结论。Kumatani – McDonough – Raj 《Microphone Array Processing for Distant Speech Recognition》CMU 课程讲义, 2012
3. 挡板效应必须纳入导向模型: 麦克风装在刚性圆柱或球体上时, 绕射和散射会改变跨通道的幅相响应。某些频段和方向上, 它能增加可辨的幅相差; 另一些位置也可能出现阴影或共振。因此应使用相应的解析散射模型或实测阵列流形, 不能把挡板一概等效为固定倍数的“虚拟孔径”。
4. 麦克风数量没有通用最优值: 增加麦克风通常能提高统计稳定性和可控自由度, 但收益取决于是否同时增加孔径、噪声相关性、带宽、算法和计算预算。对独立等功率自噪声, 理想 DSB 的 WNG 为  $10 \log_{10} M$ , 麦数翻倍增加约 3 dB; 这只是特定噪声模型下的基准, 不能单独决定产品所需的麦克风数量。

### 算例 3-3: 6 麦圆环的数字

考虑一个用于教学的 6 麦均匀圆环, 环径取 7.5 cm, 即半径  $r = 3.75 \text{ cm}$ 。这个尺寸只用于展示计算方法, 不对应某一款产品; 声速取  $c = 343 \text{ m/s}$ 。

第 1 步: 相邻麦距。6 个麦均匀分布在圆周上, 相邻两麦的连线是正六边形的一条边。相邻麦距

$$d = 2r \sin \frac{\pi}{6} = 2 \times 0.0375 \times 0.5 = 0.0375 \text{ m} = 3.75 \text{ cm}$$

正六边形的边长恰好等于半径——这是 6 麦圆环特有的整齐性质。

第 2 步: 相邻间距的保守检查。对均匀线阵, 全视场无空间混叠的充分安全线是  $d \leq \lambda/2$  (§ 2.6)。圆阵不是一条周期均匀线阵, 这里只把相邻弦长代入同一条件, 作为保守的设计检查; 超过该频率表示不再得到全视场无歧义保证, 不表示每个转向都必然出现等高栅瓣。代入:

$$f_{\max} = \frac{c}{2d} = \frac{343}{2 \times 0.0375} \approx 4573 \text{ Hz} \approx 4.6 \text{ kHz}$$

因此，按相邻间距的半波长充分条件，这个阵列约在 4.6 kHz 以下满足全视场无混叠要求。16 kHz 采样时，4.6~8 kHz 频段不再得到这一保证。

可选措施包括降低高频子带权重、采用非均匀间距以减弱周期性歧义，以及定位时主要使用无混叠频段、增强时再利用高频信息。

第 3 步：波长与孔径的比。阵列孔径（阵列的最大尺寸） $D = 2r = 7.5 \text{ cm}$ 。

- 1 kHz: 波长  $\lambda = c/f = 343/1000 = 0.343 \text{ m} = 34.3 \text{ cm}$ ，孔径比  $D/\lambda = 0.075/0.343 \approx 0.22$ ——整个阵列只有约五分之一波长大小；
- 4 kHz:  $\lambda = 343/4000 \approx 0.0858 \text{ m} = 8.6 \text{ cm}$ ， $D/\lambda = 0.075/0.0858 \approx 0.87$ ——孔径接近一个波长。

第 4 步：常规波束的角宽量级。用  $\lambda/D$ （弧度，§ 2.6）做孔径尺度估计：

- 1 kHz:  $\lambda/D \approx 0.343/0.075 \approx 4.6 \text{ rad} \approx 262^\circ$ 。这个尺度超过线阵从  $-90^\circ$  到  $+90^\circ$  的  $180^\circ$  可视角域；对圆阵则不能把借自连续孔径的一维角宽直接与  $360^\circ$  方位周期作严格比较。它仍清楚表明：1 kHz 下这只 7.5 cm 的环电尺寸很小，常规波束的方向选择性很弱；
- 4 kHz:  $\lambda/D \approx 1.14 \text{ rad} \approx 66^\circ$ ，对应主瓣宽度量级  $\approx 0.886\lambda/D \approx 58^\circ$ （借用线阵公式估量级，圆阵精确系数不同）——进入「几十度」的量级，总算能分出「大概在哪一边」。

结论：4 kHz 时阵列的电尺寸接近 1，常规波束已可能呈现几十度量级的方向选择性；1 kHz 时电尺寸只有约 0.22，常规波束很宽。子空间估计或学习方法能在合适条件下利用微弱的跨通道差异，但不会凭空增加观测信息；低信噪比、强混响或模型失配时，低频方向仍难估。

#### 算例 3-4: ULA 主瓣宽度计算

取一条 4 麦 ULA（等间距直线排列的阵列），间距  $d = 3 \text{ cm}$ ，指向正横。首末阵元的物理跨度为  $(M - 1)d = 9 \text{ cm}$ ；§ 2.6 从离散阵因子推得的窄主瓣近似则是

$$\text{HPBW} \approx \frac{0.886 \lambda}{Md} \text{ rad}$$

这里的  $Md = 12 \text{ cm}$  来自 Dirichlet 核的近似尺度，不等于物理跨度。对小阵列要保留这个区别。

1 kHz: 波长  $\lambda = 343/1000 = 0.343 \text{ m}$ 。若强行代入窄主瓣近似，会得到  $0.886 \times 0.343/0.12 \approx 2.53 \text{ rad}$ ，但这个数不是该阵列的 HPBW。直接计算精确阵因子：端射处  $\psi = 2\pi d/\lambda \approx 0.550 \text{ rad}$ ，

$$|B(90^\circ)| = \left| \frac{\sin(M\psi/2)}{M \sin(\psi/2)} \right| \approx 0.821.$$

即  $20 \log_{10} 0.821 \approx -1.71 \text{ dB}$ 。从  $-90^\circ$  到  $90^\circ$  都没有降到  $-3 \text{ dB}$ ，所以本例在 1 kHz 下没有可定义的  $-3 \text{ dB}$  主瓣宽度。

8 kHz: 波长  $\lambda = 343/8000 \approx 0.0429 \text{ m}$ ，

$$\text{HPBW} \approx \frac{0.886 \times 0.0429}{0.12} \approx 0.317 \text{ rad} \approx 18.1^\circ$$

这两个结果怎么读：1 kHz 下精确阵因子在可视范围内没有  $-3 \text{ dB}$  交点，只能说明波束方向选择性很弱；不能把近似式给出的  $145^\circ$  当成实际 HPBW。8 kHz 下近似估计约为  $18.1^\circ$ ，主瓣明显收窄。只要几何和转向不变，处在窄主瓣近似的适用区间时，频率减半会使 HPBW 约增大一倍。

图9 麦克风数量增加时的理想增益与处理量  
(公式计算, 不给出产品选型排名)




图 9 (a) 在目标精确对齐、各通道噪声独立同方差的条件下, 按  $10\log_{10} M$  画出理想 DSB 白噪声增益。(b) 分别按  $M$ 、 $M(M-1)/2$  和  $M^2$  计算输入通道、无序麦对与完整协方差矩阵的元素数量。右图的纵轴采用以 2 为底的对数刻度。这些数量用于说明数据结构怎样随  $M$  增长, 不等同于具体实现的运行时间、功耗或价格。

§ 3.3 转向非均匀稀疏阵, 说明怎样用差分协同阵扩展虚拟孔径。

### 3.3 稀疏阵列与差分协同阵

协同阵的概念: 从麦的位置到麦对的间距

均匀线阵若要在整个可视角域避免栅瓣, 阵元间距需不大于半波长 (§ 2.6)。在给定麦克风数量下, 这一条件限制了物理孔径。

稀疏阵列 (sparse array) 相对于一个明确的密集参考网格, 只启用其中一部分候选位置; “麦克风少” 或 “位置不均匀” 本身都不足以构成这个定义。常见设计包括非均匀的嵌套阵、互质阵和删减阵, 也可能保留等间距但存在空位。利用麦克风对的位置差, 可以构造比物理阵元集合更长的虚拟阵列。

核心概念: 差分协同阵 (difference co-array)。理想远场窄带模型下, 协方差矩阵第  $i, j$  个元素的相位由麦  $i$  与麦  $j$  的位置差决定。收集所有麦对的位置差, 就得到差分协同阵。

6 麦均匀线阵的位置是  $\{0, 1, 2, 3, 4, 5\}$  (单位  $\lambda/2$ ) , 不同的有符号滞后是  $\{0, \pm 1, \dots, \pm 5\}$ , 共 11 个。6 麦嵌套阵  $\{0, 1, 2, 3, 7, 11\}$  可得到  $\{0, \pm 1, \dots, \pm 11\}$ , 共 23 个连续滞后 (图 10)。

这 23 个数是连续的有符号差分滞后, 不是 23 路彼此独立的物理快拍。若按滞后平均、构造 Toeplitz 虚拟协方差并做空间平滑, 可得到比物理阵更长的虚拟 ULA。

在模型和秩条件满足时, 部分协同阵方法可能估计多于物理麦数的非相干源。可分辨源数仍取决于连续单侧滞后长度、重构方法、平滑后的矩阵维数、信噪比和快拍数, 不能直接等同于 23。

差分集合只给出虚拟阵列的位置。要把这些位置用于子空间估计, 还需要从协方差中构造相应的二阶统计量。

协方差为什么能当虚拟观测

为什么协方差能提供虚拟滞后观测：对互不相干的远场源， $\mathbf{R}$  的第  $i, j$  个元素是各源功率乘相位项  $e^{-j2\pi f(\tau_i - \tau_j)}$  的和，只依赖两麦位置差。相同位置差的麦对可做平均，降低估计方差；不同位置差提供不同滞后。

把协方差元素按滞后重排后，可把连续的一段滞后解释为虚拟 ULA 的二阶统计量。它不是原始阵列快照，因此标准 MUSIC 不能不经处理直接套用。通常还需 Toeplitz 重构、直接协同阵处理或空间平滑，才能形成满足子空间方法要求的虚拟协方差。

相干源、宽带混响、有限快拍和有洞差集都会降低可用秩和自由度。

可以把它理解为重新整理“麦对间距表”：相同间距的观测合并，不同间距按顺序排成一条虚拟标尺。标尺更长，潜在孔径更大；但只有完成统计重构并满足秩条件后，这些滞后才会转化为可用的子空间自由度。

图10 稀疏阵列：6 个物理麦克风对应不同的有符号差分位置（模拟）




图 10 左侧比较均匀、嵌套和互质三种摆法，横轴单位是半波长；右侧枚举所有有序麦对的位置差，得到有符号差分位置（也称有符号滞后）。均匀阵有 11 个连续滞后，图中的嵌套阵有 23 个连续滞后，互质阵覆盖范围更大但中间有空缺。连续滞后数描述虚拟孔径结构，不应直接写成 MUSIC 可分辨的源数。

这种虚拟观测依赖统计重构和秩条件；差分集合中的空缺、宽带信号和混响都会限制可用自由度。

代价与边界：差分空缺、宽带和混响

代价与边界：协同阵使用的是二阶统计量，需要专门的协同阵 MUSIC、Toeplitz 重构、空间平滑或稀疏重构。差分滞后中的洞还会使可用连续虚拟孔径缩短，插值或矩阵补全又会引入额外假设。

嵌套阵与互质阵最初主要在窄带阵列模型下发展，原始方法见 [Pal 与 Vaidyanathan 的嵌套阵论文](#)与 [Vaidyanathan 与 Pal 的互质阵论文](#)。

语音宽带、混响和频率相关阵列流形会增加处理难度。因此实际使用前应在目标频带和房间条件下验证，不能只按理论差集长度选型。

稀疏阵与分布式阵不是同一概念。稀疏阵强调只占用密集候选网格中的部分位置，位置可以非均匀，也可以是带空位的等间距子集；分布式阵由多个独立设备组成，除了几何布局，还要处理节点标定、独立时钟和通信。

上述几何分析默认通道和位置准确。实际系统还需要通过标定减小增益、相位、耦合和位置误差。

### 3.4 阵列校准：麦克风个个不一样时怎么办

前面的理想公式假设各通道增益和相位一致、阵元位置准确，并忽略壳体散射、声学耦合和电串扰。实际偏差会使导向模型与观测不匹配。本节把常见偏差写进模型，再说明怎样测量和补偿。

#### 3.4.1 增益相位自校准：利用未知声源的多位置观测

1. 增益相位自校准的思想。把每只麦的响应误差写成一个复数：增益误差是幅度缩放，相位误差是额外旋转，合起来第  $m$  路的实际增益是  $(1 + \Delta g_m)e^{j\Delta\phi_m}$ ，理想值是 1。

导向矢量  $\vec{a}(\theta)$  的每个分量都会乘上这个误差，因此 MUSIC 谱峰会变宽或偏移，波束零陷也会变浅。麦克风阵列实测校准的一个原始例子见 [Sachar、Silverman 与 Patterson 2004](#)。

自校准可以不用已知方向的专用声源。常见做法是交替估计：先固定通道误差估方向，再固定方向估各麦的复增益，循环到目标函数收敛。

这种方法依赖可辨识条件。若只有一个固定方向，声源相位、传播相位和麦克风相位误差可能互相混淆；加入多个充分分散的方向、频点或几何约束后，才有机会分离这些未知量。具体需要多少方向取决于模型参数和约束，不能用一条固定数字概括。

复增益标定处理单通道幅相偏差；跨通道电串扰可在一定线性近似下写成频率相关混合矩阵，壳体散射则通常还随入射方向变化。

#### 3.4.2 互耦补偿：把串音矩阵抵消掉

2. 耦合与串扰补偿。电路走线或器件间的线性串扰，在近似不随声源方向变化时可写成频率相关矩阵  $\mathbf{C}(f)$ ，实际导向矢量变为  $\mathbf{C}(f)\vec{a}(f, \theta)$ 。

壳体绕射和散射直接改变声场，通常应写成方向相关的实测流形  $\vec{a}_{\text{meas}}(f, \theta)$ ，或在确有依据时用  $\mathbf{C}(f, \theta)\vec{a}(f, \theta)$  表示，不能无条件并入固定  $\mathbf{C}(f)$ 。可用已知方向的测量拟合模型，也可直接把实测阵列流形存入系统。

若对固定混合矩阵显式求逆， $\mathbf{C}(f)$  条件数很大时会放大噪声，因此通常需要正则化，而不是无条件左乘精确逆矩阵。依赖深零陷的差分或超指向设计通常比 DSB 更容易受失配影响。

耦合矩阵描述通道间混合，但不能替代麦克风坐标标定。位置误差会直接改变传播相位。

#### 3.4.3 位置自标定：有锚测绘、无锚边走边建图

3. 位置自标定。8 kHz 的波长约为 4.3 cm，2 mm 位置误差对应的相位误差为  $2\pi \times 0.002/0.0429 \approx 0.29$  rad，即约  $17^\circ$ ；低频下同一位置误差造成的相位偏差较小。

位置标定有两类方法：

- 有锚点标定：在多个已知位置播放信号，由 TDOA 反解麦克风坐标；
- 无锚点自标定：同时估计声源位置与麦克风位置，要求声源运动或多位置观测满足可辨识条件。

无外部锚时，观测至少不能区分整体平移、旋转和镜像；只用方向观测时还可能不能确定尺度。实现中要固定参考麦克风、坐标轴和尺度，或加入已知距离，才能报告唯一的绝对坐标。相关可辨识性分析可参见 [Kuang 等, ICASSP 2013](#)。

分布式阵列还需同时估计节点时钟关系（§ 10.2），否则 TDOA 会包含系统偏差。

下表汇总不同失配首先影响的量、误差尺度和补偿方法。

#### 3.4.4 失配灵敏度表：先坏哪、坏多少

4. 失配灵敏度表：

| 失配类型       | 典型量级          | 最先坏掉的东西     | 数量感                                                                                                              | 补救                             |
|------------|---------------|-------------|------------------------------------------------------------------------------------------------------------------|--------------------------------|
| 增益失配       | 1% (约 0.1 dB) | 差分/超指向的零陷深度 | 本例残差相对单麦为 -40 dB; 波束图归一到前方响应后约 -31 dB (§ 3.1 算例 3-1 第 5 步)                                                       | 产线逐只配对、出厂标定系数                  |
| 相位失配       | 2° (高频段)      | 高频指向精度      | 2° 相位误差在 8 kHz 约等于 0.24 mm 等效位置误差, MUSIC 峰偏、旁瓣抬高                                                                 | 同增益, 一起标                       |
| 位置误差       | 2 mm          | 高频导向矢量      | 8 kHz 下约 17° 相位误差; 1 kHz 下约 2°。后者对常规主瓣可能较小, 但在依赖精确相消的零陷中仍可能显著: 两路残余幅度约 $2 \sin(1^\circ) = 0.0349$ , 相对单路约 -29 dB | 有锚/无锚位置标定                      |
| 耦合与壳体散射    | 随结构、频率而变      | 零陷深度、旁瓣电平   | 不能仅由一个间距门槛判断; 须比较自由场模型与实测流形                                                                                      | 使用实测流形, 或正则化估计 $\mathbf{C}(f)$ |
| 时钟漂移 (分布式) | 晶振几十 ppm      | TDOA 系统性偏差  | 跑 1 小时即差约 0.18 秒 (百毫秒级), 是百微秒级时差的上千倍 (§ 2.1、§ 10.2)                                                              | 共时钟/在线同步补偿                     |

位置误差造成的相位偏差随频率增大; 增益漂移、耦合和噪声则未必遵循同一单调关系。依赖精确相消的零陷和超指向设计通常最敏感。

固定一体式阵列常用出厂标定。分布式阵列还需处理节点位置、时钟偏移和采样率漂移, 并根据设备移动或时钟变化决定是否在线更新。

工程流程通常分三步:

1. 在受控声场中测各通道的频率响应和阵列流形;
2. 把补偿参数写入设备;
3. 用若干已知方向复测主瓣、旁瓣和零陷。

若设备结构、温度或节点位置会变化, 还要定义重新标定的触发条件。采用逐只通道修正、整机流形查表还是在线联合估计, 取决于硬件一致性、存储、算力和使用环境。

标定结果不能只保存一组没有上下文的复数。最小标定记录应包括设备或阵列序列号、麦克风通道顺序、坐标系与长度单位、参考麦克风、采样率、频率网格、复增益或实测流形、测量温湿度、测量日期、算法版本和原始记录校验值。加载时先核对通道数、设备身份、坐标维度和频率网格; 任一项不匹配时应拒绝套用, 而不是截断或重排数组。产线验收还要用未参与拟合的方向复测目标响应、旁瓣或零陷, 并把允许误差写成设备规格, 而不是沿用某个教学算例的门槛。

[geometry.py](#) 提供统一的平面波和球面波导向矢量, 正角、参考麦克风和声速约定与 § 2.1 一致。它是校准前后的共同计算基线, 不包含针对某种硬件的自动校准器。对应测试会检查正角时  $\tau_{21} < 0$ 、导向相位为正, 以及近场幅度和传播距离; 这样可在替换实测流形前先排除坐标轴、通道顺序和傅里叶符号错误。

几何决定可观测的空间信息, 标定决定理论模型能否用于实测数据。第 4 章将从 GCC-PHAT 开始介绍声源定位算法。

### 本章练习

1. 协同阵数差集验证: 6 麦均匀线阵位置记为  $\{0, 1, 2, 3, 4, 5\}$  (单位  $\lambda/2$ ), 列出全部麦对位置差, 验证连续差集是  $\{0, \pm 1, \dots, \pm 5\}$ 、共 11 个有符号滞后; 再对嵌套阵  $\{0, 1, 2, 3, 7, 11\}$  做一遍, 验证是  $\{0, \pm 1, \dots, \pm 11\}$ 、共 23 个连续滞后。为什么还不能直接说它能分辨 22 个声源?

答案要点: 这些数是二阶统计量中的有符号滞后, 不是 23 路独立快拍。必须先按滞后平均并构造满足结构约束的虚拟协方差, 必要时再做空间平滑。可分辨源数由平滑后矩阵的维数和秩、源相关性、信噪比及快拍数共同决定, 不能直接用 23 减 1。

2. 栅瓣与挡板二选一: 7.5 cm 环径的 6 麦圆环 (§ 3.2 算例 3-3), 若把工作频率推到 8 kHz, 会发生什么? 挡板 (规律 3) 又是在补哪一段的短板?

答案要点: 8 kHz 波长约 4.3 cm, 半波长约 2.1 cm, 小于 3.75 cm 相邻麦距, 已经不满足全视场无混叠的充分条件。圆阵是否在某一转向出现等高歧义, 要看完整几何和宽带融合, 不能只套 ULA 的单一栅瓣角公式。挡板会以频率和方向相关的方式改变

幅相响应；若模型使用得当，这些额外差异可帮助消歧，但它不是固定地把低频下限移动某个倍频程。

---

## 第 4 章 · 声源定位 (DOA 估计)

### 4.1 总览：四大类思路

声源定位算法

└—— A. 两阶段法 (到达时间差, Time Difference of Arrival, TDOA) : 先测时延, 再算位置

|   └—— GCC 加权互相关 (SCOT / Roth / PHAT / ML)

|   └—— SRP-PHAT (全阵列麦对累积扫描)

|   └—— 多麦对几何解算 (LS, least squares, 最小二乘 / 泰勒迭代)

└—— B. 波束扫描类: 逐个扫描候选方向并比较输出功率

|   └—— Bartlett 波束形成谱

|   └—— Capon / MVDR (最小方差无失真响应) 谱

└—— C. 子空间类 (超分辨)

|   └—— 多重信号分类 (Multiple Signal Classification, MUSIC) /

|       借助旋转不变技术估计信号参数 (ESPRIT) (相干源需配空间平滑预处理)

└—— D. 稀疏重构与深度学习类

|   └—— L1-SVD / SBL (压缩感知; SBL = sparse Bayesian learning)


|   └—— DNN (deep neural network, 深度神经网络; SRP-CNN、GCC-PHAT+CRNN、ACCDIA)

图 11 在同一个两源仿真 (−20°、30°) 中比较 Bartlett、Capon 和 MUSIC。条件为 8 元半波长 ULA、每阵元总输入 SNR 20 dB、400 个快拍，两源相隔 50°。这个较容易的条件只展示三种谱形，不检验最小可分辨角度。

Bartlett 按标准空间谱计算。Capon 在样本协方差上使用相对对角加载  $\eta = 10^{-6}$ ，即  $\hat{\mathbf{R}} + \eta \text{tr}(\hat{\mathbf{R}})\mathbf{I}/M$ 。MUSIC 给出伪谱，峰高不是功率。

只有在源间隔、信噪比、快拍数、源数和阵列失配都明确时，才能用重复试验比较分辨成功率。

图11 两信号源( $-20^\circ$ ,  $30^\circ$ ) DOA空间谱估计对比 (8元ULA, 每阵元总输入SNR=20dB, 400快拍, 模拟)



图示说明：比较三类方法的谱形，不比较图中的绝对峰高。Bartlett 的分辨率受阵列孔径限制；Capon 利用协方差逆矩阵抑制其他方向；MUSIC 依赖信号子空间与噪声子空间的正交性。谱峰个数也不能无条件当作源数：旁瓣、相干多径和有限快拍都可能产生假峰或合并真峰，源数估计要按下一节的方法独立完成。

#### 4.1.1 源数估计：确定信号子空间维数

子空间类（MUSIC、ESPRIT）必须先确定源数  $K$ 。 $K$  定错后，信号子空间与噪声子空间的切分位置也会错。

MUSIC 还要满足  $K < M$ ，否则没有非零维噪声子空间可供正交检验。ESPRIT 的两个子阵也都必须至少有  $K$  维，实际通常保留更多阵元以降低有限快拍误差。下面给出两种常用估计方法。

方法 1：特征值间隙（eigen-gap）。把固定频点  $f_k$  的协方差矩阵  $\hat{\mathbf{R}}(f_k)$ （读作“R 帽”，帽子表示用有限快拍估计出来的版本）的特征值从大到小排列。前  $K$  个特征值包含信号与噪声功率，后面  $M - K$  个在白噪声模型下接近  $\sigma^2$ 。

算例 4-4 的无噪声单源给出  $3, 0, 0$ ，因此  $K = 1$ 。实际数据中，低信噪比或快拍不足会缩小相邻特征值之间的间隔；可比较相邻特征值的比值或差值，并把最大间隙所在位置作为候选分界。这种方法计算简单，但在低信噪比或快拍不足时不稳定。

方法 2：信息准则（AIC/MDL）。增加候选源数通常会改善数据拟合，同时也会增加模型复杂度。AIC（Akaike information criterion，赤池信息准则）和 MDL（minimum description length，最小描述长度）用不同的复杂度惩罚项平衡这两部分，并取准则

值最小的候选  $K$ 。Wax 与 Kailath 的阵列源数信息准则原文，式(7) – (8)给出了白噪声、独立快拍模型下基于最小特征值算术均值与几何均值之比的打分式。实现时必须核对复/实数据、快拍数和惩罚项口径；低 SNR、快拍不足、彩色噪声或相干源导致的信号协方差降秩都会造成误判。

信噪比高、快拍充足时，可以先看特征间隙；需要自动选择  $K$  时可用 MDL，并用特征值谱交叉检查。相干源场景还存在一个实际循环：空间平滑要按候选源数选择子阵长度，而源数又要从平滑后的谱估计。可先给出源数上界  $K_{\max}$ ，对候选  $K$  和子阵长度联合扫描，再检查结果对参数是否稳定。对  $M$  元均匀线阵（Uniform Linear Array, ULA）做前向空间平滑时，若切成  $L$  个长度为  $P = M - L + 1$  的重叠子阵，要分辨  $K$  个完全相干源，至少需要  $L \geq K$  且  $P > K$ 。这两个条件同时限制可分辨源数和剩余有效孔径。Shan、Wax 与 Kailath 的空间平滑分析。

子空间法需要源数，GCC-PHAT 不需要。下一节先从双通道时延估计讲起。

## 4.2 GCC-PHAT: “对齐两段录音，找最吻合的错位”

本章沿用 § 2.1 ~ § 2.3: 麦 1 在  $x = 0$ ，麦 2 在  $+x$ ；正横为  $0^\circ$ ，正角朝麦 2； $\vec{u}$  从阵列指向声源，传播方向为  $-\vec{u}$ ； $\tau_{ij} = t_i - t_j$ 。

采用前向核  $e^{-j2\pi ft}$  时，

$$\tau_{m1} = -(\vec{r}_m - \vec{r}_1)^\top \vec{u} / c,$$

$$a_m = e^{-j2\pi f \tau_{m1}} = e^{+j2\pi f (\vec{r}_m - \vec{r}_1)^\top \vec{u} / c}.$$

因此正角双麦有  $\tau_{21} < 0$ 、 $\tau_{12} > 0$ 。

直觉：把第二路录音左右平移，平移到与第一路最像的那个错位量就是时间差。

时域定义。两路离散信号  $x_1(n)$ 、 $x_2(n)$ ，定义时延  $\tau$  处的互相关值（ $\tau$  以采样点为单位，取遍  $\dots, -2, -1, 0, 1, 2, \dots$ ）：

$$R(\tau) = \sum_n x_1(n) x_2(n - \tau).$$

把  $x_2$  往右挪  $\tau$  格，和  $x_1$  上下对齐，逐点相乘再求和。加总越大，这个错位下两路越像。最后取峰： $\hat{\tau} = \arg \max_{\tau} R(\tau)$ （ $\arg \max$  返回峰的位置，不是峰高）。直接计算需要  $O(N^2)$  次乘加；频域实现可把复杂度降到  $O(N \log N)$ 。

频域等价式（相关定理）：时域逐点算出的整条  $R(\tau)$ ，等于频域共轭相乘后再作逆变换——

$$R(\tau) = \text{IFFT}\{X_1(f)X_2^*(f)\}$$

连续时间形式写成积分，见下文的快速实现公式。

两边是同一个相关函数，只是计算路线不同。本文把  $\tau_{12} > 0$  定义为“信号到麦 1 比到麦 2 晚”，即  $x_1(t) = x_2(t - \tau_{12})$ 。在这个定义下， $\text{ifft}(X_1 \cdot \text{conj}(X_2))$  的峰位是  $+\tau_{12}$ ；若交换两路，峰位变成  $-\tau_{12}$ 。实现和论文若采用不同的信号次序或相关定义，符号也会随之改变。


频域实现：用一次 IFFT 计算整条相关曲线。两路信号为  $x_1, x_2$ ， $X_1(f)$ 、 $X_2(f)$  是它们在第  $f$  个频点上的复数谱值，都是标量。运算顺序是先对  $X_2(f)$  取共轭得到  $X_2^*(f)$ ，再与  $X_1(f)$  逐频点相乘：

$$R_{x_1 x_2}(\tau) = \int \Phi(f) X_1(f) X_2^*(f) e^{j2\pi f \tau} df, \quad \hat{\tau} = \arg \max_{\tau} R(\tau).$$

代码里就是 `ifft(Φ · X1 · conj(X2))` 后找最大值索引。快速傅里叶变换（Fast Fourier Transform, FFT）负责计算整条相关曲线，`arg max` 负责从曲线上读峰位，两者是前后两步。

复杂度从  $O(N^2)$  降到  $O(N \log N)$ 。实际加速比还取决于帧长、补零长度、FFT 库和硬件，不能只由渐近复杂度给出固定倍数。

图33 互相关的两种等价实现（GCC 中  $\Phi(f)=1$  的特例；非 PHAT 加权）



图示说明：图33(a)给出零填充整数延迟信号；(b)按定义逐个 lag 直接求和；(c)计算频域乘积  $X_1 X_2^*$ ；(d)用零填充 FFT 和 IFFT 得到线性互相关。时域与频域由独立代码计算，图中给出最大数值误差。该图对应  $\Phi(f) = 1$  的普通互相关，不包含 PHAT 加权。

线性相关与补零：FFT 算的是圆周相关（序列尾部会卷绕到开头），帧不够长时两端的  $R(\tau)$  会被卷绕项污染；工程上补零到  $N \geq N_1 + N_2 - 1$ （两帧长度之和减一）再做 FFT。下文 8 点手算例因脉冲远离边缘、考察点无混叠，所以未补零也能得到相同结果；一般输入仍须补零。

符号说明：这里的  $R(\tau)$  是时延  $\tau$  的标量互相关函数；后文 § 4.5 起的  $\hat{\mathbf{R}}(f_k)$  是频点  $f_k$  上的  $M \times M$  协方差矩阵，以黑体和估计符号相区别。

为什么相位里藏着时延：沿用“麦 1 晚到”为正的定， $x_1(t) = x_2(t - \tau_0)$ ，因此  $X_1(f) = X_2(f)e^{-j2\pi f\tau_0}$ 。于是

$$X_1(f)X_2^*(f) = |X_2(f)|^2 e^{-j2\pi f\tau_0},$$

相位  $\angle\{X_1 X_2^*\} = -2\pi f\tau_0$  的斜率是  $-2\pi\tau_0$ 。例如  $\tau_0 = 58.3 \mu s$  时，1 kHz 和 2 kHz 处的相位分别约为  $-0.366 \text{ rad}$  和  $-0.733 \text{ rad}$ 。逆变换在  $\tau = \tau_0$  处乘上  $e^{j2\pi f\tau_0}$ ，恰好抵消这条负斜率，各频点同相相加形成峰。

PHAT 把互谱除以其幅度，使每个保留频点只贡献单位幅度的相位项。理想单时延模型下，这样可以减少谱包络对相关峰形的展宽。

PHAT 不会修复混响或噪声造成的错误相位，还可能放大原本很弱、信噪比很低的频点。因此实现时通常在分母加  $\epsilon$ ，并可配合频带筛选或可靠度加权。

算例 4-Obis: 8 点脉冲手算——时域与频域结果一致

下面用最简单的脉冲分别计算时域相关和频域等价式，核对峰值位置与数值。

设定:  $N = 8$ , 序列 ( $n = 0 \dots 7$ ) 为

- $x_1 = [0, 0, 3, 0, 0, 0, 0, 0]$ , 3 在  $n = 2$  处, 即  $x_1$  比  $x_2$  晚到 2 拍;
- $x_2 = [2, 0, 0, 0, 0, 0, 0, 0]$ , 2 在  $n = 0$  处。

线性互相关定义为  $R(\tau) = \sum_n x_1(n)x_2(n - \tau)$ , 越界按 0 处理。考察  $\tau = 0/1/2$  时, 下标  $2 - \tau = 2/1/0$  都落在序列范围内, 因此线性相关与 8 点圆周相关在这三点没有回绕混叠、数值相等。一般情况仍要补零到  $N \geq N_1 + N_2 - 1$ , 见上文补零提醒。

时域计算: 逐  $\tau$  算  $R(0)$ 、 $R(1)$ 、 $R(2)$ , 取最大值。 $x_1$  只在  $n = 2$  处非零 (值为 3), 加总只剩一项:  
 $R(\tau) = 3 \cdot x_2(2 - \tau)$ 。 $R(0) = 3 \cdot x_2(2) = 3 \times 0 = 0$ ;  $R(1) = 3 \cdot x_2(1) = 3 \times 0 = 0$ ;  
 $R(2) = 3 \cdot x_2(0) = 3 \times 2 = 6$  (最大值,  $\hat{\tau} = 2$ , 即  $x_1$  晚到 2 个采样点, 峰在 +2, 与设定一致)。

频域手算: DFT 共轭乘 + IDFT。记  $W = e^{-j2\pi/8}$ , DFT 定义  $X[k] = \sum_n x[n]W^{kn}$ 。 $x_2$  只有  $n = 0$  项, 所以  $X_2[k] = 2$ ,  $k = 0 \dots 7$  全是 2。

$x_1$  只有  $n = 2$  项, 因此  $X_1[k] = 3W^{2k} = 3e^{-j\pi k/2}$ 。逐个写出:

$$X_1 = [3, -3j, -3, 3j, 3, -3j, -3, 3j],$$

$$X_2^* = [2, 2, 2, 2, 2, 2, 2, 2],$$

$$G[k] = X_1X_2^* = [6, -6j, -6, 6j, 6, -6j, -6, 6j]。$$

IDFT 为  $r[\tau] = \frac{1}{8} \sum_k G[k]e^{+j2\pi k\tau/8}$ 。分别计算三个候选点:

1.  $\tau = 0$  时,  $\frac{1}{8}(6 - 6j - 6 + 6j + 6 - 6j - 6 + 6j)$  的实部和虚部各自相消, 得  $\mathbf{r}[0] = 0 = R(0)$ ;
2.  $\tau = 1$  时,  $G[k] \cdot e^{j2\pi k/8} = 6(e^{-j\pi/4})^k$ 。 $k = 0 \dots 7$  构成公比不等于 1 的完整周期几何级数, 配对相消, 得  $\mathbf{r}[1] = 0 = R(1)$ ;
3.  $\tau = 2$  时,  $G[k] \cdot e^{j2\pi k \cdot 2/8} = 6e^{-j\pi k/2} \cdot e^{+j\pi k/2} = 6$ 。8 项全是 6, 得  $r[2] = 48/8 = 6 = R(2)$ 。

在  $\tau = 2$  处, 各频点的相位因子精确抵消, 8 个实数 6 同相相加; 其他两个候选时延的正负项相消。

时域与频域结果对照:  $\tau = 0$  处时域和频域均为 0;  $\tau = 1$  处均为 0;  $\tau = 2$  处均为最大值 6, 因此两种计算都得到  $\hat{\tau} = 2$ 。

本例的 PHAT 结果:  $|G[k]| = 6$  在所有频点相等, 所以归一化不改变相对频谱。PHAT 谱  $\Psi[k] = G[k]/|G[k]| = [1, -j, -1, j, 1, -j, -1, j]$ , IDFT 在  $\tau = 2$  处为 1, 其余位置为 0。理想单时延、无噪条件下峰位不变; 实际数据中, PHAT 改变各频点权重, 峰位仍会受噪声和混响影响。

核心是加权函数  $\Phi(f)$  的选择:

| 加权                                          | 公式                                  | 特点                                                                                         |
|---------------------------------------------|-------------------------------------|--------------------------------------------------------------------------------------------|
| 互相关 CC                                      | $\Phi = 1$                          | 抗噪差, 峰被噪声淹没                                                                                |
| Roth                                        | $1/(\hat{G}_{11} + \varepsilon)$    | 用通道 1 的平滑自功率谱对互谱加权; 结果与通道次序有关, 谱估计很小时需要 $\varepsilon$ 避免过度放大                               |
| SCOT (Smoothed Coherence Transform, 平滑相干变换) | $1/\sqrt{\hat{G}_{11}\hat{G}_{22}}$ | 用两路自功率谱估计的几何平均对互谱作对称归一化; $\hat{G}_{11}$ 、 $\hat{G}_{22}$ 可由时间平均、频率平滑或 Welch 方法估计, 必须记录具体口径 |
| PHAT (相位变换)                                 | $1/( X_1X_2^*  + \varepsilon)$      | 归一化互谱幅度、保留相位; 理想单时延下峰更尖, 但不会消除错误相位, 低信噪比频点需筛选或再加权                                          |
| ML                                          | 由信号与噪声统计模型决定                        | 只在指定概率模型与参数假设下谈最优; 不能用一条通用权重概括                                                             |

单帧直接代入时， $\sqrt{|X_1|^2|X_2|^2} = |X_1 X_2^*|$ ，SCOT 与 PHAT 的分母数值相同。使用统计谱估计后，SCOT 的分母来自两路自谱，而 PHAT 的分母来自互谱幅度；两者的偏差和方差取决于平均窗、频带、信噪比及谱估计方法，不能笼统断言哪一个始终更稳。

由时延换算角度： $\hat{\theta} = \arcsin(c\hat{\tau}/d)$ 。先检查  $|c\hat{\tau}/d| \leq 1$ ：轻微超限若能由已验证的数值舍入界解释，可限幅后计算；明显超限说明该峰不满足双麦平面波几何，应判为野值或低置信度，不能一律吸附到端射方向。


这个换算怎么来的：几何推导见 § 2.1 “时差的几何来源”。平面波以角  $\theta$  斜入射，路程差  $\Delta = d \sin \theta$ （图12(c)），因此  $\hat{\tau} = d \sin \theta / c$ ； $\theta$  从正横方向起算。若论文把角度定义为相对麦克风连线，则同一关系写成  $\hat{\tau} = d \cos \theta / c$ 。双麦只给一个标量时延，三维中相容方向构成以连线为轴的锥面；要解除该模糊，需要增加不共线的麦克风或加入其他先验。

两个实用细节：


1. 16 kHz 下一个采样点为  $62.5 \mu\text{s}$ 。对 4 cm 间距，从正横方向的 0 延迟跳到 1 个采样点对应  $\arcsin(343 \times 62.5 \mu\text{s} / 0.04) \approx 32.4^\circ$ ，而且越靠近端射方向，同样的时延误差造成的角度误差越大。实际系统要对相关峰插值或拟合相位斜率，得到亚采样时延。
2. PHAT 提高了相位的相对权重，因此麦克风相位响应不一致会直接造成定位偏差（见 § 10.2）。

图12 GCC-PHAT 声源定位原理：亚采样时延估计（模拟）


(a) 两路信号（放大 0.5 ms 窗口）



(b) GCC-PHAT (16×时延网格插值)



(c)  $\theta = \arcsin(c \cdot \tau / d) = \arcsin(0.5) = 30^\circ$   
( $\theta$  自正横方向起算)



图示说明：图 12 (a) 的两路波形设定为  $d = 4 \text{ cm}$ 、 $\theta = 30^\circ$ ，对应  $\tau_0 \approx 58.3 \mu s$ ，即 16 kHz 下约 0.933 个采样点。

图 12 (b) 将两路固定噪声样例做 16 倍时延网格插值后计算 GCC-PHAT，峰值落在  $58.59375 \mu s$ ，即 0.9375 个原始采样点；虚线标出  $58.3 \mu s$  真值。图 12 (c) 把时差乘声速得到路程差，再除以间距得到角度正弦， $\theta$  从正横起算，与 § 2.1 约定一致。

本次固定样例的估计接近真值，但单个样例不能代表误差分布。

算例：GCC-PHAT 完整数字链 ( $d = 4 \text{ cm}$ 、 $\theta = 30^\circ$ )：按 § 2.1 几何关系，真值时延

$\tau_0 = d \sin \theta / c = 0.04 \times 0.5 / 343 \approx 58.3 \mu\text{s}$ ；16 kHz 下 1 个采样点 =  $62.5 \mu\text{s}$ ，故真值在  $58.3 / 62.5 \approx 0.933$  格。直接取整读峰只能得到 1 格，对应  $\arcsin(343 \times 62.5 \mu\text{s} / 0.04) \approx 32.4^\circ$ 。

图 12 的脚本不是三点抛物线拟合，而是对互谱补零，把 GCC-PHAT 的时延网格细化到  $62.5 / 16 \approx 3.91 \mu\text{s}$ ，再在相关序列上取最大值。固定随机种子的噪声样例得到  $58.59375 \mu\text{s}$ ，即 0.9375 格；换算角度为

$$\hat{\theta} = \arcsin\left(\frac{343 \times 58.59375 \times 10^{-6}}{0.04}\right) \approx 30.16^\circ.$$

该估计比  $30^\circ$  真值高约  $0.16^\circ$ 。这个固定样例说明时延网格插值能避免只在整数采样点上搜索；实际偏差仍取决于信号带宽、观测长度、噪声、混响和插值方法，需要在多次试验或实测数据上统计。

优缺点：频域实现的主导运算量为  $O(N \log N)$ ；是否满足实时要求仍取决于窗长、帧移、麦对数量、FFT 库、硬件、线程、缓存和计时范围，不能由复杂度记号直接推出。但一对麦每帧通常只读一个主峰，多源时会出现多个峰且跨麦对难以配对。强混响或低信噪比还会使峰展宽或选错。GCC 加权家族的定义、统计模型和最大似然权重见 Knapp 与 Carter, *IEEE TASSP*, 1976。

参数口径反例： $T_{60}$  不能单独推出定位趋势。反射会把多个延迟副本叠到直达声上，使相关背景抬高、主峰展宽并出现旁峰；但一张合成图的变化方向还取决于如何归一化反射尾。

图 13 把两个因素分开控制：每路冲激响应的直达能量固定为 1，随机指数数尾分别归一到 DRR=+6、0、-6 dB；尾长取  $1.1T_{60}$ ，考察  $T_{60} = 0.1、0.4、0.8 \text{ s}$ 。采样率为 16 kHz，帧长约 64 ms，无额外传感器噪声，每个  $T_{60} \times \text{DRR}$  条件做 150 次固定种子的试验。

互谱按  $X_1 X_2^*$  定义。第二路比第一路晚 9 点时， $\tau_{12} = -9$  点，真峰 lag 也为 -9。估计峰落在真值  $\pm 1$  点内算正确。

正确率给出 Wilson 95% 区间；峰值对比度采用  $\max g / \text{median } |g|$ ，汇报中位数和四分位区间。


这个受控试验把每条随机尾的总能量固定在目标 DRR，并为两个通道独立生成随机尾。因此，增大  $T_{60}$  会把同一总能量分散到更长的时间；在 64 ms 短帧内，瞬时尾能量可能反而降低，所以正确率和峰对比度不必随  $T_{60}$  单调变差。这不能解释为“混响更长有利于 GCC-PHAT”。

独立通道随机尾没有模拟真实晚期混响随麦距和频率变化的空间相干性。这些随机尾不是几何房间的镜像法 RIR，也不是实测数据。

图 13 只比较该说明模型内两个因素对峰统计量的影响，不能外推绝对性能。

图13 GCC-PHAT 的两因素实验：随机尾时长  $T_{60}$  与尾能量 DRR

直达能量=1；两通道独立随机尾按目标 DRR 固定总能量；64 ms 帧；无加性噪声；本书仿真



图示说明：图13(a)在 DRR=0 dB 下比较三个  $T_{60}$  的固定种子单帧；(b)分别画出三种 DRR 下的正确率和 Wilson 95% 区间；(c)画峰值对比度的中位数和四分位区间。读图时应同时指定  $T_{60}$  与 DRR：前者控制尾的衰减时长，后者控制尾相对直达声的总能量。

双麦 GCC 只提供一个麦对时延。三维定位或多源场景通常需要 § 4.3 的 SRP-PHAT，联合多个麦对进行空间扫描。

### 4.3 SRP-PHAT：跨麦对累积空间响应

对空间中每个候选位置  $\vec{r}$ ：由几何算出“若声源在此，各麦对时延应是多少”  $\tau_{ij}(\vec{r})$ ，再查 GCC-PHAT 值并累加：

$$\hat{p} = \arg \max_{\vec{r}} \sum_{i < j} R_{x_i x_j}^{PHAT}(\tau_{ij}(\vec{r}))。 \tag{4-1}$$

其中  $\tau_{ij}(\vec{r}) = (\|\vec{r}_i - \vec{r}\| - \|\vec{r}_j - \vec{r}\|)/c$ ——候选点到麦  $i$  的距离减去到麦  $j$  的距离，再除以声速；几何意义即下文 § 4.4 的双曲线（等时差线）。

候选位置正确时，各麦对会在各自预测 TDOA 附近取得较大的 GCC-PHAT 值，累积得分随之升高；候选位置错误时，各麦对的取值通常无法同时达到峰值。扫描可扩展到三维网格，也可从空间响应图中寻找多个局部峰。多个峰是否对应真实声源，仍需结合最小峰距、置信度和跨帧一致性判断。

SRP-PHAT 把 PHAT 加权引入可控响应功率扫描的原始系统论述见 [DiBiase, Brown University 博士论文, 2000](#)。式(4-1)采用麦对 GCC-PHAT 在预测时延处求和的实现形式；搜索区域、网格间距、频带和插值共同决定响应图的离散化与峰形。

#### 算例 4-1：SRP-PHAT 的六麦对累积

下面用两个候选点计算预测时延，再比较六个麦对的累积得分。

设定：平面 4 麦矩形阵，坐标  $\vec{r}_1 = (0, 0)$ 、 $\vec{r}_2 = (4 \text{ cm}, 0)$ 、 $\vec{r}_3 = (0, 3 \text{ cm})$ 、 $\vec{r}_4 = (4 \text{ cm}, 3 \text{ cm})$ ；真实声源在  $\vec{p} = (2 \text{ m}, 1.5 \text{ m})$ ；声速  $c = 343 \text{ m/s}$ ，采样率  $f_s = 16 \text{ kHz}$ （1 个采样点 =  $1/f_s = 62.5 \mu\text{s}$ ，折合成路程  $c/f_s = 343/16000 = 0.0214375 \text{ m}$ ——后文所有“采样点”都靠这个数换算）。

第 1 步：算出“真实测量值”。声源在  $\vec{p}$ ，各麦到声源的距离由勾股定理 ( $d_i = \|\vec{p} - \vec{r}_i\|$ )：

| 麦 $i$ | 算式                                       | $d_i$ (m) |
|-------|------------------------------------------|-----------|
| 1     | $\sqrt{2^2 + 1.5^2} = \sqrt{6.25}$       | 2.500000  |
| 2     | $\sqrt{1.96^2 + 1.5^2} = \sqrt{6.0916}$  | 2.468117  |
| 3     | $\sqrt{2^2 + 1.47^2} = \sqrt{6.1609}$    | 2.482116  |
| 4     | $\sqrt{1.96^2 + 1.47^2} = \sqrt{6.0025}$ | 2.450000  |

( $\vec{r}_4$  那行数值凑得正好： $6.0025 = 2.45^2$  恰好开方开尽，方便手算核对。)

麦对  $(i, j)$  的真实 TDOA（到达时间差）折成采样点：

$$\tau_{ij} = \frac{d_i - d_j}{c} f_s = \frac{d_i - d_j}{0.0214375}。$$

（单位：采样点。）

例如麦对  $(1, 2)$ ： $\tau_{12} = (2.500000 - 2.468117)/0.0214375 = 0.031883/0.0214375 \approx +1.4873$  个采样点——物理含义：声波到麦 1 的路程比到麦 2 长 3.19 cm，所以麦 2 早到约 1.49 个采样点。这就是 GCC-PHAT（§ 4.2）在每对麦上实际测到的峰位置。全部 6 对的结果见下表“真值”列。

第 2 步：计算候选点的几何预测。假设声源在候选点  $\vec{r}$ ，预测每对麦的时延  $\tau_{ij}(\vec{r}) = (\|\vec{r}_i - \vec{r}\| - \|\vec{r}_j - \vec{r}\|) f_s / c$ ，再读取相应时延处的 GCC 值。

- 候选点 A =  $(2, 1.5)$ （就是真源）：距离与第 1 步完全相同，预测的  $\tau_{ij}$  与真值逐对相等；
- 候选点 B =  $(0.5, 0.5)$ （离阵列很近的错误点）： $d_1 = \sqrt{0.5^2 + 0.5^2} = 0.707107$ 、 $d_2 = \sqrt{0.46^2 + 0.5^2} = 0.679412$ 、 $d_3 = \sqrt{0.5^2 + 0.47^2} = 0.686222$ 、 $d_4 = \sqrt{0.46^2 + 0.47^2} = 0.657647 \text{ m}$ 。

第 3 步：对比表（单位均为采样点；“错位” = 候选点预测值 - 真值）：

| 麦对 $(i, j)$ | 真值 = A 的预测 | B 的预测   | B 的错位   |
|-------------|------------|---------|---------|
| (1, 2)      | +1.4873    | +1.2919 | -0.1954 |
| (1, 3)      | +0.8342    | +0.9742 | +0.1400 |
| (1, 4)      | +2.3324    | +2.3071 | -0.0252 |
| (2, 3)      | -0.6530    | -0.3177 | +0.3354 |
| (2, 4)      | +0.8451    | +1.0152 | +0.1701 |
| (3, 4)      | +1.4981    | +1.3329 | -0.1652 |


第 4 步：由时延偏差计算得分。为便于手算，这里用理想全带、无窗截断条件下的 sinc 峰模型：真实时延处取值 1，偏离  $\Delta\tau$  个采样点后取  $\sin(\pi\Delta\tau)/(\pi\Delta\tau)$ 。实际 GCC 峰形还受带宽、窗函数、补零和混响影响，因此该模型只用于说明累积过程。

- 候选点 A：6 对麦的预测时延都等于真值，每对贡献 1，SRP 得分 =  $6 \times 1 = \mathbf{6.0000}$ ；
- 候选点 B：6 对的贡献分别为 0.9384、0.9681、0.9989、0.8250、0.9531、0.9557，合计 **5.6392**。各麦对的时延偏差不同，累积得分低于 A；
- 镜像方向候选点  $(-1, 1.5)$  的六对贡献约为 0.12、0.83、0.10、0.05、0.86、0.12，合计约 2.08。其中多组预测时延已落到 sinc 主峰之外。

结果解释：候选点 B 虽然与真源相距较远，得分仍接近峰值，说明小孔径阵列的空间响应峰可能较宽。错位量以采样点计时，16 kHz 下 1 个采样点对应约 2.14 cm 的传播距离，因此实际系统常用亚采样插值（§ 4.2 细节①）。网格间隔、插值方式和 GCC 峰宽都会影响最终定位精度。

本手算采用 sinc 峰便于逐项计算；图 14 采用高斯 GCC 峰便于显示连续的等时差亮带。两者都在演示式(4-1)的麦对累积过程，数值不能相互代入。

图14 SRP-PHAT 定位过程（独立米级分布式阵列例）  
4 m × 3 m 四麦；源(5.5, 3.8) m；c=343 m/s；高斯峰 $\sigma=166.7 \mu\text{s}$ ；90×68网格



图示说明：图 14 是与前述厘米级手算独立的米级分布式阵列例。四麦坐标为  $(0, 0)$ 、 $(4, 0)$ 、 $(0, 3)$ 、 $(4, 3)$  m，真实声源为  $(5.5, 3.8)$  m，声速取 343 m/s。

图 14 (a) 给出几何和候选点；图 14 (b) 在  $x \in [-0.5, 7.0]$  m、 $y \in [-0.5, 5.2]$  m 的  $90 \times 68$  网格上扫描。每个麦对的理想高斯 GCC 峰标准差取  $1/6000 \text{ s} \approx 166.7 \mu\text{s}$ 。亮带对应单个麦对的近似等时差轨迹，多条亮带在真实声源附近相交。

色标是六个麦对 GCC 取值的平均数，不是实测声功率。峰宽还取决于设定的 GCC 峰宽和网格间隔。

计算口径：全网格计算量约随  $N_{\text{grid}}M(M-1)/2$  增长。网格间距只给出离散化误差的下限，实际误差还受孔径、混响、信噪比、标定和插值影响。工程上常先粗扫，再只在主峰邻域细扫；节省多少计算量取决于两级网格范围，不能脱离配置给出固定倍数。

SRP 的计算量随网格点数和麦对数增加。若已获得可靠且已配对的 TDOA，也可以采用 § 4.4 的几何解算，直接估计位置坐标。

## 4.4 两阶段法的几何解算

从时延到几何：一对麦克风测得时延差  $\tau_{ij}$ ，意味着声源到两麦的距离差为  $c\tau_{ij}$ 。平面上“到两定点距离差为常数”的轨迹是双曲线，三维中是双曲面。图14(b)用理想化高斯 GCC 峰给这些等时差轨迹赋予有限宽度，再累加六个麦对的分数；多条亮带在声源附近相交。

以麦 1 为参考，各麦对的 TDOA 构成方程组：

$$\|\vec{p} - \vec{r}_i\| - \|\vec{p} - \vec{r}_1\| = c\tau_{i1}, \quad i = 2..M。$$

- $\vec{p}$ : 待求声源位置，远场只需方向；
- $\vec{r}_i$ : 第  $i$  个麦的坐标，已知且依赖标定；
- 方程共  $M-1$  个。对一般近场非线性方程，二维至少需要 3 只不共线麦、三维至少需要 4 只不共面麦，且某些几何仍可能有多个候选解。方程数超过位置维数后可用最小二乘吸收测量误差；
- 下面的 Chan 线性化还引入参考距离这一附加未知量，因此其第一阶段无正则最小二乘在二维至少需要 4 只麦、三维至少需要 5 只麦，并要求线性方程组满列秩。

算例 4-2: TDOA 几何解算数值例——两个时延怎么变成一个方向

§ 4.4 给出了方程组  $\|\vec{p} - \vec{r}_i\| - \|\vec{p} - \vec{r}_1\| = c\tau_{i1}$ 。远场条件下它退化为非常简单的几何：每对麦给出方向的一个“方向余弦”分量。用具体数字走一遍。

设定：3 麦直角布置， $\vec{r}_1 = (0, 0)$ （参考麦）、 $\vec{r}_2 = (4 \text{ cm}, 0)$ 、 $\vec{r}_3 = (0, 4 \text{ cm})$ ；测得  $\tau_{21} = +0.0583 \text{ ms}$ 、 $\tau_{31} = +0.0825 \text{ ms}$ （按 § 4.4 的约定， $\tau_{i1}$  = 声波到麦  $i$  的路程减去到麦 1 的路程，再除以  $c$ ）。求声源方向。

第 1 步：时延折成路程差。

$$c\tau_{21} = 343 \times 0.0583 \times 10^{-3} = 0.0199969 \text{ m} \approx 2.00 \text{ cm}$$

$$c\tau_{31} = 343 \times 0.0825 \times 10^{-3} = 0.0282975 \text{ m} \approx 2.83 \text{ cm}$$

物理读法：声波到麦 2 比到麦 1 多走约 2.00 cm，到麦 3 比到麦 1 多走约 2.83 cm。

第 2 步：除以间距，得方向余弦的绝对值。远场平面波假设下，麦 1-2 连线（ $x$  轴）方向上的路程差就是  $d|u_x|$ （ $u_x$  是声源方向单位向量  $\vec{u}$  在  $x$  轴上的分量，即“方向余弦”），于是：

$$\frac{c\tau_{21}}{d} = \frac{0.0199969}{0.04} = 0.4999 \approx 0.5 \quad \Rightarrow \quad \theta_x = \arcsin(0.5) = 30.0^\circ$$

$$\frac{c\tau_{31}}{d} = \frac{0.0282975}{0.04} = 0.7074 \approx \frac{\sqrt{2}}{2} \quad \Rightarrow \quad \theta_y = \arcsin(0.7074) \approx 45.0^\circ$$

（这里  $\theta_x$  是从麦 1-2 连线的正横方向起算的角度，与 § 4.2 的约定一致。给定的两个  $\tau$  本身是四舍五入过的：精确的  $30^\circ$  对应  $\tau_{21} = 0.058309 \text{ ms}$ ，精确的  $45^\circ$  对应  $\tau_{31} = 0.082461 \text{ ms}$ ，保留 3 位有效数字正是题给数值。）

第 3 步：定符号。方向余弦的符号由时延的正负直接读出： $\tau_{21} > 0$  说明声波到麦 2 的路程更长，即声源在麦 1 那一侧、沿  $-x$  方向；同理声源沿  $-y$  方向。所以

$$u_x = -0.5, \quad u_y = -\frac{\sqrt{2}}{2} \approx -0.7071$$

第4步：一致性检查与第三个分量。方向余弦必须满足  $u_x^2 + u_y^2 + u_z^2 = 1$ 。先检查：  $u_x^2 + u_y^2 = 0.25 + 0.5 = 0.75 \leq 1$  ✓——若这一步算出大于1，说明时延测量有野值，方程无解，这是工程上最便宜的自检。于是

$$u_z = \pm\sqrt{1-0.75} = \pm 0.5$$

±号无法由数据决定：三只麦共面，平面上下两侧镜像的方向产生完全相同的TDOA——这正是 §3.1 所说平面阵“上下镜像模糊”的具体实例。取上半球  $u_z = +0.5$ 。

第5步：合成方位角与俯仰角。把  $\vec{u} = (-0.5, -0.7071, 0.5)$  投到阵列平面内：

$$\varphi = \text{atan2}(u_y, u_x) = \text{atan2}(-0.7071, -0.5) = -125.26^\circ。$$

(即  $234.74^\circ$ 。) 俯仰角  $\phi_{\text{el}} = \arcsin(u_z) = \arcsin(0.5) = 30^\circ$ 。

( $\text{atan2}$  是带象限判断的反正切：  $\arctan(0.7071/0.5) = \arctan(1.4142) = 54.74^\circ$ ，因  $u_x, u_y$  同为负，落在第三象限，即  $54.74^\circ - 180^\circ = -125.26^\circ$ 。)

第6步：代回几何模型验证。把这个方向代回平面波公式  $c\tau_{i1} = -\vec{u} \cdot \vec{r}_i$ ：

- $c\tau_{21} = -\vec{u} \cdot \vec{r}_2 = -(-0.5) \times 0.04 = 0.020000 \text{ m} \Rightarrow \tau_{21} = 0.020000/343 = 0.058309 \text{ ms} \approx +0.0583 \text{ ms}$  ✓
- $c\tau_{31} = -\vec{u} \cdot \vec{r}_3 = -(-0.7071) \times 0.04 = 0.028284 \text{ m} \Rightarrow \tau_{31} = 0.028284/343 = 0.082461 \text{ ms} \approx +0.0825 \text{ ms}$  ✓

完全回到给定值。

近场修正的量级：若声源位于  $L = 2 \text{ m}$  处的  $\vec{p} = 2\vec{u} = (-1, -1.4142, 1) \text{ m}$ ，按球面波精确计算得  $\tau_{21} = 0.0592 \text{ ms}$ 、 $\tau_{31} = 0.0830 \text{ ms}$ 。它们分别比远场结果大 1.5% 和 0.7%，说明不同麦对不能共用一个固定修正比例； $L = 10 \text{ m}$  时差异约为 0.3%。

本例阵列孔径为  $\sqrt{4^2 + 4^2} \approx 5.66 \text{ cm}$ ，2 m 已满足较大的距离孔径比，因此残余曲率误差处于百分比量级。

怎么解：方程带根号、非线性，有两条经典路线。

路线1：Chan 算法。把方程平方并重组为线性方程组。第一阶段把参考距离  $R_1 = \|\vec{p} - \vec{r}_1\|$  当作附加未知量，与位置一起求解；第二阶段再利用  $R_1$  与位置的平方关系做加权修正。

二维时未知量为  $(p_x, p_y, R_1)$ ，所以第一阶段至少要  $M - 1 \geq 3$ ，即 4 只麦；三维至少要 5 只麦。计数只是必要条件，还需阵列几何使矩阵满列秩、通道同步、TDOA 与麦对关联正确，并满足点声源近场模型。低噪声且误差模型匹配时，两步加权最小二乘可接近相应的 CRLB。Chan & Ho, IEEE TSP 1994

可跳过·进阶★★：平方消根号的线性化展开（以  $i = 2$  为例）

记  $R_1 = \|\vec{p} - \vec{r}_1\|$ 。原方程  $\|\vec{p} - \vec{r}_i\| = r_{i,1} + R_1$  两边平方得  $\|\vec{p}\|^2 - 2\vec{r}_i^\top \vec{p} + \|\vec{r}_i\|^2 = r_{i,1}^2 + 2r_{i,1}R_1 + R_1^2$ 。

又有  $R_1^2 = \|\vec{p}\|^2 - 2\vec{r}_1^\top \vec{p} + \|\vec{r}_1\|^2$ 。代入后， $\|\vec{p}\|^2$  在等式两边恰好相消。整理得

$$(\vec{r}_1 - \vec{r}_i)^\top \vec{p} - r_{i,1}R_1 = \frac{1}{2}(r_{i,1}^2 + \|\vec{r}_1\|^2 - \|\vec{r}_i\|^2)。$$

左边对未知量  $(\vec{p}, R_1)$  是线性的，右边全是已知量。把  $i = 2..M$  的行摞起来，即得线性方程组  $\mathbf{G} [\vec{p}^\top, R_1]^\top = \vec{h}$ 。

例如  $M = 3$ 、估计二维位置时，未知量  $(p_x, p_y, R_1)$  共 3 个，方程  $i = 2, 3$  只有 2 行， $\mathbf{G}$  是  $2 \times 3$  的矮胖矩阵。这就是为什么二维定位至少要 4 只麦，即三对时延：方程数  $M - 1$  必须不少于未知量个数。第一步最小二乘先解该线性方程组，第二步再用  $R_1 = \|\vec{p} - \vec{r}_1\|$  的平方关系加权修正一次。

以  $i = 2$  代入算例 4-2 的数验量纲： $\vec{r}_1 = (0, 0)$ 、 $\vec{r}_2 = (0.04, 0)$ 、 $r_{2,1} = 0.02 \text{ m}$ 。右边  $= \frac{1}{2}(0.02^2 + 0 - 0.04^2) = \frac{1}{2}(0.0004 - 0.0016) = -0.0006 \text{ m}^2$ ；左边  $(\vec{r}_1 - \vec{r}_2)^\top \vec{p} - 0.02R_1$  也是“米×米”量级，等式两边单位均为  $\text{m}^2$ 。

路线 2：泰勒级数迭代。从 SRP-PHAT 的粗解出发，在当前估计点  $\vec{p}_k$  把方程一阶展开，用最小二乘解修正量并更新：

$$\vec{p} \leftarrow \vec{p} + (\mathbf{J}^\top \mathbf{J})^{-1} \mathbf{J}^\top \boldsymbol{\varepsilon}。$$

令观测距离差为  $\vec{z} = [c\tau_{21}, \dots, c\tau_{M1}]^\top$ ，模型预测为  $\vec{h}(\vec{p})$ ，这里定义残差  $\boldsymbol{\varepsilon} = \vec{z} - \vec{h}(\vec{p})$ ，即实测减预测； $\mathbf{J} = \partial \vec{h} / \partial \vec{p}$ 。在这个残差定义下，上式使用加号。若把残差定义成预测减实测，更新式必须改用减号。 $\mathbf{J}$  的第  $i$  行是两个单位方向向量之差。

上面的逆矩阵写法只在  $\mathbf{J}$  满列秩且条件良好时适用。基线方向过于单一或声源处于不利位置时，实现应用 QR/SVD、伪逆或阻尼 Gauss - Newton，而不是显式求  $\mathbf{J}^\top \mathbf{J}$  的逆。

各 TDOA 共用同一参考麦时，其测量误差通常相关；若已知或能估计误差协方差，应用加权最小二乘。迭代还需要足够接近真解的初值。要抗野点需配合稳健损失或剔除机制，普通最小二乘本身并不抗野点。

几何怎样放大测量误差（GDOP, geometric dilution of precision, 几何精度因子）：把 TDOA 模型在真值附近线性化后，位置或角度误差由几何雅可比矩阵传播。麦对基线过短、方向过于相似或声源位于端射等不利方位时，雅可比矩阵接近秩亏，固定的时延误差会被放大。对双麦、正横附近的一维角度模型，有

$$\text{var}(\theta) \approx \left( \frac{c}{d \cos \theta} \right)^2 \sigma_\tau^2$$

- $\sigma_\tau$ ：时延估计误差的标准差； $d$ ：麦间距。这个一阶近似来自  $d\theta = \frac{c}{d \cos \theta} d\tau$ 。因此角度标准差相对正横方向放大  $1/|\cos \theta|$ ，角度方差放大  $1/\cos^2 \theta$ ；例如  $\theta = 60^\circ$  时，标准差放大 2 倍，方差放大 4 倍。端射附近  $\cos \theta \rightarrow 0$ ，线性化失效，有限时延偏差应按反正弦精确计算并检查物理时延上限（见 § 4.9 第 1 题）。4 cm 间距下  $10 \mu\text{s}$  的时延误差在正横附近对应约  $5^\circ$  的角度误差。

这条近似只说明基线和方位对局部角度误差的影响。分布式阵列可以用更长基线降低部分几何放大，但厘米级位置误差还要求足够带宽、同步、标定、信噪比和可控多径；不能只由阵列尺寸推出。

两阶段几何法需要先把各麦对 TDOA 归属于同一声源；多源时数据关联会显著变难。§ 4.5 的 Bartlett 和 Capon 改为空间扫描，可直接从多个谱峰寻找候选方向。

## 4.5 波束扫描类：Bartlett 与 Capon

Bartlett：在固定频点  $f_k$ ， $P_B(f_k, \theta) = \vec{a}^H(f_k, \theta) \hat{\mathbf{R}}(f_k) \vec{a}(f_k, \theta)$ 。按式(2-2)， $\hat{\mathbf{R}}(f_k) = L^{-1} \sum_{\ell=1}^L \vec{x}(f_k, \ell) \vec{x}^H(f_k, \ell)$ ； $L$  是快拍数， $\ell$  是快拍索引。

矩阵对角元是各通道自功率，非对角元是通道间互功率。二次型给出按候选导向矢量转向后的平均输出功率。若各方向的  $\|\vec{a}(f_k, \theta)\|$  相同，省略统一归一化不改变峰位。

Bartlett 的典型分辨尺度由该阵列的常规波束主瓣决定。Rayleigh 类判据是约定的分辨标准，不是所有噪声和检测条件下的绝对物理边界。下面的单频算例为减轻记号负担，省略固定的  $f_k$ 。

Capon/MVDR 谱：对每个候选方向设计“该方向增益为 1、输出功率最小”的滤波器：

$$P_C(f_k, \theta) = \frac{1}{\vec{a}^H(f_k, \theta) \hat{\mathbf{R}}^{-1}(f_k) \vec{a}(f_k, \theta)}。 \quad (4-2)$$

这个式子来自约束优化：最小化  $\vec{w}^H \hat{\mathbf{R}} \vec{w}$ ，同时要求  $\vec{w}^H \vec{a}(\theta) = 1$ 。拉格朗日乘子法给出  $\vec{w} = \hat{\mathbf{R}}^{-1} \vec{a} / (\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a})$ ；把该权重代回输出功率，得到上面的 Capon 谱。完整推导见 § 5.4 和式(5-3)。

候选方向与真实源方向一致时，无失真约束保留该源，因此最小输出功率较大；方向不匹配时，优化器可进一步压低输出功率。 $\hat{\mathbf{R}}$  是  $M \times M$  协方差矩阵。

Capon 在模型准确、快拍充分时通常比 Bartlett 得到更窄的谱峰。快拍不足、相干多径或协方差病态时，应加正则并检查稳健性。

这里的“加载”必须注明口径。绝对加载用  $\hat{\mathbf{R}} + \delta \mathbf{I}$ ， $\delta$  与协方差元素同量纲；相对加载用  $\hat{\mathbf{R}} + \eta \text{tr}(\hat{\mathbf{R}}) \mathbf{I} / M$ ， $\eta$  无量纲。图11 的 Capon 采用相对加载  $\eta = 10^{-6}$ ；图15的超指向波束也采用相对加载，但两图的数据模型不同，不能比较裸谱值。不同信号幅度下直接复用同一个绝对  $\delta$  会改变实际正则强度，因此比较实现时不能只比较裸数值。

可跳过·进阶★★★：拉格朗日求解三步：

第 1 步——列函数、求梯度：拉格朗日函数  $L(\vec{w}, \lambda) = \vec{w}^H \hat{\mathbf{R}} \vec{w} + \lambda(1 - \vec{w}^H \vec{a}) + \lambda^*(1 - \vec{a}^H \vec{w})$ ；对  $\vec{w}^H$  求梯度并置零得  $\hat{\mathbf{R}} \vec{w} = \lambda \vec{a}$ ，即  $\vec{w} = \lambda \hat{\mathbf{R}}^{-1} \vec{a}$ ；

第 2 步——代约束、定倍数：把上式代入约束  $\vec{w}^H \vec{a} = 1$ ，定出  $\lambda = 1 / (\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a})$ ，于是最优权重  $\vec{w}_{\text{opt}} = \hat{\mathbf{R}}^{-1} \vec{a} / (\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a})$ ；

第 3 步——代回、看相消：最小输出功率  $\vec{w}_{\text{opt}}^H \hat{\mathbf{R}} \vec{w}_{\text{opt}}$  里分子分母的  $\hat{\mathbf{R}}$  与  $\hat{\mathbf{R}}^{-1}$  相消一次，剩下  $1 / (\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a})$ ；Capon 谱把这个“最小功率”直接当作该方向的空间谱值——干扰方向的功率被约束优化主动压掉，谱峰于是比 Bartlett 尖锐。

算例 4-3: Bartlett vs Capon 最小可算例——同一个  $\hat{\mathbf{R}}$ ，两种读法

§ 4.5 说 Capon 谱“更尖”，尖多少？用一个  $2 \times 2$  的例子把两种谱在同一组数据上各算两个点。

设定： $M = 2$  麦，间距  $d = \lambda/2$ ；单源在  $\theta = 0^\circ$ （正横方向），信号功率归一为 1，各麦独立白噪声功率  $\sigma^2 = 0.25$ （SNR =  $10 \lg(1/0.25) \approx 6$  dB）。导向矢量（§ 2.6 相位差公式的  $M = 2$  版本）：

$$\vec{a}(\theta) = [1, e^{+j\pi \sin \theta}]^\top。$$

（横写加  $^\top$  与列向量等价，省版面。）

第 1 步：写出协方差矩阵。源在正横、两麦同相（ $\sin 0^\circ = 0$ ， $\vec{a} = [1, 1]^\top$ ），于是  $\hat{\mathbf{R}} = \vec{a} \vec{a}^H + \sigma^2 \mathbf{I}$ ：非对角元 =  $1 \times 1 = 1$ （两麦信号的互相关系数），对角元 = 信号 1 + 噪声 0.25：

$$\hat{\mathbf{R}} = \begin{bmatrix} 1.25 & 1 \\ 1 & 1.25 \end{bmatrix}$$

第 2 步：Bartlett 谱读两个点。  $P_B(\theta) = \vec{a}^H \hat{\mathbf{R}} \vec{a}$ 。

- 源方向  $\theta = 0^\circ$ ：  $\vec{a} = [1, 1]^\top$ ，  $P_B$  = 四个元素之和 =  $1.25 + 1 + 1 + 1.25 = 4.5$ （功率展开读：对角自功率  $2 \times 1.25 = 2.5$ ，非对角互功率  $2 \times 1 = 2$ ——峰值里一半是各麦自己的音量，一半是两麦齐唱的功劳）；

- 错开方向  $\theta = 30^\circ$ :  $\vec{a} = [1, +j]^\top$ 。先算  $\hat{\mathbf{R}}\vec{a} = [1.25 + j, 1 + 1.25j]^\top$ ，再左乘  $\vec{a}^H = [1, -j]$ :  
 $P_B = (1.25 + j) - j(1 + 1.25j) = 2.5$ 。虚部精确相消，符合厄米二次型为实数的自检。

峰/旁比 =  $4.5/2.5 = 1.8$ ，约 2.6 dB； $30^\circ$  处仍为峰值的 56%，说明这个两阵元示例的主峰较宽。

第 3 步：Capon 谱读同样两个点。先求逆： $\det \hat{\mathbf{R}} = 1.25^2 - 1^2 = 0.5625$ ，

$$\hat{\mathbf{R}}^{-1} = \frac{1}{0.5625} \begin{bmatrix} 1.25 & -1 \\ -1 & 1.25 \end{bmatrix}$$

- 源方向  $\theta = 0^\circ$ :  $\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a} = \frac{1.25 - 1 - 1 + 1.25}{0.5625} = \frac{0.5}{0.5625} \approx 0.889$ ,  $P_C = 1/0.889 = \mathbf{1.125}$ ;
- 错开方向  $\theta = 30^\circ$ :  $\hat{\mathbf{R}}^{-1} \vec{a} = [1.25 - j, -1 + 1.25j]^\top / 0.5625$ ，再左乘  $\vec{a}^H = [1, -j]$ ，得  
 $\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a} = 2.5/0.5625 \approx 4.444$ ，所以  $P_C = \mathbf{0.225}$ 。

峰/旁比 =  $1.125/0.225 = \mathbf{5.0}$ ，约 7.0 dB—— $30^\circ$  处只剩峰值的 20%。

为什么 Capon 更尖：Bartlett 在  $30^\circ$  候选方向计算固定导向矢量的二次型，不会根据观测协方差主动抑制  $0^\circ$  强源；Capon 则在  $30^\circ$  保持无失真响应的同时最小化总输出功率。对这个例子，协方差逆使最优权重在  $0^\circ$  强源方向形成零陷，从而降低其泄漏。

$M = 2$  最多提供一个独立零陷约束；阵元增多会增加空间自由度，但实际零陷数和谱峰形状仍受约束数、快拍数和模型失配影响。

扫描类方法的分辨率受阵列孔径和频率限制。§ 4.6 的 MUSIC 与 ESPRIT 可在模型匹配时获得更窄的峰，但对源数、标定误差和相干源更敏感。

## 4.6 子空间类：MUSIC 与 ESPRIT

MUSIC（多重信号分类，Schmidt, 1986）

思想三步：1. 由数据估协方差矩阵  $\hat{\mathbf{R}}$  并特征分解：前  $K$  个大特征值张成信号子空间  $\mathbf{E}_s$ ，其余  $M - K$  个小特征值张成噪声子空间  $\mathbf{E}_n$ （ $K$  为源数）；2. 利用模型关键性质——真实方向上的导向向量与噪声子空间正交；3. 构造伪谱，分母在真实 DOA 处趋零，出现尖峰：

$$P_{MU}(\theta) = \frac{1}{\vec{a}^H(\theta) \mathbf{E}_n \mathbf{E}_n^H \vec{a}(\theta)} \quad (4-3)$$

正交检验的含义是：候选导向向量若属于信号子空间，它在理想噪声子空间上的投影为零，伪谱分母趋近零；候选方向不匹配时，该投影通常非零，伪谱保持有限。

第 2 步为什么成立：信号模型下协方差矩阵是  $\mathbf{R} = \mathbf{A} \mathbf{S} \mathbf{A}^H + \sigma^2 \mathbf{I}$ ，其中  $\mathbf{A}$  是  $M \times K$  的导向向量矩阵、 $\mathbf{S}$  是  $K \times K$  的源协方差矩阵。

只有当  $K < M$ 、 $\mathbf{A}$  列满秩且  $\mathbf{S}$  满秩时， $\mathbf{A} \mathbf{S} \mathbf{A}^H$  的秩才等于  $K$ ，其列空间才等于  $\text{span}(\mathbf{A})$ 。空间白噪声项  $\sigma^2 \mathbf{I}$  只平移特征值，不改变特征向量；其余  $M - K$  个特征向量因此与真实导向向量正交。

相干源使  $\mathbf{S}$  降秩，彩色噪声也不再只平移特征值。这两种情况都破坏上述论证。[Schmidt 的 MUSIC 原始论文](#)。

可跳过 · 进阶★★：正交三步的秩论证（分步说明）

1.  $\text{rank}(\mathbf{A}\mathbf{S}\mathbf{A}^H) \leq \min(M, K, K) = K$ 。非相干源时， $\mathbf{S}$  满秩且  $\mathbf{A}$  列满秩，取等号。于是  $\mathbf{R}$  的前  $K$  个大特征值对应信号，其余  $M - K$  个特征值等于  $\sigma^2$ 。
2. 信号子空间  $\text{span}(\mathbf{E}_s) = \text{span}(\mathbf{A})$ ，且  $\mathbf{E}_n \perp \mathbf{E}_s$ ，所以  $\mathbf{E}_n^H \mathbf{A} = \mathbf{0}$ 。
3. 分母  $\|\mathbf{E}_n^H \vec{a}(\theta)\|^2$  在真实 DOA 处为零，偏离时通常大于零，扫描  $\theta$  因而得到峰值。

源数  $K$  对应  $K$  维信号子空间和  $M - K$  维噪声子空间；算例 4-4 的  $M = 3$ 、 $K = 1$  给出特征值  $3, 0, 0$ 。相干源会使  $\mathbf{S}$  秩降低，第一步的等号不再成立，这正是空间平滑所处理的条件。

#### 算例 4-4: MUSIC 最小可算例——逐项验证正交性

§ 4.6 的 MUSIC 基于一个条件：真实方向的导向矢量与噪声子空间正交。用一个  $3 \times 3$  的例子把这句话算成看得见的数字。

设定： $M = 3$  麦均匀线阵，间距  $d = \lambda/2$  ( $\lambda$  为波长)；单源，方向  $\theta = 0^\circ$ （正横方向，即垂直于阵列连线）；无噪声。

第 1 步：写出导向矢量的显式形式。 $d = \lambda/2$  时相邻麦相位差为  $\psi = \frac{2\pi d}{\lambda} \sin \theta = \pi \sin \theta$ （§ 2.6 的相位差公式），以麦 1 为参考：

$$\vec{a}(\theta) = [1, e^{+j\pi \sin \theta}, e^{+j2\pi \sin \theta}]^\top。$$

（横写加  $^\top$  与列向量等价，省版面。）

代入  $\theta = 0^\circ$  ( $\sin \theta = 0$ )： $\vec{a}(0^\circ) = [1, 1, 1]^\top$ ——正横方向声波同时到达三只麦，相位全同，符合直觉 ✓。

第 2 步：写出无噪声协方差矩阵。无噪声时快拍  $\vec{x} = \vec{a}s$ ，于是  $\mathbf{R} = E\{\vec{x}\vec{x}^H\} = \vec{a}\vec{a}^H \cdot E\{|s|^2\}$ ，取信号功率归一（ $E\{|s|^2\} = 1$ ）即  $\mathbf{R} = \vec{a}\vec{a}^H$ 。第  $m$  行第  $n$  列为  $e^{j(m-n)\pi \sin \theta}$ ：

$$\mathbf{R} = \begin{bmatrix} 1 & e^{-j\pi \sin \theta} & e^{-j2\pi \sin \theta} \\ e^{+j\pi \sin \theta} & 1 & e^{-j\pi \sin \theta} \\ e^{+j2\pi \sin \theta} & e^{+j\pi \sin \theta} & 1 \end{bmatrix} \xrightarrow{\theta=0^\circ} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

若改用  $\theta = 30^\circ$ ，则  $\psi = \pi/2$ ，

$$\mathbf{R} = \begin{bmatrix} 1 & -j & -1 \\ j & 1 & -j \\ -1 & j & 1 \end{bmatrix}。$$

这能直接检查复协方差的两个性质： $R_{nm} = R_{mn}^*$ ，所以  $\mathbf{R} = \mathbf{R}^H$ ；对角元是各通道功率，必须为非负实数。

第 3 步：口算特征值。两个事实就够：①  $\mathbf{R} = \vec{a}\vec{a}^H$  是秩 1 矩阵（每一列都是  $\vec{a}$  的倍数——这里三列完全相同），秩 1 意味着只有一个非零特征值；② 特征值之和 = 矩阵的迹（对角线之和）=  $1 + 1 + 1 = 3$ 。所以三个特征值必是

$$\lambda_1 = 3, \quad \lambda_2 = \lambda_3 = 0。$$

（此处  $\lambda$  表矩阵特征值，不是波长——字母复用，见 § 2.3 清单。）

“1 个大特征值 = 1 个源”——这就是 § 4.6 “前  $K$  个大特征值张成信号子空间”在最简单情形下的样子。（附注：若加入功率为  $\sigma^2$  的白噪声，特征值变成  $3 + \sigma^2, \sigma^2, \sigma^2$ ——大特征值被整体抬高，噪声子空间的地板露出来，数值验证  $\sigma^2 = 0.01$  时得  $3.01, 0.01, 0.01$ ，与理论一致。）

第 4 步：找出噪声子空间。零特征值对应的特征向量满足  $\mathbf{R}\vec{e} = \vec{0}$ ，即“与  $[1, 1, 1]^\top$  正交的向量”。任取两个互相也正交的：

$$\vec{e}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}, \quad \vec{e}_3 = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix}$$

验证  $\mathbf{R}\vec{e}_2$ : 每一行都是  $1 \times 1 + 1 \times (-1) + 1 \times 0 = 0$ , 再除以  $\sqrt{2}$  仍是 0 ✓;  $\mathbf{R}\vec{e}_3$ : 每行  $1 + 1 - 2 = 0$  ✓; 且  $\vec{e}_2^H \vec{e}_3 = (1 \times 1 + (-1) \times 1 + 0 \times (-2)) / \sqrt{12} = 0$  ✓。  $\{\vec{e}_2, \vec{e}_3\}$  张成噪声子空间  $\mathbf{E}_n$ 。

第 5 步: 见证正交性。拿真实方向  $\theta = 0^\circ$  的导向矢量与噪声子空间做内积:

$$\vec{a}^H(0^\circ) \vec{e}_2 = \frac{1}{\sqrt{2}} (1 \times 1 + 1 \times (-1) + 1 \times 0) = 0$$

$$\vec{a}^H(0^\circ) \vec{e}_3 = \frac{1}{\sqrt{6}} (1 \times 1 + 1 \times 1 + 1 \times (-2)) = 0$$

两个内积精确为零——MUSIC 伪谱的分母  $\vec{a}^H \mathbf{E}_n \mathbf{E}_n^H \vec{a} = |0|^2 + |0|^2 = 0$ , 因此理想无噪模型下真实方向的谱值趋于无穷大。

第 6 步: 对照——候选方向不匹配时投影非零。试  $\theta = 30^\circ$ :  $\psi = \pi \sin 30^\circ = \pi/2$ ,

$\vec{a}(30^\circ) = [1, e^{+j\pi/2}, e^{+j\pi}]^\top = [1, j, -1]^\top$ 。逐个算:

$$\vec{a}^H(30^\circ) \vec{e}_2 = \frac{1}{\sqrt{2}} (1 \times 1 + (-j) \times (-1) + (-1) \times 0) = \frac{1+j}{\sqrt{2}} \Rightarrow \left| \frac{1+j}{\sqrt{2}} \right|^2 = 1$$

$$\vec{a}^H(30^\circ) \vec{e}_3 = \frac{1}{\sqrt{6}} (1 \times 1 + (-j) \times 1 + (-1) \times (-2)) = \frac{3-j}{\sqrt{6}} \Rightarrow \left| \frac{3-j}{\sqrt{6}} \right|^2 = \frac{5}{3}$$

分母  $= 1 + \frac{5}{3} = \frac{8}{3} \approx 2.667 \neq 0$ , 伪谱  $P_{MU}(30^\circ) = \frac{1}{8/3} = \frac{3}{8} = 0.375$ 。  $0^\circ$  处在理想无噪模型下趋于无穷大, 而  $30^\circ$  处是有限值 0.375; 数值上对应“匹配方向的噪声子空间投影为零, 不匹配方向的投影非零”。实际有限快拍和噪声会使峰值有限。

能力: 在高 SNR、快拍充分、源数正确、标定准确且没有未处理相干多径时, MUSIC 的谱峰可窄于同一阵列的常规波束主瓣。这种超分辨能力仍依赖孔径和阵列几何: 孔径决定不同方向导向矢量的可区分程度, SNR、快拍数、源间隔和模型失配共同决定有限数据下能否分开近邻源。

三个适用边界: - 需事先知道源数  $K$ 。可按 § 4.1.1 比较特征值间隙, 或使用 AIC/MDL 信息准则。低 SNR、快拍不足和相干源都会削弱特征值分界, 进而造成子空间维数误判; - 相干源失效: 混响多径使信号子空间塌缩。设反射是直达信号延迟 3 个采样点后再衰减一半,  $s_2(n) = 0.5s_1(n-3)$ 。在频点  $f$  上定义  $q(f) = 0.5e^{-j2\pi f(3/f_s)}$ , 则  $S_2(f) = q(f)S_1(f)$ 。若  $E\{|S_1(f)|^2\} = 1$ , 两路源谱的协方差为

$$\mathbf{S}(f) = \begin{bmatrix} 1 & q^*(f) \\ q(f) & |q(f)|^2 \end{bmatrix}。$$

第二行等于第一行乘  $q(f)$ , 因此行列式为零、秩为 1。旧写法把非对角元直接写成 0.5, 只适用于  $q$  恰为实数的特殊频点; 上式保留了 3 个采样点延迟造成的复相位。于是  $\mathbf{A}\mathbf{S}\mathbf{A}^H$  随之降为秩 1, 本该两个的大特征值只剩一个。补救方法是空间平滑: ULA (uniform linear array, 均匀线阵) 切成  $L$  个重叠子阵 ( $L \geq K$ , 即子阵个数不少于相干源数)、分别估协方差再平均, 恢复可用秩。定量代价是有效子阵长度为  $M - L + 1$ , 即用有效孔径换秩, 分辨率也会降低; - 对模型误差敏感 (麦位标定、相位响应、精确流形), 这是它与 SRP-PHAT 在鲁棒性上的根本交换。

空间平滑的尺寸还要同时满足子阵可分辨性。若  $L$  表示重叠子阵数, 则每个子阵长度为  $P = M - L + 1$ ; 恢复  $K$  个相干源通常至少要求  $L \geq K$ , 而 MUSIC 还需  $P > K$  才保留非空噪声子空间。只检查  $L \geq K$  不够。

变体: root-MUSIC 把 ULA 的 MUSIC 分母写成  $z$  域多项式, 选择靠近单位圆的根并由根相位反演角度, 从而免去角度网格扫描。宽带语音则需在多个频点合并信息; 非相干叠加、CSSM/WAVES 聚焦和 TOPS 的处理方式不同, 下一节分别说明。

### 专栏：NormMUSIC——宽带逐频叠加时，为什么要先归一化

语音是宽带信号，而窄带 MUSIC 每次只处理一个频点。非相干平均先在各频点计算 MUSIC 伪谱，再跨频率相加。各频点的阵列电尺寸、信噪比和伪谱尺度不同：低频谱峰可能较宽，高频谱峰可能较窄且数值更大。未经归一化直接相加时，少数峰值尺度较大的频点可能主导结果，低可靠度频点的旁瓣也可能形成伪峰。

本书把“NormMUSIC”限定为 pyroomacoustics 0.10.0 中 `frequency_normalization=True` 的实现口径：各频点伪谱先归一化，再沿频率轴平均。[pyroomacoustics 0.10.0 NormMUSIC 官方文档](#)。其他论文或软件的同名实现可能采用不同归一化，比较前应核对源码。频率归一化会削弱不同频点绝对峰高的差异，但也可能把纯噪声频点放大，因此仍需按信噪比或峰背比筛选频点。

宽带合并前的频点筛选：归一化伪谱接近平坦时，该频点提供的方向信息有限。可按信噪比、谱峰与背景之比或统计可靠度选择频点；门限应在目标数据集上验证，不能把某个经验值当作通用标准。

### ESPRIT（借助旋转不变技术估计信号参数，Estimation of Signal Parameters via Rotational Invariance Techniques）

先看单源情形：两个平移子阵接收的信号子空间只差一个由子阵位移决定的相位因子，求出该因子即可反演方向，不需要逐角度扫描。

多源时，每个源对应  $\Psi$  的一个特征值。具体地， $\mathbf{E}_{s2} = \mathbf{E}_{s1} \Psi$ ，其中  $\mathbf{E}_{s1}$ 、 $\mathbf{E}_{s2}$  是两个子阵的信号子空间， $\Psi$  是二者之间的旋转矩阵；其特征值相位由子阵位移和 DOA 决定。

ESPRIT 的优点是免谱搜索。它仍需准确知道两子阵的相对位移与取向，并要求阵列具有平移不变结构。相干源需要先做去相关处理，宽带或球阵扩展也会受混响和模型误差影响。[Roy 与 Kailath 的 ESPRIT 原始论文](#)。

算例：ESPRIT 最小数字链（ $M = 3$ 、 $d = \lambda/2$ ）：子阵 1 取麦 {1,2}，子阵 2 取麦 {2,3}。在本章导向矢量约定下，旋转因子为  $\Psi = e^{+j\pi \sin \theta}$ ，因此反演式是

$$\theta = \arcsin\left(\frac{\arg \Psi}{\pi}\right)。$$

$\theta = 0^\circ$  时  $\Psi = 1$ ，反演得  $0^\circ$ ； $\theta = 30^\circ$  时  $\Psi = +j$ 、 $\arg \Psi = +\pi/2$ ，反演得  $30^\circ$ 。

不能对  $\arg \Psi$  取绝对值，否则会丢失左右方向的符号。若交换两子阵的次序， $\Psi$  变为共轭，反演式中的符号也要同时改变。

上式还假定相位没有空间混叠。 $d > \lambda/2$  时，主值相位可能对应多个角度，必须限制搜索区间或使用额外频率消歧。

MUSIC 与 ESPRIT 的上述推导基于窄带模型。宽带语音需要在频率维度合并信息，下一节讨论相干与非相干宽带处理。

#### 4.6.1 宽带聚焦：跨频率合并子空间信息

MUSIC、ESPRIT 的基本推导采用窄带假设：在单个频点内，导向矢量  $\vec{a}(f, \theta)$  固定。宽带语音的波长随频率变化，同一个物理方向在不同频点对应不同的阵列流形。NormMUSIC 在各频点独立计算伪谱后再合并，不能利用跨频率的相干信息。聚焦类方法先把不同频点的导向矢量映射到共同的参考频率，再合并协方差并进行特征分解。

聚焦矩阵的思想。选定参考频率  $f_0$  后，对每个频点  $f_j$  构造变换矩阵  $\mathbf{T}(f_j)$ ，使选定角度集合上的  $\mathbf{T}(f_j)\vec{a}(f_j, \theta) \approx \vec{a}(f_0, \theta)$ 。各频点协方差经  $\mathbf{T}\hat{\mathbf{R}}(f_j)\mathbf{T}^H$  变换后再合并。CSSM（coherent signal-subspace method，相干信号子空间方法）是代表方法；经典构造通常依赖初始 DOA 或聚焦角集合，初值偏差会造成聚焦损失。[Wang 与 Kaveh 的 CSSM 原始论文](#)。

初始角从哪来。CSSM 可先用 Bartlett 或 SRP-PHAT 粗扫得到候选角，再据此构造聚焦集合。是否迭代、迭代次数和停止条件属于具体实现，不能假定一两轮必然收敛。

相干源为什么影响聚焦子空间法。混响多径中的直达与反射可能相干，使源协方差矩阵降秩（§ 4.6 的  $2 \times 2$  例子中，完全相干时  $\mathbf{S}$  的秩从 2 降为 1）。若聚焦后仍直接使用降秩协方差，MUSIC 可能合并谱峰或产生方向偏差。均匀线阵可在各频点聚焦前做空间平滑以恢复可用秩，代价是有效子阵孔径减小。

TOPS：不使用聚焦初值。TOPS（test of orthogonality of projected subspaces，投影子空间正交性检验）用候选方向构造频率间变换，检验变换后的信号子空间与各频点噪声子空间的正交性。它不需要 CSSM/WAVES 的初始值预处理，但性能仍取决于频点选择、快拍数、源数和信噪比。[Yoon、Kaplan 与 McClellan 的 TOPS 原始论文](#)。

WAVES：聚焦后加权信号子空间。WAVES（weighted average of signal subspaces，加权信号子空间平均）把聚焦矩阵与按可靠度加权的信号子空间结合，以降低传统 CSSM 对聚焦误差的敏感性；它仍属于需要初始值预处理的相关宽带方法，不能写成免聚焦初值。[Di Claudio 与 Parisi 的 WAVES 原始论文](#)。

选择时先区分是否有可靠初值和阵列是否满足各方法的模型：CSSM 与 WAVES 依赖聚焦预处理，TOPS 不需要该初值。相关源还会使频点内源协方差降秩；ULA 可尝试空间平滑，但必须同时检查子阵长度、源数上界和损失的有效孔径。

子空间法完成宽带扩展后，§ 4.7 转向稀疏重构与数据驱动定位。

## 4.7 稀疏重构与深度学习

稀疏重构：把角度网格化（ $N_{\text{grid}} \gg M$  个候选方向），每个方向摆一个“模板”（导向矢量）。真实信号只来自其中少数几个方向，因此“用模板拼出观测数据”的系数向量是稀疏的，绝大多数位置为零。用  $\ell_1$  正则或稀疏贝叶斯学习（SBL，sparse Bayesian learning，稀疏贝叶斯学习）估计少数非零位置，即得 DOA。

不同算法不能共用“单快拍、超分辨、免源数估计”这一组无条件标签。例如 [L1-SVD 原论文](#)先用奇异值分解汇总多个时间或频率样本，再做稀疏重构；SBL 的输入统计量、超参数和选峰规则又不同。

稀疏先验可在条件合适时产生窄于常规波束的峰，也可不显式预设源数，但结果仍受正则强度、信噪比、样本数和停止或选峰规则影响。共同代价是优化开销与离散网格失配。

网格无关方法：FRIDA 与原子范数。离散稀疏重构存在网格失配：真实方向是连续值，若声源位于两个候选角之间，估计能量可能分散到相邻网格并产生角度偏差。网格越细，离散误差通常越小，但字典规模和计算量随之增加。网格无关方法直接在连续角度域中估计参数，避免预先量化角度。

两条代表路线如下：

- FRIDA（finite rate of innovation DOA，有限新息率波达方向估计）把任意阵列的空间协方差元素线性变换为均匀采样的指数和，再从连续参数反解方向，不需要离散角度网格。其可辨识条件和误差受阵列几何、源数、标定与噪声影响。[Pan et al. 的 FRIDA 原始论文](#)。
- 原子范数（atomic norm）把连续频率或角度上的复指数导向矢量集合定义为“原子”，用这些原子的最小加权组合解释观测。对满足结构条件的线阵模型可转化为半定规划，定义与条件见 [Tang 等 2013](#)及其阵列扩展 [Yang 与 Xie 2015](#)。

两类方法避免了预设角度网格的量化误差，但仍有阵列结构、最小间隔、样本数和噪声条件，计算量也通常高于固定网格扫描。实时性、精度和源数条件必须绑定到具体实现与数据，不能用统一的  $1^\circ$  门限选择算法。

DNN 定位：网络用带方向标签的多通道数据学习噪声、混响与直达声线索之间的映射。训练规模、房间覆盖范围和阵列几何决定其泛化边界。

| 路线                | 代表（骨干 × 输出格式）                                                                                                                    | 做法                                        | 效果特征                         |
|-------------------|----------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------|------------------------------|
| GCC-PHAT 特征 + DNN | Vesperini、Vecchiotti 等（ <i>Computer Speech &amp; Language</i> , vol.49, 2018）：MLP（multilayer perceptron，多层感知机）/CNN 骨干 × 角度网格分类输出 | 多麦对 GCC-PHAT Patterns 向量 → MLP/CNN 角度网格分类 | 输出分辨率由角度类别间距决定；抗噪性取决于训练与测试条件 |

| 路线                         | 代表（骨干 × 输出格式）                                                                          | 做法                                                                                              | 效果特征                                                  |
|----------------------------|----------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------|-------------------------------------------------------|
| 球面<br>SRP 图<br>+ 等变<br>CNN | icoDOA: 二十面体 CNN 骨干 × soft-argmax 连续方向回归                                               | 先把多麦对信息形成二十面体网格上的 SRP-PHAT 图；网络对正二十面体的 60 个离散旋转对称保持等变，再用 soft-argmax 把末层球面分布变成连续三维方向            | 这 60 个离散旋转近似而不等于任意连续三维旋转；收益须在同一数据和网格上与直接取 SRP 峰比较     |
| 直达声<br>IPD 估计              | IPDnet (IEEE/ACM TASLP, 2024) : 交替窄带/全带层 × 多轨直达声 IPD 输出                                | 从多通道谱估计多个声源的直达声麦间相位差 (DP-IPD)，再结合已知阵列几何转换为位置；原文还给出可变量数与拓扑的训练方式                                  | 不是“粗分类 + 细回归”；跨房间和跨阵列结果须按原文数据及未见阵列设置核对                |
| 相位图<br>分类                  | Chakrabarty & Habets 2017/2019: CNN 骨干 × 多标签方位类别输出                                     | 多通道 STFT 相位图 → CNN 的 sigmoid 方位类别后验；原文把方位离散成类别，并在已知声源数时取后验最高的若干类，不是连续 DOA 回归                    | 可输出多个离散方向；类别间距限制输出网格，性能数字只适用于原文文的数据、阵列和噪声条件           |
| 序列模型                       | CRNN/Transformer 骨干 × ACCDOA 输出格式 (ACCDOA = activity-coupled Cartesian DOA, 活动耦合笛卡尔方向) | 向量长度表示活动强度，方向表示 DOA；例如 30°、活动值 0.9 时，二维示意输出为 $0.9(\cos 30^\circ, \sin 30^\circ) = (0.78, 0.45)$ | 原始 ACCDOA 每类每帧一条向量，不能表示同类同时多源；multi-ACCDOA 用多轨输出处理该情况 |

球面 SRP 图 + 等变 CNN 的使用边界：它解决的是把经纬度球面图直接送入平面 CNN 时邻域畸变、极区采样和旋转模式不一致的问题。相对解析 SRP 基线，它不替换麦对几何累积，而是在二十面体网格上学习空间响应的球面局部模式。

成立条件是阵列坐标与声速模型已知、训练与推理使用兼容的球面采样，并且训练数据覆盖部署时的声源数、混响和噪声。

最小比较应在同一批多通道数据上生成相同分辨率的 SRP-PHAT 球面图，以直接取峰为基线，再训练 icoDOA，并在未参与训练的旋转和房间上用同一角误差与检出规则比较。若没有这些数据覆盖或算力，解析 SRP-PHAT 更适合作为可解释基线。算法定义、60 个离散旋转等变性和 soft-argmax 输出见 [Díaz-Guerra、Miguel 与 Beltrán 的原论文](#)。

官方 icoDOA 代码仓库给出的最小入口是 `1sourceTracking_icoCNN.py`。README 记录的验证环境为 Python 3.8.1、PyTorch 1.8.1，并依赖 gpuRIR；合成训练需准备 LibriSpeech，实录测试需准备 LOCATA，输入图分辨率由脚本参数 `r` 控制，预训练模型和对应结果位于 `models/`、`results/`。这些版本和路径是仓库的复现口径，不是对其他版本的兼容性保证。该仓库采用 [AGPL-3.0](#)，并明确定位为论文复现代码而非通用软件库；本书只给官方链接，不复制其源码。许可证与环境信息核实于 2026-09-22，当日 `master` 的完整提交为 `04d1a89594c78ae3cf42f07d94c3737bdc1f7c82`；实际使用前仍应复查目标提交及模型、数据集的附加条款。

数据驱动结果的比较范围：定位网络必须在相同数据集、阵列、信噪比、混响、训练数据和误差指标下比较。上表只归纳输入与输出形式，不给出跨论文排名。卷积空间谱定位可参见 Chakrabarty & Habets [期刊论文](#)；IPDnet 见 Wang、Yang 与 Li 的 [IEEE/ACM TASLP 2024 正式论文](#)；ACCDOA 见 [Shimada et al., ICASSP 2021](#)。使用时还需评估标注成本、跨房间泛化和模型复杂度。

SELD（声事件定位与检测，sound event localization and detection）同时估计事件类别、方向和活动时段。STARSS23 是 DCASE 2023 Task 3 使用的带距离元数据示例；当届正式输出并未要求距离。任务定义、划分和指标应按[当届官方任务页](#)核对，不能把某一届设置外推为长期不变的“前沿”。

## DCASE 任务变化（核实于 2026-09-21）

- 2024 Task 3 把声源距离估计纳入正式输出。
- 2025 Task 3 改用常规视频内容中的双声道音频。因双声道几何存在前后与上下歧义，该届只评水平方位，同时保留距离。
- 2026 Task 3 转向语义声学成像。

2026 开发阶段提供 32 通道 Eigenmike 录音和高分辨率声学图标签。评测阶段不提供标签、元数据或 32 通道录音，只给 4 通道四面体阵列/一阶 Ambisonics 音频，视听赛道另给视频。

每个提交 JSON 的 annotations 条目必须写 metadata\_frame\_index、category\_id、score 和 segmentation；其中 segmentation 是一个或多个由 [x,y,intensity] 三元组构成的空间掩码，distance 为可选字段。

这些变化说明，学习式定位的“输出”已经从稀疏 DOA 向量扩展到距离和稠密空间图。复现时必须绑定届次，不能只写“DCASE Task 3”。

**距离估计：从方向扩展到三维位置：**远场模型只给方向；近场球面模型同时含角度和距离（见 § 2.7）。网络也可能利用波前曲率、直达混响比和声级衰减，但后两类线索受声源级别、房间和训练分布影响。距离结果必须在明确的数据集、误差定义和范围内报告，不能与只估方向的结果直接比较。

### 4.7.1 近场模型失配：角度相同，距离仍会改变导向矢量

取 3 麦 ULA，阵元横坐标为  $[-5, 0, 5]$  cm；声源距阵列中心  $r = 20$  cm，方位  $\theta = 30^\circ$ （从正横起算）。声源坐标为  $(r \sin \theta, r \cos \theta) = (0.10, 0.1732)$  m。三个传播距离约为  $[0.22913, 0.20000, 0.18028]$  m，因此相对中心麦的路程差为

$$\delta_{\text{sph}} = [+29.13, 0, -19.72] \text{ mm}。$$

若误用远场平面波，预测值是  $-x_m \sin \theta$ ，即  $[+25, 0, -25]$  mm。两者的路程差均方根误差为

$$\sqrt{\frac{(29.13 - 25)^2 + 0^2 + (-19.72 + 25)^2}{3}} \approx 3.87 \text{ mm}，$$

相当于约  $11.3 \mu\text{s}$ ；在 4 kHz ( $\lambda \approx 85.8$  mm) 处对应约  $16.2^\circ$  的均方根相位误差。

**锚点算法：角度 × 距离球面扫描。**为把“加入距离维度”变成可复算步骤，仍取上面的 3 麦阵列，并假定单个点声源、自由场、已知声速  $c = 343$  m/s、通道同步且已校准；这个最小例只用 TDOA，不使用  $1/d_m$  幅度线索。对候选  $(r, \theta)$ ：

1. 把候选点写成  $\vec{p}(r, \theta) = (r \sin \theta, r \cos \theta)$ ；
2. 计算到第  $m$  个麦的距离  $d_m(r, \theta) = \|\vec{p}(r, \theta) - [x_m, 0]^\top\|$ ，并以中心麦  $m = 2$  为参考，得到相对路程差  $\delta_m = d_m - d_2$ ；
3. 将观测相对路程差记作  $\delta_m^{\text{obs}}$ ，对每个候选计算 TDOA 均方根失配

$$J(r, \theta) = \sqrt{\frac{1}{3} \sum_{m=1}^3 \left( \frac{\delta_m(r, \theta) - \delta_m^{\text{obs}}}{c} \right)^2}，$$

这里把参考麦  $m = 2$  的恒零项  $\delta_2 - \delta_2^{\text{obs}} = 0$  也计入三通道均方根，所以分母为 3。若只对两个非参考麦取均方根，分母应改为 2， $J$  的数值会整体乘以  $\sqrt{3/2}$ ，但最小点不变。

实际 SRP 或宽带最大似然会用多频复数观测和噪声权重打分；这里的  $J$  只用于手算几何核心。算法选择  $J$  最小的网格点。

真值  $(0.20 \text{ m}, 30^\circ)$  给出  $\delta^{\text{obs}} = [29.13, 0, -19.72]$  mm，即相对时延约  $[84.9, 0, -57.5]$   $\mu\text{s}$ 。取角度网格  $\{20^\circ, 30^\circ, 40^\circ\}$ 、距离网格  $\{0.20, 0.50, 2.00\}$  m，逐格代入上式：

| 距离 $r$ | $\theta = 20^\circ$ | $\theta = 30^\circ$ | $\theta = 40^\circ$ |
|--------|---------------------|---------------------|---------------------|
| 0.20 m | 18.6 $\mu\text{s}$  | 0.0 $\mu\text{s}$   | 17.1 $\mu\text{s}$  |
| 0.50 m | 18.6 $\mu\text{s}$  | 6.8 $\mu\text{s}$   | 19.7 $\mu\text{s}$  |
| 2.00 m | 20.1 $\mu\text{s}$  | 10.2 $\mu\text{s}$  | 21.1 $\mu\text{s}$  |

因此这个无噪、真值落在网格上的例子选中  $(0.20\text{ m}, 30^\circ)$ 。它说明角度相同不等于近场导向矢量相同，也说明网格范围和间距本身会限制输出精度。

若真实位置落在格点之间，应做局部细化或连续优化，不能把粗网格误差归因于观测噪声。球面波下联合估计角度与距离的宽带最大似然模型可参见 [Chen、Hudson 与 Yao 2002](#)。

距离不可观测边界：当  $r \rightarrow \infty$  时， $d_m - d_2 \rightarrow -x_m \sin \theta$ ，对  $r$  的导数趋近 0；不同大距离候选的 TDOA 因而趋于同一平面波值。此时表中同角度的失配差会继续缩小，距离维度形成平坦谷。孔径很小、带宽或 SNR 不足、通道相位未标定时也会出现相同现象；算法应报告距离低置信度或只输出 DOA，而不是把搜索边界当成可靠距离。

4.7.2 可执行基线的输入契约、回退与外部实现边界

本书的原创 NumPy 基线位于 [doa.py](#)。gcc\_phat 对应 § 4.2，返回的正时延严格表示  $\tau_{12} = t_1 - t_2$ ；它使用零填充线性相关、物理时延裁剪和可选三点插值。srp\_phat 对应式(4-1)，输入多通道谱的形状固定为 通道  $\times$  频点  $\times$  帧。bartlett\_spectrum、capon\_spectrum、music\_spectrum 和 esprit\_ula 分别对应 § 4.5、§ 4.6；平面波和近场导向矢量来自 [geometry.py](#)。完整小例与手算回归见 [ch02\\_05\\_baselines.py](#) 和 [test\\_codes\\_doa\\_beam.py](#)。

接入实际录音时还要固定 WAV 数值口径、采样率、通道顺序、麦克风坐标及单位、参考麦、坐标轴、声速和时间戳。GCC 必须按物理孔径裁剪 lag，并同时输出峰值、峰背比和有效频带；SRP 还要记录阵元对、二维或三维搜索范围、网格单位、插值和粗到细规则。扫描谱要记录快拍窗口、频带合并、源数、选峰间距和加载口径。Capon/MUSIC/MVDR 使用厄米线性求解或 `eigh`，不显式形成矩阵逆；协方差奇异且没有加载时，示例代码会报错，调用方应明确选择增加快拍、相对加载、保持上次可靠估计或退回 SRP/Bartlett，不能把 NaN 当成方向。

本书不复制第三方定位代码。核实于 2026-09-22 的官方索引包括：[pyroomacoustics](#)（MIT；发布页当日显示 v0.10.1，书中 NormMUSIC 仍固定为 0.10.0 口径）、[ODAS](#)（MIT；面向嵌入式定位、追踪、分离和后处理，复现时应固定完整提交号）以及前述 [icoDOA](#)（AGPL-3.0）。CSSM、WAVES、TOPS、FRIDA、原子范数、SBL 和神经定位涉及额外优化器、训练数据或许可证，本轮只保留原文与官方仓库索引，不把第三方实现改写成来源不清的“简化版”。

4.8 定位算法总对比

| 方法               | 主要输入与输出                        | 是否预先给源数     | 主要模型条件                  | 典型失败模式              | 主要计算项                              |
|------------------|--------------------------------|-------------|-------------------------|---------------------|------------------------------------|
| GCC-PHAT         | 一对通道 $\rightarrow$ 一个主 TDOA    | 否           | 同一主导源、带宽足够、通道同步         | 多源峰难配对；混响或低 SNR 选错峰 | FFT: $O(N \log N)$                 |
| SRP-PHAT         | 多麦对 GCC $\rightarrow$ 角度/位置响应图 | 找多个峰时需峰选择规则 | 几何与声速已知；搜索区覆盖真值         | 网格误差、宽峰、多径假峰        | 约 $O(N_{\text{grid}} M^2)$ ，另有 GCC |
| Bartlett         | 协方差 $\rightarrow$ 常规空间谱        | 否；找多峰需规则    | 导向模型已知                  | 主瓣宽、旁瓣或失配形成假峰       | $O(TM^2 + N_{\text{grid}} M^2)$    |
| Capon            | 协方差逆 $\rightarrow$ 自适应空间谱      | 否；找多峰需规则    | 协方差可稳定求逆、导向模型准确         | 少快拍、病态矩阵、相干多径、流形失配  | $O(M^3 + N_{\text{grid}} M^2)$     |
| MUSIC/root-MUSIC | 噪声子空间 $\rightarrow$ 伪谱/多项式根    | 是           | $K < M$ 、源协方差满秩、白噪声或已白化 | 源数错误、相干源、有限快拍、标定误差  | 特征分解 $O(M^3)$ ，MUSIC 另需扫描          |
| ESPRIT           | 两个平移子阵的信号子空间 $\rightarrow$ 参数  | 是           | 已知且准确的平移不变子阵结构          | 子阵几何失配、相干源、空间混叠     | 特征/奇异值分解，量级常为 $O(M^3)$             |

| 方法       | 主要输入与输出               | 是否预先给源数  | 主要模型条件           | 典型失败模式               | 主要计算项             |
|----------|-----------------------|----------|------------------|----------------------|-------------------|
| 稀疏/连续参数法 | 字典或连续阵列模型<br>→ 少量 DOA | 取决于正则与实现 | 稀疏源、阵列模型准确       | 网格失配或优化代价；连续法也有可辨识条件 | 随求解器、网格和迭代次数变化    |
| 学习型方法    | 多通道特征 → DOA/<br>位置/活动 | 取决于输出格式  | 训练数据覆盖目标阵列、房间和源数 | 训练—测试失配、置信度失准        | 绑定到具体模型、硬件和批量大小报告 |

表中的复杂度只列主导运算量，不等于延迟、内存或功耗。不同方法的分辨率和鲁棒性不能脱离阵列、SNR、混响、快拍数、搜索网格与训练数据排成统一星级。

Cramér – Rao 下界（CRLB）的适用口径。CRLB 给出指定观测模型下无偏估计量的方差下界。对已知波形、加性白噪声中的时延估计，Fisher 信息随线性 SNR、观测量以及信号的均方根带宽平方增加，因此时延方差下界随这些量减小。

精确系数取决于单通道还是双通道模型、SNR 定义、单边或双边谱、波形是否已知以及是否同时估计未知幅度等条件。条件未写全时，不能把某个系数或微秒数当成通用下界。

对 DOA 而言，还要通过阵列几何的雅可比把时延下界换成角度下界。定性上，SNR、有效带宽、快拍数和有效孔径增大通常会降低方差，端射方向和退化阵列几何会放大误差。

选择依据：先检查几何与采样率带来的可观测性，包括孔径、GDOP、空间混叠和亚采样时延能力。算法可在明确模型或先验下改善统计效率，但不能恢复几何中不存在的信息。资源受限且不使用训练数据时，可把 SRP-PHAT 作为基线并验证粗到细搜索；满足源数、秩和标定条件时，可评估 MUSIC/root-MUSIC；学习型方法只有在训练数据覆盖目标阵列、房间、噪声与源数，并在同条件验证集上优于解析基线时，才有采用依据。

定位置信度与丢轨判据：单帧给一个方向是不够的，在线系统还要回答“这个方向值不值得信、目标跟丢了没有”。三个常用健康度量如下：

- 1. 峰值显著度：主峰与次高峰或背景均值的比值，例如 SRP 功率图或 GCC 峰背比；比值越大，指向越明确；
- 2. 帧间一致性：连续多帧 DOA 的方差或中值偏移；平稳声源下跳动大即不可信；
- 3. 信号存在性：该方向波束输出的 SNR 或语音存在概率；静音段的方向估计直接弃用。

丢轨阈值必须用本系统验证集标定。满足丢轨条件后，追踪器应转入重捕获状态，而不是继续输出抖动角度。这三类量是第 9 章追踪状态机的输入。

### 4.9 本章练习

- 1. ★基础（TDOA + GDOP）：4 cm 双麦、正横方向附近，时延估计偏了 10 μs，角度会偏多少？（参考答案：正横附近  $\Delta\theta \approx c\Delta\tau/d = 343 \times 10 \times 10^{-6}/0.04 \approx 0.086 \text{ rad} \approx 4.9^\circ$ 。线性近似只能在偏差足够小时使用。例如真值为 85° 时，时延约 116.2 μs；估计值增加 10 μs 会超过 4 cm 双麦的物理上限  $d/c \approx 116.6 \mu\text{s}$ ，应判为越界或限制到端射。若减少 10 μs，精确反算为  $\arcsin[(116.2 - 10) \times 10^{-6} \times 343/0.04] \approx 65.6^\circ$ ，误差约 19.4°。这与 § 3.1 算例 3-2 一致：端射附近的有限偏差必须用反正弦精确反算，不能把微分式的 56.4° 当成精确答案。）
- 2. ★★进阶（CRLB 口径题）：为什么只写“带宽 4 kHz、SNR 0 dB”还不足以算出唯一的 TDOA CRLB？（参考答案：还需说明单通道或双通道观测、波形已知与否、SNR 和单/双边谱定义、观测时长或快拍数、信号的实际谱形及其均方根带宽，以及未知幅度等干扰参数；条件不同，Fisher 信息和常数系数都会变化。）

## 第 5 章 · 波束形成

### 5.1 统一问题表述

波束形成器对  $M$  路信号做线性组合（频域）：

$$y(k, n) = \vec{w}^H(k, n) \vec{x}(k, n)。$$

本章沿用第 2 章的几何约定，并把相位符号写全：均匀线阵的麦 1 在左端、位置为  $x_1 = 0$ ，麦 2 及后续阵元沿  $+x$  方向排列；正角声源位于  $+x$  一侧，单位向量  $\vec{u}$  从阵列指向声源。到达时刻差定义为  $\tau_{ij} = t_i - t_j$ 。因此正角远场声源先到达右侧阵元， $\tau_{21} = -d \sin \theta / c$ ；以麦 1 为相位参考时，

$$a_m(f, \theta) = e^{+j2\pi f(m-1)d \sin \theta / c}, \quad m = 1, \dots, M。$$

输出始终写成  $y = \vec{w}^H \vec{x}$ 。所以延迟求和权重为  $\vec{w} = \vec{a} / M$ ，真正乘到第  $m$  路观测上的系数是  $w_m^*$ ；后面的正负号与共轭都按这组约定计算。

本章先研究一类共同问题：在期望方向  $\theta_0$  无失真（ $\vec{w}^H \vec{a}(\theta_0) = 1$ ）的前提下，最小化某类噪声或干扰的输出功率。延迟求和波束形成器（Delay-and-Sum Beamformer, DSB）、超指向、最小方差无失真响应（Minimum Variance Distortionless Response, MVDR）和线性约束最小方差（Linearly Constrained Minimum Variance, LCMV）可用噪声模型与线性约束的差异统一描述。

多通道维纳滤波（Multichannel Wiener Filter, MWF）直接最小化均方误差，广义特征值（Generalized Eigenvalue, GEV）波束形成最大化输出信噪比，并不满足同一个无失真优化问题。它们在后文单独说明。

三类噪声的现实对应如下：

- 传感器白噪声：麦克风自噪声 → 对应度量白噪声增益（White Noise Gain, WNG）；本章把线性量记为  $G_{\text{WNG}}$ ，dB 量记为  $\text{WNG}_{\text{dB}}$ ；
- 弥散噪声：充分弥散的晚期混响。在球面各向同性场模型中，协方差矩阵  $\mathbf{\Gamma}$  的第  $i, j$  个元素为  $[\mathbf{\Gamma}]_{ij} = \text{sinc}(2fd_{ij}/c)$ ， $d_{ij}$  为两麦间距。本章  $\text{sinc}$  用归一化定义  $\text{sinc}(x) = \sin(\pi x) / (\pi x)$ ，部分文献用  $\sin x / x$ ，对照时要换算自变量。对应的线性量为指向因数（directivity factor） $Q$ ，dB 量为指向性指数（Directivity Index, DI）。DI 越高，表示对目标方向保持单位响应时，指定弥散场模型下的输出噪声功率越低。风噪常由麦克风附近的局部湍流产生，不能无条件纳入这个各向同性模型；
- 定向点干扰：竞争说话人、电视 → 在干扰方向形成零陷。

前两类噪声分别用白噪声增益的线性量  $G_{\text{WNG}}$  和指向因数  $Q$  衡量；换成 dB 后分别记为  $\text{WNG}_{\text{dB}}$  和指向性指数 DI。DSB、超指向、WNG 约束和对角加载都可在这两个指标下比较：

$$G_{\text{WNG}} = \frac{|\vec{w}^H \vec{a}|^2}{\vec{w}^H \vec{w}}, \quad \text{WNG}_{\text{dB}} = 10 \log_{10} G_{\text{WNG}}, \quad Q = \frac{|\vec{w}^H \vec{a}|^2}{\vec{w}^H \mathbf{\Gamma} \vec{w}}, \quad \text{DI} = 10 \log_{10} Q。 \quad (5-1)$$

$G_{\text{WNG}}$  是阵列对通道独立白噪声的输出 SNR 线性增益， $Q$  是指定弥散场模型下的输出 SNR 线性增益；式(5-1)明确区分了线性量和 dB 量。无失真约束下两个线性量的分子恒为 1，只需比较分母。4 元  $\lambda/2$  线阵的算例见算例 2-2。图 15 的纵轴标成  $\text{WNG}(\text{dB})$  和  $\text{DI}(\text{dB})$ ，分别对应  $\text{WNG}_{\text{dB}}$  与 DI。

弥散场有两种常用理想模型：球面各向同性假定声音从三维各方向等概率到达，相干系数为  $\text{sinc}$  形；柱面各向同性只对水平面方位角积分，相干系数为零阶贝塞尔函数  $J_0(2\pi fd/c)$ 。Habets, JASA 2008 实际会议室中的说话人、反射和设备噪声通常不满足严格的柱面各向同性分布，应由测得的空间相干性或验证集结果选择模型，不能仅凭场景名称判定。

时域还是频域实现？本章公式写在频域，每个频点各有一组权重  $\vec{w}(k)$ 。短时傅里叶变换（Short-Time Fourier Transform, STFT）把宽带语音分解为一组近似窄带的问题（§ 2.5），逐频点求解后再逆变换。

对应的时域形式称为滤波求和（filter-and-sum）：每路麦克风经过一段有限冲激响应（Finite Impulse Response, FIR）滤波器后求和。DSB 是滤波器退化为纯延迟的特例；Frost 波束形成器则是时域自适应 LCMV 的经典实现。Frost, *Proceedings of the IEEE*, 1972

两种实现的计算量、算法延迟和约束实现方式取决于帧长、滤波器长度与硬件，不应只凭“时域”或“频域”作统一判断。

## 5.2 延迟求和波束形成器 (Delay-and-Sum Beamformer, 简称 DSB)：“合唱前先把大家对齐”

$\vec{w}_{DSB} = \frac{1}{M}\vec{a}(\theta_0)$ ：按导向向量把各通道时延补偿后等权相加。若不除以  $M$ ，对齐后的目标幅度是单通道的  $M$  倍；本章采用的  $1/M$  归一化使目标响应为 1。这两种写法的输出 SNR 相同，但绝对幅度增益不同。

手算例子：2 麦相距  $d = 4$  cm，声源与阵列正横方向夹角  $30^\circ$ （从正横量角，§ 2.1 约定，本章统一用此约定），频率  $f = 1$  kHz。

1. 时延差： $\Delta\tau = \frac{d \sin 30^\circ}{c} = \frac{0.04 \times 0.5}{343} \approx 58.3 \mu\text{s}$ ；
  2. 相位差： $\Delta\phi = 2\pi f \Delta\tau = 2\pi \times 1000 \times 58.3 \mu\text{s} \approx 0.366 \text{ rad} \approx 21^\circ$ ；
  3. 麦 2 在  $+x$  侧，正角声源先到达麦 2，所以有符号时延为  $\tau_{21} = -58.3 \mu\text{s}$ 。以麦 1 为参考的导向向量是  $\vec{a} = [1, e^{+j0.366}]^\top$ ；
  4. DSB 权重： $\vec{w} = \vec{a}/2 = [0.5, 0.5e^{+j0.366}]^\top$ ，验证无失真约束： $\vec{w}^H \vec{a} = \frac{1}{2}(1 + e^{-j0.366}e^{+j0.366}) = 1 \checkmark$ ；
  5. 含义： $y = \vec{w}^H \vec{x}$  中，麦 2 实际乘以  $w_2^* = 0.5e^{-j0.366}$ ，抵消其相对麦 1 的  $+0.366 \text{ rad}$  相位，两路目标信号同相相加。
- 若直接求和，目标幅度变为 2 倍、目标功率变为 4 倍，独立同功率白噪声的功率只变为 2 倍，因此输出 SNR 提高 2 倍，即 3 dB ( $10 \log_{10} 2$ )。写成  $\vec{w} = \vec{a}/M$  的平均形式时，目标响应应保持为 1，噪声功率减半，所得 SNR 增益相同。

波束图的等比数列推导：

1. 把波束指向  $\theta_0$  后，去测另一个方向  $\theta$  的输出：各通道先按  $\theta_0$  补偿相位，再求和。记相邻两麦的残余相位差  $\psi = \frac{2\pi d}{\lambda}(\sin \theta - \sin \theta_0)$ ，则第  $m$  个麦在求和时带着因子  $e^{jm\psi}$ ；
2. 输出幅度就是等比数列求和（公比  $e^{j\psi}$ ）：

$$B(\psi) = \sum_{m=0}^{M-1} e^{jm\psi} = e^{j(M-1)\psi/2} \frac{\sin(M\psi/2)}{\sin(\psi/2)}$$

3. 取模： $|B| = \left| \frac{\sin(M\psi/2)}{\sin(\psi/2)} \right|$ 。 $\psi = 0$ （即  $\theta = \theta_0$ ）时分子分母都趋于零，取极限得最大值  $M$ 。离开目标方向后，该比值随  $\psi$  周期变化，形成主瓣、零点和旁瓣；
4. 主瓣边缘：第一个零点在  $M\psi/2 = \pi$ ，即  $\psi = 2\pi/M$ 。

正横附近用  $\sin \theta \approx \theta$ ，并把主瓣内离散阵因子近似为连续孔径时，“零点到零点”宽度约为  $2\lambda/(Md)$ ，半功率宽度约为  $0.886\lambda/(Md)$ ；斜指向时还要按 § 2.6 除以  $\cos \theta_0$ 。后一个系数是充分大  $M$ 、正横小角度下的近似值，小阵列应直接从上述数值求半功率点。

这里的  $Md$  来自  $M$  项离散阵因子，不等于阵列首尾的物理跨度  $D = (M-1)d$ 。用  $\lambda/D$  表示的是孔径尺度估计；两者只在  $M$  较大时接近，小阵列中必须说明采用哪一种口径。两种写法都表达同一趋势：阵元数或间距增大、波长减小时，主瓣变窄。

均匀加权等价于空间域的矩形窗。其第一旁瓣随  $M$  增大才趋近相对主瓣约 -13.26 dB；例如按上面的离散阵因子复算，

$M = 3, 4, 8, 16$  时约为 -9.54、-11.30、-12.80、-13.15 dB， $M = 2$  则没有常规意义下的旁瓣。因此小阵列不能直接套用“-13 dB”。非均匀加权（如 Dolph-Chebyshev 加权）可按设计值降低旁瓣，但会展宽主瓣；因此必须在旁瓣电平、主瓣宽度和有效孔径之间权衡。

WNG 上限是怎么算出来的（两步，柯西-施瓦茨不等式）：

1. 代入 DSB 权重  $\vec{w} = \vec{a}/M$ ： $G_{\text{WNG}} = \frac{|\vec{w}^H \vec{a}|^2}{\|\vec{w}\|^2} = \frac{|\vec{a}^H \vec{a}/M|^2}{\|\vec{a}\|^2/M^2} = \frac{1}{M/M^2} = M$ ，所以 DSB 的  $\text{WNG}_{\text{dB}} = 10 \log_{10} M \text{ dB}$ ；

2. 若各阵元目标响应幅度均为 1，则  $\|\vec{a}\|^2 = M$ 。柯西-施瓦茨不等式给出  $|\vec{w}^H \vec{a}| \leq \|\vec{w}\| \|\vec{a}\|$ ，所以满足精确无失真约束的权重有  $G_{\text{WNG}} \leq M$ ，等号在  $\vec{w} \propto \vec{a}$  时成立。这个结论针对空间白噪声、精确导向矢量和单位幅度阵列流形；阵元增益不等、噪声相关或导向失配时不能直接套用。

- 优点：在上述理想模型下达到最大  $G_{\text{WNG}}$ ，结构简单；若实际导向矢量等于设计值，目标响应为 1；
- 缺点：不能根据干扰方向自适应放置零陷；波束图中仍可能存在由阵元数、间距和频率决定的固定零点。课程讲义引用的球阵/圆阵实验称其所测小阵列 DSB 几乎无法改善识别率，该结论只适用于讲义中的阵列、数据和识别器。Kumatani et al.

DSB 常作为固定波束基线，也可作为自适应算法的初始权重。

### 5.3 超指向的白噪声增益—指向性权衡

在期望方向无失真约束下最大化  $Q$ ，也就最大化 DI（等价于 MVDR 对阵各向同性噪声）：

$$\min_{\vec{w}} \vec{w}^H \mathbf{\Gamma} \vec{w} \quad \text{s.t.} \quad \vec{w}^H \vec{a}(\theta_0) = 1, \quad \Rightarrow \quad \vec{w}_{SD} = \frac{\mathbf{\Gamma}^{-1} \vec{a}}{\vec{a}^H \mathbf{\Gamma}^{-1} \vec{a}}. \quad (5-2)$$

式(5-2)最大化的是线性指向因数  $Q$ ；由于对数单调，它也最大化 DI。其推导与式(5-3)使用同一个带线性约束的二次型优化，只是把噪声协方差  $\mathbf{R}_{nn}$  换成弥散噪声相干矩阵  $\mathbf{\Gamma}$ 。完整推导见 § 5.4。

小间距阵列可利用相邻通道的差分获得高于 DSB 的弥散场指向性。代价是低频  $G_{\text{WNG}}$  降低，阵元自噪声、增益误差、相位误差和阵列模型误差都会被放大。

实际设计通常加入  $\vec{w}^H \vec{w} \leq \delta$  形式的  $G_{\text{WNG}}$  下限约束，或按频段选择不同权重：低频在白噪声增益预算内提高指向性，高频在  $\mathbf{\Gamma} \approx \mathbf{I}$  时使用接近 DSB 的解。

课程讲义给出了特定小尺寸球阵条件下的对比结果，不能脱离其阵列与数据条件外推。[Kumatani et al. (出处同 § 5.2 引文)]

算例 5-1：超指向权重与  $\text{WNG}_{\text{dB}}$

题设：2 麦小间距  $d = 0.05\lambda$ ，弥散噪声相干矩阵  $\mathbf{\Gamma} = \begin{bmatrix} 1 & \text{sinc}(0.1) \\ \text{sinc}(0.1) & 1 \end{bmatrix}$  (§ 5.1:  $[\mathbf{\Gamma}]_{ij} = \text{sinc}(2d_{ij}/\lambda)$ ，这里  $\text{sinc}(x) = \sin(\pi x)/(\pi x)$ ， $\text{sinc}(0.1) = \frac{\sin(0.1\pi)}{0.1\pi} \approx 0.9836$ )。超指向权重  $\vec{w}_{SD} = \frac{\mathbf{\Gamma}^{-1} \vec{a}}{\vec{a}^H \mathbf{\Gamma}^{-1} \vec{a}}$  (§ 5.3)。

第 1 步：检查  $\mathbf{\Gamma}$  的病态程度

$$\det \mathbf{\Gamma} = 1 - 0.9836^2 = 0.0325, \quad \mathbf{\Gamma}^{-1} = \frac{1}{0.0325} \begin{bmatrix} 1 & -0.9836 \\ -0.9836 & 1 \end{bmatrix} \approx \begin{bmatrix} 30.80 & -30.29 \\ -30.29 & 30.80 \end{bmatrix}$$

两麦噪声的相干系数为  $\rho = 0.9836$ ，所以  $\mathbf{\Gamma}$  接近奇异，逆矩阵元素达到 30 量级。后续求得的权重会相应放大。

第 2 步：正横指向的退化情形

若  $\theta_0 = 0^\circ$ ，则  $\vec{a}_0 = [1, 1]^\top$  恰好是  $\mathbf{\Gamma}$  的特征向量 ( $\mathbf{\Gamma} \vec{a}_0 = (1 + \rho) \vec{a}_0$ )，于是  $\mathbf{\Gamma}^{-1} \vec{a}_0 = \vec{a}_0 / (1 + \rho) \propto \vec{a}_0$ ，归一化后

$$\vec{w}_{SD} = [0.5, 0.5]^\top = \vec{w}_{DSB}, \quad \text{WNG}_{\text{dB}} = +3.0 \text{ dB}$$

——超指向解退化成普通延迟求和。对称双麦阵在正横方向的导向矢量正好是弥散相干矩阵的特征向量，因此没有额外收益。随着指向偏离正横方向，超指向解与 DSB 的差异增大，端射附近通常最明显；不能概括成“只有端射才有增益”。下面用端射方向展示最强的差分效应。

第 3 步：端射指向的权重

$\psi = 2\pi \times 0.05 \times \sin 90^\circ = 0.1\pi \approx 0.3142 \text{ rad } (18^\circ)$ ， $\vec{a} = [1, e^{+j0.3142}]^\top = [1, 0.9511 + 0.3090j]^\top$ 。

分子： $\mathbf{\Gamma}^{-1}\vec{a} \approx \begin{bmatrix} 1.9869 - 9.3616j \\ -1.0033 + 9.5174j \end{bmatrix}$ （模长接近 10，且两分量近乎反号）；

分母： $\vec{a}^H \mathbf{\Gamma}^{-1} \vec{a} \approx 3.9737$ （正实数）；

相除：

$$\vec{w}_{SD} \approx \begin{bmatrix} 0.5000 - 2.3559j \\ -0.2525 + 2.3951j \end{bmatrix}, \quad |w_1| = |w_2| \approx 2.41$$

第 4 步：验证无失真约束

$$\vec{w}^H \vec{a} = \underbrace{(0.5000 + 2.3559j)}_{w_1^* a_1} + \underbrace{(0.5000 - 2.3559j)}_{w_2^* a_2} = 1 \checkmark$$

每一项的模长都是 2.41，而两项虚部  $-2.356j$  相消后留下单位目标响应。权重分量明显大于最终目标响应，因此很小的通道误差也会破坏这种相消关系。

第 5 步：算  $\text{WNG}_{\text{dB}}$ ，看代价

$$\|\vec{w}\|^2 = 2.41^2 + 2.41^2 \approx 11.60, \quad \text{WNG}_{\text{dB}} = 10 \log_{10} \frac{1}{11.60} \approx -10.6 \text{ dB}$$

对照：同一指向的 DSB 有  $\text{WNG}_{\text{dB}} = +3.0 \text{ dB}$ 。负的  $\text{WNG}_{\text{dB}}$  表示独立的阵元自噪声被权重能量放大；本例  $\|\vec{w}\|^2 \approx 11.6$ ，即相对单麦高约 10.6 dB。作为交换，在本例的理想各向同性弥散场、紧凑双麦端射模型下，指向因数  $Q = 1/(\vec{w}^H \mathbf{\Gamma} \vec{w}) \approx 3.97$ ，所以  $\text{DI} \approx +6.0 \text{ dB}$ 。这个结果依赖模型和极限条件，不是任意双麦几何、频率与噪声场的保证。

第 6 步：通道失配的影响

给麦 2 加 1% 的增益失配，即把  $\vec{a}$  的第二分量乘以 1.01：

$$\vec{w}^H \vec{a}_{\text{mis}} = 1.0050 - 0.0236j。$$

目标响应误差幅度约 2.4%。


相同的 1% 增益失配作用在 DSB 上时，目标响应误差为 0.5%；本例超指向误差约为其 5 倍。权重范数越大，通道增益与相位误差造成的响应偏差通常越明显。因此超指向设计应结合器件规格做失配扫描，并加入  $G_{\text{WNG}}$  下限约束或对角加载（§ 5.4）。

第 7 步：比较不同归一化间距（均指向端射  $90^\circ$ ）：

| $d$                      | $0.5\lambda$ | $0.1\lambda$ | $0.05\lambda$ | $0.02\lambda$ | $0.01\lambda$ |
|--------------------------|--------------|--------------|---------------|---------------|---------------|
| 权重模长 $ w_i $             | 0.50         | 1.24         | 2.41          | 5.98          | 11.94         |
| $\text{WNG}_{\text{dB}}$ | +3.0 dB      | -4.9 dB      | -10.6 dB      | -18.5 dB      | -24.6 dB      |

在本例的双麦端射模型中，间距减半时权重模长近似翻倍， $\text{WNG}_{\text{dB}}$  约降低 6 dB；这一近似来自权重随  $\lambda/d$  增长、白噪声输出功率随  $(\lambda/d)^2$  增长。表中数值只对应所列理想模型，实际设计还要加入通道失配、自噪声与阵列几何误差。

图15 6元圆阵（半径=相邻弦长=4 cm）超指向 vs 延迟求和：WNG与DI  
（三维各向同性弥散场；超指向相对对角加载= $10^{-6}$ ；目标方向单位响应；本书仿真）



图示说明：图 15 使用半径 4 cm 的 6 元均匀圆阵；六边形相邻阵元的弦长也为 4 cm。导向矢量与三维各向同性弥散场相干矩阵都由同一组二维阵元坐标计算。

左图比较 DSB 与超指向的  $\text{WNG}_{\text{dB}}$ ，右图比较二者的 DI。两种算法同时用颜色和线型区分，灰度打印时仍可辨认。

超指向协方差矩阵加入相对对角加载  $10^{-6}$ ，即绝对加载量为  $10^{-6} \text{tr}(\mathbf{\Gamma})/M$ ；两种方法均归一化为目标方向单位响应。曲线只展示该模型下的频率趋势，不代表硬件实测，也不能把某个交点当作通用设计门限。

差分麦克风阵列（Differential Microphone Array，简称 DMA）是与紧凑超指向设计密切相关的一类时域结构，但两者不是可以直接互换的名称。超指向设计先规定弥散噪声模型并优化  $Q$ ；DMA 则用通道差分、延迟和均衡合成目标方向图，只有在相应噪声模型、约束与近似条件下才可能实现某个超指向解。

一阶两抽头形式可写为  $y(t) = x_1(t) - g x_2(t - \tau)$ ，其中  $g$  是实数幅度系数， $\tau$  是内延迟。更一般的时域实现用 FIR 滤波器提供频率相关的幅相响应。 $\tau = 0$  且  $g = 1$  的纯实数相减只能得到前后对称的偶极子；心形需要延迟与相减配合，推导见算例 3-1。

在  $\kappa d \ll 1$  ( $\kappa = 2\pi f/c$ ，麦距远小于波长) 的低频近似下，配合所需的幅度均衡后，归一化指向形状可在一段频带内近似不变。有限间距、离散延迟、壳体散射和失配都会破坏该近似。DMA 尺寸小，但  $\text{WNG}_{\text{dB}}$  可能很低，对麦距和通道失配敏感。

四项诊断量：超指向或 MVDR 权重求出后，应检查以下指标，再进入录音评估。

1. 白噪声增益余量：算  $G_{\text{WNG}} = 1/\|\vec{w}\|^2$ （精确无失真约束下），再按式(5-1)换成  $\text{WNG}_{\text{dB}}$ 。最低允许值应由本机自噪声、增益/相位公差和目标输出余量共同确定，不能用一个固定 dB 数覆盖所有设备；
2. 条件数：算  $\mathbf{\Gamma}$  或  $\hat{\mathbf{R}}_{nn}$  的条件数  $\kappa = \lambda_{\max}/\lambda_{\min}$ 。条件数增大表示求逆对协方差估计误差更敏感；可通过对角加载（§ 5.4）、降阶或减少约束改善。可接受上限应由浮点精度、快拍数和失配仿真共同确定；
3. 削波率与动态余量：把权重作用于代表性录音或按目标电平生成的测试信号，检查输出峰值和削波率。权重范数大时，通道叠加可能增加峰值；应预留数字动态余量，并在需要时收紧 WNG 约束；
4. 通道失配灵敏度：按照麦克风数据手册、标定残差和装配误差给导向矢量逐通道施加增益、相位与位置扰动，统计目标响应  $|\vec{w}^H \vec{a}_{mis} - 1|$ 、零陷位置与 WNG 的变化。算例 5-1 第 6 步提供了 1% 增益失配的手算；实际扰动范围和验收门限必须按设备确定。

专栏：差分麦克风（DMA）——从一阶心形到高阶与神经差分

上一节末尾把 DMA 归入紧凑超指向设计。下面说明差分、延迟和均衡如何共同形成一阶方向图，以及提高阶数时为什么必须同时检查 WNG。

一阶差分原理：两个相距很近的麦克风接收同一远场声波时存在小的传播时延差。对其中一路施加内部延迟和增益后相减，可使某些方向相消、另一些方向保留。输出写成  $y(t) = x_1(t) - g x_2(t - \tau)$ ：  $g$  控制两路幅度与相位配比，  $\tau$  控制相减前的内部延迟；改变  $(g, \tau)$  就会改变零点位置和指向图形状。

后向零点怎样变成近似心形：设端射双麦间距为  $d$ ，某方向的传播时延差为  $\tau_p(\theta)$ 。该方向的频率响应可写成

$$H(\omega, \theta) = 1 - g e^{-j\omega[\tau + \tau_p(\theta)]}。$$

选择  $g$  和内部延迟  $\tau$  可以令后向响应在设计频率或低频近似下为零。仅有这个零点还不能证明整个宽带方向图是心形。

当  $\kappa d = 2\pi f d / c \ll 1$ ，把指数项作一阶展开，并用均衡器补偿差分器随频率上升的幅度后，归一化方向图才可在一段频带内近似“全向项加偶极项”；取相应系数时得到心形、超心形或8字形。

频率升高、间距不再远小于波长、延迟量化或通道失配都会使形状偏离该近似。 $\tau = 0$  且  $g = 1$  的纯相减只产生前后对称的偶极响应。[Elko & Pong, ICASSP 1997](#)

算例：一阶 DMA 的零点、均衡与 WNG。取端射双麦  $d = 2$  cm、 $c = 343$  m/s，则  $T = d/c = 58.31 \mu s$ 。沿用式中的符号约定，令后向  $\tau_p = -T$ 、前向  $\tau_p = +T$ ，并取  $g = 1, \tau = T$ 。后向响应为  $H_b = 1 - e^0 = 0$ 。在  $f = 500$  Hz，前向响应

$$H_f = 1 - e^{-j2\omega T}, \quad |H_f| = 2 \sin(\omega T) = 2 \sin(0.1832) \approx 0.3644。$$

因此要把前向响应归一到 1，均衡器幅度需乘  $1/0.3644 \approx 2.744$ 。两路独立、单位功率的阵元自噪声在均衡后功率为  $2/|H_f|^2 \approx 15.06$ ，所以  $\text{WNG}_{\text{dB}} = 10 \log_{10}(1/15.06) \approx -11.78$  dB。

若第二通道有 1% 增益误差，原本的后向零点变为  $|1 - 1.01|/|H_f| \approx 0.0274$ ，即相对前向约 -31.2 dB；零点不再无限深。

这个单频点数例只验证相消和噪声放大的代价。它不证明宽带心形：500 Hz 时  $\kappa d \approx 0.183$  尚可作低频近似，频率升高、均衡器限幅或误差增大时必须重新计算方向图和 WNG。

提高阶数改变了什么：多个一阶差分单元级联可形成高阶方向图，并提供更多可配置零点。阶数增加并不对应一个脱离条件的固定 DI 增量。理想 DI 取决于采用球面还是柱面弥散场、目标方向图和归一化方式；换成 dB 后也不能概括为“每阶线性增加”。

高阶差分包含更强的相消和低频均衡，通常增大权重范数，使阵元自噪声和增益、相位、位置误差更容易进入输出。

设计时应按每个频点同时报告方向图、DI、WNG、条件数和失配扫描，而不是只按阶数选型。[Elko, Differential Microphone Arrays](#)

| 设计变化   | 可能获得的能力                      | 同时增加的风险               | 必须固定的比较条件          |
|--------|------------------------------|-----------------------|--------------------|
| 增加差分阶数 | 可配置更多零点和更细的空间变化              | 权重范数增大，低频自噪声和失配更易被放大  | 频率、间距、噪声场、目标图形与均衡器 |
| 减小阵元间距 | 在更高频率前维持 $\kappa d \ll 1$ 近似 | 通道观测更相似，差分后的 WNG 可能降低 | 麦克风自噪声、标定残差与数值精度   |
| 增强低频均衡 | 补偿差分器的低频衰减                   | 同时放大低频传感器噪声和风噪        | 最大增益、削波余量与 WNG 下限  |

学习方法若用于 DMA，更适合估计受约束的系数、掩码或正则化参数，再由解析差分结构形成输出。这样仍可检查零点、WNG 和失配；若网络直接输出任意滤波器，则应按 § 5.9 的端到端方法评价，不能仅因输入来自小间距阵列就称为 DMA。

在精确导向和空间白噪声模型下，DSB 达到最大的  $G_{\text{WNG}}$ ；超指向针对弥散噪声提高  $Q$  与 DI，但通常降低低频  $\text{WNG}_{\text{dB}}$ 。后面的 MVDR 和稳健波束形成把这种指标权衡推广到估计得到的噪声协方差与导向误差。

## 5.4 最小方差无失真响应

最小方差无失真响应（Minimum Variance Distortionless Response，简称 MVDR）在设计导向矢量上施加单位响应，同时最小化输出噪声功率。只有设计导向矢量与真实目标传递向量一致时，“无失真”才对真实目标成立。

$$\min_{\vec{w}} \vec{w}^H \mathbf{R}_{nn} \vec{w} \quad \text{s.t.} \quad \vec{w}^H \vec{a}(\theta_0) = 1。$$

符号： $\mathbf{R}_{nn}$  是  $M \times M$  噪声协方差矩阵。对角元表示各通道噪声功率，非对角元表示通道间相关性。它与 § 4.2 的标量互相关函数  $R(\tau)$  不同。

推导（拉格朗日乘子法，四步，每步都有物理读法）：

第 1 步：把约束加入目标。复约束  $\vec{w}^H \vec{a} = 1$  要与其共轭约束成对写入拉格朗日函数：

$$L(\vec{w}, \lambda) = \vec{w}^H \mathbf{R}_{nn} \vec{w} + \lambda(1 - \vec{w}^H \vec{a}) + \lambda^*(1 - \vec{a}^H \vec{w})。$$

$\lambda$  是复标量拉格朗日乘子。后两项互为共轭，所以  $L$  保持为实数。

第 2 步：求梯度并令它为零。复数向量求导用 Wirtinger 规则——把  $\vec{w}$  和它的共轭  $\vec{w}^*$  当成两个独立变量，对  $\vec{w}^*$  求偏导：

$$\frac{\partial L}{\partial \vec{w}^*} = \mathbf{R}_{nn} \vec{w} - \lambda \vec{a} = \vec{0} \quad \Rightarrow \quad \vec{w} = \lambda \mathbf{R}_{nn}^{-1} \vec{a}$$

物理读法：最优权重与经噪声协方差白化后的导向矢量成比例。 $\mathbf{R}_{nn}^{-1}$  根据噪声空间相关结构调整各方向的响应，比例系数再由无失真约束确定。

第 3 步：用约束确定倍数。把结果代回无失真约束  $\vec{w}^H \vec{a} = 1$ ：

$$\lambda^* \vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a} = 1。$$

由于  $\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}$  是正实数，所以  $\lambda^* = \lambda$ ，并且

$$\lambda = \frac{1}{\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}}$$

协方差矩阵一般是半正定的；这里写普通逆矩阵，额外假定  $\mathbf{R}_{nn}$  正定。若快拍不足或矩阵奇异，应加正则、使用降秩方法或在明确秩条件下用伪逆。正定时分母是正实数。

第 4 步：把倍数代回第 2 步。

$$\boxed{\vec{w}_{MVDR} = \frac{\mathbf{R}_{nn}^{-1} \vec{a}}{\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}}}。 \quad (5-3)$$

正定时  $\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}$  为正实数，因此上面由  $\vec{w}^H \vec{a} = 1$  求得的乘子无需再区分共轭值。

此权重代回输出功率即得式(4-2)的 Capon 谱——同一优化器的两种读法（推导见 § 4.5）。

推导关系：梯度条件给出  $\vec{w} \propto \mathbf{R}_{nn}^{-1} \vec{a}$ ，无失真约束再确定比例系数，使  $\vec{w}^H \vec{a} = 1$ 。因此  $\mathbf{R}_{nn}^{-1}$  决定噪声抑制方向，分母负责目标响应归一化。LCMV（§ 5.5）沿用同一二次型优化，只把一条约束推广为多条约束。

两个特例：白噪声下  $\mathbf{R}_{nn} \propto \mathbf{I}$ ，MVDR 退化为 DSB；协方差中含定向强干扰时，MVDR 会降低该方向的响应。图 16 的 MVDR 曲线使用 8 元阵和  $20^\circ$  干扰，参数与下面算例 5-2 的 2 元阵、 $30^\circ$  干扰不同。

算例 5-2：2 麦 MVDR 数值推导

题设：2 麦，间距  $d = \lambda/2$ ；目标方向  $\theta_0 = 0^\circ$ （正横）；干扰来自  $\theta_i = 30^\circ$ ，干扰噪声功率比  $\text{INR} = 10$ （干扰功率是各麦白噪声功率的 10 倍）。求 MVDR 权重  $\vec{w}_{MVDR} = \frac{\mathbf{R}_{nn}^{-1} \vec{a}}{\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}}$ （式(5-3)的闭式解），并验证它的两个承诺。

第 1 步：写出两个导向矢量

- 目标方向： $\psi_0 = \pi \sin 0^\circ = 0$ ，所以  $\vec{a}_0 = [1, 1]^\top$ ；
- 干扰方向： $\psi_i = \pi \sin 30^\circ = \frac{\pi}{2}$ ，所以  $\vec{a}_i = [1, e^{+j\pi/2}]^\top = [1, +j]^\top$ （相对麦 1，麦 2 的频域相位为  $+90^\circ$ ）。

## 第 2 步：构造噪声协方差矩阵 $\mathbf{R}_{nn}$

噪声模型 = 定向干扰 + 各麦独立白噪（功率归一化为 1）：

$$\mathbf{R}_{nn} = 10 \cdot \vec{a}_i \vec{a}_i^H + \mathbf{I}$$

先算外积  $\vec{a}_i \vec{a}_i^H = \begin{bmatrix} 1 \\ +j \end{bmatrix} [1, -j] = \begin{bmatrix} 1 & -j \\ +j & 1 \end{bmatrix}$ （注意  $(\vec{a}_i \vec{a}_i^H)_{12} = 1 \cdot (+j)^* = -j$ ），于是

$$\mathbf{R}_{nn} = \begin{bmatrix} 11 & -10j \\ +10j & 11 \end{bmatrix}$$

读法：对角元 11 = 干扰功率 10 + 白噪功率 1（每个麦收到的总噪声功率）；非对角元  $\pm 10j$  记录两麦噪声的相关性和相位差。对本例的单个定向干扰，方向信息体现在这对非对角元中；一般 MVDR 还同时依赖整个协方差矩阵、导向矢量和无失真约束，不能把零陷归因于所有非对角元的某个通用模式。

## 第 3 步：求逆 $\mathbf{R}_{nn}^{-1}$

2×2 矩阵求逆公式  $\begin{bmatrix} p & q \\ r & s \end{bmatrix}^{-1} = \frac{1}{ps - qr} \begin{bmatrix} s & -q \\ -r & p \end{bmatrix}$ 。行列式：

$$\det \mathbf{R}_{nn} = 11 \times 11 - (-10j)(10j) = 121 - 100 = 21$$

注意  $(-10j)(10j) = -100j^2 = +100$ 。2×2 行列式为  $ps - qr$ ，所以这里得到  $121 - 100 = 21$ 。

该矩阵的特征值为 21 和 1，2-范数条件数为 21；算例 5-1 的  $\mathbf{I}$  特征值约为 1.9836 和 0.0164，条件数约为 121。条件数而不是未归一化的行列式可直接比较求逆敏感度。于是

$$\mathbf{R}_{nn}^{-1} = \frac{1}{21} \begin{bmatrix} 11 & +10j \\ -10j & 11 \end{bmatrix} \approx \begin{bmatrix} 0.5238 & +0.4762j \\ -0.4762j & 0.5238 \end{bmatrix}$$

## 第 4 步：算权重

分子： $\mathbf{R}_{nn}^{-1} \vec{a}_0 = \frac{1}{21} \begin{bmatrix} 11 + 10j \\ 11 - 10j \end{bmatrix} \approx \begin{bmatrix} 0.5238 + 0.4762j \\ 0.5238 - 0.4762j \end{bmatrix}$ ；

分母： $\vec{a}_0^H \mathbf{R}_{nn}^{-1} \vec{a}_0 = \frac{1}{21} [(11 + 10j) + (11 - 10j)] = \frac{22}{21} \approx 1.0476$ （正实数，与 § 5.4 推导第 3 步的论断一致）；

相除：

$$\vec{w}_{MVDR} = \frac{1}{22} \begin{bmatrix} 11 + 10j \\ 11 - 10j \end{bmatrix} = \begin{bmatrix} 0.5000 + 0.4545j \\ 0.5000 - 0.4545j \end{bmatrix}$$

两个权重模长相同（ $\approx 0.676$ ）、虚部符号相反，不再是 DSB 的  $[0.5, 0.5]$ 。这组反号的相位分量使干扰方向的两路加权响应接近相消。

## 第 5 步：验证两个承诺

① 目标无失真： $\vec{w}^H \vec{a}_0 = (0.5 - 0.4545j) \cdot 1 + (0.5 + 0.4545j) \cdot 1 = 1 \checkmark$ （两个虚部恰好抵消）；

② 干扰方向零陷：

$$\vec{w}^H \vec{a}_i = (0.5 - \frac{5}{11}j) \cdot 1 + (0.5 + \frac{5}{11}j)(+j) = \frac{1}{22}(1 + j) \approx 0.0455 + 0.0455j$$

$|\vec{w}^H \vec{a}_i| = \frac{\sqrt{2}}{22} \approx 0.0643$ , 即  $-23.8$  dB。干扰幅度约为输入阵元响应的  $1/15.6$ , 输出干扰功率  $10 \times 0.0643^2 \approx 0.041$ , 低于输出白噪声功率  $\|\vec{w}\|^2 \approx 0.913$ 。

为什么不是精确的 0? MVDR 只显式约束目标方向, 不强制干扰方向响应为零。干扰的空间相关信息包含在  $\mathbf{R}_{nn}$  的非对角元中; 本例 INR 为 10, 优化得到约  $-24$  dB 的残余响应, INR 增大时该响应继续降低并趋近零。若必须在已知方向形成精确零陷, 应使用 § 5.5 的 LCMV 约束。


第 6 步: 检查波束图的五个方向 ( $|B(\theta)| = |\vec{w}^H \vec{a}(\theta)|$ , 完整曲线见图 16):

| 角度          | 增益 (dB) | 含义          |
|-------------|---------|-------------|
| $0^\circ$   | 0.00    | 无失真约束保持单位响应 |
| $+30^\circ$ | -23.84  | 零陷正对干扰      |
| $+15^\circ$ | -5.05   | 过渡带, 被连带压低  |
| $-30^\circ$ | +2.61   | 无干扰一侧被抬高    |
| $+45^\circ$ | -8.62   | 远旁瓣残余       |

读图:  $0^\circ$  处因无失真约束保持 0 dB,  $30^\circ$  干扰方向的响应为  $-23.8$  dB; 波束图不再左右对称。干扰一侧 ( $+\theta$ ) 整体降低, 而  $-30^\circ$  附近增益升高 2.6 dB。该权重是在本例协方差与单位目标响应约束下使输出功率最小的解; 协方差或干扰方向改变后, 曲线也会改变。

WNG 代价: 这组权重的  $G_{\text{WNG}} = 1/\|\vec{w}\|^2 = 1/0.9133$ , 所以  $\text{WNG}_{\text{dB}} \approx +0.39$  dB, 比同一双麦阵的 DSB 低约 2.6 dB。该差值与干扰抑制量都只对应本算例的 INR、几何和噪声模型。

图16 8元ULA  $0^\circ$ 指向波束图: DSB/MVDR 用  $d=\lambda/2$ , 超指向用  $d=0.2\lambda$   
(各曲线保持目标方向单位响应; MVDR 干扰=20°; 超指向相对对角加载=10<sup>-6</sup>; 模拟)



图示说明: 图 16 的三组权重都满足目标方向单位响应。线性幅度图保留这一绝对响应, dB 图以目标响应为 0 dB 参考, 并截断到  $-40$  dB。

DSB 与 MVDR 使用 8 元、 $d = \lambda/2$ , MVDR 协方差模型含  $20^\circ$  定向干扰。超指向使用另一个  $d = 0.2\lambda$  的紧凑阵列和相对对角加载  $10^{-6}$ 。

由于阵元间距和噪声模型不同，超指向曲线不能作为与前两条曲线的同几何性能排名；该图也不能直接给出 WNG 或 DI。图中参数与算例 5-2 的 2 元阵、30° 干扰不同，零陷深度不能直接互比。

实现中的三个问题：1.  $\hat{\mathbf{R}}_{nn}$  从哪来：无目标帧估计（语音活动检测即 VAD 辅助）；语音场景经典做法是时频掩码（Time-Frequency mask，简称 TF-mask）——神经网络预测每个时频点是语音还是噪声，分别加权估出目标/噪声协方差（在 CHiME 系列远场语音识别挑战赛中验证有效的主流做法；这类掩码做法在完整系统里的效果证据见 § 8.1）；2. 病态与对角加载：小快拍下  $\hat{\mathbf{R}}$  可能病态，可改用  $\hat{\mathbf{R}} + \epsilon \mathbf{I}$ 。它抬高小特征值并限制权重范数；与显式 WNG 约束的关系见下文，二者不能不加条件地写成同一个问题；3. 混响中的约束对象：自由场导向向量只描述直达传播。混响房间中的目标通道还包含早期反射，因此实际目标传递向量可能与自由场模型不一致。可估计相对传递函数（Relative Transfer Function，简称 RTF），用各麦相对参考麦的目标传递函数作为约束向量；RTF 估计误差仍需通过失配仿真评估。

对角加载、WNG 约束与正则化的关系：绝对加载写成  $\hat{\mathbf{R}} + \epsilon \mathbf{I}$ ，其中  $\epsilon$  与协方差矩阵的元素具有相同量纲；它等于在目标函数中加入  $\epsilon \|\vec{w}\|^2$ 。

为使输入整体缩放后加载强度不变，本节比较表改用无量纲相对加载量  $\alpha$ ：

$$\hat{\mathbf{R}}_{\text{load}} = \hat{\mathbf{R}} + \alpha \frac{\text{tr}(\hat{\mathbf{R}})}{M} \mathbf{I}.$$

在无失真约束下，显式约束  $\|\vec{w}\|^2 \leq \delta$  就是在设置 WNG 下限。若该约束在最优点处有效，其拉格朗日乘子会产生同形的对角加载。

给定  $\delta$  对应的  $\alpha$  依赖  $\hat{\mathbf{R}}$ 、 $\vec{a}$  和频点，不能把任意加载量与任意 WNG 门限视为相同。 $\alpha$  应按协方差条件数、器件失配仿真和所需 WNG 扫描选择。Li, Stoica & Wang, IEEE TSP 2003

对角加载的代价表（相对加载量  $\alpha$  从小到大）：

| $\alpha$ 取值 | 加载相对平均特征值的大小           | 白噪声增益     | 指向性/零陷深度 | 稳健性          | 适用场合            |
|-------------|------------------------|-----------|----------|--------------|-----------------|
| 较小          | 只轻微抬高特征值               | 接近未加载解    | 接近未加载解   | 小快拍下求逆仍可能病态  | 快拍充足、标定较好的离线处理  |
| 中等（由验证集确定）  | 小特征值被抬高                | 通常回升      | 通常变浅     | 对估计误差和轻微失配较稳 | 按 WNG 与目标失真联合调参 |
| 较大          | 加载项主导小特征值，继续增大时可主导整个矩阵 | 趋近 DSB 上限 | 深零陷逐渐变浅  | 解逐渐接近固定波束    | 稳健模式或诊断对照       |

读法： $\alpha$  增大时，条件数通常改善、权重范数减小，零陷和指向性也可能减弱。变化多少由协方差特征值、导向向量与加载归一化口径共同决定，不能预先保证若干 dB。应画出 WNG、目标失真和噪声输出随归一化加载量的曲线，再按系统预算选点。

5.4.1 稳健波束形成方法

对角加载主要限制协方差求逆的敏感度和权重范数，不能覆盖所有失配来源。下面按四类误差分别说明可选方法、假设和代价：

- A：导向向量失配：DOA 误差、通道增益/相位不一致或阵列标定误差使约束向量偏离真实目标传递向量；
- B：协方差估计误差：快拍不足、噪声非平稳或目标泄漏使  $\hat{\mathbf{R}}_{nn}$  偏离真实噪声协方差，求逆会放大其中的小特征值误差；
- C：相干干扰或混响：早期反射与直达声相干，可能降低信号子空间秩并改变零陷位置；
- D：目标自消：含目标的协方差与失配约束共同作用，使自适应权重抑制真实目标。

方法 1：最差情况优化（Worst-Case Optimization）。若把真实导向向量限制在球形不确定集  $\|\vec{a}_{true} - \vec{a}_0\| \leq \epsilon$  中，可要求集合内所有导向向量都满足最低响应。对常见球形、范数有界模型，其 KKT 条件常导出对角加载形式，但加载量需由不确定集半径和数据共同求得；任意固定加载并不等同于完整的鲁棒 Capon 问题。 $\epsilon$  应由 DOA 误差和通道标定统计确定，取大时会牺牲 DI 与零陷深度。Vorobyov, Gershman & Luo, IEEE TSP, 2003

方法 2：特征空间波束形成（Eigenspace Beamforming）。对含目标的采样协方差做特征分解，把权重投影到由主要特征向量张成的子空间中，可减小小特征值估计误差造成的权重偏差。代价是必须选择子空间维数；低信噪比或弱目标条件下，信号与噪声特征值难以分开，投影也可能删除有用成分。[Chang & Yeh, IEEE Transactions on Antennas and Propagation, 1992](#)

方法 3：协方差重构（Covariance Reconstruction）。MVDR 需要干扰加噪声协方差，但 VAD 选出的噪声段可能含目标残留和混响尾音。以 Capon 谱积分重构为例，可在非目标角度区域估计空间谱，再积分重建  $\hat{\mathbf{R}}_{nn}$ 。代价是增加谱估计与积分计算；目标区域或积分区域设错时，也会删除干扰信息或保留目标泄漏。[Gu & Leshem, IEEE TSP, 2012](#)

方法 4：前后向空间平滑（Forward-Backward Spatial Smoothing）。均匀线阵可切成重叠子阵，先平均前向子阵协方差，再加入共轭反转的后向项。该处理可恢复部分相干源条件下的协方差秩。代价是子阵长度小于原阵列，因而有效孔径和剩余自由度下降；子阵数量必须同时满足去相关与可分辨性要求。[Shan, Wax & Kailath, IEEE TASSP, 1985](#)（空间平滑）、[Pillai & Kwon, IEEE TASSP, 1989](#)（前后向扩展）

方法选择表（对角加载主要处理病态求逆和权重范数，其他误差还需针对性处理）：

| 现象                          | 主要误差来源  | 首选                            | 备选/联合                     | 验证重点                           |
|-----------------------------|---------|-------------------------------|---------------------------|--------------------------------|
| DOA 偏差达到设备验证集中的高分位值时，目标响应下降 | A 导向失配  | 最差情况优化（ $\epsilon$ 按 DOA 误差定） | 导数约束（LCMV，§ 5.5）降低主瓣内响应起伏 | 先测 DOA 误差分布和目标响应，再定 $\epsilon$ |
| 更换麦克风批次后结果变化明显              | A 通道不一致 | 通道标定 + 最差情况优化                 | 对角加载                      | 用批次间标定残差设置不确定集                 |
| 噪声段含目标，自适应后目标衰减             | D 目标自消  | 改善 VAD/SPP 与协方差估计             | 特征空间投影                    | 同时报目标响应和噪声降低量                  |
| 快拍少、噪声时变，求逆病态               | B 估计误差  | 对角加载 + 协方差重构                  | 减少约束或降阶                   | 扫描加载量、WNG 与目标失真                |
| 强早期反射或相干干扰造成零陷偏移            | C 相干    | 适用阵列上的空间平滑                    | RTF 约束                    | 检查子阵结构和剩余孔径                    |
| 低频 WNG 很低、权重范数很大            | 超指向固有   | WNG 约束/对角加载，分频段设计             | 降阶 DMA                    | 见算例 5-1 第 7 步                  |

使用该表时，应先用 § 5.3 的四项诊断量确定主要误差来源，再分别验证候选方法。每次改变稳健化参数，都应重新测量 WNG、目标响应、噪声输出和任务指标。

MVDR 的闭式解依赖准确的协方差和约束向量。对角加载、最差情况优化、特征空间投影、协方差重构与空间平滑分别针对不同误差来源，选择前应先确定失配模型。

5.5 线性约束最小方差（Linearly Constrained Minimum Variance，简称 LCMV）：多约束推广

多个线性约束写成矩阵形式  $\mathbf{C}^H \vec{w} = \vec{f}$ （ $\mathbf{C}$ ：约束矩阵，每列是一个约束方向/约束向量； $\vec{f}$ ：对应的约束值向量），LCMV 闭式解为：

$$\vec{w}_{LCMV} = \mathbf{R}^{-1} \mathbf{C} (\mathbf{C}^H \mathbf{R}^{-1} \mathbf{C})^{-1} \vec{f}.$$

(5-4)

（ $\mathbf{R}$  可以是噪声协方差  $\mathbf{R}_{nn}$ ；目标缺席样本不可得时也会使用含目标的  $\mathbf{R}_{xx}$ ，但目标泄漏会带来自消风险。快拍少会使两种采样协方差都不稳定，仍需对角加载、收缩估计或降阶，不能把  $\mathbf{R}_{xx}$  当作小快拍问题的自动解法；见 § 5.4 工程要点。）

推导：与式(5-3)使用相同的拉格朗日乘子法，只是标量乘子改为  $K_c \times 1$  向量  $\vec{\lambda}$ 。要保证对  $\vec{w}^*$  求导时约束项确实产生  $\mathbf{C} \vec{\lambda}$ ，完整写法为

$$L = \vec{w}^H \mathbf{R} \vec{w} + \vec{\lambda}^H (\vec{f} - \mathbf{C}^H \vec{w}) + (\vec{f}^H - \vec{w}^H \mathbf{C}) \vec{\lambda}.$$

对  $\vec{w}^*$  求导并置零： $\mathbf{R} \vec{w} - \mathbf{C} \vec{\lambda} = \vec{0}$ ，因此  $\vec{w} = \mathbf{R}^{-1} \mathbf{C} \vec{\lambda}$ 。代入  $\mathbf{C}^H \vec{w} = \vec{f}$  得

$$\vec{\lambda} = (\mathbf{C}^H \mathbf{R}^{-1} \mathbf{C})^{-1} \vec{f}。$$

再代回就得到式(5-4)。原先只写  $\vec{\lambda}^H (\mathbf{C}^H \vec{w} - \vec{f})$  时，该项不含  $\vec{w}^*$ ，不能导出下一步；必须保留与之成对的共轭项。除  $M \times M$  的  $\mathbf{R}$  外，还要对  $K_c \times K_c$  的约束矩阵求逆。

**维度核对：**约束有  $K_c$  条， $\vec{f}$  和  $\vec{\lambda}$  都是  $K_c \times 1$  向量； $\mathbf{C}$  是  $M \times K_c$ ，所以  $\mathbf{C}^H \vec{w}$  与  $\vec{f}$  维度一致。矩阵  $\mathbf{C}^H \mathbf{R}^{-1} \mathbf{C}$  为  $K_c \times K_c$ 。若  $\mathbf{C}$  满列秩， $K_c$  条独立复线性约束把可调子空间的复维数从  $M$  降为  $M - K_c$ ； $K_c = M$  时，权重通常由约束唯一确定。

解的结构由两部分组成： $\mathbf{R}^{-1}$  按噪声与干扰的空间相关结构加权，后半部分把结果投影并归一化到满足全部约束的可行集合。常用约束包括：

1. 期望方向无失真，即  $f = 1$ ；
2. 已知干扰方向响应为零，即  $\vec{a}^H(\theta_i) \vec{w} = 0$ ；
3. 导数约束：令波束图在期望方向处对角度的一阶导数为零，以展宽目标方向附近的低失真区域。

导数约束可降低小幅 DOA 失配的影响，但会占用自由度并改变 WNG。

**约束不是免费的：**若  $\mathbf{C}$  满列秩，数学上可有  $K_c \leq M$  条独立约束。 $K_c = M$  时权重通常被约束唯一确定，没有剩余自由度用于根据  $\mathbf{R}$  压噪；若希望保留至少一个自适应自由度，则需  $K_c < M$ 。约束增多不必然使 WNG 单调恶化，但会缩小可行集合，必须逐频点检查 WNG 与目标响应。

#### 算例 5-2 补充：LCMV 双约束

**题设：**沿用算例 5-2 的 2 麦阵 ( $d = \lambda/2$ ，目标  $0^\circ$ ，干扰  $30^\circ$ )，但这次干扰方向已知，要求同时满足两条约束：目标方向增益为 1、干扰方向增益为 0。约束矩阵  $\mathbf{C} = [\vec{a}_0, \vec{a}_i] (2 \times 2)$ ，约束值  $\vec{f} = [1, 0]^\top$ ，噪声取白噪  $\mathbf{R} = \mathbf{I}$ （先看约束本身的效果，不掺自适应）。

**求解：** $\mathbf{R} = \mathbf{I}$  时  $\mathbf{C}^H \mathbf{R}^{-1} \mathbf{C} = \mathbf{C}^H \mathbf{C}$ 。 $\vec{a}_0 = [1, 1]^\top$ ， $\vec{a}_i = [1, +j]^\top$ ，所以

$$\mathbf{C}^H \mathbf{C} = \begin{bmatrix} 2 & 1+j \\ 1-j & 2 \end{bmatrix}。$$

该矩阵的行列式为  $4 - |1+j|^2 = 2$ ，逆为  $\frac{1}{2} \begin{bmatrix} 2 & -(1+j) \\ -(1-j) & 2 \end{bmatrix}$ 。

$\vec{w} = \mathbf{C}(\mathbf{C}^H \mathbf{C})^{-1} \vec{f}$  取逆矩阵第一列： $\vec{w} = \frac{1}{2}(2\vec{a}_0 - (1-j)\vec{a}_i)$ 。展开得  $\vec{w} = [0.5 + 0.5j, 0.5 - 0.5j]^\top$ 。

**验证约束：** $\vec{w}^H \vec{a}_0 = (0.5 - 0.5j) + (0.5 + 0.5j) = 1 \checkmark$ ； $\vec{w}^H \vec{a}_i = (0.5 - 0.5j) + (0.5 + 0.5j)(+j) = 0 \checkmark$ 。干扰方向满足精确零响应约束。

此时  $\|\vec{w}\|^2 = 1$ ， $\text{WNG}_{\text{dB}} = 0 \text{ dB}$ ，比 DSB 的 +3 dB 低 3 dB。2 个麦和 2 条独立约束使权重由约束唯一确定，没有剩余自由度再根据  $\mathbf{R}$  调整白噪声输出。

相比之下，算例 5-2 的 MVDR 只约束目标，得到  $\text{WNG}_{\text{dB}} = +0.39 \text{ dB}$  和干扰方向 -23.8 dB。LCMV 适合方向先验可靠且需要硬约束的情形；MVDR 根据估计协方差自适应抑制干扰。两者的选择还取决于方向误差和协方差估计质量。

多通道维纳滤波（Multichannel Wiener Filter，简称 MWF）直接在均方误差准则下权衡目标失真与残余噪声；MVDR 则施加硬的无失真约束，两者不能一般性地视为同一个解。语音失真加权多通道维纳滤波（Speech Distortion Weighted MWF，简称 SDW-MWF）写成

$$J(\vec{w}) = E\{|n_{out}|^2\} + \frac{1}{\mu} E\{|s_{out} - s_{ref}|^2\} \Rightarrow \vec{w}_{SDW} = (\mathbf{R}_{ss} + \mu \mathbf{R}_{nn})^{-1} \mathbf{R}_{ss} \vec{e}_r。 \quad (5-5)$$

- $\mathbf{R}_{ss}, \mathbf{R}_{nn}$ : 目标与噪声协方差矩阵;  $\vec{e}_r$ : 参考麦选择向量 (第  $r$  位为 1 的单位向量, 即 “以第  $r$  个麦收到的目标为基准”);
- $\mu = 1$  是普通 MWF;  $\mu > 1$  更重视噪声项, 抑制增强而目标失真通常增大;  $\mu < 1$  更重视目标保真。令  $\mu \rightarrow \infty$  时权重趋近零, 并不趋近 MVDR。只有秩一目标模型  $\mathbf{R}_{ss} = \phi_s \vec{a} \vec{a}^H$  且参考麦归一化  $a_r = 1$  时, 才有

$$\vec{w}_{SDW} = \frac{\phi_s q}{\mu + \phi_s q} \vec{w}_{MVDR}, \quad q = \vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}.$$

此时 SDW-MWF 是 MVDR 输出再乘一个标量 Wiener 增益, 并在  $\mu \rightarrow 0^+$  时趋近 MVDR。目标协方差满秩时没有这个简单关系。[Doclo, Spriet, Wouters & Moonen, \*Speech Communication\*, vol.49, p.636, 2007](#)

前文给出的是 LCMV 的频域闭式解。Frost 算法是它的一种经典时域在线实现; 下面给出更新式, 并与 GSC 的结构对照。

Frost 波束形成器 (1972) : LCMV 的时域在线版。§ 5.1 末提过它是滤波求和的自适应代表, 这里把更新式写出来: 每路麦接一段  $J$  抽头 FIR, 第  $m$  路第  $j$  抽头权重记  $w_{m,j}$ , 全权重向量  $\vec{w}$  共  $MJ$  个系数。约束是“看目标方向”的线性约束  $\mathbf{C}^H \vec{w} = \vec{f}$  (比如每列约束钉住一个抽头时刻的目标响应), 更新分两步走:

$$\vec{w}(l+1) = \mathbf{P} [\vec{w}(l) - \mu \vec{x}(l) y^*(l)] + \vec{w}_q.$$

方括号中是复数 LMS 的瞬时负梯度步: 对  $|y(l)|^2$  求导得到与  $\vec{x}(l) y^*(l)$  同向的梯度。投影矩阵  $\mathbf{P} = \mathbf{I} - \mathbf{C}(\mathbf{C}^H \mathbf{C})^{-1} \mathbf{C}^H$  把更新限制在约束零空间,  $\vec{w}_q = \mathbf{C}(\mathbf{C}^H \mathbf{C})^{-1} \vec{f}$  是满足约束的最小范数特解。约束模型匹配时, 更新不改变受约束的目标响应; 指向或传递函数失配时, 真实目标仍可能失真。步长太大会发散, 太小则跟不上非平稳干扰。

Frost 与 GSC 对照表 (同一类 LCMV 约束的两种实现结构) :

|       | Frost (1972)                                 | GSC                                         |
|-------|----------------------------------------------|---------------------------------------------|
| 域     | 时域 FIR 抽头                                    | 频域逐频点 (TF-GSC) 或时域皆可                        |
| 约束怎么装 | 投影矩阵 $\mathbf{P}$ , 每步拽回约束平面                 | 结构吸收: 固定上支路 + 阻塞矩阵, 下支路无约束自适应               |
| 自适应算法 | 原始 Frost 使用带投影的 LMS; 也可研究其他受约束更新             | 下支路可使用 LMS、NLMS、RLS 等无约束更新                  |
| 收敛与跟踪 | 由自适应算法、输入协方差特征值分布、步长和约束实现共同决定                | 还受阻塞矩阵、下支路输入统计和所选自适应算法影响; 结构本身不保证比 Frost 更快 |
| 失配症状  | 目标泄漏进 LMS, 实际目标不再满足设计约束                      | 目标泄漏进阻塞矩阵下支路, 被当作干扰抵消                       |
| 延迟    | 不含 STFT 分帧等待, 但仍有滤波器群时延、约束对齐延迟、输入输出缓冲和硬件分块延迟 | 频域版另有窗、帧移、重叠相加和前瞻造成的等待; 时域版仍有滤波与缓冲延迟        |
| 约束实现  | 每次更新后投影回约束子空间                                | 固定支路与阻塞矩阵从结构上满足约束                           |


Frost 用投影更新实现时域 LCMV; 下一节的 GSC 用固定支路和阻塞矩阵实现同一类约束。

### 5.6 广义旁瓣对消器 (Generalized Sidelobe Canceller, 简称 GSC) : 把约束改装成 “噪声对消器”

广义旁瓣对消器把 LCMV 约束吸收进结构, 分两条支路。[Griffiths & Jim, \*IEEE Transactions on Antennas and Propagation\*, 1982](#)

图17 GSC（广义旁瓣对消器）结构框图

上支路（设计目标：期望方向单位响应）



模型匹配且滤波器收敛时：保持目标响应，对消相关干扰

图示说明：上支路固定波束形成器输出目标与残留噪声  $d$ ；下支路的阻塞矩阵在模型匹配时消除目标，得到近似不含目标的干扰参考  $u$ ；自适应滤波器由  $u$  估计上支路中与它相关的残留干扰  $y$ ，最后相减得到  $e = d - y$ 。图中的“目标无失真”和“干扰/噪声被自适应对消”表示设计目标，只有固定支路满足约束、阻塞矩阵模型匹配且自适应滤波器收敛时才成立。数值过程见算例 5-3。

- 上支路：固定波束形成器的设计目标是在期望方向保持规定响应，输出  $d$  包含目标与残留噪声；
- 下支路：阻塞矩阵  $\mathbf{B}$ （设计条件为  $\mathbf{B}^H \vec{a}(\theta_0) = \vec{0}$ ）在模型匹配时消除目标，产生干扰与噪声参考；多通道自适应滤波器再估计上支路中与该参考相关的分量  $y$ ；
- 相减  $e = d - y$ ：在上支路满足目标约束、阻塞矩阵精确消除目标且自适应滤波器收敛时，对消与下支路相关的噪声，同时保持设计目标响应。任一条件失配都可能造成目标衰减。

算例 5-3：GSC 数字走一遍——干扰是怎么被“减掉”的。 `scripts/make_figures.py::fig_gsc` 只生成图17的结构框图；本例直接求给定单快拍模型下的最优系数，不模拟有限步自适应收敛。

题设：2 麦， $d = \lambda/2$ ；目标  $0^\circ$ ，即正横方向；干扰  $60^\circ$ 。

上支路使用延迟求和。下支路使用阻塞矩阵  $\mathbf{B} = [1, -1]^\top$ ，其维度为  $2 \times 1$ ，两路相减。这是 2 麦特例； $M$  麦时  $\mathbf{B}$  为  $M \times (M - 1)$ ，常用相邻通道相减或取  $\vec{a}(\theta_0)$  的正交补基。

2 麦阻塞后只剩 1 路噪声参考，因此自适应滤波器退化为 1 个复数抽头  $h$ 。

预备数字： $\psi_{60} = \pi \sin 60^\circ = 2.7207 \text{ rad } (155.9^\circ)$ ， $\vec{a}(0^\circ) = [1, 1]^\top$ ， $\vec{a}(60^\circ) = [1, e^{+j2.7207}]^\top = [1, -0.9127 + 0.4086j]^\top$ 。

第 1 步：上支路（延迟求和）漏进多少干扰

上支路权重  $\vec{w}_u = [0.5, 0.5]^\top$ 。目标方向增益  $\vec{w}_u^H \vec{a}(0^\circ) = 1 \checkmark$ （无失真）； $60^\circ$  方向的泄漏增益：

$$g_u = \vec{w}_u^H \vec{a}(60^\circ) = \frac{1}{2}(1 + e^{+j2.7207}) = 0.0436 + 0.2043j, \quad |g_u| = |\cos \frac{\psi}{2}| = 0.2089 \text{ } (-13.6 \text{ dB})$$

干扰在目标支路里还残留约 21% 的幅度——这就是图17 中 “ $d$  = 目标 + 漏入噪声” 里那部分 “漏入噪声”。

## 第 2 步：下支路把目标陷掉、只留干扰

验证阻塞： $\mathbf{B}^H \vec{a}(0^\circ) = 1 \times 1 + (-1) \times 1 = 0 \checkmark$ 。目标方向被精确陷掉，下支路里没有目标。这是整个结构的关键前提；§ 5.6 所说的“阻塞矩阵失配”，就是指这个 0 在实际中保不住。

干扰在下支路的增益为

$$g_\ell = \mathbf{B}^H \vec{a}(60^\circ) = 1 - e^{+j2.7207} = 1.9127 - 0.4086j, \quad |g_\ell| = 2 \left| \sin \frac{\psi}{2} \right| = 1.9559$$

两路相减反而把干扰放大了近 2 倍（因为  $60^\circ$  方向上两麦相位差  $155.9^\circ$ ，接近反相，相减近乎同相叠加）——没关系，它只是一份“干扰参考样本”。

## 第 3 步：拿一个具体快拍走一遍

设该频点目标谱  $s = 1$ 、干扰谱  $i = 1$ （都是标量复数），则阵列快拍：

$$\vec{x} = \vec{a}(0^\circ) \cdot 1 + \vec{a}(60^\circ) \cdot 1 = \begin{bmatrix} 2.0000 \\ 0.0873 + 0.4086j \end{bmatrix}$$

$$\text{上支路输出: } d = \vec{w}_u^H \vec{x} = \frac{2.0000 + 0.0873 + 0.4086j}{2} = 1.0436 + 0.2043j = \underbrace{1}_s + \underbrace{(0.0436 + 0.2043j)}_{g_u \cdot i};$$

（花括号下第二项即泄漏项  $g_u \cdot i$ 。）

$$\text{下支路输出: } u = \mathbf{B}^H \vec{x} = 2.0000 - (0.0873 + 0.4086j) = 1.9127 - 0.4086j (= g_\ell \cdot i, \text{ 纯干扰, 目标分量为 } 0)。$$

## 第 4 步：自适应滤波器学出的那个系数

对消器要减掉的正是泄漏项  $g_u \cdot i$ ，而它手里只有  $u = g_\ell \cdot i$ ，所以最优系数：

$$h^* = \frac{g_u}{g_\ell} = +0.1068j, \quad h = -0.1068j$$

（直接乘子  $h^*$  是纯虚数：把下支路的干扰副本旋转  $+90^\circ$ ，再缩放到 0.107 倍。）验证：

$$h^* \cdot u = +0.1068j \times (1.9127 - 0.4086j) = 0.0436 + 0.2043j。$$

（在给定舍入精度内与泄漏项一致。）

$$e = d - h^* u = (1.0436 + 0.2043j) - (0.0436 + 0.2043j) = 1.0000 = s \checkmark$$

在本例的单个相干干扰、精确阵列模型和最优系数下，输出只剩目标。把同一路径上的干扰标量换成  $i = 0.5j$ 、 $-2$ 、 $0.3 + 0.7j$  再算， $e$  仍等于 1，因为上下支路的干扰都按同一标量缩放。加入不相关噪声、第二个独立干扰、阻塞泄漏或有限步自适应后，这个结论不再成立。

## 第 5 步： $h$ 不是算出来的，是“学”出来的

实际系统不知道  $g_u$ 、 $g_\ell$ 。按  $e = d - h^* u$  的复数约定，NLMS 更新应写成  $h \leftarrow h + \mu u e^* / (|u|^2 + \varepsilon)$ 。若阻塞支路中只有与目标不相关的干扰，这个更新会学习上支路中与  $u$  相关的分量。本例的收敛目标是  $h = -0.1068j$ ，等价的直接乘子  $h^*$  为  $+0.1068j$ ；具体稳定步长和收敛帧数取决于输入统计，不能由这一帧手算固定。

## 第 6 步：检查阻塞矩阵失配

上述对消依赖  $\mathbf{B}^H \vec{a}(0^\circ) = 0$ 。若目标实际方向偏到  $2^\circ$ ，则  $\mathbf{B}^H \vec{a}(2^\circ) = 1 - e^{+j\pi \sin 2^\circ} \approx 0.0060 - 0.1094j$ ；其模约为 0.1096，功率约为 1.2%。自适应滤波器会把泄漏目标的一部分当作干扰抵消，造成语音衰减或断续。可使用自适应阻塞矩阵（ABM）和语音存在门控降低这一风险。

**优点：**约束由固定支路与阻塞矩阵实现，下支路可用 LMS 等无约束自适应算法。**主要边界——阻塞矩阵失配：**目标因 DOA 误差或混响泄漏进下支路时，会被当作噪声对消。可使用自适应阻塞（ABM）、语音存在概率门控步长和泄漏均衡（CA-GSC）。

LCMV 与 GSC 的等价条件：若固定权重满足 LCMV 约束，阻塞矩阵的列满秩且张成约束矩阵的零空间，无约束支路又达到同一二次目标的最优解，那么 GSC 与 LCMV 给出同一个最优权重。GSC 把“带约束求解”改写成“固定支路 + 零空间内的无约束优化”。有限步自适应、阻塞矩阵失配、秩不足或不同的正则化都会破坏严格等价，因此工程实现仍要分别检查收敛和目标泄漏。Breed & Strauss, IEEE SPL 2002

LCMV 把 MVDR 的单约束推广为多约束；Frost 用投影更新实现时域 LCMV；GSC 用固定支路和阻塞矩阵实现相同约束。三者都受约束失配影响，GSC 还要单独检查目标向下支路的泄漏。

## 5.7 后置滤波

波束形成后仍可能保留弥散噪声、旁瓣干扰和估计误差。后置滤波利用时频统计进一步衰减这些残留，本节依次讨论 SPP 噪声估计（§ 5.7.1）、Wiener 增益（§ 5.7.2）和音乐噪声代价（§ 5.7.3）。

波束输出通常仍含残留混响与弥散噪声，可再级联单通道增强器。基本过程是在波束输出上估计残留噪声谱，再按每个时频点的信噪比计算增益。不同方法的主要区别在于噪声谱估计方式：

- Zelinski (1988)：先按目标方向做时延/相位对齐，并通常把各通道目标传递幅度归一化；随后假设对齐后的目标在各麦间同相幅、噪声互不相关，用“各麦自谱平均 - 互谱实部平均”估计噪声功率谱：

$$\hat{\Phi}_{nn}(k) = \frac{1}{M} \sum_{i=1}^M \Phi_{x_i x_i}(k) - \frac{2}{M(M-1)} \sum_{i < j} \text{Re}\{\Phi_{x_i x_j}(k)\}.$$

（式中  $\Phi$  均为功率谱： $\Phi_{x_i x_i}$  为自功率谱， $\Phi_{x_i x_j}$  为互功率谱。）若没有先对齐，目标互谱带有传播相位，其实部不再等于目标功率，公式会把目标的一部分误判为噪声。即使已对齐，噪声相关或通道目标幅度不同也会造成偏差；

- McCowan (2003) 的改进：Zelinski 的“各麦噪声互不相关”假设不适用于弥散混响场；相邻麦噪声具有相干性，直接使用互谱关系可能低估噪声功率，有限样本下还可能得到负估计。McCowan 方法引入弥散噪声场的理论相干函数（sinc 形的  $\mathbf{\Gamma}$ ，§ 5.1）修正互谱项。其效果取决于实际声场与弥散模型的匹配程度（本节算例给出指定输入下的偏差量级）；
- 对数谱幅度（Log-Spectral Amplitude, LSA）/优化修正 LSA（Optimally Modified LSA, OM-LSA）：在对数谱幅度最小均方误差准则下估计增益；OM-LSA 还显式结合语音存在不确定性。Habets & Cohen, IWAENC 2006

### 5.7.1 逐时频点语音存在概率（SPP）

SPP（Speech Presence Probability，语音存在概率）记为  $p(k, n) \in [0, 1]$ ，表示第  $k$  个频点、第  $n$  帧含语音的后验概率。它不同于 VAD 的帧级 0/1 判决，可用于在语音保留与噪声更新之间连续加权。

最小值控制递归平均（Minima-Controlled Recursive Averaging, MCRA）：算法在每个频点跟踪一段时间内的平滑功率最小值，并根据当前功率相对该最小值的偏离估计 SPP。SPP 较低时更新噪声谱，SPP 较高时减慢或冻结更新，以减少语音泄漏对噪声估计的污染。改进最小值控制递归平均（Improved Minima-Controlled Recursive Averaging, IMCRA）进一步改进了最小值跟踪和概率估计；具体窗口与门限应按所用文献版本实现。

对前级自适应模块的门控：GSC 可把 NLMS 步长乘以  $(1 - p)$ ，在语音存在概率高时减慢更新；MVDR 也可主要使用低 SPP 时频点更新噪声协方差。这些门控都依赖 SPP 的校准质量，错误的高概率会降低跟踪速度，错误的低概率会增加目标泄漏。

### 5.7.2 Wiener 后滤通用式：SPP 加权与 MWF 级联

上面 Zelinski/McCowan 都是“先估噪声谱、再按信噪比打折”，统一写成 Wiener 通用式：

$$G(k, n) = \max\left(1 - \frac{\hat{\Phi}_{nn}(k, n)}{\Phi_{yy}(k, n)}, G_{\min}\right), \quad \hat{S} = G \cdot Y.$$

$Y$  是波束输出， $\Phi_{yy}$  是其功率谱， $\hat{\Phi}_{nn}$  是估计的残留噪声谱， $G_{\min}$  是最小允许增益，也称增益地板。它限制最大衰减量，以减轻谱估计误差造成的音乐噪声；取值应按听感、目标失真和残留噪声共同确定。SPP 可用于条件更新噪声谱，也可连续调节增益。优化修正 LSA（OM-LSA）是在对数谱幅度最小均方误差准则下结合语音存在不确定性的一类方法。

与 MWF 的关系：MWF（§ 5.5 末）在一个均方误差目标中联合权衡残留噪声和目标失真。MVDR 与单通道 Wiener 后滤级联时，前级施加空间无失真约束，后级再按时频统计抑制残留噪声；两级的估计误差和延迟会累加。两种结构没有无条件的优劣，应在同一目标参考、延迟预算和任务指标下比较。

### 5.7.3 音乐噪声与三项调节参数

音乐噪声表现为随时间和频率随机出现的窄带音调成分。主要原因是噪声谱估计误差使相邻时频点的增益变化不连续，以及  $G_{\min}$  过低导致被强衰减点与残留点之间反差过大。

三项参数分别影响不同误差：

1. 提高增益地板  $G_{\min}$  会减小相邻时频点之间的衰减反差，通常也会保留更多残留噪声。
2. 帧间或频间平滑会减小增益的局部波动，但平滑时间或频带过宽时会模糊语音起止和瞬态。
3. 把增益改为  $1 - \alpha \hat{\Phi}_{nn} / \Phi_{yy}$  且取  $\alpha > 1$ ，会增大估计噪声的扣除量，同时提高目标语音被衰减的风险。 $\alpha$  没有脱离算法版本、噪声估计偏差和数据集的通用范围。

参数选择应在同一组验证片段上做受控扫描，同时报告残留噪声、目标失真和音乐噪声的听评或指标。比较某一参数时保持其余参数不变。

#### 算例 5-4：残留噪声谱估计与逐点增益

题设：3 麦已按目标对齐。某频点三路输入功率谱都是  $\Phi_{xx} = 4$ （目标功率 3、噪声功率 1），两两噪声互谱实部为  $+0.3$ ，所以总互谱实部为  $3.3$ 。用 Zelinski 式估噪声谱，再算维纳型后置增益。

第 1 步（估噪声谱）：自谱平均为 4，互谱实部平均为 3.3，因此  $\hat{\Phi}_{nn} = 4 - 3.3 = 0.7$ 。真实噪声功率是 1，Zelinski 低估了 0.3：正相关噪声被误当成相干目标。若噪声互不相关，互谱实部为 3.0，估计才等于 1.0；若噪声相关实部为负，偏差方向会相反。

第 2 步（算增益）：若波束输出功率谱取 4，则  $G = 1 - 0.7/4 = 0.825$ 。同一个实数增益会把该时频点的目标和噪声功率都乘以  $G^2$ ，所以单个时频点的 SNR 不变。整段信号的 SNR 改善来自不同点使用不同增益：语音缺席、噪声占优的点应压得更多。具体改善量取决于语音存在率、谱估计偏差、增益平滑和评价区间，不能由这个单点例子推出固定的 dB 数。

为什么放在最后、且通常只改幅度：波束形成先利用空间信息，后置滤波再按时频统计压制残留噪声。实数非负增益保留波束输出相位，但仍会改变目标幅度；降噪量与目标失真必须在同一测试集、同一参考信号和同一统计区间内同时报告，不能脱离条件承诺固定 dB 收益。学习型后置滤波器也要按相同口径检查目标失真、因果延迟和目标硬件上的资源消耗，不能仅凭模型名称推断效果。

## 5.8 球谐域波束形成（球阵专属）

球阵把声场分解为球谐系数：

$$p(\kappa, \Omega) = \sum_{n=0}^N \sum_{m=-n}^n b_n(\kappa r) Y_n^m(\Omega) \varphi_{nm}(\kappa)$$

逐个符号说明如下。式中已省略与方向无关的常数因子。

- $p(\kappa, \Omega)$  是波数  $\kappa = 2\pi f/c$ 、方向  $\Omega$  处的声压；这里改用  $\kappa$ ，避免与前文的 STFT 频点索引  $k$  混淆；
- $Y_n^m(\Omega)$  是球谐函数，阶数  $n$  表示球面上的空间变化快慢，同一阶有  $2n + 1$  个不同的  $m$ ；
- $b_n(\kappa r)$  是径向项，描述半径  $r$  的球阵对第  $n$  阶成分的响应；刚性球与开放球的形式不同；
- $\varphi_{nm}(\kappa)$  是声场在第  $(n, m)$  个空间模式上的系数。

球谐展开与时间傅里叶展开的共同点是都把信号投影到一组正交基。两者的定义域和物理单位不同，不能把波数直接当作频点编号。

在理想球谐表示、相同阶数截断和正确旋转下，波束图可通过旋转系数转向而不改变自身形状。该性质支持高阶立体声（Higher-Order Ambisonics，简称 HOA）录音、最大 DI 波束和相位模式超指向。

表示到  $N$  阶共有  $(N + 1)^2$  个系数，因此  $M \geq (N + 1)^2$  只是阵元数量的必要条件。采样矩阵还必须满列秩，阵元布局要能稳定区分这些模式，径向响应也不能落入未正则化的深零点。高阶重建常因径向补偿和采样条件数而放大噪声。

课程讲义引用的特定实验称小球阵可接近大线阵的识别性能，该结论只适用于其阵列、数据和识别器。[Kumatani et al. (出处同 § 5.2 引文) ]

圆阵的二维对应：相位模式（phase-mode / 圆谐波）处理。智能音箱的圆阵用同一思想的二维版：圆环上的声场做方位角傅里叶分解（Jacobi – Anger 展开），各阶圆谐波系数经模态补偿（除以贝塞尔函数  $J_n(\kappa r)$ ）后，可在模型成立的频带内合成可电子旋转的目标波束。代价与球阵同族：模态阶数受麦数限制， $J_n(\kappa r)$  接近零时补偿会放大噪声，需要正则化和 WNG 约束。同心多环圆阵（Concentric Circular Microphone Array, 同心圆麦克风阵列, CCMA）可扩展可控频带与空间自由度（Huang, Chen & Benesty, *Insights into Frequency-Invariant Beamforming with Concentric Circular Microphone Arrays*, IEEE/ACM TASLP, vol.26, no.12, pp.2305 – 2318, DOI [10.1109/TASLP.2018.2862826](https://doi.org/10.1109/TASLP.2018.2862826)）。

球谐域实现步骤：

1. 设备选型：先定最高工作频率  $f_{\max}$  与球半径  $r$ ，算  $\kappa r = 2\pi f_{\max} r / c$ ；阵元数要满足  $M \geq (N + 1)^2$ ，还要检查实际采样矩阵的秩和条件数。刚性球与开放球的径向响应不同，选型时应计算目标频带内各阶  $b_n(\kappa r)$  的最小幅度，而不能只按麦数定阶；
2. 定阶数： $N \approx \kappa r$  可作为声场截断的起点，因为远高于  $\kappa r$  的阶成分幅度通常较小。如  $r = 4.2$  cm、 $f = 4$  kHz， $\kappa r \approx 3.1$ ，可先评估  $N = 3$ （至少需要 16 个稳定、独立的采样通道）；最终阶数还要受 WNG 和径向条件数约束；
3. 径向补偿：球谐系数  $\varphi_{nm}$  要从麦克风声压反推，需除以径向项  $b_n(\kappa r)$ 。当  $|b_n|$  很小时，补偿会放大噪声；应对逆径向滤波做正则化或显式限制模态 WNG，并报告阈值的归一化口径；
4. 正则化：对高阶模态加入特征波束正则。它与 § 5.4 的对角加载都通过限制病态方向上的增益改善数值稳定性，但作用域和参数定义不同；
5. 实现检查：先用球谐变换把阵列信号转成  $\varphi_{nm}(\kappa)$ ，再在模态域设计权重。固定目标波束可用 Wigner-D 矩阵旋转系数；涉及数据相关 SCM 的 MVDR 仍要更新统计量和权重，不能把所有波束都概括为“一次闭式求解”。

## 5.9 深度神经网络（Deep Neural Network, 简称 DNN）波束形成

神经网络最适合先解决解析波束形成中难估计的统计量，而不是把多个模型名称并列成性能等级。以掩码波束形成为例，固定频点  $k$ ，多通道观测为  $\vec{x}(k, n) \in \mathbb{C}^M$ ，网络输出目标掩码  $m_s(k, n)$  和噪声掩码  $m_n(k, n)$ 。一个可复现的处理顺序如下。

1. 掩码到空间协方差矩阵（Spatial Covariance Matrix, SCM）：

$$\hat{\mathbf{R}}_{ss}(k) = \frac{\sum_n m_s(k, n) \vec{x}(k, n) \vec{x}^H(k, n)}{\sum_n m_s(k, n) + \epsilon}, \quad \hat{\mathbf{R}}_{nn}(k) = \frac{\sum_n m_n(k, n) \vec{x}(k, n) \vec{x}^H(k, n)}{\sum_n m_n(k, n) + \epsilon}.$$

分母只做掩码权重归一化； $\epsilon$  防止整段掩码接近零。协方差是否使用未来帧决定这一步能否在线运行。

2. SCM 到约束向量或广义特征向量：在秩一目标近似下，可取  $\hat{\mathbf{R}}_{ss}$  的主特征向量并按参考麦归一化，得到相对传递函数  $\hat{\vec{a}}$ 。MVDR 再用式(5-3)求权重。另一条路线直接解

$$\hat{\mathbf{R}}_{ss} \vec{w}_{GEV} = \lambda_{\max} \hat{\mathbf{R}}_{nn} \vec{w}_{GEV},$$

最大化估计输出 SNR。GEV 没有无失真约束， $c \vec{w}_{GEV}$  对任意非零复数  $c$  都表示同一广义特征向量，因此必须注明参考麦归一化、盲解析归一化（Blind Analytic Normalization, BAN）或后置滤波的尺度规则。Warsitz & Haeb-Umbach 2007

3. 滤波与检查：输出  $Y = \vec{w}^H \vec{x}$ 。除信号指标外，还要检查  $\hat{\mathbf{R}}_{nn}$  条件数、目标响应、WNG、掩码泄漏和通道置换。网络训练集未覆盖的阵列几何或混响条件可能使 SCM 估计偏离真实统计量；解析求解并不会自动消除这种误差。Erdogan et al., Interspeech 2016、Heymann et al., ICASSP 2017

两麦小例子：设掩码估得  $\hat{\mathbf{R}}_{nn} = \text{diag}(2, 1)$ ，目标 RTF 为  $\hat{\vec{a}} = [1, 1]^T$ 。则  $\hat{\mathbf{R}}_{nn}^{-1} \hat{\vec{a}} = [0.5, 1]^T$ ，归一化分母为 1.5，所以  $\vec{w}_{MVDR} = [1/3, 2/3]^T$ 。

可直接验证  $\vec{w}^H \hat{\vec{a}} = 1$ ，输出噪声功率为  $\vec{w}^H \hat{\mathbf{R}}_{nn} \vec{w} = 2/3$ 。

若目标掩码把干扰大量计入  $\hat{\mathbf{R}}_{ss}$ ，RTF 会偏移，上述无失真条件只对错误的  $\hat{\vec{a}}$  成立。

端到端网络也可以直接估计复数权重、时域滤波器或输出波形。它不再自动满足无失真、WNG 或因果约束，必须把阵列泛化、前瞻帧数、目标失真和目标硬件上的资源消耗列入评测。若与 ASR 联合训练，还应固定后端识别器和评分脚本，同时报告前端信号指标与词错误率（Word Error Rate, WER）。Gu et al., IEEE/ACM TASLP 2023

可执行基线与上线检查

`beamforming.py` 提供 DSB、弥散场相干矩阵、加载超指向/MVDR、LCMV、GSC 阻塞矩阵和 Wiener 增益的原创 NumPy 基线。权重约定统一为输出  $Y = \vec{w}^H \vec{x}$ ，多通道谱形状统一为 通道 × 频点 × 帧；逐频点权重为 频点 × 通道。函数用线性方程求解代替显式求逆；未加载协方差病态、LCMV 约束不独立或空统计量都会报错。正文算例的 DSB 单位响应、Capon 数值、MVDR 权重、LCMV 双约束、GSC 阻塞和 Wiener 增益由 `test_codes_doa_beam.py` 独立回归，串联示例见 `ch02_05_baselines.py`。

这些函数是公式基线，不是完整设备状态机。实时实现还要记录 STFT 窗长和帧移、分数延时滤波器、固定传播补偿、参考通道、SCM 遗忘因子、VAD/SPP 门控、权值更新周期和输出限幅。每次更新后检查条件数、 $|\vec{w}^H \vec{a} - 1|$ 、WNG 和输出峰值；空掩码或病态矩阵出现时，应在“保持上一组已验证权值、增加已标明口径的加载、退回 DSB”之间预先规定顺序。目标泄漏时应冻结噪声 SCM 或 GSC 自适应支路，并记录触发原因，不能只在输出失真后重新初始化。

第三方项目只作索引，不复制源码。核实于 2026-09-22 的官方参考包括：[torchaudio MVDR 教程及其官方示例源码](#)（BSD-2-Clause）。该教程链接指向 nightly 文档，页面当日打印的版本为 `torchaudio 2.11.0a0+2470b9c`；官方仓库当日 `main` 的完整提交为 `b85c99ccac635a06b1afaf5284bf4c1a00c1f9b5`，两者不能当成同一个稳定发行版。官方主页还说明 `torchaudio` 自 2.8 起进入维护阶段，部分 API 在 2.8 弃用并于 2.9 移除，因此复现应固定实际验证版本。`ESPnet beamformer` 采用 Apache-2.0，当日发布页显示 v.202609；`SpeechBrain` 采用 Apache-2.0。完整 GEV+BAN、WPD、神经掩码、球谐径向滤波、MCRA/IMCRA 与 OM-LSA 需要额外算法和依赖，本轮不把它们伪装成本书已经覆盖的最小实现。

5.10 波束形成算法总对比

不同方法的混响抑制量不能脱离阵列、数据、因果性和指标压成星级。下表只比较可由定义确定的目标、输入与失败条件；运算量仍要按通道数、频点数、滤波长度和实现测量。

| 方法            | 优化目标或固定规则       | 需要的统计量/先验        | 目标保持条件                   | 主要失败模式           | 主要计算            |
|---------------|-----------------|------------------|--------------------------|------------------|-----------------|
| DSB           | 导向后等权平均         | 导向向量或时延          | 导向匹配                     | 空间分辨率有限；混叠或导向误差  | 延迟/相位补偿与求和      |
| 超指向           | 在弥散场模型下最大化 DI   | 阵列几何、弥散相干矩阵      | 精确模型与单位响应约束              | 低频 WNG、阵元失配、矩阵病态 | 每频点线性方程求解       |
| DMA           | 小间距差分形成目标图形     | 间距、内部延迟、均衡器      | $\kappa d \ll 1$ 近似及标定成立 | 自噪声和失配经差分、均衡放大   | 延迟、FIR 与求和      |
| MVDR          | 无失真约束下最小输出噪声    | 噪声 SCM、导向向量或 RTF | 约束向量等于真实目标传递向量           | SCM 误差、目标泄漏、导向失配 | SCM 估计与矩阵求解     |
| LCMV          | 多个线性约束下最小输出功率   | SCM、全部约束向量与响应    | 约束模型匹配且可行                | 约束占用自由度、约束失配     | MVDR 外加小型约束矩阵求解 |
| GSC           | 在约束零空间内自适应对消    | 固定支路、阻塞矩阵、噪声参考   | 精确阻塞且自适应支路收敛             | 目标泄漏到阻塞支路        | 阻塞变换与自适应滤波      |
| MWF/SDW-MWF   | 最小化目标估计均方误差     | 目标与噪声 SCM、参考麦    | 不保证严格无失真                 | 统计失配和目标—噪声权衡设置错误 | SCM 估计与矩阵求解     |
| 掩码 + MVDR/GEV | 网络估计 SCM，解析层求权重 | 多通道谱、训练得到的掩码     | MVDR 还需正确 RTF；GEV 需定尺度   | 掩码泄漏、训练分布和阵列变化   | 网络推理、SCM 与矩阵求解  |

| 方法    | 优化目标或固定规则      | 需要的统计量/先验   | 目标保持条件          | 主要失败模式         | 主要计算         |
|-------|----------------|-------------|-----------------|----------------|--------------|
| 端到端滤波 | 按训练损失直接估计权重或输出 | 训练数据与固定输入定义 | 由损失和结构决定，通常无硬保证 | 域外阵列、未知设备、目标失真 | 由模型、上下文和硬件决定 |

贯穿全章的约束：在单位幅度导向向量和精确无失真约束下， $G_{\text{WNG}} \leq M$ ，等价地  $\text{WNG}_{\text{dB}} \leq 10 \log_{10} M$  dB。DI 同时受阵列几何、频率、噪声场模型和白噪声增益预算限制。紧凑端射阵在理想弥散场模型下可能获得高于 DSB 的 DI，但逼近强相消解通常伴随很低的  $\text{WNG}_{\text{dB}}$ ；脱离阵列几何、频率、噪声场和稳健性约束，不应给出统一的 DI 上限。

上表“目标保持条件”列只说明算法约束，并不是目标失真的数值。若要量化目标损伤，必须先固定基线。以参考麦选择向量  $\vec{e}_r$  为基线，噪声降低量定义为

$$\text{NR}_{\text{ref}} = 10 \log_{10} \frac{\vec{e}_r^H \mathbf{R}_{nn} \vec{e}_r}{\vec{w}^H \mathbf{R}_{nn} \vec{w}}.$$

分子、分母要用同一频带和统计窗口。若以 DSB 为基线，就把分子换成 DSB 的输出噪声功率并明确标注。存在导向失配时，只报 NR 会掩盖目标衰减，还应同时报告  $|\vec{w}^H \vec{a}_{\text{true}} - 1|$ ，或报告相对同一参考麦的输出 SNR 改善。

延伸阅读：Kumatani 等的 CMU 课程讲义

本章 § 5.2、§ 5.3、§ 5.8 引用的是同一份 [Kumatani et al. (出处同 § 5.2 引文)] CMU 远场语音识别课程讲义，其中讨论球阵、圆阵上的波束形成与识别实验。该材料是课程讲义而非期刊论文，适合用来比较算法结构与识别评测；公式与适用条件仍需回到相应原始论文核对。阅读时可围绕以下三点整理记录。

第一，GEV 与 MVDR 的约束差异。GEV 最大化输出信噪比，没有无失真约束，输出尺度由后续归一化确定；MVDR 对设计导向向量施加单位响应。阅读讲义的对比表时，应同时记录噪声抑制、目标失真、归一化方法和最终识别率，不能只比较单一分数。

第二，特征波束 (eigen-beam) 的结构。球谐或圆谐波域中的各阶模态可分别正则化。高阶模态通常提供更细的空间变化，也更容易放大噪声；应按 WNG 预算限制其增益。该处理与阵元域对角加载都用于限制病态逆问题，但作用矩阵和参数口径不同。

第三，与识别联合的评估视角。讲义同时报告前端波束形成和后端词错误率 (WER)。前端 SNR 改善不能保证 WER 同步改善，因为目标失真、相位变化和谱空洞也会影响识别器。复现实验时应在固定后端、数据划分和评分脚本下同时报告信号指标与任务指标。

这份讲义适合作为阵列算法与远场语音识别评估之间的补充材料；公式与适用条件仍应回到本章相应小节及原始论文核对。

**本章小结：**DSB 提供固定波束基线；超指向在弥散场 DI 与 WNG 之间权衡；MVDR、LCMV、Frost 和 GSC 用不同形式实现协方差驱动的约束优化；后滤波处理残留噪声；球谐域方法适用于球阵；神经网络可估计掩码、协方差或滤波器。选型时应同时报告目标响应、WNG、噪声降低量、延迟和任务指标。

### 5.11 本章练习

- DSB 增益与 WNG 上限：4 麦均匀线阵、DSB 指向目标，白噪声增益是多少 dB？再用柯西-施瓦茨不等式说明：任何满足无失真约束 ( $\vec{w}^H \vec{a} = 1$ ) 的权重， $G_{\text{WNG}}$  都不超过 4。（参考答案： $\text{WNG}_{\text{dB}} = 10 \log_{10} 4 \approx 6$  dB； $1 = |\vec{w}^H \vec{a}| \leq \|\vec{w}\| \|\vec{a}\| = \|\vec{w}\| \sqrt{4}$ ，故  $G_{\text{WNG}} = 1/\|\vec{w}\|^2 \leq 4$ ——等号在  $\vec{w} \propto \vec{a}$  即 DSB 时成立，完整两步见 § 5.2 的上限推导。）
- GSC 阻塞失配：沿用算例 5-3 的 2 麦阵，若目标实际偏到  $2^\circ$ （DOA 估计差  $2^\circ$ ），下支路会漏进多少目标功率？自适应对消器会如何处理这部分泄漏，输出会出现什么变化？（参考答案： $\mathbf{B}^H \vec{a}(2^\circ) \approx 0.0060 - 0.1094j$ ，模约为 0.1096，漏进约 1.2% 的目标功率（见算例第 6 步）；下支路的目标与上支路相关，对消器会把它也当干扰抵消，导致目标语音衰减或断续。对策见 § 5.6 末。）

# 第 6 章 · 声学回声消除 (AEC)

第 4、5 章和第 9 章讨论声源方向、波束和轨迹。本章转向设备播放声返回麦克风所形成的回声。混响拖尾和多说话人混合分别见第 7、8 章。

## 6.1 AEC 的模型、算法与实现

问题：音箱放音乐时，扬声器的声音经房间反射回到自己的麦克风。回声相对近端语音的强弱取决于播放音量、距离、房间和器件耦合；当回声占优时，唤醒和通话都会受到影响。

回声有一个可利用的条件：设备保存着播放信号  $x(n)$ 。未知的是播放信号经过扬声器、房间和麦克风之后形成的回声路径。本节先建立线性近似，再讨论非线性、双讲、残余抑制以及它与波束形成的顺序。

线性模型与自适应滤波（§ 6.1.1 ~ § 6.1.3）

### 6.1.1 回声从哪来：系统模型与四种场景

信号模型。先把播放链路近似成有限长、线性、时不变系统。麦克风录到的信号可以写成三项之和：


$$d(n) = s(n) + (x * h)(n) + v(n), \quad (x * h)(n) = \sum_{\ell=0}^{L-1} h[\ell]x[n - \ell]. \tag{6-1}$$

其中， $d(n)$  是第  $n$  个采样时刻的麦克风样本； $s(n)$  是需要保留的近端语音； $x(n)$  是设备保存的远端播放参考； $h[\ell]$  是长度为  $L$  的线性回声路径冲激响应， $\ell$  是抽头索引； $v(n)$  是环境噪声， $*$  表示卷积。短时间内采用固定的  $h[\ell]$ ；若要显式描述路径随时间变化，可写成  $h_n[\ell]$ 。AEC 要估计并减去  $x * h$ ，同时尽量保留  $s$ 。


这个模型不是完整的扬声器—房间—麦克风模型。它只覆盖参考抽头之后、在分析时间内可近似为线性且缓慢变化的部分。扬声器削顶、功放压缩和结构振动不能由单个线性卷积准确表示；人移动、设备转动和温度变化又会使  $h$  随时间改变。实际系统因此把  $h$  当作短时间内有效的近似，并用持续自适应跟踪变化；非线性残余另由 § 6.1.4 和 § 6.1.6 的模块处理。

图26 回声形成:  $d(n) = s(n) + x(n)*h[\ell] + v(n)$

(a) 用脉冲响应  $h[\ell]$  表示房间回声路径



(b) 卷积把声音拖长:  $x \rightarrow$  回声



(c) 麦克风里三者相加得  $d(n)$




图26 (a) 的合成路径显式放置直达分量和若干早期反射, 再叠加逐渐衰减的晚期尾声; 这些成分只用于说明卷积结构, 不代表某个实测房间。(b) 给出远端参考、卷积后的回声和 0.8~1.2 s 的近端语音。(c) 显示三者在麦克风信号  $d(n)$  中叠加。AEC 根据参考估计回声分量, 再从  $d(n)$  中减去该估计。

$h[\ell]$  表示从参考抽头到麦克风之间的线性等效路径, 包括转换器、扬声器的小信号响应、声学传播和麦克风响应。它与 § 2.4 的纯声学房间冲激响应有关, 但还包含电声器件的线性响应, 二者不能完全等同。滤波器所需覆盖时间应由目标设备的实测回声路径确定; 16 kHz 下 1 ms 对应 16 个抽头, 64 ms 对应 1024 个抽头。滤波器没有覆盖的晚期部分会留在残差中, 再由残余回声抑制器处理。

四种工作场景 (谈论任何 AEC 指标前先声明场景, 否则数字没有意义):

1. 远端单讲 (Single-Talk Far-End, STFE): 只有扬声器在响,  $s(n) = 0$ 。此时残差中的目标回声可以单独统计, 回声返回损失增强 (Echo Return Loss Enhancement, ERLE) 只在这个场景下有清楚的物理意义;
2. 近端单讲 (Single-Talk Near-End, STNE): 只有用户在说话, 回声路径没有激励, AEC 不应改变近端通道;
3. 双讲 (Double-Talk, DT): 两者同时存在。残差  $e$  中含近端语音, 继续更新会使路径估计偏离, 残余抑制也可能损伤近端语音, 控制方法见 § 6.1.5;
4. 双方沉默 (idle): 回声与语音都没有。滤波器不应在纯噪声激励下持续漂移, 残余抑制也不应把背景压成突兀的静音。测试矩阵应覆盖沉默期路径变化以及重新播放后的恢复过程 (§ 6.1.9、§ 6.1.12)。

免提通话需要同时控制远端单讲时的残余回声和双讲时的近端语音损伤。具体验收阈值应由目标场景、适用标准和主观听测确定, ERLE 的统计口径见 § 6.1.8。

主要难点 (Breining et al. 1999 年的综述系统讨论了以下四项):

1. 冲激响应长：回声路径覆盖时间增加时，时域滤波器需要更多抽头，计算量增加，收敛也可能变慢；§ 6.1.3 说明分区频域方案怎样降低滤波器的计算量；
2. 非线性：微型扬声器与功放在大音量下失真，线性滤波器怎么学都学不出来——§ 6.1.4 整节讲它；
3. 双讲：参考与目标同时存在，近端语音会使自适应更新产生偏差，见 § 6.1.5；
4. 路径时变：人走动、门开关、设备被挪动都会改变等效路径  $h_n[\ell]$ ；参考具有足够激励时，滤波器需要更新以跟踪这些变化。  
Breining et al., IEEE Signal Processing Magazine 1999

边栏：温度如何搬动回声。

声速随温度变化  $v \approx 331 + 0.61 T$  m/s,  $T$  为摄氏温度。温度每变化  $1^\circ \text{C}$ ，声速改变约 0.18%；变化  $10^\circ \text{C}$ ，就是约 1.8%。对固定 1 m 路径，传播时延从  $20^\circ \text{C}$  的  $1/343.2 \approx 2.914$  ms 变为  $30^\circ \text{C}$  的  $1/349.3 \approx 2.863$  ms，缩短约 51  $\mu\text{s}$ ，在 16 kHz 下约 0.82 个采样。

反射路径长度各不相同，所以每条路径按自身长度产生不同的时延变化，并非整条冲激响应统一平移 50  $\mu\text{s}$ 。

Elko、Diethorn 与 Gänslar (IWAENC 2003) 的实测表明，缓慢的热漂移会侵蚀已收敛 AEC 的性能。这是“路径时变”比较隐蔽、也无法靠出厂标定消除的一种形式。Elko, Diethorn & Gänslar, IWAENC 2003、Frontiers in Signal Processing 2024 (温度对 AEC 影响的实测研究)

减法与乘法两类处理。AEC 有已知参考，可以估计回声的幅度和相位后做减法；相位估计错误时，减法也可能放大残余。降噪 (§ 5.7) 通常没有噪声波形参考，只能估计能量并施加 0~1 的增益。§ 6.1.9 的非线性处理 (Nonlinear Processing, NLP) 残余抑制和第 5 章的后置滤波都属于后一类方法。

图27 AEC 结构：根据播放参考估计回声，再从麦克风信号中相减




图27显示基本信号流：播放参考一支经过扬声器和房间进入麦克风，另一支进入自适应滤波器以估计回声路径。估计回声从麦克风信号中减去，双讲检测控制滤波器是否更新。

### 6.1.2 线性自适应滤波：NLMS 回顾

做法：用一个自适应滤波器  $\hat{w}(n)$  去模仿这条回声路径  $h[\ell]$ ，把参考信号过滤一遍得到“回声副本”  $\hat{y}(n)$ ，再从麦克风信号里减掉：

$$e(n) = d(n) - \hat{w}^\top(n) \vec{x}(n)$$

滤波器当前的路径估计作用于播放参考，产生估计回声；残差越小，说明路径估计越接近实际路径。其中：

- $d(n)$ ：麦克风录到的信号（回声 + 用户语音 + 噪声，标量）； $\vec{x}(n)$ ：由最近一段播放样本组成的向量，其长度等于滤波器抽头数。抽头数应按采样率、参考到麦克风的纯延迟、实测路径覆盖时间和可接受残余共同确定；
- $e(n)$ ：残差。路径估计改善时，远端单讲条件下的  $e$  通常减小；经典更新算法是归一化最小均方（Normalized Least Mean Squares, NLMS）：

$$\hat{\vec{w}}(n+1) = \hat{\vec{w}}(n) + \mu \frac{e(n) \vec{x}(n)}{\|\vec{x}(n)\|^2 + \varepsilon} \quad (6-2)$$

更新量与残差和输入向量成正比，并由输入能量归一化。 $\varepsilon$  防止静默时分母接近零。若实现为了手算或节省运算而省略  $\varepsilon$ ，必须另设零能量保护： $\|\vec{x}(n)\|^2 = 0$  时跳过更新，不能计算未定义的  $0/0$ 。

这个更新式怎么来的（三步）：

1. 定目标：想让残差功率最小。最直接的瞬时目标  $J(n) = e(n)^2$ ，对  $\hat{\vec{w}}$  求梯度： $\frac{\partial J}{\partial \hat{\vec{w}}} = -2e(n)\vec{x}(n)$ （因为  $e = d - \hat{\vec{w}}^\top \vec{x}$ ，链式法则一步得出）；
2. 最速下降：沿负梯度方向走一小步  $\hat{\vec{w}} \leftarrow \hat{\vec{w}} + \mu' e(n) \vec{x}(n)$ ，得到最小均方（Least Mean Squares, LMS）算法；
3. 归一化步长：固定步长  $\mu'$  对输入幅度敏感，幅度较大时可能发散，较小时又会减慢收敛。NLMS 用  $\|\vec{x}(n)\|^2 + \varepsilon$  对更新归一化， $\varepsilon$  是防止静音时除以零的小正数。

理想假设下  $\mu \in (0, 2)$  可保持均方稳定； $\mu = 1$  只对应同一帧给定输入下的瞬时最优，并非统计最优。实际步长要在目标参考信号、双讲控制和路径变化条件下扫描；图 18 (b) 的本书仿真使用  $\mu = 0.5$ 。

#### 算例 6-1：NLMS 的一步手算

题设：3 抽头滤波器，参考向量  $\vec{x}(n) = [1, 0.5, -0.5]^\top$ （最近 3 个播放样本），当前滤波器  $\hat{\vec{w}}(n) = [0, 0, 0]^\top$ （零初值），麦克风信号  $d(n) = 0.8$ ，步长  $\mu = 0.5$ ， $\varepsilon$  很小先忽略。按式(6-2)更新一步。

第 1 步：算回声副本与残差。 $\hat{y}(n) = \hat{\vec{w}}^\top(n) \vec{x}(n) = 0 \times 1 + 0 \times 0.5 + 0 \times (-0.5) = 0$ ——滤波器还是零，回声一点没被减掉，残差  $e(n) = d(n) - \hat{y}(n) = 0.8$  就是全部。

第 2 步：算归一化因子。 $\|\vec{x}(n)\|^2 = 1^2 + 0.5^2 + (-0.5)^2 = 1.5$ 。用输入能量归一化后，播放幅度增大时分母也随之增大，可降低固定步长对输入幅度变化的敏感性。

第 3 步：算更新量、更新滤波器。

$$\mu \frac{e(n)}{\|\vec{x}(n)\|^2} \vec{x}(n) = \frac{0.5 \times 0.8}{1.5} \begin{bmatrix} 1 \\ 0.5 \\ -0.5 \end{bmatrix} = \frac{0.4}{1.5} \begin{bmatrix} 1 \\ 0.5 \\ -0.5 \end{bmatrix} \approx \begin{bmatrix} 0.267 \\ 0.133 \\ -0.133 \end{bmatrix}$$

$$\hat{\vec{w}}(n+1) = [0, 0, 0]^\top + \Delta \vec{w} \approx [0.267, 0.133, -0.133]^\top$$

这里  $\Delta \vec{w}$  就是上式算出的更新向量。

这一步只修正了当前输入方向上的误差；其他方向需要后续不同的输入向量提供梯度信息。更新方向与  $\vec{x}(n)$  平行。

第 4 步：用更新后的系数重算回声副本。

$$\hat{y}'(n) = \hat{\vec{w}}^\top(n+1) \vec{x}(n) = 0.267 \times 1 + 0.133 \times 0.5 + (-0.133) \times (-0.5) \approx 0.267 + 0.067 + 0.067 \approx 0.4$$

新残差  $e'(n) = 0.8 - 0.4 = 0.4$ 。把更新式代回残差可得  $e'(n) \approx (1 - \mu) e(n)$ ，因此  $\mu = 0.5$  时同一帧的后验残差减半； $\mu = 1$  时到达该帧的瞬时最优。连续输入上的多次更新使滤波器逐步收敛。

$e' \approx (1 - \mu)e$  的推导。把更新式代回同一帧的残差：

$$e'(n) = d - \hat{w}^\top(n+1)\vec{x} = [d - \hat{w}^\top(n)\vec{x}] - \mu e(n) \frac{\vec{x}^\top \vec{x}}{\|\vec{x}\|^2 + \varepsilon} = e(n) \left[ 1 - \mu \frac{\|\vec{x}\|^2}{\|\vec{x}\|^2 + \varepsilon} \right]$$

$\varepsilon \ll \|\vec{x}\|^2$  时方括号约等于  $(1 - \mu)$ ，即  $e'(n) \approx (1 - \mu)e(n)$ 。 $\mu = 1$  时  $e' \approx 0$ ，只表示本帧给定  $\vec{x}$  下的瞬时最优；下一帧输入变化后仍需继续更新。 $\mu = 0.5$  时本帧残差减半。 $\mu = 1.8$  时  $e' \approx -0.8e$ ，残差变号且幅度仍为原来的 80%； $\mu = 2$  对应幅度不减的临界情况。


第二个手算例（换一组数，验证“减半”不是巧合）： $\vec{x} = [0.8, -0.4, 0.4]^\top$ ， $d = 0.6$ ， $\hat{w}(n) = 0$ ， $\mu = 0.5$ 。

$\|\vec{x}\|^2 = 0.64 + 0.16 + 0.16 = 0.96$ ，更新量  $= 0.5 \times 0.6/0.96 \times \vec{x} = [0.25, -0.125, 0.125]^\top$ 。重算得到  $\hat{y}' = 0.25 \times 0.8 + (-0.125) \times (-0.4) + 0.125 \times 0.4 = 0.2 + 0.05 + 0.05 = 0.3$ ，新残差为  $0.6 - 0.3 = 0.3$ 。

残差同样减半，说明规律  $e' \approx (1 - \mu)e$  与这组具体数字无关。

图18 声学回声消除（AEC）原理

(a) AEC 结构：残差反馈更新滤波器，DTD 在双讲时停止系数更新



(b) NLMS 收敛过程（ERLE，模拟）





图18 (a) 给出整体结构；(b) 给出 NLMS 在模拟回声路径上的收敛曲线。仿真取  $\mu = 0.5$ ，回归向量按


$\vec{x}(n) = [x(n), x(n-1), \dots, x(n-L+1)]^\top$  排列，与生成回声的卷积索引一致，不额外引入一拍延迟。图中标注的是固定随机种子下  $0.45 < t < 0.8$  s 远端单讲窗口的 ERLE 均值；粉色区域表示双讲期间冻结更新，该区间不统计 ERLE。

图28 NLMS 自适应：路径估计逐步逼近真实响应

(a)  $\hat{w}$  逐步逼近  $h$



(b) 失配下降, ERLE 上升



(c) 步长  $\mu$ : 增大可加快收敛, 也会增大波动




图28 (a) 显示  $\hat{w}$  从零开始逐步逼近真实路径  $h$ 。(b) 在本仿真中, 系数欧氏失配下降时 ERLE 总体上升, 但二者不是互为相反数: 有色输入下的残余功率还由输入协方差加权, 两个纵轴也采用不同的时间统计。(c) 比较不同步长: 较大的  $\mu$  收敛较快, 但稳态波动也较大。 $\mu \in (0, 2)$  是理想假设下的范围, 实际取值需用目标信号验证。

图29 NLMS 收敛与双讲冻结




图29上方三行使用共同尺度的均方根包络，分别显示参考  $x$ 、麦克风信号  $d$  和残差  $e$ 。粉色区域为双讲时段，此时残差含近端语音，ERLE 不能评价回声抵消量，因此曲线在该区间不绘制。滤波器在双讲期间冻结更新，双讲结束后继续沿原路径工作。图28中的“0步”曲线表示更新前的全零初值；后续编号表示已完成的更新次数。

**步长与正则项：**较大的  $\mu$  通常收敛较快，但稳态波动较大；较小的  $\mu$  则相反。 $\epsilon$  防止静默时分母趋近于零。固定下限与随参考功率缩放的正则项使用不同量纲和归一化口径，不能照搬同一个数值。可扫描静音、低电平参考和正常播放三类输入，选择既不在静音时产生大更新、又不过度减慢小信号收敛的取值。

**收敛还需要充分激励。**NLMS 每步只能沿当前输入方向  $\vec{x}(n)$  修正（见算例 6-1 第 3 步）。纯音或窄带参考不能充分激励所有滤波器系数，未被激励的方向会收敛得很慢。调试时可用已知宽带测试信号检查滤波器是否能辨识目标路径；这项测试不能代替真实节目内容上的收敛与双讲验证。

单位脉冲是一个容易混淆的边界例子。对  $L$  抽头回归器，单个单位脉冲会依次产生  $L$  个标准基向量，因此方向并不缺失；但每个方向只更新一次。若  $\mu = 0.5$ 、初值为零且忽略非零  $\epsilon$  的微小影响，每个抽头只走到真实值的一半。要继续逼近真实路径，需要重复脉冲或其他持续激励；输入归零后应按上面的零能量规则跳过更新。

### 6.1.3 工程化自适应：频域、子带、比例、卡尔曼

**时域实现的计算量。** $L = 1024$  抽头的时域 NLMS 每样本约需  $3L \approx 3000$  次乘法，8 kHz 下约 2500 万次/秒。48 kHz、4096 抽头时会达到每秒数亿次，而且抽头越多、输入频谱越不均匀，收敛通常越慢。常见改进包括频域分块、子带处理、比例步长和卡尔曼估计。

分区块频域自适应滤波 (Partitioned-Block Frequency-Domain Adaptive Filtering, PBFDAF)。它沿用多延迟块频域 (Multidelay Block Frequency-Domain, MDF) 方法的思路, 把  $L$  个抽头分成  $P = \lceil L/N \rceil$  个长度为  $N$  的分区, 并用长度  $2N$  的快速傅里叶变换 (Fast Fourier Transform, FFT) 完成重叠保存卷积。

每块的频域滤波和梯度相关都要遍历  $P$  个分区, 因此不能只写成  $O((L/N) \log N)$ 。忽略实现常数时, 无梯度约束版本每个新样本约为  $O(\log N + L/N)$ ; 若每个分区都做时域梯度约束, 还会增加约  $O((L/N) \log N)$ 。FFT 的固定成本随块长对数增长, 分区乘法则随  $L/N$  线性增长。

具体倍数还取决于实数或复数 FFT、频谱共轭对称复用、功率估计、约束频率以及一次乘加如何计数, 不能脱离这些约定比较。KU Leuven DSP-CIS 讲义第 13 章

算例 6-2: PBFDAF 的乘法计数 ( $L = 1024$ 、 $N = 128$ 、8 kHz, 看“一个数量级”是怎么省出来的)

时域 NLMS 的账: 每样本滤波  $L$  次乘法 + 更新  $L$  次 + 功率归一  $L$  次, 共约  $3L = 3072$  次乘法/样本。

PBFDAF 的账: 块长  $N = 128$ , FFT 长度取  $2N = 256$  (overlap-save 结构, 防循环卷积混叠), 分区数  $P = L/N = 8$ 。每来一块 128 个新样本, 要做的活是:

1. 新参考块算 1 次 FFT——旧分区的频谱整体平移复用, 不必重算, 这是“分区”省钱的根源;
2. 8 个分区各做一次长度 256 的复数相乘 (滤波 = 频域相乘), 合起来做 1 次逆快速傅里叶变换 (Inverse Fast Fourier Transform, IFFT) 得到输出块;
3. 误差块 1 次 FFT, 8 个分区各做一次共轭相关复乘 (梯度方向);
4. 若对每个分区施加时域梯度约束, 要把该分区的频域梯度做 IFFT、把无效的后半段清零, 再 FFT 回频域, 因此每个分区增加一对变换; 无约束版可省掉这一步, 间歇约束版则按实际约束频率折算。

为使下面的算术可逐项复算, 这里采用一个保守的全复数上界口径: 不利用实信号频谱的共轭对称, 把每次  $2N$  点变换按完整复 FFT 计为约  $4N \log_2(2N) = 4 \times 128 \times 8 = 4096$  次实乘法, 长度 256 的逐点复乘按  $256 \times 4 = 1024$  次实乘法计。实际实 FFT 只需保存  $N + 1 = 129$  个独立频点, 若复用共轭对称, FFT 和逐点乘法都应按具体库重新计数, 不能沿用下面的 4096 和 1024:

- 无约束版:  $3 \times 4096 + 2 \times 8 \times 1024 = 12288 + 16384 = 28672$  次/块  $\rightarrow$  每样本  $28672/128 \approx 224$  次;
- 逐分区约束版: 再加  $2 \times 8 \times 4096 = 65536$ , 共 94208 次/块  $\rightarrow$  每样本约 736 次。

在上述未复用共轭对称的上界口径下, 无约束版约为 224 次实乘法/样本, 逐分区每块约束版约为 736 次, 时域 NLMS 按 3072 次计, 得到约 14 倍和 4.2 倍的差距。

这些数不能当作实 FFT 库的操作数或实测速度。若约束不是每块、每分区都执行, 平均开销会降低, 报告时要注明约束周期。

块长  $N = 128$ 、采样率 8 kHz 时, 每块含 16 ms 新数据; 实际算法延迟由重叠保存、调度方式和系统缓冲共同决定, 不能仅凭“两个块”固定写成 32 ms。滤波器加长时, 时域复杂度按  $L$  增长, 而分区频域方法的主要项按  $L/N$  增长, 因此长回声路径更适合用分区频域实现。Soo & Pang 1990

PBFDAF 更新式。记第  $m$  块、第  $k$  个频点的参考谱为  $X(k, m)$ , 第  $p$  个分区的滤波器谱为  $W_p(k, m)$ , 误差谱为  $E(k, m)$ , 其中  $p = 0, \dots, P - 1$ 。一种按全部分区参考功率归一化的更新写成

$$W_p(k, m + 1) = W_p(k, m) + \mu \frac{E(k, m) X^*(k, m - p)}{\sum_{q=0}^{P-1} |X(k, m - q)|^2 + \delta}。$$

分区  $p$  使用延迟了  $p$  个块的参考  $X(k, m - p)$ ; 若省略该下标, 公式就只描述单分区 FDAF。与时域 NLMS 相比, 分子仍是“误差  $\times$  参考共轭”, 分母仍做参考功率归一;  $E(k, m)$  是用旧滤波器得到的先验误差。文献和代码也会为每个分区维护独立平滑功率, 比较实现时必须核对归一化定义。更新后若执行梯度约束, 应对每个  $W_p$  的更新量做 IFFT、清零循环卷积对应的无效时域部分, 再 FFT 回频域。以  $N = 128$ 、8 kHz 为例, 每秒更新约  $8000/128 \approx 62$  次; 每次更新同时利用 128 个新样本, 整体乘法量见算例 6-2。

**子带自适应**：分析滤波器组把信号分成多个子带。带内频谱较平坦，有利于收敛；降采样也会缩短各带滤波器并降低计算量。临界采样时子带间存在混叠，严格重建需要带间交叉滤波器补偿（Gilloire & Vetterli, *IEEE Trans. Signal Processing* 1992）。Gilloire & Vetterli 1992

**IPNLMS**：按稀疏度分配步长。真实回声路径通常由直达声和少数强反射贡献主要能量，其余抽头较小。NLMS 对所有抽头使用同类更新；比例归一化最小均方（Proportionate Normalized Least-Mean-Square, PNLMS; Duttweiler 2000）与改进比例归一化最小均方（Improved Proportionate Normalized Least-Mean-Square, IPNLMS; Benesty & Gay, ICASSP 2002）按系数当前幅度分配更新量，使较大的系数优先收敛。按 Benesty 与 Gay 的常用参数化，混合系数  $\alpha \in [-1, 1]$ ： $\alpha = -1$  退化为 NLMS， $\alpha = 1$  对应纯比例更新， $\alpha = 0$  对两部分等权混合。不同文献可能改写参数，比较数值前要先核对定义。声学回声路径通常不如网络回声路径稀疏，因此 IPNLMS 的收益需在实际路径上验证。

**递归最小二乘与卡尔曼方法**。递归最小二乘（Recursive Least Squares, RLS）用带遗忘的最小二乘代替随机梯度，标准全矩阵实现复杂度为  $O(L^2)$ 。遗忘因子  $\lambda$  越小，历史样本衰减越快，路径变化后适应得更快，但稳态估计方差也更大。有效记忆长度常用  $1/(1 - \lambda)$  粗略估计： $\lambda = 0.99$  约为 100 个样本， $\lambda = 0.999$  约为 1000 个样本。Elisei-Iliescu et al. 2017（AEC 自适应算法综述）

**频域卡尔曼滤波**（Frequency-Domain Kalman Filter, FDKF）把每个频点的回声路径系数当作随时间缓慢变化的状态。卡尔曼增益的作用类似自适应步长，但只有在状态模型、过程噪声方差和观测噪声方差与实际相符时才是相应模型下的最小均方误差增益。双讲时，如果观测噪声估计能及时包含近端语音能量，增益会减小；估计滞后或模型失配时仍可能误更新，所以工程实现通常还会结合双讲检测或增益上限。

FDKF 把回声路径作为状态变量，其状态方程和观测方程可写为（实际在频域逐频点计算，此处用时域记号示意）：

$$\vec{h}(n) = a\vec{h}(n-1) + \Delta\vec{h}(n), \quad d(n) = \vec{x}^\top(n)\vec{h}(n) + s(n) + v(n)$$

第一行是状态方程：上一时刻的路径乘状态转移因子  $a$ ，再加过程噪声  $\Delta\vec{h}$ ，用来描述缓慢漂移和偶发突变。第二行是观测方程：麦克风信号由参考经过路径滤波后，再叠加近端语音和噪声。对应 § 9.2 的卡尔曼递推，状态是  $\vec{h}$ ，观测是  $d$ ，近端语音与噪声合并为观测噪声。双讲时观测噪声估计增大，卡尔曼增益随之减小；路径变化使预测误差增大时，增益会上升以加快重新收敛。每个频点还需维护误差方差或协方差，因此计算量高于普通 PBFDAF。

逐频点写完整的一次递推。省略频点下标， $W_{m-1}$  是上一块的路径系数， $P_{m-1}$  是其误差方差， $a$  是状态转移因子， $\Phi_m$  和  $\Psi_m$  分别是过程噪声与观测噪声方差：

$$\begin{aligned} \hat{W}_m^- &= aW_{m-1}, & P_m^- &= |a|^2 P_{m-1} + \Phi_m, \\ E_m &= D_m - X_m \hat{W}_m^-, & K_m &= \frac{P_m^- X_m^*}{|X_m|^2 P_m^- + \Psi_m}, \\ W_m &= \hat{W}_m^- + K_m E_m, & P_m &= (1 - K_m X_m) P_m^-. \end{aligned} \quad (6-3)$$

前两式先预测路径和不确定度；协方差传播使用  $|a|^2$ ，因为复数状态模型的一般形式是  $APA^H + Q$ 。中间两式根据先验残差计算增益；最后两式更新系数和误差方差。标量复数模型中  $K_m X_m$  为实数且位于 0 与 1 之间。实际分区频域实现还要处理矩阵协方差、块卷积约束和频点平滑。Enzner & Vary 2006

若暂时固定  $W$ ，并把残差视为零均值圆对称复高斯变量，单帧负对数似然中与  $\Psi$  有关的部分为  $|E|^2/\Psi + \log \Psi$ 。正确的导数是

$$\frac{\partial}{\partial \Psi} \left( \frac{|E|^2}{\Psi} + \log \Psi \right) = -\frac{|E|^2}{\Psi^2} + \frac{1}{\Psi}.$$

令它为零得到单帧极大似然估计  $\hat{\Psi} = |E|^2$ 。单帧估计波动很大，还把未建模回声混入“观测噪声”，所以实际系统会做时间平滑、双讲判决或由网络估计  $\Psi$ ，不能直接把当前  $|E|^2$  当成准确的近端语音功率。

最小数例取  $X = 1$ 、 $P^- = 1$ 。远端单讲时若  $\Psi = 0.01$ ， $K = 1/1.01 \approx 0.990$ ，残差的大部分用于更新；双讲时若  $\Psi = 10$ ， $K = 1/11 \approx 0.091$ ，更新量约为前者的 9.2%。这说明软门控会缩小更新，但并没有严格冻结。

完整的一轮标量递推。取实数特例  $W_{m-1} = 0.2$ 、 $P_{m-1} = 0.5$ 、 $a = 1$ 、 $\Phi_m = 0.1$ 、 $X_m = 2$ 、 $D_m = 1.4$ 、 $\Psi_m = 0.4$ 。预测得到  $\hat{W}_m^- = 0.2$ 、 $P_m^- = 0.6$ ；先验残差  $E_m = 1.4 - 2 \times 0.2 = 1.0$ 。于是

$$K_m = \frac{0.6 \times 2}{2^2 \times 0.6 + 0.4} = \frac{1.2}{2.8} \approx 0.4286,$$

$$W_m = 0.2 + 0.4286 \times 1.0 \approx 0.6286, \quad P_m = (1 - 0.4286 \times 2)0.6 \approx 0.0857.$$

用更新后的系数回看该观测，残差为  $1.4 - 2 \times 0.6286 \approx 0.1429$ ；它是后验检查，不应代替式(6-3)中用于更新的先验残差。若  $\Psi_m \rightarrow \infty$ ，则  $K_m \rightarrow 0$ ，路径几乎不更新；若理想化地令  $\Psi_m \rightarrow 0$  且  $X_m \neq 0$ ，标量模型会令  $K_m \rightarrow 1/X_m$ 、 $P_m \rightarrow 0$ 。实际系统存在模型失配和数值误差，需要为方差设置正下限，不能把  $P_m = 0$  当作永久确定。

方法对比（描述相对趋势；具体计算量和收敛速度取决于滤波长度、输入谱、块长与实现，选型条件另见图32（c））：

| 算法         | 每样本复杂度                                            | 收敛速度           | 双讲鲁棒性               | 适用场景          |
|------------|---------------------------------------------------|----------------|---------------------|---------------|
| 时域 NLMS    | $O(L)$ （约 $3L$ 次乘法）                               | 慢，有色输入更慢       | 弱，需另配双讲检测           | 短路径、算力受限      |
| IPNLMS     | $O(L)$ （常数略大）                                     | 中（稀疏路径快）       | 弱，需另配双讲检测           | 网络回声、稀疏路径     |
| PBFDAP     | 无约束约 $O(\log N + L/N)$ ；逐分区约束另加 $O((L/N) \log N)$ | 中（逐频点归一化）      | 弱，需双讲检测或连续步长控制      | 长路径、全频带       |
| 子带自适应      | 低（降采样后各带很短）                                       | 快（带内近白噪）       | 弱，需另配双讲检测           | 低功耗嵌入式        |
| RLS        | $O(L^2)$                                          | 在模型匹配时可比随机梯度法快 | 遗忘因子较小时更易受双讲干扰      | 短滤波器、研究基准     |
| 频域卡尔曼 FDKF | 以分区频域滤波为基础，另有状态统计量维护                              | 取决于过程噪声和观测噪声估计 | 软门控（增益自适应，仍需验证双讲控制） | 长路径且需要跟踪变化的系统 |

§ 6.1.1~§ 6.1.3 建立了线性回声模型，并比较了 NLMS、分区频域方法、比例步长和频域卡尔曼滤波。ERLE 只适用于远端单讲；线性滤波只能处理参考可表示的线性回声，参考抽头位置和双讲控制还需另行设计。

非线性回声与双讲控制（§ 6.1.4~§ 6.1.5）

6.1.4 非线性回声：模型失配与处理方法


非线性从哪来。微型扬声器的悬边与磁路在大振幅下不再线性（悬边变硬、音圈跑出匀强磁场区），功放或数字播放链在大音量下可能削顶（clipping），机壳与结构件也可能随声压振动产生二次辐射。Birkett & Goubran（WASPAA 1995）实测讨论了免提终端中的非线性回声，Klippel（JAES 2006）从扬声器物理模型分析了相关机制。这里不作“最早提出”的优先权判断。

平台从哪里来。线性滤波器只能估计播放参考的线性组合。扬声器软削波产生的谐波和互调分量不在这个线性子空间内，因此即使路径估计已经收敛，残差仍会保留非线性分量。


图 19（a）用一组独立定量仿真展示这项能力边界，图 31 则用另一组受控仿真和静态映射检查同一机制。两图都取 3 s 输入、256 抽头、步长 0.3 和驱动系数 1.1。

两图的随机种子、参考序列边界成形方式、具体输入和路径实现不同，属于两次独立单次仿真，ERLE 数值不能横向比较。每个平台高度只属于各自图示配置，不能外推为某类设备固定的 ERLE 上限。

图19 AEC 的模型失配与方法分类



(b) 按模型假设和处理对象区分 AEC 方法



这些模块按路径长度、变化速度、非线性程度和资源约束选择; 横向位置不表示年代或性能排名。

图19 (a) 是独立定量仿真, 只支持其图示配置下“非线性失配使线性 AEC 出现残差平台”这一结论; 它与图31不是同一实验, 不能比较两图的平台高低。 (b) 按模型假设和处理对象区分逐样本时域 LMS/NLMS、分区块频域 MDF/PBFDAF、状态空间频域卡尔曼滤波和残余抑制。横向位置不表示年代或性能排名; 选择方法时要结合路径长度、变化速度、非线性程度和资源约束。

tanh 的最小手算。

图 31 使用归一化映射  $y = \tanh(1.1x)/\tanh(1.1)$ ，使  $x = 1$  时  $y = 1$ 。取  $x = 0.3$ ，得到  $y \approx 0.398$ ；取  $x = 1.5$ ，得到  $y \approx 1.160$ 。相对参考直线  $y = x$ ，两点的偏差分别约为  $+0.098$  和  $-0.340$ 。

该映射在零点附近的斜率为  $1.1/\tanh(1.1) \approx 1.37$ ，所以  $y = x$  只是图中的参考线，不是它的小信号切线。

这两个采样点只说明映射具有曲率，不能推出整段语音的失真功率或 ERLE。平台数值还取决于输入分布、路径、最佳线性拟合和统计窗口。

图31 本仿真中的线性匹配与非线性失配




图31 (a) 在当前仿真参数下比较线性路径与  $\tanh(1.1x)/\tanh(1.1)$  非线性路径，后段均值由脚本按图示窗口计算，不是设备性能上限。(b) 显示同一映射相对参考直线  $y = x$  的曲率。图31的唯一职责是把“映射曲率—线性模型残差平台”对应起来；线性滤波器无法精确表示由此产生的非线性分量，因此只增加抽头或调整步长不能消除该模型失配。

出路①：把非线性建进模型。二阶 Volterra (沃尔泰拉) 级数在线性核之外增加作用于  $x(n-i)x(n-j)$  的二阶核。完整二阶核有  $O(L^2)$  个系数，实用实现会限制核的结构或保留部分系数，以交换计算量和建模能力。

Hammerstein/Wiener 级联则用“静态非线性 + 线性动态”两段建模。Nollett & Jones (NSIP 1997) 在该论文的实验配置下报告相对线性基线提高 8.4 dB。Nollett & Jones 1997

这个数值与论文中的输入、失真模型、路径和统计口径绑定。当真实失真偏离模型假设时，需要重新测量收益。

出路②：换参考，绕开建模。非线性发生在播放链路里，可以把参考取在更接近扬声器的一端，使参考包含更多已经发生的失真。

- 电信号参考直接采样扬声器端子的电压或电流。Shah et al. 在论文所述的受控设备和测试条件下报告，相对原参考的改善约为 6 ~15 dB；该结果只覆盖实验中的电—气链路失真，不能外推到结构二次辐射或其他硬件。Shah et al., IEEE/ACM TASLP 2015
- 机械振动参考用加速度计采集振膜或机壳振动，需增加传感器和采集通道。

两种做法都要比较新增参考带来的收益、噪声、同步误差和硬件代价。

出路③：神经网络。深度神经网络 (Deep Neural Network, DNN) 可以从数据学习残余抑制，适用条件和验证方法见 § 6.1.6。

### 6.1.5 双讲检测与自适应控制

双讲时，残差同时包含路径失配和近端语音。若仍按普通 NLMS 更新，近端语音会进入梯度并使路径估计偏离。双讲检测 (Double-Talk Detection, DTD) 用于降低步长或冻结更新。门限过于敏感会延迟路径跟踪，门限过于迟钝则可能导致误更新。

常见 DTD 方法 (DTD = 双讲检测, double-talk detection; NCC = 归一化互相关, normalized cross-correlation) :

1. Geigel 能量比较: 设  $x_a$  为已经补偿延迟、送入长度  $L$  自适应滤波器的参考, 可写成

$$\xi(n) = |d(n)| / \max_{0 \leq j < L} |x_a(n - j)|; \text{ 高于阈值时判为双讲。}$$

经典示例阈值  $T = 0.5$  来自线路回声中混合器至少衰减 6 dB 的假设 ( $20 \log_{10} 2 \approx 6$  dB), 不是任意声学回声路径的固定阈值。多抽头路径的若干项还会在同一样本叠加, 单个参考峰值与麦克风回声峰值之间没有通用的 0.5 上界。

若声学回声较强, 远端单讲也可能被误判; 若回声很弱, 小声近端语音又可能漏检。因此该方法适合低成本初筛, 不宜单独承担声学双讲检测。Duttweiler, *IEEE Transactions on Communications* 1978; 2. 互相关 / 归一化互相关 (NCC) (Benesty 等): 利用“滤波器收敛后残差  $e$  与参考  $x$  去相关”的性质—— $e$  与  $x$  还有相关性, 说明回声没消完; 相关性降低且  $e$  能量仍大, 才可能是双讲。判决还需结合滤波器失配和噪声条件; 3. 频域 NCC (Gänsler & Benesty, *Signal Processing* 2001): 在频域逐频点估计相关性, 可与 PBFDAF 复用部分频域表示; 额外计算量取决于平滑、频带汇总和判决实现; 4. 相干函数法: 用  $d$  与  $x$  的幅度平方相干判别, 与 NCC 同族; 5. 双滤波器法: 前台滤波器负责输出, 后台滤波器用更大的步长寻找新路径。后台并不是“不怕双讲”; 双讲时照常大步更新同样会偏离真实路径, 所以它也要根据双讲置信度缩小步长或冻结。

只有当后台滤波器在一段保持时间内持续得到更小的远端单讲残差, 才把系数复制到前台。切换判决需要门限和迟滞, 避免两套滤波器来回切换。

WebRTC AEC3 的 refined/coarse 结构采用了相近的快慢滤波思路, 但具体更新和切换规则以对应版本源码为准。

Geigel 判决的数字例子。只为复算经典线路回声假设, 设参考历史窗的峰值为 1.0, 并把回声简化为单个衰减 6 dB 的副本, 则远端单讲时  $|d| \approx 0.5$ , 阈值 0.5 位于边界。这个数字没有包含声学多径叠加、背景噪声或参考失配, 不能据此为声学 AEC 固定阈值。实际强回声可能在远端单讲时误判, 弱回声叠加小声近端语音又可能漏检。

从二值冻结到连续步长。冻结是 0/1 开关, 也可以根据残余回声与近端干扰的相对功率连续调整步长。Mäder、Puder & Schmidt (*Signal Processing* 2000) 推导的最优步长  $\alpha(k)$  在  $[0, 1]$  内变化: 回声占优时增大, 双讲占优时减小。连续控制可减少硬切换造成的跟踪迟滞。

图30 延迟对齐与双讲冻结




图 30 属于本节的时序控制例。图 30 (a) 在前 4000 个样本上计算参考与麦克风信号的有符号互相关，最大正相关峰位于约 331 个采样。仿真设置的纯延迟是 300 个采样；参考是有色信号，路径又含多个正负抽头，因此相关峰是输入自相关与整条路径共同作用的结果，不能解释成“300 加某个主抽头位置”。若改取互相关绝对值、使用广义互相关（Generalized Cross-Correlation, GCC）加权或改变参考频谱，峰值也可能改变。

图 30 (b) 中，对齐后的远端单讲 ERLE 约为 28 dB，不对齐时约为 2 dB。本例的纯延迟超过 128 抽头滤波器的覆盖范围，因此差异较大。

图 30 (c) 比较双讲期间冻结和继续更新；后者会使路径估计偏离，双讲结束后需要重新收敛。排查时应分别检查延迟估计方法和双讲控制。

神经 DTD. Ivry et al. 的深度变步长（Deep Variable Step-Size, DVSS, ICASSP 2022）用 DNN 预测逐帧步长。在该论文的数据、路径突变定义、成功判据和基线实现下，DVSS 的重收敛时间为 3.4 s、成功率为 95%，NLMS 加经典 DTD 基线分别为 7.9 s 和 58%。这些是论文实验结果，不是产品验收阈值；复现时要沿用论文的判据，部署时则按目标设备另定恢复条件。Ivry et al., ICASSP 2022

§ 6.1.4~§ 6.1.5 分别说明了非线性失配和双讲误更新。非线性残余可通过显式建模、改变参考位置或学习型抑制处理；双讲期间应根据检测置信度冻结或减小步长。由于输出含近端语音，双讲区间不能用普通 ERLE 评价。

学习型残余抑制、阵列顺序与评测（§ 6.1.6~§ 6.1.8）

### 6.1.6 学习型 AEC

微软 AEC Challenge 的评测变化。以下只摘录 ICASSP 2021 会议报告和介绍 2023 年挑战的 IEEE OJSP 2024 期刊报告中可直接定位的信息。挑战赛年份与论文出版年份不同；挑战赛的届次名称、任务、排名指标和延迟约束也会改变，不能由仓库更新时间推断后续

赛事状态。

| 报告                          | 可复核的设置                              | 读取时的限定                       |
|-----------------------------|-------------------------------------|------------------------------|
| ICASSP 2021 报告              | 发布真实设备录音并引入 ITU-T P.808 众包主观评价      | 数据数量、系统排名和分数应直接查报告的数据与结果表    |
| 2023 挑战 (IEEE OJSP 2024 报告) | 包含一般 AEC 和个性化 AEC 任务，并同时考查主观质量与语音识别 | 注册语音、延迟和排名条件只属于该届规则，不是通用产品规范 |

Sridhar et al. (ICASSP 2021 AEC Challenge 报告)、Cutler et al. (2023 AEC Challenge, IEEE OJSP, vol. 5, pp. 675 – 685, 2024)

这些报告说明，ERLE 不能单独表示双讲质量或近端语音损伤，因此评测还需主观质量和下游识别指标。参赛系统同时包含线性 AEC 加学习型后滤波的混合方案和端到端方案。两类方法应按延迟、算力、泛化和故障诊断要求分别评估。

后续报告继续加入全频带、个性化和下游识别等条件。复现时应从对应年份的规则和论文表格读取采样率、延迟、注册语音与排名指标，不把某届数字写成后续系统的通用限值。

混合式结构：线性估计加学习型残余抑制。自适应滤波器利用已知参考估计线性回声，不需要训练数据；神经网络则处理线性模型未覆盖的残余回声、环境噪声和部分晚期混响。两者分工可以减少网络需要学习的动态范围，同时保留线性段的路径与收敛诊断。

可以用 SER（信号回声比，signal-to-echo ratio）为 -20 dB 的时频点说明两类方法的差别：此时回声能量是近端语音的 100 倍。

只考虑相位完全正确的标量幅度误差，令真实回声为  $y$ 、副本为  $\hat{y} = 0.9y$ ，则残差为  $0.1y$ ，残余能量是原回声的  $|0.1|^2 = 1\%$ ，相当于降低 20 dB。若副本还有相位误差，残余比应按  $|1 - \alpha e^{j\phi}|^2$  计算，不能沿用 1%。

若只对混合信号施加同一个增益  $g$ ，回声和近端语音会同比缩放，该时频点的 SER 不变。混合结构因此先用参考完成线性减法，再对无法建模的残余施加增益抑制。

图32 线性回声消除与残余抑制：按系统条件选择模块  
混合处理流程：线性前级与残余后处理各有适用前提




图32 (a) 给出一类混合流程：参考先经过延迟估计与对齐，再由线性 AEC 产生残差；学习型残余抑制可同时使用残差  $e$  和参考  $x$ ，双讲检测与步长控制负责约束自适应更新。(b) 列出线性滤波、规则型残余抑制和学习型残余抑制各自处理的对象、使用前提和验证重点。(c) 从路径长度、路径变化、非线性残余和训练数据等条件比较 NLMS、分区频域滤波、FDKF 与混合学习方案。该表用于确定需要验证的条件，不给出固定性能档次。

后滤波器的输入与输出：输入可以包括残差  $e$ 、参考  $x$  的逐帧谱，以及滤波器系数范数、当前步长和各频带相干性等线性 AEC 内部量。网络输出逐频带增益或其他滤波参数。频带划分、特征维度和训练目标属于具体模型版本，不能在不同实现之间直接套用。

代表方案如下：

- PercepNet：在传统线性 AEC 之后，用网络估计 Bark 频带增益和周期性滤波参数，联合抑制残余回声与噪声。这个结构说明了解析路径估计与学习型后处理的功能分工；论文中的实时性只适用于所述模型、处理器和计时口径，换设备后仍需重测双讲近端保护与资源占用。[Valin et al., ICASSP 2021](#)；
- Ma et al. 2020：自适应滤波器加 RNN 后处理的公开实现展示了同一混合思路；该来源是 arXiv 预印本，结果应按文中的数据与基线解读。[Ma et al., arXiv:2005.09237](#)；
- DeepVQE (Interspeech 2023)：单模型联合 AEC、降噪和去混响，用交叉注意力在参考与麦克风信号之间做软对齐。论文报告了作者实现面向 Teams 场景的实时测试；这一结论只适用于论文所述模型、硬件和软件配置，不能据此推断其他实现的实时性。[DeepVQE, DOI 10.21437/Interspeech.2023-1028](#)

端到端神经 AEC 把问题写成条件语音分离：输入麦克风信号和播放参考，直接估计近端语音。它能联合建模非线性与残余噪声，但低 SER 下的近端保护、未见设备上的泛化、因果延迟和故障诊断都需要单独验证。深度滤波不只输出 0~1 掩码，而是估计复数时频滤波器，可以同时调整幅度和相位。不同方案的 MOS 与 ERLE 只有在数据、场景、延迟和统计区间相同的条件下才能比较。

训练数据。回声路径可以用 § 2.4 的镜像法生成不同房间尺寸和  $T_{60}$ ，非线性失真可以用随机 Wiener – Hammerstein 级联参数化，SER 和 SNR 也可按区间采样。真实设备录音仍用于覆盖仿真中缺少的扬声器、结构振动和系统链路特性。常见做法是先用合成数据训练，再用目标设备录音微调并验证。

神经卡尔曼滤波：保留递推结构，学习难以建模的参数。这类方法保留 FDKF 的预测、更新和增益递推，由 DNN 估计卡尔曼增益、状态转移因子或非线性修正项。增益曲线和残余谱仍可用于诊断。

NeuralKalman 已发表于 ASRU 2023；引用性能结果时需同时给出论文中的数据集、基线和表格位置。[NeuralKalman, DOI 10.1109/ASRU57964.2023.10389780](#)

Deep Adaptive AEC 把自适应滤波器写成可微分层，并由网络估计参考变换和时变学习因子。这种联合训练仍需在目标设备上验证路径突变与双讲时的稳定性。[Zhang et al., ICASSP 2022](#)

Seidel et al. 的综述发表于 *IEEE Signal Processing Magazine*, vol. 41, no. 6, pp. 24 – 38, 2024。各方法的收敛、双讲保护和计算量应按该文的具体实验设置解读。[Seidel et al., DOI 10.1109/MSP.2024.3449557](#)

把混合式方案按功能拆开，可分为自适应控制、线性路径估计和残余抑制。网络可以估计步长、卡尔曼统计量或残余增益；PBFDAF/FDKF 等解析结构仍提供可检查的路径估计和收敛状态。具体分工取决于延迟、算力和训练数据，不能写成固定的行业结论。

个性化 AEC (personalized AEC, pAEC)：2023 年 AEC Challenge 报告描述了个性化任务，系统要消除回声并保留注册用户的近端语音。注册语音时长、延迟和评分条件应按该报告的对应规则复现，不能写成所有 pAEC 产品的通用标准。[Cutler et al., IEEE OJSP 2024](#)

系统从注册语音提取声纹嵌入，并把它作为网络条件。这一思路与目标说话人提取 (Target Speaker Extraction, TSE；见 § 13.3) 相近。[GTCNN, Interspeech 2022](#) 合规与验收细节见 § 6.1.14。

pAEC 门限例子。设注册嵌入为  $\vec{e}_{\text{enroll}}$ ，逐帧近端嵌入为  $\vec{e}_t$ ，余弦相似度  $c = \cos(\vec{e}_t, \vec{e}_{\text{enroll}})$ 。阈值不能从通用经验直接照搬，应在目标设备、注册时长、距离和噪声条件下，用目标用户和非目标用户验证集标定。可以设置放行、抑制和不确定三个区间；不确定区间采用较保守的抑制，降低误压目标用户的风险。验收时分别报告目标用户误抑制率、非目标用户泄漏率和普通双讲质量，而不是只报一个相似度阈值。

多通道扩展：网络的输入通道数由训练时的结构决定，不能把任意数量的麦克风或播放参考直接拼接给固定模型。常见做法有三种：

1. 固定阵列几何和通道数训练；
2. 先用共享编码器逐通道提取特征，再用池化或注意力聚合可变通道；
3. 先做逐通道线性 AEC 和波束形成，只让单通道网络处理波束输出。

第二种能适应缺失通道，但仍需在训练中覆盖通道数、阵列几何和通道置换。多通道网络还要保持跨通道相位一致性，否则会损害后续波束形成。

对实时语音交互，设备播放语音时仍要检测用户插话。通常先用线性 AEC 降低设备自身播放，再把残差送入语音活动检测和识别；残余抑制的工作点要同时检查回声泄漏、近端语音失真和下游识别。若参考信号只能在远端获得，模块顺序需要按实际接口重新设计。

三类神经方案对比（定性；需要在相同数据、延迟和硬件下实测）：

| 路线    | 代表方案                | 可检查的内部量        | 主要风险             | 资源验证             |
|-------|---------------------|----------------|------------------|------------------|
| 混合式   | 线性 AEC 加学习型残余抑制     | 线性段路径、残差和 ERLE | 后滤波可能损伤近端语音      | 按频带数、模型版本和目标硬件测量 |
| 端到端   | 以麦克风信号和播放参考直接估计近端语音 | 通常缺少显式路径估计     | 域外设备、低 SER 和故障定位 | 按模型、上下文和目标硬件测量   |
| 神经卡尔曼 | 保留状态递推并学习增益或统计量     | 递推增益、状态估计和残差   | 统计量估计失配、模型计算量    | 同时报递推部分与网络部分     |

按设备条件选型：耳机和手表受算力、内存与功耗限制，可比较端侧小模型与传统频域方案；音箱和会议终端可评估 PBFDAF 或 FDKF 加神经后滤波；双讲条件复杂且需要保留递推诊断量时，可进一步评估神经卡尔曼；需要只保留注册用户时再评估 pAEC。语音助手还要单独验证用户插话（barge-in）时的近端保护。无论采用哪条路线，系统设计仍需处理 § 6.1.9 所列的参考、延迟、双讲和残余回声问题。

6.1.7 阵列中的 AEC：与波束形成的三种顺序

多麦克风设备里，AEC 与波束形成（第 5 章）谁先做，是系统级的架构决策，教科书上三种排法：

1. AEC→BF（每通道独立 AEC）：每个麦克风通道各配一套 AEC，波束形成在回声消除之后进行。优点是各通道回声路径  $h_m(n)$  不受波束权重变化影响；代价是线性 AEC 的计算与状态量随麦克风数  $M$  增加，量化见本节算力表。

当波束权重持续变化且计算资源允许时，这是优先评估的结构；2. BF→AEC（波束后单 AEC）：线性 AEC 从每个麦克风一路减少为波束输出的一路；实际节省量还要扣除波束处理和共享计算。

频域波束权重变化时，第  $k$  个频点的等效回声传递函数为  $H_{\text{eff}}(k, n) = \sum_m w_m^*(k, n) H_m(k, n)$ ；若采用固定时域 FIR 波束器，则相应形式是各路波束 FIR 与  $h_m$  卷积后求和。

权重变化会使等效路径变化，AEC 需要重新跟踪，暂态可能出现回声泄漏。暂时保持波束权重可以减小该变化，但会降低追踪灵活性；3. 联合优化（GEIC，广义回声与干扰对消，Generalized Echo and Interference Canceller）：Herbordt 与 Kellermann 把回声路径与波束权重放进同一个约束优化框架联合求解。在相应模型和目标函数下可得到联合最优解，但实现需要维护更多统计量和滤波系数。经典出处为 Kellermann (ICASSP 1997) 与 Springer 《Microphone Arrays》（2001）第 13 章。

联合分析：Schwartz et al. (Interspeech 2024) 在论文所述的多通道维纳滤波（Multichannel Wiener Filter，MCWF）模型下分析了 AEC 与波束形成的顺序。结论依赖其统计模型和目标函数；实际系统若采用波束后 AEC，需要验证权重变化期间的回声泄漏，也可评估在重收敛期间暂时保持波束权重。[Schwartz et al., Interspeech 2024](#)

边栏：立体声 AEC 的非唯一性问题。两个扬声器的参考完全线性相关时，参考相关矩阵秩亏，正常方程奇异：除了真实回声路径，还存在无穷多组解能拟合当前数据。参考只是高度相关而非完全相关时，矩阵通常不是严格奇异，但可能病态，对噪声和节目内容变化很敏感 (Sondhi, Morgan & Hall, *IEEE Signal Processing Letters* 1995)。去相关方法给各路参考加轻微且互不相同的处理，以改善条件数；非线性处理的可闻影响和改善程度要另行测量 (Benesty et al., ICASSP 1997)。 [Benesty et al. 1997](#) 完整选型见 § 6.1.10。

立体声非唯一性的数字例子。若  $x_1 = x_2 = x$ ，真实路径  $h_1 = 0.8$ 、 $h_2 = 0.2$  与另一组  $h'_1 = 1.3$ 、 $h'_2 = -0.3$  都产生  $(h_1 + h_2)x = x$ ，仅凭当前参考无法区分。相关系数  $\rho = 0.99$  时，归一化相关矩阵的特征值为  $1 \pm \rho$ ，条件数约为 199，说明估计对噪声和信号变化很敏感。去相关的目标是改善条件数，但改善程度仍应由实际节目内容和处理强度测量。

排序理由见本节，参考链路见 § 10.1 和图23。波束权重变化会使波束后 AEC 看到的等效路径变化，因此不能只按麦克风数量决定顺序。选型时应同时测量逐通道 AEC 的资源开销，以及波束后 AEC 在权重切换、目标移动和双讲条件下的恢复过程。

**多通道计算量手算。**下面只比较能够从本章计数规则复算的乘法量。共同条件为 16 kHz、 $L = 2048$ 、PBFDAF 块长  $N = 128$ 。

时域 NLMS 每样本按  $3L = 6144$  次实乘法计。PBFDAF 沿算例 6-2 的同一口径，16 个分区时无约束版约 352 次/样本。若每块对每个分区执行“IFFT、清零、FFT”梯度约束，再加  $2 \times 16 \times 4096/128 = 1024$  次/样本，总计约 1376 次/样本。

结果不含延迟搜索、双讲检测、残余抑制、内存访问和硬件并行。

| 算法               | 单通道本书手算                                   | $M$ 通道关系                                 | 仍需实测的资源                  |
|------------------|-------------------------------------------|------------------------------------------|--------------------------|
| 时域 NLMS          | $6144 \times 16000 \approx 98.3$ 百万次实乘法/s | 约为 $M_{\text{mic}} \times 98.3$ 百万次实乘法/s | 指令数、内存带宽、系数与历史缓冲         |
| PBFDAF，无逐分区梯度约束  | $352 \times 16000 \approx 5.6$ 百万次实乘法/s   | 约为 $M_{\text{mic}} \times 5.6$ 百万次实乘法/s  | FFT 实现、功率估计、约束频率与缓冲      |
| PBFDAF，每块逐分区梯度约束 | $1376 \times 16000 \approx 22.0$ 百万次实乘法/s | 约为 $M_{\text{mic}} \times 22.0$ 百万次实乘法/s | 同上，并计入每个分区的一对约束变换；间歇约束另算 |
| FDKF 或神经后滤波      | 不给固定倍数                                    | 由状态维度或模型结构决定                             | 目标实现的算子、线程、内存和实时因子       |

逐通道线性 AEC 的主要计算量随麦克风数  $M$  近似线性增长；放在波束后的单通道处理只运行一路，但会面对等效路径随波束权重变化的问题。两种结构应分别在目标实现上测量资源，并检查波束切换期间的回声泄漏。

6.1.8 评测体系与工程验收清单

**客观指标与适用边界。**ERLE (echo return loss enhancement，回声返回损失增强) 应在远端单讲的同一统计窗口内计算：

$$\text{ERLE} = 10 \log_{10} \frac{\sum_n |y(n)|^2}{\sum_n |e_{\text{echo}}(n)|^2}。$$

(6-4)

其中  $y = x * h$  是进入消除器前的回声分量， $e_{\text{echo}}$  是消除后的回声分量。

真实录音通常不能直接分离这两项。测试时可用远端单讲录音，以 AEC 输入和输出功率近似，但背景噪声会给分母设置下限。报告中应注明采样率、统计窗口、是否去除初始收敛段，以及输出是否包含残余抑制。

双讲时输出含近端语音，ERLE 不再表示回声衰减，应改用双讲回声和近端语音质量指标。图 18、图 19 (a)、图 29 和图 31 来自不同仿真配置，数值不能横向比较。

ERLE 换算。若残余回声能量与输入回声能量之比为 0.0063，ERLE 为  $10 \log_{10}(1/0.0063) \approx 22$  dB；比值为 0.0001 时，ERLE 为 40 dB。双讲段的输出还含近端语音，不能把总输出能量直接代入 ERLE 分母。

**主观与自动感知指标。**ERLE 只度量能量衰减，不能反映残余回声的音色或近端语音损伤。AECMOS (Purin et al., ICASSP 2022) 分别预测回声感知分和“Other”维度；后者表示回声之外的其他可闻退化，例如语音失真和噪声。AECMOS 自动感知模型会受到训练域、版本和输入处理影响，不能替代双盲听测；报告时应固定模型版本，并与真人听测和下游任务一起使用。

**系统验收的三类结果：**

1. 收敛后残余回声：在远端单讲稳定期分别报告线性滤波输出和最终输出。前者用于检查路径估计，后者还包含残余抑制；两者不能共用一个 ERLE 名称而不说明取点。

2. 重收敛过程：规定路径突变方式，并报告从突变发生到恢复到项目基线的时间及成功比例。§ 6.1.5 的 DVSS 数字是论文结果，只能用于复现该论文，不能用来划分产品的“优”或“可接受”。

3. 双讲期质量：同时评估近端语音损伤和残余回声。阈值要绑定具体标准版本、测试序列和目标设备基线；自动指标可用于固定版本的回归测试，不能替代真人听测。

§ 6.1.6~ § 6.1.8比较了混合式、端到端和神经卡尔曼方案，并说明了阵列中的模块顺序和评测口径。线性 ERLE、最终输出质量和近端语音损伤应分别报告；AEC 放在波束形成之后时，还需验证波束权重变化造成的路径突变。

系统实现与验收（§ 6.1.9~ § 6.1.18）


#### 6.1.9 WebRTC AEC3 的结构与排障

基本系统功能（图20（a）给出对应信号流）：

1. 参考—麦克风延迟对齐：播放缓冲、采集缓冲和声学传播共同决定总延迟，其大小应在目标音频路径上测量。若参考与麦克风信号里的回声没有对齐，滤波器会用部分抽头覆盖纯延迟，延迟超出覆盖范围时则无法表示完整路径（抽头点细节见 § 6.1.11）；
2. 双讲检测（DTD）：双讲期的  $e$  含近端语音，继续更新会使路径估计偏离；检测到双讲后冻结或减小更新（见图18（b）、图29和图30（c））；
3. 非线性处理器（Nonlinear Processor, NLP）残余回声抑制：扬声器失真和回声路径时变会产生线性滤波器未建模的回声分量，可在频域进一步衰减（工作点设置见 § 6.1.13）。采集端麦克风或模数转换器削波会同时破坏近端语音，已丢失的幅度不能由 NLP 恢复；应优先用模拟/数字增益控制避免削波，并用饱和检测触发冻结更新或降级处理；
4. 舒适噪声生成（Comfort Noise Generation, CNG）：强抑制可能使背景噪声突然消失，听感上形成不连续的静音。CNG 可按真实底噪的频谱和电平合成背景；频谱或电平失配时，合成噪声本身会变得可辨认。

图20 AEC 信号处理链：自适应滤波与混合式结构（示意）

(a) 经典 AEC 信号流：已知参考学出回声副本再相减（示意）



(b) 混合式处理链：线性回声估计 + 学习型残余抑制（示意）




图20 (a) 显示参考输入、延迟估计与自适应滤波的基本信号流；该子图没有绘出本节所述的 NLP 和 CNG。(b) 显示混合式结构，橙色框表示可采用学习型残余抑制的部分。完整产品还需按前述顺序接入 NLP、CNG 和对应的双讲保护。

WebRTC AEC3 架构示例。AEC3 的内部模块和参数会随源码版本及构建配置变化，下面依据 WebRTC 官方源码提交 0467d2b91cc20b9b001c2bbb73d43ea6b2491f3e 说明一种开源实现的分工，不把内部常数当作产品规格：

- 分块流水处理：采集和参考按内部子块推进。子块大小、采样率转换和缓冲共同决定延迟，需针对所用源码版本实测；
- Render Buffer：保存远端参考历史，为延迟估计和路径滤波提供候选数据。所需覆盖范围由播放、采集和传输链路的实测延迟及抖动确定；

- 候选滤波器辅助延迟搜索：比较不同候选对齐位置的残差，路径或输出设备切换后重新选择候选；
- refined/coarse 双滤波器：两组滤波器使用不同更新增益。该版本的 `echo_remover.cc` 比较 refined/coarse 残差功率、回声功率等量来选择线性输出并平滑切换；`subtractor.cc` 在 coarse 连续较差时还会用 refined 系数重置它。输出选择不能概括成由 `FilterAnalyzer` 单独决定；
- 频域抑制器和舒适噪声：线性部分之后按频带控制残余回声，并在需要时生成与背景相符的舒适噪声。具体增益规则应以所用版本源码和目标设备测试为准。[WebRTC subtractor.cc](#)、[WebRTC echo\\_remover.cc](#)

排障清单（回声消不掉，按顺序查）：

1. 检查参考抽头位置：优先选择能够覆盖混音、音量、均衡和限幅等已知数字处理的最晚可用参考。若取自应用层原始音源，抽头之后的时变或非线性变换会成为线性滤波器不能稳定表示的残余；抽头点对照见 § 6.1.11；
2. 检查延迟估计：逐步注入已知延迟并记录 ERLE 和路径估计。失配仍在滤波器覆盖范围内时，影响取决于剩余可用抽头和路径能量分布；失配超过滤波器跨度时，滤波器无法覆盖完整路径。图30（b）只展示本书仿真的一个越界例子；
3. 检查双讲冻结或步长缩减：否则近端语音会使路径估计偏离（见图30（c））；
4. 比较算法前先排除接口问题：确认参考内容、取点、延迟覆盖、削波和双讲控制，再在同一录音与统计窗口上比较算法。收敛时间和稳态 ERLE 应相对项目基线判断，不使用通用秒数或 dB 阈值。

6.1.10 多参考 AEC 模型与去相关选型

单参考 AEC 假设只有一路播放；立体声外放、双扬声器和多分区播放属于多参考问题。模型是否可辨识取决于参考声道之间的相关性和各条回声路径，不能用固定 ERLE 损失概括。

三种多参考模型：

| 模型                                           | 结构                                                                                   | 可辨识性                | 资源关系             | 适用条件              |
|----------------------------------------------|--------------------------------------------------------------------------------------|---------------------|------------------|-------------------|
| 独立单声道（dual-mono）                             | 各参考分别运行单参考 AEC，再合成估计回声                                                               | 参考强相关时仍可能得到不唯一的路径估计 | 近似随参考路数增加        | 参考内容近似独立，并已验证合成残差 |
| 联合 MISO（多输入单输出，Multiple-Input Single-Output） | 多路参考联合估计到一个麦克风的多条路径                                                                  | 仍受参考相关矩阵条件数限制       | 同时维护多组路径和交叉统计量   | 单个麦克风接收多路播放回声     |
| MIMO 阵列联合                                    | 多参考和多麦克风联合估计，例如广义回声与干扰对消（GEIC）和扩展多通道维纳滤波（extended Multichannel Wiener Filter，MWFext） | 可联合利用跨通道统计量，但仍需满秩激励 | 随参考数、麦克风数和状态维度增加 | 需要联合回声与空间干扰处理     |

参考声道越多，待估参数越多；声道内容越相关，正常方程越接近奇异。去相关用于改善相关矩阵的条件数。

去相关方法对照（以立体声 AEC 为例）：

| 方法                            | 做法                | 可能的副作用        | 验证方法                     |
|-------------------------------|-------------------|---------------|--------------------------|
| 半波整流（half-wave rectification） | 各声道施加不同的轻微非线性     | 谐波失真、声像变化     | 同时测参考相关矩阵条件数、远端单讲残余和主观音质 |
| 时变相位调制                        | 各声道施加独立的慢变全通相位    | 瞬态或声像可能变化     | 在语音与音乐材料上分别盲听，并检查路径跟踪    |
| 独立小频移                         | 各声道施加方向或大小不同的微小频移 | 音乐可能出现拍频或音高扰动 | 扫描移频量，比较可辨识性与可闻失真        |
| 低电平去相关噪声注入                    | 各声道叠加独立、整形后的低电平噪声 | 底噪升高          | 按目标播放电平测条件数、底噪和听感        |

是否启用去相关，应根据目标节目材料在工作频带内的相干函数、相关矩阵条件数和路径估计稳定性判断。确定候选方法后，逐步增加处理强度，并同时复测远端单讲残余、近端单讲失真、双讲质量和主观音质；处理强度的上限由项目听测与任务指标共同决定。

多参考相关性的数字例子。两路参考的归一化相关系数为  $\rho$  时，理想化的  $2 \times 2$  相关矩阵条件数为  $(1 + \rho)/(1 - \rho)$ 。  
 $\rho = 0.95$  时条件数为 39， $\rho = 0.6$  时降为 4。这个计算说明去相关能改善可辨识性，但不能直接换算成固定的 ERLE 增益；实际收益还取决于声道内容、回声路径、去相关失真和估计器。

6.1.11 播放链参考抽头位置及其对 ERLE 的影响

播放链路是一串变换：应用音源 → 混音 → 音效/均衡（Equalization, EQ）→ 自动增益控制（Automatic Gain Control, AGC）/ 动态范围压缩（Dynamic Range Compression, DRC）→ 限幅 → 重采样 → 编解码 → 数模转换器（Digital-to-Analog Converter, DAC）→ 功放 → 扬声器。

参考抽头越早，抽头之后未反映在参考中的处理越多。固定线性变换可以并入等效回声路径；时变增益、削波、丢帧和编解码伪影则可能造成难以稳定建模的残余。

抽头点对照表（T1 最早、T5 最晚；实际系统可能只能访问其中一部分）：

| 抽头点         | 位置          | 抽头之后的变换              | 主要风险              | 检查方法                   |
|-------------|-------------|----------------------|-------------------|------------------------|
| T1 应用层原始音源  | 应用输出        | 混音、系统音量及全部后处理        | 参考可能缺少其他应用声音和时变处理 | 切换音源、通知音和音量，观察参考是否同步变化 |
| T2 混音后、音效前  | 混音器输出       | EQ、AGC/DRC、限幅及后续处理   | 时变增益或限幅造成失配       | 分别旁路后处理，比较残余与路径估计      |
| T3 音效后、AGC前 | 均衡后         | AGC/DRC 增益包络、限幅及后续处理 | 增益变化和削波未进入参考      | 扫描播放电平并记录残余、削波和恢复过程    |
| T4 限幅后、编解码前 | 限幅器输出       | 重采样、编解码和传输链路         | 延迟抖动、丢帧或编码伪影      | 注入已知信号并记录端到端延迟分布和残余    |
| T5 最晚可用数字参考 | DAC 前的可访问节点 | DAC、功放、扬声器和声学路径      | 模拟与声学非线性仍不在参考中    | 作为候选基线，与电压/电流参考及更早抽头对照 |

在可访问的节点中，通常优先评估包含更多数字处理且时间戳可靠的较晚参考。

若音量增益发生在抽头之后，线性区内播放增益变化会等比例改变等效路径增益；收敛时间和 ERLE 变化量需在目标实现上测量。抽头位于时变增益之前时，可以比较包络补偿与改取较晚参考两种方案。

无线或外接播放链路还要实测延迟分布、突变和丢帧，并让延迟搜索与缓冲覆盖所需分位数，而不是采用固定抖动范围。

云端若拿不到与麦克风时钟对齐、且能代表实际播放链路的参考，就不能直接运行依赖该参考的线性 AEC；此时可在端侧完成 AEC，云端再做无参考或弱参考的声学回声抑制（Acoustic Echo Suppression, AES）。另一种方案是上传对齐后的参考波形或特征，但会增加上行带宽、同步、隐私和故障恢复负担。选择哪种划分应同时记录参考取点、时间戳精度、传输抖动与端云总延迟，不能把“云端只做 AES”当作架构定律。

6.1.12 测试覆盖与验收矩阵

下面的矩阵用于组织测试，不给出通用认证阈值。若项目受某项通信、车载或主观听测标准约束，应记录标准号、版本、测试序列、设备配置和适用 profile，并直接采用该版本规定的判据。

| #  | 测试项              | 条件              | 记录结果                  | 阈值来源        |
|----|------------------|-----------------|-----------------------|-------------|
| C1 | STFE 收敛后线性段 ERLE | 远端单讲，排除初始收敛段    | 均值或分位数、统计窗口、输入与线性输出取点 | 目标设备线性段基线   |
| C2 | STFE 最终输出        | 与 C1 使用同一录音     | 最终残余、AECMOS 回声维和听测结果  | 目标应用的可闻回声要求 |
| C3 | 初始收敛             | 规定冷启动状态和播放材料    | 从播放开始到达到项目基线的时间分布     | 交互延迟与任务要求   |
| C4 | 路径突变重收敛          | 规定移动、遮挡或设备切换动作  | 恢复时间、成功比例和暂态最大残余      | 目标场景允许的中断时间 |
| C5 | 双讲语音质量           | 规定 SER、说话人和双讲序列 | 近端质量、内容保持与残余回声        | 选定标准或项目听测基线 |

| #   | 测试项       | 条件                  | 记录结果              | 阈值来源         |
|-----|-----------|---------------------|-------------------|--------------|
| C6  | 双讲回声泄漏    | 与 C5 同一批样本          | AECMOS 回声维及真人听测   | 固定模型版本和听测协议  |
| C7  | STNE 近端损伤 | 近端单讲，AEC 开关对照       | 频谱、客观质量、下游任务与听测差异 | 旁路基线和允许损伤    |
| C8  | 沉默期稳定性    | 覆盖项目最长空闲段并在期间改变路径   | 系数漂移及重新播放后的恢复过程   | 最长会话和使用状态    |
| C9  | 非线性播放     | 覆盖目标播放电平和材料，并含双讲    | 线性段残余、最终残余和近端损伤   | 设备声学过载与音质要求  |
| C10 | 时钟偏移      | 覆盖实际播放与采集时钟域及最长会话   | 延迟漂移、重采样状态和残余趋势   | 时钟规格和最长运行时间  |
| C11 | 输出切换与丢帧   | 执行目标系统支持的切换和故障注入    | 延迟重搜、恢复时间和音频连续性   | 交互与通话连续性要求   |
| C12 | 适用的认证指标   | 按所选标准及 profile 生成条件 | 标准要求的指标和统计过程      | 所选标准的明确版本与条款 |
| C13 | 下游任务      | AEC 旁路与启用使用同一批输入    | 唤醒、识别或通信任务的差异     | 任务基线与允许退化    |

发布或产线回归可以从上述矩阵抽取一组稳定测试，但抽样长度、重复次数和验收判据要来自项目的历史分布、器件公差和故障成本，不能从本教程复制固定数值：

| #  | 回归项      | 快速方法                  | 判定依据                       |
|----|----------|-----------------------|----------------------------|
| A1 | 参考内容与取点  | 查信号图，并改变音源、通知音、音量和后处理 | 参考包含预期播放内容；未覆盖的处理已有补偿或风险记录 |
| A2 | 延迟覆盖     | 读取延迟估计日志，并注入链路抖动和切换   | 搜索范围与滤波器跨度覆盖目标延迟分布并留有设计余量  |
| A3 | STFE 双取点 | 固定远端单讲样本，分别记录线性段和最终输出 | 两个取点分别达到对应项目基线，口径见 § 6.1.8 |
| A4 | 双讲       | 使用固定且版本化的双讲测试集        | 近端损伤、残余回声和滤波器稳定性均满足项目基线    |
| A5 | 路径突变     | 执行可重复的移动、遮挡或切换动作      | 在规定时间内恢复到项目基线，并报告失败比例      |
| A6 | 真人听测     | 按预先定义的样本量、随机化和播放协议盲听  | 使用所选协议的统计判据，不以单个听众意见代替结果   |
| A7 | 自动多指标复核  | 固定模型、软件版本和输入集         | 只用于回归；阈值由版本基线和人工复核结果确定     |

### 6.1.13 AEC 诊断方法与 NLP 工作点

诊断表（按“征兆 → 量测 → 工具 → 判据”排列）：

| #  | 征兆             | 量测                                | 工具/信号                                                                       | 判断依据                         |
|----|----------------|-----------------------------------|-----------------------------------------------------------------------------|------------------------------|
| D1 | ERLE 低于项目基线    | 参考与真实播放是否一致                       | 对比参考与实际播放内容；查抽头点                                                            | 改变音源、音量或后处理时，参考应包含相同变化或有明确补偿 |
| D2 | ERLE 不再上升      | 延迟失配                              | 互相关峰、图30（a）和延迟日志                                                            | 峰位置应落入滤波器覆盖范围；多峰时检查多路径与周期信号  |
| D3 | 双讲后恢复慢         | 自适应控制                             | DTD 判决、步长和路径失配日志                                                            | 恢复过程相对同一设备的远端单讲基线无异常停滞       |
| D4 | ERLE 随播放电平出现平台 | 非线性占比                             | 多个播放电平的 ERLE 与失真对比                                                          | 电平降低后残余非线性同步减小，见图31的仿真机制     |
| D5 | 断续/闷罐/背景声突然消失  | NLP 过度抑制                          | 旁路 NLP，对比适用版本的 ITU-T P.863、AECMOS Other 维和听测；历史回归若保留 PESQ，须固定 P.862 实现与带宽口径 | 旁路后语音改善 → 减小 NLP 抑制量         |
| D6 | 沉默段背景突变        | CNG 频谱与电平                         | 沉默段频谱与真实底噪对照                                                                | 以盲听和频带差异共同调节，不使用统一 dB 阈值     |
| D7 | 长通话逐渐变差        | 采样率偏移（Sample Rate Offset，SRO）累积漂移 | 覆盖最长目标会话的延迟估计曲线                                                             | 残余速率差应满足相干性和任务指标要求           |

| #  | 征兆            | 量测   | 工具/信号              | 判断依据                        |
|----|---------------|------|--------------------|-----------------------------|
| D8 | 切歌或切设备<br>后失效 | 延迟突变 | 对齐切换事件的 ERLE 与延迟轨迹 | 在项目规定时间内恢复，并检查<br>搜窗是否覆盖新路径 |

D1~D3检查参考、延迟和双讲控制；D4用于判断非线性残余；D5~D6检查近端语音和舒适噪声；D7~D8检查长时漂移和链路切换。ITU-T 已于 2024 年 1 月 5 日删除 P.862、P.862.1、P.862.2 和 P.862.3，并指向 P.863、P.863.1 与 P.863.2；因此 PESQ 只宜用于需要延续既有 P.862 基线的历史回归，新测试应先确认 P.863 的带宽、预处理和适用条件。[ITU-T P.862 状态页](#)、[ITU-T P.863](#)

采样率偏移 (Sample Rate Offset, SRO)。播放与采集时钟相差 10 ppm 时，16 kHz 下每秒相差  $16000 \times 10^{-5} = 0.16$  个采样；1 小时累积 576 个采样，即 36 ms。延迟重搜只能重新选择整数或分数延迟，不能消除持续增长的速率差；长通话通常需要估计 SRO 并对参考做重采样补偿。若硬件允许，共用时钟可以从源头消除该偏移。

NLP 工作点 (NLP = 非线性处理器, nonlinear processor)。NLP 对各频带施加增益；抑制增强时，残余回声可能降低，但近端语音损伤、背景抽动和断续风险会上升。工作点不能只用一个最大抑制深度定义：

| 调节方向   | 需要控制的量                 | 同时观察            | 回退条件                     |
|--------|------------------------|-----------------|--------------------------|
| 近端保护优先 | 提高增益地板，减慢或限制双讲期抑制      | 近端频谱、下游识别、双讲听感  | 仍有回声时再逐步增强抑制，而不是一次设置固定档位 |
| 回声抑制优先 | 在远端单讲置信度高的频带降低增益       | 残余回声、音乐噪声和背景连续性 | 出现近端内容丢失、抽动或背景突变         |
| 状态自适应  | 用远端活动、双讲置信度和残余估计连续控制增益 | 状态切换时的暂态和恢复时间   | 置信度不足或切换产生可闻伪影           |
| 舒适噪声配合 | 根据真实底噪估计 CNG 频谱与电平     | 沉默段的连续性与噪声颜色    | CNG 可单独辨认或掩盖近端弱语音        |

设置时先固定测试集和取点，从旁路 NLP 开始逐步增加抑制，绘制残余回声、近端质量、下游任务和听测结果之间的曲线。增益地板由曲线的折中点和双讲保护要求确定，不存在通用的 -20 dB 下限。

6.1.14 个性化 AEC 的合规检查

pAEC (个性化 AEC, personalized AEC) 在 § 6.1.6 定义。注册语音和算法延迟的具体限制应从采用的挑战赛规则、论文实验设置或产品需求中逐项读取，不能把某一届任务条件直接当作通用产品规格。实现时还要检查以下隐私、访问控制与体验问题：

| #  | 检查项      | 需要明确的设计                              | 不满足的后果           |
|----|----------|--------------------------------------|------------------|
| P1 | 注册数据量与质量 | 在目标距离、噪声和说话变化下绘制注册数据量与错误率曲线          | 嵌入不可靠，双讲时误压目标用户  |
| P2 | 告知与授权    | 按适用法律和产品政策说明用途、处理位置、保留期与删除方式         | 用户无法判断数据怎样使用     |
| P3 | 嵌入存储     | 明确端侧或云侧位置、访问控制、加密和备份范围               | 未授权访问或数据范围扩张     |
| P4 | 首帧可用性    | 若要求从开头保护目标用户，应在首个处理帧前准备嵌入；延迟计入系统关键路径 | 开场语音可能未受个性化条件保护  |
| P5 | 删除与退出    | 定义删除入口、传播范围、完成时间和退出后的普通 AEC 行为       | 用户无法撤回个性化处理      |
| P6 | 低置信度处理   | 规定无注册、低置信度和多人混淆时的旁路、回退或提示            | 误抑制非注册说话人或目标用户   |
| P7 | 共享设备     | 明确多用户配置、权限、切换和未成年人场景的授权流程            | 配置串用或家庭成员被误抑制    |
| P8 | 验收加测     | 在 C5/C6 基础上加入目标用户、非目标用户及多人双讲组合       | 普通双讲测试无法覆盖身份条件错误 |

6.1.15 研究方向

当前研究主要沿四条路线展开：学习自适应步长或卡尔曼统计量、在多通道上联合处理回声与干扰、把声纹条件加入个性化 AEC，以及用感知模型评价残余回声。阅读新工作时要先检查因果性、总延迟、通道数、参考抽头位置、双讲数据构成和指标口径。预印本或挑战赛结果只有在版本、测试集和基线一致时才能比较，因此本章不列无法按这些条件复核的近期性能数字。

图表对照。

| 图    | 内容                                                            | 对应正文                 | 口径提醒                                              |
|------|---------------------------------------------------------------|----------------------|---------------------------------------------------|
| 图 27 | 播放参考、路径估计与相减结构                                                | § 6.1.1              | 顶部 DTD 控制自适应滤波器更新                                 |
| 图 18 | (a) 结构 + DTD 开关； (b) NLMS 收敛 + 双讲冻结                           | § 6.1.2              | current-first 回归向量与回声卷积索引一致；图中均值来自固定种子和标示窗口       |
| 图 28 | (a) $\hat{w}$ 逼近 $h$ ； (b) 失配与 ERLE 的关系； (c) $\mu$ 取舍         | § 6.1.2              | “0步”是更新前初值； $\mu \in (0, 2)$ 只对应理想假设              |
| 图 19 | (a) 独立仿真线性/非线性场景； (b) 按模型假设和处理对象分类                            | § 6.1.4、<br>§ 6.1.6  | (a) 支持自身配置下的定量结论；与图31配置不同，ERLE 数值不可横向比较           |
| 图 20 | (a) 系统信号流； (b) 混合结构                                           | § 6.1.9、<br>§ 6.1.6  | 橙色模块表示可选的学习型残余抑制                                  |
| 图 29 | 三路均方根包络与远端单讲 ERLE                                             | § 6.1.2<br>末、§ 6.1.5 | 双讲区不绘制 ERLE，因为残差含近端语音                             |
| 图 30 | (a) 有符号互相关的最大正峰约 331 采样； (b) 对齐约 28 dB、不对齐约 2 dB； (c) 冻结与继续更新 | § 6.1.5、<br>§ 6.1.9  | 设置的纯延迟为 300 个采样；相关峰还受有色参考和多径影响，且该延迟超过 128 抽头滤波器跨度 |
| 图 31 | (a) 线性与归一化 $\tanh$ 非线性路径； (b) 同一映射                            | § 6.1.4              | 唯一职责是量化映射曲率与线性模型残差平台；后段均值由图示配置计算                  |
| 图 32 | (a) 混合处理流程； (b) 模块前提； (c) 选型条件                                | § 6.1.6、<br>§ 6.1.3  | 不给固定性能档次，需按目标设备实测                                 |

6.1.16 可执行基线与开源实现边界

本书提供只依赖 NumPy 的时域 NLMS 与 ERLE 基线，源码见 [codes/array\\_tutorial/aec.py](#)，四章联合示例见 [codes/examples/ch06\\_09\\_baselines.py](#)。在仓库根目录运行：

```
.venv/bin/python -m codes.examples.ch06_09_baselines
```

`nlms(reference, microphone, filter_length, ...)` 接收两个等长一维实数数组，返回残差、估计回声和最终抽头。`freeze[n]=True` 时仍产生当前样本输出，但不更新抽头；参考回归向量能量为零时也跳过更新。`erle_db()` 用 `double_talk_mask` 明确排除双讲样本；调用者还需用 `valid_mask` 排除初始收敛段、近端单讲和静音段。该实现用于核对式(6-2)的抽头顺序、冻结语义和指标窗口，不包含延迟搜索、非线性处理、舒适噪声或实时音频接口。

自动测试见 [tests/test\\_codes\\_aec\\_wpe\\_sep\\_track.py](#)，覆盖零能量参考、已知路径收敛、路径突变、冻结更新以及双讲样本不进入 ERLE。接入设备时还必须增加参考断流、纯延迟超过滤波器覆盖范围、削波、多参考高度相关、块边界和长时路径漂移测试；异常时的安全回退是冻结自适应更新或旁路线性抵消，而不是继续用不可信残差更新。

WebRTC AEC3 属于完整工业实现层级，包含参考缓冲、延迟处理、快慢滤波器、残余抑制和舒适噪声；本书只索引 § 6.1.9 固定提交的官方源码，不复制其实现。PBFDAF/MDF、FDKF、神经 DTD、DeepVQE、个性化 AEC 与 GEIC 也只给原始论文或官方项目入口。评估这些实现时应固定源码提交、许可证、构建选项、采样率、声道数、帧长、参考抽头、允许延迟、状态重置规则和测试取点；模型权重与挑战赛数据还需分别核对再分发许可。不能用本节教学 NLMS 的结果替代这些系统的验收。

6.1.17 常见误区与自测题

常见误区：

- 参考抽头过早；
- 双讲段仍计算 ERLE；
- 双讲时加大步长；

- 静音时继续更新；
- 把 AEC 固定放在时变波束之后；
- 靠增加线性抽头处理扬声器非线性；
- 只看自动分数而不听双讲语音。

各项对应的模型和检查方法见 § 6.1.4、§ 6.1.5、§ 6.1.7、§ 6.1.8 和 § 6.1.11。

自测题（答案要点见 § 6.1 对应小节）：

1. 默写三项模型并说出每个符号的含义。
2. 换算 16 kHz 下 64 ms 与 128 ms 对应的抽头数。
3. 在播放链路上标出抽头点 T1 – T5，并说明怎样用参考完整性、延迟和残余测量选择抽头。
4. 手推 LMS 到 NLMS 的归一化三步。
5. 复算算例 6-1，验证残差关系  $e' \approx (1 - \mu)e$ 。
6. 说出步长  $\mu$  的大小取舍，并设计目标信号上的扫描方法。
7. 已知残余能量比 0.0063 与 0.0001，分别算出 ERLE。
8. 写出 Geigel 判决的参考历史窗，并解释阈值 0.5 对应的线路回声假设为什么不能直接当作声学 AEC 的固定阈值。
9. 对着图 31 说清非线性平台从哪来。
10. 按算例 6-2 的计数规则比较时域 NLMS、无约束 PBFDAF 和逐分区约束 PBFDAF。
11. 在 SER=-20 dB 下算一笔减法与乘法的账。
12. 为 A3、A4 和 A6 分别写出测试输入、取点、统计量与项目阈值来源。
13. 说清双讲冻结与连续小步长的取舍。
14. 对三种阵列方案各说一句选型话。
15. 画出 AEC3 示例中的参考缓冲、延迟估计、自适应滤波、残余抑制与舒适噪声关系。
16. 说出客观 ERLE、主观 MOS 和自动 AECMOS 各自评价什么，并说明双讲时为什么不能用 ERLE。

#### 6.1.18 延伸阅读

1. Häsler & Schmidt, *Acoustic Echo and Noise Control* (Wiley 2004) ——AEC 领域的经典大部头，从自适应理论到免提终端工程全覆盖。 [Wiley 在线版](#)
2. Benesty, Gäsler, Morgan, Sondhi & Gay, *Advances in Network and Acoustic Echo Cancellation* (Springer 2001) ——PBFDAF、IPNLMS、立体声 AEC 的原始出处合集（读 IPNLMS 认符号  $\alpha$ ，读 PBFDAF 注意 MDF 一脉）。
3. Enzner et al., *Acoustic Echo Control* (Elsevier 2014) ——IEEE SPM 经典综述的扩展版，卡尔曼路线讲得最透。
4. Breining et al., IEEE SPM 1999——四大难点的经典出处，一节一引，入门必读（链接见 § 6.1.1）。
5. 中文参考：《语音识别服务实战》第 3.4 节，侧重工程实现。

§ 6.1.9~§ 6.1.18 讨论了 AEC3 的信号流、多参考相关性、参考抽头、验收、诊断、个性化处理、代码基线和研究方向。部署时应先确认参考信号与延迟对齐，再检查自适应控制和残余抑制。

第 7 章讨论 WPE 去混响，第 8 章讨论多说话人分离。

第 7 章 · 去混响 (WPE)

第 6 章处理设备播放声返回麦克风形成的回声。本章讨论房间混响的晚期拖尾及 WPE 去混响。多说话人分离、掩码估计和完整处理顺序见第 8 章。

7.1 WPE 去混响

声学回声消除 (Acoustic Echo Cancellation, AEC) 处理已知播放参考产生的回声；加权预测误差法 (Weighted Prediction Error, WPE) 利用语音跨帧预测结构估计晚期混响。保护延迟用来减少对直达声和早期反射的损伤，但不能保证它们完全不受影响；估计误差、过小的保护延迟和模型失配都可能产生语音失真。

去混响有三条常见路线：**波束形成**（第 5 章，利用空间选择性压低弥散混响）、**盲逆滤波或线性预测**，以及神经网络谱增强。本节重点介绍 WPE。WPE 既指它采用的加权预测误差准则，也常用来指基于该准则的去混响算法。

WPE 之前的三类方法。多通道逆滤波、倒谱分离和谱方差抑制分别依赖已知路径、倒谱域可分性或晚期混响功率估计。它们的假设和局限有助于理解 WPE 的设计。

**多通道逆滤波定理** (Multiple-input/output INverse Theorem, MINT; Miyoshi & Kaneda 1988)。它假设房间冲激响应 (Room Impulse Response, RIR) 已知，且各通道传递函数没有公共零点，再用有限冲激响应 (Finite Impulse Response, FIR) 逆滤波器抵消房间响应。条件满足时可作为理想逆滤波的参考，但它对 RIR 估计误差、公共零点和加性噪声敏感，滤波器长度也随混响时间增加。因此实际系统很少依赖预先精确测得的 RIR。

**倒谱 liftering**。这类单通道方法假设声门激励与声道、房间响应在倒谱域占据不同区域。对数功率谱经逆傅里叶变换进入倒谱域后，用窗函数保留指定倒谱区间。计算量较低，但重混响和强谐波会使两类成分重叠，窗口选择不当会同时损伤语音。

**谱方差抑制**。该方法假设晚期混响与直达声统计独立，并从历史帧递推晚期混响功率谱，再用维纳增益或谱减法抑制。它可以按帧因果运行，但会受到功率估计滞后、非平稳噪声和音乐噪声影响。现代学习型谱增强仍沿用“估计干扰功率或增益，再施加频带增益”的基本形式。

MINT 说明已知房间响应时的逆滤波条件；倒谱方法说明单通道频谱分解的局限；谱方差方法提供了逐帧功率估计与增益抑制思路。WPE 不要求预先测量 RIR，并可扩展到多通道，同时通过保护延迟只预测晚期成分。

**三路线对照表**。不同论文使用的阵列、数据集、识别器和因果条件不同，不能把词错率改善幅度横向拼成统一范围。表中只比较处理对象与实现条件；需要性能数字时，应引用同一数据集上的原始实验。

| 路线    | 代表                                                                                                                | 主要处理对象        | 所需输入或假设                                                    | 因果性与计算                   | 主要限制                |
|-------|-------------------------------------------------------------------------------------------------------------------|---------------|------------------------------------------------------------|--------------------------|---------------------|
| 空间选择  | 最小方差无失真响应 (Minimum Variance Distortionless Response, MVDR)、广义特征值 (Generalized Eigenvalue, GEV) 波束形成, 见第 5 章 § 5.4 | 弥散混响与定向干扰     | 多通道信号，以及目标方向或掩码                                            | 可按帧流式处理；计算随通道数和频点数增加     | 混响占优且方向线索弱时，空间选择性有限 |
| 延迟预测  | WPE、在线 WPE                                                                                                        | 可由历史帧预测的晚期混响  | 短时傅里叶变换 (Short-Time Fourier Transform, STFT) 复谱、保护延迟与足够统计量 | 批处理版迭代整段数据；在线版递推统计量      | 短语音、模型失配或预测阶数过大时不稳定 |
| 谱增益估计 | 深度神经网络 (Deep Neural Network, DNN) 去混响、谱方差抑制                                                                       | 全带混响，也可联合处理噪声 | 训练数据或可靠的晚期混响功率估计                                           | 是否因果取决于网络前瞻与特征窗；计算量依模型而定 | 跨房间、跨设备泛化和语音失真需单独验证 |

长混响可先评估 WPE；存在定向干扰时再结合波束形成；学习型后滤波还需满足算力和训练数据条件。多通道 WPE、波束形成与单通道后滤波可以组成一条候选链路，但实际顺序取决于统计量和通道数，见第 10 章 § 10.1。

REVERB 挑战赛中的 WPE：REVERB 包含 8 通道、2 通道和单通道设置，仿真数据的混响时间约为 0.25~0.7 s，另含真实房间录音。

Kinoshita 等在 *EURASIP Journal on Advances in Signal Processing* 2016 的挑战总结表明，WPE 对远场识别的改善与通道数和数据条件有关；引用结果时必须注明通道数与测试集。REVERB Challenge 官方任务说明、Kinoshita et al., 2016, § 2、§ 4.1.1 与图5图21 (b) 中音节结束后的横向能量拖尾，在 (c) 中得到减弱。

WPE 的直觉：晚期混响在所选时频模型中被近似为可由历史观测线性预测的成分，再从当前帧减去该预测。这不要求语音或混响全程平稳；算法用随帧变化的功率  $\lambda(n, f)$  表示语音非平稳性。保护延迟  $\Delta$  隔开当前帧与预测历史，跳过最近的  $\Delta - 1$  帧，以降低直达声和早期反射进入预测项的程度。

WPE 的预测式只引用当前帧之前的观测，这使它可以改造成流式算法。但经典批处理 WPE 会用整段录音反复估计滤波器和时变功率，仍然是非因果处理。只有把统计量、滤波器和功率估计都改为只使用当前及历史数据，并计入 STFT 分帧带来的等待时间，才能称为因果在线 WPE。

模型（每个频点  $f$  独立处理；本节  $X$ 、 $E$ 、 $G$  都是逐时频点的复数标量，多通道版才升级为向量）：

$$X(n, f) = E(n, f) + \sum_{k=\Delta}^{\Delta+K-1} G^*(k, f) X(n - k, f). \quad (7-1)$$

这里  $E(n, f)$  表示希望保留的直达声与早期反射。

式(7-1)把当前观测分成早期成分  $E$  和由历史帧线性预测的晚期成分。不同频点的混响衰减不同，因此每个频点分别估计一组  $G$ ，实时可并行计算。 $\Delta$  将当前帧与预测历史隔开，避免使用最近几帧预测直达声和早期反射。其中：

- $X(n, f)$ ：第  $n$  帧、频点  $f$  的观测谱（拿到的数据）； $E(n, f)$ ：想恢复的干净早期成分；
- $G(k, f)$ ：预测滤波器系数； $\Delta$ ：保护延迟，求和的  $k$  从  $\Delta$  起算，因此跳过最近  $\Delta - 1$  帧； $K$ ：预测阶数，决定使用多少个历史帧。 $\Delta$  和  $K$  没有脱离帧移、数据量和目标失真指标的通用默认值。

图24 WPE 延迟预测： $\Delta=3$  时保护  $t-1$ 、 $t-2$ ， $K=5$  使用  $t-3 \dots t-7$




图24 使用与 `nara_wpe` 一致的索引： $\Delta = 3$ 、 $K = 5$  时，受保护而不参与预测的是  $t - 1$ 、 $t - 2$ ；五个预测帧依次为  $t - 3$  到  $t - 7$ 。统一写成

$$\hat{r}(t) = \sum_{q=0}^{K-1} G_q^* X(t - \Delta - q).$$

因此  $q = 0$  对应  $t - \Delta$ ，不是保护区的一部分。该预测式只含历史样本；批处理还是在线处理，则取决于  $G_q$  和功率统计是否使用未来帧。

#### 算例 7-1: WPE 的一步直觉数值例（单通道、单频点）

WPE 用历史观测预测晚期混响，再从当前帧中减去预测值。完整算法要交替估计系数  $G$  和时变功率；本例将  $G$  视为已知，只计算一次预测与相减。

取单通道、单频点、预测阶数  $K = 2$ 、保护延迟  $\Delta = 2$ 。预测使用第  $n - 2$ 、 $n - 3$  帧，跳过最近的第  $n - 1$  帧。已知：

- 过去帧观测： $X(n - 2) = 0.8 + 0.1j$ ， $X(n - 3) = 0.5 - 0.2j$ （都是复数标量，实部虚部分别携带该时频点的幅度与相位信息）；
- 预测系数： $G(2) = 0.5 + 0.1j$ ， $G(3) = 0.3 - 0.05j$ ；
- 当前帧观测： $X(n) = 0.9 + 0.4j$ 。

用到的唯一工具是复数乘法： $(a + bj)(c + dj) = (ac - bd) + (ad + bc)j$ 。

教程模型里出现的是共轭  $G^*$ （共轭 = 虚部变号），所以  $G^*(2) = 0.5 - 0.1j$ ， $G^*(3) = 0.3 + 0.05j$ 。

第 1 步：用  $n - 2$  帧预测一份拖尾

$$G^*(2) X(n - 2) = (0.5 - 0.1j)(0.8 + 0.1j)$$

实部  $= ac - bd = 0.5 \times 0.8 - (-0.1) \times 0.1 = 0.40 + 0.01 = 0.41$ ；

虚部  $= ad + bc = 0.5 \times 0.1 + (-0.1) \times 0.8 = 0.05 - 0.08 = -0.03$ 。

所以  $G^*(2) X(n - 2) = 0.41 - 0.03j$ 。

第 2 步：用  $n - 3$  帧再预测一份拖尾

$$G^*(3) X(n - 3) = (0.3 + 0.05j)(0.5 - 0.2j)$$

实部  $= 0.3 \times 0.5 - 0.05 \times (-0.2) = 0.15 + 0.01 = 0.16$ ；

虚部  $= 0.3 \times (-0.2) + 0.05 \times 0.5 = -0.06 + 0.025 = -0.035$ 。

所以  $G^*(3) X(n - 3) = 0.16 - 0.035j$ 。

第 3 步：两份拖尾相加，得到当前帧里“可预测的陈旧成分”

$$\hat{r}(n) = 0.41 - 0.03j + 0.16 - 0.035j = 0.57 - 0.065j$$

这个  $\hat{r}(n)$  是当前帧晚期混响拖尾的估计。

第 4 步：从当前帧观测中减掉它

$$E(n) = X(n) - \hat{r}(n) = (0.9 + 0.4j) - (0.57 - 0.065j) = 0.33 + 0.465j$$

$E(n) = 0.33 + 0.465j$  就是去混响后的输出：实部  $0.9 - 0.57 = 0.33$ ，虚部  $0.4 - (-0.065) = 0.465$ 。

观测幅度为  $|X(n)| \approx 0.985$ ，相减后的幅度为  $|E(n)| \approx 0.570$ ；对应能量从约 0.97 降到约 0.325，相差约 4.7 dB。

这个数例只检查复数乘法、共轭和帧索引。系数  $G$  是人为给定的，因此能量下降不能作为去混响效果证据，也不能据此断言剩余量恰好等于直达声与早期反射。

真实 WPE 还要从多帧数据估计  $G$  与功率  $\lambda(n, f)$ ，并用独立的干净参考或识别指标评价失真。

#### 算例 7-2: 保护期加宽一帧（ $\Delta = 3$ 、 $K = 2$ ）

题设为单通道、单频点， $\Delta = 3$ 、 $K = 2$ 。已知：

- 过去帧为  $X(n-3) = 0.6 + 0.2j$ 、 $X(n-4) = 0.4 + 0.3j$ ;
- 预测系数为  $G(3) = 0.4 - 0.2j$ 、 $G(4) = 0.2 + 0.1j$ ;
- 当前帧为  $X(n) = 1.0 + 0.5j$ 。

要求去混响输出  $E(n)$ 。

求和下标为  $k = 3, 4$ ，因此使用第  $n-3$ 、 $n-4$  帧；第  $n-1$ 、 $n-2$  帧位于保护区，不参与预测。若当前帧  $n = 10$ ，预测使用第 7、6 帧，跳过第 9、8 帧。相较算例 7-1，保护期增加一帧。

第 1 步：计算第一个预测项。先取  $G^*(3) = 0.4 + 0.2j$ ，再计算

$$\begin{aligned} G^*(3)X(n-3) &= (0.4 + 0.2j)(0.6 + 0.2j) \\ &= (0.4 \times 0.6 - 0.2 \times 0.2) + (0.4 \times 0.2 + 0.2 \times 0.6)j \\ &= 0.20 + 0.20j. \end{aligned}$$

第 2 步：计算第二个预测项。取  $G^*(4) = 0.2 - 0.1j$ ，得到

$$\begin{aligned} G^*(4)X(n-4) &= (0.2 - 0.1j)(0.4 + 0.3j) \\ &= (0.2 \times 0.4 + 0.1 \times 0.3) + (0.2 \times 0.3 - 0.1 \times 0.4)j \\ &= 0.11 + 0.02j. \end{aligned}$$

第 3 步：相加预测项并从当前观测中减去。拖尾估计为

$$\hat{r} = 0.20 + 0.20j + 0.11 + 0.02j = 0.31 + 0.22j,$$

因此

$$E = (1.0 - 0.31) + (0.5 - 0.22)j = 0.69 + 0.28j.$$

输入与输出的幅度分别为  $|X| = \sqrt{1.25} \approx 1.118$ 、 $|E| = \sqrt{0.4761 + 0.0784} \approx 0.745$ ；能量从 1.25 降到约 0.55，相差约 3.5 dB。

本例的能量变化约为 3.5 dB，小于算例 7-1 的约 4.7 dB。两组系数为人为设定，差异不能作为一般性能结论。

固定  $K = 2$  时， $\Delta$  从 2 增至 3 并没有减少预测帧数量，仍使用两帧；它只是排除更多靠近当前帧的样本，并把长度相同的历史窗整体移远。 $\Delta$  的选择见 § 7.1.1。

交替估计  $G$  与  $\lambda$  (Nakatani et al., 2010)。假设早期成分  $E$  服从零均值复高斯分布，方差  $\lambda(n, f)$  随时间变化；这里的  $\lambda$  表示第  $n$  帧的功率谱。时变方差使不同能量的语音帧获得不同权重，减少高能量帧对估计的支配。下面在固定频点  $f$  上写出从最大似然到加权最小二乘的推导。Nakatani et al., IEEE TASLP 2010

中间行 1——写出似然：各帧独立，观测  $X(n)$  在给定  $G$ 、 $\lambda(n)$  下服从均值为预测值  $\sum_k G^*(k)X(n-k)$ 、方差为  $\lambda(n)$  的复高斯，总似然是各帧密度连乘：

$$p(X | G, \lambda) = \prod_n \frac{1}{\pi \lambda(n)} \exp \left( -\frac{|X(n) - \sum_k G^*(k)X(n-k)|^2}{\lambda(n)} \right)$$

。

中间行 2——取负对数：最大化似然等价于最小化负对数似然。去掉与  $G$  无关的常数后，权重  $1/\lambda(n)$  直接来自高斯密度指数项的分母：

$$-\log p = \sum_n \frac{|X(n) - \sum_k G^*(k)X(n-k)|^2}{\lambda(n)} + \sum_n \log \lambda(n) + \text{const}$$

。

固定  $\lambda$  时第二项是常数，最小化第一项就是加权最小二乘。用后文的历史向量  $\vec{x}(n)$  和系数向量  $\vec{g}$  可写成

$$\hat{\vec{g}} = \arg \min_{\vec{g}} \sum_n \frac{|X(n) - \vec{g}^H \vec{x}(n)|^2}{\lambda(n)}. \quad (7-2)$$

中间行 3——对  $G$  求导得正规方程：把历史帧排成向量  $\vec{x}(n) = [X(n - \Delta), \dots, X(n - \Delta - K + 1)]^\top$ ，记  $\vec{g} = [G(\Delta), \dots, G(\Delta + K - 1)]^\top$ 。求和式可写成  $E(n) = X(n) - \vec{g}^H \vec{x}(n)$ ，其中上标  $H$  表示共轭转置。

对  $\vec{g}^*$  使用 Wirtinger 导数并令其为零，得到  $K \times K$  加权正规方程：

$$\mathbf{R} = \sum_n \frac{\vec{x}(n) \vec{x}^H(n)}{\lambda(n)}, \quad \vec{r} = \sum_n \frac{\vec{x}(n) X^*(n)}{\lambda(n)}, \quad \mathbf{R} \vec{g} = \vec{r}. \quad (7-3)$$

$\mathbf{R}$  是加权自相关矩阵， $\vec{r}$  是加权互相关向量；解式(7-3)即可得到式(7-2)的预测系数  $\vec{g}$ 。

$R$  是  $K \times K$  共轭对称矩阵；当正则化后的  $R$  为正定矩阵时，可用 Cholesky 分解求解。

$K$  应根据可用帧数、拖尾覆盖范围、通道数和矩阵条件数在目标数据上选择，不能只凭固定区间设定。

算法交替固定  $\lambda$  求  $G$ 、固定  $G$  更新  $\lambda$ ；第一次迭代的  $\lambda$  可用观测能量初始化。在线版改用递推统计量，并需要单独处理样本不足和矩阵病态。

固定  $G$  后再更新逐帧功率；在未平滑的标量模型中有  $\lambda(n, f) = |E(n, f)|^2$ 。

固定  $G$  后，对  $\lambda(n) > 0$  求导：

$$\frac{\partial}{\partial \lambda(n)} \left( \frac{|E(n)|^2}{\lambda(n)} + \log \lambda(n) \right) = -\frac{|E(n)|^2}{\lambda^2(n)} + \frac{1}{\lambda(n)}.$$

令导数为零得到  $\hat{\lambda}(n) = |E(n)|^2$ 。实际实现通常会在频率或时间上平滑并设置正数下限，避免单个近零残差造成权重过大。

离线单通道 WPE 的完整一轮：下面把散落的公式按实现顺序连起来。每个频点独立执行，所有下限和正则化强度都要随信号尺度定义。

1. 由观测功率初始化  $\lambda^{(0)}(n, f)$ ，并设相对功率下限，避免静音帧产生过大的  $1/\lambda$ ；
2. 对有效帧构造  $\vec{x}(n) = [X(n - \Delta), \dots, X(n - \Delta - K + 1)]^\top$ 。最早有效帧为  $n = \Delta + K - 1$ ；
3. 用当前  $\lambda^{(i)}$  累加  $\mathbf{R}$  和  $\vec{r}$ 。为保持输入整体缩放时的相对正则化强度，可解

$$\left[ \mathbf{R} + \epsilon \frac{\text{tr}(\mathbf{R})}{K} \mathbf{I} \right] \vec{g}^{(i+1)} = \vec{r},$$

其中无量纲  $\epsilon$  是相对对角加载量；若  $\text{tr}(\mathbf{R}) = 0$ ，该频点应旁路或使用单独定义的正数下限；

4. 更新  $E^{(i+1)}(n) = X(n) - [\vec{g}^{(i+1)}]^H \vec{x}(n)$ ，再由平滑后的  $|E^{(i+1)}(n)|^2$  更新  $\lambda^{(i+1)}$ ；
5. 达到预设迭代次数，或目标函数相对变化低于预先声明的阈值时停止。报告结果时同时给出迭代次数/停止阈值、功率下限、平滑方式和  $\epsilon$ 。

边界检查包括： $K = 0$  时输出应退化为输入；全零频点不应求逆；把输入整体乘以常数时，采用上述相对加载的滤波器形状不应因绝对幅度而改变。

算例 7-3：加权最小二乘求解器的手算（单抽头  $K = 1$ 、3 帧）

取单频点、 $K = 1$ ，只估计一个抽头  $g = G(\Delta)$ 。3 帧观测为  $X = [1.0, 0.6, 0.2]$ ，历史样本为  $x = [0.8, 0.5, 0.4]$ ，权重  $w(n) = 1/\lambda(n) = [1, 4, 1]$ 。

为简化运算，本例使用实数。要求闭式解  $\hat{g}$ 。

标量正规方程为  $Rg = r$ ，其中  $R = \sum wx^2$ 、 $r = \sum wxX$ 。代入可得

$$R = 1 \times 0.64 + 4 \times 0.25 + 1 \times 0.16 = 1.80,$$

$$r = 1 \times 0.8 \times 1.0 + 4 \times 0.5 \times 0.6 + 1 \times 0.4 \times 0.2 = 2.08,$$

因此  $\hat{g} = 2.08/1.80 \approx 1.156$ 。该人为数例中的  $\hat{g}$  大于 1，不代表一般路径系数范围。

若所有权重都为 1，则  $R = 1.05$ 、 $r = 1.18$ 、 $\hat{g} \approx 1.124$ 。较大的第二帧权重使估计更接近该帧对应的比值。 $K > 1$  时，同样的加权关系写成矩阵正规方程。

多通道版 (MIMO-WPE, Yoshioka & Nakatani 2012)：预测第  $m$  个通道的当前帧时，使用所有  $M$  个通道的历史帧：

$$X_m(n, f) = E_m(n, f) + \sum_{m'=1}^M \sum_{k=\Delta}^{\Delta+K-1} G_{m,m'}^*(k, f) X_{m'}(n-k, f)$$

。


每个滞后  $k$  对应一个  $M \times M$  系数矩阵。把  $K$  个滞后的所有通道历史堆叠后，回归向量长度为  $MK$ ，联合系数可写成  $MK \times M$ 。因此每个频点的正规方程矩阵是  $MK \times MK$ ，而不是单通道的  $K \times K$ 。

例如  $M = 8, K = 10$  时矩阵为  $80 \times 80$ 。有效帧数若只接近 80，样本协方差很容易病态，还要为非平稳性、掩码和相关帧留出余量。


晚期混响会同时出现在多个麦克风上，但幅度和相位不同，多通道观测因此提供额外空间信息。相对收益取决于混响、阵列和数据长度，具体数字应查原论文的实验条件。[Yoshioka & Nakatani 2012](#)

图21 WPE 去混响效果（本书单通道仿真）


(a) 按 10 ms 传播时延对齐的干净参考



(b) 混响语音：能量沿时间拖尾、边界变模糊



(c) WPE 去混响后：拖尾被抑制



配置：16 kHz、1.4 s、种子 21001；RIR 直达延迟 10 ms、 $T_{60}=0.6$  s、DRR=6 dB；  
Hann 512 点、帧移 128 点；WPE  $\Delta=6$ 、 $K=10$ 、3 次迭代；三图共用对齐时间与谱幅参考。

图21 的横轴约为 0~1400 ms，纵轴约为 0~2.5 kHz，颜色表示相对能量的 dB 值。三幅语谱图在显示前都已补偿合成路径的 10 ms 直达传播时延，因此横轴表示同一对齐时间基准。

(a) 给出无混响参考；(b) 加入合成混响后，音节结束处出现横向拖尾；(c) 经本书单通道 WPE 示例处理后，拖尾减弱但仍有残留。

脚本按对齐后的无混响参考帧功率定义活动帧和安静帧，随后报告安静帧能量占比，以及活动帧相对该对齐参考、经复增益校准后的谱域归一化均方误差 (Normalized Mean Square Error, NMSE)。前者下降而后者增大时，说明去拖尾与语音损伤之间存在权衡。

功率  $\lambda$  使用居中的 5 帧移动平均，因此会读取左右各 2 帧，图中实现是离线而非因果；功率下限为该频点峰值的  $10^{-5}$ 。正规方程使用  $\epsilon \text{tr}(R)\mathbf{I}/K$  的相对对角加载， $\epsilon = 10^{-6}$ 。

合成混响的全卷积尾部被裁到 1.4 s 记录长度，图中指标只统计保留的对齐窗口，不覆盖被裁掉的尾部。这些量来自同一个固定随机种子的合成例，不代表公开数据集上的平均性能。

与其他模块的组合：WPE 可先减弱晚期混响，掩码 MVDR 再抑制噪声与定向干扰。Drude et al. (Interspeech 2018) 在其测试条件下报告了联合系统相对单模块的改善。[Interspeech 2018 论文](#)

WPE  $\rightarrow$  GSS  $\rightarrow$  MVDR/GEV 也可不使用神经分离网络，见第 8 章。Raj et al. (Interspeech 2023) 展示了 GSS 的 GPU 并行实现；速度比较只能按其论文的硬件、数据、代码版本和计时范围解读，不将加速倍数外推到其他实现。

开源实现 `nara_wpe` 的离线与在线接口需要分开选择。

在线版分为按块更新和逐帧递推两类。块在线 WPE 在最近一段历史上估计统计量；递推 WPE 用遗忘因子逐帧更新相关矩阵和滤波器。[在线 WPE](#)

短块提供的有效样本较少， $\lambda$  和相关矩阵的方差更大；块过长又会增加等待时间，并使旧房间统计占比过高。

在线实现还要处理初始化、矩阵正则化、静音冻结和路径突变，不能只把批处理迭代次数改成 1。DNN-WPE 可以用网络估计  $\lambda$ ，但是否优于传统估计取决于训练数据与测试房间是否匹配。

三帧因果递推小例。对单频点、单抽头实数特例，令历史回归量为  $x_t = X_{t-\Delta}$ ，遗忘因子  $\alpha = 0.5$ 、 $\lambda_t = 1$ ，并按

$$R_t = \alpha R_{t-1} + x_t^2 / \lambda_t, \quad r_t = \alpha r_{t-1} + x_t X_t / \lambda_t, \quad g_t = r_t / (R_t + \delta)$$

递推。本例为便于手算取  $\delta = 0$ ，且  $R_0 = r_0 = 0$ 。三帧  $(x_t, X_t)$  依次为  $(1, 0.8), (2, 1.6), (1, 1.0)$ ：

- 第 1 帧：  $R_1 = 1$ ,  $r_1 = 0.8$ ,  $g_1 = 0.8$ ;
- 第 2 帧：  $R_2 = 0.5 \times 1 + 4 = 4.5$ ,  $r_2 = 0.5 \times 0.8 + 3.2 = 3.6$ ,  $g_2 = 0.8$ ;
- 第 3 帧：  $R_3 = 0.5 \times 4.5 + 1 = 3.25$ ,  $r_3 = 0.5 \times 3.6 + 1 = 2.8$ ,  $g_3 \approx 0.8615$ 。

流式输出应先用上一帧已有的  $g_{t-1}$  预测当前拖尾，再用当前  $(x_t, X_t)$  更新出  $g_t$  供下一帧使用；初始化阶段可旁路。

这个例子只演示因果统计量顺序，不包含交替更新的功率估计。 $\lambda_t$  也必须只用当前与历史信息，不能沿用图 21 的居中平滑。

$\alpha \rightarrow 1$  记忆更长但跟踪更慢， $\alpha \rightarrow 0$  跟踪更快但估计方差增大，实际实现还需  $\delta > 0$  和静音冻结。[Drude et al., 2018, § 4.2~§ 4.3](#)、[Kinoshita et al., Interspeech 2017](#)

帧移为 8 ms 时，0.25 s 约含 31 帧，2 s 含 250 帧。这个换算可以用来估计统计样本量和块等待时间，但不能单独决定参数。起始值应在目标数据上同时检查拖尾衰减、语音失真、计算量和端到端延迟，再调整块长、遗忘因子、预测阶数和正则化强度。

开源实现 `nara_wpe` 是常用的 MIMO-WPE 参考实现。下面固定 PyPI 0.0.11 版；其他版本的轴序和在线接口应重新检查。

```
pip install nara-wpe==0.0.11
```

```
from nara_wpe.wpe import wpe
Z = wpe(Y, taps=10, delay=3, # taps=K (预测阶数), delay=Δ (保护延迟)
        iterations=3)      # 离线交替迭代次数；改成 1 仍是离线调用
```

其中  $Y$  是复数 STFT。后两轴为通道  $D$ 、帧  $T$ ，其余前轴可用于频点等维度；0.0.11 版 `help(wpe)` 标注为 `(..., D, T)`。

上述 `wpe()` 会在已给整段数据上交替估计，属于离线调用。

块在线或逐帧递推必须使用包内对应模块，并按安装版本的官方文档与示例确认轴序、状态和接口；安装命令本身不能证明在线因果性。[fgnt/nara\\_wpe](#) 官方仓库

DNN 与 WPE 的位置。神经网络可以预测干净复谱、时频掩码或 WPE 所需的功率  $\lambda$ 。常见位置取决于网络输出：

- 网络若对每个通道独立做波形或复谱映射，可能改变跨通道相位关系，通常放在多通道 WPE 和波束形成之后；
- 网络若只估计共享掩码、空间协方差或  $\lambda$ ，而多通道复谱仍由解析滤波器处理，可以放在 WPE 或波束形成内部；
- 联合训练的多通道模型可以同时完成去混响与波束形成。

模块位置应由输入输出是否保留空间相位、是否使用未来帧和训练目标决定，不能简单规定所有 DNN 都在链尾。

局限与处理办法：WPE 的模型目标是抑制可由延迟历史预测的晚期混响，而不是主动消除直达声与早期反射；保护延迟、功率估计或预测模型失配时，输出仍可能改变这些希望保留的成分。下列条件会使估计不稳定、早期成分失真或收益有限：

| 场景            | 现象                              | 对策                                                                     |
|---------------|---------------------------------|------------------------------------------------------------------------|
| 可用帧数与待估参数数量接近 | 二阶统计量方差增大，相关矩阵可能病态              | 降低预测阶数、增加正则化；流式实现另行调节遗忘因子                                              |
| 弱混响或高信噪比近讲    | 可预测拖尾较弱，处理收益可能小于失真              | 先测混响时间、直混比和旁路差异，再决定是否启用                                                |
| 强加性噪声         | 模型里没有独立噪声项， $G$ 与 $\lambda$ 被污染 | 采用显式含噪模型或联合卷积波束形成；不能把单独去噪器的收益算作 WPE 本身                                 |
| 大间距分布式阵列      | 统一 $\Delta$ 让参考与预测仍相关，输出失真      | 麦克风相关延迟：按到达时延给各通道定各自延迟 ( <a href="#">Lohmann et al., ICASSP 2023</a> ) |

启用 WPE 前应检查可用帧数、混响强度、加性噪声和通道时延。任一条件不满足时，应调整块长、模型或旁路策略。

卷积功率最小无失真响应（Weighted Power minimization Distortionless response, WPD）把多帧、多通道滤波写进同一个无失真最小功率问题，可同时处理去混响与波束形成。它不是简单串联两个现成模块，也不能用条件不同的 WPE、MPDR 数字相加预测收益。

把当前多通道帧及延迟历史堆成  $\vec{\tilde{x}}_t = [\vec{x}_t^\top, \vec{x}_{t-\Delta}^\top, \dots]^\top$ ，并把目标导向约束扩展为  $\vec{\tilde{v}} = [\vec{v}^\top, \vec{0}^\top, \dots]^\top$ 。在加权协方差  $\bar{\mathbf{R}} = \sum_t \vec{\tilde{x}}_t \vec{\tilde{x}}_t^H / \lambda_t$  下，解为

$$\vec{\tilde{w}}_{\text{WPD}} = \frac{\bar{\mathbf{R}}^{-1} \vec{\tilde{v}}}{\vec{\tilde{v}}^H \bar{\mathbf{R}}^{-1} \vec{\tilde{v}}}。$$

最小维度检查：2 麦、1 个历史块时， $\vec{\tilde{x}}$  和  $\vec{\tilde{w}}$  都有 4 个元素。若  $\bar{\mathbf{R}} = \text{diag}(2, 1, 4, 4)$ 、 $\vec{v} = [1, 1]^\top$ ，则扩展约束向量为  $\vec{\tilde{v}} = [1, 1, 0, 0]^\top$ 。

此时  $\bar{\mathbf{R}}^{-1} \vec{\tilde{v}} = [0.5, 1, 0, 0]^\top$ ，分母为 1.5，故

$$\vec{\tilde{w}} = [1/3, 2/3, 0, 0]^\top，$$

并可直接验证  $\vec{\tilde{w}}^H \vec{\tilde{v}} = 1$ 。

这里当前帧与历史块没有互相关，历史权重退化为零，WPD 退化到当前帧的加权 MPDR（weighted minimum power distortionless response，加权最小功率无失真响应）。 $\bar{\mathbf{R}}$  仍是用  $1/\lambda_t$  加权的观测协方差，不是噪声协方差。只有把优化中的矩阵明确取为目标缺席时的噪声协方差  $\mathbf{R}_{nn}$ ，同形闭式解才对应 MVDR。

延迟历史与当前晚期混响之间存在可利用相关性时，历史权重才会参与去混响。

该模型还假设希望保留的早期目标可由当前块的导向向量描述、 $\lambda_t > 0$  且加载后的协方差可逆；若  $\lambda_t$  或协方差使用未来帧，所得实现仍是离线的。

原始 WPD 工作见 Nakatani 与 Kinoshita 2019，后续因式分解工作说明了它与 WPE、波束形成的关系。Nakatani & Kinoshita, EUSIPCO 2019、Boeddeker et al., ICASSP 2020

可执行 WPE 基线。codes/array\_tutorial/dereverberation.py 提供只依赖 NumPy 的最小离线 WPE。offline\_wpe() 接收复数 STFT，单通道轴序为 (频点, 帧)，多通道轴序为 (频点, 通道, 帧)，输出保持相同形状；它实现保护延迟、按滞后堆叠多通道历史、共享功率权重、相对对角加载和复共轭预测。taps=0、迭代次数为零、记录短于首个有效回归帧或整个频点为零时直接旁路。输入必须是复谱，不能把幅度谱传入后再补相位。

联合示例用 .venv/bin/python -m codes.examples.ch06\_09\_baselines 运行，边界测试见 tests/test\_codes\_aec\_wpe\_sep\_track.py。测试固定检查  $K = 0$ 、短输入、全零频点、单抽头复共轭方向、多通道形状和整体幅度缩放等变性。实际音频管线还要自行固定 STFT 的窗、帧移、center /补零约定与 ISTFT 长度，并测试短语音、静音权重、病态矩阵、通道交换及块边界。求解失败时应增加加载、降低  $K$  或旁路该频点，不能输出 NaN。

该基线是整段离线估计，不宣称因果或实时。nara\_wpe 的离线、块在线和逐帧接口属于官方参考实现层级，应按所装版本记录提交、许可证、轴序、初始化、状态重置和延迟；DNN-WPE、WPD、GPU GSS 等大型实现只索引官方仓库或论文，不复制训练代码、模型权重和第三方数据。工程比较还必须固定通道数、上下文长度、硬件、计时范围以及是否使用未来帧。

### 7.1.1 $\Delta$ 与 $K$ 的参数换算

先把帧数换成物理时间。若帧移为  $H$  ms，最近的预测帧是  $t - \Delta$ ，其时延为  $\Delta H$ ； $K$  个预测帧从  $t - \Delta$  到  $t - (\Delta + K - 1)$ ，最远时延为  $(\Delta + K - 1)H$ 。这个索引关系比“ $\Delta + K$  帧”少一帧，因为起点已算入  $K$  个样本。

以图 21 的本书仿真为例：采样率 16 kHz，短时傅里叶变换 (Short-Time Fourier Transform, STFT) 窗长 512 点 (32 ms)，帧移 128 点 (8 ms)， $\Delta = 6$ 、 $K = 10$ 、交替迭代 3 次。因此使用  $t - 6$  到  $t - 15$  的十帧：最近预测帧延迟  $6 \times 8 = 48$  ms，最远为  $15 \times 8 = 120$  ms。这些数值只是图 21 的可复现配置，不是会议室、教室或其他房间的通用起点。

选参时，先对  $\Delta$  扫描并检查直达声和早期成分的失真；再在数据量足够的条件下增大  $K$ ，检查晚期拖尾、矩阵条件数、计算量和下游任务指标。增大  $K$  会增加参数量，在短语音或强噪声下反而可能使估计不稳定。 $T_{60}$  只描述整体衰减时间，不能单独决定  $\Delta$ 、 $K$  或迭代次数。

### 7.1.2 常见错误与练习

五项常见错误：

1. 取  $\Delta = 0$ ，使回归器包含当前帧，允许恒等或近恒等的退化预测，而不只是“多减一点直达声”；
2. 无条件增大  $K$ ，导致数据不足时过拟合；
3. 用 WPE 处理本应保留的早期反射；
4. 把 WPE 当作加性噪声抑制器，忽略模型中没有独立噪声项；
5. 在弱混响条件下仍强制启用 WPE。

对应的检查量分别是当前帧泄漏与早期语音损伤、有效样本数、直混比、噪声强度和混响时间。

### 练习 7-1 (自测九题)

1. 默写单通道 WPE 模型并解释  $\Delta$ 、 $K$ 。(要点:  $X = E + \sum G^* X$ ;  $\Delta$  保护延迟,  $K$  预测阶数)
2.  $\Delta = 2$ 、 $K = 2$ 、 $n = 10$  时用哪几帧、跳过哪几帧?(要点: 用第 8、7 帧; 跳过第 9 帧)
3. 复算算例 7-1 第 1 步的复数乘法。(要点:  $(0.5 - 0.1j)(0.8 + 0.1j) = 0.41 - 0.03j$ )
4. 独立完成算例 7-2 并算出 dB 数。(要点:  $E = 0.69 + 0.28j$ ; 能量约 1.25→0.55, 约 3.5 dB)
5. 写出最大似然交替的两步, 并写出固定  $\lambda$  时的正规方程  $R\vec{g} = \vec{r}$ 。(要点: 固定  $\lambda$  时用加权最小二乘解  $G$ ; 固定  $G$  时用  $\lambda = |E|^2$  更新功率; 迭代次数或停止条件要随实现与数据一并报告;  $R$ 、 $\vec{r}$  为  $\lambda$  加权的自相关和互相关)
6. 手算算例 7-3, 并解释权重如何改变估计。(要点:  $\hat{g} \approx 1.156$ ; 第 2 帧权重较大, 因此对结果影响更大)
7. 图 21 的帧移为 8 ms,  $\Delta = 6$ 、 $K = 10$ 。写出最近和最远预测帧及对应的物理时延。(要点: 用  $t - 6$  到  $t - 15$ ; 最近 48 ms, 最远 120 ms; 这是本书仿真配置, 不是由  $T_{60}$  唯一决定的通用参数)
8. 说出在线版相对离线版打折的两处来源与对策。(要点: 短块  $\lambda$  不准; 老  $G$  过时; 对策是 DNN 估计功率谱、遗忘因子)
9. 神经网络可以放在 WPE 前、后或内部吗?(要点: 独立改写各通道复谱的网络通常放在多通道处理之后; 只估计共享掩码、协方差或  $\lambda$  的网络可以放在解析算法内部; 还要检查是否使用未来帧)

### 7.1.3 研究方向

WPE 的改进主要围绕四个限制展开: 分布式阵列需要按通道到达时延调整预测延迟; 麦克风很多时需要参考通道或子集选择; 短块和强噪声下需要更稳健的功率估计; 系统级方法尝试把去混响与波束形成联合求解。神经网络可以为这些解析结构估计功率、掩码或先验, 但比较结果时要对齐数据集、通道数、因果性和延迟。本章不列无法按这些条件复核的近期性能数字。

参数设置应先在目标数据上把直达声和早期反射的损伤控制在声明的指标阈值内, 再根据晚期拖尾长度和可用帧数选择  $K$ 。保护延迟不能保证早期成分完全不变; 弱混响时可以旁路 WPE。多说话人分离见第 8 章。

## 第 8 章 · 语音分离

第 7 章讨论单个声源的混响拖尾，本章讨论多个说话人同时发声时的混合与分离。主要方法包括免训练盲源分离（Blind Source Separation, BSS）、导引源分离（Guided Source Separation, GSS）和深度分离；§ 8.2再说明这些方法在前端系统中的顺序。

### 8.1 多说话人语音分离：鸡尾酒会问题

去混响处理单个声源的时间拖尾，语音分离处理多个声源在同一观测中的叠加。本节依次介绍免训练 BSS、GSS 和深度分离。时频掩码既可用于分离，也可用于 § 5.4 的空间协方差估计。

卷积混合模型。第  $m$  个麦克风接收各说话人经过相应房间冲激响应后的叠加，再加上噪声：

$$x_m(t) = \sum_{n=1}^N \sum_{\tau} h_{mn}(\tau) s_n(t - \tau) + v_m(t). \quad (8-1)$$

$h_{mn}$  是第  $n$  个声源到第  $m$  个麦克风的房间冲激响应， $s_n$  是第  $n$  个源信号。源数  $N$  与麦克风数  $M$  有三种关系：

- $N = M$  是确定混合；
- $N < M$  是超定混合，可保留冗余通道、先降维或使用超定扩展；
- $N > M$  是欠定混合，不能只靠一个方阵解混器恢复全部源，还要利用时频稀疏性、源谱模型或满秩空间协方差等结构。

标准方阵辅助函数型独立向量分析（Auxiliary-function-based Independent Vector Analysis, AuxIVA）和独立低秩矩阵分析（Independent Low-Rank Matrix Analysis, ILRMA）通常针对  $N = M$ 。多通道非负矩阵分解（Multichannel Nonnegative Matrix Factorization, MNMF）能表示  $N > M$ ，但可靠性仍取决于源数、数据长度、初始化和模型匹配。

单麦  $M = 1$  时没有跨通道方向信息。此时多说话人分离只能依赖源信号先验或监督学习，不能使用后文的多通道方向聚类作为证据。

短时傅里叶变换（Short-Time Fourier Transform, STFT）常把卷积近似为每个频点上的瞬时混合：

$$X_m(f, k) \approx \sum_{n=1}^N A_{mn}(f) S_n(f, k) + V_m(f, k). \quad (8-2)$$

其中  $k$  是帧号， $A_{mn}(f)$  是  $h_{mn}$  在频率  $f$  处的近似频响。写成向量形式为  $\mathbf{X}(f, k) = \mathbf{A}(f)\mathbf{S}(f, k) + \mathbf{V}(f, k)$ ：  
 $\mathbf{X} \in \mathbb{C}^{M \times 1}$ 、 $\mathbf{A} \in \mathbb{C}^{M \times N}$ 、 $\mathbf{S} \in \mathbb{C}^{N \times 1}$ 、 $\mathbf{V} \in \mathbb{C}^{M \times 1}$ 。

这个窄带近似要求分析窗相对通道冲激响应的有效长度足够长，并且源与通道在窗内变化不快。 $T_{60}$  不能单独给出一个“超过多少就失效”的通用阈值；窗长、早晚期能量分布、帧移和允许误差都会影响近似质量。

远场平面波条件下， $\mathbf{A}$  的每一列对应一个导向矢量（steering vector），表示给定方向在各麦克风上的相位差：

$$\mathbf{a}(f, \theta) = [1, e^{+j2\pi f d \sin \theta / c}, e^{+j2\pi f 2d \sin \theta / c}, \dots, e^{+j2\pi f (M-1)d \sin \theta / c}]^\top$$

例如麦间距  $d = 4$  cm、声速  $c = 343$  m/s、目标方向  $\theta = 30^\circ$ 。按第 5 章约定，麦 1 在左端，正角声源位于  $+x$  一侧， $\tau_{21} = t_2 - t_1 = -d \sin \theta / c \approx -58.3 \mu\text{s}$ 。在  $f = 2$  kHz 时，相位差的绝对值为  $2\pi f |\tau_{21}| \approx 0.733$  rad，即约  $42^\circ$ ；以麦 1 为参考的 4 麦导向矢量约为  $[1, e^{+j42^\circ}, e^{+j84^\circ}, e^{+j126^\circ}]^\top$ 。

频率升到 4 kHz 时，相位差绝对值增至约  $84^\circ$ 。2 kHz 的波长约 17 cm，4 cm 间距小于半波长；8 kHz 的波长约 4.3 cm，此间距会产生空间混叠和栅瓣。

最小方差无失真响应（Minimum Variance Distortionless Response, MVDR）和广义特征值（Generalized Eigenvalue, GEV）波束形成直接使用空间协方差矩阵（Spatial Covariance Matrix, SCM）；MNMF 也以源相关的 SCM 描述传播。观测 SCM 可写成  $\mathbf{R}(f, k) = E[\mathbf{X}\mathbf{X}^H] \approx \mathbf{A}\mathbf{R}_s\mathbf{A}^H + \mathbf{R}_v$ 。

复角中心高斯混合模型（Complex Angular Central Gaussian Mixture Model, cACGMM）先把每个观测归一化到复单位球面，拟合只描述方向分布的形状矩阵。它不把未归一化的观测功率 SCM 直接当作概率密度。

GSS 和部分深度方法先由 cACGMM 或网络估计时频掩码，再用原始  $\mathbf{X}\mathbf{X}^H$  加权计算目标与干扰 SCM，做法见 § 5.4。

波束形成一次输出通常针对一个目标，但可以用不同导向或掩码构造多组权重，分别输出多个人的信号。因此“波束形成”和“语音分离”不是互斥方法：GSS 正是先估掩码，再为每个目标计算一组波束权重。下面按解混矩阵、空间聚类 and 监督学习三条路线比较。

| 路线          | 代表                                                                                                                                                   | 思想                                                        | 局限                                                            |
|-------------|------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------|---------------------------------------------------------------|
| 经典盲源分离（BSS） | 独立成分分析（Independent Component Analysis, ICA）/独立向量分析（Independent Vector Analysis, IVA）                                                                 | 假设各说话人统计独立，找一组解混矩阵让输出互相独立；IVA 用“同一声源跨频点相关”解决逐频点排列混乱（置换问题） | 需要源数不多于麦克风数、对混响敏感                                             |
| 空间混合模型（免训练） | cACGMM → GSS                                                                                                                                         | 见下文展开                                                     | 依赖较长的上下文，计算量随通道数、源数、时频点数和迭代次数增加；GPU 并行化的适用边界见本节“GSS 的源数与计算规模” |
| 深度学习分离      | 时频掩码估计、深度聚类（deep clustering：把每个时频点映射成嵌入向量再按说话人聚类）、置换不变训练（Permutation Invariant Training, PIT：对输出与参考说话人的所有对应关系分别计算损失，取最小者反向传播）、Conv-TasNet（全卷积时域分离网络） | 直接学习从混合信号到各声源的映射                                          | 依赖训练数据，跨场景泛化需验证                                               |

置换不变训练（Permutation Invariant Training, PIT）在所有输出—参考排列中选择总损失最小者。对  $N$  个输出，其定义为

$$\mathcal{L}_{\text{PIT}} = \min_{\pi \in \mathcal{S}_N} \sum_{n=1}^N \mathcal{L}(\hat{s}_n, s_{\pi(n)}), \tag{8-3}$$

其中  $\mathcal{S}_N$  是  $N$  个对象的排列集合。

PIT 的  $2 \times 2$  手算例。分离器输出为  $\hat{s}_1, \hat{s}_2$ ，参考为  $s_1, s_2$ 。假设某种失真损失的矩阵为

$$\mathbf{L} = \begin{bmatrix} L(\hat{s}_1, s_1) & L(\hat{s}_1, s_2) \\ L(\hat{s}_2, s_1) & L(\hat{s}_2, s_2) \end{bmatrix} = \begin{bmatrix} 0.4 & 3.1 \\ 2.8 & 0.6 \end{bmatrix}.$$

保持对应关系时总损失是  $0.4 + 0.6 = 1.0$ ；交换参考时是  $3.1 + 2.8 = 5.9$ ，所以本次更新使用前一种对应关系。

这个例子说明 PIT 解决的是“输出槽位没有固定说话人标签”，并不自动解决未知人数或跨长录音的身份保持。逐帧独立选择排列会让同一输出在相邻帧换人；整句级置换不变训练（utterance-level PIT, uPIT）在整句上只选一次排列，可减少这种帧间交换。

只有当总目标确实分解成式(8-3)这种“每个输出—参考对各贡献一个代价，再把所选代价相加”的形式时，才能把  $N \times N$  成对损失矩阵交给线性指派算法求最小总代价。若损失含有跨输出耦合项、集合级正则项或共同解码约束，就不能直接用匈牙利算法代替全排列目标。[PIT 正式论文](#)、[uPIT 正式论文](#)。

四类经典 BSS 方法。以下按模型假设、计算代价和失效条件比较 AuxIVA、ILRMA、MNMF 与 TRINICON。

AuxIVA（辅助函数型独立向量分析，Auxiliary-function IVA, Ono 2011）。它假设不同说话人统计独立，并联合建模同一说话人在各频点的分量。频域 ICA 在各频点独立求解，可能得到不同的输出排列；IVA 利用跨频点包络相关性缓解该置换问题。AuxIVA 使用辅助函数进行闭式更新，不需要设置梯度步长，目标函数在理论条件下单调下降。标准实现仍是整段迭代，在线版本需要递推改写；强混响、说话人包络高度相关和短语音都会削弱统计独立性或估计稳定性。它常作为免训练分离基线。

ILRMA（独立低秩矩阵分析，Independent Low-rank Matrix Analysis）。ILRMA 在独立性假设之外，再用非负矩阵分解（Nonnegative Matrix Factorization, NMF）表示每个源的低秩功率谱，并联合优化解混矩阵与谱模型。它增加了基数、迭代次数等超参数，计算量和初始化敏感性也高于 AuxIVA。复杂音乐、重叠笑声和强混响可能不满足低秩或独立性假设，需用目标数据验证。

MNMF（多通道 NMF，Multichannel NMF）。MNMF 同样使用低秩源谱模型，但以满秩空间协方差描述传播，不要求方阵解混矩阵可逆，因此可以表示欠定混合。谱基、激活和空间协方差需要联合做最大似然估计，参数较多、迭代较慢且对初值敏感。实践中可用 AuxIVA 或 ILRMA 结果初始化。其计算量通常更适合离线分析或伪标签生成。

TRINICON（三重 N 卷积混合盲分离，TRiple-N ICA for CONvolute mixtures）直接优化时域解混滤波器，用二阶去相关和高阶独立性处理卷积混合，因此不依赖逐频点瞬时混合近似。代价是滤波器与统计窗口较长、优化量大，声源或房间变化时还要重新适应。滤波器长度决定能表示多长的卷积逆，但不等于端到端延迟：因果 FIR 可逐样本输出，块实现的额外等待由分块、缓冲、FFT 和是否使用未来样本决定。

AuxIVA 适合确定混合的免训练基线；ILRMA 进一步利用源谱低秩结构；MNMF 用满秩空间协方差表示欠定混合；TRINICON 直接处理时域卷积混合。选择时需同时检查源数与麦克风数、混响强度、数据长度和实时预算。

BSS 的排列与尺度歧义。若  $\mathbf{W}(f)$  能把混合信号分开，交换  $\mathbf{W}$  的两行只会交换两个输出；把某一行乘非零复数，也不会破坏输出间的统计独立性。因此 BSS 只能在排列和复尺度因子意义下恢复声源。IVA、ILRMA 用跨频点结构缓解频点间排列错乱，但仍要固定输出尺度。方阵情形可令  $\hat{\mathbf{A}}(f) = \mathbf{W}^{-1}(f)$ ，选参考麦克风  $r$ ，再做

$$\tilde{Y}_n(f, k) = \hat{A}_{rn}(f) Y_n(f, k).$$

这一步称为回投影（projection back）：它把第  $n$  个分离输出恢复到参考通道上的幅度和相位尺度。回投影不能修复分离错误，也不能保证不同时间块中的说话人编号一致；连续录音仍要做跨块排列对齐。

BSS 方法的规模例子。以下计算用于说明参数数量和迭代规模；性能数字必须以各论文的测试集和评测脚本为准。

AuxIVA 的规模例子：2 源 2 麦、8 kHz、3 s 语音，STFT 取 256 点窗和 64 点帧移。名义帧率为  $8000/64 = 125$  帧/s，3 s 约为 375 帧；不补零、从首样本开始取完整窗时，精确帧数是  $\lfloor (24000 - 256)/64 \rfloor + 1 = 372$ 。非负频点数为 129，每个频点维护一个  $2 \times 2$  解混矩阵，共 516 个复数参数。

辅助函数迭代不需要学习率。帧数还取决于是否居中、边界补零和丢弃尾部不完整窗。算法见 [AuxIVA 原始论文](#)（Ono, WASPAA 2011, pp. 189 – 192；公开实现见 [piva](#)）。

ILRMA 在同一 2 源 2 麦例子中，还要为每个源维护 NMF 基矩阵和激活矩阵。若每源取 2 个基，则矩阵尺寸分别为  $129 \times 2$  和  $2 \times 375$ ，并与解混矩阵交替更新。基数、迭代次数和初值都会影响计算量与结果。语音与音乐是否满足同样的低秩假设，需要分别验证。见 [ILRMA 原始论文](#)（Kitamura et al., IEEE/ACM TASLP 24(9), 2016, pp. 1626 – 1641）。

MNMF 可以表示 3 个说话人、2 个麦克风的欠定混合。每个频点、每个源对应一个  $2 \times 2$  Hermitian 空间协方差；129 个频点和 3 个源共需 387 个协方差矩阵，还要联合估计谱基和激活。计算量和局部最优问题使初始化十分重要，AuxIVA 或 ILRMA 结果可作为初值。见 [MNMF 原始论文](#)（Sawada et al., IEEE TASL 21(5), 2013, pp. 971 – 982）。

TRINICON 的长度换算可以这样看：8 kHz 下，0.5 s 对应 4000 个采样，但这不代表解混滤波器必须取 4000 点，也不表示算法延迟就是 0.5 s。实际长度是在可表示的卷积范围、估计方差、计算量和块实现之间折中。例如 1024 点与 2048 点分别覆盖 128 ms 和 256 ms 的滤波器记忆；系统仍要单独报告块大小、帧移、前视和输入输出缓冲，才能得到算法延迟。见 [TRINICON 原始论文](#)（Buchner et al., 2005）。

GSS（导引源分离，guided source separation）在 CHiME-5/6 的真实晚宴多通道任务中得到广泛使用（Boeddeker et al., CHiME-5 2018；CHiME-8 任务设置已经变化，引用时应按届规则）：1. cACGMM 空间聚类：记 WPE 输出、尚未做方向归一化的多通道 STFT 为  $\mathbf{Y}(f, k)$ 。先剔除  $\|\mathbf{Y}(f, k)\|_2 \leq \varepsilon_E$  的低能量点，再对保留点严格归一化为  $\mathbf{z} = \mathbf{Y}/\|\mathbf{Y}\|_2$ ，主要保留通道间的复数比例。第  $n$  个分量的密度满足

$$p(\mathbf{z} | \mathbf{B}_n) \propto \frac{1}{\det(\mathbf{B}_n)} (\mathbf{z}^H \mathbf{B}_n^{-1} \mathbf{z})^{-M}, \quad \|\mathbf{z}\|_2 = 1. \quad (8-4)$$

其中  $\mathbf{B}_n$  是正定的形状矩阵。cAC 密度对  $\mathbf{B}_n$  的正比例缩放不变，所以每次更新后必须固定尺度，例如令  $\text{tr}(\mathbf{B}_n) = M$ 。式(8-4)建模的是归一化方向  $\mathbf{z}$  的密度，不是  $\mathbf{Y}$  的功率 SCM。混合模型的后验概率  $\gamma_n(f, k)$  用作软时频掩码。“免训练”只表示聚类参数在当前录音上用期望最大化（Expectation-Maximization, EM）估计，不需要预先训练分离网络；说话人活动标注仍可能来自监督模型。2. 导引（Guided）：各频点独立聚类会产生簇标签置换。GSS 使用说话人活动时间标注（diarization 输出）限制每个说话人

可出现的帧，从而统一不同频点的簇标签；3. 级联：WPE 去混响 → GSS 得到掩码 → 掩码估计目标/噪声协方差 → MVDR/GEV 波束形成。MVDR 是最小方差无失真响应，GEV 是广义特征值波束形成，见 § 5.4。GSS 论文在 CHiME-5 的特定阵列和打分集上报告了识别结果；引用数字时必须同时给出原文表号、阵列配置、打分集和基线。[GSS 原始论文](#)

紧凑实现顺序。下面的伪代码强调依赖关系，不替代具体实现中的复数矩阵更新式。

1. 从 WPE 输出  $\mathbf{Y}$  中剔除  $\|\mathbf{Y}\|_2 \leq \varepsilon_E$  的点；对其余点计算严格单位向量  $\mathbf{z} = \mathbf{Y} / \|\mathbf{Y}\|_2$ 。活动标注只初始化或约束混合权重（以及允许的分量掩码）； $\mathbf{B}_n$  另用单位阵或空间统计量初始化，不能把活动标注当作形状矩阵。
2. E 步按式(8-4)计算后验  $\gamma_n(f, k)$ ，并把活动标注为“不发言”的分量权重重置零，再对允许的分量归一化。
3. M 步按 cACG 的固定点更新形状矩阵：每个  $\mathbf{z}\mathbf{z}^H$  外积除以当前二次型  $\mathbf{z}^H \mathbf{B}_n^{-1} \mathbf{z}$ ，再用  $\gamma_n$  加权求和；每次更新后令  $\text{tr}(\mathbf{B}_n) = M$ （或采用等价的固定行列式约定），再加入小的正则项。有效权重接近零或条件数过大时，重置该分量，不能继续求逆。
4. 重复 E/M 步，直到对数似然相对变化小于预设阈值，或达到最大迭代次数；报告实际迭代数、停止条件和重置次数。
5. 将后验作为掩码，但用同一 WPE 阶段、未做方向归一化的  $\mathbf{Y}\mathbf{Y}^H$  按式(8-5)估计目标/干扰 SCM，再计算每个目标的 MVDR 或 GEV 权重。这里不能把单位向量  $\mathbf{z}$  的外积误当成带功率信息的 SCM。

活动标注只限制允许的簇，不会自动修复错误分割；短活动段、空分量或近奇异形状矩阵仍需要正则化和失败检测。

GSS 的源数与计算规模：输入通常是一段包含重叠语音的会议录音。cACGMM 的分量数通常由日志或系统配置预先给定；它不会仅凭式(8-4)可靠推断未知说话人数。

$M \geq 2$  才有跨通道方向信息。当  $N \leq M$  时，掩码波束形成通常还有空间自由度；当  $N > M$  时，仍可为每个已知目标估计掩码和 SCM，但分离依赖时频占优、活动标注与数据量，不能获得方阵解混的可逆性保证。

WPE 先减弱晚期混响；cACGMM 在目标段附近的上下文上做 EM 聚类，为每个时频点输出说话人后验掩码；目标和非目标掩码分别用于估计 SCM，再计算 MVDR 或 GEV 权重。

上下文长度和 EM 迭代次数会共同影响估计方差、延迟与计算量。GPU 并行化的收益必须绑定硬件、数据、代码版本和计时范围，不能作为跨实现的通用加速倍数。

以 16 kHz 采样、512 点窗、128 点帧移为例，每秒有 125 帧，30 s 上下文含 3750 帧和 257 个非负频点，约 96 万个时频点。这个换算只给出待处理样本数，不能保证 EM 在固定次数内收敛。实现应监测对数似然相对变化，并设置最大迭代次数；空分量、近奇异  $\mathbf{B}_n$  和低能量时频点还需要正则化或重置。

掩码换成目标协方差时，用

$$\mathbf{R}_{\text{tar}}(f) = \frac{\sum_k \gamma(f, k) \mathbf{Y}(f, k) \mathbf{Y}^H(f, k)}{\sum_k \gamma(f, k) + \varepsilon}. \quad (8-5)$$

噪声协方差可用相应的非目标掩码估计。软权重的有效样本数不是“ $\gamma > 0.8$  的帧数”，而可用 Kish 公式近似：

$$N_{\text{eff}}(f) = \frac{(\sum_k \gamma(f, k))^2}{\sum_k \gamma^2(f, k)}.$$

例如 900 帧权重全为 1 时  $N_{\text{eff}} = 900$ ；若权重集中在少数帧，有效样本数会明显更小。

估计  $M \times M$  协方差不仅需要样本数大于矩阵维度，还要覆盖足够多的独立空间状态；高度相关的连续帧不能当作同等数量的独立快照。工程上应检查  $N_{\text{eff}}$ 、矩阵条件数，并在必要时做对角加载。

说话人活动标注用于限制各簇可出现的时间区间，从而减少跨频点置换。见 [cACGMM 原始工作](#) (Ito et al., EUSIPCO 2016, pp. 1153–1157) 与 [GSS 原始论文](#)。

掩码到波束权重的小例子。以下实数向量只是 WPE 输出复数 STFT 的简化手算。两个时频快照取  $\mathbf{Y}_1 = [1, 1]^T$ 、 $\mathbf{Y}_2 = [1, -1]^T$ ，目标掩码为  $\gamma = [0.9, 0.1]$ 。因为权重和为 1，目标协方差为

$$\mathbf{R}_{\text{tar}} = 0.9\mathbf{Y}_1\mathbf{Y}_1^H + 0.1\mathbf{Y}_2\mathbf{Y}_2^H = \begin{bmatrix} 1 & 0.8 \\ 0.8 & 1 \end{bmatrix}.$$

若这个二分类例子中用  $1 - \gamma = [0.1, 0.9]$  估计干扰协方差，则  $\mathbf{R}_{\text{int}} = \begin{bmatrix} 1 & -0.8 \\ -0.8 & 1 \end{bmatrix}$ 。正的非对角项表示目标快照中两通道同相成分占优，负的非对角项表示干扰快照中反相成分占优。

随后可从  $\mathbf{R}_{\text{tar}}$  估计目标相对传递函数，并与  $\mathbf{R}_{\text{int}}$  一起计算 MVDR。GEV 则直接求矩阵对  $(\mathbf{R}_{\text{tar}}, \mathbf{R}_{\text{int}})$  的主广义特征向量，并需另做尺度归一化。

真实的“目标 + 多个说话人 + 环境噪声”并非二分类， $1 - \gamma$  会把所有非目标成分合在一起，不能解释成纯噪声掩码。实际实现还要检查有效样本数、条件数和对角加载。[掩码波束形成实例](#)。

定位结果可以给分离提供方向先验；分离网络输出的掩码又能用于估计 MVDR 的目标与干扰协方差。

常用的尺度不变信号失真比（scale-invariant signal-to-distortion ratio, SI-SDR）先把估计信号  $\hat{s}$  投影到参考  $s$  上： $s_{\text{tar}} = \langle \hat{s}, s \rangle s / \|s\|^2$ ，再计算  $10 \log_{10}(\|s_{\text{tar}}\|^2 / \|\hat{s} - s_{\text{tar}}\|^2)$ 。SI-SDR 提升量（SI-SDRi）是输出 SI-SDR 减去混合输入的 SI-SDR，两项必须使用同一预处理和实现。

分离指标的最小报告模板：

- 写明目标信号定义（无混响干声、带混响参考或参考麦克风图像）、参考通道、采样率与截断长度；
- 说明是否去均值，以及固定传播时延、算法时延和整体增益怎样对齐；
- 给出活动区间、静音段处理、输出一参考排列规则和输入混合基线；
- 固定指标实现及版本，并对多次随机实验报告种子、次数和离散程度。

若其中任一项不同，SI-SDRi、SI-SNRi 或 WER 数字不能直接横向排名。

数据集口径表：去混响与分离的论文使用不同数据、通道和指标。下表只说明各数据集的用途，不给出脱离原文表格的性能范围。

| 数据集              | 考什么                      | 房间/混响口径                                                                            | 通道/采样口径                                                                  | 怎么用                                                                                                   |
|------------------|--------------------------|------------------------------------------------------------------------------------|--------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------|
| REVERB 挑战赛       | 去混响（含识别端 WER）            | 仿真三档混响时间约 0.25 / 0.5 / 0.7 s；另有真实房间录音（MC-WSJ-AV 基）                                 | 8 通道 / 2 通道 / 单通道三种设置；基线语音来自 WSJCAM0                                     | 比较 WPE 时必须注明通道数、识别器、测试子集和 WER 的绝对/相对口径                                                                |
| CHiME-5          | 真实晚宴多说话人（分离 + 识别端 WER）   | 真实家庭：厨房、餐厅、客厅多房间自然混响加生活噪声                                                          | 每场 6 台 Kinect、每台 4 个同步麦克风；每位参与者另戴双耳麦                                     | 6 台设备不能缩写成“6 麦阵列”；双耳录音用于辅助转写与时间对齐，不是干净评分参考。见 <a href="#">CHiME-5 官方数据说明</a>                           |
| CHiME-6          | 重新对齐的 CHiME-5 录音；多阵列远场识别 | 与 CHiME-5 相同的真实家庭录音，但版本与划分必须写清                                                     | 共 32 个物理通道：6 台四麦阵列的 24 通道，加 4 套双耳设备的 8 通道                                | Track 2 评测中双耳通道只允许同步，不能用于分割、增强或识别；GSS 还要注明实际选用阵列、日志输入、打分集和表号。见 <a href="#">CHiME-6 Track 2 官方数据规则</a> |
| WHAMR            | 噪声 + 混响 + 重叠三合一          | 合成房间冲激响应； $T_{60}$ 低、中、高三档分别从 0.1~0.3 s、0.2~0.6 s、0.4~1.0 s 均匀采样，这三档表示混响程度，不表示房间大小 | 8 kHz / 16 kHz；min 版（截短对齐）/ max 版（全长）两版；底子是 WSJ0-2mix 加 WHAM 噪声          | 报告时注明 min/max、采样率、源数、目标是无混响还是带混响语音，以及 SI-SDRi 实现。见 <a href="#">WHAMR 正式论文 § 2 与表 1</a>                |
| WSJ0-2mix / 3mix | 干净重叠两/三人                 | 无噪声、无混响（近场干声直接叠加）                                                                  | 8 kHz / 16 kHz；min 版（按最短截断）/ max 版（全长补零）；30 小时训练 / 10 小时验证 / 5 小时测试      | 引用时注明采样率、min/max、源数、静态/动态混合和指标实现                                                                      |
| LibriMix         | 干净或含噪声重叠（WSJ0 的开源替代）     | clean 版无污染；noisy 版叠加 WHAM 环境噪声                                                     | 8 kHz / 16 kHz；train-100/train-360；min/max；另行发布的 SparseLibriMix 是稀疏重叠测试集 | 用于跨语料验证时，同时注明训练集、测试集、噪声版本和是否使用 SparseLibriMix。见 <a href="#">LibriMix 论文与官方生成仓库</a>                    |

| 数据集      | 考什么           | 房间/混响口径                                                                                     | 通道/采样口径                         | 怎么用                                                                |
|----------|---------------|---------------------------------------------------------------------------------------------|---------------------------------|--------------------------------------------------------------------|
| LibriCSS | 连续会议式重叠与长录音识别 | 扬声器在真实会议室回放 LibriSpeech 语音；共 10 个约 1 h 会话，每个分成 6 个约 10 min 小会话，条件为 0S、0L、10%、20%、30%、40% 重叠 | 7 通道圆阵录音；0S 与 0L 都无重叠，但句间静音长度不同 | 检查具体重叠条件、分块、跨块排列、输出流数和识别评测的说话人分配规则。见 <a href="#">LibriCSS 正式论文</a> |

REVERB 主要用于去混响与识别，CHiME-5/6 用于真实重叠语音的分离与识别，WHAMR 同时包含噪声、混响和重叠，WSJ0-2mix/3mix 是干净混合基准，LibriMix 还可检查跨数据集泛化，LibriCSS 则把问题扩展到连续会议。CHiME-6 重新对齐了 CHiME-5 的部分录音，引用结果时不能把两个版本混为同一数据版本。[CHiME-6 官方说明](#)。不同数据集的数字不能直接比较。

连续语音分离（Continuous Speech Separation，CSS）不能把整句分离器机械地逐块调用。长录音中的活动人数会变化，同一输出槽位还可能在相邻块交换说话人。

实现需明确四件事：

- 1. 每块使用多少左、右上下文；
- 2. 重叠块怎样加权拼接；
- 3. 跨块排列依据声纹、波形相关性还是联合优化；
- 4. 输出流数固定还是随活动人数变化。

连续识别的指标也要写清分配规则。连接最小排列词错误率（Concatenated Minimum-Permutation WER，cpWER）、最优参考组合词错误率（Optimal Reference Combination WER，ORC-WER）和说话人归属词错误率（Speaker-Attributed WER，sa-WER）处理说话人对应的方式不同，不能只写“WER”。

CSS 解决长录音的分块与输出一致性，不保证身份永久不交换；需要稳定身份时还要结合分割或说话人跟踪。

VarArray 的正式论文发表于 ICASSP 2022（pp. 6027 – 6031，DOI [10.1109/ICASSP43922.2022.9746876](#)），通过通道置换/数量不变的聚合结构适配不同麦克风数量和论文评测中的多种同步阵列几何。“阵列几何无关”不表示对任意未见孔径、异步时钟、通道失配或设备频响都有保证；这些条件仍需在目标设备上验证。

时频稀疏性与掩码：在某些语音混合中，同一时频点往往由一个声源占优，文献将这种近似称为 W-不重叠正交性（W-disjoint orthogonality，WDO）。掩码方法可以据此估计每个时频点属于各声源的权重。说话人在同一时频区域强烈重叠时，WDO 近似变差。波束形成的区别不是“对整个频带统一加权”：宽带 STFT 波束形成通常在每个频点使用一组复权重，利用通道间的幅度和相位关系做空间选择。

深度分离的几类结构。下表只比较建模方式。原论文的指标、数据生成和评测代码并不完全相同，不在表中按单个 dB 数排名。

| 结构     | 代表                                  | 主要结构                                                                              | 结果复现要求                                                           | 优点与限制                                                                                                  |
|--------|-------------------------------------|-----------------------------------------------------------------------------------|------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------|
| 时域卷积   | Conv-TasNet (Luo & Mesgarani, 2019) | 可学习的短窗编码器代替 STFT，时序卷积网络（Temporal Convolutional Network，TCN）的空洞卷积建模长上下文，再对编码系数施加掩码 | 核对数据版本、采样率、因果设置和 SI-SNRi 实现                                      | 端到端延迟取决于编码窗、感受野和缓冲。见 <a href="#">Conv-TasNet 正式论文</a>                                                  |
| 双路径循环  | DPRNN (Luo et al., 2020)            | 长序列分块，块内 RNN 建模局部，块间 RNN 建模较长时间关系                                                 | 核对模型规模、块长、静态/动态混合和 SI-SNRi 实现                                    | RNN 顺序计算会限制并行度，块长影响内存与上下文。见 <a href="#">DPRNN 正式论文</a>                                                 |
| 双路径注意力 | SepFormer (Subakan et al., 2021)    | 在双路径结构中用 Transformer 替换 RNN                                                       | 核对源数、数据生成、模型版本和 SI-SNRi 实现                                       | 注意力内存随序列长度增长，长句通常需分块。见 <a href="#">SepFormer 正式论文</a>                                                  |
| 状态空间   | S4M (Chen et al., 2023)             | 用多尺度编码和结构化状态空间块替换分离骨干中的循环或注意力时序建模                                                 | 原文使用固定两源的 WSJ0-2Mix、LibriMix 与 LRS2-Mix；核对 8/16 kHz 数据版本、源数和官方配置 | 状态递推提供长程建模的另一种实现，但原文未验证严格因果的前瞻量与端到端延迟。见 <a href="#">Interspeech 2023 正式论文</a> 与 <a href="#">官方复现仓库</a> |

| 结构   | 代表                             | 主要结构                                                                | 结果复现要求                                     | 优点与限制                                                                    |
|------|--------------------------------|---------------------------------------------------------------------|--------------------------------------------|--------------------------------------------------------------------------|
| 时频网络 | TF-GridNet (Wang et al., 2023) | 在时频域分别建模时间、频率与跨帧关系，并结合子带长短期记忆网络 (Long Short-Term Memory, LSTM) 和注意力 | 会议版是单通道分离，原文主表使用 SI-SDRi；多通道混响扩展是另一模型与实验设置 | 整句注意力需要改造后才能流式运行。见 <a href="#">单通道会议正式论文</a> 与 <a href="#">多通道混响期刊扩展</a> |

比较分离数字时要对齐采样率、`min / max` 混合方式、静态或动态混合、源数、评测脚本和指标名称。分离文献中的 SI-SNR 常采用与 SI-SDR 相同的正交投影公式，二者在相同去均值与数值实现下可以相等；也有代码把均值处理、截断长度或稳定项写得不同。不能笼统地说两者固定相差若干 dB。引用 SI-SNRi 或 SI-SDRi 时，应给出实现或至少说明是否去均值，并始终用同一指标计算输入基线和输出结果。

**深度分离的结构选择。**卷积、循环网络、注意力和状态空间模型都可以作为分离骨干。S4M 改变的是编码器—分离器—解码器中的时序建模骨干：多尺度表示送入结构化状态空间块，而不是仅更换损失函数。

论文实验使用已知的两个输出源和监督干净参考，官方仓库给出训练入口。未知源数、无监督会议录音或任意麦克风阵列不属于这项结果的直接覆盖范围。论文把该结构称为流式分离的潜在方案，但没有报告严格因果实现的前瞻样本数、首帧延迟或端到端延迟。

部署前仍需检查双向上下文与缓冲。选择时不要只看单个榜单分数，还要检查模型是否使用整句上下文、块边界如何处理、状态能否在流式推理中延续，以及计算量和内存怎样随语句长度变化。生成式方法还要检查采样步数和语音幻觉。

近期模型若没有在相同数据、采样率、混合方式和评测脚本下比较，本章不按论文年份或模型名称给出性能排序。

目标说话人提取 (target speaker extraction, TSE) 不要求输出所有声源，而是用注册语音、视觉或方向等与目标说话人绑定的条件提取一条音轨。声纹网络可把注册语音变成定长嵌入，再将其广播到混合语音的各帧；嵌入可在编码器入口拼接，也可用逐层缩放与偏置调制 (FILM) 或交叉注意力注入。

嵌入维度、注册时长和余弦阈值由具体模型和训练数据决定，不存在跨模型通用的“同人区间”。部署时要验证注册信道失配、非目标泄漏、目标误抑制和首帧延迟。

§ 6.1.6 的 pAEC 也使用声纹条件，但训练目标还包含回声消除。见 [SpeakerBeam/TSE 系列](#)；声纹嵌入的端侧存储、加密和删除要求见 § 6.1.14。

文本查询通用声音分离是另一项任务：查询词描述“警报声”“狗叫”等声音类别，不保证对应某个可注册的说话人。对比语言—音频预训练 (Contrastive Language-Audio Pretraining, CLAP) 可提供文本与音频嵌入，但 CLAP 本身不是分离器；实际系统还需要用查询嵌入控制掩码或波形生成模块。

见 [CLAP](#) 与使用语言查询的 AudioSep。AudioSep 已正式发表于 *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 33, pp. 458 – 471, DOI [10.1109/TASLP.2024.3520017](#)；[官方仓库](#)提供模型与推理入口。

TSE 的身份泄漏、注册信道和声纹保护测试，不能由文本查询分离的类别级结果替代。

**可执行分离基线与代码边界。**[codes/array\\_tutorial/separation.py](#) 提供四个只依赖 NumPy 的小模块：`si_sdr()` 接收等长一维估计与参考；`pit_permutation()` 接收 (源, 样本) 数组并枚举排列，返回“第几个输出对应第几个参考”的元组和平均 SI-SDR；`masked_spatial_covariance()` 接收 (频点, 通道, 帧) 复谱与 (频点, 帧) 非负掩码；`mask_mvdr_2x2()` 用目标 SCM 的主特征向量估计相对传递函数，再以干扰 SCM 求两麦 MVDR，返回 (频点, 帧) 输出和 (频点, 2) 权重。

联合示例用 `.venv/bin/python -m codes.examples.ch06_09_baselines` 运行，测试见 [tests/test\\_codes\\_aec\\_wpe\\_sep\\_track.py](#)。测试覆盖输出交换、静音参考和静音估计拒绝、SCM 厄米性、MVDR 无失真约束，以及目标或干扰掩码为空时回退参考麦。实际评测还必须固定去均值、时延/增益对齐、静音段、截断长度和输入基线；秩亏 SCM、单通道输入、 $N > M$ 、跨块换人及 STFT 重构均需单独测试。教学版 MVDR 在目标或干扰统计不可用时退回参考麦克风，不应把这一回退的输出解释成成功分离。

AuxIVA/ILRMA 的完整数值实现应使用 `piva` 等上游项目；MNMF、TRINICON、ChiME GSS/GPU-GSS、Asteroid/SpeechBrain/ESPnet 中的 Conv-TasNet、DPRNN、SepFormer，以及 S4M、SpeakerBeam 和 AudioSep 均只索引论文官方仓库，不在本书复制。使用时记录提交或发布版、许可证、训练/测试数据版本、预训练权重许可、采样率、源数、因果/前瞻设置、块状态、指标脚本、硬件和峰值内存。cACGMM 的正文伪代码用于解释依赖关系，不是生产 GSS；若没有空分量重置、对数域后验和收敛检查，不能把它列为可复现基线。

练习 8-1（自测三题）

1. 说明 WDO 假设及其失效条件。

答案要点：同一时频点通常只有一个人占优；重叠越重，近似越差。

2. GSS 三步顺序是什么？

答案要点：WPE 去混响 → cACGMM 聚类得到掩码 → 用掩码估计 SCM，再计算 MVDR/GEV 权重。

3. 掩码换协方差要写哪两个矩阵？

答案要点：目标协方差  $\mathbf{R}_{\text{tar}}$  与干扰协方差  $\mathbf{R}_{\text{int}}$ ；二分类例子可分别用  $\gamma$  与  $1 - \gamma$  加权，多说话人加环境噪声时应按模型分别定义非目标掩码，不能把  $1 - \gamma$  一律解释成纯噪声。

8.2 处理模块的顺序

回声、混响和多说话人混合对应不同的信号模型。以下顺序由参考可用性、空间相位保持和统计量依赖关系决定，接口定义见 § 10.1。

一种较完整的音频主链见第 10 章 § 10.1：采集 → AEC → WPE → 解析波束形成 → 单通道增强。定位/追踪、说话人分割/GSS/SCM 是为解析波束提供条件的支路；神经或 CSS 分离则是从多通道特征到单通道/多流输出的替代音频路径，不与 GSS 掩码或解析波束合并成一个黑箱。项目只启用满足输入条件且能改善目标指标的模块。

- 1. 启用声学回声消除（Acoustic Echo Cancellation, AEC）时先处理回声：回声参考与麦克风回声之间的线性关系可能被后续自适应波束、非线性增益或单通道增强改变，见第 10 章 § 10.1；
- 2. 多通道 WPE 通常在波束之前：晚期混响会污染波束形成所需的协方差估计。WPE 是线性处理，但各通道的预测滤波器不同，不能笼统保证所有跨通道相位关系完全不变。应验证处理后的目标相对传递函数和协方差是否仍适用于后续波束；
- 3. 定位/追踪给波束指方向：MVDR/GEV 要目标方向或掩码才能成形，先有方向、再有波束（见第 5 章与第 9 章）；
- 4. diarization 在 GSS 聚类之前、掩码在 MVDR 之前：diarization 提供“谁在何时说话”的标注，用于约束 cACGMM 的跨频点置换；掩码随后用于估计目标和噪声协方差，再计算波束权重（见 § 5.4 和 § 8.1）；
- 5. DNN 的位置由输出决定：逐通道改写复谱或波形的网络可能破坏跨通道相位，通常放在波束形成后的单通道链路；只输出共享掩码、协方差或 WPE 功率先验的网络可以放在多通道算法内部；联合多通道网络则可能同时完成分离和波束形成。还要单独检查网络是否使用未来帧。

对于“逐通道线性前端—波束形成—单通道增强”这类实现，逐通道处理通常位于前端，单通道增强位于波束形成之后。若神经网络只估计解析算法所需的统计量，或本身联合建模多通道相位，则不受这个顺序限制。

本章模块与图 23 的对应关系（图的信号取点与启用条件见第 10 章 § 10.1）：

| 本章模块                                                                                                   | 图 23 中的位置                                              | 作用                                                                |
|--------------------------------------------------------------------------------------------------------|--------------------------------------------------------|-------------------------------------------------------------------|
| diarization / GSS                                                                                      | “说话人分割 → GSS/cACGMM 掩码”支路                              | diarization 约束活动时间与跨频点置换；它不直接输出 SCM 或音频                           |
| 目标/干扰 SCM 与解析波束                                                                                        | “GSS 掩码 + 同阶段 WPE 输出未方向归一 STFT → SCM → DSB/MVDR/GEV”支路 | 掩码只给权重，SCM 仍由 $\mathbf{Y}\mathbf{Y}^H$ 加权计算；不能改用单位向量 $\mathbf{z}$ |
| 神经分离 / CSS                                                                                             | WPE 后的替代音频路径，可绕过解析波束后接单通道增强                            | 是否输出固定多流、使用未来上下文和跨块排列，都要单独说明                                      |
| DNN 后滤波 / DNN 后端                                                                                       | 波束形成或分离后的单通道增强或后端                                      | 独立改写复谱的网络通常放在多通道 WPE/MVDR 之后，以免破坏空间相位                             |
| 降噪（Noise Suppression, NS）/自动增益控制（Automatic Gain Control, AGC）/语音活动检测（VAD）/关键词检出（Keyword Spotting, KWS） | 单通道增强与可选 KWS 旁路；VAD 属控制面                               | 各模块按目标任务启用，不在本章展开                                                 |

回声、混响和分离使用不同的参考与统计假设，模块顺序需要服从这些条件。下一章讨论如何把逐帧定位结果连接成连续轨迹。

---

## 第 9 章 · 声源追踪

### 9.1 问题与声学特殊性

声源追踪持续估计运动声源状态  $\vec{s}_t = [\theta_t, \dot{\theta}_t, \ddot{\theta}_t]^\top$ ，其中三项分别为角度、角速度和角加速度。它把含噪且可能间断的逐帧定位结果融合成连续轨迹，再为波束形成提供抖动较小的因果方向估计。[LOCATA 声源定位与追踪挑战](#)包含静止或运动的声源与阵列录音，并提供光学动捕真值；使用时要按任务编号区分单源/多源、静止/运动和阵列配置，数据选择的一般原则见 § 10.6。

声学追踪有四个特点：

- 说话人停顿会造成间歇观测，需要语音活动检测（Voice Activity Detection, VAD）门控和轨迹维持；
- 混响会产生非高斯误差和野点；
- 声源数会随时间变化；
- 到达方向（Direction of Arrival, DOA）与笛卡尔位置之间是非线性关系。

若状态为平面位置与速度  $[x, y, \dot{x}, \dot{y}]$ ，阵列中心为  $(x_0, y_0)$ ，则观测函数为  $\theta = \text{atan2}(y - y_0, x - x_0)$ 。

单个固定阵列的一次方位观测不能确定距离。令阵列中心为  $(0, 0)$ ，声源在  $(1 \text{ m}, 1 \text{ m})$  与  $(2 \text{ m}, 2 \text{ m})$  时都得到  $45^\circ$ ；沿同一射线缩放位置不会改变  $\text{atan2}$  的结果。

连续仅测方位观测只有在已知运动约束和足够的阵列一声源相对运动使系统可观测时，才可能逐步估计距离。否则，即使用扩展卡尔曼滤波（Extended Kalman Filter, EKF）或无迹卡尔曼滤波（Unscented Kalman Filter, UKF），径向位置仍不能由滤波器自行产生。

位置级追踪通常还要引入已知中心不同的多个阵列、到达时间差（Time Difference of Arrival, TDOA）或距离观测，或利用满足可观测条件的移动阵列轨迹。[仅测方位可观测性分析](#)。

EKF 用该观测函数的雅可比做一阶线性化。标准对称或缩放无迹变换的 UKF 通常传播  $2L + 1$  个 sigma 点；对位置—速度状态  $[x, y, \dot{x}, \dot{y}]^\top$ ，状态维数  $L = 4$ ，因此是 9 个点。单纯方位—角速度状态只有  $L = 2$ ，对应 5 个点。也有单纯形、球面径向等减少点数的变体，不能把  $2L + 1$  写成所有 UKF 的定义。近距离或声源越过阵列附近时非线性更强，应比较 UKF、粒子滤波或其他非线性方法，而不是直接套用线性卡尔曼滤波（Kalman Filter, KF）。

### 9.2 单目标追踪

状态与观测模型写为

$$\vec{s}_t = \mathbf{F}\vec{s}_{t-1} + \vec{v}_t, \quad \vec{z}_t = \mathbf{H}\vec{s}_t + \vec{w}_t. \quad (9-1)$$

其中  $\mathbf{F}$  描述匀速或匀加速运动， $\vec{v}_t$  是未建模运动造成的过程噪声。若状态维数为  $d$ 、观测维数为  $p$ ，则过程噪声协方差  $\mathbf{Q} = E[\vec{v}_t \vec{v}_t^\top] \in \mathbb{R}^{d \times d}$ ，观测噪声协方差  $\mathbf{R} = E[\vec{w}_t \vec{w}_t^\top] \in \mathbb{R}^{p \times p}$ 。

协方差元素的单位由对应状态分量相乘决定。例如  $[\theta, \dot{\theta}]^\top$  的对角线单位分别是  $\text{deg}^2$  和  $(\text{deg}/\text{frame})^2$ 。若定位器只输出角度， $\vec{z}_t$  退化为标量  $\theta_t^{\text{obs}}$ ， $\vec{w}_t$  是观测噪声， $\mathbf{R}$  也退化为角度方差。

三维状态时  $\mathbf{H} = [1, 0, 0]$ ；下文二维简化状态  $[\theta, \dot{\theta}]^\top$  使用  $\mathbf{H} = [1, 0]$ 。

贝叶斯递推包含预测和更新。预测阶段依据运动模型外推状态，并增加因过程噪声带来的不确定度；更新阶段用观测与预测之差，即新息，修正状态和协方差。在线性高斯假设下，卡尔曼滤波给出这两个阶段的闭式递推。

卡尔曼滤波（KF）的五步递推（状态取 [角度, 角速度]）：1. 预测状态：

$$\hat{\vec{s}}_t^- = \mathbf{F}\hat{\vec{s}}_{t-1}. \quad (9-2)$$

2. 预测协方差：

$$\mathbf{P}_t^- = \mathbf{F}\mathbf{P}_{t-1}\mathbf{F}^\top + \mathbf{Q}。 \quad (9-3)$$

$\mathbf{F}$  先把上一帧协方差传播到当前状态， $\mathbf{Q}$  再加入未建模运动的过程噪声。不能据此断言任意  $\mathbf{F}$  下每个协方差元素都必然增大；本章的无观测匀速数例中，角度方差会增大。3. 计算卡尔曼增益：

$$\mathbf{K}_t = \mathbf{P}_t^- \mathbf{H}^\top (\mathbf{H}\mathbf{P}_t^- \mathbf{H}^\top + \mathbf{R})^{-1}。 \quad (9-4)$$

$\mathbf{R}$  是式(9-1)定义的观测噪声协方差。观测噪声较小时增益增大，更新更依赖观测；预测协方差较小时增益减小，更新更依赖运动模型。4. 更新状态：

$$\hat{\mathbf{s}}_t = \hat{\mathbf{s}}_t^- + \mathbf{K}_t(\theta_t^{obs} - \mathbf{H}\hat{\mathbf{s}}_t^-)。 \quad (9-5)$$

括号里的差称为新息（innovation），即观测与预测之差。5. 更新协方差：

$$\mathbf{P}_t = (\mathbf{I} - \mathbf{K}_t \mathbf{H}) \mathbf{P}_t^-。 \quad (9-6)$$

方位角跨越表示区间边界时，新息不能直接相减。若角度约定为  $[-180^\circ, 180^\circ)$ ，定义

$$\text{wrap}_{180}(\alpha) = ((\alpha + 180^\circ) \bmod 360^\circ) - 180^\circ。 \quad (9-7)$$

并在第 4 步使用  $\text{wrap}_{180}(\theta_t^{obs} - \mathbf{H}\hat{\mathbf{s}}_t^-)$ 。预测和更新完成后，还应把状态中的角度分量按式(9-7)映射回同一表示区间；角速度等非角度分量不做环绕。

例如预测为  $+179^\circ$ 、观测为  $-179^\circ$ ，直接相减得到  $-358^\circ$ ，最短圆周角差却是  $+2^\circ$ 。不做环绕会让滤波器沿错误方向大幅更新，门控也可能把正确观测判成野点。

若设备只搜索一个不跨边界的有限扇区，则应使用该扇区的边界模型，不能把  $-180^\circ$  与  $+180^\circ$  自动视为相邻。

式(9-6)便于手算；浮点实现可使用数值上更稳健的 Joseph 形式

$$\mathbf{P}_t = (\mathbf{I} - \mathbf{K}_t \mathbf{H}) \mathbf{P}_t^- (\mathbf{I} - \mathbf{K}_t \mathbf{H})^\top + \mathbf{K}_t \mathbf{R} \mathbf{K}_t^\top。 \quad (9-8)$$

式(9-6)与式(9-8)在精确算术和标准卡尔曼增益下等价。Joseph 形式把两个半正定项相加，更不容易因舍入误差得到不对称或负方差；实现中仍应检查  $\mathbf{P}_t$  的对称性和最小特征值。

算例 9-1：卡尔曼滤波单步数值例（跟住一个正在转头的说话人）

下面用一组数值复算式(9-2)至式(9-6)。状态向量取 § 9.1 三维状态的二维简化版  $\vec{s} = [\theta, \dot{\theta}]^\top$ ，单位分别为度和度/帧。该模型省略加速度，适合运动较平缓的示例；频繁机动时可改用含加速度的模型或后文的 IMM。已知：

- 上一帧估计： $\hat{\mathbf{s}}_{t-1} = [30, 0.5]^\top$ （目标在  $30^\circ$ ，每帧向右走  $0.5^\circ$ ）；
- 上一帧不确定度： $\mathbf{P}_{t-1} = \begin{bmatrix} 4 & 0 \\ 0 & 0.25 \end{bmatrix}$ （角度方差  $4^\circ^2$ ，即标准差  $2^\circ$ ；角速度方差 0.25）；
- 状态转移矩阵（匀速模型）： $\mathbf{F} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ （“新角度 = 旧角度 + 1 帧 × 角速度，角速度不变”的矩阵写法）；
- 过程噪声： $\mathbf{Q} = \begin{bmatrix} 0.1 & 0 \\ 0 & 0.01 \end{bmatrix}$ （“目标其实会乱动”的程度， $\mathbf{Q}$  越大滤波器越不自信自己的预测）；
- 观测矩阵： $\mathbf{H} = [1, 0]$ （DOA 算法只报角度，不报角速度）；
- 本帧观测： $\theta_t^{obs} = 32^\circ$ ；观测噪声  $\mathbf{R} = 25$ （标准差  $5^\circ$ ，反映单帧 DOA 估计相当粗糙）。

第 1 步：预测  $\hat{\mathbf{s}}_t^- = \mathbf{F}\hat{\mathbf{s}}_{t-1}$

$$\hat{\underline{s}}_t^- = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 30 \\ 0.5 \end{bmatrix} = \begin{bmatrix} 1 \times 30 + 1 \times 0.5 \\ 0 \times 30 + 1 \times 0.5 \end{bmatrix} = \begin{bmatrix} 30.5 \\ 0.5 \end{bmatrix}$$

“他上一帧在  $30^\circ$  、每帧走  $0.5^\circ$  ，这帧大概到  $30.5^\circ$  。”

第 2 步：预测的不确定度  $\mathbf{P}_t^- = \mathbf{F}\mathbf{P}_{t-1}\mathbf{F}^\top + \mathbf{Q}$

先算  $\mathbf{F}\mathbf{P}_{t-1} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 0.25 \end{bmatrix} = \begin{bmatrix} 4 & 0.25 \\ 0 & 0.25 \end{bmatrix}$  (第一行:  $1 \times 4 + 1 \times 0 = 4$ ,  $1 \times 0 + 1 \times 0.25 = 0.25$ ; 第二行照算)。

再乘  $\mathbf{F}^\top = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$ :

$$\mathbf{F}\mathbf{P}_{t-1}\mathbf{F}^\top = \begin{bmatrix} 4 & 0.25 \\ 0 & 0.25 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 4 \times 1 + 0.25 \times 1 & 4 \times 0 + 0.25 \times 1 \\ 0 \times 1 + 0.25 \times 1 & 0 \times 0 + 0.25 \times 1 \end{bmatrix} = \begin{bmatrix} 4.25 & 0.25 \\ 0.25 & 0.25 \end{bmatrix}$$

左上角从 4 增加到 4.25, 因为角速度的不确定度会在预测后传播到角度。再加上  $\mathbf{Q}$ :

$$\mathbf{P}_t^- = \begin{bmatrix} 4.25 & 0.25 \\ 0.25 & 0.25 \end{bmatrix} + \begin{bmatrix} 0.1 & 0 \\ 0 & 0.01 \end{bmatrix} = \begin{bmatrix} 4.35 & 0.25 \\ 0.25 & 0.26 \end{bmatrix}$$

即预测的角度不确定度为标准差  $\sqrt{4.35} \approx 2.09^\circ$ 。

第 3 步：卡尔曼增益  $\mathbf{K}_t = \mathbf{P}_t^- \mathbf{H}^\top (\mathbf{H}\mathbf{P}_t^- \mathbf{H}^\top + \mathbf{R})^{-1}$

$\mathbf{H}\mathbf{P}_t^- \mathbf{H}^\top$  只是取出  $\mathbf{P}_t^-$  的左上角元素 4.35 (因为  $\mathbf{H} = [1, 0]$  起到“挑出角度分量”的作用), 于是分母是标量:

$$\mathbf{H}\mathbf{P}_t^- \mathbf{H}^\top + \mathbf{R} = 4.35 + 25 = 29.35$$

分子  $\mathbf{P}_t^- \mathbf{H}^\top = \begin{bmatrix} 4.35 & 0.25 \\ 0.25 & 0.26 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 4.35 \\ 0.25 \end{bmatrix}$  (取  $\mathbf{P}_t^-$  的第一列)。

$$\mathbf{K}_t = \frac{1}{29.35} \begin{bmatrix} 4.35 \\ 0.25 \end{bmatrix} = \begin{bmatrix} 0.148 \\ 0.0085 \end{bmatrix}$$

中间值分别为 0.1482 和 0.00852, 这里保留三位和两位有效数字。

增益是  $2 \times 1$  向量:  $K_1 = 0.148$  (角度分量信观测的比例)、 $K_2 = 0.0085$  (角速度分量分到的一点残差信息——观测虽只报角度, 但角度残差里也藏着“速度估偏了”的线索)。

$K_1 \approx 0.148$  表示角度更新量取新息的约 14.8%。观测噪声方差 25 大于预测角度方差 4.35, 因此估计更接近预测值。若  $\mathbf{R}$  减小,  $K_1$  会增大, 观测对更新的影响也会增加。

第 4 步：更新  $\hat{\underline{s}}_t = \hat{\underline{s}}_t^- + \mathbf{K}_t(\theta_t^{obs} - \mathbf{H}\hat{\underline{s}}_t^-)$

新息 (innovation, 观测与预测之差) 为  $\theta_t^{obs} - \mathbf{H}\hat{\underline{s}}_t^- = 32 - 30.5 = 1.5^\circ$ 。

$$\hat{\underline{s}}_t = \begin{bmatrix} 30.5 \\ 0.5 \end{bmatrix} + \begin{bmatrix} 0.148 \\ 0.0085 \end{bmatrix} \times 1.5 = \begin{bmatrix} 30.5 + 0.222 \\ 0.5 + 0.0128 \end{bmatrix} = \begin{bmatrix} 30.72 \\ 0.513 \end{bmatrix}$$

角度由预测值向观测值修正约  $0.22^\circ$ , 角速度更新为  $0.513^\circ/\text{帧}$ 。最终角度  $30.72^\circ$  位于预测值  $30.5^\circ$  与观测值  $32^\circ$  之间, 并因  $K_1$  较小而更接近预测值。

第 5 步：更新的不确定度  $\mathbf{P}_t = (\mathbf{I} - \mathbf{K}_t \mathbf{H}) \mathbf{P}_t^-$

先算  $\mathbf{K}_t \mathbf{H} = \begin{bmatrix} 0.148 \\ 0.0085 \end{bmatrix} [1, 0] = \begin{bmatrix} 0.148 & 0 \\ 0.0085 & 0 \end{bmatrix}$ , 于是

$$\mathbf{I} - \mathbf{K}_t \mathbf{H} = \begin{bmatrix} 1 - 0.148 & 0 \\ -0.0085 & 1 \end{bmatrix} = \begin{bmatrix} 0.852 & 0 \\ -0.0085 & 1 \end{bmatrix}$$

$$\mathbf{P}_t = \begin{bmatrix} 0.852 & 0 \\ -0.0085 & 1 \end{bmatrix} \begin{bmatrix} 4.35 & 0.25 \\ 0.25 & 0.26 \end{bmatrix} = \begin{bmatrix} 3.705 & 0.213 \\ 0.213 & 0.258 \end{bmatrix}$$

(第一行:  $0.852 \times 4.35 = 3.705$ ,  $0.852 \times 0.25 = 0.213$ ; 第二行:  $-0.0085 \times 4.35 + 1 \times 0.25 = 0.213$ ,  $-0.0085 \times 0.25 + 1 \times 0.26 = 0.258$ 。)

角度方差从 4.35 降到 3.71 (标准差约  $1.93^\circ$ ) ——每吸收一次观测, 不确定度就降一截。若下一帧说话人停顿没有观测, 就只做第 1、2 步:  $\mathbf{P}$  重新涨大, 波束指向维持外推, 这就是“静默保持”(§ 9.4)。算例 9-1 说明了单步卡尔曼递推。下表比较常见单目标追踪方法的假设、计算量和适用条件。其中,  $\alpha$ - $\beta$  滤波器所说的“免 Riccati 迭代”, 是把第 2、3、5 步的不确定度递推 (Riccati 方程) 换成固定增益。

| 方法                                                                            | 原理                                 | 优点                   | 缺点                                                                                | 适用               |
|-------------------------------------------------------------------------------|------------------------------------|----------------------|-----------------------------------------------------------------------------------|------------------|
| 滑动平均/中值/直方图众数                                                                 | 对 DOA 序列低通                         | 结构简单, 不需递推协方差        | 隐含局部平稳假设; 延迟大、跟不上机动、多源混杂                                                          | 目标缓慢、观测较密时的基线    |
| $\alpha$ - $\beta$ / $\alpha$ - $\beta$ - $\gamma$                            | 稳态增益卡尔曼                            | 免 Riccati 迭代         | 增益非最优                                                                             | 嵌入式              |
| 卡尔曼滤波 KF                                                                      | 高斯线性贝叶斯递推 (预测+新息加权更新)              | 在线性高斯模型正确时得到最小均方误差估计 | 稠密实现随状态维数 $d$ 、观测维数 $p$ 约为 $O(d^3 + p^3)$ ; 标量 DOA 更新可更低, 但仍需在目标硬件计时; 抗野点差、需调 Q/R | 观测质量较好且模型近似成立    |
| EKF (扩展卡尔曼滤波) / UKF (无迹卡尔曼滤波)                                                 | 一阶线性化/无迹变换处理非线性                    | 可处理位置到角度的非线性观测       | EKF 对线性化误差敏感; 标准对称/缩放 UKF 常传播 $2L + 1$ 个 sigma 点, 其他变体点数不同                        | 分布式阵列位置级追踪       |
| IMM 交互多模型                                                                     | 静止、匀速、加速等多个运动模型各自运行 KF, 再按新息似然加权融合 | 可在多个预设运动模式之间平滑切换     | 计算量随模型数增加; 未包含的运动模式仍会失配, 且需标定模型转移概率                                               | 包含启动、停止和匀速段的机动场景 |
| 粒子滤波 (Particle Filter, PF) / 序贯重要性重采样 (Sequential Importance Resampling, SIR) | 带权粒子近似后验; 预测、加权、按需重采样              | 能表示非线性、非高斯和多峰后验      | 鲁棒性取决于似然与杂波模型; 会权重退化和样本贫化                                                         | 观测多峰或运动模型明显非线性   |

**IMM 的模型切换:** IMM 并行运行静止、匀速或加速等运动模型, 再根据各模型的新息似然更新权重。它适合包含启动、停止和匀速段的轨迹。

两模型例子可使用静止与匀速模型; 转移矩阵的对角元素表示保持当前运动模式的概率。IMM 的转移概率和各模型过程噪声需要用目标运动数据标定。0.95 或 0.9 只能作为示例, 实际数值不能脱离帧率和目标运动数据直接照搬。

**EKF 与 UKF:** EKF 对  $\theta = \text{atan2}(y - y_0, x - x_0)$  求雅可比, 并在当前估计附近做一阶线性化; 估计偏离真实状态较大时, 线性化误差可能导致发散。标准对称或缩放 UKF 不显式求导, 而是将  $2L + 1$  个 sigma 点通过原始非线性观测函数, 再重构均值与协方差; 减少 sigma 点的变体使用不同构造。计算量要按状态维数、sigma 点数、观测维数和矩阵实现估算, 不能只按“UKF”名称排序。

#### 算例 9-2: 10 个粒子的一轮加权与重采样

卡尔曼滤波用均值和协方差表示单峰高斯后验。**粒子滤波** (particle filter, PF) 用  $N$  个带权样本近似后验, 可以表达偏斜或多峰分布。它并不会自动抵抗观测野点: 若似然模型把野点当成高置信观测, 粒子权重仍会被错误观测拉偏。鲁棒性来自观测门控、重尾似然或“目标加均匀杂波”的混合似然。下面用 10 个粒子演示加权与重采样。

设本帧 10 个粒子的角度猜测 (单位: 度) 为:

$$x_1, \dots, x_{10} = [25, 27, 28, 30, 30, 31, 32, 33, 35, 40]$$

本帧观测  $\theta^{obs} = 31^\circ$ , 观测噪声标准差  $\sigma = 5^\circ$  (方差  $\sigma^2 = 25$ )。

第 1 步：根据观测似然计算权重

每个粒子的权重用高斯似然：离观测越近分越高，

$$w_i = \exp\left(-\frac{(x_i - \theta^{obs})^2}{2\sigma^2}\right) = \exp\left(-\frac{(x_i - 31)^2}{50}\right)$$

逐个计算  $((x_i - 31)^2)$  先列出来）：

| 粒子 $x_i$ | $(x_i - 31)^2$ | $w_i = \exp(-(x_i - 31)^2/50)$ |
|----------|----------------|--------------------------------|
| 25       | 36             | $\exp(-0.72) = 0.4868$         |
| 27       | 16             | $\exp(-0.32) = 0.7261$         |
| 28       | 9              | $\exp(-0.18) = 0.8353$         |
| 30       | 1              | $\exp(-0.02) = 0.9802$         |
| 30       | 1              | $\exp(-0.02) = 0.9802$         |
| 31       | 0              | $\exp(0) = 1.0000$             |
| 32       | 1              | $\exp(-0.02) = 0.9802$         |
| 33       | 4              | $\exp(-0.08) = 0.9231$         |
| 35       | 16             | $\exp(-0.32) = 0.7261$         |
| 40       | 81             | $\exp(-1.62) = 0.1979$         |

权重和

$= 0.4868 + 0.7261 + 0.8353 + 0.9802 + 0.9802 + 1.0000 + 0.9802 + 0.9231 + 0.7261 + 0.1979 = 7.8359$ 。

第 2 步：归一化权重

$$\tilde{w}_i = \frac{w_i}{7.8359} \Rightarrow [0.0621, 0.0927, 0.1066, 0.1251, 0.1251, 0.1276, 0.1251, 0.1178, 0.0927, 0.0253]$$

校验：归一化权重之和为 1。40° 是一个远离当前观测的粒子，不是观测野点；它的权重较小，只说明当前高斯似然会压低不符合观测的候选状态，不能证明粒子滤波对错误观测鲁棒。

第 3 步：计算有效粒子数  $N_{eff}$

$$N_{eff} = \frac{1}{\sum_{i=1}^{10} \tilde{w}_i^2} = \frac{1}{0.0621^2 + 0.0927^2 + 0.1066^2 + 0.1251^2 + \cdots + 0.0253^2} = \frac{1}{0.1101} \approx 9.08$$

若 10 个粒子权重相等， $N_{eff} = 10$ ；若全部权重集中在一个粒子上， $N_{eff} = 1$ ，称为粒子退化。本例得到 9.08。常见实现会在  $N_{eff}$  低于给定阈值时触发重采样，例如  $N/2$ ；阈值需要结合粒子数和任务验证。

第 4 步：在重采样前计算本帧估计

$$\hat{\theta} = \sum_{i=1}^{10} \tilde{w}_i x_i = 0.0621 \times 25 + 0.0927 \times 27 + 0.1066 \times 28 + 0.1251 \times 30 + \cdots + 0.0253 \times 40 \approx 30.65^\circ$$

不加权的平均为 31.1°，加权估计约为 30.65°。这个后验均值必须用重采样前的粒子和归一化权重计算。重采样后权重重置为  $1/N$ ，不能把旧权重再乘到新粒子上；重采样后取均值只是在有限样本下近似同一后验。

第 5 步：为演示算法，强制执行一次系统重采样。本例  $N_{eff} = 9.08 > N/2 = 5$ ，按上一段的示例阈值本来不会触发重采样。下面只为展示系统重采样的索引过程而人为执行一次，不能把它当作阈值判决结果。

系统重采样按归一化权重重新抽取 10 个粒子，允许高权重粒子重复出现，并把新权重统一重置为  $1/10$ 。

先计算累积和  $[0.0621, 0.1548, 0.2614, 0.3865, 0.5116, 0.6392, 0.7643, 0.8821, 0.9747, 1.0000]$ ，再从  $[0, 0.1)$  取起点  $u_0 = 0.0637$ ，以 0.1 为间隔得到 10 个采样点。对应的新粒子群为：

$$[27, 28, 30, 30, 30, 31, 32, 32, 33, 35]$$

$30^\circ$  和  $32^\circ$  的粒子被重复抽取， $25^\circ$  和  $40^\circ$  的粒子未被抽中。重采样是随机过程，不按单个粒子的权重机械排序； $31^\circ$  虽有最高单粒子权重，本次仍只保留一份。下一帧先按运动模型传播粒子，再根据新观测重新计算权重。

粒子滤波依次执行状态传播、似然加权、归一化和按需重采样。它能表示多峰后验，但观测野点仍需门控或杂波似然处理。

抗野点技巧包括观测门控、混合似然和辅助粒子滤波（Auxiliary Particle Filter, APF）。门控阈值不能只照搬固定的  $3\sigma$ ，应结合观测误差分布和漏检代价标定。

图22(a) 为序贯重要性重采样粒子滤波（Sequential Importance Resampling Particle Filter, SIR-PF）递推估计 DOA 的本书仿真。配置如下：

- 真值与观测：真值是  $60^\circ + 40^\circ \sin(2\pi t/120)$  的正弦轨迹；逐帧观测加标准差  $7^\circ$  的高斯噪声，并将约 20% 帧替换为  $0^\circ \sim 120^\circ$  均匀野点；
- 缺测：第 48~57 帧被置为缺测，这 10 帧只执行状态预测；
- 滤波器：使用 200 个粒子和“高斯目标 + 均匀杂波”混合似然，均匀杂波权重为 0.1；
- 初始化与边界：初始角度粒子在允许扇区内均匀采样，不读取未来第一个有效观测。状态只允许落在  $[0^\circ, 120^\circ]$  有限扇区，越界粒子按扇区端点作镜面反射。

镜面反射是便于展示的玩具边界，不是圆周角的  $360^\circ$  环绕，也不代表真实墙面反射。

图22 声源追踪示意（模拟）




图22 (a) 中，灰点为逐帧 DOA 观测，黑线为正弦真值轨迹，红线为粒子滤波估计，紫色阴影标出连续 10 帧缺测，橙色竖线表示有效粒子数低于  $N/2$  后执行了系统重采样。紫色叉号只标出该帧预测后至少 5% 粒子越界并被镜面反射的时刻，避免用“任一粒子越界”放大单个尾部样本。

缺测段没有似然更新，轨迹只由匀速状态模型与过程噪声外推； $0^\circ$  与  $120^\circ$  是采用反射规则的有限扇区边界。

图22 (b) 在  $-25^\circ$  和  $+40^\circ$  附近设置两个强度峰，用于说明多目标强度函数。峰数只能近似用于提取人数，严格定义见 § 9.3。

单目标追踪由预测和观测更新组成。线性高斯条件下可使用卡尔曼滤波；非线性、多峰或重尾观测可考虑 UKF 或粒子滤波。粒子滤波仍需门控或杂波似然处理野点，IMM 用于多运动模型切换，VAD 用于控制无观测时的更新。

9.3 多目标追踪

多目标追踪需要同时解决观测与轨迹的数据关联，并估计当前的声源数量。

| 方法族                                                                                                | 代表                                                                                            | 思想                           | 声学表现                                         |
|----------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------|------------------------------|----------------------------------------------|
| 数据关联+单目标滤波                                                                                         | 联合概率数据关联（Joint Probabilistic Data Association, JPDA）、多假设跟踪（Multiple Hypothesis Tracking, MHT） | 计算观测属于各轨迹的概率或假设树             | 假设数可能随观测和轨迹数快速增长                             |
| 多目标粒子滤波                                                                                            | Brutti et al. 2010                                                                            | 每目标一簇粒子 + 数据关联               | 计算量、数据关联和目标数先验都需按实验验证                        |
| 随机有限集（Random Finite Set, RFS）/概率假设密度（Probability Hypothesis Density, PHD）滤波                        | PHD、势概率假设密度（Cardinalized PHD, CPHD）、序贯蒙特卡洛 PHD（Sequential Monte Carlo PHD, SMC-PHD）           | 传播目标集合的一阶强度；积分给期望目标数，峰用于提取状态 | 避免显式枚举关联，但不保留身份；峰提取和参数设置影响结果 Liu et al. 2018 |
| 标记多伯努利（Labeled Multi-Bernoulli, LMB）/δ-广义标记多伯努利（delta-Generalized Labeled Multi-Bernoulli, δ-GLMB） | 带标签的 RFS                                                                                      | 为目标维护标签、输出带身份轨迹              | 标签管理、假设数和计算量随具体实现而变                          |
| 检测前追踪（Track-Before-Detect, TBD）                                                                    | 对经校准的定位谱或似然场直接递推                                                                              | 不先把弱峰硬切成离散观测，可保留阈值以下的证据      | 输入谱必须有跨帧一致的尺度与杂波模型；未经校准的 DNN 分数不能直接当似然       |
| 序列神经网络                                                                                             | 循环神经网络（Recurrent Neural Network, RNN）/Transformer 处理定位后验序列                                    | 可学习时间平滑与活动模式                 | 仍需训练数据；是否输出稳定身份取决于标签和损失                      |

三帧关联辅助例子。设两条匀速轨迹的预测角分别为 A: 20°, 30°, 40°, B: 60°, 50°, 40°；三帧观测依次为 (22°, 58°)、(15°, 31°, 48°)、(39°, 41°)。假设独立高斯角度误差的标准差  $\sigma = 3^\circ$ 。为先算清最小 JPDA 归一化，暂时假设第一、三帧没有漏检和杂波，且两个全局关联事件先验相同。

第一帧“顺接”事件的似然正比于  $\exp[-(2^2 + (-2)^2)/(2 \times 3^2)] = e^{-8/18} \approx 0.641$ ；“交换”事件的残差为 38°, -38°，似然约为  $e^{-2888/18}$ ，归一化后的顺接概率在所示精度下为 1。

第三帧两条预测都为 40°，两个交换事件的残差平方和都为  $(-1)^2 + 1^2 = 2$ ，似然都为  $e^{-2/18} \approx 0.895$ 。归一化后两个全局事件各为 0.5，因此每条轨迹关联到 39° 或 41° 的边缘概率也各为 0.5。

第二帧多出的 15° 只有在给定检测概率、杂波空间密度和漏检模型后才能得到完整概率；仅比较残差时，近邻两对的代价为  $5/18 \approx 0.278$ ，但这不是完整 JPDA 后验。

JPDA 在每帧枚举满足一对一约束、漏检和杂波模型的联合事件，再把事件概率边缘化到每条轨迹；交叉处的两条轨迹可能因共享两个观测而向同一均值靠拢。MHT 则把第三帧的两种全局历史都暂时保留，等后续观测拉开后再按累计似然和剪枝规则决策，因此更能延迟身份决定，但假设树会增长。这个例子只比较关联机制；实际概率还必须包含检测概率、杂波强度和门控归一化。JPDA 原始论文、MHT 原始论文。

LMB/δ-GLMB 为目标维护标签，可输出带身份的轨迹。检测前追踪直接递推定位谱，保留未越过检测阈值的弱证据。

把连续定位谱接入 TBD 前，应先在独立验证集上校准“谱值一似然或似然比”的映射，并固定角度网格、归一化、温度缩放、声源数先验、信噪比与混响条件。网络 softmax 分数只在其类别集合内归一化，不能自动跨帧比较；出生、存活、漏检和杂波参数也要与同一标定口径匹配。若这些条件变化，应重新标定或把分数仅作为特征输入，而不是直接解释为概率。

活动耦合笛卡尔 DOA (Activity-Coupled Cartesian DOA, ACCDOA) 把向量方向编码为 DOA、向量长度编码为活动强度。它本身是逐帧声事件定位与检测的输出表示，不等同于追踪器；只有结合时序模型、平滑和身份关联后，才形成轨迹。

PHD 强度  $D_t(x)$  也不是“某处有人”的普通概率密度。它在区域  $A$  上的积分表示该区域内目标数的期望，因而总目标数估计来自  $\hat{N}_t = \int D_t(x) dx$ ，再按整数规则取值。目标位置通常从强度峰或聚类中心提取；“峰数就是人数”只是实现近似。PHD 避免显式枚举观测—目标关联，但只传播一阶矩，不保留目标身份，也不能完整描述目标间相关性。

下面的递推针对标准独立点目标模型：各目标独立演化，检测事件相互独立，每个被检测目标每帧至多产生一条观测，杂波是与目标观测独立的 Poisson 随机有限集，并忽略由既有目标衍生新目标 (spawning) 的过程，只用  $\gamma_t$  表示自发出生；为得到下面的标准闭式更新，还采用 Poisson 型预测多目标分布近似。PHD 的预测式为

$$D_{t|t-1}(x) = \int p_S(x') f_t(x | x') D_{t-1}(x') dx' + \gamma_t(x). \quad (9-9)$$

其中  $p_S$  是存活概率， $f_t$  是状态转移密度， $\gamma_t$  是新生目标强度。给定本帧观测集合  $Z_t$ ，标准 PHD 更新为

$$D_t(x) = [1 - p_D(x)] D_{t|t-1}(x) + \sum_{z \in Z_t} \frac{p_D(x) g_t(z | x) D_{t|t-1}(x)}{\kappa_t(z) + \int p_D(\xi) g_t(z | \xi) D_{t|t-1}(\xi) d\xi}. \quad (9-10)$$

$p_D$  是检测概率， $g_t(z | x)$  是目标在状态  $x$  时产生观测  $z$  的似然， $\kappa_t(z)$  是杂波强度。第一项保留可能漏检的目标；求和中的每个分母比较“该观测来自杂波”与“来自任一目标”的解释，因此杂波强度越大，单条观测增加的目标强度越少。

用两个离散角度网格做手算。预测强度质量为  $D^- = [0.8, 0.6]$ ，表示两个网格合计期望目标数 1.4；取  $p_D = 1$ ，本帧只有一个观测，其似然为  $g = [0.9, 0.1]$ ，杂波强度为 0.1。分母是  $0.1 + 0.9 \times 0.8 + 0.1 \times 0.6 = 0.88$ ，更新后两个网格的强度质量分别为  $0.72/0.88 \approx 0.818$  和  $0.06/0.88 \approx 0.068$ ，总和约 0.886。

总和小于 1，是因为这条观测仍有一部分概率由杂波解释；若  $p_D < 1$ ，还要加上第一项的漏检质量。

这个离散例子只解释更新各项，不能替代连续状态中的积分、峰提取和轨迹身份管理。相关混响峰不满足独立杂波假设，扩展目标还可能在一帧产生多条观测；这两类情况需修改似然或杂波模型，或采用相应的扩展目标、多目标滤波模型，不能直接套用上式。

粒子或高斯混合只是表示和计算强度函数的不同方法。目标数由强度积分估计，位置再从峰或聚类中心提取。[PHD 原始论文](#)；音视频视觉粒子实现见 [Liu et al. 2019](#)。

多目标追踪还要估计观测与轨迹的对应关系以及目标数。JPDA 和 MHT 显式处理关联；PHD 传播随机有限集的一阶强度；LMB 保留目标标签；检测前追踪保留未越过检测阈值的弱证据。最优子模式分配距离 (Optimal Subpattern Assignment, OSPA) 同时度量定位误差和目标数误差，但不评价身份连续性。

可执行单目标基线与高级算法边界。[codes/array\\_tutorial/tracking.py](#) 提供常速度角度 Kalman 滤波器、 $[-180^\circ, 180^\circ)$  环绕、系统重采样和圆周角 SIR 粒子滤波器。`ConstantVelocityKalman` 的状态单位是 [度, 度/秒]；每帧先用实际秒数 `dt` 调用 `predict()`，有观测时再以角度方差调用 `update()`，缺测时不调用更新。协方差使用 Joseph 形式。`CircularParticleFilter` 用圆周高斯目标似然与均匀杂波的混合更新权重，按有效粒子数决定是否系统重采样；它只估计单个圆周角，不包含速度粒子、有限扇区反射或轨迹身份。

联合示例用 `.venv/bin/python -m codes.examples.ch06_09_baselines` 运行，测试见 [tests/test\\_codes\\_aec\\_wpe\\_sep\\_track.py](#)。测试覆盖  $179^\circ$  与  $-179^\circ$  的最短新息、缺测时角度方差增长、Joseph 更新后的对称半正定性、远距离高置信观测的对数权重、退化权重的系统重采样，以及对称后验下未定义的圆周均值。教学 Kalman 类的过程噪声矩阵  $Q$  已按一次预测间隔离散化；若 `dt` 改变，不能继续照搬同一个  $Q$ 。粒子后验的圆周合向量接近零时，代码会明确报错，而不是返回由浮点残差决定的任意角度。设备只搜索有限扇区时不得使用圆周环绕；还需测试迟到/乱序观测、长缺测、错误时间戳、野点门控、目标交叉、轨迹出生/确认/删除、ID 重用和消息超时。无有效观测时应只预测并增大不确定度，超过有效期后回到搜索模式。

EKF/UKF、IMM、完整 JPDA/MHT、SMC/GM-PHD、CPHD、LMB/ $\delta$ -GLMB、检测前追踪与神经 SELD/ACCDOA 属于成熟库或论文官方实现层级，本书不复制其大型实现。可从 Stone Soup、FilterPy 或作者仓库核对具体算法，但正式采用前必须确认版本、许可证、坐标与时间单位、出生/存活/漏检/杂波模型、门控和剪枝规则、随机种子及评测协议。论文伪代码或两网格 PHD 手算不能替代这些工程契约。


## 9.4 定位、追踪与波束形成的接口

---

在线追踪器向波束形成器提供因果滤波或预测方向和置信度；只有离线算法显式使用当前帧之后的观测回修过去状态时，才称为平滑(smoothing)。若定位又使用波束形成后的信号，两个模块会相互影响，因此需要限制更新速率并处理静默期。

图23 远场语音前端：播放参考、音频主链与三条条件支路

实线=音频；红/橙=参考、方向或控制；紫点线=GSS统计；绿点划线=神经旁路。



追踪器兼有因果滤波和预测作用：它减小 DOA 抖动，并在目标短时静默时外推方向。图 23 中，定位与追踪只向解析波束形成器提供方向，不直接控制 GSS 掩码；VAD、远端活动和双讲检测通过控制面约束状态更新。

波束方向的变化上限应按帧率、目标最大转速和允许跟随延迟确定。静默超时或唤醒词触发时还需保持或重置状态，避免定位与波束权重相互影响而振荡。

| 追踪输出字段            | 含义与单位                   | 消费方必须检查          |
|-------------------|-------------------------|------------------|
| frame_id / 坐标系    | 阵列坐标、设备坐标或世界坐标；角度零点与正方向 | 与导向矢量使用同一坐标约定    |
| measurement_time  | 产生定位观测的采样时刻             | 不可用消息到达时刻替代      |
| publish_time      | 追踪结果发布时刻                | 用于测量计算与调度延迟      |
| 状态与协方差            | 角度/角速度或位置/速度，以及同维协方差    | 单位、维度、圆周角新息与置信区间 |
| 活动/存在概率           | 当前目标存在或发声的证据            | 阈值、校准集、静默保持策略    |
| track_id 与生命周期    | 出生、确认、维持、删除和重用规则        | ID 不能等同于永久说话人身份  |
| last_update / 有效期 | 最近一次真实观测更新与允许外推时长       | 超时后保持、降置信度或回搜索模式 |

例如目标角速度为  $30^\circ/\text{s}$ ，波束形成器收到的状态比采样时间晚 80 ms；若直接使用旧角度，确定性外推误差可达  $30 \times 0.080 = 2.4^\circ$ 。消费方应使用 `measurement_time` 和角速度外推到实际生效时刻，并把协方差随预测步长增大；超过接口约定的有效期就不能继续把旧方向当作高置信观测。

多目标结果可用最优子模式分配距离（optimal subpattern assignment, OSPA）评价。若真值集  $X$  有  $m$  个目标，估计集  $Y$  有  $n \geq m$  个目标，截断距离为  $c$ ，阶数为  $p$ ，则

$$d_p^{(c)}(X, Y) = \left[ \frac{1}{n} \left( \min_{\pi} \sum_{i=1}^m \min\{c, d(x_i, y_{\pi(i)})\}^p + c^p(n - m) \right) \right]^{1/p} \tag{9-11}$$

式(9-11)先写  $n \geq m$ ；若  $m > n$ ，交换  $X, Y$  的角色，因此距离保持对称。边界约定是  $d_p^{(c)}(\emptyset, \emptyset) = 0$ ；若仅一侧为空、另一侧非空，则距离为  $c$ 。

第一项是最优配对后的截断定位误差，第二项惩罚目标数不一致，最后还要除以较大的集合大小。

若状态是完整圆周方位，应使用  $d(\theta_1, \theta_2) = \min(|\theta_1 - \theta_2|, 360^\circ - |\theta_1 - \theta_2|)$ ；图22的  $0^\circ \sim 120^\circ$  有限扇区不是圆周，不能套用环绕距离。

OSPA 不保留身份，所以身份切换要另报身份切换次数（Identity Switch, ID switch）等轨迹指标。

这个定义来自 Schuhmacher、Vo 与 Vo 的 OSPA 原始论文（IEEE TSP 56(8), 2008, pp. 3447 – 3457, DOI 10.1109/TSP.2008.920469）。截断距离  $c$  同时限制单个定位误差并设定漏检/虚警的惩罚尺度，因此比较系统时必须使用相同的  $p$ 、 $c$ 、坐标和角度环绕约定。

本章练习

1. KF 手算 + 静默外推：沿用算例 9-1 的末态（估计  $[30.72, 0.513]^\top$ ，协方差左上角 3.705）。假设接下来两帧说话人静默、无观测，只做预测不做更新：手算两帧后的角度估计与角度方差，并说明波束应使用哪个方向。  
答案要点：每帧角度  $+0.513^\circ$ ，两帧后约  $31.75^\circ$ ；在本题给定的  $\mathbf{F}$  与  $\mathbf{Q}$  下，角度方差约按  $3.705 \rightarrow 4.49 \rightarrow 5.80$  增长，完整协方差依次约为  $\begin{bmatrix} 4.49 & 0.47 \\ 0.47 & 0.27 \end{bmatrix}$  和  $\begin{bmatrix} 5.80 & 0.74 \\ 0.74 & 0.28 \end{bmatrix}$ 。波束可暂时使用外推值。  
若目标允许的最大角速度为  $\omega_{\max}$ ，帧间隔为  $\Delta t$ ，单帧转角限值应与  $\omega_{\max} \Delta t$  同量级，再根据允许跟随延迟和机械转速标定；不能在无帧率时固定写成  $3 \sim 5^\circ/\text{帧}$ 。
2. 数据关联二选一：两条轨迹（A 在  $20^\circ$ 、B 在  $60^\circ$ ），本帧两个观测（ $22^\circ$ 、 $58^\circ$ ），JPDA 和最近邻分别如何处理？再加入一个  $19^\circ$  的杂波假峰，并假设门内观测至多分给一条轨迹、每条轨迹至多取一个观测，比较两种方法。  
答案要点：无杂波时，最近邻把  $22^\circ$  配给 A、 $58^\circ$  配给 B；JPDA 在噪声很小且无其他可行事件时也会让这两对关联概率占优。

加入  $19^\circ$  后，硬最近邻会把距离 A 仅  $1^\circ$  的假峰分给 A，把  $58^\circ$  分给 B， $22^\circ$  留作未分配观测。JPDA 不先固定一组配对，而是枚举满足一对一约束、门控、漏检和杂波模型的联合事件，再求每个“轨迹—观测”对的边缘关联概率；A 的更新会综合  $19^\circ$ 、 $22^\circ$  及漏检事件。

若只使用高斯角度残差且杂波模型过弱，JPDA 也可能偏向  $19^\circ$ ，因此软关联不是自动识别杂波，还要标定检测概率、杂波强度和门限。[JPDA 原始论文](#)。

3. PHD + OSPA：某帧从 PHD 强度中提取出  $30^\circ$  和  $70^\circ$  两个目标，真值是  $32^\circ$  处一人。人数估对了吗？取  $p = 1$ 、 $c = 10^\circ$ ，算出这一帧的 OSPA。

答案要点：人数估计为 2，真值为 1。最优配对把  $30^\circ$  与  $32^\circ$  配在一起，截断定位误差为  $2^\circ$ ；多出的  $70^\circ$  目标产生  $10^\circ$  的基数惩罚。按较大集合大小 2 归一化，OSPA 为  $(2^\circ + 10^\circ)/2 = 6^\circ$ 。若把  $70^\circ$  错配给真值，其定位误差先截断为  $10^\circ$ ，结果不会更小。

4. VAD 门控 + 波束限速：说话人突然静默 5 帧（无观测），追踪只做预测；第 1 问：WPE、噪声协方差和降噪器的噪声功率各应怎样更新？第 2 问：已知目标最大角速度  $\omega_{\max}$  和帧间隔  $\Delta t$ ，5 帧内转角限值如何设定，之后如何处理？

答案要点：静音且参考能量不足时冻结 WPE 系数，避免病态统计；确认无目标语音时，可以更新噪声协方差和降噪器的噪声功率。目标语音活动时则避免把目标泄漏写入噪声统计，WPE 是否更新由其语音活动和矩阵条件共同决定。

单帧转角限值可以  $\omega_{\max} \Delta t$  为物理起点，5 帧累计上限为  $5\omega_{\max} \Delta t$ ；超过保持时间或不确定度阈值后，应降低波束更新置信度或回到搜索模式。

---

## 第 10 章 · 工程实现、评测与产业实践

本章把前九章的算法放进真实系统，讨论模块启用条件、信号取点、资源预算和验收方法。

本章常用缩写如下：

| 缩写        | 中文名与英文全称                                                       |
|-----------|----------------------------------------------------------------|
| AFE       | 音频前端（Audio Front End）                                          |
| AEC       | 声学回声消除（Acoustic Echo Cancellation）                             |
| WPE       | 加权预测误差去混响（Weighted Prediction Error）                           |
| NS / AGC  | 噪声抑制（Noise Suppression） / 自动增益控制（Automatic Gain Control）       |
| VAD       | 语音活动检测（Voice Activity Detection）                               |
| KWS / ASR | 关键词唤醒（Keyword Spotting） / 自动语音识别（Automatic Speech Recognition） |
| SRO       | 采样率偏移（Sampling Rate Offset）                                    |
| RTF       | 实时因子（Real-Time Factor）                                         |

本章中的 RTF 均指实时因子；波束形成中的“目标相对传递函数”（relative transfer function）不缩写为 RTF，以免混淆。

### 10.1 参考链路 with 端到端延迟

音频前端没有适用于所有产品的固定流水顺序。图 23 给出的是一条参考链路，只表达模块间的依赖，不表示每个项目都要启用全部模块。

音频主链是“多通道采集 → AEC → WPE → 解析波束形成 → 单通道 NS/AGC → KWS/ASR”。

定位与追踪读取多通道特征，只向解析波束提供带时间戳的方向状态。说话人分割约束 GSS/cACGMM 掩码；掩码与同一 WPE 阶段输出、未做方向归一化的多通道 STFT 一起形成目标/干扰 SCM，再送入波束形成。

神经或连续语音分离（Continuous Speech Separation，CSS）是 WPE 后绕过解析波束的替代音频路径，不与“GSS 掩码—SCM—波束”合并成一个模块。

- 设备不播放声音，或不需要边播边听时，可以不启用 AEC。
- 晚期混响已不影响目标指标时，可以不启用 WPE。
- 目标方向固定时，波束形成可以直接使用已知方向，不必持续定位和追踪。
- 只有多人重叠且下游确实需要独立语流时，才需要语音分离。
- VAD、远端活动检测和双讲检测是控制信号。它们不应画成主音频流中的串行处理框。

图23 远场语音前端：播放参考、音频主链与三条条件支路

实线=音频；红/橙=参考、方向或控制；紫点线=GSS统计；绿点划线=神经旁路。




图 23 按较完整的语音交互系统绘制。远端音频先经过混音、均衡和音量控制；AEC 的 render tap 取在这些播放处理之后、DAC/功放之前，扬声器经房间和机壳耦合回麦克风形成声学回路。虚线表示活动控制，实线表示音频、特征或统计量依赖。

图中 AEC 的“最先处理”是指：启用 AEC 时，应在会破坏播放参考与回声之间线性关系的 NS、AGC 等处理之前消除回声，并不表示任何系统都必须以 AEC 开头。

确定实际模块后，还要重新核对各信号取点。AEC 通常位于会改变回声路径关系的非线性处理之前。参考信号应覆盖实际播放链中的增益、均衡和混音变化。若参考取在这些处理之前，AEC 看到的参考与扬声器实际播放内容不一致。WPE、波束和 NS 的先后则要结合实现判断：多通道 WPE 需要多通道输入；单通道 WPE 可以放在波束之后；神经网络若联合完成波束与去混响，也不能再套用传统串行顺序。

10.1.1 延迟不能把每个模块的耗时直接相加

端到端延迟应沿实际关键路径测量，并分成五类：

| 类别      | 含义                                            | 常见来源                                            |
|---------|-----------------------------------------------|-------------------------------------------------|
| 前瞻或算法等待 | 输出当前样本前必须等待的未来输入                              | 居中窗、双向网络、判决确认窗                                  |
| 缓冲      | 驱动、直接存储器访问（Direct Memory Access，DMA）、网络或帧拼接等待 | 声卡周期、抖动缓冲、整帧推理                                  |
| 计算      | 当前数据到输出完成的执行时间                                | 快速傅里叶变换（Fast Fourier Transform，FFT）、矩阵分解、神经网络推理 |
| 调度      | 任务虽已就绪但尚未运行                                   | 操作系统抢占、队列拥塞、加速器排队                               |
| 解码与交互   | 前端之后的关键路径                                     | 流式 ASR 解码、网络往返、播报准备                             |


同一帧内有多个模块串行执行时，它们的计算时间要相加；并行分支取耗时最长的关键分支；流水重叠的等待只沿关键路径计一次。在线 WPE 只使用历史帧时，本身不需要未来帧，但其分帧、平滑和实现缓冲仍可能产生延迟。

可把第  $p$  条路径写成

$$L_p = L_{\text{lookahead}} + L_{\text{buffer}} + L_{\text{compute}} + L_{\text{schedule}} + L_{\text{decode}}, \quad L_{\text{e2e}} = \max_p L_p.$$

(10-1)

图25 端到端延迟关键路径（示例数字非产品指标）



连续音频：统计到可用音频输出；首个判决：另含确认窗；端点 hangover：只延后结束事件。WPE/追踪历史状态不是未来帧等待。

图 25(a) 把“采集/帧就绪等待”示意为 32 ms，再与未来帧前瞻 16 ms、首个判决确认 25 ms、计算 14 ms 和调度 6 ms 组成一条 93 ms 的示例关键路径。这里的 32 ms 是工作表示例，不等同于 STFT 窗长，也不是所有 32 ms 窗都会增加 32 ms 算法等待；窗的左右对齐、声卡周期、帧移和模块何时开始计算都会改变实际值。

图 25(b) 另行区分三条口径：连续增强音频只计其实际前瞻、缓冲、计算与调度；首个 KWS/ASR 判决还可能等待确认窗；端点 hangover 只延后“语音结束”事件，不应自动计入连续音频或首个判决。

WPE 历史帧、追踪状态、递归协方差和因果 AGC 时间常数是历史状态，不能机械当作未来等待。

这些数字只说明记账方法，没有包含图外可能存在的解码和交互延迟。实际系统应在声学输入与最终输出之间记录时间戳或回采脉冲，分别测量冷启动、稳定运行和最不利调度条件。

把 STFT 窗长从 32 ms 改为 16 ms，也不等于必然省下 16 ms：只有依赖完整窗或未来样本的等待发生变化，关键路径才会缩短。

延迟报告不能只有平均值。稳定运行阶段至少给出中位数（p50）与尾延迟（如 p95、p99）、样本数和测量时长；冷启动另报模型加载、内存分配和状态填充所需时间。若系统存在不同设备、网络或调度模式，应分别报告，而不是把所有样本混成一个分位数。测量点也要写清，例如“音频驱动时间戳 → 第一块可播放增强 PCM”与“音频入口 → 首个 ASR token”是两条不同关键路径。

10.1.2 实时回调只搬运数据

声卡回调线程的首要目标是按时交付下一块音频。回调中临时分配大数组、等待互斥锁、访问磁盘、打印日志或执行时间不确定的模型推理，都可能让驱动错过期限。常见结构是：回调只复制交织或非交织样本、记录设备时间戳和状态位，再把固定大小的数据块写入预分配的环形缓冲；工作线程从缓冲读取并执行 AEC、波束和后端。回调与工作线程的时钟、缓冲单位和丢帧策略必须写清。

环形缓冲已满时，系统需要事先选择“丢最旧块”“丢新块”或“降级处理”。任何一种策略都会改变输出：丢块破坏连续状态，等待会阻塞采集，积压则增大延迟。本书的 `RingBuffer` 采用“丢最旧样本”的可见基线，并累计 `dropped`；它用来说明容量和溢出语义，不是无锁实时队列。

`simulate_deadline_queue` 用一条串行工作队列区分三件事：处理完成晚于本帧期限、队列达到高水位、容量已满而丢帧。平均 RTF 小于 1 仍可能出现其中任何一种。正式设备还要记录驱动报告的 `underrun/overrun`（合称 `xrun`）、线程优先级、CPU 频率策略和并发负载。

参考接口可按下表检查：

| 模块              | 启用条件             | 主要输入                                      | 主要输出                                       | 首要检查                                              |
|-----------------|------------------|-------------------------------------------|--------------------------------------------|---------------------------------------------------|
| 采集与同步           | 多通道输入需要保持时序关系    | 麦克风、时钟                                    | 对齐的多通道脉冲编码调制（Pulse-Code Modulation, PCM）样本 | 映射、削波、丢帧、相对时延                                     |
| AEC             | 本机播放可能进入麦克风      | 麦克风；播放处理之后、DAC/功放之前的 render tap；远端活动/双讲状态 | 回声减弱的麦克风信号、残余回声与适配状态                       | 参考是否覆盖混音/EQ/音量、参考一麦克风风整体延迟、削波、双讲稳定性               |
| WPE             | 晚期混响影响任务         | 多通道或单通道 STFT                              | 去混响 STFT                                   | 预测延迟、阶数、语音损伤                                      |
| 定位/追踪           | 波束或应用需要方向/轨迹     | 多通道特征、活动状态、测量时间                           | 坐标系、测量/发布时间、状态与协方差、活动/存在概率、轨迹 ID 与有效期      | 坐标变换、过期外推、漏检/虚警、ID 生命周期；接口细节见 § 9.4               |
| GSS 掩码/SCM/解析波束 | 已知活动日志且需要多人空间增强  | 分割活动标注、多通道 STFT、GSS 掩码、目标/干扰 SCM 或方向      | 每目标增强信号、条件数/有效样本诊断                         | diarization→掩码→SCM→BF 的依赖不能省略；掩码不是 SCM，方向只控制解析 BF |
| 神经分离/CSS/TSE    | 重叠内容需多流，或有可靠目标条件 | 多通道特征；可选注册语音、视觉或方向条件                      | 固定/动态输出流、单目标音轨                             | 左右上下文、首帧延迟、跨块排列、身份泄漏、域外泛化；它是解析波束的替代路径             |
| NS/AGC          | 残余噪声或电平范围影响后端    | 增强信号                                      | 抑噪、稳电平信号                                   | 语音损伤、增益抽动、削波                                      |
| KWS/ASR         | 应用需要关键词检测或语音识别   | 音频或特征                                     | 事件或文本                                      | 取点、缓存、误报与漏报                                       |

## 10.2 拾音、同步与增益

麦克风选型至少要看自噪声、声学过载点、灵敏度、频响和通道一致性。单个器件的典型值不能代替整机测试：声孔、密封、挡板、电源噪声和装配偏差都会改变阵列响应。

脉冲密度调制（Pulse-Density Modulation, PDM）、芯片间音频总线（Inter-IC Sound, I<sup>2</sup>S）和时分复用（Time-Division Multiplexing, TDM）是常见数字接口，但一根数据线能承载多少通道取决于器件、时钟和控制器配置，不能只按接口名称判断。阵列处理还要确认通道是否共享采样时钟、帧同步是否一致，以及驱动是否会独立丢样。

16 位、24 位和 32 位浮点描述的是数字样本格式。32 位浮点便于保留中间动态范围，不能提高麦克风的声学过载点，也不能消除模拟前端的底噪或削波。某些录音设备以浮点文件保存多增益通路合成后的信号，但这仍不等于“无需增益设计”。

### 10.2.1 SRO：先区分初始时差和采样率偏移

设参考设备采样率为  $f_s$ ，另一设备满足  $f_{\text{device}} = f_s(1 + \varepsilon)$ 。经过  $T$  秒后，两路时间轴的相对漂移一阶近似为

$$\Delta t(T) = \varepsilon T. \quad (10-2)$$

100 ppm（parts per million，百万分之一）即  $\varepsilon = 100 \times 10^{-6}$ 。若不校正，1 秒累积 100  $\mu\text{s}$ ，10 分钟累积 60 ms。这里的 60 ms 是时间轴长期累积的错位，不能直接当成每一秒都存在的到达时间差（Time Difference of Arrival, TDOA），也不能据此直接换算成固定的波达方向（Direction of Arrival, DOA）偏差。定位退化取决于重对齐周期、分析窗、频带、阵列孔径和估计器。

工程处理分三步：

1. 估计相对速率；
2. 按估计值重采样；
3. 持续跟踪温漂。

互相关峰漂移、相位漂移或专用导频都可用于估计。更新周期和允许残差应由最长连续运行时间、相干性要求及任务指标反推，不宜照搬固定 ppm 门槛。

能够共享硬件时钟时，应优先消除 SRO 来源；不能共享时钟时，再评估在线补偿。

初始时差表现为整条“延迟—时间”曲线的截距，稳定 SRO 表现为斜率，偶发丢样则表现为阶跃。三者不能只靠首尾两个点可靠区分。工程上可分块估计互相关峰，先检查峰值置信度，再对可信的“时间—相对延迟”点做直线拟合；残差中若出现近似一个或多个采样间隔的突跳，应先查丢样和时间戳，而不是把所有变化都拟合成 ppm。

[estimate\\_sro\\_ppm](#) 把相对延迟定义为“参考时间减设备时间”，再拟合截距和斜率；正斜率表示设备采样率较高，与 [resample\\_sro\\_to\\_reference](#) 的符号一致。若横轴使用参考时间，精确斜率为  $\varepsilon/(1 + \varepsilon)$ ；函数按小偏移的一阶近似把斜率乘  $10^6$  报为 ppm，在音频设备常见的几十至数百 ppm 范围内用于教学。要求更高时应反解  $\varepsilon = s/(1 - s)$ ，其中  $s$  是拟合斜率。重采样函数用线性插值演示长度和方向；线性插值没有足够的带外抑制，只适合教学检查。设备实现要换成有抗混叠滤波和跨块状态的异步采样率转换器，并测量补偿后的相位残差。

### 10.2.2 增益变化与 AEC

AEC 前的时变增益会改变它要辨识的等效回声路径。设计时应记录每一级增益位于参考取点之前还是之后，并确保 AEC 能获知或跟踪这些变化。常见做法是：AEC 收敛和双讲期间保持前置增益稳定；发生削波风险时允许保护性衰减，同时重置或减小自适应步长。锁定时间、解锁条件和允许步进都应通过本机回声路径和双讲集确定，不存在通用的秒数或 dB 阈值。

阵列标定应覆盖相对增益、相位/时延和麦克风坐标。位置误差造成的相位误差为

$$\Delta\phi = 2\pi f \Delta r/c. \quad (10-3)$$

例如  $\Delta r = 0.5 \text{ mm}$ 、 $f = 4 \text{ kHz}$ 、 $c = 343 \text{ m/s}$  时， $\Delta\phi \approx 2.1^\circ$ 。这说明高频和深零陷波束更敏感，不表示 0.5 mm 是所有产品的统一公差。

标定不能止于得到一组系数。可执行流程应包含：确认通道编号和设备时间戳；在多个已知方向播放宽带信号；估计相对增益、固定时延和随频率变化的相位；核对实际麦克风坐标与坐标系；把系数连同设备序列、采样率、温度和标定日期保存；最后在未参与拟合的方向复测波束图和 DOA。更换声孔、密封件、麦克风或采集板后，要重新判断旧系数是否仍适用。

### 10.3 NS、控制信号与唤醒分支

#### 10.3.1 单通道 NS 的方法和边界

单通道 NS 常放在波束输出之后，因为此处计算量较小，也不会反过来破坏传统 AEC 的线性关系。但联合增强网络、多通道掩码估计或为定位专设的增强支路可能采用不同顺序。应依据训练输入和模块假设决定取点。

| 方法                                                                                | 基本思想           | 主要风险          |
|-----------------------------------------------------------------------------------|----------------|---------------|
| 谱减                                                                                | 从带噪功率谱中减去噪声估计  | 谱下限过低会产生音乐噪声  |
| 维纳滤波                                                                              | 按估计信噪比设置频点增益   | 噪声和先验信噪比估计滞后  |
| 子空间法                                                                              | 分离语音主子空间与噪声子空间 | 阶数估计和矩阵分解成本   |
| 最小均方误差短时谱幅度估计（Minimum Mean-Square Error Short-Time Spectral Amplitude, MMSE-STSA） | 最小化短时谱幅度的均方误差  | 分布假设与参数估计失配   |
| 最小均方误差对数谱幅度估计（Minimum Mean-Square Error Log-Spectral Amplitude, MMSE-LSA）         | 最小化对数谱幅度的均方误差  | 低信噪比下仍可能有语音损伤 |
| 神经网络掩码/映射                                                                         | 从数据学习谱或波形映射    | 域外噪声、伪影和内容改变  |

MMSE-STSA 和 MMSE-LSA 不是同一目标：前者估计短时谱幅度，后者在对数谱幅度域定义误差。噪声估计也不必“只在 VAD 判无话时更新”。最小统计量、软语音存在概率和神经网络软掩码都能在语音段缓慢更新；关键是避免把语音持续吸收到噪声模型中。

#### 10.3.2 控制状态不能只看一个 VAD 比特

控制状态需要涵盖近端语音、远端播放和双讲。下表列出这些状态下的更新条件；具体实现可以使用离散状态，也可以使用连续的活动概率。

| 状态      | AEC 自适应          | NS 噪声估计         | 波束/空间统计         | WPE 更新       | ASR/KWS                  |
|---------|------------------|-----------------|-----------------|--------------|--------------------------|
| 仅远端播放   | 参考有效且无削波时可更新     | 残余回声未污染噪声估计时可更新 | 避免把回声当目标        | 视残余回声而定      | 需要播放时唤醒时，KWS 可监听 AEC 后信号 |
| 仅近端语音   | 保持；没有有效远端参考可供辨识  | 软更新或保持          | 更新目标统计，谨慎更新噪声统计 | 可按功率加权更新     | 送入后端                     |
| 双讲      | 由双讲检测降低步长或采用鲁棒更新 | 软更新或保持          | 分离目标与干扰统计       | 不应仅因“有语音”而冻结 | 保留近端语音                   |
| 无近端、无远端 | 保持               | 更新背景模型          | 更新噪声统计          | 按实现选择保持或更新   | 后端可休眠，KWS 是否常开由应用需求决定    |

WPE 正是利用语音及其晚期混响的统计关系估计预测滤波器，不能用“VAD 有话就冻结”作为通用规则。AEC 的控制则必须结合远端活动和双讲检测；仅用近端 VAD 无法判断滤波器是否有可学习的回声参考。

VAD 的迟滞、挂起和预卷缓存应由语料中的短词、停顿和噪声脉冲调节。

KWS 是否绕过 VAD、是否持续运行、从 AEC 后还是增强后取信号，取决于功耗和训练域。

阈值需要在指定误唤醒率下报告漏唤醒率，不能只给一个孤立分数。

10.3.3 VAD 与 AGC 的最小可运行基线

能量 VAD 虽然简单，却能把控制逻辑讲清。启动阈值应高于继续阈值，避免能量在单一阈值附近来回切换；hangover 在能量下降后继续保持若干帧，减少词尾被截断。预卷缓存解决的是词首：VAD 刚触发时，把触发前保留的短时音频一并送给后端。三个时间量都要换算成帧数，并在短词、长停顿和脉冲噪声上分别验证。

`HysteresisVAD` 输入线性均方能量，不接受 dB 阈值；把 dBFS 门限传给它会造成口径错误。`hangover_frames=2` 表示首次跌破继续阈值的两帧仍保持活动，第三帧才关闭。该基线没有噪声自适应、频带特征和神经网络，也不自行保存预卷；预卷可用 `RingBuffer` 保留触发前的固定帧数，并在 VAD 由假变真时先取出缓存。

AGC 要区分“把正常语音逐渐推向目标电平”和“立刻避免削波”。增益上升可以缓慢释放，增益下降需要更快；即使平滑状态来不及下降，当前块也要受安全上限约束。`PeakProtectAGC` 给出这种峰值保护基线。它不估计响度，也不能修复模拟前端已经发生的削波。验收时要同时画输入电平、增益、输出峰值和削波比例，并在 AEC 双讲期间检查增益变化是否破坏回声路径模型。

10.4 定点化、算力与功耗预算

10.4.1 从浮点实现到目标芯片

定点化要检查四件事：

- 数值范围；
- 累加位宽；
- 非线性函数近似；
- 模块间缩放。

协方差矩阵求解与 WPE 线性方程组尤其要观察条件数；对角加载能改善数值稳定性，但加载量应相对矩阵尺度定义。32 位或更宽的累加器可以减少乘加溢出，不能保证病态矩阵求解正确。

训练后量化（Post-Training Quantization，PTQ）先用校准数据确定量化尺度；量化感知训练（Quantization-Aware Training，QAT）在训练中模拟量化误差。选哪一种应由目标芯片的算子、代表性数据上的任务指标和最不利输入测试决定。不能预先承诺固定的指标下降量或加速倍数。

定点格式还要明确舍入和饱和规则。本书的 `q15_quantize` 把  $[-1, 1)$  映射到有符号 Q1.15：乘 32768、按最近偶数舍入，再饱和到  $[-32768, 32767]$ 。因此  $-1$  可以精确表示， $+1$  只能饱和为 32767/32768。`q15_dot` 用 64 位整数累加乘积，只在输出时除以  $2^{15}$ 、按最近偶数舍入并饱和；目标 DSP 若使用不同累加位宽或逐乘积舍入，就不应期待 bit-exact 相同。测试既要覆盖正常小数，也要覆盖  $\pm 1$ 、超范围输入和累加器极值；不能只比较平均误差。

SIMD（单指令多数据）优化从数据布局开始。连续的频点、通道或抽头便于向量加载，跨步访问和频繁转置会抵消乘加加速。报告 SIMD 收益时要写明标量基线、指令集、编译选项、数组对齐、块尺寸、线程数和是否包含格式转换。运行时派发还要保留标量回退，并让两条路径通过同一组数值容差或 bit-exact 测试；“编译器打开了向量化”不能代替这些检查。

10.4.2 不混用指令数、乘加次数和实时因子

- 每秒乘加次数（Multiply-Accumulate Operations per Second，MAC/s）或每秒百万次乘加（Million MAC/s，MMAC/s）适合描述已经明确算子图和计数规则的算法计算量。
- 每秒百万条指令（Millions of Instructions per Second，MIPS）依赖指令集、并行宽度、存储访问和编译器。同一算法在不同处理器上的 MIPS 不可直接比较。
- RTF 定义为处理时长除以音频时长。RTF 小于 1 只说明平均速度足够；还要检查单帧最坏耗时、调度抖动和队列增长。

“帧耗时/帧长”得到的是 RTF，不是等效 MIPS。预算表应记录测量平台和版本：

| 模块   | 配置与输入尺寸        | MAC/s 或分析复杂度 | 最坏帧耗时   | RTF     | 峰值内存  | 平均/峰值功率 |
|------|----------------|--------------|---------|---------|-------|---------|
| 示例模块 | 麦数、采样率、帧长、模型版本 | 在同一计数规则下统计   | 在目标芯片实测 | 同一段音频实测 | 高水位实测 | 功率仪实测   |

电池容量应换算为能量。若标称电压为  $V$ 、容量为  $C_{Ah}$ ，标称能量近似为  $E = VC_{Ah}$  Wh，其中 Wh (watt-hour) 表示瓦时。续航估算为

$$t \approx \frac{E\eta}{P_{avg}}, \tag{10-4}$$

其中  $\eta$  包含可用容量、转换效率和老化裕量， $P_{avg}$  是包含占空比的整机平均功率。只给毫安时 (mAh) 而不给电压和平均功耗，无法推出续航。

### 10.5 评测体系

每项指标只能回答一部分问题。面向完整系统的评测通常还需覆盖任务效果、语音质量、稳定性、资源占用和长时间运行。

| 对象    | 可用指标                                                                                                                                                                                          | 不能单独说明什么                                      |
|-------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------|
| AEC   | 回声返回损失增强 (Echo Return Loss Enhancement, ERLE)、双讲恢复、残余回声主观分                                                                                                                                    | ERLE 高不等于近端语音无损                               |
| 定位    | 角误差、漏检率、虚警率、均方根误差 (Root Mean Square Error, RMSE)                                                                                                                                              | 单源 RMSE 不代表多人追踪稳定                             |
| 波束/分离 | 尺度不变信号失真比 (Scale-Invariant Signal-to-Distortion Ratio, SI-SDR)、串扰；多输出转写用 cpWER、ORC-WER 或 sa-WER                                                                                               | 单个客观分不代表听感或内容正确；多输出指标的排列/身份口径见第 11 章“多人重叠”决策表 |
| 说话人分割 | 分割错误率 (Diarization Error Rate, DER)、Jaccard 错误率 (Jaccard Error Rate, JER)                                                                                                                     | 必须固定 collar、重叠计分、参考区域和评分工具版本；分割正确不等于分离内容正确    |
| 增强    | 短时客观可懂度 (Short-Time Objective Intelligibility, STOI)、旧研究复现中的感知语音质量评估 (Perceptual Evaluation of Speech Quality, PESQ)、感知客观听音质量分析 (Perceptual Objective Listening Quality Analysis, POLQA)、主观听测 | 客观模型可能在新失真上失真                                 |
| 追踪    | 最优子模式分配距离 (Optimal Sub-Pattern Assignment, OSPA)、轨迹完整度、轨迹中断/碎片数、轨迹身份切换 (ID switch)                                                                                                            | 位置准确不等于身份连续；OSPAs 的 $p, c$ 和角度距离见 § 9.4       |
| 系统    | 端到端延迟、RTF、功耗、崩溃/丢帧                                                                                                                                                                            | 平均值不代表末尾延迟和最坏状态                               |

OSPAs 把定位误差与目标数量错误合成一个集合距离；经典 OSPA 本身不保留身份标签，因此不能用它代替轨迹身份切换指标。报告还应给出轨迹中断/碎片数、ID 切换和关联规则，而不是用一个集合距离覆盖全部时序失败。

ITU-T 已于 2024 年 1 月 5 日撤销 P.862 (PESQ)，并在官方页面指向 P.863 (POLQA)。因此，PESQ 适合在必须对照旧论文时按原条件复现；新的标准合规性表述不应把 P.862 写成现行建议书。P.863 是现行的客观语音质量建议书，但其适用范围和版本仍需随正式报告记录。

ITU-T P.835 (07/2026) 用于对含噪语音处理系统做主观听测，分别评价语音信号 (Signal, SIG)、背景噪声 (Background, BAK) 和总体效果 (Overall, OVRL)。它适合区分“噪声是否减弱”和“语音是否受损”，但不能直接评价 DOA、轨迹身份或空间位置。正式报告应写明标准版本、听测材料、听众筛选、播放设备和统计区间。

ITU-T P.566 (07/2026) 的官方条目将其列为“已生效，待发布” (in force / to be published) 的单端机器学习多维语音质量模型。在正式文本发布前，本书不从二手资料扩写输出维度或评分细则。P.566 的单端客观预测不能代替 P.835 主观听测，也不评价 DOA、轨迹或空间位置。

### 10.6 数据、仿真与复现

公开数据集适合建立可复现基线，不能代替目标设备录音。选择数据时要核对采样率、麦克风几何、房间、说话人数、重叠率、参考真值和许可证。训练、调参、最终测试应按房间或说话人隔离，避免相邻片段泄漏。

录音和声纹还要有数据治理清单：

- 记录采集目的与用户同意范围；

- 区分原始音频、转写文本、声纹嵌入和调试日志；
- 说明数据在端侧还是云侧处理，传输与静态存储怎样加密，哪些角色可以访问；
- 规定保留期限、删除与撤回流程；
- 导出故障样本前做身份信息检查；
- 第三方数据集按许可证限制保存和再分发。

目标说话人提取使用的注册声纹可能比普通缓存更敏感，不能因为只保存嵌入而默认无法关联个人。

具体法律和认证要求取决于部署地区与产品用途，应由相应合规审查确认。

房间冲激响应仿真也要写全条件。以下代码按 [pyroomacoustics 0.10.0](#) 编写，说明 `max_order` 与混响时间的关系；安装命令见项目 README：

```
import pyroomacoustics as pra

room_dim = [6.0, 5.0, 3.0]
target_rt60 = 0.45
absorption, max_order = pra.inverse_sabine(target_rt60, room_dim)
room = pra.ShoeBox(
    room_dim,
    fs=16000,
    materials=pra.Material(absorption),
    max_order=max_order,
)
```

`inverse_sabine` 根据目标混响时间  $T_{60}$  和房间尺寸给出吸收参数及建议的镜像源截断阶数； $T_{60}$  表示声能衰减 60 dB 所需的时间。

这里的 `target_rt60=0.45` 是设计目标，不是已经测得的仿真结果。生成房间冲激响应（Room Impulse Response, RIR）后，还应由 RIR 的 Schroeder 能量衰减曲线估计实际  $T_{60}$ ，并报告拟合区间。衰减动态范围不足时，不应把短区间外推值写成直接测得的 60 dB 衰减时间。

`max_order` 控制镜像反射的截断深度，不能单独决定  $T_{60}$ 。可逐步增加 `max_order`，直到测得  $T_{60}$ 、RIR 总能量和目标任务结果在预定容差内不再明显变化。若始终不收敛，应调整房间或仿真方法，而不是只抬高阶数。

论文或报告还应记录：

- 目标与实测  $T_{60}$ ；
- 声源和麦克风坐标；
- 材料模型、随机种子与噪声生成方法；
- pyroomacoustics 版本和拟合方法。

## 10.7 分布式阵列

分布式系统要分别解决三类问题：

1. 时间轴：初始时差、SRO、丢包和网络抖动要分开估计。长录音首尾对齐只能发现累计误差，不能代替运行时监测。
2. 坐标与增益：节点位置、朝向、通道增益和频响决定导向矢量能否共用。节点移动后要更新几何。
3. 融合：集中式波束需要传多通道信号或统计量，对同步和带宽要求高；通道选择和识别结果融合要求较低，但损失空间信息。应把弱节点加入后的退化列为测试项。

验收阈值应由网络带宽、最长会话和目标任务确定。例如，要求一小时内相位相干的系统与只做句级识别的系统，对残余 SRO 的要求不会相同。

10.8 阵列形态与场景约束

公开产品的麦克风数量、位置和算法会随硬件版本及地区型号变化。若没有可追溯的一手资料，不应从拆解照片推断算法链。本教程因此只讨论可迁移的设计条件：

| 场景               | 先确认的约束                                                 | 可能启用的模块                      | 必测状态                    |
|------------------|--------------------------------------------------------|------------------------------|-------------------------|
| 带扬声器的音箱/<br>会议终端 | 播放声压、参考取点、覆盖角                                          | AEC；按混响决定 WPE；按覆盖<br>决定定位/波束 | 远端单讲、近端单讲、双讲、<br>音乐播放   |
| 会议室              | 房间混响、座位分布、重叠说话比例                                       | 多波束或分离；晚期混响明显时用<br>WPE       | 单人、抢话、键盘/空调、不同<br>座位    |
| 车载               | 舱位、车速相关噪声、多个时钟域                                        | 分区波束、SRO 补偿、参考完整<br>的 AEC    | 怠速、行驶、开窗、空调、音<br>乐与通话并发 |
| 耳机/助听设备          | 上下行路径、佩戴泄漏、低延迟和电池约束                                    | 固定/自适应双麦波束、NS、反馈<br>抑制       | 不同佩戴、风噪、自己说话、<br>最坏增益   |
| 机器人              | 运动自噪声、阵列姿态、惯性测量单元（Inertial<br>Measurement Unit，IMU）时间戳 | 运动前馈、姿态补偿、定位/追踪              | 静止、转头、行驶、风扇/电机<br>变速    |
| 手机/手持设备          | 握持、遮挡、横竖屏、通话模式                                         | 通道选择、波束/NS、模式切换              | 手指挡孔、风噪、贴脸、免<br>提、录像    |

球阵的可用球谐阶数同时受空间采样、阵列半径、频率和模态噪声放大限制。这里  $k = 2\pi f/c$  是波数， $r$  是球阵半径， $kr$  是无量纲频率。

表示到  $N$  阶的完整球谐系数共有  $(N + 1)^2$  个，因此离散阵元数至少要能支撑相应的空间采样；实际还要留出几何和数值稳定性余量。

可用阶数在高频受阵元空间混叠限制，在低频又受  $kr$  较小和径向滤波噪声放大限制。不能用  $N = \lceil kr \rceil + 1$  一条式子替代完整设计，也不能把“某阶需要多少系数”直接等同于任意摆放的同数麦克风一定可用。

三个非共点麦克风已经构成阵列。若几何非共线，它们能提供二维空间信息；若接近共线，则某些方向存在镜像或条件数问题。手机的主要限制通常是孔径小、结构遮挡和工作模式变化，而不是“三麦构不成阵列”。

10.9 从模型到设备

部署前先固定输入尺寸、算子版本、量化方式和线程配置，再测算力与内存。模型参数从 32 位浮点量化到 8 位整数时，参数存储在理想情况下约缩小四倍；端到端速度取决于硬件是否有相应整数内核、访存和算子融合，不能据此承诺“快四倍”。

低功耗常驻任务和高算力按需任务可以分开：例如 KWS 在低功耗处理器上运行，唤醒后再启动 ASR 或分离网络。但 AEC、波束、WPE 是否常驻取决于是否需要持续边播边听、录音或通话，不应把“唤醒前关闭完整前端”写成固定方案。

端侧、云侧或混合部署要比较隐私、断网可用性、网络尾延迟、更新能力和能耗。对品牌产品的实现方式没有公开证据时，只能写成候选架构，不能当作产品事实。

10.9.1 开源实现怎样用作工程对照

开源项目解决的是链路中的不同部分，不能因为都能处理音频就横向替换。下面只列本书正文能够说明用途和边界的项目；固定来源、提交、许可证和核实日期统一记录在 `codes/SOURCES.lock.json`，代码、模型权重和数据集许可证分别检查。

| 官方项目                                  | 可以对照什么                                       | 不能由它证明什么                     |
|---------------------------------------|----------------------------------------------|------------------------------|
| <a href="#">WebRTC AEC3 固定提交</a>      | 实时 AEC 的延迟估计、线性消除和残余回声抑制分工，详见 § 6.1.9        | 不能把内部常数当成本产品阈值，也不覆盖阵列定位和 WPE |
| <a href="#">PortAudio 19.7.0 固定提交</a> | 跨平台设备枚举、阻塞与回调式音频输入输出；该提交按官方 Release Notes 定位 | 不负责跨设备同步、重采样、AEC 或波束形成       |

| 官方项目                                        | 可以对照什么                                            | 不能由它证明什么                           |
|---------------------------------------------|---------------------------------------------------|------------------------------------|
| <a href="#">pyroomacoustics 0.10.0 发布记录</a> | 房间、RIR、DOA 与波束的 Python 原型                         | 仿真通过不等于目标设备达到实时性或实录效果              |
| <a href="#">nara_wpe 0.0.11 发布记录</a>        | 离线、块在线和递归 WPE 的接口对照                               | 安装命令不能证明所选接口因果，也不能证明当前 Python 环境兼容 |
| <a href="#">ONNX Runtime 固定源码快照</a>         | 模型执行、执行提供程序和量化后的设备部署；链接固定到本轮核实的完整提交，不把未发布版本写成正式发布 | 它是运行时，不定义 NS、分离或波束算法的训练目标          |

WebRTC 与 PortAudio 规模较大，本仓库不复制其源码。需要对照时按锁定清单获取，并在隔离环境构建。`codes/array_tutorial/` 中的程序是本书教学基线，作用是复算约定和边界；它们不冒充上游项目，也不构成产品性能承诺。

模型落地时还要固定输入采样率、通道顺序、块长、动态轴、归一化、状态张量、算子集、运行时版本和线程配置。冷启动测量包含模型读取、图优化、权重上传和首轮内核准备；稳定运行延迟要在 warm-up 后另测。更新模型前保存可回滚版本，并用同一硬件、同一数据和同一计时范围比较。

### 10.10 联调与验收

联调应按依赖关系排查，不必强行把所有模块串成一个固定顺序。

| 阶段      | 检查内容                           | 验收口径怎样确定                     |
|---------|--------------------------------|------------------------------|
| 采集      | 通道映射、时间戳、削波、丢帧、自噪声、SRO         | 由器件规格、最长运行时间和下游容差确定          |
| AEC     | 参考对齐、路径覆盖、单讲收敛、双讲稳定、路径变化恢复     | 分别报告 ERLE、近端损伤和恢复时间；覆盖目标播放状态 |
| WPE     | 晚期混响衰减、直达声损伤、长时稳定              | 在目标房间和说话距离上与关闭 WPE 对照        |
| 定位/追踪   | 角误差、漏检、虚警、人数、轨迹身份切换、轨迹中断       | 按覆盖区和应用允许误差设线，包含交叉与遮挡        |
| 波束/分离   | 目标保持、干扰抑制、失配鲁棒性、串扰             | 同时报任务指标与语音损伤，不只报 SI-SDR      |
| NS/AGC  | 噪声残留、语音损伤、抽动、削波                | 覆盖噪声类型和输入电平，补 P.835 主观听测     |
| KWS/ASR | 指定误报率下的漏报率、WER/CER、首尾截断        | 使用目标语言、距离、噪声、说话人和播放状态        |
| 系统      | 关键路径延迟、RTF、峰值内存、平均/峰值功耗、长时间稳定性 | 在目标硬件、发布配置和最不利并发状态实测         |

每个验收阈值都应包含测量条件、统计量和样本量。例如“角误差小于 5°”还要说明声源角度分布、距离、房间、信噪比，以及该数值是均值还是某个分位数。教程中的算例只能用于验证计算，不能直接作为产品验收阈值。

在线监控应记录足以定位故障、但不默认保存原始语音的字段。本书给出的 `telemetry_schema.json` 采用以下口径；它是最小示例，不含用户身份、转写文本或原始音频。

| 字段组                                                    | 单位与统计口径                     |
|--------------------------------------------------------|-----------------------------|
| <code>timestamp_ns</code> 、 <code>frame_index</code>   | 单调采集时钟域；时间戳指本帧首样本，不是墙上时间    |
| <code>queue_depth</code>                               | 发布该条记录时仍在等待的帧数，不含正在执行的帧     |
| <code>xrun_count</code> 、 <code>dropped_samples</code> | 从流启动起的累计值；丢样按时间样本计，不按通道展开   |
| <code>clipping_fraction</code>                         | 本帧所有通道标量样本中的削波比例            |
| <code>sro_ppm</code>                                   | 相对指定参考设备、在已配置估计窗内得到的采样率偏移   |
| <code>rtf</code> 、 <code>deadline_miss</code>          | 本帧关键路径处理时长除以音频时长，以及是否越过本帧期限 |
| <code>agc_gain</code> 、 <code>model_version</code>     | 本帧线性幅度增益；完整有序模型链的稳定版本标识     |

`simulate_deadline_queue` 的 `queue_high_water` 包含正在处理的帧，故不能直接写进上表的等待队列深度。实际产品若要记录敏感内容，应按 § 10.6 的同意、访问、保留和删除规则另行设计。

故障注入要对应恢复动作。固定延迟跳变用于检查 AEC 重对齐；单通道增益或相位扰动用于检查标定和波束鲁棒性；插入或删除样本用于区分丢样与 SRO；CPU 负载脉冲用于检查队列、尾延迟和降级；截断或 NaN 模型输出用于检查旁路和重置。每次试验都要记录注入位置、持续时间、期望状态转换和恢复时间，不能只确认进程没有崩溃。

常见故障可按依赖关系缩小范围：

| 现象          | 先查                    | 再查                |
|-------------|-----------------------|-------------------|
| 播放时残余回声突然增大 | 参考取点、整体延迟、削波、前置增益变化   | 滤波器长度和双讲控制        |
| 语音发闷或辅音丢失   | NS 增益、WPE 预测延迟、AGC 抽动 | 波束指向失配和标定         |
| 定位随时间缓慢漂移   | 时钟域、SRO、丢样            | 几何和温漂后的标定         |
| 唤醒差但 ASR 正常 | KWS 取点、缓存、训练域和阈值曲线    | VAD 是否错误截断 KWS 输入 |
| 平均实时但偶尔爆音   | 最坏帧耗时、调度抖动、缓冲下溢       | 平均 RTF 和内存带宽      |

### 10.11 本章小结

1. 图 23 是参考依赖图，不是所有设备必须执行的固定流水线。
  2. 延迟、算力和续航必须在目标硬件上按明确口径测量；窗口长度、MIPS 和 mAh 不能互相替代。
  3. 门控至少要区分近端语音、远端播放和双讲；单个 VAD 比特不足以控制 AEC、WPE 和全部后端。
  4. 固定阈值和品牌案例不能替代项目条件。每个验收数字都要带场景、统计口径和来源。
-

第 11 章 · 总结与选型指南

选型应从任务和约束开始。同一个四麦阵列用于固定座位通话、多人会议或机器人跟随时，合适的处理链可能完全不同。本章先确定目标，再选择几何和模块，最后按第 10 章的方法验证。

本章常用缩写如下：

| 缩写       | 中文名与英文全称                                                 |
|----------|----------------------------------------------------------|
| DOA      | 波达方向（Direction of Arrival）                               |
| AEC      | 声学回声消除（Acoustic Echo Cancellation）                       |
| WPE      | 加权预测误差去混响（Weighted Prediction Error）                     |
| NS / VAD | 噪声抑制（Noise Suppression）/语音活动检测（Voice Activity Detection） |
| RTF      | 实时因子（Real-Time Factor）                                   |
| SRO      | 采样率偏移（Sampling Rate Offset）                              |

各定位、波束和追踪算法的全称在首次出现处给出。

11.1 先回答六个问题

1. 系统要输出什么？ 输出一个方向、连续轨迹、增强语音、彼此独立的多人语流、指定目标的一条语流，还是识别文本？多人输出还要说明人数固定还是随时间变化、整句处理还是连续流、是否需要保持说话人身份。输出不同，所需模块不同。只做固定方向录音时，不需要在线定位；只做方向显示时，也未必需要波束形成和 NS。
2. 覆盖区域和声源距离是什么？ 线阵适合重点覆盖阵列轴所在平面或扇区，但会有前后或镜像歧义；圆阵适合水平面环绕覆盖；平面阵与球阵可提供俯仰信息，但需要更多通道和更严格的标定。形态不是按“几只麦”直接决定的。
3. 空间分辨率和最高工作频率是什么？ 孔径影响角分辨率，阵元间距限制无空间混叠频带。增大孔径有利于低频方向信息，减小间距有利于高频无混叠。两者冲突时，可以增加阵元、限制工作频带或采用非均匀几何；不能只报一个间距就宣称覆盖全频带。
4. 有哪些干扰？ 本机播放造成回声时才需要 AEC；晚期混响妨碍任务时再考虑 WPE；多人重叠且要输出独立语流时才考虑分离；稳定背景噪声可能用解析 NS 即可，复杂域外噪声则要验证神经网络的泛化。
5. 目标是否移动、人数是否变化？ 单个慢速目标可从简单平滑或卡尔曼滤波开始。人数变化、交叉和遮挡要求显式处理轨迹出生、消失和数据关联。概率假设密度（Probability Hypothesis Density，PHD）滤波、带标签多伯努利（Labeled Multi-Bernoulli，LMB）滤波或其他随机有限集方法不会因“人数多”自动成为合适方案；还要考虑观测模型、身份连续性要求和实现成本。
6. 硬件和合规边界是什么？ 写明采样率、麦数、时钟域、算力、峰值内存、功耗、关键路径延迟、隐私和认证要求。使用注册声纹或云端录音时，还要写明同意、访问、保留和删除方式，见第 10 章 § 10.6。每秒百万条指令（Millions of Instructions per Second，MIPS）不能脱离处理器型号比较，电池续航要用瓦时（Wh）与整机平均功耗估算，见第 10 章 § 10.4。

11.2 按条件选择模块

| 决策对象   | 适合先尝试的方案                                                                                                                                  | 何时换方案                                                                                                                                                             | 同时检查的风险         |
|--------|-------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------|
| 单源 DOA | 广义互相关相位变换（Generalized Cross-Correlation with Phase Transform，GCC-PHAT）或导向响应功率相位变换（Steered Response Power with Phase Transform，SRP-PHAT）基线 | 需要更高分辨率且协方差条件满足时，评估多重信号分类（Multiple Signal Classification，MUSIC）或旋转不变子空间（Estimation of Signal Parameters via Rotational Invariance Techniques，ESPRIT）；复杂混响下可评估学习方法 | 阵列歧义、混响、宽带融合、虚警 |

| 决策对象   | 适合先尝试的方案                                        | 何时换方案                                                                                                                               | 同时检查的风险                                 |
|--------|-------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------|
| 固定方向增强 | 延时求和或固定超指向（superdirective）波束                    | 噪声场变化且统计量可估计时，评估最小方差无失真响应（Minimum Variance Distortionless Response, MVDR）或线性约束最小方差（Linearly Constrained Minimum Variance, LCMV）波束形成 | 白噪声增益、方向失配、标定                           |
| 自适应波束  | MVDR 或 LCMV 加稳健化                                | 目标相对传递函数或导向矢量难以估计时，评估掩码辅助或联合模型                                                                                                      | 协方差秩、对角加载、目标泄漏                          |
| 晚期混响   | 先用关闭 WPE 的基线                                    | 晚期混响确实限制词错误率（Word Error Rate, WER）、可懂度或听感时启用 WPE                                                                                    | 预测延迟、阶数、直达声损伤                           |
| 本机回声   | 有播放泄漏时启用 AEC                                    | 非线性扬声器、路径变化或多扬声器时增加相应建模                                                                                                             | 参考取点、整体延迟、双讲                            |
| 多人重叠   | 只需一路增强时先试多波束选择或掩码波束                             | 需要保留重叠中的全部语音内容时评估分离/CSS；只需指定一人且有可靠目标条件时评估 TSE                                                                                       | 最大同时说话数、固定/变化总人数、整句/连续流、跨块排列、身份、内容改变、算力 |
| 轨迹平滑   | $\alpha$ - $\beta$ 或卡尔曼滤波                       | 多目标交叉、漏检和虚警明显时换多目标滤波                                                                                                                | 坐标系、时间戳、轨迹身份切换、轨迹中断                     |
| 残余噪声   | 维纳或最小均方误差（Minimum Mean-Square Error, MMSE）等解析基线 | 非平稳噪声下基线不足时评估神经 NS                                                                                                                  | 语音损伤、域外噪声、下游 WER                        |

算法名只确定了方法类别，还没有确定参数。WPE 的预测延迟和阶数、MVDR 的加载量、AEC 的滤波器覆盖范围、VAD 的挂起时间都应由目标数据和硬件测量得到，不应作为通用默认值从别的产品复制。

多人重叠场景可按下面的决策维度缩小范围：

下表使用三种不同的识别口径：

- 拼接最小排列词错误率（Concatenated minimum-Permutation Word Error Rate，cpWER）先按说话人拼接参考与假设，再寻找一个全局最优的说话人排列；
- 最优参考组合同词错误率（Optimal Reference Combination Word Error Rate，ORC-WER）允许参考语句在输出流之间做最优组合，不要求一条输出流全程对应同一个人；
- 说话人归属词错误率（Speaker-Attributed Word Error Rate，sa-WER）把词转写与说话人标签一起评价，归属错误会影响结果。

三者不能互换：ORC-WER 偏向检查内容是否被完整识别，cpWER 还要求全局输出流一致，sa-WER 用于确实需要身份归属的任务。

实现时还要记录分段与重叠处理、标记规则，以及固定的评分工具版本或提交。本文核实于 2026-09-22，并将 MeetEval 对 cpWER、ORC-WER、MIMO-WER 和 DI-cpWER 的算法说明钉在提交 [6e3dc81284f2d6928f7ef9e620fd3b6906daa429](#)；该锁定文档没有把 sa-WER 列作同一工具的实现，使用 sa-WER 时应另行固定定义与评分器。复现实验还应记录实际安装包版本或完整提交号，不能只写会移动的 `main`。

| 任务条件  | 一路波束/掩码波束            | 连续语音分离（CSS）                    | 目标说话人提取（TSE）            |
|-------|----------------------|--------------------------------|-------------------------|
| 需要的输出 | 一路增强音频               | 固定或少量无重叠输出流；同一路可在不同时段承载不同说话人   | 被注册语音、视觉或方向指定的一人        |
| 人数变化  | 可跟随一个选中目标；不负责完整输出所有人 | 总参会人数可多于输出流数；流数由最大同时说话数和系统设计决定 | 非目标人数可变化，但目标条件必须持续有效    |
| 时间范围  | 可逐帧或分块在线处理           | 连续长录音；必须说明分块、上下文和拼接            | 可整句或流式；需报告注册和首帧延迟       |
| 身份连续  | 由追踪/分割模块提供           | 分离槽位不等于永久身份，通常还需分割或声纹关联        | 目标条件提供身份线索，但会受注册信道和冒用影响 |

| 任务条件 | 一路波束/掩码波束        | 连续语音分离（CSS）                        | 目标说话人提取（TSE）          |
|------|------------------|------------------------------------|-----------------------|
| 主要验收 | 目标保持、串扰、语音损伤、WER | 重叠段遗漏、跨块换人、cpWER/ORC-WER/sa-WER、延迟 | 目标遗漏、非目标泄漏、错误目标、隐私与删除 |

这张表比较的是任务条件，不表示 CSS 或 TSE 一定优于解析波束。若应用只消费一路音频，多输出分离会增加排列和资源问题；若应用要完整转写未知参会者，要求预先注册每个人的 TSE 又会成为功能性限制。

### 11.3 几何与算法要一起选

阵列几何决定观测中有哪些空间信息，算法决定如何使用这些信息。

- 双麦或近似线阵：可以估计沿阵列轴投影的时差并形成方向性，但某些方向会有镜像歧义。适合已知目标扇区、孔径和外形受限的设备。
- 非共线三麦及平面阵：能提供二维几何约束。精度仍受孔径、频带、遮挡和标定影响，不能把“三麦”简单归为单麦处理。
- 圆阵：便于覆盖水平面。阵元数和半径应由所需角分辨率、最高频率与结构尺寸共同确定，不存在“全向必须至少四麦、六麦最好”的通用答案。
- 球阵或三维阵：适合需要俯仰角、声场分析或多方向波束的任务。可用球谐阶数受阵元采样、无量纲频率  $kr$  ( $k = 2\pi f/c$  为波数， $r$  为球阵半径)、径向滤波噪声放大和标定误差共同限制，详见 § 10.8。
- 稀疏阵：差分共阵可增加二阶统计中的虚拟滞后数，但不会凭空增加独立物理通道，也不保证宽带、相干声源和有限快拍下都能得到同样的自由度。应按第 3 章的适用条件验证。

白噪声增益（White Noise Gain，WNG）和指向性指数（Directivity Index，DI）之间常有取舍。更窄的波束或更深的零陷可能放大传感器自噪声和标定误差。对角加载、WNG 约束和限制工作频带都能改善鲁棒性，但通常会牺牲一部分空间选择性。

### 11.4 四个场景怎样推导方案

下表给的是推导方法，不是产品清单。

| 场景        | 条件变化             | 方案怎样变化                                                          |
|-----------|------------------|-----------------------------------------------------------------|
| 带扬声器的语音终端 | 若要求播放时仍能唤醒或通话    | AEC 成为必要候选；参考取在实际播放处理之后。圆阵、线阵或平面阵由覆盖区域和外形决定。无明显晚期混响时不必默认加 WPE。  |
| 会议室       | 若多人重叠较少，只需一路会议音频 | 先比较多波束选择和自适应波束。只有重叠说话造成任务失败，且需要独立语流时，再增加分离。远距离和长混响房间要用实测决定 WPE。 |
| 车载        | 若麦克风跨多个时钟域       | 先解决 SRO 和时间戳，再谈分区波束。播放参考需覆盖音乐、导航和通话混音。算法要在怠速、行驶、开窗和空调状态分别测试。    |
| 耳机或助听设备   | 若监听路径对延迟和电池很敏感   | 监听与通话上行可采用不同链路。固定双麦波束和轻量 NS 是候选基线，不是必选答案；法规、反馈路径、佩戴变化和听觉安全优先。   |

同一场景也可能得出不同答案。例如会议设备安装在墙边时，覆盖区域可能只有半空间；放在桌中央时则要覆盖周向。前者可能适合线阵或弧形阵，后者可能适合圆阵。覆盖区域确定后，才能据此选择阵列形态和麦克风数量。

### 11.5 把候选方案写成可验证的规格

为了复现实验并比较方案，候选方案的规格应覆盖以下内容：

| 项目 | 应写内容                 |
|----|----------------------|
| 任务 | 输入、输出、目标声源数、是否需要身份连续 |
| 几何 | 坐标、尺寸公差、声孔和遮挡、工作频带   |
| 场景 | 距离、角度、房间、噪声、播放和运动状态  |

| 项目   | 应写内容                          |
|------|-------------------------------|
| 链路   | 每个模块的启用条件、取点、旁路和控制信号          |
| 资源   | 目标硬件上的 RTF、最坏帧耗时、峰值内存、平均/峰值功耗 |
| 延迟   | 前瞻、缓冲、计算、调度和解码关键路径            |
| 指标   | 任务指标、语音损伤、稳定性、置信区间和样本量        |
| 异常处理 | 通道失效、方向低置信度、网络断开和算力过载时的行为     |

可以先建立最小基线，再一次增加一个模块。增加模块后要同时检查收益、语音损伤、延迟、功耗和失败样例。

如果 WPE 没有改善目标房间的结果，或分离网络虽然提高了尺度不变信号失真比（Scale-Invariant Signal-to-Distortion Ratio, SI-SDR）却增加了内容错误，就不应因为流程图里画了它而保留。

开源实现也要按任务筛选。项目名称不能代替算法条件：PortAudio 解决设备输入输出，不解决跨设备同步；ONNX Runtime 执行模型，不规定模型训练目标；pyroomacoustics 适合房间与阵列原型，不证明目标设备实时；WebRTC AEC3 可以对照实时回声链路，但其内部参数不是其他产品的默认值。选择开源项目时应把规范仓库、固定提交或发布、许可证、支持平台、输入输出契约、维护状态和最小测试一起写入方案，详见 § 10.9.1 与 [codes/SOURCES.lock.json](#)。

本书代码使用三种标记：短小且可由公式独立复算的“教学实现”、调用固定外部版本的“适配器”、不复制大型上游源码的“参考索引”。教学实现通过单元测试，只能说明约定和边界算例正确；它没有经过目标设备的实时、长稳、合规和主观听测，不能直接标成工业实现。

**完整决策例：未知参会者的连续转写。**假设会议中共有 2~6 名未注册说话人，人数随时间变化，但任一时刻最多两人同时说话。系统要连续输出全部内容给 ASR，并要求端到端延迟可测但尚未给定阈值。先用硬约束筛选，再进入实测：

| 条件或证据              | 一路掩码波束              | 两路 CSS                               | 注册声纹 TSE                  | 决定                |
|--------------------|---------------------|--------------------------------------|---------------------------|-------------------|
| 必须保留重叠双方内容         | 单路输出可能丢失其中一人，未通过硬约束 | 两路分别承载同一时刻最多两人的语音，设计目标与要求一致          | 每次只提取已指定目标，未通过“全部未知说话人”约束 | 保留两路 CSS 候选       |
| 总参会人数为 2~6 人且随时间变化 | 可选择当前目标，但不输出完整集合    | 不同说话人可在不同时段复用两路输出；需验证静默流和跨块排列        | 需事先获得每位目标条件，本场景没有         | 记录 CSS 的人数与槽位管理风险 |
| 连续长录音              | 可流式                 | 必须报告块长、左右上下文、拼接和状态重置                 | 模型若支持可流式，但功能约束已淘汰         | 对 CSS 设置延迟测试项     |
| 身份与识别评测            | 单路 WER 不能评价重叠双方     | 报 ORC-WER 或 cpWER；若要求身份再报 sa-WER     | 需另测错误目标和声纹冒用              | 先按无注册转写口径验收       |
| 资源与质量证据            | 作为低成本基线保留           | 在目标硬件测 p50/p95/p99 延迟、RTF、内存、遗漏和内容错误 | 功能约束不满足，不参加性能比较           | CSS 只有实测净收益后才采用   |

这个例子中，2~6 是整场会议的总参会人数，两路输出由“最多同时两人重叠”决定，二者并不冲突；输出槽位也不代表永久说话人身份。例子没有填写性能分数，因为算力和准确率必须在目标硬件与目标会议数据上测量。

若需求改成“始终只听主持人，且主持人可注册”，硬约束会改变，TSE 才重新成为候选。

## 11.6 练习

### 题 1：带播放的周向语音终端

需求是水平面周向覆盖，设备会播放音乐，主要任务是唤醒和单人指令。请写出候选几何、必要模块和两个关键对照实验。

**答案要点：**圆阵是候选，不应在没有孔径与频带要求时先定麦数。播放时仍需拾音，因此要评估 AEC，并确保参考覆盖播放处理。定位或多方向固定波束可用于周向选择；WPE 和分离不是默认必选。关键对照至少包括“静音播放与音乐播放下的唤醒曲线”和“AEC 开关下的近端语音损伤及残余回声”。

## 题 2：多人会议

房间混响明显，偶尔有人抢话，只输出一路会议音频。什么时候需要 WPE，什么时候需要分离？

答案要点：先在目标房间比较关闭/开启 WPE 后的 WER、可懂度和语音损伤；晚期混响限制任务且净收益稳定时才启用。若多波束或掩码波束已经满足一路输出的串扰要求，不必因为存在重叠就输出独立语流；只有重叠段仍造成不可接受的任务失败，且应用需要保留各说话人内容时，再评估分离网络。

## 题 3：跨时钟车载阵列

四只麦克风分属两个时钟域。为什么不能先调波束权重？应该先测什么？

答案要点：相对 SRO 会让通道相位关系随时间漂移，固定权重和导向矢量很快失配。应先测初始时差、累计漂移、丢样和时间戳稳定性，完成重采样或时钟同步后再标定几何与增益，最后调波束。验收要覆盖温度和长时间运行，而不是只看一段短录音。

## 题 4：把空间带宽、同步与延迟放进同一张选型表

候选四麦均匀线阵间距为 4 cm，声速取 343 m/s，需求频带上限为 4 kHz。两个采集设备的最坏相对 SRO 为 80 ppm，目前每 5 min 才重新对齐一次，而允许的通道错位不超过 0.1 ms。连续处理路径的采集/分帧、前瞻、计算、调度和解码分别为 16、8、22、5、70 ms；候选分离器若串行加入，还会增加 48 ms 前瞻和 18 ms 计算。要求端到端延迟小于 150 ms。判断阵元间距、同步周期、基础路径和分离器是否满足硬约束。

答案要点：

1. 阵元间距：空间混叠边界为  $f_{\text{alias}} = c/(2d) = 343/(2 \times 0.04) \approx 4288$  Hz，因此 4 kHz 仍低于该理想远场边界，但余量只有约 288 Hz，实际还要考虑麦位误差与宽带过渡。
2. 同步周期：80 ppm 经过 300 s 的漂移为  $80 \times 10^{-6} \times 300 = 0.024$  s，即 24 ms，远超 0.1 ms；若只靠周期性重对齐，最大间隔应不超过  $0.1 \text{ ms} / (80 \times 10^{-6}) = 1.25$  s。
3. 基础路径：总延迟为  $16 + 8 + 22 + 5 + 70 = 121$  ms，满足 150 ms，但只剩 29 ms 裕量。
4. 加入分离器：串行加入后为  $121 + 48 + 18 = 187$  ms，不满足约束；除非通过并行、流水、减少前瞻或更换后端重新测得关键路径低于 150 ms，否则不应启用该候选。

## 11.7 后续阅读

要实现算法，可回到第 4~9 章查看定位、波束、AEC、WPE、分离和追踪。要制定整机预算和验收计划，见第 10 章。附录 A 汇总符号与数学工具，附录 B 给出进一步阅读、练习和排错入口。

附录 A · 符号术语数学

本附录沿用 12.1~12.3 的节号，便于与正文既有引用对应；下一篇是附录 B。

12.1 符号表

约定同 § 2.3：斜体 = 标量，头顶箭头 = 向量，加粗大写 = 矩阵； $^H$  表示共轭转置， $^\top$  表示转置， $\hat{\phantom{x}}$  表示估计值。 $X(f)$ 、 $X(f_k, \ell)$  这类大写字母按语音文献惯例表示逐频点复数标量。

本书采用前向傅里叶核  $e^{-j2\pi ft}$ 。

阵列坐标约定为：麦 1 位于  $\boldsymbol{x} = \mathbf{0}$ ，麦 2 位于  $+\boldsymbol{x}$ ；正横为  $0^\circ$ ，正角朝麦 2； $\vec{\boldsymbol{u}}$  从阵列指向声源，传播方向为  $-\vec{\boldsymbol{u}}$ 。

字母复用（与 § 2.3 一致）：受文献惯例所限， $\boldsymbol{k}$  可表示频点索引、波数或 WPE 的滞后帧号； $\boldsymbol{D}$  可表示阵列孔径或 PHD 强度函数； $\lambda$  可表示波长、WPE 功率谱或矩阵特征值； $\boldsymbol{K}$  可表示声源数或 WPE 预测阶数； $\boldsymbol{s}$  可表示源信号或追踪状态。具体含义以所在公式的定义为准。需要区分 STFT 网格时，本书用  $\boldsymbol{k}$  表示频点索引、 $f_k = \boldsymbol{k}f_s/N$  表示对应的 Hz 频率、 $\ell$  表示帧索引；连续时间仍用  $t$ ，离散采样索引用  $n$ 。

| 符号                                                           | 含义                                                                                                                                                     |
|--------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------|
| $M, d, D$                                                    | 麦数、阵元间距、阵列孔径                                                                                                                                           |
| $c, \lambda, f, f_k$                                         | 声速（ $\approx 343$ m/s）、波长、连续物理频率（Hz）、第 $\boldsymbol{k}$ 个 DFT/STFT 频点对应的物理频率 $f_k = \boldsymbol{k}f_s/N$                                               |
| $\theta, \theta_0$                                           | 正横方向起算的入射角、波束指向角；端射为 $\pm 90^\circ$                                                                                                                    |
| $\vec{\boldsymbol{u}}(\theta)$                               | 从阵列指向声源的单位向量；声波传播方向为 $-\vec{\boldsymbol{u}}$                                                                                                           |
| $\vec{\boldsymbol{r}}_m, \vec{\boldsymbol{p}}$               | 第 $m$ 个麦克风的位置向量、声源位置向量                                                                                                                                 |
| $t, n, \boldsymbol{k}, \ell, T$                              | 连续时间、离散采样索引、频点索引、帧索引、用于统计的快拍数；WPE 等局部公式若复用 $\boldsymbol{k}$ 作滞后号，会在公式旁重新定义                                                                             |
| $\psi$                                                       | 相邻两麦的相位差， $\psi = \frac{2\pi d}{\lambda}(\sin \theta - \sin \theta_0)$ （§ 2.6、§ 5.2）                                                                   |
| $\vec{\boldsymbol{a}}(\theta), \vec{\boldsymbol{w}}$         | 导向矢量、波束权重                                                                                                                                              |
| $\hat{\mathbf{R}}, \mathbf{R}_{nn}, \mathbf{R}_{ss}$         | 空间协方差矩阵、噪声协方差矩阵、目标协方差矩阵                                                                                                                                |
| $\mathbf{\Gamma}$                                            | 弥散噪声相干矩阵， $[\mathbf{\Gamma}]_{ij} = \text{sinc}(2fd_{ij}/c)$ （§ 5.1；球面向各同性口径。声音只从水平面来时对应形状是零阶贝塞尔 $J_0$ ，见 § 5.1 第三段）                                   |
| $\mathbf{E}_n$ ( $\mathbf{E}_s$ )                            | 噪声（信号）子空间的特征向量基（§ 4.6）                                                                                                                                 |
| $\sigma^2$                                                   | 噪声方差/功率（白噪声下协方差为 $\sigma^2 \mathbf{I}$ ）                                                                                                               |
| $\mathbf{C}, \vec{\boldsymbol{f}}$                           | LCMV 约束矩阵与约束值向量， $\mathbf{C}^H \vec{\boldsymbol{w}} = \vec{\boldsymbol{f}}$ （§ 5.5）                                                                    |
| $\vec{\boldsymbol{e}}_r$                                     | 参考麦选择向量（第 $r$ 位为 1 的单位向量，见 § 5.5 参考麦选择，MWF/SDW 用）                                                                                                      |
| $\mathbf{B}$                                                 | GSC 阻塞矩阵，满足 $\mathbf{B}^H \vec{\boldsymbol{a}}(\theta_0) = \vec{\mathbf{0}}$ （§ 5.6）                                                                   |
| $\Phi(f)$                                                    | GCC 加权函数（§ 4.2）vs 功率谱（§ 5.7），语境区分                                                                                                                      |
| $\mathbf{P}, \mathbf{K}, \mathbf{Q}, \mathbf{F}, \mathbf{H}$ | 卡尔曼滤波：误差协方差、卡尔曼增益、过程噪声协方差、状态转移、观测矩阵（§ 9.2）                                                                                                             |
| $V, A, S, \bar{\alpha}$                                      | 房间体积、等效吸声面积、总表面积、平均吸声系数（§ 2.4）                                                                                                                         |
| $\mu_{\text{NLMS}}$                                          | 归一化最小均方（Normalized Least Mean Squares, NLMS）步长（§ 6.1）；理想化独立性假设下常讨论 $0 < \mu < 2$ ，实际取值还受输入相关性、正则项和时变路径影响                                               |
| $\mu_{\text{SDW}}$                                           | 语音失真加权多通道维纳滤波（Speech-Distortion-Weighted Multichannel Wiener Filter, SDW-MWF）的失真—降噪折中系数（§ 5.5）；与上一行的 NLMS 步长不是同一物理量                                    |
| $\varepsilon_{\text{NLMS}}$                                  | 归一化最小均方（Normalized Least Mean Squares, NLMS）更新分母中的小正数，用于防止输入能量接近零时除零（§ 6.1）                                                                            |
| $\delta, \eta$                                               | 绝对对角加载 $\mathbf{R} + \delta \mathbf{I}$ 中的 $\delta$ 与 $\mathbf{R}$ 同量纲；相对加载 $\mathbf{R} + \eta \text{tr}(\mathbf{R})\mathbf{I}/M$ 中的 $\eta$ 无量纲（§ 5.4） |

| 符号                         | 含义                                                                                                                              |
|----------------------------|---------------------------------------------------------------------------------------------------------------------------------|
| $\tau_{ij}$ , TDOA         | $\tau_{ij} = t_i - t_j$ ; 到达时间差 (Time Difference of Arrival, TDOA) 。远场下 $\tau_{m1} = -(\vec{r}_m - \vec{r}_1)^\top \vec{u}/c$   |
| $T_{60}$ , DRR, $d_c$      | 混响时间、直达混响比 (Direct-to-Reverberant Ratio, DRR; dB 域读数)、临界距离                                                                      |
| WNG, DI, HPBW, SLL         | 白噪声增益 (White Noise Gain, WNG) 、指向性指数 (Directivity Index, DI) 、半功率波束宽度 (Half-Power Beamwidth, HPBW) 、旁瓣电平 (Side-Lobe Level, SLL) |
| RTF                        | 相对传递函数 (Relative Transfer Function, RTF)                                                                                        |
| $h(n)$ , $\hat{w}$ , ERLE  | 回声路径、AEC 自适应滤波器、回声返回损失增强 (Echo Return Loss Enhancement, ERLE)                                                                   |
| $G(k, f)$ , $\Delta$ , $K$ | WPE 预测系数 (本书为滞后 $k$ 、频点 $f$ 的系数)、保护延迟、预测阶数                                                                                      |
| PHD/RFS                    | 概率假设密度 (Probability Hypothesis Density, PHD) /随机有限集 (Random Finite Set, RFS)                                                    |

3 分钟手算 (12.1) : 在无失真归一化、各通道自噪声独立且等功率时,  $M = 6$  的 DSB WNG 是多少 dB?  $2 \times 2$  对角协方差  $\text{diag}(4, 1)$  的特征值是哪两个数?

答案:  $10 \log_{10} 6 \approx 7.8$  dB; 对角阵的特征值就是对角元 4 和 1。这里的特征向量是两条传感器空间坐标轴, 不一定对应真实空间中的两个入射方向。

## 12.2 术语词典

下表按主题解释正文和相关文献中常见的术语。

### 信号与数学基础

| 术语                         | 解释                                                                                                      |
|----------------------------|---------------------------------------------------------------------------------------------------------|
| STFT (短时傅里叶变换)             | 把波形分成重叠短帧, 并对每帧计算频谱, 得到时间—频率复数表示。窗长与帧移按频率分辨率、时变性和延迟要求选择; 逐频点处理可把宽带问题近似拆成多个窄带问题 ( § 2.5)                 |
| 快拍 (snapshot)              | 某一帧、某一频点上, $M$ 个麦克风复数谱排成的列向量——阵列的一张“空间照片” ( § 2.5)                                                      |
| 空间协方差矩阵 $\hat{\mathbf{R}}$ | 阵列文献常把快拍外积的时间平均称为空间协方差。若未减均值, 它严格说是未中心化二阶矩; 零均值或已经中心化时才等于样本协方差。它是 Capon/MVDR/MUSIC 的共同输入 ( § 2.5)       |
| 特征分解 / 子空间                 | 把厄米矩阵拆成特征值与特征向量。在源协方差满秩、 $K < M$ 、空间白噪声、模型正确且快拍充足时, 较大特征值对应的特征向量张成信号子空间, 噪声底对应的特征向量张成噪声子空间 (图6d、 § 4.6) |
| 超定方程组                      | 方程比未知数多, 通常无精确解、只可求最小二乘解——TDOA 定位的麦对多于未知数时就是这样 (见 § 4.4)                                                |
| 双曲线定位                      | 一对麦测出时延差 $\Leftrightarrow$ 声源在“到两麦距离差为常数”的双曲线上; 多对麦的双曲线交点即声源 (见 § 4.4)                                  |
| 常规波束分辨率 / 超分辨              | 常规波束主瓣宽度的量级约为 $\lambda/D$ ; 子空间方法在模型正确、信噪比和快拍数足够时可形成更窄谱峰, 因此称为超分辨 ( § 2.6、 § 4.6)                       |
| 波束图 (beam pattern)         | 波束形成器对各个方向的增益图, 主瓣/旁瓣/零陷都在上面读 (图7a)                                                                     |
| 自由度 (DOF)                  | 可调参数的个数。 $M$ 麦波束形成器有 $M$ 个复数自由度, 每条约束消耗一个 ( § 5.5) ; 稀疏阵用协同阵 (见本组“差分协同阵”行) 增加虚拟自由度 ( § 3.3)             |
| 抽头 (tap)                   | FIR 滤波器的一个系数。“128 个抽头”表示 128 个系数; 按多项式阶数定义时对应 127 阶, 阅读文献时需核对作者采用的口径 ( § 6.1)                           |
| 优先效应 (precedence effect)   | 直达声之后短时间内到达的反射, 会与直达声共同影响听觉事件, 但方向判断通常更偏向先到声。延迟、声级差和信号类型改变时, 反射仍可能改变音色、清晰度或定位结果 ( § 2.4)                |
| 拉格朗日乘子法                    | 带约束求极值的标准工具: “约束写成等式加到目标里, 再求导令零”, MVDR 的闭式解就是这么推的 ( § 5.4)                                             |

| 术语                | 解释                                                                                                                                                                    |
|-------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 白化<br>(whitening) | 调整各频率分量的幅度，使其贡献更均衡。GCC-PHAT 通过幅度归一化主要保留互功率谱相位，可减弱源谱着色，但不会消除反射产生的多径相位（§ 4.2）                                                                                           |
| sinc 函数           | 本书定义 $\text{sinc}(x) = \sin(\pi x)/(\pi x)$ 。球面各向同性弥散场中的两麦相干系数具有 sinc 形式；若声源只在水平面各向同性分布，则对应零阶贝塞尔函数 $J_0(2\pi f d/c)$ （§ 5.1）。另一些文献把 sinc 定义为 $\sin x/x$ ，代入公式前必须先核对定义 |
| SNR（信噪比）          | 信号功率与噪声功率之比，常以 dB 表示。输出 SNR 减去输入 SNR 得到 SNR 增益。SER 在 AEC 语境中比较近端目标与回声功率，使用时应明确分子、分母和测量时段（§ 5.1、§ 6.1）                                                                 |
| dB（分贝）            | 比值的对数表示；功率比使用 $10 \log_{10}$ ，幅度比使用 $20 \log_{10}$ 。两种写法只有在功率与幅度平方成正比且参考阻抗一致时才对应同一物理变化（详见 § 12.3 ②）                                                                   |
| FFT（快速傅里叶变换）      | 离散傅里叶变换的高效算法，把一帧时域样本转换为各频点的复数谱；STFT 对连续短帧重复这一运算（§ 2.5）                                                                                                                |
| DNN（深度神经网络）       | 由多层参数化变换组成、通过数据优化的模型。本教程主要用于估计时频掩码、方向概率或增强信号（§ 4.7、§ 5.9）                                                                                                             |
| 远场 / 近场           | 远场中波前可近似为平面，导向模型主要由方向决定；近场采用球面波模型，还要考虑距离和通道幅度差。 $2D^2/\lambda$ 可作为检查波前相位曲率的距离尺度，但不是单独决定远近场的硬边界；还要检查 $r \gg D$ 、允许的相位误差和通道幅度差（§ 2.2）                                   |

房间声学

| 术语                                      | 解释                                                                                                                                                          |
|-----------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|
| RIR（房间脉冲响应）                             | 在指定声源、接收位置和系统近似线性时，RIR 描述从声源到麦克风的声学传递路径；干净信号与 RIR 卷积可得到该路径下的接收信号（§ 2.4）                                                                                     |
| $T_{60}$                                | 混响时间：房间声能衰减 60 dB 所需时间。具体数值取决于房间体积、表面吸声和测量频带                                                                                                                |
| 直达混响比（Direct-to-Reverberant Ratio, DRR） | 直达声能量 ÷ 混响声能量，dB 域读数：DRR (dB) >0 直达占优，DRR (dB) <0 混响占优；负值绝对值越大，混响能量相对越高                                                                                     |
| 临界距离 $d_c$                              | 在给定声源指向性与扩散场假设下，直达声和混响声能量相等、即 DRR=0 的距离；Sabine 近似下常写成 $d_c \approx 0.057\sqrt{QV/T_{60}}$ ，其中 $Q$ 是声源指向因子。取全向声源 $Q = 1$ 时才化为 $0.057\sqrt{V/T_{60}}$ （§ 2.4） |
| 镜像法                                     | 把墙面反射等效成墙后镜像声源的仿真方法（Allen & Berkley 1979），pyroomacoustics 的核心                                                                                               |
| 弥散噪声场                                   | 来自大量方向、没有单一主导入射方向的声场模型。晚期混响常用这一模型近似；麦克风附近的湍流风噪通常不满足各向同性弥散场假设                                                                                                |

自适应滤波、增强与分离

| 术语               | 解释                                                                                                                                                                                |
|------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| LMS / NLMS / RLS | 最小均方（Least Mean Squares, LMS）结构简单；归一化最小均方（Normalized LMS, NLMS）按输入功率归一化步长；递归最小二乘（Recursive Least Squares, RLS）利用输入相关矩阵的递推逆，通常收敛更快，但计算量和存储量也更大。实际差距取决于输入相关性、滤波长度和参数设置（§ 5.6、§ 6.1） |
| 音乐噪声             | 谱减类方法过度估计噪声后残留的随机孤立谱峰，听起来像叮咚作响的流水声（§ 5.7）                                                                                                                                         |
| ICA / IVA / PIT  | ICA 利用源间统计独立性估计解混矩阵；IVA 把同一输出在各频点的分量组成向量联合估计，以降低频点间排列不一致；PIT（排列不变训练）在训练时选择与参考源匹配代价最小的输出排列（§ 8.1）                                                                                  |

波束形成与阵列度量

| 术语                     | 解释                                         |
|------------------------|--------------------------------------------|
| 导向矢量 $\vec{a}(\theta)$ | “如果声音从 $\theta$ 来，各麦应该是什么相位”的标准答案向量（§ 2.3） |
| 转向（steering）           | 把波束对准某个方向：按导向矢量补偿各通道时延/相位                  |
| 主瓣 / 旁瓣 / 零陷           | 波束图中目标指向附近的主要响应区、主瓣外的局部峰，以及响应接近零的方向（图 7a）  |

| 术语                                                             | 解释                                                                                                                                                                                                                                                             |
|----------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 栅瓣                                                             | 空间采样混叠产生的高旁瓣；均匀线阵在特定间距和转向下可出现与主瓣等高的方向歧义（§ 2.6、图 7b）                                                                                                                                                                                                            |
| 白噪声增益（White Noise Gain, WNG）                                   | 衡量波束权重对各通道独立等功率白噪声的放大或抑制；在目标方向无失真归一化下， $M$ 元 DSB 达到 $10 \log_{10} M$ dB（§ 2.6）                                                                                                                                                                                 |
| 指向性指数（Directivity Index, DI）                                   | 指定各向同性弥散场与归一化口径下的方向性收益（§ 2.6）                                                                                                                                                                                                                                  |
| 半功率波束宽度（Half-Power Beamwidth, HPBW）/旁瓣电平（Side-Lobe Level, SLL） | HPBW 是主瓣两个 -3 dB 点间的角宽；SLL 是最高旁瓣相对主瓣的电平（§ 2.6、§ 5.2）                                                                                                                                                                                                           |
| CRLB / CRB（克拉美－罗下界，Cramér－Rao Lower Bound）                     | 给定概率模型和正则条件下，无偏估计器方差的下界；模型、参数化或偏差条件改变，下界也改变（§ 2.6）                                                                                                                                                                                                             |
| MVDR（最小方差无失真响应）                                                | 在 $\vec{w}^H \vec{a} = 1$ 的约束下最小化输出噪声功率。它保护目标方向或 RTF，同时压低噪声（§ 5.4）                                                                                                                                                                                             |
| MWF（多通道维纳滤波）                                                   | 直接最小化参考目标与输出之间的均方误差，允许目标缩放来换取更小总误差。秩一目标模型下，MWF 可分解成 MVDR 空间滤波器乘一个标量维纳后滤波器，但两者不是简单的“加不加约束”关系。对本书 $\vec{w}_{\text{SDW}} = (\mathbf{R}_{ss} + \mu \mathbf{R}_{nn})^{-1} \mathbf{R}_{ss} \vec{e}_r$ 的定义， $\mu = 1$ 是标准 MWF； $\mu$ 增大时更重视降噪并趋向零输出，而不是趋向 MVDR（§ 5.5） |
| 相对传递函数（Relative Transfer Function, RTF）                        | 各通道相对参考通道的声学传递响应；是否包含早期反射取决于估计目标和时间窗，混响中 MVDR 常保护 RTF 而不是自由场导向向量（§ 5.4）                                                                                                                                                                                        |
| 对角加载                                                           | 求逆前在协方差矩阵上增加对角项，以改善条件数并降低对失配的敏感性。绝对加载写成 $\mathbf{R} + \delta \mathbf{I}$ ，相对加载写成 $\mathbf{R} + \eta \text{tr}(\mathbf{R}) \mathbf{I} / M$ ；两种参数的量纲和缩放行为不同（§ 5.4、§ 12.3）                                                                                        |
| 相干源                                                            | 内容高度相关的多个源（直达声 + 强反射）。MUSIC 遇相干源会失效（§ 4.6）                                                                                                                                                                                                                     |
| 空间平滑                                                           | 把线阵切成重叠子阵分别估协方差再平均，牺牲孔径换去相干（§ 4.6）                                                                                                                                                                                                                             |
| 差分协同阵                                                          | 由全部阵元位置差组成的虚拟位置集合；结合二阶统计重构，可在条件满足时获得长于物理阵列的连续虚拟孔径（§ 3.3）                                                                                                                                                                                                       |
| GEV 波束形成器                                                      | 最大化输出信噪比的波束形成器（广义特征值问题的解），与 MVDR（见本组 MVDR 行）并列的掩码后处理选项（§ 5.9）                                                                                                                                                                                                  |
| GSS（导引源分离）                                                     | 利用方向或说话人活动信息引导空间聚类与波束形成的分离方法；常用 cACGMM 估计时频掩码，并用活动标注约束输出排列（§ 8.1）                                                                                                                                                                                              |
| WDO（W-不相关正交）                                                   | 一种近似假设：不同说话人的主要能量在时频平面上较少重叠。假设接近成立时，可通过逐时频点估计主导声源来构造分离掩码；强混响或多人同时发声会削弱这一近似（§ 8.1）                                                                                                                                                                              |

### 定位与追踪

| 术语                                      | 解释                                                                                                                                                  |
|-----------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------|
| 到达时间差（Time Difference of Arrival, TDOA） | 本书定义 $\tau_{ij} = t_i - t_j$ ；同一声源到达一对麦克风的带符号时间差，是远场和近场定位的重要观测量（§ 2.1）                                                                              |
| DOA（波达方向）                               | 声从哪个方向来，一般指角度。TDOA 是两路麦克风信号的到达时间差；紧凑阵列中常为几十到几百微秒。远场模型下，可结合麦克风间距和声速把 TDOA 换算成入射角（§ 4.1、§ 4.4）                                                        |
| ITD / ILD                               | 双耳时间差（Interaural Time Difference, ITD）/双耳声级差（Interaural Level Difference, ILD）。双重理论把低频细结构 ITD 与高频 ILD 视为主要线索，但不是硬分界：低频可有 ILD，调制高频声也可提供包络 ITD（§ 1.1） |
| HRTF                                    | 头相关传递函数：头、耳廓和躯干对声音的方向相关滤波；其谱形是判断俯仰和减少前后混淆的重要线索之一，并非唯一线索（§ 1.1）                                                                                      |
| 鸡尾酒会效应                                  | 人类在多人嘈杂环境中选择性聆听的能力；对应机器的波束形成 + 语音分离（§ 1.1、§ 8.1）                                                                                                    |
| GCC-PHAT                                | 广义互相关 + 相位加权：把两路信号错位到最像，峰值位置即时间差（§ 4.2）                                                                                                             |

| 术语                                            | 解释                                                                                                                   |
|-----------------------------------------------|----------------------------------------------------------------------------------------------------------------------|
| SRP-PHAT                                      | 遍历候选位置并汇总各麦对 PHAT 相关值的定位方法，是常用的稳健基线之一（§ 4.3）                                                                         |
| Capon / MUSIC / ESPRIT                        | Capon 逐方向计算最小方差谱；MUSIC 利用导向矢量与噪声子空间的正交性形成伪谱；ESPRIT 利用阵列的平移不变结构直接估计参数。三者的协方差、源数和几何条件不同（§ 4.5、§ 4.6）                   |
| GDOP（几何精度因子）                                  | 同样的时延误差经过不同几何布局会产生不同的位置误差。阵列孔径较小、麦对基线方向单一或目标位于不利方位时，几何误差放大通常更明显（§ 4.4）                                               |
| VAD（语音活动检测）                                   | 判断“当前帧有没有人在说话”，给定位/更新做门控                                                                                             |
| 时频掩码（Time-Frequency Mask, TF-mask）            | 定义在时频网格上的权重或选择函数，用于加权目标、干扰或噪声统计量。二值掩码和理想比值掩码常限制在 $[0, 1]$ ，但复值掩码、幅度比掩码及某些网络输出可以超出该区间；使用时必须写明类型、取值域和作用对象（§ 5.4、§ 5.9） |
| 新息（innovation）                                | 卡尔曼滤波里“观测－预测”的差，用它修正状态估计（§ 9.2）                                                                                      |
| EKF（扩展卡尔曼滤波） / UKF（无迹卡尔曼滤波）                   | 两种非线性卡尔曼滤波。EKF 用雅可比做局部线性化；UKF 让一组 sigma 点通过非线性函数。UKF 可减小某些非线性变换的近似误差，但不保证总比 EKF 稳或准，仍取决于模型、调参和数值实现（§ 9.2）            |
| JPDA / MHT                                    | 多目标追踪中解决“观测属于谁”的两类经典方法：联合概率数据关联 / 多假设跟踪（§ 9.3）                                                                       |
| 锥面模糊                                          | 线阵只观测方向在阵列轴上的投影，同一时延可对应绕阵列轴的一圈方向；平面阵的两侧则是法向镜像歧义，二者不要混为一种（§ 3.1）                                                      |
| FIR 滤波器                                       | 有限长冲激响应滤波器：输出 = 输入最近若干样本的加权和，抽头数（抽头见本表“信号与数学基础”组）就是加权长度（§ 5.1、§ 6.1）                                                 |
| 重采样（粒子滤波）                                     | 把权重小的粒子删掉、权重大的复制，防粒子退化（§ 9.2 算例 9-2 下集）                                                                              |
| 概率假设密度（Probability Hypothesis Density, PHD）滤波 | 传播随机有限集（Random Finite Set, RFS）的一阶矩（强度函数）。某一区域上 $D(\vec{x})$ 的积分给出该区域内目标数的期望值；实际目标状态常从强度峰或高斯分量提取，峰的个数本身不等于人数（§ 9.3）  |
| OSPA（最优子模式分配距离）                               | 多目标追踪误差度量，同时罚定位误差和人数错误（§ 10.5 评测指标表）                                                                                 |

系统与硬件

| 术语                                           | 解释                                                                   |
|----------------------------------------------|----------------------------------------------------------------------|
| AEC                                          | 声学回声消除（Acoustic Echo Cancellation, AEC）：用已知的播放信号做参考，估计回声副本再相减（§ 6.1） |
| DTD（双讲检测）                                    | 检测近端语音与远端播放同时活动的状态，用于冻结、减小步长或切换到稳健的 AEC 更新策略（§ 6.1）                  |
| 回声返回损失增强（Echo Return Loss Enhancement, ERLE） | 衡量远端单讲时回声功率被降低多少；目标值取决于设备、声学路径、非线性和测量窗口，不能用一个通用区间代替验收条件（§ 6.1）       |
| WPE                                          | 加权预测误差去混响：用过去帧预测晚期混响拖尾再减掉（§ 7.1）                                     |
| SI-SDR / STOI / PESQ / WER                   | 分离增强失真比 / 可懂度 / 主观质量预测 / 识别错误率（§ 10.5 评测指标表）                         |
| SDR / SIR / SAR                              | BSS_eval 三件套：总失真 / 干扰残留 / 算法伪影的分解指标（语音分离论文常用）                        |
| MEMS 麦克风                                     | 使用微机电工艺制造的微型麦克风，是小型阵列中的常见器件（§ 10.2）                                  |
| PDM / I2S / TDM                              | 常见数字音频接口。单线承载的通道数、时隙和位宽由具体控制器及协议配置决定；阵列通道应共享或校准采样时钟（§ 10.2）          |
| dBA                                          | A 计权声级：按规定的 A 计权频率响应处理后得到的声级。它不是未加权 dB，比较数据时要核对参考量和计权方式（§ 10.2）      |
| AOP（声学过载点）                                   | 在数据手册规定的失真阈值和测试条件下，麦克风可承受的最大声压级；比较器件时必须同时核对阈值、频率和供电条件（§ 10.2）        |
| 孔径（aperture）                                 | 阵列的最大跨度 $D$ ；分辨率 $\approx$ 波长/孔径                                     |
| 阵列流形（manifold）                               | 全体候选方向或位置的导向矢量集合，即阵列的方向响应模型；几何定义见 § 2.3，实测标定见 § 3.4 与 § 10.2         |

| 术语              | 解释                                                                                                                                |
|-----------------|-----------------------------------------------------------------------------------------------------------------------------------|
| AFE（音频前端）       | Audio Front End：位于采集与识别、通信或交互后端之间的音频处理部分，可包含 AEC、去混响、波束、降噪和电平控制；实际模块由任务决定（§ 10.1）                                                 |
| 双讲（double-talk） | 远端播放与近端用户同时发声。近端语音出现在麦克风或误差信号中，不应出现在理想的远端参考信号中；它会使 AEC 的误差不再只含路径失配，因此需用 DTD 控制自适应更新（§ 6.1）                                        |
| MOS（平均意见分）      | 按规定听测流程收集受试者评分并取统计量。量表、问题、材料和受试者筛选由具体标准规定；客观模型只能在其验证范围内近似预测主观质量（§ 10.5）                                                           |
| CHiME           | 面向复杂声学场景的公开挑战系列，不同届次覆盖远场识别、会议转写、分离或增强等不同任务；数据生成方式和指标应按届说明读取（附录 B 13.2）                                                            |
| KWS（关键词唤醒）      | Keyword Spotting：检测预设关键词的模型。可作为低功耗常驻任务，也可与 VAD、AEC 或增强共享前端；取点和运行方式由功耗及训练数据决定（§ 10.3、§ 10.9）                                       |
| BOM（物料成本）       | Bill of Materials：设备所用元器件的采购成本总和。增加麦克风还可能增加接口、结构、标定和计算成本（§ 11.1）                                                                  |
| HATS（人工头）       | Head and Torso Simulator：带耳廓与躯干声学模型的测量假人，麦克风置于鼓膜位置，用于模拟“人听到的效果”的客观测量（§ 10.5）                                                      |
| NLP（非线性处理）      | Non-Linear Processing：AEC 里接在线性滤波器之后的残余回声抑制（谱减式/神经式），对付扬声器非线性失真等线性滤波器消不掉的部分（§ 6.1）；注意与自然语言处理（Natural Language Processing）同缩写，语境区分 |
| PBFDAP          | 分区块频域自适应滤波：把长回声路径分块并用 FFT 计算卷积与更新。相对时域实现能节省多少计算取决于滤波长度、分块、FFT 库和硬件（§ 6.1.3）                                                       |
| IPNLMS          | 改进比例 NLMS：按抽头幅度分配各系数的更新量。常见定义中，混合系数 $\alpha = -1$ 退化为 NLMS， $\alpha = 1$ 接近纯比例更新， $\alpha = 0$ 是两部分的折中；具体取值要与所用公式和数据一同验证（§ 6.1.3） |
| CNG（舒适噪声）       | Comfort Noise Generation：残余抑制压得太狠时补回的轻微背景噪声，避免通话“死寂”听感（§ 6.1.9）                                                                   |
| pAEC            | 个性化 AEC：把目标说话人的声纹嵌入作为条件，在双讲中增强目标说话人；定义和隐私要求见 § 6.1.6、§ 6.1.14                                                                     |
| barge-in（打断）    | 设备播放 TTS 或音乐时用户直接说话的交互状态。系统需在自发声期间保留近端语音或唤醒词，并让 VAD/KWS 使用合适的 AEC 后取点（§ 6.1.6）                                                    |
| TCLw            | 加权终端耦合损耗：免提终端回声衰减的测试指标。阈值、信号和收敛窗口必须按产品适用的标准版本及测试条款核对，不能跨标准套用一个固定数值（§ 6.1.8）                                                       |

3 分钟手算（12.2）：幅度减半是多少 dB？功率减半又是多少 dB？这是两个不同的物理变化；§ 12.3 还会说明同一物理变化怎样用幅度比或功率比等价表示。

答案：幅度减半为  $20 \log_{10} 0.5 \approx -6$  dB；功率减半为  $10 \log_{10} 0.5 \approx -3$  dB。前者对应功率变为四分之一，后者对应幅度变为  $1/\sqrt{2}$ 。

## 12.3 预备知识速览

本节为零基础读者准备，只讲“够用”的程度。

### ① 复数与相位——为什么信号要用复数表示

本书用  $e^{+j2\pi ft}$  表示正频率复正弦，并采用前向傅里叶变换  $X(f) = \int x(t)e^{-j2\pi ft} dt$ 。复数可写成  $z = Ae^{j\phi}$ ，且  $e^{j\phi} = \cos \phi + j \sin \phi$ 。

在此约定下，延迟  $\tau$  对应乘子  $e^{-j2\pi f\tau}$ 。对麦 1 参考的远场导向矢量， $\tau_{m1} = -(\vec{r}_m - \vec{r}_1)^\top \vec{u}/c$ ，所以

$$a_m = e^{-j2\pi f\tau_{m1}} = e^{+j2\pi f(\vec{r}_m - \vec{r}_1)^\top \vec{u}/c}。$$

若采用相反傅里叶约定，相关公式的相位符号也要整体改变，不能只改其中一式（§ 2.3、§ 4.2）。

### ② 分贝 dB——比值的对数表示

能量比用  $10 \log_{10}(\cdot)$ ，幅度比用  $20 \log_{10}(\cdot)$ 。系数相差一倍，是因为相同阻抗下功率与幅度平方成正比。

因此，同一物理变化用两种比值表示时，dB 数相同：幅度变为 0.5 时功率变为 0.25， $20 \log_{10} 0.5 = 10 \log_{10} 0.25 \approx -6 \text{ dB}$ 。

| dB     | 幅度比                           | 功率比                          |
|--------|-------------------------------|------------------------------|
| +6 dB  | $\times 2$                    | $\times 4$                   |
| +3 dB  | $\times 1.41 \ (\sqrt{2})$    | $\times 2$                   |
| 0 dB   | $\times 1$                    | $\times 1$                   |
| -3 dB  | $\times 0.707 \ (1/\sqrt{2})$ | $\times 1/2 \ (\text{半功率点})$ |
| -6 dB  | $\times 1/2 \ (\text{幅度减半})$  | $\times 1/4$                 |
| -20 dB | $\times 0.1$                  | $\times 0.01$                |

对数把连乘转为相加，便于表示跨越多个数量级的增益、信噪比和衰减。

dB 练习：① 功率先乘 4 再乘 2，总增益是多少 dB？② 电压增益为 -6 dB 时，幅度比约为多少？

答案：①  $10 \log_{10}(4 \times 2) \approx 9 \text{ dB}$ ；② 幅度约减半，功率约为原来的四分之一。

SNR 换算例。目标功率为 3、噪声功率为 1 时，线性 SNR 为 3，对应  $10 \log_{10} 3 \approx 4.8 \text{ dB}$ 。若处理后输出 SNR 为 12 dB，则 SNR 增益约为  $12 - 4.8 = 7.2 \text{ dB}$ 。输入 SNR、输出 SNR 和 SNR 增益是三个不同的量（§ 5.1）。

③ 卷积与相关

卷积  $y = x * h$  表示信号  $x$  经过线性时不变系统  $h$  后的输出；在固定声源和接收位置的近似下， $h$  可以取房间脉冲响应（§ 2.4）。

相关  $R(\tau)$  衡量两段信号在相对位移  $\tau$  下的相似度；峰值位置可作为时延候选（§ 4.2）。

傅里叶变换把线性卷积转成频域乘法，配合快速傅里叶变换可降低长卷积的计算量，但分帧、补零和重叠相加仍要按实现条件处理。

④ 期望、方差与协方差矩阵

期望  $E[\cdot]$  表示统计平均；方差描述变量偏离均值的平方平均；协方差描述两个中心化变量共同变化的程度。把  $M$  个麦克风两两协方差排成矩阵，就是空间协方差矩阵。

§ 2.5 的常用估计式未显式减均值，因此在零均值假设下才与协方差相同；否则应称未中心化二阶矩。

⑤ 最小二乘

方程比未知数多时通常没有精确解。最小二乘求使总残差平方最小的  $\hat{\vec{x}}$ ：

$$\min_{\vec{x}} \|\mathbf{A}\vec{x} - \vec{b}\|^2。$$

当  $\mathbf{A}$  满列秩时， $\hat{\vec{x}} = (\mathbf{A}^H \mathbf{A})^{-1} \mathbf{A}^H \vec{b}$ 。秩不足或条件很差时，应使用 Moore-Penrose 伪逆、QR/SVD 或正则化，不能直接求逆。

TDOA 几何解算（§ 4.4）和 WPE 系数估计（§ 7.1）都会用到这一思想。

拉格朗日四步模板 (MVDR)

第 1 步：写拉格朗日函数。复约束必须同时包含约束及其共轭，常写成实值函数

$$L = \vec{w}^H \mathbf{R} \vec{w} + 2 \operatorname{Re}\{\lambda^* (\vec{w}^H \vec{a} - 1)\}。$$

第 2 步：求驻点。对  $\vec{w}^*$  做 Wirtinger 求导并令零，得到  $\mathbf{R} \vec{w} + \lambda^* \vec{a} = 0$ 。

第 3 步：写出比例关系。乘子的命名可吸收共轭与负号，因此得到  $\vec{w} \propto \mathbf{R}^{-1} \vec{a}$ 。

第 4 步：代回约束。用  $\vec{w}^H \vec{a} = 1$  定出比例系数，即得 § 5.4 式(5-3)。LCMV 把标量约束和乘子换成向量形式（§ 5.5）。

Wirtinger 求导。对实值目标函数，可在 Wirtinger 微积分中把  $\vec{w}$  和  $\vec{w}^*$  视为形式上独立的变量，对  $\vec{w}^*$  求偏导并令其为零。§ 5.4 给出了与实部、虚部分别求导等价的完整推导。

## ⑥ 特征值分解

对 Hermitian 协方差矩阵可写  $\mathbf{R} = \mathbf{E}\mathbf{A}\mathbf{E}^H$ 。特征向量是传感器观测空间中的正交主轴，特征值表示沿这些主轴的能量；它们通常不等于真实空间中的 DOA。

MUSIC (§ 4.6) 在独立源、白噪声和模型正确等条件下，把较大的特征值所张成的空间解释为信号子空间，把噪声底对应的空间解释为噪声子空间。

3 分钟手算 (12.3)：协方差  $\begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}$  的特征值和特征向量各是什么？若两个共轭对称的非对角元都变成 0.5，哪个特征值变大？

答案：特征值为 4 和 1，对应特征向量可取  $[1, 0]^T$  和  $[0, 1]^T$ 。非对角元都变为 0.5 后，两个特征值为  $(5 \pm \sqrt{10})/2$ ，约 4.08 和 0.92；通道相关性使特征值间隔增大。

## 病态矩阵与对角加载

当最大、最小奇异值相差很大时，矩阵条件数高，求逆会放大数据和舍入误差。低频小间距的超指向设计 (§ 5.3) 是常见例子。

- 绝对加载写作  $\mathbf{R} + \delta \mathbf{I}$ ， $\delta$  与协方差元素同量纲；
- 相对加载写作  $\mathbf{R} + \eta \text{tr}(\mathbf{R})\mathbf{I}/M$ ， $\eta$  无量纲，整体缩放  $\mathbf{R}$  时加载也同比缩放。

两者都可抬高小特征值，但会改变最优权重和指向性。报告参数时必须说明采用哪一种口径，不能只写一个无单位的 “ $\varepsilon$ ”。

附录 B 第 8 题可比较加载前后的 WNG、DI 与条件数；数值由脚本参数决定，不预设固定区间。

---

13.1 研究生学习路径

下面的阅读与实验顺序从经典模型开始，再过渡到公开基线、数据集和硬件实验。

- 1. 基础阅读：Van Veen & Buckley, *Beamforming: A Versatile Approach to Spatial Filtering* (IEEE ASSP Mag. 1988) ； Krim & Viberg, *Two Decades of Array Signal Processing* (IEEE SPM 1996) 。
- 2. 语音场景：Kumatani et al., *Microphone Array Processing for Distant Speech Recognition*; Gannot et al., *A Consolidated Perspective on Multimicrophone Speech Enhancement and Source Separation* (IEEE/ACM TASLP 2017) 。
- 3. 原始论文：Capon (1969)、Griffiths & Jim GSC (1982, *An Alternative Approach to Linearly Constrained Adaptive Beamforming*, IEEE Trans. Antennas Propag. 30(1):27 – 34)、Schmidt MUSIC (1986)、Roy & Kailath ESPRIT (1989)、Allen & Berkley 镜像法 (1979)、Nakatani et al. WPE (IEEE TASLP 2010)、Pal & Vaidyanathan 嵌套阵 (IEEE TSP 2010) 。
- 4. 回声消除：Hänsler & Schmidt, *Acoustic Echo and Noise Control* (Wiley 2004) ； 近年进展看 ICASSP AEC Challenge 系列报告。
- 5. DNN 方向：Chakrabarty & Habets (IEEE JSTSP 2019)、Gu et al. 全神经波束形成 (IEEE/ACM TASLP, vol.31, pp.849 – 862, DOI 10.1109/TASLP.2022.3229261) 。
- 6. 实验顺序：先运行 `codes/` 中只依赖 NumPy 的教学实现，核对手算、数组维度和边界；再用 `pyroomacoustics` 验证 DSB、MVDR、MUSIC 和 SRP-PHAT 基线；运行 `scripts/` 中的两个绘图脚本，复现 33 张图；随后选择与研究任务匹配的公开数据和固定版本参考系统；最后在可用的多通道硬件上验证实时性、同步和标定。数据集、框架和硬件只是候选工具，应根据任务与许可证选择。

13.2 领域地图：教材、会议、期刊与挑战赛

本节按教材、会议、期刊、挑战赛和历史脉络组织，可按需要查阅。

教材与专著（由浅到深）：

| 书                                                                                                                                                                  | 特点                        |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------|
| Benesty, Chen & Huang, <i>Microphone Array Signal Processing</i> (Springer 2008)                                                                                   | 覆盖阵列模型、定位、波束形成与多通道增强      |
| Brandstein & Ward (eds.), <i>Microphone Arrays: Signal Processing Techniques and Applications</i> (Springer 2001)                                                  | 经典论文式合集，各章由领域奠基人撰写        |
| Tashev, <i>Sound Capture and Processing: Practical Approaches</i> (Wiley 2009)                                                                                     | 从工程视角讨论捕获链路、器件和实现权衡       |
| Johnson & Dudgeon, <i>Array Signal Processing: Concepts and Techniques</i> (Prentice Hall 1993)                                                                    | 通用阵列信号处理经典（雷达/声呐同源理论）     |
| Van Trees, <i>Optimum Array Processing</i> (Wiley 2002)                                                                                                            | 系统推导最优阵列处理，适合查阅数学细节       |
| Vincent, Virtanen & Gannot (eds.), <i>Audio Source Separation and Speech Enhancement</i> (Wiley 2018)                                                              | 分离与增强方向的现代合集              |
| Rafaely, <i>Fundamentals of Spherical Array Processing</i> (Springer, 一版2015, DOI 10.1007/978-3-662-45664-4; 二版 online 2018、版权2019, DOI 10.1007/978-3-319-99561-8) | 系统介绍球阵与球谐域处理，可配合 § 5.8 阅读 |

会议：ICASSP（信号处理旗舰会）、Interspeech（语音领域旗舰会）、WASPAA（音频与声学信号处理研讨会，两年一届）、IWAENC（声学信号增强研讨会）、HSCMA（免提语音通信与麦克风阵列研讨会）、DCASE Workshop（声事件与场景）。

期刊：IEEE/ACM Transactions on Audio, Speech, and Language Processing（TASLP，本领域主刊）、IEEE JSTSP（信号处理选题特刊）、JASA（美国声学学会刊）、Speech Communication。

挑战赛用于了解公开任务和评测口径。

CHiME 覆盖远场、多说话人和多通道语音处理；CHiME-9 设置 MCoRec 多会话鸡尾酒会转写与会话聚类、ECHI 低延迟助听对话增强。[CHiME 官方](#)于 2026 年 7 月公布 CHiME-10 的 ECHI-2、URGENT、SG-TSE 三项任务；挑战计划于 2027 年 2 月 4 日开放，提交期暂定为 2027 年 8~9 月。日程可能调整，参赛时应以官方页面为准。

DCASE 2026 已于 2026 年 6 月 15 日结束，并在 7 月 1 日公布结果；Task 3 是 Semantic Acoustic Imaging SELD，与 DCASE 2024 Task 3 的距离估计设置不同。以上状态核实于 2026 年 9 月，任务定义与结果见 [DCASE 2026 官方页面](#)和[结果公告](#)。

其他公开评测包括 REVERB 去混响评测、ICASSP DNS/AEC Challenge，以及已结束的 [SPEAR Challenge 2023](#)。SPEAR 使用头戴式 6 通道设备研究 AR 语音增强；它的年份、阵列和任务条件不应外推为当前持续榜单。

历史脉络（本领域是雷达/声呐技术向语音的迁移史）：

| 年代          | 里程碑                                                                                                                                  |
|-------------|--------------------------------------------------------------------------------------------------------------------------------------|
| 1940s – 60s | 雷达/声呐阵列处理奠基（Bartlett 波束扫描）                                                                                                           |
| 1969        | Capon 最小方差谱估计（为地震学阵列而做）                                                                                                              |
| 1972        | Frost 时域约束自适应波束形成                                                                                                                    |
| 1979 – 82   | Allen & Berkley 镜像法房间仿真；Griffiths & Jim 提出 GSC                                                                                       |
| 1985        | Flanagan 等报告了可计算转向的大孔径会议室麦克风阵列                                                                                                       |
| 1986 – 89   | MUSIC（1986）与 ESPRIT（1989）用子空间结构估计到达方向；分辨能力仍受孔径、信噪比、快拍数和模型失配限制                                                                        |
| 1990s       | Elko 差分麦克风阵列进入助听器与桌面会议设备                                                                                                             |
| 2001 – 08   | Brandstein & Ward、Benesty 等教材出版，语音阵列知识体系化                                                                                            |
| 2010        | Nakatani 提出 WPE 去混响；Pal & Vaidyanathan 提出嵌套阵                                                                                         |
| 2011        | 首届 CHiME 挑战赛，远场语音成为公开评测对象                                                                                                            |
| 2014        | Amazon Echo 把多麦克风远场语音带入一类消费设备；具体阵列规格随硬件代次而变                                                                                          |
| 2015 – 18   | CHiME-3/4/5 的公开任务推动了掩码辅助波束与 GSS 等方法的可复现比较                                                                                            |
| 2019 – 24   | DNN 定位/追踪（ACCCDOA：声源活动与方向联合输出，Shimada et al., ICASSP 2021）、端到端一体化；CHiME-7/8 大模型后端；STARSS23（DCASE 2024 Task 3 使用的开发与评测数据集）支持声源距离估计子任务 |
| 2025 – 26   | CHiME-9 设置 MCoRec 与 ECHI；2026 年 7 月公布 CHiME-10 三项任务；DCASE 2026 Task 3 转为 Semantic Acoustic Imaging SELD，并于 2026 年 7 月公布挑战结果          |

DCASE 2024 Task 3 的官方任务页明确将开发集和评测集称为 STARSS23，数据集名中的年份不应随挑战年份改写。[DCASE 2024 Task 3 官方说明](#)

### 13.3 研究前沿速览（2024—）

本节把正文中的经典方法与 2024 年以来若干公开研究方向相连。具体成绩只在原论文的数据、实现和评测条件下成立；带日程的内容以对应挑战赛官方页面为准。

1. 预训练模型用作远场识别后端：CHiME-7/8（2023/2024）部分参赛系统使用 Whisper、WavLM 等预训练模型作为识别后端，也有系统保留 GSS（导引源分离，详见 § 8.1）和解析波束。这些参赛系统只能说明相应架构在该届数据和评测中被实现，不能

据此断言整个领域已转向某一种架构。[CHiME-7/8 综述预印本](#), [arXiv:2507.18161](#)

2. 阵列无关 (array-agnostic) 系统: CHiME-8 的 DASR 系统报告描述了不固定阵列拓扑的设计。其泛化范围只能以报告中的训练阵列、测试设备、任务和打分脚本为边界。[CHiME-8 DASR](#)
3. 目标说话人提取 (Target Speaker Extraction, TSE): 系统用注册语音、视觉或方向提示描述目标说话人, 再从混合语音中提取相应音轨。AR 眼镜阵列和手机结构辅助方向提取提供了不同的条件输入形式。

[SonicSieve](#), [CHI 2026 TEA-PSE](#) (ICASSP 2022, DOI 10.1109/ICASSP43922.2022.9747765; 后续版本 [arXiv:2303.07704](#)) 和 [CIENet](#) 等方法从注册语音提取说话人嵌入, 再通过条件注入或帧级对齐估计目标掩码。

§ 6.1.6 的个性化 AEC 与这类条件提取方法相关, 但训练目标和回声参考结构仍需分别定义。

4. 生成式语音增强与推理加速: SGMSE+ (Richter et al., IEEE/ACM TASLP 2023) 在复数 STFT 域使用基于随机微分方程的扩散模型; StoRM (Lemercier et al., IEEE/ACM TASLP 2023) 把判别式回归与生成过程结合, 以减少采样负担。[SGMSE+ 代码与论文](#)、[StoRM 代码与论文](#)。

这类方法可能改善特定数据上的感知质量, 也可能生成参考中不存在的语音细节, 因此要同时评估听感、内容一致性和下游 WER。流匹配、蒸馏和一致性模型试图减少采样步数。

[FlowSep](#) (ICASSP 2025) 把整流流用于 VAE 隐空间中的文本查询通用音频分离, 其结论不能直接外推到多通道语音增强。[FlowSep](#), DOI 10.1109/ICASSP49660.2025.10890129

多通道生成模型还需显式处理跨通道相位、空间协方差和实时性, 目前与 § 5.9 的掩码加解析波束属于不同成熟度的技术路线。5. TF-GridNet 与复数谱映射骨干: TF-GridNet 的单通道会议版 (Wang et al., ICASSP 2023) 研究单通道说话人分离; 期刊扩展 (IEEE/ACM TASLP 2023) 进一步覆盖噪声、混响和多通道条件。具体 SI-SDRi 必须按原文的数据版本、混合方式和表号引用, 不能把两版结果混在一起。[ICASSP 2023 单通道会议版](#)、[TASLP 2023 期刊扩展](#)。6. 几何无关前端的期刊研究: Kamo et al. 在 *Computer Speech & Language* 95:101820 (2026) 中整理了几何无关的多说话人远场识别系统, 并在真实会议数据上评估。[Kamo et al., Computer Speech & Language](#) 它与 CHiME-8 的系统共同说明, 不固定阵列拓扑可以作为明确的系统设计目标; 泛化范围仍以论文的训练阵列、测试设备和数据为边界。7. CHiME-9 与大模型后端: CHiME-9 设置 MCoRec 和 ECHI 两项任务; 前者涉及多会话转写与会话聚类, 后者研究低延迟助听对话增强。[CHiME-9 官网](#)

DiCoW (Polok et al., *Computer Speech & Language* 95:101841, 2026) 把分割信息作为条件注入 Whisper, 用于目标说话人识别。这个实例说明前端的分割、增强结果可以作为大模型后端的显式条件, 而不只是输出单路音频。[DiCoW](#), DOI 10.1016/j.csl.2025.101841

8. 扩散先验用于无监督盲分离: ArrayDPS (Xu et al., ICML 2025) 处理“没有阵列几何、房间冲激响应和配对分离标签”的多通道盲分离问题。AuxIVA 通过源独立性直接迭代解混矩阵; ArrayDPS 改为从单说话人扩散先验采样, 并在每个采样步骤内估计相对房间冲激响应, 用该近似混合模型计算似然梯度。

它仍假设说话人数已知、各通道同步、混合可由卷积模型近似, 而且单说话人先验要覆盖测试语音域; 扩散先验不能替代源数估计、同步或域外验证。

最小复现可沿用官方 SMS-WSJ 配置: 两名说话人、3 通道、8 kHz, 先下载作者提供的单说话人扩散模型, 再运行 `separate.py`, 设置 `num_speakers=2`、`n_channels=3`、`num_steps=400`, 将输出与其 IVA 初始化按同一 SI-SDR 实现比较, 同时记录总耗时和峰值显存。官方说明要求显存大于 7 GB; 400 步扩散采样还嵌套相对 RIR 优化, 因此它是离线研究候选, 不应直接列入低延迟流式基线。[ArrayDPS 论文 \(PMLR 267\)](#)、[官方实现与复现命令](#)。

## 专栏: 神经网络前端的泛化失配与四类对策

本专栏解释阵列或房间改变后性能下降的原因, 并展开 13.3 第 2、6 条涉及的四类对策。

神经网络前端可能在训练阵列和房间上表现良好, 换到新的几何、声学条件或任务后却明显退化, 这就是泛化失配。下面把失配分为阵列、声学、任务与数据三类, 再从数据、表示、训练和部署四方面讨论缓解方法。

失配三源:

1. **阵列失配**：训练与部署的几何、通道数、麦克风一致性或采样时钟不同。若网络依赖固定通道编号及其相位关系，更换阵列后这些特征不再成立，端到端波束尤其容易受影响（§ 5.9 第 2 条）。
2. **声学失配**：混响时间、噪声类型和说话人距离改变。训练数据未覆盖相应混响尾部或噪声结构时，掩码估计误差会传递到协方差和 MVDR 权重。
3. **任务与数据失配**：仿真未包含麦位误差、挡板散射或非平坦频响；训练与测试的语言不同；面向听感训练的增强模型被直接用于 ASR。最后一种情况还要检查生成式模型是否改变语音内容（§ 13.3 第 4 条）。

四类对策：

1. **数据**：混合多种阵列几何、房间、采样率和噪声进行训练，并用少量目标设备录音适配。目标是覆盖可能变化的相位和幅度关系，而不是穷举设备。
2. **表示**：让网络输出掩码、协方差或说话人活动等中间量，再由 MVDR 或 GSS 等解析方法施加无失真约束（§ 5.9 第 1 条）。这种分工仍需验证中间量是否真正跨几何泛化。
3. **训练**：随机丢弃通道、置换通道顺序并扰动麦克风坐标，分别模拟通道失效、可变麦数和标定误差；网络结构还要满足相应的置换不变或等变性质。
4. **部署**：先做通道一致性和几何标定，再根据置信度、资源和失败模式选择模型或解析基线。模型分级只是候选架构，是否有净收益要在目标硬件上测量。

**阵列无系统的常见结构**：各通道先独立提取特征，再用注意力或池化聚合成对通道顺序不敏感、可接受可变通道数的表示。中间量可选掩码、协方差或说话人活动；分离与波束部分采用 GSS 等解析方法，或使用满足几何无关要求的神经前端。后端再用预训练识别模型吸收残余失配。

CHiME-8 DASR 与 § 13.3 第 6 条的期刊系统给出了两类公开实例。复现时应画出实际流程图，并逐项标明训练数据、通道聚合方式、解析约束和测试阵列范围。

**TAC 与 VarArray**。TAC (Transform-Average-Concatenate) 先对各通道独立变换，再跨通道平均并把聚合结果拼回各通道，从结构上支持可变通道数和通道置换。

VarArray 把 TAC、Conformer 分离和通道间相位差特征用于几何无关的连续语音分离，并在 AMI 会议转写上报告端到端 sa-WER 结果。它们为后续跨设备系统提供了结构基础。[VarArray, ICASSP 2022, DOI 10.1109/ICASSP43922.2022.9746876](#)

## 13.4 常见问题与调试指南

下面按“现象 → 优先检查项”列出八类常见问题。

1. **MUSIC 没有峰 / 峰位置不稳定** → 先看样本协方差的秩与条件数。若直接用  $T$  个  $M$  维快照计算未中心二阶矩，矩阵秩不超过  $T$ ，所以  $T < M$  时必然奇异；若先估计并减去样本均值，中心化后的  $T$  个向量线性和为零，秩上限通常降为  $T - 1$ ，所以  $T \leq M$  时必然奇异。快照数超过这一最低门槛也不代表估计已经稳定。

再检查源数  $K$  和噪声底是否可分，最后检查直达声与反射是否强相干。空间平滑只适用于具有可重叠子阵的几何，而且会缩短有效孔径；它不是所有混响场景的必选项（§ 2.5、§ 4.6）。2. **GCC-PHAT 峰位置在离散时延格点间跳变** → 没有做亚采样时延估计，或原始时延网格太粗；也可能是强反射峰超过直达峰（图13）。图12采用 16 倍互谱补零插值，不是三点抛物线拟合；其他实现也可采用相关峰插值或相位斜率拟合（§ 4.2）。3. **波束形成后目标语音反而失真** → 先查 DOA、RTF 和通道标定是否一致，再检查噪声协方差的估计方式。

噪声协方差既可由目标缺席帧估计，也可由时频掩码加权估计；关键是尽量排除目标泄漏，同时保留足够有效快拍。混响中还要确认约束对象是否应改用 RTF（§ 5.4、§ 5.9）。4. **超指向输出噪声很大** → 检查 WNG、协方差条件数、通道增益相位和阵列流形误差。容许的失配没有统一 dB 门槛，应从目标 WNG、最高工作频率和实测波束图反推；可用对角加载或显式 WNG 约束改善稳健性（§ 5.3、§ 5.4）。5. **AEC 残余回声较大** → 优先检查参考取点、参考与麦克风的整体延迟、扬声器削波以及滤波器覆盖时间。参考不同步是需要排查的原因之一，不是所有设备的固定首因。

若线性路径已收敛而仍有与播放相关的非线性残余，再评估非线性处理（NLP）或学习型 AEC（§ 6.1）。6. **SRP-PHAT 出现镜像假峰** → 间距超过半波长出现栅瓣（§ 2.6），或墙面的强反射形成了“镜像声源”——先检查无混叠带宽，再考虑限制搜索空间。7. **多麦**

录音各通道逐渐错位 → 先区分固定的初始时差、独立丢样和 SRO。单设备可让通道共享采样时钟；分布式设备无法共享时钟时，要估计相对采样率并重采样。PDM/TDM 是接口形式，不自动保证跨设备同步（§ 10.2）。8. 仿真很好、实测很差 → 逐项加入麦位误差、通道增益相位误差、壳体散射、频响差异、时钟偏移和扬声器非线性，寻找哪一项能复现实测退化。

位置容差应按最高频率允许的相位误差换算，不存在对所有阵列通用的毫米阈值。完成标定后，再在容差范围和多个位置上复测。

13.5 核心公式速查卡

下表汇总正文中的关键公式，便于复习和查阅。公式成立条件仍以对应章节为准。

| 公式                                                                                              | 含义                                                                                                 | 章节                  |
|-------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------|---------------------|
| $10 \log_{10} M$                                                                                | 无失真归一化、各通道独立等功率白噪声下， $M$ 元 DSB 的 WNG (dB)                                                          | § 1、<br>§ 5.2       |
| $r_F = 2D^2/\lambda$                                                                            | Fraunhofer 相位曲率检查尺度；不是远近场硬分界。使用平面波模型还要检查 $r \gg D$ 、阵元幅度差和允许的相位误差                                  | § 2.2               |
| $T_{60} = 0.161V/A$                                                                             | 赛宾公式：房间混响时间                                                                                        | § 2.4               |
| $d_c = 0.057\sqrt{QV/T_{60}}$                                                                   | 临界距离：直达/混响相等处； $Q$ 为声源指向因子， $Q = 1$ 时才化为原来的全向式                                                     | § 2.4               |
| $\vec{x} = \vec{a}(\theta)s + \vec{n}$                                                          | 远场窄带阵列信号模型                                                                                         | § 2.3               |
| $\hat{\mathbf{R}} = \frac{1}{T} \sum_t \vec{x}\vec{x}^H$                                        | 空间协方差矩阵估计                                                                                          | § 2.5               |
| $d < \lambda/2$                                                                                 | ULA 在整个闭可视角域内避免端点歧义的充分条件； $d = \lambda/2$ 时两个端火方向 $-90^\circ$ 与 $+90^\circ$ 可产生相同阵元采样，限定转向范围时可另行分析 | § 2.6               |
| CRB 公式                                                                                          | 给定统计模型与正则条件下，无偏 DOA 估计方差的下界                                                                        | § 2.6               |
| $\hat{\theta} = \arcsin(c\hat{\tau}_{12}/d)$                                                    | 双麦时延差 → 角度；本书定义 $\tau_{12} = t_1 - t_2$ ，并以 $X_1X_2^*$ 的 GCC 峰估计它                                  | § 2.1<br>、<br>§ 4.2 |
| $R(\tau) = \int \Phi X_1X_2^*e^{j2\pi f\tau}df$                                                 | GCC 加权互相关                                                                                          | § 4.2               |
| $\hat{p} = \arg \max_{\vec{r}} \sum R^{PHAT}$                                                   | SRP-PHAT 全阵列投票                                                                                     | § 4.3               |
| $P_C = 1/(\vec{a}^H\hat{\mathbf{R}}^{-1}\vec{a})$                                               | Capon 谱                                                                                            | § 4.5               |
| $P_{MU} = 1/(\vec{a}^H\mathbf{E}_n\mathbf{E}_n^H\vec{a})$                                       | MUSIC 伪谱                                                                                           | § 4.6               |
| $\vec{w}_{DSB} = \vec{a}/M$                                                                     | 延迟求和波束                                                                                             | § 5.2               |
| $ B(\theta)  = \left  \frac{\sin(M\psi/2)}{M\sin(\psi/2)} \right $                              | 等权 ULA 的归一化阵因子， $\psi = 2\pi d(\sin \theta - \sin \theta_0)/\lambda$                               | § 5.2               |
| $\vec{w}_{SD} = \frac{\mathbf{\Gamma}^{-1}\vec{a}}{\vec{a}^H\mathbf{\Gamma}^{-1}\vec{a}}$       | 超指向：在无失真约束下最小化弥散噪声输出                                                                               | § 5.3               |
| $\vec{w}_{MVDR} = \mathbf{R}_{nn}^{-1}\vec{a}/(\vec{a}^H\mathbf{R}_{nn}^{-1}\vec{a})$           | 最小方差无失真                                                                                            | § 5.4               |
| $\vec{w}_{LCMV} = \mathbf{R}^{-1}\mathbf{C}(\mathbf{C}^H\mathbf{R}^{-1}\mathbf{C})^{-1}\vec{f}$ | 多约束最小方差解                                                                                           | § 5.5               |
| $\vec{w}_{SDW} = (\mathbf{R}_{ss} + \mu\mathbf{R}_{nn})^{-1}\mathbf{R}_{ss}\vec{e}_r$           | 失真可调维纳滤波                                                                                           | § 5.5               |
| $e = d - y$                                                                                     | GSC 中固定波束输出 $d$ 减去自适应抵消输出 $y$ ；在阻塞矩阵理想、支路自由度足够且优化收敛时与相应 LCMV 等价                                    | § 5.6               |
| NLMS 更新式                                                                                        | AEC 自适应滤波                                                                                          | § 6.1               |
| $\text{ERLE} = 10 \log_{10} \frac{\sum_n  y(n) ^2}{\sum_n  e_{\text{echo}}(n) ^2}$              | 同一远端单讲窗口内的回声返回损失增强； $y = x * h$ 为消除前回声， $e_{\text{echo}}$ 为消除后回声分量                                 | § 6.1               |
| $X(n, f) = E(n, f) + \sum_{k=\Delta}^{\Delta+K-1} G^*(k, f)X(n - k, f)$                         | 单通道记法下的 WPE 预测模型；多通道时 $G$ 与历史观测为向量                                                                 | § 7.1               |

| 公式                                                                                                                          | 含义                                          | 章节      |
|-----------------------------------------------------------------------------------------------------------------------------|---------------------------------------------|---------|
| KF 五步                                                                                                                       | 预测-更新-增益循环；圆周角新息先做 wrap，浮点实现可用 Joseph 协方差更新 | § 9.2   |
| $D_{t t-1}(\vec{x}) = \gamma_t(\vec{x}) + \int p_S(\vec{\xi}) f_{t t-1}(\vec{x}   \vec{\xi}) D_{t-1}(\vec{\xi}) d\vec{\xi}$ | PHD 预测：新生目标强度加存活目标的状态转移                     | 式(9-9)  |
| $D_t = (1 - p_D) D^- + \sum_{z \in Z_t} \frac{p_D g(z   x) D^-}{\kappa(z) + \int p_D g(z   \xi) D^-(\xi) d\xi}$             | PHD 更新：漏检项加每条观测的“目标/杂波”归一化贡献                | 式(9-10) |

### 13.6 思考与练习

练习按章节排列。修改脚本参数时，应同时记录随机种子、实验条件和输出指标。数值题附参考答案，综合题附思路提示。

练习涉及的绘图函数（做题时打开对应函数按题面改参数就行）：

| 函数名              | 它画的是什么      | 用在哪道题 |
|------------------|-------------|-------|
| fig_geometries   | 阵列形态布局      | 题4    |
| fig_gcc_phat     | GCC-PHAT 原理 | 题5    |
| fig_doa_spectrum | DOA 空间谱     | 题6    |
| fig_wng_di       | WNG – DI 权衡 | 题8    |
| fig_wpe          | WPE 去混响     | 题9    |
| fig_tracking     | 粒子滤波追踪      | 题13   |

动手题用的绘图函数都在 `scripts/` 里，具体对应关系见上表。第 16 题还要安装 `pyroomacoustics 0.10.0`；它是房间声学仿真的扩展依赖，命令见该题和项目 README。

#### 第 1 章（问题定义）

- 思考题：为什么“双耳 + 自由转头”通常比静止双耳更容易消除前后混淆？  
提示：静止时并非只有两个数；ITD、ILD 和 HRTF 的频谱线索都随频率变化。某些镜像方向仍会产生相近线索，转头后这些线索按不同轨迹变化，动态观测可打破歧义。联系 § 1.1 与 § 3.1 的几何对称性。

#### 第 2 章（基础）

- 手算：3 麦线阵、间距 3 cm、声源 45°、频率 2 kHz，写出导向矢量；该频率是否满足全视场无混叠条件？6 kHz 呢？  
参考答案：2 kHz 时  $\lambda = 17.15 \text{ cm}$ ， $\psi = \frac{2\pi d}{\lambda} \sin 45^\circ \approx 0.777 \text{ rad}$ ， $\vec{a} = [1, e^{+j0.777}, e^{+j1.554}]^\top$ ；正角声源先到达 + $x$  侧的后续阵元，按本书的傅里叶变换约定对应正的相对相位。 $d < \lambda/2$ ，满足全视场安全条件。  
6 kHz 时  $\lambda \approx 5.72 \text{ cm}$ ， $d > \lambda/2$ ，不再保证所有方向无混叠。但对本题  $\theta_0 = 45^\circ$ ，候选歧义满足  $\sin \theta = \sin 45^\circ \pm \lambda/d \approx 0.707 \pm 1.91$ ，两解都落在  $[-1, 1]$  外，因此该转向本身没有可见等高栅瓣。条件被突破不等于每个转向都必然出现栅瓣。
- 用赛宾公式估算你所在房间的  $T_{60}$  与临界距离  $d_c$ ，判断 3 m 对话处在直达占优还是混响占优区。  
参考示例：5 m × 4 m × 2.8 m 客厅， $V = 56 \text{ m}^3$ 、 $A \approx 18 \text{ m}^2$ （取平均吸声系数约 0.2） $\rightarrow T_{60} = 0.161V/A \approx 0.5 \text{ s}$ 。若声源指向因子  $Q = 1$ ，则  $d_c = 0.057\sqrt{QV/T_{60}} \approx 0.6 \text{ m}$ ；3 m 对话距离  $\gg d_c$ ，在该模型下属于混响占优区。改变  $Q$  会按  $\sqrt{Q}$  改变临界距离。

#### 第 3 章（几何）

- 打开 `fig_geometries` 按题面改：把 6+1 圆环改成 8 麦；改麦数时坐标、标题、图注要一起改。思考：中心麦能提供什么新信息？  
提示：它可作为参考通道，并新增从中心到各环麦的基线；“到各环麦距离相等”描述的是几何布局，不表示任意入射方向下都与环麦等相位。固定半径时增加环上麦数会缩短相邻间距，但不会增加最大孔径。

## 第4章（定位）

5. 打开 `fig_gcc_phat`，逐步增加噪声并比较 PHAT 与普通互相关。记录每个随机种子、信号谱和混响条件下的峰值误差，不预设固定 SNR 崩溃点。

提示：PHAT 去掉幅度谱着色，可能让峰变尖，也可能在低信噪比频带放大相位噪声。它的优势取决于源谱、噪声谱和反射结构。6. 在 `fig_doa_spectrum()` 中把两源间隔从  $50^\circ$  缩到  $15^\circ$ 、 $8^\circ$ ，观察 Bartlett、Capon、MUSIC 的谱峰。

比较基准：8 元半波 ULA 的离散阵因子 HPBW 近似为  $0.886\lambda/(Md) \approx 12.7^\circ$ ；用物理跨度  $D = (M-1)d = 3.5\lambda$  得到的  $\lambda/D \approx 16.4^\circ$  只是孔径尺度。

不要预先规定谁在某个角度必然失败。实际结果取决于 SNR、快拍数、源相关性、加载和峰值判据。MUSIC 在理想独立源条件下可能分辨小于常规主瓣宽度的两源，但不保证在失配或相干源下保持这一能力。

## 第5章（波束形成）

7. 从拉格朗日函数推出 MVDR 闭式解，再回 § 5.4 对答案。

提示：构造实值函数  $L = \vec{w}^H \mathbf{R}_{nn} \vec{w} + 2 \operatorname{Re}\{\lambda^* (\vec{w}^H \vec{a} - 1)\}$ ，对  $\vec{w}^*$  求导，得到  $\vec{w} \propto \mathbf{R}_{nn}^{-1} \vec{a}$ ，再代入约束定比例系数。8. 在 `fig_wng_di()` 中把麦距从 4 cm 改成 2 cm 与 8 cm，画出 WNG、DI 和协方差条件数，再比较有无对角加载。记录脚本实际输出，不预设某个频率的固定 dB 数。

解释重点：低频  $kd$  很小时，各阵元观测接近相同，弥散噪声相干矩阵容易病态；超指向解需要大幅度、相互抵消的权重，因而 WNG 下降。增大间距可能改善低频条件数，也可能在高频引入空间混叠，不能只看一端。

## 第7章（去混响）

9. 打开 `fig_wpe` 按题面修改：把  $T_{60}$  从 0.6 s 改为 0.3 s 与 1.0 s，再把 `prediction_delay` 从 6 改为 1，其他参数保持 `prediction_order=10`、`iters=3`。记录每次试验的参数，比较图中拖尾与语音谱结构的变化。

提示：当前 `wpe_past_frames` 要求 `delay >= 1`，因此 `delay=0` 会报错，不是可比较的算法配置。8 ms 帧移时，`delay=6` 从 48 ms 历史开始预测，`delay=1` 则从 8 ms 开始，更容易将需保留的早期成分纳入预测。

## 第6章（AEC）

10. 手算（AEC，接算例 6-1）：回声路径  $\vec{h} = [0.8, 0.3, 0.1]^\top$ ，参考为单位脉冲  $x(0) = 1$ 、其余时刻为 0；3 抽头 NLMS， $\hat{\vec{w}}(0) = \vec{0}$ ， $\mu = 0.5$ 。在  $\|\vec{x}\|^2 > 0$  时为便于手算取  $\varepsilon = 0$ ；零能量时按 § 6.1.2 的规则跳过更新。手算  $n = 0, 1, 2, 3$  的  $d(n)$ 、 $e(n)$  与  $\hat{\vec{w}}(n+1)$ ，并解释为什么 3 步之后滤波器恰好停在  $0.5\vec{h}$ 。

参考答案： $d = [0.8, 0.3, 0.1, 0]$ ，因为单位脉冲卷上  $\vec{h}$  就是  $\vec{h}$  本身。

- $n = 0$ :  $\vec{x} = [1, 0, 0]^\top$ ， $\hat{y} = 0$ ， $e = 0.8$ ， $\|\vec{x}\|^2 = 1$ ， $\hat{\vec{w}} \leftarrow [0.4, 0, 0]^\top$ ；
- $n = 1$ :  $\vec{x} = [0, 1, 0]^\top$ ， $\hat{y} = 0$ ， $e = 0.3$ ， $\hat{\vec{w}} \leftarrow [0.4, 0.15, 0]^\top$ ；
- $n = 2$ :  $\vec{x} = [0, 0, 1]^\top$ ， $e = 0.1$ ， $\hat{\vec{w}} \leftarrow [0.4, 0.15, 0.05]^\top$ ；
- $n = 3$ :  $\vec{x} = \vec{0}$ ，按零能量规则跳过更新。

前三个回归向量已经依次覆盖三个正交方向，但每个方向只更新一次； $\mu = 0.5$  使每个抽头只走完一半误差，所以终点恰为  $0.5\vec{h}$ 。若要继续收敛到  $\vec{h}$ ，需要在这些方向上获得更多非零更新；持续的白噪声或语音通常同时提供重复观测和多方向激励。

11. 论述题：为什么多数时变波束系统把 AEC 放在波束形成之前？有没有例外？

思路提示：若权重随追踪变化，波束后的等效回声路径  $h_{\text{eff}}(t) = \vec{w}(t)^H \vec{h}(t)$  也随时间变化，单路 AEC 更难跟踪。若波束固定或采用联合多通道回声模型，波束后 AEC 并非数学上不可能，只是路径变化、双讲控制和多波束复用要重新设计。

## 第8章（语音分离）

12. 手算与设计题：

1. 某两输出分离器对两条参考语音的损失矩阵为  $\begin{bmatrix} 1.2 & 0.3 \\ 0.4 & 1.5 \end{bmatrix}$ ，求 PIT 选择的排列与总损失。

2. 取两个双通道时频快照  $\mathbf{X}_1 = [1, 1]^\top$ 、 $\mathbf{X}_2 = [1, -1]^\top$ ，目标掩码  $\gamma = [0.75, 0.25]$ ，计算目标协方差和互补掩码协方差。
3. 若把模型用于连续会议，还要增加哪三类处理？

参考答案：

1. 保持排列的损失为  $1.2 + 1.5 = 2.7$ ，交换排列为  $0.3 + 0.4 = 0.7$ ，故选择交换。
2. 两组权重和都为 1， $\mathbf{R}_{\text{tar}} = 0.75\mathbf{X}_1\mathbf{X}_1^H + 0.25\mathbf{X}_2\mathbf{X}_2^H = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}$ ，互补掩码得到  

$$\mathbf{R}_{\text{int}} = \begin{bmatrix} 1 & -0.5 \\ -0.5 & 1 \end{bmatrix}。$$
3. 连续会议至少要定义分块与上下文、重叠块拼接、跨块排列/输出流管理；需要身份时还要增加分割或说话人关联。互补掩码在这个二分类题中成立，不能据此把多说话人加噪声场景中的  $1 - \gamma$  一律称为纯噪声。

## 第 9 章（追踪）

13. 打开 `fig_tracking`，按下面的条件修改：

- 当前基线：200 个粒子、 $7^\circ$  观测噪声、“高斯目标 + 均匀杂波”混合似然（杂波权重 0.1）、第 48~57 帧连续缺测、 $0^\circ \sim 120^\circ$  有限搜索扇区的镜面反射边界，以及有效粒子数低于  $N/2$  时的系统重采样；
- 实验变量：把生成观测的标准差和 `particle_filter_doa(..., observation_std=...)` 同时从  $7^\circ$  改为  $20^\circ$ ，分别用  $N = 200, 500, 1000$  运行；
- 其余保持不变：杂波权重、缺测区间、有限扇区边界和系统重采样阈值沿用当前基线；
- 要记录：轨迹 RMSE、`n_eff` 的最小值/中位数、`resampled` 为真的帧数、`reflection_fraction` 的最大值/中位数与不低于 5% 的帧数，并单独报告缺测段 RMSE。

提示：当前图用橙色竖线标出重采样帧，用紫色叉号标出反射粒子比例不低于 5% 的帧，但没有绘制 `n_eff` 或反射比例曲线；需要曲线时应增加子图。只改一处噪声参数是观测模型失配实验。粒子数增加是否改善结果，应由这些记录判断。

## 第 10 章（工程实现）

14. 思考题：一台 6 麦音箱的项目需求规定“唤醒到应答 < 300 ms”。按 § 10.1 的延迟分类和关键路径公式拆分预算，并指出三处优先优化项。

提示：分别列出前瞻、缓冲、计算、调度和解码/交互。把 STFT 窗长从 32 ms 改为 16 ms 只会改变依赖完整窗的等待，不会自动把端到端延迟减半；WPE 流式化和后端分级也要以实测关键路径验收。

运行 `.venv/bin/python -m codes.examples.ch10_engineering_baselines`，再把调度示例中的两个 18 ms 处理帧逐步增大。记录 deadline miss、队列高水位和丢帧数。该模拟器只有一条串行工作线程，不含操作系统抢占；它验证记账方式，不是目标硬件性能测试。

## 第 11 章（选型）

15. 思考题：给“车载 4 麦分布式 + 强发动机噪声 + 免唤醒连续对话”场景写一段选型论证，分别说明几何、定位、波束和 AEC。

提示：按 § 11.1 的六个问题补齐条件；检查分布式 SRO 风险（§ 10.2）、低频噪声下超指向的 WNG、AEC 参考是否覆盖车机实际播放处理，以及连续对话期间哪些模块需要保持运行。功耗预算见 § 10.4 和 § 10.9。

## 综合

16. 用 `pyroomacoustics 0.10.0` 生成目标  $T_{60} = 0.6$  s 的房间 RIR，跑 SRP-PHAT，并在多个距离、方向和随机声源位置上重复实验。用 `.venv/bin/pip install pyroomacoustics==0.10.0` 安装该扩展依赖。

实验要求：

- 吸声系数由房间体积、表面积与目标  $T_{60}$  反算；
- 镜像阶数提高到结果收敛，并在代码中写入实际计算值；
- 画出定位误差、DRR 与距离三者的关系；
- 分别报告目标  $T_{60}$  与由生成 RIR 测得的  $T_{60}$ ，并注明拟合区间和实际安装版本。

临界距离给出 DRR 量级参考，但定位误差不保证在该处出现清晰拐点。

17. (研究拓展) 读一篇 CHiME-8 参赛系统报告 (见 § 13.3 引用)，按报告实际结构画出前端流程图，与本书图23 对照。

逐项标出定位、分割、GSS/波束、增强和 ASR 后端是否存在，不先假定高排名系统都采用同一架构；再说明其阵列无关设计依赖哪些训练数据或解析模块。

## 13.7 复现说明

下面先运行代码基线的单元测试和第 10 章示例，再重新生成全部 33 张图：

```
.venv/bin/python -m unittest tests.test_codes_engineering -v  
.venv/bin/python -m codes.examples.ch10_engineering_baselines
```

第 10 章示例使用确定性输入，覆盖 SRO 直线拟合与线性重采样、VAD 迟滞与 hangover、峰值保护 AGC、固定容量环形缓冲、deadline/队列模拟和 Q1.15 饱和量化。线性重采样、Python 环形缓冲和调度模拟都是教学基线，不应替换带抗混叠滤波的流式重采样器、无锁实时队列或目标系统测量。

绘图脚本都在 `scripts/` 里。在仓库根目录跑两个命令，结果进 `figures/`，共 33 张图：

```
.venv/bin/python scripts/make_figures.py # 图 1~25、图 33  
.venv/bin/python scripts/make_aec_figures.py # 图 26~32 (回声消除专题)
```

Windows 上把 `.venv/bin/python` 换成 `.venv\Scripts\python`，其余不变。

运行时间随硬件、软件版本和负载变化。报告耗时时应同时记录这些条件、运行次数和统计方式。

代码基线只依赖 `numpy`；绘图脚本依赖 `numpy` 和 `matplotlib`，并使用固定随机种子，因此相同环境和参数下应得到相同结果。每个脚本生成哪些图、练习需要哪些扩展依赖，见 `scripts/README.md`；代码覆盖范围、上游来源和许可证见 `codes/README.md`、`codes/COVERAGE.md` 与 `codes/SOURCES.lock.json`。

正文中引用的定量结果应追溯到相应论文、标准或本仓库脚本，并同时记录数据、通道、参数和指标口径。不同实验条件下的数值不直接排名。