

麦克风阵列信号处理教程

深入浅出 · 从阵列摆位到工程选型（合订本）

构建日期 2026-09-21 · git 7f9c090+dirty · 共 14 篇：导读、11 章正文、2 篇附录

麦克风阵列信号处理教程

- 导读与导航
 - 1. 这是一份什么样的教程
 - 2. 14 个文件一览
 - 3. 每篇讲什么，读完能弄清什么
 - 4. 阅读顺序
 - 5. 三条阅读路径
 - 6. 插图地图：33 张图在哪篇
 - 7. 十处跨文档联系
 - 8. 动手复现
 - 9. 常见问题
 - 附录：下一步清单
- 第 1 章 · 问题定义与双耳启示
 - 1.1 双耳听觉的三类定位线索
- 第 2 章 · 声音到达阵列时发生了什么
 - 2.1 核心事实：同一声音，到达各麦克风有先有后
 - 2.2 近场与远场
 - 2.3 信号模型：把“声音有先有后”写成数学
 - 2.4 房间声学：混响到底是怎么来的
 - 2.5 数据怎么组织：STFT、快拍与协方差矩阵
 - 2.6 怎么衡量一个波束好不好：先学会读波束图
 - 2.7 小结：声源走近了，平面波不够用——近场要换的三样东西
 - 本章练习
- 第 3 章 · 阵列几何形态
 - 3.1 形态总览
 - 3.2 四条设计规律
 - 3.3 稀疏阵列与差分协同阵

- 3.4 阵列校准：麦克风个个不一样时怎么办
 - 本章练习
- 第 4 章 · 声源定位 (DOA 估计)
 - 4.1 总览：四大类思路
 - 4.2 GCC-PHAT：“对齐两段录音，找最吻合的错位”
 - 4.3 SRP-PHAT：跨麦对累积空间响应
 - 4.4 两阶段法的几何解算
 - 4.5 波束扫描类：Bartlett 与 Capon
 - 4.6 子空间类：MUSIC 与 ESPRIT
 - 4.7 稀疏重构与深度学习
 - 4.8 定位算法总对比
 - 4.9 本章练习
- 第 5 章 · 波束形成
 - 5.1 统一问题表述
 - 5.2 延迟求和波束形成器 (Delay-and-Sum Beamformer, 简称 DSB)：“合唱前先把大家对齐”
 - 5.3 超指向与 WNG-DI 权衡
 - 5.4 最小方差无失真响应
 - 5.5 线性约束最小方差 (Linearly Constrained Minimum Variance, 简称 LCMV)：多约束推广
 - 5.6 广义旁瓣对消器 (Generalized Sidelobe Canceller, 简称 GSC)：把约束改装成“噪声对消器”
 - 5.7 后置滤波
 - 5.8 球谐域波束形成 (球阵专属)
 - 5.9 深度神经网络 (Deep Neural Network, 简称 DNN) 波束形成
 - 5.10 波束形成算法总对比
 - 5.11 本章练习
- 第 6 章 · 声学回声消除 (AEC)
 - 6.1 AEC 的模型、算法与实现
- 第 7 章 · 去混响 (WPE)
 - 7.1 WPE 去混响
- 第 8 章 · 语音分离
 - 8.1 多说话人语音分离：鸡尾酒会问题
 - 8.2 处理模块的顺序
- 第 9 章 · 声源追踪
 - 9.1 问题与声学特殊性
 - 9.2 单目标追踪
 - 9.3 多目标追踪
 - 9.4 定位、追踪与波束形成的接口
 - 本章练习
- 第 10 章 · 工程实现与产业实践
 - 10.1 参考链路与端到端延迟
 - 10.2 拾音、同步与增益
 - 10.3 NS、控制信号与唤醒分支
 - 10.4 定点化、算力与功耗预算

- 10.5 评测体系
- 10.6 数据、仿真与复现
- 10.7 分布式阵列
- 10.8 阵列形态与场景约束
- 10.9 从模型到设备
- 10.10 联调与验收
- 10.11 本章小结
- 第 11 章 · 总结与选型指南
 - 11.1 先回答六个问题
 - 11.2 按条件选择模块
 - 11.3 几何与算法要一起选
 - 11.4 四个场景怎样推导方案
 - 11.5 把候选方案写成可验证的规格
 - 11.6 练习
 - 11.7 后续阅读
- 附录 A · 符号术语数学
 - 12.1 符号表
 - 12.2 术语词典
 - 12.3 预备知识速览
- 附录 B · 路径地图与练习
 - 13.1 研究生学习路径
 - 13.2 领域地图：教材、会议、期刊与挑战赛
 - 13.3 研究前沿速览（2024—）
 - 13.4 常见问题与调试指南
 - 13.5 核心公式速查卡
 - 13.6 思考与练习
 - 13.7 复现说明

导读与导航

本页是全套教程的入口，一共 14 个文件：本页导读+11 章正文+2 篇附录。11 章正文和 2 篇附录既可顺序阅读，也可按第 5 节的学习路径选读。每篇开头都列出上一篇、下一篇和首页链接。全套教程配了 33 张图，图 18~20、图 26~32 在第 6 章，抽象概念都配了直观图像。

1. 这是一份什么样的教程

这是一份讲麦克风阵列的教程。零基础可以从头读，读完还可以当手册查。文里配了 33 张图，先看图，再看公式。教程从生活例子讲起：你站在 3 米外跟音箱说话，它怎么听清你的声音。顺着这个问题往下走：麦克风怎么摆，怎么判断声音从哪来，怎么只听一个方向，房间混响和回声怎么处理，好几个人同时说话怎么分开，人走动时怎么跟住，到产品里怎么评测，收尾是不同场景怎么选方案。

各章先建立直觉，再给出公式、符号、算例和适用边界。比较实验数字前，要先核对阵列几何、房间、数据集、实现和评测口径；条件不同的结果只能用于观察趋势。

2. 14 个文件一览

编号	文件	配图	难度	预计时间
00	00_overview.md（本页）	0 张专属图	入门	15~20 分钟，先读本页
01	01_problem-definition.md	图1	入门	10 分钟
02	02_basics-signal-model.md	图2~图7，共 6 张	进阶	45~60 分钟，建议完整读一遍
03	03_array-geometry.md	图8~图10，共 3 张	进阶	30 分钟
04	04_doa-estimation.md	图11~图14、图33，共 5 张	较难	60~90 分钟，建议分两次读
05	05_beamforming.md	图15~图17，共 3 张	较难	60~90 分钟，跟着手算一遍
06	06_aec.md	图18~20、图26~32，共 10 张，另引用图23	较难	60~80 分钟，建议分两次读
07	07_wpe-dereverberation.md	图21、图24，共 2 张	进阶	30~45 分钟
08	08_speech-separation.md	0 张专属图，引用图23	进阶	30~45 分钟

编号	文件	配图	难度	预计时间
09	09_source-tracking.md	本章专属图22，另引用图23	进阶	30~40 分钟
10	10_engineering-practice.md	新图 1 张（图25），另引用图23	进阶	约 45~60 分钟
11	11_selection-guide.md	0 张专属图	入门	20~30 分钟；按任务、约束和场景条件形成候选方案
附录 A（文件 12）	12_appendix-symbols-math.md	0 张专属图	查阅	通读约 25 分钟，也可以当词典查
附录 B（文件 13）	13_appendix-guide.md	0 张专属图	查阅	通读约 40 分钟，也可以按需查

预计时间的算法：中文每分钟读 450 字，每张图多加 2~3 分钟，推导部分再加停留时间。按上表逐篇相加，全部精读约需 9~11 小时；练习和复现实验另计。按路径读见第 5 节。时间有限时，可先读本页、01 和 11，明确问题与选型条件，再读 02 补齐信号模型。需要定位、波束、AEC、去混响或分离时，分别选读 04~08；工程实现配合第 10 章和附录 B 的排错部分，研究选题配合第 4、9 章和附录 B 的领域地图。

3. 每篇讲什么，读完能弄清什么

01 · 问题定义与双耳启示

约 86 行（约 3400 字符），1 张图，入门。以智能音箱为例说明噪声、混响、干扰和麦克风自噪声，再区分定位、波束形成和追踪三项空间任务。阵列收益分三类度量：独立通道噪声看 WNG（白噪声增益），弥散场看 DI（指向性指数），定向干扰看零陷深度。三种指标的声场假设不同，不能直接互换。

人只用两只耳朵就能定位，机器用一堆麦克风，办法是相通的：人用双耳时间差，机器也测时间差。人靠耳朵形状分辨方向，机器靠事先测好的方向数据。细节都在第 1 章。

读完能弄清：为什么要用一群麦克风。增益上限是多少。人耳的方案对应到机器的哪些模块。

02 · 基础：声音到达阵列时发生了什么

约 323 行（约 2.27 万字符），6 张图，进阶。全书的符号和概念都在这章第一次出现。建议完整读一遍。后面看不懂随时回来查。2.1 节讲时延：声音到达每个麦克风有先有后。采样率 16kHz 时，一格是 62.5 微秒，约等于 2.1 厘米。时延估计要用到比采样间隔更细的插值。多路信号必须用同一个时钟录。2.2 节讲远场和近场：常用判据是距离大于两倍孔径平方除以波长。分界同时取决于孔径和频率；小孔径、低频时较容易满足远场近似，大孔径、高频或近距离时要检查球面波模型。2.3 节讲导向矢量：时域的移位变成频域的相位旋转。导向矢量就是每个方向对应的标准相位组合，后面定位和波束形成都要用它。2.4 节讲房间混响：声音经反射形成拖尾， T_{60} 描述能量衰减 60 dB 所需时间，DRR（直达混响比）描述直达声与混响的相对能量。临界距离随房间体积和吸声条件变化。2.5 节讲 STFT（短时傅里叶变换）：把波形分帧后得到复数时频表示，再由多通道快拍估计协方差矩阵。窗长和帧移要根据采样率、延迟与频率分辨率选择，正文用一组语音参数作示例。2.6 节讲四个评价量：主瓣宽度、旁瓣、DI、WNG。还讲分辨率极限、栅瓣条件（间距不超过半波长）、CRLB（克拉美-罗下界，估计精度理论上最好能到多少）。

读完能弄清：时延、相位、导向矢量、协方差分别是什么。后文公式里的符号是什么意思。

03 · 阵列几何形态

约 221 行（约 1.23 万字符），3 张图，进阶。讲麦克风怎么摆，以及摆法决定什么上限。

两种双麦摆法。六种常见形态对比：线阵、圆阵、方阵、球阵、螺旋阵、分布式阵列。共线的阵列分不清绕阵列轴的方位，靠在同一条线上继续加麦克风也破不了这个几何模糊。端射方向（阵列轴线方向）对误差敏感，同样的时延误差在端射方向会被放大很多。四条规律：孔径和波长的比值决定分辨率；圆阵在水平面各方向都能利用孔径；挡板会改变阵列流形；增加麦数能改善白噪声增益和统计稳定性，但收益取决于几何、频段和噪声场。稀疏阵把麦对位置差组织成差分协同阵。例子中的 6 麦嵌套阵产生 23 个连续的有符号滞后；要把这些滞后用于 MUSIC，还需构造虚拟协方差并做空间平滑或等价重构。

读完能弄清：麦克风怎么摆决定什么上限。小阵列为什么在低频分不清方向。不同场景选哪种形态。

04 · 声源定位 DOA 估计

约 490 行（约 3.68 万字符），5 张图，较难。DOA 是到达方向估计，也就是判断声音从哪来。本章算法种类多，建议分两次读。

四类方法：两步法（互相关+几何解算）、扫描法、子空间法、稀疏重构+深度学习。GCC-PHAT（广义互相关相位变换）：看相位随频率的变化斜率。混响会拖宽或扰乱相关峰。图 13 用 16 kHz、64 ms 信号和 150 次蒙特卡洛试验构造随机衰减尾，只用于展示这一趋势，不代表真实房间的通用正确率。时延估计还要做亚采样插值。SRP（可控响应功率）：全阵列投票找能量最大的点。算例里真点得分 6.0，偏 1.8 米的点 5.64，镜像点 2.08。粗到细两级搜索能把计算时间从上千秒压到几十秒。几何解算：Chan 算法和泰勒迭代。还有 GDOP（精度稀释，几何摆位不好时误差会被放大）。扫描法：Bartlett 波束能量宽，Capon（最小方差谱估计）峰更尖，例子里峰旁比 1.8 对 5.0。子空间法 MUSIC（多重信号分类）靠信号子空间和噪声子空间正交来找峰。相干信号会让协方差矩阵掉秩，要用空间平滑恢复。ESPRIT（旋转不变子空间法）利用阵列的平移结构直接解角度，不用逐格扫描。DNN（深度神经网络）方法在强混响下能把误差从 15~30 度压到 5~10 度。CRLB（克拉美-罗下界）说明带宽是立方关系，加带宽最划算。

读完能弄清：四类定位方法各适合什么几何和算力。混响怎么影响互相关法。MUSIC 方法为什么怕相干信号。

05 · 波束形成 Beamforming

约 574 行（约 3.75 万字符），3 张图，较难。波束形成就是只听一个方向，压住别的方向。统一写成加权求和，目标是在不损伤目标方向的前提下压住噪声。跟着手算一遍效果更好。三类噪声对应三类招数：麦克风自身噪声看 WNG，用延迟求和。弥散混响看 DI，用超指向。单个方向干扰用零陷，用 MVDR（最小方差无失真响应）。DSB（延迟求和波束形成）：权重就是导向矢量除以麦克风数，WNG 等于麦克风数。超指向在低频把指向性做上去，代价是 WNG 暴跌。例子是两麦端射，WNG 掉到负 10 分贝，换 DI 提高 6 分贝。间距减半，WNG 再掉约 6 分贝。MVDR 分四步推导。算例里负 23.8 分贝的零陷自己长出来，正对着干扰方向。LCMV（线性约束最小方差）加多个约束。MWF（多通道维纳滤波）再考虑降噪和失真的折中。GSC（广义旁瓣对消器）分成固定波束、阻塞矩阵、自适应对消三路，算例里对消系数正好抵消干扰，它跟 LCMV 在数学上等价。后置滤波只改幅度不改相位。球谐方法适合球阵，旋转后波束形状不变。DNN 方法有三条线：掩码估计、掩码+MVDR、直接端到端。

读完能弄清：WNG 和 DI 的权衡怎么做。MVDR 的零陷从哪里来。GSC 和 LCMV 是什么关系。

06 · 声学回声消除 AEC

约 565 行 (约 3.49 万字符), 10 张图 (图18~20、图26~32, 另引用图23), 较难。专讲回声消除这一件事, 对照图 18、图 26~32 看收敛过程最直观。

AEC (声学回声消除): 设备自己放的声音又被自己的麦克风收进去, 要减掉。四种场景, 四处难点。能预测波形就做减法, 这是减法和乘法的分界。NLMS (归一化最小均方自适应滤波) 给出基础更新式。PBFDAF (分块频域自适应滤波)、子带方法、IPNLMS 和 FDKF (频域卡尔曼滤波) 用于降低长回声路径的计算量或改善收敛。扬声器非线性会限制线性 AEC, 需根据失真来源增加非线性模型或神经网络。DTD (双讲检测) 用于控制近端和远端同时活动时的自适应更新。AEC 与其他模块的参考关系见 §10.1 和图 23。评测要同时考虑远端单讲时的 ERLE、双讲稳定性、近端语音损伤和主观听测; ERLE 高并不能证明近端语音无损。WebRTC AEC3 可作为公开实现参考。

读完能弄清: 回声参考应怎样取得, AEC 与波束的顺序受哪些条件影响, 线性模型、非线性失真和双讲分别怎样处理。

07 · 去混响 WPE

约 229 行, 2 张图 (图21、图24), 进阶。专讲时间维度的清理: 房间的拖尾怎么收掉。

WPE (加权预测误差去混响) 用历史帧预测晚期混响并相减, 保护延迟用于避免直接预测当前直达声。正文算例在指定条件下展示混响能量变化; 预测延迟和阶数要按帧长、混响与语音损伤验证。多人重叠语音在第 8 章讨论, 模块启用条件和参考关系见 §10.1。

读完能弄清: WPE 的保护延迟 Δ 有什么作用, 多通道与单通道 WPE 的位置怎样受输入条件影响, 以及 MINT、倒谱和谱方差方法各自采用什么假设。

08 · 语音分离

约 156 行, 0 张专属图 (引用全书链路总图23), 进阶。专讲好几个人同时说话怎么分开, 以及掩码这个枢纽。

三条路线包括经典盲源分离 (AuxIVA、ILRMA、MNMF、TRINICON)、GSS (引导源分离, 用说话人活动标注处理输出排列) 和深度分离 (掩码估计、深度聚类、PIT、Conv-TasNet、状态空间模型及查询型分离)。§8.1 介绍方法, §8.2 与图 23 给出较完整前端的参考关系; 实际顺序和模块启用条件以 §10.1 为准。

读完能弄清: 源数超过麦克风数时四兄弟里谁还能用。GSS 的导引解决什么问题。分离掩码怎么回过去帮波束形成估计噪声。

09 · 声源追踪 Source Tracking

约 236 行 (约 1.36 万字符), 2 张图, 进阶。讲人走动时方向一直在变, 怎么平滑地跟住。状态是角度、角速度、角加速度。声音信号有四个麻烦: 时断时续、野点多、人数会变、角度计算有非线性。KF (卡尔曼滤波) 由状态预测、观测更新和协方差递推组成, 观测与预测的权重由噪声模型决定, 不是固定比例。PF (粒子滤波) 用带权粒子近似后验分布, 并通过重采样缓解权重退化。多人追踪还会用到 IMM (交互多模型)、PHD (概率假设密度)、LMB 和 TBD (检测前追踪)。§9.4 讨论定位与波束之间的反馈; 更新限幅、静默保持和重置条件都应由目标运动与帧率确定。

读完能弄清: 追踪为什么处在定位和波束之间。多目标和单目标方法怎么选。实际系统里方向更新要加哪些约束。

10 · 工程实现、评测与产业实践

约 276 行，新图 1 张（图25），另引用图23，进阶。图 23 是参考依赖图，不表示每个项目都要启用全部模块。第 10 章按启用条件说明 AEC、WPE、定位、波束、NS 和后端的取点关系，并把延迟分为前瞻、缓冲、计算、调度和解码关键路径。硬件部分区分数字样本格式、模拟动态范围、初始时差和 SRO（采样率偏移）。资源预算分别使用 MAC/s、MIPS、RTF、峰值内存和功耗，续航用 Wh 与整机平均功率计算。评测部分说明 SI-SDR、STOI、PESQ/POLQA、WER/CER、OSPA 与主观听测各自回答什么问题。

读完能弄清：延迟、同步、标定预算怎么做。评测指标各测什么。从算法到产品要补哪些环节。

11 · 总结与选型指南

约 110 行，入门。11.1 从输出任务、覆盖区域、频带、干扰、目标运动和硬件边界六方面定义问题；11.2 给出不同模块的启用与替换条件；11.3 说明几何和算法怎样共同决定性能；11.4 用四类场景演示怎样从条件推导候选方案；11.5 把方案写成可验证规格；11.6 配有三道练习。

读完能弄清：怎样从任务和约束形成候选方案，何时启用 AEC、WPE 或分离，以及怎样把几何、WNG/DI 权衡和资源预算写进验收规格。

12 · 附录 A：符号、术语、数学

约 222 行（约 1.34 万字符），查阅用。12.1 节是符号表。12.2 节是术语词典，按信号与数学基础、房间声学、波束形成与阵列度量、定位与追踪、系统与硬件分组。12.3 节介绍复数、分贝、卷积和相关、期望和协方差、最小二乘与特征分解。

遇到未定义符号、术语或数学步骤时，可按主题查阅，无需顺序通读。

13 · 附录 B：路径、地图、前沿、排错、练习、复现

约 231 行（约 1.66 万字符），查阅加动手。13.1 节是学习路径。13.2 节是教材、会议、期刊、挑战赛与历史地图。13.3 节介绍九个研究方向与泛化失配。13.4 节是排错指南，13.5 节是公式速查卡，13.6 节有 16 道练习题，13.7 节说明怎样复现 33 张图。

需要查学习资料、研究方向、排错方法、练习或复现步骤时，可直接进入对应小节。

4. 阅读顺序

本页先读。接着读 01，建立问题意识，10 分钟。再读 02，打基础。符号不懂回 12 查。这是后面所有章节的共同起点。之后可分三条线。几何线：03 讲形态怎样限制观测信息，读完可用 §11.1~§11.3 形成候选几何。空间线：04 找方向，09 跟轨迹，05 指波束。04 的掩码估计连着 05 的 MVDR 和 08 的分离方法。干扰处理线：06 讲回声消除，07 讲去混响，08 讲语音分离；启用条件和参考依赖见 §10.1 与图 23。工程线：10 讲链路、硬件、评测、芯片，看完去 11 定方案。附录 A（文件 12）汇总符号、术语和数学。附录 B（文件 13）提供学习路径、领域地图、前沿、排错、练习和复现说明。完成第 11 章后，工程读者可到 §10.10 制定联调与验收计划，遇到问题查 §13.4；研究读者可读 §13.3，再做 §13.6 的第 14、16 题。两篇附录均可按需查阅。

5. 三条阅读路径

路径 A：零基础入门（能跑通演示，约 2~3 周）

- 1. 先读本页和第 1 章，再读 §11.1~§11.3，了解选型需要哪些输入条件。
- 2. 02 精读 60 分钟。推导可以先跳，重点是会读图 2~图 7。
- 3. 03 读表格+算例 30 分钟。04 读 4.2、4.3 节+算例 60 分钟，对照看图 12、图 14。05 读 5.1、5.2、5.4 节，跟着手算 60 分钟，对照看图 16。
- 4. 06 读 6.1.1、6.1.2、6.1.7（AEC 在阵列里放哪）、6.1.9 共 60 分钟，对照看图 18。07 读 7.1 节直觉部分和 7.1.1（ Δ/K 照表取值），对照看图 21、图24。08 读 8.1 节三条路线和掩码枢纽 30 分钟。09 读 9.2 节卡尔曼滤波五步 30 分钟。
- 5. 阅读 §10.1、§10.4 和 §10.6，了解参考链路、资源口径与房间仿真。按需查附录 A，再做附录 B 的第 2、3、5、7、10、11、13 题，并用 §13.4 检查常见问题。
- 6. 终点：对照第 8 节自己动手画一遍 33 张图，再在树莓派+ReSpeaker 麦克风阵列上实现指哪说哪。

路径 B：工程实现（形成可验证的前端方案，约 1 周精读）

- 1. 用 §11.1~§11.5 写清任务、几何、场景、模块启用条件和验收指标。第 5 章重点读 MVDR、稳健化与后置滤波；第 6 章核对回声参考、双讲和与波束的顺序条件；第 7 章根据目标房间验证 WPE；第 8 章在确有重叠语音需求时选择分离方法。更换阵列前阅读 §13.3 的泛化专栏。
- 2. 通读第 10 章，按关键路径核算延迟，区分多设备同步与 SRO，统一评测、算力和功耗口径。再查 §13.4，完成 §13.6 的第 7、8、9、11、13、14 题。
- 3. 终点：输出延迟、同步、标定三张预算表。对照 WebRTC AEC3 检查回声消除。用 ERLE 和 MOS 验收。

路径 C：研究前沿（发论文或者打榜，长期）

- 1. 02 的 CRLB 定性能上限。03 的稀疏阵列。04 的 4.6、4.7 节（空间平滑、深度学习定位、ACCDOA 多目标联合表示、SELD 声事件定位检测）。05 的 RTF（相对传递函数）版 MVDR、球谐方法、掩码+GEV（广义特征值波束形成）、端到端网络。
- 2. 06 的 FDKF、混合神经卡尔曼。07 的在线 WPE。08 的扩散模型、GSS 与掩码枢纽。09 的 PHD、LMB、TBD。10 的指标口径（SI-SDR 和 BSS-eval 两套指标不能直接比数值）+CHiME、LibriCSS、STARSS 数据集。
- 3. 用附录 B §13.2 查领域资料，阅读 §13.3 中与课题相关的方向和泛化专栏，再做 §13.6 的第 6、8、12、15、16 题。阅读 CHiME-8 系统报告时，可把实际前端结构与图 23 对照。
- 4. 终点：掩码+MVDR 或者几何无关前端，配大模型后端做基线。

6. 插图地图：33 张图在哪篇

图	文件	所在文档	类型	内容
图1	fig01_binaural	01	示意+曲线	双耳时间差和声级差，Rayleigh 双重理论

图	文件	所在文档	类型	内容
图2	fig02_dsin_geometry	02	示意	时延几何直角三角形
图3	fig03_near_far_field	02	示意	球面波和平面波，远场判据
图4	fig04_delay_phase	02	示意 + 曲线	时延等于相位旋转，给互相关法铺垫
图5	fig05_room_acoustics	02	示意 + 曲线	房间脉冲响应三段、T60、直达临界距离、直达混响比
图6	fig06_stft_cov	02	仿真 + 矩阵	分帧语谱加协方差热图加特征谱
图7	fig07_beampattern_anatomy	02	仿真教学	主瓣、旁瓣、零陷、主瓣宽度、栅瓣
图8	fig08_geometries	03	布局示意	线阵、圆阵、球阵、螺旋阵、分布式
图9	fig09_tradeoffs	03	趋势，分两幅看	(a) 规模权衡：麦数与算法复杂度的取舍；(b) 混响误差曲线：三类定位算法误差随混响加重各自变坏的速度，只看趋势不读绝对值
图10	fig10_sparse_array	03	集合图解	嵌套阵差集，6 个麦得到 23 个连续有符号滞后
图11	fig11_doa_spectrum	04	仿真	Bartlett 峰宽，Capon 峰尖，MUSIC 峰如针
图12	fig12_gcc_phat	04	示意 + 仿真	亚采样 0.93 格加角度换算
图13	fig13_gcc_reverb	04	仿真，核心实证	T60 从 0.4 秒到 1.0 秒，正确率从约 99% 掉到约 55%
图14	fig14_srp_grid	04	仿真 + 几何	网格投票加双曲线交汇
图15	fig15_wng_di	05	仿真，基础结论	超指向低频 WNG 暴跌，延迟求和保持恒定
图16	fig16_beampattern	05	仿真	延迟求和对比 MVDR 在 20 度处的零陷
图17	fig17_gsc	05	系统框图	固定波束、阻塞矩阵、对消器三路
图18	fig18_aec	06	框图 + 仿真	NLMS 收敛约 22 分贝，双讲时冻结更新
图19	fig19_aec_landscape	06	仿真 + 时间线	指定非线性条件下的性能平台与方法演进
图20	fig20_aec_pipeline	06	系统框图	经典链路与线性、神经网络混合链路对比

图	文件	所在文档	类型	内容
图 21	fig21_wpe	07	仿真	语谱拖尾被压掉，边界恢复
图 22	fig22_tracking	09	仿真	粒子滤波平滑后的方向轨迹
图 23	fig23_pipeline	08、09、10	系统框图	较完整前端的参考依赖关系与方向反馈（08、09 只引用）
图 24	fig24_wpe_frames	07	示意	WPE 帧结构：只用过去历史预测当前帧，保护延迟 Δ 的作用
图 25	fig25_latency_budget	10	瀑布条	一组旧设计的延迟拆分示意；实际预算按 §10.1 的关键路径重新测量
图 26	fig26_aec_problem	06	示意	回声怎么形成：房间冲激响应、卷积拖尾、麦克风三者相加
图 27	fig27_aec_concept	06	示意	估计回声路径并相减，DTD 控制自适应更新
图 28	fig28_aec_nlms	06	仿真	NLMS 自适应过程：滤波器长成回声路径，步长取舍
图 29	fig29_aec_erle_freeze	06	仿真	收敛与冻结：平时爬升，双讲段定义失效必须冻结
图 30	fig30_aec_delay_dtd	06	仿真	延迟对齐与双讲：不对齐掉几十分贝，对齐是第一要务
图 31	fig31_aec_nonlinear	06	仿真	指定仿真条件下线性路径与 tanh 非线性路径的性能平台
图 32	fig32_aec_hybrid_select	06	框图 + 示意	线性与神经网络混合处理及条件化选型
图 33	fig33_gcc_two_ways	04	对照	时域滑动乘加等于频域共轭乘加 IFFT，两条路算出同一条曲线、同一个峰

示意图用于解释几何关系，曲线展示指定条件下的可复现结果，框图说明模块之间的信号与控制关系。

7. 十处跨文档联系

- 定位连着追踪连着波束：04 找方向，09 跟轨迹，05 指波束，见 9.4 节和图 23。
- 前端模块的参考依赖与启用条件见 §10.1 和图 23。
- 导向矢量：02 的 2.3 节定义，04、05、08、09 都要用。
- 协方差矩阵：02 的 2.5 节定义，04、05、06 都要用。对角加载可改善条件数，但不能代替足够的独立观测。
- WNG 和 DI 的权衡：02 的 2.6 节提出，05 详细计算，11 用于条件化选型。
- 混响这条线：02 的 2.4 节讲混响是什么，04、05、06、07 讲各自怎么对付它。
- 掩码估计：02 讲语音稀疏性，05 和 08 用掩码估计目标或噪声协方差，并把它们交给波束形成或导引分离。
- 减法和乘法：06 的 6.1 节讲能预测波形就做减法，05 的 5.7 节讲只能估计幅度就做乘法。

9. 几何上限：03 讲摆位定的上限，04、09、10 都要回来看它。
10. 标定和同步：10 的 10.2 节讲标定同步，13 的附录 B 13.4 节讲排错时怎么查它。
-

8. 动手复现

绘图脚本位于 `scripts/`。在仓库根目录运行第 13.7 节列出的两个命令，可重新生成 33 张图；运行时间取决于机器。具体步骤和错误处理见 `scripts/README.md`。Windows 上需把命令中的 `.venv/bin/python` 换成 `.venv\Scripts\python`。

9. 常见问题

图片看不到怎么办？ 请保留仓库目录结构并从仓库中打开文档；图片使用相对路径，单独复制 Markdown 文件会使链接失效。

先读哪篇？ 先读本页，再读 01 和 11，再读 02。之后按第 5 节的路径走。赶时间只读 11 也能得到选型结论。

公式看不懂怎么办？ 先查第 2 章和附录 A 中的符号、术语与数学基础，再结合图 7、图 11、图 15、图 16 阅读第 4、5、7、8 章的推导。

想跑实验怎么办？ 可先按第 8 节重绘 33 张图，再用 `pyroomacoustics` 建立房间仿真基线。公开数据和硬件实验应根据任务、许可证与设备条件选择，练习入口见附录 B 的 §13.1、§13.6。

不同实验的绝对数值能比吗？ 不能。阵列几何、房间、信噪比、数据集、实现和评测口径不同，绝对数值不能直接横向比较。先确认条件一致，再比较趋势和量级。

附录：下一步清单

- [] 15 分钟读完本页，选一条第 5 节的路径。
- [] 阅读第 1 章和第 11 章，分别明确问题定义与选型条件。
- [] 60 分钟读 02，学会读图 7（主瓣、旁瓣、零陷、主瓣宽度、栅瓣）。
- [] 按第 2 节的时间表读 04~08：04、05 各 60~90 分钟，06 约 60~80 分钟，07、08 各 30~45 分钟。
- [] 对照第 8 节画一遍 33 张图，打开 `figures/` 对照正文看图。
- [] 做附录 B 的练习题（入门做 2、3、5、7、10、11、13 题，进阶+6、8、12、15、16 题）。
- [] 用附录 B §13.4 排查常见问题，并按第 10 章编制延迟、同步和标定预算。

阵列几何决定可观测的空间信息，算法在给定数据和模型下利用这些信息。房间混响是远场拾音的主要困难之一。比较波束形成器时，应同时说明目标保持、干扰抑制和失配鲁棒性。

第 1 章 · 问题定义与双耳启示

⚠ 本篇是教程正文第 1 章（正文共 11 章，另有附录 A/B），可独立阅读，前后篇见下方导航。

🏠 首页导读： [00_overview.md](#) | 上一篇：(无) | 下一篇： [02_basics-signal-model.md](#)

本章从客厅里的远场语音交互出发，依次说明空间处理的三项任务、阵列增益的不同度量，以及双耳听觉为机器阵列提供的线索。

客厅里那句“今天天气怎么样”

想象你坐在客厅里，对 3 米外的智能音箱说“今天天气怎么样”。音箱听清这句话，要同时战胜四个敌人：

- 1. **环境噪声**：空调声、车声；
- 2. **房间混响**：声音经墙壁、桌面、天花板反射形成“拖尾”，把音节糊在一起；
- 3. **干扰说话人**：旁边有人在看电视或说话；
- 4. **麦克风自噪声**：传感器自身的底噪，包括热噪声和电路噪声。普通环境里，它往往低于环境噪声；超指向波束形成依赖通道间的精确相消，可能显著放大自噪声，因此自噪声会限制阵列性能（见 §2.6 的白噪声增益 WNG 和 §5.3）。

人用两只耳朵毫不费力就能做到的事，机器要靠**一群麦克风**来做到：因为每个麦克风处于空间不同位置，同一声音到达它们的**时间、强度略有不同**——这些“不同”里藏着声音的**方向信息**，也给了机器**挑选某个方向**的能力。

这些干扰的结构不同，不能用同一个“降噪增益”概括。先区分阵列空间处理承担的任务，再分别定义收益。

空间处理的三项任务

下面三项是阵列空间处理的核心任务：

任务	类比	回答的问题
声源定位	你闭着眼判断声音从哪来	“声音在哪个方向？”
波束形成	你扭头把耳朵和注意力转向说话人	“怎么只听这个方向？”
声源追踪	你跟着走动的说话人持续转头	“他动了，怎么一直盯着听？”

它们没有覆盖开头的全部问题。设备自己的回声由 AEC 处理，房间拖尾由去混响处理，多人同时说话还需要语音分离；这些任务分别在第 6~8 章展开。

定位、波束形成和追踪回答的问题不同，对应的评价指标也不同。下面先计算最基础的白噪声阵列增益。

三类阵列收益

麦克风阵列最容易算清的一项理论收益，是对白噪声的**阵列增益**： M 元延迟求和阵列在理想条件下可得到 $10 \log_{10} M$ dB（功率 2 倍约 3 dB，10 倍为 10 dB；4 麦约 6 dB、8 麦约 9 dB）。这里的条件是：各通道噪声互不相关、目标可按远场平面波对齐、各麦增益和相位一致。定向干扰、弥散混响和模型失配不能直接并入这一个数字；

它们要分别看零陷、DI 与稳健性，具体收益随场景变化。[Kumatani—McDonough—Raj 《Microphone Array Processing for Distant Speech Recognition》CMU 课程讲义，2012](#)

这三类收益不能混用。 $10 \log_{10} M$ 描述独立、等功率通道噪声下的**白噪声增益**（WNG，§2.6），延迟求和阵列在理想无失真归一化下达到这一数值。四面八方到来的**弥散场**，例如晚期混响，要用**指向性指数**（DI）评价；超指向设计可获得高于同麦数延迟求和阵列的 DI，但通常会牺牲 WNG (§5.3)。单个定向干扰则看零陷深度，§5.4 的算例给出一个 -24 dB 零陷。三种声场分别对应 WNG、DI 和零陷深度，不能用其中一个指标替代另外两个。

白噪声增益的推导（各麦噪声相互独立）：

1. **信号侧**：各麦收到的是“同一个声音错开一点时间”，对齐后同相相加——幅度变成 M 倍，所以功率变成 M^2 倍（功率正比于幅度的平方）；
2. **噪声侧**：各麦的噪声互相独立（不相关），相加时不会同相叠加而是“随机抵消一部分”——功率只变成 M 倍（独立随机变量的和的方差 = 方差的和）；
3. **相除**：信噪比提升 $= M^2 / M = M$ ，换成分贝就是 $10 \log_{10} M$ 。

以 4 只麦为例：信号幅度变为 4 倍，功率变为 16 倍；独立噪声的总功率变为 4 倍。因此信噪比提高 4 倍，约为 6 dB。满足上述条件时，麦数翻倍可增加约 3 dB。


对白噪声而言，**信号同相相加，独立噪声只按功率相加**。这给出延迟求和的 WNG 上限；它不是 DI、零陷深度或所有阵列算法的共同上限。

这个结果只依赖相干信号与独立噪声的叠加规律。真实系统还可利用双耳听觉中类似的时差、声级差和方向相关频谱线索。

1.1 双耳听觉的三类定位线索

从阵列模型看，双耳可以近似为带有头部散射的双传感器系统。人类主要利用三组线索判断声源方向，并在嘈杂环境中进行选择聆听：

图1 人类双耳听觉的定位线索（Rayleigh 双重理论）



1. **ITD（双耳时间差）**：声音先到近耳、后到远耳，正侧面时两耳的时间差最大，量级约为数百微秒；按常见成人头部尺寸和 Woodworth 绕头模型估算，约为 $700 \mu s$ （图1(b)）。人耳能利用很小的时间差，但可辨阈值随频率、声级和实验任务变化。频率升高后，相位会绕圈，听觉神经的波形锁相也逐渐减弱，因此纯相位 ITD 会出现歧义。

2. **ILD (双耳声级差, Interaural Level Difference)**: 头颅遮挡使远耳听到的高频变弱; 频率越高、入射越偏向一侧, 声级差通常越明显 (图1(c))。低频波长比头部尺寸大, 绕射更强, ILD 较小。低频主要利用 ITD、高频更多利用 ILD, 是瑞利**双重理论 (duplex theory)** 的直觉版本。机器阵列不能照搬这个频段划分: 当均匀阵间距不满足半波长安全条件时, 高频窄带相位会产生空间混叠, 但非均匀几何、实测阵列流形和宽带融合仍可利用高频信息 (§2.6、§3.2)。
3. **HRTF (头相关传递函数, Head-Related Transfer Function)**: 耳廓的褶皱, 加上头和肩膀的散射, 对不同方向、尤其是不同俯仰角的声音产生不同的滤波 (谱峰/谱谷位置变化), 这是人类分辨前后、上下的依据。

这些听觉线索在机器阵列中都有对应的观测量或处理方法。


双耳线索与阵列方法的对应关系

下表列出双耳听觉现象与阵列处理方法之间的联系:

人类的办法	机器阵列的对应技术 (术语先不用记)	章节
ITD 双耳时间差	GCC-PHAT 测 TDOA (§4.2)	§4
头颅当挡板	挡板效应放大麦间相位差 (§3.2)	§3
ILD 与 HRTF 谱线索	测量每个方向的“标准答案” (导向矢量; 全体方向的集合叫阵列流形, 标定见 §3.4、§10.2)、DNN 学习方向特征 (§4.7)	§3、§4、§10
优先效应 (先到声主导方位感)	提醒算法区分直达声、早期反射与晚期混响; WPE 主要预测晚期混响, 机制与听觉优先效应不同	§2.4、§7.1
鸡尾酒会效应 (多人里挑一个听)	波束形成 + 语音分离	§5、§8.1

人类用两只耳朵、头部与耳廓产生 ITD、ILD 和 HRTF, 再由神经系统融合这些线索。硬件形态先提供可观测信息, 后端算法再利用信息; 机器阵列也是同一分工。解析模型负责约束和可解释边界, 数据驱动方法可补足难以精确建模的细节。

第 2 章将从传播时延出发, 把这些空间差异写成阵列信号模型。



第 2 章 · 声音到达阵列时发生了什么

⚠ 本篇是正文第 2 章（正文共 11 章，另有附录 A/B），可独立阅读，前后篇见下方导航。

🏠 首页导读： [00_overview.md](#) | 上一篇： [01_problem-definition.md](#) | 下一篇： [03_array-geometry.md](#)

2.1 核心事实：同一声音，到达各麦克风有先有后

声音速度 $c \approx 343$ m/s。两个相距 4 cm 的麦克风，当声音沿两麦连线的方向传来时（先到近麦、后到远麦，时差最大的情形），到达时间差约 $\frac{0.04}{343} \approx 0.116$ ms（16 kHz 采样率下约 2 个采样点）；当声音垂直于连线传来时，两麦同时收到、时差为零。时差随方向连续变化——这正是它能用来测向的原因。这个“到达时间差”是整个领域的信息源泉，记作 TDOA（Time Difference of Arrival）。

时差的几何来源： $\Delta\tau = d \sin \theta / c$ 。平面波以角度 θ 斜入射到间距 d 的两个麦克风：波前是平面，先碰到近麦、再碰到远麦，多走一截路程。把两麦连线（长度 d ，作斜边）与波前（作一条直角边）画成直角三角形， θ 角的对边就是路程差 $\Delta = d \sin \theta$ （图2）；路程折成时间即得全书最常用的几何关系：

$$\Delta\tau = \frac{d \sin \theta}{c}。$$

其中 d 为两麦间距（m）， θ 为声源方向角， c 为声速。

全书角度约定（后文凡涉角度一律沿用）： θ 从正横方向（broadside，垂直于两麦连线的方向）起算。正横 $\theta = 0^\circ$ 时两麦同时收到波前，时差为零；端射方向（endfire，沿两麦连线） $\theta = \pm 90^\circ$ 时路程差幅值为 d 、时差幅值最大。有些文献从阵列轴起算，此时关系写成 $\Delta\tau = d \cos \theta / c$ 。比较公式前应先统一角度零点和正方向；两种起算方式相差 90° 。

图2 时延的几何来源与角度约定（示意）




图 2 中的直角三角形给出路程差 $d \sin \theta$ 。本书规定入射角从正横方向起算，因此正横时差为零，端射时差达到最大。

离散化与同步。16 kHz 采样率下，采样间隔为 $1/16000 = 62.5 \mu\text{s}$ ，对应约 $343 \times 62.5 \mu\text{s} \approx 2.1 \text{ cm}$ 的传播距离。4 cm 阵列的最大时差约为 $117 \mu\text{s}$ ，不到两个采样间隔。仅按整数采样点定位会得到很粗的方向，因此实际系统需要亚采样 TDOA 估计，例如对互相关峰插值、对相关函数上采样，或在频域拟合相位斜率（见 §4.2）。多路信号还必须同步采样。同一设备可让多通道模数转换器（ADC，Analog-to-Digital Converter）共享时钟；分布式设备则有独立晶振。相对偏移为 50 ppm 时，1 小时累积约 $50 \times 10^{-6} \times 3600 = 0.18 \text{ 秒}$ ，远大于阵列所测的微秒级时差，因此需要时钟同步或采样率偏移补偿（§10.2）。

上式在 §2.3 编号为式（2-1），采用平面波近似。声源接近阵列时，波前曲率不能忽略，需要先区分近场与远场。

2.2 近场与远场

- **近场**（声源很近）：波前（波阵面，即相位相同的面）是球面，各麦克风信号的时间和幅度都有差别；
- **远场**（声源距离远大于阵列尺寸）：波前近似平面，各麦克风收到的是“同一个信号错开一些时间”，幅度几乎相同。

经验判据（Fraunhofer 距离）：当 $r > \frac{2D^2}{\lambda}$ （ D 为阵列孔径、 λ 为波长）时按远场处理。**注意孔径 D 是平方项，阵列越小越容易满足**：7 cm 小阵列在 1 kHz（ $\lambda = 0.343 \text{ m}$ ）时只需 $2 \times 0.07^2 / 0.343 \approx 0.029 \text{ m} \approx 3 \text{ cm}$ ——所以智能音箱这类小阵列在整个房间内都是远场问题；而 1.26 m 的会议大线阵在 1 kHz 下需要约 9 m 才算远场，放在会议室里近场球面波效应不可忽略，定位与波束都得改用球面波模型。

Fraunhofer 判据的推导：1. 球面波到达阵列中心与到达边缘的路程不一样。阵列半宽 $D/2$ ，由勾股定理，这个额外路程是 $\sqrt{r^2 + (D/2)^2} - r$ ；2. $r \gg D$ 时用近似 $\sqrt{1+x} \approx 1 + x/2$ 展开： $\sqrt{r^2 + (D/2)^2} - r \approx \frac{D^2}{8r}$ ；

B-1 泰勒展开：先提出 r^2 ： $\sqrt{r^2 + (D/2)^2} - r = r \left[\sqrt{1+x} - 1 \right]$ ，其中 $x = (D/2r)^2$ 。当 $x \ll 1$ 时， $\sqrt{1+x} \approx 1 + x/2$ ，因此路程差近似为 $r \cdot x/2 = D^2/(8r)$ 。Fraunhofer 判据中的 $8r$ 由此得到。3. 工程约定：只要这个“球面弯曲造成的误差”小于约十六分之一波长（ $\lambda/16$ ，相位误差约 22.5° ，平面波假设就足够准），就算远场： $\frac{D^2}{8r} \leq \frac{\lambda}{16} \Rightarrow r \geq \frac{2D^2}{\lambda}$ 。

所以 Fraunhofer 距离不是物理突变点，而是“相位误差还能忍”的约定线。

为何选 $\lambda/16$ （ 22.5° ）作为示例容限：路程误差 Δ 对应相位误差 $2\pi\Delta/\lambda$ ；当 $\Delta = \lambda/16$ 时，相位误差为 22.5° 。两路等幅信号相干叠加时，这一相位差造成的幅度损失约 2%（约 0.2 dB）。 $\lambda/16$ 是本节为了说明数量级采用的工程容限，不是普适常数。

图3 近场与远场声场模型




图 3 对比两种波前：近场采用球面波模型，各通道同时存在传播时延和幅度差；远场近似为平面波，传播模型主要由方向决定。这是下一节远场向量模型的前提。

确定远场条件后，可以把麦克风之间的传播时延写成导向矢量。

2.3 信号模型：把“声音有先有后”写成数学

符号约定（全书通用）：标量用普通斜体，如 s 、 τ 、 θ 、 σ^2 ；向量用头顶箭头，如 $\vec{x}$ 、 $\vec{a}$ 、 $\vec{w}$ （默认列向量，零向量记 $\vec{0}$ ）；矩阵用加粗大写，如 $\mathbf{R}$ 、 $\mathbf{C}$ 、 $\mathbf{\Gamma}$ 、 $\mathbf{E}_n$ 。

再认几枚上标： H 是共轭转置（频域复数用）、 $\top$ 是转置（时域实数用）、 $*$ 是共轭、 $^{-1}$ 是逆； $\hat{\cdot}$ 表示估计值， $\|\cdot\|$ 为范数、 $|\cdot|$ 为幅度。

标量上标星号 vs 向量上标 H：单个复数取共轭用上标星号（如 X_2^* ），整列向量转置再共轭用上标 H（如 $\vec{x}^H$ ）——后文凡见上标 H 都是向量/矩阵操作，凡见上标星号都是标量操作，对上号就不会认错。

一个容易踩坑的例外：语音文献习惯用 $X(f)$ 、 $X(n, f)$ 这类大写字母表示“第 f 个频点上的复数谱值”——它们是标量（单个复数），不是矩阵；本报告沿用此习惯，并在首次出现处注明。

字母复用：受文献惯例所限， k 可表示频点索引、波数或 WPE 的滞后帧号； D 可表示阵列孔径或 PHD 强度函数； λ 可表示波长、WPE 功率谱或矩阵特征值； K 可表示声源数或 WPE 预测阶数； s 可表示源信号或追踪状态。每个符号以所在公式的定义为准。

本节只做一件事：把 §2.1 那句“同一声音到达各麦有先有后”一步步写成可以计算的式子。分三步走，每一步都交代“为什么”。

第一步：时域模型——每个麦克风一个式子

远场、单声源时，第 m 个麦克风 ($m = 1, 2, \dots, M$) 录到的信号：

$$x_m(t) = s(t - \tau_m) + n_m(t)。$$

- $x_m(t)$: 第 m 路录音波形——这是你实际拿到的数据；下标 m 表示“第几个麦克风”， t 是时间；
- $s(t)$: 声源发出的原始信号——你想恢复的东西；注意它不带下标 m ，因为远场平面波假设下各麦收到的是同一个 $s(t)$ ，只是时间有先后；
- τ_m : 声音到达第 m 个麦的时延（秒）——关键未知量，它由声源方向 θ 决定（所以后面写成 $\tau_m(\theta)$ ）；
- $n_m(t)$: 第 m 路的噪声。

这个式子很诚实，但有个麻烦：“移位”操作不好算—— $s(t - \tau_m)$ 里未知数藏在函数的自变量里，没法做加减乘除、没法解方程。

第二步：搬到频率域——延迟从“移位”变成“转个角度”

傅里叶变换有一条关键性质（时移性质）：

$$s(t - \tau) \xrightarrow{\text{傅里叶变换}} S(f) e^{-j2\pi f \tau}。$$

左边是时域的“晚到 τ 秒”，右边是频域的“乘上一个复数”。乘法比移位好处理得多——这就是整个领域都在频域干活的原因。

这个 $e^{-j2\pi f \tau}$ 到底是什么？它是复平面上一个长度为 1 的箭头，从正实轴出发顺时针转过角度 $2\pi f \tau$ （图4(b)）。其中 j 是虚数单位（ $j^2 = -1$ ）； e 的复指数由欧拉公式定义： $e^{j\phi} = \cos \phi + j \sin \phi$ ；有些书把 $2\pi f$ 写成 ω （角频率），两者是一回事。直觉检验：延迟恰好等于一个周期（ $\tau = 1/f$ ）时转过整整一圈 2π ——波形平移一个周期后与原波形重合，箭头也转回原地，两边对上了 $\checkmark$ 。

图4 时延为什么变成 $e^{-j2\pi f \tau}$ ：几何直觉（4 cm 麦距、正侧向、 $\tau=0.116$ ms）




图 4 (b) 表明，纯时延对应单位模复数，只改变相位而不改变幅度。图 4 (c) 给出相位与频率的线性关系，其斜率为 $-2\pi\tau$ ；§4.2 的 GCC-PHAT 正是利用这项关系估计时延。

图 4 (c) 还说明，同一时延引起的相位旋转与频率成正比。相位展开后，直线斜率为 $-2\pi\tau$ ；实际数据中的相位缠绕、噪声和混响会使估计更复杂。

第三步：把 M 个式子摞起来，写成向量

对第 m 路、第 f 个频点，时移性质给出：

$$X_m(f) = e^{-j2\pi f \tau_m(\theta)} S(f) + N_m(f)。$$

- $X_m(f)$ 、 $S(f)$ 、 $N_m(f)$: 第 m 路/声源在第 f 个频点上的复数谱值——都是标量（单个复数）；
- $e^{-j2\pi f \tau_m(\theta)}$: 延迟造成的相位旋转因子——也是标量。

把 M 路的式子竖着摆起来：

$$\underbrace{\begin{bmatrix} X_1(f) \\ X_2(f) \\ \vdots \\ X_M(f) \end{bmatrix}}_{\vec{x}(f)} = \underbrace{\begin{bmatrix} e^{-j2\pi f\tau_1(\theta)} \\ e^{-j2\pi f\tau_2(\theta)} \\ \vdots \\ e^{-j2\pi f\tau_M(\theta)} \end{bmatrix}}_{\vec{a}(\theta)} S(f) + \underbrace{\begin{bmatrix} N_1(f) \\ \vdots \\ N_M(f) \end{bmatrix}}_{\vec{n}(f)}。$$

每一行就是上面那个标量式子；把公共的 $S(f)$ 提到列向量外面，就得到全书最常用的紧凑形式：

$$\vec{x} = \vec{a}(\theta) s + \vec{n}。$$

(2-1)

- $\vec{x}$ ： M 路信号的列向量（ M 为麦数），头顶箭头 = 向量； $\vec{a}(\theta)$ ： 导向矢量（定义见下条）； θ ： 声源方向（想求的）； s ： 该频点的声源谱（标量），即上面逐行式子中的 $S(f)$ ； $\vec{n}$ ： 噪声向量（紧凑写法省略频点自变量 f ），下文沿用此简写）；
- $\vec{a}(\theta)$ ： 导向矢量（steering vector）——它是“如果声源真的在 θ 方向，各麦信号的相对相位应该是什么样”的**标准答案**。注意它的每个分量模长都是 1（只转相位、不改幅度），分量之间的差异全部来自各麦时延差 $\tau_m(\theta)$ 。几乎所有定位与波束算法，本质都是“拿真实数据和各个方向的 $\vec{a}(\theta)$ 比对”。

手算一遍：阵列配置——3 麦、间距 4 cm、孔径 8 cm；声源 30° （正横起算，§2.1 的约定与推导；取麦 1 为参考， $\tau_1 = 0$ ）、 $f = 1$ kHz。相邻麦时延差 $\Delta\tau = \frac{d \sin 30^\circ}{c} = \frac{0.04 \times 0.5}{343} \approx 58.3 \mu\text{s}$ ，相邻麦相位差 $2\pi f \Delta\tau \approx 0.366 \text{ rad} \approx 21^\circ$ ，于是 $\vec{a} = [1, e^{-j0.366}, e^{-j0.733}]^\top$ ——读作：“麦 2 比麦 1 相位落后 21° ，麦 3 落后 42° ”。把这句话从“文字”变成“一个复数向量”，就是导向矢量的全部含义。

混响：实际房间中麦克风收到“直达声 + 一堆反射”的叠加（声源与房间脉冲响应 RIR 的卷积），混响强度用 T_{60} 度量——混响是本领域最难缠的敌人之一（与噪声、干扰、自噪并列，见 §1），它到底是怎么来的、怎么定量描述，见下一节。

直达声模型明确后，§2.4 再加入房间反射，说明混响会怎样改变观测。

2.4 房间声学：混响到底是怎么来的

房间脉冲响应（RIR, Room Impulse Response）：在房间里拍手一次，麦克风录到的“啪——嗡嗡嗡”就是 RIR。它就是房间的“指纹”：麦克风收到的任何声音 = 干净声音与 RIR 做卷积。RIR 分三段（图5(a)）：

1. **直达声**：从声源直线到达，最干净、携带最准的方向信息；
2. **早期反射**（到达后约 80 ms 内）：只反射一两次的回声。它响度上有帮助，但会**模糊方向线索**——人类听觉靠“优先效应”（先入为主）不被它带偏，算法却容易被带偏；
3. **晚期混响**：经多次反射后形成的弥散尾音。统计建模时，常把充分弥散的晚期混响近似为各向同性声场；这个近似适合分析波束形成器的 DI（指向性指数，§2.6），但不表示混响在时间上就是独立白噪声。WPE（第 7 章）正是利用晚期混响仍有时间相关性来做预测消除。

图5 房间声学基础：混响从哪来、有多强、多远开始失控（模拟）




图 5 (a) 把房间脉冲响应分为直达声、早期反射和晚期混响；图 5 (b) 用能量衰减 60 dB 所需时间定义 T_{60} ；图 5 (c) 展示给定房间参数下临界距离与体积、混响时间的关系。图中的距离只适用于相应参数，不能直接作为所有房间的分界。

混响有多强： T_{60} 与赛宾公式。 T_{60} 是声能衰减 60 dB 所需的时间（图5(b)），可用赛宾（Sabine）公式估算：

$$T_{60} = \frac{0.161 V}{A}, \quad A = \sum_i S_i \alpha_i.$$

- V ：房间体积 (m^3)； S_i 、 α_i ：第 i 个表面的面积与吸声系数 (0=全反射的光滑瓷砖，1=全吸声的开放窗户)。
- **算例**（本例是房间算例，不涉及阵列配置）：5 m × 4 m × 2.8 m 的客厅 ($V = 56 \text{ m}^3$)，软硬装合计吸声量 $A \approx 18 \text{ m}^2$ ，则 $T_{60} \approx 0.5 \text{ s}$ ——正是“安静客厅 0.3~0.5 s”的来历；瓷砖大食堂 A 小一个量级， T_{60} 可达 2 s 以上。

这个公式怎么推出来的（五步，能量守恒 + 一个几何事实）：1. **模型**：混响期的声能在房间里近似均匀分布（扩散场假设），声线不断撞墙，每撞一次被吸收掉一部分；2. **几何事实**：声线在房间中平均飞行 $\ell = \frac{4V}{S}$ 米撞一次墙（统计几何的经典结果， S 是所有墙面的总面积）。直觉检验：房间越大飞得越远、墙越多撞得越勤，都对得上；

可跳过：式中 4 从哪里来（平均自由程 $4V/S$ ）：想象房间里各方向均匀乱飞的大量声线。任取一个小体积元，它“看到”的墙面投影平均后恰好是总表面积的 $1/4$ （名字不用记：凸体平均投影面积 = 表面积/4，直觉是球面各方向投影平均带来因子 $1/4$ ）。单位体积内声线单位时间扫过的“墙面碰撞率” = $cS/(4V)$ ，走一步的平均距离即其倒数 $\ell = 4V/S$ 。量纲检查： V/S 是长度，乘无量纲的 4 仍是长度 ✓；立方房间边长为 L 时 $\ell = 4L^3/(6L^2) = 2L/3$ ，与“穿过房间约半个边长撞一次墙”的直觉一致。3. **每秒能量损失率**：撞墙频率 = $\frac{c}{\ell} = \frac{cS}{4V}$ （次/秒），每次损失能量比例 $\bar{\alpha}$ （平均吸声系数），于是每秒损失率 = $\frac{cS\bar{\alpha}}{4V} = \frac{cA}{4V}$ ；4. **列方程求解**： $\frac{dE}{dt} = -\frac{cA}{4V} E$ ——“损失率正比于当前能量”的方程，解是指数衰减 $E(t) = E_0 e^{-\frac{cA}{4V}t}$ ；5. **代入定义收尾**： T_{60} 是能量衰减 60 dB 的时间——注意 60 dB 是能量比 10^6 （不是 10^3 ：能量的 dB 用 $10 \log_{10}$ ， $10 \log_{10} 10^6 = 60$ ）。令 $e^{-\frac{cA}{4V}T_{60}} = 10^{-6}$ ，两边取对数： $-\frac{cA}{4V}T_{60} = 6 \ln 10$ ，解出

$$T_{60} = \frac{24 \ln 10}{c} \cdot \frac{V}{A} = \frac{55.3}{343} \cdot \frac{V}{A} \approx 0.161 \frac{V}{A} \checkmark.$$

B-2 常数 0.161 的来源： $24 \ln 10 \approx 55.26$ ；取声速 $c = 343 \text{ m/s}$ ， $55.26/343 \approx 0.161$ 。其中 $6 \ln 10$ 来自 60 dB 的能量比，几何平均路径项再带来因子 4。

适用边界：推导用了“扩散场 + 弱吸收”假设。当平均吸声系数较大 ($\bar{\alpha} > 0.3$ ，比如录音棚) 时赛宾会高估混响时间，要换 Eyring 公式 $T_{60} = \frac{-0.161V}{S \ln(1 - \bar{\alpha})}$ (极端检查: $\bar{\alpha} = 1$ 时 Eyring 给出 $T_{60} = 0$ ，物理正确；赛宾却给出非零值，错了)。

多远开始失控：直达混响比 DRR 与临界距离。直达声随距离按平方反比衰减 (每远一倍弱 6 dB)，而晚期混响在房间里处处一样响。两者相等的位置叫**临界距离** d_c ：

$$d_c \approx 0.057 \sqrt{\frac{V}{T_{60}}} \text{ (m)}。$$

(此式默认声源全向辐射，即指向性因子 $Q = 1$ ；若声源有指向性 (如人声朝前更响)，把 Q 乘进根号内的分子：
 $d_c \approx 0.057 \sqrt{QV/T_{60}}$ 。)

这个公式怎么推出来的 (四步，全是能量账)：1. **直达声能量密度**：声源功率 W 均匀洒在半径 r 的球面上，距离 r 处的能量密度 $\propto \frac{W}{4\pi r^2}$ ——平方反比，越近越强；2. **混响声能量密度**：房间里的混响能量不断被墙面吸收、又不断被声源补充，稳态下弥散能量密度 $\propto \frac{4W}{A}$ (A 是赛宾吸声量)——与位置无关，处处一样；

可跳过：弥散能量式中 4 从哪里来 ($4W/A$)：稳态能量平衡是“注入功率 = 吸收功率”。墙面每秒吸收的功率 = 能量密度 $E \times$ 声速 $c \times$ 有效吸收面积。关键一步：各向同性声场中，只有面向墙面方向的能量流才会被吸收，对半球方向平均后有效因子恰为 $1/4$ (各向同性场向墙面投影平均带来的 $1/4$ 因子，直觉版的严格说法见上)，于是吸收功率 = $E \cdot cA/4$ 。令它等于注入功率 W ，解得 $E = 4W/(cA)$ ；写成正比关系即 $4W/A$ 。与上一步平均自由程里的 4 是同一个几何根源：都是“各向同性场向一面墙投影”带来的 $1/4$ 。3. **令两者相等** (临界距离的定义)： $\frac{1}{4\pi r^2} = \frac{4}{A} \Rightarrow d_c = \sqrt{\frac{A}{16\pi}}$ ；4. **代入赛宾公式** $A = \frac{0.161V}{T_{60}}$ ：
 $d_c = \sqrt{\frac{0.161V}{16\pi T_{60}}} = \sqrt{0.00321 \frac{V}{T_{60}}} \approx 0.057 \sqrt{\frac{V}{T_{60}}}$ 。B-3 常数 0.057 的来源： $0.161/(16\pi) \approx 0.003203$ ，再开平方得到 $0.0566 \approx 0.057$ 。因此该常数同时包含赛宾公式中的 0.161 和球面扩散项 16π 。

典型客厅 d_c 只有 0.5~1.5 m (图5(c))。智能音箱在 3 m 外交互时，混响能量已经超过直达声 (DRR < 0) ——远场语音难，难在使用场景天然运行在混响占优区。DRR 也是估计声源距离的物理依据。[Montana State 房间声学讲义](#)

仿真怎么造混响：镜像法 (Image Method, 镜像声源法, Allen & Berkley 1979) 把墙面反射等效为镜像声源的叠加，开源库 pyroomacoustics 可直接生成任意房间、任意阵列的房间脉冲响应 (RIR)：拿 ShoeBox 类建房、调 compute_rir 算脉冲响应 (函数名以版本文档为准)。

反过来，怎么实测一个房间的混响：粗糙做法是拍手/爆破气球后看衰减 (只能估个大概)；标准做法是**指数正弦扫频 (ESS, Farina 2000)**——播放一段频率从低到高指数上升的扫频信号，录音后做反卷积即可干净地分离出 RIR，抗噪且不受播放设备失真影响 (失真成分会被推到 RIR 的“负时间”区直接丢弃)。也可以用普通语音盲估 T_{60} 和 DRR (例如利用两麦相干函数估计直达-弥散比)，供无法播放测试音的在线场景使用。

房间传播模型解释了麦克风信号的组成。算法实现还需要把连续波形组织成 STFT、快拍和协方差矩阵。

2.5 数据怎么组织：STFT、快拍与协方差矩阵

后面的算法反复出现三个词——STFT、快拍、协方差矩阵，先在这里一次讲清。

STFT（短时傅里叶变换，Short-Time Fourier Transform）把波形切成重叠短帧，每帧加窗后做快速傅里叶变换（Fast Fourier Transform, FFT），得到时间—频率复数网格，即语谱图（图 6（a）（b））。增强或波束示例可用 32 ms 窗、8 ms 帧移；自动语音识别（Automatic Speech Recognition, ASR）前端常见另一组设置为 25 ms/10 ms。比较文献时应核对采样率、窗函数、窗长和帧移。每个时频点同时包含幅度与相位。

为什么非要这张表？因为**宽带语音由此被切成一堆窄带问题**：同一频点上，阵列模型 $\vec{x} = \vec{a}(\theta)s + \vec{n}$ 才严格成立——时延 τ 对应的相位旋转 $2\pi f\tau$ 随频率变化，只在一个频点内，“延迟”才恰好是“乘一个固定复数”；宽带信号的导向矢量随频率而变，共用不了一个 $\vec{a}(\theta)$ 。这就是第 4、5 章算法逐频点（STFT 后）处理的原因。

STFT 分帧数字例子：阵列配置——4 麦、常规小间距；采样率 16 kHz、窗长 32 ms、帧移 8 ms。窗长折成采样点 $= 16000 \times 0.032 = 512$ 点（FFT 常用 512 点）；帧移 $= 16000 \times 0.008 = 128$ 点，相邻帧重叠 $(512 - 128)/512 = 75\%$ 。1 s 语音共 $(1000 - 32)/8 + 1 \approx 122$ 帧；每帧 FFT 给出 257 个有效频点（0~8 kHz，频率分辨率 $16000/512 = 31.25$ Hz）。于是 1 s、4 麦录音展开为 $122 \times 257 = 31354$ 个时频点，每个点上一个 4 维快拍向量——这就是后文协方差矩阵 $\hat{\mathbf{R}}(f)$ 在每个频点上平均的对象（每频点约 122 个快拍参与平均）。

快拍（snapshot，快照向量）：固定一个频点 f 、取某一帧 t ，把 M 个麦克风在该时频点 (f, t) 的复数谱排成列向量 $\vec{x}(f, t)$ ，就是一个快拍——相当于阵列在某瞬间拍下的一张“空间照片”（图6(b) 里标的那个格子就是它，按正文记作 (f, t) ， f 是频点号、 t 是帧号）。

空间协方差矩阵：单张快拍太噪，把几十到几百个快拍平均：

$$\hat{\mathbf{R}}(f) = \frac{1}{T} \sum_t \vec{x}(f, t) \vec{x}^H(f, t)。$$

(2-2)

它是 $M \times M$ 的复数矩阵，第 m, n 个元素记录“麦 m 与麦 n 在该频点上的相关程度与相位差”（图6(c)）。它浓缩了阵列数据的二阶统计信息。Capon、MVDR、MUSIC 都以它为输入；MUSIC 再用特征分解把观测空间分成信号子空间和噪声子空间。只有在窄带远场模型正确、 $K < M$ 个声源互不相干、噪声为空间白噪声且快拍足够多时，才可能把高于噪声底的 K 个特征值解释成 K 个声源。相干反射、彩色噪声、有限快拍和阵列失配都会破坏这种整齐分组。

图6 从波形到协方差矩阵：阵列算法处理的数据形态（模拟）




图 6 (a) (b) 展示语谱图中的复数时频点，图 6 (c) 展示通道间相关性和相位差形成的协方差矩阵。图 6 (d) 只在独立声源、白噪声和充足快拍等条件下，才能把较大特征值的个数与声源数联系起来。

两个常考的细节：①快拍数太少时 $\hat{\mathbf{R}}$ 估计不准、小特征值乱跳，这是 Capon/MVDR 需要“对角加载” (§5.4) 的根源；②帧移小、相邻帧高度重叠，快拍间并不独立，有效快拍数比帧数少。

快拍不够时会发生什么（处理方法见 §5.4、§8.1）：样本协方差是 T 个秩一外积之和，因此

$$\text{rank}(\hat{\mathbf{R}}) \leq \min(M, T)。$$

若未去均值， $T < M$ 时它必然奇异；若先用同一批样本估计并减去均值，秩至多为 $T - 1$ ，此时 $T \leq M$ 就必然奇异。即使 $T \geq M$ ，强相关快拍、很差的样本数和估计误差仍可能让求逆不稳，所以不存在通用的“ $T \geq 2M$ 就安全”门槛。常见处理有两类：一是收缩估计

$$\hat{\mathbf{R}}_{\text{shrink}} = (1 - \rho)\hat{\mathbf{R}} + \rho \frac{\text{tr} \hat{\mathbf{R}}}{M} \mathbf{I},$$

用 $0 \leq \rho \leq 1$ 在样本统计量和各向同性先验之间折中；§5.4 的对角加载与它目标相近。二是用时频掩码为快拍加权，分别估计目标或噪声协方差 (§8.1)。掩码可以减少干扰泄漏，但也会减少有效样本数，仍须检查矩阵的条件数并配合加载。

顺带认识一下语音这个信号本身（后面许多设计都与这三条有关）：①典型成人语音的基频常落在约 80~300 Hz，电话语音传统通带约为 300 Hz~3.4 kHz；宽带语音还包含更高频的辅音和摩擦音。谐波结构会让互相关出现周期性假峰，因此 TDOA 算法常做宽带加权 (§4.2)。②语音短时近似平稳、长时非平稳，所以常按几十毫秒分帧。③多说话人语音在时频域常呈近似稀疏：不少时频点由某个声源占优，这是掩码类方法与聚类方法能工作的依据 (§8.1)，但混响和同频谐波会削弱这一近似。阵列能否利用高频定位，还要同时检查混叠：4 cm 间距对应的全视场安全上限

约 4.3 kHz, 3 cm 间距约 5.7 kHz (§2.6); 超过上限并非一律不能用, 而是必须结合转向范围、阵列几何和宽带融合处理歧义。

有了协方差和导向矢量, 便可以定义波束图及其分辨率、旁瓣、WNG 和 DI。

2.6 怎么衡量一个波束好不好：先学会读波束图

本节路线图：四个度量回答四个问题——主瓣多窄（看得多细）？旁瓣多高（漏多少）？DI（抗混响/弥散噪声的能力）？WNG（抗自身底噪的能力）？

前面说过，波束形成器就是“让某个方向的信号通过、压住其他方向”。把它对每个方向的增益都画出来，就是波束图（beam pattern）——横轴是方向，纵轴是增益（dB）。它是本节四个度量的共同载体，先花一分钟学会读它（图 7(a)）：

- 主瓣（main lobe）：想听的方向上拱起的那个高峰。峰顶增益 0 dB（无失真通过）；
- 旁瓣（side lobes）：主瓣两侧一连串越来越矮的小峰——它们在其他方向的声音漏进来的通道；
- 零点（nulls）：瓣与瓣之间的深谷——这些方向上各麦信号恰好相消干涉，几乎完全听不到；
- 为什么长这样：同相叠加形成峰、反相抵消形成谷——完整推导（等比数列求和）见 §5.2，此处先会读图。




图 7 (a) 标出主瓣、旁瓣、零点和半功率宽度；数值结果约为 14.8° ，离散 ULA 近似为 14.7° 。图 7 (b) 把间距增至 λ ，在 -7.7° 出现与主瓣等高的栅瓣。

度量一：主瓣宽度 HPBW（分辨率，Half-Power Beam Width）。主瓣两侧功率降到峰值一半的两个点之间的夹角，就是半功率波束宽度。

半功率点与 -3 dB 点：功率减半为 $10\log_{10} 0.5 = -3.01\text{ dB}$ 。波束图若按幅度绘制，半功率对应幅度 $1/\sqrt{2} \approx 0.707$ ，同样得到 $20\log_{10} 0.707 = -3.01\text{ dB}$ 。因此“半功率点”和“ -3 dB 点”指同一位置（图 7 (a) 的红色双箭头）。幅度减半则是 -6 dB ，对应功率变为四分之一。

对常规波束扫描而言，HPBW 可用来估计角分辨率：两个源的间隔小于主瓣宽度时，扫描谱往往难以形成两个清楚峰值。对 M 元、等权、等间距 ULA，其离散阵因子给出的宽阵列近似为

$$\text{HPBW} \approx \frac{0.886 \lambda}{Md \cos \theta_0} \text{ rad.}$$

可跳过：系数 0.886 从哪里来：均匀线阵的归一化阵因子是 Dirichlet 核 $\frac{\sin(M\psi/2)}{M \sin(\psi/2)}$ (§5.2 的等比数列求和结果)，其中 $\psi = 2\pi d(\sin \theta - \sin \theta_0)/\lambda$ 。半功率点要求幅度 $= 1/\sqrt{2}$ ，即 $|\sin(M\psi/2)/(M\psi/2)| \approx 1/\sqrt{2}$ (大 M 时分母 $\sin(\psi/2) \approx \psi/2$)。解 $\sin x/x = 1/\sqrt{2}$ 得 $x \approx 1.3916$ ($x = M\psi/2$)，于是单边 $\psi_{3dB} = 2 \times 1.3916/M = 2.7832/M$ ；双边宽度换算到 $\sin \theta$ 域再除以 $\cos \theta_0$ ($d \sin \theta$ 微分带来 $1/\cos \theta_0$)，得 $\text{HPBW} = 2 \times 1.3916/(\pi) \times \lambda/(Md \cos \theta_0)$ ，而 $2 \times 1.3916/\pi = 0.8859 \approx 0.886$ 。

系数 0.886 来自方程 $\sin x/x = 1/\sqrt{2}$ 的解。分母中的 Md 是离散阵因子近似产生的尺度，物理首末阵元跨度仍为 $D_{\text{phys}} = (M-1)d$ 。当 M 较大时两者接近； λ/D_{phys} 可用于孔径量级判断，但不是上述离散 ULA 公式的精确替换。

读法：阵列的电尺寸越大、频率越高（波长越短），主瓣越窄；转向接近端射时， $\cos \theta_0$ 变小，主瓣变宽。该式还用了主瓣附近的小角近似，因此主瓣很宽或转向接近端射时，应直接计算阵因子，而不是把公式外推到几百度。若只知道小阵列的物理跨度 $D_{\text{phys}} = 7 \text{ cm}$ ，用 λ/D_{phys} 可看出：1 kHz 时比整个可视范围还宽，8 kHz 时进入几十度量级。这只是孔径尺度判断。图7(a)的条件是 8 麦、 $d = \lambda/2$ 、指向 30° ；代入离散 ULA 公式得 $0.886/(8 \times 0.5 \times \cos 30^\circ) \approx 0.256 \text{ rad} \approx 14.7^\circ$ ，与图中约 14.8° 一致。

B-4 孔径尺度的明细： $0.886 \times 0.343/0.07 \approx 4.34 \text{ rad}$ 。这个量已超过线阵的 180° 可视范围，说明窄主瓣近似不适用；正确结论是“该物理孔径在 1 kHz 几乎没有方向选择能力”，而不是把 249° 当成可测的 HPBW。

度量二：旁瓣电平 SLL（泄漏）。最高的那个旁瓣比主瓣低多少 dB。均匀加权的 DSB (DSB = 延迟求和波束形成器，即“对齐后等权相加”，详见 §5.2) 约 -13 dB ——换算过来是：最强泄漏方向的功率仍有主瓣方向的约 5% ($10^{-13/10}$)。如果恰好有个大音量干扰（电视）落在那个方向，它就会漏进来 5%——所以 MVDR 要专门在干扰方向挖零陷 (§5.4)。压低旁瓣的经典办法是给麦克风加权（中间重、边缘轻，如汉明加权），代价是主瓣变宽——又是权衡。

可跳过：-13 dB 从哪里来：均匀加权阵因子近似为 $\sin x/x$ 型 (x 正比于偏离指向的相位)。第一个旁瓣是该函数第一个负向极值点，位置约 $x \approx 4.4934$ (方程 $\tan x = x$ 的首个非零解)，函数值 $\sin(4.4934)/4.4934 \approx -0.2172$ 。幅度比 0.2172 折成功率 $0.2172^2 \approx 0.0472$ ，取 $10 \log_{10} 0.0472 \approx -13.26 \text{ dB}$ ——这就是“约 -13 dB ”的来历。直觉：等权矩形窗的傅里叶变换是 sinc，旁瓣是 sinc 振铃的第一个波峰，高度由 sinc 包络 $1/x$ 决定；加窗（汉明等）就是把矩形边沿削薄，振铃随之降低。

度量三：指向性指数 DI（抗混响/抗弥散噪声）。混响尾音、风噪这类噪声从四面八方均匀地涌来。DI 回答的是：“如果所有方向均匀放同样强度的噪声，这个波束能挡掉多少？”——主瓣方向增益的平方，除以全空间平均增益的平方，再取对数：

$$\text{DI} = 10 \log_{10} \frac{4\pi |B(\theta_0)|^2}{\int |B(\theta)|^2 d\Omega}.$$

$B(\theta)$ 是波束图， $d\Omega$ 是立体角微元，整个球面的立体角为 4π 。分母对波束图在整个球面上积分，表示弥散场中各方向输入的总贡献。DI = 0 dB 表示没有方向选择性；DI 越大，能量越集中于目标方向。超指向波束形成 (§5.3) 的目

标之一就是提高这一指标。

度量四：白噪增益 WNG（抗自身噪声/稳健性）。每个麦克风自己有底噪（热噪声），各通道互相独立。波束权重把它们合起来时会放大多少倍？这就是 WNG：

$$\text{WNG} = 10 \log_{10} \frac{|\vec{w}^H \vec{a}(\theta)|^2}{\|\vec{w}\|^2}。$$

分子是目标方向的增益平方，分母是权重自身的能量。**WNG 是负数意味着权重把自身噪声放大了**——这在超指向设计里真实会发生：权重变得巨大且正负相抵，任何麦克风失配都被同步放大，波束就“碎”了。上限是 $10 \log_{10} M$ （DSB 达到，§5.2 有证明）。

DI 与 WNG 的此消彼长是波束设计的第一性权衡（详见 §5.3、图15）：想要更尖的指向（DI 高），就要牺牲稳健性（WNG 低）；反之亦然。

常规波束的分辨率尺度。HPBW 的量级约为 λ/D ，因此它常被用作常规波束扫描能否分开两个近邻源的经验尺度。这不是所有估计器都不能越过的普适物理边界：MUSIC 等子空间方法在模型正确、信噪比和快拍数足够时可以得到窄于常规主瓣的谱峰，所以称为**超分辨（super-resolution）**；代价是对源相关性、阵列失配和有限样本更敏感。

空间混叠（栅瓣）：相邻麦间距超过半波长后，不同方向可能产生相同的离散空间相位。图 7（b）中，8 麦阵列指向 60° ，间距从 $\lambda/2$ 增至 λ 后， -7.7° 出现与主瓣等高的栅瓣，因而无法仅凭该频点区分两个方向。

这个 -7.7° 可以手算验证：栅瓣条件 $\sin \theta - \sin \theta_0 = \pm \lambda/d$ ，取 $d = \lambda$ 、 $\theta_0 = 60^\circ$ ，得 $\sin \theta = \sin 60^\circ - 1 = 0.8660 - 1 = -0.1340$ ， $\theta = \arcsin(-0.1340) \approx -7.7^\circ$ ——与图7(b) 标注一致。消费级阵列（麦距 2~4 cm）的无混叠带宽约 4.3~8.6 kHz（验算 $c/(2d) = 343/(2 \times 0.04) \approx 4.3$ kHz、 $343/(2 \times 0.02) \approx 8.6$ kHz）。

这与时间域奈奎斯特采样具有相似结构：时间采样要求 $f_s \geq 2f_{max}$ 以避免频谱混叠；均匀线阵在整个可视角域避免空间混叠的充分条件是 $d \leq \lambda/2$ 。超过这一间距后，不同方向可能产生相同的离散空间相位序列，表现为栅瓣。

为什么 $d \leq \lambda/2$ 是安全线（三步推导）：1. 相邻两麦对来自 θ 方向的平面波，相位差为 $\psi = 2\pi d \sin \theta / \lambda$ （正横方向起算）；2. 相位以 2π 为周期，因此 ψ 与 $\psi + 2\pi$ 不可区分。当 $\frac{2\pi d}{\lambda}(\sin \theta - \sin \theta_0) = 2\pi$ ，即 $\sin \theta - \sin \theta_0 = \frac{\lambda}{d}$ 时，另一个方向与指向方向产生相同的阵元相位序列，波束图上出现等高栅瓣；3. $\sin$ 的取值范围是 $[-1, 1]$ ，所以 $|\sin \theta - \sin \theta_0| \leq 2$ 。当 $d < \lambda/2$ 时， $\lambda/d > 2$ ，上式在可见范围内无解。反之， $d > \lambda/2$ 只表示不再保证全视场无栅瓣；某个特定转向是否出现可见等高栅瓣，还要检查上式是否有可见解。

精度理论下界（CRB）（统计内容较重，第一遍可跳过，§4 用到时再回）：克拉美—罗界（Cramér—Rao Bound）是在给定观测模型和正则条件下，对无偏到达方向（Direction of Arrival, DOA）估计器方差的下界。下面的显式式子采用单源、窄带、确定性信号模型，阵列是 M 元均匀线阵（Uniform Linear Array, ULA）、间距为 d ，共有 T 个独立快拍，噪声为空间白高斯噪声，信噪比（Signal-to-Noise Ratio, SNR）按单阵元定义；改变这些假设，界也会改变：

$$\text{CRB}(\theta) = \frac{6}{T \cdot \text{SNR} \cdot M(M^2 - 1) \cdot \left(\frac{2\pi d}{\lambda}\right)^2 \cos^2 \theta} \quad (\text{rad}^2)。$$

三个规律一目了然：误差方差与 **SNR、快拍数、孔径平方**（ M^3 与 $(d/\lambda)^2$ ）成反比，且在端射方向（ $\cos \theta \rightarrow 0$ ）发散。公式里的 $M(M^2 - 1)$ 来自各麦位置绕阵列中心的二阶矩 $\sum_m (m - \frac{M-1}{2})^2 = \frac{M(M^2-1)}{12}$ ——孔径在公式里

的真实身份就是“麦克风位置的方差”。

算例 2-1: CRB 最小数值例

阵列配置——6 麦、间距 1.4 cm、孔径 7 cm；正横方向、 $f = 1$ kHz、 $T = 100$ 快拍。

在上述模型内，任何满足正则条件的无偏估计器，其方差都不低于该 CRB；它不直接约束有偏估计器的均方误差，也不能脱离模型解释成所有算法的绝对极限。正横方向 ($\theta = 0^\circ$ ，即 $\cos \theta = 1$)、 $\lambda = 0.343$ m。SNR 要换成线性值再代入：SNR = 10 dB 对应 10，0 dB 对应 1。代入上式：

$$\text{CRB} = \frac{6}{100 \times 10 \times 6 \times 35 \times (2\pi \times 0.014/0.343)^2 \times 1} \approx 4.3 \times 10^{-4} \text{ rad}^2。$$

B-5 CRB 分母五个因子： $T = 100$ (快拍数)；SNR = 10 (10 dB 的线性值)；

$M(M^2 - 1) = 6 \times 35 = 210$ (麦克风位置方差项)； $(2\pi d/\lambda)^2 \approx 0.0658$ (电尺寸项)； $\cos^2 \theta = 1$ (正横方向)。分母乘积约为 13800，因此 $6/13800 \approx 4.3 \times 10^{-4} \text{ rad}^2$ 。改变阵列或频率时，应重新计算这五项。

开方得标准差 $\approx 0.021 \text{ rad} \approx 1.2^\circ$ ；SNR 降到 0 dB (线性值 1) 则 $\approx 3.8^\circ$ 。阵列的物理跨度为 $(M - 1)d = 5 \times 1.4 \text{ cm} = 7 \text{ cm}$ ；CRB 里的 $M(M^2 - 1)d^2$ 则来自全部阵元位置的二阶矩，不能用一个 HPBW 孔径项代替。这组数只说明：在本例的窄带、无偏估计和白噪声模型内，低信噪比会显著抬高方差下界。实际误差还受混响、失配、源相关性和估计器偏差影响。

算例 2-2: DI 与 WNG 的数字感 (4 元半波线阵，两个 6 dB)

阵列配置——4 麦、间距 $\lambda/2$ 、孔径 1.5λ ；延迟求和 (DSB, Delay-and-Sum Beamforming) 指向正横。

上面四个度量还只有公式没有数字，拿这个最小例子建立量级感：- **WNG**：DSB 恰好达到上限 (§5.2 有证明)， $\text{WNG} = 10 \log_{10} M = 10 \log_{10} 4 \approx 6 \text{ dB}$ ；- **DI**：把 DSB 波束图按定义式在整个球面上数值积分，得 $\text{DI} \approx 6 \text{ dB}$ (3D 各向同性弥散场口径)——对 $\lambda/2$ 间距的线阵，两者数值恰好相等。原因是：弥散场噪声在两麦间的相关系数正比于 $\text{sinc}(2\pi d/\lambda)$ ， $d = \lambda/2$ 时恰好为 0，即各麦的弥散噪声互不相关，统计性质与自噪声一致，两本账自然相同。(口径注：此处 sinc 取 $\sin x/x$ 定义；§5.1 用归一化定义 $\sin(\pi x)/(\pi x)$ ，同一物理量在该口径下写作 $\text{sinc}(1) = 0$ ——差的只是自变量里的 π ，对照时先换算。)

量级结论：在本例的半波间距、空间白噪声近似下，4 元 DSB 的 WNG 和 DI 都是 6 dB。若针对某个弥散噪声模型提高 DI，权重通常会变得更敏感，WNG 可能下降；具体上限取决于阵列几何、频率、噪声相关矩阵和稳健性约束，不能只由麦克风数给出。

上述度量基于远场平面波模型。声源进入近场后，导向模型、搜索空间和定位参数都要加入距离维度。

2.7 小结：声源走近了，平面波不够用——近场要换的三样东西

远场模型把波前当平面，只剩方向一个未知数；声源走近后波前弯成球面，到达各麦的距离本身也携带信息。本小节把近场需要换掉的三样东西一次列清。

① **球面导向矢量**：远场导向矢量的第 m 个分量只有相位旋转 $e^{-j2\pi f\tau_m(\theta)}$ （幅度视为相同）；近场要写成球面波形式——声源在位置 $\vec{p}$ 时，第 m 个麦（位置 $\vec{r}_m$ ）收到的复增益正比于 $\frac{e^{-j2\pi f\|\vec{p}-\vec{r}_m\|/c}}{\|\vec{p}-\vec{r}_m\|}$ 。与远场相比多出两处变化：相位按**真实距离** $\|\vec{p}-\vec{r}_m\|$ 计算（不再是方向投影 $d\sin\theta$ ），幅度按 $1/\text{距离}$ 衰减（各麦幅度不再相等，近的响、远的弱）。归一化后即近场导向矢量 $\vec{a}(\vec{p})$ ——注意自变量从方向 θ 变成了位置 $\vec{p}$ ，定位输出自然从“角度”升级为“角度 + 距离”。

② **距离估计从哪里来**：球面弯曲在阵列边缘相对中心造成的额外路程约为 $D^2/(8r)$ (§2.2 第 2 步)，它同时改变相位曲率与幅度差。声源越近，波前越弯，边缘麦相对平面波预测的相位偏差越大；拟合这部分曲率可以估计距离 r 。距离是否可观测取决于 $D^2/(r\lambda)$ 、信噪比、带宽、麦数和几何形态。孔径很小或声源很远时，球面模型与平面模型几乎不可区分，此时距离估计会很不稳定。距离误差用米、角度误差用弧度，不能用“相差一个量级”直接比较。

③ **切换线：何时必须换球面模型**：工程上以 Fraunhofer 距离 $r = 2D^2/\lambda$ 为切换线——声源远于此线，用平面模型（本章第 3 节向量式）；近于此线，换球面导向 $\vec{a}(\vec{p})$ ，SRP 搜索网格也从角度一维扩展为位置二维/三维 (§4.3 的 $\tau_{ij}(\vec{r})$ 本来就是按距离差写的，天然兼容近场)。记忆锚点：7 cm 小阵列在 1 kHz 下切换线仅约 3 cm（整个房间都是远场）；1.26 m 大线阵在同频率下切换线约 9 m（会议室里全程近场）。频率越高波长越短，切换线越远——宽带系统一般按最高工作频率核定是否需要近场模型。

本章从传播时延建立了远近场模型，并定义了 STFT、快拍、协方差及四项阵列度量。第 3 章将讨论麦克风几何如何限制这些观测与指标。

本章练习

- STFT 分帧换算：采样率 8 kHz、窗长 32 ms、帧移 8 ms，求窗长采样点数、帧移采样点数、重叠率和 1 s 语音的帧数。（参考答案：窗长 $8000 \times 0.032 = 256$ 点；帧移 $8000 \times 0.008 = 64$ 点；重叠率 $(256 - 64)/256 = 75\%$ ；帧数 $(1000 - 32)/8 + 1 \approx 122$ 帧——帧数与 16 kHz 时一样，因为只由窗长帧移的时间值决定。口径注：此处是无补零做法，即 FFT 点数 = 窗长点数（256 点窗做 256 点 FFT）；若补零到 512 点再做 FFT，频点数与频率分辨率另算，本题不按那个口径。）
- 协方差读数：2 麦在某频点上信号完全相干（互相关系数幅值为 1、相位差 30° ），各麦总功率都是 2，写出 2×2 协方差矩阵 $\hat{\mathbf{R}}$ 。（参考答案： $\hat{\mathbf{R}} = \begin{bmatrix} 2 & 2e^{j\pi/6} \\ 2e^{-j\pi/6} & 2 \end{bmatrix}$ 。对角线是各麦功率，非对角线的模是相干强度，辐角是麦间相位差；矩阵应满足对角元为实数且整体共轭对称。这里约定麦 1 相位超前 30° ；若采用相反的通道顺序，非对角元的相位符号也相反。）
- CRB 估算：阵列配置沿用算例 2-1（6 麦、间距 1.4 cm、孔径 7 cm）与 100 快拍，若 SNR 从 10 dB 提到 20 dB（线性值从 10 到 100），角度标准差从约 1.2° 变成多少？再想想：快拍数翻 10 倍与 SNR 提 10 dB，哪个更划算？（参考答案：方差与 SNR 成反比，标准差缩小 $\sqrt{10} \approx 3.16$ 倍，约 $1.2^\circ/3.16 \approx 0.38^\circ$ ；两者在公式里是乘积关系，效果等价——实际中加快拍只要多听一会儿，提高 SNR 却要改硬件或走近点，前者通常更便宜。）

第 3 章 · 阵列几何形态

⚠ 本篇是正文第 3 章（正文共 11 章，另有附录 A/B），可独立阅读，前后篇见下方导航。

🏠 首页导读：00_overview.md | 上一篇：02_basics-signal-model.md | 下一篇：04_doa-estimation.md

3.1 形态总览

图8 常见麦克风阵列几何形态示意




图8 画出八种常见形态：(a) 双麦前后排（Endfire）、(b) 双麦左右排（Broadside）、(c) 四麦均匀线阵、(d) 四麦方阵、(e) 六麦圆阵加中心麦、(f) 32 麦均匀球阵、(g) 螺旋或对数阵、(h) 分布式或非规则阵。(a) 的拾音主轴沿两麦连线，(b) 的主轴垂直于连线。(d) 的四只麦虽然也落在同一个圆周上，这里按方阵的平面几何分析。

两种基础双麦摆法（只有 2 麦时仅这两种有意义）：

- **Endfire（前后排列）**：拾音主轴沿连线方向，类似心形指向话筒——前方灵敏、后方抑制。用于真无线立体声（True Wireless Stereo, TWS）耳机、手机；

专栏（算例独立）：算例 3-1 双麦耳机的差分——1 cm 间距怎么做心形指向

TWS 耳机上的双麦常采用端射（endfire）摆法：两个麦前后排列、间距 $d = 1\text{ cm}$ ，主轴沿两麦连线。它构成 §5.3 所述的一阶差分麦克风阵列（DMA, Differential Microphone Array）。若只把两路信号乘实数增益后相减，即 $y = x_1 - g x_2$ （ g 为标量），无法形成心形指向。纯实增益不改变相位；前方与后来声的麦间相位差分别为 $-\Delta\phi$ 和 $+\Delta\phi$ ，而前方 $|1 - ge^{-j\Delta\phi}|$ 与后方 $|1 - ge^{+j\Delta\phi}|$ 相等，结果是前后对称的 8 字形。要打破这种对称性，需先引入时延再相减：把后路麦的信号延迟 $\tau_0 = d/c$ ，再从前路麦信号中减去：

$$y(t) = x_1(t) - x_2(t - \frac{d}{c}) \xrightarrow{\text{频域}} Y(f) = X_1(f) - e^{-j2\pi fd/c} X_2(f)$$

其中 x_1 是前路麦， x_2 是后路麦， d/c 是声音传播一个麦间距所需的时间。下面分别计算前方和后方来声的响应。

第 1 步：两麦之间的相位差。声音沿连线方向传来时，两麦时差最大：

$$\Delta\tau = \frac{d}{c} = \frac{0.01}{343} \approx 29.2\ \mu s$$

1 kHz 时对应的相位差（时延在频域就是相位旋转，§2.3）：

$$\Delta\phi = 2\pi f \Delta\tau = \frac{2\pi \times 1000 \times 0.01}{343} \approx 0.183\ \text{rad} \approx 10.5^\circ$$

第 2 步：后方来声——恰好抵消（零陷）。后方的声音先到后路麦 x_2 、晚 $\Delta\tau$ 才到前路麦 x_1 ；而我们人为给 x_2 补上的延迟 $\tau_0 = d/c$ 正好等于这个自然时差——两路在减法器里对齐成完全一样的波形， $y = 0$ 。后方被挖出一个理论上无穷深的零陷。

第 3 步：前方来声——还剩多少。前方的声音先到 x_1 、晚 $\Delta\tau$ 到 x_2 ； x_2 又被电延迟推后 $\Delta\tau$ ，两路共错开 $2\Delta\tau$ ，即相位差 $2\Delta\phi \approx 21^\circ$ 。两路信号是复平面上两个长度相同、夹角 21° 的箭头，相减得到连接两尖端的弦。剩余幅度（两路幅度归一化为 1）：

$$|Y| = \left| 1 - e^{-j2\Delta\phi} \right| = 2 \sin \Delta\phi = 2 \sin 10.5^\circ \approx 0.365$$

换算成分贝： $20 \log_{10} 0.365 \approx -8.8\ \text{dB}$ 。前方保留而后方出现零陷，因此得到心形指向。低频近似下，只要电延迟与几何时差的关系保持不变，归一化波束形状随频率变化较小。

第 4 步：计算输出信噪比变化。与单个麦克风相比，前方信号幅度为 0.365，对应 $-8.8\ \text{dB}$ 。两路独立自噪声相减后功率相加，噪声功率增加约 3 dB，因此输出信噪比降低约 $8.8 + 3 = 11.8\ \text{dB}$ 。这是一阶 DMA 在低频 WNG 较低的原因：间距越小、频率越低， $\Delta\phi$ 越小，目标信号在相减中保留得越少。

第 5 步：失配最先伤害哪里。后方零陷靠的是「两路幅度精确相等、相减归零」。若两麦增益差 1%，后方相减后留下约 1% 的残余——零陷从理论无穷深变浅到约 $20 \log_{10} 0.01 = -40\ \text{dB}$ ；而前方响应只跟着轻微变化。也就是说，增益失配主要伤害后方零陷的深度（约 40 dB 封顶），这就是为什么耳机、助听器这类微型设备用得起差分（尺寸刚需，且产线可逐只配对标定），而大阵列宁可走延迟求和路线。

端射摆法利用延迟与相减形成前后不对称；正横（Broadside）摆法则把主轴放在麦克风连线的垂直方向。

- **Broadside（左右排列）：**拾音主轴垂直于连线，用于笔记本、平板通话降噪。

双麦只有 1 个独立时延观测。在预先限定声源位于某个平面或半空间时，它可以估计一维入射角并形成固定波束；若要在三维空间同时求方位和俯仰，一个时延方程不够，同一时延对应绕阵列轴的一圈方向，形成锥面模糊。

双麦只有一个独立时延约束。增加阵元并改变几何后，覆盖范围、歧义形式和端射灵敏度也会变化。

多麦形态对比：

形态	覆盖	优点	缺点	典型应用
均匀线阵 ULA	一维 $\pm 90^\circ$	算法最成熟（MUSIC/ESPRIT 天然适配）、孔径利用率高	分不清俯仰、端射分辨率崩塌、前后模糊	Soundbar、会议条
均匀圆阵 UCA	水平 360°	方位各向同性（波束形状不随转向畸变）、紧凑	俯仰分辨弱、小半径低频差	智能音箱、桌面会议设备

形态	覆盖	优点	缺点	典型应用
方阵/平面阵	单侧半空间；若两侧都开放则有镜像歧义	方位+俯仰都能测	阵列平面两侧的镜像方向具有相同时延，需挡板或先验消歧	视频会议一体机
球阵（刚性/开放球）	全 4π 立体角	三维覆盖较均匀，可录 3D 声场	成本高、体积大；有限阵元下波束仍随频率和方向变化	机器人听觉头、3D 录音、学术研究
螺旋阵/对数阵	宽频带	非均匀间距可打散周期性栅瓣	设计与宽带优化较复杂；自由场导向矢量仍可按已知坐标计算	高品质远场录音
分布式/随机阵	超大孔径	房间级间距换高分辨率、抗混响（空间分集）	标定与同步困难	多房间节点、大型会议室

（表中的算法名词如 MUSIC/ESPRIT 可先跳过，读完 §4 后回看本表会更清晰。）

读表时要区分两种模糊。线阵只有沿阵列轴的位置投影信息，因此同一组时延对应以阵列轴为轴的锥面；把麦继续加在同一直线上，能提高阵列增益和估计精度，却不能消除这类锥面模糊。非共线的平面阵能同时估计两个方向余弦，但若阵列两侧都开放，平面法向两侧的镜像方向仍可能产生相同时延，需要挡板、幅度模型或半空间先验消歧。另一类问题是端射分辨率下降：正横起算时 $\Delta\tau = (d/c)\sin\theta$ ，在 $\theta \rightarrow \pm 90^\circ$ 处导数趋近于零，同样的时延误差会对应更大的角度区间；这与 §2.6 CRB 中 $\cos\theta \rightarrow 0$ 时下界发散一致。

专栏（算例独立）：算例 3-2 端射崩塌的数字——同一个 10 μs 误差，正横是小事、端射是灾难

§3.1 说线阵「端射分辨率崩塌」，根源是时延与角度的关系 $\Delta\tau = \frac{d}{c}\sin\theta$ (θ 从正横方向起算， d 为麦间距)。对 θ 求导：

$$\frac{d\Delta\tau}{d\theta} = \frac{d}{c}\cos\theta \quad \Rightarrow \quad d\theta \approx \frac{c}{d\cos\theta} d\Delta\tau$$

即：同样的时延误差 $d\Delta\tau$ ，换算成角度误差时要除以 $\cos\theta$ 。取 $d = 4\text{ cm}$ 的线阵（与 §4.4 的例子一致）、时延误差 $d\Delta\tau = 10\text{ }\mu\text{s}$ （16 kHz 采样下不到 1/5 个采样点，是很容易残留的误差量级），算两个方向。

正横方向 ($\theta = 0^\circ$)： $\cos 0^\circ = 1$,

$$d\theta = \frac{343 \times 10 \times 10^{-6}}{0.04 \times 1} \approx 0.0858\text{ rad} \approx 4.9^\circ$$

10 μs 误差换来约 5° 的角度误差——肉疼，但还能用（这也复现了 §4.4 「4 cm 间距下 10 μs 误差对应约 5°」的结论）。

端射附近 ($\theta = 85^\circ$) 不能继续把 10 μs 当作“小扰动”。本例最大物理时延是 $d/c \approx 116.6\text{ }\mu\text{s}$ ， 85° 对应 $\tau \approx 116.2\text{ }\mu\text{s}$ 。若估计值增加 10 μs，便超过物理上限，没有实数角度与之对应，系统应当判为越界或把结果限制在端射。若估计值减少 10 μs，则

$$\hat{\theta} = \arcsin\left(\frac{(116.2 - 10) \times 10^{-6} \times 343}{0.04}\right) \approx 65.6^\circ,$$

误差约 19.4°。微分式在足够小的误差下仍说明灵敏度按 $1/\cos\theta$ 增大，但不能把 85° 处的 10 μs 线性外推成 56° 并当作精确误差。实际可用角域由允许误差、信噪比、快拍数和几何共同决定，不存在统一的“端点扣掉 30°”规则。

端射方向的非线性算例说明，阵列灵敏度随入射角变化。下面把几何设计中最常用的四条规律集中列出。

3.2 四条设计规律

1. 常规波束的分辨率尺度由孔径与波长之比决定 (约 λ/D): 7 cm 级圆阵在 1 kHz 的这个尺度已经超过线阵的整个可视角域, 方向选择性很弱; 到 4 kHz 才进入几十度量级 (见算例 3-3)。高频虽然能提供更大的电尺寸, 却也更容易遇到空间混叠、传播衰减和阵列失配。设计时必须把这些因素一起考虑。

算例 3-3: 6 麦圆环的数字

考虑一个用于教学的 6 麦均匀圆环, 环径取 7.5 cm, 即半径 $r = 3.75$ cm。这个尺寸只用于展示计算方法, 不对应某一款产品; 声速取 $c = 343$ m/s。

第 1 步: 相邻麦距。6 个麦均匀分布在圆周上, 相邻两麦的连线是正六边形的一条边。相邻麦距

$$d = 2r \sin \frac{\pi}{6} = 2 \times 0.0375 \times 0.5 = 0.0375 \text{ m} = 3.75 \text{ cm}$$

正六边形的边长恰好等于半径——这是 6 麦圆环特有的整齐性质。

第 2 步: 无混叠频率上限。空间奈奎斯特定理 (§2.6) 要求 $d \leq \lambda/2$, 即间距不能超过半波长, 否则波束图上出现与主瓣等高的假峰 (栅瓣)。代入:

$$f_{\max} = \frac{c}{2d} = \frac{343}{2 \times 0.0375} \approx 4573 \text{ Hz} \approx 4.6 \text{ kHz}$$

因此, 按相邻间距的半波长充分条件, 这个阵列约在 4.6 kHz 以下满足全视场无混叠要求。16 kHz 采样时, 4.6~8 kHz 频段不再得到这一保证。可选措施包括降低高频子带权重、采用非均匀间距以减弱周期性歧义, 以及定位时主要使用无混叠频段、增强时再利用高频信息。

第 3 步: 波长与孔径的比。阵列孔径 (阵列的最大尺寸) $D = 2r = 7.5$ cm。- 1 kHz: 波长

$\lambda = c/f = 343/1000 = 0.343 \text{ m} = 34.3 \text{ cm}$, 孔径比 $D/\lambda = 0.075/0.343 \approx 0.22$ ——整个阵列只有约五分之一波长大小; - 4 kHz: $\lambda = 343/4000 \approx 0.0858 \text{ m} = 8.6 \text{ cm}$, $D/\lambda = 0.075/0.0858 \approx 0.87$ ——孔径接近一个波长。

第 4 步: 常规波束的角宽量级。用 λ/D (弧度, §2.6) 做孔径尺度估计: - 1 kHz: $\lambda/D \approx 0.343/0.075 \approx 4.6 \text{ rad} \approx 262^\circ$ ——这个数已经超过了整个可视范围 (线阵 $\pm 90^\circ$ 、圆阵水平面 360° 一圈), 物理含义是: 1 kHz 下这只 7.5 cm 的环几乎没有方向分辨能力, 主瓣宽到接近全向; - 4 kHz: $\lambda/D \approx 1.14 \text{ rad} \approx 66^\circ$, 对应主瓣宽度量级 $\approx 0.886\lambda/D \approx 58^\circ$ (借用线阵公式估量级, 圆阵精确系数不同) ——进入「几十度」的量级, 总算能分出「大概在另一边」。

结论: 4 kHz 时阵列的电尺寸接近 1, 常规波束已可能呈现几十度量级的方向选择性; 1 kHz 时电尺寸只有约 0.22, 常规波束很宽。子空间估计或学习方法能在合适条件下利用微弱的跨通道差异, 但不会凭空增加观测信息; 低信噪比、强混响或模型失配时, 低频方向仍难估。

算例 3-4: ULA 主瓣宽度计算

取一条 4 麦均匀线阵 (ULA, uniform linear array, 等间距直线排列的阵列), 间距 $d = 3$ cm, 指向正横。首末阵元的物理跨度为 $(M-1)d = 9$ cm; §2.6 从离散阵因子推得的窄主瓣近似则是

$$\text{HPBW} \approx \frac{0.886 \lambda}{Md} \text{ rad}$$

这里的 $Md = 12\text{ cm}$ 来自 Dirichlet 核的近似尺度，不等于物理跨度。对小阵列要保留这个区别。

1 kHz: 波长 $\lambda = 343/1000 = 0.343\text{ m}$,

$$\frac{0.886 \times 0.343}{0.12} \approx 2.53\text{ rad} \approx 145^\circ$$

8 kHz: 波长 $\lambda = 343/8000 \approx 0.0429\text{ m}$,

$$\text{HPBW} \approx \frac{0.886 \times 0.0429}{0.12} \approx 0.317\text{ rad} \approx 18.1^\circ$$

这两个数怎么读：1 kHz 下估计值已接近整个可视范围，窄主瓣近似本身很粗，只能说明波束方向选择性很弱；此时应直接计算阵因子。8 kHz 下估计约为 18.1° ，主瓣明显收窄。只要几何和转向不变，处在公式适用区间时，频率减半会使 HPBW 约增大一倍。

2. **圆阵与线阵各有适用方向**：线阵在正横附近投影孔径最大，转向端射时灵敏度下降；圆阵在水平面各方位的几何更均衡。球阵还可提供俯仰信息。哪一种识别率更高，取决于尺寸、挡板、房间、算法和评测方向分布，不能只按阵形下结论。Kumatani—McDonough—Raj 《Microphone Array Processing for Distant Speech Recognition》CMU 课程讲义，2012
3. **挡板效应必须纳入导向模型**：麦克风装在刚性圆柱或球体上时，绕射和散射会改变跨通道的幅相响应。某些频段和方向上，它能增加可辨的幅相差；另一些位置也可能出现阴影或共振。因此应使用相应的解析散射模型或实测阵列流形，不能把挡板一概等效为固定倍数的“虚拟孔径”。
4. **麦克风数量没有统一甜蜜区**：增加麦克风通常能提高统计稳定性和可控自由度，但收益取决于是否同时增加孔径、噪声相关性、带宽、算法和计算预算。对独立等功率自噪声，理想 DSB 的 WNG 为 $10 \log_{10} M$ ，麦数翻倍增加 3 dB；这只是一个特定噪声模型下的基准，不足以推出所有产品都应选 4~8 麦。

图9 阵列规模与算法鲁棒性（概念玩具数据，不是性能测试）




图9 只用于说明两类权衡：(a) 增加麦数可能提高性能，也会增加通道、同步、功耗和计算成本；曲线不是通用选型结论。(b) 混响会使不同定位方法以不同速度退化，具体数值取决于仿真条件。

图9 (b) 从另一个角度补充了“多麦”的意义：三类定位算法（TDOA 类、波束扫描类、子空间类）的误差随混响加重的对比——多麦阵列的冗余度，正是转化为这种混响下的定位稳健性。这里只看定性趋势（混响越重误差越大，但各类算法恶化的快慢不同），定量讨论见 §4.8（各类算法本身的细节见 §4.2~§4.6）。

§3.3 转向非均匀稀疏阵，说明怎样用差分协同阵扩展虚拟孔径。

3.3 稀疏阵列与差分协同阵

协同阵的概念：从麦的位置到麦对的间距

均匀线阵若要在整个可视角域避免栅瓣，阵元间距需不大于半波长 (§2.6)。在给定麦克风数量下，这一条件限制了物理孔径。**稀疏阵列 (sparse array)** 采用非均匀位置，并利用麦克风对的位置差构造更长的虚拟阵列。

核心概念：差分协同阵 (difference co-array)。理想远场窄带模型下，协方差矩阵第 i, j 个元素的相位由麦 i 与麦 j 的位置差决定。收集所有麦对的位置差，就得到差分协同阵。6 麦均匀线阵的位置是 $\{0, 1, 2, 3, 4, 5\}$ (单位 $\lambda/2$)，不同的有符号滞后是 $\{0, \pm 1, \dots, \pm 5\}$ ，共 11 个；6 麦嵌套阵 $\{0, 1, 2, 3, 7, 11\}$ 可得到 $\{0, \pm 1, \dots, \pm 11\}$ ，共 23 个连续滞后 (图10)。这 23 个数是连续的**有符号差分滞后**，不是 23 路彼此独立的物理快拍。若按滞后平均、构造 Toeplitz 虚拟协方差并做空间平滑，可得到比物理阵更长的虚拟 ULA；在模型和秩条件满足时，部分协同阵方法因而可能估计多于物理麦数的非相干源。可分辨源数仍取决于连续单侧滞后长度、重构方法、平滑后的矩阵维数、信噪比和快拍数，不能直接等同于 23。

差分集合只给出虚拟阵列的位置。要把这些位置用于子空间估计，还需要从协方差中构造相应的二阶统计量。

协方差为什么能当虚拟观测

为什么协方差能提供虚拟滞后观测：对互不相干的远场源， $\mathbf{R}$ 的第 i, j 个元素是各源功率乘相位项 $e^{-j2\pi f(\tau_i - \tau_j)}$ 的和，只依赖两麦位置差。相同位置差的麦对可做平均，降低估计方差；不同位置差提供不同滞后。把协方差元素按滞后重排后，可把连续的一段滞后解释为虚拟 ULA 的二阶统计量。它不是原始阵列快拍，因此标准 MUSIC 不能不经处理直接套用；通常还需 Toeplitz 重构、直接协同阵处理或空间平滑，才能形成满足子空间方法要求的虚拟协方差。相干源、宽带混响、有限快拍和有洞差集都会降低可用秩和自由度。

可以把它理解为重新整理“麦对间距表”：相同间距的观测合并，不同间距按顺序排成一条虚拟标尺。标尺更长，潜在孔径更大；但只有完成统计重构并满足秩条件后，这些滞后才会转化为可用的子空间自由度。




图10 左侧比较均匀、嵌套和互质三种摆法，横轴单位是半波长；右侧比较有符号差分滞后。均匀阵有 11 个连续滞后，图中的嵌套阵有 23 个连续滞后，互质阵覆盖更远但中间有洞。连续滞后数描述虚拟孔径结构，不应直接写成 MUSIC 可分辨的源数。

这种虚拟观测依赖统计重构和秩条件；差分集合中的空缺、宽带信号和混响都会限制可用自由度。

代价与边界：差分空缺、宽带和混响

代价与边界：协同阵使用的是二阶统计量，需要专门的协同阵 MUSIC、Toeplitz 重构、空间平滑或稀疏重构；差分滞后中的洞还会使可用连续虚拟孔径缩短，插值或矩阵补全又会引入额外假设。嵌套阵与互质阵最初主要在窄带阵列模型下发展。语音宽带、混响和频率相关阵列流形会增加处理难度，因此实际使用前应在目标频带和房间条件下验证，而不能只按理论差集长度选型。[Pal & Vaidyanathan 嵌套阵原始论文](#)、[互质阵自由度分析](#)

稀疏阵与分布式阵不是同一概念。稀疏阵通常指按特定非均匀位置设计的阵列；分布式阵由多个独立设备组成，除了几何布局，还要处理节点标定、独立时钟和通信。

上述几何分析默认通道和位置准确。实际系统还需要通过标定减小增益、相位、耦合和位置误差。

3.4 阵列校准：麦克风个个不一样时怎么办

前面的理想公式假设各通道增益和相位一致、阵元位置准确，并忽略壳体散射、声学耦合和电串扰。实际偏差会使导向模型与观测不匹配。本节把常见偏差写进模型，再说明怎样测量和补偿。

3.4.1 增益相位自校准：利用未知声源的多位置观测

1. 增益相位自校准的思想。把每只麦的“不一样”写成一个复数：增益误差是幅度缩放，相位误差是额外旋转，合起来第 m 路的实际增益是 $(1 + \Delta g_m)e^{j\Delta\phi_m}$ （理想值是 1）。导向矢量 $\vec{a}(\theta)$ 的每个分量就被乘上这么一个误差，MUSIC 谱峰塌掉、波束零陷变浅，全是从这来的。

自校准可以不用已知方向的专用声源。常见做法是交替估计：先固定通道误差估方向，再固定方向估各麦的复增益，循环到目标函数收敛。它依赖可辨识条件。若只有一个固定方向，声源相位、传播相位和麦克风相位误差可能互相混淆；加入多个充分分散的方向、频点或几何约束后，才有机会分离这些未知量。具体需要多少方向取决于模型参数和约束，不能用一条固定数字概括。

复增益标定处理单通道幅相偏差；壳体散射和跨通道串扰还需要频率相关的耦合模型。

3.4.2 互耦补偿：把串音矩阵抵消掉

2. 耦合与串扰补偿。壳体和相邻器件会改变声场，电路走线也可能产生串扰。在线性近似下，可以把这类通道间混合写成频率相关矩阵 $\mathbf{C}(f)$ ，实际导向矢量变为 $\mathbf{C}(f)\vec{a}(f, \theta)$ 。可用已知方向的测量拟合 $\mathbf{C}(f)$ ，也可直接把实测阵列流形存入系统。若显式求逆， $\mathbf{C}(f)$ 条件数很大时会放大噪声，因此通常需要正则化，而不是无条件左乘精确逆矩阵。依赖深零陷的差分或超指向设计通常比 DSB 更容易受失配影响。

耦合矩阵描述通道间混合，但不能替代麦克风坐标标定。位置误差会直接改变传播相位。

3.4.3 位置自标定：有锚测绘、无锚边走边建图

3. 位置自标定。8 kHz 的波长约为 4.3 cm，2 mm 位置误差对应的相位误差为 $2\pi \times 0.002/0.0429 \approx 0.29$ rad，即约 17° ；低频下同一位置误差造成的相位偏差较小。位置标定有两类方法：①**有锚点标定**，在多个已知位置播放信号，由 TDOA 反解麦克风坐标；②**无锚点自标定**，同时估计声源位置与麦克风位置，要求声源运动或多位置观测满足可辨识条件。分布式阵列还需同时估计节点时钟关系 (§10.2)，否则 TDOA 会包含系统偏差。

下表汇总不同失配首先影响的量、误差尺度和补偿方法。

3.4.4 失配灵敏度表：先坏哪、坏多少

4. 失配灵敏度表：

失配类型	典型量级	最先坏掉的东西	数量感	补救
增益失配	1% (约 0.1 dB)	差分/超指向的零陷深度	零陷从理论无穷深封顶到约 -40 dB (§3.1 算例 3-1 第 5 步)；前方响应几乎不动	产线逐只配对、出厂标定系数
相位失配	2° (高频段)	高频指向精度	2° 相位误差在 8 kHz 约等于 0.24 mm 等效位置误差，MUSIC 峰偏、旁瓣抬高	同增益，一起标
位置误差	2 mm	高频导向矢量	8 kHz 下约 17° 相位误差，导向矢量失配；1 kHz 下仅约 2°，几乎无感——失配的伤害随频率线性涨	有锚/无锚位置标定
耦合与壳体散射	随结构、频率而变	零陷深度、旁瓣电平	不能仅由一个间距门槛判断；须比较自由场模型与实测流形	使用实测流形，或正则化估计 $C(f)$
时钟漂移 (分布式)	晶振几十 ppm	TDOA 系统性偏差	跑 1 小时即差约 0.18 秒 (百毫秒级)，是百微秒级时差的上千倍 (§2.1、§10.2)	共时钟/在线同步补偿

位置误差造成的相位偏差随频率增大；增益漂移、耦合和噪声则未必遵循同一单调关系。依赖精确相消的零陷和超指向设计通常最敏感。固定一体式阵列常用出厂标定，分布式阵列还需处理节点位置、时钟偏移和采样率漂移，并根据设备移动或时钟变化决定是否在线更新。

工程流程通常分三步：先在受控声场中测各通道的频率响应和阵列流形，再把补偿参数写入设备，最后用若干已知方向复测主瓣、旁瓣和零陷。若设备结构、温度或节点位置会变化，还要定义重新标定的触发条件。采用逐只通道修正、整机流形查表还是在线联合估计，取决于硬件一致性、存储、算力和使用环境。

几何决定可观测的空间信息，标定决定理论模型能否用于实测数据。第 4 章将从 GCC-PHAT 开始介绍声源定位算法。

本章练习

- 协同阵数差集验证：6 麦均匀线阵位置记为 {0, 1, 2, 3, 4, 5} (单位 $\lambda/2$)，列出全部麦对位置差，验证连续差集是 {0, ± 1 , ..., ± 5 }、共 11 个有符号滞后；再对嵌套阵 {0, 1, 2, 3, 7, 11} 做一遍，验证是 {0, ± 1 , ..., ± 11 }、共 23 个连续滞后。为什么还不能直接说它能分辨 22 个声源？答案要点：这些数是二阶统计量中的有符号滞后，不是 23 路独立快拍。必须先按滞后平均并构造满足结构约束的虚拟协方差，必要时再做空间平滑。可分辨源数由平滑后矩阵的维数和秩、源相关性、信噪比及快拍数共同决定，不能直接用 23 减 1。
- 栅瓣与挡板二选一：7.5 cm 环径的 6 麦圆环 (§3.2 算例 3-3)，若把工作频率推到 8 kHz，会发生什么？挡板 (规律 3) 又是在补哪一段的短板？答案要点：8 kHz 波长约 4.3 cm，半波长约 2.1 cm，小于 3.75 cm 相邻麦距，已经不满足全视场无混叠的充分条件。圆阵是否在某一转向出现等高歧义，要看完整几何和宽带融合，不能只套 ULA 的单一栅瓣角公式。挡板会以频率和方向相关的方式改变幅相响应；若模型使用得当，这些额外差异可帮助消歧，但它不是固定地把低频下限移动某个倍频程。

第 4 章 · 声源定位 (DOA 估计)

4.1 总览：四大类思路

声源定位算法

— A. 两阶段法 (TDOA, time difference of arrival, 到达时间差类): 先测时延, 再算位置

— GCC 加权互相关 (SCOT / Roth / PHAT / ML)

— SRP-PHAT (全阵列麦对累积扫描)

— 多麦对几何解算 (LS, least squares, 最小二乘 / 泰勒迭代)

— B. 波束扫描类: 转动灯头、把“聚光灯”转一圈看哪里最亮

— Bartlett 波束形成谱

— Capon / MVDR (最小方差无失真响应) 谱

— C. 子空间类 (超分辨)


— MUSIC / ESPRIT (相干源——一路是另一路的延迟衰减副本——需配空间平滑预处理)

— D. 稀疏重构与深度学习类

— L1-SVD / SBL (压缩感知; SBL = sparse Bayesian learning, 稀疏贝叶斯学习)

— DNN (deep neural network, 深度神经网络; SRP-CNN、GCC-PHAT+CRNN、ACCD0A)

图 11 在同一个两源仿真 (−20°、30°) 中比较 Bartlett、Capon 和 MUSIC。Bartlett 与 Capon 按各自的标准空间谱公式计算; MUSIC 给出伪谱, 峰高不是功率。高信噪比 (SNR, signal-to-noise ratio)、快拍 (snapshot, 阵列同一时刻所有麦的一组采样) 充足、源数正确且阵列模型准确时, Capon 和 MUSIC 的窄峰才能转化为可靠的分辨率优势。



图示说明：比较三类方法的谱形，不比较图中的绝对峰高。Bartlett 的分辨率受阵列孔径限制；Capon 利用协方差逆矩阵抑制其他方向；MUSIC 依赖信号子空间与噪声子空间的正交性。谱峰个数也不能无条件当作源数：旁瓣、相干多径和有限快拍都可能产生假峰或合并真峰，源数估计要按下一节的方法独立完成。

4.1.1 源数估计：确定信号子空间维数

子空间类 (MUSIC、ESPRIT) 必须先确定源数 K 。 K 定错后，信号子空间与噪声子空间的切分位置也会错。还要满足 $K < M$ ，否则没有非零维噪声子空间可供 MUSIC 做正交检验；ESPRIT 的两个子阵也都必须至少有 K 维，实际通常保留更多阵元以降低有限快拍误差。下面给出两种常用估计方法。

方法 1：特征值间隙 (eigen-gap)。把协方差矩阵 $\hat{\mathbf{R}}$ （读作“R 帽”，帽子表示用有限快拍估计出来的版本）的特征值从大到小排列。前 K 个特征值包含信号与噪声功率，后面 $M - K$ 个在白噪声模型下接近 σ^2 。算例 4-4 的无噪声单源给出 3, 0, 0，因此 $K = 1$ 。实际数据中，低信噪比或快拍不足会缩小相邻特征值之间的间隔；可比较相邻特征值的比值或差值，并把最大间隙所在位置作为候选分界。这种方法计算简单，但在低信噪比或快拍不足时不稳定。

方法 2：信息准则 (AIC/MDL)。增加候选源数通常会改善数据拟合，同时也会增加模型复杂度。AIC (Akaike information criterion, 赤池信息准则) 和 MDL (minimum description length, 最小描述长度) 用不同的复杂度惩罚项平衡这两部分，并取准则值最小的 K 。具体打分式及其适用假设应以所用实现的文献为准。两者在低 SNR 或快拍不足时都可能误判；相干源还会使信号协方差降秩。此时应先做空间平滑，再估计源数（见 §4.6）。

信噪比高、快拍充足时，可以先看特征间隙；需要自动选择 K 时可用 MDL，并用特征值谱交叉检查。相干源场景要先恢复协方差秩，再估源数。对 M 元均匀线阵 (Uniform Linear Array, ULA) 做前向空间平滑时，若切成 L 个长度为 $P = M - L + 1$ 的重叠子阵，要分辨 K 个完全相干源，至少需要 $L \geq K$ 且 $P > K$ ；这两个条件同时限制可分辨源数和剩余有效孔径。

子空间法需要源数，GCC-PHAT 不需要。下一节先从双通道时延估计讲起。

4.2 GCC-PHAT：“对齐两段录音，找最吻合的错位”

直觉：把第二路录音左右平移，平移到与第一路最像的那个错位量就是时间差。

慢做法：把直觉逐字翻译成数学。两路离散信号 $x_1(n)$ 、 $x_2(n)$ ，定义时延 τ 处的互相关值 (τ 以采样点为单位，取遍 $\dots, -2, -1, 0, 1, 2, \dots$)：

$$R(\tau) = \sum_n x_1(n) x_2(n - \tau)。$$

把 x_2 往右挪 τ 格，和 x_1 上下对齐，逐点相乘再求和。加总越大，这个错位下两路越像。最后取峰：

$\hat{\tau} = \arg \max_{\tau} R(\tau)$ ($\arg \max$ 返回峰的位置，不是峰高)。直接计算需要 $O(N^2)$ 次乘加；频域实现可把复杂度降到 $O(N \log N)$ 。

定理桥：慢做法的救星是一个恒等式 (相关定理)：时域逐点算出的整条 $R(\tau)$ ，恰好等于频域共轭相乘再逆变换回来——

$$R(\tau) = \text{IFFT}\{X_1(f)X_2^*(f)\} \quad (\text{连续写成积分，即下文快做法的公式})$$

两边是同一个相关函数，只是计算路线不同。本文把 $\tau_{12} > 0$ 定义为“信号到麦 1 比到麦 2 晚”，即


$x_1(t) = x_2(t - \tau_{12})$ 。在这个定义下， $\text{ifft}(X_1 \cdot \text{conj}(X_2))$ 的峰位是 $+\tau_{12}$ ；若交换两路，峰位变成 $-\tau_{12}$ 。实现和论文若采用不同的信号次序或相关定义，符号也会随之改变。

快做法：整条曲线一次 IFFT 全算出来（两路信号 x_1, x_2 ， $X_1(f)$ 、 $X_2(f)$ 是它们在第 f 个频点上的复数谱值——标量；运算顺序是“先共轭再乘”：先对 $X_2(f)$ 取共轭得到 $X_2^*(f)$ ，再与 $X_1(f)$ 逐频点相乘）：

$$R_{x_1 x_2}(\tau) = \int \Phi(f) X_1(f) X_2^*(f) e^{j2\pi f \tau} df, \quad \hat{\tau} = \arg \max_{\tau} R(\tau)。$$

代码里就是 `ifft(Φ·X1·conj(X2))` 后找最大值索引。快速傅里叶变换（Fast Fourier Transform, FFT）负责计算整条相关曲线，`arg max` 负责从曲线上读峰位，两者是前后两步。复杂度从 $O(N^2)$ 降到 $O(N \log N)$ ；实际加速比还取决于帧长、补零长度、FFT 库和硬件，不能只由渐近复杂度给出固定倍数。

图33 互相关的两种等价实现（GCC 中 $\Phi(f)=1$ 的特例；非 PHAT 加权）



图示说明：图33(a)给出零填充整数延迟信号；(b)按定义逐个 lag 直接求和；(c)计算频域乘积 $X_1 X_2^*$ ；(d)用零填充 FFT 和 IFFT 得到线性互相关。时域与频域由独立代码计算，图中给出最大数值误差。该图对应 $\Phi(f) = 1$ 的普通互相关，不包含 PHAT 加权。

线性相关与补零：FFT 算的是圆周相关（尾巴会卷绕到开头），帧不够长时两端的 $R(\tau)$ 会被卷绕污染；工程上补零到 $N \geq N_1 + N_2 - 1$ （两帧长度之和减一）再做 FFT。下文 8 点手算例因脉冲远离边缘、考察点无混叠，所以没补零也对得上——一般情况别省这一步。

符号说明：这里的 $R(\tau)$ 是时延 τ 的标量互相关函数，后文 §4.5 起的 $\hat{\mathbf{R}}$ 是 $M \times M$ 协方差矩阵——黑体加帽子，一撇之差，别认错。

为什么相位里藏着时延：沿用“麦 1 晚到”为正的定義， $x_1(t) = x_2(t - \tau_0)$ ，因此 $X_1(f) = X_2(f)e^{-j2\pi f\tau_0}$ 。于是

$$X_1(f)X_2^*(f) = |X_2(f)|^2 e^{-j2\pi f\tau_0},$$

相位 $\angle\{X_1 X_2^*\} = -2\pi f\tau_0$ 的斜率是 $-2\pi\tau_0$ 。例如 $\tau_0 = 58.3 \mu\text{s}$ 时，1 kHz 和 2 kHz 处的相位分别约为 -0.366 rad 和 -0.733 rad 。逆变换在 $\tau = \tau_0$ 处乘上 $e^{j2\pi f\tau_0}$ ，恰好抵消这条负斜率，各频点同相相加形成峰。PHAT 把互谱除以其幅度，使每个保留频点只贡献单位幅度的相位项；理想单时延模型下，减少谱包络对相关峰形的展宽。它不会修复混响或噪声造成的错误相位，还可能放大原本很弱、信噪比很低的频点，因此实现时通常在分母加 ε ，并可配合频带筛选或可靠度加权。

算例 4-0bis：8 点脉冲手算——慢做法与快做法数对上了

上面说“同一个 max”，空口无凭，用最简单的脉冲把两边各算一遍，数对上才算数。

设定： $N = 8$ ，序列 $(n = 0 \dots 7)$ ： $x_1 = [0, 0, 3, 0, 0, 0, 0, 0]$ （3 在 $n = 2$ 处，即 x_1 比 x_2 晚到 2 拍），
 $x_2 = [2, 0, 0, 0, 0, 0, 0, 0]$ （2 在 $n = 0$ 处）。线性互相关定义 $R(\tau) = \sum_n x_1(n)x_2(n - \tau)$ ，越界按 0 处理。脉冲位置远离边缘（考察 $\tau = 0/1/2$ 时下标 $2 - \tau = 2/1/0$ 全非负），线性相关与圆周相关在这三点无混叠、数值相等——一般情况记得补零到 $N \geq N_1 + N_2 - 1$ ，见上文补零提醒。

慢做法：时域逐 τ 算 $R(0)$ 、 $R(1)$ 、 $R(2)$ ，取 $\max$ 。 x_1 只在 $n = 2$ 处非零（值为 3），加总只剩一项：
 $R(\tau) = 3 \cdot x_2(2 - \tau)$ 。 $R(0) = 3 \cdot x_2(2) = 3 \times 0 = 0$ ； $R(1) = 3 \cdot x_2(1) = 3 \times 0 = 0$ ；
 $R(2) = 3 \cdot x_2(0) = 3 \times 2 = 6$ （ $\max$ ， $\hat{\tau} = 2$ ✓—— x_1 晚到 2 拍，峰在 +2，与设定一致）。

快做法：DFT 共轭乘 + IDFT，一项项手算。记 $W = e^{-j2\pi/8}$ ，DFT 定义 $X[k] = \sum_n x[n]W^{kn}$ 。 x_2 只有 $n = 0$ 项： $X_2[k] = 2$ （ $k = 0 \dots 7$ 全是 2）； x_1 只有 $n = 2$ 项： $X_1[k] = 3W^{2k} = 3e^{-j\pi k/2}$ ，逐个写出：
 $X_1 = [3, -3j, -3, 3j, 3, -3j, -3, 3j]$ ， $X_2^* = [2, 2, 2, 2, 2, 2, 2, 2]$ ，互谱
 $G[k] = X_1X_2^* = [6, -6j, -6, 6j, 6, -6j, -6, 6j]$ 。IDFT 为 $r[\tau] = \frac{1}{8} \sum_k G[k]e^{+j2\pi k\tau/8}$ ，算三点： $\tau = 0$ 时
 $\frac{1}{8}(6 - 6j - 6 + 6j + 6 - 6j - 6 + 6j)$ ，实部虚部各自相消，得 $\mathbf{r}[0] = 0$ ✓（ $= R(0)$ ）； $\tau = 1$ 时
 $G[k] \cdot e^{j2\pi k/8} = 6(e^{-j\pi/4})^k$ ， $k = 0 \dots 7$ 是公比 $\neq 1$ 的完整周期几何级数、配对相消，得 $\mathbf{r}[1] = 0$ ✓（ $= R(1)$ ）； $\tau = 2$ 时 $G[k] \cdot e^{j2\pi k \cdot 2/8} = 6e^{-j\pi k/2} \cdot e^{+j\pi k/2} = 6$ （指数精确抵消！）8 项全是 6，得 $r[2] = 48/8 = 6$ ✓（ $= R(2)$ ）。 $\tau = 2$ 处“指数精确抵消”正是上文“各频点相位恰好全部对齐（同相叠加）”的手算肉身——8 个频点在 $\tau = 2$ 处全变成实数 6 叠成 48，其他 τ 处有正有负互相抵消成 0。

对照表（数对上）： $\tau = 0$ 处时域 0、频域 0 ✓； $\tau = 1$ 处时域 0、频域 0 ✓； $\tau = 2$ 处时域 6（ $\max$ ）、频域 6（ $\max$ ）✓， $\hat{\tau} = 2$ 一致。

PHAT 在这例子里长什么样： $|G[k]| = 6$ 全频点相等，所以归一化不改变相对频谱。PHAT 谱
 $\Psi[k] = G[k]/|G[k]| = [1, -j, -1, j, 1, -j, -1, j]$ ，IDFT 在 $\tau = 2$ 处为 1，其余位置为 0。理想单时延、无噪条件下峰位不变；现实中，PHAT 改变各频点权重，峰位也可能受噪声和混响影响。

核心是加权函数 $\Phi(f)$ 的选择：

加权	公式	特点
互相关 CC	$\Phi = 1$	抗噪差，峰被噪声淹没
Roth	$1/ X_1 ^2$	抑制一路噪声
SCOT (smoothed coherence transform, 平滑相干变换)	$1/\sqrt{\hat{G}_{11}\hat{G}_{22}}$	对称白化：分母是平滑自功率谱的几何平均（ $\hat{G}_{11}$ 、 $\hat{G}_{22}$ 为 Welch 多帧平均得到的自功率谱，平滑抑制了噪声谱起伏）；多帧平均可减小单帧谱的随机起伏
PHAT (相位变换)	$1/(X_1X_2^* + \epsilon)$	归一化互谱幅度、保留相位；理想单时延下峰更尖，但不会消除错误相位，低信噪比频点需筛选或再加权
ML	依噪声谱自适应	理论最优但需噪声先验

（注意：单帧时 $\sqrt{|X_1|^2|X_2|^2} = |X_1X_2^*|$ ，SCOT 与 PHAT 字面等价；差别在多帧平均——SCOT 的分母换成平滑后的自谱，不受瞬时谱起伏影响，更稳。）


由时延换算角度： $\hat{\theta} = \arcsin(c\hat{\tau}/d)$ 。实现时自变量先限幅到 $[-1, 1]$ ，超限按端射方向处理或判为野值。

这个换算怎么来的：几何推导见 §2.1“时差的几何来源”。平面波以角 θ 斜入射，路程差 $\Delta = d \sin \theta$ （图12(c)），因此 $\hat{\tau} = d \sin \theta / c$ ； θ 从正横方向起算。若论文把角度定义为相对麦克风连线，则同一关系写成 $\hat{\tau} = d \cos \theta / c$ 。双麦

只给一个标量时延，三维中相容方向构成以连线为轴的锥面；要解除该模糊，需要增加不共线的麦克风或加入其他先验。

两个实用细节：①16 kHz 下一个采样点为 $62.5\ \mu\text{s}$ ；对 4 cm 间距，从正横方向的 0 延迟跳到 1 个采样点对应 $\arcsin(343 \times 62.5\ \mu\text{s}/0.04) \approx 32.4^\circ$ ，而且越靠近端射方向，同样的时延误差造成的角度误差越大。实际系统要对相关峰插值或拟合相位斜率，得到亚采样时延。②PHAT 提高了相位的相对权重，因此麦克风相位响应不一致会直接造成定位偏差（见 §10.2）。

图12 GCC-PHAT 声源定位原理：亚采样时延估计（模拟）




图示说明：(a) 两路波形错开一点（ $d = 4\ \text{cm}$ 、 $\theta = 30^\circ$ ，真实时延 $\tau \approx 58.3\ \mu\text{s}$ ）；(b) 互相关只有一个尖峰，峰值位置即时间差——注意 $58.3\ \mu\text{s}$ 只有约 0.93 个采样点（16 kHz 下一格 $62.5\ \mu\text{s}$ ），图中峰落在采样格之间，必须靠插值读出亚采样位置；(c) 时差 $\times$ 声速 = 路程差，路程差 $\div$ 间距 = 角度正弦（ θ 从正横起算，与 §2.1 约定一致）。这个“峰落在格子之间”的情形不是特例而是常态——§2.1“离散化与同步”说过 4 cm 小阵列的最大时差也不到 2 个采样格，因此需要亚采样插值。

算例：GCC-PHAT 完整数字链（ $d = 4\ \text{cm}$ 、 $\theta = 30^\circ$ ）：按 §2.1 几何关系，真值时延

$\tau_0 = d \sin \theta / c = 0.04 \times 0.5 / 343 \approx 58.3\ \mu\text{s}$ ；16 kHz 下 1 个采样点 = $62.5\ \mu\text{s}$ ，故峰的真值位置在 $58.3 / 62.5 \approx 0.93$ 个采样点（图12(b) 的峰正在格子之间）。直接取整读峰只能得到 1 个采样点（对应 $\arcsin(343 \times 62.5\ \mu\text{s} / 0.04) \approx 32.4^\circ$ ，偏差约 2.4° ）；做三点抛物线插值（取峰顶与其左右邻点拟合抛物线、顶点即亚采样峰位），可恢复出约 0.93 格，折回角度 $\arcsin(343 \times 0.93 \times 62.5\ \mu\text{s} / 0.04) \approx 30^\circ$ （精度注：按 0.93 格精确算是 $\arcsin(0.4984) \approx 29.9^\circ$ ，与 30° 真值的 0.1° 之差来自“约 0.93”的舍入，不是方法偏差）。这条“时延 $\rightarrow$ 格数 $\rightarrow$ 插值 $\rightarrow$ 角度”的链条就是亚采样级 TDOA（time difference of arrival，到达时间差：声波到两麦的时间差）估计的全部内容。

优缺点：频域实现为 $O(N \log N)$ ，适合实时处理；但一对麦每帧通常只读一个主峰，多源时会出现多个峰且跨麦对难以配对。强混响或低信噪比还会使峰展宽或选错。GCC 加权家族的经典出处是 Knapp & Carter, “The generalized correlation method for estimation of time delay”, *IEEE Trans. Acoustics, Speech, and Signal Processing*, 24(4): 320–327, 1976。

混响如何影响它：反射会把多个延迟副本叠到直达声上，使相关背景抬高、主峰展宽并出现旁峰。图13采用说明性的随机衰减尾模型：每路冲激响应由单位直达项和相互独立的指数衰减随机尾组成；采样率 16 kHz、帧长约 64 ms、无额外传感器噪声，每个 T_{60} 点做 150 次固定随机种子的试验。它不是几何房间的镜像法 RIR，也不是实测。图中只能支持“在这套随机尾模型下， T_{60} 增大时峰形和选峰正确率变差”的趋势；曲线上的精确百分比不能外推为真实房间或产品性能。工程系统还需去混响（§7.1）、帧间平滑与追踪（第 9 章），不能只信单帧峰值。



图示说明：图13(a)–(d)是随机衰减尾模型的单帧样例，旁峰位置受随机实现影响；图13(e)汇总 150 次玩具试验。该图用于说明衰减尾增强时主峰对比度和选峰正确率下降，不代表镜像法房间仿真或实测性能。

双麦 GCC 只提供一个麦对时延。三维定位或多源场景通常需要 §4.3 的 SRP-PHAT，联合多个麦对进行空间扫描。

4.3 SRP-PHAT：跨麦对累积空间响应

对空间中每个候选位置 $\vec{r}$ ：由几何算出“若声源在此，各麦对时延应是多少” $\tau_{ij}(\vec{r})$ ，再查 GCC-PHAT 值并累加：

$$\hat{\vec{p}} = \arg \max_{\vec{r}} \sum_{i < j} R_{x_i x_j}^{PHAT}(\tau_{ij}(\vec{r}))。$$

(4-1)

其中 $\tau_{ij}(\vec{r}) = (\|\vec{r}_i - \vec{r}\| - \|\vec{r}_j - \vec{r}\|)/c$ ——候选点到麦 i 的距离减去到麦 j 的距离，再除以声速；几何意义即下文 §4.4 的双曲线（等时差线）。

候选位置正确时，各麦对会在各自预测 TDOA 附近取得较大的 GCC-PHAT 值，累积得分随之升高；候选位置错误时，各麦对的取值通常无法同时达到峰值。扫描可扩展到三维网格，也可从空间响应图中寻找多个局部峰。多个峰是否对应真实声源，仍需结合最小峰距、置信度和跨帧一致性判断。

算例 4-1：SRP-PHAT 的六麦对累积

下面用两个候选点计算预测时延，再比较六个麦对的累积得分。

设定：平面 4 麦矩形阵，坐标 $\vec{r}_1 = (0, 0)$ 、 $\vec{r}_2 = (4\text{ cm}, 0)$ 、 $\vec{r}_3 = (0, 3\text{ cm})$ 、 $\vec{r}_4 = (4\text{ cm}, 3\text{ cm})$ ；真实声源在 $\vec{p} = (2\text{ m}, 1.5\text{ m})$ ；声速 $c = 343\text{ m/s}$ ，采样率 $f_s = 16\text{ kHz}$ （1 个采样点 $= 1/f_s = 62.5\text{ }\mu\text{s}$ ，折合成路程 $c/f_s = 343/16000 = 0.0214375\text{ m}$ ——后文所有“采样点”都靠这个数换算）。

第 1 步：算出“真实测量值”。声源在 $\vec{p}$ ，各麦到声源的距离由勾股定理 ($d_i = \|\vec{p} - \vec{r}_i\|$)：

麦 i	算式	d_i (m)
1	$\sqrt{2^2 + 1.5^2} = \sqrt{6.25}$	2.500000

麦 i	算式	d_i (m)
2	$\sqrt{1.96^2 + 1.5^2} = \sqrt{6.0916}$	2.468117
3	$\sqrt{2^2 + 1.47^2} = \sqrt{6.1609}$	2.482116
4	$\sqrt{1.96^2 + 1.47^2} = \sqrt{6.0025}$	2.450000

($\vec{r}_4$ 那行数值凑得正好: $6.0025 = 2.45^2$ 恰好开方开尽, 方便手算核对。)

麦对 (i, j) 的真实 TDOA (到达时间差) 折成采样点:

$$\tau_{ij} = \frac{d_i - d_j}{c} f_s = \frac{d_i - d_j}{0.0214375}^\circ$$

(单位: 采样点。)

例如麦对 $(1, 2)$: $\tau_{12} = (2.500000 - 2.468117)/0.0214375 = 0.031883/0.0214375 \approx +1.4873$ 个采样点——
物理含义: 声波到麦 1 的路程比到麦 2 长 3.19 cm, 所以麦 2 早到约 1.49 个采样点。这就是 GCC-PHAT (§4.2)
在每对麦上实际测到的峰位置。全部 6 对的结果见下表“真值”列。

第 2 步: 计算候选点的几何预测。假设声源在候选点 $\vec{r}$, 预测每对麦的时延 $\tau_{ij}(\vec{r}) = (\|\vec{r}_i - \vec{r}\| - \|\vec{r}_j - \vec{r}\|) f_s / c$, 再读取相应时延处的 GCC 值。

- 候选点 A = (2, 1.5) (就是真源): 距离与第 1 步完全相同, 预测的 τ_{ij} 与真值逐对相等;
- 候选点 B = (0.5, 0.5) (离阵列很近的错误点): $d_1 = \sqrt{0.5^2 + 0.5^2} = 0.707107$ 、
 $d_2 = \sqrt{0.46^2 + 0.5^2} = 0.679412$ 、 $d_3 = \sqrt{0.5^2 + 0.47^2} = 0.686222$ 、
 $d_4 = \sqrt{0.46^2 + 0.47^2} = 0.657647$ m。

第 3 步: 对比表 (单位均为采样点; “错位” = 候选点预测值 - 真值):

麦对 (i, j)	真值 = A 的预测	B 的预测	B 的错位
(1, 2)	+1.4873	+1.2919	-0.1954
(1, 3)	+0.8342	+0.9742	+0.1400
(1, 4)	+2.3324	+2.3071	-0.0252
(2, 3)	-0.6530	-0.3177	+0.3354
(2, 4)	+0.8451	+1.0152	+0.1701
(3, 4)	+1.4981	+1.3329	-0.1652

第 4 步: 由时延偏差计算得分。为便于手算, 这里用理想全带、无窗截断条件下的 sinc 峰模型: 真实时延处取值 1, 偏离 $\Delta\tau$ 个采样点后取 $\sin(\pi\Delta\tau)/(\pi\Delta\tau)$ 。实际 GCC 峰形还受带宽、窗函数、补零和混响影响, 因此该模型只用于说明累积过程。


- 候选点 A: 6 对麦的预测时延都等于真值, 每对贡献 1, SRP 得分 = $6 \times 1 = \mathbf{6.0000}$;
- 候选点 B: 6 对的贡献分别为 0.9384、0.9681、0.9989、0.8250、0.9531、0.9557, 合计 **5.6392**。各麦对的时延偏差不同, 累积得分低于 A;

- 镜像方向候选点 $(-1, 1.5)$ 的六对贡献约为 0.12、0.83、0.10、0.05、0.86、0.12，合计约 2.08。其中多组预测时延已落到 sinc 主峰之外。

结果解释：候选点 B 虽然与真源相距较远，得分仍接近峰值，说明小孔径阵列的空间响应峰可能较宽。错位量以采样点计时，16 kHz 下 1 个采样点对应约 2.14 cm 的传播距离，因此实际系统常用亚采样插值 (§4.2 细节①)。网格间隔、插值方式和 GCC 峰宽都会影响最终定位精度。

本手算采用 sinc 峰便于逐项计算；图14采用高斯 GCC 峰便于显示连续的等时差亮带。两者都在演示式(4-1)的麦对累积过程，数值不能相互代入。

图14 SRP-PHAT 定位过程（理想化 GCC 峰；6 个麦对 TDOA 累积）



图示说明：图14(a)给出四麦几何和候选网格；(b)先由真实声源计算六个麦对的观测 TDOA，再对每个候选点计算预测 TDOA，并在理想化高斯 GCC 峰上取值累积。亮带对应单个麦对的近似等时差轨迹，多条亮带在真实声源附近相交。色标是归一化麦对累积分数，不是实测声功率；峰宽还取决于设定的 GCC 峰宽和网格间隔。

计算口径：全网格计算量约随 $N_{\text{grid}}M(M-1)/2$ 增长。网格间距只给出离散化误差的下限，实际误差还受孔径、混响、信噪比、标定和插值影响。工程上常先粗扫，再只在主峰邻域细扫；节省多少计算量取决于两级网格范围，不能脱离配置给出固定倍数。

SRP 的计算量随网格点数和麦对数增加。若已获得可靠且已配对的 TDOA，也可以采用 §4.4 的几何解算，直接估计位置坐标。

4.4 两阶段法的几何解算

从时延到几何：一对麦克风测得时延差 τ_{ij} ，意味着声源到两麦的距离差为 $c\tau_{ij}$ 。平面上“到两定点距离差为常数”的轨迹是双曲线，三维中是双曲面。图14(b)用理想化高斯 GCC 峰给这些等时差轨迹赋予有限宽度，再累加六个麦对的分数；多条亮带在声源附近相交。

以麦 1 为参考，各麦对的 TDOA 构成方程组：

$$\|\vec{p} - \vec{r}_i\| - \|\vec{p} - \vec{r}_1\| = c\tau_{i1}, \quad i = 2..M.$$

- $\vec{p}$: 待求声源位置 (远场只需方向); $\vec{r}_i$: 第 i 个麦的坐标 (已知, 靠标定);
- 方程共 $M - 1$ 个。对一般近场非线性方程, 二维至少需要 3 只不共线麦、三维至少需要 4 只不共面麦, 且某些几何仍可能有多个候选解。方程数超过位置维数后可用最小二乘吸收测量误差。下面的 Chan 线性化还引入参考距离这一附加未知量, 因此其第一阶段无正则最小二乘在二维至少需要 4 只麦、三维至少需要 5 只麦, 并要求线性方程组满列秩。

算例 4-2: TDOA 几何解算数值例——两个时延怎么变成一个方向

§4.4 给出了方程组 $\|\vec{p} - \vec{r}_i\| - \|\vec{p} - \vec{r}_1\| = c\tau_{i1}$ 。远场条件下它退化为非常简单的几何: 每对麦给出方向的一个“方向余弦”分量。用具体数字走一遍。

设定: 3 麦直角布置, $\vec{r}_1 = (0, 0)$ (参考麦)、 $\vec{r}_2 = (4 \text{ cm}, 0)$ 、 $\vec{r}_3 = (0, 4 \text{ cm})$; 测得 $\tau_{21} = +0.0583 \text{ ms}$ 、 $\tau_{31} = +0.0825 \text{ ms}$ (按 §4.4 的约定, τ_{i1} = 声波到麦 i 的路程减去到麦 1 的路程, 再除以 c)。求声源方向。

第 1 步: 时延折成路程差。

$$c\tau_{21} = 343 \times 0.0583 \times 10^{-3} = 0.0199969 \text{ m} \approx 2.00 \text{ cm}$$

$$c\tau_{31} = 343 \times 0.0825 \times 10^{-3} = 0.0282975 \text{ m} \approx 2.83 \text{ cm}$$

物理读法: 声波到麦 2 比到麦 1 多走约 2.00 cm, 到麦 3 比到麦 1 多走约 2.83 cm。

第 2 步: 除以间距, 得方向余弦的绝对值。远场平面波假设下, 麦 1-2 连线 (x 轴) 方向上的路程差就是 $d|u_x|$ (u_x 是声源方向单位向量 $\vec{u}$ 在 x 轴上的分量, 即“方向余弦”), 于是:

$$\frac{c\tau_{21}}{d} = \frac{0.0199969}{0.04} = 0.4999 \approx 0.5 \Rightarrow \theta_x = \arcsin(0.5) = 30.0^\circ$$

$$\frac{c\tau_{31}}{d} = \frac{0.0282975}{0.04} = 0.7074 \approx \frac{\sqrt{2}}{2} \Rightarrow \theta_y = \arcsin(0.7074) \approx 45.0^\circ$$

(这里 θ_x 是从麦 1-2 连线的正横方向起算的角度, 与 §4.2 的约定一致。给定的两个 τ 本身是四舍五入过的: 精确的 30° 对应 $\tau_{21} = 0.058309 \text{ ms}$, 精确的 45° 对应 $\tau_{31} = 0.082461 \text{ ms}$, 保留 3 位有效数字正是题给数值。)

第 3 步: 定符号。方向余弦的符号由时延的正负直接读出: $\tau_{21} > 0$ 说明声波到麦 2 的路程更长, 即声源在麦 1 那一侧、沿 $-x$ 方向; 同理声源沿 $-y$ 方向。所以

$$u_x = -0.5, \quad u_y = -\frac{\sqrt{2}}{2} \approx -0.7071$$

第 4 步: 一致性检查与第三个分量。方向余弦必须满足 $u_x^2 + u_y^2 + u_z^2 = 1$ 。先检查:

$u_x^2 + u_y^2 = 0.25 + 0.5 = 0.75 \leq 1$ ✓——若这一步算出大于 1, 说明时延测量有野值, 方程无解, 这是工程上最便宜的自检。于是

$$u_z = \pm\sqrt{1 - 0.75} = \pm 0.5$$

± 号无法由数据决定: 三只麦共面, 平面上下两侧镜像的方向产生完全相同的 TDOA——这正是 §3.1 所说平面阵“上下镜像模糊”的具体实例。取上半球 $u_z = +0.5$ 。

第 5 步: 合成方位角与俯仰角。把 $\vec{u} = (-0.5, -0.7071, 0.5)$ 投到阵列平面内:

$$\varphi = \text{atan2}(u_y, u_x) = \text{atan2}(-0.7071, -0.5) = -125.26^\circ。$$

(即 234.74° 。) 俯仰角 $\phi_{el} = \arcsin(u_z) = \arcsin(0.5) = 30^\circ$ 。

(atan2 是带象限判断的反正切: $\arctan(0.7071/0.5) = \arctan(1.4142) = 54.74^\circ$, 因 u_x, u_y 同为负, 落在第三象限, 即 $54.74^\circ - 180^\circ = -125.26^\circ$ 。)

第 6 步: 代回几何模型验证。把这个方向代回平面波公式 $c\tau_{i1} = -\vec{u} \cdot \vec{r}_i$:

- $c\tau_{21} = -\vec{u} \cdot \vec{r}_2 = -(-0.5) \times 0.04 = 0.020000 \text{ m} \Rightarrow \tau_{21} = 0.020000/343 = 0.058309 \text{ ms} \approx +0.0583 \text{ ms} \checkmark$
- $c\tau_{31} = -\vec{u} \cdot \vec{r}_3 = -(-0.7071) \times 0.04 = 0.028284 \text{ m} \Rightarrow \tau_{31} = 0.028284/343 = 0.082461 \text{ ms} \approx +0.0825 \text{ ms} \checkmark$

完全回到给定值。顺便看一眼近场修正的量级: 若声源其实不远, 放在 $L = 2 \text{ m}$ 处的点

$\vec{p} = 2\vec{u} = (-1, -1.4142, 1) \text{ m}$ 上精确计算 (球面波, 不再用平面波近似), 得 $\tau_{21} = 0.0592 \text{ ms}$ 、 $\tau_{31} = 0.0830 \text{ ms}$ (分量注: τ_{21} 比远场 0.0583 ms 大 1.5% , τ_{31} 比远场 0.0825 ms 大 0.7% ——近场修正对两对麦的影响不一样, 不能按同一个比例折算); 放到 $L = 10 \text{ m}$ 则只差 0.3% ——这就是 §2.2 远场近似“多远算远”在这个具体阵列上的手感 (本例阵列孔径约 5.7 cm ——两条 4 cm 直角边的斜边 $\sqrt{4^2 + 4^2} = \sqrt{32} \approx 5.66 \text{ cm}$ —— 2 m 处已接近远场, 误差主要体现为百分比级)。

怎么解: 方程带根号、非线性, 有两条经典路线——1. **Chan 算法:** 把方程平方并重组为线性方程组。第一阶段把参考距离 $R_1 = \|\vec{p} - \vec{r}_1\|$ 当作附加未知量, 与位置一起求解; 第二阶段再利用 R_1 与位置的平方关系做加权修正。二维时未知量为 (p_x, p_y, R_1) , 所以第一阶段至少要 $M - 1 \geq 3$, 即 4 只麦; 三维至少要 5 只麦。计数只是必要条件, 还需阵列几何使矩阵满列秩、通道同步、TDOA 与麦对关联正确, 并满足点声源近场模型。低噪声且误差模型匹配时, 两步加权最小二乘可接近相应的 CRLB。Chan & Ho, IEEE TSP 1994

可跳过·进阶★★: 平方消根号的线性化展开 (以 $i = 2$ 为例): 记 $R_1 = \|\vec{p} - \vec{r}_1\|$, 原方程

$\|\vec{p} - \vec{r}_i\| = r_{i,1} + R_1$ 两边平方得 $\|\vec{p}\|^2 - 2\vec{r}_i^\top \vec{p} + \|\vec{r}_i\|^2 = r_{i,1}^2 + 2r_{i,1}R_1 + R_1^2$; 而

$R_1^2 = \|\vec{p}\|^2 - 2\vec{r}_1^\top \vec{p} + \|\vec{r}_1\|^2$, 代入后 $\|\vec{p}\|^2$ 在等式两边恰好相消; 整理得

$(\vec{r}_1 - \vec{r}_i)^\top \vec{p} - r_{i,1}R_1 = \frac{1}{2}(r_{i,1}^2 + \|\vec{r}_1\|^2 - \|\vec{r}_i\|^2)$ ——左边对未知量 $(\vec{p}, R_1)$ 是线性的, 右边全是已知量; 把

$i = 2..M$ 的行摞起来即线性方程组 $\mathbf{G} [\vec{p}^\top, R_1]^\top = \vec{h}$ (矩阵样例: $M = 3$ 、估 2D 位置时未知量

(p_x, p_y, R_1) 共 3 个、方程 $i = 2, 3$ 只有 2 行, $\mathbf{G}$ 是 2×3 的矮胖矩阵——这就是为什么 2D 定位至少要 4

只麦 (三对时延): 方程数 $M - 1$ 必须压过未知量个数), 第一步最小二乘先解它, 第二步再用 $R_1 = \|\vec{p} - \vec{r}_1\|$

的平方关系加权修正一次。以 $i = 2$ 代入算例 4-2 的数验量纲: $\vec{r}_1 = (0, 0)$ 、 $\vec{r}_2 = (0.04, 0)$ 、 $r_{2,1} = 0.02$

m, 右边 $= \frac{1}{2}(0.02^2 + 0 - 0.04^2) = \frac{1}{2}(0.0004 - 0.0016) = -0.0006 \text{ (m}^2\text{)}$, 左边

$(\vec{r}_1 - \vec{r}_2)^\top \vec{p} - 0.02R_1$ 也是“米×米”量级, 等式两边单位均为 m^2 。2. **泰勒级数迭代:** 从 SRP-PHAT 的粗解

出发, 在当前估计点 $\vec{p}_k$ 把方程一阶展开 (线性化), 用最小二乘解修正量并更新:

$$\vec{p} \leftarrow \vec{p} + (\mathbf{J}^\top \mathbf{J})^{-1} \mathbf{J}^\top \boldsymbol{\varepsilon}.$$

令观测距离差为 $\vec{z} = [c\tau_{21}, \dots, c\tau_{M1}]^\top$, 模型预测为 $\vec{h}(\vec{p})$, 这里定义残差 $\boldsymbol{\varepsilon} = \vec{z} - \vec{h}(\vec{p})$ (实测减预测),

$\mathbf{J} = \partial \vec{h} / \partial \vec{p}$ 。在这个残差定义下, 上式使用加号; 若把残差定义成预测减实测, 更新式必须改用减号。 $\mathbf{J}$ 的第 i 行是两个单位方向向量之差。迭代需要足够接近真解的初值; 要抗野点还需配合稳健损失或剔除机制, 普通最小二乘本身并不抗野点。

为什么小阵列定位难——几何放大 (GDOP, geometric dilution of precision, 几何精度因子)：观察双曲线会发现，在小阵列附近“等时差线”非常密集且近乎平行，一丁点时延误差就会被几何关系放大成大角度误差——好比拿手电照远墙：灯头只转一度，墙上光斑能挪几米，转角没变，是距离把它放大了；小阵列的短基线正是这个“远墙”，时延误差是灯头的抖，角度误差是墙上晃的光斑：

$$\text{var}(\theta) \propto \left(\frac{c}{d}\right)^2 \sigma_\tau^2$$

- σ_τ ：时延估计误差； d ：麦间距。上式是正横方向附近的一阶近似。一般方向还要除以 $|\cos \theta|$ ，因此端射附近误差放大更明显（见 §4.9 第 1 题）。例如，4 cm 间距下 10 μs 的时延误差在正横附近对应约 5° 的角度误差。

这就是“同样是 GCC，贴脸的双麦耳机只能粗判左右，房间级分布式阵列却能做到厘米级定位”的根本原因——不是算法差，是几何差 (GDOP, 几何精度因子，越小越好)。

两阶段几何法需要先把各麦对 TDOA 归属于同一声源；多源时数据关联会显著变难。§4.5 的 Bartlett 和 Capon 改为空间扫描，可直接从多个谱峰寻找候选方向。

4.5 波束扫描类：Bartlett 与 Capon

Bartlett: $P_B(\theta) = \vec{a}^H(\theta) \hat{\mathbf{R}} \vec{a}(\theta)$ 。读法： $\hat{\mathbf{R}} = \frac{1}{T} \sum_t \vec{x} \vec{x}^H$ 是数据的协方差——好比合唱考勤表：对角线是每只麦自己的音量（自功率），非对角是两只麦齐唱的程度（互相关），整张表就是阵列的“合唱快照”； $\vec{a}^H \hat{\mathbf{R}} \vec{a}$ 正好是“拿导向矢量当权重、把波束转向 θ 后的平均输出功率”——所以它叫**波束扫描**：转动灯头、把聚光灯逐方向转一圈，哪里亮声源就在哪。分辨率被瑞利限锁死（主瓣宽度就是它的分辨极限，§2.6），旁瓣高。

Capon/MVDR 谱：对每个候选方向设计“该方向增益为 1、输出功率最小”的滤波器：

$$P_C(\theta) = \frac{1}{\vec{a}^H(\theta) \hat{\mathbf{R}}^{-1} \vec{a}(\theta)}。$$

(4-2)

这个式子来自约束优化：最小化 $\vec{w}^H \hat{\mathbf{R}} \vec{w}$ ，同时要求 $\vec{w}^H \vec{a}(\theta) = 1$ 。拉格朗日乘子法给出 $\vec{w} = \hat{\mathbf{R}}^{-1} \vec{a} / (\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a})$ ；把该权重代回输出功率，得到上面的 Capon 谱。完整推导见 §5.4 和式(5-1)。候选方向与真实源方向一致时，无失真约束保留该源，因此最小输出功率较大；方向不匹配时，优化器可进一步压低输出功率。 $\hat{\mathbf{R}}$ 是 $M \times M$ 协方差矩阵。Capon 在模型准确、快拍充分时通常比 Bartlett 得到更窄的谱峰；快拍不足、相干多径或协方差病态时，应加正则并检查稳健性。

可跳过·进阶★★★：拉格朗日求解三步：

第 1 步——列函数、求梯度：拉格朗日函数 $L(\vec{w}, \lambda) = \vec{w}^H \hat{\mathbf{R}} \vec{w} + \lambda(1 - \vec{w}^H \vec{a}) + \lambda^*(1 - \vec{a}^H \vec{w})$ ；对 $\vec{w}^H$ 求梯度并置零得 $\hat{\mathbf{R}} \vec{w} = \lambda \vec{a}$ ，即 $\vec{w} = \lambda \hat{\mathbf{R}}^{-1} \vec{a}$ ；

第 2 步——代约束、定倍数：把上式代入约束 $\vec{w}^H \vec{a} = 1$ ，定出 $\lambda = 1/(\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a})$ ，于是最优权重 $\vec{w}_{\text{opt}} = \hat{\mathbf{R}}^{-1} \vec{a} / (\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a})$ ；

第 3 步——代回、看相消：最小输出功率 $\vec{w}_{\text{opt}}^H \hat{\mathbf{R}} \vec{w}_{\text{opt}}$ 里分子分母的 $\hat{\mathbf{R}}$ 与 $\hat{\mathbf{R}}^{-1}$ 相消一次，剩下 $1/(\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a})$ ；Capon 谱把这个“最小功率”直接当作该方向的空间谱值——干扰方向的功率被约束优化主动压掉，谱峰于是比 Bartlett 尖锐。

算例 4-3：Bartlett vs Capon 最小可算例——同一个 $\hat{\mathbf{R}}$ ，两种读法

§4.5 说 Capon 谱“更尖”，尖多少？用一个 2×2 的例子把两种谱在同一组数据上各算两个点。

设定： $M = 2$ 麦，间距 $d = \lambda/2$ ；单源在 $\theta = 0^\circ$ （正横方向），信号功率归一为 1，各麦独立白噪声功率 $\sigma^2 = 0.25$ （ $\text{SNR} = 10 \lg(1/0.25) \approx 6 \text{ dB}$ ）。导向矢量（§2.6 相位差公式的 $M = 2$ 版本）：

$$\vec{a}(\theta) = [1, e^{-j\pi \sin \theta}]^\top.$$

（横写加 $^\top$ 与列向量等价，省版面。）

第 1 步：写出协方差矩阵。源在正横、两麦同相（ $\sin 0^\circ = 0$ ， $\vec{a} = [1, 1]^\top$ ），于是 $\hat{\mathbf{R}} = \vec{a} \vec{a}^H + \sigma^2 \mathbf{I}$ ：非对角元 $= 1 \times 1 = 1$ （两麦信号的互相关系数），对角元 = 信号 1 + 噪声 0.25：

$$\hat{\mathbf{R}} = \begin{bmatrix} 1.25 & 1 \\ 1 & 1.25 \end{bmatrix}$$

第 2 步：Bartlett 谱读两个点。 $P_B(\theta) = \vec{a}^H \hat{\mathbf{R}} \vec{a}$ 。

- 源方向 $\theta = 0^\circ$ ： $\vec{a} = [1, 1]^\top$ ， $P_B =$ 四个元素之和 $= 1.25 + 1 + 1 + 1.25 = 4.5$ （功率展开读：对角自功率 $2 \times 1.25 = 2.5$ ，非对角互功率 $2 \times 1 = 2$ ——峰值里一半是各麦自己的音量，一半是两麦齐唱的功劳）；
- 错开方向 $\theta = 30^\circ$ ： $\vec{a} = [1, -j]^\top$ （ $\sin 30^\circ = 0.5$ ， $e^{-j\pi/2} = -j$ ），先算 $\hat{\mathbf{R}} \vec{a} = [1.25 \times 1 + 1 \times (-j), 1 \times 1 + 1.25 \times (-j)]^\top = [1.25 - j, 1 - 1.25j]^\top$ ，再左乘 $\vec{a}^H = [1, +j]$ （注意共轭： $-j$ 取共轭变 $+j$ ）： $P_B = 1 \times (1.25 - j) + j \times (1 - 1.25j) = 1.25 - j + j - 1.25j^2$ ，其中 $-1.25j^2 = +1.25$ ，虚部 $-j + j = 0$ 精确相消，得 **2.5**（纯实数，符合“二次型必为实数”的自检）。

峰/旁比 $= 4.5/2.5 = 1.8$ ，约 2.6 dB—— 30° 处还残留峰值的 56%，峰又宽又肉。

第 3 步：Capon 谱读同样两个点。先求逆： $\det \hat{\mathbf{R}} = 1.25^2 - 1^2 = 0.5625$ ，

$$\hat{\mathbf{R}}^{-1} = \frac{1}{0.5625} \begin{bmatrix} 1.25 & -1 \\ -1 & 1.25 \end{bmatrix}$$

- 源方向 $\theta = 0^\circ$ ： $\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a} = \frac{1.25 - 1 - 1 + 1.25}{0.5625} = \frac{0.5}{0.5625} \approx 0.889$ ， $P_C = 1/0.889 = 1.125$ ；

• 错开方向 $\theta = 30^\circ$: $\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a} = \frac{1 \times (1.25 + j) + j \times (-1 - 1.25j)}{0.5625} = \frac{2.5}{0.5625} \approx 4.444$,
 $P_C = 1/4.444 = \mathbf{0.225}$ 。

峰/旁比 = $1.125/0.225 = \mathbf{5.0}$ ，约 7.0 dB—— 30° 处只剩峰值的 20%。

为什么 Capon 更尖：Bartlett 在 30° 方向上只是“被动接收”，源从 0° 漏进旁瓣的能量照单全收；Capon 的滤波器被要求在 30° 保持增益 1 的同时**总输出功率最小**——而 $\hat{\mathbf{R}}$ 里最大的功率来源就是 0° 那个源，最优解只好在 0° 方向压出一个零陷，把漏进来的能量定向抵消掉。同一个 $\hat{\mathbf{R}}$ ，Bartlett 只用到“二次型”，Capon 用到了它的逆——逆矩阵里藏着“源在哪、往哪躲”的信息。 $M = 2$ 只能压一个零陷，反差还算温和；麦数越多，能同时压的干扰方向越多，峰越尖。

扫描类方法的分辨率受阵列孔径和频率限制。§4.6 的 MUSIC 与 ESPRIT 可在模型匹配时获得更窄的峰，但对源数、标定误差和相干源更敏感。

4.6 子空间类：MUSIC 与 ESPRIT

MUSIC（多重信号分类，Schmidt, 1986）

思想三步： 1. 由数据估协方差矩阵 $\hat{\mathbf{R}}$ 并特征分解：前 K 个大特征值张成**信号子空间 $\mathbf{E}_s$** ，其余 $M - K$ 个小特征值张成**噪声子空间 $\mathbf{E}_n$** （ K 为源数）； 2. 利用模型关键性质——**真实方向上的导向矢量与噪声子空间正交**； 3. 构造伪谱，分母在真实 DOA 处趋零，出现尖峰：

$$P_{MU}(\theta) = \frac{1}{\vec{a}^H(\theta) \mathbf{E}_n \mathbf{E}_n^H \vec{a}(\theta)}。$$

(4-3)

钥匙类比：候选导向矢量是钥匙，噪声子空间是锁孔——钥匙对上（正交），锁“咔哒”打开（分母为零、谱值冲天）；没对上，钥匙根本插不进去（分母有限、谱值平平）。

第 2 步为什么成立（一行推导）：信号模型下协方差矩阵是 $\mathbf{R} = \mathbf{A} \mathbf{S} \mathbf{A}^H + \sigma^2 \mathbf{I}$ ，其中 $\mathbf{A}$ 是 $M \times K$ 的导向矢量矩阵（每列是一个源的导向矢量）、 $\mathbf{S}$ 是 $K \times K$ 的源信号协方差矩阵、 $\sigma^2 \mathbf{I}$ 是白噪声（ $\mathbf{I}$ 为 $M \times M$ 单位矩阵）。第一项 $\mathbf{A} \mathbf{S} \mathbf{A}^H$ 的秩最多是 K （源数），它张成的空间恰好就是各导向矢量张成的空间——即信号子空间 $\mathbf{E}_s$ ；剩下的 $M - K$ 个特征向量与这个空间正交，组成 $\mathbf{E}_n$ 。白噪声只是把所有特征值整体抬高 σ^2 ，不改变特征向量。所以拿候选方向的导向矢量去和 $\mathbf{E}_n$ 做内积：**猜对了就是零，猜错了不是零**——把分母换成这个内积，谱峰自然尖锐如针。

可跳过·进阶★★：正交三步的秩论证（分步说明）：第1步—— $\text{rank}(\mathbf{A}\mathbf{S}\mathbf{A}^H) \leq \min(M, K, K) = K$ （非相干源时 $\mathbf{S}$ 满秩、 $\mathbf{A}$ 列满秩，取等为 K ），故 $\mathbf{R}$ 的前 K 个大特征值对应信号、后 $M - K$ 个小特征值（值 $= \sigma^2$ ）对应噪声，特征分解把两者切开；第2步——信号子空间 $\text{span}(\mathbf{E}_s) = \text{span}(\mathbf{A})$ （同一 K 维空间的两组基），而特征分解保证 $\mathbf{E}_n \perp \mathbf{E}_s$ ，于是 $\mathbf{E}_n^H \mathbf{A} = \mathbf{0}$ ，即每个真实导向矢量都与整个噪声子空间正交；第3步——分母 $\|\mathbf{E}_n^H \vec{a}(\theta)\|^2$ 在真实 DOA 处为零（伪谱冲向无穷）、偏离时大于零，扫描 θ 即得尖峰。 K 到子空间的映射对应关系为：源数 $K \rightarrow$ 大特征值 K 个 $\rightarrow \mathbf{E}_s$ 占 K 维、 $\mathbf{E}_n$ 占 $M - K$ 维（具体数字手感见算例 4-4： $M = 3, K = 1$ 时特征值 3, 0, 0， $\mathbf{E}_n$ 恰为 $\vec{e}_2, \vec{e}_3$ 两维）。相干源时 $\mathbf{S}$ 掉秩、第一步的“ $= K$ ”不再成立，这正是空间平滑要修复的前提。

算例 4-4：MUSIC 最小可算例——亲手摸一摸“正交”

§4.6 的 MUSIC 基于一个条件：真实方向的导向矢量与噪声子空间正交。用一个 3×3 的例子把这句话算成看得见的数字。

设定： $M = 3$ 麦均匀线阵，间距 $d = \lambda/2$ （ λ 为波长）；单源，方向 $\theta = 0^\circ$ （正横方向，即垂直于阵列连线）；无噪声。

第1步：写出导向矢量的显式形式。 $d = \lambda/2$ 时相邻麦相位差为 $\psi = \frac{2\pi d}{\lambda} \sin \theta = \pi \sin \theta$ （§2.6 的相位差公式），以麦 1 为参考：

$$\vec{a}(\theta) = [1, e^{-j\pi \sin \theta}, e^{-j2\pi \sin \theta}]^\top。$$

（横写加 $^\top$ 与列向量等价，省版面。）

代入 $\theta = 0^\circ$ （ $\sin \theta = 0$ ）： $\vec{a}(0^\circ) = [1, 1, 1]^\top$ ——正横方向声波同时到达三只麦，相位全同，符合直觉 ✓。

第2步：写出无噪声协方差矩阵。无噪声时快拍 $\vec{x} = \vec{a}s$ ，于是 $\mathbf{R} = E\{\vec{x}\vec{x}^H\} = \vec{a}\vec{a}^H \cdot E\{|s|^2\}$ ，取信号功率归一（ $E\{|s|^2\} = 1$ ）即 $\mathbf{R} = \vec{a}\vec{a}^H$ 。第 m 行第 n 列为 $e^{j(n-m)\pi \sin \theta}$ ：

$$\mathbf{R} = \begin{bmatrix} 1 & e^{j\pi \sin \theta} & e^{j2\pi \sin \theta} \\ e^{-j\pi \sin \theta} & 1 & e^{j\pi \sin \theta} \\ e^{-j2\pi \sin \theta} & e^{-j\pi \sin \theta} & 1 \end{bmatrix} \xrightarrow{\theta=0^\circ} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

若改用 $\theta = 30^\circ$ ，则 $\psi = \pi/2$ ，

$$\mathbf{R} = \begin{bmatrix} 1 & j & -1 \\ -j & 1 & j \\ -1 & -j & 1 \end{bmatrix}。$$

这能直接检查复协方差的两个性质： $R_{nm} = R_{mn}^*$ ，所以 $\mathbf{R} = \mathbf{R}^H$ ；对角元是各通道功率，必须为非负实数。

第3步：口算特征值。两个事实就够：① $\mathbf{R} = \vec{a}\vec{a}^H$ 是秩 1 矩阵（每一列都是 $\vec{a}$ 的倍数——这里三列完全相同），秩 1 意味着只有一个非零特征值；② 特征值之和 = 矩阵的迹（对角线之和）= $1 + 1 + 1 = 3$ 。所以三个特征值必是

$$\lambda_1 = 3, \quad \lambda_2 = \lambda_3 = 0。$$

（此处 λ 表矩阵特征值，不是波长——字母复用，见 §2.3 清单。）

“1 个大特征值 = 1 个源”——这就是 §4.6“前 K 个大特征值张成信号子空间”在最简单情形下的样子。(附注：若加入功率为 σ^2 的白噪声，特征值变成 $3 + \sigma^2, \sigma^2, \sigma^2$ ——大特征值被整体抬高，噪声子空间的地板露出来，数值验证 $\sigma^2 = 0.01$ 时得 3.01, 0.01, 0.01，与理论一致。)

第 4 步：找出噪声子空间。零特征值对应的特征向量满足 $\mathbf{R}\vec{e} = \vec{0}$ ，即“与 $[1, 1, 1]^\top$ 正交的向量”。任取两个互相也正交的：

$$\vec{e}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}, \quad \vec{e}_3 = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix}$$

验证 $\mathbf{R}\vec{e}_2$ ：每一行都是 $1 \times 1 + 1 \times (-1) + 1 \times 0 = 0$ ，再除以 $\sqrt{2}$ 仍是 0 ✓； $\mathbf{R}\vec{e}_3$ ：每行 $1 + 1 - 2 = 0$ ✓；且 $\vec{e}_2^H \vec{e}_3 = (1 \times 1 + (-1) \times 1 + 0 \times (-2)) / \sqrt{12} = 0$ ✓。 $\{\vec{e}_2, \vec{e}_3\}$ 张成噪声子空间 $\mathbf{E}_n$ 。

第 5 步：见证正交性。拿真实方向 $\theta = 0^\circ$ 的导向矢量与噪声子空间做内积：

$$\begin{aligned} \vec{a}^H(0^\circ) \vec{e}_2 &= \frac{1}{\sqrt{2}} (1 \times 1 + 1 \times (-1) + 1 \times 0) = 0 \\ \vec{a}^H(0^\circ) \vec{e}_3 &= \frac{1}{\sqrt{6}} (1 \times 1 + 1 \times 1 + 1 \times (-2)) = 0 \end{aligned}$$

两个内积精确为零——MUSIC 伪谱的分母 $\vec{a}^H \mathbf{E}_n \mathbf{E}_n^H \vec{a} = |0|^2 + |0|^2 = 0$ ，理想无噪下谱值趋于无穷大：真实方向上竖起一根针。

第 6 步：对照——猜错方向就不正交。试 $\theta = 30^\circ$ ： $\psi = \pi \sin 30^\circ = \pi/2$ ，

$\vec{a}(30^\circ) = [1, e^{-j\pi/2}, e^{-j\pi}]^\top = [1, -j, -1]^\top$ 。逐个算：

$$\begin{aligned} \vec{a}^H(30^\circ) \vec{e}_2 &= \frac{1}{\sqrt{2}} (1 \times 1 + (+j) \times (-1) + (-1) \times 0) = \frac{1-j}{\sqrt{2}} \Rightarrow \left| \frac{1-j}{\sqrt{2}} \right|^2 = \frac{2}{2} = 1 \\ \vec{a}^H(30^\circ) \vec{e}_3 &= \frac{1}{\sqrt{6}} (1 \times 1 + (+j) \times 1 + (-1) \times (-2)) = \frac{3+j}{\sqrt{6}} \Rightarrow \left| \frac{3+j}{\sqrt{6}} \right|^2 = \frac{10}{6} = \frac{5}{3} \end{aligned}$$

分母 $= 1 + \frac{5}{3} = \frac{8}{3} \approx 2.667 \neq 0$ ，伪谱 $P_{MU}(30^\circ) = \frac{1}{8/3} = \frac{3}{8} = 0.375$ ——一个平平无奇的有限值。 0° 处是理想无噪下的无穷大尖峰、 30° 处只有 0.375：“猜对了就是零，猜错了不是零”变成了具体的数字。整个 MUSIC 就是把这 $M = 3$ 的口算推广到任意 M 、再对 θ 扫描一遍。

能力：理想条件下（高 SNR、快拍充分、标定准确、无相干多径——即本节“三个代价”都不触发时）可突破瑞利限——主瓣宽几十度的阵列仍能分出间隔只有几度的两个源，分辨率由 SNR 与快拍数限制而非孔径。

三个适用边界：– 需事先知道源数 K 。可按 §4.1.1 比较特征值间隙，或使用 AIC/MDL 信息准则。低 SNR、快拍不足和相干源都会削弱特征值分界，进而造成子空间维数误判；– **相干源失效：**混响多径使信号子空间塌缩——为什么“相干”会塌秩？两路信号完全相干（一路是另一路的延迟衰减副本）时，源协方差矩阵 $\mathbf{S}$ 的秩从 2 掉到 1。用一个 2×2 的例子可以直接验证：设反射是直达延迟 3 个采样点再衰减一半， $s_2(n) = 0.5 s_1(n-3)$ （混响味的写法：直达幅度 1，反射幅度 0.5、晚到 3 拍），信号功率归一（ $E\{|s_1|^2\} = 1$ ），则 $\mathbf{S} = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 0.25 \end{bmatrix}$ ——第二行恰是第一行的一半，两行线性相关，行列式 $= 1 \times 0.25 - 0.5 \times 0.5 = 0$ ，秩为 1。于是 $\mathbf{A}\mathbf{S}\mathbf{A}^H$ 随之塌成秩 1，本该两个的大特征值只剩一个——特征谱“大-小台阶”直接塌掉，MUSIC 把两个源当成一个。补救是空间平滑：ULA（uniform linear array，均匀线阵）切成 L 个重叠子阵（ $L \geq K$ ，即子阵个数不少于相干源数）、分别估协方

差再平均，子阵间相位差把相干“打散”、恢复满秩——定量代价是有效孔径从 M 降为 $M - L + 1$ (L 取 $M/2$ 量级时约损失一半孔径)，即用有效孔径换秩，分辨率也会降低；- 对模型误差敏感（麦位标定、相位响应、精确流形），这是它与 SRP-PHAT 在鲁棒性上的根本交换。

空间平滑的尺寸还要同时满足子阵可分辨性。若 L 表示重叠子阵数，则每个子阵长度为 $P = M - L + 1$ ；恢复 K 个相干源通常至少要求 $L \geq K$ ，而 MUSIC 还需 $P > K$ 才保留非空噪声子空间。只检查 $L \geq K$ 不够。

变体：root-MUSIC（ULA 上多项式求根，免网格搜索、精度更高——对应关系为：把分母 $\vec{a}^H \mathbf{E}_n \mathbf{E}_n^H \vec{a}$ 写成 z 域多项式；取最靠近单位圆的 K 个根；由根的相位反推角度）；宽带语音需逐频点非相干叠加，或聚焦类方法（CSSM、TOPS——把各频点的导向矢量先对齐到同一参考频率再合并处理，让宽带信号也能用窄带子空间方法）。

专栏：NormMUSIC——宽带逐频叠加时，为什么要先归一化

语音是宽带信号（300 Hz 到 8 kHz 都有能量），窄带 MUSIC 一次只能吃一个频点。最糙的宽带办法叫非相干平均：每个频点各自算一条 MUSIC 伪谱，再把各频点的谱直接加起来找峰。听起来顺理成章，实则有个坑：各频点的谱峰高低差得离谱——低频段波长长、阵列电尺寸小，伪谱峰又矮又胖；高频段峰又高又尖。直接相加等于让高频段一票否决低频段，低频的信息基本被淹没，弱源的峰还可能被某频点的旁瓣冒名顶替。

NormMUSIC 在各频点分别计算伪谱，再除以该频点伪谱的最大值，最后跨频率求和。归一化削弱了不同频点绝对峰高的差异，使合并结果更强调峰的位置。它也会把纯噪声频点的最大值归一到 1，因此实际系统通常还要根据频点信噪比或伪谱峰背比筛选低可靠度频点。

宽带合并前的频点筛选：归一化伪谱接近平坦时，该频点提供的方向信息有限。可按信噪比、谱峰与背景之比或统计可靠度选择频点；门限应在目标数据集上验证，不能把某个经验值当作通用标准。

ESPRIT（旋转不变子空间法，Roy & Kailath, 1989）

先看单源情形：两个平移子阵接收的信号子空间只差一个由子阵位移决定的相位因子，求出该因子即可反演方向，不需要逐角度扫描。多源时，每个源对应 Ψ 的一个特征值。具体地， $\mathbf{E}_{s2} = \mathbf{E}_{s1} \Psi$ ，其中 $\mathbf{E}_{s1}$ 、 $\mathbf{E}_{s2}$ 是两个子阵的信号子空间， Ψ 是二者之间的旋转矩阵；其特征值相位由子阵位移和 DOA 决定。ESPRIT 的优点是免谱搜索；它仍需准确知道两子阵的相对位移与取向，并要求阵列具有平移不变结构。相干源需要先做去相关处理，宽带或球阵扩展也会受混响和模型误差影响。

算例：ESPRIT 最小数字链 ($M = 3$ 、 $d = \lambda/2$)：子阵 1 取麦 {1,2}，子阵 2 取麦 {2,3}。在本章导向矢量约定下，旋转因子为 $\Psi = e^{-j\pi \sin \theta}$ ，因此反演式是

$$\theta = \arcsin\left(-\frac{\arg \Psi}{\pi}\right)。$$

$\theta = 0^\circ$ 时 $\Psi = 1$ ，反演得 0° ； $\theta = 30^\circ$ 时 $\Psi = -j$ 、 $\arg \Psi = -\pi/2$ ，反演得 30° 。不能对 $\arg \Psi$ 取绝对值，否则会丢失左右方向的符号。若交换两子阵的次序， Ψ 变为共轭，反演式中的符号也要同时改变。上式还假定相位没有空间混叠； $d > \lambda/2$ 时，主值相位可能对应多个角度，必须限制搜索区间或使用额外频率消歧。

MUSIC 与 ESPRIT 的上述推导基于窄带模型。宽带语音需要在频率维度合并信息，下一节讨论相干与非相干宽带处理。

4.6.1 宽带聚焦：跨频率合并子空间信息

MUSIC、ESPRIT 的基本推导采用窄带假设：在单个频点内，导向矢量 $\vec{a}(f, \theta)$ 固定。宽带语音的波长随频率变化，同一个物理方向在不同频点对应不同的阵列流形。NormMUSIC 在各频点独立计算伪谱后再合并，不能利用跨频率的相干信息。聚焦类方法先把不同频点的导向矢量映射到共同的参考频率，再合并协方差并进行特征分解。

聚焦矩阵的思想。挑一个参考频率 f_0 （常取频带中央），对每个实际频点 f_j 找一个变换矩阵 $\mathbf{T}(f_j)$ （就叫聚焦矩阵），要求它把该频点的导向矢量“搬运”到参考频率的样子： $\mathbf{T}(f_j)\vec{a}(f_j, \theta) \approx \vec{a}(f_0, \theta)$ ，对关心的角度范围内都成立。搬运完成后，各频点的协方差矩阵也跟着搬（ $\mathbf{T}\hat{\mathbf{R}}(f_j)\mathbf{T}^H$ ），再按信号能量加权平均成一个“聚焦后的协方差”，然后继续使用 MUSIC 或 ESPRIT。CSSM（coherent signal-subspace method，相干信号子空间方法）是这类方法的代表。聚焦矩阵把不同频率下的阵列流形映射到共同参考流形。

初始角从哪来。构造 $\mathbf{T}(f_j)$ 时“关心的角度范围”必须事先给出来——这构成聚焦类方法的一项限制：它要一份初始角度猜测（比如先用 Bartlett 或 SRP-PHAT 粗扫一遍，峰在哪就把聚焦区间划在哪）。初始猜测偏了，聚焦矩阵往错误的方向上对齐，后面 MUSIC 峰也会跟着偏。工程上常做两轮：粗扫给初值 → 聚焦精估 → 拿精估结果当新的初值再聚一次，迭代一两次收敛。

相干源为什么让聚焦失效。混响多径里直达和反射是相干的（一个是另一个的延迟衰减副本），源协方差矩阵掉秩（§4.6 的 2×2 例子：完全相干时 $\mathbf{S}$ 行列式为零、秩从 2 掉到 1）。聚焦矩阵的构造默认各源不相干、子空间结构干净；相干时聚焦后的协方差把直达和反射搅在一起，对齐的“目标语言”本身就是糊的，MUSIC 峰要么合并、要么指偏。补救还是空间平滑那一套，只是在聚焦前先对每个频点做平滑，代价同样是有有效孔径打折。

TOPS：避免依赖初始角度。TOPS（test of orthogonality of projected subspaces，投影子空间正交性检验）回答“行”：它不构造聚焦矩阵、也不做频率搬运，而是换了个检验思路——把某个候选方向的参考导向矢量投影到每个频点的信号/噪声子空间上，看“正交关系”在各频点之间是否自治。真实方向在所有频点都满足正交性，假方向在各频点正交得七零八落。代价：失去了聚焦带来的相干增益，低 SNR 下通常不如 CSSM 能利用相干增益；优点：彻底摆脱初始角依赖，适合缺少可靠初值的宽带多源粗估。

WAVES：按频点可靠度加权。WAVES（weighted average of signal subspaces，加权信号子空间平均）处在两者之间：不做显式聚焦，而是按频点的信噪比或子空间质量加权平均信号子空间：可靠频点权重较大，噪声占优的频点权重较小。它同样不要精确初始角（权重只跟信噪比和子空间质量有关），鲁棒性在三者里最好，代价是权重设计多一两个超参要调。

选择时可按以下条件区分：有可靠初值且希望利用跨频率相干信息，可用 CSSM 类聚焦；缺少初值时可考虑 TOPS；各频点可靠度差异较大时可用 WAVES 加权。相干源场景通常先在各频点做空间平滑，再进行宽带合并。

子空间法完成宽带扩展后，§4.7 转向稀疏重构与数据驱动定位。

4.7 稀疏重构与深度学习

稀疏重构：把角度网格化 ($N_{\text{grid}} \gg M$ 个候选方向)，每个方向摆一个“模板”（导向矢量），真实信号只来自其中少数几个方向，于是“用模板拼出观测数据”的系数向量是**稀疏的**（绝大多数位置为零）；用 L1 正则（惩罚系数绝对值之和，使解倾向于只保留少量非零系数）或稀疏贝叶斯学习（SBL, sparse Bayesian learning, 稀疏贝叶斯学习）把少数非零位置挑出来，即得 DOA。优点：单快拍可用、超分辨、免源数估计；代价：计算量大、存在网格失配（真实方向不在网格点上就偏，需 off-grid 扩展）。

网格无关方法：FRIDA 与原子范数。上面稀疏重构有个先天别扭：真实方向是连续值，算法却先把它按 1° 一格切好再挑——真源落在两格之间（比如 30.4° ）时能量漏到相邻两格上，幅度被摊薄、位置还偏，这就是网格失配。网格切越细失配越小，但字典矩阵越胖、算得越慢，计算代价随之增加。网格无关方法把“先切格子”这步整个拿掉，直接在连续角度域上找最稀疏的解释。

两条代表路线如下：①FRIDA (finite rate of innovation DOA, 有限新息率波到达方向估计)：把阵列输出看成“每源贡献一个有向脉冲”的连续信号，用类谱估计的手段（先估出指数和的参数、再反解角度，路子接近 ESPRIT 的连续参数精神）一次性解出方向，不经过任何网格，单快拍也能工作，代价是对模型标定和噪声同样敏感；②原子范数 (atomic norm)：把 L1 的“鼓励稀疏”从离散格子推广到连续原子集合——优化目标直接写成“用最少的连续导向矢量拼出数据”，数学上是半定规划，精度不受网格限制，还可以估计“到底用了几个原子”（免源数估计的连续版）。两者的共同代价：计算量比网格版更大（半定规划+连续优化），实时系统里多半离线用或当高精度基准；共同优点：彻底没有“格子切多细”的超参纠结，可避免离散网格本身引入的量化偏差。选择依据是：要实时、能容忍 1° 量级网格偏，就用网格版 L1-SVD/SBL；要做离线高精度分析、或者源恰好卡在格子缝里，就换 FRIDA/原子范数这类连续域方法。

DNN 定位：网络用带方向标签的多通道数据学习噪声、混响与直达声线索之间的映射。训练规模、房间覆盖范围和阵列几何决定其泛化边界。

路线	代表（骨干 × 输出格式）	做法	效果特征
GCC- PHA T 特 征 + DNN	Vesperini、Vecchiotti 等（ <i>Computer Speech & Language</i> , vol.49, 2018）：MLP（multilayer perceptron, 多层感知机）/CNN 骨干 × 角度网格分类输出	多麦对 GCC-PHAT Patterns 向量 → MLP/CNN 角度网格分类	低分辨率（ $5\sim 10^\circ$ 网格）但极抗噪
特征 + 级 联回 归 (IP Dnet 一族)	IPDnet 类：CNN/CRNN（convolutional recurrent neural network, 卷积循环网络）骨干 × 分类粗定 + 回归细化两级输出	吃相位差 (IPD, inter-microphone phase difference, 麦间相位差) + 幅度谱堆叠特征，先分网格粗定再回归细化，天然适配宽带语音、免 CSSM 式频率对齐	混响下单/多源误差明显小于 SRP-PHAT，跨阵列迁移好于端到端波形网

路线	代表（骨干 × 输出格式）	做法	效果特征
空间谱学习	Chakrabarty & Habets 2017/2019: CNN 骨干 × 空间谱/DOA 直接回归输出	声像图 → CNN 直接回归空间谱/DOA, 噪声信号训练实现多源 arXiv:1807.11722	多源同时定位, 强混响下大幅优于 SRP-PHAT
TF 单元级定位	帧级/时频 bin 级网络 + 直方图累积	利用语音时频稀疏性 (每 bin 常单源占优); 全频带联合建模 (cross-band 跨频带相关, 借 §5.9/§8.1 的 SpatialNet 分离网思想) 是已知改进方向	可与分离联合, 性能依赖训练与测试匹配
序列模型	CRNN/Transformer 骨干 × ACCDOA/multi-ACCDOA 输出格式 (ACCDOA = activity-coupled Cartesian DOA, 活动耦合笛卡尔坐标方向, Shimada et al., ICASSP 2021: 向量长度表有无声、方向表位置, 一根向量同时回答“谁在说、在哪说”; 向量例子: 30° 方向有人说话输出 $0.9 \times (\cos 30^\circ, \sin 30^\circ) = (0.78, 0.45)$ ——长度 0.9 表“有人在说”、指向表“在 30° 说”, 静音段输出长度 ≈ 0 的小向量、直接弃用)	利用时序上下文, 输出活动-定位耦合	同时解决“谁在说、在哪说”, 多说话人/强混响下报告精度较好的方案之一 (截至 2026 年, 代表性结果以原文为准)

图9(b)的使用范围：三条曲线由概念玩具模型生成，只用于说明误差可能随混响增强而上升，以及不同方法的退化速度可能不同。曲线的绝对数值、交点和方法排序都不是实验结果，不能据此比较算法性能。真实比较必须固定数据集、阵列、信噪比、混响、训练数据与误差指标。卷积空间谱定位的代表性方法可参见 Chakrabarty & Habets [arXiv:1807.11722](#)，期刊版 DOI [10.1109/JSTSP.2019.2901664](#)。数据驱动方法还需要考虑标注成本、跨房间泛化和模型复杂度。

相关研究前沿——SELD（声事件定位与检测，sound event localization and detection）：不只回答“说话人在哪”，而是同时回答“**什么声音**（狗叫/键盘/玻璃碎）+ **从哪里来** + **什么时候发生**”，是 DCASE 挑战赛的核心任务（代表数据集 STARSS23），方法上与 ACCDOA 一脉相承，也是机器人听觉、安防监控的技术基础。[DCASE Challenge](#)

距离估计：从方向扩展到三维位置：远场模型只给方向；只有进入近场、波前曲率不可忽略时，阵列几何才直接包含距离信息（见 §3.1）。声音事件定位与检测任务也可增加距离输出头，同时估计事件类别、方向和距离。网络可能利用波前曲率、直达混响比和声级衰减等线索，但这些线索都受声源级别、房间和训练分布影响。距离结果必须在明确的数据集、误差定义和距离范围内报告，不能与只估方向的结果直接比较。

4.8 定位算法总对比

算法	分辨率	鲁棒性	多源	实时性	方法定位
GCC-PHAT	极低	★★	✗	极佳	双麦快速基线（源数免知； $O(N \log N)$ ）
SRP-PHAT	中	★★☆	✓	好(加速后)	常用网格扫描基线（源数免知； $O(N_{\text{grid}} M^2)$ ）
Bartlett	低	★☆	✓	好	教学基准（源数免知； $O(N_{\text{grid}} M^2 + T M^2)$ ）
Capon	中高	★★	✓	好	自适应扫描（源数免知； $O(N_{\text{grid}} M^2 + M^3)$ ）
MUSIC/root-MUSIC	高	★★☆(相干源需平滑)	✓	好	超分辨标杆，怕标定误差（需已知源数； $O(M^3 + N_{\text{grid}} M^2)$ ）
ESPRIT	高	★★☆	✓	极佳	免谱搜索、对导向矢量标定不敏感（仍需精确标定子阵平移量），要对称阵（需已知源数； $O(M^3)$ ）
L1-SVD/SBL	高	★★	✓	差	单快拍超分辨（源数免知；计算量大）
DNN（SRP-CNN/CRNN）	高	★★★★	✓	中	强混响下可选的 DNN 路线之一（代价见 §4.7），依赖训练数据（源数免知；推理开销大）

表注：鲁棒性一星到四星只做横向排序、不做绝对精度承诺，抗混响与抗噪合看（混响权重更高）； N_{grid} =角度/位置网格数， N =帧长， T =快拍数， M =麦克风数。Bartlett 每网格点算 $\vec{a}^H \hat{\mathbf{R}} \vec{a}$ 是 $O(M^2)$ ，另有 $O(TM^2)$ 估协方差；SRP-PHAT 的 $O(N_{\text{grid}} M^2)$ 按麦对数 $M(M-1)/2 \approx M^2/2$ 计；MUSIC 行的“需平滑”指相干源场景需空间平滑预处理，其代价是约一半有效孔径（§4.6）。

理论极限长什么样——CRLB 小框。Cramér-Rao 下界（CRLB）给出指定观测模型下无偏估计量的方差下界。对已知波形、加性白噪声中的时延估计，Fisher 信息随线性 SNR、观测量以及信号的均方根带宽平方增加，因此时延方差下界随这些量减小。精确系数取决于单通道还是双通道模型、SNR 定义、单边或双边谱、波形是否已知以及是否同时估计未知幅度等条件；条件未写全时，不能把某个系数或微秒数当成通用下界。对 DOA 而言，还要通过阵列几何的雅可比把时延下界换成角度下界。定性上，SNR、有效带宽、快拍数和有效孔径增大通常会降低方差，端射方向和退化阵列几何会放大误差。

选择依据：先看几何与采样率预算（孔径、GDOP、亚采样能力），再选算法——小孔径场景任何算法都救不回来。在此之上：资源受限且不使用训练数据时可考虑 SRP-PHAT（免训练、粗到细加速）；高分辨研究用 MUSIC/root-MUSIC + 空间平滑；强混响/多说话人/算力充足 → DNN（CRNN/ACCDOA）或与 SRP-PHAT 级联。

定位置信度与丢轨判据：单帧给一个方向是不够的，在线系统还要回答“这个方向值不值得信、目标跟丢了没有”。三个常用健康度量：①**峰值显著度**（主峰与次高峰/背景均值的比值，SRP 功率图或 GCC 峰背比；比值越大说明指向越明确）；②**帧间一致性**（连续多帧 DOA 的方差或中值偏移，平稳声源下跳动大即不可信）；③**信号存在性**（该方向波束输出的 SNR 或语音存在概率，静音段的方向估计直接弃用）。丢轨阈值必须用本系统验证集标定；满足丢轨条件后，追踪器应转入重捕获状态，而不是继续输出抖动角度。这三类量是第 9 章追踪状态机的输入。

4.9 本章练习

1. ★基础 (TDOA + GDOP): 4 cm 双麦、正横方向附近, 时延估计偏了 $10\ \mu\text{s}$, 角度会偏多少? (参考答案: 正横附近 $\Delta\theta \approx c\Delta\tau/d = 343 \times 10 \times 10^{-6}/0.04 \approx 0.086\ \text{rad} \approx 5^\circ$ —— $10\ \mu\text{s}$ 还不到 1/6 个采样点, 角度已经晃 5° , 这就是 §4.4 那笔账; 再想想: 声源转到端射方向, 同样的 $10\ \mu\text{s}$ 会偏得更大还是更小? 追问答案: 更大, 而且越靠近端射放大越狠—— $\Delta\theta \approx c\Delta\tau/(d\cos\theta)$, 声源在 $30^\circ/60^\circ/80^\circ/85^\circ$ 处同样的 $10\ \mu\text{s}$ 分别对应约 $5.67^\circ/9.83^\circ/28.3^\circ/56.4^\circ$; 85° 处不到 1/6 个采样点的误差能晃出 56° , 端射附近的角度估计会非常不稳定。) (符号对齐正文: Δ 表偏差量, σ 表标准差 (σ_r^2 为方差); 时延单位 s (此处 μs), 角度单位 rad (此处换算成 $^\circ$)).)
 2. ★★进阶 (CRLB 口径题): 为什么只写“带宽 4 kHz、SNR 0 dB”还不足以算出唯一的 TDOA CRLB? (参考答案: 还需说明单通道或双通道观测、波形已知与否、SNR 和单/双边谱定义、观测时长或快拍数、信号的实际谱形及其均方根带宽, 以及未知幅度等干扰参数; 条件不同, Fisher 信息和常数系数都会变化.)
-
-

第 5 章 · 波束形成

5.1 统一问题表述

波束形成器对 M 路信号做线性组合（频域）：

$$y(k, n) = \vec{w}^H(k, n) \vec{x}(k, n)。$$

设计目标：期望方向 θ_0 无失真 ($\vec{w}^H \vec{a}(\theta_0) = 1$) 的前提下，最小化某类噪声/干扰的输出功率。所有经典波束形成器的差别只在：用什么噪声模型、加什么约束。三类噪声的现实对应：

- **传感器白噪声**：麦克风自噪声 $\rightarrow$ 对应度量白噪声增益 (White Noise Gain, 简称 WNG)；
- **弥散噪声**：混响尾音、风噪（各向同性散射场，协方差矩阵 $\mathbf{\Gamma}$ 的第 i, j 个元素为 $[\mathbf{\Gamma}]_{ij} = \text{sinc}(2fd_{ij}/c)$, d_{ij} 为两麦间距；本章 sinc 用归一化定义 $\text{sinc}(x) = \sin(\pi x)/(\pi x)$ ，部分文献用 $\sin x/x$ ，对照时注意因子 π ；口径与第 02 章的 sinc 定义互标一致，换算时先统一定义） $\rightarrow$ 对应度量指向性指数 (Directivity Index, 简称 DI)。DI 越高，表示对目标方向保持单位响应时，来自其他方向的弥散噪声输出功率越低；
- **定向点干扰**：竞争说话人、电视 $\rightarrow$ 在干扰方向形成零陷。

前两类噪声分别用 WNG 和 DI 衡量。DSB、超指向、WNG 约束和对角加载都可在这两个指标下比较：

$$\text{WNG} = \frac{|\vec{w}^H \vec{a}|^2}{\vec{w}^H \vec{w}}, \quad \text{DI} = \frac{|\vec{w}^H \vec{a}|^2}{\vec{w}^H \mathbf{\Gamma} \vec{w}}。$$

WNG 是阵列对**通道独立白噪声**的输出 SNR 增益，DI 是对指定弥散场模型的输出 SNR 增益。两者都是功率比，换算为 dB 时取 $10 \log_{10}$ ；无失真约束下分子恒为 1，只需比较分母。4 元 $\lambda/2$ 线阵的算例见算例 2-2。

弥散场其实有两种常用模型，读论文时要分清：**球面各向同性**（声音从四面八方来，相干系数为 sinc 形，晚期混响用）与**柱面各向同性**（声音只从水平面各方向来，相干系数为零阶贝塞尔函数 $J_0(2\pi fd/c)$ ，会议室多人噪声更接近这种）[Habets, JASA 2008](#)。

时域还是频域实现？ 本章公式写在频域，每个频点各有一组权重 $\vec{w}(k)$ 。短时傅里叶变换 (STFT) 把宽带语音分解为一组近似窄带的问题 (§2.5)，逐频点求解后再逆变换。对应的时域形式称为**滤波求和 (filter-and-sum)**：每路麦克风经过一段 FIR 滤波器后求和，DSB 是滤波器退化为纯延迟的特例；Frost 波束形成器则是时域自适应 LCMV 的经典实现。两种实现的计算量、算法延迟和约束实现方式取决于帧长、滤波器长度与硬件，不应只凭“时域”或“频域”作统一判断。

5.2 延迟求和波束形成器 (Delay-and-Sum Beamformer, 简称 DSB)：“合唱前先把大家对齐”

$\vec{w}_{DSB} = \frac{1}{M} \vec{a}(\theta_0)$ ：按导向矢量把各通道时延补偿后等权相加，目标方向同相叠加（增益 M 倍），其他方向因未对齐而部分抵消。

手算例子：2 麦相距 $d = 4$ cm，声源与阵列正横方向夹角 30° （从正横量角，§2.1 约定，本章统一用此约定），频率 $f = 1$ kHz。1. 时延差： $\Delta\tau = \frac{d \sin 30^\circ}{c} = \frac{0.04 \times 0.5}{343} \approx 58.3 \mu\text{s}$ ； 2. 相位差：

$\Delta\phi = 2\pi f\Delta\tau = 2\pi \times 1000 \times 58.3\mu s \approx 0.366 \text{ rad} \approx 21^\circ$; 3. 导向矢量 (以麦 1 为参考): $\vec{a} = [1, e^{-j0.366}]^\top$; 4. DSB 权重: $\vec{w} = \vec{a}/2 = [0.5, 0.5e^{-j0.366}]^\top$, 验证无失真约束: $\vec{w}^H \vec{a} = \frac{1}{2}(1 + e^{j0.366}e^{-j0.366}) = 1 \checkmark$; 5. 含义: 麦 2 的信号乘上 $e^{+j0.366}$ 后补偿到达相位差, 两路目标信号同相相加。若直接求和, 目标幅度变为 2 倍、目标功率变为 4 倍, 独立同功率白噪声的功率只变为 2 倍, 因此输出 SNR 提高 2 倍, 即 3 dB ($10 \log_{10} 2$)。写成 $\vec{w} = \vec{a}/M$ 的平均形式时, 目标响应保持为 1, 噪声功率减半, 所得 SNR 增益相同。

波束图的等比数列推导: 1. 把波束指向 θ_0 后, 去测另一个方向 θ 的输出: 各通道先按 θ_0 补偿相位, 再求和。记相邻两麦的残余相位差 $\psi = \frac{2\pi d}{\lambda}(\sin \theta - \sin \theta_0)$, 则第 m 个麦在求和时带着因子 $e^{jm\psi}$; 2. 输出幅度就是等比数列求和 (公比 $e^{j\psi}$):

$$B(\psi) = \sum_{m=0}^{M-1} e^{jm\psi} = e^{j(M-1)\psi/2} \frac{\sin(M\psi/2)}{\sin(\psi/2)}$$

3. 取模: $|B| = \left| \frac{\sin(M\psi/2)}{\sin(\psi/2)} \right|$ 。 $\psi = 0$ (即 $\theta = \theta_0$) 时分子分母都趋于零, 取极限得最大值 M 。离开目标方向后, 该比值随 ψ 周期变化, 形成主瓣、零点和旁瓣; 4. 主瓣边缘: 第一个零点在 $M\psi/2 = \pi$ 即 $\psi = 2\pi/M$, 换算回角度得“零点到零点”宽度 $= 2\lambda/(Md)$ (正横附近, 斜指向按 §2.6 除 $\cos\theta_0$), 半功率宽度 $\approx 0.886\lambda/(Md)$ ——§2.6 的主瓣宽度公式就是这么来的: 孔径越大、频率越高, 主瓣越窄。(口径: 本报告 HPBW 一律按有效孔径 $(M-1)d$, 大 M 近似下写作 Md , 见 §2.6 与算例 3-4。)

均匀加权等价于空间域的矩形窗, 其第一旁瓣相对主瓣约为 -13 dB。非均匀加权 (如 Dolph-Chebyshev 加权) 可按设计值降低旁瓣, 但会展宽主瓣; 因此必须在旁瓣电平、主瓣宽度和有效孔径之间权衡。

WNG 上限是怎么算出来的 (两步, 柯西-施瓦茨不等式): 1. 代入 DSB 权重 $\vec{w} = \vec{a}/M$:

$\text{WNG} = \frac{|\vec{w}^H \vec{a}|^2}{\|\vec{w}\|^2} = \frac{|\vec{a}^H \vec{a}/M|^2}{\|\vec{a}\|^2/M^2} = \frac{1}{M/M^2} = M$ ——所以 DSB 的白噪增益恰好是 $10 \log_{10} M$ dB; 2. 若各阵元目标响应幅度均为 1, 则 $\|\vec{a}\|^2 = M$ 。柯西-施瓦茨不等式给出 $|\vec{w}^H \vec{a}| \leq \|\vec{w}\| \|\vec{a}\|$, 所以满足精确无失真约束的权重有 $\text{WNG} \leq M$, 等号在 $\vec{w} \propto \vec{a}$ 时成立。这个结论针对空间白噪声、精确导向矢量和单位幅度阵列流形; 阵元增益不等、噪声相关或导向失配时不能直接套用。

- **优点:** 在上述理想模型下达到最大 WNG, 结构简单; 若实际导向矢量等于设计值, 目标响应为 1;
- **缺点:** DI 平庸、无干扰零陷能力——课程讲义引用的球阵/圆阵实验称小阵列 DSB 几乎无法改善识别率。

[Kumatani et al.](#)

DSB 常作为固定波束基线, 也可作为自适应算法的初始权重。

5.3 超指向与 WNG-DI 权衡

在期望方向无失真约束下最大化 DI (等价于 MVDR 对阵各向同性噪声):

$$\min_{\vec{w}} \vec{w}^H \mathbf{\Gamma} \vec{w} \quad \text{s.t.} \quad \vec{w}^H \vec{a}(\theta_0) = 1, \quad \Rightarrow \quad \vec{w}_{SD} = \frac{\mathbf{\Gamma}^{-1} \vec{a}}{\vec{a}^H \mathbf{\Gamma}^{-1} \vec{a}}.$$

(推导与式(5-1)使用同一个带线性约束的二次型优化, 只是把噪声协方差 $\mathbf{R}_{nn}$ 换成弥散噪声相干矩阵 $\mathbf{\Gamma}$ 。完整推导见 §5.4。)

小间距阵列可利用相邻通道的差分获得高于 DSB 的弥散场指向性。代价是低频 WNG 降低，阵元自噪声、增益误差、相位误差和阵列模型误差都会被放大。实际设计通常加入 $\vec{w}^H \vec{w} \leq \delta$ 形式的 WNG 约束，或按频段选择不同权重：低频在 WNG 预算内提高指向性，高频在 $\mathbf{\Gamma} \approx \mathbf{I}$ 时使用接近 DSB 的解。课程讲义给出了特定小尺寸球阵条件下的对比结果，不能脱离其阵列与数据条件外推。[Kumatani et al. (出处同 §5.2 引文)]

算例 5-1：超指向权重与 WNG

题设：2 麦小间距 $d = 0.05\lambda$ ，弥散噪声相干矩阵 $\mathbf{\Gamma} = \begin{bmatrix} 1 & \text{sinc}(0.1) \\ \text{sinc}(0.1) & 1 \end{bmatrix}$ (§5.1: $[\mathbf{\Gamma}]_{ij} = \text{sinc}(2d_{ij}/\lambda)$), 这里 $\text{sinc}(x) = \sin(\pi x)/(\pi x)$, $\text{sinc}(0.1) = \frac{\sin(0.1\pi)}{0.1\pi} \approx 0.9836$ 。超指向权重 $\vec{w}_{SD} = \frac{\mathbf{\Gamma}^{-1} \vec{a}}{\vec{a}^H \mathbf{\Gamma}^{-1} \vec{a}}$ (§5.3)。

第 1 步：检查 $\mathbf{\Gamma}$ 的病态程度

$$\det \mathbf{\Gamma} = 1 - 0.9836^2 = 0.0325, \quad \mathbf{\Gamma}^{-1} = \frac{1}{0.0325} \begin{bmatrix} 1 & -0.9836 \\ -0.9836 & 1 \end{bmatrix} \approx \begin{bmatrix} 30.80 & -30.29 \\ -30.29 & 30.80 \end{bmatrix}$$

两麦噪声的相干系数为 $\rho = 0.9836$ ，所以 $\mathbf{\Gamma}$ 接近奇异，逆矩阵元素达到 30 量级。后续求得的权重会相应放大。

第 2 步：正横指向的退化情形

若 $\theta_0 = 0^\circ$ ，则 $\vec{a}_0 = [1, 1]^\top$ 恰好是 $\mathbf{\Gamma}$ 的特征向量 ($\mathbf{\Gamma} \vec{a}_0 = (1 + \rho) \vec{a}_0$)，于是 $\mathbf{\Gamma}^{-1} \vec{a}_0 = \vec{a}_0 / (1 + \rho) \propto \vec{a}_0$ ，归一化后

$$\vec{w}_{SD} = [0.5, 0.5]^\top = \vec{w}_{DSB}, \quad \text{WNG} = +3.0 \text{ dB}$$

——超指向解退化成普通延迟求和。对称双麦阵在正横方向的导向矢量正好是弥散相干矩阵的特征向量，因此没有额外收益。随着指向偏离正横方向，超指向解与 DSB 的差异增大，端射附近通常最明显；不能概括成“只有端射才有增益”。下面用端射方向展示最强的差分效应。

第 3 步：端射指向的权重

$$\psi = 2\pi \times 0.05 \times \sin 90^\circ = 0.1\pi \approx 0.3142 \text{ rad } (18^\circ), \quad \vec{a} = [1, e^{-j0.3142}]^\top = [1, 0.9511 - 0.3090j]^\top。$$

$$\text{分子: } \mathbf{\Gamma}^{-1} \vec{a} \approx \begin{bmatrix} 1.9869 + 9.3616j \\ -1.0033 - 9.5174j \end{bmatrix} \quad (\text{已经接近 } 10 \text{ 量级, 且两分量近乎反号});$$

$$\text{分母: } \vec{a}^H \mathbf{\Gamma}^{-1} \vec{a} \approx 3.9737 \quad (\text{正实数});$$

相除：

$$\vec{w}_{SD} \approx \begin{bmatrix} 0.5000 + 2.3559j \\ -0.2525 - 2.3951j \end{bmatrix}, \quad |w_1| = |w_2| \approx 2.41$$

第 4 步：验证无失真约束

$$\vec{w}^H \vec{a} = \underbrace{(0.5000 - 2.3559j)}_{w_1^* a_1} + \underbrace{(0.5000 + 2.3559j)}_{w_2^* a_2} = 1 \quad \checkmark$$

每一项的模长都是 2.41，而两项虚部 $\mp 2.356j$ 相消后留下单位目标响应。权重分量明显大于最终目标响应，因此很小的通道误差也会破坏这种相消关系。

第 5 步：算 WNG，看代价

$$\|\vec{w}\|^2 = 2.41^2 + 2.41^2 \approx 11.60, \quad \text{WNG} = 10 \log_{10} \frac{1}{11.60} \approx -10.6 \text{ dB}$$

对照：同一指向的 DSB 是 +3.0 dB。负 WNG 表示独立的阵元自噪声被权重能量放大；本例 $\|\vec{w}\|^2 \approx 11.6$ ，即相对单麦高约 10.6 dB。作为交换，在本例的理想各向同性弥散场、紧凑双麦端射模型下，指向因数为 $1/(\vec{w}^H \mathbf{\Gamma} \vec{w}) \approx 3.97$ ，约 +6.0 dB。这个上限依赖模型和极限条件，不是任意双麦几何、频率与噪声场的保证。

第 6 步：通道失配的影响

给麦 2 加 1% 的增益失配，即把 $\vec{a}$ 的第二分量乘以 1.01：

$$\vec{w}^H \vec{a}_{mis} = 1.0050 + 0.0236j。$$


目标响应误差幅度约 2.4‰。

相同的 1% 增益失配作用在 DSB 上时，目标响应误差为 0.5‰；本例超指向误差约为其 5 倍。权重范数越大，通道增益与相位误差造成的响应偏差通常越明显。因此超指向设计应结合器件规格做失配扫描，并加入 WNG 约束或对角加载 (§5.4)。

第 7 步：比较不同归一化间距（均指向端射 90°）：

d	0.5λ	0.1λ	0.05λ	0.02λ	0.01λ
权重模长 $ w_i $	0.50	1.24	2.41	5.98	11.94
WNG	+3.0 dB	-4.9 dB	-10.6 dB	-18.5 dB	-24.6 dB

在本例的双麦端射模型中，间距减半时权重模长近似翻倍，WNG 约降低 6 dB；这一近似来自权重随 λ/d 增长、白噪声输出功率随 $(\lambda/d)^2$ 增长。表中数值只对应所列理想模型，实际设计还要加入通道失配、自噪声与阵列几何误差。



图示说明：图15使用 6 元均匀圆阵，圆半径按相邻阵元弦长 4 cm 确定；导向矢量与弥散相干矩阵都由同一组二维阵元坐标计算。左图比较 DSB 与超指向的 WNG，右图比较二者在球面各向同性弥散场模型下的 DI。超指向解加入很小的数值正则以稳定求逆。曲线展示该理想模型下的频率趋势，不代表硬件实测，也不能把某个交点当作通用设计门限。

差分麦克风阵列 (Differential Microphone Array, 简称 DMA) 是超指向的时域形态：一阶 DMA 输出

$y(t) = x_1(t) - g x_2(t - \tau)$, 复数增益 g 与内时延 τ 共同决定心形/超心形/8 字形 ($\tau = 0$ 且 $g = 1$ 时为偶极——纯实增益相减只能得到前后对称的 8 字形族, 心形必须“延迟+相减”, 完整的双麦推导见算例 3-1; 端射双麦即一阶 DMA), 多级差分叠加成更高阶指向族; 频率无关的恒定波束、尺寸极小 (TWS 耳机可用), 但 WNG 差、对麦距与增益失配极敏感。

四项诊断量: 超指向或 MVDR 权重求出后, 应检查以下指标, 再进入录音评估。

1. **WNG 余量:** 算 $\text{WNG} = 1/\|\vec{w}\|^2$ (精确无失真约束下), 再用本机的自噪声、增益/相位公差和目标输出余量确定最低允许值。阈值必须来自器件规格与失配仿真, 不能用一个固定 dB 数覆盖所有设备;
2. **条件数:** 算 $\mathbf{\Gamma}$ 或 $\hat{\mathbf{R}}_{nn}$ 的条件数 $\kappa = \lambda_{\max}/\lambda_{\min}$ 。条件数增大表示求逆对协方差估计误差更敏感; 可通过对角加载 (§5.4)、降阶或减少约束改善。可接受上限应由浮点精度、快拍数和失配仿真共同确定;
3. **削波率与动态余量:** 把权重作用于代表性录音或按目标电平生成的测试信号, 检查输出峰值和削波率。权重范数大时, 通道叠加可能增加峰值; 应预留数字动态余量, 并在需要时收紧 WNG 约束;
4. **通道失配灵敏度:** 按照麦克风数据手册、标定残差和装配误差给导向矢量逐通道施加增益、相位与位置扰动, 统计目标响应 $|\vec{w}^H \vec{a}_{mis} - 1|$ 、零陷位置与 WNG 的变化。算例 5-1 第 6 步提供了 1% 增益失配的手算; 实际扰动范围和验收门限必须按设备确定。

专栏: 差分麦克风 (DMA) ——从一阶心形到高阶与神经差分

上一节末尾说 DMA 是“超指向的时域形态”, 这里把这句话展开: 它到底差分了什么、心形从哪来、为什么能做小、以及它和现在研究里的神经差分是什么关系。

一阶差分原理: 两个相距很近的麦克风接收同一远场声波时存在小的传播时延差。对其中一路施加内部延迟和增益后相减, 可使某些方向相消、另一些方向保留。输出写成 $y(t) = x_1(t) - g x_2(t - \tau)$: g 控制两路幅度与相位配比, τ 控制相减前的内部延迟; 改变 (g, τ) 就会改变零点位置和指向图形状。

心形是怎么配出来的 (端射双麦): 设声音从 0° (正对麦 1 一侧) 来, 两麦延迟差为 $\tau_0 = d/c$ 。取 $g = 1$ 、 $\tau = \tau_0$, 则 180° (正后方) 来的声音在两麦间走出的路程差恰好被内部延迟抵掉、两路同相相减归零——零点打在后; 而 0° (正前方) 来的声音在两麦间多走了一个来回, 相减反而保留——前方拾取。零点在后、波瓣在前的形状就是**心形 (cardioid)**: 前方拾取、后方抑制。若把零点从 180° 往两侧挪 (调 g 与 τ 的配比), 过渡带压得更窄、但后方冒出小旁瓣, 这就是**超心形 (supercardioid)** 一族。**8 字形 (figure-8)** 则是另一副模样: 零点打在侧向 ($\pm 90^\circ$)、前后两个波瓣对称拾取。同一套减法硬件, 参数不同、零点位置不同。注意心形必须“延迟+相减”配合: $\tau = 0$ 且 $g = 1$ 的纯实数相减只能得到前后对称的偶极子 (dipole), 变不出前后不对称的心形。

高阶 DMA (拿级联换更窄的波束): 把多个一阶差分单元串起来 (前级的输出做后级的输入), N 级级联就是 N 阶 DMA, 指向性随阶数变窄 (理想指向性指数随阶数线性增长), 且整套结构仍然只用加减延迟、尺寸可以做得很小——助听器、真无线耳机里塞的就是它。代价同样级联放大: 每加一阶, 白噪声增益再掉一截, 对麦克风间距与增益一致性的要求再严一档; 所以三阶以上很少裸用, 一般要配均衡或与超指向的白噪声增益约束联合设计。

高阶 DMA 设计对照表 (端射摆位, 一阶原型取心形/超心形族): 阶数每加一, 零点多一个、波束窄一圈、白噪增益掉一截——选阶数就是在这三者之间点菜。

阶数 N	零点 数 (理想)	典型形状举例	理想 DI (端射)	WNG 趋势	失配敏感度	适用
1	1	心形 (零点在 180°)、超心形 (零点约 $\pm 120^\circ$)、8 字形	约 4~6 dB (心形约 4.8 dB、超心形约 5.7 dB、8 字形约 4.8 dB)	基准 (已比 DSB 低)	敏感	TWS 通话、助听器
2	2	二阶心形/超心形组合, 旁瓣出现	约 6~9 dB	再掉约 6 dB	更严 (间距 + 增益双标定)	可穿戴近场拾音
3	3	三阶组合, 主瓣更窄、旁瓣更多	约 9~12 dB	裸用多半不可接受	严苛 (一般要配均衡)	实验室/配约束用
≥ 4	≥ 4	理论可继续变窄	理论值继续增加, 实际值受失配限制	很低 (需强约束)	通常不直接使用	理论对照

表中的 DI 与 WNG 是理想模型下的趋势。实测结果还受通道失配、阵元位置误差和混响影响。阶数应根据麦克风一致性、允许的 WNG 和标定能力确定，不能只按理想 DI 选择。

神经差分 (解析结构 + 学习参数)：可把 (g, τ) 、级联系数或阶数选择设为可学习参数，并保留可转向的高阶差分结构。解析结构限定基本指向特性，网络用训练数据估计真实佩戴和混响条件下的参数。这与 §5.9 的“学习参数或掩码，再由结构化波束形成器求解”属于同一类组合方法。

阶段小结 (DSB 与超指向)：在精确导向和空间白噪声模型下，DSB 达到最大 WNG；超指向针对弥散噪声提高 DI，但通常降低低频 WNG。后面的 MVDR 和稳健波束形成把这种指标权衡推广到估计得到的噪声协方差与导向误差。

5.4 最小方差无失真响应

最小方差无失真响应 (Minimum Variance Distortionless Response, 简称 MVDR) 在设计导向矢量上施加单位响应，同时最小化输出噪声功率。只有设计导向矢量与真实目标传递向量一致时，“无失真”才对真实目标成立。

$$\min_{\vec{w}} \vec{w}^H \mathbf{R}_{nn} \vec{w} \quad \text{s.t.} \quad \vec{w}^H \vec{a}(\theta_0) = 1。$$

符号： $\mathbf{R}_{nn}$ 是 $M \times M$ 噪声协方差矩阵。对角元表示各通道噪声功率，非对角元表示通道间相关性。它与 §4.2 的标量互相关函数 $R(\tau)$ 不同。

推导 (拉格朗日乘子法，四步，每步都有物理读法)：1. 把约束“定价”进目标：构造拉格朗日函数

$$L(\vec{w}, \lambda) = \vec{w}^H \mathbf{R}_{nn} \vec{w} + \lambda (\vec{w}^H \vec{a} - 1)$$

λ 是拉格朗日乘子 (标量)。原问题是“约束下求最小”，现在变成“无约束求 L 的最小”——违反约束的权重会被 L 惩罚；2. **求梯度令零**：复数向量求导用 Wirtinger 规则——把 $\vec{w}$ 和它的共轭 $\vec{w}^*$ 当成两个独立变量，对 $\vec{w}^*$ 求偏导：

$$\frac{\partial L}{\partial \vec{w}^*} = \mathbf{R}_{nn} \vec{w} + \lambda \vec{a} = \vec{0} \quad \Rightarrow \quad \vec{w} = -\lambda \mathbf{R}_{nn}^{-1} \vec{a}$$

物理读法：最优权重 = 经噪声协方差“白化”后的导向矢量，只差一个待定倍数——噪声大的方向被 $\mathbf{R}_{nn}^{-1}$ 自动压扁； 3. 用约束定倍数：把结果代回无失真约束 $\vec{w}^H \vec{a} = 1$ ：

$$-\lambda \vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a} = 1 \quad \Rightarrow \quad \lambda = -\frac{1}{\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}}$$

（协方差矩阵一般是半正定的；这里写普通逆矩阵，额外假定 $\mathbf{R}_{nn}$ 正定。若快拍不足或矩阵奇异，应加正则、使用降秩方法或在明确秩条件下用伪逆。正定时分母是正实数。）； 4. 代回第 2 步，负负得正：

$$\boxed{\vec{w}_{MVDR} = \frac{\mathbf{R}_{nn}^{-1} \vec{a}}{\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}}}。$$

(5-1)

（脚注：复约束 $\vec{w}^H \vec{a} = 1$ 等价于两个实约束（实部、虚部各一），完整拉格朗日写法需加共轭项 $\lambda(\vec{w}^H \vec{a} - 1) + \lambda^*(\vec{a}^H \vec{w} - 1)$ ；Wirtinger 求导下两种写法结果相同，上面用紧凑写法。）

此权重代回输出功率即得式(4-2)的 Capon 谱——同一优化器的两种读法（推导见 §4.5）。

推导关系：梯度条件给出 $\vec{w} \propto \mathbf{R}_{nn}^{-1} \vec{a}$ ，无失真约束再确定比例系数，使 $\vec{w}^H \vec{a} = 1$ 。因此 $\mathbf{R}_{nn}^{-1}$ 决定噪声抑制方向，分母负责目标响应归一化。LCMV (§5.5) 沿用同一二次型优化，只把一条约束推广为多条约束。

特例校准直觉：白噪声下 $\mathbf{R}_{nn} \propto \mathbf{I}$ ，MVDR 退化为 DSB；混有定向强干扰时自动在干扰方向挖零陷（图16 红线在 20° 的坑；注意图16 用 8 元阵、20° 干扰做演示，参数与下面算例 5-2 的 2 元阵、30° 干扰不同）。

算例 5-2：2 麦 MVDR 数值推导

题设：2 麦，间距 $d = \lambda/2$ ；目标方向 $\theta_0 = 0^\circ$ （正横）；干扰来自 $\theta_i = 30^\circ$ ，干扰噪声功率比 $\text{INR} = 10$ （干扰功率是各麦白噪功率的 10 倍）。求 MVDR 权重 $\vec{w}_{MVDR} = \frac{\mathbf{R}_{nn}^{-1} \vec{a}}{\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}}$ （式(5-1)的闭式解），并验证它的两个承诺。

第 1 步：写出两个导向矢量

- 目标方向： $\psi_0 = \pi \sin 0^\circ = 0$ ，所以 $\vec{a}_0 = [1, 1]^\top$ ；
- 干扰方向： $\psi_i = \pi \sin 30^\circ = \frac{\pi}{2}$ ，所以 $\vec{a}_i = [1, e^{-j\pi/2}]^\top = [1, -j]^\top$ （麦 2 比麦 1 相位落后 90°）。

第 2 步：构造噪声协方差矩阵 $\mathbf{R}_{nn}$

噪声模型 = 定向干扰 + 各麦独立白噪（功率归一化为 1）：

$$\mathbf{R}_{nn} = 10 \cdot \vec{a}_i \vec{a}_i^H + \mathbf{I}$$

先算外积 $\vec{a}_i \vec{a}_i^H = \begin{bmatrix} 1 \\ -j \end{bmatrix} [1, j] = \begin{bmatrix} 1 & j \\ -j & 1 \end{bmatrix}$ （注意 $(\vec{a}_i \vec{a}_i^H)_{12} = 1 \cdot (-j)^* = +j$ ），于是

$$\mathbf{R}_{nn} = \begin{bmatrix} 11 & 10j \\ -10j & 11 \end{bmatrix}$$

读法：对角元 11 = 干扰功率 10 + 白噪功率 1（每个麦收到的总噪声功率）；非对角元 $\pm 10j$ 记录着“两麦噪声高度相关、且相位差 90°”——干扰的方向信息就藏在这两个非对角元里，这是 MVDR 能挖出零陷的全部依据。

第 3 步：求逆 $\mathbf{R}_{nn}^{-1}$

2×2 矩阵求逆公式 $\begin{bmatrix} p & q \\ r & s \end{bmatrix}^{-1} = \frac{1}{ps - qr} \begin{bmatrix} s & -q \\ -r & p \end{bmatrix}$ 。行列式：

$$\det \mathbf{R}_{nn} = 11 \times 11 - (10j)(-10j) = 121 - 100 = 21$$

(注意 $(10j)(-10j) = -100j^2 = +100$ —— $j^2 = -1$ ，两个虚数相乘先得实数再参与加减。2×2 行列式对照：

$\det \begin{bmatrix} p & q \\ r & s \end{bmatrix} = ps - qr$ ，这里 $qr = (10j)(-10j) = +100$ ， $ps - qr = 121 - 100 = 21$ ；与算例 5-1 第 1 步的 $\det \mathbf{I} = 1 - 0.9836^2 = 0.0325$ 对照看：同样是 2×2 求逆，一个行列式 21（健康，条件数小），一个 0.0325（病态，逆矩阵元素冲到 30 量级）——行列式的量级就是求逆稳不稳的第一眼信号。）所以

$$\mathbf{R}_{nn}^{-1} = \frac{1}{21} \begin{bmatrix} 11 & -10j \\ 10j & 11 \end{bmatrix} \approx \begin{bmatrix} 0.5238 & -0.4762j \\ 0.4762j & 0.5238 \end{bmatrix}$$

第 4 步：算权重

$$\text{分子: } \mathbf{R}_{nn}^{-1} \vec{a}_0 = \frac{1}{21} \begin{bmatrix} 11 - 10j \\ 10j + 11 \end{bmatrix} \approx \begin{bmatrix} 0.5238 - 0.4762j \\ 0.5238 + 0.4762j \end{bmatrix};$$

$$\text{分母: } \vec{a}_0^H \mathbf{R}_{nn}^{-1} \vec{a}_0 = \frac{1}{21} [(11 - 10j) + (10j + 11)] = \frac{22}{21} \approx 1.0476 \text{ (正实数, 与 §5.4 推导第 3 步的论断一致);}$$

相除：

$$\vec{w}_{MVDR} = \frac{1}{22} \begin{bmatrix} 11 - 10j \\ 11 + 10j \end{bmatrix} = \begin{bmatrix} 0.5000 - 0.4545j \\ 0.5000 + 0.4545j \end{bmatrix}$$

观察：两个权重模长相同 (≈ 0.676)、虚部符号相反——不是 DSB 的 $[0.5, 0.5]$ 了，MVDR 悄悄给两路加上了反号的相位偏转，这就是零陷的来源。

第 5 步：验证两个承诺

$$\text{① 目标无失真: } \vec{w}^H \vec{a}_0 = (0.5 + 0.4545j) \cdot 1 + (0.5 - 0.4545j) \cdot 1 = 1 \checkmark \text{ (两个虚部恰好抵消);}$$

② 干扰方向零陷：

$$\vec{w}^H \vec{a}_i = (0.5 + \frac{5}{11}j) \cdot 1 + (0.5 - \frac{5}{11}j)(-j) = \frac{1}{22}(1 - j) \approx 0.0455 - 0.0455j$$

$|\vec{w}^H \vec{a}_i| = \frac{\sqrt{2}}{22} \approx 0.0643$ ，即 **-23.8 dB**。干扰被压到约 1/15.6 的幅度，输出功率 $10 \times 0.0643^2 \approx 0.041$ ，已远低于输出白噪声水平 ($\|\vec{w}\|^2 \approx 0.913$) ——干扰实际上被“淹没”掉了。

为什么不是精确的 0？ 2 个麦只有 2 个复数自由度：1 个被无失真约束占用，剩下 1 个压干扰，压的深度随干扰强度 (INR) 增长而加深 (本例 INR=10，残余约 -24 dB；INR 趋于无穷时趋于理想零陷)。关键在于：没人告诉 MVDR 干扰在 30° ——零陷是它从 $\mathbf{R}_{nn}$ 非对角元里自己“读”出来的，这正是自适应与手工设计的分界。


第 6 步：检查波束图的五个方向 ($|B(\theta)| = |\vec{w}^H \vec{a}(\theta)|$ ，完整曲线见图16)：

角度	增益 (dB)	含义
0°	0.00	无失真约束钉死
+30°	-23.84	零陷正对干扰
+15°	-5.05	过渡带，被连带压低
-30°	+2.61	无干扰一侧被抬高
+45°	-8.62	远旁瓣残余

读图：0° 钉死在 0 dB（约束），30° 处一个 -23.8 dB 的深坑（零陷），而波束图不再左右对称——干扰一侧（+θ）整体被压低，代价是无干扰一侧（-30° 附近）增益被抬高了 2.6 dB，那里若再来个新干扰就会漏进来。2 麦只有这点自由度，这已经是“保护目标”前提下数学上能做到的最好结果。

WNG 代价：这组权重的 $WNG = 10 \log_{10}(1/\|\vec{w}\|^2) = 10 \log_{10}(1/0.9133) \approx +0.39 \text{ dB}$ ，比同一双麦阵的 DSB 低约 2.6 dB。该差值与干扰抑制量都只对应本算例的 INR、几何和噪声模型。

图16 8元ULA 0°指向波束图对比：DSB / MVDR(零陷@20°) / 超指向 (f=2kHz, d=λ/2, c=343m/s, 上=0°正横, 模拟)



图示说明：0° 处的 0 dB 来自无失真约束；20° 处的零陷对应协方差模型中的定向干扰。图16使用 8 元阵和 20° 干扰，参数与算例 5-2 的 2 元阵、30° 干扰不同，不能把图中的零陷深度与手算结果直接比较。

实现中的三个问题： 1. $\mathbf{R}_{nn}$ 从哪来：无目标帧估计（语音活动检测即 VAD 辅助）；语音场景经典做法是时频掩码（Time-Frequency mask，简称 TF-mask）——神经网络预测每个时频点是语音还是噪声，分别加权估出目标/噪声协方差（在 CHiME 系列远场语音识别挑战赛中验证有效的主流做法；这类掩码做法在完整系统里的效果证据见 §8.1）； 2. **病态与对角加载：**小快拍下 $\hat{\mathbf{R}}$ 可能病态，可改用 $\hat{\mathbf{R}} + \epsilon \mathbf{I}$ 。它抬高小特征值并限制权重范数；与显式 WNG 约束的关系见下文，二者不能不加条件地写成同一个问题； 3. **混响中的约束对象：**自由场导向矢量只描述直达传播。混响房间中的目标通道还包含早期反射，因此实际目标传递向量可能与自由场模型不一致。可估计相对传递函数（Relative Transfer Function，简称 RTF），用各麦相对参考麦的目标传递函数作为约束向量；RTF 估计误差仍需通过失配仿真评估。

对角加载、WNG 约束与正则化的关系：把 $\hat{\mathbf{R}}$ 换成 $\hat{\mathbf{R}} + \epsilon \mathbf{I}$ ，等于在目标函数中加入 $\epsilon \|\vec{w}\|^2$ 。在无失真约束下，显式约束 $\|\vec{w}\|^2 \leq \delta$ 就是在设置 WNG 下限；若该约束在最优点处有效，其拉格朗日乘子会产生同形的对角加载。给

定 δ 对应的 ε 依赖 $\hat{\mathbf{R}}$ 、 $\vec{a}$ 和频点，不能把任意加载量与任意 WNG 门限视为相同。加载量应按协方差条件数、器件失配仿真和所需 WNG 扫描选择。

对角加载的代价表 (ε 从小到大):

ε 取值	相对平均特征值	白噪声增益	指向性/零陷深度	稳健性	适用场合
很小 ($\sim 10^{-3}$)	几乎不掺假	接近理论值	几乎无损	差: 小快拍下求逆仍可能病态	快拍充足、标定好的离线处理
中等 (由验证集确定)	小特征值被抬高	通常回升	通常变浅	对估计误差和轻微失配较稳	按 WNG 与目标失真联合调参
很大 (~ 1)	白噪占主导	趋近 DSB 上限	退化: 深零陷被抹平	过度保守: 接近固定波束	稳健模式或诊断对照

读法: ε 增大时, 条件数通常改善、权重范数减小, 零陷和指向性也可能减弱。变化多少由协方差特征值、导向矢量与加载归一化口径共同决定, 不能预先保证若干 dB。应画出 WNG、目标失真和噪声输出随归一化加载量的曲线, 再按系统预算选点。

5.4.1 稳健波束形成方法

对角加载主要限制协方差求逆的敏感度和权重范数, 不能覆盖所有失配来源。下面按四类误差分别说明可选方法、假设和代价:

- **A: 导向矢量失配:** DOA 误差、通道增益/相位不一致或阵列标定误差使约束向量偏离真实目标传递向量;
- **B: 协方差估计误差:** 快拍不足、噪声非平稳或目标泄漏使 $\hat{\mathbf{R}}_{nn}$ 偏离真实噪声协方差, 求逆会放大其中的小特征值误差;
- **C: 相干干扰或混响:** 早期反射与直达声相干, 可能降低信号子空间秩并改变零陷位置;
- **D: 目标自消:** 含目标的协方差与失配约束共同作用, 使自适应权重抑制真实目标。

方法 1: 最差情况优化 (Worst-Case Optimization)。若把真实导向矢量限制在球形不确定集 $\|\vec{a}_{true} - \vec{a}_0\| \leq \epsilon$ 中, 可要求集合内所有导向矢量都满足最低响应。对常见球形、范数有界模型, 其 KKT 条件常导出对角加载形式, 但加载量需由不确定集半径和数据共同求得; 任意固定加载并不等同于完整的鲁棒 Capon 问题。 ϵ 应由 DOA 误差和通道标定统计确定, 取大时会牺牲 DI 与零陷深度。

方法 2: 特征空间波束形成 (Eigenspace Beamforming)。对含目标的采样协方差做特征分解, 把权重投影到由主要特征向量张成的子空间中, 可减小小特征值估计误差造成的权重偏差。代价是必须选择子空间维数; 低信噪比或弱目标条件下, 信号与噪声特征值难以分开, 投影也可能删除有用成分。

方法 3: 协方差重构 (Covariance Reconstruction)。MVDR 需要干扰加噪声协方差, 但 VAD 选出的噪声段可能含目标残留和混响尾音。以 Capon 谱积分重构为例, 可在非目标角度区域估计空间谱, 再积分重建 $\hat{\mathbf{R}}_{nn}$ 。代价是增加谱估计与积分计算; 目标区域或积分区域设错时, 也会删除干扰信息或保留目标泄漏。

方法 4: 前后向空间平滑 (Forward-Backward Spatial Smoothing)。均匀线阵可切成重叠子阵, 先平均前向子阵协方差, 再加入共轭反转的后向项。该处理可恢复部分相干源条件下的协方差秩。代价是子阵长度小于原阵列, 因而有效孔径和剩余自由度下降; 子阵数量必须同时满足去相关与可分辨性要求。

方法选择表 (对角加载主要处理病态求逆和权重范数, 其他误差还需针对性处理):

现象	主要误差来源	首选	备选/联合	验证重点
DOA 偏 2~3° 目标就被吃	A 导向失配	最差情况优化 (ε 按 DOA 误差定)	导数约束 (LCMV, §5.5) 把主瓣做平	先看 DOA 模块的误差分布再定 ε
更换麦克风批次后结果变化明显	A 通道不一致	通道标定 + 最差情况优化	对角加载	用批次间标定残差设置不确定集
噪声段含目标, 自适应后目标衰减	D 目标自消	改善 VAD/SPP 与协方差估计	特征空间投影	同时报目标响应和噪声降低量
快拍少、噪声时变, 求逆病态	B 估计误差	对角加载 + 协方差重构	减少约束或降阶	扫描加载量、WNG 与目标失真
强早期反射或相干干扰造成零陷偏移	C 相干	适用阵列上的空间平滑	RTF 约束	检查子阵结构和剩余孔径
低频 WNG 很低、权重范数很大	超指向固有	WNG 约束/对角加载, 分频段设计	降阶 DMA	见算例 5-1 第 7 步

使用该表时, 应先用 §5.3 的四项诊断量确定主要误差来源, 再分别验证候选方法。每次改变稳健化参数, 都应重新测量 WNG、目标响应、噪声输出和任务指标。

阶段小结 (MVDR 与稳健化): MVDR 的闭式解依赖准确的协方差和约束向量。对角加载、最差情况优化、特征空间投影、协方差重构与空间平滑分别针对不同误差来源, 选择前应先确定失配模型。

5.5 线性约束最小方差 (Linearly Constrained Minimum Variance, 简称 LCMV): 多约束推广

多个线性约束写成矩阵形式 $\mathbf{C}^H \vec{w} = \vec{f}$ ($\mathbf{C}$: 约束矩阵, 每列是一个约束方向/约束向量; $\vec{f}$: 对应的约束值向量), LCMV 闭式解为:

$$\vec{w}_{LCMV} = \mathbf{R}^{-1} \mathbf{C} (\mathbf{C}^H \mathbf{R}^{-1} \mathbf{C})^{-1} \vec{f}.$$

(5-2)

($\mathbf{R}$ 可以是噪声协方差 $\mathbf{R}_{nn}$, 也可以是含目标的 $\mathbf{R}_{xx}$ ——小快拍下常用后者, 代价是目标自消风险, 见 §5.4 工程要点。)

推导: 与式(5-1)使用相同的拉格朗日乘法, 只是标量乘子 λ 改为向量 $\vec{\lambda}$ (每条约束对应一个分量)。构造 $L = \vec{w}^H \mathbf{R} \vec{w} + \vec{\lambda}^H (\mathbf{C}^H \vec{w} - \vec{f})$, 对 $\vec{w}^*$ 求导令零得 $\vec{w} = -\mathbf{R}^{-1} \mathbf{C} \vec{\lambda}$; 代入约束后解出 $\vec{\lambda} = -(\mathbf{C}^H \mathbf{R}^{-1} \mathbf{C})^{-1} \vec{f}$, 再代回得到式(5-2)。除 $M \times M$ 的 $\mathbf{R}$ 外, 还要对 $K_c \times K_c$ 的约束矩阵求逆。

维度核对: 约束有 K_c 条, $\vec{f}$ 和 $\vec{\lambda}$ 都是 $K_c \times 1$ 向量; $\mathbf{C}$ 是 $M \times K_c$, 所以 $\mathbf{C}^H \vec{w}$ 与 $\vec{f}$ 维度一致。矩阵 $\mathbf{C}^H \mathbf{R}^{-1} \mathbf{C}$ 为 $K_c \times K_c$ 。若 $\mathbf{C}$ 满列秩, K_c 条独立复线性约束把可调子空间的复维数从 M 降为 $M - K_c$; $K_c = M$ 时, 权重通常由约束唯一确定。

解的结构可以理解为“先白化、再钉约束”： $\mathbf{R}^{-1}$ 负责把干扰方向压扁，后半部分负责把权重精确钉在满足所有约束的子空间上。常用约束举例：①期望方向无失真 ($f = 1$)；②已知干扰方向强制零陷 ($\vec{a}^H(\theta_i)\vec{w} = 0$)；③**导数约束**——令波束图在期望方向处对角度的一阶导数为零，主瓣变得“平顶”，这样 DOA 估计有角度误差、或说话人稍微晃动时目标仍被保护，是抗指向误差的经典手段。

约束不是免费的：若 $\mathbf{C}$ 满列秩，数学上可有 $K_c \leq M$ 条独立约束。 $K_c = M$ 时权重通常被约束唯一确定，没有剩余自由度用于根据 $\mathbf{R}$ 压噪；若希望保留至少一个自适应自由度，则需 $K_c < M$ 。约束增多不必然使 WNG 单调恶化，但会缩小可行集合，必须逐频点检查 WNG 与目标响应。

算例 5-2 补充：LCMV 双约束

题设：沿用算例 5-2 的 2 麦阵 ($d = \lambda/2$, 目标 0° , 干扰 30°)，但这次干扰方向已知，要求同时满足两条约束：目标方向增益为 1、干扰方向增益为 0。约束矩阵 $\mathbf{C} = [\vec{a}_0, \vec{a}_i]$ (2×2)，约束值 $\vec{f} = [1, 0]^\top$ ，噪声取白噪 $\mathbf{R} = \mathbf{I}$ (先看约束本身的效果，不掺自适应)。

求解： $\mathbf{R} = \mathbf{I}$ 时 $\mathbf{C}^H \mathbf{R}^{-1} \mathbf{C} = \mathbf{C}^H \mathbf{C}$ 。 $\vec{a}_0 = [1, 1]^\top$, $\vec{a}_i = [1, -j]^\top$ ，得 $\mathbf{C}^H \mathbf{C} = \begin{bmatrix} 2 & 1-j \\ 1+j & 2 \end{bmatrix}$ ，行列式 $= 4 - |1-j|^2 = 2$ ，逆为 $\frac{1}{2} \begin{bmatrix} 2 & -(1-j) \\ -(1+j) & 2 \end{bmatrix}$ 。 $\vec{w} = \mathbf{C}(\mathbf{C}^H \mathbf{C})^{-1} \vec{f}$ 取逆矩阵第一列：
 $\vec{w} = \frac{1}{2}(2\vec{a}_0 - (1+j)\vec{a}_i)$ ，展开得 $\vec{w} = [0.5 - 0.5j, 0.5 + 0.5j]^\top$ 。

验证： $\vec{w}^H \vec{a}_0 = (0.5 + 0.5j) + (0.5 - 0.5j) = 1 \checkmark$ ； $\vec{w}^H \vec{a}_i = (0.5 + 0.5j) + (0.5 - 0.5j)(-j) = 0 \checkmark$ ——干扰方向被精确钉死在零点。代价： $\|\vec{w}\|^2 = 1$, WNG = 0 dB，比 DSB 的 +3 dB 低了 3 dB——2 个麦、2 条约束，自由度被约束吃光，一点压白噪的余地都没剩。对比算例 5-2 的 MVDR (WNG +0.39 dB、零陷 -23.8 dB)：MVDR 只约束目标、把干扰交给数据去压，零陷虽非理想零但 WNG 更好——这就是“硬约束零陷”与“自适应零陷”的区别：干扰方向已知且静止时 LCMV 更彻底；方向未知或干扰走动时 MVDR 更划算。

多通道维纳滤波 (Multichannel Wiener Filter, 简称 MWF) 直接在均方误差准则下权衡目标失真与残余噪声；MVDR 则施加硬的无失真约束，两者不能一般性地视为同一个解。语音失真加权多通道维纳滤波 (Speech Distortion Weighted MWF, 简称 SDW-MWF) 写成

$$J(\vec{w}) = E\{|n_{out}|^2\} + \frac{1}{\mu} E\{|s_{out} - s_{ref}|^2\} \Rightarrow \vec{w}_{SDW} = (\mathbf{R}_{ss} + \mu \mathbf{R}_{nn})^{-1} \mathbf{R}_{ss} \vec{e}_r$$

- $\mathbf{R}_{ss}, \mathbf{R}_{nn}$ ：目标与噪声协方差矩阵； $\vec{e}_r$ ：参考麦选择向量 (第 r 位为 1 的单位向量，即“以第 r 个麦收到的目标为基准”)；
- $\mu = 1$ 是普通 MWF； $\mu > 1$ 更重视噪声项，抑制增强而目标失真通常增大； $\mu < 1$ 更重视目标保真。令 $\mu \rightarrow \infty$ 时权重趋近零，并不趋近 MVDR。只有秩一目标模型 $\mathbf{R}_{ss} = \phi_s \vec{a} \vec{a}^H$ 且参考麦归一化 $a_r = 1$ 时，才有

$$\vec{w}_{SDW} = \frac{\phi_s q}{\mu + \phi_s q} \vec{w}_{MVDR}, \quad q = \vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}.$$

此时 SDW-MWF 是 MVDR 输出再乘一个标量 Wiener 增益，并在 $\mu \rightarrow 0^+$ 时趋近 MVDR。目标协方差满秩时没有这个简单关系。Doclo, Spriet, Wouters & Moonen, *Speech Communication*, vol.49, p.636, 2007

LCMV 上面都是频域闭式写法，落到时域在线实现就是 Frost——下面把它的更新式和 GSC 的对照一次收拢在本节末，免得前后翻。

Frost 波束形成器 (1972)：LCMV 的时域在线版。§5.1 末提过它是滤波求和的自适应代表，这里把更新式写出来：每路麦接一段 J 抽头 FIR，第 m 路第 j 抽头权重记 $w_{m,j}$ ，全权重向量 $\vec{w}$ 共 MJ 个系数。约束是“看目标方向”的线性约束 $\mathbf{C}^H \vec{w} = \vec{f}$ （比如每列约束钉住一个抽头时刻的目标响应），更新分两步走：

$$\vec{w}(l+1) = \mathbf{P}[\vec{w}(l) - \mu \vec{x}(l)y^*(l)] + \vec{w}_q。$$

方括号中是复数 LMS 的瞬时负梯度步：对 $|y(l)|^2$ 求导得到与 $\vec{x}(l)y^*(l)$ 同向的梯度。投影矩阵 $\mathbf{P} = \mathbf{I} - \mathbf{C}(\mathbf{C}^H \mathbf{C})^{-1} \mathbf{C}^H$ 把更新限制在约束零空间， $\vec{w}_q = \mathbf{C}(\mathbf{C}^H \mathbf{C})^{-1} \vec{f}$ 是满足约束的最小范数特解。约束模型匹配时，更新不改变受约束的目标响应；指向或传递函数失配时，真实目标仍可能失真。步长太大会发散，太小则跟不上非平稳干扰。

Frost vs GSC 对照表（同一个 LCMV，两种穿法）：


	Frost (1972)	GSC
域	时域 FIR 抽头	频域逐频点 (TF-GSC) 或时域皆可
约束怎么装	投影矩阵 $\mathbf{P}$ ，每步拽回约束平面	结构吸收：固定上支路 + 阻塞矩阵，下支路无约束自适应
自适应算法	LMS (含投影)	NLMS/RLS
跟踪非平稳干扰	中 (LMS 收敛慢)	快 (下支路纯噪声参考，对消直接)
失配症状	目标泄漏进 LMS，实际目标不再满足设计约束	目标泄漏进阻塞矩阵下支路，被当作干扰对消
延迟	低 (时域直接出样点)	频域版有 STFT 帧延迟
约束实现	每次更新后投影回约束子空间	固定支路与阻塞矩阵从结构上满足约束

Frost 用投影更新实现时域 LCMV；下一节的 GSC 用固定支路和阻塞矩阵实现同一类约束。

5.6 广义旁瓣对消器 (Generalized Sidelobe Canceller, 简称 GSC)：把约束改装成“噪声对消器”

广义旁瓣对消器把 LCMV 约束吸收进结构，分两条支路：

图17 GSC（广义旁瓣对消器）结构框图



图示说明：上支路固定波束形成器输出目标与残留噪声 d ；下支路的阻塞矩阵在模型匹配时消除目标，得到噪声参考 u ；自适应滤波器由 u 估计上支路残留干扰 y ，最后相减得到 $e = d - y$ 。数值过程见算例 5-3。

- 上支路：延迟求和（固定波束），输出 $d = \text{目标} + \text{漏入噪声}$ ；
- 下支路：阻塞矩阵 $\mathbf{B}$ （满足 $\mathbf{B}^H \vec{a}(\theta_0) = \vec{0}$ ，把目标方向陷掉）→ 纯噪声参考 → 多通道自适应滤波（NLMS/RLS）学出噪声副本 y ；
- 相减 $e = d - y$ ：噪声对消、目标无损。

算例 5-3：GSC 数字走一遍——干扰是怎么被“减掉”的（对应脚本 `scripts/make_figures.py::fig_gsc`，改步长可看收敛过程）

题设：2 麦， $d = \lambda/2$ ；目标 0° （正横），干扰 60° 。按 §5.6 的 GSC 结构逐数走一遍：上支路延迟求和，下支路阻塞矩阵 $\mathbf{B} = [1, -1]^\top$ （2×1，两路相减——这是 2 麦特例； M 麦时 $\mathbf{B}$ 为 $M \times (M-1)$ ，常用相邻通道相减或取 $\vec{a}(\theta_0)$ 的正交补基），自适应滤波器退化为 1 个复数抽头 h （2 麦时阻塞后只剩 1 路噪声参考，滤波器只需 1 个系数）。

预备数字： $\psi_{60} = \pi \sin 60^\circ = 2.7207 \text{ rad}$ （155.9°）， $\vec{a}(0^\circ) = [1, 1]^\top$ ， $\vec{a}(60^\circ) = [1, e^{-j2.7207}]^\top = [1, -0.9127 - 0.4086j]^\top$ 。

第 1 步：上支路（延迟求和）漏进多少干扰

上支路权重 $\vec{w}_u = [0.5, 0.5]^\top$ 。目标方向增益 $\vec{w}_u^H \vec{a}(0^\circ) = 1 \checkmark$ （无失真）； 60° 方向的泄漏增益：

$$g_u = \vec{w}_u^H \vec{a}(60^\circ) = \frac{1}{2} (1 + e^{-j2.7207}) = 0.0436 - 0.2043j, \quad |g_u| = |\cos \frac{\psi}{2}| = 0.2089 \text{ } (-13.6 \text{ dB})$$

干扰在目标支路里还残留约 21% 的幅度——这就是图17 中“ $d = \text{目标} + \text{漏入噪声}$ ”里那部分“漏入噪声”。

第 2 步：下支路把目标陷掉、只留干扰

验证阻塞： $\mathbf{B}^H \vec{a}(0^\circ) = 1 \times 1 + (-1) \times 1 = 0$ ✓——目标方向被精确陷掉，下支路里**没有目标**（这是整个结构的关键前提，§5.6 说的“阻塞矩阵失配”就是指这个 0 在实际中保不住）。干扰在下支路的增益：

$$g_\ell = \mathbf{B}^H \vec{a}(60^\circ) = 1 - e^{-j2.7207} = 1.9127 + 0.4086j, \quad |g_\ell| = 2 \left| \sin \frac{\psi}{2} \right| = 1.9559$$

两路相减反而把干扰放大了近 2 倍（因为 60° 方向上两麦相位差 155.9° ，接近反相，相减近乎同相叠加）——没关系，它只是一份“干扰参考样本”。

第 3 步：拿一个具体快拍走一遍

设该频点目标谱 $s = 1$ 、干扰谱 $i = 1$ （都是标量复数），则阵列快拍：

$$\vec{x} = \vec{a}(0^\circ) \cdot 1 + \vec{a}(60^\circ) \cdot 1 = \begin{bmatrix} 2.0000 \\ 0.0873 - 0.4086j \end{bmatrix}$$

$$\text{上支路输出: } d = \vec{w}_u^H \vec{x} = \frac{2.0000 + 0.0873 - 0.4086j}{2} = 1.0436 - 0.2043j = \underbrace{1}_s + \underbrace{(0.0436 - 0.2043j)}_{g_u i};$$

（花括号下第二项即泄漏项 $g_u \cdot i$ 。）

下支路输出： $u = \mathbf{B}^H \vec{x} = 2.0000 - (0.0873 - 0.4086j) = 1.9127 + 0.4086j$ （ $= g_\ell \cdot i$ ，纯干扰，目标分量为 0）。

第 4 步：自适应滤波器学出的那个系数

对消器要减掉的正是泄漏项 $g_u \cdot i$ ，而它手里只有 $u = g_\ell \cdot i$ ，所以最优系数：

$$h^* = \frac{g_u}{g_\ell} = -0.1068j, \quad h = +0.1068j$$

（一个纯虚数——恰好把下支路的干扰副本旋转 -90° 再缩到 0.107 倍，补成上支路泄漏项的模样。）验证：

$$h^* \cdot u = -0.1068j \times (1.9127 + 0.4086j) = 0.0436 - 0.2043j。$$

（与泄漏项分毫不差。）

$$e = d - h^* u = (1.0436 - 0.2043j) - (0.0436 - 0.2043j) = 1.0000 = s \quad \checkmark$$

输出只剩目标。把干扰换成 $i = 0.5j$ 、 -2 、 $0.3 + 0.7j$ 再算， e 都恒等于 1——对消效果与干扰强度无关，这正是“对消”优于“压制”的地方。

第 5 步： h 不是算出来的，是“学”出来的

实际系统不知道 g_u 、 g_ℓ 。按 $e = d - h^* u$ 的复数约定，NLMS 更新应写成 $h \leftarrow h + \mu u e^* / (|u|^2 + \varepsilon)$ 。若阻塞支路中只有与目标不相关的干扰，这个更新会学习上支路中与 u 相关的分量。本例的收敛目标是 $h = +0.1068j$ ，等价的直接乘子 h^* 为 $-0.1068j$ ；具体稳定步长和收敛帧数取决于输入统计，不能由这一帧手算固定。

第 6 步：看一眼这个结构的命门

上述对消依赖 $\mathbf{B}^H \vec{a}(0^\circ) = 0$ 。若目标实际方向偏到 2° ，则 $\mathbf{B}^H \vec{a}(2^\circ) = 1 - e^{-j\pi \sin 2^\circ} \approx +0.1096j$ ，约 1.2% 的目标功率泄漏进下支路。自适应滤波器会把泄漏目标的一部分当作干扰抵消，造成语音衰减或断续。可使用自适应阻塞矩阵（ABM）和语音存在门控降低这一风险。

优点：约束由固定支路与阻塞矩阵实现，下支路可用 LMS 等无约束自适应算法。**主要边界——阻塞矩阵失配：**目标因 DOA 误差或混响泄漏进下支路时，会被当作噪声对消。可使用自适应阻塞（ABM）、语音存在概率门控步长和泄漏均衡（CA-GSC）。

一个值得知道的定理：GSC 与 LCMV 在数学上完全等价（Breed & Strauss 2002 的简短证明，A short proof of the equivalence of LCMV and GSC beamforming, *IEEE Signal Process. Lett.*, vol.9, pp.168–169）——GSC 并没有产生新东西，它只是把 LCMV 的“带约束求解”改写成“固定支路 + 无约束自适应滤波”的结构。等价的意义是双向的：GSC 的所有性能边界可以用 LCMV 理论分析，而 LCMV 的所有约束都继承为 GSC 的结构设计问题（阻塞矩阵的好坏就是约束的好坏）。Breed & Strauss, *IEEE SPL* 2002

阶段小结（LCMV、Frost 与 GSC）：LCMV 把 MVDR 的单约束推广为多约束；Frost 用投影更新实现时域 LCMV；GSC 用固定支路和阻塞矩阵实现相同约束。三者都受约束失配影响，GSC 还要单独检查目标向下支路的泄漏。

5.7 后置滤波

空间上能挖的都挖完了，剩下弥散残留只能靠时频点上的统计压制——这就是后置滤波的位置。后置滤波分三步：SPP 估计噪声底（§5.7.1）、Wiener 增益（§5.7.2）、音乐噪声代价（§5.7.3）。

波束输出通常仍含残留混响与弥散噪声，可再级联单通道增强器。基本过程是在波束输出上估计残留噪声谱，再按每个时频点的信噪比计算增益。不同方法的主要区别在于噪声谱估计方式：

- **Zelinski (1988)：**先按目标方向做时延/相位对齐，并通常把各通道目标传递幅度归一化；随后假设对齐后的目标在各麦间同相同幅、噪声互不相关，用“各麦自谱平均 - 互谱实部平均”估计噪声功率谱：

$$\hat{\Phi}_{nn}(k) = \frac{1}{M} \sum_{i=1}^M \Phi_{x_i x_i}(k) - \frac{2}{M(M-1)} \sum_{i < j} \text{Re}\{\Phi_{x_i x_j}(k)\}.$$

（式中 Φ 均为功率谱： $\Phi_{x_i x_i}$ 为自功率谱， $\Phi_{x_i x_j}$ 为互功率谱。）若没有先对齐，目标互谱带有传播相位，其实部不再等于目标功率，公式会把目标的一部分误判为噪声。即使已对齐，噪声相关或通道目标幅度不同也会造成偏差；

- **McCowan (2003) 的改进：**Zelinski 的“各麦噪声互不相关”假设在混响场里不成立——弥散噪声在相邻麦上其实高度相干，直接相减会把噪声功率谱估小甚至估负。McCowan 改用弥散噪声场的**已知相干**（sinc 形的 $\mathbf{\Gamma}$ ，§5.1）替代“互不相干”假设，把互谱项按其理论相干折算后再减，把混响场里失效的噪声估计救了回来（偏差量级见本节算例 5-3 补，约 0.3）；
- **LMA/OM-LSA：**用对数谱的最小均方误差准则加语音存在概率（每个时频点“这里有没有语音”的概率，来自语音活动检测器即 VAD 类估计）。

5.7.1 语音存在概率 SPP：每个时频点的“有人吗”

SPP（Speech Presence Probability，语音存在概率）记为 $p(k, n) \in [0, 1]$ ，表示第 k 个频点、第 n 帧含语音的后验概率。它不同于 VAD 的帧级 0/1 判决，可用于在语音保留与噪声更新之间连续加权。

MCRA (Minima-Controlled Recursive Averaging, 最小值控制递归平均, Cohen): 算法在每个频点跟踪一段时间内的平滑功率最小值, 并根据当前功率相对该最小值的偏离估计 SPP。SPP 较低时更新噪声谱, SPP 较高时减慢或冻结更新, 以减少语音泄漏对噪声估计的污染。IMCRA 进一步改进了最小值跟踪和概率估计; 具体窗口与门限应按所用文献版本实现。

对前级自适应模块的门控: GSC 可把 NLMS 步长乘以 $(1 - p)$, 在语音存在概率高时减慢更新; MVDR 也可主要使用低 SPP 时频点更新噪声协方差。这些门控都依赖 SPP 的校准质量, 错误的高概率会降低跟踪速度, 错误的低概率会增加目标泄漏。

5.7.2 Wiener 后滤通用式: SPP 加权与 MWF 级联

上面 Zelinski/McCowan 都是"先估噪声谱、再按信噪比打折", 统一写成 Wiener 通用式:

$$G(k, n) = \max\left(1 - \frac{\hat{\Phi}_{nn}(k, n)}{\Phi_{yy}(k, n)}, G_{\min}\right), \quad \hat{S} = G \cdot Y。$$

Y 是波束输出, Φ_{yy} 是其功率谱, $\hat{\Phi}_{nn}$ 是估计的残留噪声谱, $G_{\min}$ 是最小允许增益, 也称增益地板。它限制最大衰减量, 以减轻谱估计误差造成的音乐噪声; 取值应按听感、目标失真和残留噪声共同确定。SPP 可用于条件更新噪声谱, 也可连续调节增益。OM-LSA (Optimally-Modified Log-Spectral Amplitude, 最优修正对数谱幅度估计) 是在对数谱幅度 MMSE 准则下结合语音存在不确定性的一类方法。

与 MWF 的关系: MWF (§5.5 末) 在一个均方误差目标中联合权衡残留噪声和目标失真。MVDR 与单通道 Wiener 后滤级联时, 前级施加空间无失真约束, 后级再按时频统计抑制残留噪声; 两级的估计误差和延迟会累加。两种结构没有无条件的优劣, 应在同一目标参考、延迟预算和任务指标下比较。

5.7.3 音乐噪声与三个调节参数

音乐噪声表现为随时间和频率随机出现的窄带音调成分。主要原因是噪声谱估计误差使相邻时频点的增益变化不连续, 以及 $G_{\min}$ 过低导致被强衰减点与残留点之间反差过大。

trade-off 三个旋钮: ① $G_{\min}$ 抬高 ($-20\text{ dB} \rightarrow -12\text{ dB}$): 音乐噪声立刻轻, 但残留噪声底上来——降噪量与音乐噪声直接换比; ② 增益平滑 (帧间/频间递归平均): 碎音连成片就不刺耳, 代价是语音起止沿被抹圆一点 (语头语尾软); ③ 过减因子 (式中 $1 - \alpha\hat{\Phi}_{nn}/\Phi_{yy}$, $\alpha > 1$ 故意多估一点噪声): 压得更干净但目标也被连带削 (发闷), α 一般 1~2 之间试, 经验值、场景相关。调参顺序: 先定 $G_{\min}$ 保听感下限, 再开平滑, 最后动 α ——三个旋钮一次只拧一个, 边听边看谱。

算例 5-3补: 后置滤波小算例——“残留噪声谱估计 + 逐点打折”

题设: 3 麦已按目标对齐。某频点三路输入功率谱都是 $\Phi_{xx} = 4$ (目标功率 3、噪声功率 1), 两两噪声互谱实部为 $+0.3$, 所以总互谱实部为 3.3。用 Zelinski 式估噪声谱, 再算维纳型后置增益。

第 1 步 (估噪声谱): 自谱平均为 4, 互谱实部平均为 3.3, 因此 $\hat{\Phi}_{nn} = 4 - 3.3 = 0.7$ 。真实噪声功率是 1, Zelinski 低估了 0.3: 正相关噪声被误当成相干目标。若噪声互不相关, 互谱实部为 3.0, 估计才等于 1.0; 若噪声相关实部为负, 偏差方向会相反。

第 2 步 (算增益): 若波束输出功率谱取 4, 则 $G = 1 - 0.7/4 = 0.825$ 。同一个实数增益会把该时频点的目标和噪声功率都乘以 G^2 , 所以单个时频点的 SNR 不变。整段信号的 SNR 改善来自不同点使用不同增益: 语音缺席、噪

声占优的点应压得更多。具体改善量取决于语音存在率、谱估计偏差、增益平滑和评价区间，不能由这个单点例子推出固定的 dB 数。

为什么放在最后、且通常只改幅度：波束形成先利用空间信息，后置滤波再按时频统计压制残留噪声。实数非负增益保留波束输出相位，但仍会改变目标幅度；降噪量与目标失真必须在同一测试集、同一参考信号和同一统计区间内同时报告，不能脱离条件承诺固定 dB 收益。现代系统也会用 DNN 降噪或去混响模块替代解析后置滤波；例如 DeepFilterNet 结合 ERB（等效矩形带宽）粗包络与深滤波，具体算力、延迟与收益应以对应模型和硬件实测为准。

5.8 球谐域波束形成（球阵专属）

球阵把声场分解为球谐系数：

$$p(k, \Omega) = \sum_{n=0}^N \sum_{m=-n}^n b_n(kr) Y_n^m(\Omega) \varphi_{nm}(k)$$

逐个符号（式中已省略与方向无关的常数因子）： $p(k, \Omega)$ 是波数 k ($k = 2\pi f/c$ ，就是“频率”的另一种写法)、方向 Ω 处的声压； $Y_n^m(\Omega)$ 是**球谐函数**——球面上的“正弦和余弦”：阶数 n 相当于空间频率（ n 越大，花纹在球面上变化越快），同一阶内 $2n + 1$ 个不同的 m 对应不同朝向的花纹（式中省略的只是全局增益常数，不影响方向，只影响整体响度）。傅里叶基注：时间信号用 $e^{j\omega t}$ 做基展开成频谱，球面声场就用 $Y_n^m(\Omega)$ 做基展开成球谐谱——式中求和 $\sum_{n,m}(\cdot)Y_n^m(\Omega)\varphi_{nm}$ 与傅里叶级数 $\sum_k(\cdot)e^{j\omega k t}X_k$ 是同一个模子，前者基函数住在球面上、后者住在时间轴上； $b_n(kr)$ 是径向项，描述半径 r 的球面麦克风阵列对各阶成分的采样响应（刚性球与开放球形式不同）； $\varphi_{nm}(k)$ 是**球谐系数**——声场在第 (n, m) 个空间模式上的含量，地位完全类比傅里叶系数之于时间信号。

SHD 域波束形成具有**旋转不变性**（波束形状与转向无关），支持高阶立体声（Higher-Order Ambisonics，简称 HOA）录音、最大 DI 波束、相位模式超指向。约束：球谐阶数 N 受麦数限制 ($M \geq (N + 1)^2$)，高阶重建对噪声病态（需特征波束正则化）。课程讲义引用的研究称小球阵可接近大线阵的识别性能。[Kumatani et al. (出处同 §5.2 引文)]

圆阵的二维对应：相位模式（phase-mode / 圆谐波）处理。智能音箱的圆阵用同一思想的二维版：圆环上的声场做方位角傅里叶分解（Jacobi–Anger 展开），各阶“圆谐波”系数经模态补偿（除以贝塞尔函数 $J_n(kr)$ ）后，可合成与**频率无关、可电子旋转**的固定形状波束（特征波束）。代价与球阵同族：模态阶数受麦数限制，低频段 $J_n(kr) \rightarrow 0$ 使补偿病态——又是 WNG–DI 权衡的一次现身。同心多环圆阵（Concentric Circular Microphone Array，同心圆麦克风阵列，简称 CCMA）可扩展带宽与俯仰控制（Huang, Chen & Benesty, *Insights into Frequency-Invariant Beamforming with Concentric Circular Microphone Arrays*, IEEE/ACM TASLP, vol.26, no.12, pp.2305–2318, DOI [10.1109/TASLP.2018.2862826](https://doi.org/10.1109/TASLP.2018.2862826)）。

球谐域实现步骤：

- 设备选型：**先定最高工作频率 $f_{\max}$ 与球半径 r ，算 $kr = 2\pi f_{\max} r/c$ ；麦数 M 决定最高可用阶数 ($M \geq (N + 1)^2$ ，如 32 麦对应 $N \leq 4$)。刚性球（实心球，带散射）低频响应好、径向项无深零点，优先选；开放球（空架子）便宜但某些频率 $b_n(kr)$ 过零、该阶直接失效；
- 定阶数：** $N \approx kr$ （经验截断：高于 kr 的阶成分幅度衰减快，硬做高阶等于放大噪声）。如 $r = 4.2$ cm、 $f = 4$ kHz， $kr \approx 3.1$ ，取 $N = 3$ （需至少 16 麦）；低频段 $kr < 1$ 时只用 $N = 1$ ，别贪高；
- 径向补偿：**球谐系数 φ_{nm} 要从麦克风声压反推，需除以径向项 $b_n(kr)$ ——低频段 b_n 很小（尤其开放球），除法等于放大噪声。实操一律加限幅： $|b_n|$ 低于阈值按阈值算，或等效成白噪声增益约束；

4. **正则化**：高阶模态统一加特征波束正则（Eigen-beamforming 正则化：对角加载的球谐版），以指向性换稳健——与 §5.4 的对角加载同一笔账；
5. **代码入口**：先用解析球谐变换把阵列信号转成 $\varphi_{nm}(k)$ ，之后所有波束（最大指向性、超指向、MVDR）都在系数域用闭式解一次算出；转向只需旋转系数（Wigner-D 矩阵乘法），不用重算权重——“旋转不变性”在代码里就是这一个矩阵乘法。

5.9 深度神经网络（Deep Neural Network，简称 DNN）波束形成

1. **掩码估计 + 解析波束形成**：DNN 逐时频点（Time-Frequency bin，简称 TF-bin）估计目标和噪声掩码，据此重构协方差，再用解析式求权重。MVDR（式(5-1)）施加无失真约束；广义特征值（Generalized Eigenvalue，简称 GEV）波束形成器求解 $\mathbf{R}_{ss}\vec{w} = \lambda \mathbf{R}_{nn}\vec{w}$ 的最大广义特征向量，以最大化输出 SNR。GEV 没有无失真约束，权重还存在任意尺度，因此通常需要归一化或后处理。相关系统见 [IEEE JSTSP 2019](#)。
2. **端到端滤波网络**：直接回归复数滤波器权重或时域卷积核，可与语音识别（Automatic Speech Recognition，简称 ASR）损失联合训练（全神经波束形成路线），抑制能力较强，但失去显式约束、跨阵列泛化能力较弱。（Gu et al., IEEE/ACM TASLP, vol.31, pp.849–862, DOI [10.1109/TASLP.2022.3229261](#), 预印本 [arXiv:2212.08348](#)）
3. **联合一体化**：定位、波束形成与分离可在同一系统中联合训练，例如 ESPnet 中的相关参考实现。评估时应固定数据、后端识别器和评分脚本，并同时报告前端信号指标与词错误率（Word Error Rate，简称 WER）。
4. **TF-GridNet 的多通道用法**：TF-GridNet 交替建模帧内频谱、子带时间序列和全频带时间序列。用于多通道前端时，可堆叠多通道谱作为输入，由网络输出目标掩码，再按第 1 条重构协方差并求 MVDR 或 GEV 权重。具体实现见 §13.3 对应条目。
5. **TF-Locoformer**：这类模型用局部与全局注意力建模时频上下文，可作为掩码估计器，后接 MVDR 或 GEV 解析求解。相较循环结构，其参数量、算力和长时依赖建模能力应按具体实现与硬件实测比较。
6. **EaBNet**：EaBNet（Embedding and Beamforming Network，嵌入与波束形成网络）先学习多通道嵌入，再在嵌入空间估计波束式加权。它保留加权结构，但不把权重完全限制为 MVDR 或 GEV 闭式，位于“掩码估计 + 解析求解”和直接端到端滤波之间。

5.10 波束形成算法总对比

算法	主要噪声或干扰	抗混响	稳健性	失真	计算量	方法定位
DSB	白噪	★	理想模型下 WNG 最高	导向匹配时无失真	极低	基准/固定上支路
超指向	弥散噪	★★★★	最差(低频)	小(失配时大)	低	必须加 WNG 正则
DMA(差分)	弥散噪	★★	差	小	极低	微型设备
MVDR(导向)	白噪+定向干扰	★★★★	取决于加载与估计	导向匹配时无失真	中	需估噪声协方差
MVDR(RTF)	含早期反射	★★★★★	好	小	中	CHiME 级
LCMV	多约束	★★★★	取决于约束与失配	约束匹配时可控	中	干扰方向已知
GSC/TF-GSC	非平稳干扰	★★★★	中	阻塞失配时失真	中	自适应快

算法	主要噪声或干扰	抗混响	稳健性	失真	计算量	方法定位
MWF	统计最优	★★★	中	有	中	常与 MVDR 结合
掩码+MVDR	训练数据覆盖的空间模式	★★★★★	取决于掩码与解析求解	导向匹配时小	大	学习协方差估计，解析求权重
端到端	训练数据覆盖的空间模式	★★★★★	依赖训练分布	不可保证	大	直接学习滤波器或输出

表注：“主要噪声或干扰”指方法设计时采用的主要统计模型；“稳健性”综合导向失配、协方差估计误差、训练分布偏移和 WNG，不能只用其中一项替代。

贯穿全章的约束：在单位幅度导向矢量和精确无失真约束下，WNG 不超过 M （dB 表示为 $10\log_{10} M$ ）。DI 同时受阵列几何、频率、噪声场模型和 WNG 预算限制。紧凑阵列在理想各向同性弥散场、端射超指向的渐近模型下可出现 M^2 的指向因数上限，但实现该极限通常伴随很低的 WNG；它不是任意孔径、频率和方向都成立的通用保证。

上表“目标失真”列若要量化，必须先固定基线。以参考麦选择向量 $\vec{e}_r$ 为基线，噪声降低量定义为

$$\text{NR}_{ref} = 10\log_{10} \frac{\vec{e}_r^H \mathbf{R}_{nn} \vec{e}_r}{\vec{w}^H \mathbf{R}_{nn} \vec{w}}。$$

分子、分母要用同一频带和统计窗口。若以 DSB 为基线，就把分子换成 DSB 的输出噪声功率并明确标注。存在导向失配时，只报 NR 会掩盖目标衰减，还应同时报告 $|\vec{w}^H \vec{a}_{true} - 1|$ ，或报告相对同一参考麦的输出 SNR 改善。

专栏 5-D · Kumatani 精读指引（CMU 课程讲义 DASR 线，约 800 字导读）

从 LCMV 一节搬到这里，因为它讲的从来不是某一个算法，而是横跨全章的对照视角：本章 §5.2、§5.3、§5.8 里三处"课程讲义口径"的出处都是同一份讲义 [Kumatani et al.（出处同 §5.2 引文）]（CMU 远场语音识别课程讲义，讲的是球阵/圆阵上的波束形成与识别实验）。读它之前先摆正预期：它不是一篇期刊论文，而是一份"把几个关键算法串起来、落到识别率上"的讲义，所以公式密度低、结论多——精读目标是摸清三件事。

第一，GEV 与 MVDR 的约束差异。GEV 最大化输出信噪比，没有无失真约束，输出尺度由后续归一化确定；MVDR 对设计导向矢量施加单位响应。阅读讲义的对比表时，应同时记录噪声抑制、目标失真、归一化方法和最终识别率，不能只比较单一分数。

第二，特征波束（eigen-beam）的结构。球谐或圆谐波域中的各阶模态可分别正则化。高阶模态通常提供更细的空间变化，也更容易放大噪声；应按 WNG 预算限制其增益。该处理与阵元域对角加载都用于限制病态逆问题，但作用矩阵和参数口径不同。

第三，与识别联合的评估视角。讲义同时报告前端波束形成和后端词错误率（WER）。前端 SNR 改善不能保证 WER 同步改善，因为目标失真、相位变化和谱空洞也会影响识别器。复现实验时应在固定后端、数据划分和评分脚本下同时报告信号指标与任务指标。

这份讲义适合作为阵列算法与远场语音识别评估之间的补充材料；公式与适用条件仍应回到本章相应小节及原始论文核对。

本章小结：DSB 提供固定波束基线；超指向在弥散场 DI 与 WNG 之间权衡；MVDR、LCMV、Frost 和 GSC 用不同形式实现协方差驱动的约束优化；后滤波处理残留噪声；球谐域方法适用于球阵；神经网络可估计掩码、协方差或滤波器。选型时应同时报告目标响应、WNG、噪声降低量、延迟和任务指标。

5.11 本章练习

1. DSB 增益与 WNG 上限：4 麦均匀线阵、DSB 指向目标，白噪声增益是多少 dB？再用柯西–施瓦茨不等式说明：任何满足无失真约束 ($\vec{w}^H \vec{a} = 1$) 的权重，WNG 都超不过这个数。（参考答案：WNG = $10 \log_{10} 4 \approx 6$ dB； $1 = |\vec{w}^H \vec{a}| \leq \|\vec{w}\| \|\vec{a}\| = \|\vec{w}\| \sqrt{4}$ ，故 $1/\|\vec{w}\|^2 \leq 4$ ——等号在 $\vec{w} \propto \vec{a}$ 即 DSB 时成立，完整两步见 §5.2 的上限推导。）
2. GSC 阻塞失配：沿用算例 5–3 的 2 麦阵，若目标实际偏到 2° （DOA 估计差 2° ），下支路会漏进多少目标功率？自适应对消器会如何处理这部分泄漏，输出会出现什么变化？（参考答案： $\mathbf{B}^H \vec{a}(2^\circ) \approx 0.1096j$ ，漏进约 1.2% 的目标功率（见算例第 6 步）；下支路的目标与上支路相关，对消器会把它也当干扰抵消，导致目标语音衰减或断续。对策见 §5.6 末。）

第 6 章 · 声学回声消除 (AEC)

第 4、5 章和第 9 章讨论声源方向、波束和轨迹。本章转向设备播放声返回麦克风所形成的回声。混响拖尾和多说话人混合分别见第 7、8 章。

6.1 AEC 的模型、算法与实现

问题：音箱放音乐时，扬声器的声音经房间反射回到自己的麦克风。回声相对近端语音的强弱取决于播放音量、距离、房间和器件耦合；当回声占优时，唤醒和通话都会受到影响。

回声有一个可利用的条件：设备保存着播放信号 $x(n)$ 。未知的是播放信号经过扬声器、房间和麦克风之后形成的回声路径。本节先建立线性近似，再讨论非线性、双讲、残余抑制以及它与波束形成的顺序。

线性模型与自适应滤波 (§6.1.1~§6.1.3)

6.1.1 回声从哪来：系统模型与四种场景

信号模型。先把播放链路近似成有限长、线性、时不变系统。麦克风录到的信号可以写成三项之和：

$$d(n) = s(n) + x(n) * h(n) + v(n)$$

其中， $d(n)$ 是第 n 个采样时刻的麦克风样本； $s(n)$ 是需要保留的近端语音； $x(n)$ 是设备保存的远端播放参考； $h(n)$ 是线性回声路径的冲激响应； $v(n)$ 是环境噪声， $*$ 表示卷积。AEC 要估计并减去 $x * h$ ，同时尽量保留 s 。

这个模型不是完整的扬声器—房间—麦克风模型。它只覆盖参考抽头之后、在分析时间内可近似为线性且缓慢变化的部分。扬声器削顶、功放压缩和结构振动不能由单个线性卷积准确表示；人移动、设备转动和温度变化又会使 h 随时间改变。实际系统因此把 h 当作短时间内有效的近似，并用持续自适应跟踪变化；非线性残余另由 §6.1.4 和 §6.1.6 的模块处理。




图26 (a) 用冲激响应 $h(n)$ 表示房间路径，前部主要包含直达声和早期反射，后部是逐渐衰减的拖尾。(b) 给出远端参考、卷积后的回声和 0.8~1.2 s 的近端语音。(c) 显示三者 in 麦克风信号 $d(n)$ 中叠加。AEC 根据参考估计回声分量，再从 $d(n)$ 中减去该估计。

$h(n)$ 表示从参考抽头到麦克风之间的**线性等效路径**，包括转换器、扬声器的小信号响应、声学传播和麦克风响应。它与 §2.4 的纯声学房间冲激响应有关，但还包含电声器件的线性响应，二者不能完全等同。滤波器所需覆盖时间应由目标设备的实测回声路径确定；16 kHz 下 1 ms 对应 16 个抽头，64 ms 对应 1024 个抽头。滤波器没有覆盖的晚期部分会留在残差中，再由残余回声抑制器处理。

四种工作场景（谈论任何 AEC 指标前先声明场景，否则数字没有意义）：

1. **远端单讲 (STFE, single-talk far-end)**：只有扬声器在响， $s(n) = 0$ 。此时残差中的目标回声可以单独统计，回声返回损失增强 (Echo Return Loss Enhancement, ERLE) 只在这个场景下有清楚的物理意义；
2. **近端单讲 (STNE, single-talk near-end)**：只有用户在说话，回声路径没有激励，AEC 什么也不该做——考验的是“别误伤”；
3. **双讲 (DT, double-talk)**：两者同时存在。残差 e 中含近端语音，继续更新会使路径估计偏离，残余抑制也可能损伤近端语音，控制方法见 §6.1.5；
4. **双方沉默 (idle)**：回声与语音都没有。滤波器不应在纯噪声激励下持续漂移，残余抑制也不应把背景压成突兀的静音。测试矩阵应覆盖沉默期路径变化以及重新播放后的恢复过程 (§6.1.9、§6.1.12)。

免提通话需要同时控制远端单讲时的残余回声和双讲时的近端语音损伤。具体验收阈值应由目标场景、适用标准和主观听测确定，ERLE 的统计口径见 §6.1.8。

主要难点 (Breining et al. 1999 年的综述系统讨论了以下四项)：

1. **冲激响应长**：回声路径覆盖时间增加时，时域滤波器需要更多抽头，计算量增加，收敛也可能变慢；§6.1.3 说明分频域方案怎样降低长滤波器的计算量；
2. **非线性**：微型扬声器与功放在大音量下失真，线性滤波器怎么学都学不出来——§6.1.4 整节讲它；
3. **双讲**：参考与目标同时存在，近端语音会使自适应更新产生偏差，见 §6.1.5；
4. **路径时变**：人走动、门开关、设备被挪动都会改变 $h(n)$ ；参考具有足够激励时，滤波器需要更新以跟踪这些变化。[Breining et al., IEEE Signal Processing Magazine 1999](#)

边栏：温度如何搬动回声。 声速随温度变化 $v \approx 331 + 0.61 T$ m/s (T 为摄氏温度)：温度每变化 1°C ，声速改变约 0.18%；变化 10°C ，就是约 1.8%。扬声器到麦克风 1 m 的直达路径约 3 ms， 10°C 的温漂把所有反射的到达时间整体搬动约 $50\ \mu\text{s}$ ——在 16 kHz 采样下不足一个样本，但高频段的相位已经转过可观角度。Elko、Diethorn 与 Gänslér (IWAENC 2003) 的实测表明，缓慢的热漂移会侵蚀已收敛 AEC 的性能——这是“路径时变”比较隐蔽、也无法靠出厂标定消除的一种形式。[Frontiers in Signal Processing 2024 \(温度对 AEC 影响的实测研究\)](#)

减法与乘法两类处理。 AEC 有已知参考，可以估计回声的幅度和相位后做减法；相位估计错误时，减法也可能放大残余。降噪 (§5.7) 通常没有噪声波形参考，只能估计能量并施加 $0\sim 1$ 的增益。§6.1.9 的非线性处理 (Nonlinear Processing, NLP) 残余抑制和第 5 章的后置滤波都属于后一类方法。

图27 AEC 结构：根据播放参考估计回声，再从麦克风信号中相减




图27显示基本信号流：播放参考一支经过扬声器和房间进入麦克风，另一支进入自适应滤波器以估计回声路径。估计回声从麦克风信号中减去，双讲检测控制滤波器是否更新。

6.1.2 线性自适应滤波：NLMS 回顾

做法：用一个自适应滤波器 $\hat{w}(n)$ 去模仿这条回声路径 $h(n)$ ，把参考信号过滤一遍得到“回声副本” $\hat{y}(n)$ ，再从麦克风信号里减掉：

$$e(n) = d(n) - \hat{w}^\top(n) \vec{x}(n)$$

滤波器当前的路径估计作用于播放参考，产生估计回声；残差越小，说明路径估计越接近实际路径。其中：

- $d(n)$ ：麦克风录到的信号（回声 + 用户语音 + 噪声，标量）； $\vec{x}(n)$ ：由最近一段播放样本组成的向量，其长度等于滤波器抽头数。抽头数应按采样率、参考到麦克风的纯延迟、实测路径覆盖时间和可接受残余共同确定；
- $e(n)$ ：残差——回声被减得越干净， e 越小，于是用 e 反过来驱动滤波器更新，经典算法是 NLMS（归一化最小均方，Normalized Least Mean Squares）：

$$\hat{w}(n+1) = \hat{w}(n) + \mu \frac{e(n) \vec{x}(n)}{\|\vec{x}(n)\|^2 + \varepsilon}$$

更新量与残差和输入向量成正比，并由输入能量归一化。 ε 防止静默时分母接近零。

这个更新式怎么来的（三步）：

1. 定目标：想让残差功率最小。最直接的瞬时目标 $J(n) = e(n)^2$ ，对 $\hat{w}$ 求梯度： $\frac{\partial J}{\partial \hat{w}} = -2e(n) \vec{x}(n)$ （因为 $e = d - \hat{w}^\top \vec{x}$ ，链式法则一步得出）；
2. 最速下降：沿负梯度方向走一小步 $\hat{w} \leftarrow \hat{w} + \mu' e(n) \vec{x}(n)$ ——这就是 LMS（最小均方，Least Mean Squares）算法，“错了就朝减小误差的方向挪一步”；
3. 归一化步长：固定步长 μ' 对输入幅度敏感，幅度较大时可能发散，较小时又会减慢收敛。NLMS 用 $\|\vec{x}(n)\|^2 + \varepsilon$ 对更新归一化， ε 是防止静音时除以零的小正数。理想假设下 $\mu \in (0, 2)$ 可保持均方稳定； $\mu = 1$ 只对应同一帧给定输入下的瞬时最优，并非统计最优。实际步长要在目标参考信号、双讲控制和路径变化条件下扫描；图18 (b) 的本书仿真使用 $\mu = 0.5$ 。

算例 6-1：NLMS 的一步手算

题设：3 抽头滤波器，参考向量 $\vec{x}(n) = [1, 0.5, -0.5]^\top$ （最近 3 个播放样本），当前滤波器 $\hat{w}(n) = [0, 0, 0]^\top$ （刚开机、一无所知），麦克风信号 $d(n) = 0.8$ ，步长 $\mu = 0.5$ ， ε 很小先忽略。就按更新式

$$\hat{\vec{w}}(n+1) = \hat{\vec{w}}(n) + \mu \frac{e(n) \vec{x}(n)}{\|\vec{x}(n)\|^2 + \varepsilon} \text{ 走一步。}$$

第 1 步：算回声副本与残差。 $\hat{y}(n) = \hat{\vec{w}}^\top(n) \vec{x}(n) = 0 \times 1 + 0 \times 0.5 + 0 \times (-0.5) = 0$ ——滤波器还是零，回声一点没被减掉，残差 $e(n) = d(n) - \hat{y}(n) = 0.8$ 就是全部。

第 2 步：算归一化因子。 $\|\vec{x}(n)\|^2 = 1^2 + 0.5^2 + (-0.5)^2 = 1.5$ 。拿输入能量去除：播放音量大时分母大、步子自动变小——这就是 NLMS 不怕音量起伏的原因。

第 3 步：算更新量、更新滤波器。

$$\mu \frac{e(n)}{\|\vec{x}(n)\|^2} \vec{x}(n) = \frac{0.5 \times 0.8}{1.5} \begin{bmatrix} 1 \\ 0.5 \\ -0.5 \end{bmatrix} = \frac{0.4}{1.5} \begin{bmatrix} 1 \\ 0.5 \\ -0.5 \end{bmatrix} \approx \begin{bmatrix} 0.267 \\ 0.133 \\ -0.133 \end{bmatrix}$$

$$\hat{\vec{w}}(n+1) = [0, 0, 0]^\top + \text{更新量} \approx [0.267, 0.133, -0.133]^\top$$

这一步只修正了当前输入方向上的误差；其他方向需要后续不同的输入向量提供梯度信息。更新方向与 $\vec{x}(n)$ 平行。

第 4 步：用更新后的系数重算回声副本。

$$\hat{y}'(n) = \hat{\vec{w}}^\top(n+1) \vec{x}(n) = 0.267 \times 1 + 0.133 \times 0.5 + (-0.133) \times (-0.5) \approx 0.267 + 0.067 + 0.067 \approx 0.4$$

新残差 $e'(n) = 0.8 - 0.4 = 0.4$ 。把更新式代回残差可得 $e'(n) \approx (1 - \mu)e(n)$ ，因此 $\mu = 0.5$ 时同一帧的后验残差减半； $\mu = 1$ 时到达该帧的瞬时最优。连续输入上的多次更新使滤波器逐步收敛。

$e' \approx (1 - \mu)e$ 的推导。把更新式代回同一帧的残差：

$$e'(n) = d - \hat{\vec{w}}^\top(n+1) \vec{x} = [d - \hat{\vec{w}}^\top(n) \vec{x}] - \mu e(n) \frac{\vec{x}^\top \vec{x}}{\|\vec{x}\|^2 + \varepsilon} = e(n) \left[1 - \mu \frac{\|\vec{x}\|^2}{\|\vec{x}\|^2 + \varepsilon} \right]$$

$\varepsilon \ll \|\vec{x}\|^2$ 时方括号约等于 $(1 - \mu)$ ，即 $e'(n) \approx (1 - \mu)e(n)$ 。 $\mu = 1$ 时 $e' \approx 0$ ，只表示本帧给定 $\vec{x}$ 下的瞬时最优；下一帧输入变化后仍需继续更新。 $\mu = 0.5$ 时本帧残差减半。 $\mu = 1.8$ 时 $e' \approx -0.8e$ ，残差变号且幅度仍为原来的 80%； $\mu = 2$ 对应幅度不减的临界情况。

第二个手算例（换一组数，验证“减半”不是巧合）： $\vec{x} = [0.8, -0.4, 0.4]^\top$ ， $d = 0.6$ ， $\hat{\vec{w}}(n) = 0$ ， $\mu = 0.5$ 。则 $\|\vec{x}\|^2 = 0.64 + 0.16 + 0.16 = 0.96$ ，更新量 $= 0.5 \times 0.6/0.96 \times \vec{x} = [0.25, -0.125, 0.125]^\top$ ，重算 $\hat{y}' = 0.25 \times 0.8 + (-0.125) \times (-0.4) + 0.125 \times 0.4 = 0.2 + 0.05 + 0.05 = 0.3$ ，新残差 $0.6 - 0.3 = 0.3$ ——同样减半，规律是 $e' \approx (1 - \mu)e$ ，与具体数字无关。

图18 声学回声消除 (AEC) 原理




图18 (a) 给出整体结构; (b) 给出 NLMS 在模拟回声路径上的收敛曲线。此仿真取 $\mu = 0.5$, ERLE 在约 0.3~0.5 s 达到约 22 dB, 粉色区域表示双讲期间冻结更新。




图28 (a) 显示 $\hat{w}$ 从零开始逐步逼近真实路径 h 。(b) 在本仿真中, 路径失配下降约 10 dB 时 ERLE 上升约 10 dB。(c) 比较不同步长: 较大的 μ 收敛较快, 但稳态波动也较大。 $\mu \in (0, 2)$ 是理想假设下的范围, 实际取值需用目标信号验证。

图29 NLMS 收敛与双讲冻结




图29上方三行使用共同尺度的均方根包络，分别显示参考 x 、麦克风信号 d 和残差 e 。粉色区域为双讲时段，此时残差含近端语音，ERLE 不能评价回声抵消量，因此曲线在该区间不绘制。滤波器在双讲期间冻结更新，双讲结束后继续沿原路径工作。

步长与正则项：较大的 μ 通常收敛较快，但稳态波动较大；较小的 μ 则相反。 ε 防止静默时分母趋近于零。固定下限与随参考功率缩放的正则项使用不同量纲和归一化口径，不能照搬同一个数值。可扫描静音、低电平参考和正常播放三类输入，选择既不在静音时产生大更新、又不过度减慢小信号收敛的取值。

收敛还需要充分激励。NLMS 每步只能沿当前输入方向 $\vec{x}(n)$ 修正（见算例 6-1 第 3 步）。纯音或窄带参考不能充分激励所有滤波器系数，未被激励的方向会收敛得很慢。调试时可用已知宽带测试信号检查滤波器是否能辨识目标路径；这项测试不能代替真实节目内容上的收敛与双讲验证。

6.1.3 工程化自适应：频域、子带、比例、卡尔曼

时域实现的计算量。 $L = 1024$ 抽头的时域 NLMS 每样本约需 $3L \approx 3000$ 次乘法，8 kHz 下约 2500 万次/秒。48 kHz、4096 抽头时会达到每秒数亿次，而且抽头越多、输入频谱越不均匀，收敛通常越慢。常见改进包括频域分块、子带处理、比例步长和卡尔曼估计。

PBFDFAF：分区块频域自适应。它沿用多延迟块频域（MDF）方法的思路，把 L 个抽头分成 $P = \lceil L/N \rceil$ 个长度为 N 的分区，并用长度 $2N$ 的 FFT 完成重叠保存卷积。每块的频域滤波和梯度相关都要遍历 P 个分区，因此不能只写成 $O((L/N) \log N)$ 。忽略实现常数时，无梯度约束版本每个新样本约为 $O(\log N + L/N)$ ；若每个分区都做时域梯度约束，还会增加约 $O((L/N) \log N)$ 。这个写法同时说明了两件事：FFT 的固定成本随块长对数增长，分区乘法则随 L/N 线性增长。具体倍数还取决于实数或复数 FFT、频谱共轭对称复用、功率估计、约束频率以及一次相加如何计数，不能脱离这些约定比较。[KU Leuven DSP-CIS 讲义第 13 章](#)

算例 6-2：PBFDFAF 的乘法计数 ($L = 1024$ 、 $N = 128$ 、8 kHz，看“一个数量级”是怎么省出来的)

时域 NLMS 的账：每样本滤波 L 次乘法 + 更新 L 次 + 功率归一 L 次，共约 $3L = 3072$ 次乘法/样本。

PBFDFAF 的账：块长 $N = 128$ ，FFT 长度取 $2N = 256$ （overlap-save 结构，防循环卷积混叠），分区数 $P = L/N = 8$ 。每来一块 128 个新样本，要做的活是：

1. 新参考块算 1 次 FFT——旧分区的频谱整体平移复用，不必重算，这是“分区”省钱的根源；
2. 8 个分区各做一次长度 256 的复数相乘（滤波 = 频域相乘），合起来 1 次 IFFT 得输出块；
3. 误差块 1 次 FFT，8 个分区各做一次共轭相关复乘（梯度方向）；
4. 若施加梯度约束（清掉时域混叠项），再加 8 次 IFFT；无约束版可省掉这一步。

按 $2N$ 点实 FFT $\approx 4N \log_2(2N) = 4 \times 128 \times 8 = 4096$ 次实乘法、长度 256 复乘 $= 256 \times 4 = 1024$ 次实乘法计：

- 无约束版： $3 \times 4096 + 2 \times 8 \times 1024 = 12288 + 16384 = 28672$ 次/块 $\rightarrow$ 每样本 $28672/128 \approx 224$ 次；
- 约束版：再加 $8 \times 4096 = 32768$ ，共 61440 次/块 $\rightarrow$ 每样本约 480 次。

在上述计数约定下，无约束版约为 224 次实乘法/样本，逐分区约束版约为 480 次，时域 NLMS 按 3072 次计，得到约 14 倍和 6 倍的差距。这些数只用于同一计数口径内比较。块长 $N = 128$ 、采样率 8 kHz 时，每块含 16 ms 新数据；实际算法延迟由重叠保存、调度方式和系统缓冲共同决定，不能仅凭“两个块”固定写成 32 ms。滤波器加长时，时域复杂度按 L 增长，而分区频域方法的主要项按 L/N 增长，因此长回声路径更适合用分区频域实现。

PBFDFAF 更新式。记第 m 块、第 k 个频点的参考谱为 $X(k, m)$ 、滤波器谱为 $W(k, m)$ 、误差谱为 $E(k, m)$ ，则逐频点更新（示意，工程实现另有梯度约束与步长平滑）：

$$W(k, m+1) = W(k, m) + \mu \frac{E(k, m) X^*(k, m)}{|X(k, m)|^2 + \delta}$$

与时域 NLMS 相比，分子仍是“误差 $\times$ 参考共轭”，分母仍做参考功率归一； $E(k, m)$ 是用旧滤波器得到的先验误差。频域实现有两点差别：① 每个频点独立归一，减少语音低频能量较强对高频更新速度的影响；② 每积累 N 个样本更新一次，因此跟踪粒度由块长决定。工程实现还需施加梯度约束，消除块卷积中的循环混叠。以 $N = 128$ 、8 kHz 为例，每秒更新约 $8000/128 \approx 62$ 次；每次更新同时利用 128 个新样本，整体乘法量见算例 6-2。

子带自适应：分析滤波器组把信号分成多个子带。带内频谱较平坦，有利于收敛；降采样也会缩短各带滤波器并降低计算量。临界采样时子带间存在混叠，严格重建需要带间交叉滤波器补偿（Gilloire & Vetterli, *IEEE Trans. Signal Processing* 1992）。Gilloire & Vetterli 1992

IPNLMS：按稀疏度分配步长。真实回声路径通常由直达声和少数强反射贡献主要能量，其余抽头较小。NLMS 对所有抽头使用同类更新；PNLMS（比例 NLMS, proportionate NLMS, Duttweiler 2000）与改进版 IPNLMS（改进比例 NLMS, improved proportionate NLMS, Benesty & Gay, ICASSP 2002）按系数当前幅度成比例分配步长，使较大的系数优先收敛。IPNLMS 用混合系数 $\alpha \in [-1, 1]$ 在均匀步长与比例步长之间插值： $\alpha = -1$ 退化为 NLMS， $\alpha = 0$ 偏向比例更新， $\alpha = -0.5$ 介于两者之间。声学回声路径通常不如网络回声路径稀疏，因此 IPNLMS 的收益需在实际路径上验证。

RLS 与卡尔曼。RLS（递归最小二乘，Recursive Least Squares）用带遗忘的最小二乘代替随机梯度，标准全矩阵实现复杂度为 $O(L^2)$ 。遗忘因子 λ 越小，历史样本衰减越快，路径变化后适应得更快，但稳态估计方差也更大。有效记忆长度常用 $1/(1 - \lambda)$ 粗略估计： $\lambda = 0.99$ 约为 100 个样本， $\lambda = 0.999$ 约为 1000 个样本。Elisei-Iliescu et al. 2017（AEC 自适应算法综述）

频域卡尔曼滤波（frequency-domain Kalman filter, FDKF）把每个频点的回声路径系数当作随时间缓慢变化的状态。卡尔曼增益的作用类似自适应步长，但只有在状态模型、过程噪声方差和观测噪声方差与实际相符时才是相应模型下的最小均方误差增益。双讲时，如果观测噪声估计能及时包含近端语音能量，增益会减小；估计滞后或模型失配时仍可能误更新，所以工程实现通常还会结合双讲检测或增益上限。

把这句话写具体。FDKF 把回声路径当作状态变量，写出一对方程（实际在频域逐频点进行，此处用时域记号示意）：

$$\vec{h}(n) = a \vec{h}(n-1) + \Delta \vec{h}(n), \quad d(n) = \vec{x}^\top(n) \vec{h}(n) + s(n) + v(n)$$

第一行是**状态方程**：上一时刻的路径乘状态转移因子 a ，再加过程噪声 $\Delta \vec{h}$ ，用来描述缓慢漂移和偶发突变。第二行是**观测方程**：麦克风信号由参考经过路径滤波后，再叠加近端语音和噪声。对应 §9.2 的卡尔曼递推，状态是 $\vec{h}$ ，观测是 d ，近端语音与噪声合并为观测噪声。双讲时观测噪声估计增大，卡尔曼增益随之减小；路径变化使预测误差增大时，增益会上升以加快重新收敛。每个频点还需维护误差方差或协方差，因此计算量高于普通 PBFDAF。

逐频点写完整的一次递推。省略频点下标， W_{m-1} 是上一块的路径系数， P_{m-1} 是其误差方差， a 是状态转移因子， Φ_m 和 Ψ_m 分别是过程噪声与观测噪声方差：

$$\begin{aligned} \hat{W}_m^- &= a W_{m-1}, & P_m^- &= a^2 P_{m-1} + \Phi_m \\ E_m &= D_m - X_m \hat{W}_m^-, & K_m &= \frac{P_m^- X_m^*}{|X_m|^2 P_m^- + \Psi_m} \\ W_m &= \hat{W}_m^- + K_m E_m, & P_m &= (1 - K_m X_m) P_m^- \end{aligned}$$

前两式先预测路径和不确定度；中间两式根据先验残差计算增益；最后两式更新系数和误差方差。标量复数模型中 $K_m X_m$ 为实数且位于 0 与 1 之间。实际分区频域实现还要处理矩阵协方差、块卷积约束和频点平滑。

若暂时固定 W ，并把残差视为零均值圆对称复高斯变量，单帧负对数似然中与 Ψ 有关的部分为 $|E|^2/\Psi + \log \Psi$ 。正确的导数是

$$\frac{\partial}{\partial \Psi} \left(\frac{|E|^2}{\Psi} + \log \Psi \right) = -\frac{|E|^2}{\Psi^2} + \frac{1}{\Psi}.$$

令它为零得到单帧极大似然估计 $\hat{\Psi} = |E|^2$ 。单帧估计波动很大，还把未建模回声混入“观测噪声”，所以实际系统会做时间平滑、双讲判决或由网络估计 Ψ ，不能直接把当前 $|E|^2$ 当成准确的近端语音功率。

最小数例取 $X = 1$ 、 $P^- = 1$ 。远端单讲时若 $\Psi = 0.01$ ， $K = 1/1.01 \approx 0.990$ ，残差的大部分用于更新；双讲时若 $\Psi = 10$ ， $K = 1/11 \approx 0.091$ ，更新量约为前者的 9.2%。这说明软门控会缩小更新，但并没有严格冻结。

方法对比（描述相对趋势；具体计算量和收敛速度取决于滤波长度、输入谱、块长与实现，选型条件另见图32 (c)）：

算法	每样本复杂度	收敛速度	双讲鲁棒性	适用场景
时域 NLMS	$O(L)$ (约 $3L$ 次乘法)	慢, 有色输入更慢	弱, 需外挂双讲检测	短路径、算力受限
IPNLMS	$O(L)$ (常数略大)	中 (稀疏路径快)	弱, 需外挂双讲检测	网络回声、稀疏路径
PBFDFAF	无约束约 $O(\log N + L/N)$; 逐分区约束另加 $O((L/N) \log N)$	中 (逐频点归一化)	弱, 需双讲检测或连续步长控制	长路径、全频带
子带自适应	低 (降采样后各带很短)	快 (带内近白噪)	弱, 需外挂双讲检测	低功耗嵌入式
RLS	$O(L^2)$	在模型匹配时可比随机梯度法快	遗忘因子较小时更易受双讲干扰	短滤波器、研究基准
频域卡尔曼 FDKF	以分区频域滤波为基础, 另有状态统计量维护	取决于过程噪声和观测噪声估计	软门控 (增益自适应, 仍需验证双讲控制)	长路径且需要跟踪变化的系统

§6.1.1~§6.1.3 建立了线性回声模型, 并比较了 NLMS、分区频域方法、比例步长和频域卡尔曼滤波。ERLE 只适用于远端单讲; 线性滤波只能处理参考可表示的线性回声, 参考抽头位置和双讲控制还需另行设计。

非线性回声与双讲控制 (§6.1.4~§6.1.5)

6.1.4 非线性回声：模型失配与处理方法

非线性从哪来。微型扬声器的悬边与磁路在大振幅下不再线性 (悬边变硬、音圈跑出匀强磁场区), D 类功放在大音量下削顶 (clipping), 机壳与结构件随声压振动产生二次辐射——Birkett & Goubran (WASPAA 1995) 的经典实测最早系统记录了免提终端中的这些成分, Klippel (JAES 2006) 给出了扬声器非线性的完整物理建模。

平台从哪里来。线性滤波器只能估计播放参考的线性组合。扬声器软削波产生的谐波和互调分量不在这个线性子空间内, 因此即使路径估计已经收敛, 残差仍会保留非线性分量。图19 (a) 是本书脚本设定下的单次仿真: 线性路径与 `tanh` 软削波路径使用同一套 NLMS 参数, 后者出现较低的平台。图中的平台高度只属于该输入幅度分布、软削波强度、路径和统计区间, 不能外推为某类设备固定的 ERLE 上限。

`tanh` 的最小手算。取归一化输入 $x = 0.3$, $\tanh(0.3) \approx 0.291$, 相对小信号线性近似 $y = x$ 的偏差为 0.009。输入增大到 $x = 1.5$ 时, $\tanh(1.5) \approx 0.905$, 同一线性近似的偏差增至 0.595。这两个采样点只说明非线性偏差随幅度增大, 不能推出整段语音的失真功率或 ERLE。要得到平台数值, 需要在给定输入、软削波参数和路径上求出最佳线性拟合, 再按远端单讲区间统计原始回声与残差的平均功率。图19 和图31展示の数値采用本书绘图脚本中的特定仿真配置。

图19 AEC 的能力边界与算法版图




图19 (a) 比较该脚本配置下的线性路径与 `tanh` 非线性路径。约 37 dB 和 19~20 dB 只适用于图中的输入、路径和统计区间。(b) 列出 LMS/NLMS、FDKF 和 AEC Challenge 等发展节点，用于说明线性估计、自适应控制与学习型残余抑制的分工变化。




图30 (a) 用互相关估计参考与麦克风信号之间的延迟，本例峰值约为 331 个采样，其中包含设置的 300 个采样纯延迟和回声路径主峰的位置。(b) 对齐后的远端单讲 ERLE 约为 28 dB，不对齐时约为 2 dB。本例的纯延迟超过 128 抽头滤波器的覆盖范围，因此差异较大。(c) 比较双讲期间冻结和继续更新；后者会使路径估计偏离，双讲结束后需要重新收敛。排查时应分别检查延迟估计和双讲控制。

出路①：把非线性建进模型。二阶 Volterra（沃尔泰拉）级数在线性核之外增加作用于 $x(n-i)x(n-j)$ 的二阶核。完整二阶核有 $O(L^2)$ 个系数，实用实现会限制核的结构或保留部分系数，以交换计算量和建模能力。

Hammerstein/Wiener 级联则用“静态非线性 + 线性动态”两段建模；Nollett & Jones (NSIP 1997) 在该论文的实验配置下报告相对线性基线提高 8.4 dB。Nollett & Jones 1997 这个数值与论文中的输入、失真模型、路径和统计口径绑定；当真实失真偏离模型假设时，需要重新测量收益。

出路②：换参考，绕开建模。非线性发生在播放链路里，可以把参考取在更接近扬声器的一端，使参考包含更多已经发生的失真。(a) 电信号参考直接采样扬声器端子的电压或电流。Shah et al. 在论文所述的受控设备和测试条件下报告，相对原参考的改善约为 6~15 dB；该结果只覆盖实验中的电一气链路失真，不能外推到结构二次辐射或其他硬件。Shah et al., IEEE/ACM TASLP 2015 (b) 机械振动参考用加速度计采集振膜或机壳振动，需增加传感器和采集通道。两种做法都要比较新增参考带来的收益、噪声、同步误差和硬件代价。

出路③：神经网络。深度神经网络 (Deep Neural Network, DNN) 可以从数据学习残余抑制，适用条件和验证方法见 §6.1.6。

6.1.5 双讲检测与自适应控制

双讲时，残差同时包含路径失配和近端语音。若仍按普通 NLMS 更新，近端语音会进入梯度并使路径估计偏离。DTD (双讲检测, double-talk detection) 用于降低步长或冻结更新。门限过于敏感会延迟路径跟踪，门限过于迟钝则可能导致误更新。

图31 本仿真中的线性匹配与非线性失配




图31 (a) 在当前仿真参数下比较线性路径与 tanh 非线性路径，后段均值分别约为 34 dB 和 18 dB。这些数值不是设备性能上限。(b) 显示 tanh 映射在输入幅度增大后逐渐偏离线性关系。线性滤波器无法表示由此产生的非线性分量，因此继续增加抽头或调整步长不能消除这部分残余。

常见 DTD 方法 (DTD = 双讲检测, double-talk detection; NCC = 归一化互相关, normalized cross-correlation):

- Geigel 能量比较:** $\xi = |d(n)| / \max |x(\cdot)|$, 高于阈值 $T = 0.5$ 时判为双讲。0.5 来自回声路径至少衰减 6 dB 的假设 ($20 \log_{10} 2 \approx 6$ dB)。若实际回声路径接近 0 dB, 远端单讲也可能被误判; 若回声很弱, 小声近端语音又可能漏检。因此该方法适合低成本初筛, 不宜单独承担声学双讲检测;
- 互相关 / 归一化互相关 (NCC)** (Benesty 等): 利用“滤波器收敛后残差 e 与参考 x 去相关”的性质—— e 与 x 还有相关性, 说明回声没消完; 相关性降低且 e 能量仍大, 才可能是双讲。判决还需结合滤波器失配和噪声条件;
- 频域 NCC** (Gänsler & Benesty, *Signal Processing* 2001): 在频域逐频点估计相关性, 可与 PBFDAF 复用部分频域表示; 额外计算量取决于平滑、频带汇总和判决实现;
- 相干函数法:** 用 d 与 x 的幅度平方相干判别, 与 NCC 同族;
- 双滤波器法:** 前台滤波器负责输出, 后台滤波器用更大的步长寻找新路径。后台并不是“不怕双讲”, 双讲时照常大步更新同样会偏离真实路径, 所以它也要根据双讲置信度缩小步长或冻结。只有当后台滤波器在一段保持

时间内持续得到更小的远端单讲残差，才把系数复制到前台；切换判决需要门限和迟滞，避免两套滤波器来回切换。WebRTC AEC3 的 refined/coarse 结构采用了相近的快慢滤波思路，但具体更新和切换规则以对应版本源码为准。

Geigel 判决的数字例子。 设 $\max |x| = 1.0$ 。远端单讲且回声路径衰减 6 dB 时， $|d| \approx 0.5$ ；阈值取 0.5 时恰好位于边界。用户开口会使比值增大，超过阈值时冻结更新。这个检测依赖回声路径增益上界：强回声可能在远端单讲时误判，弱回声叠加小声近端语音又可能漏检。因此 Geigel 判决适合说明原理，不宜单独承担声学双讲检测。

从二值冻结到连续步长。冻结是 0/1 开关，也可以根据残余回声与近端干扰的相对功率连续调整步长。Mäder、Puder & Schmidt (*Signal Processing* 2000) 推导的最优步长 $\alpha(k)$ 在 $[0, 1]$ 内变化：回声占优时增大，双讲占优时减小。连续控制可减少硬切换造成的跟踪迟滞。

神经 DTD。lvry et al. 的深度变步长 (Deep Variable Step-Size, DVSS, ICASSP 2022) 用 DNN 预测逐帧步长。在该论文的数据、路径突变定义、成功判据和基线实现下，DVSS 的重收敛时间为 3.4 s、成功率为 95%，NLMS 加经典 DTD 基线分别为 7.9 s 和 58%。这些是论文实验结果，不是产品验收阈值；复现时要沿用论文的判据，部署时则按目标设备另定恢复条件。[lvry et al., ICASSP 2022](#)

§6.1.4~§6.1.5分别说明了非线性失配和双讲误更新。非线性残余可通过显式建模、改变参考位置或学习型抑制处理；双讲期间应根据检测置信度冻结或减小步长。由于输出含近端语音，双讲区间不能用普通 ERLE 评价。

学习型残余抑制、阵列顺序与评测 (§6.1.6~§6.1.8)

6.1.6 学习型 AEC

分水岭：微软 AEC Challenge。2021 年起微软连续举办了共 4 届 AEC 挑战赛 (ICASSP 2021、Interspeech 2021、ICASSP 2022、ICASSP 2023) ——**注意没有 2024 届**：2024 年起微软转向丢包隐藏 (PLC, packet loss concealment) 挑战赛，网上流传的“AEC Challenge 2024”系误传 (官方仓库停在 2023 年第四届)。四届的关键信息：

届次	关键升级	代表结果
ICASSP 2021	开源 2500+ 条真实设备录音；改用 P.808 众包 MOS 排名 (动机：ERLE/PESQ 与真实听感相关性差)	冠军 Amazon PercepNet (线性 AEC + Bark 域轻量神经后滤波)；亚军 wRLS+NN；季军 DTLN-AEC
Interspeech 2021	延续首届设置，扩充真实场景与设备覆盖	排名前列仍以混合式方案为主
ICASSP 2022	升级 48 kHz 全频带；新增 WAcc (对下游 ASR 的影响，2023 届沿用 MOS + WAcc 双排名)	神经卡尔曼与混合式并驾齐驱
ICASSP 2023	新增个性化 AEC 任务 (注册语音 15~25 s)；算法与缓冲延迟从 40 ms 收紧到 20 ms	非个性化冠军：西工大 NPU-ASLP

[Sridhar et al. \(ICASSP 2021 AEC Challenge 报告\)](#)、[Cutler et al. 2023 \(ICASSP 2023 AEC Challenge 报告\)](#)

挑战赛带来了三项变化。**评测指标**从单独比较 ERLE 和 PESQ，转向 P.808 众包主观 MOS (平均意见分, Mean Opinion Score)，因为较高的 ERLE 仍可能伴随可闻的非线性残余。**测试数据**加入 2500 多条真实设备录音，覆盖


真实扬声器失真、房间和双讲条件。**系统结构**方面，首届前三名中既有线性 AEC 加神经后滤波的混合方案，也有纯神经端到端的 DTLN-AEC。两类方法应按延迟、算力、泛化和故障诊断要求分别评估。

后续规则继续增加约束。2022 届采用 48 kHz 全频带信号，高频相位对路径失配更敏感；同届新增词准确率 (WAcc, word accuracy)，用于评价前端对下游识别的影响。2023 届把算法和缓冲延迟预算从 40 ms 收紧到 20 ms，长窗和长缓冲方案需要相应改成果或低前视实现。

混合式结构：线性估计加学习型残余抑制。自适应滤波器利用已知参考估计线性回声，不需要训练数据；神经网络则处理线性模型未覆盖的残余回声、环境噪声和部分晚期混响。两者分工可以减少网络需要学习的动态范围，同时保留线性段的路径与收敛诊断。

可以用 SER（信号回声比，signal-to-echo ratio）为 -20 dB 的时频点说明两类方法的差别：此时回声能量是近端语音的 100 倍。若回声副本幅度误差为 10%，残余回声能量约为原回声的 1%，相当于降低 20 dB，而近端语音不参与该减法。若只对混合信号施加同一个增益 g ，回声和近端语音会同比缩放，该时频点的 SER 不变。混合结构因此先用参考完成线性减法，再对无法建模的残余施加增益抑制。

图32 线性回声消除与残余抑制：按系统条件选择模块
(a) 一种常见的混合处理流程



(b) 每个模块都要满足前提条件

模块	主要对象	使用前提	重点验证
线性自适应滤波	线性回声	参考信号已对齐	失调、ERLE
规则型残余抑制	稳定残余回声	可靠的双讲保护	近端失真、衰减量
学习型残余抑制	非线性残余与噪声	匹配数据、算力与时延预算	近端失真、跨场景稳定性

(c) 选型时比较这些条件

方案	路径长度	路径变化	非线性残余	训练数据
NLMS	短到中等	逐样本	不直接处理	不需要
分区频域滤波	适合长路径	按块更新	不直接处理	不需要
频域卡尔曼滤波	适合长路径	依赖状态模型	不直接处理	不需要
混合学习方案	由线性前级承担	取决于前级与模型	可针对性处理	需要匹配数据

模块叠加不保证性能单调提升；必须在目标设备、房间和双讲条件下实测。

还要同时核对算力、内存、端到端时延、参考位置和双讲策略。

图32 (a) 给出一类混合流程：参考先经过延迟估计与对齐，再由线性 AEC 产生残差；学习型残余抑制可同时使用残差 e 和参考 x ，双讲检测与步长控制负责约束自适应更新。(b) 列出线性滤波、规则型残余抑制和学习型残余抑制各自处理的对象、使用前提和验证重点。(c) 从路径长度、路径变化、非线性残余和训练数据等条件比较 NLMS、分区频域滤波、FDKF 与混合学习方案。该表用于确定需要验证的条件，不给出固定性能档次。

后滤波器的输入与输出（以 PercepNet 类结构为例）：输入可以包括残差 e 、参考 x 的逐帧谱，以及滤波器系数范数、当前步长和各频带相干性等线性 AEC 内部量。网络输出逐频带增益或其他滤波参数。频带划分、特征维度和训练目标属于具体模型版本，不能在不同实现之间直接套用。

代表方案如下：

- **PercepNet** (Amazon, 首届冠军)：经典线性 AEC 之后接一个 Bark 域（人耳听觉刻度）的轻量 RNN（循环神经网络, Recurrent Neural Network），输出逐频带增益。是否实时取决于模型版本、处理器、线程和计时范围；
- **Ma et al. 2020**：自适应滤波器 + RNN 后处理的系统化实现，把混合式做成可复现的开源基线 [Ma et al. 2020](#)；
- **DTLN-AEC** (首届季军)：双级 LSTM（长短期记忆网络, Long Short-Term Memory），第一级在时域分离，第二级在频域细化，两级之间用可学习变换连接；
- **DeepVQE** (Microsoft, Interspeech 2023)：单模型联合 AEC、降噪和去混响，用交叉注意力在参考与麦克风信号之间做软对齐。论文报告了作者实现面向 Teams 场景的实时测试；这一结论只适用于论文所述模型、硬件和软件配置，不能据此推断其他实现的实时性。[DeepVQE](#)

端到端神经 AEC 把问题写成条件语音分离：输入麦克风信号和播放参考，直接估计近端语音。它能联合建模非线性与残余噪声，但低 SER 下的近端保护、未见设备上的泛化、因果延迟和故障诊断都需要单独验证。深度滤波不只输出 0~1 掩码，而是估计复数时频滤波器，可以同时调整幅度和相位。不同方案的 MOS 与 ERLE 只有在数据、场景、延迟和统计区间相同的条件下才能比较。

训练数据。回声路径可以用 §2.4 的镜像法生成不同房间尺寸和 T_{60} ，非线性失真可以用随机 Wiener-Hammerstein 级联参数化，SER 和 SNR 也可按区间采样。真实设备录音仍用于覆盖仿真中缺少的扬声器、结构振动和系统链路特性。常见做法是先用合成数据训练，再用目标设备录音微调并验证。

神经卡尔曼滤波：保留递推结构，学习难以建模的参数。这类方法保留 FDKF 的预测、更新和增益递推，由 DNN 估计卡尔曼增益、状态转移因子或非线性修正项。增益曲线和残余谱仍可用于诊断。NeuralKalman (ASRU 2023) 报告了下游任务改善，引用性能结果时需同时给出论文中的数据、基线和表格位置。[NeuralKalman](#), [arXiv:2301.12363](#) Deep Adaptive AEC (Amazon, ICASSP 2022) 把自适应滤波器写成可微分层，与深度网络联合训练。[Deep Adaptive AEC](#) Seidel et al. 比较了经典 FDKF 与神经变体；各方法的收敛、双讲保护和计算量应按该文的具体实验设置解读。[Seidel et al., IEEE SPM 2024](#)

把混合式方案按功能拆开，可分为自适应控制、线性路径估计和残余抑制。网络可以估计步长、卡尔曼统计量或残余增益；PBFDAF/FDKF 等解析结构仍提供可检查的路径估计和收敛状态。具体分工取决于延迟、算力和训练数据，不能写成固定的行业结论。

个性化 AEC (personalized AEC, pAEC)：2023 届 AEC Challenge 的个性化任务要求系统消除回声并保留注册用户的近端语音；该届规则使用 15~25 s 注册语音，并把算法与缓冲延迟限制为 20 ms。这两个数字是该届挑战赛条件，不是所有 pAEC 产品的注册时长和延迟标准。[Cutler et al. 2023](#) 系统从注册语音提取声纹嵌入，并把它作为网络条件；这一思路与目标说话人提取 (Target Speaker Extraction, TSE；见 §13.3) 相近。[GTCNN](#), [Interspeech 2022](#) 合规与验收细节见 §6.1.14。

pAEC 门限例子。设注册嵌入为 $\vec{e}_{\text{enroll}}$ ，逐帧近端嵌入为 $\vec{e}_t$ ，余弦相似度 $c = \cos(\vec{e}_t, \vec{e}_{\text{enroll}})$ 。阈值不能从通用经验直接照搬，应在目标设备、注册时长、距离和噪声条件下，用目标用户和非目标用户验证集标定。可以设置放行、抑制和不确定三个区间；不确定区间采用较保守的抑制，降低误压目标用户的风险。验收时分别报告目标用户误抑制率、非目标用户泄漏率和普通双讲质量，而不是只报一个相似度阈值。

多通道扩展：网络的输入通道数由训练时的结构决定，不能把任意数量的麦克风或播放参考直接拼接给固定模型。常见做法有三种：固定阵列几何和通道数训练；先用共享编码器逐通道提取特征，再用池化或注意力聚合可变通道；或先做逐通道线性 AEC 和波束形成，只让单通道网络处理波束输出。第二种能适应缺失通道，但仍需在训练中覆盖通道数、阵列几何和通道置换。多通道网络还要保持跨通道相位一致性，否则会损害后续波束形成。

对实时语音交互，设备播放语音时仍要检测用户插话。通常先用线性 AEC 降低设备自身播放，再把残差送入语音活动检测和识别；残余抑制的工作点要同时检查回声泄漏、近端语音失真和下游识别。若参考信号只能在远端获得，模块顺序需要按实际接口重新设计。

三类神经方案对比（定性；需要在相同数据、延迟和硬件下实测）：

路线	代表方案	可检查的内部量	主要风险	资源验证
混合式	PercepNet、DeepVQE	线性段路径、残差和 ERLE	后滤波可能损伤近端语音	按模型、频带数和目标硬件测量
端到端	Zhang & Wang 2019 等	通常缺少显式路径估计	域外设备、低 SER 和故障定位	按模型、上下文和目标硬件测量
神经卡尔曼	NeuralKalman、Deep Adaptive AEC	递推增益、状态估计和残差	统计量估计失配、模型计算量	同时报递推部分与网络部分

按设备条件选型：耳机和手表受算力、内存与功耗限制，可比较端侧小模型与传统频域方案；音箱和会议终端可评估 PBFDAF 或 FDKF 加神经后滤波；双讲条件复杂且需要保留递推诊断量时，可进一步评估神经卡尔曼；需要只保留注册用户时再评估 pAEC。语音助手还要单独验证用户插话（barge-in）时的近端保护。无论采用哪条路线，系统设计仍需处理 §6.1.9 所列的参考、延迟、双讲和残余回声问题。

6.1.7 阵列中的 AEC：与波束形成的三种顺序

多麦克风设备里，AEC 与波束形成（第 5 章）谁先做，是系统级的架构决策，教科书上三种排法：

1. **AEC→BF（每通道独立 AEC）：**每个麦克风通道各配一套 AEC，波束形成在回声消除之后进行。优点是各通道回声路径 $h_m(n)$ 不受波束权重变化影响；代价是线性 AEC 的计算与状态量随麦克风数 M 增加（量化见本节算力表）。当波束权重持续变化且计算资源允许时，这是优先评估的结构；
2. **BF→AEC（波束后单 AEC）：**线性 AEC 从每个麦克风一路减少为波束输出的一路；实际节省量还要扣除波束处理和共享计算。波束权重 $\vec{w}(t)$ 变化时，等效回声路径 $h_{\text{eff}}(t) = \sum_m w_m(t) * h_m$ 也会变化，AEC 需要跟踪新路径，暂态可能出现回声泄漏。暂时保持波束权重可以减小该变化，但会降低追踪灵活性；
3. **联合优化（GEIC，广义回声与干扰对消，Generalized Echo and Interference Canceller）：**Herbordt 与 Kellermann 把回声路径与波束权重放进同一个约束优化框架联合求解。在相应模型和目标函数下可得到联合最优解，但实现需要维护更多统计量和滤波系数。经典出处为 Kellermann（ICASSP 1997）与 Springer《Microphone Arrays》（2001）第 13 章。

联合分析：Schwartz et al.（Interspeech 2024）在论文所述的多通道维纳滤波（Multichannel Wiener Filter，MCWF）模型下分析了 AEC 与波束形成的顺序。结论依赖其统计模型和目标函数；实际系统若采用波束后 AEC，需要验证权重变化期间的回声泄漏，也可评估在重收敛期间暂时保持波束权重。[Schwartz et al., Interspeech 2024](#)

边栏：立体声 AEC 的非唯一性问题。 两个扬声器播同源内容（立体声左右声道强相关）时，正常方程奇异：除了真实回声路径，还存在无穷多组解都能拟合当前数据，而这些“伪解”全都依赖远端房间——对端房间一变，回声立刻漏出（Sondhi, Morgan & Hall, *IEEE Signal Processing Letters* 1995）。出路是给两路参考去相关：对每声道加轻微且互不相同的非线性（如半波整流），破坏通道间的完全相关性（Benesty et al., ICASSP 1997）。Benesty et al. 1997 完整选型见 §6.1.10。

立体声非唯一性的数字例子。 若 $x_1 = x_2 = x$ ，真实路径 $h_1 = 0.8$ 、 $h_2 = 0.2$ 与另一组 $h'_1 = 1.3$ 、 $h'_2 = -0.3$ 都产生 $(h_1 + h_2)x = x$ ，仅凭当前参考无法区分。相关系数 $\rho = 0.99$ 时，归一化相关矩阵的特征值为 $1 \pm \rho$ ，条件数约为 199，说明估计对噪声和信号变化很敏感。去相关的目标是改善条件数，但改善程度仍应由实际节目内容和处理强度测量。

排序理由见本节，参考链路见 §10.1 和图23。波束权重变化会使波束后 AEC 看到的等效路径变化，因此不能只按麦克风数量决定顺序。选型时应同时测量逐通道 AEC 的资源开销，以及波束后 AEC 在权重切换、目标移动和双讲条件下的恢复过程。

多通道计算量手算。 下面只比较能够从本章计数规则复算的乘法量。取 16 kHz、 $L = 2048$ 、PBFDAF 块长 $N = 128$ ，时域 NLMS 每样本按 $3L = 6144$ 次实乘法计；PBFDAF 沿算例 6-2 的同一口径，16 个分区时无约束版约 352 次/样本，逐分区约束版约 864 次/样本。结果不含延迟搜索、双讲检测、残余抑制、内存访问和硬件并行。

算法	单通道本书手算	M 通道关系	仍需实测的资源
时域 NLMS	$6144 \times 16000 \approx 98.3$ MMAC/s	约为 $98.3M$ MMAC/s	指令数、内存带宽、系数与历史缓冲
PBFDAF，无逐分区梯度约束	$352 \times 16000 \approx 5.6$ MMAC/s	约为 $5.6M$ MMAC/s	FFT 实现、功率估计、约束频率与缓冲
PBFDAF，逐分区梯度约束	$864 \times 16000 \approx 13.8$ MMAC/s	约为 $13.8M$ MMAC/s	同上，并计入所有约束变换
FDKF 或神经后滤波	不给固定倍数	由状态维度或模型结构决定	目标实现的算子、线程、内存和实时因子

逐通道线性 AEC 的主要计算量随麦克风数 M 近似线性增长；放在波束后的单通道处理只运行一路，但会面对等效路径随波束权重变化的问题。两种结构应分别在目标实现上测量资源，并检查波束切换期间的回声泄漏。

6.1.8 评测体系与工程验收清单

客观指标与适用边界。 ERLE（echo return loss enhancement，回声返回损失增强）应在远端单讲的同一统计窗口内计算：

$$\text{ERLE} = 10 \log_{10} \frac{\sum_n |y(n)|^2}{\sum_n |e_{\text{echo}}(n)|^2},$$

其中 $y = x * h$ 是进入消除器前的回声分量， e_{echo} 是消除后的回声分量。真实录音通常不能直接分离这两项，测试时可用远端单讲录音，以 AEC 输入和输出功率近似，但背景噪声会给分母设置下限。报告中应注明采样率、统计窗口、是否去除初始收敛段，以及输出是否包含残余抑制。双讲时输出含近端语音，ERLE 不再表示回声衰减，应改用双讲回声和近端语音质量指标。图18、图29和图31来自不同仿真配置，数值不能横向比较。

ERLE 换算。若残余回声能量与输入回声能量之比为 0.0063, ERLE 为 $10\log_{10}(1/0.0063) \approx 22$ dB; 比值为 0.0001 时, ERLE 为 40 dB。双讲段的输出还含近端语音, 不能把总输出能量直接代入 ERLE 分母。

主观与自动感知指标。ERLE 只度量能量衰减, 不能反映残余回声的音色或近端语音损伤。AECMOS (Purin et al., ICASSP 2022) 分别预测回声和其他失真的主观评分, 可用于批量回归测试。[AECMOS](#) 自动感知模型会受到训练域、版本和输入处理影响, 不能替代双盲听测; 报告时应固定模型版本, 并与真人听测和下游任务一起使用。

系统验收的三类结果:

1. **收敛后残余回声:** 在远端单讲稳定期分别报告线性滤波输出和最终输出。前者用于检查路径估计, 后者还包含残余抑制; 两者不能共用一个 ERLE 名称而不说明取点。
2. **重收敛过程:** 规定路径突变方式, 并报告从突变发生到恢复到项目基线的时间及成功比例。§6.1.5 的 DVSS 数字是论文结果, 只能用于复现该论文, 不能用来划分产品的“优”或“可接受”。
3. **双讲期质量:** 同时评估近端语音损伤和残余回声。阈值要绑定具体标准版本、测试序列和目标设备基线; 自动指标可用于固定版本的回归测试, 不能替代真人听测。

§6.1.6~§6.1.8 比较了混合式、端到端和神经卡尔曼方案, 并说明了阵列中的模块顺序和评测口径。线性 ERLE、最终输出质量和近端语音损伤应分别报告; AEC 放在波束形成之后时, 还需验证波束权重变化造成的路径突变。

系统实现与验收 (§6.1.9~§6.1.17)

6.1.9 WebRTC AEC3 的结构与排障

基本系统功能 (图20 (a) 给出对应信号流):

1. **参考—麦克风延迟对齐:** 播放缓冲、采集缓冲和声学传播共同决定总延迟, 其大小应在目标音频路径上测量。若参考与麦克风信号里的回声没有对齐, 滤波器会用部分抽头覆盖纯延迟, 延迟超出覆盖范围时则无法表示完整路径 (抽头点细节见 §6.1.11);
2. **双讲检测 (DTD):** 双讲期的 e 含近端语音, 继续更新会使路径估计偏离; 检测到双讲后冻结或减小更新 (见图 18 (b)、图29和图30 (c));
3. **残余回声抑制 (NLP, 非线性处理器, nonlinear processor):** 扬声器失真、麦克风削波、回声路径时变都是非线性/未建模成分, 线性滤波器减不掉, 需频域再压一道 (工作点设置见 §6.1.13);
4. **舒适噪声 (CNG, 舒适噪声生成, comfort noise generation):** 残余压得太狠会听起来“死寂”, 补一点背景噪声——完全寂静的通话反而让对方以为断线, 且 CNG 的谱电平须与真实底噪匹配, 否则一补就露馅。

图20 AEC 系统管线：从经典自适应结构到现代混合式（示意）




图20 (a) 显示延迟对齐、自适应滤波、NLP 和 CNG 的完整信号流。(b) 显示混合式结构，橙色框表示可采用神经网络残余抑制的部分。

WebRTC AEC3 架构示例。AEC3 的内部模块和参数会随源码版本及构建配置变化，下面只用它说明一种开源实现的分工，不把内部常数当作产品规格：

- **分块流水处理：**采集和参考按内部子块推进。子块大小、采样率转换和缓冲共同决定延迟，需针对所用源码版本实测；
- **Render Buffer：**保存远端参考历史，为延迟估计和路径滤波提供候选数据。所需覆盖范围由播放、采集和传输链路的实测延迟及抖动确定；
- **候选滤波器辅助延迟搜索：**比较不同候选对齐位置的残差，路径或输出设备切换后重新选择候选；
- **refined/coarse 双滤波器：**两组滤波器分别侧重稳定输出和路径变化跟踪，`FilterAnalyzer` 根据对应版本中的判据决定切换；
- **频域抑制器和舒适噪声：**线性部分之后按频带控制残余回声，并在需要时生成与背景相符的舒适噪声。具体增益规则应以所用版本源码和目标设备测试为准。

排障清单（回声消不掉，按顺序查）：

1. **检查参考抽头位置：**优先选择能够覆盖混音、音量、均衡和限幅等已知数字处理的最晚可用参考。若取自应用层原始音源，抽头之后的时变或非线性变换会成为线性滤波器不能稳定表示的残余；抽头点对照见 §6.1.11；
2. **检查延迟估计：**逐步注入已知延迟并记录 ERLE 和路径估计。失配仍在滤波器覆盖范围内时，影响取决于剩余可用抽头和路径能量分布；失配超过滤波器跨度时，滤波器无法覆盖完整路径。图30 (b) 只展示本书仿真的一个越界例子；
3. **检查双讲冻结或步长缩减：**否则近端语音会使路径估计偏离（见图30 (c)）；

4. 比较算法前先排除接口问题：确认参考内容、取点、延迟覆盖、削波和双讲控制，再在同一录音与统计窗口上比较算法。收敛时间和稳态 ERLE 应相对项目基线判断，不使用通用秒数或 dB 阈值。

6.1.10 多参考 AEC 模型与去相关选型

单参考 AEC 假设只有一路播放；立体声外放、双扬声器和多分区播放属于多参考问题。模型是否可辨识取决于参考声道之间的相关性和各条回声路径，不能用固定 ERLE 损失概括。

三种多参考模型：

模型	结构	可辨识性	资源关系	适用条件
独立单声道（dual-mono）	各参考分别运行单参考 AEC，再合成估计回声	参考强相关时仍可能得到不唯一的路径估计	近似随参考路数增加	参考内容近似独立，并已验证合成残差
联合 MISO（多输入单输出，Multiple-Input Single-Output）	多路参考联合估计到一个麦克风的多条路径	仍受参考相关矩阵条件数限制	同时维护多组路径和交叉统计量	单个麦克风接收多路播放回声
MIMO 阵列联合	多参考和多麦克风联合估计，见 GEIC/MWFext	可联合利用跨通道统计量，但仍需满秩激励	随参考数、麦克风数和状态维度增加	需要联合回声与空间干扰处理

参考声道越多，待估参数越多；声道内容越相关，正常方程越接近奇异。去相关用于改善相关矩阵的条件数。

去相关方法对照（以立体声 AEC 为例）：

方法	做法	可能的副作用	验证方法
半波整流（half-wave rectification）	各声道施加不同的轻微非线性	谐波失真、声像变化	同时测参考相关矩阵条件数、远端单讲残余和主观音质
时变相位调制	各声道施加独立的慢变全通相位	瞬态或声像可能变化	在语音与音乐材料上分别盲听，并检查路径跟踪
独立小频移	各声道施加方向或大小不同的微小频移	音乐可能出现拍频或音高扰动	扫描移频量，比较可辨识性与可闻失真
低电平去相关噪声注入	各声道叠加独立、整形后的低电平噪声	底噪升高	按目标播放电平测条件数、底噪和听感

是否启用去相关，应根据目标节目材料在工作频带内的相干函数、相关矩阵条件数和路径估计稳定性判断。确定候选方法后，逐步增加处理强度，并同时复测远端单讲残余、近端单讲失真、双讲质量和主观音质；处理强度的上限由项目听测与任务指标共同决定。

多参考相关性的数字例子。 两路参考的归一化相关系数为 ρ 时，理想化的 2×2 相关矩阵条件数为 $(1 + \rho)/(1 - \rho)$ 。 $\rho = 0.95$ 时条件数为 39， $\rho = 0.6$ 时降为 4。这个计算说明去相关能改善可辨识性，但不能直接换算成固定的 ERLE 增益；实际收益还取决于声道内容、回声路径、去相关失真和估计器。

6.1.11 播放链参考抽头位置及其对 ERLE 的影响

播放链路是一串变换：应用音源 → 混音 → 音效/EQ → AGC/DRC（动态范围控制，dynamic range compression）→ 限幅 → 重采样 → 编解码 → DAC → 功放 → 扬声器。参考抽头越早，抽头之后未反映在参考中的处理越多。固

定线性变换可以并入等效回声路径；时变增益、削波、丢帧和编解码伪影则可能造成难以稳定建模的残余。

抽头点对照表（T1 最早、T5 最晚；实际系统可能只能访问其中一部分）：

抽头点	位置	抽头之后的变换	主要风险	检查方法
T1 应用层原始音源	应用输出	混音、系统音量及全部后处理	参考可能缺少其他应用声音和时变处理	切换音源、通知音和音量，观察参考是否同步变化
T2 混音后、音效前	混音器输出	EQ、AGC/DRC、限幅及后续处理	时变增益或限幅造成失配	分别旁路后处理，比较残余与路径估计
T3 音效后、AGC 前	均衡后	AGC/DRC 增益包络、限幅及后续处理	增益变化和削波未进入参考	扫描播放电平并记录残余、削波和恢复过程
T4 限幅后、编解码前	限幅器输出	重采样、编解码和传输链路	延迟抖动、丢帧或编码伪影	注入已知信号并记录端到端延迟分布和残余
T5 最晚可用数字参考	DAC 前的可访问节点	DAC、功放、扬声器和声学路径	模拟与声学非线性仍不在参考中	作为候选基线，与电压/电流参考及更早抽头对照

在可访问的节点中，通常优先评估包含更多数字处理且时间戳可靠的较晚参考。若音量增益发生在抽头之后，线性区内播放增益变化会等比例改变等效路径增益；收敛时间和 ERLE 变化量需在目标实现上测量。抽头位于时变增益之前时，可以比较包络补偿与改取较晚参考两种方案。无线或外接播放链路还要实测延迟分布、突变和丢帧，并让延迟搜索与缓冲覆盖所需分位数，而不是采用固定抖动范围。

云端无法取得末端参考时，可由端侧完成线性 AEC，云端只做声学回声抑制（AES，acoustic echo suppression）。

6.1.12 测试覆盖与验收矩阵

下面的矩阵用于组织测试，不给出通用认证阈值。若项目受某项通信、车载或主观听测标准约束，应记录标准号、版本、测试序列、设备配置和适用 profile，并直接采用该版本规定的判据。

#	测试项	条件	记录结果	阈值来源
C1	STFE 收敛后线性段 ERLE	远端单讲，排除初始收敛段	均值或分位数、统计窗口、输入与线性输出取点	目标设备线性段基线
C2	STFE 最终输出	与 C1 使用同一录音	最终残余、AECMOS 回声维和听测结果	目标应用的可闻回声要求
C3	初始收敛	规定冷启动状态和播放材料	从播放开始到达到项目基线的时间分布	交互延迟与任务要求
C4	路径突变重收敛	规定移动、遮挡或设备切换动作	恢复时间、成功比例和暂态最大残余	目标场景允许的中断时间
C5	双讲语音质量	规定 SER、说话人和双讲序列	近端质量、内容保持与残余回声	选定标准或项目听测基线
C6	双讲回声泄漏	与 C5 同一批样本	AECMOS 回声维及真人听测	固定模型版本和听测协议
C7	STNE 近端损伤	近端单讲，AEC 开关对照	频谱、客观质量、下游任务与听测差异	旁路基线和允许损伤
C8	沉默期稳定性	覆盖项目最长空闲段并在期间改变路径	系数漂移及重新播放后的恢复过程	最长会话和使用状态

#	测试项	条件	记录结果	阈值来源
C9	非线性播放	覆盖目标播放电平和材料，并含双讲	线性段残余、最终残余和近端损伤	设备声学过载与音质要求
C10	时钟偏移	覆盖实际播放与采集时钟域及最长会话	延迟漂移、重采样状态和残余趋势	时钟规格和最长运行时间
C11	输出切换与丢帧	执行目标系统支持的切换和故障注入	延迟重搜、恢复时间和音频连续性	交互与通话连续性要求
C12	适用的认证指标	按所选标准及 profile 生成条件	标准要求的指标和统计过程	所选标准的明确版本与条款
C13	下游任务	AEC 旁路与启用使用同一批输入	唤醒、识别或通信任务的差异	任务基线与允许退化

发布或产线回归可以从上述矩阵抽取一组稳定测试，但抽样长度、重复次数和验收判据要来自项目的历史分布、器件公差和故障成本，不能从本教程复制固定数值：

#	回归项	快速方法	判定依据
A1	参考内容与取点	查信号图，并改变音源、通知音、音量和后处理	参考包含预期播放内容；未覆盖的处理已有补偿或风险记录
A2	延迟覆盖	读取延迟估计日志，并注入链路抖动和切换	搜索范围与滤波器跨度覆盖目标延迟分布并留有设计余量
A3	STFE 双取点	固定远端单讲样本，分别记录线性段和最终输出	两个取点分别达到对应项目基线，口径见 §6.1.8
A4	双讲	使用固定且版本化的双讲测试集	近端损伤、残余回声和滤波器稳定性均满足项目基线
A5	路径突变	执行可重复的移动、遮挡或切换动作	在规定时间内恢复到项目基线，并报告失败比例
A6	真人听测	按预先定义的样本量、随机化和播放协议盲听	使用所选协议的统计判据，不以单个听众意见代替结果
A7	自动多指标复核	固定模型、软件版本和输入集	只用于回归；阈值由版本基线和人工复核结果确定

6.1.13 AEC 诊断方法与 NLP 工作点

诊断表（按“征兆 → 量测 → 工具 → 判据”排列）：

#	征兆	量测	工具/信号	判断依据
D1	ERLE 低于项目基线	参考与真实播放是否一致	对比参考与实际播放内容；查抽头点	改变音源、音量或后处理时，参考应包含相同变化或有明确补偿
D2	ERLE 不再上升	延迟失配	互相关峰、图30（a）和延迟日志	峰位置应落入滤波器覆盖范围；多峰时检查多路径与周期信号
D3	双讲后恢复慢	自适应控制	DTD 判决、步长和路径失配日志	恢复过程相对同一设备的远端单讲基线无异常停滞

#	征兆	量测	工具/信号	判断依据
D4	ERLE 随播放电平出现平台	非线性占比	多个播放电平的 ERLE 与失真对比	电平降低后残余非线性同步减小，见图31的仿真机制
D5	断续/闷罐/死寂	NLP 过压	旁路 NLP 对比 PESQ/AECMOS Other 维	旁路后语音明显改善 → 回退 NLP
D6	沉默段背景突变	CNG 频谱与电平	沉默段频谱与真实底噪对照	以盲听和频带差异共同调节，不使用统一 dB 阈值
D7	长通话逐渐变差	SRO 累积漂移	覆盖最长目标会话的延迟估计曲线	残余速率差应满足相干性和任务指标要求
D8	切歌或切设备后失效	延迟突变	对齐切换事件的 ERLE 与延迟轨迹	在项目规定时间内恢复，并检查搜窗是否覆盖新路径

D1~D3检查参考、延迟和双讲控制；D4用于判断非线性残余；D5~D6检查近端语音和舒适噪声；D7~D8检查长时漂移和链路切换。

采样率偏移（SRO）。 播放与采集时钟相差 10 ppm 时，16 kHz 下每秒相差 $16000 \times 10^{-5} = 0.16$ 个采样；1 小时累积 576 个采样，即 36 ms。延迟重搜只能重新选择整数或分数延迟，不能消除持续增长的速率差；长通话通常要估计 SRO 并对参考做重采样补偿。若硬件允许，共用时钟可以从源头消除该偏移。

NLP 工作点（NLP = 非线性处理器，nonlinear processor）。NLP 对各频带施加增益；抑制增强时，残余回声可能降低，但近端语音损伤、背景抽动和断续风险会上升。工作点不能只用一个最大抑制深度定义：

调节方向	需要控制的量	同时观察	回退条件
近端保护优先	提高增益地板，减慢或限制双讲期抑制	近端频谱、下游识别、双讲听感	仍有回声时再逐步增强抑制，而不是一次设置固定档位
回声抑制优先	在远端单讲置信度高的频带降低增益	残余回声、音乐噪声和背景连续性	出现近端内容丢失、抽动或背景突变
状态自适应	用远端活动、双讲置信度和残余估计连续控制增益	状态切换时的暂态和恢复时间	置信度不足或切换产生可闻伪影
舒适噪声配合	根据真实底噪估计 CNG 频谱与电平	沉默段的连续性与噪声颜色	CNG 可单独辨认或掩盖近端弱语音

设置时先固定测试集和取点，从旁路 NLP 开始逐步增加抑制，绘制残余回声、近端质量、下游任务和听测结果之间的曲线。增益地板由曲线的折中点和双讲保护要求确定，不存在通用的 -20 dB 下限。

6.1.14 个性化 AEC 的合规检查

pAEC（个性化 AEC，personalized AEC）在 §6.1.6 定义。15~25 s 注册语音和 20 ms 延迟是 2023 届 AEC Challenge 的任务条件；实际产品应根据注册错误率、首帧处理和端到端延迟另定规格。实现时还要检查以下隐私、访问控制与体验问题：

#	检查项	需要明确的设计	不满足的后果
P1	注册数据量与质量	在目标距离、噪声和说话变化下绘制注册数据量与错误率曲线	嵌入不可靠，双讲时误压目标用户
P2	告知与授权	按适用法律和产品政策说明用途、处理位置、保留期与删除方式	用户无法判断数据怎样使用
P3	嵌入存储	明确端侧或云侧位置、访问控制、加密和备份范围	未授权访问或数据范围扩张
P4	首帧可用性	若要求从开头保护目标用户，应在首个处理帧前准备嵌入；延迟计入系统关键路径	开场语音可能未受个性化条件保护
P5	删除与退出	定义删除入口、传播范围、完成时间和退出后的普通 AEC 行为	用户无法撤回个性化处理
P6	低置信度处理	规定无注册、低置信度和多人混淆时的旁路、回退或提示	误抑制非注册说话人或目标用户
P7	共享设备	明确多用户配置、权限、切换和未成年人场景的授权流程	配置串用或家庭成员被误抑制
P8	验收加测	在 C5/C6 基础上加入目标用户、非目标用户及多人双讲组合	普通双讲测试无法覆盖身份条件错误

6.1.15 研究方向

当前研究主要沿四条路线展开：学习自适应步长或卡尔曼统计量、在多通道上联合处理回声与干扰、把声纹条件加入个性化 AEC，以及用感知模型评价残余回声。阅读新工作时要先检查因果性、总延迟、通道数、参考抽头位置、双讲数据构成和指标口径。预印本或挑战赛结果只有在版本、测试集和基线一致时才能比较，因此本章不列无法按这些条件复核的近期性能数字。

图表对照。

图	内容	对应正文	口径提醒
图 27	播放参考、路径估计与相减结构	§6.1.1	顶部 DTD 控制自适应滤波器更新
图 18	(a) 结构 + DTD 开关；(b) NLMS 收敛 + 双讲冻结	§6.1.2	约 22 dB 是短时仿真在纯线性、 $\mu = 0.5$ 条件下的末段数值，不代表性能上限
图 28	(a) $\hat{w}$ 逼近 h ；(b) 失配与 ERLE 的关系；(c) μ 取舍	§6.1.2	$\mu \in (0, 2)$ 只对理想假设，实际范围要用目标信号和双讲场景验证
图 19	(a) 线性与非线性路径对比；(b) 算法时间线	§6.1.4、 §6.1.6	约 37 dB 与 19~20 dB 只适用于该图的仿真配置
图 20	(a) 系统信号流；(b) 混合结构	§6.1.9、 §6.1.6	橙色模块表示可选的学习型残余抑制
图 29	三路均方根包络与远端单讲 ERLE	§6.1.2 末、 §6.1.5	双讲区不绘制 ERLE，因为残差含近端语音
图 30	(a) 互相关峰约 331 采样；(b) 对齐约 28 dB、不对齐约 2 dB；(c) 冻结与继续更新	§6.1.9、 §6.1.5	延迟 300 个采样超过 128 抽头滤波器跨度，因此不对齐时差异较大
图 31	(a) 线性与 tanh 非线性路径；(b) tanh 映射	§6.1.4	后段均值约 34 dB 和 18 dB，只描述图中参数
图 32	(a) 混合处理流程；(b) 模块前提；(c) 选型条件	§6.1.6、 §6.1.3	不给固定性能档次，需按目标设备实测

6.1.16 常见误区与自测题

常见误区：参考抽头过早；双讲段仍计算 ERLE；双讲时加大步长；静音时继续更新；把 AEC 固定放在时变波束之后；靠增加线性抽头处理扬声器非线性；只看自动分数而不听双讲语音。各项对应的模型和检查方法见 §6.1.4、§6.1.5、§6.1.7、§6.1.8 和 §6.1.11。

自测题（答案要点见 §6.1 对应小节）：

- 默写三项模型并说出每个符号的含义。
- 换算 16 kHz 下 64 ms 与 128 ms 对应的抽头数。
- 在播放链路上标出抽头点 T1–T5，并说明怎样用参考完整性、延迟和残余测量选择抽头。
- 手推 LMS 到 NLMS 的归一化三步。
- 复算算例 6–1，验证残差关系 $e' \approx (1 - \mu)e$ 。
- 说出步长 μ 的大小取舍，并设计目标信号上的扫描方法。
- 已知残余能量比 0.0063 与 0.0001，分别算出 ERLE。
- 解释 Geigel 阈值 0.5 对应 6 dB 的来源。
- 对着图31 说清非线性平台从哪来。
- 按算例 6–2 的计数规则比较时域 NLMS、无约束 PBFDAF 和逐分区约束 PBFDAF。
- 在 SER=–20 dB 下算一笔减法与乘法的账。
- 为 A3、A4 和 A6 分别写出测试输入、取点、统计量与项目阈值来源。

13. 说清双讲冻结与连续小步长的取舍。
14. 对三种阵列方案各说一句选型话。
15. 画出 AEC3 示例中的参考缓冲、延迟估计、自适应滤波、残余抑制与舒适噪声关系。
16. 说出客观 ERLE、主观 MOS 和自动 AECMOS 各自评价什么，并说明双讲时为什么不能用 ERLE。

6.1.17 延伸阅读

1. Hänsler & Schmidt, *Acoustic Echo and Noise Control* (Wiley 2004) ——AEC 领域的经典大部头，从自适应理论到免提终端工程全覆盖。[Wiley 在线版](#)
2. Benesty, Gansler, Morgan, Sondhi & Gay, *Advances in Network and Acoustic Echo Cancellation* (Springer 2001) ——PBFDAF、IPNLMS、立体声 AEC 的原始出处合集（读 IPNLMS 认符号 α ，读 PBFDAF 注意 MDF 一脉）。
3. Enzner et al., *Acoustic Echo Control* (Elsevier 2014) ——IEEE SPM 经典综述的扩展版，卡尔曼路线讲得最透。
4. Breining et al., IEEE SPM 1999——四大难点的经典出处，一节一引，入门必读（链接见 §6.1.1）。
5. 中文参考：《语音识别服务实战》第 3.4 节，侧重工程实现。

§6.1.9~§6.1.17讨论了 AEC3 的信号流、多参考相关性、参考抽头、验收、诊断、个性化处理和研究方向。部署时应先确认参考信号与延迟对齐，再检查自适应控制和残余抑制。

第 7 章讨论 WPE 去混响，第 8 章讨论多说话人分离。



[回首页](#)

第 7 章 · 去混响 (WPE)

第 6 章处理设备播放声返回麦克风形成的回声。本章讨论房间混响的晚期拖尾及 WPE 去混响。多说话人分离、掩码估计和完整处理顺序见第 8 章。

7.1 WPE 去混响

AEC 处理已知播放参考产生的回声，WPE 则利用语音跨帧预测结构估计晚期混响。它保留直达声和早期反射，只减去延迟若干帧之后的可预测成分。

去混响有三条常见路线：**波束形成**（第 5 章，利用空间选择性压低弥散混响）、**盲逆滤波或线性预测**，以及神经网络谱增强。本节重点介绍加权预测误差法（weighted prediction error，WPE）。WPE 既指它采用的加权预测误差准则，也常用来指基于该准则的去混响算法。

WPE 之前的三类方法。多通道逆滤波、倒谱分离和谱方差抑制分别依赖已知路径、倒谱域可分性或晚期混响功率估计。它们的假设和局限有助于理解 WPE 的设计。

MINT 多通道逆滤波（Multiple-input/output INverse Theorem, Miyoshi & Kaneda 1988）。它假设房间冲激响应（Room Impulse Response, RIR）已知，且各通道传递函数没有公共零点，再用有限脉冲响应（Finite Impulse Response, FIR）逆滤波器抵消房间响应。条件满足时可作为理想逆滤波的参考，但它对 RIR 估计误差、公共零点和加性噪声敏感，滤波器长度也随混响时间增加。因此实际系统很少依赖预先精确测得的 RIR。

倒谱 liftering。这类单通道方法假设声门激励与声道、房间响应在倒谱域占据不同区域。对数功率谱经逆傅里叶变换进入倒谱域后，用窗函数保留指定倒谱区间。计算量较低，但重混响和强谐波会使两类成分重叠，窗口选择不当会同时间损伤语音。

谱方差抑制。该方法假设晚期混响与直达声统计独立，并从历史帧递推晚期混响功率谱，再用维纳增益或谱减法抑制。它可以按帧因果运行，但会受到功率估计滞后、非平稳噪声和音乐噪声影响。现代学习型谱增强仍沿用“估计干扰功率或增益，再施加频带增益”的基本形式。

MINT 说明已知房间响应时的逆滤波条件；倒谱方法说明单通道频谱分解的局限；谱方差方法提供了逐帧功率估计与增益抑制思路。WPE 不要求预先测量 RIR，并可扩展到多通道，同时通过保护延迟只预测晚期成分。

三路线对照表。不同论文使用的阵列、数据集、识别器和因果条件不同，不能把词错率改善幅度横向拼成统一范围。表中只比较处理对象与实现条件；需要性能数字时，应引用同一数据集上的原始实验。

路线	代表	主要处理对象	所需输入或假设	因果性与计算	主要限制
空间选择	最小方差无失真响应 (MVDR)、广义特征值 (GEV) 波束形成，见第 5 章	弥散混响与定向干扰	多通道信号，以及目标方向或掩码	可按帧流式处理；计算随通道数和频点数增加	混响占优且方向线索弱时，空间选择性有限
延迟预测	WPE、在线 WPE	可由历史帧预测的晚期混响	短时傅里叶变换 (STFT) 复谱、保护延迟与足够统计量	批处理版迭代整段数据；在线版递推统计量	短语音、模型失配或预测阶数过大时不稳定

路线	代表	主要处理对象	所需输入或假设	因果性与计算	主要限制
谱增益估计	深度神经网络（DNN）去混响、谱方差抑制	全带混响，也可联合处理噪声	训练数据或可靠的晚期混响功率估计	是否因果取决于网络前瞻与特征窗；计算量依模型而定	跨房间、跨设备泛化和语音失真需单独验证

长混响可先评估 WPE；存在定向干扰时再结合波束形成；学习型后滤波还需满足算力和训练数据条件。多通道 WPE、波束形成与单通道后滤波可以组成一条候选链路，但实际顺序取决于统计量和通道数，见第 10 章 §10.1。

REVERB 挑战赛中的 WPE：REVERB 包含 8 通道、2 通道和单通道设置，仿真数据的混响时间约为 0.25~0.7 s，另含真实房间录音。Kinoshita 等在 *Computer Speech & Language* 2016 的总结表明，WPE 对远场识别的改善与通道数和数据条件有关；引用结果时必须注明通道数与测试集。图21（b）中音节结束后的横向能量拖尾，在（c）中得到减弱。

WPE 的直觉：晚期混响是当前帧之前若干帧的“回声叠加”，统计上近似平稳——**可以用过去的观测把拖尾预测出来，然后减掉**。为了不让算法把直达声也“预测掉”，预测时故意跳过最近的 $\Delta - 1$ 帧（保护直达声与早期反射）。

WPE 的预测式只引用当前帧之前的观测，这使它可以改造成流式算法。但经典批处理 WPE 会用整段录音反复估计滤波器和时变功率，仍然是非因果处理。只有把统计量、滤波器和功率估计都改为只使用当前及历史数据，并计入 STFT 分帧带来的等待时间，才能称为因果在线 WPE。保护延迟 Δ 用来隔开当前帧与预测历史，避免把直达声和早期反射当成可预测拖尾一并减去。

模型（每个频点 f 独立处理；本节 X 、 E 、 G 都是逐时频点的复数标量，多通道版才升级为向量）：

$$X(n, f) = \underbrace{E(n, f)}_{\text{直达+早期}} + \sum_{k=\Delta}^{\Delta+K-1} G^*(k, f) X(n - k, f)$$

。

该式把当前观测分成早期成分 E 和由历史帧线性预测的晚期成分。不同频点的混响衰减不同，因此每个频点分别估计一组 G ，实现时可并行计算。 Δ 将当前帧与预测历史隔开，避免使用最近几帧预测直达声和早期反射。其中：

- $X(n, f)$ ：第 n 帧、频点 f 的观测谱（拿到的数据）； $E(n, f)$ ：想恢复的干净早期成分；
- $G(k, f)$ ：预测滤波器系数（混响拖尾的规律，要求的东西）； Δ ：保护延迟（典型 2~3 帧，即跳过最近 $\Delta - 1$ 帧、求和的 k 从 Δ 起算，以保护直达声与早期反射）， K ：预测阶数（覆盖混响尾巴，典型 8~20 帧）。




图24 使用与 `nara_wpe` 一致的索引： $\Delta = 3$ 、 $K = 5$ 时，受保护而不参与预测的是 $t - 1$ 、 $t - 2$ ；五个预测帧依次为 $t - 3$ 到 $t - 7$ 。统一写成

$$\hat{r}(t) = \sum_{q=0}^{K-1} G_q^* X(t - \Delta - q).$$

因此 $q = 0$ 对应 $t - \Delta$ ，不是保护区的一部分。该预测式只含历史样本；批处理还是在线处理，则取决于 G_q 和功率统计是否使用未来帧。

算例 7-1：WPE 的一步直觉数值例（单通道、单频点）

WPE 用历史观测预测晚期混响，再从当前帧中减去预测值。完整算法要交替估计系数 G 和时变功率；本例将 G 视为已知，只计算一次预测与相减。

取单通道、单频点、预测阶数 $K = 2$ 、保护延迟 $\Delta = 2$ 。预测使用第 $n - 2$ 、 $n - 3$ 帧，跳过最近的第 $n - 1$ 帧。已知：

- 过去帧观测： $X(n - 2) = 0.8 + 0.1j$ ， $X(n - 3) = 0.5 - 0.2j$ （都是复数标量，实部虚部分别携带该时频点的幅度与相位信息）；
- 预测系数： $G(2) = 0.5 + 0.1j$ ， $G(3) = 0.3 - 0.05j$ ；
- 当前帧观测： $X(n) = 0.9 + 0.4j$ 。

用到的唯一工具是复数乘法： $(a + bj)(c + dj) = (ac - bd) + (ad + bc)j$ 。另外注意教程模型里出现的是共轭 G^* （共轭 = 虚部变号），所以 $G^*(2) = 0.5 - 0.1j$ ， $G^*(3) = 0.3 + 0.05j$ 。

第 1 步：用 $n - 2$ 帧预测一份拖尾

$$G^*(2) X(n - 2) = (0.5 - 0.1j)(0.8 + 0.1j)$$

实部 = $ac - bd = 0.5 \times 0.8 - (-0.1) \times 0.1 = 0.40 + 0.01 = 0.41$ ；

虚部 = $ad + bc = 0.5 \times 0.1 + (-0.1) \times 0.8 = 0.05 - 0.08 = -0.03$ 。

所以 $G^*(2) X(n - 2) = 0.41 - 0.03j$ 。

第 2 步：用 $n - 3$ 帧再预测一份拖尾

$$G^*(3) X(n - 3) = (0.3 + 0.05j)(0.5 - 0.2j)$$

实部 = $0.3 \times 0.5 - 0.05 \times (-0.2) = 0.15 + 0.01 = 0.16$ ；

虚部 = $0.3 \times (-0.2) + 0.05 \times 0.5 = -0.06 + 0.025 = -0.035$ 。

所以 $G^*(3) X(n - 3) = 0.16 - 0.035j$ 。

第 3 步：两份拖尾相加，得到当前帧里“可预测的陈旧成分”

$$\hat{r}(n) = 0.41 - 0.03j + 0.16 - 0.035j = 0.57 - 0.065j$$

这个 $\hat{r}(n)$ 是当前帧晚期混响拖尾的估计。

第 4 步：从当前帧观测中减掉它

$$E(n) = X(n) - \hat{r}(n) = (0.9 + 0.4j) - (0.57 - 0.065j) = 0.33 + 0.465j$$

$E(n) = 0.33 + 0.465j$ 就是去混响后的输出：实部 $0.9 - 0.57 = 0.33$ ，虚部 $0.4 - (-0.065) = 0.465$ 。

观测幅度为 $|X(n)| \approx 0.985$ ，相减后的幅度为 $|E(n)| \approx 0.570$ ；对应能量从约 0.97 降到约 0.325，相差约 4.7 dB。这个数例只检查复数乘法、共轭和帧索引。系数 G 是人为给定的，因此能量下降不能作为去混响效果证据，也不能据此断言剩余量恰好等于直达声与早期反射。真实 WPE 还要从多帧数据估计 G 与功率 $\lambda(n, f)$ ，并用独立的干净参考或识别指标评价失真。

算例 7-2：保护期加宽一帧 ($\Delta = 3$ 、 $K = 2$)

出题：单通道、单频点， $\Delta = 3$ 、 $K = 2$ 。已知过去帧 $X(n-3) = 0.6 + 0.2j$ ， $X(n-4) = 0.4 + 0.3j$ ；系数 $G(3) = 0.4 - 0.2j$ ， $G(4) = 0.2 + 0.1j$ ；当前帧 $X(n) = 1.0 + 0.5j$ 。求去混响输出 $E(n)$ 。

求和下标为 $k = 3, 4$ ，因此使用第 $n-3$ 、 $n-4$ 帧；第 $n-1$ 、 $n-2$ 帧位于保护区，不参与预测。若当前帧 $n = 10$ ，预测使用第 7、6 帧，跳过第 9、8 帧。相较算例 7-1，保护期增加一帧。

手算（先取共轭再乘）： $G^*(3) = 0.4 + 0.2j$ ， $(0.4 + 0.2j)(0.6 + 0.2j)$ 实部 $= 0.4 \times 0.6 - 0.2 \times 0.2 = 0.20$ ，虚部 $= 0.4 \times 0.2 + 0.2 \times 0.6 = 0.20$ ，得 $0.20 + 0.20j$ ； $G^*(4) = 0.2 - 0.1j$ ， $(0.2 - 0.1j)(0.4 + 0.3j)$ 实部 $= 0.2 \times 0.4 + 0.1 \times 0.3 = 0.11$ ，虚部 $= 0.2 \times 0.3 - 0.1 \times 0.4 = 0.02$ ，得 $0.11 + 0.02j$ 。拖尾估计 $\hat{r} = 0.31 + 0.22j$ ，输出 $E = (1.0 - 0.31) + (0.5 - 0.22j) = 0.69 + 0.28j$ 。幅度 $|X| = \sqrt{1.25} \approx 1.118$ ， $|E| = \sqrt{0.4761 + 0.0784} \approx 0.745$ ；能量从 1.25 降到约 0.55，约 3.5 dB。

本例的能量变化约为 3.5 dB，小于算例 7-1 的约 4.7 dB。两组系数为人为设定，差异只能用于说明增加保护期会减少可参与预测的近邻帧，不能作为一般性能结论。 Δ 的选择见 §7.1.1。

交替估计 G 与 λ (Nakatani et al., 2010)。假设早期成分 E 服从零均值复高斯分布，方差 $\lambda(n, f)$ 随时间变化；这里的 λ 表示第 n 帧的功率谱。时变方差使不同能量的语音帧获得不同权重，减少高能量帧对估计的支配。下面在固定频点 f 上写出从最大似然到加权最小二乘的推导。

中间行 1——写出似然：各帧独立，观测 $X(n)$ 在给定 G 、 $\lambda(n)$ 下服从均值为预测值 $\sum_k G^*(k)X(n-k)$ 、方差为 $\lambda(n)$ 的复高斯，总似然是各帧密度连乘：

$$p(X | G, \lambda) = \prod_n \frac{1}{\pi \lambda(n)} \exp \left(-\frac{|X(n) - \sum_k G^*(k)X(n-k)|^2}{\lambda(n)} \right)$$

。

中间行 2——取负对数：最大化似然等价于最小化负对数似然。去掉与 G 无关的常数后，权重 $1/\lambda(n)$ 直接来自高斯密度指数项的分母：

$$-\log p = \sum_n \frac{|X(n) - \sum_k G^*(k)X(n-k)|^2}{\lambda(n)} + \sum_n \log \lambda(n) + \text{const}$$

。

固定 λ 时第二项是常数，最小化第一项就是**加权最小二乘**。

中间行 3——对 G 求导得正规方程： 把历史帧排成向量 $\vec{x}(n) = [X(n - \Delta), \dots, X(n - \Delta - K + 1)]^\top$ ，记 $\vec{g} = [G(\Delta), \dots, G(\Delta + K - 1)]^\top$ ，则求和式可写成 $E(n) = X(n) - \vec{g}^H \vec{x}(n)$ ，其中上标 H 表示共轭转置。对 $\vec{g}^*$ 使用 Wirtinger 导数并令其为零，得到 $K \times K$ 加权正规方程：

$$\underbrace{\left(\sum_n \frac{\vec{x}(n) \vec{x}^H(n)}{\lambda(n)} \right)}_{\text{加权自相关 } R} \vec{g} = \underbrace{\sum_n \frac{\vec{x}(n) X^*(n)}{\lambda(n)}}_{\text{加权互相关 } \vec{r}}, \quad \hat{G} \text{ 即解 } R\vec{g} = \vec{r}$$

。

R 是 $K \times K$ 共轭对称矩阵， K 典型取 5~20 时可用 Cholesky 分解求解。算法交替固定 λ 求 G 、固定 G 更新 λ ；第一次迭代的 λ 常用整段观测能量初始化。在线版通常减少交替次数，并用递推统计量补偿样本不足。

$$\hat{G} = \arg \min_G \sum_n \frac{|X(n, f) - \sum_k G^*(k, f) X(n - k, f)|^2}{\lambda(n, f)}, \quad \lambda(n, f) = |E(n, f)|^2$$

。

固定 G 后，对 $\lambda(n) > 0$ 求导：

$$\frac{\partial}{\partial \lambda(n)} \left(\frac{|E(n)|^2}{\lambda(n)} + \log \lambda(n) \right) = -\frac{|E(n)|^2}{\lambda^2(n)} + \frac{1}{\lambda(n)}.$$

令导数为零得到 $\hat{\lambda}(n) = |E(n)|^2$ 。实际实现通常会在频率或时间上平滑并设置正数下限，避免单个近零残差造成权重过大。

算例 7-3：加权最小二乘求解器的手算（单抽头 $K = 1$ 、3 帧）

取单频点、 $K = 1$ ，只估计一个抽头 $g = G(\Delta)$ 。3 帧观测为 $X = [1.0, 0.6, 0.2]$ ，历史样本为 $x = [0.8, 0.5, 0.4]$ ，权重 $w(n) = 1/\lambda(n) = [1, 4, 1]$ 。为简化运算，本例使用实数。求闭式解 $\hat{g}$ 。

标量正规方程为 $Rg = r$ ，其中 $R = \sum wx^2$ 、 $r = \sum wxX$ 。代入可得 $R = 1 \times 0.64 + 4 \times 0.25 + 1 \times 0.16 = 1.80$ ， $r = 1 \times 0.8 \times 1.0 + 4 \times 0.5 \times 0.6 + 1 \times 0.4 \times 0.2 = 2.08$ ，因此 $\hat{g} = 2.08/1.80 \approx 1.156$ 。该人为数例中的 $\hat{g}$ 大于 1，不代表一般路径系数范围。若所有权重都为 1，则 $R = 1.05$ 、 $r = 1.18$ 、 $\hat{g} \approx 1.124$ 。较大的第二帧权重使估计更接近该帧对应的比值。 $K > 1$ 时，同样的加权关系写成矩阵正规方程。

多通道版（MIMO-WPE, Yoshioka & Nakatani 2012）： 预测第 m 个通道的当前帧时，使用所有 M 个通道的历史帧：

$$X_m(n, f) = E_m(n, f) + \sum_{m'=1}^M \sum_{k=\Delta}^{\Delta+K-1} G_{m,m'}^*(k, f) X_{m'}(n - k, f)$$

。

G 相应扩展为 $M \times M$ 的矩阵滤波器。晚期混响会同时出现在多个麦克风上，但幅度和相位不同；多通道观测因此提供额外空间信息。相对收益取决于混响、阵列和数据长度，具体数字应查 Yoshioka 2012 的实验条件。开源 `nara_wpe` 实现了这种 MIMO-WPE 形式。

图21 WPE 去混响效果（单通道数值演示： $T_{60}=0.6$ s, DRR=6 dB, $\Delta=6$ 帧, $K=10$ ）




图21的横轴约为 0~1400 ms，纵轴约为 0~2.5 kHz，颜色表示相对能量的 dB 值。(a) 给出无混响参考；(b) 加入合成混响后，音节结束处出现横向拖尾；(c) 经本书单通道 WPE 示例处理后，拖尾减弱，但仍有残留。该图用于观察同一示例的前后差异，不代表公开数据集上的平均性能。

与其他模块的组合：WPE 先减弱晚期混响，掩码 MVDR 再抑制噪声与定向干扰。Drude et al. (Interspeech 2018) 在其测试条件下报告了联合系统相对单模块的改善。WPE → GSS → MVDR/GEV 也可不使用神经分离网络，见第 8 章。Raj et al. (Interspeech 2023) 的 GPU 实现报告约 300 倍加速；引用时应注明其硬件、数据和基线。开源实现 `nara_wpe` 可直接调用，在线形式见下段。[Interspeech 2018 论文](#)、[在线 WPE](#)

在线版分为按块更新和逐帧递推两类。块在线 WPE 在最近一段历史上估计统计量；递推 WPE 用遗忘因子逐帧更新相关矩阵和滤波器。短块提供的有效样本较少， λ 和相关矩阵的方差更大；块过长又会增加等待时间，并使旧房间统计占比过高。在线实现还要处理初始化、矩阵正则化、静音冻结和路径突变，不能只把批处理迭代次数改成 1。DNN-WPE 可以用网络估计 λ ，但是否优于传统估计取决于训练数据与测试房间是否匹配。

帧移为 8 ms 时，0.25 s 约含 31 帧，2 s 含 250 帧。这个换算可以用来估计统计样本量和块等待时间，但不能单独决定参数。起始值应在目标数据上同时检查拖尾衰减、语音失真、计算量和端到端延迟，再调整块长、遗忘因子、预测阶数和正则化强度。

开源实现 `nara_wpe` (MIMO-WPE 的事实标准实现，PyPI 包 `nara_wpe`，算法基线 Yoshioka & Nakatani 2012)，最小可复制调用三行：

```
pip install nara_wpe # 含离线迭代 / 块在线 / 帧递推三版实现
```

```
from nara_wpe.wpe import wpe
Z = wpe(Y, taps=10, delay=3, # taps=K (预测阶数), delay=Δ (保护延迟)
        iterations=3)      # 交替迭代次数，离线取 3，在线可减到 1
```

其中 Y 是复数 STFT（后两轴为通道 D 、帧 T ，其余前轴为频点等多维，0.0.11 版 `help(wpe)` 原话是 `(..., D, T)`；大版本轴序可能变，用前先看一眼 `help`）；多通道就是把所有通道一起传进去，包内自动走 MIMO-WPE；块在线/帧在线见包内在线模块与示例 notebook。

DNN 与 WPE 的位置。神经网络可以预测干净复谱、时频掩码或 WPE 所需的功率 λ 。若网络对每个通道独立做波形或复谱映射，它可能改变跨通道相位关系；这类网络通常放在多通道 WPE 和波束形成之后。若网络只估计共享掩码、空间协方差或 λ ，而多通道复谱仍由解析滤波器处理，则网络可以放在 WPE 或波束形成内部。还有联合训练的多通道模型同时完成去混响与波束形成。模块位置应由输入输出是否保留空间相位、是否使用未来帧和训练目标决定，不能简单规定所有 DNN 都在链尾。

局限与处理办法：WPE 只去除晚期混响，不处理直达声与早期反射。下列条件会使估计不稳定或收益有限：

场景	现象	对策
短语音（1~2 s 以内）	二阶统计估不准，迭代把误差放大	块在线加遗忘因子，或 DNN 直接给 λ
弱混响/高信噪比（T60 小于约 0.2 s、近讲）	拖尾本来就小，减法主要减出失真	先测混响时间/直混比，弱混响直接 bypass
强加性噪声	模型里没有噪声项， G 与 λ 被污染	前/后加 DNN 去噪，或 WPD 联合（WPE 加 MPDR，Fujita et al., APSIPA 2024）
大间距分布式阵列	统一 Δ 让参考与预测仍相关，输出失真	麦克风相关延迟：按到达时延给各通道定各自延迟（Lohmann et al., ICASSP 2023）

启用 WPE 前应检查可用帧数、混响强度、加性噪声和通道时延。任一条件不满足时，应调整块长、模型或旁路策略。

7.1.1 Δ 与 K 的参数起点

以下换算采用 16 kHz、32 ms 窗和 8 ms 帧移。保护时间用于保留直达声和早期反射， Δ 约等于保护时间除以帧移；预测窗口覆盖需要建模的晚期拖尾， K 约等于覆盖时间除以帧移。帧移改变时，应按物理时间同比调整 Δ 和 K 。增加麦克风数可能减少达到同等估计稳定性所需的 K ，但仍需在目标阵列上验证。

房间/混响时间	帧移 8 ms（标准）	帧移 16 ms（省算力）	说明
小房间/办公室，T60 不超过 0.3 s	$\Delta = 2\sim3$, $K = 5\sim10$, 迭代 2~3	$\Delta = 1\sim2$, $K = 3\sim5$	尾巴短， K 小就够，贪大反过拟合
会议室/教室，T60 约 0.3~0.7 s	$\Delta = 3$, $K = 10$, 迭代 3	$\Delta = 2$, $K = 5\sim8$	最稳的一档，先跑这组再调
大厅/报告厅，T60 约 0.7~1.0 s	$\Delta = 3\sim4$, $K = 12\sim16$, 迭代 3~5	$\Delta = 2$, $K = 6\sim8$	尾巴长 K 跟上，建议配 DNN 估计功率谱
礼堂/教堂，T60 超过 1 s	$\Delta = 4$, $K = 15\sim20$, 迭代 3~5 加 DNN 先验	$\Delta = 2\sim3$, $K = 8\sim10$ 加 DNN 先验	纯 WPE 回报递减，需结合目标数据验证
分布式大间距阵列	在上表基础上用麦克风相关延迟（Lohmann et al., ICASSP 2023：按到达时延补偿后定各通道延迟）	同左	大间距下统一延迟会失真

Δ 应覆盖需要保留的早期反射， K 应覆盖主要晚期拖尾。增大 K 会增加计算量和过拟合风险。算力不足时可先减少交替迭代次数，再缩短 K ；改变 Δ 前应先检查直达声和早期反射是否受到损伤。

换算数字例子（把“T60 → 毫秒 → 帧数”走一遍）：设会议室 $T_{60} = 0.6$ s、标准 STFT（16 kHz，帧移 8 ms）。① Δ ：要保住直达加早期反射约 30~50 ms，取保护 24 ms → $\Delta = 24/8 = 3$ ，即预测窗从 $t - 3$ 起算（跳过 $t - 1$ 、 $t - 2$ ，正是图24 画的那档）。② K ：0.6 s 的尾巴不可能全覆盖——200 ms 之后的尾巴又弱又不可预报，硬加抽头只涨误差不涨擦除；取覆盖约 80 ms → $K = 80/8 = 10$ （预测窗 $t - 3$ 到 $t - 12$ 共 10 帧）。从当前帧算起最远回溯 $\Delta + K = 13$ 帧 ≈ 104 ms——注意 104 ms 含 24 ms 保护期，真正擦除的是 80 ms。这 104 ms 就是选型表里“会议室档 $\Delta = 3$ 、 $K = 10$ ”的来历。③ 换帧移：如果为了省算力把帧移放大到 16 ms，物理时间不变， $\Delta = 24/16 \approx 1\sim2$ 、 $K = 80/16 = 5$ ，与表中 16 ms 列对上。④ 换房间：小办公室 $T_{60} = 0.25$ s，尾巴短，

$K = 5$ (40 ms) 就够, 贪大到 15 只会过拟合; 大厅 $T_{60} = 0.9$ s, 把 K 加到 12~16 (约 100~130 ms) 再往上就配 DNN 估计 λ , 纯加抽头回报递减。

7.1.2 常见错误与练习

五项常见错误: ① 取 $\Delta = 0$, 使预测器同时减去直达声; ② 无条件增大 K , 导致数据不足时过拟合; ③ 用 WPE 处理本应保留的早期反射; ④ 把 WPE 当作加性噪声抑制器, 忽略模型中没有独立噪声项; ⑤ 在弱混响条件下仍强制启用 WPE。对应的检查量分别是早期语音损伤、有效样本数、直混比、噪声强度和混响时间。

练习 7-1 (自测九题)

1. 默写单通道 WPE 模型并解释 Δ 、 K 。(要点: $X = E + \sum G^* X$; Δ 保护延迟, K 预测阶数)
2. $\Delta = 2$ 、 $K = 2$ 、 $n = 10$ 时用哪几帧、跳过哪几帧? (要点: 用第 8、7 帧; 跳过第 9 帧)
3. 复算算例 7-1 第 1 步的复数乘法。(要点: $(0.5 - 0.1j)(0.8 + 0.1j) = 0.41 - 0.03j$)
4. 独立完成算例 7-2 并算出 dB 数。(要点: $E = 0.69 + 0.28j$; 能量约 1.25→0.55, 约 3.5 dB)
5. 写出最大似然交替的两步, 并写出固定 λ 时的正规方程 $R\vec{g} = \vec{r}$ 。(要点: 固定 λ 加权最小二乘解 G ; 固定 G 用 $\lambda = |E|^2$; 2~5 次收敛; R 、 $\vec{r}$ 为 λ 加权的自/互相关)
6. 手算算例 7-3, 并解释权重如何改变估计。(要点: $\hat{g} \approx 1.156$; 第 2 帧权重较大, 因此对结果影响更大)
7. $T_{60}=0.6$ s、帧移 8 ms, 给出 Δ/K 起点并说理由。(要点: $\Delta = 3$ 、 $K = 10$; 会议室档默认起点; 保护约 24 ms、覆盖约 80 ms 拖尾)
8. 说出在线版相对离线版打折的两处来源与对策。(要点: 短块 λ 不准; 老 G 过时; 对策是 DNN 估计功率谱、遗忘因子)
9. 神经网络可以放在 WPE 前、后或内部吗? (要点: 独立改写各通道复谱的网络通常放在多通道处理之后; 只估计共享掩码、协方差或 λ 的网络可以放在解析算法内部; 还要检查是否使用未来帧)

7.1.3 研究方向

WPE 的改进主要围绕四个限制展开: 分布式阵列需要按通道到达时延调整预测延迟; 麦克风很多时需要参考通道或子集选择; 短块和强噪声下需要更稳健的功率估计; 系统级方法尝试把去混响与波束形成联合求解。神经网络可以为这些解析结构估计功率、掩码或先验, 但比较结果时要对齐数据集、通道数、因果性和延迟。本章不列无法按这些条件复核的近期性能数字。

参数设置应先保证直达声和早期反射不受损, 再根据晚期拖尾长度选择 K 。弱混响时可以旁路 WPE。多说话人分离见第 8 章。

第 8 章 · 语音分离

第 7 章讨论单个声源的混响拖尾，本章讨论多个说话人同时发声时的混合与分离。主要方法包括免训练盲源分离（Blind Source Separation, BSS）、导引源分离（Guided Source Separation, GSS）和深度分离；§8.2再说明这些方法在前端系统中的顺序。

8.1 多说话人语音分离：鸡尾酒会问题

去混响处理单个声源的时间拖尾，语音分离处理多个声源在同一观测中的叠加。本节依次介绍免训练 BSS、GSS 和深度分离。时频掩码既可用于分离，也可用于 §5.4 的空间协方差估计。

卷积混合模型。第 m 个麦克风接收各说话人经过相应房间冲激响应后的叠加，再加上噪声：

$$x_m(t) = \sum_{n=1}^N \sum_{\tau} h_{mn}(\tau) s_n(t - \tau) + v_m(t)$$

h_{mn} 是第 n 个声源到第 m 个麦克风的房间冲激响应， s_n 是第 n 个源信号。源数 N 与麦克风数 M 要分三种情况： $N = M$ 是确定混合， $N < M$ 是超定混合， $N > M$ 是欠定混合。方阵解混的辅助函数型独立向量分析（AuxIVA）和独立低秩矩阵分析（ILRMA）通常要求确定混合；超定情形可以先降维或使用相应扩展；欠定情形还需要稀疏性、空间协方差等额外结构。多通道非负矩阵分解（MNMF）能表示欠定混合，但能否可靠分离仍取决于源数、数据长度、初始化和模型匹配。

短时傅里叶变换（STFT）常把卷积近似为每个频点上的瞬时混合：

$$X_m(f, k) \approx \sum_{n=1}^N A_{mn}(f) S_n(f, k) + V_m(f, k)$$

其中 k 是帧号， $A_{mn}(f)$ 是 h_{mn} 在频率 f 处的近似频响。写成向量形式为 $\mathbf{X}(f, k) = \mathbf{A}(f)\mathbf{S}(f, k) + \mathbf{V}(f, k)$ ，三者维度依次为 $M \times 1$ 、 $M \times N$ 和 $N \times 1$ 。这个窄带近似要求分析窗相对通道冲激响应的有效长度足够长，并且源与通道在窗内变化不快。 T_{60} 不能单独给出一个“超过多少就失效”的通用阈值；窗长、早晚期能量分布、帧移和允许误差都会影响近似质量。

远场平面波条件下， $\mathbf{A}$ 的每一列对应一个导向矢量（steering vector），表示给定方向在各麦克风上的相位差：

$$\mathbf{a}(f, \theta) = [1, e^{-j2\pi f d \sin \theta / c}, e^{-j2\pi f 2d \sin \theta / c}, \dots, e^{-j2\pi f (M-1)d \sin \theta / c}]^T$$

例如麦间距 $d = 4$ cm、声速 $c = 343$ m/s、目标方向 $\theta = 30^\circ$ 。在 $f = 2$ kHz 时，相邻麦克风时延差 $\Delta t = d \sin \theta / c \approx 58.3 \mu\text{s}$ ，相位差为 $2\pi f \Delta t \approx 0.733$ rad，即约 42° 。4 麦阵列的导向矢量约为 $[1, e^{-j42^\circ}, e^{-j84^\circ}, e^{-j126^\circ}]^T$ 。频率升到 4 kHz 时，相位差增至约 84° 。2 kHz 的波长约 17 cm，4 cm 间距小于半波长；8 kHz 的波长约 4.3 cm，此间距会产生空间混叠和栅瓣。

最小方差无失真响应（MVDR）、广义特征值（GEV）波束形成、MNMF 和复角中心高斯混合模型（complex Angular Central Gaussian Mixture Model, cACGMM）都会使用二阶统计量：

$$\mathbf{R}(f, k) = E[\mathbf{X}\mathbf{X}^H] \approx \mathbf{A}\mathbf{R}_s\mathbf{A}^H + \mathbf{R}_v$$

。其中 $\mathbf{R}_s$ 是源信号协方差， $\mathbf{R}_v$ 是噪声协方差。BSS 直接估计解混矩阵；GSS 和部分深度方法先估计时频掩码，再由掩码计算目标与干扰协方差，做法见 §5.4。

波束形成一次输出通常针对一个目标，但可以用不同导向或掩码构造多组权重，分别输出多个人的信号。因此“波束形成”和“语音分离”不是互斥方法：GSS 正是先估掩码，再为每个目标计算一组波束权重。下面按解混矩阵、空间聚类 and 监督学习三条路线比较。

路线	代表	思想	局限
经典盲源分离 BSS（盲源分离，blind source separation）	ICA（独立成分分析，independent component analysis） / IVA（独立向量分析，independent vector analysis）	假设各说话人统计独立，找一组解混矩阵让输出互相独立；IVA 用“同一声源跨频点相关”解决逐频点排列混乱（置换问题）	需要源数 $\leq$ 麦数附近、对混响敏感
空间混合模型（免训练）	cACGMM $\rightarrow$ GSS	见下文展开	依赖较长的上下文，计算量大（GPU 加速版见第 7 章 §7.1.3）
深度学习分离	时频掩码估计、deep clustering（深度聚类：把每个时频点映射成嵌入向量再按说话人聚类）、PIT（置换不变训练，permutation invariant training：对输出与参考说话人的所有对应关系分别计算损失，取最小者反向传播）、Conv-TasNet（全卷积时域分离网络）	直接学习从混合信号到各声源的映射	依赖训练数据，跨场景泛化需验证

四类经典 BSS 方法。以下按模型假设、计算代价和失效条件比较 AuxIVA、ILRMA、MNMF 与 TRINICON。

AuxIVA（辅助函数型独立向量分析，Auxiliary-function IVA，Ono 2011）。它假设不同说话人统计独立，并联合建模同一说话人在各频点的分量。频域 ICA 在各频点独立求解，可能得到不同的输出排列；IVA 利用跨频点包络相关性缓解该置换问题。AuxIVA 使用辅助函数进行闭式更新，不需要设置梯度步长，目标函数在理论条件下单调下降。标准实现仍是整段迭代，在线版本需要递推改写；强混响、说话人包络高度相关和短语音都会削弱统计独立性或估计稳定性。它常作为免训练分离基线。

ILRMA（独立低秩矩阵分析，Independent Low-rank Matrix Analysis）。ILRMA 在独立性假设之外，再用非负矩阵分解（NMF）表示每个源的低秩功率谱，并联合优化解混矩阵与谱模型。它增加了基数、迭代次数等超参数，计算量和初始化敏感性也高于 AuxIVA。复杂音乐、重叠笑声和强混响可能不满足低秩或独立性假设，需用目标数据验证。

MNMF（多通道 NMF，Multichannel NMF）。MNMF 同样使用低秩源谱模型，但以满秩空间协方差描述传播，不要求方阵解混矩阵可逆，因此可以表示欠定混合。谱基、激活和空间协方差需要联合做最大似然估计，参数较多、迭代较慢且对初值敏感。实践中可用 AuxIVA 或 ILRMA 结果初始化。其计算量通常更适合离线分析或伪标签生成。

TRINICON（三重 N 卷积混合盲分离，TRiple-N ICA for CONvolutive mixtures）直接优化时域解混滤波器，用二阶自相关和高阶独立性处理卷积混合，因此不依赖逐频点瞬时混合近似。代价是滤波器与统计窗口较长、优化量大，声源或房间变化时还要重新适应。滤波器长度决定能表示多长的卷积逆，但不等于端到端延迟：因果 FIR 可逐样本输出，块实现的额外等待由分块、缓冲、FFT 和是否使用未来样本决定。

AuxIVA 适合确定混合的免训练基线；ILRMA 进一步利用源谱低秩结构；MNMF 用满秩空间协方差表示欠定混合；TRINICON 直接处理时域卷积混合。选择时需同时检查源数与麦克风数、混响强度、数据长度和实时预算。

BSS 方法的规模例子。以下计算用于说明参数量和迭代规模；性能数字必须以各论文的测试集和评测脚本为准。

AuxIVA 的规模例子：2 源 2 麦、8 kHz、3 s 语音，STFT 取 256 点窗和 64 点帧移。每秒有 125 帧，3 s 共 375 帧，非负频点数为 129。每个频点维护一个 2×2 解混矩阵，共 516 个复数参数。辅助函数迭代不需要学习率。无混响确定混合与混响条件下的 SI-SDRi 不能直接沿用同一数值，引用时应回到原论文的具体表格。算法见 [AuxIVA 原始论文](#) (Ono, WASPAA 2011；公开实现见 [pyIVA](#))。

ILRMA 在同一 2 源 2 麦例子中，还要为每个源维护 NMF 基矩阵和激活矩阵。若每源取 2 个基，则矩阵尺寸分别为 129×2 和 2×375 ，并与解混矩阵交替更新。基数、迭代次数和初值都会影响计算量与结果。语音与音乐是否满足同样的低秩假设，需要分别验证。见 [ILRMA 原始论文](#) (Kitamura et al., TASLP 2016)。

MNMF 可以表示 3 个说话人、2 个麦克风的欠定混合。每个频点、每个源对应一个 2×2 Hermitian 空间协方差；129 个频点和 3 个源共需 387 个协方差矩阵，还要联合估计谱基和激活。计算量和局部最优问题使初始化十分重要，AuxIVA 或 ILRMA 结果可作为初值。见 [MNMF 综述与原始工作](#) (Sawada et al., 2013 起系列工作)。

TRINICON 的长度换算可以这样看：8 kHz 下，0.5 s 对应 4000 个采样，但这不表示解混滤波器必须取 4000 点，也不表示算法延迟就是 0.5 s。实际长度是在可表示的卷积范围、估计方差、计算量和块实现之间折中。例如 1024 点与 2048 点分别覆盖 128 ms 和 256 ms 的滤波器记忆；系统仍要单独报告块大小、帧移、前视和输入输出缓冲，才能得到算法延迟。见 [TRINICON 原始论文](#) (Buchner et al., 2005)。

GSS (导引源分离, guided source separation) 在 CHiME-5/6 的真实晚宴多通道任务中得到广泛使用

(Boeddeker et al., CHiME-5 2018；CHiME-8 任务设置已经变化，引用时应按当届规则)：1. **cACGMM (复角中心高斯混合模型, complex angular central Gaussian mixture model)** **空间聚类**：把多通道观测向量归一化为 $\mathbf{z} = \mathbf{X} / \|\mathbf{X}\|_2$ ，主要保留通道间的复数比例。第 n 个分量的密度满足

$$p(\mathbf{z} | \mathbf{B}_n) \propto \frac{1}{\det(\mathbf{B}_n)} (\mathbf{z}^H \mathbf{B}_n^{-1} \mathbf{z})^{-M},$$

其中 $\mathbf{B}_n$ 是正定的形状矩阵，整体尺度需要固定，因为 cACG 分布对尺度不敏感。混合模型的后验概率 $\gamma_n(f, k)$ 用作软时频掩码。“免训练”只表示聚类参数在当前录音上用 EM 估计，不需要预先训练分离网络；说话人活动标注仍可来自监督模型。2. **导引 (Guided)**：各频点独立聚类会产生簇标签置换。GSS 使用**说话人活动时间标注**

(diarization 输出) 限制每个说话人可出现的帧，从而统一不同频点的簇标签；3. **级联**：WPE 去混响 → GSS 得到掩码 → 掩码估计目标/噪声协方差 → MVDR/GEV 波束形成。MVDR 是最小方差无失真响应，GEV 是广义特征值波束形成，见 §5.4。GSS 论文在 CHiME-5 的特定阵列和打分集上，相对延时求和基线报告了约 10~21% 的前端 WER 相对降低；引用时应注明原文表格和打分集。[GSS 原始论文](#) (GPU 加速版见 §7.1.3)

GSS 的计算规模：输入通常是一段包含重叠语音的会议录音。WPE 先减弱晚期混响；cACGMM 在目标段附近的上下文上做 EM 聚类，为每个时频点输出说话人后验掩码；目标和非目标掩码分别用于估计空间协方差，再计算 MVDR 或 GEV 权重。上下文长度和 EM 迭代次数会共同影响估计方差、延迟与计算量。Raj et al. (Interspeech 2023) 通过频点和分段批量并行报告了约 300 倍 GPU 加速，具体实时性应按原文硬件与数据条件解释。

以 16 kHz 采样、512 点窗、128 点帧移为例，每秒有 125 帧，30 s 上下文含 3750 帧和 257 个非负频点，约 96 万个时频点。这个换算只给出待处理样本数，不能保证 EM 在固定次数内收敛。实现应监测对数似然相对变化，并设置最大迭代次数；空分量、近奇异 $\mathbf{B}_n$ 和低能量时频点还需要正则化或重置。

掩码换成目标协方差时，用

$$\mathbf{R}_{\text{tar}}(f) = \frac{\sum_k \gamma(f, k) \mathbf{X}(f, k) \mathbf{X}^H(f, k)}{\sum_k \gamma(f, k) + \varepsilon}.$$

噪声协方差可用相应的非目标掩码估计。软权重的有效样本数不是“ $\gamma > 0.8$ 的帧数”，而可用 Kish 公式近似：

$$N_{\text{eff}}(f) = \frac{(\sum_k \gamma(f, k))^2}{\sum_k \gamma^2(f, k)}.$$

例如 900 帧权重全为 1 时 $N_{\text{eff}} = 900$ ；若权重集中在少数帧，有效样本数会明显更小。估计 $M \times M$ 协方差不仅需要样本数大于矩阵维度，还要覆盖足够多的独立空间状态；高度相关的连续帧不能当作同等数量的独立快照。工程上应检查 N_{eff} 、矩阵条件数，并在必要时做对角加载。说话人活动标注用于限制各簇可出现的时间区间，从而减少跨频点置换。见 [cACGMM 原始工作](#) (Ito et al., TASLP 2016) 与 [GSS 原始论文](#)。

定位结果可以给分离提供方向先验；分离网络输出的掩码又能用于估计 MVDR 的目标与干扰协方差。常用的尺度不变信号失真比 (scale-invariant signal-to-distortion ratio, SI-SDR) 先把估计信号 $\hat{s}$ 投影到参考 s 上： $s_{\text{tar}} = \langle \hat{s}, s \rangle s / \|s\|^2$ ，再计算 $10 \log_{10}(\|s_{\text{tar}}\|^2 / \|\hat{s} - s_{\text{tar}}\|^2)$ 。SI-SDR 提升量 (SI-SDRi) 是输出 SI-SDR 减去混合输入的 SI-SDR，两项必须使用同一预处理和实现。

数据集口径表（本章数字的出处，引用时须补版本与打分集）：去混响与分离的论文数字口径乱，不先对齐数据集，降幅百分比没有意义。

数据集	考什么	房间/混响口径	通道/采样口径	怎么用
REVE RB 挑战赛	去混响（含识别端 WER）	仿真三档混响时间约 0.25 / 0.5 / 0.7 s；另有真实房间录音（MC-WSJ-AV 基）	8 通道 / 2 通道 / 单通道三种设置；基线语音来自 WSJCAM0	比较 WPE 时必须注明通道数。示例：8 通道 WER 相对降低约 20~30%，单通道约 10%（约数，以 Kinoshita 等总结论文表格为准）
CHiME-5/6	真实晚宴多说话人（分离 + 识别端 WER）	真实家庭：厨房、餐厅、客厅多房间自然混响加生活噪声	每处多台 Kinect 6 麦阵列（共用参考 binaural 打分）；重叠率高、说话人走动	GSS 使用整段上下文与 diarization 导引；报告数字必须注明阵列配置与打分集。示例：相对延时求和基线，前端 WER 相对降低约 10~21%（以 GSS 原文为准）
WHA MR	噪声 + 混响 + 重叠三合一	合成房间冲激响应，混响时间约 0.1~1 s（大/中/小三档房间混搭）	8 kHz；min 版（截短对齐）/ max 版（全长）两版；底子是 WSJ0-2mix 加 WHAM 噪声	用于训练和评价深度分离；报告数字必须注明 min/max 与采样率。三类污染下 SI-SDRi 常为个位数 dB 量级，具体值见原文表格
WSJ0-2mix / 3mix	干净重叠两/三人	无噪声、无混响（近场干声直接叠加）	8 kHz / 16 kHz；min 版（按最短截断）/ max 版（全长补零）；30 小时训练 / 10 小时验证 / 5 小时测试	表中四个约数统一按 8 kHz、min、SI-SNRi 口径列出；引用时还应注明静态或动态混合
LibriMix	干净或含噪声重叠（WSJ0 的开源替代）	clean 版无污染；noisy 版叠加 WHAM 环境噪声	16 kHz；train-100/train-360 两档训练量；另有稀疏重叠测试集	用于检查跨数据集泛化。跨集下降 2~4 dB 只是原文条件下的量级，必须同时注明训练集和测试集。见 LibriMix

REVERB 主要用于去混响与识别，CHiME-5/6 用于真实重叠语音的分离与识别，WHAMR 同时包含噪声、混响和重叠，WSJ0-2mix/3mix 是干净混合基准，LibriMix 还可检查跨数据集泛化。不同数据集的数字不能直接比较。

深度分离为什么可行：语音在时频域是稀疏的——两个人同时说话时，同一个时频点通常只有一个人占优（文献称近似 W-不重叠正交性，W-disjoint orthogonality, WDO）。于是分离问题近似退化为“把每个时频点分类归属给某个人”，这正是掩码类方法有效的根源，也是它与传统波束形成（对整个频带做统一加权）的本质区别。此处不给数字，只记结论：重叠越重假设越崩。

深度分离四代（Conv-TasNet → DPRNN → SepFormer → TF-GridNet；WSJ0-2mix 口径一次对齐，引用时以原文表位与是否动态混合为准）。

代	代表	主要结构	WSJ0-2mix（8 kHz min 版，SI-SNRi 约数）	优点与限制
时域 卷积 代	Conv-TasNet（预印本 2018，正式发表 Luo & Mesgarani, 2019）	可学习的短窗编码器代替 STFT，TCN 空洞卷积建模长上下文，再对编码系数施加掩码	约 15.3 dB，首次超过理想幅度掩码	直接在波形域分离，延迟可降到毫秒量级；超长语句会超出有限感受野。见 Conv-TasNet
双路 径循 环代	DPRNN（预印本 2019，正式发表 Luo et al., 2020）	长序列分块，块内 RNN 建模局部，块间 RNN 建模较长时间关系	约 18.8 dB，模型比上一代小一个量级	参数量较小；RNN 并行度有限，超长语句还会受到块间状态容量限制。见 DPRNN
注意 力代	SepFormer（预印本 2020，正式发表 Subakan et al., 2021）	在双路径结构中用 Transformer 替换 RNN	约 22.3 dB（WSJ0-3mix 约 19.5 dB）	训练并行度较高；注意力内存随序列长度增长，长句仍需分块。见 SepFormer
时频 网格 代	TF-GridNet（预印本 2022，正式发表 Wang et al., 2023）	在时频域分别建模时间、频率与跨帧关系，并结合子带 LSTM 和注意力	约 23.5 dB SI-SDRi	同时使用时间与频率结构，计算量较高；整句注意力需要改造后才能流式运行。见 TF-GridNet

比较分离数字时要对齐采样率、min / max 混合方式、静态或动态混合、源数、评测脚本和指标名称。分离文献中的 SI-SNR 常采用与 SI-SDR 相同的正交投影公式，二者在相同去均值与数值实现下可以相等；也有代码把均值处理、截断长度或稳定项写得不同。不能笼统地说两者固定相差若干 dB。引用 SI-SNRi 或 SI-SDRi 时，应给出实现或至少说明是否去均值，并始终用同一指标计算输入基线和输出结果。

深度分离的结构选择。卷积、循环网络、注意力和状态空间模型都可以作为分离骨干。选择时不要只看单个榜单分数，还要检查模型是否使用整句上下文、块边界如何处理、状态能否在流式推理中延续，以及计算量和内存怎样随语句长度变化。生成式方法还要检查采样步数和语音幻觉。近期模型若没有在相同数据、采样率、混合方式和评测脚本下比较，本章不按论文年份或模型名称给出性能排序。

目标说话人提取（target speaker extraction, TSE）不要求输出所有声源，而是用注册语音、说话人活动标注或文本查询指定目标。注册条件可以在编码器入口拼接、通过逐层缩放与偏置调制，或由交叉注意力读取。无论采用哪种结构，都要在目标设备上验证注册信道失配、非目标泄漏、目标误抑制和首帧延迟。

TSE 嵌入的注入与帧对齐。注册语音经过声纹网络得到定长嵌入，可在编码器入口拼接，也可通过逐层缩放与偏置调制（FiLM）或交叉注意力作为分离条件。嵌入需要广播到混合语音的每一帧，并在首帧处理前加载。§6.1.6 的 pAEC 也使用声纹条件，但其输出目标是在消除回声的同时保留注册用户。声纹嵌入的端侧存储、加密和删除要求见 §6.1.14。

TSE 条件如何与帧对齐。声纹网络把注册语音变成定长嵌入，再把同一个嵌入广播到混合语音的每一帧。16 kHz、128 点帧移时，每秒有 125 帧，这个换算与嵌入维度无关。嵌入维度、注册时长和余弦阈值都由具体声纹模型及训练数据决定，不能给出跨模型通用的“同人区间”。产品标定应覆盖近讲注册、远场使用、噪声、混响和声线变化，并分

别报告目标误拒和非目标误接。见 [SpeakerBeam/TSE 系列](#) (Žmolíková et al. 起) 与 [CLAP](#) (Elizalde et al., 2022)。

练习 8-1 (自测三题)

- 1. 说明 WDO 假设及其失效条件。(要点：同一时频点通常只有一个人占优；重叠越重，近似越差)
- 2. GSS 三步顺序是什么？(要点：WPE 去混响 → cACGMM 聚类得掩码 → 掩码换协方差喂 MVDR/GEV)
- 3. 掩码换协方差要写哪两个矩阵？(要点：目标协方差 R_{target} 与噪声协方差，分别用掩码 γ 与 $1-\gamma$ 加权平均)

8.2 处理模块的顺序

回声、混响和多说话人混合对应不同的信号模型。以下顺序由参考可用性、空间相位保持和统计量依赖关系决定，接口定义见 §10.1。

一种较完整的参考链见 [第 10 章 §10.1](#)：**AEC → WPE → 定位/追踪 → 波束形成 → 单通道增强**。项目只启用满足输入条件且能改善目标指标的模块。说话人日志和 GSS 掩码不是独立音频处理框，而是波束形成的外部控制或统计量输入。各模块采用这一相对位置的原因如下：

- 1. **启用 AEC 时先处理回声**：回声参考与麦克风回声之间的线性关系可能被后续自适应波束、非线性增益或单通道增强改变，见 [第 10 章 §10.1](#)；
- 2. **WPE 紧随、且在波束之前**：晚期混响会污染波束形成所需的协方差估计。WPE 是线性多通道处理，在正确实现下保留通道间相位关系；
- 3. **定位/追踪给波束指方向**：MVDR/GEV 要目标方向或掩码才能成形，先有方向、再有波束（见 [第 5 章](#)与 [第 9 章](#)）；
- 4. **diarization 在 GSS 聚类之前、掩码在 MVDR 之前**：diarization 提供“谁在何时说话”的标注，用于约束 cACGMM 的跨频点置换；掩码随后用于估计目标和噪声协方差，再计算波束权重（见 §5.4 和 §8.1）；
- 5. **DNN 的位置由输出决定**：逐通道改写复谱或波形的网络可能破坏跨通道相位，通常放在波束形成后的单通道链路；只输出共享掩码、协方差或 WPE 功率先验的网络可以放在多通道算法内部；联合多通道网络则可能同时完成分离和波束形成。还要单独检查网络是否使用未来帧。

默认链路把逐通道线性处理放在前面，把单通道增强放在波束形成之后。若神经网络只估计解析算法所需的统计量，或本身联合建模多通道相位，则不受这个默认顺序限制。

本章模块与图 23 的对应关系（图的信号取点与启用条件见 [第 10 章 §10.1](#)）：

本章模块	图 23 中的位置	作用
diarization / GSS（说话人日志给时间标注，cACGMM 聚类得掩码）	波束形成的外部活动标注与掩码输入	diarization 约束跨频点置换，掩码用于估计目标和噪声协方差，见 §5.4
DNN 后滤波 / DNN 后端	波束形成后的单通道增强或后端	独立改写复谱的网络通常放在多通道 WPE/MVDR 之后，以免破坏空间相位
NS / AGC / VAD / KWS	单通道增强与可选 KWS 旁路；VAD 属控制面	各模块按目标任务启用，不在本章展开

回声、混响和分离使用不同的参考与统计假设，模块顺序需要服从这些条件。下一章讨论如何把逐帧定位结果连接成连续轨迹。

第 9 章 · 声源追踪

9.1 问题与声学特殊性

声源追踪持续估计运动声源状态 $\vec{s}_t = [\theta_t, \dot{\theta}_t, \ddot{\theta}_t]^\top$ ，其中三项分别为角度、角速度和角加速度。它把含噪且可能间断的逐帧定位结果融合成连续轨迹，再为波束形成提供较平滑的指向。LOCATA 声源定位与追踪挑战数据集包含运动说话人录音和光学动捕真值，可用于比较本章方法，入口见 §10.6。

声学追踪有四个特点：说话人停顿会造成间歇观测，需要语音活动检测（Voice Activity Detection, VAD）门控和轨迹维持；混响会产生非高斯误差和野点；声源数会随时间变化；到达方向（Direction of Arrival, DOA）与笛卡尔位置之间是非线性关系。若状态为平面位置与速度 $[x, y, \dot{x}, \dot{y}]$ ，阵列中心为 (x_0, y_0) ，则观测函数为 $\theta = \text{atan2}(y - y_0, x - x_0)$ 。扩展卡尔曼滤波（Extended Kalman Filter, EKF）用该函数的雅可比做一阶线性化，无迹卡尔曼滤波（Unscented Kalman Filter, UKF）则传播 $2L + 1$ 个 sigma 点；此处 $L = 4$ ，需要 9 个点。近距离或跨越阵列正上方时非线性更强，应比较 UKF、粒子滤波或其他非线性方法，而不是直接套用线性卡尔曼滤波（Kalman Filter, KF）。

9.2 单目标追踪

状态模型写为 $\vec{s}_t = \mathbf{F}\vec{s}_{t-1} + \vec{v}_t$ ，其中 $\mathbf{F}$ 描述匀速或匀加速运动， $\vec{v}_t$ 是未建模运动造成的过程噪声。若定位器只输出角度，观测模型为 $\theta_t^{obs} = \mathbf{H}\vec{s}_t + w_t$ ， w_t 是观测噪声。三维状态时 $\mathbf{H} = [1, 0, 0]$ ；下文二维简化状态 $[\theta, \dot{\theta}]^\top$ 使用 $\mathbf{H} = [1, 0]$ 。

贝叶斯递推包含预测和更新。预测阶段依据运动模型外推状态，并增加因过程噪声带来的不确定度；更新阶段用观测与预测之差，即新息，修正状态和协方差。在线性高斯假设下，卡尔曼滤波给出这两个阶段的闭式递推。

卡尔曼滤波（KF）的五步递推（状态取 [角度, 角速度]）：1. **预测**： $\hat{\vec{s}}_t^- = \mathbf{F}\hat{\vec{s}}_{t-1}^-$ ——“他上一帧以这个速度在走，这帧大概到这儿”；2. **预测的不确定度**： $\mathbf{P}_t^- = \mathbf{F}\mathbf{P}_{t-1}^-\mathbf{F}^\top + \mathbf{Q}$ ——不确定度只会随时间增大， $\mathbf{Q}$ 是过程噪声协方差（“目标多爱乱动”）；3. **计算卡尔曼增益**： $\mathbf{K}_t = \mathbf{P}_t^-\mathbf{H}^\top(\mathbf{H}\mathbf{P}_t^-\mathbf{H}^\top + \mathbf{R})^{-1}$ ，其中 $\mathbf{R}$ 是观测噪声协方差。观测噪声较小时增益增大，更新更依赖观测；预测协方差较小时增益减小，更新更依赖运动模型；4. **更新**： $\hat{\vec{s}}_t = \hat{\vec{s}}_t^- + \mathbf{K}_t(\theta_t^{obs} - \mathbf{H}\hat{\vec{s}}_t^-)$ ——括号里的差叫**新息**（innovation，观测与预测之差），用增益加权的新息修正预测；5. **更新的不确定度**： $\mathbf{P}_t = (\mathbf{I} - \mathbf{K}_t\mathbf{H})\mathbf{P}_t^-$ ——每吸收一次观测，不确定度就降一截。

算例 9-1：卡尔曼滤波单步数值例（跟住一个正在转头的说话人）

下面用一组数值执行完整递推。状态向量取 §9.1 三维状态的二维简化版 $\vec{s} = [\theta, \dot{\theta}]^\top$ ，单位分别为度和度/帧。该模型省略加速度，适合运动较平缓的示例；频繁机动时可改用含加速度的模型或后文的 IMM。已知：

- 上一帧估计： $\hat{\vec{s}}_{t-1} = [30, 0.5]^\top$ （目标在 30° ，每帧向右走 0.5° ）；
- 上一帧不确定度： $\mathbf{P}_{t-1} = \begin{bmatrix} 4 & 0 \\ 0 & 0.25 \end{bmatrix}$ （角度方差 4°^2 ，即标准差 2° ；角速度方差 0.25）；
- 状态转移矩阵（匀速模型）： $\mathbf{F} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ （“新角度 = 旧角度 + 1 帧 × 角速度，角速度不变”的矩阵写法）；

- 过程噪声： $\mathbf{Q} = \begin{bmatrix} 0.1 & 0 \\ 0 & 0.01 \end{bmatrix}$ （“目标其实会乱动”的程度， $\mathbf{Q}$ 越大滤波器越不敢信自己的预测）；
- 观测矩阵： $\mathbf{H} = [1, 0]$ （DOA 算法只报角度，不报角速度）；
- 本帧观测： $\theta_t^{obs} = 32^\circ$ ；观测噪声 $\mathbf{R} = 25$ （标准差 5° ，反映单帧 DOA 估计相当粗糙）。

第 1 步：预测 $\hat{\mathbf{s}}_t^- = \mathbf{F}\hat{\mathbf{s}}_{t-1}$

$$\hat{\mathbf{s}}_t^- = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 30 \\ 0.5 \end{bmatrix} = \begin{bmatrix} 1 \times 30 + 1 \times 0.5 \\ 0 \times 30 + 1 \times 0.5 \end{bmatrix} = \begin{bmatrix} 30.5 \\ 0.5 \end{bmatrix}$$

“他上一帧在 30° 、每帧走 0.5° ，这帧大概到 30.5° 。”

第 2 步：预测的不确定度 $\mathbf{P}_t^- = \mathbf{F}\mathbf{P}_{t-1}\mathbf{F}^\top + \mathbf{Q}$

先算 $\mathbf{F}\mathbf{P}_{t-1} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 0.25 \end{bmatrix} = \begin{bmatrix} 4 & 0.25 \\ 0 & 0.25 \end{bmatrix}$ （第一行： $1 \times 4 + 1 \times 0 = 4$ ， $1 \times 0 + 1 \times 0.25 = 0.25$ ；第二行照算）。

再乘 $\mathbf{F}^\top = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$ ：

$$\mathbf{F}\mathbf{P}_{t-1}\mathbf{F}^\top = \begin{bmatrix} 4 & 0.25 \\ 0 & 0.25 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 4 \times 1 + 0.25 \times 1 & 4 \times 0 + 0.25 \times 1 \\ 0 \times 1 + 0.25 \times 1 & 0 \times 0 + 0.25 \times 1 \end{bmatrix} = \begin{bmatrix} 4.25 & 0.25 \\ 0.25 & 0.25 \end{bmatrix}$$

左上角从 4 增加到 4.25，因为角速度的不确定度会在预测后传播到角度。再加上 $\mathbf{Q}$ ：

$$\mathbf{P}_t^- = \begin{bmatrix} 4.25 & 0.25 \\ 0.25 & 0.25 \end{bmatrix} + \begin{bmatrix} 0.1 & 0 \\ 0 & 0.01 \end{bmatrix} = \begin{bmatrix} 4.35 & 0.25 \\ 0.25 & 0.26 \end{bmatrix}$$

即预测的角度不确定度为标准差 $\sqrt{4.35} \approx 2.09^\circ$ 。

第 3 步：卡尔曼增益 $\mathbf{K}_t = \mathbf{P}_t^- \mathbf{H}^\top (\mathbf{H}\mathbf{P}_t^- \mathbf{H}^\top + \mathbf{R})^{-1}$

$\mathbf{H}\mathbf{P}_t^- \mathbf{H}^\top$ 只是取出 $\mathbf{P}_t^-$ 的左上角元素 4.35（因为 $\mathbf{H} = [1, 0]$ 起到“挑出角度分量”的作用），于是分母是标量：

$$\mathbf{H}\mathbf{P}_t^- \mathbf{H}^\top + \mathbf{R} = 4.35 + 25 = 29.35$$

分子 $\mathbf{P}_t^- \mathbf{H}^\top = \begin{bmatrix} 4.35 & 0.25 \\ 0.25 & 0.26 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 4.35 \\ 0.25 \end{bmatrix}$ （取 $\mathbf{P}_t^-$ 的第一列）。

$$\mathbf{K}_t = \frac{1}{29.35} \begin{bmatrix} 4.35 \\ 0.25 \end{bmatrix} = \begin{bmatrix} 0.148 \\ 0.0085 \end{bmatrix} \quad (\text{已修约: } 0.1482 \rightarrow 0.148, 0.00852 \rightarrow 0.0085)$$

增益是 2×1 向量： $K_1 = 0.148$ （角度分量信观测的比例）、 $K_2 = 0.0085$ （角速度分量分到的一点残差信息——观测虽只报角度，但角度残差里也藏着“速度估偏了”的线索）。

$K_1 \approx 0.148$ 表示角度更新量取新息的约 14.8%。观测噪声方差 25 大于预测角度方差 4.35，因此估计更接近预测值。若 $\mathbf{R}$ 减小， K_1 会增大，观测对更新的影响也会增加。

第 4 步：更新 $\hat{\mathbf{s}}_t = \hat{\mathbf{s}}_t^- + \mathbf{K}_t(\theta_t^{obs} - \mathbf{H}\hat{\mathbf{s}}_t^-)$

新息（innovation，观测与预测之差）为 $\theta_t^{obs} - \mathbf{H}\hat{\mathbf{s}}_t^- = 32 - 30.5 = 1.5^\circ$ 。

$$\hat{\mathbf{s}}_t = \begin{bmatrix} 30.5 \\ 0.5 \end{bmatrix} + \begin{bmatrix} 0.148 \\ 0.0085 \end{bmatrix} \times 1.5 = \begin{bmatrix} 30.5 + 0.222 \\ 0.5 + 0.0128 \end{bmatrix} = \begin{bmatrix} 30.72 \\ 0.513 \end{bmatrix}$$

角度由预测值向观测值修正约 0.22°，角速度更新为 0.513°/帧。最终角度 30.72° 位于预测值 30.5° 与观测值 32° 之间，并因 K_1 较小而更接近预测值。

第 5 步：更新的不确定度 $\mathbf{P}_t = (\mathbf{I} - \mathbf{K}_t \mathbf{H}) \mathbf{P}_t^-$

先算 $\mathbf{K}_t \mathbf{H} = \begin{bmatrix} 0.148 \\ 0.0085 \end{bmatrix} [1, 0] = \begin{bmatrix} 0.148 & 0 \\ 0.0085 & 0 \end{bmatrix}$ ，于是

$$\mathbf{I} - \mathbf{K}_t \mathbf{H} = \begin{bmatrix} 1 - 0.148 & 0 \\ -0.0085 & 1 \end{bmatrix} = \begin{bmatrix} 0.852 & 0 \\ -0.0085 & 1 \end{bmatrix}$$

$$\mathbf{P}_t = \begin{bmatrix} 0.852 & 0 \\ -0.0085 & 1 \end{bmatrix} \begin{bmatrix} 4.35 & 0.25 \\ 0.25 & 0.26 \end{bmatrix} = \begin{bmatrix} 3.705 & 0.213 \\ 0.213 & 0.258 \end{bmatrix}$$

(第一行： $0.852 \times 4.35 = 3.705$ ， $0.852 \times 0.25 = 0.213$ ；第二行： $-0.0085 \times 4.35 + 1 \times 0.25 = 0.213$ ， $-0.0085 \times 0.25 + 1 \times 0.26 = 0.258$ 。)

角度方差从 4.35 降到 3.71（标准差约 1.93°）——每吸收一次观测，不确定度就降一截。若下一帧说话人停顿没有观测，就只做第 1、2 步： $\mathbf{P}$ 重新涨大，波束指向维持外推，这就是“静默保持” (§9.4)。

算例 9-1 说明了单步卡尔曼递推。下表比较常见单目标追踪方法的假设、计算量和适用条件。

表中 α - β 滤波器说的“免 Riccati 迭代”，指的就是把第 2、3、5 步的不确定度递推（Riccati 方程）换成固定增益。

方法	原理	优点	缺点	适用
滑动平均/中值/直方图众数	对 DOA 序列低通	极简、零假设	延迟大、跟不上机动、多源混杂	早期音箱近似
α - β / α - β - γ	稳态增益卡尔曼	免 Riccati 迭代	增益非最优	嵌入式
卡尔曼滤波 KF	高斯线性最优贝叶斯递推（预测+新息加权更新）	最优（线性高斯）、 $O(d^3)$ 且 d 只有 2~3，计算量可忽略	抗野点差、需调 Q/R	观测质量好时首选
EKF（扩展卡尔曼滤波）/UKF（无迹卡尔曼滤波）	一阶线性化/无迹变换处理非线性	位置↔角度非线性可处理	EKF 易发散、UKF 需传播约 $2L+1$ 个 sigma 点	分布式阵列位置级追踪
IMM 交互多模型	静止/匀速/加速等多个运动模型并行跑 KF，按各自似然动态加权融合	机动与静止通吃、无需预知运动模式	计算为单 KF 的数倍、需调模型间转移概率	说话人“停一走一停”的机动场景
粒子滤波 (PF) /SIR	带权粒子近似后验；预测、加权、按需重采样	能表示非线性、非高斯和多峰后验	鲁棒性取决于似然与杂波模型；会权重退化和样本贫化	观测多峰或运动模型明显非线性

IMM 的转移概率和各模型过程噪声需要用目标运动数据标定。对角占优的转移矩阵表示运动模式通常会持续多帧，但具体数值不能脱离帧率和语料直接照搬。

IMM 的模型切换：IMM 并行运行静止、匀速或加速等运动模型，再根据各模型的新息似然更新权重。它适合包含启动、停止和匀速段的轨迹。两模型例子可使用静止与匀速模型；转移矩阵的对角元素表示保持当前运动模式的概率。0.95 或 0.9 只能作为示例，实际数值必须结合帧率和目标运动数据估计。

EKF 与 UKF：EKF 对 $\theta = \text{atan2}(y - y_0, x - x_0)$ 求雅可比，并在当前估计附近做一阶线性化；估计偏离真实状态较大时，线性化误差可能导致发散。UKF 不显式求导，而是将 $2L + 1$ 个 sigma 点通过原始非线性观测函数，再重构均值与协方差，计算量通常高于 EKF。

算例 9-2：10 个粒子的一轮加权与重采样

卡尔曼滤波用均值和协方差表示单峰高斯后验。**粒子滤波**（particle filter, PF）用 N 个带权样本近似后验，可以表达偏斜或多峰分布。它并不会自动抵抗观测野点：若似然模型把野点当成高置信观测，粒子权重仍会被错误观测拉偏。鲁棒性来自观测门控、重尾似然或“目标加均匀杂波”的混合似然。下面用 10 个粒子演示加权与重采样。

设本帧 10 个粒子的角度猜测（单位：度）为：

$$x_1, \dots, x_{10} = [25, 27, 28, 30, 30, 31, 32, 33, 35, 40]$$

本帧观测 $\theta^{obs} = 31^\circ$ ，观测噪声标准差 $\sigma = 5^\circ$ （方差 $\sigma^2 = 25$ ）。

第 1 步：根据观测似然计算权重

每个粒子的权重用高斯似然：离观测越近分越高，

$$w_i = \exp\left(-\frac{(x_i - \theta^{obs})^2}{2\sigma^2}\right) = \exp\left(-\frac{(x_i - 31)^2}{50}\right)$$

逐个计算（ $(x_i - 31)^2$ 先列出来）：

粒子 x_i	$(x_i - 31)^2$	$w_i = \exp(-(x_i - 31)^2/50)$
25	36	$\exp(-0.72) = 0.4868$
27	16	$\exp(-0.32) = 0.7261$
28	9	$\exp(-0.18) = 0.8353$
30	1	$\exp(-0.02) = 0.9802$
30	1	$\exp(-0.02) = 0.9802$
31	0	$\exp(0) = 1.0000$
32	1	$\exp(-0.02) = 0.9802$
33	4	$\exp(-0.08) = 0.9231$
35	16	$\exp(-0.32) = 0.7261$
40	81	$\exp(-1.62) = 0.1979$

权重和

$= 0.4868 + 0.7261 + 0.8353 + 0.9802 + 0.9802 + 1.0000 + 0.9802 + 0.9231 + 0.7261 + 0.1979 = 7.8359$ 。

第 2 步：归一化权重

$$\tilde{w}_i = \frac{w_i}{7.8359} \Rightarrow [0.0621, 0.0927, 0.1066, 0.1251, 0.1251, 0.1276, 0.1251, 0.1178, 0.0927, 0.0253]$$

校验：归一化权重之和为 1。 40° 是一个远离当前观测的粒子，不是观测野点；它的权重较小，只说明当前高斯似然会压低不符合观测的候选状态，不能证明粒子滤波对错误观测鲁棒。

第 3 步：计算有效粒子数 N_{eff}

$$N_{eff} = \frac{1}{\sum_{i=1}^{10} \tilde{w}_i^2} = \frac{1}{0.0621^2 + 0.0927^2 + 0.1066^2 + 0.1251^2 + \dots + 0.0253^2} = \frac{1}{0.1101} \approx 9.08$$

若 10 个粒子权重相等， $N_{eff} = 10$ ；若全部权重集中在一个粒子上， $N_{eff} = 1$ ，称为粒子退化。本例得到 9.08。常见实现会在 N_{eff} 低于给定阈值时触发重采样，例如 $N/2$ ；阈值需要结合粒子数和任务验证。

第 4 步：在重采样前计算本帧估计

$$\hat{\theta} = \sum_{i=1}^{10} \tilde{w}_i x_i = 0.0621 \times 25 + 0.0927 \times 27 + 0.1066 \times 28 + 0.1251 \times 30 + \dots + 0.0253 \times 40 \approx 30.65^\circ$$

不加权的平均为 31.1° ，加权估计约为 30.65° 。这个后验均值必须用重采样前的粒子和归一化权重计算。重采样后权重重置为 $1/N$ ，不能把旧权重再乘到新粒子上；重采样后取均值只是在有限样本下近似同一后验。

第 5 步：系统重采样。连续加权会使多数粒子的权重趋近于零。系统重采样按归一化权重重新抽取 10 个粒子，允许高权重粒子重复出现，并把新权重统一重置为 $1/10$ 。先计算累积和

$[0.0621, 0.1548, 0.2614, 0.3865, 0.5116, 0.6392, 0.7643, 0.8821, 0.9747, 1.0000]$ ，再从 $[0, 0.1)$ 取起点 $u_0 = 0.0637$ ，以 0.1 为间隔得到 10 个采样点。对应的新粒子群为：

$$[27, 28, 30, 30, 30, 31, 32, 32, 33, 35]$$

30° 和 32° 的粒子被重复抽取， 25° 和 40° 的粒子未被抽中。重采样是随机过程，不按单个粒子的权重机械排序； 31° 虽有最高单粒子权重，本次仍只保留一份。下一帧先按运动模型传播粒子，再根据新观测重新计算权重。

粒子滤波依次执行状态传播、似然加权、归一化和按需重采样。它能表示多峰后验，但观测野点仍需门控或杂波似然处理。

抗野点技巧包括观测门控、混合似然和辅助粒子滤波（Auxiliary Particle Filter, APF）。门控阈值不能只照搬固定的 3σ ，应结合观测误差分布和漏检代价标定。图22(a) 为序贯重要性重采样粒子滤波（Sequential Importance Resampling Particle Filter, SIR-PF）平滑 DOA 观测的模拟（仿真条件：单目标匀速转弯、每帧 DOA 观测加零均值高斯噪声、混入约 20% 均匀野点，粒子数 200）：灰点是含噪观测，黑线是真实轨迹，红线平滑跟住目标。

图22 声源追踪示意（模拟）




图22 (a) 中，灰点为逐帧 DOA 观测，黑线为真实轨迹，红线为粒子滤波估计。仿真使用匀速转弯、高斯观测噪声、约 20% 均匀野点和 200 个粒子；观测缺失时，轨迹由运动模型短时外推。(b) 在 -25° 和 $+40^\circ$ 附近设置两个强度峰，用于说明多目标强度函数。峰数只能近似用于提取人数，严格定义见 §9.3。

单目标追踪由预测和观测更新组成。线性高斯条件下可使用卡尔曼滤波；非线性、多峰或重尾观测可考虑 UKF 或粒子滤波。粒子滤波仍需门控或杂波似然处理野点，IMM 用于多运动模型切换，VAD 用于控制无观测时的更新。

9.3 多目标追踪

多目标追踪需要同时解决观测与轨迹的**数据关联**，并估计当前的**声源数量**。

方法族	代表	思想	声学表现
数据关联+单目标滤波	JPDA（联合概率数据关联）、MHT（多假设跟踪）	算观测属于各轨迹的概率/假设树	有效但组合爆炸，声学实现重
多目标粒子滤波	Brutti et al. 2010 经典	每目标一簇粒子 + 最近邻分配	2~3 源内有效，源数需先验
随机有限集 (RFS) / PHD 滤波	PHD、CPHD、SMC-PHD	传播目标集合的一阶强度；积分给期望目标数，峰用于提取状态	避免显式枚举关联，但不保留身份；峰提取和参数设置影响结果 Liu et al. 2018
LMB（标记多伯努利） / δ -GLMB	labeled RFS	给目标贴标签、输出带身份轨迹	语音领域新兴（2020+），计算重
track-before-detect	对定位谱直接滤波	不硬切观测，保留弱目标信息	与 DNN 定位谱天然契合
序列神经网络	RNN/Transformer 处理定位后验序列	可学习时间平滑与活动模式	仍需训练数据；是否输出稳定身份取决于标签和损失

LMB/ δ -GLMB 为目标维护标签，可输出带身份的轨迹；检测前追踪直接递推定位谱，保留未越过检测阈值的弱证据。活动耦合笛卡尔 DOA（activity-coupled Cartesian DOA, ACCDOA）把向量方向编码为 DOA、向量长度编码为活动强度。它本身是逐帧声事件定位与检测的输出表示，不等同于追踪器；只有结合时序模型、平滑和身份关联后，才形成轨迹。

PHD 强度 $D_t(x)$ 也不是“某处有人”的普通概率密度。它在区域 A 上的积分表示该区域内目标数的期望，因而总目标数估计来自 $\hat{N}_t = \int D_t(x) dx$ ，再按整数规则取值。目标位置通常从强度峰或聚类中心提取；“峰数就是人数”只

是实现近似。PHD 避免显式枚举观测—目标关联，但只传播一阶矩，不保留目标身份，也不能完整描述目标间相关性。

PHD 的预测式为

$$D_{t|t-1}(x) = \int p_S(x') f_t(x | x') D_{t-1}(x') dx' + \gamma_t(x),$$


其中 p_S 是存活概率， f_t 是状态转移密度， γ_t 是新生目标强度。更新式把漏检项与每条观测的贡献相加；分母中的杂波强度会抑制孤立假峰。粒子或高斯混合只是表示和计算这张强度函数的不同方法。目标数由强度积分估计，位置再从峰或聚类中心提取。Liu et al. 2019

多目标追踪还要估计观测与轨迹的对应关系以及目标数。JPDA 和 MHT 显式处理关联；PHD 传播随机有限集的一阶强度；LMB 保留目标标签；检测前追踪保留未越过检测阈值的弱证据。OSPA 同时度量定位误差和目标数误差，但不评价身份连续性。

9.4 定位、追踪与波束形成的接口

追踪器向波束形成器提供平滑方向和置信度。若定位又使用波束形成后的信号，两个模块会相互影响，因此需要限制更新速率并处理静默期。

图23 远场语音前端：音频主链、方向反馈、状态控制与可选旁路



追踪器兼有平滑和预测作用：它减小 DOA 抖动，并在目标短时静默时外推方向。图 23 中，定位与追踪向波束形成提供方向，VAD、远端活动和双讲检测通过控制面约束状态更新；详细输入输出见第 10 章 §10.1。波束方向的变化上限应按帧率、目标最大转速和允许跟随延迟确定；静默超时或唤醒词触发时还需保持或重置状态，避免定位与波束权重相互影响而振荡。

多目标结果可用最优子模式分配距离（optimal subpattern assignment, OSPA）评价。若真值集 X 有 m 个目标，估计集 Y 有 $n \geq m$ 个目标，截断距离为 c ，阶数为 p ，则

$$d_p^{(c)}(X, Y) = \left[\frac{1}{n} \left(\min_{\pi} \sum_{i=1}^m \min\{c, d(x_i, y_{\pi(i)})\}^p + c^p(n - m) \right) \right]^{1/p}.$$

第一项是最优配对后的截断定位误差，第二项惩罚目标数不一致，最后还要除以较大的集合大小。OSPA 不保留身份，所以身份切换要另报 ID switch 等轨迹指标。

本章练习

1. KF 手算 + 静默外推：沿用算例 9-1 的末态（估计 $[30.72, 0.513]^\top$ ，协方差左上角 3.705）。假设接下来两帧说话人静默、无观测，只做预测不做更新：手算两帧后的角度估计与角度方差，并说明波束应使用哪个方向。
答案要点：每帧角度 $+0.513^\circ$ ，两帧后约 31.75° ；方差每步按 $\mathbf{F}\mathbf{P}\mathbf{F}^\top + \mathbf{Q}$ 只涨不降（约 $4.5 \rightarrow 5.8$ ：第一步左上角 $3.705 \rightarrow$ 约 4.49 ，第二步 $\rightarrow$ 约 5.80 ；别漏了非对角交叉项的贡献——左上角递推里有 2×0.213 这一项，漏掉它就会算成偏小的约 $3.9 \rightarrow 4.1$ ）；完整协方差跟着一起记：第一帧后 $\mathbf{P} \approx \begin{bmatrix} 4.49 & 0.47 \\ 0.47 & 0.27 \end{bmatrix}$ ，两帧后 $\mathbf{P} \approx \begin{bmatrix} 5.80 & 0.74 \\ 0.74 & 0.28 \end{bmatrix}$ （角速度方差几乎不动，交叉项越涨越大——这就是“走久了连速度都不敢信”）；波束指向听外推值，但要限幅 $3 \sim 5^\circ/\text{帧}$ ，静默太久就冻结在最后可信方向等唤醒词重置。
2. 数据关联二选一：两条轨迹（A 在 20° 、B 在 60° ），本帧两个观测（ 22° 、 58° ），JPDA 和最近邻分别如何配对？再加一个 40° 的杂波假峰，比较两种方法的处理方式。答案要点：无杂波时两者都把 22° 配给 A、 58° 配给 B；混入 40° 假峰后，最近邻可能把更近的假峰分配给轨迹。JPDA 计算每个观测属于各轨迹的概率并做加权更新，单个假峰只获得部分关联概率。
3. PHD+OSPA：某帧从 PHD 强度中提取出 30° 和 70° 两个目标，真值是 32° 处一人。人数估对了吗？取 $p = 1$ 、 $c = 10^\circ$ ，算出这一帧的 OSPA。答案要点：人数估计为 2，真值为 1。最优配对把 30° 与 32° 配在一起，截断定位误差为 2° ；多出的 70° 目标产生 10° 的基数惩罚。按较大集合大小 2 归一化，OSPA 为 $(2^\circ + 10^\circ)/2 = 6^\circ$ 。若把 70° 错配给真值，其定位误差先截断为 10° ，结果不会更小。
4. VAD 门控 + 波束限幅：说话人突然静默 5 帧（无观测），追踪只做预测；第 1 问：WPE、噪声协方差和降噪器的噪声功率各应怎样更新？第 2 问：波束指向每帧限幅 3° ，5 帧最多转多少度，之后如何处理？答案要点：静音且参考能量不足时冻结 WPE 系数，避免病态统计；确认无目标语音时，可以更新噪声协方差和降噪器的噪声功率。目标语音活动时则避免把目标泄漏写入噪声统计，WPE 是否更新由其语音活动和矩阵条件共同决定。5 帧的累计限幅为 $5 \times 3^\circ = 15^\circ$ ；超过保持时间或不确定度阈值后，应降低波束更新置信度或回到搜索模式，而不是永久沿预测方向外推。

第 10 章 · 工程实现与产业实践

⚠ 本篇是教程第 10 章。前后篇见下方导航。

🏠 首页导读: 00_overview.md | 上一篇: 09_source-tracking.md | 下一篇: 11_selection-guide.md

本章把前九章的算法放进真实系统，讨论模块启用条件、信号取点、资源预算和验收方法。

本章常用缩写如下：音频前端（Audio Front End, AFE）、声学回声消除（Acoustic Echo Cancellation, AEC）、加权预测误差去混响（Weighted Prediction Error, WPE）、噪声抑制（Noise Suppression, NS）、自动增益控制（Automatic Gain Control, AGC）、语音活动检测（Voice Activity Detection, VAD）、关键词唤醒（Keyword Spotting, KWS）、自动语音识别（Automatic Speech Recognition, ASR）、采样率偏移（Sampling Rate Offset, SRO）和实时因子（Real-Time Factor, RTF）。本章中的 RTF 均指实时因子；波束形成中的“目标相对传递函数”（relative transfer function）不缩写为 RTF，以免混淆。

10.1 参考链路 with 端到端延迟

音频前端没有适用于所有产品的固定流水顺序。图 23 给出的是一条参考链路：

多通道采集 → AEC → WPE → 定位与追踪 → 波束形成 → 单通道 NS/AGC → KWS/ASR。

它表达模块间的依赖，不表示每个项目都要启用全部模块。

- 设备不播放声音，或不需要边播边听时，可以不启用 AEC。
- 晚期混响已不影响目标指标时，可以不启用 WPE。
- 目标方向固定时，波束形成可以直接使用已知方向，不必持续定位和追踪。
- 只有多人重叠且下游确实需要独立语流时，才需要语音分离。
- VAD、远端活动检测和双讲检测是控制信号。它们不应画成主音频流中的串行处理框。

图23 远场语音前端：音频主链、方向反馈、状态控制与可选旁路




图 23 按较完整的语音交互系统绘制。虚线表示控制关系或可选旁路，实线表示音频或特征的传递关系。图中 AEC 的“最先处理”是指：启用 AEC 时，应在会破坏播放参考与回声之间线性关系的 NS、AGC 等处理之前消除回声，并

不表示任何系统都必须以 AEC 开头。确定实际模块后，还要重新核对各信号取点。

AEC 通常位于会改变回声路径关系的非线性处理之前。参考信号应覆盖实际播放链中的增益、均衡和混音变化。若参考取在这些处理之前，AEC 看到的参考与扬声器实际播放内容不一致。WPE、波束和 NS 的先后则要结合实现判断：多通道 WPE 需要多通道输入；单通道 WPE 可以放在波束之后；神经网络若联合完成波束与去混响，也不能再套用传统串行顺序。

10.1.1 延迟不能把每个模块的耗时直接相加

端到端延迟应沿实际关键路径测量，并分成五类：

类别	含义	常见来源
前瞻或算法等待	输出当前样本前必须等待的未来输入	居中窗、双向网络、判决确认窗
缓冲	驱动、直接存储器访问 (Direct Memory Access, DMA)、网络或帧拼接等待	声卡周期、抖动缓冲、整帧推理
计算	当前数据到输出完成的执行时间	快速傅里叶变换 (Fast Fourier Transform, FFT)、矩阵分解、神经网络推理
调度	任务虽已就绪但尚未运行	操作系统抢占、队列拥塞、加速器排队
解码与交互	前端之后的关键路径	流式 ASR 解码、网络往返、播报准备

若若干模块在同一帧内串行执行，它们的计算时间要相加；并行分支取耗时最长的关键分支；流水重叠的等待只沿关键路径计一次。在线 WPE 只使用历史帧时，本身不需要未来帧，但其分帧、平滑和实现缓冲仍可能产生延迟。

可把第 p 条路径写成

$$L_p = L_{\text{lookahead}} + L_{\text{buffer}} + L_{\text{compute}} + L_{\text{schedule}} + L_{\text{decode}}, \quad L_{\text{e2e}} = \max_p L_p. \tag{10-1}$$




图 25(a) 用采集与分帧 32 ms、未来帧前瞻 16 ms、判决确认 25 ms、计算与调度 20 ms 组成一条 93 ms 的示例关键路径。这些数字用于说明记账方法，不是通用预算，也没有包含图外可能存在的解码和交互延迟。实际系统应在声学输入与最终输出之间记录时间戳或回采脉冲，分别测量冷启动、稳定运行和最不利调度条件。把短时傅里叶变换（Short-Time Fourier Transform, STFT）窗长从 32 ms 改为 16 ms，也不等于必然省下 16 ms：只有依赖完整窗或未来样本的等待发生变化，关键路径才会缩短。

参考接口可按下表检查：

模块	启用条件	主要输入	主要输出	首要检查
采集与同步	多通道输入需要保持时序关系	麦克风、时钟	对齐的多通道脉冲编码调制（Pulse–Code Modulation, PCM）样本	映射、削波、丢帧、相对时延
AEC	本机播放可能进入麦克风	麦克风、播放参考	回声减弱的麦克风信号	参考取点、整体延迟、双讲稳定性
WPE	晚期混响影响任务	多通道或单通道 STFT	去混响 STFT	预测延迟、阶数、语音损伤
定位/追踪	波束或应用需要方向/轨迹	多通道信号	方向、置信度、轨迹	坐标系、时间戳、漏检与虚警
波束形成	需要空间选择性	多通道信号、方向或目标相对传递函数	增强信号	失配、白噪声增益、协方差估计
NS/AGC	残余噪声或电平范围影响后端	增强信号	抑噪、稳电平信号	语音损伤、增益抽动、削波
KWS/ASR	应用需要关键词检测或语音识别	音频或特征	事件或文本	取点、缓存、误报与漏报

10.2 拾音、同步与增益

麦克风选型至少要看自噪声、声学过载点、灵敏度、频响和通道一致性。单个器件的典型值不能代替整机测试：声孔、密封、挡板、电源噪声和装配偏差都会改变阵列响应。

脉冲密度调制（Pulse–Density Modulation, PDM）、芯片间音频总线（Inter–IC Sound, I²S）和时分复用（Time–Division Multiplexing, TDM）是常见数字接口，但一根数据线能承载多少通道取决于器件、时钟和控制器配置，不能只按接口名称判断。阵列处理还要确认通道是否共享采样时钟、帧同步是否一致，以及驱动是否会独立丢样。

16 位、24 位和 32 位浮点描述的是数字样本格式。32 位浮点便于保留中间动态范围，不能提高麦克风的声学过载点，也不能消除模拟前端的底噪或削波。某些录音设备以浮点文件保存多增益通路合成后的信号，但这仍不等于“无需增益设计”。

10.2.1 SRO：先区分初始时差和采样率偏移

设参考设备采样率为 f_s ，另一设备的相对偏移为 ε 。经过 T 秒后，两路时间轴的相对漂移近似为

$$\Delta t(T) = \varepsilon T.$$

(10-2)

100 ppm（parts per million，百万分之一）即 $\varepsilon = 100 \times 10^{-6}$ 。若不校正，1 秒累积 100 μ s，10 分钟累积 60 ms。这里的 60 ms 是时间轴长期累积的错位，不能直接当成每一秒都存在的到达时间差（Time Difference of Arrival, TDOA），也不能据此直接换算成固定的波达方向（Direction of Arrival, DOA）偏差。定位退化取决于重对齐周期、分析窗、频带、阵列孔径和估计器。

工程处理分三步：估计相对速率，按估计值重采样，再持续跟踪温漂。互相关峰漂移、相位漂移或专用导频都可用于估计。更新周期和允许残差应由最长连续运行时间、相干性要求及任务指标反推，不宜照搬固定 ppm 门限。能够共享硬件时钟时，应优先消除 SRO 来源；不能共享时钟时，再评估在线补偿。

10.2.2 增益变化与 AEC

AEC 前的时变增益会改变它要辨识的等效回声路径。设计时应记录每一级增益位于参考取点之前还是之后，并确保 AEC 能获知或跟踪这些变化。常见做法是：AEC 收敛和双讲期间保持前置增益稳定；发生削波风险时允许保护性衰减，同时重置或减小自适应步长。锁定时间、解锁条件和允许步进都应通过本机回声路径和双讲集确定，不存在通用的秒数或 dB 阈值。

阵列标定应覆盖相对增益、相位/时延和麦克风坐标。位置误差造成的相位误差为

$$\Delta\phi = 2\pi f \Delta r/c.$$

(10-3)

例如 $\Delta r = 0.5\text{ mm}$ 、 $f = 4\text{ kHz}$ 、 $c = 343\text{ m/s}$ 时， $\Delta\phi \approx 2.1^\circ$ 。这说明高频和深零陷波束更敏感，不表示 0.5 mm 是所有产品的统一公差。

10.3 NS、控制信号与唤醒分支

10.3.1 单通道 NS 的方法和边界

单通道 NS 常放在波束输出之后，因为此处计算量较小，也不会反过来破坏传统 AEC 的线性关系。但联合增强网络、多通道掩码估计或为定位专设的增强支路可能采用不同顺序。应依据训练输入和模块假设决定取点。

方法	基本思想	主要风险
谱减	从带噪功率谱中减去噪声估计	谱下限过低会产生音乐噪声
维纳滤波	按估计信噪比设置频点增益	噪声和先验信噪比估计滞后
子空间法	分离语音主子空间与噪声子空间	阶数估计和矩阵分解成本
最小均方误差短时谱幅度估计 (Minimum Mean-Square Error Short-Time Spectral Amplitude, MMSE-STSA)	最小化短时谱幅度的均方误差	分布假设与参数估计失配
最小均方误差对数谱幅度估计 (Minimum Mean-Square Error Log-Spectral Amplitude, MMSE-LSA)	最小化对数谱幅度的均方误差	低信噪比下仍可能有语音损伤
神经网络掩码/映射	从数据学习谱或波形映射	域外噪声、伪影和内容改变

MMSE-STSA 和 MMSE-LSA 不是同一目标：前者估计短时谱幅度，后者在对数谱幅度域定义误差。噪声估计也不必“只在 VAD 判无话时更新”。最小统计量、软语音存在概率和神经网络软掩码都能在语音段缓慢更新；关键是避免把语音持续吸收到噪声模型中。

10.3.2 控制状态不能只看一个 VAD 比特

控制状态需要涵盖近端语音、远端播放和双讲。下表列出这些状态下的更新条件；具体实现可以使用离散状态，也可以使用连续的活动概率。

状态	AEC 自适应	NS 噪声估计	波束/空间统计	WPE 更新	ASR/KWS
仅远端播放	参考有效且无削波时可更新	残余回声未污染噪声估计时可更新	避免把回声当目标	视残余回声而定	需要播放时唤醒时，KWS 可监听 AEC 后信号
仅近端语音	保持；没有有效远端参考可供辨识	软更新或保持	更新目标统计，谨慎更新噪声统计	可按功率加权更新	送入后端
双讲	由双讲检测降低步长或采用鲁棒更新	软更新或保持	分离目标与干扰统计	不应仅因“有语音”而冻结	保留近端语音
无近端、无远端	保持	更新背景模型	更新噪声统计	按实现选择保持或更新	后端可休眠，KWS 是否常开由应用需求决定

WPE 正是利用语音及其晚期混响的统计关系估计预测滤波器，不能用“VAD 有话就冻结”作为通用规则。AEC 的控制则必须结合远端活动和双讲检测；仅用近端 VAD 无法判断滤波器是否有可学习的回声参考。

VAD 的迟滞、挂起和预卷缓存应由语料中的短词、停顿和噪声脉冲调节。KWS 是否绕过 VAD、是否持续运行、从 AEC 后还是增强后取信号，也取决于功耗和训练域。阈值需要在指定误唤醒率下报告漏唤醒率，不能只给一个孤立分数。

10.4 定点化、算力与功耗预算

10.4.1 从浮点实现到目标芯片

定点化要检查四件事：数值范围、累加位宽、非线性函数近似和模块间缩放。协方差矩阵求解与 WPE 线性方程组尤其要观察条件数；对角加载能改善数值稳定性，但加载量应相对矩阵尺度定义。32 位或更宽的累加器可以减少乘加溢出，不能保证病态矩阵求解正确。

训练后量化（Post-Training Quantization, PTQ）先用校准数据确定量化尺度；量化感知训练（Quantization-Aware Training, QAT）在训练中模拟量化误差。选哪一种应由目标芯片的算子、代表性数据上的任务指标和最不利输入测试决定。不能预先承诺固定的指标下降量或加速倍数。

10.4.2 不混用指令数、乘加次数和实时因子

- 每秒乘加次数（Multiply-Accumulate Operations per Second, MAC/s）或每秒百万次乘加（Million MAC/s, MMAC/s）适合描述已经明确算子图和计数规则的算法计算量。
- 每秒百万条指令（Millions of Instructions per Second, MIPS）依赖指令集、并行宽度、存储访问和编译器。同一算法在不同处理器上的 MIPS 不可直接比较。
- RTF 定义为处理时长除以音频时长。RTF 小于 1 只说明平均速度足够；还要检查单帧最坏耗时、调度抖动和队列增长。

“帧耗时/帧长”得到的是 RTF，不是等效 MIPS。预算表应记录测量平台和版本：

模块	配置与输入尺寸	MAC/s 或分析复杂度	最坏帧耗时	RTF	峰值内存	平均/峰值功率
示例模块	麦数、采样率、帧长、模型版本	在同一计数规则下统计	在目标芯片实测	同一段音频实测	高水位实测	功率仪实测

电池容量应换算为能量。若标称电压为 V 、容量为 C_{Ah} ，标称能量近似为 $E = VC_{Ah}$ Wh，其中 Wh (watt-hour) 表示瓦时。续航估算为

$$t \approx \frac{E\eta}{P_{avg}}, \tag{10-4}$$

其中 η 包含可用容量、转换效率和老化裕量， P_{avg} 是包含占空比的整机平均功率。只给毫安时 (mAh) 而不给电压和平均功耗，无法推出续航。

10.5 评测体系

每项指标只能回答一部分问题。面向完整系统的评测通常还需覆盖任务效果、语音质量、稳定性、资源占用和长时间运行。

对象	可用指标	不能单独说明什么
AEC	回声返回损失增强 (Echo Return Loss Enhancement, ERLE)、双讲恢复、残余回声主观分	ERLE 高不等于近端语音无损
定位	角误差、漏检率、虚警率、均方根误差 (Root Mean Square Error, RMSE)	单源 RMSE 不代表多人追踪稳定
波束/分离	尺度不变信号失真比 (Scale-Invariant Signal-to-Distortion Ratio, SI-SDR)、下游词错误率 (Word Error Rate, WER) 或字错误率 (Character Error Rate, CER)、串扰	单个客观分不代表听感或内容正确
增强	短时客观可懂度 (Short-Time Objective Intelligibility, STOI)、感知语音质量评估 (Perceptual Evaluation of Speech Quality, PESQ)、感知客观听音质量分析 (Perceptual Objective Listening Quality Analysis, POLQA)、主观听测	客观模型可能在新失真上失准
追踪	最优子模式分配距离 (Optimal Sub-Pattern Assignment, OSPA)、轨迹完整度、轨迹身份切换 (ID switch)	位置准确不等于身份连续
系统	端到端延迟、RTF、功耗、崩溃/丢帧	平均值不代表尾延迟和最坏状态

OSPA 把定位误差与目标数量错误合成一个集合距离；经典 OSPA 本身不保留身份标签，因此不能用它代替轨迹身份切换指标。OSPA(2) 比较一段时间内的轨迹集合，仍应把身份连续性指标及轨迹关联规则另行说明。

ITU-T P.835 (07/2026) 用于对含噪语音处理系统做主观听测，分别评价语音信号 (Signal, SIG)、背景噪声 (Background, BAK) 和总体效果 (Overall, OVRL)。它适合区分“噪声是否减弱”和“语音是否受损”，但不能直接评价 DOA、轨迹身份或空间位置。正式报告应写明标准版本、听测材料、听众筛选、播放设备和统计区间。

10.6 数据、仿真与复现

公开数据集适合建立可复现基线，不能代替目标设备录音。选择数据时要核对采样率、麦克风几何、房间、说话人数、重叠率、参考真值和许可证。训练、调参、最终测试应按房间或说话人隔离，避免相邻片段泄漏。

房间冲激响应仿真也要写全条件。以下代码说明 max_order 与混响时间的关系：

```
import pyroomacoustics as pra

room_dim = [6.0, 5.0, 3.0]
target_rt60 = 0.45
absorption, max_order = pra.inverse_sabine(target_rt60, room_dim)
room = pra.ShoeBox(
    room_dim,
    fs=16000,
    materials=pra.Material(absorption),
    max_order=max_order,
)
```

`inverse_sabine` 根据目标混响时间 T_{60} 和房间尺寸给出吸收参数及建议的镜像源截断阶数； T_{60} 表示声能衰减 60 dB 所需的时间。`max_order` 控制镜像反射的截断深度，不能单独决定 T_{60} 。论文或报告还应记录声源/麦克风坐标、材料模型、随机种子、噪声生成方法和所用库版本。

10.7 分布式阵列

分布式系统要分别解决三类问题：

- 1. **时间轴**：初始时差、SRO、丢包和网络抖动要分开估计。长录音首尾对齐只能发现累计误差，不能代替运行时监测。
- 2. **坐标与增益**：节点位置、朝向、通道增益和频响决定导向矢量能否共用。节点移动后要更新几何。
- 3. **融合**：集中式波束需要传多通道信号或统计量，对同步和带宽要求高；通道选择和识别结果融合要求较低，但损失空间信息。应把弱节点加入后的退化列为测试项。

验收阈值应由网络带宽、最长会话和目标任务确定。例如，要求一小时内相位相干的系统与只做句级识别的系统，对残余 SRO 的要求不会相同。

10.8 阵列形态与场景约束

公开产品的麦克风数量、位置和算法会随硬件版本及地区型号变化。若没有可追溯的一手资料，不应从拆解照片推断算法链。本教程因此只讨论可迁移的设计条件：

场景	先确认的约束	可能启用的模块	必测状态
带扬声器的音箱/会议终端	播放声压、参考取点、覆盖角	AEC；按混响决定 WPE；按覆盖决定定位/波束	远端单讲、近端单讲、双讲、音乐播放
会议室	房间混响、座位分布、重叠说话比例	多波束或分离；晚期混响明显时用 WPE	单人、抢话、键盘/空调、不同座位
车载	舱位、车速相关噪声、多个时钟域	分区波束、SRO 补偿、参考完整的 AEC	怠速、行驶、开窗、空调、音乐与通话并发
耳机/助听设备	上下行路径、佩戴泄漏、低延迟和电池约束	固定/自适应双麦波束、NS、反馈抑制	不同佩戴、风噪、自己说话、最坏增益

场景	先确认的约束	可能启用的模块	必测状态
机器人	运动自噪声、阵列姿态、惯性测量单元（Inertial Measurement Unit, IMU）时间戳	运动前馈、姿态补偿、定位/追踪	静止、转头、行驶、风扇/电机变速
手机/手持设备	握持、遮挡、横竖屏、通话模式	通道选择、波束/NS、模式切换	手指挡孔、风噪、贴脸、免提、录像

球阵的可用球谐阶数同时受空间采样、阵列半径、频率和模态噪声放大限制。表示到 N 阶的完整球谐系数共有 $(N + 1)^2$ 个，因此离散阵元数至少要能支撑相应的空间采样；实际还要留出几何和数值稳定性余量。可用阶数在高频受阵元空间混叠限制，在低频又受 kr 较小和径向滤波噪声放大限制。不能用 $N = \lceil kr \rceil + 1$ 一条式子替代完整设计，也不能把“某阶需要多少系数”直接等同于任意摆放的同数麦克风一定可用。

三个非共点麦克风已经构成阵列。若几何非共线，它们能提供二维空间信息；若接近共线，则某些方向存在镜像或条件数问题。手机的主要限制通常是孔径小、结构遮挡和工作模式变化，而不是“三麦构不成阵列”。

10.9 从模型到设备

部署前先固定输入尺寸、算子版本、量化方式和线程配置，再测算力与内存。模型参数从 32 位浮点量化到 8 位整数时，参数存储在理想情况下约缩小四倍；端到端速度取决于硬件是否有相应整数内核、访存和算子融合，不能据此承诺“快四倍”。

低功耗常驻任务和高算力按需任务可以分开：例如 KWS 在低功耗处理器上运行，唤醒后再启动 ASR 或分离网络。但 AEC、波束、WPE 是否常驻取决于是否需要持续边播边听、录音或通话，不应把“唤醒前关闭完整前端”写成固定方案。

端侧、云侧或混合部署要比较隐私、断网可用性、网络尾延迟、更新能力和能耗。对品牌产品的实现方式没有公开证据时，只能写成候选架构，不能当作产品事实。

10.10 联调与验收

联调应按依赖关系排查，不必强行把所有模块串成一个固定顺序。

阶段	检查内容	验收口径怎样确定
采集	通道映射、时间戳、削波、丢帧、自噪声、SRO	由器件规格、最长运行时间和下游容差确定
AEC	参考对齐、路径覆盖、单讲收敛、双讲稳定、路径变化恢复	分别报告 ERLE、近端损伤和恢复时间；覆盖目标播放状态
WPE	晚期混响衰减、直达声损伤、长时稳定	在目标房间和说话距离上与关闭 WPE 对照
定位/追踪	角误差、漏检、虚警、人数、轨迹身份切换、轨迹中断	按覆盖区和应用允许误差设线，包含交叉与遮挡
波束/分离	目标保持、干扰抑制、失配鲁棒性、串扰	同时报任务指标与语音损伤，不只报 SI-SDR
NS/AGC	噪声残留、语音损伤、抽动、削波	覆盖噪声类型和输入电平，补 P.835 主观听测
KWS/ASR	指定误报率下的漏报率、WER/CER、首尾截断	使用目标语言、距离、噪声、说话人和播放状态

阶段	检查内容	验收口径怎样确定
系统	关键路径延迟、RTF、峰值内存、平均/峰值功耗、长时间稳定性	在目标硬件、发布配置和最不利并发状态实测

每个验收阈值都应包含测量条件、统计量和样本量。例如“角误差小于 5°”还要说明声源角度分布、距离、房间、信噪比，以及该数值是均值还是某个分位数。教程中的算例只能用于验证计算，不能直接作为产品验收阈值。

常见故障可按依赖关系缩小范围：

现象	先查	再查
播放时残余回声突然增大	参考取点、整体延迟、削波、前置增益变化	滤波器长度和双讲控制
语音发闷或辅音丢失	NS 增益、WPE 预测延迟、AGC 抽动	波束指向失配和标定
定位随时间缓慢漂移	时钟域、SRO、丢样	几何和温漂后的标定
唤醒差但 ASR 正常	KWS 取点、缓存、训练域和阈值曲线	VAD 是否错误截断 KWS 输入
平均实时但偶尔爆音	最坏帧耗时、调度抖动、缓冲下溢	平均 RTF 和内存带宽

10.11 本章小结

- 1. 图 23 是参考依赖图，不是所有设备必须执行的固定流水线。
- 2. 延迟、算力和续航必须在目标硬件上按明确口径测量；窗口长度、MIPS 和 mAh 不能互相替代。
- 3. 门控至少要区分近端语音、远端播放和双讲；单个 VAD 比特不足以控制 AEC、WPE 和全部后端。
- 4. 固定阈值和品牌案例不能替代项目条件。每个验收数字都要带场景、统计口径和来源。

第 11 章 · 总结与选型指南

⚠ 本篇是教程第 11 章。前后篇见下方导航。

🏠 首页导读: [00_overview.md](#) | 上一篇: [10_engineering-practice.md](#) | 下一篇: [12_appendix-symbols-math.md](#)

选型应从任务和约束开始。同一个四麦阵列用于固定座位通话、多人会议或机器人跟随时，合适的处理链可能完全不同。本章先确定目标，再选择几何和模块，最后按第 10 章的方法验证。

本章常用缩写如下：波达方向（Direction of Arrival, DOA）、声学回声消除（Acoustic Echo Cancellation, AEC）、加权预测误差去混响（Weighted Prediction Error, WPE）、噪声抑制（Noise Suppression, NS）、语音活动检测（Voice Activity Detection, VAD）、实时因子（Real-Time Factor, RTF）和采样率偏移（Sampling Rate Offset, SRO）。各定位、波束和追踪算法的全称在首次出现处给出。

11.1 先回答六个问题

- 系统要输出什么？** 输出一个方向、连续轨迹、增强语音、彼此独立的多人语流，还是识别文本？输出不同，所需模块不同。只做固定方向录音时，不需要在线定位；只做方向显示时，也未必需要波束形成和 NS。
- 覆盖区域和声源距离是什么？** 线阵适合重点覆盖阵列轴所在平面或扇区，但会有前后或镜像歧义；圆阵适合水平面环绕覆盖；平面阵与球阵可提供俯仰信息，但需要更多通道和更严格的标定。形态不是按“几只麦”直接决定的。
- 空间分辨率和最高工作频率是什么？** 孔径影响角分辨率，阵元间距限制无空间混叠频带。增大孔径有利于低频方向信息，减小间距有利于高频无混叠。两者冲突时，可以增加阵元、限制工作频带或采用非均匀几何；不能只报一个间距就宣称覆盖全频带。
- 有哪些干扰？** 本机播放造成回声时才需要 AEC；晚期混响妨碍任务时再考虑 WPE；多人重叠且要输出独立语流时才考虑分离；稳定背景噪声可能用解析 NS 即可，复杂域外噪声则要验证神经网络的泛化。
- 目标是否移动、人数是否变化？** 单个慢速目标可从简单平滑或卡尔曼滤波开始。人数变化、交叉和遮挡要求显式处理轨迹出生、消失和数据关联。概率假设密度（Probability Hypothesis Density, PHD）滤波、带标签多伯努利（Labeled Multi-Bernoulli, LMB）滤波或其他随机有限集方法不会因“人数多”自动成为合适方案；还要考虑观测模型、身份连续性要求和实现成本。
- 硬件和合规边界是什么？** 写明采样率、麦数、时钟域、算力、峰值内存、功耗、关键路径延迟、隐私和认证要求。每秒百万条指令（Millions of Instructions per Second, MIPS）不能脱离处理器型号比较，电池续航要用瓦时（Wh）与整机平均功耗估算，见第 10 章 §10.4。

11.2 按条件选择模块

决策对象	适合先尝试的方案	何时换方案	同时检查的风险
单源 DOA	广义互相关相位变换（Generalized Cross-Correlation with Phase Transform, GCC-PHAT）或导向响应功率相位变换（Steered Response Power with Phase Transform, SRP-PHAT）基线	需要更高分辨率且协方差条件满足时，评估多重信号分类（Multiple Signal Classification, MUSIC）或旋转不变子空间（Estimation of Signal Parameters via Rotational Invariance Techniques, ESPRIT）；复杂混响下可评估学习方法	阵列歧义、混响、宽带融合、虚警
固定方向增强	延时求和或固定超指向波束	噪声场变化且统计量可估计时，评估最小方差无失真响应（Minimum Variance Distortionless Response, MVDR）或线性约束最小方差（Linearly Constrained Minimum Variance, LCMV）波束形成	白噪声增益、方向失配、标定
自适应波束	MVDR 或 LCMV 加稳健化	目标相对传递函数或导向矢量难以估计时，评估掩码辅助或联合模型	协方差秩、对角加载、目标泄漏
晚期混响	先用关闭 WPE 的基线	晚期混响确实限制词错误率（Word Error Rate, WER）、可懂度或听感时启用 WPE	预测延迟、阶数、直达声损伤
本机回声	有播放泄漏时启用 AEC	非线性扬声器、路径变化或多扬声器时增加相应建模	参考取点、整体延迟、双讲
多人重叠	多波束或掩码波束	需要独立语流且空间方法仍串扰时启用分离网络	输出人数、排列、内容改变、算力
轨迹平滑	α - β 或卡尔曼滤波	多目标交叉、漏检和虚警明显时换多目标滤波	坐标系、时间戳、轨迹身份切换、轨迹中断
残余噪声	维纳或最小均方误差（Minimum Mean-Square Error, MMSE）等解析基线	非平稳噪声下基线不足时评估神经 NS	语音损伤、域外噪声、下游 WER

算法名只确定了方法类别，还没有确定参数。WPE 的预测延迟和阶数、MVDR 的加载量、AEC 的滤波器覆盖范围、VAD 的挂起时间都应由目标数据和硬件测量得到，不应作为通用默认值从别的产品复制。

11.3 几何与算法要一起选

阵列几何决定观测中有哪些空间信息，算法决定如何使用这些信息。

- **双麦或近似线阵**：可以估计沿阵列轴投影的时差并形成方向性，但某些方向会有镜像歧义。适合已知目标扇区、孔径和外形受限的设备。
- **非共线三麦及平面阵**：能提供二维几何约束。精度仍受孔径、频带、遮挡和标定影响，不能把“三麦”简单归为单麦处理。

- **圆阵**：便于覆盖水平面。阵元数和半径应由所需角分辨率、最高频率与结构尺寸共同确定，不存在“全向必须至少四麦、六麦最好”的通用答案。
- **球阵或三维阵**：适合需要俯仰角、声场分析或多方向波束的任务。可用球谐阶数受阵元采样、 kr 、径向滤波噪声放大和标定误差共同限制，详见 §10.8。
- **稀疏阵**：差分共阵可增加二阶统计中的虚拟滞后数，但不会凭空增加独立物理通道，也不保证宽带、相干声源和有限快拍下都能得到同样的自由度。应按第 3 章的适用条件验证。

白噪声增益（White Noise Gain, WNG）和指向性指数（Directivity Index, DI）之间常有取舍。更窄的波束或更深的零陷可能放大传感器自噪声和标定误差。对角加载、WNG 约束和限制工作频带都能改善鲁棒性，但通常会牺牲一部分空间选择性。

11.4 四个场景怎样推导方案

下表给的是推导方法，不是产品清单。

场景	条件变化	方案怎样变化
带扬声器的语音终端	若要求播放时仍能唤醒或通话	AEC 成为必要候选；参考取在实际播放处理之后。圆阵、线阵或平面阵由覆盖区域和外形决定。无明显晚期混响时不必默认加 WPE。
会议室	若多人重叠较少，只需一路会议音频	先比较多波束选择和自适应波束。只有重叠说话造成任务失败，且需要独立语流时，再增加分离。远距离和长混响房间要用实测决定 WPE。
车载	若麦克风跨多个时钟域	先解决 SRO 和时间戳，再谈分区波束。播放参考需覆盖音乐、导航和通话混音。算法要在急速、行驶、开窗和空调状态分别测试。
耳机或助听设备	若监听路径对延迟和电池很敏感	监听与通话上行可采用不同链路。固定双麦波束和轻量 NS 是候选基线，不是必选答案；法规、反馈路径、佩戴变化和听觉安全优先。

同一场景也可能得出不同答案。例如会议设备安装在墙边时，覆盖区域可能只有半空间；放在桌中央时则要覆盖周向。前者可能适合线阵或弧形阵，后者可能适合圆阵。覆盖区域确定后，才能据此选择阵列形态和麦克风数量。

11.5 把候选方案写成可验证的规格

为了复现实验并比较方案，候选方案的规格应覆盖以下内容：

项目	应写内容
任务	输入、输出、目标声源数、是否需要身份连续
几何	坐标、尺寸公差、声孔和遮挡、工作频带
场景	距离、角度、房间、噪声、播放和运动状态
链路	每个模块的启用条件、取点、旁路和控制信号
资源	目标硬件上的 RTF、最坏帧耗时、峰值内存、平均/峰值功耗
延迟	前瞻、缓冲、计算、调度和解码关键路径
指标	任务指标、语音损伤、稳定性、置信区间和样本量
异常处理	通道失效、方向低置信度、网络断开和算力过载时的行为

可以先建立最小基线，再一次增加一个模块。增加模块后要同时检查收益、语音损伤、延迟、功耗和失败样例。如果 WPE 没有改善目标房间的结果，或分离网络虽然提高了尺度不变信号失真比（Scale-Invariant Signal-to-Distortion Ratio, SI-SDR）却增加了内容错误，就不应因为流程图里画了它而保留。

11.6 练习

题 1：带播放的周向语音终端

需求是水平面周向覆盖，设备会播放音乐，主要任务是唤醒和单人指令。请写出候选几何、必要模块和两个关键对照实验。

答案要点：圆阵是候选，不应在没有孔径与频带要求时先定麦数。播放时仍需拾音，因此要评估 AEC，并确保参考覆盖播放处理。定位或多方向固定波束可用于周向选择；WPE 和分离不是默认必选。关键对照至少包括“静音播放与音乐播放下的唤醒曲线”和“AEC 开关下的近端语音损伤及残余回声”。

题 2：多人会议

房间混响明显，偶尔有人抢话，只输出一路会议音频。什么时候需要 WPE，什么时候需要分离？

答案要点：先在目标房间比较关闭/开启 WPE 后的 WER、可懂度和语音损伤；晚期混响限制任务且净收益稳定时才启用。若多波束或掩码波束已经满足一路输出的串扰要求，不必因为存在重叠就输出独立语流；只有重叠段仍造成不可接受的任务失败，且应用需要保留各说话人内容时，再评估分离网络。

题 3：跨时钟车载阵列

四只麦克风分属两个时钟域。为什么不能先调波束权重？应该先测什么？

答案要点：相对 SRO 会让通道相位关系随时间漂移，固定权重和导向矢量很快失配。应先测初始时差、累计漂移、丢样和时间戳稳定性，完成重采样或时钟同步后再标定几何与增益，最后调波束。验收要覆盖温度和长时间运行，而不是只看一段短录音。

11.7 后续阅读

要实现算法，可回到第 4~9 章查看定位、波束、AEC、WPE、分离和追踪。要制定整机预算和验收计划，见第 10 章。附录 A 汇总符号与数学工具，附录 B 给出进一步阅读、练习和排错入口。

附录 A · 符号术语数学

⚠ 本篇是附录 A（正文共 11 章，另有附录 A/B），可独立查阅，前后篇见下方导航。

🏠 首页导读：00_overview.md | 上一篇：11_selection-guide.md | 下一篇：13_appendix-guide.md

本附录沿用 12.1~12.3 的节号，便于与正文既有引用对应；下一篇是附录 B。

12.1 符号表

约定同 §2.3：斜体 = 标量，头顶箭头 = 向量，加粗大写 = 矩阵；^H 共轭转置、[⊤] 转置、[^] 估计值； $X(f)$ 、 $X(n, f)$ 类大写字母为逐频点复数标量（语音文献习惯）。

字母复用（与 §2.3 一致）：受文献惯例所限， k 可表示频点索引、波数或 WPE 的滞后帧号； D 可表示阵列孔径或 PHD 强度函数； λ 可表示波长、WPE 功率谱或矩阵特征值； K 可表示声源数或 WPE 预测阶数； s 可表示源信号或追踪状态。具体含义以所在公式的定义为准。

符号	含义
M, d, D	麦数、阵元间距、阵列孔径
c, λ, f	声速 (≈ 343 m/s)、波长、频率
θ, θ_0	正横方向起算的入射角、波束指向角；端射为 $\pm 90^\circ$
$\vec{r}_m, \vec{p}$	第 m 个麦克风的位置向量、声源位置向量
t, n, f, k, T	连续时间、帧或采样索引、频率或频点、算法内索引、快拍数；具体含义看所在公式
ψ	相邻两麦的相位差， $\psi = \frac{2\pi d}{\lambda}(\sin \theta - \sin \theta_0)$ (§2.6、§5.2)
$\vec{a}(\theta), \vec{w}$	导向矢量、波束权重
$\hat{\mathbf{R}}, \mathbf{R}_{nn}, \mathbf{R}_{ss}$	空间协方差矩阵、噪声协方差矩阵、目标协方差矩阵
$\mathbf{\Gamma}$	弥散噪声相干矩阵， $[\mathbf{\Gamma}]_{ij} = \text{sinc}(2fd_{ij}/c)$ (§5.1；球面各向同性口径。声音只从水平面来时对应形状是零阶贝塞尔 J_0 ，见§5.1 第三段)
$\mathbf{E}_n (\mathbf{E}_s)$	噪声（信号）子空间的特征向量基 (§4.6)
σ^2	噪声方差/功率（白噪声下协方差为 $\sigma^2 \mathbf{I}$ ）
$\mathbf{C}, \vec{f}$	LCMV 约束矩阵与约束值向量， $\mathbf{C}^H \vec{w} = \vec{f}$ (§5.5)
$\vec{e}_r$	参考麦选择向量（第 r 位为 1 的单位向量，见§5.5 参考麦选择，MWF/SDW 用）
$\mathbf{B}$	GSC 阻塞矩阵，满足 $\mathbf{B}^H \vec{a}(\theta_0) = \vec{0}$ (§5.6)
$\Phi(f)$	GCC 加权函数 (§4.2) vs 功率谱 (§5.7)，语境区分
$\mathbf{P}, \mathbf{K}, \mathbf{Q}, \mathbf{F}, \mathbf{H}$	卡尔曼滤波：误差协方差、卡尔曼增益、过程噪声协方差、状态转移、观测矩阵 (§9.2)
$V, A, S, \bar{\alpha}$	房间体积、等效吸声面积、总表面积、平均吸声系数 (§2.4)

符号	含义
μ_{NLMS}	NLMS 步长 (§6.1)；理想化独立性假设下常讨论 $0 < \mu < 2$ ，实际取值还受输入相关性、正则项和时变路径影响
μ_{SDW}	SDW 失真—降噪折中系数 (§5.5)；与上一行的 NLMS 步长不是同一物理量
ε	小正数：防除零 (NLMS 归一化分母，见§6.1)、防病态 (对角加载 $\mathbf{R} + \varepsilon \mathbf{I}$ ，§5.4)
τ_{ij} , TDOA	麦对时延差
T_{60} , DRR, d_c	混响时间、直达混响比 (dB 域读数)、临界距离
WNG, DI, HPBW, SLL	白噪增益、指向性指数、半功率瓣宽、旁瓣电平 (CRB/CRLB 混用见 CRLB 行)
RTF	相对传递函数
$h(n)$, $\hat{w}$, ERLE	回声路径、AEC 自适应滤波器、回声返回损失增强
$G(k, f)$, Δ , K	WPE 预测系数 (本书为滞后 k 、频点 f 的系数)、保护延迟、预测阶数
PHD/RFS	概率假设密度 / 随机有限集

3 分钟手算 (12.1)：在无失真归一化、各通道自噪声独立且等功率时， $M = 6$ 的 DSB WNG 是多少 dB？ 2×2 对角协方差 $\text{diag}(4, 1)$ 的特征值是哪两个数？ 答案： $10 \log_{10} 6 \approx 7.8$ dB；对角阵的特征值就是对角元 4 和 1。这里的特征向量是两条传感器空间坐标轴，不一定对应真实空间中的两个入射方向。

12.2 术语词典

下表按主题解释正文和相关文献中常见的术语。

信号与数学基础

术语	解释
STFT (短时傅里叶变换)	把波形分成重叠短帧，并对每帧计算频谱，得到时间—频率复数表示。窗长与帧移按频率分辨率、时变性和延迟要求选择；逐频点处理可把宽带问题近似拆成多个窄带问题 (§2.5)
快拍 (snapshot)	某一帧、某一频点上， M 个麦克风复数谱排成的列向量——阵列的一张“空间照片” (§2.5)
协方差矩阵 $\hat{\mathbf{R}}$	快拍与其共轭转置的外积做时间平均；浓缩“几个源、多强、从哪来、噪声什么结构”，是 Capon/MVDR/MUSIC 的共同输入 (§2.5)
特征分解 / 子空间	把协方差矩阵拆成特征值与特征向量：大特征值对应的方向张成信号子空间，小的张成噪声子空间 (图6d)
超定方程组	方程比未知数多，通常无精确解、只可求最小二乘解——TDOA 定位的麦对多于未知数时就是这样 (见§4.4)
双曲线定位	一对麦测出时延差 $\Leftrightarrow$ 声源在“到两麦距离差为常数”的双曲线上；多对麦的双曲线交点即声源 (见§4.4)
常规波束分辨率 / 超分辨	常规波束主瓣宽度的量级约为 λ/D ；子空间方法在模型正确、信噪比和快拍数足够时可形成更窄谱峰，因此称为超分辨 (§2.6、§4.6)
波束图 (beam pattern)	波束形成器对各个方向的增益图，主瓣/旁瓣/零陷都在上面读 (图7a)

术语	解释
自由度 (DOF)	可调参数的个数。 M 麦波束形成器有 M 个复数自由度，每条约束消耗一个 (§5.5)；稀疏阵用协同阵（见本组“差分协同阵”行）增加虚拟自由度 (§3.3)
抽头 (tap)	FIR 滤波器的一个系数。“128 个抽头”表示 128 个系数；按多项式阶数定义时对应 127 阶，阅读文献时需核对作者采用的口径 (§6.1)
优先效应 (precedence effect)	人耳“先入为主”：先到的直达声决定方向感，几 ms 后的反射不干扰定位；机器没有这种本能，需要算法来对抗早期反射 (§2.4)
拉格朗日乘法	带约束求极值的标准工具：“约束写成等式加到目标里，再求导令零”，MVDR 的闭式解就是这么推的 (§5.4)
白化 (whitening)	调整各频率分量的幅度，使其贡献更均衡。GCC-PHAT 通过幅度归一化主要保留互功率谱相位，可减弱源谱着色，但不会消除反射产生的多径相位 (§4.2)
sinc 函数	本书定义 $\text{sinc}(x) = \sin(\pi x)/(\pi x)$ 。球面各向同性弥散场中的两麦相干系数具有 sinc 形式；若声源只在水平面各向同性分布，则对应零阶贝塞尔函数 $J_0(2\pi f d/c)$ (§5.1)。另一些文献把 sinc 定义为 $\sin x/x$ ，代入公式前必须先核对定义
SNR (信噪比)	信号功率与噪声功率之比，常以 dB 表示。输出 SNR 减去输入 SNR 得到 SNR 增益。SER 在 AEC 语境中比较近端目标与回声功率，使用时应明确分子、分母和测量时段 (§5.1、§6.1)
dB (分贝)	比值的对数表示；功率比使用 $10 \log_{10}$ ，幅度比使用 $20 \log_{10}$ 。两种写法只有在功率与幅度平方成正比且参考阻抗一致时才对应同一物理变化 (详见 §12.3 ②)
FFT (快速傅里叶变换)	离散傅里叶变换的高效算法，把一帧时域样本转换为各频点的复数谱；STFT 对连续短帧重复这一运算 (§2.5)
DNN (深度神经网络)	由多层参数化变换组成、通过数据优化的模型。本教程主要用于估计时频掩码、方向概率或增强信号 (§4.7、§5.9)
远场 / 近场	远场中波前可近似为平面，导向模型主要由方向决定；近场采用球面波模型，还要考虑距离和通道幅度差。常用 Fraunhofer 判据为 $r > 2D^2/\lambda$ ，其中 D 是孔径；其数值随频率和孔径变化 (§2.2)

房间声学

术语	解释
RIR (房间脉冲响应)	房间的“指纹”：拍一下手录到的声音。任何声音 = 干净声 $\otimes$ RIR (§2.4)
T_{60}	混响时间：房间声能衰减 60 dB 所需时间。具体数值取决于房间体积、表面吸声和测量频带
DRR (直达混响比)	直达声能量 $\div$ 混响声能量，dB 域读数：DRR (dB) >0 直达占优，DRR (dB) <0 混响占优；负得越多越难
临界距离 d_c	在给定声源指向性与扩散场假设下，直达声和混响声能量相等、即 DRR=0 的距离；本书简化模型为 $d_c \approx 0.057\sqrt{V/T_{60}}$ (§2.4)
镜像法	把墙面反射等效成墙后镜像声源的仿真方法 (Allen & Berkley 1979)，pyroomacoustics 的核心
LMS / NLMS / RLS	LMS 结构简单；NLMS 按输入功率归一化步长；RLS 利用输入相关矩阵的递推逆，通常收敛更快，但计算量和存储量也更大。实际差距取决于输入相关性、滤波长度和参数设置 (§5.6、§6.1)
音乐噪声	谱减类方法过度估计噪声后残留的随机孤立谱峰，听起来像叮咚作响的流水声 (§5.7)

术语	解释
ICA / IVA / PIT	语音分离术语：ICA 按“各说话人统计独立”解混；IVA 把各频点绑成向量联合解混，一次定下排列不用来回对齐；PIT（排列不变训练）让分离网络不用管“哪个输出口对应哪个人” (§8.1)
弥散噪声场	从四面八方均匀涌来的噪声场（晚期混响、风噪的模型），DI 度量就是针对它

波束形成与阵列度量

术语	解释
导向矢量 $\vec{a}(\theta)$	“如果声音从 θ 来，各麦应该是什么相位”的标准答案向量 (§2.3)
转向 (steering)	把波束对准某个方向：按导向矢量补偿各通道时延/相位
主瓣 / 旁瓣 / 零陷	波束图中目标指向附近的主要响应区、主瓣外的局部峰，以及响应接近零的方向 (图 7a)
栅瓣	空间采样混叠产生的高旁瓣；均匀线阵在特定间距和转向下可出现与主瓣等高的方向歧义 (§2.6、图 7b)
WNG (白噪增益)	衡量波束权重对各通道独立等功率白噪声的放大或抑制；在目标方向无失真归一化下， M 元 DSB 达到 $10 \log_{10} M$ dB (§2.6)
DI (指向性指数)	对四面八方弥散噪声（混响尾音）的抑制能力 (§2.6)
HPBW / SLL	主瓣半功率宽度（分辨率）/ 最大旁瓣高度（泄漏水平） (§2.6；SLL 本表收录，§5.2 称旁瓣电平，对的是同一个东西)
CRLB / CRB (克拉美－罗下界, Cramér–Rao Lower Bound)	给定概率模型和正则条件下，无偏估计器方差的下界；模型、参数化或偏差条件改变，下界也改变 (§2.6)
MVDR (最小方差无失真响应)	在 $\vec{w}^H \vec{a} = 1$ 的约束下最小化输出噪声功率。它保护目标方向或 RTF，同时压低噪声 (§5.4)
MWF (多通道维纳滤波)	直接最小化参考目标与输出之间的均方误差，允许目标缩放来换取更小总误差。秩一目标模型下，MWF 可分解成 MVDR 空间滤波器乘一个标量维纳后滤波器，但两者不是简单的“加不加约束”关系。对本书 $\vec{w}_{\text{SDW}} = (\mathbf{R}_{ss} + \mu \mathbf{R}_{nn})^{-1} \mathbf{R}_{ss} \vec{e}_r$ 的定义， $\mu = 1$ 是标准 MWF； μ 增大时更重视降噪并趋向零输出，而不是趋向 MVDR (§5.5)
RTF (相对传递函数)	各通道间“直达 + 含早期反射的相对响应”；混响中 MVDR 应该保护它而不是裸导向矢量 (§5.4)
对角加载	协方差矩阵加 $\varepsilon \mathbf{I}$ (ε 见 12.1) 再求逆，改善条件数并降低对失配的敏感性 (§5.4)
相干源	内容高度相关的多个源（直达声 + 强反射）。MUSIC 遇相干源会失效 (§4.6)
空间平滑	把线阵切成重叠子阵分别估协方差再平均，牺牲孔径换去相干 (§4.6)
差分协同阵	由全部阵元位置差组成的虚拟位置集合；结合二阶统计重构，可在条件满足时获得长于物理阵列的连续虚拟孔径 (§3.3)
GEV 波束形成器	最大化输出信噪比的波束形成器（广义特征值问题的解），与 MVDR（见本组 MVDR 行）并列的掩码后处理选项 (§5.9)
GSS (导引源分离)	利用方向或说话人活动信息引导空间聚类与波束形成的分离方法；常用 cACGMM 估计时频掩码，并用活动标注约束输出排列 (§8.1)
WDO (W-不相关正交)	分离掩码（掩码见本表“定位与追踪”组掩码行）的理论依据：不同说话人的语谱在时频平面上几乎不重叠（每个时频点基本只被一个人占据），所以逐时频点“贴标签”就能分人 (§8.1)

定位与追踪

术语	解释
TDOA	同一声源到达一对麦克风的时间差，是远场和近场定位的重要观测量 (§2.1)
DOA (波达方向)	声从哪个方向来，一般指角度。TDOA 是“两麦差了几毫秒” (时间量)，DOA 是“换算完指向几度” (角度量)，远场下 DOA 直接由 TDOA 算出来 (§4.1、§4.4)
ITD / ILD	双耳时间差 / 双耳声级差：人类定位的两大线索，低频靠 ITD、高频靠 ILD (瑞利双重理论，§1.1)
HRTF	头相关传递函数：头与耳廓对声音的方向相关滤波，人类分辨前后/上下的依据 (§1.1)
鸡尾酒会效应	人类在多人嘈杂环境中选择性聆听的能力；对应机器的波束形成 + 语音分离 (§1.1、§8.1)
GCC-PHAT	广义互相关 + 相位加权：把两路信号错位到最像，峰值位置即时间差 (§4.2)
SRP-PHAT	遍历候选位置并汇总各麦对 PHAT 相关值的定位方法，是常用的稳健基线之一 (§4.3)
Capon / MUSIC / ESPRIT	Capon 逐方向计算最小方差谱；MUSIC 利用导向矢量与噪声子空间的正交性形成伪谱；ESPRIT 利用阵列的平移不变结构直接估计参数。三者的协方差、源数和几何条件不同 (§4.5、§4.6)
GDOP (几何精度因子)	同样的时延误差，几何布局差时被放大得更多；小孔径阵列的 GDOP 天然大 (§4.4)
VAD (语音活动检测)	判断“当前帧有没有人在说话”，给定位/更新做门控
掩码 (TF-mask)	语谱图上每个时频点一个 0~1 的数：这一点主要是目标语音还是噪声。DNN 前端的核心产物 (§5.4、§5.9)
新息 (innovation)	卡尔曼滤波里“观测 - 预测”的差，用它修正状态估计 (§9.2)
EKF (扩展卡尔曼滤波) / UKF (无迹卡尔曼滤波)	两种非线性卡尔曼滤波。EKF 用雅可比做局部线性化；UKF 让一组 sigma 点通过非线性函数。UKF 可减小某些非线性变换的近似误差，但不保证总比 EKF 稳或准，仍取决于模型、调参和数值实现 (§9.2)
JPDA / MHT	多目标追踪中解决“观测属于谁”的两类经典方法：联合概率数据关联 / 多假设跟踪 (§9.3)
锥面模糊	线阵只观测方向在阵列轴上的投影，同一时延可对应绕阵列轴的一圈方向；平面阵的两侧则是法向镜像歧义，二者不要混为一种 (§3.1)
FIR 滤波器	有限长冲激响应滤波器：输出 = 输入最近若干样本的加权和，抽头数 (抽头见本表“信号与数学基础”组) 就是加权长度 (§5.1、§6.1)
重采样 (粒子滤波)	把权重小的粒子删掉、权重大的复制，防粒子退化 (§9.2 算例 9-2 下集)
PHD (概率假设密度) 滤波	传播随机有限集的一阶矩 (强度函数)。某一区域上 $D(\vec{x})$ 的积分给出该区域内目标数的期望值；实际目标状态常从强度峰或高斯分量提取，峰的个数本身不等于人数 (§9.3)
OSPA (最优子模式分配距离)	多目标追踪误差度量，同时罚定位误差和人数错误 (§10.5 评测指标表)

系统与硬件

术语	解释
AEC	声学回声消除：用已知的播放信号做参考，学出回声副本再相减 (§6.1)
DTD (双讲检测)	检测近端语音与远端播放同时活动的状态，用于冻结、减小步长或切换到稳健的 AEC 更新策略 (§6.1)
ERLE	回声返回损失增强，衡量远端单讲时回声功率被降低多少；目标值取决于设备、声学路径、非线性和测量窗口，不能用一个通用区间代替验收条件 (§6.1)

术语	解释
WPE	加权预测误差去混响：用过去帧预测晚期混响拖尾再减掉 (§7.1)
SI-SDR / STOI / PESQ / WER	分离增强失真比 / 可懂度 / 主观质量预测 / 识别错误率 (§10.5 评测指标表)
SDR / SIR / SAR	BSS_eval 三件套：总失真 / 干扰残留 / 算法伪影的分解指标（语音分离论文常用）
MEMS 麦克风	使用微机电工艺制造的微型麦克风，是小型阵列中的常见器件 (§10.2)
PDM / I2S / TDM	常见数字音频接口。单线承载的通道数、时隙和位宽由具体控制器及协议配置决定；阵列通道应共享或校准采样时钟 (§10.2)
dBA	A 计权声级：按规定的 A 计权频率响应处理后得到的声级。它不是未加权 dB，比较数据时要核对参考量和计权方式 (§9.2)
AOP（声学过载点）	在数据手册规定的失真阈值和测试条件下，麦克风可承受的最大声压级；比较器件时必须同时核对阈值、频率和供电条件 (§10.2)
孔径 (aperture)	阵列的最大跨度 D ；分辨率 $\approx$ 波长/孔径
阵列流形 (manifold)	全体候选方向或位置的导向矢量集合，即阵列的方向响应模型；几何定义见 §2.3，实测标定见 §3.4 与 §10.2
AFE（音频前端）	Audio Front End：位于采集与识别、通信或交互后端之间的音频处理部分，可包含 AEC、去混响、波束、降噪和电平控制；实际模块由任务决定 (§10.1)
双讲 (double-talk)	远端播放与近端用户同时发声。近端语音出现在麦克风或误差信号中，不应出现在理想的远端参考信号中；它会使 AEC 的误差不再只含路径失配，因此需用 DTD 控制自适应更新 (§6.1)
MOS（平均意见分）	按规定听测流程收集受试者评分并取统计量。量表、问题、材料和受试者筛选由具体标准规定；客观模型只能在其验证范围内近似预测主观质量 (§10.5)
CHiME	面向复杂声学场景的公开挑战系列，不同届次覆盖远场识别、会议转写、分离或增强等不同任务；数据生成方式和指标应按当届说明读取（附录 B 13.2）
KWS（关键词唤醒）	Keyword Spotting：检测预设关键词的模型。可作为低功耗常驻任务，也可与 VAD、AEC 或增强共享前端；取点和运行方式由功耗及训练数据决定 (§10.3、§10.9)
BOM（物料成本）	Bill of Materials：设备所用元器件的采购成本总和。增加麦克风还可能增加接口、结构、标定和计算成本 (§11.1)
HATS（人工头）	Head and Torso Simulator：带耳廓与躯干声学模型的测量假人，麦克风置于鼓膜位置，用于模拟“人听到的效果”的客观测量 (§10.5)
NLP（非线性处理）	Non-Linear Processing：AEC 里接在线性滤波器之后的残余回声抑制（谱减式/神经式），对付扬声器非线性失真等线性滤波器消不掉的部分 (§6.1)；注意与自然语言处理 (Natural Language Processing) 同缩写，语境区分
PBFDAP	分区块频域自适应滤波：把长回声路径分块并用 FFT 计算卷积与更新。相对时域实现能节省多少计算取决于滤波长度、分块、FFT 库和硬件 (§6.1.3)
IPNLMS	改进比例 NLMS：按抽头幅度成比例分配步长，稀疏冲激响应上收敛更快；混合系数 $\alpha = -1$ 时退化为 NLMS，实践常取 0 或 -0.5 (§6.1.3)
CNG（舒适噪声）	Comfort Noise Generation：残余抑制压得太狠时补回的轻微背景噪声，避免通话“死寂”听感 (§6.1.9)
pAEC	个性化 AEC：把目标说话人的声纹嵌入作为条件，在双讲中增强目标说话人；定义和隐私要求见 §6.1.6、§6.1.14

术语	解释
barge-in (打断)	设备播放 TTS 或音乐时用户直接说话的交互状态。系统需在自发声期间保留近端语音或唤醒词，并让 VAD/KWS 使用合适的 AEC 后取点 (§6.1.6)
TCLw	加权终端耦合损耗：免提终端回声衰减的测试指标。阈值、信号和收敛窗口必须按产品适用的标准版本及测试条款核对，不能跨标准套用固定数值 (§6.1.8)

3 分钟手算 (12.2)：幅度减半是多少 dB？功率减半又是多少 dB？这是两个不同的物理变化；§12.3 还会说明同一物理变化怎样用幅度比或功率比等价表示。答案：幅度减半为 $20 \log_{10} 0.5 \approx -6$ dB；功率减半为 $10 \log_{10} 0.5 \approx -3$ dB。前者对应功率变为四分之一，后者对应幅度变为 $1/\sqrt{2}$ 。

12.3 预备知识速览

本节为零基础读者准备，只讲“够用”的程度。

① **复数与相位——为什么信号要用复数表示。** 本书采用 $e^{j2\pi ft}$ 的时间约定： $e^{j2\pi ft} = \cos(2\pi ft) + j \sin(2\pi ft)$ 。复数可写成幅度与相位的乘积 $z = Ae^{j\phi}$ 。在这个约定下，延迟 τ 对应乘子 $e^{-j2\pi f\tau}$ ，相位变化为 $-2\pi f\tau$ ；若只谈相位差大小，则为 $2\pi f|\tau|$ 。符号正负还取决于通道相减的顺序，估计 TDOA 时必须与通道定义保持一致 (§2.3、§4.2)。

② **分贝 dB——比值的对数表示。** 能量比用 $10 \log_{10}(\cdot)$ ，幅度比用 $20 \log_{10}(\cdot)$ 。系数相差一倍，是因为相同阻抗下功率与幅度平方成正比。因此同一物理变化用两种比值表示时，dB 数相同：幅度变为 0.5 时功率变为 0.25， $20 \log_{10} 0.5 = 10 \log_{10} 0.25 \approx -6$ dB。

dB	幅度比	功率比
+6 dB	×2	×4
+3 dB	×1.41 ($\sqrt{2}$)	×2
0 dB	×1	×1
−3 dB	×0.707 ($1/\sqrt{2}$)	×1/2 (半功率点)
−6 dB	×1/2 (幅度减半)	×1/4
−20 dB	×0.1	×0.01

对数把连乘转为相加，便于表示跨越多个数量级的增益、信噪比和衰减。

dB 练习：① 功率先乘 4 再乘 2，总增益是多少 dB？② 电压增益为 −6 dB 时，幅度比约为多少？答案：① $10 \log_{10}(4 \times 2) \approx 9$ dB；② 幅度约减半，功率约为原来的四分之一。

SNR 换算例。 目标功率为 3、噪声功率为 1 时，线性 SNR 为 3，对应 $10 \log_{10} 3 \approx 4.8$ dB。若处理后输出 SNR 为 12 dB，则 SNR 增益约为 $12 - 4.8 = 7.2$ dB。输入 SNR、输出 SNR 和 SNR 增益是三个不同的量 (§5.1)。

③ **卷积与相关。** 卷积 $y = x * h$ ：信号 x 经过系统 h 后的输出，房间里就是“干净声音卷上 RIR” (§2.4)。相关 $R(\tau)$ ：把两段信号错开 τ 后看相似度，峰在哪里，时延就是多少 (§4.2)。傅里叶变换把卷积变成乘法（时域卷 = 频域乘），这是所有频域算法快的原因。

④ 期望、方差与协方差矩阵。期望 $E[\cdot]$ = 平均；方差 = 离平均多远；协方差 = 两个量“一起起伏”的程度。把 M 个麦克风的协方差排成矩阵就是空间协方差矩阵 $\hat{\mathbf{R}}$ (§2.5) ——它记录的是“哪些麦的信号总是一起动、相位差多少”。

⑤ 最小二乘。方程比未知数多时通常没有精确解，最小二乘求使总残差平方最小的 $\hat{\vec{x}}$: $\min_{\vec{x}} \|\mathbf{A}\vec{x} - \vec{b}\|^2$ 。当 $\mathbf{A}$ 满列秩时， $\hat{\vec{x}} = (\mathbf{A}^H \mathbf{A})^{-1} \mathbf{A}^H \vec{b}$ ；秩不足或条件很差时，应使用 Moore–Penrose 伪逆、QR/SVD 或正则化，不能直接求逆。TDOA 几何解算 (§4.4) 和 WPE 系数估计 (§7.1) 都会用到这一思想。

拉格朗日四步模板 (MVDR)。复约束必须同时包含约束及其共轭，常写成实值函数

$$L = \vec{w}^H \mathbf{R} \vec{w} + 2 \operatorname{Re}\{\lambda^* (\vec{w}^H \vec{a} - 1)\}.$$

对 $\vec{w}^*$ 做 Wirtinger 求导并令零，可写成 $\mathbf{R} \vec{w} + \lambda^* \vec{a} = 0$ ；乘子的命名可吸收共轭与负号，因此得到 $\vec{w} \propto \mathbf{R}^{-1} \vec{a}$ 。再代入 $\vec{w}^H \vec{a} = 1$ 定出比例系数，即得 §5.4 式(5-1)。LCMV 把标量约束和乘子换成向量形式 (§5.5)。

Wirtinger 求导。对实值目标函数，可在 Wirtinger 微积分中把 $\vec{w}$ 和 $\vec{w}^*$ 视为形式上独立的变量，对 $\vec{w}^*$ 求偏导并令其为零。§5.4 的脚注给出与实部、虚部分别求导等价的写法。

⑥ 特征值分解。对 Hermitian 协方差矩阵可写 $\mathbf{R} = \mathbf{E} \mathbf{\Lambda} \mathbf{E}^H$ 。特征向量是传感器观测空间中的正交主轴，特征值表示沿这些主轴的能量；它们通常不等于真实空间中的 DOA。MUSIC (§4.6) 在独立源、白噪声和模型正确等条件下，把较大的特征值所张成的空间解释为信号子空间，把噪声底对应的空间解释为噪声子空间。

3 分钟手算 (12.3)：协方差 $\begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}$ 的特征值和特征向量各是什么？若两个共轭对称的非对角元都变成 0.5，哪个特征值变大？答案：特征值为 4 和 1，对应特征向量可取 $[1, 0]^T$ 和 $[0, 1]^T$ 。非对角元都变为 0.5 后，两个特征值为 $(5 \pm \sqrt{10})/2$ ，约 4.08 和 0.92；通道相关性使特征值间隔增大。

病态矩阵与对角加载。当最大、最小奇异值相差很大时，矩阵条件数高，求逆会放大数据和舍入误差。低频小间距的超指向设计 (§5.3) 是常见例子。把 $\mathbf{R}$ 换成 $\mathbf{R} + \epsilon \mathbf{I}$ 可抬高小特征值、改善条件数，但也会改变最优权重并牺牲一部分指向性。附录 B 第 8 题可比较加载前后的 WNG、DI 与条件数；数值由脚本参数决定，不预设固定区间。

附录 B · 路径地图与练习

⚠ 本篇是附录 B（正文共 11 章，另有附录 A/B），可独立查阅，前后篇见下方导航。

🏠 首页导读：00_overview.md | 上一篇：12_appendix-symbols-math.md | 下一篇：(无)

13.1 研究生学习路径

下面的阅读与实验顺序从经典模型开始，再过渡到公开基线、数据集和硬件实验。

- 1. **基础阅读**：Van Veen & Buckley, *Beamforming: A Versatile Approach to Spatial Filtering* (IEEE ASSP Mag. 1988)；Krim & Viberg, *Two Decades of Array Signal Processing* (IEEE SPM 1996)。
- 2. **语音场景**：Kumatani et al., *Microphone Array Processing for Distant Speech Recognition*；Gannot et al., *A Consolidated Perspective on Multimicrophone Speech Enhancement and Source Separation* (IEEE/ACM TASLP 2017)。
- 3. **原始论文**：Capon (1969)、Griffiths & Jim GSC (1982, *An Alternative Approach to Linearly Constrained Adaptive Beamforming*, IEEE Trans. Antennas Propag. 30(1):27–34)、Schmidt MUSIC (1986)、Roy & Kailath ESPRIT (1989)、Allen & Berkley 镜像法 (1979)、Nakatani et al. WPE (IEEE TASLP 2010)、Pal & Vaidyanathan 嵌套阵 (IEEE TSP 2010)。
- 4. **回声消除**：Hänsler & Schmidt, *Acoustic Echo and Noise Control* (Wiley 2004)；近年进展看 ICASSP AEC Challenge 系列报告。
- 5. **DNN 方向**：Chakrabarty & Habets (IEEE JSTSP 2019)、Gu et al. 全神经波束形成 (IEEE/ACM TASLP, vol.31, pp.849–862, DOI 10.1109/TASLP.2022.3229261)。
- 6. **实验顺序**：用 pyroomacoustics 验证 DSB、MVDR、MUSIC 和 SRP-PHAT 基线；运行 scripts/ 中的两个绘图脚本，复现 33 张图；选择与研究任务匹配的公开数据和参考系统；最后在可用的多通道硬件上验证实时性、同步和标定。数据集、框架和硬件只是候选工具，应根据任务与许可证选择。

13.2 领域地图：教材、会议、期刊与挑战赛

本节按教材、会议、期刊、挑战赛和历史脉络组织，可按需要查阅。

教材与专著（由浅到深）：

书	特点
Benesty, Chen & Huang, <i>Microphone Array Signal Processing</i> (Springer 2008)	本领域标准入门书，篇幅适中，覆盖定位/波束/去混响
Brandstein & Ward (eds.), <i>Microphone Arrays: Signal Processing Techniques and Applications</i> (Springer 2001)	经典论文式合集，各章由领域奠基人撰写
Tashev, <i>Sound Capture and Processing: Practical Approaches</i> (Wiley 2009)	微软工程视角，工业实现细节最丰富

书	特点
Johnson & Dudgeon, <i>Array Signal Processing: Concepts and Techniques</i> (Prentice Hall 1993)	通用阵列信号处理经典（雷达/声呐同源理论）
Van Trees, <i>Optimum Array Processing</i> (Wiley 2002)	权威“圣经”大部头，适合深入时查阅
Vincent, Virtanen & Gannot (eds.), <i>Audio Source Separation and Speech Enhancement</i> (Wiley 2018)	分离与增强方向的现代合集
Rafaely, <i>Fundamentals of Spherical Array Processing</i> (Springer, 一版2015, DOI 10.1007/978-3-662-45664-4; 二版 online 2018、版权2019, DOI 10.1007/978-3-319-99561-8)	系统介绍球阵与球谐域处理，可配合 §5.8 阅读

会议：ICASSP（信号处理旗舰会）、Interspeech（语音领域旗舰会）、WASPAA（音频与声学信号处理研讨会，两年一届）、IWAENC（声学信号增强研讨会）、HSCMA（免提语音通信与麦克风阵列研讨会）、DCASE Workshop（声事件与场景）。

期刊：IEEE/ACM Transactions on Audio, Speech, and Language Processing (TASLP, 本领域主刊)、IEEE JSTSP（信号处理选题特刊）、JASA（美国声学学会刊）、Speech Communication。

挑战赛（用于了解公开任务和评测口径）：CHiME 覆盖远场、多说话人和多通道语音处理；CHiME-9 设置 MCoRec 多会话鸡尾酒会转写与会话聚类、ECHI 低延迟助听对话增强。[CHiME 官方](#)于 2026 年 7 月公布 CHiME-10 的 ECHI-2、URGENT、SG-TSE 三项任务；挑战计划于 2027 年 2 月 4 日开放，提交期暂定为 2027 年 8~9 月。日程可能调整，参赛时应以官方页面为准。DCASE 2026 Task 3 是 Semantic Acoustic Imaging SELD，与 DCASE 2024 Task 3 的距离估计设置不同；任务定义见 [DCASE 2026 官方页面](#)。其他公开评测包括 REVERB 去混响评测、ICASSP DNS/AEC Challenge，以及面向 AR 设备语音增强的 SPEAR。

历史脉络（本领域是雷达/声呐技术向语音的迁移史）：

年代	里程碑
1940s—60s	雷达/声呐阵列处理奠基（Bartlett 波束扫描）
1969	Capon 最小方差谱估计（为地震学阵列而做）
1972	Frost 时域约束自适应波束形成
1979—82	Allen & Berkley 镜像法房间仿真；Griffiths & Jim 提出 GSC
1985	Flanagan 等在 Bell Labs 做出首个计算转向的大孔径会议室麦克风阵列
1986—89	MUSIC（1986）、ESPRIT（1989）把到达方向估计的分辨率推进到突破瑞利限的水平
1990s	Elko 差分麦克风阵列进入助听器与桌面会议设备
2001—08	Brandstein & Ward、Benesty 等教材出版，语音阵列知识体系化
2010	Nakatani 提出 WPE 去混响；Pal & Vaidyanathan 提出嵌套阵
2011	首届 CHiME 挑战赛，远场语音成为公开评测对象
2014	Amazon Echo（6+1 圆环麦克风）开启消费级远场语音时代

年代	里程碑
2015—18	CHiME-3/4/5 引爆“掩码 + 波束形成”路线；GSS（2018）
2019—24	DNN 定位/追踪（ACCDQA：声源活动与方向联合输出，Shimada et al., ICASSP 2021）、端到端一体化；CHiME-7/8 大模型后端；STARSS24（DCASE 2024 Task 3）新增声源距离估计子任务
2025—26	CHiME-9 设置 MCoRec 与 ECHI；2026 年 7 月公布 CHiME-10 三项任务；DCASE 2026 Task 3 转为 Semantic Acoustic Imaging SELD

13.3 研究前沿速览（2024—）

本节把正文中的经典方法与 2024 年以来若干公开研究方向相连。具体成绩只在原论文的数据、实现和评测条件下成立。

本节把正文中的经典方法与 2024 年以来的若干研究方向相连。带具体年份、成绩或日程的内容会随新论文和官方页面更新，不应据此推断整个领域已经形成共识。

- 大模型进入远场后端**：CHiME-7/8（2023/2024）的明显趋势是 Whisper、WavLM 等大规模预训练模型做识别后端，前端+后端的端到端化加速；同时GSS（导引源分离，详见 §8.1，用分割结果引导的解析波束）仍是多通道任务中成绩较好的常见选择，纯神经分离在真实复杂场景中尚未完全取代解析方法。[CHiME-7/8 综述 arXiv:2507.18161](#)
- 阵列无关（array-agnostic）系统**：CHiME-8 展示了不固定阵列拓扑、可跨设备使用的系统设计，并报告了与特定几何系统相近的结果。这个结论受任务、训练数据和参赛系统范围限制，更适合用来说明跨阵列泛化已具备可行基线。[CHiME-8 DASR](#)
- 目标说话人提取（Target Speaker Extraction, TSE）**：系统用注册语音、视觉或方向提示描述目标说话人，再从混合语音中提取相应音轨。AR 眼镜阵列和手机结构辅助方向提取提供了不同的条件输入形式。[SonicSieve, arXiv:2504.10793](#) TEA-PSE（ICASSP 2022, DOI 10.1109/ICASSP43922.2022.9747765；后续版本 arXiv:2303.07704）和 [CIENet](#) 等方法从注册语音提取说话人嵌入，再通过条件注入或帧级对齐估计目标掩码。§6.1.6 的个性化 AEC 与这类条件提取方法相关，但训练目标和回声参考结构仍需分别定义。
- 神经差分与方向滤波**：把第 5 章的超指向或 DMA 结构参数化，再用数据学习延迟、增益或级联系数。这类“解析结构 + 学习参数”方法兼顾可解释性和适配能力，是小型阵列的一条活跃研究路线；是否优于掩码加解析波束，仍要按设备尺寸、延迟、训练数据和失配条件比较。
- 生成式语音增强与推理加速**：SGMSE+（Richter et al., IEEE/ACM TASLP 2023）在复数 STFT 域使用基于随机微分方程的扩散模型；StoRM（Lemercier et al., IEEE/ACM TASLP 2023）把判别式回归与生成过程结合，以减少采样负担。[SGMSE+ 代码与论文](#)、[StoRM 代码与论文](#)。这类方法可能改善特定数据上的感知质量，也可能生成参考中不存在的语音细节，因此要同时评估听感、内容一致性和下游 WER。流匹配、蒸馏和一致性模型试图减少采样步数；FlowSep（ICASSP 2025）把整流流用于 VAE 隐空间中的文本查询通用音频分离，其结论不能直接外推到多通道语音增强。[FlowSep, arXiv:2409.07614](#) 多通道生成模型还需显式处理跨通道相位、空间协方差和实时性，目前与 §5.9 的掩码加解析波束属于不同成熟度的技术路线。
- TF-GridNet 与复数谱映射骨干**：TF-GridNet（IEEE/ACM TASLP 2023）最初用于单通道说话人分离，并在 WSJ0-2mix 上报告 23.4 dB SI-SDRi；后续多通道方法也借用了其帧内、帧间双路径结构。[TF-GridNet](#),

[arXiv:2209.03952](#) TF-LoCoformer (IWAENC 2024) 用包含卷积前馈网络和注意力的结构替换循环模块，代表了 Transformer 化的改进方向。[TF-LoCoformer](#), [arXiv:2408.03440](#)

7. **状态空间模型用于语音分离**: SPMamba (2024) 把状态空间模块用于双路径时频建模，并在 WSJ0-2Mix、WHAM!、Libri2Mix 和 Echo2Mix 上报告性能与效率结果；SepMamba (ICASSP 2025) 也把 Mamba 引入说话人分离。线性序列复杂度是其处理长录音的潜在优势，但端到端速度仍取决于算子实现和硬件。

[SPMamba](#), [arXiv:2404.02063](#)

8. **几何无关前端的期刊研究**: Kamo et al. 在 *Computer Speech & Language* 95:101820 (2026) 中整理了几何无关的多说话人远场识别系统，并在真实会议数据上评估。[Kamo et al., Computer Speech & Language](#) 它与 CHiME-8 的系统共同说明，不固定阵列拓扑可以作为明确的系统设计目标；泛化范围仍以论文的训练阵列、测试设备和数据为边界。
9. **CHiME-9 与大模型后端**: CHiME-9 设置 MCoRec 和 ECHI 两项任务；前者涉及多会话转写与会话聚类，后者研究低延迟助听对话增强。[CHiME-9 官网](#) DiCoW (Polok et al., *Computer Speech & Language* 95:101841, 2026) 把分割信息作为条件注入 Whisper，用于目标说话人识别，说明前端的分割、增强结果可以作为大模型后端的显式条件，而不只是输出单路音频。[DiCoW](#), DOI [10.1016/j.csl.2025.101841](#)

专栏：神经网络前端的泛化失配与四类对策

本专栏解释阵列或房间改变后性能下降的原因，并展开 13.3 第 2、8 条涉及的四类对策。

神经网络前端可能在训练阵列和房间上表现良好，换到新的几何、声学条件或任务后却明显退化，这就是**泛化失配**。下面把失配分为阵列、声学、任务与数据三类，再从数据、表示、训练和部署四方面讨论缓解方法。

失配三源：

1. **阵列失配**：训练与部署的几何、通道数、麦克风一致性或采样时钟不同。若网络依赖固定通道编号及其相位关系，更换阵列后这些特征不再成立，端到端波束尤其容易受影响 (§5.9 第 2 条)。
2. **声学失配**：混响时间、噪声类型和说话人距离改变。训练数据未覆盖相应混响尾部或噪声结构时，掩码估计误差会传递到协方差和 MVDR 权重。
3. **任务与数据失配**：仿真未包含麦位误差、挡板散射或非平坦频响；训练与测试的语言不同；面向听感训练的增强模型被直接用于 ASR。最后一种情况还要检查生成式模型是否改变语音内容 (§13.3 第 5 条)。

四类对策：

1. **数据**：混合多种阵列几何、房间、采样率和噪声进行训练，并用少量目标设备录音适配。目标是覆盖可能变化的相位和幅度关系，而不是穷举设备。
2. **表示**：让网络输出掩码、协方差或说话人活动等中间量，再由 MVDR 或 GSS 等解析方法施加无失真约束 (§5.9 第 1 条)。这种分工仍需验证中间量是否真正跨几何泛化。
3. **训练**：随机丢弃通道、置换通道顺序并扰动麦克风坐标，分别模拟通道失效、可变麦数和标定误差；网络结构还要满足相应的置换不变或等变性质。
4. **部署**：先做通道一致性和几何标定，再根据置信度、资源和失败模式选择模型或解析基线。模型分级只是候选架构，是否有净收益要在目标硬件上测量。

阵列无关系统的常见结构：各通道先独立提取特征，再用注意力或池化聚合成对通道顺序不敏感、可接受可变通道数的表示。中间量可选掩码、协方差或说话人活动；分离与波束部分采用 GSS 等解析方法，或使用满足几何无关要求的神经前端。后端再用预训练识别模型吸收残余失配。CHiME-8 DASR 与 §13.3 第 8 条的期刊系统给出了两类公开实例。复现时应画出实际流程图，并逐项标明训练数据、通道聚合方式、解析约束和测试阵列范围。

TAC 与 VarArray。TAC (Transform–Average–Concatenate) 先对各通道独立变换，再跨通道平均并把聚合结果拼回各通道，从结构上支持可变通道数和通道置换。VarArray 把 TAC、Conformer 分离和通道间相位差特征用于几何无关的连续语音分离，并在 AMI 会议转写上报告端到端 saWER 结果。它们为后续跨设备系统提供了结构基础。
[VarArray, arXiv:2110.05745](#)

13.4 常见问题与调试指南

下面按“现象 → 优先检查项”列出八类常见问题。

- 1. **MUSIC 没有峰 / 峰乱飞** → 先看样本协方差的秩与条件数：未去均值时 $T < M$ 必然奇异， $T \geq M$ 也不代表估计已经稳定；再检查源数 K 和噪声底是否可分，最后检查直达声与反射是否强相干。空间平滑只适用于具有可分重叠子阵的几何，而且会缩短有效孔径；它不是所有混响场景的必选项 (§2.5、§4.6)。
- 2. **GCC-PHAT 峰位置跳格子** → 没有做亚采样插值 (§4.2 的抛物线插值)，或采样率太低；也可能是强反射峰超过直达峰 (图13)。
- 3. **波束形成后目标语音反而失真** → 先查 DOA、RTF 和通道标定是否一致，再检查噪声协方差的估计方式。它既可由目标缺席帧估计，也可由时频掩码加权估计；关键是尽量排除目标泄漏，同时保留足够有效快拍。混响中还要确认约束对象是否应改用 RTF (§5.4、§5.9)。
- 4. **超指向输出噪声很大** → 检查 WNG、协方差条件数、通道增益相位和阵列流形误差。容许的失配没有统一 dB 门槛，应从目标 WNG、最高工作频率和实测波束图反推；可用对角加载或显式 WNG 约束改善稳健性 (§5.3、§5.4)。
- 5. **AEC 总是消不干净** → 最常见病根是参考信号与真实播放不同步 (参考要取播放链路末端并补偿系统延迟)；其次是扬声器非线性失真超出线性滤波器能力，需 NLP 或神经 AEC (§6.1)。
- 6. **SRP-PHAT 出现镜像假峰** → 间距超过半波长出现栅瓣 (§2.6)，或墙面的强反射形成了“镜像声源”——先检查无混叠带宽，再考虑限制搜索空间。
- 7. **多麦录音各通道逐渐错位** → 先区分固定的初始时差、独立丢样和 SRO。单设备可让通道共享采样时钟；分布式设备无法共享时钟时，要估计相对采样率并重采样。PDM/TDM 是接口形式，不自动保证跨设备同步 (§10.2)。
- 8. **仿真很好、实测很差** → 逐项加入麦位误差、通道增益相位误差、壳体散射、频响差异、时钟偏移和扬声器非线性，寻找哪一项能复现实测退化。位置容差应按最高频率允许的相位误差换算，不存在对所有阵列通用的毫米阈值。完成标定后，再在容差范围和多个位置上复测。

13.5 核心公式速查卡

下表汇总正文中的关键公式，便于复习和查阅。公式成立条件仍以对应章节为准。

公式	含义	章节
$10 \log_{10} M$	无失真归一化、各通道独立等功率白噪声下， M 元 DSB 的 WNG (dB)	§1、 §5.2
$r > 2D^2/\lambda$	远场/近场分界 (Fraunhofer)	§2.2
$T_{60} = 0.161V/A$	赛宾公式：房间混响时间	§2.4
$d_c = 0.057\sqrt{V/T_{60}}$	临界距离：直达/混响相等处	§2.4
$\vec{x} = \vec{a}(\theta)s + \vec{n}$	远场窄带阵列信号模型	§2.3

公式	含义	章节
$\hat{\mathbf{R}} = \frac{1}{T} \sum_t \vec{x} \vec{x}^H$	空间协方差矩阵估计	§2.5
$d \leq \lambda/2$	ULA 在整个可视角域避免栅瓣的充分条件；限定转向范围时可放宽	§2.6
CRB 公式	给定统计模型与正则条件下，无偏 DOA 估计方差的下界	§2.6
$\hat{\theta} = \arcsin(c\hat{\tau}/d)$	时延差 $\rightarrow$ 角度	§4.2
$R(\tau) = \int \Phi X_1 X_2^* e^{j2\pi f\tau} df$	GCC 加权互相关	§4.2
$\hat{\vec{p}} = \arg \max_{\vec{r}} \sum R^{PHAT}$	SRP-PHAT 全阵列投票	§4.3
$P_C = 1/(\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a})$	Capon 谱	§4.5
$P_{MU} = 1/(\vec{a}^H \mathbf{E}_n \mathbf{E}_n^H \vec{a})$	MUSIC 伪谱	§4.6
$\vec{w}_{DSB} = \vec{a}/M$	延迟求和波束	§5.2
$ B(\theta) = \left \frac{\sin(M\psi/2)}{M \sin(\psi/2)} \right $	等权 ULA 的归一化阵因子， $\psi = 2\pi d(\sin \theta - \sin \theta_0)/\lambda$	§5.2
$\vec{w}_{SD} = \frac{\mathbf{\Gamma}^{-1} \vec{a}}{\vec{a}^H \mathbf{\Gamma}^{-1} \vec{a}}$	超指向：在无失真约束下最小化弥散噪声输出	§5.3
$\vec{w}_{MVDR} = \mathbf{R}_{nn}^{-1} \vec{a} / (\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a})$	最小方差无失真	§5.4
$\vec{w}_{LCMV} = \mathbf{R}^{-1} \mathbf{C} (\mathbf{C}^H \mathbf{R}^{-1} \mathbf{C})^{-1} \vec{f}$	多约束最小方差解	§5.5
$\vec{w}_{SDW} = (\mathbf{R}_{ss} + \mu \mathbf{R}_{nn})^{-1} \mathbf{R}_{ss} \vec{e}_r$	失真可调维纳滤波	§5.5
$e = d - y$	GSC 中固定波束输出 d 减去自适应抵消输出 y ；在阻塞矩阵理想、支路自由度足够且优化收敛时与相应 LCMV 等价	§5.6
NLMS 更新式	AEC 自适应滤波	§6.1
$ERLE = 10 \log_{10} \frac{E[d^2]}{E[e^2]}$	回声返回损失增强，仅远端单讲时段测量	§6.1
$X(n, f) = E(n, f) + \sum_{k=\Delta}^{\Delta+K-1} G^*(k, f) X(n-k, f)$	单通道记法下的 WPE 预测模型；多通道时 G 与历史观测为向量	§7.1
KF 五步	预测-更新-增益循环	§9.2
$D_{t t-1}(\vec{x}) = \gamma_t(\vec{x}) + \int p_S(\vec{\xi}) f_{t t-1}(\vec{x} \vec{\xi}) D_{t-1}(\vec{\xi}) d\vec{\xi}$	PHD 预测：新生目标强度加存活目标的状态转移	§9.3

13.6 思考与练习

练习按章节排列。修改脚本参数时，应同时记录随机种子、实验条件和输出指标。

练习涉及的绘图函数（做题时打开对应函数按题面改参数就行）：

函数名	它画的是什么	用在哪道题
<code>fig_geometries</code>	阵列形态布局	题4
<code>fig_gcc_phat</code>	GCC-PHAT 原理	题5
<code>fig_doa_spectrum</code>	DOA 空间谱	题6
<code>fig_wng_di</code>	WNG-DI 权衡	题8
<code>fig_wpe</code>	WPE 去混响	题9

函数名	它画的是什么	用在哪道题
fig_tracking	粒子滤波追踪	题12

按章节编排，动手题用的绘图函数都在 `scripts/` 里（哪个题用哪个函数见上表），第 15 题还要装开源库 `pyroomacoustics`（房间声学仿真库，扩展依赖，见 §13.7）。数值题附参考答案（区间），综合题附思路提示。

第 1 章（问题定义）

- 思考题：为什么“双耳 + 自由转头”通常比静止双耳更容易消除前后混淆？（提示：静止时并非只有两个数；ITD、ILD 和 HRTF 的频谱线索都随频率变化。某些镜像方向仍会产生相近线索，转头后这些线索按不同轨迹变化，动态观测可打破歧义。联系 §1.1 与 §3.1 的几何对称性。）

第 2 章（基础）

- 手算：3 麦线阵、间距 3 cm、声源 45° 、频率 2 kHz，写出导向矢量；该频率是否满足全视场无混叠条件？6 kHz 呢？（参考答案：2 kHz 时 $\lambda = 17.15$ cm, $\psi = \frac{2\pi d}{\lambda} \sin 45^\circ \approx 0.777$ rad, $\vec{a} = [1, e^{-j0.777}, e^{-j1.554}]^\top$; $d < \lambda/2$, 满足全视场安全条件。6 kHz 时 $\lambda \approx 5.72$ cm, $d > \lambda/2$, 不再保证所有方向无混叠。但对本题 $\theta_0 = 45^\circ$, 候选歧义满足 $\sin \theta = \sin 45^\circ \pm \lambda/d \approx 0.707 \pm 1.91$, 两解都落在 $[-1, 1]$ 外, 因此该转向本身没有可见等高栅瓣。条件被突破不等于每个转向都必然出现栅瓣。）
- 用赛宾公式估算你所在房间的 T_{60} 与临界距离 d_c , 判断 3 m 对话处在直达占优还是混响占优区。（参考示例：5 m × 4 m × 2.8 m 客厅, $V = 56$ m³、 $A \approx 18$ m²（取平均吸声系数约 0.2） $\rightarrow T_{60} = 0.161V/A \approx 0.5$ s, $d_c = 0.057\sqrt{V/T_{60}} \approx 0.6$ m; 3 m 对话距离 $\gg d_c$, 处于混响占优区——这正是远场语音难做的日常写照。）

第 3 章（几何）

- 打开 `fig_geometries` 按题面改：把 6+1 圆环改成 8 麦；改麦数时坐标、标题、图注要一起改。思考：中心麦能提供什么新信息？（提示：它可作为参考通道，并新增从中心到各环麦的基线；“到各环麦距离相等”描述的是几何布局，不表示任意入射方向下都与环麦等相位。固定半径时增加环上麦数会缩短相邻间距，但不会增加最大孔径。）

第 4 章（定位）

- 打开 `fig_gcc_phat`, 逐步增加噪声并比较 PHAT 与普通互相关。记录每个随机种子、信号谱和混响条件下的峰值误差，不预设固定 SNR 崩溃点。（提示：PHAT 去掉幅度谱着色，可能让峰变尖，也可能在低信噪比频带放大相位噪声。它的优势取决于源谱、噪声谱和反射结构。）
- 在 `fig_doa_spectrum()` 中把两源间隔从 50° 缩到 15° 、 8° , 观察 Bartlett、Capon、MUSIC 的谱峰。8 元半波 ULA 的离散阵因子 HPBW 近似为 $0.886\lambda/(Md) \approx 12.7^\circ$; 用物理跨度 $D = (M-1)d = 3.5\lambda$ 得到的 $\lambda/D \approx 16.4^\circ$ 只是孔径尺度。不要预先规定谁在某个角度必然失败：实际结果取决于 SNR、快拍数、源相关性、加载和峰值判据。MUSIC 在理想独立源条件下可能分辨小于常规主瓣宽度的两源，但不保证在失配或相干源下保持这一能力。

第 5 章（波束形成）

- 从拉格朗日函数推出 MVDR 闭式解，再回 §5.4 对答案。（提示：构造实值函数 $L = \vec{w}^H \mathbf{R}_{nn} \vec{w} + 2 \operatorname{Re}\{\lambda^* (\vec{w}^H \vec{a} - 1)\}$, 对 $\vec{w}^*$ 求导，得到 $\vec{w} \propto \mathbf{R}_{nn}^{-1} \vec{a}$, 再代入约束定比例系数。）

8. 在 `fig_wng_di()` 中把麦距从 4 cm 改成 2 cm 与 8 cm, 画出 WNG、DI 和协方差条件数, 再比较有无对角加载。记录脚本实际输出, 不预设某个频率的固定 dB 数。解释: 低频 kd 很小时, 各阵元观测接近相同, 弥散噪声相干矩阵容易病态; 超指向解需要大幅度、相互抵消的权重, 因而 WNG 下降。增大间距可能改善低频条件数, 也可能在高频引入空间混叠, 不能只看一端。

第 7 章 (去混响)

9. 打开 `fig_wpe` 按题面修改: 把 T_{60} 从 0.6 s 改为 0.3 s 与 1.0 s, 观察去混响效果的边界; 再把保护延迟改为 0。只修改 `wpe_dereverb(Yr, K=8, delay=2, iters=3)` 调用中的实参 `delay=2`, 保持函数定义的默认值不变。比较输出并解释原因。(提示: T_{60} 越长, 固定 K 的预测窗越难覆盖完整拖尾, 残余混响会增加; `delay=0` 使预测项包含当前帧, 可能把直达声一并消除并造成明显失真。)

第 6 章 (AEC)

10. 手算 (AEC, 接算例 6-1): 回声路径 $\vec{h} = [0.8, 0.3, 0.1]^T$, 参考为单位脉冲 $x(0) = 1$ 、其余时刻为 0; 3 抽头 NLMS, $\hat{\vec{w}}(0) = \vec{0}$, $\mu = 0.5$, 忽略 ε 。手算 $n = 0, 1, 2, 3$ 的 $d(n)$ 、 $e(n)$ 与 $\hat{\vec{w}}(n+1)$, 并解释为什么 3 步之后滤波器恰好停在 $0.5\vec{h}$ 。(参考答案: $d = [0.8, 0.3, 0.1, 0]$ (脉冲卷上 $\vec{h}$ 就是 $\vec{h}$ 本身); $n = 0$: $\vec{x} = [1, 0, 0]^T$, $\hat{y} = 0$, $e = 0.8$, $\|\vec{x}\|^2 = 1$, $\hat{\vec{w}} \leftarrow [0.4, 0, 0]^T$; $n = 1$: $\vec{x} = [0, 1, 0]^T$, $\hat{y} = 0$, $e = 0.3$, $\hat{\vec{w}} \leftarrow [0.4, 0.15, 0]^T$; $n = 2$: $\vec{x} = [0, 0, 1]^T$, $e = 0.1$, $\hat{\vec{w}} \leftarrow [0.4, 0.15, 0.05]^T$; $n = 3$: $\vec{x} = \vec{0}$, 归一化分母为零、跳过更新。脉冲每步只激励一个抽头, 该抽头按 $e' = (1 - \mu)e$ 学到一半, 故终点恰为 $0.5\vec{h}$; 想让所有抽头收敛到 $\vec{h}$ 本身, 需要持续且方向丰富的激励 (白噪声、语音) ——这就是 §6.1.2“激励要够丰富”的手算版。)
11. 论述题: 为什么多数时变波束系统把 AEC 放在波束形成之前? 有没有例外? (思路提示: 若权重随追踪变化, 波束后的等效回声路径 $h_{\text{eff}}(t) = \vec{w}(t)^H \vec{h}(t)$ 也随时间变化, 单路 AEC 更难跟踪。若波束固定或采用联合多通道回声模型, 波束后 AEC 并非数学上不可能, 只是路径变化、双讲控制和多波束复用要重新设计。)

第 9 章 (追踪)

12. 打开 `fig_tracking` 按题面改: 把观测噪声从 7° 增大到 20° , 粒子滤波需要把粒子数加到多少才能不丢目标? 观察粒子退化现象。注意观测噪声有两个 7 要一起改: 生成观测数据的那个, 和算似然权重分母里的那个; 只改一处等于观测和模型对不上, 做的就是模型失配实验, 不是单纯的噪声变大。(参考区间: 粒子数从 300 加到约 1000~2000 量级通常可稳住, 这是经验量级 (约 3~7 倍)。真正决定下限的是观测噪声: 本玩具里 20° 噪声下 RMSE floor 约 13° , 加粒子几乎不降; 真正需要加粒子的情形是状态维度升高、似然更尖或模型失配。同时观察 `n_eff` 曲线: 观测噪声大时权重扁平化, 退化反而变慢, 但估计方差增大、峰值期易飘移。缓解手段是调大过程噪声或改用系统重采样。)

第 10 章 (工程实现)

13. 思考题: 一台 6 麦音箱的项目需求规定“唤醒到应答 < 300 ms”。按 §10.1 的延迟分类和关键路径公式拆分预算, 并指出三处优先优化项。(提示: 分别列出前瞻、缓冲、计算、调度和解码/交互。把 STFT 窗长从 32 ms 改为 16 ms 只会改变依赖完整窗的等待, 不会自动把端到端延迟减半; WPE 流式化和后端分级也要以实测关键路径验收。)

第 11 章 (选型)

14. 思考题：给“车载 4 麦分布式 + 强发动机噪声 + 免唤醒连续对话”场景写一段选型论证，分别说明几何、定位、波束和 AEC。（提示：按 §11.1 的六个问题补齐条件；检查分布式 SRO 风险 (§10.2)、低频噪声下超指向的 WNG、AEC 参考是否覆盖车机实际播放处理，以及连续对话期间哪些模块需要保持运行。功耗预算见 §10.4 和 §10.9。）

综合

15. 用 pyroomacoustics 生成目标 $T_{60} = 0.6$ s 的房间 RIR，跑 SRP-PHAT，并在多个距离、方向和随机声源位置上重复实验。吸声系数应由房间体积、表面积与目标 T_{60} 反算，镜像阶数要提高到结果收敛，并在代码中写入实际计算值。画定位误差、DRR 与距离三者的关系。临界距离给出 DRR 量级参考，但定位误差不保证在该处出现清晰拐点。
16. （研究拓展）读一篇 CHiME-8 参赛系统报告（见 §13.3 引用），按报告实际结构画出前端流程图，与本报告图 23 对照。逐项标出定位、分割、GSS/波束、增强和 ASR 后端是否存在，不先假定高排名系统都采用同一架构；再说明其阵列无关设计依赖哪些训练数据或解析模块。

13.7 复现说明

下面两条命令用于重新生成全部 33 张图。

绘图脚本都在 `scripts/` 里。在报告根目录跑两个命令，结果进 `figures/`，共 33 张图（图 1~25、图 33 约 20 秒，图 26~32 约 11 秒，全套约半分钟，机器不同有出入）：

```
.venv/bin/python scripts/make_figures.py      # 图 1~25、图 33
.venv/bin/python scripts/make_aec_figures.py  # 图 26~32（回声消除专题）
```

Windows 上把 `.venv/bin/python` 换成 `.venv\Scripts\python`，其余不变。

脚本的基础依赖是 `numpy` 和 `matplotlib`，并使用固定随机种子，因此相同环境和参数下应得到相同结果。每个脚本生成哪些图、练习需要哪些扩展依赖，见 `scripts/README.md`。

主要定量结论引自公开文献与专利实验（见正文引用链接），不同实验条件下绝对数值不可直接横向比较，请以量级与趋势为准。