

# 麦克风阵列信号处理教程

深入浅出 · 从阵列摆位到工程选型（合订本）

构建日期 2026-09-24 · 源文件 sha256 aa6753028900 · 共 14 篇：导读、11 章正文、2 篇附录

# 目录

---

- 导读与导航
  - 1. 这是一份什么样的教程
  - 2. 14 个文件一览
  - 3. 各篇内容与学习目标
  - 4. 阅读顺序
  - 5. 三条阅读路径
  - 6. 插图地图：39 张图在哪篇
  - 7. 十处跨文档联系
  - 8. 动手复现
  - 9. 常见问题
  - 附录：下一步清单
- 第 1 章 · 问题定义与双耳启示
  - 导入：从客厅场景认识阵列任务
    - 客厅里的远场语音问题
    - 空间处理的三项任务
    - 三类阵列收益与白噪声增益
  - 1.1 双耳听觉的三类定位线索
  - 本章练习
- 第 2 章 · 声音到达阵列时发生了什么
  - 2.1 核心事实：同一声音，到达各麦克风有先有后
  - 2.2 近场与远场
  - 2.3 信号模型：把“声音有先有后”写成数学
  - 2.4 房间声学：混响到底是怎么来的
    - 2.4.1 房间脉冲响应与早晚反射
    - 2.4.2 混响时间：从吸声量算衰减
    - 2.4.3 直达混响比与临界距离
    - 2.4.4 仿真与实测房间脉冲响应
  - 2.5 数据怎么组织：STFT、快拍与协方差矩阵
    - 2.5.1 从波形到逐频点的短时谱
    - 2.5.2 从多通道快拍到空间二阶矩
    - 2.5.3 真实录音：交叉项为何不能随意省去
    - 2.5.4 语音信号会改变哪些估计条件
  - 2.6 怎么衡量一个波束好不好：先学会读波束图
    - 2.6.1 半功率波束宽度：主瓣有多宽
    - 2.6.2 旁瓣电平：其他方向漏进多少
    - 2.6.3 指向性指数：弥散场中的目标方向优势
    - 2.6.4 白噪声增益：独立通道底噪怎样进入输出
    - 2.6.5 分辨率尺度与空间混叠
    - 2.6.6 精度理论下界：克拉美 – 罗界
    - 2.6.7 算例 2-1：复算 CRB 的五个因子
    - 2.6.8 算例 2-2：同一阵列的 DI 与 WNG
  - 2.7 小结：声源走近了，平面波不够用——近场要换的三样东西
  - 本章练习

## • 第 3 章 · 阵列几何形态

- 3.1 形态总览
  - 算例 3-1 双耳耳机的差分——1 cm 间距怎么做心形指向
  - 算例 3-2 端射灵敏度——同一个 10  $\mu$ s 误差在不同方向的影响
- 3.2 四条设计规律
  - 3.2.1 先看孔径、方向、挡板和麦数
  - 3.2.2 算例 3-3: 6 麦圆环的数字
  - 3.2.3 算例 3-4: ULA 主瓣宽度计算
- 3.3 稀疏阵列与差分协同阵
  - 3.3.1 协同阵的概念: 从麦的位置到麦对的间距
  - 3.3.2 物理协方差怎样给出虚拟滞后
  - 3.3.3 代价与边界: 差分空缺、宽带和混响
- 3.4 阵列校准: 麦克风个个不一样时怎么办
  - 3.4.1 增益相位自校准: 利用未知声源的多位置观测
  - 3.4.2 互耦补偿: 把串音矩阵抵消掉
  - 3.4.3 位置自标定: 有锚测绘、无锚边走边建图
  - 3.4.4 失配灵敏度表: 先坏哪、坏多少
- 本章练习

## • 第 4 章 · 声源定位 (DOA 估计)

- 4.1 总览: 四大类思路
  - 4.1.1 源数估计: 确定信号子空间维数
- 4.2 GCC-PHAT: “对齐两段录音, 找最吻合的错位”
- 4.3 SRP-PHAT: 跨麦对累积空间响应
- 4.4 两阶段法的几何解算
- 4.5 波束扫描类: Bartlett 与 Capon
- 4.6 子空间类: MUSIC 与 ESPRIT
  - 窄带方法一: MUSIC (多重信号分类, Schmidt, 1986)
  - 窄带方法二: ESPRIT (借助旋转不变技术估计信号参数, Estimation of Signal Parameters via Rotational Invariance Techniques)
  - 宽带聚焦: 跨频率合并子空间信息
- 4.7 稀疏重构、学习式定位与实现边界
  - 稀疏与连续参数方法: 角度网格从哪里来
  - 学习式定位: 输入特征、输出形式与泛化
  - 任务和数据: 不同届 DCASE 的输出不能混用
  - 4.7.1 近场模型失配: 角度相同, 距离仍会改变导向矢量
  - 4.7.2 可执行基线的输入契约、回退与外部实现边界
- 4.8 定位算法总对比
  - 4.8.1 双源分辨率: 先规定成功, 再重复抽样
- 4.9 MDL 源数估计: 逐候选评分与数值例
  - 重复抽样: 把模型失败与有限样本误差分开
- 4.10 四麦亚采样时差: 从几何到可听信号
- 4.11 本章练习

## • 第 5 章 · 波束形成

- 5.1 统一问题表述
- 5.2 延迟求和波束形成器 (Delay-and-Sum Beamformer, 简称 DSB): “合唱前先把大家对齐”
- 5.3 超指向的白噪声增益—指向性权衡
  - 5.3.1 差分麦克风: 从一阶心形到高阶设计
- 5.4 最小方差无失真响应
  - 5.4.1 稳健波束形成方法
- 5.5 线性约束最小方差 (Linearly Constrained Minimum Variance, 简称 LCMV): 多约束推广
- 5.6 广义旁瓣对消器 (Generalized Sidelobe Canceller, 简称 GSC): 把约束改装成“噪声对消器”
- 5.7 后置滤波
  - 5.7.1 逐时频点语音存在概率 (SPP)
  - 5.7.2 Wiener 后滤通用式: SPP 加权与 MWF 级联
  - 5.7.3 音乐噪声与三项调节参数
- 5.8 球谐域波束形成 (球阵专属)
- 5.9 深度神经网络 (Deep Neural Network, 简称 DNN) 波束形成
  - 5.9.1 可执行基线与上线检查
- 5.10 波束形成算法总对比
  - 5.10.1 延伸阅读: Kumatani 等的 CMU 课程讲义
- 5.11 本章练习

## • 第 6 章 · 声学回声消除 (AEC)

- 6.1 回声模型与基础自适应滤波
  - 6.1.1 回声从哪来：系统模型与四种场景
  - 6.1.2 线性自适应滤波：NLMS 回顾
- 6.2 工程化自适应：频域、子带、比例、RLS 与卡尔曼
  - 6.2.1 PBFDAF：从长回声路径到逐块更新
  - 6.2.2 频域多抽头 NLMS：抽头是什么，何时等于 PBFDAF
  - 6.2.3 子带 AEC：分带、交叉项与可辨识性
  - 6.2.4 IPNLMS：均匀更新与比例更新如何混合
  - 6.2.5 RLS：用参考相关矩阵改变更新方向
  - 6.2.6 Kalman：同时描述路径变化与观测不确定度
- 6.3 非线性回声：模型失配与处理方法
- 6.4 双讲检测与自适应控制
  - 6.4.1 自动双讲检测的四状态实验
- 6.5 学习型 AEC
- 6.6 阵列中的 AEC：与波束形成的三种顺序
- 6.7 评测体系与工程验收清单
- 6.8 WebRTC AEC3 的结构与排障
- 6.9 多参考 AEC 模型与去相关选型
- 6.10 播放链参考抽头位置及其对 ERLE 的影响
- 6.11 测试覆盖与验收矩阵
- 6.12 AEC 诊断方法与 NLP 工作点
- 6.13 个性化 AEC 的合规检查
- 6.14 研究方向
- 6.15 可执行基线与开源实现边界
  - 6.15.1 教学 NLMS、PBFDAF 与状态边界
  - 6.15.2 外部 AEC 接口及输出取点
  - 6.15.3 真实配对录音及双讲控制组
  - 6.15.4 已知近端注入的受控检查
  - 6.15.5 WebRTC AEC3 的取点与同输入真值实验
  - 6.15.6 工业源码与设备验证边界
- 6.16 常见误区与自测题
- 6.17 延伸阅读

## • 第 7 章 · 去混响 (WPE)

- 7.1 问题、模型与直觉算例
- 7.2 离线 WPE：交替估计预测器与语音功率
- 7.3 多通道 WPE
- 7.4 在线 WPE 的因果更新
- 7.5 nara\_wpe 的接口与时间索引
- 7.6 与其他模块组合及失效边界
- 7.7 可执行教学基线与复现实验
- 7.8 保护延迟与预测抽头数的参数换算
- 7.9 常见错误与练习
- 7.10 研究方向

## • 第 8 章 · 语音分离

- 8.1 多说话人语音分离：鸡尾酒会问题
- 8.2 处理模块的顺序
- 8.3 经典盲源分离：AuxIVA、ILRMA、MNMF 与 TRINICON
- 8.4 GSS：活动导引、空间聚类与波束形成
  - 8.4.1 输入、空间模型与完整处理链
  - 8.4.2 活动约束下的 EM 迭代
  - 8.4.3 活动门控手算与错误标注反例
  - 8.4.4 协方差、波束权重与适用边界
  - 8.4.5 可运行的 cACGMM—SCM—MVDR 受控链
- 8.5 分离指标与数据集口径
- 8.6 连续语音分离与深度模型
- 8.7 教学代码与源码复现
- 8.8 练习与可复算答案

## • 第 9 章 · 声源追踪

- 9.1 问题与声学特殊性
- 9.2 单目标追踪
  - 9.2.1 卡尔曼预测、观测更新与角度边界
  - 9.2.2 算例 9-1：卡尔曼滤波单步复算
  - 9.2.3 运动模型切换与非线性观测
  - 9.2.4 算例 9-2：粒子加权与重采样
  - 9.2.5 单目标追踪仿真与缺测边界
- 9.3 多目标追踪
  - 9.3.1 数据关联与目标数
  - 9.3.2 三帧关联手算与 PHD 强度
  - 9.3.3 可执行基线与双目标交叉实验
- 9.4 定位、追踪与波束形成的接口
- 9.5 自由场移动声源的双麦音频与传播真值
- 9.6 本章练习



## • 第 10 章 · 工程实现、评测与产业实践

- 10.1 参考链路与端到端延迟
  - 10.1.1 延迟不能把每个模块的耗时直接相加
  - 10.1.2 实时回调的期限与数据搬运
- 10.2 拾音、同步与增益
  - 10.2.1 SRO：先区分初始时差和采样率偏移
  - 专题：有状态重采样的比率、余量与时间标记
  - 10.2.2 增益变化与 AEC
- 10.3 NS、控制信号与唤醒分支
  - 10.3.1 单通道 NS 的方法和边界
  - 10.3.2 功率谱减：一个频点怎样算到输出
  - 10.3.3 控制状态不能只看一个 VAD 比特
  - 10.3.4 VAD 与 AGC 的最小可运行基线
- 10.4 定点化、算力与功耗预算
  - 10.4.1 从浮点实现到目标芯片
  - 10.4.2 不混用指令数、乘法次数和实时因子
  - 10.4.3 把吞吐、排队、内存和功率放进同一预算
- 10.5 评测体系
- 10.6 数据、仿真与复现
- 10.7 分布式阵列
- 10.8 阵列形态与场景约束
- 10.9 从模型到设备
  - 10.9.1 开源实现怎样用作工程对照
- 10.10 联调与验收
- 10.11 本章练习
- 10.12 本章小结

## • 第 11 章 · 总结与选型指南

- 11.1 先回答六个问题
- 11.2 按条件选择模块
- 11.3 几何与算法要一起选
- 11.4 四个场景怎样推导方案
- 11.5 把候选方案写成可验证的规格
  - 11.5.1 先写规格和证据口径
  - 11.5.2 完整决策例：未知参会者的连续转写
- 11.6 练习
  - 题 1：带播放的周向语音终端 (E11-05)
  - 题 2：多人会议 (E11-06)
  - 题 3：跨时钟车载阵列 (E11-07)
  - 题 4：把空间带宽、同步与延迟放进同一张选型表
  - 题 5：评分覆盖与电池预算 (E11-02)
  - 题 6：平均文件分数与合并计数 (E11-03)
  - 题 7：p99 为什么还需要注明计算方法 (E11-04)
- 11.7 后续阅读

## • 附录 A · 符号术语数学

- 12.1 符号表
- 12.2 术语词典
  - 信号与数学基础
  - 房间声学
  - 自适应滤波、增强与分离
  - 波束形成与阵列度量
  - 定位与追踪
  - 系统与硬件
- 12.3 预备知识速览
  - 12.3.1 复数与相位：时延的符号
  - 12.3.2 分贝：幅度比与功率比
  - 12.3.3 卷积与相关
  - 12.3.4 期望、方差与协方差矩阵
  - 12.3.5 最小二乘
  - 12.3.6 带约束的最小化：MVDR 拉格朗日推导
  - 12.3.7 特征值分解
  - 12.3.8 病态矩阵与对角加载
- 12.4 计算练习

## • 附录 B · 路径地图与练习

- 13.1 研究生学习路径
- 13.2 领域地图：教材、会议、期刊与挑战赛
- 13.3 研究前沿速览 (2024—)
  - 研究方向一：预训练模型用作远场识别后端
  - 研究方向二：阵列无关系统
  - 研究方向三：目标说话人提取
  - 研究方向四：生成式语音增强与推理加速
  - 研究方向五：TF-GridNet 与复数谱映射骨干
  - 研究方向六：几何无关前端的期刊研究
  - 研究方向七：CHiME-9 与大模型后端
  - 研究方向八：扩散先验用于无监督盲分离
    - 13.3.1 神经网络前端的泛化失配与四类对策
- 13.4 常见问题与调试指南
- 13.5 核心公式速查卡
- 13.6 思考与练习
  - 13.6.1 基础与几何：第 1~3 章的题 1~4
  - 13.6.2 定位与波束：第 4、5 章的题 5~8
  - 13.6.3 增强、分离与追踪：第 6~9 章的题 9~13
  - 13.6.4 工程预算与方案选型：题 14~15
  - 13.6.5 房间仿真：第 16 题的输入、测量和结果
  - 13.6.6 公开系统复核：题 17
  - 13.6.7 补充计算：试听归一化
- 13.7 复现说明

# 导读与导航

本页是全套教程的入口，教程正文一共 14 个文件：本页导读 + 11 章正文 + 2 篇附录。另有 6 篇[源码研究手册](#)网页，展开实现与工业复现，不计入正文篇数。

11 章正文和 2 篇附录既可顺序阅读，也可按第 5 节的学习路径选读。每篇开头都列出上一篇、下一篇和首页链接。

全套教程配了 39 张图，图 18~20、图 26~32 和图 36~39 在第 6 章。插图分为几何示意、指定条件下的仿真和系统框图，阅读时要同时核对图注中的参数。

## 1. 这是一份什么样的教程

这是一份讲麦克风阵列的教程。零基础可以从头读，读完还可以当手册查。

文里配了 39 张图。第一次阅读时，可以先看图和算例，再回到公式核对条件与计算步骤。

教程从一个具体问题讲起：你站在 3 米外跟音箱说话，它怎样从噪声、混响和自身播放声中提取你的语音。全书依次讨论阵列几何、声源定位、定向拾音、回声与混响处理、重叠语音分离、移动声源追踪、系统评测和场景选型。

各章先建立直觉，再给出公式、符号、算例和适用边界。比较实验数字前，要先核对阵列几何、房间、数据集、实现和评测口径；条件不同的结果只能用于观察趋势。

## 2. 14 个文件一览

| 编号 | 文件                        | 配图                 | 难度 | 预计时间             |
|----|---------------------------|--------------------|----|------------------|
| 00 | 00_overview.md<br>(本页)    | 图34                | 入门 | 15~20 分钟，先读本页    |
| 01 | 01_problem-definition.md  | 图1                 | 入门 | 10 分钟            |
| 02 | 02_basics-signal-model.md | 图2~图7，共 6 张        | 进阶 | 45~60 分钟，建议完整读一遍 |
| 03 | 03_array-geometry.md      | 图8~图10，共 3 张       | 进阶 | 30 分钟            |
| 04 | 04_doa-estimation.md      | 图11~图14、图 33，共 5 张 | 较难 | 60~90 分钟，建议分两次读  |

| 编号           | 文件                          | 配图                                   | 难度 | 预计时间                        |
|--------------|-----------------------------|--------------------------------------|----|-----------------------------|
| 05           | 05_beamforming.md           | 图15~图17, 共 3 张                       | 较难 | 60~90 分钟, 跟着手算一遍            |
| 06           | 06_aec.md                   | 图18~20、图26~32、图36~39, 共 14 张, 另引用图23 | 较难 | 60~80 分钟, 建议分两次读            |
| 07           | 07_wpe-dereverberation.md   | 图21、图24, 共 2 张                       | 进阶 | 30~45 分钟                    |
| 08           | 08_speech-separation.md     | 0 张专属图, 引用图23                        | 进阶 | 30~45 分钟                    |
| 09           | 09_source-tracking.md       | 本章专属图22, 另引用图23                      | 进阶 | 30~40 分钟                    |
| 10           | 10_engineering-practice.md  | 图25, 另引用图23                          | 进阶 | 约 45~60 分钟                  |
| 11           | 11_selection-guide.md       | 0 张专属图                               | 入门 | 20~30 分钟; 按任务、约束和场景条件形成候选方案 |
| 附录 A (文件 12) | 12_appendix-symbols-math.md | 0 张专属图                               | 查阅 | 通读约 25 分钟, 也可以当词典查          |
| 附录 B (文件 13) | 13_appendix-guide.md        | 图35                                  | 查阅 | 通读约 40 分钟, 也可以按需查           |

预计时间的算法：中文每分钟读 450 字，每张图多加 2~3 分钟，推导部分再加停留时间。按上表逐篇相加，全部精读约需 9~11 小时；练习和复现实验另计。按路径读见第 5 节。

时间有限时，可先读本页、01 和 11，明确问题与选型条件，再读 02 补齐信号模型。需要定位、波束、AEC、去混响或分离时，分别选读 04~08；工程实现配合第 10 章和附录 B 的排错部分，研究选题配合第 4、9 章和附录 B 的领域地图。

### 3. 各篇内容与学习目标

---

#### 01 · 问题定义与双耳启示

1 张图，入门。以智能音箱为例说明噪声、混响、干扰和麦克风自噪声，再区分定位、波束形成和追踪三项空间任务。阵列收益分三类度量：独立通道噪声看 WNG（白噪声增益），弥散场看 DI（指向性指数），定向干扰看零陷深度。三种指标的声场假设不同，不能直接互换。

人的听觉系统会利用双耳时间差、声级差和耳廓滤波线索。麦克风阵列也可利用通道间时延和幅相差，但需要显式的几何模型或实测阵列流形。细节见第 1 章。

学习目标：解释多麦克风相对单麦克风增加了哪些空间信息，复算理想白噪声模型下的阵列增益，并区分双耳线索与阵列观测。

#### 02 · 基础：声音到达阵列时发生了什么

6 张图，进阶。全书的符号和概念都在这章第一次出现。建议完整读一遍，后面看不懂时再回来查。

- 2.1 节讲时延：声音到达每个麦克风有先有后。采样率 16 kHz 时，一格是 62.5 微秒，约等于 2.1 厘米。时延估计要用到比采样间隔更细的插值，多路信号还必须用同一个时钟录。
- 2.2 节讲远场和近场：对中心对称孔径，常用相位曲率尺度是两倍孔径平方除以波长；其他几何要按参考点到最远阵元的距离推导。分界同时取决于孔径和频率。
- 2.3 节讲导向矢量：时域的移位变成频域的相位旋转。导向矢量就是每个方向对应的标准相位组合，后面定位和波束形成都要用它。
- 2.4 节讲房间混响：声音经反射形成拖尾， $T_{60}$  描述能量衰减 60 dB 所需时间，DRR（直达混响比）描述直达声与混响的相对能量。
- 2.5 节讲 STFT（短时傅里叶变换）：把波形分帧后得到复数时频表示，再由多通道快拍估计协方差矩阵。
- 2.6 节讲主瓣宽度、旁瓣、DI、WNG，还介绍分辨率尺度、栅瓣条件和 CRLB（克拉美 - 罗下界）。

本章结束时，读者应能从时延推到相位和导向矢量，解释协方差矩阵各元素的含义，并查清后续章节使用的基础符号。

#### 03 · 阵列几何形态

3 张图，进阶。讲麦克风怎么摆，以及摆法决定什么上限。

双麦只有一条物理基线，正横、端射和中间角度是相对该基线的连续工作方向。随后比较线阵、圆阵、方阵、球阵、螺旋阵和分布式阵列。

共线阵列无法分辨绕阵列轴的方位，继续在同一直线上增加麦克风也不能消除这种几何模糊。端射附近的时延对角度变化不敏感，同样的时延误差会对应更大的角度误差。

本章归纳四条设计规律：孔径和波长的比值影响分辨率；圆阵在水平面各方向都能利用孔径；挡板会改变阵列流形；增加麦数能改善白噪声增益和统计稳定性，但收益取决于几何、频段和噪声场。

稀疏阵只占用密集参考网格中的部分候选位置，再把麦对位置差组织成差分协同阵。例子中的 6 麦嵌套阵产生 23 个连续的有符号滞后；要把这些滞后用于 MUSIC，还需构造虚拟协方差并做空间平滑或等价重构。

读者可以据此说明阵列形态怎样限制可观测方向、孔径和无混叠频带，并按覆盖范围、同步条件和安装空间筛选几何方案。

## 04 · 声源定位 DOA 估计

5 张图，较难。DOA 是波达方向（Direction of Arrival），也就是判断声音从哪来。本章算法种类多，建议分两次读。

§ 4.10 四麦分数采样时差把 4 cm 阵列的几何时差、理想相量计算和四通道合成 WAV 放在同一练习中；它只验证指定模型，不替代真实房间的定位评测。

本章把方法分为四类：两步法（互相关 + 几何解算）、扫描法、子空间法、稀疏重构与深度学习方法。

- GCC-PHAT（广义互相关相位变换）从相位随频率的变化估计时延，混响会拖宽或扰乱相关峰，时延估计还要做亚采样插值。图 13 用 16 kHz、64 ms 分析帧和 150 次固定种子试验构造随机衰减尾。它用于说明固定尾能量时  $T_{60}$  与 DRR 的联合作用，以及仿真参数口径可能改变趋势；该图不能当作“ $T_{60}$  越长性能越差”的单调证据，也不代表真实房间的通用正确率。
- SRP（可控响应功率）在每个候选位置累加各麦对的相关响应，再寻找最大值。算例里真点得分 6.0，偏 1.8 米的点 5.64，镜像点 2.08。粗到细两级搜索可减少需要评估的网格点；实际耗时取决于搜索范围、网格间距、麦对数、实现和硬件。
- 几何解算包括 Chan 算法和泰勒迭代。GDOP（精度稀释）描述几何摆位不好时误差怎样被放大。



- 扫描法包括 Bartlett 与 Capon（最小方差谱估计）。双麦例子中， $0^\circ$  与  $30^\circ$  两个候选方向的谱值比分别为 1.8 和 5.0；这里的  $30^\circ$  不是旁瓣位置，不能把这个比值称为旁瓣抑制比。

子空间法 MUSIC（多重信号分类）利用信号子空间与噪声子空间的正交关系寻找谱峰。相干信号会使源协方差秩下降，均匀线阵可在满足子阵条件时用空间平滑恢复可用秩。ESPRIT（旋转不变子空间法）利用阵列的平移结构直接解角度，不用逐格扫描。

DNN（深度神经网络）方法可用带方向标签的多通道数据学习定位特征，效果取决于训练数据是否覆盖测试阵列、房间、噪声和声源数。CRLB（克拉美 – 罗下界）用来分析指定观测模型下的方差下界；对已知波形的时延估计，有效带宽增大通常会增加 Fisher 信息，但具体幂次和系数取决于 SNR、频谱和参数定义。

完成本章后，读者应能按阵列几何、源数、混响和计算预算比较四类定位方法，并解释互相关峰受多径影响、MUSIC 在相干源下失效的原因。

## 05 · 波束形成 Beamforming

3 张图，较难。波束形成对多通道信号加权求和，在保持目标方向响应的同时降低指定噪声场或干扰方向的输出功率。正文给出可复算的权重和响应例子。

三类噪声需要不同模型：麦克风自身噪声用 WNG 评价，延迟求和是解析基线；弥散场用 DI 评价，可比较超指向设计；定向干扰则检查零陷和 MVDR（最小方差无失真响应）的输出。

DSB（延迟求和和波束形成）的权重是导向矢量除以麦克风数，理想独立白噪声下 WNG 等于麦克风数。超指向在低频提高 DI 时可能显著降低 WNG。两麦端射算例在指定间距和频率下得到约  $-10$  dB 的 WNG 与约  $6$  dB 的 DI；间距减半时，该算例的 WNG 再降低约  $6$  dB。

MVDR 分四步推导。算例中，噪声协方差所含的定向干扰信息使  $30^\circ$  处响应降至  $-23.8$  dB。LCMV（线性约束最小方差）加入多条约束，MWF（多通道维纳滤波）权衡降噪与失真。GSC（广义旁瓣对消器）分成固定波束、阻塞矩阵、自适应对消三路；在约束与实现一致时，它可表示 LCMV 解。

后置滤波调整时频增益，球谐方法用于球阵和球面声场表示。DNN 方法包括掩码估计、掩码结合 MVDR 和直接端到端映射。

本章要求读者能计算 WNG 与 DI，说明 MVDR 怎样利用协方差中的空间信息抑制定向干扰，并比较 GSC 与 LCMV 的约束表达。

## 06 · 声学回声消除 AEC

14 张图（图18~20、图26~32、图36~39，另引用图23），较难。图 18、图 26~32 解释回声模型、收敛与工程条件，图 36 展示非线性残留；图 37~38 分别说明子带交叉项和 IPNLMS/RLS/Kalman 的不同状态，图 39 拆开 PBFDAF 的预测和更新。

AEC（声学回声消除）处理设备自己播放、又被自身麦克风收进来的声音。能预测回声波形时可估计后相减，这是本章区分减法处理与增益抑制的起点。

NLMS（归一化最小均方自适应滤波）给出基础更新式。PBFDAF（分区块频域自适应滤波）把长路径分区，按频点使用多个历史参考块更新；在第 6 章规定的同一分块、误差和归一化口径下，它就是频域多抽头 NLMS 的具体实现，不是与之并列的新算法。

子带方法、IPNLMS 和 FDKF（频域卡尔曼滤波）分别改变信号表示、系数分配或状态估计。扬声器非线性会限制线性 AEC，需根据失真来源考虑非线性模型或神经网络。DTD（双讲检测）用于控制近端和远端同时活动时的自适应更新。

AEC 与其他模块的参考关系见 § 10.1 和图 23。评测要同时考虑远端单讲时的 ERLE、双讲稳定性、近端语音损伤和主观听测；ERLE 高并不能证明近端语音无损。WebRTC AEC3 可作为公开实现参考。

读者应能确定回声参考取点，解释 AEC 与波束顺序的条件，并为线性路径、非线性失真和双讲分别选择验证方法。

## 07 · 去混响 WPE

2 张图（图21、图24），进阶。讨论怎样利用跨帧预测估计并减弱晚期混响。

WPE（加权预测误差去混响）用历史帧预测晚期混响并相减，保护延迟用于避免直接预测当前直达声。正文算例在指定条件下展示混响能量变化；预测延迟和阶数要按帧长、混响与语音损伤验证。多人重叠语音在第 8 章讨论，模块启用条件和参考关系见 § 10.1。

本章给出保护延迟  $\Delta$  和预测阶数的选择依据，比较单通道与多通道 WPE，并说明 MINT、倒谱和谱方差方法各自依赖的假设。

## 08 · 语音分离

0 张专属图（引用全书链路总图23），进阶。讨论重叠语音的分离方法，以及时频掩码怎样连接分离、协方差估计和波束形成。

三条路线包括经典盲源分离（AuxIVA、ILRMA、MNMF、TRINICON）、GSS（引导源分离，用说话人活动标注处理输出排列）和深度分离（掩码估计、深度聚类、PIT、Conv-TasNet、状态空间模型及查询型分离）。§ 8.2 与图 23 说明处理顺序；§ 8.3、§ 8.4 和 § 8.6 分别展开三条路线。实际模块启用条件见 § 10.1。

读者应能按源数与麦克风数的关系区分 AuxIVA、ILRMA、MNMF 和 TRINICON 的模型条件，解释 GSS 使用活动信息的原因，并用分离掩码估计目标或干扰协方差。

## 09 · 声源追踪 Source Tracking

2 张图，进阶。讨论方向观测随目标运动、漏检和野点变化时，怎样估计连续轨迹。状态可以包括角度、角速度和角加速度。

声音观测有四类困难：

- 语音时断时续；
- 定位结果含有野点；
- 说话人数会变化；
- 角度观测与状态之间可能是非线性关系。

KF（卡尔曼滤波）由状态预测、观测更新和协方差递推组成，观测与预测的权重由噪声模型决定，不是固定比例。PF（粒子滤波）用带权粒子近似后验分布，并通过重采样缓解权重退化。

多人追踪还会用到 IMM（交互多模型）、PHD（概率假设密度）、LMB 和 TBD（检测前追踪）。§ 9.4 讨论定位与波束之间的反馈；更新限幅、静默保持和重置条件都应由目标运动与帧率确定。

完成本章后，读者应能说明追踪器在定位与波束之间传递什么状态，比较单目标与多目标方法，并设置方向更新、静默保持和重捕获条件。

## 10 · 工程实现、评测与产业实践

本章的图 25 展示端到端延迟关键路径，另引用图 23 的参考依赖关系。图 23 不表示每个项目都要启用全部模块。第 10 章按启用条件说明 AEC、WPE、定位、波束、NS 和后端的取点关系，并把延迟分为前瞻、缓冲、计算、调度和解码关键路径。

硬件部分区分数字样本格式、模拟动态范围、初始时差和 SRO（采样率偏移）。资源预算分别使用 MAC/s、MIPS、RTF、峰值内存和功耗，续航用 Wh 与整机平均功率计算。

评测部分说明 SI-SDR、STOI、PESQ/POLQA、WER/CER、OSPA 与主观听测各自回答什么问题。



本章结束时，读者应能编制延迟、同步和标定预算，选择与任务相符的评测指标，并列出部署时还需验证的资源与故障状态。

## 11 · 总结与选型指南

入门。11.1 从输出任务、覆盖区域、频带、干扰、目标运动和硬件边界六方面定义问题；11.2 给出不同模块的启用与替换条件；11.3 说明几何和算法怎样共同决定性能。

11.4 用四类场景演示怎样从条件推导候选方案；11.5 把方案写成可验证规格；11.6 配有七道练习，其中四道有独立代码。

本章把任务和约束转成候选方案，给出 AEC、WPE 和分离的启用条件，并示范怎样把几何、WNG/DI 权衡和资源预算写成可测的验收规格。

## 12 · 附录 A：符号、术语、数学

查阅用。12.1 节是符号表。12.2 节是术语词典，按信号与数学基础、房间声学、自适应滤波与分离、波束形成与阵列度量、定位与追踪、系统与硬件分组。12.3 节介绍复数、分贝、卷积和相关、期望和协方差、最小二乘与特征分解；12.4 节用四道代码题复算卷积、复二阶矩、秩亏最小二乘，并区分频谱相位加权与空间噪声白化。

遇到未定义符号、术语或数学步骤时，可按主题查阅，无需顺序通读。

## 13 · 附录 B：路径、地图、前沿、排错、练习、复现

查阅加动手。13.1 节是学习路径。13.2 节是教材、会议、期刊、挑战赛与历史地图。13.3 节介绍八个研究方向与泛化失配。13.4 节是排错指南，13.5 节是公式速查卡，13.6 节有 17 道练习题及共同增益代码题，13.7 节说明怎样复现 39 张图。

需要查学习资料、研究方向、排错方法、练习或复现步骤时，可直接进入对应小节。

---

## 4. 阅读顺序

1. 先读本页，再用约 10 分钟读第 1 章，建立问题意识。
2. 读第 2 章，补齐全书共用的信号模型。符号不懂时查附录 A。
3. 几何线从第 3 章开始，了解阵列形态怎样限制观测信息，再用 § 11.1 ~ § 11.3 形成候选几何。
4. 空间处理线依次关联第 4 章的定位、第 9 章的追踪和第 5 章的波束。第 2、5、8 章介绍的时频掩码可用于估计目标或噪声协方差，再交给 MVDR 或分离模块。

5. 干扰处理线包括第 6 章的回声消除、第 7 章的去混响和第 8 章的语音分离；启用条件和参考依赖见 § 10.1 与图 23。
6. 工程线用第 10 章核对链路、硬件、评测和芯片，再到第 11 章形成方案。

附录 A（文件 12）汇总符号、术语和数学。附录 B（文件 13）提供学习路径、领域地图、前沿、排错、练习和复现说明。

完成第 11 章后，工程读者可到 § 10.10 制定联调与验收计划，遇到问题查 § 13.4。研究读者可读 § 13.3，再做 § 13.6 的第 16、17 题，分别练习房间仿真和论文系统复核。两篇附录均可按需查阅。

---

## 5. 三条阅读路径

---

### 路径 A：零基础入门（能复现演示，约 2~3 周）

1. 先读本页和第 1 章，再读 § 11.1~§ 11.3，了解选型需要哪些输入条件。
2. 02 精读 60 分钟。推导可以先跳，重点是会读图 2~图 7。
3. 03 读表格 + 算例 30 分钟。04 读 4.2、4.3 节 + 算例 60 分钟，对照看图 12、图 14。05 读 5.1、5.2、5.4 节，跟着手算 60 分钟，对照看图 16。
4. 第 6 章读 § 6.1.1、§ 6.1.2、§ 6.6（AEC 在阵列里放哪）和 § 6.8，共约 60 分钟，对照看图 18。第 7 章读 § 7.1 的直觉部分和 § 7.8 的保护延迟、抽头数换算，对照看图 21、图 24。第 8 章读 § 8.1 的分离任务和 § 8.4 的掩码用途，约 30 分钟。第 9 章读 § 9.2 的卡尔曼滤波五步，约 30 分钟。
5. 阅读 § 10.1、§ 10.4 和 § 10.6，了解参考链路、资源口径与房间仿真。按需查附录 A，再做附录 B 的第 2、3、5、7、10、11、14 题，并用 § 13.4 检查常见问题。
6. 终点：重新生成并解释 39 张图，再在可用的多通道硬件上实现一个可测方向响应的基线系统。

### 路径 B：工程实现（形成可验证的前端方案，约 1 周精读）

1. 用 § 11.1~§ 11.5 写清任务、几何、场景、模块启用条件和验收指标。第 5 章重点读 MVDR、稳健化与后置滤波；第 6 章核对回声参考、双讲和与波束的顺序条件；第 7 章根据目标房间验证 WPE；第 8 章在确有重叠语音需求时选择分离方法。更换阵列前阅读 § 13.3 的泛化专栏。
2. 通读第 10 章，按关键路径核算延迟，区分多设备同步与 SRO，统一评测、算力和功耗口径。再查 § 13.4，完成 § 13.6 的第 7、8、9、11、14、15 题。

3. 终点：输出延迟、同步、标定三张预算表。对照 WebRTC AEC3 检查回声消除，分开评价远端单讲残余、双讲稳定性、近端损伤与主观质量；资源和时序仍须在目标设备测量。
- 路径 C：研究复现与公开评测（长期）
1. 02 的 CRLB 给出指定观测模型和正则条件下无偏估计方差的下界。03 的稀疏阵列。04 的 4.6、4.7 节（空间平滑、宽带子空间方法、学习型定位、ACCDOA 声事件定位表示）。05 的 RTF（相对传递函数）版 MVDR、球谐方法、掩码 + GEV（广义特征值波束形成）、端到端网络。
2. 06 的 FDKF、混合神经卡尔曼。07 的在线 WPE。08 的扩散模型、GSS 与掩码协方差估计。09 的 PHD、LMB、TBD。10 的指标口径（SI-SDR 和 BSS-eval 两套指标不能直接比数值）+ CHiME、LibriCSS、STARSS 数据集。
3. 用附录 B § 13.2 查领域资料，阅读 § 13.3 中与课题相关的方向和泛化专栏，再做 § 13.6 的第 6、8、12、13、16、17 题，分别覆盖定位分辨、稳健波束、分离、追踪、房间仿真和论文系统复核。阅读 CHiME-8 系统报告时，可把实际前端结构与图 23 对照。
4. 终点：在一个公开数据集上固定阵列、训练/测试划分和指标，分别实现一个解析基线和一个数据驱动基线，并记录模型版本、输入特征和推理资源。

## 6. 插图地图：39 张图在哪篇

| 图  | 文件                   | 所在文档 | 类型      | 内容                        |
|----|----------------------|------|---------|---------------------------|
| 图1 | fig01_binaural       | 01   | 示意 + 曲线 | 双耳时间差和声级差，Rayleigh 双重理论   |
| 图2 | fig02_dsin_geometry  | 02   | 示意      | 时延几何直角三角形                 |
| 图3 | fig03_near_far_field | 02   | 示意      | 球面波和平面波，远场判据              |
| 图4 | fig04_delay_phase    | 02   | 示意 + 曲线 | 时延等于相位旋转，给互相关法铺垫          |
| 图5 | fig05_room_acoustics | 02   | 示意 + 曲线 | 房间脉冲响应三段、T60、直达临界距离、直达混响比 |

| 图   | 文件                        | 所在文档 | 类型        | 内容                                                                                                             |
|-----|---------------------------|------|-----------|----------------------------------------------------------------------------------------------------------------|
| 图6  | fig06_stft_cov            | 02   | 仿真 + 矩阵   | 分帧语谱加协方差<br>热图加特征谱                                                                                             |
| 图7  | fig07_beampattern_anatomy | 02   | 仿真教学      | 主瓣、旁瓣、零陷、主瓣宽度、栅瓣                                                                                               |
| 图8  | fig08_geometries          | 03   | 布局示意      | 线阵、圆阵、球阵、螺旋阵、分布式                                                                                               |
| 图9  | fig09_tradeoffs           | 03   | 公式计算，分两幅看 | (a) 独立同方差白噪声下的理想<br>WNG 为 $10 \log_{10} M$ ；<br>(b) 输入通道数 $M$ 、无序麦对数 $M(M-1)/2$ 和完整协方差元素数 $M^2$ ，不等于运行时间、功耗或价格 |
| 图10 | fig10_sparse_array        | 03   | 集合图解      | 所有有序麦对形成有符号差分位置；<br>图中 6 麦嵌套阵得到 23 个连续有符号滞后                                                                    |
| 图11 | fig11_doa_spectrum        | 04   | 仿真        | 指定高信噪比、充足快拍条件下的三种谱形；Capon 使用相对对角加载 $\eta = 10^{-6}$ ；不检验分辨极限                                                   |
| 图12 | fig12_gcc_phat            | 04   | 示意 + 仿真   | 真值约 0.933 格；<br>固定噪声样例经 16 倍时延网格插值得 $58.59375 \mu\text{s}$ ，即 0.9375 格、约 $30.16^\circ$                         |

| 图   | 文件                | 所在文档 | 类型        | 内容                                                                                                                        |
|-----|-------------------|------|-----------|---------------------------------------------------------------------------------------------------------------------------|
| 图13 | fig13_gcc_reverb  | 04   | 参数口径反例    | 在 16 kHz、64 ms 分析帧、无传感器噪声的随机衰减尾模型中，每点 150 次固定种子试验；正确率带 95% Wilson 区间，峰对比度带四分位区间；用于检查固定尾能量时 $T_{60}$ 与 DRR 的联合作用，不支持单调退化结论 |
| 图14 | fig14_srp_grid    | 04   | 仿真 + 几何   | 麦对相关响应的网格累加与双曲线交汇                                                                                                         |
| 图15 | fig15_wng_di      | 05   | 指定模型仿真    | 半径 4 cm 的 6 元圆阵；超指向使用相对对角加载 $10^{-6}$ ，两种方法均保持目标方向单位响应                                                                    |
| 图16 | fig16_beampattern | 05   | 指定模型仿真    | 三条曲线保持目标方向单位响应；DSB/MVDR 用 $d = \lambda/2$ ，超指向用 $d = 0.2\lambda$ ，MVDR 干扰方向为 $20^\circ$                                   |
| 图17 | fig17_gsc         | 05   | 系统框图      | 固定波束、阻塞矩阵、对消器三路                                                                                                           |
| 图18 | fig18_aec         | 06   | 框图 + 本书仿真 | 固定随机种子样例在 $0.45 < t < 0.8$ s 窗口的 NLMS ERLE 均值约 29.23 dB（图中取整约 29 dB）；双讲区间冻结更新                                             |

| 图   | 文件                   | 所在文档     | 类型        | 内容                                                                             |
|-----|----------------------|----------|-----------|--------------------------------------------------------------------------------|
| 图19 | fig19_aec_landscape  | 06       | 仿真 + 方法分类 | <p>(a) 指定未建模非线性条件下的线性 AEC 性能平台；</p> <p>(b) 按模型假设和处理对象区分四类方法，横向位置不表示年代或性能排名</p> |
| 图20 | fig20_aec_pipeline   | 06       | 系统框图      | 经典链路与线性、神经网络混合链路对比                                                             |
| 图21 | fig21_wpe            | 07       | 仿真        | 共用谱幅参考值比较干净、混响和 WPE 输出；统计量按 10 ms 直达延迟对齐干净参考，再报告静音帧能量占比与活跃帧复增益对齐谱域 NMSE        |
| 图22 | fig22_tracking       | 09       | 仿真        | 单目标粒子滤波轨迹与两目标 PHD 强度示意                                                         |
| 图23 | fig23_pipeline       | 08、09、10 | 系统框图      | 较完整前端的参考依赖关系与方向反馈（08、09 只引用）                                                   |
| 图24 | fig24_wpe_frames     | 07       | 示意        | WPE 帧结构：只用过去历史预测当前帧，保护延迟 $\Delta$ 的作用                                          |
| 图25 | fig25_latency_budget | 10       | 瀑布条       | 一组旧设计的延迟拆分示意；实际预算按 § 10.1 的关键路径重新测量                                            |



| 图   | 文件                      | 所在文档 | 类型      | 内容                                                  |
|-----|-------------------------|------|---------|-----------------------------------------------------|
| 图26 | fig26_aec_problem       | 06   | 示意      | 回声怎么形成：房间冲激响应、卷积拖尾、麦克风三者相加                          |
| 图27 | fig27_aec_concept       | 06   | 示意      | 估计回声路径并相减，DTD 控制自适应更新                               |
| 图28 | fig28_aec_nlms          | 06   | 仿真      | NLMS 自适应过程：滤波器长成回声路径，步长取舍                           |
| 图29 | fig29_aec_erle_freeze   | 06   | 仿真      | 收敛与冻结：本图在已知双讲区间冻结，双讲段不以混合残差直接计算回声分量 ERLE；其他控制策略需另验证 |
| 图30 | fig30_aec_delay_dtd     | 06   | 仿真      | 延迟对齐与双讲：不对齐掉几十分贝，对齐是第一要务                            |
| 图31 | fig31_aec_nonlinear     | 06   | 仿真      | 指定仿真条件下线性路径与 tanh 非线性路径的性能平台                        |
| 图32 | fig32_aec_hybrid_select | 06   | 框图 + 示意 | 线性与神经网络混合处理及条件化选型                                   |
| 图33 | fig33_gcc_two_ways      | 04   | 对照      | 时域滑动乘加等于频域共轭乘加<br>IFFT，两条路算出同一条曲线、同一个峰              |

| 图   | 文件                          | 所在文档 | 类型      | 内容                                              |
|-----|-----------------------------|------|---------|-------------------------------------------------|
| 图34 | fig34_audio_examples        | 00   | 合成音频对照  | 从实际 PCM 文件读取对齐平均、双讲冻结和 WPE 的波形/能量，不能代替实录语音质量评分  |
| 图35 | fig35_audio_counterexamples | 13   | 合成反例    | 相关噪声、极性错误、病态求逆的 PCM 对照；每组共同增益、无评分时延或增益拟合        |
| 图36 | fig36_nonlinear_echo        | 06   | 非线性回声反例 | 500 Hz 输入经三次模型产生 1500 Hz 残留；同增益波形及 PCM 实测单边幅度   |
| 图37 | fig37_aec_subband           | 06   | 精确代数示例  | 两带 Haar 表示下，一采样回声路径的跨带项；仅保留对角项会遗漏交叉项，不是自适应算法性能图 |
| 图38 | fig38_aec_four_methods      | 06   | 手算状态图   | IPNLMS 抽头增益、RLS 逆相关矩阵及卡尔曼增益的指定小规模状态；不表示方法间性能排名  |
| 图39 | fig39_aec_pbfda_flow        | 06   | 算法流程图   | 播放参考、声学路径、分区频域预测、有效区残差、冻结控制及梯度合法区投影             |

示意图用于解释几何关系，曲线展示指定条件下的可复现结果，框图说明模块之间的信号与控制关系。

## 7. 十处跨文档联系

---

1. 定位连着追踪连着波束：04 找方向，09 跟轨迹，05 指波束，见 9.4 节和图 23。
  2. 前端模块的参考依赖与启用条件见 § 10.1 和图 23。
  3. 导向矢量：02 的 2.3 节定义，04、05、08、09 都要用。
  4. 协方差矩阵：02 的 2.5 节定义，04、05、06 都要用。对角加载可改善条件数，但不能代替足够的独立观测。
  5. WNG 和 DI 的权衡：02 的 2.6 节提出，05 详细计算，11 用于条件化选型。
  6. 混响这条线：02 的 2.4 节讲混响是什么，04、05、06、07 讲各自怎么对付它。
  7. 掩码估计：02 讲语音稀疏性，05 和 08 用掩码估计目标或噪声协方差，并把它们交给波束形成或导引分离。
  8. 减法和乘法：06 的 6.1 节讲能预测波形就做减法，05 的 5.7 节讲只能估计幅度就做乘法。
  9. 几何上限：03 讲摆位定的上限，04、09、10 都要回来看它。
  10. 标定和同步：10 的 10.2 节讲标定同步，13 的附录 B 13.4 节讲排错时怎么查它。
- 

## 8. 动手复现

---

`codes/` 先提供与公式相对应的小规模教学基线，`scripts/` 再生成书中的图。前者适合逐步检查时延、矩阵形状、约束残差和边界输入；后者适合复现正文的完整示意或仿真条件。算法覆盖状态见 `codes/COVERAGE.md`，第三方官方实现、固定提交和许可证边界见 `codes/THIRD_PARTY.md`。

在仓库根目录先运行三组章节例子：

```
.venv/bin/python codes/examples/ch02_05_baselines.py
.venv/bin/python codes/examples/ch06_09_baselines.py
.venv/bin/python codes/examples/ch10_engineering_baselines.py
.venv/bin/python -m unittest discover -s tests -p 'test_codes*.py' -v
```

再运行第 13.7 节列出的绘图命令，可重新生成 39 张图；运行时间取决于机器。具体构建步骤和错误处理见 `scripts/README.md`。Windows 上需把命令中的 `.venv/bin/python` 换成 `.venv\Scripts\python`。

另有 94 道带答案的[章节代码练习与音频实验](#)，从第 1 章到附录 B 使用 E01-01 等稳定编号。第 6 章 E06-07~E06-20 包含算法边界手算与子带、IPNLMS、RLS、Kalman 的小规模复算。每道题对应输入、执行代码和可核查结果，不替代原有练习题号。

60 个 WAV 样本由本书合成，分为 14 组，覆盖对齐平均、四麦分数采样时差、AEC、WPE、已知矩阵解混、工程失真、双声道声像，以及相关噪声、极性错误、病态求逆、非线性回声、四种 AEC 自适应方法、两带跨项和功率谱减。先运行 `codes/examples/generate_audio_samples.py`，再按手册比较参考、输入和输出；网页提供不自动播放的试听控件。

另有独立清单管理的 [GSS 五路合成音频与中间状态](#)、[自由场移动声源三路音频与轨迹真值](#)，以及附录 B 六位置房问题的 18 个白噪声合成 WAV。三套补充资产均不计入主清单 60 个样本。

三组反例见附录 B 图 35，非线性残留见第 6 章图 36。图 37 解释两带子带模型的交叉项；图 38 分别展示 IPNLMS、RLS 和 Kalman 的受控状态变化，三幅子图不构成性能排名。图 39 展示 AEC 方法的选择流程。

对应的 AEC 合成音频在研究手册第 15~16 节；谱减试听与前奏数字在第 18 节。这些音频与图 39 的流程图分别用于听辨和选型。

真实录音另存于 `codes/real_audio/`：DEMAND 河流场景的 10 s、16 通道摘录，以及单麦、双麦平均、16 麦平均三个派生文件。数据采用 CC BY-SA 3.0，来源、许可和修改记录随文件保留。该实验检验实际通道间的相关项，不提供干净语音参考或语音增强分数。

图34 可下载合成音频的波形与分段能量（16 kHz；非实测语音）




图 34 直接读取已导出的 PCM：(a) 在 500~520 ms 对比晚到 3 个采样的参考、单麦与对齐平均；(b) 用 20 ms 块 RMS 标出 1.2~1.8 s 的已知双讲冻结；(c) 对比含 40 ms、80 ms 副本的输入、离线 WPE 和无回声参考。三组均为 16 kHz 合成信号，每组共用导出增益，不作单文件峰值归一化。

图中的波形接近、能量降低和主观听感是不同证据。谐波目标本身可预测，WPE 也可能损伤它；已知冻结掩码不代表实现了双讲检测。样本不能用于报告真实语音 MOS 或产品性能。

这些 NumPy/标准库程序用于复算。进一步阅读[源码研究手册](#)：

- [空间处理与追踪](#)展开宽带定位、球谐编码、工业声源成像和数据关联；
- [AEC、WPE 与语音分离](#)展开自适应控制、跨帧状态、盲分离和神经系统；
- [工业部署与评测](#)展开设备接口、重采样、固件、推理运行时和官方评分器。

可获取的官方源码按固定提交保存在 `codes/upstream/_downloads/`，具体入口见[锁定清单](#)。源码、依赖构建、示例运行和数值对照分别记录；完整设备实现还要核对参考取点、时钟、缓冲及连续状态。代码、模型、数据和示例录音的许可证分别适用，独立下载目录不随本书 Git 提交。

---

## 9. 常见问题

---

### 图片看不到怎么办？

请保留仓库目录结构并从仓库中打开文档；图片使用相对路径，单独复制 Markdown 文件会使链接失效。

### 先读哪篇？

先读本页，再读 01 和 11，再读 02。之后按第 5 节的路径走。赶时间只读 11 也能得到选型结论。

### 公式看不懂怎么办？

先查第 2 章和附录 A 中的符号、术语与数学基础，再结合图 7、图 11、图 15、图 16 阅读第 4、5、7、8 章的推导。

### 想跑实验怎么办？

先按第 8 节运行章节教学基线，确认公式约定和边界输入，再重绘 39 张图。之后可按锁定版本用 `pyroomacoustics` 建立房间仿真基线。公开数据、模型和硬件实验应根据任务、许可证与设备条件选择，练习入口见附录 B 的 § 13.1、§ 13.6。

### 不同实验的绝对数值能比吗？

不能。阵列几何、房间、信噪比、数据集、实现和评测口径不同，绝对数值不能直接横向比较。先确认条件一致，再比较趋势和量级。

---

## 附录：下一步清单

---

- [] 15 分钟读完本页，选一条第 5 节的路径。
- [] 阅读第 1 章和第 11 章，分别明确问题定义与选型条件。
- [] 60 分钟读 02，学会读图 7（主瓣、旁瓣、零陷、主瓣宽度、栅瓣）。



- [] 按第 2 节的时间表读 04~08: 04、05 各 60~90 分钟, 06 约 60~80 分钟, 07、08 各 30~45 分钟。
- [] 对照第 8 节画一遍 39 张图, 打开 `figures/` 对照正文看图。
- [] 运行 `codes/examples/` 的三组基线, 并从 `codes/COVERAGE.md` 选一个原理索引项目核对其官方实现边界。
- [] 做附录 B 的练习题 (入门做 2、3、5、7、10、11、14 题, 进阶再做 6、8、12、13、16、17 题)。
- [] 用附录 B § 13.4 排查常见问题, 并按第 10 章编制延迟、同步和标定预算。

# 第 1 章 · 问题定义与双耳启示

本章从客厅里的远场语音交互出发，依次说明空间处理的三项任务、阵列增益的不同度量，以及双耳听觉为机器阵列提供的线索。

## 导入：从客厅场景认识阵列任务

本节先从可观察的干扰出发，再分清阵列要解决的任务和三种不同的收益。之后的 § 1.1 才把双耳听觉作为空间线索的参照。

### 客厅里的远场语音问题

想象你坐在客厅里，对 3 米外的智能音箱说“今天天气怎么样”。音箱要听清这句话，需要处理四类干扰：

- 1. 环境噪声：空调声、车声；
- 2. 房间混响：声音经墙壁、桌面、天花板反射形成“拖尾”，把音节糊在一起；
- 3. 干扰说话人：旁边有人在看电视或说话；
- 4. 麦克风自噪声：传感器自身的底噪，包括热噪声和电路噪声。普通环境里，它往往低于环境噪声；超指向波束形成依赖通道间的精确相消，可能显著放大大自噪声，因此自噪声会限制阵列性能（见 § 2.6 的白噪声增益（White Noise Gain, WNG）和 § 5.3）。

人的听觉系统会合并双耳线索来定位和选择性聆听。机器可以用一组麦克风观测类似的空间差异：每个麦克风处于不同位置，同一声音到达它们的时间、强度略有不同。这些差异包含方向信息，也使系统能够优先保留某个方向的声音。

这些干扰的结构不同，不能用同一个“降噪增益”概括。先区分阵列空间处理承担的任务，再分别定义收益。

### 空间处理的三项任务

下面三项是阵列空间处理的核心任务：

| 任务   | 类比              | 回答的问题          |
|------|-----------------|----------------|
| 声源定位 | 你闭着眼判断声音从哪来     | “声音在哪个方向？”     |
| 波束形成 | 你扭头把耳朵和注意力转向说话人 | “怎么只听这个方向？”    |
| 声源追踪 | 你跟着走动的说话人持续转头   | “他动了，怎么一直盯着听？” |

把表中的问题落实到一段四路麦克风录音，三项任务的输入和输出分别是：

- **定位**读入同步的多路信号，输出一个或多个候选方向；某些方法还给出用于排序的方向分数，但分数不一定是校准过的置信度。
- **波束形成**利用目标方向和多路信号，产生一条更偏向该方向的输出音频。
- **追踪**把连续时刻的定位结果接起来，估计目标是否移动，以及何时应保持上次方向或重新捕获。

定位结果可控制波束，但三项任务的输出不相同，不能用波束输出音量替代定位误差或追踪身份正确率。

它们没有覆盖开头的全部问题。设备自己的回声由声学回声消除（Acoustic Echo Cancellation, AEC）处理，房间拖尾由去混响处理，多人同时说话还需要语音分离；这些任务分别在第 6~8 章展开。

定位、波束形成和追踪回答的问题不同，对应的评价指标也不同。下面先计算最基础的白噪声阵列增益。

### 三类阵列收益与白噪声增益

麦克风阵列最容易算清的一项理论收益，是对白噪声的**阵列增益**： $M$  元延迟求和阵列在理想条件下可得到  $10\log_{10} M$  dB。功率 2 倍约为 3 dB，10 倍为 10 dB；4 麦约为 6 dB，8 麦约为 9 dB。

这个结果要求各通道噪声互不相关、目标可按远场平面波对齐，而且各麦克风的增益和相位一致。Kumatani – McDonough – Raj 《Microphone Array Processing for Distant Speech Recognition》CMU 课程讲义，2012

定向干扰、弥散混响和模型失配不能直接并入这一个数字。它们要分别检查零陷、DI 与稳健性，具体收益随场景变化。

三类声场对应三种不同收益：

- 对独立、等功率通道噪声，用 WNG 评价。延迟求和阵列在理想无失真归一化下达到  $10\log_{10} M$ 。
- 对四面八方到来的弥散场，例如晚期混响，用指向性指数（Directivity Index, DI）评价。超指向设计可获得高于同麦数延迟求和阵列的 DI，但通常会牺牲 WNG（§ 5.3）。
- 对单个定向干扰，检查零陷深度。§ 5.4 的算例给出一个 -24 dB 零陷。

WNG、DI 和零陷深度的声场假设不同，不能用其中一个指标替代另外两个。

**白噪声增益的推导**（各麦噪声相互独立）：

1. 信号侧：各麦收到的是“同一个声音错开一点时间”，对齐后同相相加——幅度变成  $M$  倍，所以功率变成  $M^2$  倍（功率正比于幅度的平方）；
2. 噪声侧：各麦的噪声互相独立（不相关），相加时不会同相叠加而是“随机抵消一部分”——功率只变成  $M$  倍（独立随机变量的和的方差 = 方差的和）；
3. 相除：信噪比提升  $= M^2/M = M$ ，换成分贝就是  $10 \log_{10} M$ 。

以 4 只麦为例：信号幅度变为 4 倍，功率变为 16 倍；独立噪声的总功率变为 4 倍。因此信噪比提高 4 倍，约为 6 dB。满足上述条件时，麦数翻倍可增加约 3 dB。

对白噪声而言，信号同相相加，独立噪声只按功率相加。这给出延迟求和的 WNG 上限；它不是 DI、零陷深度或所有阵列算法的共同上限。

这个结果只依赖相干信号与独立噪声的叠加规律。真实系统还可利用双耳听觉中类似的时差、声级差和方向相关频谱线索。


## 1.1 双耳听觉的三类定位线索

---

从阵列模型看，双耳可以近似为带有头部散射的双传感器系统。人类主要利用三组线索判断声源方向，并在嘈杂环境中进行选择聆听：


图1 人类双耳定位线索：几何 ITD 与双重理论的适用边界

(a) 头 + 双耳 = 天然的 2 麦阵列 (带挡板)




头影：远侧耳被头遮挡  
路程差 → 双耳时间差 ITD  
遮挡 → 双耳声级差 ILD

(b) 双耳时间差 ITD (Woodworth 模型)



(c) 双重理论的线索主导区 (理论示意, 不是人体响应曲线)



1. ITD (双耳时间差)：声音先到近耳、后到远耳，正侧面时两耳的时间差最大，量级约为数百微秒；按头部半径 8.75 cm、声速 343 m/s 的 Woodworth 刚性球模型计算，正侧面约为 656  $\mu$ s，即约 0.66 ms (图1(b))。

图中“正前方偏 1° 约对应 9  $\mu$ s”只是该几何模型的换算，不是普适的听觉阈值。实际可辨阈值随频率、声级、刺激类型和实验任务变化。Woodworth 模型是高频射线近似，低频窄带声还需考虑绕射模型。[Aaronson 与 Hartmann 对 Woodworth 模型假设及适用范围的检验, JASA 2014](#)。频率升高后，相位会绕圈，听觉神经的波形锁相也逐渐减弱，因此纯相位 ITD 会出现歧义。

2. ILD（双耳声级差，Interaural Level Difference）： 头颅遮挡使远耳听到的高频通常更弱，低频绕射则会减小两耳声级差。

瑞利双重理论（duplex theory）把低频细结构 ITD 和高频 ILD 视为主要线索，但它不是互不重叠的硬分界。[Brughera、Dunai 与 Hartmann 的纯音实验](#)显示，细结构 ITD 的高频可辨上限因人而异，并在略高于 1.4 kHz 后消失；低频仍可能存在 ILD。[Bernstein 与 Trahiotis 的高频调制刺激实验](#)则说明，高频载波的包络 ITD 仍可影响侧向感知，不能与纯音相位 ITD 混为一谈。

图1(c)据此只画理论线索区和约 1.4 kHz 的非硬性边界，不画未经测量支持的人体 ILD 数值曲线。机器阵列也不能照搬这一频段划分：当均匀阵间距不满足半波长安全条件时，高频窄带相位会产生空间混叠，但非均匀几何、实测阵列流形和宽带融合仍可利用高频信息（§ 2.6、§ 3.2）。

3. HRTF（头相关传递函数，Head-Related Transfer Function）： 耳廓的褶皱，加上头和肩膀的散射，对不同方向、尤其是不同俯仰角的声音产生不同的滤波（谱峰/谱谷位置变化）。

这种方向相关谱形是人类判断俯仰和减少前后混淆的重要线索之一。判断还会联合双耳时差、双耳声级差、头部运动和既有听觉经验，不能把 HRTF 写成唯一依据。经典综述可参见[Middlebrooks 与 Green 1991](#)。

这些听觉线索在机器阵列中都有对应的观测量或处理方法。

双耳线索与阵列方法的对应关系

下表列出双耳听觉现象与阵列处理方法之间的联系：

| 人类的办法     | 机器阵列的对应技术（术语先不用记）          | 章节  |
|-----------|----------------------------|-----|
| ITD 双耳时间差 | GCC-PHAT 测 TDOA（§ 4.2）     | § 4 |
| 头颅当挡板     | 挡板散射改变与频率、方向有关的幅相响应（§ 3.2） | § 3 |

| 人类的办法           | 机器阵列的对应技术（术语先不用记）                                                   | 章节           |
|-----------------|---------------------------------------------------------------------|--------------|
| ILD 与 HRTF 谱线索  | 测量每个方向的“标准答案”（导向矢量；全体方向的集合叫阵列流形，标定见 § 3.4、§ 10.2）、DNN 学习方向特征（§ 4.7） | § 3、§ 4、§ 10 |
| 优先效应（先到声主导方位感）  | 提醒算法区分直达声、早期反射与晚期混响；WPE 主要预测晚期混响，机制与听觉优先效应不同                        | § 2.4、§ 7.1  |
| 鸡尾酒会效应（多人里挑一个听） | 波束形成 + 语音分离                                                         | § 5、§ 8.1    |

人类用两只耳朵、头部与耳廓产生 ITD、ILD 和 HRTF，再由神经系统融合这些线索。硬件形态先提供可观测信息，后端算法再利用信息；机器阵列也是同一分工。

解析模型负责约束和可解释边界，数据驱动方法可补足难以精确建模的细节。

第 2 章将从传播时延出发，把这些空间差异写成阵列信号模型。

## 本章练习

下面三题可用 `exercises_spatial.py` 复算。程序输出按 E01-01~E01-03 标识，不需要下载数据。这里的数字是本书推导，不是设备实测。

E01-01：四只麦不一定得到 6 dB。目标已经对齐，各路噪声功率均为 1，任意两路噪声的相关系数均为  $\rho$ 。对四路信号取平均，分别计算  $\rho = 0、0.5、1$  时的输出噪声功率和 SNR 改善量。为什么完全相同的噪声不会被平均消除？

参考答案：四个对角项贡献 4，十二个非对角项贡献  $12\rho$ ；平均权重的乘积均为  $1/16$ ，所以输出噪声功率为  $(4 + 12\rho)/16 = (1 + 3\rho)/4$ 。目标响应仍为 1，SNR 改善量是该噪声功率倒数的  $10\log_{10}$ 。

| 噪声相关系数 $\rho$ | 输出噪声功率 | SNR 改善量 |
|---------------|--------|---------|
| 0             | 0.250  | 6.02 dB |
| 0.5           | 0.625  | 2.04 dB |
| 1             | 1.000  | 0.00 dB |



相关系数为 1 时，四路噪声也同相相加，平均后原样保留。 $\rho$  不能任意取值：这个四路等相关矩阵的特征值是  $1 + 3\rho$ （一次）和  $1 - \rho$ （三次）。噪声协方差必须半正定，所以  $-1/3 \leq \rho \leq 1$ ；超出范围时，公式甚至可能给出负噪声功率，已不对应可能的噪声模型。

这个等相关模型用于隔离噪声相关性的影响。真实弥散场的相关性还随频率和麦间距变化，不能用一个固定  $\rho$  描述整段语音。

E01-02：更轻的声音是否一定更干净？对序列  $[0, 1, 0, -1]$  整体乘 0.5，计算均方功率比和电平变化。如果目标与噪声同时乘 0.5，SNR 会提高吗？

参考答案：原均方功率为  $2/4 = 0.5$ ，缩放后为  $0.5/4 = 0.125$ ，功率比为 0.25。因此电平变化为  $10\log_{10} 0.25 = 20\log_{10} 0.5 \approx -6.02$  dB。目标与噪声功率同时缩小到四分之一，SNR 不变。

比较处理前后音频时，应保留共同的幅度尺度；若分别归一化到同一峰值，这项整体增益变化就会被隐藏。这里的 dB 是相对功率变化，不是声压级 dB SPL。

E01-03：噪声较大的麦应当占多少权重？两路目标已经对齐且幅度相同，噪声互不相关，功率分别为 1 和 4。用实权重  $w_1, w_2$  相加，要求  $w_1 + w_2 = 1$ 。先算等权平均的输出噪声，再求使输出噪声最小的权重。

参考答案：等权平均的输出噪声为  $(1 + 4)/4 = 1.25$ 。将  $w_2 = 1 - w_1$  代入，输出噪声变为  $w_1^2 + 4(1 - w_1)^2$ ；对  $w_1$  求导得  $10w_1 - 8 = 0$ ，所以权重为  $[0.8, 0.2]^\top$ ，输出噪声为  $0.8^2 + 4 \times 0.2^2 = 0.8$ 。

两种权重的目标响应都是 1，因此后者相对等权平均的 SNR 改善为  $10\log_{10}(1.25/0.8) \approx 1.94$  dB。它甚至优于只取噪声功率为 1 的第一路，但不是多加一只麦就必有这一收益：本题依赖独立噪声、准确功率估计和目标对齐。第 5 章的 MVDR 将这一思路推广到复权重与相关噪声。

可在[章节代码练习与音频实验](#)中试听“单麦输入”和“对齐后平均”。文件共用增益，使用本书合成的谐波音和独立噪声，不是真人语音；先从低播放音量开始。听音用于观察差别，不能替代本题的功率计算。

## 第 2 章 · 声音到达阵列时发生了什么

### 2.1 核心事实：同一声音，到达各麦克风有先有后

本书取声速  $c \approx 343 \text{ m/s}$ ，这是约  $20^\circ \text{ C}$  干空气中的常用近似；温度、湿度和气体成分改变时，声速也会改变。Cramer 1993 给出湿空气声速计算式及适用范围，JASA 93(5)。

两个相距 4 cm 的麦克风，当声音沿两麦连线的方向传来时，先到近麦、后到远麦，时差幅值最大，约为  $0.04/343 \approx 0.116 \text{ ms}$ 。当声音垂直于连线传来时，两麦同时收到，时差为零。这个到达时间差称为到达时间差（Time Difference of Arrival, TDOA）。

坐标、方向和时差约定。把麦 1 放在  $x = 0$ ，麦 2 放在  $x = d > 0$ ；正横方向为  $\theta = 0^\circ$ ，正角朝  $+x$ 、即麦 2 一侧。单位向量  $\vec{u}(\theta)$  从阵列指向声源，声波实际传播方向为  $-\vec{u}$ 。到达时刻之差统一定义为  $\tau_{ij} = t_i - t_j$ 。

按这些约定，正角时波前先到麦 2，有  $t_2 < t_1$ ，即  $\tau_{21} < 0$ 、 $\tau_{12} > 0$ 。

平面波下，麦 1 相对麦 2 的带符号路程差为  $d \sin \theta$ （图2），所以带符号的麦对时差为

$$\tau_{12} = t_1 - t_2 = \frac{d \sin \theta}{c}, \quad \tau_{21} = -\frac{d \sin \theta}{c}。$$

其中  $d$  为两麦间距（m）， $\theta$  为声源方向角， $c$  为声速。只讨论大小时可写  $|\tau_{12}| = d|\sin \theta|/c$ ；不能把无符号“时差”直接代入需要方向的公式。

全书角度约定（后文凡涉角度一律沿用）： $\theta$  从正横方向（broadside，垂直于两麦连线的方向）起算。正横  $\theta = 0^\circ$  时两麦同时收到波前，时差为零；端射方向（endfire，沿两麦连线） $\theta = \pm 90^\circ$  时路程差幅值为  $d$ 、时差幅值最大。有些文献从阵列轴起算，此时关系写成  $\Delta\tau = d \cos \theta/c$ 。比较公式前应先统一角度零点和正方向；两种起算方式相差  $90^\circ$ 。

图2 时延的几何来源与角度约定（示意）




图2中麦1位于左侧、麦2位于右侧。正角声源位于麦2一侧，波前先到麦2；直角三角形给出  $\tau_{12} = d \sin \theta / c > 0$ 。正横时差为零，端射时差幅值达到最大。

离散化。16 kHz 采样率下，采样间隔为  $1/16000 = 62.5 \mu\text{s}$ ，对应约  $343 \times 62.5 \mu\text{s} \approx 2.1 \text{ cm}$  的传播距离。4 cm 阵列的最大时差约为  $117 \mu\text{s}$ ，不到两个采样间隔。仅按整数采样点定位会得到很粗的方向，因此实际系统需要亚采样 TDOA 估计，例如对互相关峰插值、对相关函数上采样，或在频域拟合相位斜率（见 § 4.2）。

同步。多路信号必须同步采样。同一设备可让多通道模数转换器（ADC，Analog-to-Digital Converter）共享时钟；分布式设备则有独立晶振。相对偏移为 50 ppm 时，1 小时累积约  $50 \times 10^{-6} \times 3600 = 0.18 \text{ 秒}$ ，远大于阵列所测的微秒级时差，因此需要时钟同步或采样率偏移补偿（§ 10.2）。

声速失配会直接变成角度偏差。示意地，若真实声速为 331 m/s、真实方向为  $60^\circ$ ，系统却按 343 m/s 反算，则  $\hat{\theta} = \arcsin[(343/331) \sin 60^\circ] \approx 63.8^\circ$ ，偏差约  $3.8^\circ$ 。这不是“331 m/s 对应某一固定气温”的断言，只用于隔离声速参数失配；实际系统应按工作环境估计或校准  $c$ 。

上式是 § 2.3 远场向量模型的几何基础；式(2-1)将在那里给出。声源接近阵列时，波前曲率不能忽略，需要先区分近场与远场。

## 2.2 近场与远场

- 近场（声源很近）：波前（波阵面，即相位相同的面）是球面，各麦克风信号的时间和幅度都有差别；
- 远场（声源距离远大于阵列尺寸）：波前近似平面，各麦克风收到的是“同一个信号错开一些时间”，幅度几乎相同。

Fraunhofer 距离  $r_F = 2D^2/\lambda$ （ $D$  为阵列最大孔径、 $\lambda$  为波长）是常用的相位曲率尺度。这个等式针对以阵列中心对称的孔径：点声源位于中心法线上，最远阵元到中心的距离为半孔径  $a = D/2$ ，并以中心到该阵元的路程差不超过  $\lambda/16$  为容限。

非中心对称阵列应直接使用从选定参考点到最远阵元的距离  $a$ ，得到  $r_F = 8a^2/\lambda$ 。对其他方位，这个尺度只能作为起始检查，而不是精确边界。该  $\lambda/16$  口径及几何推导也见 [ETSI ETR 273-1-1 条款 7.2.3.1 \(p.76\)](#)。

当  $r$  大于该尺度，且同时满足下面展开所需的  $r \gg a$  时，可以把球面波的相位近似为平面波。对实际拾音距离，还应检查阵列到声源的距离比、各阵元的幅度差，以及最高使用频率。

例如，7 cm 中心对称阵列在 1 kHz（ $\lambda = 0.343$  m）时的公式值是  $2 \times 0.07^2/0.343 \approx 2.9$  cm，但 2.9 cm 并不满足  $r \gg D$ ，不能据此宣称从 3 cm 开始整个房间都是远场。作为对照，1.26 m 的中心对称线阵在 1 kHz 下有  $r_F \approx 9.3$  m，普通会议室内应核对球面波模型。

Fraunhofer 判据的推导：

1. 球面波到达阵列中心与到达最远阵元的路程不一样。把中心到最远阵元的距离记作  $a$ ；中心对称阵列有  $a = D/2$ 。由勾股定理，额外路程是  $\sqrt{r^2 + a^2} - r$ 。
2.  $r \gg a$  时用近似  $\sqrt{1+x} \approx 1 + x/2$  展开： $\sqrt{r^2 + a^2} - r \approx \frac{a^2}{2r}$ 。
3. 工程约定：只要这个“球面弯曲造成的误差”小于约十六分之一波长（ $\lambda/16$ ，相位误差约  $22.5^\circ$ ，平面波假设就足够准），就算远场： $\frac{a^2}{2r} \leq \frac{\lambda}{16} \Rightarrow r \geq \frac{8a^2}{\lambda}$ 。只有在  $a = D/2$  时，这才化为  $r \geq \frac{2D^2}{\lambda}$ 。

泰勒展开的中间步：先提出  $r^2$ ： $\sqrt{r^2 + a^2} - r = r \left[ \sqrt{1+x} - 1 \right]$ ，其中  $x = (a/r)^2$ 。当  $x \ll 1$  时， $\sqrt{1+x} \approx 1 + x/2$ ，因此路程差近似为  $r \cdot x/2 = a^2/(2r)$ 。中心对称孔径代入  $a = D/2$  后才得到  $D^2/(8r)$ 。

所以 Fraunhofer 距离不是物理突变点，而是“相位误差还能忍”的约定线。

为何选  $\lambda/16$  ( $22.5^\circ$ ) 作为示例容限：路程误差  $\Delta$  对应相位误差  $2\pi\Delta/\lambda$ ；当  $\Delta = \lambda/16$  时，相位误差为  $22.5^\circ$ 。若只看两路等幅信号、其中一路存在这项相位误差，归一化相干和的幅度为  $|1 + e^{j\pi/8}|/2 = \cos(\pi/16) \approx 0.981$ ，即约  $-0.17$  dB。 $\lambda/16$  是本节为了说明数量级采用的工程容限，不是普适常数；要求更深零陷或更小相位误差时，所需距离会更大。

图3 近场与远场声场模型




图3 对比两种波前：近场采用球面波模型，各通道同时存在传播时延和幅度差；远场近似为平面波，传播模型主要由方向决定。这是下一节远场向量模型的前提。

确定远场条件后，可以把麦克风之间的传播时延写成导向矢量。

## 2.3 信号模型：把“声音有先有后”写成数学

符号约定（全书通用）：标量用普通斜体，如  $s$ 、 $\tau$ 、 $\theta$ 、 $\sigma^2$ ；向量用头顶箭头，如  $\vec{x}$ 、 $\vec{a}$ 、 $\vec{w}$ （默认列向量，零向量记  $\vec{0}$ ）；矩阵用加粗大写，如  $\mathbf{R}$ 、 $\mathbf{C}$ 、 $\mathbf{\Gamma}$ 、 $\mathbf{E}_n$ 。

再认几枚上标： $H$  是共轭转置（频域复数用）、 $\top$  是转置（时域实数用）、 $*$  是共轭、 $^{-1}$  是逆； $\hat{\cdot}$  表示估计值， $\|\cdot\|$  为范数、 $|\cdot|$  为幅度。

标量上标星号 vs 向量上标 H：单个复数取共轭用上标星号（如  $X_2^*$ ），整列向量转置再共轭用上标 H（如  $\vec{x}^H$ ）——后文凡见上标 H 都是向量/矩阵操作，凡见上标星号都是标量操作，对上号就不会认错。

大写谱值仍可为标量：语音文献习惯用  $X(f)$ 、 $X(f_k, \ell)$  这类大写字母表示某一物理频率或时频点上的复数谱值。它们是标量，不是矩阵；本书沿用这一惯例，并在首次出现处注明。

字母复用：受文献惯例所限， $k$  可表示频点索引、波数或 WPE 的滞后帧号； $D$  可表示阵列孔径或 PHD 强度函数； $\lambda$  可表示波长、WPE 功率谱或矩阵特征值； $K$  可表示声源数或 WPE 预测阶数； $s$  可表示源信号或追踪状态。每个符号以所在公式的定义为准。

频率与帧索引：本章的连续频率统一记作  $f$ ，单位 Hz；DFT/STFT 的频点索引记作  $k$ ，其物理频率为  $f_k = kf_s/N$ ；帧索引记作  $\ell$ 。文献中常见的  $\vec{x}(f, t)$  是简写，本书需要区分离散网格时写成  $\vec{x}(f_k, \ell)$ 。复指数  $e^{-j2\pi f\tau}$  中必须代入 Hz 频率  $f$  或  $f_k$ ，不能直接代入无量纲索引  $k$ 。

本节只做一件事：把 § 2.1 那句“同一声音到达各麦有先有后”一步步写成可以计算的式子。分三步走，每一步都交代“为什么”。

### 第一步：时域模型——每个麦克风一个式子

远场、单声源时，先把各麦相对麦 1 的到达时延定义为  $\tau_{m1} = t_m - t_1$ 。由 § 2.1 的方向约定，

$$\tau_{m1} = -\frac{(\vec{r}_m - \vec{r}_1)^\top \vec{u}}{c}。$$

正角 ULA 上  $\vec{r}_m - \vec{r}_1$  的  $x$  分量为正，所以  $m > 1$  时  $\tau_{m1} < 0$ ：右侧麦更早收到。把麦 1 的到达时刻作为时间原点，第  $m$  个麦克风（ $m = 1, 2, \dots, M$ ）录到的信号为

$$x_m(t) = s(t - \tau_{m1}) + n_m(t)。$$

- $x_m(t)$ ：第  $m$  路录音波形——这是你实际拿到的数据；下标  $m$  表示“第几个麦克风”， $t$  是时间；



- $s(t)$ : 麦 1 处的理想直达目标分量，源端到参考麦的公共传播延迟和幅度衰减已经吸收入其中。它不带下标  $m$ ，因为等幅远场模型把其余通道写成它的相对时移，而不是声源端原波形的直接副本；
- $\tau_{m1}$ : 第  $m$  个麦相对麦 1 的带符号到达时延（秒），它由声源方向决定，可为负数；
- $n_m(t)$ : 第  $m$  路的噪声。

时移位于  $s(t - \tau_{m1})$  的自变量中。变换到频域后，它会成为可直接相乘的复相位因子。

## 第二步：搬到频率域——延迟从“移位”变成“转个角度”

本书采用前向傅里叶变换  $X(f) = \int x(t)e^{-j2\pi ft} dt$ 。在此约定下，时移性质为

$$s(t - \tau) \xrightarrow{\mathcal{F}} S(f) e^{-j2\pi f\tau}$$

箭头上的  $\mathcal{F}$  表示傅里叶变换。

左边表示时域延迟  $\tau$  秒，右边表示频域中乘以复相位因子。频域形式便于把宽带信号分频点处理，也便于将卷积近似为乘法，因此许多阵列算法采用 STFT 实现；这种近似的边界见 § 2.5。

这个  $e^{-j2\pi f\tau}$  到底是什么？它是复平面上一个长度为 1 的箭头，从正实轴出发顺时针转过角度  $2\pi f\tau$ （图4(b)）。其中  $j$  是虚数单位（ $j^2 = -1$ ）； $e$  的复指数由欧拉公式定义：

$e^{j\phi} = \cos \phi + j \sin \phi$ ；有些书把  $2\pi f$  写成  $\omega$ （角频率），两者是一回事。

直觉检验：延迟恰好等于一个周期（ $\tau = 1/f$ ）时转过整整一圈  $2\pi$ ——波形平移一个周期后与原波形重合，箭头也转回原地，两边对上了 ✓。



图4 时延为什么变成  $e^{-j2\pi f\tau}$ ：几何直觉  
(4 cm 麦距；端射方向达到最大麦间时延  $\tau=d/c\approx 0.117$  ms)




图 4 的三幅子图采用同一组参数：4 cm 麦距、声速 343 m/s、端射方向，因此  $\tau = d/c \approx 0.1166$  ms。时域波形右移约 0.117 ms；1 kHz 复相量顺时针旋转约  $2\pi \times 1000 \times 0.1166 \text{ ms} \approx 42^\circ$ ；相位—频率图的斜率为  $-2\pi\tau$ ，2 kHz 处约为  $-84^\circ$ 。§ 4.2 的 GCC-PHAT 正是利用这项关系估计时延。

图 4 (c) 还说明，同一时延引起的相位旋转与频率成正比。相位展开后，直线斜率为  $-2\pi\tau$ ；实际数据中的相位缠绕、噪声和混响会使估计更复杂。

第三步：把  $M$  个式子摞起来，写成向量

对第  $m$  路、物理频率  $f$ ，时移性质给出：

$$X_m(f) = e^{-j2\pi f\tau_{m1}(\theta)} S(f) + N_m(f)。$$

- $X_m(f)$ 、 $S(f)$ 、 $N_m(f)$ ：第  $m$  路/声源在物理频率  $f$  处的复数谱值——都是标量（单个复数）；
- $e^{-j2\pi f\tau_{m1}(\theta)}$ ：相对时延造成的相位旋转因子，也是标量。

把  $M$  路的式子竖着摞起来。相对时延满足  $\tau_{m1} = -(\vec{r}_m - \vec{r}_1)^\top \vec{u}/c$ ，所以第  $m$  个导向分量也可写为

$$a_m(f, \theta) = e^{-j2\pi f\tau_{m1}} = e^{+j2\pi f(\vec{r}_m - \vec{r}_1)^\top \vec{u}/c}。$$

于是

$$\underbrace{\begin{bmatrix} X_1(f) \\ X_2(f) \\ \vdots \\ X_M(f) \end{bmatrix}}_{\vec{x}(f)} = \underbrace{\begin{bmatrix} e^{-j2\pi f\tau_{11}(\theta)} \\ e^{-j2\pi f\tau_{21}(\theta)} \\ \vdots \\ e^{-j2\pi f\tau_{M1}(\theta)} \end{bmatrix}}_{\vec{a}(f, \theta)} S(f) + \underbrace{\begin{bmatrix} N_1(f) \\ \vdots \\ N_M(f) \end{bmatrix}}_{\vec{n}(f)}。$$

每一行就是上面那个标量式子；把公共的  $S(f)$  提到列向量外面，就得到全书最常用的紧凑形式：

$$\vec{x} = \vec{a}(\theta) s + \vec{n}。 \quad (2-1)$$

- $\vec{x}$ ： $M$  路信号的列向量， $M$  为麦克风数量；
- $\vec{a}(\theta)$ ：导向矢量 (steering vector)，描述声源位于  $\theta$  方向时各麦克风相对麦 1 的相位；
- $\theta$ ：声源方向，也是定位时想求的量；
- $s$ ：该频点的声源谱，是标量，即上面逐行式子中的  $S(f)$ ；
- $\vec{n}$ ：噪声向量。

式(2-1)省略了频点自变量  $(f)$ ，下文沿用此简写。在本节的等幅远场模型中， $\vec{a}(\theta)$  每个分量的模长为 1，分量差异来自相对时延  $\tau_{m1}(\theta)$ 。定位算法可用候选方向的导向矢量解释观测，波束形成器则用它规定目标方向响应；近场或含散射时还要加入距离和幅度项。

手算一遍：3 麦 ULA 的麦 1、2、3 依次位于  $x = 0, 4, 8$  cm；声源位于正角  $30^\circ$ ， $f = 1$  kHz。

相邻麦的  $\tau_{m1}$  变化量为  $-d \sin 30^\circ / c \approx -58.3 \mu\text{s}$ ，所以相邻导向相位变化为  $-2\pi f(-58.3 \mu\text{s}) \approx +0.366 \text{ rad}$ ，即约  $+21^\circ$ 。因此

$$\vec{a} = [1, e^{+j0.366}, e^{+j0.733}]^\top。$$

时域解释是麦 2 比麦 1 早  $58.3 \mu\text{s}$ 。在本书的傅里叶约定下，较早到达对应相对麦 1 的正相位。

**混响：**实际房间中麦克风收到直达声与多条反射路径的叠加，即声源与房间脉冲响应（Room Impulse Response, RIR）的卷积。 $T_{60}$  描述混响尾的衰减时间；下一节给出定义、计算和适用边界。

直达声模型明确后，§ 2.4 再加入房间反射，说明混响会怎样改变观测。

## 2.4 房间声学：混响到底是怎么来的

房间脉冲响应说明反射怎样进入录音，混响时间描述拖尾的衰减，直达混响比描述两种能量的相对大小。以下分别建立这三个量，再说明怎样仿真和测量。

### 2.4.1 房间脉冲响应与早晚反射


**房间脉冲响应（Room Impulse Response, RIR）：**RIR 是房间和收发位置固定时，系统对理想单位冲激的响应。在线性、时不变近似下，麦克风信号等于声源信号与 RIR 的卷积。

拍手录音可以粗略显示直达声和衰减尾，却不是严格的 RIR：拍手本身有有限时长和频谱，麦克风响应也会进入录音。要得到可用于计算的 RIR，通常播放已知测试信号并反卷积，测量方法见本节末。

RIR 可按图5(a)作教学性分段：

1. **直达声：**从声源直线到达，最干净、携带最准的方向信息；
2. **早期反射：**直达声后较早到达、仍能分辨出路径结构的反射。图5(a)用  $80 \text{ ms}$  作示意分界； $80 \text{ ms}$  也是音乐清晰度指标  $C_{80}$  的积分分界，而语音清晰度常用  $50 \text{ ms}$  的  $C_{50}$ 。这不是早、晚反射的普适物理边界， $80 \text{ ms}$  内的反射次数也取决于房间尺度和路径。早期反射可能增加响度，也会模糊方向线索；
3. **晚期混响：**经多次反射后形成的弥散尾音。统计建模时，常把充分弥散的晚期混响近似为各向同性声场；这个近似适合分析波束形成器的 DI（指向性指数，§ 2.6），但不表示混响在时间上就是独立白噪声。WPE（第 7 章）正是利用晚期混响仍有时间相关性来做预测消除。

图5 房间脉冲响应、能量衰减与直达混响比（本书仿真）



## 2.4.2 混响时间：从吸声量算衰减

$T_{60}$  与赛宾公式。 $T_{60}$  是声能衰减 60 dB 所需的时间（图5(b)），可用赛宾（Sabine）公式估算。原始理论可追溯到 Sabine 的声学论文集。实测时要按空间类型选标准：[ISO 3382-1:2009](#)面向演出空间，[ISO 3382-2:2008](#)面向普通房间：

$$T_{60} = \frac{0.161 V}{A}, \quad A = \sum_i S_i \alpha_i.$$

- $V$ ：房间体积（ $\text{m}^3$ ）； $S_i$ 、 $\alpha_i$ ：第  $i$  个表面的面积与吸声系数（0=全反射的光滑瓷砖，1=全吸声的开放窗户）。
- 算例（本例是参数演示，不代表某类房间的通用测量值）：房间尺寸取  $5 \text{ m} \times 4 \text{ m} \times 2.8 \text{ m}$ ，故  $V = 56 \text{ m}^3$ ；再假设各表面的赛宾吸声量合计为  $A = 18 \text{ m}^2$ ，则  
 $T_{60} = 0.161 \times 56 / 18 \approx 0.50 \text{ s}$ 。改变表面材料或摆设会改变  $A$ ，因此同尺寸房间也可能得到不同结果。

这个公式怎么推出来的（五步，能量守恒 + 一个几何事实）：

1. 模型：混响期的声能在房间里近似均匀分布（扩散场假设），声线不断撞墙，每撞一次被吸收掉一部分；
2. 几何事实：声线在房间中平均飞行  $\ell_{\text{mfp}} = \frac{4V}{S}$  米撞一次墙（统计几何的经典结果， $S$  是所有墙面的总面积）。直觉检验：房间越大飞得越远、墙越多撞得越勤，都对得上；
3. 每秒能量损失率：撞墙频率  $= \frac{c}{\ell_{\text{mfp}}} = \frac{cS}{4V}$ （次/秒），每次损失能量比例  $\bar{\alpha}$ （平均吸声系数），于是每秒损失率  $= \frac{cS\bar{\alpha}}{4V} = \frac{cA}{4V}$ ；
4. 列方程求解： $\frac{dE}{dt} = -\frac{cA}{4V}E$ ——“损失率正比于当前能量”的方程，解是指数衰减  
 $E(t) = E_0 e^{-\frac{cA}{4V}t}$ ；
5. 代入定义收尾： $T_{60}$  是能量衰减 60 dB 的时间——注意 60 dB 是能量比  $10^6$ （不是  $10^3$ ：能量的 dB 用  $10 \log_{10}$ ， $10 \log_{10} 10^6 = 60$ ）。令  $e^{-\frac{cA}{4V}T_{60}} = 10^{-6}$ ，两边取对数： $\frac{cA}{4V}T_{60} = 6 \ln 10$ ，解出

$$T_{60} = \frac{24 \ln 10}{c} \cdot \frac{V}{A} = \frac{55.3}{343} \cdot \frac{V}{A} \approx 0.161 \frac{V}{A} \checkmark.$$

平均自由程中的因子 4：在声线方向各向同性、房间为凸体的假设下，墙面对各方向的平均投影面积是总表面积的 1/4。因此单位体积内声线单位时间的墙面碰撞率为  $cS/(4V)$ ，两次碰撞间的平均距离为其传播距离形式的倒数  $\ell_{\text{mfp}} = 4V/S$ 。量纲检查： $V/S$  是长度；立方房间边长为  $L$  时， $\ell_{\text{mfp}} = 4L^3/(6L^2) = 2L/3$ 。

常数 0.161 的来源： $24 \ln 10 \approx 55.26$ ；取声速  $c = 343 \text{ m/s}$ ， $55.26/343 \approx 0.161$ 。其中  $6 \ln 10$  来自 60 dB 的能量比，几何平均路径项再带来因子 4。

适用边界：推导用了“扩散场 + 弱吸收”假设。平均吸声系数不再很小时，赛宾的一阶近似会逐渐偏离，可改用 Eyring 公式  $T_{60} = \frac{-0.161V}{S \ln(1 - \bar{\alpha})}$ （极端检查： $\bar{\alpha} = 1$  时 Eyring 给出  $T_{60} = 0$ ，赛宾却给出非零值）。这里不设一个适用于所有房间的硬阈值；应按频带、声场扩散程度和测量标准核对。公式来源见 [Eyring 1930 原文](#)。

### 2.4.3 直达混响比与临界距离

直达混响比 (Direct-to-Reverberant Ratio, DRR) 比较同一声源的直达分量与混响分量能量： $\text{DRR} = 10 \log_{10}(E_{\text{direct}}/E_{\text{reverberant}}) \text{ dB}$ 。DRR 为正表示直达能量较大，为负表示混响能量较大。

两项能量须来自同一次声学条件与相同频带、幅度参考；直达窗与混响窗的各自边界也要说明。图 5 (c) 采用下述理想扩散场模型，真实房间的直达与反射分界仍要按测量方法确定。

直达声随距离按平方反比衰减（每远一倍弱 6 dB），而理想扩散场中的晚期混响能量密度近似不随位置变化。两者相等的位置称为临界距离  $d_c$ ：

$$d_c \approx 0.057 \sqrt{\frac{V}{T_{60}}} \text{ (m)}.$$

（此式默认声源全向辐射，即指向性因子  $Q = 1$ ；若声源有指向性（如人声朝前更响），把  $Q$  乘进根号内的分子： $d_c \approx 0.057 \sqrt{QV/T_{60}}$ 。）

临界距离公式的推导（四步）：

1. 求直达声能量密度。全向声源的功率  $W$  均匀分布在半径  $r$  的球面上，声强为  $I_d = W/(4\pi r^2)$ ，单位是  $\text{W/m}^2$ 。对向外传播的波作局部平面波近似，再除以声速，得到能量密度  $E_d = I_d/c = W/(4\pi r^2 c)$ ，单位是  $\text{J/m}^3$ 。
2. 求混响声能量密度。房间里的混响能量不断被墙面吸收，又不断由声源补充。稳态扩散场中的能量密度为  $E_r = 4W/(cA)$ ，其中  $A$  是赛宾吸声量；该理想模型把它视为不随位置变化。下面的说明框解释分子中的 4。



3. 令两种能量密度相等。在临界距离  $r = d_c$  处,  $E_d = E_r$ 。将上面两式代入, 先消去共同的声源功率  $W$  与声速  $c$ , 再解  $d_c^2$ :

$$\begin{aligned}\frac{W}{4\pi d_c^2 c} &= \frac{4W}{cA}, \\ \frac{1}{4\pi d_c^2} &= \frac{4}{A}, \\ d_c^2 &= \frac{A}{16\pi}.\end{aligned}$$

4. 代入赛宾公式。由  $T_{60} = 0.161V/A$  得  $A = 0.161V/T_{60}$ 。代入上一步, 最后才开平方:

$$\begin{aligned}d_c &= \sqrt{\frac{0.161V}{16\pi T_{60}}}, \\ &= \sqrt{0.00320 \frac{V}{T_{60}}}, \\ &\approx 0.057 \sqrt{\frac{V}{T_{60}}} \text{ m}.\end{aligned}$$

这里把  $V$  的数值按  $\text{m}^3$ 、 $T_{60}$  的数值按  $\text{s}$  代入, 结果才按  $\text{m}$  读取; 写成带量纲的等式时, 赛宾常数 0.161 的单位是  $\text{s/m}$ 。

可跳过: 弥散能量式中 4 从哪里来 ( $4W/(cA)$ ) : 稳态能量平衡是“注入功率 = 吸收功率”。墙面每秒吸收的功率 = 能量密度  $E \times$  声速  $c \times$  有效吸收面积。关键一步: 各向同性声场中, 只有面向墙面方向的能量流才会被吸收, 对半球方向平均后有效因子恰为 1/4 (各向同性场向墙面投影平均带来的 1/4 因子, 直觉版的严格说法见上), 于是吸收功率 =  $E \cdot cA/4$ 。令它等于注入功率  $W$ , 解得  $E = 4W/(cA)$ 。与上一步平均自由程里的 4 是同一个几何根源: 都是“各向同性场向一面墙投影”带来的 1/4。

常数 0.057 的来源:  $0.161/(16\pi) \approx 0.003203$ , 再开平方得到  $0.0566 \approx 0.057$ 。因此该常数同时包含赛宾公式中的 0.161 和球面扩散项  $16\pi$ 。

图 5 (b) 的指数包络把名义  $T_{60}$  设为 0.5 s; 加入固定随机尾和早期反射后, Schroeder 剩余能量积分曲线最接近 -60 dB 的位置约为 0.514 s。因此 0.5 s 是生成模型的名义参数, 不表示该固定样例恰好在 0.500 s 穿过 -60 dB。

这里直接寻找 -60 dB 交点, 只用于核对这条合成曲线。实测应按场所选择 ISO 3382 的相应分册, 常对衰减曲线的 -5~-25 dB ( $T_{20}$ ) 或 -5~-35 dB ( $T_{30}$ ) 区间回归, 再外推到 60 dB。



图 5 (c) 是设定  $d_c = 1.0 \text{ m}$  的归一化示例。在该模型中，3 m 处的 DRR 为  $-20 \log_{10}(3/1) \approx -9.5 \text{ dB}$ ，表示混响能量高于直达声；这个数不能外推到未测量的房间。实际  $d_c$  还随体积、吸声量和声源指向性变化。

DRR 可作为距离估计的声学线索，但必须同时考虑房间和声源指向性。在上述线性模型中，直达声与混响声能量都正比于声源功率  $W$ ，两者相除后  $W$  抵消，因此只把声源整体调大并不会改变 DRR。若从含噪或发生削波的录音估计 DRR，测得的比值还可能受噪声和非线性影响。

#### 2.4.4 仿真与实测房间脉冲响应

仿真怎么造混响：镜像法（Image Method，镜像声源法）把墙面反射等效为镜像声源的叠加，算法定义见 [Allen 与 Berkley 1979 原论文](#)。开源库 `pyroomacoustics` 可生成给定房间和阵列的 RIR；本书固定链接到 [pyroomacoustics 0.10.0 的 PyPI 发布页](#)，示例接口以该版本为准。不同版本的接口、默认值或依赖可能变化，复现时应记录实际安装版本。

反过来，怎么实测一个房间的混响：拍手或爆破气球后观察衰减只能作粗略估计。更可控的做法是指数正弦扫频（Exponential Sine Sweep，ESS）：播放频率指数上升的已知扫频，录音后反卷积得到 RIR，方法见 [Farina 2000](#)，[AES Convention Paper 5093](#)。

在系统近似时不变、没有削波且扫频长度足够时，ESS 可将若干谐波失真成分与线性 RIR 在反卷积结果中分开。环境噪声、削波、时变非线性和播放/录音链路的频响仍会影响测量。

无法播放测试音的在线场景也可以用普通语音盲估  $T_{60}$  和 DRR，例如利用两麦相干函数估计直达-弥散比。

房间传播模型解释了麦克风信号的组成。算法实现还需要把连续波形组织成 STFT、快拍和协方差矩阵。

## 2.5 数据怎么组织：STFT、快拍与协方差矩阵

---

后面的算法反复出现三个词——STFT、快拍、协方差矩阵，先在这里一次讲清。

### 2.5.1 从波形到逐频点的短时谱

STFT（短时傅里叶变换，Short-Time Fourier Transform）把波形切成重叠短帧，每帧加窗后做快速傅里叶变换（Fast Fourier Transform，FFT），得到时间-频率复数网格，即语谱图（图 6 (a) (b)）。每个时频点同时包含幅度与相位。

增强或波束示例可用 32 ms 窗、8 ms 帧移；自动语音识别（Automatic Speech Recognition, ASR）前端常见另一组设置为 25 ms/10 ms。比较文献时应核对采样率、窗函数、窗长和帧移。

为什么需要这张表？因为 STFT 把宽带语音分解为一组近似窄带问题。时延  $\tau$  对应的相位旋转  $2\pi f_k \tau$  随频率变化，因此第  $k$  个频点要使用自己的  $\vec{a}(f_k, \theta)$ 。

把卷积在每个时频点写成  $\vec{x}(f_k, \ell) \approx \vec{a}(f_k, \theta)s(f_k, \ell) + \vec{n}(f_k, \ell)$  仍是窄带近似。窗函数会使直线卷积在 STFT 中产生频带内和跨频带项，长房间响应、过短窗或频率变化过快时误差更大。第 4、5 章逐频点处理时，需把窗长与有效冲激响应长度纳入验证。

STFT 分帧数字例子：阵列配置为 4 麦常规小间距，采样率 16 kHz、窗长 32 ms、帧移 8 ms。

- 窗长为  $16000 \times 0.032 = 512$  点，FFT 常用 512 点。
- 帧移为  $16000 \times 0.008 = 128$  点，相邻帧重叠率为  $(512 - 128)/512 = 75\%$ 。
- 不在信号两端补零、只取完整窗时，1 s 语音共有  $\lfloor (16000 - 512)/128 \rfloor + 1 = 122$  帧。
- 每帧 FFT 给出 257 个有效频点（0~8 kHz），相邻频点间隔为  $16000/512 = 31.25$  Hz。

这个 31.25 Hz 是 DFT 网格间隔，不等于能分开两条相邻谱线的频率分辨能力；后者还取决于窗函数的主瓣宽度等条件。Harris 1978 详细讨论了窗函数对谱分析的影响。

分帧还要单独指定端点策略。本书 `spectral.py` 的默认设置 `center=True` 会在两端各补半窗，并把末端补到完整帧，因此同一段 1 s 信号得到 126 帧；设为 `center=False` 时，本例才得到 122 帧。一般长度若不能恰好覆盖，代码仍会补齐末帧，不能直接套用只取完整窗的向下取整式。

信号端点补零会改变帧数；固定一帧后，把 FFT 从 512 点补到 1024 点则只加密频率网格，两者不是同一个操作。外部接口也应分别检查端点扩展和末尾补齐设置，见 SciPy STFT 的 `boundary` 与 `padded` 定义。

按上述不补端点、只取完整窗的口径，1 s、4 麦录音展开为  $122 \times 257 = 31354$  个时频点，每个点上有一个 4 维快拍向量。这就是后文协方差矩阵  $\hat{\mathbf{R}}(f_k)$  在每个频点上平均的对象，每个频点有 122 个快拍参与平均。

## 2.5.2 从多通道快拍到空间二阶矩

快拍（snapshot，快照向量）：固定频点索引  $k$ 、取第  $\ell$  帧，把  $M$  个麦克风在该时频点  $(f_k, \ell)$  的复数谱排成列向量  $\vec{x}(f_k, \ell)$ ，就是一个快拍——相当于阵列在某一短帧拍下的一张“空间照片”（图 6(b) 里标的那个格子就是它）。

空间二阶矩（阵列文献常称空间协方差矩阵）：单张快拍太噪，把几十到几百个快拍平均：

$$\hat{\mathbf{R}}(f_k) = \frac{1}{L} \sum_{\ell=1}^L \vec{x}(f_k, \ell) \vec{x}^H(f_k, \ell). \quad (2-2)$$

式(2-2)没有减去样本均值，严格说是未中心化的样本二阶矩；当 STFT 快拍在所用时间段内可视为零均值，或已经去均值时，它才等于样本协方差。阵列文献常把两者都简称为空间协方差，使用实现或论文时要核对其定义。

$\hat{\mathbf{R}}$  是  $M \times M$  的复数矩阵，第  $m, n$  个元素记录麦  $m$  与麦  $n$  在该频点上的相关幅度与相位差。Capon、MVDR、MUSIC 都以它为输入；MUSIC 再用特征分解把观测空间分成信号子空间和噪声子空间。

只有在窄带远场模型正确、 $K < M$ 、导向矩阵与源协方差均满秩、噪声为空间白噪声且快拍足够多时，才可把高于噪声底的  $K$  个特征值解释成  $K$  个声源。相干反射、彩色噪声、有限快拍和阵列失配都会破坏这种分组。

图6 从波形到协方差矩阵：阵列算法处理的数据形态（模拟）




图 6 (a) (b) 来自单通道示意语音，用来解释分帧和时频点。图 6 (c) (d) 是另一组独立的 8 麦、2 个互不相干窄带源加空间白噪声理论例，并非由 (a) (b) 的单通道波形累积得到。

图 6 (c) 只画  $|R_{ij}|$ ，相位仍包含在复数  $R_{ij}$  中但未在图上显示。图中  $(k, l)$  依次表示频点索引和帧索引；正文用  $\ell$  代替容易与数字 1 混淆的字母  $l$ ，对应物理频率为  $f_k$ 。

只有在源协方差满秩、噪声为空间白噪声、阵列模型正确且快拍充足等条件下，才能把较大特征值的个数与声源数联系起来。

协方差估计的两个细节：

1. 快拍数太少时， $\hat{\mathbf{R}}$  的估计方差增大，小特征值也会明显波动。这是 Capon/MVDR 使用对角加载 (§ 5.4) 的原因之一。
2. 帧移小、相邻帧高度重叠时，快拍间并不独立，有效快拍数会少于帧数。

其中  $L$  是参与平均的快拍数， $\ell$  是快拍（帧）索引。快拍不够时会发生什么（处理方法见 § 5.4、§ 8.4）：样本协方差是  $L$  个秩一外积之和，因此

$$\text{rank}(\hat{\mathbf{R}}(f_k)) \leq \min(M, L)。$$

若未去均值， $L < M$  时它必然奇异；若先用同一批样本估计并减去均值，秩至多为  $L - 1$ ，此时  $L \leq M$  就必然奇异。

即使  $L \geq M$ ，强相关快拍、很差的条件数和估计误差仍可能让求逆不稳，所以不存在通用的“ $L \geq 2M$  就安全”门槛。

第一类处理是收缩估计：

$$\hat{\mathbf{R}}_{\text{shrink}}(f_k) = (1 - \rho)\hat{\mathbf{R}}(f_k) + \rho \frac{\text{tr} \hat{\mathbf{R}}(f_k)}{M} \mathbf{I},$$

其中  $0 \leq \rho \leq 1$ ，用于在样本统计量和各向同性先验之间折中；§ 5.4 的对角加载与它目标相近。

第二类处理是用时频掩码为快拍加权，分别估计目标或噪声协方差（§ 8.4）。掩码可以减少干扰泄漏，但也会减少有效样本数，仍须检查矩阵的条件数并配合加载。

本书代码采用的数组与流式约定。`spectral.py` 中的 STFT 固定输出 通道数  $\times$  频点数  $\times$  帧数，即  $M \times F \times L$ ；`covariance.py` 再把它变成  $F$  个  $M \times M$  空间二阶矩。示例使用前向变换  $e^{-j2\pi ft}$ 、周期 Hann 窗和加权重叠相加。

`center=True` 会在两端补半窗，因此离线重构可对齐原波形；实时系统不能据此把延迟写成零，还要把首帧等待、窗长、帧移、分块缓存和可能的前瞻一并计入端到端延迟。

协方差实现同时给出批量估计和指数递归更新。掩码在某个频点全为零时，代码会报错，而不是用  $\varepsilon$  伪造一个无统计依据的矩阵。非零掩码先除以该频点的最大权重，再累积归一化二阶矩；这个共同缩放不改变估计值，却避免把很小的权重单位误判成没有数据。

有限精度造成的非厄米残差会被对称化；中间计算超出浮点数范围时明确报错。需要加载时采用无量纲相对口径  $\alpha \text{tr}(\hat{\mathbf{R}})\mathbf{I}/M$ 。权重可归一化不代表独立快拍充足，还需检查秩、权重集中程度和模型条件。

上线还应记录遗忘因子、VAD/SPP 更新门控、每频点有效权重、条件数以及回退方式；这些参数共同决定跟踪速度，不能只记录“用了 MVDR”。可运行的端到端小例见 `ch02_05_baselines.py`，解析边界测试见 `test_codes_doa_beam.py`。



2.5.3 真实录音：交叉项为何不能随意省去

真实录音 R01：忽略通道交叉项会怎样？[DEMAND 数据库](#)的 NRIVER 场景提供真实同步环境噪声。本书取其 16 kHz 版本前 10 s，即各通道样本 [0,160000]，分别平均通道 1~2 和 1~16。

16 只麦克风由同一设备采集，原始通道增益未经彼此校准；没有干净语音参考或声源位置真值。数据及本书派生音频按 CC BY-SA 3.0 分发，作者、采集条件、几何和修改说明见[真实录音说明](#)。

PCM 整数除以 32768 后，直接计算未去均值的二阶矩  $R_{ij} = T^{-1} \sum_n x_i[n]x_j[n]$ ，这里  $T = 160000$ 。等权平均功率包含全部  $R_{ij}$ ；若只保留对角项，就得到“交叉项为零”的预测。这个预测仍保留各通道自身功率，不另行假设麦克风等增益。非零均值下，统计独立也不自动意味着二阶交叉项为零。

| 使用通道 | 仅对角项预测功率                  | 保留交叉项的平均功率                | WAV 读回相对预测 (dB) |
|------|---------------------------|---------------------------|-----------------|
| 1~2  | $5.653225 \times 10^{-6}$ | $6.683714 \times 10^{-6}$ | 0.7272          |
| 1~16 | $6.857479 \times 10^{-7}$ | $1.809816 \times 10^{-6}$ | 4.2148          |

功率单位为数字满刻度幅度平方，不是  $\text{Pa}^2$ 。全部文件导出增益为 1，无去直流、时移或逐文件归一化；平均后仅做一次 PCM16 舍入，故 WAV 读回功率与表中量化前功率有微小差别。数值为本书对该固定片段的计算，表格最后统一舍入。

本片段的交叉项为正，忽略它们会低估平均后的数字功率；增加通道并没有消除这个偏差。平均后的音量下降不等于语音增强成功，因为这里没有目标语音可供检验。练习 R01 的逐步计算、10 个连续 1 s 子段、代码及三个单通道试听对照见[真实河流录音实验](#)。子段范围不是独立重复实验的置信区间。

2.5.4 语音信号会改变哪些估计条件

语音信号对阵列处理的影响：

1. 语音既含低频基频及谐波，也含更高频的辅音和摩擦音；具体频带随说话人、发音和采集链路变化。谐波结构会让互相关出现周期性假峰，因此 TDOA 算法常做宽带加权（§ 4.2）。
2. 语音短时近似平稳、长时非平稳，所以常按几十毫秒分帧。
3. 多说话人语音在时频域常呈近似稀疏：不少时频点由某个声源占优，这是掩码类方法与聚类方法能工作的依据（§ 8.4），但混响和同频谐波会削弱这一近似。

阵列能否利用高频定位，还要同时检查混叠：4 cm 间距对应的全视场安全上限约 4.3 kHz，3 cm 间距约 5.7 kHz（§ 2.6）。超过上限并非一律不能用，而是必须结合转向范围、阵列几何和宽带融合处理歧义。

有了协方差和导向矢量，便可以定义波束图及其分辨率、旁瓣、WNG 和 DI。

## 2.6 怎么衡量一个波束好不好：先学会读波束图

本节路线图：四个度量回答四个问题——主瓣多窄（看得多细）？旁瓣多高（漏多少）？DI（抗混响/弥散噪声的能力）？WNG（抗自身底噪的能力）？

波束形成器让指定方向保持所需响应，同时改变其他方向的增益。把各方向的增益画出来就是波束图（beampattern）；图7(a)标出本节使用的四个读图要素：

- 主瓣（main lobe）：想听的方向上拱起的那个大峰。峰顶增益 0 dB（无失真通过）；
- 旁瓣（side lobes）：主瓣两侧一连串越来越矮的小峰——它们在其他方向的声音漏进来的通道；
- 零点（nulls）：瓣与瓣之间的深谷——这些方向上各麦信号恰好相消干涉，几乎完全听不到；

同相叠加形成峰，反相抵消形成谷；等比数列求和得到完整阵因子，见 § 5.2。图 7（a）先帮助读者辨认这些结构，后面再计算其宽度和电平。

图7 波束图怎么读：主瓣 / HPBW / 旁瓣 / 零点 / 栅瓣（模拟）






图 7 (a) 标出主瓣、旁瓣、零点和半功率宽度；数值结果约为  $14.8^\circ$ ，离散 ULA 近似为  $14.7^\circ$ 。图 7 (b) 把间距增至  $\lambda$ ，在  $-7.7^\circ$  出现与主瓣等高的栅瓣。

### 2.6.1 半功率波束宽度：主瓣有多宽

半功率波束宽度 (Half-Power Beam Width, HPBW) 是主瓣两侧功率降到峰值一半的两个点之间的夹角。

半功率点与  $-3$  dB 点：功率减半为  $10\log_{10} 0.5 = -3.01$  dB。波束图若按幅度绘制，半功率对应幅度  $1/\sqrt{2} \approx 0.707$ ，同样得到  $20\log_{10} 0.707 = -3.01$  dB。因此“半功率点”和“ $-3$  dB 点”指同一位置（图 7 (a) 的红色双箭头）。幅度减半则是  $-6$  dB，对应功率变为四分之一。

对常规波束扫描而言，HPBW 可用来估计角分辨率：两个源的间隔小于主瓣宽度时，扫描谱往往难以形成两个清楚峰值。对  $M$  元、等权、等间距 ULA，其离散阵因子给出的宽阵列近似为

$$\text{HPBW} \approx \frac{0.886 \lambda}{Md \cos \theta_0} \text{ rad.} \quad (2-3)$$

可跳过：系数 0.886 从哪里来：均匀线阵的归一化阵因子是 Dirichlet 核  $\frac{\sin(M\psi/2)}{M \sin(\psi/2)}$  (§ 5.2 的等比数列求和结果)，其中  $\psi = 2\pi d(\sin \theta - \sin \theta_0)/\lambda$ 。半功率点要求幅度  $= 1/\sqrt{2}$ ，即  $|\sin(M\psi/2)/(M\psi/2)| \approx 1/\sqrt{2}$ （大  $M$  时分母  $\sin(\psi/2) \approx \psi/2$ ）。

解  $\sin x/x = 1/\sqrt{2}$  得  $x \approx 1.3916$  ( $x = M\psi/2$ )，于是单边  $\psi_{3dB} = 2 \times 1.3916/M = 2.7832/M$ ；双边宽度换算到  $\sin \theta$  域再除以  $\cos \theta_0$  ( $d \sin \theta$  微分带来  $1/\cos \theta_0$ )，得  $\text{HPBW} = 2 \times 1.3916/(\pi) \times \lambda/(Md \cos \theta_0)$ ，而  $2 \times 1.3916/\pi = 0.8859 \approx 0.886$ 。

系数 0.886 来自方程  $\sin x/x = 1/\sqrt{2}$  的解。分母中的  $Md$  是离散阵因子近似产生的尺度，物理首末阵元跨度仍为  $D_{\text{phys}} = (M-1)d$ 。当  $M$  较大时两者接近； $\lambda/D_{\text{phys}}$  可用于孔径量级判断，但不是上述离散 ULA 公式的精确替换。

读法：阵列的电尺寸越大、频率越高（波长越短），主瓣越窄；转向接近端射时， $\cos \theta_0$  变小，主瓣变宽。

该式还用了主瓣附近的小角近似，因此主瓣很宽或转向接近端射时，应直接计算阵因子，而不是把公式外推到几百度。若只知道小阵列的物理跨度  $D_{\text{phys}} = 7$  cm，用  $\lambda/D_{\text{phys}}$  可看出：1 kHz 时比整个可视范围还宽，8 kHz 时进入几十度量级。这只是孔径尺度判断。

图7(a) 的条件是 8 麦、 $d = \lambda/2$ 、指向  $30^\circ$ 。代入离散 ULA 公式得  $0.886/(8 \times 0.5 \times \cos 30^\circ) \approx 0.256 \text{ rad} \approx 14.7^\circ$ ，与图中约  $14.8^\circ$  一致。

孔径尺度的明细： $0.886 \times 0.343/0.07 \approx 4.34 \text{ rad}$ 。这个量已超过线阵的  $180^\circ$  可视范围，说明窄主瓣近似不适用；正确结论是“该物理孔径在 1 kHz 几乎没有方向选择能力”，而不是把  $249^\circ$  当成可测的 HPBW。

### 2.6.2 旁瓣电平：其他方向漏进多少

旁瓣电平（Side Lobe Level, SLL）是最高可见旁瓣相对主瓣的电平。均匀加权的延迟求和波束形成器（Delay-and-Sum Beamformer, DSB, 详见 § 5.2）在阵元数较多、可见角域包含第一旁瓣时，最高旁瓣趋近  $-13.26 \text{ dB}$ ，对应功率比约  $10^{-13.26/10} \approx 0.047$ 。

定向干扰位于旁瓣方向时仍会进入输出。加窗权重（例如汉明权重）可降低旁瓣，代价是主瓣变宽；MVDR 可根据噪声协方差在干扰方向自适应形成零陷（§ 5.4）。

阵元数和转向范围会改变实际 SLL。图 7 (a) 的 8 麦半波线阵指向  $30^\circ$ ，精确离散阵因子在可见角域的最高旁瓣约为  $-12.8 \text{ dB}$ 。若改成 4 麦半波线阵并指向正横，最高可见旁瓣约为  $-11.3 \text{ dB}$ ；同样正横指向的 2 麦半波线阵在可见角域没有旁瓣，也就不能给它套一个  $-13 \text{ dB}$  的 SLL。

可跳过： $-13.26 \text{ dB}$  与 4 麦结果从哪里来：阵元数较多时，均匀加权阵因子在主瓣及第一旁瓣附近近似为  $\sin x/x$ 。第一个旁瓣的极值位置约  $x = 4.4934$ （满足  $\tan x = x$ ），幅度比  $|\sin x/x| \approx 0.2172$ ，所以电平趋近  $20 \log_{10} 0.2172 \approx -13.26 \text{ dB}$ 。

4 麦正横指向、间距  $d = \lambda/2$  时，令  $u = \sin \theta$ ，精确阵因子的幅度为  $|\cos(\pi u/2) \cos(\pi u)|$ 。第一旁瓣位于  $1/2 < |u| < 1$ ；设  $z = \cos(\pi|u|/2)$ ，幅度变为  $z(1 - 2z^2)$ ，在  $z = 1/\sqrt{6}$  处取最大值  $2/(3\sqrt{6}) \approx 0.2722$ 。因此实际 SLL 为  $20 \log_{10}[2/(3\sqrt{6})] \approx -11.30 \text{ dB}$ 。这个有限阵元结果不能用大阵元数近似替代。

直觉上，等权矩形窗的傅里叶变换是 sinc，旁瓣是 sinc 振铃的第一个波峰，高度由 sinc 包络  $1/x$  决定。加窗（汉明等）相当于把矩形边沿削薄，振铃随之降低。

### 2.6.3 指向性指数：弥散场中的目标方向优势

充分弥散的晚期混响常近似为从各方向入射的声场；实际风噪通常由局部湍流激发，不能无条件按弥散场处理。指向性指数（Directivity Index, DI）表示在指定的各向同性弥散场模型下，波束对目标方向的信噪比改善。它由主瓣方向增益的平方除以全空间平均增益的平方，再取对数：

$$\text{DI} = 10 \log_{10} \frac{4\pi |B(\Omega_0)|^2}{\int_{4\pi} |B(\Omega)|^2 d\Omega}。 \quad (2-4)$$

$\Omega = (\theta, \phi)$  表示三维方向， $B(\Omega)$  是该方向上的复响应， $\Omega_0$  是目标方向； $d\Omega$  是立体角微元，整个球面的立体角为  $4\pi$ 。分母对波束图在整个球面上积分，表示弥散场中各方向输入的总贡献。只有波束图轴对称时，才能把  $B(\Omega)$  简写为单角变量。

DI = 0 dB 表示所选目标方向的功率响应等于全空间平均功率响应。全向波束满足这一条件，但非全向波束在某个方向也可能满足它，所以仅凭一个 DI 数字不能判断整个波束图是否平坦。对固定的目标方向，DI 越大，表示该方向相对弥散场平均响应的增益越大。超指向波束形成 (§ 5.3) 的目标之一就是提高这一指标。

#### 2.6.4 白噪声增益：独立通道底噪怎样进入输出

每个麦克风自己有底噪（热噪声），各通道互相独立。白噪声增益（White Noise Gain, WNG）衡量目标响应相对独立通道底噪的增益：

$$\text{WNG} = 10 \log_{10} \frac{|\vec{w}^H \vec{a}(\theta)|^2}{\|\vec{w}\|^2} \quad (2-5)$$

分子是目标方向的增益平方，分母是权重自身的能量。无失真约束下，WNG 为负表示输出白噪声功率高于单通道参考。

超指向设计在低频可能产生较大的正负权重，使通道增益、相位和位置失配显著改变主瓣或零陷。单位幅度导向矢量下的 WNG 上限是  $10 \log_{10} M$ ，DSB 达到该上限 (§ 5.2)。

DI 与 WNG 的定义及其在阵列设计中的用法可参见 [Brandstein 与 Ward 编《Microphone Arrays》](#)，第 2 章，2001。引用这些指标时仍须说明声场模型、导向归一化和积分范围。

DI 与 WNG 需要联合检查（详见 § 5.3、图 15）：在固定紧凑阵列上，超指向设计为提高弥散场 DI 往往会增大权重范数并降低 WNG，但变化幅度取决于频率、几何、对角加载和失配。不能只按其中一个指标选择权重。

#### 2.6.5 分辨率尺度与空间混叠

HPBW 的量级约为  $\lambda/D$ ，因此它常被用作常规波束扫描能否分开两个近邻源的经验尺度。

这不是所有估计器都不能越过的普适物理边界。MUSIC 等子空间方法在模型正确、信噪比和快拍数足够时可以得到窄于常规主瓣的谱峰，所以称为超分辨（super-resolution）；代价是对源相关性、阵列失配和有限样本更敏感。

**空间混叠（栅瓣）：**相邻麦间距超过半波长后，不同方向可能产生相同的离散空间相位。图 7 (b) 中，8 麦阵列指向  $60^\circ$ ，间距从  $\lambda/2$  增至  $\lambda$  后， $-7.7^\circ$  出现与主瓣等高的栅瓣，因而无法仅凭该频点区分两个方向。

这个  $-7.7^\circ$  可以手算验证：栅瓣条件  $\sin \theta - \sin \theta_0 = \pm \lambda/d$ ，取  $d = \lambda$ 、 $\theta_0 = 60^\circ$ ，得  $\sin \theta = \sin 60^\circ - 1 = 0.8660 - 1 = -0.1340$ ， $\theta = \arcsin(-0.1340) \approx -7.7^\circ$ 。这个结果与图7(b) 标注一致。

对麦距为 2~4 cm 的阵列，按上述半波长条件换算，无混叠带宽约为 4.3~8.6 kHz：

$$c/(2d) = 343/(2 \times 0.04) \approx 4.3 \text{ kHz}, \quad 343/(2 \times 0.02) \approx 8.6 \text{ kHz}.$$

这与时间域奈奎斯特采样具有相似结构：时间采样要求  $f_s \geq 2f_{max}$  以避免频谱混叠；工程上常用  $d \leq \lambda/2$  作为均匀线阵的全视场安全线。

若把可视角写成闭区间  $[-90^\circ, 90^\circ]$ ，等号处仍有一个端点退化： $+90^\circ$  与  $-90^\circ$  的相邻相位分别为  $+\pi$  与  $-\pi$ ，两者相差  $2\pi$ ，无法仅凭该频点区分。要求闭区间内严格一一对应时应取  $d < \lambda/2$ 。

为什么  $d \leq \lambda/2$  是安全线（三步推导）：

1. 相邻两麦对来自  $\theta$  方向的平面波，相位差为  $\psi = 2\pi d \sin \theta / \lambda$ （正横方向起算）；
2. 相位以  $2\pi$  为周期，因此  $\psi$  与  $\psi + 2\pi$  不可区分。当  $\frac{2\pi d}{\lambda}(\sin \theta - \sin \theta_0) = 2\pi$ ，即  $\sin \theta - \sin \theta_0 = \frac{\lambda}{d}$  时，另一个方向与指向方向产生相同的阵元相位序列，波束图上出现等高栅瓣；
3.  $\sin$  的取值范围是  $[-1, 1]$ ，所以  $|\sin \theta - \sin \theta_0| \leq 2$ 。当  $d < \lambda/2$  时， $\lambda/d > 2$ ，上式在可见范围内无解。反之， $d > \lambda/2$  只表示不再保证全视场无栅瓣；某个特定转向是否出现可见等高栅瓣，还要检查上式是否有可见解。

等号边界可直接代入核对： $d = \lambda/2$ 、 $\theta = +90^\circ$  与  $\theta_0 = -90^\circ$  时， $\sin \theta - \sin \theta_0 = 2 = \lambda/d$ 。因此“半波长安全线”包含端射两端重合这一边界例外。

## 2.6.6 精度理论下界：克拉美 – 罗界

这一部分的统计内容较重，第一遍可以跳过，在第 4 章需要分析定位精度时再读。克拉美 – 罗界（Cramér – Rao Bound, CRB）是在给定观测模型和正则条件下，对无偏波达方向（Direction of Arrival, DOA）估计器方差的下界。

下面的显式式子采用单源、窄带、确定性信号模型。每个快拍的未知复幅度作为干扰参数；阵列是  $M$  元均匀线阵（Uniform Linear Array, ULA）、间距为  $d$ ；共有  $T$  个独立快拍；噪声为各阵元方差均为  $\sigma^2$  的圆对称复白高斯噪声。

这里的单阵元线性 SNR 定义为  $\text{SNR} = \sum_{t=1}^T |s_t|^2 / (T\sigma^2)$ 。在这些约定下可得到下式。改变复/实噪声、已知/未知幅度或 SNR 定义会改变常数，推导口径见 [Stoica 与 Nehorai 1989](#)：

$$\text{CRB}(\theta) = \frac{6}{T \cdot \text{SNR} \cdot M(M^2 - 1) \cdot \left(\frac{2\pi d}{\lambda}\right)^2 \cos^2 \theta} \quad (\text{rad}^2)。 \quad (2-6)$$

误差方差与 SNR、快拍数和阵元位置的二阶矩成反比，并在端射方向 ( $\cos \theta \rightarrow 0$ ) 发散。

- 固定间距  $d$  并增加阵元时， $M(M^2 - 1)d^2$  约按  $M^3 d^2$  增长。
- 固定物理孔径  $D = (M - 1)d$  时，同一项可写成  $M(M + 1)D^2 / (M - 1)$ ，约按  $MD^2$  增长，不能仍称为  $M^3$  标度。

公式里的  $M(M^2 - 1)$  来自各麦位置绕阵列中心的二阶矩  $\sum_m (m - \frac{M-1}{2})^2 = \frac{M(M^2-1)}{12}$ 。

### 2.6.7 算例 2-1：复算 CRB 的五个因子

阵列配置——6 麦、间距 1.4 cm、孔径 7 cm；正横方向、 $f = 1$  kHz、 $T = 100$  快拍。

在上述模型内，任何满足正则条件的无偏估计器，其方差都不低于该 CRB。它不直接约束有偏估计器的均方误差，也不能脱离模型解释成所有算法的绝对极限。

本例取正横方向（ $\theta = 0^\circ$ ，即  $\cos \theta = 1$ ）、 $\lambda = 0.343$  m。SNR 要换成线性值再代入：SNR = 10 dB 对应 10，0 dB 对应 1。代入上式：

$$\text{CRB} = \frac{6}{100 \times 10 \times 6 \times 35 \times (2\pi \times 0.014/0.343)^2 \times 1} \approx 4.3 \times 10^{-4} \text{ rad}^2.$$

CRB 分母五个因子： $T = 100$ （快拍数）；SNR = 10（10 dB 的线性值）； $M(M^2 - 1) = 6 \times 35 = 210$ （麦克风位置方差项）； $(2\pi d/\lambda)^2 \approx 0.0658$ （电尺寸项）； $\cos^2 \theta = 1$ （正横方向）。分母乘积约为 13800，因此  $6/13800 \approx 4.3 \times 10^{-4} \text{ rad}^2$ 。改变阵列或频率时，应重新计算这五项。

开方得标准差  $\approx 0.021 \text{ rad} \approx 1.2^\circ$ ；SNR 降到 0 dB（线性值 1）时，标准差约为  $3.8^\circ$ 。

阵列的物理跨度为  $(M - 1)d = 5 \times 1.4 \text{ cm} = 7 \text{ cm}$ ；CRB 里的  $M(M^2 - 1)d^2$  则来自全部阵元位置的二阶矩，不能用一个 HPBW 孔径项代替。

这组数只说明：在本例的窄带、无偏估计和白噪声模型内，低信噪比会显著抬高方差下界。实际误差还受混响、失配、源相关性和估计器偏差影响。

### 2.6.8 算例 2-2：同一阵列的 DI 与 WNG

本例采用 4 元半波线阵，核对两项指标在这一频点为何都约为 6 dB。

阵列配置——4 麦、间距  $\lambda/2$ 、孔径  $1.5\lambda$ ；延迟求和（DSB，Delay-and-Sum Beamforming）指向正横。

这个例子用同一组权重比较 WNG 与 DI：

- WNG：DSB 恰好达到上限（§ 5.2 有证明）， $\text{WNG} = 10 \log_{10} M = 10 \log_{10} 4 \approx 6 \text{ dB}$ ；
- DI：把 DSB 波束图按定义式在整个球面上数值积分，得  $\text{DI} \approx 6 \text{ dB}$ ，这里采用 3D 各向同性弥散场口径。



对  $\lambda/2$  间距的线阵，DI 与 WNG 的数值恰好相等。相距  $q$  个阵元间隔的两麦，其弥散场相干系数为  $\text{sinc}(q\pi)$ ；整数  $q \neq 0$  时为 0，所以该频点的弥散噪声空间二阶矩与等功率白噪声成同比例。这里比较的是二阶空间统计量，不是声场的所有统计性质。

口径注：此处  $\text{sinc}$  取  $\sin x/x$  定义；§ 5.1 用归一化定义  $\sin(\pi x)/(\pi x)$ ，相邻麦的同一物理量在该口径下写作  $\text{sinc}(1) = 0$ 。两种写法只差自变量里的  $\pi$ ，对照时应先换算。

量级结论：在本例的半波间距、空间白噪声近似下，4 元 DSB 的 WNG 和 DI 都是 6 dB。若针对某个弥散噪声模型提高 DI，权重通常会变得更敏感，WNG 可能下降；具体上限取决于阵列几何、频率、噪声相关矩阵和稳健性约束，不能只由麦克风数给出。

上述度量基于远场平面波模型。声源进入近场后，导向模型、搜索空间和定位参数都要加入距离维度。

## 2.7 小结：声源走近了，平面波不够用——近场要换的三样东西

远场模型把波前当平面，只剩方向一个未知数；声源走近后波前弯成球面，到达各麦的距离本身也携带信息。本小节把近场需要换掉的三样东西一次列清。

### ① 球面导向矢量

远场导向矢量的第  $m$  个分量只有相对相位旋转  $e^{-j2\pi f\tau_{m1}(\theta)}$ ，幅度视为相同。近场要写成球面波形式：声源在位置  $\vec{p}$  时，第  $m$  个麦克风位于  $\vec{r}_m$ ，它收到的复增益正比于

$$\frac{e^{-j2\pi f\|\vec{p}-\vec{r}_m\|/c}}{\|\vec{p}-\vec{r}_m\|}。$$

与远场相比，近场有两处变化：相位按真实距离  $\|\vec{p}-\vec{r}_m\|$  计算，不再是方向投影  $d\sin\theta$ ；幅度按距离的倒数衰减，各麦幅度不再相等。以麦 1 归一化后得到近场导向矢量  $\vec{a}(\vec{p})$ ，其自变量从方向  $\theta$  变成位置  $\vec{p}$ ，定位输出也由角度扩展为角度和距离。

### ② 距离估计从哪里来

球面弯曲在阵列边缘相对中心造成的额外路程约为  $D^2/(8r)$ （§ 2.2 第 2 步），它同时改变相位曲率与幅度差。声源越近，波前越弯，边缘麦相对平面波预测的相位偏差越大；拟合这部分曲率可以估计距离  $r$ 。

距离是否可观测取决于  $D^2/(r\lambda)$ 、信噪比、带宽、麦数和几何形态。孔径很小或声源很远时，球面模型与平面模型几乎不可区分，此时距离估计会很不稳定。距离误差用米、角度误差用弧度，不能用“相差一个量级”直接比较。

### ③ 何时换球面模型

对中心对称孔径，Fraunhofer 距离  $r_F = 2D^2/\lambda$ ；一般应从选定参考点到最远阵元的距离  $a$  出发，用  $r_F = 8a^2/\lambda$  作相位曲率的起始检查。它不是跨过就立即从近场变为远场的物理分界。

使用平面波模型前，还要满足推导里的  $r \gg a$ ，并核对幅度差和允许的相位误差。条件不满足时，改用球面导向  $\vec{a}(\vec{p})$ ，SRP 搜索网格也从角度一维扩展为位置二维或三维（§ 4.3 的  $\tau_{ij}(\vec{r})$  已按距离差写出）。

7 cm 中心对称阵列在 1 kHz 下有  $r_F \approx 2.9$  cm，该数只表示相位曲率尺度，不能单独支持“整个房间都是远场”。1.26 m 中心对称线阵在同频率下有  $r_F \approx 9.3$  m，会议室内常需要球面波模型。频率越高、波长越短， $r_F$  越大；宽带系统应在目标频带内逐频检查建模误差。

本章从传播时延建立了远近场模型，并定义了 STFT、快拍、协方差及四项阵列度量。第 3 章将讨论麦克风几何如何限制这些观测与指标。

## 本章练习

1. STFT 分帧换算：采样率 8 kHz、窗长 32 ms、帧移 8 ms，求窗长采样点数、帧移采样点数、重叠率和 1 s 语音的帧数。

参考答案：窗长  $8000 \times 0.032 = 256$  点；帧移  $8000 \times 0.008 = 64$  点；重叠率  $(256 - 64)/256 = 75\%$ ；不补信号端点、只取完整窗时，帧数  $\lfloor (8000 - 256)/64 \rfloor + 1 = 122$ 。采用同一端点策略且采样点数恰好对应这些时间值时，帧数与 16 kHz 情形相同。

口径注：另取 FFT 点数等于窗长点数，即 256 点窗做 256 点 FFT。若同一帧补零到 512 点，单边频点数从 129 增为 257，网格间隔从 31.25 Hz 减为 15.625 Hz；观测窗没有变长，分开相邻谱线的能力并不因此提高。端点补零对帧数的影响见 E02-01。

2. 协方差读数：2 麦在某频点上信号完全相干（互相关系数幅值为 1、相位差  $30^\circ$ ），各麦总功率都是 2，写出  $2 \times 2$  协方差矩阵  $\hat{\mathbf{R}}$ 。

参考答案： $\hat{\mathbf{R}} = \begin{bmatrix} 2 & 2e^{j\pi/6} \\ 2e^{-j\pi/6} & 2 \end{bmatrix}$ 。对角线是各麦功率，非对角线的模是相干强度，辐角是麦间相位差；矩阵应满足对角元为实数且整体共轭对称。这里约定麦 1 相位超前  $30^\circ$ ；若采用相反的通道顺序，非对角元的相位符号也相反。

3. CRB 估算：阵列配置沿用算例 2-1（6 麦、间距 1.4 cm、孔径 7 cm）与 100 快拍，若 SNR 从 10 dB 提到 20 dB（线性值从 10 到 100），角度标准差从约  $1.2^\circ$  变成多少？再想想：快拍数翻 10 倍与 SNR 提 10 dB，哪个更划算？

参考答案：方差与 SNR 成反比，标准差缩小  $\sqrt{10} \approx 3.16$  倍，约为  $1.2^\circ/3.16 \approx 0.38^\circ$ 。在该模型里，独立快拍数与 SNR 成乘积关系，两种变化对下界的影响相同。增加观测时间不需要提高单帧 SNR，却会增加等待时间；声源移动或统计量变化时，也不能把更多帧当作同一方向的独立快拍。因此要按延迟预算和场景平稳性选择，而不能断言增加快拍总是更合算。

以下六题的复算入口为 [exercises\\_spatial.py](#)，结果采用稳定标识 E02-01~E02-06。

E02-01：同一段录音为什么有两种帧数？对 8 kHz、1 s 的信号，取窗长 256 点、帧移 64 点，分别使用 `center=False` 和 `center=True`。再对其中同一个 256 点窗做 256 点与 512 点实 FFT。哪些输出数量改变，哪些物理信息没有增加？

参考答案：不居中时为  $(8000 - 256)/64 + 1 = 122$  帧。居中时两端各补 128 点，为  $(8256 - 256)/64 + 1 = 126$  帧。两种 FFT 的单边频点数分别是  $256/2 + 1 = 129$  和  $512/2 + 1 = 257$ 。FFT 补零改变网格密度，不增加观测时长；端点补零增加的帧也不是新录到的独立声音。

E02-02：用复数协方差检查通道顺序。各路功率为 2，麦 1 相位超前麦 2 为  $30^\circ$ 。构造两帧  $\vec{x}$  和  $-\vec{x}$ ，使样本均值为零，计算二阶矩、特征值和交换通道后的非对角相位。

参考答案：可取  $\vec{x} = \sqrt{2}[e^{j\pi/6}, 1]^\top$ 。两帧的外积相同，因此平均后  $R_{11} = R_{22} = 2$ ， $R_{12} = 2e^{j\pi/6} = \sqrt{3} + j$ ， $R_{21} = R_{12}^*$ 。行列式为  $4 - |R_{12}|^2 = 0$ ，迹为 4，特征值为 0 和 4。

交换通道后  $R_{12}$  变为  $\sqrt{3} - j$ ，相位由  $+30^\circ$  变成  $-30^\circ$ 。这不是另一个声源方向，而是坐标与通道顺序变化；不能交换音频而不交换麦克风坐标。

E02-03：窗重叠足够，为什么首点仍可能无法恢复？用固定种子 20260922 生成 8 kHz、1 s 的零均值高斯样本，周期 Hann 窗长 256 点、帧移 64 点，完成 STFT/iSTFT 往返。比较居中与不居中两种边界处理。

参考答案：居中并保留原长度时，双精度实现的最大绝对重建误差应小于  $10^{-12}$ 。不居中时，第一点只被 Hann 窗的零端点覆盖，合成分母为零，本书实现会拒绝输出而不是把错误样本补成零。

需要检查的是每个保留样本的窗平方和是否非零，不能只看“重叠了 75%”。SciPy 的 [NOLA 条件说明](#)给出这一归一化分母。这个实验只验证分析与合成的一致性，不证明修改过频谱后仍无失真，也不代表居中处理适合零前瞻实时系统。

E02-04：掩码总和非零，协方差就可逆吗？两通道的三帧快拍为  $[1, 0]^\top$ 、 $[0, 1]^\top$ 、 $[1, 1]^\top$ 。按  $\sum_t q_t \vec{x}_t \vec{x}_t^H / \sum_t q_t$  计算加权二阶矩，分别取掩码  $[1, 0, 1]$  和  $[1, 0, 0]$ 。再将第一组权重全部乘 2，结果是否改变？

参考答案：第一组保留首、末两帧，外积相加再除以 2，得到

$$\mathbf{R}_A = \begin{bmatrix} 1 & 1/2 \\ 1/2 & 1/2 \end{bmatrix}, \quad \mathbf{R}_B = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

$\mathbf{R}_A$  的行列式为 1/4、秩为 2； $\mathbf{R}_B$  的行列式为 0、秩为 1。所有权重同时乘 2 时，分子与分母等比放大， $\mathbf{R}_A$  不变。权重集中程度可用本题的辅助量  $L_w = (\sum_t q_t)^2 / \sum_t q_t^2$  比较，两组分别为 2 和 1。

$L_w$  只描述权重分布，不自动等于统计独立的快拍数，也不保证满秩：即使均匀保留很多帧，若它们彼此成比例，协方差仍可能秩一。全零掩码没有可用统计量，本书代码会拒绝计算，而不是仅在分母加一个小数后宣称得到有效协方差。

E02-05：递归协方差启动时为何偏小？固定快拍  $\vec{x} = [1, 2]^\top$ ，从零矩阵开始，使用  $\mathbf{S}_t = 0.5\mathbf{S}_{t-1} + 0.5\vec{x}\vec{x}^H$ 。计算前三步的矩阵和累计权重，再按累计权重归一化。

参考答案：外积为  $\mathbf{Q} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$ 。第一步为  $0.5\mathbf{Q}$ ；第二步为  $(0.5^2 + 0.5)\mathbf{Q} = 0.75\mathbf{Q}$ ；第三步为  $(0.5^3 + 0.5^2 + 0.5)\mathbf{Q} = 0.875\mathbf{Q}$ 。

| 步数 $t$ | 累计权重 $b_t = 1 - 2^{-t}$ | 未归一化矩阵            | $\mathbf{S}_t/b_t$ |
|--------|-------------------------|-------------------|--------------------|
| 1      | 0.500                   | $0.500\mathbf{Q}$ | $\mathbf{Q}$       |
| 2      | 0.750                   | $0.750\mathbf{Q}$ | $\mathbf{Q}$       |
| 3      | 0.875                   | $0.875\mathbf{Q}$ | $\mathbf{Q}$       |

这是零初始化造成的权重总和不足，不是信号功率随时间上升。归一化修正这一尺度，却不会增加独立观测，也不会把本题的秩一矩阵变成可逆矩阵。有跳帧、可变遗忘因子或掩码时，应按实际更新递推累计权重，不能继续照搬  $1 - 2^{-t}$ 。

E02-06：掩码很小，是否意味着没有数据？沿用 E02-04 的三帧  $[1, 0]^\top$ 、 $[0, 1]^\top$ 、 $[1, 1]^\top$ ，令掩码为  $a[1, 0, 1]$ ，分别取  $a = 10^{-200}, 1, 10^{200}$ 。计算归一化二阶矩，并说明为什么全零掩码必须另行处理。

参考答案：对任意  $a > 0$ ，加权外积之和与权重之和分别为

$$\sum_t q_t \vec{x}_t \vec{x}_t^H = a \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}, \quad \sum_t q_t = 2a.$$

相除后，三种尺度都得到

$$\mathbf{R} = \frac{1}{2a} a \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1/2 \\ 1/2 & 1/2 \end{bmatrix}.$$

直接把原始权重和与固定小数比较，会把第一组误判为没有数据；先除以最大权重后，三组掩码都变为  $[1, 0, 1]$ ，再累积即可。


全零掩码无法执行这项归一化，也没有可用观测权重，因此本书代码拒绝计算。共同缩放保持的是这三个既定快拍的加权结果，不会增加独立样本，也不会提高源数估计的可信度。结果与独立手算逐元素比较，双精度绝对误差应小于  $10^{-14}$ 。

[音频实验总览](#)提供已知采样率与通道顺序的 WAV，可用同一分析/合成参数检查边缘重建；比较时保留原长度，不把端点丢失误认为降噪效果。

# 第 3 章 · 阵列几何形态

## 3.1 形态总览

图8 常见麦克风阵列几何形态示意



(a)(b) 平行线为波前，箭头为传播方向；各平面子图只比较几何形态，坐标不代表统一的米制尺度。



图8 画出八种常见形态。(a) (b) 使用完全相同的一条双麦基线，只把目标方向分别放在端射 (endfire) 和正横 (broadside) 两个极限；平行线表示平面波的波前，箭头表示传播方向。这说明“端射/正横”首先描述工作方向相对基线的关系，不是两套不同的双麦硬件。

其余子图依次为均匀线阵 (Uniform Linear Array, ULA)、方阵、均匀圆阵 (Uniform Circular Array, UCA) 加中心麦、按斐波那契球面规则确定性布置的 32 麦近均匀球阵、螺旋阵和分布式非规则阵。

裸露的全向麦克风只有几何位置，不会仅凭排列产生主瓣。(d) 的四只麦虽然也落在同一个圆周上，这里按方阵的平面几何分析。

两种基础双麦摆法（端射与正横是两个典型极限工作方向，中间角度同样有意义）：

- Endfire（前后排列）：配合延时和差分等处理后，目标主轴可沿连线方向，形成前方保留、后方抑制的响应。用于真无线立体声 (True Wireless Stereo, TWS) 耳机、手机；
- Broadside（左右排列）：配合相应波束形成器后，目标主轴可设为垂直于连线，用于笔记本、平板通话降噪。

### 算例 3-1 双麦耳机的差分——1 cm 间距怎么做心形指向

TWS 耳机上的双麦常采用端射 (endfire) 摆法：两个麦前后排列、间距  $d = 1\text{ cm}$ ，主轴沿两麦连线。它构成 § 5.3 所述的一阶差分麦克风阵列 (DMA, Differential Microphone Array)。

若只把两路信号乘实数增益后相减，即  $y = x_1 - g x_2$  ( $g$  为实标量)，无法形成前后不对称的心形幅度响应。前方与后方来声的麦间相位差分别为  $-\Delta\phi$  和  $+\Delta\phi$ ，而  $|1 - g e^{-j\Delta\phi}|$  与  $|1 - g e^{+j\Delta\phi}|$  相等。

前后对称不等于一定是 8 字形。只有等增益相减 ( $g = 1$ )，且麦间距相对波长足够小时，归一化响应才近似 8 字形； $g = 0$  就是单麦全向响应， $g = 0.5$  时正横方向仍保留幅度  $|1 - g| = 0.5$ ，没有 8 字形在该方向的零点。章末 E03-05 可复算这些差别。

要打破这种对称性，需先引入时延再相减：把后路麦的信号延迟  $\tau_0 = d/c$ ，再从前路麦信号中减去：

$$y(t) = x_1(t) - x_2\left(t - \frac{d}{c}\right) \xrightarrow{\mathcal{F}} Y(f) = X_1(f) - e^{-j2\pi f d/c} X_2(f)$$

$\mathcal{F}$  表示傅里叶变换。

其中  $x_1$  是前路麦， $x_2$  是后路麦， $d/c$  是声音传播一个麦间距所需的时间。下面分别计算前方和后方来声的响应。

第 1 步：两麦之间的相位差。本算例用  $\Delta\tau$  表示时差的非负幅值；带符号的  $\tau_{ij} = t_i - t_j$  仍按 § 2.1 定义。声音沿连线方向传来时，两麦时差幅值最大：

$$\Delta\tau = \frac{d}{c} = \frac{0.01}{343} \approx 29.2 \mu s$$

1 kHz 时对应的相位差（时延在频域就是相位旋转，§ 2.3）：

$$\Delta\phi = 2\pi f \Delta\tau = \frac{2\pi \times 1000 \times 0.01}{343} \approx 0.183 \text{ rad} \approx 10.5^\circ$$

第 2 步：后方来声——理想模型下抵消。后方的声音先到后路麦  $x_2$ 、晚  $\Delta\tau$  才到前路麦  $x_1$ ；给  $x_2$  补上的延迟  $\tau_0 = d/c$  正好等于自然时差，两路在减法器中对齐，理想等幅模型给出  $y = 0$ 。有限精度、通道失配和反射会使实际零陷保持有限深度。

第 3 步：前方来声——还剩多少。前方的声音先到  $x_1$ 、晚  $\Delta\tau$  到  $x_2$ ； $x_2$  又被电延迟推后  $\Delta\tau$ ，两路共错开  $2\Delta\tau$ ，即相位差  $2\Delta\phi \approx 21^\circ$ 。两路信号是复平面上两个长度相同、夹角  $21^\circ$  的箭头，相减得到连接两尖端的弦。剩余幅度（两路幅度归一化为 1）：

$$|Y| = |1 - e^{-j2\Delta\phi}| = 2 \sin \Delta\phi \approx 0.3643$$

这里先用未舍入的  $\Delta\phi = 2\pi \times 1000 \times 0.01/343$  计算，最后才舍入幅度。换算成分贝：

$20 \log_{10} 0.3643 \approx -8.8 \text{ dB}$ 。前方保留而后方出现零陷，低频近似下得到心形指向。只要电延迟与几何时差的关系保持不变，低频归一化波束形状随频率变化较小。

第 4 步：计算输出信噪比变化。与单个麦克风相比，前方信号幅度为 0.3643，对应  $-8.8 \text{ dB}$ 。两路独立自噪声相减后功率相加，噪声功率增加约 3 dB，因此输出信噪比降低约  $8.8 + 3 = 11.8 \text{ dB}$ 。这是一阶 DMA 在低频 WNG 较低的原因：间距越小、频率越低， $\Delta\phi$  越小，目标信号在相减中保留得越少。

第 5 步：失配最先伤害哪里。后方零陷靠的是“两路幅度精确相等、相减归零”。若麦 2 的增益是 1.01，后方响应的绝对幅度为  $|1 - 1.01| = 0.01$ ；相对单麦输入是  $20 \log_{10} 0.01 = -40 \text{ dB}$ 。波束图通常将目标方向归一化为 0 dB，这时还要除以失配后的前方响应：

$$|B_{\text{front}}| = |1 - 1.01e^{-j2\Delta\phi}| \approx 0.3663, \quad 20 \log_{10} \frac{0.01}{0.3663} \approx -31.3 \text{ dB}.$$

因此，“约  $-40 \text{ dB}$ ”是以单麦幅度为参考的绝对残差；本算例归一到前方主响应后，零陷约为  $-31 \text{ dB}$ 。两个数的参考量不同，不能混用。增益失配主要限制后方零陷的深度，依赖精确相消的微型差分阵列因此需要通道配对和标定。

端射摆法利用延迟与相减形成前后不对称；正横摆法则把主轴放在麦克风连线的垂直方向。

双麦只有 1 个独立时延观测。在预先限定声源位于某个平面或半空间时，它可以估计一维入射角并形成固定波束；若要在三维空间同时求方位和俯仰，一个时延方程不够，同一时延对应绕阵列轴的一圈方向，形成锥面模糊。增加阵元并改变几何后，覆盖范围、歧义形式和端射灵敏度也会变化。

多麦形态对比：

读表时先分清三个问题：覆盖说明阵列几何能观测哪些方向，优缺点说明同一几何在哪些条件下容易辨向或失效，典型应用只举安装场景，不代表该形态在应用中总是性能最优。表内“可测方位和俯仰”仍以阵列标定、同步和足够的信噪比为前提。

| 形态         | 覆盖                 | 优点                                    | 缺点                                                     | 典型应用              |
|------------|--------------------|---------------------------------------|--------------------------------------------------------|-------------------|
| 均匀线阵（ULA）  | 一维 $\pm 90^\circ$  | 可直接利用平移不变结构；阵元集中在一条轴上，给定阵元数和间距时轴向孔径较大 | 不能由时延单独区分俯仰；靠近端射时 $d\tau/d\theta$ 趋近 0，角度误差被放大；还存在锥面模糊 | Soundbar、会议条      |
| 均匀圆阵（UCA）  | 水平 $360^\circ$     | 水平面基线方向较均衡，适合全方位扫描                    | 有限阵元只有离散旋转对称，波束仍随频率和转向变化；小半径在低频的电尺寸小，俯仰信息也有限           | 智能音箱、桌面会议设备       |
| 方阵/平面阵     | 单侧半空间；若两侧都开放则有镜像歧义 | 方位+俯仰都能测                              | 阵列平面两侧的镜像方向具有相同时延，需挡板或先验消歧                             | 视频会议一体机           |
| 球阵（刚性/开放球） | 全 $4\pi$ 立体角       | 三维覆盖较均匀，可录 3D 声场                      | 成本高、体积大；有限阵元下波束仍随频率和方向变化                               | 机器人听觉头、3D 录音、学术研究 |
| 螺旋阵/对数阵    | 宽频带                | 非均匀间距可打散周期性栅瓣                         | 设计与宽带优化较复杂；自由场导向矢量仍可按已知坐标计算                            | 高品质远场录音           |

| 形态      | 覆盖         | 优点                            | 缺点                                                      | 典型应用         |
|---------|------------|-------------------------------|---------------------------------------------------------|--------------|
| 分布式/随机阵 | 节点跨度可达房间尺度 | 长基线可提高部分方位的几何灵敏度；多位置观测可提供空间分集 | 节点常有独立时钟和不同声学路径；同步、位置标定、通信和缺包误差可能抵消长基线收益，空间分集也不保证抑制所有多径 | 多节点会议室、机器人网络 |

例如，会议设备若只需判断桌面周围的水平  $360^\circ$  方位，可先考虑圆阵；若还要分辨声源在阵列平面上方还是下方，单层圆阵的纯时延观测存在镜像歧义，应增加非共面阵元、挡板信息或场景先验。

跨房间多设备协同是另一类任务：长基线可能改善几何灵敏度，但必须先把跨设备时钟偏移和位置误差纳入预算。这些例子用任务条件筛选结构，并非表中形态的性能排名。

*MUSIC* 是多重信号分类 (*Multiple Signal Classification*)，*ESPRIT* 是借助旋转不变技术估计信号参数 (*Estimation of Signal Parameters via Rotational Invariance Techniques*)；本章只指出其几何前提，算法见 § 4.6。

读表时要区分两种几何歧义。线阵只有沿阵列轴的位置投影信息，因此同一组时延对应以阵列轴为轴的锥面；把麦继续加在同一直线上，能提高阵列增益和估计精度，却不能消除这类锥面模糊。非共线的平面阵能同时估计两个方向余弦，但若阵列两侧都开放，平面法向两侧的镜像方向仍可能产生相同时延，需要挡板、幅度模型或半空间先验消歧。

端射分辨率下降是另一类问题。若用  $\Delta\tau = d \sin \theta / c$  表示时差幅值随角度的局部关系，则  $\theta \rightarrow \pm 90^\circ$  时导数趋近于零，同样的时延误差会对应更大的角度区间；这与 § 2.6 CRB 中  $\cos \theta \rightarrow 0$  时下界发散一致。

### 算例 3-2 端射灵敏度——同一个 $10\ \mu\text{s}$ 误差在不同方向的影响

§ 3.1 所述端射附近灵敏度下降，根源是时延与角度的关系  $\Delta\tau = \frac{d}{c} \sin \theta$  ( $\theta$  从正横方向起算， $d$  为麦间距)。对  $\theta$  求导：

$$\frac{d\Delta\tau}{d\theta} = \frac{d}{c} \cos \theta \quad \Rightarrow \quad d\theta \approx \frac{c}{d \cos \theta} d\Delta\tau$$

即：同样的时延误差  $d\Delta\tau$ ，换算成角度误差时要除以  $\cos \theta$ 。

取  $d = 4\ \text{cm}$  的线阵（与 § 4.4 的例子一致）、时延误差  $d\Delta\tau = 10\ \mu\text{s}$ （16 kHz 采样下不到 1/5 个采样点，是很容易残留的误差量级），算两个方向。

正横方向 ( $\theta = 0^\circ$ ) :  $\cos 0^\circ = 1$ ,

$$d\theta = \frac{343 \times 10 \times 10^{-6}}{0.04 \times 1} \approx 0.0858 \text{ rad} \approx 4.9^\circ$$

10  $\mu\text{s}$  误差对应约  $5^\circ$  的角度误差。这也复现了 § 4.4 “4 cm 间距下 10  $\mu\text{s}$  误差对应约  $5^\circ$ ” 的结论。

端射附近 ( $\theta = 85^\circ$ ) 不能继续把 10  $\mu\text{s}$  当作“小扰动”。本例最大物理时延是  $d/c \approx 116.6 \mu\text{s}$ ,  $85^\circ$  对应  $\tau \approx 116.2 \mu\text{s}$ 。若估计值增加 10  $\mu\text{s}$ , 便超过物理上限, 没有实数角度与之对应, 系统应当判为越界或把结果限制在端射。

若估计值减少 10  $\mu\text{s}$ , 则

$$\hat{\theta} = \arcsin\left(\frac{(116.2 - 10) \times 10^{-6} \times 343}{0.04}\right) \approx 65.6^\circ,$$

误差约  $19.4^\circ$ 。微分式在足够小的误差下仍说明灵敏度按  $1/\cos\theta$  增大, 但不能把  $85^\circ$  处的 10  $\mu\text{s}$  线性外推成  $56^\circ$  并当作精确误差。实际可用角域由允许误差、信噪比、快拍数和几何共同决定, 不存在统一的“端点扣掉  $30^\circ$ ”规则。

端射方向的非线性算例说明, 阵列灵敏度随入射角变化。下面把几何设计中最常用的四条规律集中列出。

## 3.2 四条设计规律

以下四条是筛选阵列形态时的检查顺序, 不是四种互不相关的性能分数。先看孔径与频带, 再看方向覆盖、壳体影响和麦数带来的收益; 两道算例随后展示数量级与近似边界。

### 3.2.1 先看孔径、方向、挡板和麦数

1. 常规波束的分辨率尺度由孔径与波长之比决定 (约  $\lambda/D$ ) : 7 cm 级圆阵在 1 kHz 的这个尺度已经超过线阵的整个可视角域, 方向选择性很弱; 到 4 kHz 才进入几十度量级 (见算例 3-3)。高频虽然能提供更大的电尺寸, 却也更容易遇到空间混叠、传播衰减和阵列失配。设计时必须把这些因素一起考虑。
2. 圆阵与线阵各有适用方向: 线阵在正横附近投影孔径最大, 转向端射时灵敏度下降; 圆阵在水平面各方位的几何更均衡。球阵还可提供俯仰信息。哪一种识别率更高, 取决于尺寸、挡板、房间、算法和评测方向分布, 不能只按阵形下结论。Kumatani – McDonough – Raj  
《Microphone Array Processing for Distant Speech Recognition》CMU 课程讲义,  
2012



3. 挡板效应必须纳入导向模型：麦克风装在刚性圆柱或球体上时，绕射和散射会改变跨通道的幅相响应。某些频段和方向上，它能增加可辨的幅相差；另一些位置也可能出现阴影或共振。因此应使用相应的解析散射模型或实测阵列流形，不能把挡板一概等效为固定倍数的“虚拟孔径”。
4. 麦克风数量没有通用最优值：增加麦克风通常能提高统计稳定性和可控自由度，但收益取决于是否同时增加孔径、噪声相关性、带宽、算法和计算预算。对独立等功率自噪声，理想 DSB 的 WNG 为  $10\log_{10} M$ ，麦数翻倍增加约 3 dB；这只是特定噪声模型下的基准，不能单独决定产品所需的麦克风数量。

### 3.2.2 算例 3-3：6 麦圆环的数字

考虑一个用于教学的 6 麦均匀圆环，环径取 7.5 cm，即半径  $r = 3.75$  cm。这个尺寸只用于展示计算方法，不对应某一款产品；声速取  $c = 343$  m/s。

第 1 步：相邻麦距。6 个麦均匀分布在圆周上，相邻两麦的连线是正六边形的一条边。相邻麦距

$$d = 2r \sin \frac{\pi}{6} = 2 \times 0.0375 \times 0.5 = 0.0375 \text{ m} = 3.75 \text{ cm}$$

正六边形的边长恰好等于半径——这是 6 麦圆环特有的整齐性质。

第 2 步：相邻间距的保守检查。对均匀线阵，常用的半波长安全线是  $d \leq \lambda/2$ ；若把两端射方向也纳入闭区间，等号仍有一对歧义（§ 2.6）。圆阵不是一条周期均匀线阵；此处只用相邻弦长做保守检查，先给出容易复算的频率尺度，再核对完整圆阵的导向矢量。代入：

$$f_{\text{check}} = \frac{c}{2d} = \frac{343}{2 \times 0.0375} \approx 4573 \text{ Hz} \approx 4.6 \text{ kHz}$$

因此，按相邻间距的半波长充分条件，约 4.6 kHz 以下可通过这一保守检查。16 kHz 采样时，4.6 ~ 8 kHz 频段不再由这条条件保证；这不表示 4.6 kHz 是圆阵的精确混叠截止频率。

对本例这种理想规则六边形、窄带平面波阵列，更精确的无歧义分析需要比较完整的六维导向矢量，而不能只看一对相邻麦。Tucker、Zhao、Ahmad 与 Potter 的原始研究，*Alias-Free Arrays*, IEEE Signal Processing Letters 2022, § V-B 给出规则六边形在完整单侧方向域上的临界相邻间距  $d = \lambda/\sqrt{3} \approx 0.577\lambda$ 。本例  $d = 3.75$  cm，对应频率  $f = c/(\sqrt{3}d) \approx 5.28$  kHz；临界点存在相位歧义，该值讨论的是理想相位流形的歧义边界，不能据此保证有噪声、混响和通道失配时仍能准确定位。

阵列平面上下两侧的镜像时延歧义与上述单侧方向域内的窄带相位混叠是不同问题，即使频率低于 4.6 kHz 也仍可能存在。



可选措施包括降低高频子带权重、采用非均匀间距以减弱周期性歧义，以及定位时主要使用无混叠频段、增强时再利用高频信息。

第 3 步：波长与孔径的比。阵列孔径（阵列的最大尺寸） $D = 2r = 7.5 \text{ cm}$ 。

- 1 kHz: 波长  $\lambda = c/f = 343/1000 = 0.343 \text{ m} = 34.3 \text{ cm}$ ，孔径比  $D/\lambda = 0.075/0.343 \approx 0.22$ ——整个阵列只有约五分之一波长大小；
- 4 kHz:  $\lambda = 343/4000 \approx 0.0858 \text{ m} = 8.6 \text{ cm}$ ， $D/\lambda = 0.075/0.0858 \approx 0.87$ ——孔径接近一个波长。

第 4 步：常规波束的角宽量级。用  $\lambda/D$ （弧度，§ 2.6）做孔径尺度估计：

- 1 kHz:  $\lambda/D \approx 0.343/0.075 \approx 4.6 \text{ rad} \approx 262^\circ$ 。这个尺度超过线阵从  $-90^\circ$  到  $+90^\circ$  的  $180^\circ$  可视角域；对圆阵则不能把借自连续孔径的一维角宽直接与  $360^\circ$  方位周期作严格比较。它仍清楚表明：1 kHz 下这只 7.5 cm 的环电尺寸很小，常规波束的方向选择性很弱；
- 4 kHz:  $\lambda/D \approx 1.14 \text{ rad} \approx 66^\circ$ ，对应主瓣宽度量级  $\approx 0.886\lambda/D \approx 58^\circ$ （借用线阵公式估量级，圆阵精确系数不同）——进入「几十度」的量级，总算能分出「大概在哪一边」。

结论：4 kHz 时阵列的电尺寸接近 1，常规波束已可能呈现几十度量级的方向选择性；1 kHz 时电尺寸只有约 0.22，常规波束很宽。子空间估计或学习方法能在合适条件下利用微弱的跨通道差异，但不会凭空增加观测信息；低信噪比、强混响或模型失配时，低频方向仍难估。

### 3.2.3 算例 3-4: ULA 主瓣宽度计算

取一条 4 麦 ULA（等间距直线排列的阵列），间距  $d = 3 \text{ cm}$ ，指向正横。首末阵元的物理跨度为  $(M-1)d = 9 \text{ cm}$ ；§ 2.6 从离散阵因子推得的窄主瓣近似则是

$$\text{HPBW} \approx \frac{0.886 \lambda}{Md} \text{ rad}$$

这里的  $Md = 12 \text{ cm}$  来自 Dirichlet 核的近似尺度，不等于物理跨度。对小阵列要保留这个区别；该式是式(2-3)在正横方向  $\cos \theta_0 = 1$  的形式。

1 kHz: 波长  $\lambda = 343/1000 = 0.343 \text{ m}$ 。若强行代入窄主瓣近似，会得到

$0.886 \times 0.343/0.12 \approx 2.53 \text{ rad}$ ，但这个数不是该阵列的 HPBW。直接计算精确阵因子：端射处  $\psi = 2\pi d/\lambda \approx 0.550 \text{ rad}$ ，

$$|B(90^\circ)| = \left| \frac{\sin(M\psi/2)}{M \sin(\psi/2)} \right| \approx 0.821,$$

即  $20 \log_{10} 0.821 \approx -1.71 \text{ dB}$ 。从  $-90^\circ$  到  $90^\circ$  都没有降到  $-3 \text{ dB}$ ，所以本例在 1 kHz 下没有可定义的  $-3 \text{ dB}$  主瓣宽度。

8 kHz: 波长  $\lambda = 343/8000 \approx 0.0429$  m,

$$\text{HPBW} \approx \frac{0.886 \times 0.0429}{0.12} \approx 0.317 \text{ rad} \approx 18.1^\circ$$

这两个结果怎么读：1 kHz 下精确阵因子在可视范围内没有  $-3$  dB 交点，只能说明波束方向选择性很弱；不能把近似式给出的  $145^\circ$  当成实际 HPBW。8 kHz 下近似估计约为  $18.1^\circ$ ，主瓣明显收窄。只要几何和转向不变，处在窄主瓣近似的适用区间时，频率减半会使 HPBW 约增大一倍。

图9 麦克风数量增加时的理想增益与处理量  
(公式计算，不给出产品选型排名)




图 9 (a) 在目标精确对齐、各通道噪声独立同方差的条件下，按  $10\log_{10} M$  画出理想 DSB 白噪声增益。(b) 分别按  $M$ 、 $M(M-1)/2$  和  $M^2$  计算输入通道、无序麦对与完整协方差矩阵的元素数量。右图的纵轴采用以 2 为底的对数刻度。这些数量用于说明数据结构怎样随  $M$  增长，不等同于具体实现的运行时间、功耗或价格。

§ 3.3 转向非均匀稀疏阵，说明怎样用差分协同阵扩展虚拟孔径。

### 3.3 稀疏阵列与差分协同阵

#### 3.3.1 协同阵的概念：从麦的位置到麦对的间距

均匀线阵若要在整个可视角域避免栅瓣，阵元间距需不大于半波长（§ 2.6）。在给定麦克风数量下，这一条件限制了物理孔径。

稀疏阵列 (sparse array) 相对于一个明确的密集参考网格, 只启用其中一部分候选位置; “麦克风风少” 或 “位置不均匀” 本身都不足以构成这个定义。常见设计包括非均匀的嵌套阵、互质阵和删减阵, 也可能保留等间距但存在空位。利用麦克风对的位置差, 可以构造比物理阵元集合更长的虚拟阵列。

核心概念: 差分协同阵 (difference co-array)。理想远场窄带模型下, 协方差矩阵第  $i, j$  个元素的相位由麦  $i$  与麦  $j$  的位置差决定。收集所有麦对的位置差, 就得到差分协同阵。

6 麦均匀线阵的位置是  $\{0, 1, 2, 3, 4, 5\}$  (单位  $\lambda/2$ ), 不同的有符号滞后是  $\{0, \pm 1, \dots, \pm 5\}$ , 共 11 个。6 麦嵌套阵  $\{0, 1, 2, 3, 7, 11\}$  可得到  $\{0, \pm 1, \dots, \pm 11\}$ , 共 23 个连续滞后 (图10)。

这 23 个数是连续的有符号差分滞后, 不是 23 路彼此独立的物理快拍。若按滞后平均、构造 Toeplitz 虚拟协方差并做空间平滑, 可得到比物理阵更长的虚拟 ULA。

在模型和秩条件满足时, 部分协同阵方法可能估计多于物理麦数的非相干源。可分辨源数仍取决于连续单侧滞后长度、重构方法、平滑后的矩阵维数、信噪比和快拍数, 不能直接等同于 23。

差分集合只给出虚拟阵列的位置。要把这些位置用于子空间估计, 还需要从协方差中构造相应的二阶统计量。

### 3.3.2 物理协方差怎样给出虚拟滞后

对互不相干的远场源,  $\mathbf{R}$  的第  $i, j$  个元素是各源功率乘相位项  $e^{-j2\pi f(\tau_i - \tau_j)}$  的和, 只依赖两麦位置差。相同位置差的麦对可做平均, 降低估计方差; 不同位置差提供不同滞后。

把协方差元素按滞后重排后, 可把连续的一段滞后解释为虚拟 ULA 的二阶统计量。它不是原始阵列快拍, 因此标准 MUSIC 不能不经处理直接套用。通常还需 Toeplitz 重构、直接协同阵处理或空间平滑, 才能形成满足子空间方法要求的虚拟协方差。

例如, 取物理阵元位置  $\{0, 1, 3\}$  (单位为半波长), 一个正横  $0^\circ$  源和一个  $+30^\circ$  源各有单位功率, 互不相关, 各麦另加功率 0.1 的独立噪声。按 § 2.3 的正相位约定, 第  $m$  个导向分量为  $a_m(\theta) = e^{j\pi p_m \sin \theta}$ 。若有符号滞后定义为  $\ell = p_i - p_j$ , 总体协方差给出

$$r[0] = 2.1, \quad r[1] = 1 + j, \quad r[2] = 0, \quad r[3] = 1 - j, \quad r[-\ell] = r[\ell]^*.$$

这些滞后可排列成位置  $\{0, 1, 2, 3\}$  的  $4 \times 4$  Toeplitz 矩阵  $T_{ij} = r[i - j]$ 。本例的特征值为 0.1, 0.1, 4.1, 4.1, 与两个独立源及正噪声功率一致; 虚拟四阵元并不代表物理系统多录到一路独立波形。逐项重排和一个有限样本反例见本章 E03-07。

相干源、宽带混响、有限快拍和有洞差集都会降低可用秩和自由度。有限样本的滞后平均即使由合法的物理样本协方差出发，也不保证直接填成的 Toeplitz 矩阵半正定；构造可供子空间方法使用的虚拟协方差，需要检查秩与半正定性或采用有此保证的专门平滑构造。[Pal 与 Vaidyanathan 原论文第 IV 节](#)提出的协同阵空间平滑与任意填表并非同一操作。

可以把它理解为重新整理“麦对间距表”：相同间距的观测合并，不同间距按顺序排成一条虚拟标尺。标尺更长，潜在孔径更大；但只有完成统计重构并满足秩条件后，这些滞后才会转化为可用的子空间自由度。

图10 稀疏阵列：6 个物理麦克风对应不同的有符号差分位置（模拟）




图 10 左侧比较均匀、嵌套和互质三种摆法，横轴单位是半波长；右侧枚举所有有序麦对的位置差，得到有符号差分位置（也称有符号滞后）。均匀阵有 11 个连续滞后，图中的嵌套阵有 23 个连续滞后，互质阵覆盖范围更大但中间有空缺。连续滞后数描述虚拟孔径结构，不应直接写成 MUSIC 可分辨的源数。

这种虚拟观测依赖统计重构和秩条件；差分集合中的空缺、宽带信号和混响都会限制可用自由度。

3.3.3 代价与边界：差分空缺、宽带和混响

协同阵使用的是二阶统计量，需要专门的协同阵 MUSIC、Toeplitz 重构、空间平滑或稀疏重构。差分滞后中的洞还会使可用连续虚拟孔径缩短，插值或矩阵补全又会引入额外假设。

嵌套阵与互质阵最初主要在窄带阵列模型下发展，原始方法见 [Pal 与 Vaidyanathan 的嵌套阵论文](#)与 [Vaidyanathan 与 Pal 的互质阵论文](#)。

语音宽带、混响和频率相关阵列流形会增加处理难度。因此实际使用前应在目标频带和房间条件下验证，不能只按理论差集长度选型。

稀疏阵与分布式阵不是同一概念。稀疏阵强调只占用密集候选网格中的部分位置，位置可以非均匀，也可以是带空位的等间距子集；分布式阵由多个独立设备组成，除了几何布局，还要处理节点标定、独立时钟和通信。

上述几何分析默认通道和位置准确。实际系统还需要通过标定减小增益、相位、耦合和位置误差。

### 3.4 阵列校准：麦克风个个不一样时怎么办

---

前面的理想公式假设各通道增益和相位一致、阵元位置准确，并忽略壳体散射、声学耦合和电串扰。实际偏差会使导向模型与观测不匹配。本节把常见偏差写进模型，再说明怎样测量和补偿。

#### 3.4.1 增益相位自校准：利用未知声源的多位置观测

把每只麦的响应误差写成一个复数：增益误差是幅度缩放，相位误差是额外旋转，合起来第  $m$  路的实际增益是  $(1 + \Delta g_m)e^{j\Delta\phi_m}$ ，理想值是 1。

导向矢量  $\vec{a}(\theta)$  的每个分量都会乘上这个误差，因此 MUSIC 谱峰会变宽或偏移，波束零陷也会变浅。麦克风阵列实测校准的一个原始例子见 [Sachar、Silverman 与 Patterson 2005, IEEE Transactions on Speech and Audio Processing, 13\(1\):42 – 52](#)。

自校准可以不用已知方向的专用声源。常见做法是交替估计：先固定通道误差估方向，再固定方向估各麦的复增益，循环到目标函数收敛。

这种方法依赖可辨识条件。若只有一个固定方向，声源相位、传播相位和麦克风相位误差可能互相混淆；加入多个充分分散的方向、频点或几何约束后，才有机会分离这些未知量。具体需要多少方向取决于模型参数和约束，不能用一条固定数字概括。

复增益标定处理单通道幅相偏差；跨通道电串扰可在一定线性近似下写成频率相关混合矩阵，壳体散射则通常还随入射方向变化。

#### 3.4.2 互耦补偿：把串音矩阵抵消掉

电路走线或器件间的线性串扰，在近似不随声源方向变化时可写成频率相关矩阵  $\mathbf{C}(f)$ ，实际导向矢量变为  $\mathbf{C}(f)\vec{a}(f, \theta)$ 。



壳体绕射和散射直接改变声场，通常应写成方向相关的实测流形  $\vec{a}_{\text{meas}}(f, \theta)$ ，或在确有依据时用  $\mathbf{C}(f, \theta)\vec{a}(f, \theta)$  表示，不能无条件并入固定  $\mathbf{C}(f)$ 。可用已知方向的测量拟合模型，也可直接把实测阵列流形存入系统。

若对固定混合矩阵显式求逆， $\mathbf{C}(f)$  条件数很大时会放大噪声，因此通常需要正则化，而不是无条件左乘精确逆矩阵。依赖深零陷的差分或超指向设计通常比 DSB 更容易受失配影响。

耦合矩阵描述通道间混合，但不能替代麦克风坐标标定。位置误差会直接改变传播相位。

3.4.3 位置自标定：有锚测绘、无锚边走边建图

8 kHz 的波长约为 4.3 cm，2 mm 位置误差对应的相位误差为  $2\pi \times 0.002/0.0429 \approx 0.29 \text{ rad}$ ，即约  $17^\circ$ ；低频下同一位置误差造成的相位偏差较小。

位置标定有两类方法：

- 有锚点标定：在多个已知位置播放信号，由 TDOA 反解麦克风坐标；
- 无锚点自标定：同时估计声源位置与麦克风位置，要求声源运动或多位置观测满足可辨识条件。

无外部锚时，观测至少不能区分整体平移、旋转和镜像；只用方向观测时还可能不能确定尺度。实现中要固定参考麦克风、坐标轴和尺度，或加入已知距离，才能报告唯一的绝对坐标。相关可辨识性分析可参见 [Kuang 等, ICASSP 2013](#)。

分布式阵列还需同时估计节点时钟关系（§ 10.2），否则 TDOA 会包含系统偏差。

下表汇总不同失配首先影响的量、误差尺度和补偿方法。

3.4.4 失配灵敏度表：先坏哪、坏多少

| 失配类型 | 典型量级          | 最先坏掉的东西     | 数量感                                                      | 补救            |
|------|---------------|-------------|----------------------------------------------------------|---------------|
| 增益失配 | 1% (约 0.1 dB) | 差分/超指向的零陷深度 | 本例残差相对单麦为 -40 dB；波束图归一到前方响应后约 -31 dB（§ 3.1 算例 3-1 第 5 步） | 产线逐只配对、出厂标定系数 |
| 相位失配 | 2°（高频段）       | 高频指向精度      | 2° 相位误差在 8 kHz 约等于 0.24 mm 等效位置误差，MUSIC 峰偏、旁瓣抬高          | 同增益，一起标       |



| 失配类型      | 典型量级     | 最先坏掉的东西    | 数量感                                                                                                                        | 补救                            |
|-----------|----------|------------|----------------------------------------------------------------------------------------------------------------------------|-------------------------------|
| 位置误差      | 2 mm     | 高频导向矢量     | 8 kHz 下约 $17^\circ$ 相位误差；1 kHz 下约 $2^\circ$ 。后者对常规主瓣可能较小，但在依赖精确相消的零陷中仍可能显著：两路残余幅度约 $2\sin(1^\circ) = 0.0349$ ，相对单路约 -29 dB | 有锚/无锚位置标定                     |
| 耦合与壳体散射   | 随结构、频率而变 | 零陷深度、旁瓣电平  | 不能仅由一个间距阈值判断；须比较自由场模型与实测流形                                                                                                 | 使用实测流形，或正则化估计 $\mathbf{C}(f)$ |
| 时钟漂移（分布式） | 晶振几十 ppm | TDOA 系统性偏差 | 跑 1 小时即差约 0.18 秒（百毫秒级），是百微秒级时差的上千倍（§ 2.1、§ 10.2）                                                                           | 共时钟/在线同步补偿                    |

位置误差造成的相位偏差随频率增大；增益漂移、耦合和噪声则未必遵循同一单调关系。依赖精确相消的零陷和超指向设计通常最敏感。

固定一体式阵列常用出厂标定。分布式阵列还需处理节点位置、时钟偏移和采样率漂移，并根据设备移动或时钟变化决定是否在线更新。

工程流程通常分三步：

1. 在受控声场中测各通道的频率响应和阵列流形；
2. 把补偿参数写入设备；
3. 用若干已知方向复测主瓣、旁瓣和零陷。

若设备结构、温度或节点位置会变化，还要定义重新标定的触发条件。采用逐只通道修正、整机流形查表还是在线联合估计，取决于硬件一致性、存储、算力和使用环境。

标定结果不能只保存一组没有上下文的复数。最小标定记录应包括设备或阵列序列号、麦克风通道顺序、坐标系与长度单位、参考麦克风、采样率、频率网格、复增益或实测流形、测量温湿度、测量日期、算法版本和原始记录校验值。加载时先核对通道数、设备身份、坐标维度和频率网格；任一项不匹配时应拒绝套用，而不是截断或重排数组。产线验收还要用未参与拟合的方向复测目标响应、旁瓣或零陷，并把允许误差写成设备规格，而不是沿用某个教学算例的门限。

`geometry.py` 提供统一的平面波和球面波导向矢量，正角、参考麦克风和声速约定与 § 2.1 一致。它是校准前后的共同计算基线，不包含针对某种硬件的自动校准器。对应测试会检查正角时  $\tau_{21} < 0$ 、导向相位为正，以及近场幅度和传播距离；这样可在替换实测流形前先排除坐标轴、通道顺序和傅里叶符号错误。

几何决定可观测的空间信息，标定决定理论模型能否用于实测数据。第 4 章将从 GCC-PHAT 开始介绍声源定位算法。

## 本章练习

1. 协同阵数差集验证：6 麦均匀线阵位置记为  $\{0, 1, 2, 3, 4, 5\}$ （单位  $\lambda/2$ ），列出全部麦对位置差，验证连续差集是  $\{0, \pm 1, \dots, \pm 5\}$ 、共 11 个有符号滞后；再对嵌套阵  $\{0, 1, 2, 3, 7, 11\}$  做一遍，验证是  $\{0, \pm 1, \dots, \pm 11\}$ 、共 23 个连续滞后。为什么还不能直接说它能分辨 22 个声源？

答案要点：这些数是二阶统计量中的有符号滞后，不是 23 路独立快拍。必须先按滞后平均并构造满足结构约束的虚拟协方差，必要时再做空间平滑。可分辨源数由平滑后矩阵的维数和秩、源相关性、信噪比及快拍数共同决定，不能直接用 23 减 1。

2. 栅瓣与挡板二选一：7.5 cm 环径的 6 麦圆环（§ 3.2 算例 3-3），若把工作频率推到 8 kHz，会发生什么？挡板（规律 3）又是在补哪一段的短板？

答案要点：8 kHz 波长约 4.3 cm，半波长约 2.1 cm，小于 3.75 cm 相邻麦距，已经不满足全视场无混叠的半波长充分条件；对理想规则六边形，它也高于 § 3.2 算出的约 5.28 kHz 完整单侧方向域无歧义边界，因此存在某些同相位的方向对。某个指定转向是否出现等高歧义，仍须检查完整几何，不能只套 ULA 的栅瓣角公式；宽带融合可能帮助区分单频点歧义。挡板会以频率和方向相关的方式改变幅相响应；若模型使用得当，这些额外差异可帮助消歧，但它不是固定地把低频下限移动某个倍频程。

下面六题使用 `exercises_spatial.py` 复算，检查差分位置、反三角函数边界、角度约定、远场近似误差、双麦相减响应和通道复增益标定。第七题用独立的协同阵脚本，避免把“差集长度”误当作有效虚拟协方差。

E03-01: 差分位置相同, 观测次数也相同吗? 对位置  $\{0, 1, 2, 3, 4, 5\}$  和  $\{0, 1, 2, 3, 7, 11\}$ , 枚举全部有序麦对, 包括同一麦与自身配对。计算每个差分滞后的重数, 并检查重数之和。位置单位为半波长。

参考答案: 两种布局都有  $6 \times 6 = 36$  个有序麦对, 零滞后的重数均为 6。均匀阵的滞后从 -5 到 5, 重数依次为 1, 2, 3, 4, 5, 6, 5, 4, 3, 2, 1, 共 11 个不同位置。

嵌套阵的滞后连续覆盖 -11 到 11, 共 23 个; 正滞后 1~11 的重数依次为 3, 2, 1, 2, 1, 1, 1, 1, 1, 1, 1, 负滞后与之对称。相同滞后的样本可以平均, 但不同麦对可能共享同一通道, 不能据重数直接假定它们统计独立, 更不能把 23 个差分位置当作 23 路原始录音。

E03-02: 把越界时延与大角度误差分开。麦距 4 cm、声速 343 m/s, 真角取  $0^\circ$  和  $85^\circ$ 。分别给真实时延加、减  $10 \mu\text{s}$ , 用完整反正弦反算; 若反正弦输入超出  $[-1, 1]$ , 应如何记录?

参考答案: 正横的真实时延为零, 两个估计角分别约为  $-4.92^\circ$ 、 $+4.92^\circ$ 。 $85^\circ$  时的真实时延约为  $116.17 \mu\text{s}$ ; 减去  $10 \mu\text{s}$  后约为  $65.57^\circ$ , 增加  $10 \mu\text{s}$  则超过最大时延  $0.04/343 \approx 116.62 \mu\text{s}$ , 无实数方向可解。保留更多位计算, 再将角度舍入到两位小数。

代码将越界结果记为 `valid=false`、角度为 `null`, 不把它悄悄夹到  $90^\circ$ 。系统可以另设夹限策略, 但必须保留越界标记; 夹限输出是恢复动作, 不是一次准确的方向观测。

E03-03: 同一方向为什么会有两个方位角数字? 已知方向单位向量  $\vec{u} = [-1/2, -1/\sqrt{2}, 1/2]^\top$ 。按本书约定——方位角零点为  $+y$ 、正角转向  $+x$ ——反算方位角与俯仰角, 并将角度重新代回方向向量。再与从  $+x$  朝  $+y$  计角的常见数学约定比较。

参考答案: 本书使用  $u_x = \sin \theta \cos \varphi$ 、 $u_y = \cos \theta \cos \varphi$ 、 $u_z = \sin \varphi$ , 因此  $\theta = \text{atan2}(u_x, u_y) \approx -144.74^\circ$ ,  $\varphi = \arcsin(1/2) = 30^\circ$ 。代回后恢复原来的三个分量, 双精度程序的最大绝对误差小于  $10^{-14}$ 。

从  $+x$  计角时,  $\alpha = \text{atan2}(u_y, u_x) \approx -125.26^\circ$ ; 它与本书的关系是  $\theta = 90^\circ - \alpha$ , 再将角度折回选定的  $360^\circ$  区间。两者描述同一方向, 不能混用数值与导向模型。[NumPy 的 atan2 文档](#)明确规定第一个参数通常对应纵坐标、第二个对应横坐标; 函数不会替调用者选择本书的角度零点。

E03-04: 球面波何时足够接近平面波? 三只麦位于  $(-0.05, 0)$ 、 $(0, 0)$ 、 $(0.05, 0)$  m, 中心麦作参考, 声速为 343 m/s。声源方向为本书方位角  $30^\circ$ , 距中心分别为 0.2、0.5、2、20 m。用真实距离差与平面投影分别计算相对时延, 比较三通道时延误差的均方根, 并换算为 4 kHz 的相位误差。

参考答案：声源位置为  $(r/2, \sqrt{3}r/2)$ ，真实距离为  $d_m = \sqrt{r^2 - 2rx_m \sin 30^\circ + x_m^2}$ ，相对时延为  $(d_m - r)/343$ ；平面近似为  $-x_m \sin 30^\circ/343$ 。在  $r = 0.2 \text{ m}$  时，真实相对路程约为  $[29.129, 0, -19.722] \text{ mm}$ ，平面模型为  $[25, 0, -25] \text{ mm}$ 。

三通道误差先平方、取平均再开方；参考麦的零误差也计入分母 3。相位误差采用未绕回的  $360f\Delta\tau$ ，不能先折回  $[-180^\circ, 180^\circ)$  再比较模型。

| 声源距离 / m | 时延误差均方根 / $\mu\text{s}$ | 4 kHz 相位误差均方根 / $^\circ$ |
|----------|-------------------------|--------------------------|
| 0.2      | 11.28                   | 16.24                    |
| 0.5      | 4.47                    | 6.44                     |
| 2        | 1.12                    | 1.61                     |
| 20       | 0.11                    | 0.16                     |

近场还存在幅度差。在 0.2 m 处，以中心麦归一化的幅度约为  $[0.8729, 1, 1.1094]$ ，并非全为 1。距离增大时，本例的相位和幅度都逐渐接近平面模型；是否可以忽略误差取决于频带与容差，不能把表中的某个距离当作所有阵列的统一边界。这是本书自由场几何计算，未模拟反射、挡板或麦克风指向性。

E03-05：前后对称为什么不一定是 8 字形？两个理想全向麦间距 1 cm，声速 343 m/s，频率 1 kHz。先计算不加电延迟的  $y = x_1 - gx_2$ ，分别取  $g = 0, 0.5, 1$ ，比较前端射、后端射和正横的幅度。再令  $g = 1$ ，给后路增加  $d/c$  延迟，比较两个端射方向。

参考答案：令  $p = 2\pi fd/c \approx 0.18318 \text{ rad}$ 。不加电延迟时，两个端射方向幅度相同，平方均为  $1 + g^2 - 2g \cos p$ ；正横幅度为  $|1 - g|$ 。按未舍入的  $p$  计算，最后保留四位小数：

| 实增益 $g$ | 前端射幅度  | 后端射幅度  | 正横幅度   |
|---------|--------|--------|--------|
| 0       | 1.0000 | 1.0000 | 1.0000 |
| 0.5     | 0.5165 | 0.5165 | 0.5000 |
| 1       | 0.1829 | 0.1829 | 0.0000 |

只有最后一行在正横有零点。额外给后路延迟  $d/c$  后，前方响应为  $|1 - e^{-j2p}| = 2 \sin p \approx 0.3643$ ，后方为 0。相对于单麦的幅度尺度保持不变，不分别把每行归一化到峰值。

本题展示增益和延迟怎样改变理想模型的对称性，不是实测零陷深度。有限通道失配、反射与高频下的小间距近似误差仍须单独验证。

E03-06：方向误差还是通道相位误差？两只同步麦克风位于  $x_1 = 0$ 、 $x_2 = d = 8.575 \text{ cm}$ ，声速为  $343 \text{ m/s}$ ，频率为  $1 \text{ kHz}$ 。按 § 2.3 的约定，麦 1 是参考通道；麦 2 有未知但在两次观测间不变的相对复增益  $g$ 。

用两个方向已知的窄带校准声源，分别置于  $+30^\circ$  与  $-30^\circ$ 。设源在麦 1 的复幅度为  $b_\theta$ ，测得两麦复谱之比  $q_\theta = X_2/X_1$  分别为  $1.2e^{j75^\circ}$  和  $1.2e^{-j15^\circ}$ 。

先根据方向求两次理想导向比  $a_2/a_1$ ，再分别由  $q_\theta$  算出  $g$ 。如果误把  $g$  当成 1，只凭  $+30^\circ$  那次测得的相位反算方向，会得到多少度？最后说明为什么一条方向未知的观测不能同时确定方向与通道相位误差。先手算，再运行 E03-06；本题没有录音噪声、房间反射或设备漂移。

参考答案：几何相位。 $d = \lambda/4$ ，故  $\psi(\theta) = 2\pi f d \sin \theta / c = (\pi/2) \sin \theta$ 。两已知方向的几何相位分别为  $+45^\circ$  和  $-45^\circ$ ，理想导向比分别为  $e^{j45^\circ}$  和  $e^{-j45^\circ}$ 。 $q_\theta$  中的公共源幅度  $b_\theta$  已经约掉，不要求两次播放同样响。

参考答案：复增益与错误角度。两次计算都得到  $g = q_\theta / (a_2/a_1) = 1.2e^{j30^\circ} = 1.03923 + 0.6j$ 。将麦 2 除以这个复增益后，相对相位回到  $\pm 45^\circ$ 。若忽略相位校准，把测得的  $75^\circ$  全当作几何相位，则  $\sin \hat{\theta} = 75^\circ / 90^\circ = 5/6$ ，得到  $\hat{\theta} \approx 56.44^\circ$ ，相对真实  $30^\circ$  偏了约  $26.44^\circ$ 。

参考答案：可辨识边界。仅有第一条方向未知的  $q = 1.2e^{j75^\circ}$  时， $(\theta = 30^\circ, \arg g = 30^\circ)$  和  $(\theta = 0^\circ, \arg g = 75^\circ)$  都能解释它，幅度同为 1.2。本题一个方向已知的无噪声观测其实足以求双麦相对复增益；第二个已知方向用于检查“复增益不随方向变化”这一假设。

若声源方向未知，仅增加任意方向的观测而不加几何、频率或校准约束，也不能保证唯一分开方向和相位误差。实测中壳体散射可能使误差随方向变化，需按 § 3.4 测量阵列流形，不能用这一个固定  $g$  外推。

E03-07：从三麦协方差构造虚拟四阵元统计量。物理位置为  $p = \{0, 1, 3\}$ ，单位为半波长。两个互不相关的远场窄带源分别在  $0^\circ$  和  $+30^\circ$ ，各有单位功率；独立通道噪声功率为 0.1。按  $a_m(\theta) = e^{j\pi p_m \sin \theta}$ 、 $R_{ij} = E[X_i X_j^*]$  和  $\ell = p_i - p_j$ ，先算有符号滞后  $r[0], r[\pm 1], r[\pm 2], r[\pm 3]$ ，再按  $T_{ij} = r[i - j]$  写出连续位置 0, 1, 2, 3 的虚拟 Toeplitz 矩阵，检查共轭对称、特征值与物理通道数。

参考答案：总体协方差。两个导向矢量是  $[1, 1, 1]^\top$  和  $[1, j, -j]^\top$ 。例如  $R_{10} = 1 + j$ ，因为  $p_1 - p_0 = 1$ ； $R_{21} = 0$ ，因为相应滞后为 2、两个源的相位项相消。因此  $r[0] = 2.1$ ， $r[1] = 1 + j$ ， $r[2] = 0$ ， $r[3] = 1 - j$ ，负滞后由共轭得到。

$$\mathbf{T} = \begin{bmatrix} 2.1 & 1-j & 0 & 1+j \\ 1+j & 2.1 & 1-j & 0 \\ 0 & 1+j & 2.1 & 1-j \\ 1-j & 0 & 1+j & 2.1 \end{bmatrix}。$$

它等于两个四维导向矢量的外积之和加  $0.1\mathbf{I}$ 。这两个向量彼此正交、平方范数均为 4，故特征值是 4.1, 4.1, 0.1, 0.1；四维只是二阶统计量的索引长度，物理录音仍只有三路。

参考答案：有限样本反例。改取一次物理快拍  $\vec{x} = [1, 0, 1]^\top$ ，样本协方差  $\vec{x}\vec{x}^H$  的特征值为 2, 0, 0，是合法半正定矩阵。按相同滞后平均， $r[0] = 2/3$ 、 $r[\pm 3] = 1$ 、其余滞后为零；直接填成的  $4 \times 4$  Toeplitz 矩阵有特征值  $5/3, 2/3, 2/3, -1/3$ ，已不再半正定。

不能把这种任意填表直接交给 MUSIC 当作有效协方差；要检查矩阵性质，或采用文献中有半正定保证的协同阵空间平滑构造。

先从上面的外积与滞后手算，再运行 [E03-07 脚本](#) 核对两组特征值。它只复算窄带二阶统计量，没有生成四通道声音，也没有证明三只麦在任何 SNR 或快拍数下都能分辨四个声源。[Pal 与 Vaidyanathan 2010 第 IV 节](#) 给出利用嵌套阵二阶统计量与空间平滑估计方向的原始方法。

更多跨章练习和音频条件见[实验总览](#)。其中整数延迟音频只提供已知通道时差，没有模拟某一真实麦克风外壳；不能由该样本推断挡板收益或阵列标定精度。



## 第 4 章 · 声源定位 (DOA 估计)

### 4.1 总览：四大类思路

#### 声源定位算法


- |—— A. 两阶段法 (到达时间差, Time Difference of Arrival, TDOA) : 先从麦对估计时延, 再解算位置
  - | |—— GCC 加权互相关 (SCOT / Roth / PHAT / ML) 估计麦对时延
  - | |—— 多麦对几何解算 (LS, least squares, 最小二乘 / 泰勒迭代)
- |—— B. 直接空间扫描类: 逐候选位置或方向计算全阵列得分
  - | |—— SRP-PHAT (按候选时延查各麦对的整条 GCC 曲线并累积)
  - | |—— Bartlett 波束形成谱
  - | |—— Capon / MVDR (最小方差无失真响应) 谱
- |—— C. 子空间类 (超分辨)
  - | |—— 多重信号分类 (Multiple Signal Classification, MUSIC) /  
| 借助旋转不变技术估计信号参数 (ESPRIT) (相干源需配空间平滑预处理)
- |—— D. 稀疏重构与深度学习类
  - |—— L1-SVD / SBL (压缩感知; SBL = sparse Bayesian learning)
  - |—— DNN (deep neural network, 深度神经网络; SRP-CNN、GCC-PHAT+CRNN、ACCDQA)

图 11 在同一个两源仿真 ( $-20^\circ$ 、 $30^\circ$ ) 中比较 Bartlett、Capon 和 MUSIC。条件为 8 元半波长 ULA、每阵元总输入 SNR 20 dB、400 个快拍, 两源相隔  $50^\circ$ 。这个较容易的条件只展示三种谱形, 不检验最小可分辨角度。

Bartlett 按标准空间谱计算。Capon 在样本协方差上使用相对对角加载  $\eta = 10^{-6}$ , 即  $\hat{\mathbf{R}} + \eta \text{tr}(\hat{\mathbf{R}})\mathbf{I}/M$ 。MUSIC 给出伪谱, 峰高不是功率。

只有在源间隔、信噪比、快拍数、源数和阵列失配都明确时, 才能用重复试验比较分辨成功率。

图11 两信号源( $-20^\circ$ ,  $30^\circ$ ) DOA空间谱估计对比 (8元ULA, 每阵元总输入SNR=20dB, 400快拍, 模拟)



图示说明：比较三类方法的谱形，不比较图中的绝对峰高。Bartlett 的分辨率受阵列孔径限制；Capon 利用协方差逆矩阵抑制其他方向；MUSIC 依赖信号子空间与噪声子空间的正交性。谱峰个数也不能无条件当作源数：旁瓣、相干多径和有限快拍都可能产生假峰或合并真峰，源数估计要按下一节的方法独立完成。

#### 4.1.1 源数估计：确定信号子空间维数

子空间类（MUSIC、ESPRIT）必须先确定源数  $K$ 。 $K$  定错后，信号子空间与噪声子空间的切分位置也会错。

MUSIC 还要满足  $K < M$ ，否则没有非零维噪声子空间可供正交检验。ESPRIT 的两个子阵也都必须至少有  $K$  维，实际通常保留更多阵元以降低有限快拍误差。下面给出两种常用估计方法。

方法 1：特征值间隙 (eigen-gap)。把固定频点  $f_k$  的协方差矩阵  $\hat{\mathbf{R}}(f_k)$  (读作“R 帽”，帽子表示用有限快拍估计出来的版本) 的特征值从大到小排列。前  $K$  个特征值包含信号与噪声功率，后面  $M - K$  个在白噪声模型下接近  $\sigma^2$ 。

算例 4-4 的无噪声单源给出 3, 0, 0，因此  $K = 1$ 。实际数据中，低信噪比或快拍不足会缩小相邻特征值之间的间隔；可比较相邻特征值的比值或差值，并把最大间隙所在位置作为候选分界。这种方法计算简单，但在低信噪比或快拍不足时不稳定。

方法 2：信息准则 (AIC/MDL)。增加候选源数通常会改善数据拟合，同时也会增加模型复杂度。AIC (Akaike information criterion, 赤池信息准则) 和 MDL (minimum description length, 最小描述长度) 用不同的复杂度惩罚项平衡这两部分，并取准则值最小的候选  $K$ 。

Wax 与 Kailath 的[1984 年原始会议论文](#)，式(10)~(15)给出了复数观测、空间白噪声、独立快拍模型下的推导；[1985 年期刊论文](#)题为 *Detection of signals by information theoretic criteria*。两篇论文的题名和公式编号不能混用。MDL 比较剩余特征值的几何均值与算术均值，再加入源数惩罚；§ 4.9 给出完整定义、逐候选计算和代码练习。

实现时必须核对复/实数据、快拍数和惩罚项口径。低 SNR、快拍不足、彩色噪声或相干源导致的信号协方差降秩都会造成误判。

信噪比高、快拍充足时，可以先看特征间隙；需要自动选择  $K$  时可用 MDL，并用特征值谱交叉检查。

相干源场景还存在一个实际循环：空间平滑要按候选源数选择子阵长度，而源数又要从平滑后的谱估计。可先给出源数上界  $K_{\max}$ ，对候选  $K$  和子阵长度联合扫描，再检查结果对参数是否稳定。对  $M$  元均匀线阵 (Uniform Linear Array, ULA) 做前向空间平滑时，若切成  $L$  个长度为  $P = M - L + 1$  的重叠子阵，要分辨  $K$  个完全相干源，至少需要  $L \geq K$  且  $P > K$ 。这两个条件同时限制可分辨源数和剩余有效孔径。[Shan、Wax 与 Kailath 的空间平滑分析](#)。

子空间法需要源数，GCC-PHAT 不需要。下一节先从双通道时延估计讲起。

## 4.2 GCC-PHAT：“对齐两段录音，找最吻合的错位”

本章沿用 § 2.1~§ 2.3：麦 1 在  $x = 0$ ，麦 2 在  $+x$ ；正横为  $0^\circ$ ，正角朝麦 2； $\vec{u}$  从阵列指向声源，传播方向为  $-\vec{u}$ ； $\tau_{ij} = t_i - t_j$ 。

采用前向核  $e^{-j2\pi ft}$  时，

$$\tau_{m1} = -(\vec{r}_m - \vec{r}_1)^\top \vec{u} / c,$$
$$a_m = e^{-j2\pi f \tau_{m1}} = e^{+j2\pi f (\vec{r}_m - \vec{r}_1)^\top \vec{u} / c}。$$

因此正角双麦有  $\tau_{21} < 0$ 、 $\tau_{12} > 0$ 。

直觉：把第二路录音左右平移，平移到与第一路最像的那个错位量就是时间差。

时域定义。两路离散信号  $x_1(n)$ 、 $x_2(n)$ ，定义时延  $\tau$  处的互相关值（ $\tau$  以采样点为单位，取遍  $\dots, -2, -1, 0, 1, 2, \dots$ ）：

$$R(\tau) = \sum_n x_1(n) x_2(n - \tau)。$$

把  $x_2$  往右挪  $\tau$  格，和  $x_1$  上下对齐，逐点相乘再求和。加总越大，这个错位下两路越像。最后取峰： $\hat{\tau} = \arg \max_\tau R(\tau)$ （ $\arg \max$  返回峰的位置，不是峰高）。直接计算需要  $O(N^2)$  次乘加；频域实现可把复杂度降到  $O(N \log N)$ 。

频域等价式（相关定理）：时域逐点算出的整条  $R(\tau)$ ，等于频域共轭相乘后再作逆变换——

$$R(\tau) = \text{IFFT}\{X_1(f)X_2^*(f)\}$$

连续时间形式写成积分，见下文的快速实现公式。

两边是同一个相关函数，只是计算路线不同。本文把  $\tau_{12} > 0$  定义为“信号到麦 1 比到麦 2 晚”，即  $x_1(t) = x_2(t - \tau_{12})$ 。在这个定义下， $\text{ifft}(X_1 \cdot \text{conj}(X_2))$  的峰位是  $+\tau_{12}$ ；若交换两路，峰位变成  $-\tau_{12}$ 。实现和论文若采用不同的信号次序或相关定义，符号也会随之改变。

频域实现：用一次 IFFT 计算整条相关曲线。两路信号为  $x_1, x_2$ ， $X_1(f)$ 、 $X_2(f)$  是它们在物理频率  $f$ （单位 Hz）处的复数谱值，都是标量。离散实现使用第  $k$  个频点及对应频率  $f_k = kf_s/N$ ，不能把无量纲索引  $k$  直接代入  $2\pi f\tau$ 。


运算顺序是先对  $X_2(f)$  取共轭得到  $X_2^*(f)$ ，再与  $X_1(f)$  逐频点相乘：

$$R_{x_1 x_2}(\tau) = \int \Phi(f) X_1(f) X_2^*(f) e^{j2\pi f \tau} df, \quad \hat{\tau} = \arg \max_\tau R(\tau)。$$

代码里就是  $\text{ifft}(\Phi \cdot X_1 \cdot \text{conj}(X_2))$  后找最大值索引。快速傅里叶变换（Fast Fourier Transform, FFT）负责计算整条相关曲线， $\arg \max$  负责从曲线上读峰位，两者是前后两步。

复杂度从  $O(N^2)$  降到  $O(N \log N)$ 。实际加速比还取决于帧长、补零长度、FFT 库和硬件，不能只由渐近复杂度给出固定倍数。

图33 互相关的两种等价实现 (GCC 中  $\Phi(f)=1$  的特例; 非 PHAT 加权)



图示说明: 图33(a)给出零填充整数延迟信号; (b)按定义逐个 lag 直接求和; (c)计算频域乘积  $X_1 X_2^*$ ; (d)用零填充 FFT 和 IFFT 得到线性互相关。时域与频域由独立代码计算, 图中给出最大数值误差。该图对应  $\Phi(f) = 1$  的普通互相关, 不包含 PHAT 加权。

线性相关与补零: FFT 算的是圆周相关 (序列尾部会卷绕到开头), 帧不够长时两端的  $R(\tau)$  会被卷绕项污染; 工程上补零到  $N \geq N_1 + N_2 - 1$  (两帧长度之和减一) 再做 FFT。下文 8 点手算例因脉冲远离边缘、考察点无混叠, 所以未补零也能得到相同结果; 一般输入仍须补零。

这项有限长度等价针对未加权互谱  $X_1 X_2^*$ 。PHAT 再除以互谱幅度后, 逆变换一般不再具有原来长度的有限支撑; 补零可以加密频率采样、减轻周期边界影响, 但不能据此称为精确的有限长线性互相关。比较实现时须记录 FFT 长度、加权和保留的 lag 范围。图 33 的严格时域等价不应外推为任意 PHAT 权重下的同一有限求和式。

符号说明: 这里的  $R(\tau)$  是时延  $\tau$  的标量互相关函数; 后文 § 4.5 起的  $\hat{\mathbf{R}}(f_k)$  是频点  $f_k$  上的  $M \times M$  协方差矩阵, 以黑体和估计符号相区别。

为什么相位里藏着时延：沿用“麦 1 晚到”为正的定 $\tau_0$ ，因此 $x_1(t) = x_2(t - \tau_0)$ ，因此 $X_1(f) = X_2(f)e^{-j2\pi f\tau_0}$ 。于是

$$X_1(f)X_2^*(f) = |X_2(f)|^2 e^{-j2\pi f\tau_0},$$

相位  $\angle\{X_1X_2^*\} = -2\pi f\tau_0$  的斜率是  $-2\pi\tau_0$ 。例如  $\tau_0 = 58.3\mu\text{s}$  时，1 kHz 和 2 kHz 处的相位分别约为  $-0.366\text{ rad}$  和  $-0.733\text{ rad}$ 。逆变换在  $\tau = \tau_0$  处乘上  $e^{j2\pi f\tau_0}$ ，恰好抵消这条负斜率，各频点同相相加形成峰。

PHAT 把互谱除以其幅度，使每个保留频点只贡献单位幅度的相位项。理想单时延模型下，这样可以减少谱包络对相关峰形的展宽。

PHAT 不会修复混响或噪声造成的错误相位，还可能放大原本很弱、信噪比很低的频点。因此实现时通常在分母加  $\varepsilon$ ，并可配合频带筛选或可靠度加权。

#### 算例 4-0bis：8 点脉冲手算——时域与频域结果一致

下面用最简单的脉冲分别计算时域相关和频域等价式，核对峰值位置与数值。

设定： $N = 8$ ，序列 ( $n = 0 \dots 7$ ) 为

- $x_1 = [0, 0, 3, 0, 0, 0, 0, 0]$ ，3 在  $n = 2$  处，即  $x_1$  比  $x_2$  晚到 2 拍；
- $x_2 = [2, 0, 0, 0, 0, 0, 0, 0]$ ，2 在  $n = 0$  处。

线性互相关定义为  $R(\tau) = \sum_n x_1(n)x_2(n - \tau)$ ，越界按 0 处理。考察  $\tau = 0/1/2$  时，下标  $2 - \tau = 2/1/0$  都落在序列范围内，因此线性相关与 8 点圆周相关在这三点没有回绕混叠、数值相等。一般情况仍要补零到  $N \geq N_1 + N_2 - 1$ ，见上文补零提醒。

时域计算：逐  $\tau$  算  $R(0)$ 、 $R(1)$ 、 $R(2)$ ，取最大值。 $x_1$  只在  $n = 2$  处非零（值为 3），加总只剩一项： $R(\tau) = 3 \cdot x_2(2 - \tau)$ 。 $R(0) = 3 \cdot x_2(2) = 3 \times 0 = 0$ ； $R(1) = 3 \cdot x_2(1) = 3 \times 0 = 0$ ； $R(2) = 3 \cdot x_2(0) = 3 \times 2 = 6$ （最大值， $\hat{\tau} = 2$ ，即  $x_1$  晚到 2 个采样点，峰在 +2，与设定一致）。

频域手算：DFT 共轭乘 + IDFT。记  $W = e^{-j2\pi/8}$ ，DFT 定义  $X[k] = \sum_n x[n]W^{kn}$ 。 $x_2$  只有  $n = 0$  项，所以  $X_2[k] = 2$ ， $k = 0 \dots 7$  全是 2。

$x_1$  只有  $n = 2$  项，因此  $X_1[k] = 3W^{2k} = 3e^{-j\pi k/2}$ 。逐个写出：

$$X_1 = [3, -3j, -3, 3j, 3, -3j, -3, 3j],$$

$$X_2^* = [2, 2, 2, 2, 2, 2, 2, 2],$$

$$G[k] = X_1X_2^* = [6, -6j, -6, 6j, 6, -6j, -6, 6j]。$$



IDFT 为  $r[\tau] = \frac{1}{8} \sum_k G[k] e^{+j2\pi k\tau/8}$ 。分别计算三个候选点：

- 1.  $\tau = 0$  时， $\frac{1}{8}(6 - 6j - 6 + 6j + 6 - 6j - 6 + 6j)$  的实部和虚部各自相消，得  $\mathbf{r}[0] = \mathbf{0} = R(0)$ ；
- 2.  $\tau = 1$  时， $G[k] \cdot e^{j2\pi k/8} = 6(e^{-j\pi/4})^k$ 。  $k = 0 \dots 7$  构成公比不等于 1 的完整周期几何级数，配对相消，得  $\mathbf{r}[1] = \mathbf{0} = R(1)$ ；
- 3.  $\tau = 2$  时， $G[k] \cdot e^{j2\pi k \cdot 2/8} = 6e^{-j\pi k/2} \cdot e^{+j\pi k/2} = 6$ 。8 项全是 6，得  $r[2] = 48/8 = 6 = R(2)$ 。

在  $\tau = 2$  处，各频点的相位因子精确抵消，8 个实数 6 同相相加；其他两个候选时延的正负项相消。

时域与频域结果对照： $\tau = 0$  处时域和频域均为 0； $\tau = 1$  处均为 0； $\tau = 2$  处均为最大值 6，因此两种计算都得到  $\hat{\tau} = 2$ 。

本例的 PHAT 结果： $|G[k]| = 6$  在所有频点相等，所以归一化不改变相对频谱。PHAT 谱  $\Psi[k] = G[k]/|G[k]| = [1, -j, -1, j, 1, -j, -1, j]$ ，IDFT 在  $\tau = 2$  处为 1，其余位置为 0。理想单时延、无噪条件下峰位不变；实际数据中，PHAT 改变各频点权重，峰位仍会受噪声和混响影响。

核心是加权函数  $\Phi(f)$  的选择：

| 加权                                          | 公式                                  | 特点                                                                                        |
|---------------------------------------------|-------------------------------------|-------------------------------------------------------------------------------------------|
| 互相关 CC                                      | $\Phi = 1$                          | 不作频谱加权，峰形受源的自相关与噪声统计影响；是否优于 PHAT 取决于信号带宽与噪声条件                                             |
| Roth                                        | $1/(\hat{G}_{11} + \varepsilon)$    | 用通道 1 的平滑自功率谱对互谱加权；结果与通道次序有关，谱估计很小时需要 $\varepsilon$ 避免过度放大                                |
| SCOT (Smoothed Coherence Transform, 平滑相干变换) | $1/\sqrt{\hat{G}_{11}\hat{G}_{22}}$ | 用两路自功率谱估计的几何平均对互谱作对称归一化； $\hat{G}_{11}$ 、 $\hat{G}_{22}$ 可由时间平均、频率平滑或 Welch 方法估计，必须记录具体口径 |
| PHAT (相位变换)                                 | $1/( X_1X_2^*  + \varepsilon)$      | 归一化互谱幅度、保留相位；理想单时延下峰更尖，但不会消除错误相位，低信噪比频点需筛选或再加权                                            |
| ML                                          | 由信号与噪声统计模型决定                        | 只在指定概率模型与参数假设下谈最优；不能用一条通用权重概括                                                             |

单帧直接代入时， $\sqrt{|X_1|^2|X_2|^2} = |X_1X_2^*|$ ，SCOT 与 PHAT 的分母数值相同。使用统计谱估计后，SCOT 的分母来自两路自谱，而 PHAT 的分母来自互谱幅度；两者的偏差和方差取决于平均窗、频带、信噪比及谱估计方法，不能笼统断言哪一个始终更稳。

教学实现 `gcc_phat` 把 `epsilon` 解释为相对本麦对互谱最大幅值的无量纲门限，并先缩放输入以避免大幅度有限样本的中间乘法溢出。全零麦对没有可估时差，函数会报错；这不是返回  $0^\circ$  或“静音方向”。门限、麦序与实际频带都必须随实验记录，不能把这里的数值保护误认为噪声下的方向置信度。

由时延换算角度： $\hat{\theta} = \arcsin(c\hat{\tau}/d)$ 。先检查  $|c\hat{\tau}/d| \leq 1$ ：轻微超限若能由已验证的数值舍入界解释，可限幅后计算；明显超限说明该峰不满足双麦平面波几何，应判为野值或低置信度，不能一律吸附到端射方向。

这个换算怎么来的：几何推导见 § 2.1 “时差的几何来源”。平面波以角  $\theta$  斜入射，路程差  $\Delta = d \sin \theta$ （图12(c)），因此  $\hat{\tau} = d \sin \theta / c$ ； $\theta$  从正横方向起算。若论文把角度定义为相对麦克风连线，则同一关系写成  $\hat{\tau} = d \cos \theta / c$ 。


双麦只给一个标量时延。三维中相容方向构成以连线为轴的锥面；要解除该模糊，需要增加不共线的麦克风或加入其他先验。

两个实用细节：


1. 16 kHz 下一个采样点为  $62.5 \mu\text{s}$ 。对 4 cm 间距，从正横方向的 0 延迟跳到 1 个采样点对应  $\arcsin(343 \times 62.5 \mu\text{s} / 0.04) \approx 32.4^\circ$ ，而且越靠近端射方向，同样的时延误差造成的角度误差越大。实际系统要对相关峰插值或拟合相位斜率，得到亚采样时延。
2. PHAT 提高了相位的相对权重，因此麦克风相位响应不一致会直接造成定位偏差（见 § 10.2）。

图12 GCC-PHAT 声源定位原理：亚采样时延估计（模拟）


(a) 两路信号（放大 0.5 ms 窗口）



(b) GCC-PHAT (16×时延网格插值)



(c)  $\theta = \arcsin(c \cdot \tau / d) = \arcsin(0.5) = 30^\circ$   
( $\theta$  自正横方向起算)



图示说明：图 12 (a) 的两路波形设定为  $d = 4 \text{ cm}$ 、 $\theta = 30^\circ$ ，对应  $\tau_0 \approx 58.3 \mu s$ ，即  $16 \text{ kHz}$  下约 0.933 个采样点。

图 12 (b) 将两路固定噪声样例做 16 倍时延网格插值后计算 GCC-PHAT，峰值落在  $58.59375 \mu\text{s}$ ，即 0.9375 个原始采样点；虚线标出  $58.3 \mu\text{s}$  真值。图 12 (c) 把时差乘声速得到路程差，再除以间距得到角度正弦， $\theta$  从正横起算，与 § 2.1 约定一致。

这个固定样例的估计接近真值，但单个样例不能代表误差分布。

算例：GCC-PHAT 完整数字链 ( $d = 4 \text{ cm}$ 、 $\theta = 30^\circ$ )：按 § 2.1 几何关系，真值时延  $\tau_0 = d \sin \theta / c = 0.04 \times 0.5 / 343 \approx 58.3 \mu\text{s}$ ；16 kHz 下 1 个采样点 =  $62.5 \mu\text{s}$ ，故真值在  $58.3 / 62.5 \approx 0.933$  格。直接取整读峰只能得到 1 格，对应  $\arcsin(343 \times 62.5 \mu\text{s} / 0.04) \approx 32.4^\circ$ 。

图 12 的脚本不是三点抛物线拟合，而是对互谱补零，把 GCC-PHAT 的时延网格细化到  $62.5 / 16 \approx 3.91 \mu\text{s}$ ，再在相关序列上取最大值。固定随机种子的噪声样例得到  $58.59375 \mu\text{s}$ ，即 0.9375 格；换算角度为

$$\hat{\theta} = \arcsin\left(\frac{343 \times 58.59375 \times 10^{-6}}{0.04}\right) \approx 30.16^\circ.$$

该估计比  $30^\circ$  真值高约  $0.16^\circ$ 。这个固定样例说明时延网格插值能避免只在整数采样点上搜索；实际偏差仍取决于信号带宽、观测长度、噪声、混响和插值方法，需要在多次试验或实测数据上统计。

优缺点：频域实现的主导运算量为  $O(N \log N)$ ；是否满足实时要求仍取决于窗长、帧移、麦对数量、FFT 库、硬件、线程、缓存和计时范围，不能由复杂度记号直接推出。但一对麦每帧通常只读一个主峰，多源时会出现多个峰且跨麦对难以配对。强混响或低信噪比还会使峰展宽或选错。GCC 加权家族的定义、统计模型和最大似然权重见 [Knapp 与 Carter, IEEE TASSP, 1976](#)。

参数口径反例： $T_{60}$  不能单独推出定位趋势。反射会把多个延迟副本叠到直达声上，使相关背景抬高、主峰展宽并出现旁峰；但一张合成图的变化方向还取决于如何归一化反射尾。

图 13 把两个因素分开控制：每路冲激响应的直达能量固定为 1，随机指数尾分别归一到 DRR=+6、0、-6 dB；尾长取  $1.1T_{60}$ ，考察  $T_{60} = 0.1、0.4、0.8 \text{ s}$ 。采样率为 16 kHz，帧长约 64 ms，无额外传感器噪声，每个  $T_{60} \times \text{DRR}$  条件做 150 次固定种子的试验。


互谱按  $X_1 X_2^*$  定义。第二路比第一路晚 9 点时， $\tau_{12} = -9$  点，真峰 lag 也为 -9。估计峰落在真值  $\pm 1$  点内算正确。

正确率给出 Wilson 95% 区间；峰值对比度采用  $\max g / \text{median } |g|$ ，汇报中位数和四分位区间。

这个受控试验把每条随机尾的总能量固定在目标 DRR，并为两个通道独立生成随机尾。因此，增大  $T_{60}$  会把同一总能量分散到更长的时间；在 64 ms 短帧内，瞬时尾能量可能反而降低，所以正确率和峰对比度不必随  $T_{60}$  单调变差。这不能解释为“混响更长有利于 GCC-PHAT”。

独立通道随机尾没有模拟真实晚期混响随麦距和频率变化的空间相干性。这些随机尾不是几何房间的镜像法 RIR，也不是实测数据。图 13 只比较该说明模型内两个因素对峰统计量的影响，不能外推绝对性能。

图13 GCC-PHAT 的两因素实验：随机尾时长  $T_{60}$  与尾能量 DRR  
直达能量=1；两通道独立随机尾按目标 DRR 固定总能量；64 ms 帧；无加性噪声；本书仿真



图示说明：图13(a)在 DRR=0 dB 下比较三个  $T_{60}$  的固定种子单帧；(b)分别画出三种 DRR 下的正确率和 Wilson 95% 区间；(c)画峰值对比度的中位数和四分位区间。读图时应同时指定  $T_{60}$  与 DRR：前者控制尾的衰减时长，后者控制尾相对直达声的总能量。

双麦 GCC 只提供一个麦对时延。三维定位或多源场景通常需要 § 4.3 的 SRP-PHAT，联合多个麦对进行空间扫描。

## 4.3 SRP-PHAT：跨麦对累积空间响应

对空间中每个候选位置  $\vec{r}$ ：由几何算出“若声源在此，各麦对时延应是多少”  $\tau_{ij}(\vec{r})$ ，再查 GCC-PHAT 值并累加：

$$\hat{\vec{p}} = \arg \max_{\vec{r}} \sum_{i < j} R_{x_i x_j}^{PHAT}(\tau_{ij}(\vec{r}))。 \quad (4-1)$$

其中  $\tau_{ij}(\vec{r}) = (\|\vec{r}_i - \vec{r}\| - \|\vec{r}_j - \vec{r}\|)/c$ ——候选点到麦  $i$  的距离减去到麦  $j$  的距离，再除以声速；几何意义即下文 § 4.4 的双曲线（等时差线）。

候选位置正确时，各麦对会在各自预测 TDOA 附近取得较大的 GCC-PHAT 值，累积得分随之升高；候选位置错误时，各麦对的取值通常无法同时达到峰值。扫描可扩展到三维网格，也可从空间响应图中寻找多个局部峰。多个峰是否对应真实声源，仍需结合最小峰距、置信度和跨帧一致性判断。

SRP-PHAT 使用每个麦对的整条相关曲线，在候选位置所预测的时延处取值；它不要求先为每个麦对挑出一个峰，再把这些峰送入几何解算。后者是 § 4.4 的两阶段路线。反射或多源造成麦对相关曲线多峰时，两条路线因此会保留不同的信息。

教学 `srp_phat` 对每个有效麦对分别做相对幅度归一化；如果输入全零或只有不能提供方向信息的直流分量，便明确报错，而不是返回一张全零图让 `argmax` 捏造网格的第一个方向。输入有声仍不保证方向可靠；宽带有效性、反射和多源峰的判断由调用者另行处理。

SRP-PHAT 把 PHAT 加权引入可控响应功率扫描的原始系统论述见 [DiBiase, Brown University 博士论文, 2000](#)。式(4-1)采用麦对 GCC-PHAT 在预测时延处求和的实现形式；搜索区域、网格间距、频带和插值共同决定响应图的离散化与峰形。

### 算例 4-1：SRP-PHAT 的六麦对累积

下面用两个候选点计算预测时延，再比较六个麦对的累积得分。



设定：平面 4 麦矩形阵，坐标  $\vec{r}_1 = (0, 0)$ 、 $\vec{r}_2 = (4\text{ cm}, 0)$ 、 $\vec{r}_3 = (0, 3\text{ cm})$ 、 $\vec{r}_4 = (4\text{ cm}, 3\text{ cm})$ ；真实声源在  $\vec{p} = (2\text{ m}, 1.5\text{ m})$ ；声速  $c = 343\text{ m/s}$ ，采样率  $f_s = 16\text{ kHz}$ （1 个采样点  $= 1/f_s = 62.5\text{ }\mu\text{s}$ ，折合成路程  $c/f_s = 343/16000 = 0.0214375\text{ m}$ ——后文所有“采样点”都靠这个数换算）。

第 1 步：算出几何真值。声源在  $\vec{p}$ ，各麦到声源的距离由勾股定理（ $d_i = \|\vec{p} - \vec{r}_i\|$ ）：

| 麦 $i$ | 算式                                       | $d_i\text{ (m)}$ |
|-------|------------------------------------------|------------------|
| 1     | $\sqrt{2^2 + 1.5^2} = \sqrt{6.25}$       | 2.500000         |
| 2     | $\sqrt{1.96^2 + 1.5^2} = \sqrt{6.0916}$  | 2.468117         |
| 3     | $\sqrt{2^2 + 1.47^2} = \sqrt{6.1609}$    | 2.482116         |
| 4     | $\sqrt{1.96^2 + 1.47^2} = \sqrt{6.0025}$ | 2.450000         |

（ $\vec{r}_4$  那行数值凑得正好： $6.0025 = 2.45^2$  恰好开方开尽，方便手算核对。）

麦对  $(i, j)$  的真实 TDOA（到达时间差）折成采样点：

$$\tau_{ij} = \frac{d_i - d_j}{c} f_s = \frac{d_i - d_j}{0.0214375}。$$

这里的  $\tau_{ij}$  以采样点为单位。

例如麦对  $(1, 2)$ ： $\tau_{12} = (2.500000 - 2.468117)/0.0214375 = 0.031883/0.0214375 \approx +1.4873$  个采样点——物理含义：声波到麦 1 的路程比到麦 2 长 3.19 cm，所以麦 2 早到约 1.49 个采样点。本例没有生成麦克风波形，也没有运行 GCC-PHAT；这个数是由已知声源位置算出的时差真值，不是实测峰位置。全部 6 对的结果见下表“真值”列。

第 2 步：计算候选点的几何预测。假设声源在候选点  $\vec{r}$ ，预测每对麦的时延

$\tau_{ij}(\vec{r}) = (\|\vec{r}_i - \vec{r}\| - \|\vec{r}_j - \vec{r}\|)f_s/c$ ，再按第 4 步规定的理想峰模型计算对应分数。实际处理录音时，这一步才读取观测得到的 GCC 曲线。

- 候选点 A = (2, 1.5)（就是真源）：距离与第 1 步完全相同，预测的  $\tau_{ij}$  与真值逐对相等；
- 候选点 B = (0.5, 0.5)（离阵列很近的错误点）： $d_1 = \sqrt{0.5^2 + 0.5^2} = 0.707107$ 、  
 $d_2 = \sqrt{0.46^2 + 0.5^2} = 0.679412$ 、 $d_3 = \sqrt{0.5^2 + 0.47^2} = 0.686222$ 、  
 $d_4 = \sqrt{0.46^2 + 0.47^2} = 0.657647\text{ m}$ 。

第 3 步：对比表（单位均为采样点；“错位” = 候选点预测值 - 真值）：

| 麦对 $(i, j)$ | 真值 = A 的预测 | B 的预测   | B 的错位   |
|-------------|------------|---------|---------|
| (1, 2)      | +1.4873    | +1.2919 | -0.1954 |

| 麦对 $(i, j)$ | 真值 = A 的预测 | B 的预测   | B 的错位   |
|-------------|------------|---------|---------|
| (1, 3)      | +0.8342    | +0.9742 | +0.1400 |
| (1, 4)      | +2.3324    | +2.3071 | -0.0252 |
| (2, 3)      | -0.6530    | -0.3177 | +0.3354 |
| (2, 4)      | +0.8451    | +1.0152 | +0.1701 |
| (3, 4)      | +1.4981    | +1.3329 | -0.1652 |


第 4 步：由时延偏差计算得分。为便于手算，这里用理想全带、无窗截断条件下的 sinc 峰模型：真实时延处取值 1，偏离  $\Delta\tau$  个采样点后取  $\sin(\pi\Delta\tau)/(\pi\Delta\tau)$ 。实际 GCC 峰形还受带宽、窗函数、补零和混响影响，因此该模型只用于说明累积过程。

- 候选点 A：6 对麦的预测时延都等于真值，每对贡献 1，SRP 得分 =  $6 \times 1 = \mathbf{6.0000}$ ；
- 候选点 B：6 对的贡献分别为 0.9384、0.9681、0.9989、0.8250、0.9531、0.9557，合计 **5.6392**。各麦对的时延偏差不同，累积得分低于 A；
- 镜像方向候选点  $(-1, 1.5)$  的六对贡献约为 0.12、0.83、0.10、0.05、0.86、0.12，合计约 2.08。其中多组预测时延已落到 sinc 主峰之外。

结果解释：候选点 B 虽然与真源相距较远，得分仍接近峰值，说明小孔径阵列的空间响应峰可能较宽。错位量以采样点计时，16 kHz 下 1 个采样点对应约 2.14 cm 的传播距离，因此实际系统常用亚采样插值（§ 4.2 细节①）。网格间隔、插值方式和 GCC 峰宽都会影响最终定位精度。

本手算采用 sinc 峰便于逐项计算；图14采用高斯 GCC 峰便于显示连续的等时差亮带。两者都在演示式(4-1)的麦对累积过程，数值不能相互代入。

图14 SRP-PHAT 定位过程（独立米级分布式阵列例）  
 4 m × 3 m 四麦；源(5.5, 3.8) m；c=343 m/s；高斯峰 $\sigma=166.7 \mu\text{s}$ ；90×68网格



图示说明：图 14 是与前述厘米级手算独立的米级分布式阵列例。四麦坐标为 (0,0)、(4,0)、(0,3)、(4,3) m，真实声源为 (5.5,3.8) m，声速取 343 m/s。

图 14 (a) 给出几何和候选点；图 14 (b) 在  $x \in [-0.5, 7.0]$  m、 $y \in [-0.5, 5.2]$  m 的  $90 \times 68$  网格上扫描。每个麦对的理想高斯 GCC 峰标准差取  $1/6000 \text{ s} \approx 166.7 \mu\text{s}$ 。亮带对应单个麦对的近似等时差轨迹，多条亮带在真实声源附近相交。

色标是六个麦对 GCC 取值的平均数，不是实测声功率。峰宽还取决于设定的 GCC 峰宽和网格间隔。

计算口径：全网格计算量约随  $N_{\text{grid}}M(M-1)/2$  增长。网格间距只给出离散化误差的下限，实际误差还受孔径、混响、信噪比、标定和插值影响。工程上常先粗扫，再只在主峰邻域细扫；节省多少计算量取决于两级网格范围，不能脱离配置给出固定倍数。

SRP 的计算量随网格点数和麦对数增加。若已获得可靠且已配对的 TDOA，也可以采用 § 4.4 的几何解算，直接估计位置坐标。

## 4.4 两阶段法的几何解算

从时延到几何：一对麦克风测得时延差  $\tau_{ij}$ ，意味着声源到两麦的距离差为  $c\tau_{ij}$ 。平面上“到两定点距离差为常数”的轨迹是双曲线，三维中是双曲面。图14(b)用理想化高斯 GCC 峰给这些等时差轨迹赋予有限宽度，再累加六个麦对的分

以麦 1 为参考，各麦对的 TDOA 构成方程组：

$$\|\vec{p} - \vec{r}_i\| - \|\vec{p} - \vec{r}_1\| = c\tau_{i1}, \quad i = 2..M。$$

- $\vec{p}$ : 待求声源位置，远场只需方向；
- $\vec{r}_i$ : 第  $i$  个麦的坐标，已知且依赖标定；
- 方程共  $M - 1$  个。对一般近场非线性方程，二维至少需要 3 只不共线麦、三维至少需要 4 只不共面麦，且某些几何仍可能有多个候选解。方程数超过位置维数后可用最小二乘吸收测量误差；
- 下面的 Chan 线性化还引入参考距离这一附加未知量，因此其第一阶段无正则最小二乘在二维至少需要 4 只麦、三维至少需要 5 只麦，并要求线性方程组满列秩。

#### 算例 4-2: TDOA 几何解算数值例——两个时延怎么变成一个方向

§ 4.4 给出了方程组  $\|\vec{p} - \vec{r}_i\| - \|\vec{p} - \vec{r}_1\| = c\tau_{i1}$ 。远场条件下它退化为非常简单的几何：每对麦给出方向的一个“方向余弦”分量。用具体数字走一遍。

设定：3 麦直角布置， $\vec{r}_1 = (0, 0)$ （参考麦）、 $\vec{r}_2 = (4 \text{ cm}, 0)$ 、 $\vec{r}_3 = (0, 4 \text{ cm})$ ；测得  $\tau_{21} = +0.0583 \text{ ms}$ 、 $\tau_{31} = +0.0825 \text{ ms}$ （按 § 4.4 的约定， $\tau_{i1}$  = 声波到麦  $i$  的路程减去到麦 1 的路程，再除以  $c$ ）。求声源方向。

第 1 步：时延折成路程差。

$$c\tau_{21} = 343 \times 0.0583 \times 10^{-3} = 0.0199969 \text{ m} \approx 2.00 \text{ cm}$$

$$c\tau_{31} = 343 \times 0.0825 \times 10^{-3} = 0.0282975 \text{ m} \approx 2.83 \text{ cm}$$

物理读法：声波到麦 2 比到麦 1 多走约 2.00 cm，到麦 3 比到麦 1 多走约 2.83 cm。

第 2 步：除以间距，得方向余弦的绝对值。远场平面波假设下，麦 1-2 连线（ $x$  轴）方向上的路程差就是  $d|u_x|$ （ $u_x$  是声源方向单位向量  $\vec{u}$  在  $x$  轴上的分量，即“方向余弦”），于是：

$$\frac{c\tau_{21}}{d} = \frac{0.0199969}{0.04} = 0.4999 \approx 0.5 \quad \Rightarrow \quad \theta_x = \arcsin(0.5) = 30.0^\circ$$

$$\frac{c\tau_{31}}{d} = \frac{0.0282975}{0.04} = 0.7074 \approx \frac{\sqrt{2}}{2} \quad \Rightarrow \quad \theta_y = \arcsin(0.7074) \approx 45.0^\circ$$

（这里  $\theta_x$  是从麦 1-2 连线的正横方向起算的角度，与 § 4.2 的约定一致。给定的两个  $\tau$  本身是四舍五入过的：精确的  $30^\circ$  对应  $\tau_{21} = 0.058309 \text{ ms}$ ，精确的  $45^\circ$  对应  $\tau_{31} = 0.082461 \text{ ms}$ ，保留 3 位有效数字正是题给数值。）

第 3 步：定符号。方向余弦的符号由时延的正负直接读出： $\tau_{21} > 0$  说明声波到麦 2 的路程更长，即声源在麦 1 那一侧、沿  $-x$  方向；同理声源沿  $-y$  方向。所以

$$u_x = -0.5, \quad u_y = -\frac{\sqrt{2}}{2} \approx -0.7071$$

第 4 步：一致性检查与第三个分量。方向余弦必须满足  $u_x^2 + u_y^2 + u_z^2 = 1$ 。先检查：

$u_x^2 + u_y^2 = 0.25 + 0.5 = 0.75 \leq 1$  ✓——若这一步算出大于 1，说明时延测量有野值，方程无解，这是工程上最便宜的自检。于是

$$u_z = \pm\sqrt{1 - 0.75} = \pm 0.5$$

$\pm$  号无法由数据决定：三只麦共面，平面上下两侧镜像的方向产生完全相同的 TDOA——这正是 § 3.1 所说平面阵“上下镜像模糊”的具体实例。取上半球  $u_z = +0.5$ 。

第 5 步：合成方位角与俯仰角。本书从  $+y$  正横方向起算，朝  $+x$  为正，因此三维单位方向写成

$$\vec{u} = [\cos \phi_{\text{el}} \sin \theta, \cos \phi_{\text{el}} \cos \theta, \sin \phi_{\text{el}}]^\top。$$

代入  $\vec{u} = (-0.5, -\sqrt{1/2}, 0.5)$ ，方位角应交换通常数学坐标中的两个参数：

$$\theta = \text{atan2}(u_x, u_y) = \text{atan2}(-0.5, -\sqrt{1/2}) \approx -144.74^\circ。$$

俯仰角为  $\phi_{\text{el}} = \arcsin(u_z) = 30^\circ$ 。回代得到  $u_x = \cos 30^\circ \sin(-144.74^\circ) \approx -0.5$ 、 $u_y = \cos 30^\circ \cos(-144.74^\circ) \approx -0.7071$ 。

若改从  $+x$  轴逆时针量角，才使用  $\varphi = \text{atan2}(u_y, u_x) \approx -125.26^\circ$ 。两种角描述同一方向，但零点与正向不同；转换关系为  $\theta = 90^\circ - \varphi$  后按  $360^\circ$  取模。不能将后一数值直接传给本书的导向矢量函数。NumPy 的 [atan2 参数定义](#) 明确第一参数对应常规坐标的纵坐标，第二参数对应横坐标。

第 6 步：代回几何模型验证。把这个方向代回平面波公式  $c\tau_{i1} = -\vec{u} \cdot \vec{r}_i$ ：

- $c\tau_{21} = -\vec{u} \cdot \vec{r}_2 = -(-0.5) \times 0.04 = 0.020000 \text{ m} \Rightarrow \tau_{21} = 0.020000/343 = 0.058309 \text{ ms}$   
 $\approx +0.0583 \text{ ms} \checkmark$
- $c\tau_{31} = -\vec{u} \cdot \vec{r}_3 = -(-0.7071) \times 0.04 = 0.028284 \text{ m} \Rightarrow \tau_{31} = 0.028284/343 = 0.082461 \text{ ms}$   
 $\approx +0.0825 \text{ ms} \checkmark$

完全回到给定值。

近场修正的量级：若声源位于  $L = 2 \text{ m}$  处的  $\vec{p} = 2\vec{u} = (-1, -1.4142, 1) \text{ m}$ ，按球面波精确计算得  $\tau_{21} = 0.0592 \text{ ms}$ 、 $\tau_{31} = 0.0830 \text{ ms}$ 。它们分别比远场结果大 1.5% 和 0.7%，说明不同麦对不能共用一个固定修正比例； $L = 10 \text{ m}$  时差异约为 0.3%。

本例阵列孔径为  $\sqrt{4^2 + 4^2} \approx 5.66$  cm，2 m 已满足较大的距离孔径比，因此残余曲率误差处于百分比量级。

怎么解：方程带根号、非线性，有两条经典路线。

路线 1：Chan 算法。把方程平方并重组为线性方程组。第一阶段把参考距离  $R_1 = \|\vec{p} - \vec{r}_1\|$  当作附加未知量，与位置一起求解；第二阶段再利用  $R_1$  与位置的平方关系做加权修正。

二维时未知量为  $(p_x, p_y, R_1)$ ，所以第一阶段至少要  $M - 1 \geq 3$ ，即 4 只麦；三维至少要 5 只麦。计数只是必要条件，还需阵列几何使矩阵满列秩、通道同步、TDOA 与麦对关联正确，并满足点声源近场模型。低噪声且误差模型匹配时，两步加权最小二乘可接近相应的 CRLB。Chan & Ho, IEEE TSP 1994

可跳过 · 进阶★★：平方消根号的线性化展开（以  $i = 2$  为例）

记  $R_1 = \|\vec{p} - \vec{r}_1\|$ 。原方程  $\|\vec{p} - \vec{r}_i\| = r_{i,1} + R_1$  两边平方得

$$\|\vec{p}\|^2 - 2\vec{r}_i^\top \vec{p} + \|\vec{r}_i\|^2 = r_{i,1}^2 + 2r_{i,1}R_1 + R_1^2。$$

又有  $R_1^2 = \|\vec{p}\|^2 - 2\vec{r}_1^\top \vec{p} + \|\vec{r}_1\|^2$ 。代入后， $\|\vec{p}\|^2$  在等式两边恰好相消。整理得

$$(\vec{r}_1 - \vec{r}_i)^\top \vec{p} - r_{i,1}R_1 = \frac{1}{2}(r_{i,1}^2 + \|\vec{r}_1\|^2 - \|\vec{r}_i\|^2)。$$

左边对未知量  $(\vec{p}, R_1)$  是线性的，右边全是已知量。把  $i = 2..M$  的行擦起来，即得线性方程组  $\mathbf{G} [\vec{p}^\top, R_1]^\top = \vec{h}$ 。

例如  $M = 3$ 、估计二维位置时，未知量  $(p_x, p_y, R_1)$  共 3 个，方程  $i = 2, 3$  只有 2 行， $\mathbf{G}$  是  $2 \times 3$  的矮胖矩阵。这就是为什么二维定位至少要 4 只麦，即三对时延：方程数  $M - 1$  必须不少于未知量个数。第一步最小二乘先解该线性方程组，第二步再用  $R_1 = \|\vec{p} - \vec{r}_1\|$  的平方关系加权修正一次。

以  $i = 2$  代入算例 4-2 的数验量纲： $\vec{r}_1 = (0, 0)$ 、 $\vec{r}_2 = (0.04, 0)$ 、 $r_{2,1} = 0.02$  m。右边  $= \frac{1}{2}(0.02^2 + 0 - 0.04^2) = \frac{1}{2}(0.0004 - 0.0016) = -0.0006$  m<sup>2</sup>；左边  $(\vec{r}_1 - \vec{r}_2)^\top \vec{p} - 0.02R_1$  也是“米×米”量级，等式两边单位均为 m<sup>2</sup>。

路线 2：泰勒级数迭代。从 SRP-PHAT 的粗解出发，在当前估计点  $\vec{p}_k$  把方程一阶展开，用最小二乘解修正量并更新：

$$\vec{p} \leftarrow \vec{p} + (\mathbf{J}^\top \mathbf{J})^{-1} \mathbf{J}^\top \boldsymbol{\varepsilon}。$$



令观测距离差为  $\vec{z} = [c\tau_{21}, \dots, c\tau_{M1}]^\top$ ，模型预测为  $\vec{h}(\vec{p})$ ，这里定义残差  $\epsilon = \vec{z} - \vec{h}(\vec{p})$ ，即实测减预测； $\mathbf{J} = \partial \vec{h} / \partial \vec{p}$ 。在这个残差定义下，上式使用加号。若把残差定义成预测减实测，更新式必须改用减号。 $\mathbf{J}$  的第  $i$  行是两个单位方向向量之差。

上面的逆矩阵写法只在  $\mathbf{J}$  满列秩且条件良好时适用。基线方向过于单一或声源处于不利位置时，实现应用 QR/SVD、伪逆或阻尼 Gauss – Newton，而不是显式求  $\mathbf{J}^\top \mathbf{J}$  的逆。

各 TDOA 共用同一参考麦时，其测量误差通常相关；若已知或能估计误差协方差，应用加权最小二乘。迭代还需要足够接近真解的初值。要抗野点需配合稳健损失或剔除机制，普通最小二乘本身并不抗野点。

几何怎样放大测量误差（GDOP，geometric dilution of precision，几何精度因子）：把 TDOA 模型在真值附近线性化后，位置或角度误差由几何雅可比矩阵传播。麦对基线过短、方向过于相似或声源位于端射等不利方位时，雅可比矩阵接近秩亏，固定的时延误差会被放大。对双麦、正横附近的一维角度模型，有

$$\text{var}(\theta) \approx \left( \frac{c}{d \cos \theta} \right)^2 \sigma_\tau^2$$

- $\sigma_\tau$ ：时延估计误差的标准差； $d$ ：麦间距。这个一阶近似来自  $d\theta = \frac{c}{d \cos \theta} d\tau$ 。因此角度标准差相对正横方向放大  $1/|\cos \theta|$ ，角度方差放大  $1/\cos^2 \theta$ ；例如  $\theta = 60^\circ$  时，标准差放大 2 倍，方差放大 4 倍。端射附近  $\cos \theta \rightarrow 0$ ，线性化失效，有限时延偏差应按反正弦精确计算并检查物理时延上限（见 § 4.11 第 1 题）。4 cm 间距下 10  $\mu\text{s}$  的时延误差在正横附近对应约  $5^\circ$  的角度误差。

这条近似只说明基线和方位对局部角度误差的影响。分布式阵列可以用更长基线降低部分几何放大，但厘米级位置误差还要求足够带宽、同步、标定、信噪比和可控多径；不能只由阵列尺寸推出。

两阶段几何法需要先把各麦对 TDOA 归属于同一声源；多源时数据关联会显著变难。§ 4.5 的 Bartlett 和 Capon 改为空间扫描，可直接从多个谱峰寻找候选方向。

## 4.5 波束扫描类：Bartlett 与 Capon

Bartlett：在固定频点  $f_k$ ， $P_B(f_k, \theta) = \vec{a}^H(f_k, \theta) \hat{\mathbf{R}}(f_k) \vec{a}(f_k, \theta)$ 。按式(2-2)， $\hat{\mathbf{R}}(f_k) = L^{-1} \sum_{\ell=1}^L \vec{x}(f_k, \ell) \vec{x}^H(f_k, \ell)$ ； $L$  是快拍数， $\ell$  是快拍索引。

矩阵对角元是各通道自功率，非对角元是通道间互功率。二次型给出按候选导向矢量转向后的平均输出功率。若各方向的  $\|\vec{a}(f_k, \theta)\|$  相同，省略统一归一化不改变峰位。

Bartlett 的典型分辨尺度由该阵列的常规波束主瓣决定。Rayleigh 类判据是约定的分辨标准，不是所有噪声和检测条件下的绝对物理边界。下面的单频算例为减轻记号负担，省略固定的  $f_k$ 。

Capon/MVDR 谱：对每个候选方向设计“该方向增益为 1、输出功率最小”的滤波器：

$$P_C(f_k, \theta) = \frac{1}{\vec{a}^H(f_k, \theta) \hat{\mathbf{R}}^{-1}(f_k) \vec{a}(f_k, \theta)}。 \quad (4-2)$$

这个式子来自约束优化：最小化  $\vec{w}^H \hat{\mathbf{R}} \vec{w}$ ，同时要求  $\vec{w}^H \vec{a}(\theta) = 1$ 。拉格朗日乘子法给出  $\vec{w} = \hat{\mathbf{R}}^{-1} \vec{a} / (\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a})$ ；把该权重代回输出功率，得到上面的 Capon 谱。完整推导见 § 5.4 和式 (5-3)。

候选方向与真实源方向一致时，无失真约束保留该源，因此最小输出功率较大；方向不匹配时，优化器可进一步压低输出功率。 $\hat{\mathbf{R}}$  是  $M \times M$  协方差矩阵。

Capon 在模型准确、快拍充分时通常比 Bartlett 得到更窄的谱峰。快拍不足、相干多径或协方差病态时，应加正则并检查稳健性。

这里的“加载”必须注明口径。绝对加载用  $\hat{\mathbf{R}} + \delta \mathbf{I}$ ， $\delta$  与协方差元素同量纲；相对加载用  $\hat{\mathbf{R}} + \eta \text{tr}(\hat{\mathbf{R}}) \mathbf{I} / M$ ， $\eta$  无量纲。

图11的 Capon 采用相对加载  $\eta = 10^{-6}$ ；图15的超指向波束也采用相对加载，但两图的数据模型不同，不能比较裸谱值。不同信号幅度下直接复用同一个绝对  $\delta$  会改变实际正则强度，因此比较实现时不能只比较裸数值。

可跳过 · 进阶★★★：拉格朗日求解三步：

第 1 步——列函数、求梯度：拉格朗日函数  $L(\vec{w}, \lambda) = \vec{w}^H \hat{\mathbf{R}} \vec{w} + \lambda(1 - \vec{w}^H \vec{a}) + \lambda^*(1 - \vec{a}^H \vec{w})$ ；对  $\vec{w}^H$  求梯度并置零得  $\hat{\mathbf{R}} \vec{w} = \lambda \vec{a}$ ，即  $\vec{w} = \lambda \hat{\mathbf{R}}^{-1} \vec{a}$ ；

第 2 步——代约束、定倍数：把上式代入约束  $\vec{w}^H \vec{a} = 1$ ，定出  $\lambda = 1 / (\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a})$ ，于是最优权重  $\vec{w}_{\text{opt}} = \hat{\mathbf{R}}^{-1} \vec{a} / (\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a})$ ；

第 3 步——代回、看相消：最小输出功率  $\vec{w}_{\text{opt}}^H \hat{\mathbf{R}} \vec{w}_{\text{opt}}$  里分子分母的  $\hat{\mathbf{R}}$  与  $\hat{\mathbf{R}}^{-1}$  相消一次，剩下  $1 / (\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a})$ ；Capon 谱把这个“最小功率”直接当作该方向的空间谱值——干扰方向的功率被约束优化主动压掉，谱峰于是比 Bartlett 尖锐。

算例 4-3：Bartlett vs Capon 最小可算例——同一个  $\hat{\mathbf{R}}$ ，两种读法

§ 4.5 说 Capon 谱“更尖”，尖多少？用一个  $2 \times 2$  的例子把两种谱在同一组数据上各算两个点。

设定：\$M = 2\$ 麦，间距 \$d = \lambda/2\$；单源在 \$\theta = 0^\circ\$（正横方向），信号功率归一为 1，各麦独立白噪声功率 \$\sigma^2 = 0.25\$（\$\text{SNR} = 10\lg(1/0.25) \approx 6\text{ dB}\$）。导向矢量（§ 2.6 相位差公式的 \$M = 2\$ 版本）：

$$\vec{a}(\theta) = [1, e^{+j\pi \sin \theta}]^\top.$$

这里先横写两个分量，再以 \$^\top\$ 表示列向量。

第 1 步：写出协方差矩阵。源在正横、两麦同相（\$\sin 0^\circ = 0\$，\$\vec{a} = [1, 1]^\top\$），于是 \$\hat{\mathbf{R}} = \vec{a}\vec{a}^H + \sigma^2\mathbf{I}\$：非对角元 \$= 1 \times 1 = 1\$（两麦的二阶互矩，尚未除以各自标准差），对角元 \$= \text{信号} + \text{噪声} = 1 + 0.25\$：

$$\hat{\mathbf{R}} = \begin{bmatrix} 1.25 & 1 \\ 1 & 1.25 \end{bmatrix}$$

第 2 步：Bartlett 谱读两个点。\$P\_B(\theta) = \vec{a}^H \hat{\mathbf{R}} \vec{a}\$。

- 源方向 \$\theta = 0^\circ\$：\$\vec{a} = [1, 1]^\top\$，\$P\_B = \text{四个元素之和} = 1.25 + 1 + 1 + 1.25 = \mathbf{4.5}\$，其中对角自功率贡献 \$2 \times 1.25 = 2.5\$，非对角互功率贡献 \$2 \times 1 = 2\$；
- 错开方向 \$\theta = 30^\circ\$：\$\vec{a} = [1, +j]^\top\$。先算 \$\hat{\mathbf{R}}\vec{a} = [1.25 + j, 1 + 1.25j]^\top\$，再左乘 \$\vec{a}^H = [1, -j]\$：\$P\_B = (1.25 + j) - j(1 + 1.25j) = 2.5\$。虚部精确相消，符合厄米二次型为实数的自检。

源方向与 \$30^\circ\$ 候选方向的谱值比 \$= 4.5/2.5 = 1.8\$，约 2.6 dB；\$30^\circ\$ 处仍为峰值的 56%，说明这个两阵元示例的主峰较宽。这里只比较两个方向，不把 \$30^\circ\$ 误称为旁瓣峰。

第 3 步：Capon 谱读同样两个点。先求逆：\$\det \hat{\mathbf{R}} = 1.25^2 - 1^2 = 0.5625\$，

$$\hat{\mathbf{R}}^{-1} = \frac{1}{0.5625} \begin{bmatrix} 1.25 & -1 \\ -1 & 1.25 \end{bmatrix}$$

- 源方向 \$\theta = 0^\circ\$：\$\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a} = \frac{1.25 - 1 - 1 + 1.25}{0.5625} = \frac{0.5}{0.5625} \approx 0.889\$，\$P\_C = 1/0.889 = \mathbf{1.125}\$；
- 错开方向 \$\theta = 30^\circ\$：\$\hat{\mathbf{R}}^{-1} \vec{a} = [1.25 - j, -1 + 1.25j]^\top / 0.5625\$，再左乘 \$\vec{a}^H = [1, -j]\$，得 \$\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a} = 2.5/0.5625 \approx 4.444\$，所以 \$P\_C = \mathbf{0.225}\$。

源方向与 \$30^\circ\$ 候选方向的谱值比 \$= 1.125/0.225 = \mathbf{5.0}\$，约 7.0 dB；\$30^\circ\$ 处只剩峰值的 20%。

为什么这个例子的 Capon 对比更明显：Bartlett 在 \$30^\circ\$ 候选方向计算固定导向矢量的二次型，不会根据观测协方差主动抑制 \$0^\circ\$ 强源；Capon 则在 \$30^\circ\$ 保持无失真响应的同时最小化总输出功率。代入本例得到权重 \$[0.5 - 0.4j, -0.4 + 0.5j]^\top\$，对 \$0^\circ\$ 的复响应为 \$0.1 - 0.1j\$，功率响应为 0.02。因此这里是降低强源泄漏，而不是在 \$0^\circ\$ 形成精确零点。

保留一条目标无失真约束后， $M = 2$  最多再施加一条独立零陷约束；Capon 没有显式施加这条约束。阵元增多会增加空间自由度，但实际抑制深度和谱峰形状仍受约束数、快拍数和模型失配影响。

扫描类方法的分辨率受阵列孔径和频率限制。§ 4.6 的 MUSIC 与 ESPRIT 可在模型匹配时获得更窄的峰，但对源数、标定误差和相干源更敏感。

## 4.6 子空间类：MUSIC 与 ESPRIT

本节先在单个频点分别讲 MUSIC 的正交检验和 ESPRIT 的子阵移位关系，二者都需要源数、有效协方差和相应阵列条件。随后讨论宽带语音怎样合并多个频点；宽带聚焦不能代替前两种窄带方法各自的输入检查。

窄带方法一：MUSIC（多重信号分类，Schmidt, 1986）

思想三步：

1. 由数据估协方差矩阵  $\hat{\mathbf{R}}$  并特征分解：前  $K$  个大特征值张成信号子空间  $\mathbf{E}_s$ ，其余  $M - K$  个小特征值张成噪声子空间  $\mathbf{E}_n$ （ $K$  为源数）；
2. 利用模型关键性质——真实方向上的导向矢量与噪声子空间正交；
3. 构造伪谱，分母在真实 DOA 处趋零，出现尖峰：

$$P_{MV}(\theta) = \frac{1}{\vec{a}^H(\theta) \mathbf{E}_n \mathbf{E}_n^H \vec{a}(\theta)}。 \quad (4-3)$$

正交检验的含义是：候选导向矢量若属于信号子空间，它在理想噪声子空间上的投影为零，伪谱分母趋近零；候选方向不匹配时，该投影通常非零，伪谱保持有限。

第 2 步为什么成立：信号模型下协方差矩阵是  $\mathbf{R} = \mathbf{A} \mathbf{S} \mathbf{A}^H + \sigma^2 \mathbf{I}$ ，其中  $\mathbf{A}$  是  $M \times K$  的导向矢量矩阵、 $\mathbf{S}$  是  $K \times K$  的源协方差矩阵。

只有当  $K < M$ 、 $\mathbf{A}$  列满秩且  $\mathbf{S}$  满秩时， $\mathbf{A} \mathbf{S} \mathbf{A}^H$  的秩才等于  $K$ ，其列空间才等于  $\text{span}(\mathbf{A})$ 。空间白噪声项  $\sigma^2 \mathbf{I}$  只平移特征值，不改变特征向量；其余  $M - K$  个特征向量因此与真实导向矢量正交。

相干源使  $\mathbf{S}$  降秩，彩色噪声也不再只平移特征值。这两种情况都破坏上述论证。[Schmidt 的 MUSIC 原始论文](#)。

输入的样本协方差必须是厄米半正定矩阵；秩亏不等于非法，但负特征值若超出舍入容差，就不再代表有效功率。教学 `music_spectrum` 会拒绝这类矩阵，也会拒绝全零协方差，因为此时无法由数据区分信号与噪声子空间。Bartlett 教学接口采用同样的协方差有效性检查。

可跳过 · 进阶★★：正交三步的秩论证（分步说明）

1.  $\text{rank}(\mathbf{A}\mathbf{S}\mathbf{A}^H) \leq \min(M, K, K) = K$ 。非相干源时， $\mathbf{S}$  满秩且  $\mathbf{A}$  列满秩，取等号。于是  $\mathbf{R}$  的前  $K$  个大特征值对应信号，其余  $M - K$  个特征值等于  $\sigma^2$ 。
2. 信号子空间  $\text{span}(\mathbf{E}_s) = \text{span}(\mathbf{A})$ ，且  $\mathbf{E}_n \perp \mathbf{E}_s$ ，所以  $\mathbf{E}_n^H \mathbf{A} = \mathbf{0}$ 。
3. 分母  $\|\mathbf{E}_n^H \vec{a}(\theta)\|^2$  在真实 DOA 处为零，偏离时通常大于零，扫描  $\theta$  因而得到峰值。

源数  $K$  对应  $K$  维信号子空间和  $M - K$  维噪声子空间；算例 4-4 的  $M = 3$ 、 $K = 1$  给出特征值 3, 0, 0。相干源会使  $\mathbf{S}$  秩降低，第一步的等号不再成立，这正是空间平滑所处理的条件。

#### 算例 4-4：MUSIC 最小可算例——逐项验证正交性

§ 4.6 的 MUSIC 基于一个条件：真实方向的导向矢量与噪声子空间正交。用一个  $3 \times 3$  的例子把这句话算成看得见的数字。

设定： $M = 3$  麦均匀线阵，间距  $d = \lambda/2$ （ $\lambda$  为波长）；单源，方向  $\theta = 0^\circ$ （正横方向，即垂直于阵列连线）；无噪声。

第 1 步：写出导向矢量的显式形式。 $d = \lambda/2$  时相邻麦相位差为  $\psi = \frac{2\pi d}{\lambda} \sin \theta = \pi \sin \theta$ （§ 2.6 的相位差公式），以麦 1 为参考：

$$\vec{a}(\theta) = [1, e^{+j\pi \sin \theta}, e^{+j2\pi \sin \theta}]^\top.$$

这里横写分量，再以  $^\top$  表示列向量。

代入  $\theta = 0^\circ$ （ $\sin \theta = 0$ ）： $\vec{a}(0^\circ) = [1, 1, 1]^\top$ ——正横方向声波同时到达三只麦，相位全同，符合直觉 ✓。

第 2 步：写出无噪声协方差矩阵。无噪声时快拍  $\vec{x} = \vec{a}s$ ，于是  $\mathbf{R} = E\{\vec{x}\vec{x}^H\} = \vec{a}\vec{a}^H \cdot E\{|s|^2\}$ ，取信号功率归一（ $E\{|s|^2\} = 1$ ）即  $\mathbf{R} = \vec{a}\vec{a}^H$ 。第  $m$  行第  $n$  列为  $e^{j(m-n)\pi \sin \theta}$ ：

$$\mathbf{R} = \begin{bmatrix} 1 & e^{-j\pi \sin \theta} & e^{-j2\pi \sin \theta} \\ e^{+j\pi \sin \theta} & 1 & e^{-j\pi \sin \theta} \\ e^{+j2\pi \sin \theta} & e^{+j\pi \sin \theta} & 1 \end{bmatrix} \xrightarrow{\theta=0^\circ} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

以下第 3~6 步始终固定真实声源在  $0^\circ$ ，使用右侧的全 1 协方差矩阵。第 6 步只改变候选方向的导向矢量；观测数据及其协方差不随扫描角重新估计。

第3步：口算特征值。两个事实就够：① $\mathbf{R} = \vec{a}\vec{a}^H$  是秩 1 矩阵（每一列都是  $\vec{a}$  的倍数——这里三列完全相同），秩 1 意味着只有一个非零特征值；②特征值之和 = 矩阵的迹（对角线之和） $= 1 + 1 + 1 = 3$ 。所以三个特征值必是

$$\lambda_1 = 3, \quad \lambda_2 = \lambda_3 = 0.$$

此处的  $\lambda$  表示矩阵特征值，不是波长；字母复用见 § 2.3。

“1 个大特征值 = 1 个源”——这就是 § 4.6 “前  $K$  个大特征值张成信号子空间”在最简单情形下的样子。（附注：若加入功率为  $\sigma^2$  的白噪声，特征值变成  $3 + \sigma^2, \sigma^2, \sigma^2$ ——大特征值被整体抬高，噪声子空间的地板露出来，数值验证  $\sigma^2 = 0.01$  时得 3.01, 0.01, 0.01，与理论一致。）

第4步：找出噪声子空间。零特征值对应的特征向量满足  $\mathbf{R}\vec{e} = \vec{0}$ ，即“与  $[1, 1, 1]^T$  正交的向量”。任取两个互相也正交的：

$$\vec{e}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}, \quad \vec{e}_3 = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix}$$

验证  $\mathbf{R}\vec{e}_2$ ：每一行都是  $1 \times 1 + 1 \times (-1) + 1 \times 0 = 0$ ，再除以  $\sqrt{2}$  仍是 0 ✓； $\mathbf{R}\vec{e}_3$ ：每行  $1 + 1 - 2 = 0$  ✓；且  $\vec{e}_2^H \vec{e}_3 = (1 \times 1 + (-1) \times 1 + 0 \times (-2)) / \sqrt{12} = 0$  ✓。  $\{\vec{e}_2, \vec{e}_3\}$  张成噪声子空间  $\mathbf{E}_n$ 。

第5步：见证正交性。拿真实方向  $\theta = 0^\circ$  的导向矢量与噪声子空间做内积：

$$\begin{aligned} \vec{a}^H(0^\circ) \vec{e}_2 &= \frac{1}{\sqrt{2}} (1 \times 1 + 1 \times (-1) + 1 \times 0) = 0 \\ \vec{a}^H(0^\circ) \vec{e}_3 &= \frac{1}{\sqrt{6}} (1 \times 1 + 1 \times 1 + 1 \times (-2)) = 0 \end{aligned}$$

两个内积精确为零——MUSIC 伪谱的分母  $\vec{a}^H \mathbf{E}_n \mathbf{E}_n^H \vec{a} = |0|^2 + |0|^2 = 0$ ，因此理想无噪模型下真实方向的谱值趋于无穷大。



第 6 步：对照——候选方向不匹配时投影非零。试  $\theta = 30^\circ$ ：  $\psi = \pi \sin 30^\circ = \pi/2$ ,

$\vec{a}(30^\circ) = [1, e^{+j\pi/2}, e^{+j\pi}]^\top = [1, j, -1]^\top$ 。逐个算：

$$\begin{aligned}\vec{a}^H(30^\circ) \vec{e}_2 &= \frac{1}{\sqrt{2}} (1 \times 1 + (-j) \times (-1) + (-1) \times 0) \\ &= \frac{1+j}{\sqrt{2}}, \\ \left| \frac{1+j}{\sqrt{2}} \right|^2 &= 1.\end{aligned}$$

$$\begin{aligned}\vec{a}^H(30^\circ) \vec{e}_3 &= \frac{1}{\sqrt{6}} (1 \times 1 + (-j) \times 1 + (-1) \times (-2)) \\ &= \frac{3-j}{\sqrt{6}}, \\ \left| \frac{3-j}{\sqrt{6}} \right|^2 &= \frac{5}{3}.\end{aligned}$$

分母  $= 1 + \frac{5}{3} = \frac{8}{3} \approx 2.667 \neq 0$ ，伪谱  $P_{MU}(30^\circ) = \frac{1}{8/3} = \frac{3}{8} = 0.375$ 。  $0^\circ$  处在理想无噪模型下趋于无穷大，而  $30^\circ$  处是有限值 0.375；数值上对应“匹配方向的噪声子空间投影为零，不匹配方向的投影非零”。实际有限快拍和噪声会使峰值有限。

如果真实声源改到  $30^\circ$ ，才应重新由  $\vec{a}(30^\circ) = [1, j, -1]^\top$  构造观测协方差：

$$\mathbf{R}(30^\circ) = \vec{a}(30^\circ) \vec{a}^H(30^\circ) = \begin{bmatrix} 1 & -j & -1 \\ j & 1 & -j \\ -1 & j & 1 \end{bmatrix}.$$

它仍是秩 1、厄米且半正定的矩阵，特征值也为 3, 0, 0，但三列不相同，噪声子空间也要重新求。例如上面针对  $0^\circ$  选出的  $\vec{e}_2$  满足  $\vec{a}^H(30^\circ) \vec{e}_2 = (1+j)/\sqrt{2} \neq 0$ ，因此不能沿用它作新矩阵的噪声特征向量。矩阵的对角元为非负实数，非对角元满足  $R_{nm} = R_{mn}^*$ ；这一检查不要求三列相同。

**能力：**在高 SNR、快拍充分、源数正确、标定准确且没有未处理相干多径时，MUSIC 的谱峰可窄于同一阵列的常规波束主瓣。这种超分辨能力仍依赖孔径和阵列几何：孔径决定不同方向导向矢量的可区分程度，SNR、快拍数、源间隔和模型失配共同决定有限数据下能否分开近邻源。

三个适用边界：

- 需事先知道源数  $K$ 。可按 § 4.1.1 比较特征值间隙，或使用 AIC/MDL 信息准则。低 SNR、快拍不足和相干源都会削弱特征值分界，进而造成子空间维数误判；

- 相干源失效：混响多径使信号子空间塌缩。设反射是直达信号延迟 3 个采样点后再衰减一半， $s_2(n) = 0.5s_1(n - 3)$ 。在频点  $f$  上定义  $q(f) = 0.5e^{-j2\pi f(3/f_s)}$ ，则  $S_2(f) = q(f)S_1(f)$ 。若  $E\{|S_1(f)|^2\} = 1$ ，两路源谱的协方差为

$$\mathbf{S}(f) = \begin{bmatrix} 1 & q^*(f) \\ q(f) & |q(f)|^2 \end{bmatrix}.$$

第二行等于第一行乘  $q(f)$ ，因此行列式为零、秩为 1。非对角元含有 3 个采样点延迟造成的复相位，只有  $q(f) = 0.5$  的特殊频点才能直接写成实数 0.5。于是  $\mathbf{ASA}^H$  随之降为秩 1，两个物理传播方向只对应一个非零信号特征值。

空间平滑可在均匀线阵上处理这种相干性：切成  $L$  个重叠子阵，分别估计协方差再平均。恢复可用秩至少需要子阵数  $L \geq K$ ，并且子阵长度  $P = M - L + 1 > K$ ，还需不同方向等模型条件成立（§ 4.1.1）。

代价是有效子阵孔径减小；恢复两个非零特征值并不等于保持原阵列的全部分辨能力。

- 对模型误差敏感。麦位标定、相位响应或阵列流形不准确时，真实方向不再满足理想正交关系。与 SRP-PHAT 比较时，应在相同失配条件下检验方向误差，不能只比较理想协方差上的谱峰宽度。

变体：root-MUSIC 把 ULA 的 MUSIC 分母写成  $z$  域多项式，选择靠近单位圆的根并由根相位反演角度，从而免去角度网格扫描。宽带语音则需在多个频点合并信息；非相干叠加、CSSM/WAVES 聚焦和 TOPS 的处理方式不同，下一节分别说明。

### 专栏：NormMUSIC——宽带逐频叠加时，为什么要先归一化

语音是宽带信号，而窄带 MUSIC 每次只处理一个频点。非相干平均先在各频点计算 MUSIC 伪谱，再跨频率相加。各频点的阵列电尺寸、信噪比和伪谱尺度不同：低频谱峰可能较宽，高频谱峰可能较窄且数值更大。未经归一化直接相加时，少数峰值尺度较大的频点可能主导结果，低可靠度频点的旁瓣也可能形成伪峰。

本书把“NormMUSIC”限定为 pyroomacoustics 0.10.0 中 `frequency_normalization=True` 的实现口径：各频点伪谱先归一化，再沿频率轴平均。[pyroomacoustics 0.10.0 NormMUSIC 官方文档](#)。其他论文或软件的同名实现可能采用不同归一化，比较前应核对源码。频率归一化会削弱不同频点绝对峰高的差异，但也可能把纯噪声频点放大，因此仍需按信噪比或峰背比筛选频点。

宽带合并前的频点筛选：归一化伪谱接近平坦时，该频点提供的方向信息有限。可按信噪比、谱峰与背景之比或统计可靠度选择频点；门限应在目标数据集上验证，不能把某个经验值当作通用标准。

## 窄带方法二：ESPRIT（借助旋转不变技术估计信号参数，Estimation of Signal Parameters via Rotational Invariance Techniques）

先看单源情形：两个平移子阵接收的信号子空间只差一个由子阵位移决定的相位因子，求出该因子即可反演方向，不需要逐角度扫描。

多源时，每个源对应  $\Psi$  的一个特征值。具体地， $\mathbf{E}_{s2} = \mathbf{E}_{s1} \Psi$ ，其中  $\mathbf{E}_{s1}$ 、 $\mathbf{E}_{s2}$  是两个子阵的信号子空间， $\Psi$  是二者之间的旋转矩阵；其特征值相位由子阵位移和 DOA 决定。

ESPRIT 的优点是免谱搜索。它仍需准确知道两子阵的相对位移与取向，并要求阵列具有平移不变结构。相干源需要先做去相关处理，宽带或球阵扩展也会受混响和模型误差影响。[Roy 与 Kailath 的 ESPRIT 原始论文](#)。

算例：ESPRIT 最小数字链（ $M = 3$ 、 $d = \lambda/2$ ）：子阵 1 取麦 {1,2}，子阵 2 取麦 {2,3}。在本章导向矢量约定下，旋转因子为  $\Psi = e^{+j\pi \sin \theta}$ ，因此反演式是

$$\theta = \arcsin\left(\frac{\arg \Psi}{\pi}\right)。$$

$\theta = 0^\circ$  时  $\Psi = 1$ ，反演得  $0^\circ$ ； $\theta = 30^\circ$  时  $\Psi = +j$ 、 $\arg \Psi = +\pi/2$ ，反演得  $30^\circ$ 。

不能对  $\arg \Psi$  取绝对值，否则会丢失左右方向的符号。在此理想、单位模的移位关系中，若交换两子阵的次序，旋转因子变为共轭，反演式中的符号也要同时改变。

实际估计到的信号子空间会有误差，移位后的两段通常不能精确相等。单源时把两段看作列向量  $\vec{e}_1, \vec{e}_2$ ，选择复数  $\hat{\Psi}$  使  $\|\vec{e}_2 - \vec{e}_1 \hat{\Psi}\|_2^2$  最小。展开平方并对  $\hat{\Psi}^*$  求导，得到  $\vec{e}_1^H \vec{e}_1 \hat{\Psi} = \vec{e}_1^H \vec{e}_2$ ；只要  $\vec{e}_1 \neq \vec{0}$ ，解为  $\hat{\Psi} = (\vec{e}_1^H \vec{e}_2) / (\vec{e}_1^H \vec{e}_1)$ 。

多源时，对应目标是  $\min_{\Psi} \|\mathbf{E}_{s2} - \mathbf{E}_{s1} \Psi\|_F^2$ 。若  $\mathbf{E}_{s1}$  满列秩，可解正规方程；病态时应检查奇异值，而不能盲目求逆。[Roy 与 Kailath 的 ESPRIT 原始论文](#)。

E04-09：用两行子阵手算 ESPRIT 最小二乘解。先用本书构造的理想信号子空间向量

$\vec{e} = [1, j, -1]^T$ ，令  $\vec{e}_1 = [e_1, e_2]^T$ 、 $\vec{e}_2 = [e_2, e_3]^T$ ；再把第三项改为  $-0.9 + 0.1j$ ，其余两项不变。两次分别计算  $\vec{e}_1^H \vec{e}_1$ 、 $\vec{e}_1^H \vec{e}_2$ 、 $\hat{\Psi}$ 、残差范数和反演方向。取  $d = \lambda/2$ ，数字只代表子空间扰动的教学示例，不代表某个快拍数或 SNR 下的统计误差。

参考答案：两次都有  $\vec{e}_1 = [1, j]^T$ ，故分母为  $1 + |j|^2 = 2$ 。理想情形分子是  $1 \cdot j + (j)^*(-1) = 2j$ ，于是  $\hat{\Psi} = j$ ，残差为 0，方向为  $\arcsin((\pi/2)/\pi) = 30^\circ$ 。

扰动后分子是  $j + (-j)(-0.9 + 0.1j) = 0.1 + 1.9j$ ，故  $\hat{\Psi} = 0.05 + 0.95j$ 。残差向量为  $[-0.05 + 0.05j, 0.05 + 0.05j]^T$ ，范数为  $\sqrt{0.01} = 0.1$ ；相位约  $86.987^\circ$ ，方向约  $28.90^\circ$ 。

这说明最小二乘只能拟合被扰动的移位关系，不保证角度仍精确。若交换子阵次序，新的最小二乘因子一般不等于原因子的共轭（分母也会改变），但这里其相位变号；反演公式须同时改变符号。代码入口为 `exercises_spatial.py` 的 E04-09，并用 `doa.py::esprit_ula` 核对由这两个向量构造的协方差。

上式还假定相位没有空间混叠。 $d > \lambda/2$  时，主值相位可能对应多个角度，必须限制搜索区间或使用额外频率消歧。

MUSIC 与 ESPRIT 的上述推导基于窄带模型。宽带语音需要在频率维度合并信息，下一节讨论相干与非相干宽带处理。

## 宽带聚焦：跨频率合并子空间信息

MUSIC、ESPRIT 的基本推导采用窄带假设：在单个频点内，导向矢量  $\vec{a}(f, \theta)$  固定。宽带语音的波长随频率变化，同一个物理方向在不同频点对应不同的阵列流形。NormMUSIC 在各频点独立计算伪谱后再合并，不能利用跨频率的相干信息。聚焦类方法先把不同频点的导向矢量映射到共同的参考频率，再合并协方差并进行特征分解。

聚焦矩阵的思想。选定参考频率  $f_0$  后，对每个频点  $f_j$  构造变换矩阵  $\mathbf{T}(f_j)$ ，使选定角度集合上的  $\mathbf{T}(f_j)\vec{a}(f_j, \theta) \approx \vec{a}(f_0, \theta)$ 。各频点协方差经  $\mathbf{T}\hat{\mathbf{R}}(f_j)\mathbf{T}^H$  变换后再合并。

CSSM (coherent signal-subspace method, 相干信号子空间方法) 是代表方法；经典构造通常依赖初始 DOA 或聚焦角集合，初值偏差会造成聚焦损失。[Wang 与 Kaveh 的 CSSM 原始论文](#)。

初始角从哪来。CSSM 可先用 Bartlett 或 SRP-PHAT 粗扫得到候选角，再据此构造聚焦集合。是否迭代、迭代次数和停止条件属于具体实现，不能假定一两轮必然收敛。

相干源为什么影响聚焦子空间法。混响多径中的直达与反射可能相干，使源协方差矩阵降秩（§ 4.6 的  $2 \times 2$  例子中，完全相干时  $\mathbf{S}$  的秩从 2 降为 1）。若聚焦后仍直接使用降秩协方差，MUSIC 可能合并谱峰或产生方向偏差。均匀线阵可在各频点聚焦前做空间平滑以恢复可用秩，代价是有效子阵孔径减小。

TOPS：不使用聚焦初值。TOPS (test of orthogonality of projected subspaces, 投影子空间正交性检验) 用候选方向构造频率间变换，检验变换后的信号子空间与各频点噪声子空间的正交性。它不需要 CSSM/WAVES 的初始值预处理，但性能仍取决于频点选择、快拍数、源数和信噪比。[Yoon、Kaplan 与 McClellan 的 TOPS 原始论文](#)。

WAVES：聚焦后加权信号子空间。WAVES (weighted average of signal subspaces, 加权信号子空间平均) 把聚焦矩阵与按可靠度加权的信号子空间结合，以降低传统 CSSM 对聚焦误差的敏感性；它仍属于需要初始值预处理的相干宽带方法，不能写成免聚焦初值。[Di Claudio 与 Parisi 的 WAVES 原始论文](#)。

选择时先区分是否有可靠初值和阵列是否满足各方法的模型：CSSM 与 WAVES 依赖聚焦预处理，TOPS 不需要该初值。相干源还会使频点内源协方差降秩；ULA 可尝试空间平滑，但必须同时检查子阵长度、源数上界和损失的有效孔径。

子空间法完成宽带扩展后，§ 4.7 转向稀疏重构与数据驱动定位。

## 4.7 稀疏重构、学习式定位与实现边界

先看离散网格、连续参数和学习式定位分别改变了哪一步。随后 § 4.7.1 检查这些方法也可能遇到的近场模型失配，§ 4.7.2 说明本书代码与外部实现的输入和验证边界。

**稀疏与连续参数方法：角度网格从哪里来**

**稀疏重构**：把角度网格化 ( $N_{\text{grid}} \gg M$  个候选方向)，每个方向摆一个“模板”（导向矢量）。真实信号只来自其中少数几个方向，因此“用模板拼出观测数据”的系数向量是稀疏的，绝大多数位置为零。用  $\ell_1$  正则或稀疏贝叶斯学习 (SBL, sparse Bayesian learning, 稀疏贝叶斯学习) 估计少数非零位置，即得 DOA。

不同算法不能共用“单快拍、超分辨、免源数估计”这一组无条件标签。例如 [L1-SVD 原论文](#) 先用奇异值分解汇总多个时间或频率样本，再做稀疏重构；SBL 的输入统计量、超参数和选峰规则又不同。

稀疏先验可在条件合适时产生窄于常规波束的峰，也可不显式预设源数，但结果仍受正则强度、信噪比、样本数和停止或选峰规则影响。共同代价是优化开销与离散网格失配。

**网格无关方法：FRIDA 与原子范数**。离散稀疏重构存在网格失配：真实方向是连续值，若声源位于两个候选角之间，估计能量可能分散到相邻网格并产生角度偏差。网格越细，离散误差通常越小，但字典规模和计算量随之增加。网格无关方法直接在连续角度域中估计参数，避免预先量化角度。

两条代表路线如下：



- FRIDA (finite rate of innovation DOA, 有限新息率波达方向估计) 把任意阵列的空间协方差元素线性变换为均匀采样的指数和, 再从连续参数反解方向, 不需要离散角度网格。其可辨识条件和误差受阵列几何、源数、标定与噪声影响。[Pan et al. 的 FRIDA 原始论文](#)。
- 原子范数 (atomic norm) 把连续频率或角度上的复指数导向矢量集合定义为“原子”, 用这些原子的最小加权组合解释观测。对满足结构条件的线阵模型可转化为半定规划, 定义与条件见 [Tang 等 2013](#) 及其阵列扩展 [Yang 与 Xie 2015](#)。

两类方法避免了预设角度网格的量化误差, 但仍有阵列结构、最小间隔、样本数和噪声条件, 计算量也通常高于固定网格扫描。实时性、精度和源数条件必须绑定到具体实现与数据, 不能用统一的 1° 门限选择算法。

### 学习式定位：输入特征、输出形式与泛化

DNN 定位：网络用带方向标签的多通道数据学习噪声、混响与直达声线索之间的映射。训练规模、房间覆盖范围和阵列几何决定其泛化边界。

| 路线                | 代表（骨干 × 输出格式）                                                                                                                        | 做法                                                                                   | 效果特征                                              |
|-------------------|--------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|---------------------------------------------------|
| GCC-PHAT 特征 + DNN | Vesperini、Vecchiotti 等 ( <i>Computer Speech &amp; Language</i> , vol.49, 2018)：MLP (multilayer perceptron, 多层感知机) /CNN 骨干 × 角度网格分类输出 | 多麦对 GCC-PHAT Patterns 向量 → MLP/CNN 角度网格分类                                            | 输出分辨率由角度类别间距决定；抗噪性取决于训练与测试条件                      |
| 球面 SRP 图 + 等变 CNN | icoDOA：二十面体 CNN 骨干 × soft-argmax 连续方向回归                                                                                              | 先把多麦对信息形成二十面体网格上的 SRP-PHAT 图；网络对正二十面体的 60 个离散旋转对称保持等变，再用 soft-argmax 把末层球面分布变成连续三维方向 | 这 60 个离散旋转近似而不等于任意连续三维旋转；收益须在同一数据和网格上与直接取 SRP 峰比较 |
| 直达声 IPD 估计        | IPDnet (IEEE/ACM TASLP, 2024)：交替窄带/全带层 × 多轨直达声 IPD 输出                                                                                | 从多通道谱估计多个声源的直达声麦间相位差 (DP-IPD)，再结合已知阵列几何转换为位置；原文还给出可变麦数与拓扑的训练方式                       | 不是“粗分类 + 细回归”；跨房间和跨阵列结果须按原文数据及未见阵列设置核对            |



| 路线    | 代表（骨干 × 输出格式）                                                                                | 做法                                                                                                                                                              | 效果特征                                                  |
|-------|----------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------|
| 相位图分类 | Chakrabarty & Habets<br>2017/2019: CNN 骨干<br>× 多标签方位类别输出                                     | 多通道 STFT 相位图 →<br>CNN 的 sigmoid 方位类别后验；原文把方位离散成类别，并在已知声源数时取后验最高的若干类，不是连续 DOA 回归                                                                                 | 可输出多个离散方向；类别间距限制输出网格，性能数字只适用于原论文的数据、阵列和噪声条件           |
| 序列模型  | CRNN/Transformer 骨干<br>× ACCDOA 输出格式<br>(ACCDOA = activity-coupled Cartesian DOA, 活动耦合笛卡尔方向) | 向量长度表示活动强度，方向表示 DOA；此处沿用外部笛卡尔示意从 $+x$ 朝 $+y$ 计角的约定， $30^\circ$ 、活动值 0.9 的输出为 $0.9(\cos 30^\circ, \sin 30^\circ) \approx (0.78, 0.42)$ ，同一方向在本书角度约定下为 $60^\circ$ | 原始 ACCDOA 每类每帧一条向量，不能表示同类同时多源；multi-ACCDOA 用多轨输出处理该情况 |

球面 SRP 图 + 等变 CNN 的使用边界：它解决的是把经纬度球面图直接送入平面 CNN 时邻域畸变、极区采样和旋转模式不一致的问题。相对解析 SRP 基线，它不替换麦对几何累积，而是在二十面体网格上学习空间响应的球面局部模式。

成立条件是阵列坐标与声速模型已知、训练与推理使用兼容的球面采样，并且训练数据覆盖部署时的声源数、混响和噪声。

最小比较应在同一批多通道数据上生成相同分辨率的 SRP-PHAT 球面图，以直接取峰为基线，再训练 icoDOA，并在未参与训练的旋转和房间上用同一角误差与检出规则比较。若没有这些数据覆盖或算力，解析 SRP-PHAT 更适合作为可解释基线。算法定义、60 个离散旋转等变性和 soft-argmax 输出见 [Díaz-Guerra、Miguel 与 Beltrán 的原论文](#)。

官方 [icoDOA 代码仓库](#) 给出的最小入口是 `1sourceTracking_icoCNN.py`。README 记录的验证环境为 Python 3.8.1、PyTorch 1.8.1，并依赖 gpuRIR；合成训练需准备 LibriSpeech，实录测试需准备 LOCATA，输入图分辨率由脚本参数 `r` 控制，预训练模型和对应结果位于 `models/`、`results/`。这些版本和路径是仓库的复现口径，不是对其他版本的兼容性保证。

该仓库采用 [AGPL-3.0](#)，并明确定位为论文复现代码而非通用软件库。本书将固定版本源码保留在独立的 `codes/upstream/_downloads/icodoa/` 研究目录，保留上游许可，不将其改标为本书教学代码的许可，也不把模型或录音授权与源码授权合并。许可证与环境信息核实于 2026-09-22，完整提交为 `04d1a89594c78ae3cf42f07d94c3737bdc1f7c82`；取得源码不代表本机已经完成训练或论文复现。

**数据驱动结果的比较范围：**定位网络必须在相同数据集、阵列、信噪比、混响、训练数据和误差指标下比较。上表只归纳输入与输出形式，不给出跨论文排名。使用时还需评估标注成本、跨房间泛化和模型复杂度。

卷积空间谱定位可参见 Chakrabarty & Habets [期刊论文](#)；IPDnet 见 Wang、Yang 与 Li 的 [IEEE/ACM TASLP 2024 正式论文](#)；ACCDOA 见 Shimada et al., [ICASSP 2021](#)。

**任务和数据：不同届 DCASE 的输出不能混用**

SELD（声事件定位与检测，sound event localization and detection）同时估计事件类别、方向和活动时段。STARSS23 是 DCASE 2023 Task 3 使用的带距离元数据示例；当届正式输出并未要求距离。任务定义、划分和指标应按[当届官方任务页](#)核对，不能把某一届设置外推为长期不变的“前沿”。

这些方法的源码也应分别阅读。IPDnet 的作者实现位于 `Audio-WestlakeU/FN-SSL` 的 `IPDnet/`，固定与可变阵列网络分别在 `FixedAarryIPDnet.py`、`VariableArrayIPDnet.py`，训练入口是 `runIPDnetOn.py` / `runIPDnetOff.py`；先检查阵列、麦对顺序与相位标签，再读网络。[IPDnet 作者目录](#)。

DCASE2022 基线则通过 `seldnet_model.py` 与 `cls_data_generator.py` 连接 multi-ACCDOA 输出和 ADPIT 训练标签，不能直接把模型轨号当作第 9 章的持久身份。[DCASE2022 官方基线](#)。

最小输出检查可以先做手算：单轨二维 ACCDOA 预测 `(0.433,0.25)`，按上表从  $+x$  朝  $+y$  计角的约定，其方向约为  $30^\circ$ ；换成本书从  $+y$  朝  $+x$  计角，用  $90^\circ$  减去外部方位角，得到约  $60^\circ$ 。向量的模约为 0.5，角度正确不表示活动判定一定通过。再放入两个同类别同时发声的方向，单轨输出无法表示二者，需要多轨输出、允许的标签置换与重复预测合并。

换到 DCASE2025 基线时，每轨的第三个音频输出是距离，不是旧三维方向中的  $z$  分量；把它一起归一化会混淆方向和距离。[DCASE2025 输出层](#)。

上述三个基线的固定提交、读码顺序、数据条件、最小实验和许可缺口分别记录在[空间处理研究文档](#)。IPDnet 根 README 仅给出 MIT 字样，两个 DCASE 基线在本次检查中未建立明确再分发授权，因此暂保留官方源码索引，不自动复制；不能把这一限制误写成“没有官方实现”。

## DCASE 任务变化（核实于 2026-09-21）

- 2024 Task 3 把[声源距离估计](#)纳入正式输出。
- 2025 Task 3 改用[常规视频内容中的双声道音频](#)。因双声道几何存在前后与上下歧义，该届只评水平方位，同时保留距离。
- 2026 Task 3 转向[语义声学成像](#)。

2026 开发阶段提供 32 通道 Eigenmike 录音和高分辨率声学图标签。评测阶段不提供标签、元数据或 32 通道录音，只给 4 通道四面体阵列/一阶 Ambisonics 音频，视听赛道另给视频。

每个提交 JSON 的 annotations 条目必须写 metadata\_frame\_index、category\_id、score 和 segmentation；其中 segmentation 是一个或多个由 [x,y,intensity] 三元组构成的空间掩码，distance 为可选字段。

这些变化说明，学习式定位的“输出”已经从稀疏 DOA 向量扩展到距离和稠密空间图。复现时必须绑定届次，不能只写“DCASE Task 3”。

**距离估计：从方向扩展到三维位置：**远场平面波的相对时延模型只给方向；近场球面波的通道间时延还随距离变化（见 § 2.7）。网络也可能利用波前曲率、直达混响比（DRR）和绝对声级。

绝对声级对应的距离线索依赖未知声源级别；在 § 2.7 所用的同一声源功率同时缩放直达声与混响声的理想模型下，DRR 是两者之比，声源功率会约去。实际 DRR 仍受房间、源与麦克风指向性、距离及录音噪声影响，不能当作单独可靠的距离刻度。距离结果必须在明确的数据集、误差定义和范围内报告，不能与只估方向的结果直接比较。

### 4.7.1 近场模型失配：角度相同，距离仍会改变导向矢量

取 3 麦 ULA，阵元横坐标为  $[-5, 0, 5]$  cm；声源距阵列中心  $r = 20$  cm，方位  $\theta = 30^\circ$ （从正横起算）。声源坐标为  $(r \sin \theta, r \cos \theta) = (0.10, 0.1732)$  m。三个传播距离约为  $[0.22913, 0.20000, 0.18028]$  m，因此相对中心麦的路程差为

$$\delta_{\text{sph}} = [+29.13, 0, -19.72] \text{ mm}.$$

若误用远场平面波，预测值是  $-x_m \sin \theta$ ，即  $[+25, 0, -25]$  mm。两者的路程差均方根误差为

$$\sqrt{\frac{(29.13 - 25)^2 + 0^2 + (-19.72 + 25)^2}{3}} \approx 3.87 \text{ mm}.$$

相当于约  $11.3 \mu\text{s}$ ；在 4 kHz ( $\lambda \approx 85.8$  mm) 处对应约  $16.2^\circ$  的均方根相位误差。

锚点算法：角度 × 距离球面扫描。为把“加入距离维度”变成可复算步骤，仍取上面的 3 麦阵列，并假定单个点声源、自由场、已知声速  $c = 343 \text{ m/s}$ 、通道同步且已校准；这个最小例只用 TDOA，不使用  $1/d_m$  幅度线索。对候选  $(r, \theta)$ ：

- 1. 把候选点写成  $\vec{p}(r, \theta) = (r \sin \theta, r \cos \theta)$ ；
- 2. 计算到第  $m$  个麦的距离  $d_m(r, \theta) = \|\vec{p}(r, \theta) - [x_m, 0]^\top\|$ ，并以中心麦  $m = 2$  为参考，得到相对路程差  $\delta_m = d_m - d_2$ ；
- 3. 将观测相对路程差记作  $\delta_m^{\text{obs}}$ ，对每个候选计算 TDOA 均方根失配

$$J(r, \theta) = \sqrt{\frac{1}{3} \sum_{m=1}^3 \left( \frac{\delta_m(r, \theta) - \delta_m^{\text{obs}}}{c} \right)^2},$$

这里把参考麦  $m = 2$  的恒零项  $\delta_2 - \delta_2^{\text{obs}} = 0$  也计入三通道均方根，所以分母为 3。若只对两个非参考麦取均方根，分母应改为 2， $J$  的数值会整体乘以  $\sqrt{3/2}$ ，但最小点不变。

实际 SRP 或宽带最大似然会用多频复数观测和噪声权重打分；这里的  $J$  只用于手算几何核心。算法选择  $J$  最小的网格点。

真值  $(0.20 \text{ m}, 30^\circ)$  给出  $\delta^{\text{obs}} = [29.13, 0, -19.72] \text{ mm}$ ，即相对时延约  $[84.9, 0, -57.5] \mu\text{s}$ 。取角度网格  $\{20^\circ, 30^\circ, 40^\circ\}$ 、距离网格  $\{0.20, 0.50, 2.00\} \text{ m}$ ，逐格代入上式：

| 距离 $r$ | $\theta = 20^\circ$ | $\theta = 30^\circ$ | $\theta = 40^\circ$ |
|--------|---------------------|---------------------|---------------------|
| 0.20 m | 18.6 $\mu\text{s}$  | 0.0 $\mu\text{s}$   | 17.1 $\mu\text{s}$  |
| 0.50 m | 18.6 $\mu\text{s}$  | 6.8 $\mu\text{s}$   | 19.7 $\mu\text{s}$  |
| 2.00 m | 20.1 $\mu\text{s}$  | 10.2 $\mu\text{s}$  | 21.1 $\mu\text{s}$  |

因此这个无噪、真值落在网格上的例子选中  $(0.20 \text{ m}, 30^\circ)$ 。它说明角度相同不等于近场导向矢量相同，也说明网格范围和间距本身会限制输出精度。

若真实位置落在格点之间，应做局部细化或连续优化，不能把粗网格误差归因于观测噪声。球面波下联合估计角度与距离的宽带最大似然模型可参见 [Chen、Hudson 与 Yao 2002](#)。

距离不可观测边界：当  $r \rightarrow \infty$  时， $d_m - d_2 \rightarrow -x_m \sin \theta$ ，对  $r$  的导数趋近 0；不同大距离候选的 TDOA 因而趋于同一平面波值。此时表中同角度的失配差会继续缩小，距离维度形成平坦谷。孔径很小、带宽或 SNR 不足、通道相位未标定时也会出现相同现象；算法应报告距离低置信度或只输出 DOA，而不是把搜索边界当成可靠距离。

4.7.2 可执行基线的输入契约、回退与外部实现边界

本书的原创 NumPy 基线位于 `doa.py`。`gcc_phat` 对应 § 4.2，返回的正时延严格表示  $\tau_{12} = t_1 - t_2$ ；它对输入补零、计算 PHAT 加权的周期逆变换，再截取物理时延范围，可选三点插值。有限补零只对未加权互相关保证线性相关等价，不能为 PHAT 保证有限支撑。

`srp_phat` 对应式(4-1)，输入多通道谱的形状固定为 通道 × 频点 × 帧。`bartlett_spectrum`、`capon_spectrum`、`music_spectrum` 和 `esprit_ula` 分别对应 § 4.5、§ 4.6；平面波和近场导向矢量来自 `geometry.py`。完整小例与手算回归见 `ch02_05_baselines.py` 和 `test_codes_doa_beam.py`。

接入实际录音时还要固定 WAV 数值口径、采样率、通道顺序、麦克风坐标及单位、参考麦、坐标轴、声速和时间戳。GCC 必须按物理孔径裁剪 lag，并同时输出峰值、峰背比和有效频带；SRP 还要记录阵元对、二维或三维搜索范围、网格单位、插值和粗到细规则。扫描谱要记录快拍窗口、频带合并、源数、选峰间距和加载口径。

Capon/MVDR 使用线性求解，不显式形成矩阵逆；协方差奇异或超过接口的条件数上限且没有适当加载时，示例代码会报错。调用方应明确选择增加快拍、相对加载、保持上次可靠估计或退回 SRP/Bartlett，不能把 NaN 当成方向。

MUSIC 使用厄米特征分解 `eigh`，不需要协方差可逆。例如无噪声单源的秩一协方差仍可用于已知源数的理想子空间演示，不能一概要求先加载。能完成特征分解也不证明真实源数、白噪声或非相干模型成立；这些前提仍需单独检查。

定位源码分为本书教学实现和按完整提交号取得的外部参考。后者保存在 `codes/upstream/_downloads/` 的独立工作目录；版本、代码许可与入口见 `SOURCES.lock.json`，具体阅读步骤和验证方案见[空间处理与追踪研究](#)。取得源码、运行一次示例和复现论文结论应分别记录。

| 本章方法                    | 外部源码入口                                                                                                               | 读码时先核对什么                   |
|-------------------------|----------------------------------------------------------------------------------------------------------------------|----------------------------|
| AIC/MDL、空间平滑、root-MUSIC | doatools 的<br><code>estimation/source_number.py</code><br>、 <code>preprocessing.py</code> 、<br><code>music.py</code> | 特征值排序、有效快拍数、子阵数与长度、半波长默认间距 |
| CSSM、WAVES、TOPS         | pyroomacoustics 的<br><code>doa/cssm.py</code> 、 <code>waves.py</code> 、<br><code>tops.py</code>                      | 初始峰、参考频点、频点筛选与协方差是否同步、迭代停止 |



| 本章方法           | 外部源码入口                                                                                           | 读码时先核对什么                          |
|----------------|--------------------------------------------------------------------------------------------------|-----------------------------------|
| FRIDA          | pyroomacoustics 的<br>doac/frida.py 与<br>tools_fri_doa_plane.py；原论文<br>库 LCAV/FRIDA 的 doac/fri.py | 协方差可见度、连续角恢复、截断<br>阶数、随机初值和重建残差   |
| 分层 SRP 与持续定位   | ODAS 的<br>src/module/mod_ssl.c、<br>src/signal/scan.c 及设备配置                                       | 粗细网格、保留候选数、麦对筛<br>选、插值与几何坐标       |
| 组稀疏与协方差匹配      | doatools 的<br>estimation/sparse.py                                                               | 快拍模型与功率模型的区别、正则<br>参数、字典归一化和求解器状态 |
| 多快拍、多频 SBL     | 作者 SBL 的<br>SBL_MF_Python/sbl.py::SBL 与<br>SBL_MF_matlab/SBL_v4.m                                | 字典、快拍轴顺序、给定源数、剪<br>枝与噪声方差更新       |
| 合并麦对的 SMP-PHAT | 作者 smpphat 的<br>src/system.c::smp_construct/sm<br>p_call                                         | 远场、等长平行基线、反向共轭、<br>坐标单位与分组容差      |

这些实现不能共用一个未经转换的角度和数组约定。例如本书麦位置为 通道 × 空间维度，pyroomacoustics 为 空间维度 × 通道；doatools 的 root-MUSIC 还要求 ULA，不能因它不扫描角度就用于任意阵列。定位输出应保留源数未满足、统计无效、优化不可行和峰歧义等状态，不应始终给一个看似确定的角度。

固定版本也可能有实现缺陷。研究文档登记了 pyroomacoustics 0.10.0 的 CSSM/WAVES 频点剔除与协方差下标对应、TOPS 真实 FFT bin 与列表下标对应的静态疑点，并给出最小下标推演；尚未完成外部包完整声学回归，因此不把这些入口写成已经通过设备验收的实现。原子范数和神经定位则仍需按具体论文确认优化器、模型、训练数据与许可。来源为 doatools 作者文档、pyroomacoustics 官方仓库、ODAS 官方仓库，源码核实于 2026-09-22。

SBL 作者实现输入为 通道 × 候选方向 × 频点 的字典，以及 通道 × 快拍 × 频点 的观测，不能直接传入本书 通道 × 频点 × 帧 的 STFT。其 Nsource 参与选峰和噪声估计，因而不是免源数方案。固定 SBL 核心。

遇到异常大幅快拍时，RobustSBL 提供 Gauss、t、Huber、Tyler 损失的对照入口；不同模式改变快拍权重，不代表能修正错误几何或任意空间有色噪声。RobustSBL 作者实现。



SMP-PHAT (Steered response power by Merging Pairs with PHase Transform) 适合有重复基线的远场阵列。它先合并等长平行麦对的互谱，反向基线取共轭，再减少逆变换和时延查表次数；这不是 SVD 的低秩近似。近场下相同基线位于不同位置时，其距离差不再普遍相等，不能沿用这一合并保证。[2022 预印本 § 3](#)。

本书在 Apple clang/arm64 上编译该固定版本后，发现负时延转无符号查表索引的实现问题，原版全方向分数未通过独立数值对照。它不推翻等效麦对合并的数学条件，但说明不能直接把这个版本当成已验证的可移植实现。具体反例和未改动源码的运行记录见[空间研究文档](#)。

本书还在临时副本中只把 `src/system.c` 的两处负时延查表转换改为有符号整数，保留锁定上游源码不变。修复版在两组固定的四麦远场合成案例中，SRP 与合并麦对 SMP 的全方向分数分别与独立 DFT 对照达到  $2 \times 10^{-4}$  以内的最大绝对误差；两组都选中预定方向。代码与逐例误差见[隔离适配脚本](#)和[运行记录](#)。

这只验证适配版的受控案例；未验证原版、真实录音、不同硬件或运行速度。

上述 SBL 与 SMP-PHAT 代码为 GPL-3.0，RobustSBL 为 MIT；模型、录音与依赖另行核对。SMP 固定构建含 x86 SIMD 选项，RobustSBL 部分模式需要 MATLAB 统计功能。入口、版本、实际运行结果及仍未执行的范围分别见[空间研究文档](#)，不能把源码可读写成实验已通过。

本书的[SBL 合成实验](#)使用四麦半波距线阵、200 个复高斯快拍、 $-80^\circ \sim 80^\circ$  的  $1^\circ$  网格和已知两源数。在总源功率相对单麦白噪声功率为 20 dB 时，一次固定随机输入得到  $-30^\circ$ 、 $30^\circ$  两个正确网格峰；低至 -10 dB 的对照则得到  $-21^\circ$ 、 $31^\circ$ ，且达到 1000 次迭代上限。

这里的停止判据是功率超参数的相对变化，不是定位正确性。每组只有一次实现，各条件共享基础随机输入，不能据此估计成功率；离网格、有色噪声和源数错设的完整结果见研究文档。

## 4.8 定位算法总对比

| 方法       | 主要输入与输出            | 是否预先给源数     | 主要模型条件          | 典型失败模式              | 主要计算项                              |
|----------|--------------------|-------------|-----------------|---------------------|------------------------------------|
| GCC-PHAT | 一对通道 → 一个主 TDOA    | 否           | 同一主导源、带宽足够、通道同步 | 多源峰难配对；混响或低 SNR 选错峰 | FFT:<br>$O(N \log N)$              |
| SRP-PHAT | 多麦对 GCC → 角度/位置响应图 | 找多个峰时需峰选择规则 | 几何与声速已知；搜索区覆盖真值 | 网格误差、宽峰、多径假峰        | 约 $O(N_{\text{grid}} M^2)$ ，另有 GCC |
| Bartlett | 协方差 → 常规空间谱        | 否；找多峰需规则    | 导向模型已知          | 主瓣宽、旁瓣或失配形成假峰       | 建协方差 + 扫描；见下文                      |

| 方法               | 主要输入与输出            | 是否预先给源数  | 主要模型条件                  | 典型失败模式               | 主要计算项                            |
|------------------|--------------------|----------|-------------------------|----------------------|----------------------------------|
| Capon            | 协方差逆 → 自适应空间谱      | 否；找多峰需规则 | 协方差可稳定求逆、导向模型准确         | 少快拍、病态矩阵、相干多径、流形失配   | $O(M^3 + N_{\text{grid}}M^2)$    |
| MUSIC/root-MUSIC | 噪声子空间 → 伪谱/多项式根    | 是        | $K < M$ 、源协方差满秩、白噪声或已白化 | 源数错误、相干源、有限快拍、标定误差   | 特征分解<br>$O(M^3)$ ，<br>MUSIC 另需扫描 |
| ESPRIT           | 两个平移子阵的信号子空间 → 参数  | 是        | 已知且准确的平移不变子阵结构          | 子阵几何失配、相干源、空间混叠      | 特征/奇异值分解，量级常为<br>$O(M^3)$        |
| 稀疏/连续参数法         | 字典或连续阵列模型 → 少量 DOA | 取决于正则与实现 | 稀疏源、阵列模型准确              | 网格失配或优化代价；连续法也有可辨识条件 | 随求解器、网格和迭代次数变化                   |
| 学习型方法            | 多通道特征 → DOA/位置/活动  | 取决于输出格式  | 训练数据覆盖目标阵列、房间和源数        | 训练—测试失配、置信度失准        | 绑定到具体模型、硬件和批量大小报告                |

表中的复杂度只列主导运算量，不等同于延迟、内存或功耗。不同方法的分辨率和鲁棒性不能脱离阵列、SNR、混响、快拍数、搜索网格与训练数据排成统一星级。

以 Bartlett 行为例，若有  $T$  个快拍、每个快拍  $M$  通道，逐帧形成  $\vec{x}\vec{x}^H$  并累加协方差，需要约  $O(TM^2)$  次标量运算。再对  $N_{\text{grid}}$  个候选方向逐一计算  $\vec{a}^H \hat{\mathbf{R}} \vec{a}$ ，直接用稠密矩阵—向量乘法时，每个方向约  $O(M^2)$ ，合计约  $O(N_{\text{grid}}M^2)$ 。因此表中“建协方差 + 扫描”对应

$$O(TM^2 + N_{\text{grid}}M^2)。$$

这是朴素稠密实现的量级，不包括生成导向矢量、找峰和数据搬运；利用阵列结构或复用中间量时，实现代价会改变。

**Cramér – Rao 下界（CRLB）的适用口径。**CRLB 给出指定观测模型下无偏估计量的方差下界。对已知波形、加性白噪声中的时延估计，Fisher 信息随线性 SNR、观测量以及信号的均方根带宽平方增加，因此时延方差下界随这些量减小。

精确系数取决于单通道还是双通道模型、SNR 定义、单边或双边谱、波形是否已知以及是否同时估计未知幅度等条件。条件未写全时，不能把某个系数或微秒数当成通用下界。

对 DOA 而言，还要通过阵列几何的雅可比把时延下界换成角度下界。定性上，SNR、有效带宽、快拍数和有效孔径增大通常会降低方差，端射方向和退化阵列几何会放大误差。

**选择依据：**先检查几何与采样率带来的可观测性，包括孔径、GDOP、空间混叠和亚采样时延能力。算法可在明确模型或先验下改善统计效率，但不能恢复几何中不存在的信息。资源受限且不使用训练数据时，可把 SRP-PHAT 作为基线并验证粗到细搜索；满足源数、秩和标定条件时，可评估 MUSIC/root-MUSIC；学习型方法只有在训练数据覆盖目标阵列、房间、噪声与源数，并在同条件验证集上优于解析基线时，才有采用依据。

**定位置信度与丢轨判据：**单帧给一个方向是不够的，在线系统还要回答“这个方向值不值得信、目标跟丢了没有”。三个常用健康度量如下：

1. **峰值显著度：**主峰与次高峰或背景均值的比值，例如 SRP 功率图或 GCC 峰背比；比值越大，指向越明确；
2. **帧间一致性：**连续多帧 DOA 的方差或中值偏移；平稳声源下跳动大即不可信；
3. **信号存在性：**该方向波束输出的 SNR 或语音存在概率；静音段的方向估计直接弃用。

丢轨阈值必须用本系统验证集标定。满足丢轨条件后，追踪器应转入重捕获状态，而不是继续输出抖动角度。这三类量是第 9 章追踪状态机的输入。

#### 4.8.1 双源分辨率：先规定成功，再重复抽样

图 11 的一次谱形不能给出“能分开多近的两个声源”的成功概率。这里把 § 13.6.2 第 6 题变成 E04-08 的重复试验：固定算法、阵列和选峰规则，只改变两源间隔，逐次记录两个方向是否都被正确找到。MUSIC 的信号与噪声子空间定义见 [Schmidt 1986 原论文](#)；下面的计数和区间是本书仿真，不是该论文的性能数字。

**输入与比较口径。**8 元半波长均匀线阵，单个窄带频点，正横为  $0^\circ$ 。两个互不相关的圆对称复高斯源各有单位功率，角度关于  $0^\circ$  对称，间隔分别为  $50^\circ$ 、 $15^\circ$  和  $8^\circ$ 。

“基线”配置中，每只麦的独立复高斯噪声功率为 0.02，故两源总体功率之和相对单麦噪声功率为  $2/0.02 = 100$ ，即阵列输入 SNR 为 20 dB；每次用 400 个独立快拍构造未中心化样本协方差。第二组“有限样本低 SNR”配置取 64 快拍、单麦噪声功率 2，即阵列输入 SNR 为 0 dB。两组均无混响、通道失配和源间相干。

每组配置各重复 200 次，随机数生成器为 PCG64，基础种子为 20260924，第  $t$  次使用 `SeedSequence([20260924,t])`。同一次抽样的两条源序列和八路噪声同时供三个算法与三个角度间隔使用；改变间隔时只改变导向矩阵。

因此同一配置内的方法比较是配对的，不能把九个方法一间隔组合当成互相独立的九批实验。两种配置分别按相同种子规则生成不同长度的输入，未构造跨配置的独立或配对统计推断；快拍数与噪声功率同时改变，不能把差异只归因于其中一个参数。

选峰与失败定义。在  $-60^{\circ}\sim 60^{\circ}$  的  $0.5^{\circ}$  网格上，Bartlett、相对加载  $10^{-6}$  的 Capon，以及已告知真实源数  $K = 2$  的 MUSIC 各求一条谱。每条谱只选最高的两个局部峰，二者至少相隔  $3^{\circ}$ ；把较小的估计角与较小真角配对，较大的与较大的配对。

两个误差都不超过  $3^{\circ}$  才算成功。只有一个可选峰、选出两个但至少一个超出容差、求谱失败分别记为“峰不足”“位置不匹配”“算法异常”；三类失败均计入 200 次分母。这个规则给所有算法两个峰的数目先验，不检验自动源数估计。

| 配置           | 方法             | 50°：成功/200 | 15°：成功/200 | 8°：成功/200 |
|--------------|----------------|------------|------------|-----------|
| 20 dB、400 快拍 | Bartlett       | 200        | 200        | 0         |
| 20 dB、400 快拍 | Capon          | 200        | 200        | 200       |
| 20 dB、400 快拍 | MUSIC, $K = 2$ | 200        | 200        | 200       |
| 0 dB、64 快拍   | Bartlett       | 200        | 197        | 0         |
| 0 dB、64 快拍   | Capon          | 200        | 200        | 0         |
| 0 dB、64 快拍   | MUSIC, $K = 2$ | 200        | 200        | 99        |

表中每格都是本书固定随机种子的 200 次合成重复试验，不是不同房间或说话人的平均。

0 dB、 $8^{\circ}$  时，Bartlett 的 200 次均为位置不匹配；Capon 有 199 次位置不匹配、1 次峰不足；MUSIC 有 101 次位置不匹配。0 dB、 $15^{\circ}$  时，Bartlett 另有 3 次位置不匹配。其他表格单元没有峰不足或算法异常；所有计数相加均为 200。

每格成功率是成功次数除以 200。用双侧 Wilson 95% 比例区间计算，200/200 的区间约为 [98.1%, 100%]，0/200 约为 [0, 1.9%]，197/200 约为 [95.7%, 99.5%]，99/200 约为 [42.6%, 56.4%]；方法和公式见 [NIST/SEMATECH 手册 § 7.2.4.1](#)。区间描述在这套固定模型下重复抽样的匹配比例，不是某次输出方向正确的后验置信度，也不是方法之间差值的配对置信区间。

在这个特定的高 SNR 合成模型中， $8^{\circ}$  的 Bartlett 谱没有按预定规则给出两个匹配峰；Capon 和 MUSIC 做到了。降低 SNR、减少快拍后， $8^{\circ}$  的 Capon 也没有成功，而 MUSIC 的成功数为 99/200。这说明“超分辨”结论必须连同样本量、噪声、源数先验和选峰规则一起报告，不能从图 11 或一个角间隔推出普适排名。更换相关源、宽带语音、反射或阵列误差，需要重新做同口径试验。

E04-08：独立复算与改参。先手算 20 dB 配置的单麦噪声功率，以及 99/200 的观察成功率；再运行 `doa_resolution_trials.py`，用两组命令分别核对九个方法—间隔组合的计数直方图与 Wilson 区间：

```
.venv/bin/python -m codes.examples.doa_resolution_trials --snapshots 400 --snr-db 20
.venv/bin/python -m codes.examples.doa_resolution_trials --snapshots 64 --snr-db 0
```

然后只改 `--snapshots` 或 `--snr-db` 中的一项重跑，保持种子、角度与峰匹配规则固定；解释新旧配置中唯一变化的因素。脚本只输出 JSON，不生成音频或图，也不把单次谱峰高度当作功率排名。

参考答案。两个单位功率源的总信号功率为 2，20 dB 的线性 SNR 为 100，因此噪声功率是  $2/100 = 0.02$ 。99/200 是 49.5%，该观察比例的双侧 Wilson 95% 区间约为 42.6%~56.4%，计算分母必须保留失败的 101 次。若改参后结果变化，只能归于新旧之间实际改变的配置；一次固定种子的变化不能证明总体性能改善。

## 4.9 MDL 源数估计：逐候选评分与数值例

本节把 § 4.1.1 的源数选择写成可复算步骤。输入是在同一频点估计的  $M \times M$  样本协方差的特征值，以及用于估计它的独立快拍数  $N$ 。MDL 输出候选信号子空间维数，不直接输出方位，也不保证等于房间里的物理声源数。

**模型与适用条件。**采用已知零均值、独立同分布的圆对称复高斯观测  $\vec{x}_n \in \mathbb{C}^M$ 。空间噪声协方差为  $\sigma^2 \mathbf{I}$ ，其中  $\sigma^2 > 0$  未知；噪声与源信号不相关，阵列流形  $\mathbf{A}$  满列秩，源协方差  $\mathbf{S}$  正定，源数  $K < M$ 。

在这些条件下， $\mathbf{R} = \mathbf{A} \mathbf{S} \mathbf{A}^H + \sigma^2 \mathbf{I}$  有  $M - K$  个相等的总体噪声特征值。有限快拍下，这些样本特征值通常不再完全相等。

样本协方差取  $\hat{\mathbf{R}} = N^{-1} \sum_{n=1}^N \vec{x}_n \vec{x}_n^H$ ，不另行估计并减去样本均值。由于它的秩不超过  $N$ ， $N \geq M$  是满秩的必要条件，但不是正确检测的保证；若先减去样本均值，则秩不超过  $N - 1$ ，必要条件变为  $N > M$ 。本节直接使用严格正的样本特征值，不能把前面无噪声算例的 3, 0, 0 代入对数。

**从尾部特征值到评分。**将样本特征值按  $\hat{\lambda}_1 \geq \dots \geq \hat{\lambda}_M > 0$  排列。对候选源数  $k = 0, \dots, M - 1$ ，把最大的  $k$  个划入信号部分，剩余  $q_k = M - k$  个暂作噪声，定义

$$\begin{aligned} a_k &= \frac{1}{M - k} \sum_{i=k+1}^M \hat{\lambda}_i, \\ g_k &= \left( \prod_{i=k+1}^M \hat{\lambda}_i \right)^{1/(M-k)}. \end{aligned} \quad (4-4)$$



$a_k$  是算术均值，也是该候选模型下噪声方差的最大似然估计； $g_k$  是几何均值。两者具有相同的功率单位，因此  $a_k/g_k$  无量纲。算术均值不小于几何均值，且相等当且仅当剩余特征值全相等，所以  $\ln(a_k/g_k)$  衡量把它们用同一个噪声方差解释时损失了多少拟合。

复高斯对数似然中，与候选有关的部分是  $-N[\ln \det \mathbf{R} + \text{tr}(\mathbf{R}^{-1}\hat{\mathbf{R}})]$ 。用前  $k$  个样本特征值和尾部均值  $a_k$  代替该候选的总体特征值后，迹项为  $M$ ，对所有候选相同。减去同样与候选无关的  $N \sum_{i=1}^M \ln \hat{\lambda}_i$  后，负对数似然的差为

$$N \left[ (M - k) \ln a_k - \sum_{i=k+1}^M \ln \hat{\lambda}_i \right] = N(M - k) \ln(a_k/g_k)。$$

复杂度不能只数  $k$  个特征值。 $k$  个复特征向量原有  $2Mk$  个实参数；正交归一约束减去  $k^2$  个，不改变协方差的各列相位再减去  $k$  个。再加上  $k$  个信号特征值和一个公共噪声方差，得到  $\nu_k = k(2M - k) + 1$  个实自由参数。MDL 的惩罚为  $\nu_k \ln N/2$ ；去掉每个候选都有的  $\ln N/2$ ，采用

$$\begin{aligned} \text{MDL}(k) &= N(M - k) \ln(a_k/g_k) + \frac{k(2M - k)}{2} \ln N, \\ \hat{K} &= \arg \min_{0 \leq k < M} \text{MDL}(k)。 \end{aligned} \quad (4-5)$$

全部对数都是自然对数，评分无单位、越小越好，但不是概率或置信度。 $k = M - 1$  时只剩一个特征值，拟合项必为零；没有复杂度惩罚就会偏向这类过大的模型。实高斯观测的似然系数和自由参数计数不同，不能直接把原始实数 PCM 的协方差当作本节复高斯模型使用。

上述模型、最大似然估计与评分对应 Wax 与 Kailath, *Determining the number of signals by information theoretic criteria*, ICASSP 1984, § II~IV、式(10)~(15), [作者公开原文](#)。本书用  $M, N, k$  统一记号，并展开参数计数；这不是阵列几何已知时按方位参数重新推导的另一种 MDL。

**算例 4-5：为什么选择两个源，而不是三个？** 给定四麦、 $N = 100$  和样本特征值  $[9, 4, 1.1, 0.9]$ ，功率单位统一为任意参考单位。这是一组为手算指定的输入，不是真实录音或论文性能数据；不需要假设某个阵列几何、采样率或 SNR 来执行此评分，也不能由这四个数反推出这些条件。

以  $k = 1$  为例，剩下  $4, 1.1, 0.9$ ，故  $a_1 = 6/3 = 2$ 、 $g_1 = (4 \times 1.1 \times 0.9)^{1/3} \approx 1.582092$ 。拟合项为  $100 \times 3 \times \ln(2/(3.96)^{1/3}) \approx 70.319752$ ，惩罚项为  $\frac{1}{2} \times 1 \times 7 \times \ln 100 \approx 16.118096$ ，合计约 86.437847。表中计算使用未舍入中间值，最后统一保留六位小数。

| 候选 $k$ | $a_k$    | $g_k$    | 拟合项        | 惩罚项       | MDL 总分     |
|--------|----------|----------|------------|-----------|------------|
| 0      | 3.750000 | 2.443343 | 171.355476 | 0.000000  | 171.355476 |
| 1      | 2.000000 | 1.582092 | 70.319752  | 16.118096 | 86.437847  |



| 候选 $k$ | $a_k$    | $g_k$    | 拟合项      | 惩罚项       | MDL 总分    |
|--------|----------|----------|----------|-----------|-----------|
| 2      | 1.000000 | 0.994987 | 1.005034 | 27.631021 | 28.636055 |
| 3      | 0.900000 | 0.900000 | 0.000000 | 34.538776 | 34.538776 |

从  $k = 1$  增至 2，拟合项减少约 69.314718，超过惩罚增加的 11.512925。再从 2 增至 3，拟合项只减少约 1.005034，却多付约 6.907755 的惩罚，所以最小值在  $\hat{K} = 2$ 。本例说明 MDL 不要求尾部两个特征值精确相等；它比较改善拟合是否值得增加模型维数。

这个结论依赖指定的谱和快拍数。保持同一组特征值、仅在评分中把  $N$  改为 4，四个总分约为 6.854219, 7.664820, 8.357968, 10.397208，会选择  $k = 0$ 。这是固定谱下的参数敏感性手算，不是从 100 个真实快拍删到 4 个快拍的实验：真正删减数据后，样本特征值也会变化。

E04-05：复算 MDL，并检验哪些输入不成立。复算表中四个候选，再计算特征值全为 1 的情况。把原谱整体乘以  $10^{-200}$  后，源数是否应改变？若最后一个特征值为零，能否随意补一个很小的常数继续评分？

参考答案：原谱选 2；全为 1 时所有拟合项为零，惩罚最小的  $k = 0$  胜出。共同正尺度在  $a_k/g_k$  中约去，所以缩放后评分和选择应在浮点误差内不变。零特征值使几何均值和对数不满足本节定义，本书接口明确拒绝；对角加载会改变谱和准则结果，不能不加说明地当作原算法的数值修补。

复算入口为 `exercises_spatial.py` 的 E04-05；通用教学接口是 `doa.py::mdl_source_count`。它接受任意顺序的严格正实特征值，内部排序但不修改输入，返回所选源数和  $k = 0$  至  $M - 1$  的全部评分。实现直接用对数求几何均值，并在每个尾部内用最大对数平移后求算术均值的对数，避免先连乘或把极小特征值除到零。独立测试用高精度标量计算核对本表，并覆盖尺度、排序、纯噪声、秩亏和样本数错误。

实际工程还要区分三类失效：空间有色噪声使尾部不平；完全相干源使信号协方差降秩；重叠 STFT 帧使独立快拍假设不成立。不能把帧数直接当成有效独立样本数，也不能随意用窗口时长替代  $N$ 。

平滑、白化或有效样本数校正需要另行验证模型；本节代码不自动执行这些步骤，不以一次选对源数证明长期检测可靠。

重复抽样：把模型失败与有限样本误差分开

E04-06：真正减少快拍后，MDL 会怎样变化？使用四麦均匀线阵， $f = 1000\text{ Hz}$ 、 $c = 343\text{ m/s}$ 、间距  $d = 0.1715\text{ m}$ ，即半波长；两源方向为  $-30^\circ, +30^\circ$ 。分别改变独立快拍数  $N$ 、每源功率  $p$ 、源间相关性和噪声空间协方差。每个条件重新生成 200 次观测，统计输出  $k = 0, 1, 2, 3$  的次数，不沿用上一题的固定特征值。

这是本书的窄带数学仿真，不是真实录音或语音质量测试。每个复高斯变量用两份独立标准正态数  $u, v$  构造  $(u + jv)/\sqrt{2}$ ，使总复数功率为 1。白噪声条件下，每通道噪声功率为 1；独立双源的每源功率为  $p$ ，所以按阵列平均功率定义的 SNR 为  $10\log_{10}(2p)$ ， $p = 1$  时为 3.01 dB， $p = 0.1$  时为 -6.99 dB。完全相干条件令两源使用同一个随机序列，仍各有功率 1，但各通道叠加功率不再相同，不能把阵列平均 SNR 写成每通道 SNR。

每次直接计算已知零均值模型的  $\hat{\mathbf{R}} = \mathbf{X}\mathbf{X}^H/N$ ，不减样本均值、不加载、不作特征值下限处理。输入是独立复快拍，因此没有音频采样率、窗长和帧移。程序按条件编号使用 `SeedSequence([20260922, 条件编号])` 与 PCG64，编号按下表从 0 开始；每次试验都重新抽取源和噪声。以下结果实运行于 NumPy 2.5.3，统计次数保留整数，比例与区间保留一位小数。

| 条件                 | $N$ | 总体协方差特征值<br>(降序) | 200 次中输出<br>[0, 1, 2, 3] 的次数 | 与物理源数相符的<br>比例；95% 区间  |
|--------------------|-----|------------------|------------------------------|------------------------|
| 独立双源， $p = 1$      | 100 | [5, 5, 1, 1]     | [0, 0, 200, 0]               | 100.0%；[98.1%, 100.0%] |
| 独立双源， $p = 1$      | 16  | [5, 5, 1, 1]     | [4, 19, 163, 14]             | 81.5%；[75.5%, 86.3%]   |
| 独立双源， $p = 0.1$    | 100 | [1.4, 1.4, 1, 1] | [199, 1, 0, 0]               | 0.0%；[0.0%, 1.9%]      |
| 独立双源， $p = 0.1$    | 16  | [1.4, 1.4, 1, 1] | [192, 7, 1, 0]               | 0.5%；[0.1%, 2.8%]      |
| 完全相干双源，<br>$p = 1$ | 100 | [9, 1, 1, 1]     | [0, 199, 1, 0]               | 0.5%；[0.1%, 2.8%]      |
| 无源、空间白噪声           | 100 | [1, 1, 1, 1]     | [200, 0, 0, 0]               | 100.0%；[98.1%, 100.0%] |
| 无源、空间有色噪声          | 100 | [9, 4, 1, 1]     | [0, 0, 200, 0]               | 0.0%；[0.0%, 1.9%]      |

最后一行的噪声协方差为 `diag(9, 4, 1, 1)`，没有加入任何声源，因此与物理源数相符应指输出 0；不能把输出 2 当成成功检测了两个声源。

每行区间使用二项比例的双侧 Wilson 95% 区间，计算对象是这个条件下“输出恰好等于物理源数”的重复试验事件；它不是单次 MDL 的后验概率，也不是七个条件同时覆盖的区间。公式依据 [NIST/SEMATECH 手册 § 7.2.4.1](#)。即便 200 次全相符，区间下限仍小于 100%，不能声称以后绝不会出错。

参考答案与解释：先不运行随机试验，也能核对总体谱。两列导向矢量各有平方范数 4，内积为零；独立源的信号协方差因此有两个非零特征值  $4p$ ，加单位白噪声后为  $[1 + 4p, 1 + 4p, 1, 1]$ 。完全相干时，信号变为  $(\vec{a}_1 + \vec{a}_2)s$ ，平方范数为 8，信号秩只有 1，所以总体谱为  $[9, 1, 1, 1]$ 。物理声源数 2 与可分辨信号秩 1 不是同一件事。

再看随机表：第一、二行只改变快拍数，较短窗口出现漏检与过检。第三、四行的源功率较弱，有限样本下拟合改善常不足以抵消惩罚；100 个快拍仍远不足以保证检出。一次或少数次偶然输出 2 不能证明更短窗口更好。

第五行的相干模型与第七行的有色噪声已经违背用该 MDL 估计物理源数的前提，增加快拍不能自动修复这种模型失配。表格只说明这些指定条件，不给出一般声源检测率，也没有检验重叠 STFT 帧的影响。

运行 `mdl_repeated_trials.py` 可单独复算全部条件，用 `--trials` 和 `--seed` 修改试验次数与种子；`exercises_spatial.py` 的 E04-06 也会实际执行默认  $7 \times 200$  次并输出相同结构。输出保留总体谱、模型是否满足物理源数解释的前提、完整计数、比例区间、种子和软件版本；`test_codes_mdl_repeated.py` 另用标量算术—几何均值式核对实际抽样后的评分，并检查总体谱与区间，不把硬编码一次随机计数当作算法正确性的证明。

## 4.10 四麦亚采样时差：从几何到可听信号

前面的整数点脉冲适合检查 GCC 的正负号，但物理阵列的时差通常不是整数采样。这里另外给出一组可核验的四麦数学合成音频。

四个麦克风在  $x = 0, 0.04, 0.08, 0.12 \text{ m}$ ， $y = 0$ ；正横为  $0^\circ$ ，声源方位为  $30^\circ$ ，声速取  $343 \text{ m/s}$ ，采样率为  $16 \text{ kHz}$ 。远场平面波从  $+x$  一侧先到达麦 4，再到达麦 1；相邻时差的绝对值为  $0.04 \sin 30^\circ / 343 = 58.3090 \mu\text{s}$ ，相当于 0.932945 个采样点。

| 麦克风 | 相对麦 1 的到达时差 / $\mu\text{s}$ | 对齐到最晚的麦 1 所需因果延迟 / 采样点 |
|-----|-----------------------------|------------------------|
| 1   | 0                           | 0                      |
| 2   | -58.309                     | 0.932945               |

| 麦克风 | 相对麦 1 的到达时差 / $\mu\text{s}$ | 对齐到最晚的麦 1 所需因果延迟 / 采样点 |
|-----|-----------------------------|------------------------|
| 3   | -116.618                    | 1.865889               |
| 4   | -174.927                    | 2.798834               |

不能把后三列直接四舍五入成整数再宣称严格对齐。合成器以线性插值定义分数采样的传播和对齐，在源信号之外补零；源信号是 383 Hz 六谐波音叠加固定种子的宽带噪声，每个麦再加独立传感器噪声，所有文件在同组共用一个导出增益。麦 1 的无噪版本是参考，不是来自真实录音的“干净语音”。

E04-07：算出时差并区分理想相量与实际 WAV。手算表中四个时差。若只取 2298 Hz 的理想单音、暂时忽略噪声与插值，四麦未经对齐直接平均后，相对单麦的幅度是多少？按表中因果时延对齐后是多少？

然后读取下列 WAV，对参考计算 20~1980 ms 的均方误差，比较两种平均方式；不得对输出逐文件调增益，也不要将单次合成结果写成真实场景的平均性能。

参考答案。相邻理想相位差的大小是  $2\pi(2298)(0.04 \sin 30^\circ / 343) \approx 0.84191 \text{ rad}$ 。未经对齐时的幅度为  $|\sum_{m=0}^3 e^{jm(0.84191)} / 4| \approx 0.607893$ ，即相对单麦约 -4.32345 dB；理想对齐后四个相量同相，目标幅度为 1。

音频还含宽带成分、两次线性插值、独立噪声和 PCM16 量化，因此 WAV 的逐样本均方误差不会等于这两个单频幅度。运行 `exercises_spatial.py` 的 E04-07 可复算理想相量，按[练习与音频实验](#)读取 WAV 并检查全频结果。

- [无噪麦 1 参考](#)
- [四通道阵列原始输入](#)
- [未经对齐的四麦平均](#)
- [按已知几何延迟对齐后的四麦平均](#)

音频中的角度和传感器时差是真值，因为它们由合成器设定；它们并不是某种 DOA 算法在真实房间中“测出”的值。先用这组样本检查算法的单位、角度零点和输出符号，仍需另用未知方向、反射及真实多通道录音评价定位性能。

## 4.11 本章练习

1. ★基础 (TDOA + GDOP)：4 cm 双麦、正横方向附近，时延估计偏了 10  $\mu\text{s}$ ，角度会偏多少？

参考答案：正横附近  $\Delta\theta \approx c\Delta\tau/d = 343 \times 10 \times 10^{-6}/0.04 \approx 0.086 \text{ rad}$ ，即约  $4.9^\circ$ 。线性近似只能在偏差足够小时使用。

真值为  $85^\circ$  时，时延约为  $116.2 \mu\text{s}$ ；增加  $10 \mu\text{s}$  会超过物理上限  $d/c \approx 116.6 \mu\text{s}$ ，应标成越界。减少  $10 \mu\text{s}$  后用反正弦精确反算约为  $65.6^\circ$ ，误差约  $19.4^\circ$ 。这与 § 3.1 算例 3-2 一致：端射附近的有限偏差不能把微分式的  $56.4^\circ$  当成精确答案。

## 2. ★★进阶（CRLB 口径题）：为什么只写“带宽 4 kHz、SNR 0 dB”还不足以算出唯一的 TDOA CRLB？

参考答案需要补齐三组条件：

- 观测模型：单通道或双通道、波形是否已知、未知幅度等干扰参数；
- 功率口径：SNR 定义、单边或双边谱、实际谱形和均方根带宽；
- 数据量：观测时长或独立快拍数。

条件不同，Fisher 信息和常数系数也会变化，因此不能仅凭名义带宽和一个 SNR 数字给出唯一答案。

以下四题用 [exercises\\_spatial.py](#) 复算。它们检查时延符号、统计秩、几何歧义和空间平滑，不把谱峰尖锐程度当作准确性的唯一依据。

ESPRIT 最小二乘练习 E04-09 随推导放在 § 4.6 的 ESPRIT 小节；分辨率重复试验 E04-08 放在 § 4.8.1；MDL 练习 E04-05、E04-06 随完整算例放在 § 4.9；四麦音频练习 E04-07 放在 § 4.10。题号保持稳定，建议先读对应专题，再做本节综合练习。

E04-01：交换两段录音，延迟应怎样变化？16 kHz 下，让麦 1 比麦 2 晚 3 点，零填充而不循环移动信号。对单脉冲和固定种子宽带噪声各算一次 GCC-PHAT，再交换两通道。静音输入应返回哪个方向？

参考答案： $\tau_{12} = 3/16000 = 187.5 \mu\text{s}$ ，交换后为  $-187.5 \mu\text{s}$ 。两类输入都应得到 +3、-3 点；零能量输入没有可辨的相关峰，本书函数会明确报错，不能把首个搜索点当成方向。

这个 3 点延迟至少对应  $343 \times 187.5 \mu\text{s} = 6.43 \text{ cm}$  的麦距，不能把它再代入 4 cm 双麦反算实数角度。本题隔离代码符号与零输入行为，不模拟混响或亚采样误差。

音频总览的“[对齐与平均](#)”实验另提供含噪的双通道 WAV，也采用第一通道晚 3 点的约定。先读取采样率和通道顺序，再估计时差；谐波样本可能产生多个相关峰，不能把 E04-01 的宽带、无噪结果直接当作该文件的误差保证。

E04-02：两个声源为什么可能只产生一个大特征值？取四麦 ULA、 $d = \lambda/2$ ，两个方向为  $-30^\circ$ 、 $+30^\circ$ ，两源功率均为 1、无传感器噪声。比较源协方差为单位阵和全 1 矩阵时的阵列协方差特征值。



参考答案：两列导向矢量的范数平方均为 4，内积为  $1 - 1 + 1 - 1 = 0$ 。非相干时  $\mathbf{R} = \mathbf{A}\mathbf{A}^H$ ，特征值为 4, 4, 0, 0；完全相干时观测方向向量为两列之和， $\mathbf{R} = (\vec{a}_1 + \vec{a}_2)(\vec{a}_1 + \vec{a}_2)^H$ ，其范数平方为 8，特征值为 8, 0, 0, 0。

物理声源数在两种情况下都是 2，变化的是二阶统计量的秩。本题用理论协方差避免有限样本扰动，不能据此宣称实际录音一定得到精确零特征值。

E04-03: MUSIC 能消除由间距造成的歧义吗？四麦 ULA 取  $d = \lambda$ ，比较  $-30^\circ$ 、 $+30^\circ$  的导向矢量。在真实方向的秩一协方差上加  $0.1\mathbf{I}$ ，分别计算这两个候选方向的音乐值。

参考答案：相邻相位分别为  $-\pi$ 、 $+\pi$ ，复指数相同，两个导向矢量均为  $[1, -1, 1, -1]^\top$ 。所以两个候选的噪声子空间投影相同；本书用  $10^{-15}$  限制伪谱分母，二者均达到约  $10^{-15}$ 。这个数由数值保护决定，不是置信度，也不是信噪比。

更密的角度扫描或更尖的谱峰不能分开完全相同的观测模型。需要改变几何、引入其他频率或限定已知可见区域；限定区域所用的先验也应随结果说明。

E04-04: 空间平滑怎样恢复二维信号子空间？沿用 E04-02 的完全相干双源，截取麦 1~3 与麦 2~4 的两个子阵协方差，再等权平均。计算平滑矩阵与特征值，并比较处理前后的孔径。复算入口仍为 [exercises\\_spatial.py](#)。

参考答案：两个源的合成导向为  $[2, 0, -2, 0]^\top$ 。两个子阵的向量分别为  $[2, 0, -2]^\top$  和  $[0, -2, 0]^\top$ ，外积平均得到

$$\mathbf{R}_{\text{sm}} = \begin{bmatrix} 2 & 0 & -2 \\ 0 & 2 & 0 \\ -2 & 0 & 2 \end{bmatrix}。$$

向量  $[1, 0, 1]^\top$ 、 $[0, 1, 0]^\top$ 、 $[1, 0, -1]^\top$  分别给出特征值 0、2、4。原矩阵只有特征值 8 非零，平滑后恢复两个非零特征值；物理源数始终为 2。

原孔径为  $3d$ ，平滑后为  $2d$ ，所以恢复秩并不保留全部孔径。记子阵数量为  $L$ 、物理源数为  $K$ 、每个子阵的麦数为  $P$ ，本例满足  $L = 2 \geq K = 2$ 、 $P = 3 > K$ ；任意非均匀阵不能只滑动矩阵下标套用。代码在本题中直接平均两个子矩阵，不提供通用空间平滑器。[doatools 官方接口](#)同样区分子阵数量与输出矩阵维数。



## 第 5 章 · 波束形成

### 5.1 统一问题表述

波束形成器对  $M$  路信号做线性组合（频域）：

$$y(k, n) = \vec{w}^H(k, n) \vec{x}(k, n)。$$

本章沿用第 2 章的几何约定，并把相位符号写全：均匀线阵的麦 1 在左端、位置为  $x_1 = 0$ ，麦 2 及后续阵元沿  $+x$  方向排列；正角声源位于  $+x$  一侧，单位向量  $\vec{u}$  从阵列指向声源。到达时刻差定义为  $\tau_{ij} = t_i - t_j$ 。因此正角远场声源先到达右侧阵元， $\tau_{21} = -d \sin \theta / c$ ；以麦 1 为相位参考时，

$$a_m(f, \theta) = e^{+j2\pi f(m-1)d \sin \theta / c}, \quad m = 1, \dots, M。$$

输出始终写成  $y = \vec{w}^H \vec{x}$ 。所以延迟求和权重为  $\vec{w} = \vec{a} / M$ ，真正乘到第  $m$  路观测上的系数是  $w_m^*$ ；后面的正负号与共轭都按这组约定计算。

本章先研究一类共同问题：在期望方向  $\theta_0$  无失真（ $\vec{w}^H \vec{a}(\theta_0) = 1$ ）的前提下，最小化某类噪声或干扰的输出功率。延迟求和波束形成器（Delay-and-Sum Beamformer, DSB）、超指向、最小方差无失真响应（Minimum Variance Distortionless Response, MVDR）和线性约束最小方差（Linearly Constrained Minimum Variance, LCMV）可用噪声模型与线性约束的差异统一描述。

多通道维纳滤波（Multichannel Wiener Filter, MWF）直接最小化均方误差，广义特征值（Generalized Eigenvalue, GEV）波束形成最大化输出信噪比，并不满足同一个无失真优化问题。它们在后文单独说明。

三类噪声的现实对应如下：

- 传感器白噪声：麦克风自噪声 → 对应度量白噪声增益（White Noise Gain, WNG）；本章把线性量记为  $G_{\text{WNG}}$ ，dB 量记为  $\text{WNG}_{\text{dB}}$ ；
- 弥散噪声：充分弥散的晚期混响。在球面各向同性场模型中，协方差矩阵  $\mathbf{\Gamma}$  的第  $i, j$  个元素为  $[\mathbf{\Gamma}]_{ij} = \text{sinc}(2fd_{ij}/c)$ ， $d_{ij}$  为两麦间距。本章 sinc 用归一化定义  $\text{sinc}(x) = \sin(\pi x)/(\pi x)$ ，部分文献用  $\sin x/x$ ，对照时要换算自变量。对应的线性量为指向因数（directivity factor） $Q$ ，dB 量为指向性指数（Directivity Index, DI）。DI 越高，表示对目标方向保持单位响应时，指定弥散场模型下的输出噪声功率越低。风噪常由麦克风附近的局部湍流产生，不能无条件纳入这个各向同性模型；
- 定向点干扰：竞争说话人、电视 → 在干扰方向形成零陷。

前两类噪声分别用白噪声增益的线性量  $G_{\text{WNG}}$  和指向因数  $Q$  衡量；换成 dB 后分别记为  $\text{WNG}_{\text{dB}}$  和指向性指数 DI。DSB、超指向、WNG 约束和对角加载都可在这两个指标下比较：

$$\begin{aligned} G_{\text{WNG}} &= \frac{|\vec{w}^H \vec{a}|^2}{\vec{w}^H \vec{w}}, & \text{WNG}_{\text{dB}} &= 10 \log_{10} G_{\text{WNG}}, \\ Q &= \frac{|\vec{w}^H \vec{a}|^2}{\vec{w}^H \mathbf{\Gamma} \vec{w}}, & \text{DI} &= 10 \log_{10} Q. \end{aligned} \quad (5-1)$$

$G_{\text{WNG}}$  是阵列对通道独立白噪声的输出 SNR 线性增益， $Q$  是指定弥散场模型下的输出 SNR 线性增益；式(5-1)明确区分了线性量和 dB 量。无失真约束下两个线性量的分子恒为 1，只需比较分母。4 元  $\lambda/2$  线阵的算例见算例 2-2。图 15 的纵轴标成 WNG (dB) 和 DI (dB)，分别对应  $\text{WNG}_{\text{dB}}$  与 DI。

弥散场有两种常用理想模型：球面各向同性假定声音从三维各方向等概率到达，相干系数为 sinc 形；柱面各向同性只对水平面方位角积分，相干系数为零阶贝塞尔函数  $J_0(2\pi fd/c)$ 。Habets, JASA 2008 实际会议室中的说话人、反射和设备噪声通常不满足严格的柱面各向同性分布，应由测得的空间相干性或验证集结果选择模型，不能仅凭场景名称判定。

时域还是频域实现？本章公式写在频域，每个频点各有一组权重  $\vec{w}(k)$ 。短时傅里叶变换 (Short-Time Fourier Transform, STFT) 把宽带语音分解为一组近似窄带的问题 (§ 2.5)，逐频点求解后再逆变换。

对应的时域形式称为滤波求和 (filter-and-sum)：每路麦克风经过一段有限冲激响应 (Finite Impulse Response, FIR) 滤波器后求和。DSB 是滤波器退化为纯延迟的特例；Frost 波束形成器则是时域自适应 LCMV 的经典实现。Frost, *Proceedings of the IEEE*, 1972

两种实现的计算量、算法延迟和约束实现方式取决于帧长、滤波器长度与硬件，不应只凭“时域”或“频域”作统一判断。

## 5.2 延迟求和波束形成器 (Delay-and-Sum Beamformer, 简称 DSB)：

### “合唱前先把大家对齐”

$\vec{w}_{\text{DSB}} = \frac{1}{M} \vec{a}(\theta_0)$ ：按导向矢量把各通道时延补偿后等权相加。若不除以  $M$ ，对齐后的目标幅度是单通道的  $M$  倍；本章采用的  $1/M$  归一化使目标响应为 1。这两种写法的输出 SNR 相同，但绝对幅度增益不同。

手算例子：2 麦相距  $d = 4 \text{ cm}$ ，声源与阵列正横方向夹角  $30^\circ$ （从正横量角，§ 2.1 约定，本章统一用此约定），频率  $f = 1 \text{ kHz}$ 。

$$1. \text{ 时延差: } \Delta\tau = \frac{d \sin 30^\circ}{c} = \frac{0.04 \times 0.5}{343} \approx 58.3 \mu\text{s};$$

2. 相位差:  $\Delta\phi = 2\pi f\Delta\tau = 2\pi \times 1000 \times 58.3\mu s \approx 0.366 \text{ rad} \approx 21^\circ$  ;
3. 麦 2 在  $+x$  侧, 正角声源先到达麦 2, 所以有符号时延为  $\tau_{21} = -58.3 \mu s$ 。以麦 1 为参考的导向矢量是  $\vec{a} = [1, e^{+j0.366}]^T$  ;
4. DSB 权重:  $\vec{w} = \vec{a}/2 = [0.5, 0.5e^{+j0.366}]^T$ , 验证无失真约束:  
 $\vec{w}^H \vec{a} = \frac{1}{2}(1 + e^{-j0.366}e^{+j0.366}) = 1 \checkmark$  ;
5. 含义:  $y = \vec{w}^H \vec{x}$  中, 麦 2 实际乘以  $w_2^* = 0.5e^{-j0.366}$ , 抵消其相对麦 1 的  $+0.366 \text{ rad}$  相位, 两路目标信号同相相加。

若直接求和, 目标幅度变为 2 倍、目标功率变为 4 倍, 独立同功率白噪声的功率只变为 2 倍, 因此输出 SNR 提高 2 倍, 即 3 dB ( $10 \log_{10} 2$ )。写成  $\vec{w} = \vec{a}/M$  的平均形式时, 目标响应应保持为 1, 噪声功率减半, 所得 SNR 增益相同。

### 波束图的等比数列推导:

1. 把波束指向  $\theta_0$  后, 去测另一个方向  $\theta$  的输出: 各通道先按  $\theta_0$  补偿相位, 再求和。记相邻两麦的残余相位差  $\psi = \frac{2\pi d}{\lambda}(\sin \theta - \sin \theta_0)$ , 则第  $m$  个麦在求和时带着因子  $e^{jm\psi}$  ;
2. 输出幅度就是等比数列求和 (公比  $e^{j\psi}$ ) :

$$B(\psi) = \sum_{m=0}^{M-1} e^{jm\psi} = e^{j(M-1)\psi/2} \frac{\sin(M\psi/2)}{\sin(\psi/2)}$$

3. 取模:  $|B| = \left| \frac{\sin(M\psi/2)}{\sin(\psi/2)} \right|$ 。  $\psi = 0$  (即  $\theta = \theta_0$ ) 时分子分母都趋于零, 取极限得最大值  $M$ 。

离开目标方向后, 该比值随  $\psi$  周期变化, 形成主瓣、零点和旁瓣;

4. 主瓣边缘: 第一个零点在  $M\psi/2 = \pi$ , 即  $\psi = 2\pi/M$ 。

正横附近用  $\sin \theta \approx \theta$ , 并把主瓣内离散阵因子近似为连续孔径时, “零点到零点”宽度约为  $2\lambda/(Md)$ , 半功率宽度约为  $0.886\lambda/(Md)$ ; 斜指向时还要按 § 2.6 除以  $\cos \theta_0$ 。后一个系数是充分大  $M$ 、正横小角度下的近似值, 小阵列应直接从上式数值求半功率点。

这里的  $Md$  来自  $M$  项离散阵因子, 不等于阵列首尾的物理跨度  $D = (M-1)d$ 。用  $\lambda/D$  表示的是孔径尺度估计; 两者只在  $M$  较大时接近, 小阵列中必须说明采用哪一种口径。两种写法都表达同一趋势: 阵元数或间距增大、波长减小时, 主瓣变窄。

均匀加权等价于空间域的矩形窗。其第一旁瓣随  $M$  增大才趋近相对主瓣约  $-13.26 \text{ dB}$ ; 例如按上面的离散阵因子复算,  $M = 3, 4, 8, 16$  时约为  $-9.54$ 、 $-11.30$ 、 $-12.80$ 、 $-13.15 \text{ dB}$ ,  $M = 2$  则没有常规意义下的旁瓣。因此小阵列不能直接套用 “ $-13 \text{ dB}$ ”。

非均匀加权 (如 Dolph – Chebyshev 加权) 可按设计值降低旁瓣, 但会展宽主瓣; 因此必须在旁瓣电平、主瓣宽度和有效孔径之间权衡。

WNG 上限是怎么算出来的（两步，柯西-施瓦茨不等式）：

1. 代入 DSB 权重  $\vec{w} = \vec{a}/M$ :  $G_{\text{WNG}} = \frac{|\vec{w}^H \vec{a}|^2}{\|\vec{w}\|^2} = \frac{|\vec{a}^H \vec{a}/M|^2}{\|\vec{a}\|^2/M^2} = \frac{1}{M/M^2} = M$ , 所以 DSB 的  $\text{WNG}_{\text{dB}} = 10 \log_{10} M \text{ dB}$ ;
  2. 若各阵元目标响应幅度均为 1, 则  $\|\vec{a}\|^2 = M$ 。柯西-施瓦茨不等式给出  $|\vec{w}^H \vec{a}| \leq \|\vec{w}\| \|\vec{a}\|$ , 所以满足精确无失真约束的权重有  $G_{\text{WNG}} \leq M$ , 等号在  $\vec{w} \propto \vec{a}$  时成立。这个结论针对空间白噪声、精确导向矢量和单位幅度阵列流形; 阵元增益不等、噪声相关或导向失配时不能直接套用。
- 优点：在上述理想模型下达到最大  $G_{\text{WNG}}$ , 结构简单; 若实际导向矢量等于设计值, 目标响应为 1;
  - 缺点：不能根据干扰方向自适应放置零陷; 波束图中仍可能存在由阵元数、间距和频率决定的固定零点。课程讲义引用的球阵/圆阵实验称其所测小阵列 DSB 几乎无法改善识别率, 该结论只适用于讲义中的阵列、数据和识别器。Kumatani et al.

DSB 常作为固定波束基线, 也可作为自适应算法的初始权重。

### 5.3 超指向的白噪声增益—指向性权衡

在期望方向无失真约束下最大化  $Q$ , 也就最大化 DI (等价于 MVDR 对阵各向同性噪声)：

$$\min_{\vec{w}} \vec{w}^H \mathbf{\Gamma} \vec{w} \quad \text{s.t.} \quad \vec{w}^H \vec{a}(\theta_0) = 1, \quad \Rightarrow \quad \vec{w}_{SD} = \frac{\mathbf{\Gamma}^{-1} \vec{a}}{\vec{a}^H \mathbf{\Gamma}^{-1} \vec{a}}. \quad (5-2)$$

式(5-2)最大化的是线性指向因数  $Q$ ; 由于对数单调, 它也最大化 DI。其推导与式(5-3)使用同一个带线性约束的二次型优化, 只是把噪声协方差  $\mathbf{R}_{nn}$  换成弥散噪声相干矩阵  $\mathbf{\Gamma}$ 。完整推导见 § 5.4。

小间距阵列可利用相邻通道的差分获得高于 DSB 的弥散场指向性。代价是低频  $G_{\text{WNG}}$  降低, 阵元自噪声、增益误差、相位误差和阵列模型误差都会被放大。

实际设计通常加入  $\vec{w}^H \vec{w} \leq \delta$  形式的  $G_{\text{WNG}}$  下限约束, 或按频段选择不同权重: 低频在白噪声增益预算内提高指向性, 高频在  $\mathbf{\Gamma} \approx \mathbf{I}$  时使用接近 DSB 的解。

课程讲义给出了特定小尺寸球阵条件下的对比结果, 不能脱离其阵列与数据条件外推。

[Kumatani et al. (出处同 § 5.2 引文)]

算例 5-1: 超指向权重与  $\text{WNG}_{\text{dB}}$

题设：2 麦小间距  $d = 0.05\lambda$ ，弥散噪声相干矩阵  $\mathbf{\Gamma} = \begin{bmatrix} 1 & \text{sinc}(0.1) \\ \text{sinc}(0.1) & 1 \end{bmatrix}$  (§ 5.1:

$[\mathbf{\Gamma}]_{ij} = \text{sinc}(2d_{ij}/\lambda)$ ，这里  $\text{sinc}(x) = \sin(\pi x)/(\pi x)$ ， $\text{sinc}(0.1) = \frac{\sin(0.1\pi)}{0.1\pi} \approx 0.9836$ )。超指向权重

$$\vec{w}_{SD} = \frac{\mathbf{\Gamma}^{-1}\vec{a}}{\vec{a}^H\mathbf{\Gamma}^{-1}\vec{a}} \quad (\S 5.3)。$$

第 1 步：检查  $\mathbf{\Gamma}$  的病态程度

$$\begin{aligned} \det \mathbf{\Gamma} &= 1 - 0.9836^2 = 0.0325, \\ \mathbf{\Gamma}^{-1} &= \frac{1}{0.0325} \begin{bmatrix} 1 & -0.9836 \\ -0.9836 & 1 \end{bmatrix} \\ &\approx \begin{bmatrix} 30.80 & -30.29 \\ -30.29 & 30.80 \end{bmatrix}. \end{aligned}$$

两麦噪声的相干系数为  $\rho = 0.9836$ ，所以  $\mathbf{\Gamma}$  接近奇异，逆矩阵元素达到 30 量级。后续求得的权重会相应放大。

第 2 步：正横指向的退化情形

若  $\theta_0 = 0^\circ$ ，则  $\vec{a}_0 = [1, 1]^\top$  恰好是  $\mathbf{\Gamma}$  的特征向量 ( $\mathbf{\Gamma}\vec{a}_0 = (1 + \rho)\vec{a}_0$ )，于是

$\mathbf{\Gamma}^{-1}\vec{a}_0 = \vec{a}_0/(1 + \rho) \propto \vec{a}_0$ ，归一化后

$$\vec{w}_{SD} = [0.5, 0.5]^\top = \vec{w}_{DSB}, \quad \text{WNG}_{\text{dB}} = +3.0 \text{ dB}$$

——超指向解退化成普通延迟求和。对称双麦阵在正横方向的导向矢量正好是弥散相干矩阵的特征向量，因此没有额外收益。随着指向偏离正横方向，超指向解与 DSB 的差异增大，端射附近通常最明显；不能概括成“只有端射才有增益”。下面用端射方向展示最强的差分效应。

第 3 步：端射指向的权重

$$\psi = 2\pi \times 0.05 \times \sin 90^\circ = 0.1\pi \approx 0.3142 \text{ rad } (18^\circ)，$$

$$\vec{a} = [1, e^{+j0.3142}]^\top = [1, 0.9511 + 0.3090j]^\top。$$

$$\text{分子: } \mathbf{\Gamma}^{-1}\vec{a} \approx \begin{bmatrix} 1.9869 - 9.3616j \\ -1.0033 + 9.5174j \end{bmatrix} \quad (\text{模长接近 } 10, \text{ 且两分量近乎反号})；$$

$$\text{分母: } \vec{a}^H\mathbf{\Gamma}^{-1}\vec{a} \approx 3.9737 \quad (\text{正实数})；$$

相除：

$$\vec{w}_{SD} \approx \begin{bmatrix} 0.5000 - 2.3559j \\ -0.2525 + 2.3951j \end{bmatrix}, \quad |w_1| = |w_2| \approx 2.41$$

第 4 步：验证无失真约束

$$\vec{w}^H \vec{a} = \underbrace{(0.5000 + 2.3559j)}_{w_1^* \cdot a_1} + \underbrace{(0.5000 - 2.3559j)}_{w_2^* \cdot a_2} = 1 \checkmark$$

每一项的模长都是 2.41，而两项虚部  $\mp 2.356j$  相消后留下单位目标响应。权重分量明显大于最终目标响应，因此很小的通道误差也会破坏这种相消关系。

第 5 步：算  $\text{WNG}_{\text{dB}}$ ，看代价

$$\begin{aligned} \|\vec{w}\|^2 &= 2.41^2 + 2.41^2 \approx 11.60, \\ \text{WNG}_{\text{dB}} &= 10 \log_{10} \frac{1}{11.60} \approx -10.6 \text{ dB}. \end{aligned}$$

对照：同一指向的 DSB 有  $\text{WNG}_{\text{dB}} = +3.0 \text{ dB}$ 。负的  $\text{WNG}_{\text{dB}}$  表示独立的阵元自噪声被权重能量放大；本例  $\|\vec{w}\|^2 \approx 11.6$ ，即相对单麦高约 10.6 dB。作为交换，在本例的理想各向同性弥散场、紧凑双麦端射模型下，指向因数  $Q = 1/(\vec{w}^H \mathbf{T} \vec{w}) \approx 3.97$ ，所以  $\text{DI} \approx +6.0 \text{ dB}$ 。这个结果依赖模型和极限条件，不是任意双麦几何、频率与噪声场的保证。

第 6 步：通道失配的影响

给麦 2 加 1% 的增益失配，即把  $\vec{a}$  的第二分量乘以 1.01：

$$\vec{w}^H \vec{a}_{\text{mis}} = 1.0050 - 0.0236j.$$

目标响应误差幅度约 2.4%。

相同的 1% 增益失配作用在 DSB 上时，目标响应误差为 0.5%；本例超指向误差约为其 5 倍。权重范数越大，通道增益与相位误差造成的响应偏差通常越明显。因此超指向设计应结合器件规格做失配扫描，并加入  $G_{\text{WNG}}$  下限约束或对角加载（§ 5.4）。


第 7 步：比较不同归一化间距（均指向端射  $90^\circ$ ）：

| $d$                      | $0.5\lambda$ | $0.1\lambda$ | $0.05\lambda$ | $0.02\lambda$ | $0.01\lambda$ |
|--------------------------|--------------|--------------|---------------|---------------|---------------|
| 权重模长 $ w_i $             | 0.50         | 1.24         | 2.41          | 5.98          | 11.94         |
| $\text{WNG}_{\text{dB}}$ | +3.0 dB      | -4.9 dB      | -10.6 dB      | -18.5 dB      | -24.6 dB      |

在本例的双麦端射模型中，间距减半时权重模长近似翻倍， $\text{WNG}_{\text{dB}}$  约降低 6 dB；这一近似来自权重随  $\lambda/d$  增长、白噪声输出功率随  $(\lambda/d)^2$  增长。表中数值只对应所列理想模型，实际设计还要加入通道失配、自噪声与阵列几何误差。



图15 6元圆阵（半径=相邻弦长=4 cm）超指向 vs 延迟求和：WNG与DI  
（三维各向同性弥散场；超指向相对对角加载= $10^{-6}$ ；目标方向单位响应；本书仿真）



图示说明：图 15 使用半径 4 cm 的 6 元均匀圆阵；六边形相邻阵元的弦长也为 4 cm。导向矢量与三维各向同性弥散场相干矩阵都由同一组二维阵元坐标计算。

左图比较 DSB 与超指向的  $WNG_{dB}$ ，右图比较二者的 DI。两种算法同时用颜色和线型区分，灰度打印时仍可辨认。

超指向协方差矩阵加入相对对角加载  $10^{-6}$ ，即绝对加载量为  $10^{-6} \text{tr}(\mathbf{\Gamma})/M$ ；两种方法均归一化为目标方向单位响应。曲线只展示该模型下的频率趋势，不代表硬件实测，也不能把某个交点当作通用设计门限。

差分麦克风阵列（Differential Microphone Array，简称 DMA）是与紧凑超指向设计密切相关的一类时域结构，但两者不是可以直接互换的名称。超指向设计先规定弥散噪声模型并优化  $Q$ ；DMA 则用通道差分、延迟和均衡合成目标方向图，只有在相应噪声模型、约束与近似条件下才可能实现某个超指向解。

一阶两抽头形式可写为  $y(t) = x_1(t) - g x_2(t - \tau)$ ，其中  $g$  是实数幅度系数， $\tau$  是内延迟。更一般的时域实现用 FIR 滤波器提供频率相关的幅相响应。 $\tau = 0$  且  $g = 1$  的纯实数相减只能得到前后对称的偶极子；心形需要延迟与相减配合，推导见算例 3-1。

在  $\kappa d \ll 1$ （ $\kappa = 2\pi f/c$ ，麦距远小于波长）的低频近似下，配合所需的幅度均衡后，归一化指向形状可在一段频带内近似不变。有限间距、离散延迟、壳体散射和失配都会破坏该近似。DMA 尺寸小，但  $WNG_{dB}$  可能很低，对麦距和通道失配敏感。

四项诊断量：超指向或 MVDR 权重求出后，应检查以下指标，再进入录音评估。

1. 白噪声增益余量：算  $G_{\text{WNG}} = 1/\|\vec{w}\|^2$ （精确无失真约束下），再按式(5-1)换成  $\text{WNG}_{\text{dB}}$ 。  
最低允许值应由本机自噪声、增益/相位公差和目标输出余量共同确定，不能用一个固定 dB 数覆盖所有设备；
2. 条件数：算  $\mathbf{\Gamma}$  或  $\hat{\mathbf{R}}_{nn}$  的条件数  $\kappa = \lambda_{\max}/\lambda_{\min}$ 。条件数增大表示求逆对协方差估计误差更敏感；可通过对角加载（§ 5.4）、降阶或减少约束改善。可接受上限应由浮点精度、快拍数和失配仿真共同确定；
3. 削波率与动态余量：把权重作用于代表性录音或按目标电平生成的测试信号，检查输出峰值和削波率。权重范数大时，通道叠加可能增加峰值；应预留数字动态余量，并在需要时收紧 WNG 约束；
4. 通道失配灵敏度：按照麦克风数据手册、标定残差和装配误差给导向矢量逐通道施加增益、相位与位置扰动，统计目标响应  $|\vec{w}^H \vec{a}_{mis} - 1|$ 、零陷位置与 WNG 的变化。算例 5-1 第 6 步提供了 1% 增益失配的手算；实际扰动范围和验收门限必须按设备确定。

### 5.3.1 差分麦克风：从一阶心形到高阶设计

上一节末尾把 DMA 归入紧凑超指向设计。下面说明差分、延迟和均衡如何共同形成一阶方向图，以及提高阶数时为什么必须同时检查 WNG。

一阶差分原理：两个相距很近的麦克风接收同一远场声波时存在小的传播时延差。对其中一路施加内部延迟和增益后相减，可使某些方向相消、另一些方向保留。输出写成  $y(t) = x_1(t) - g x_2(t - \tau)$ ：  $g$  控制两路幅度与相位配比， $\tau$  控制相减前的内部延迟；改变  $(g, \tau)$  就会改变零点位置和指向图形状。

后向零点怎样变成近似心形：设端射双麦间距为  $d$ ，某方向的传播时延差为  $\tau_p(\theta)$ 。该方向的频率响应可写成

$$H(\omega, \theta) = 1 - g e^{-j\omega[\tau + \tau_p(\theta)]}.$$

选择  $g$  和内部延迟  $\tau$  可以令后向响应在设计频率或低频近似下为零。仅有这个零点还不能证明整个宽带方向图是心形。

当  $\kappa d = 2\pi f d / c \ll 1$ ，把指数项作一阶展开，并用均衡器补偿差分器随频率上升的幅度后，归一化方向图才可在一段频带内近似“全向项加偶极项”；取相应系数时得到心形、超心形或 8 字形。

频率升高、间距不再远小于波长、延迟量化或通道失配都会使形状偏离该近似。 $\tau = 0$  且  $g = 1$  的纯相减只产生前后对称的偶极响应。Elko & Pong, ICASSP 1997

算例：一阶 DMA 的零点、均衡与 WNG。取端射双麦  $d = 2\text{ cm}$ 、 $c = 343\text{ m/s}$ ，则  $T = d/c = 58.31\text{ }\mu\text{s}$ 。沿用式中的符号约定，令后向  $\tau_p = -T$ 、前向  $\tau_p = +T$ ，并取  $g = 1, \tau = T$ 。后向响应为  $H_b = 1 - e^0 = 0$ 。在  $f = 500\text{ Hz}$ ，前向响应

$$H_f = 1 - e^{-j2\omega T}, \quad |H_f| = 2 \sin(\omega T) = 2 \sin(0.1832) \approx 0.3644.$$

因此要把前向响应归一到 1，均衡器幅度需乘  $1/0.3644 \approx 2.744$ 。两路独立、单位功率的阵元自噪声在均衡后功率为  $2/|H_f|^2 \approx 15.06$ ，所以  $\text{WNG}_{\text{dB}} = 10 \log_{10}(1/15.06) \approx -11.78\text{ dB}$ 。

若第二通道有 1% 增益误差，原本的后向零点变为  $|1 - 1.01|/|H_f| \approx 0.0274$ ，即相对前向约  $-31.2\text{ dB}$ ；零点不再无限深。

这个单频点数例只验证相消和噪声放大的代价。它不证明宽带心形：500 Hz 时  $\kappa d \approx 0.183$  尚可作低频近似，频率升高、均衡器限幅或误差增大时必须重新计算方向图和 WNG。

提高阶数改变了什么：多个一阶差分单元级联可形成高阶方向图，并提供更多可配置零点。阶数增加并不对应一个脱离条件的固定 DI 增量。理想 DI 取决于采用球面还是柱面弥散场、目标方向图和归一化方式；换成 dB 后也不能概括为“每阶线性增加”。

高阶差分包含更强的相消和低频均衡，通常增大权重范数，使阵元自噪声和增益、相位、位置误差更容易进入输出。

设计时应按每个频点同时报告方向图、DI、WNG、条件数和失配扫描，而不是只按阶数选型。  
*Elko, Differential Microphone Arrays*

| 设计变化   | 可能获得的能力                      | 同时增加的风险               | 必须固定的比较条件          |
|--------|------------------------------|-----------------------|--------------------|
| 增加差分阶数 | 可配置更多零点和更细的空间变化              | 权重范数增大，低频自噪声和失配更易被放大  | 频率、间距、噪声场、目标图形与均衡器 |
| 减小阵元间距 | 在更高频率前维持 $\kappa d \ll 1$ 近似 | 通道观测更相似，差分后的 WNG 可能降低 | 麦克风自噪声、标定残差与数值精度   |
| 增强低频均衡 | 补偿差分器的低频衰减                   | 同时放大低频传感器噪声和风噪        | 最大增益、削波余量与 WNG 下限  |

学习方法若用于 DMA，更适合估计受约束的系数、掩码或正则化参数，再由解析差分结构形成输出。这样仍可检查零点、WNG 和失配；若网络直接输出任意滤波器，则应按 § 5.9 的端到端方法评价，不能仅因输入来自小间距阵列就称为 DMA。

在精确导向和空间白噪声模型下，DSB 达到最大的  $G_{\text{WNG}}$ ；超指向针对弥散噪声提高  $Q$  与 DI，但通常降低低频  $\text{WNG}_{\text{dB}}$ 。后面的 MVDR 和稳健波束形成把这种指标权衡推广到估计得到的噪声协方差与导向误差。

## 5.4 最小方差无失真响应

最小方差无失真响应（Minimum Variance Distortionless Response，简称 MVDR）在设计导向矢量上施加单位响应，同时最小化输出噪声功率。只有设计导向矢量与真实目标传递向量一致时，“无失真”才对真实目标成立。

$$\min_{\vec{w}} \vec{w}^H \mathbf{R}_{nn} \vec{w} \quad \text{s.t.} \quad \vec{w}^H \vec{a}(\theta_0) = 1.$$

符号： $\mathbf{R}_{nn}$  是  $M \times M$  噪声协方差矩阵。对角元表示各通道噪声功率，非对角元表示通道间相关性。它与 § 4.2 的标量互相关函数  $R(\tau)$  不同。

推导（拉格朗日乘法，四步，每步都有物理读法）：

第 1 步：把约束加入目标。复约束  $\vec{w}^H \vec{a} = 1$  要与其共轭约束成对写入拉格朗日函数：

$$L(\vec{w}, \lambda) = \vec{w}^H \mathbf{R}_{nn} \vec{w} + \lambda(1 - \vec{w}^H \vec{a}) + \lambda^*(1 - \vec{a}^H \vec{w}).$$

$\lambda$  是复标量拉格朗日乘子。后两项互为共轭，所以  $L$  保持为实数。

第 2 步：求梯度并令它为零。复数向量求导用 Wirtinger 规则——把  $\vec{w}$  和它的共轭  $\vec{w}^*$  当成两个独立变量，对  $\vec{w}^*$  求偏导：

$$\frac{\partial L}{\partial \vec{w}^*} = \mathbf{R}_{nn} \vec{w} - \lambda \vec{a} = \vec{0} \quad \Rightarrow \quad \vec{w} = \lambda \mathbf{R}_{nn}^{-1} \vec{a}$$

物理读法：最优权重与经噪声逆协方差加权后的导向矢量成比例。 $\mathbf{R}_{nn}^{-1}$  根据噪声空间相关结构调整各方向的响应，比例系数再由无失真约束确定。这里不能把  $\mathbf{R}_{nn}^{-1}$  本身叫作白化矩阵：对正定噪声协方差，常用的厄米白化矩阵是  $\mathbf{R}_{nn}^{-1/2}$ ，因为它把噪声协方差变成单位阵；直接乘逆矩阵后，噪声协方差仍是  $\mathbf{R}_{nn}^{-1}$ 。

第 3 步：用约束确定倍数。把结果代回无失真约束  $\vec{w}^H \vec{a} = 1$ ：

$$\lambda^* \vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a} = 1.$$

由于  $\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}$  是正实数，所以  $\lambda^* = \lambda$ ，并且

$$\lambda = \frac{1}{\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}}$$

协方差矩阵一般是半正定的；这里写普通逆矩阵，额外假定  $\mathbf{R}_{nn}$  正定。若快拍不足或矩阵奇异，应加正则、使用降秩方法或在明确秩条件下用伪逆。正定时分母是正实数。

第 4 步：把倍数代回第 2 步。

$$\vec{w}_{MVDR} = \frac{\mathbf{R}_{nn}^{-1} \vec{a}}{\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}} \quad (5-3)$$

正定时  $\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}$  为正实数，因此上面由  $\vec{w}^H \vec{a} = 1$  求得的乘子无需再区分共轭值。

此权重代回输出功率即得式(4-2)的 Capon 谱——同一优化器的两种读法（推导见 § 4.5）。

推导关系：梯度条件给出  $\vec{w} \propto \mathbf{R}_{nn}^{-1} \vec{a}$ ，无失真约束再确定比例系数，使  $\vec{w}^H \vec{a} = 1$ 。因此  $\mathbf{R}_{nn}^{-1}$  决定噪声抑制方向，分母负责目标响应归一化。LCMV（§ 5.5）沿用同一二次型优化，只把一条约束推广为多条约束。

两个特例：白噪声下  $\mathbf{R}_{nn} \propto \mathbf{I}$ ，MVDR 退化为 DSB；协方差中含定向强干扰时，MVDR 会降低该方向的响应。图 16 的 MVDR 曲线使用 8 元阵和  $20^\circ$  干扰，参数与下面算例 5-2 的 2 元阵、 $30^\circ$  干扰不同。

#### 算例 5-2：2 麦 MVDR 数值推导

题设：2 麦，间距  $d = \lambda/2$ ；目标方向  $\theta_0 = 0^\circ$ （正横）；干扰来自  $\theta_i = 30^\circ$ ，干扰噪声功率比 INR = 10（干扰功率是各麦白噪功率的 10 倍）。求 MVDR 权重  $\vec{w}_{MVDR} = \frac{\mathbf{R}_{nn}^{-1} \vec{a}}{\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}}$ （式(5-3)的闭式解），并验证它的两个承诺。

##### 第 1 步：写出两个导向矢量

- 目标方向： $\psi_0 = \pi \sin 0^\circ = 0$ ，所以  $\vec{a}_0 = [1, 1]^\top$ ；
- 干扰方向： $\psi_i = \pi \sin 30^\circ = \frac{\pi}{2}$ ，所以  $\vec{a}_i = [1, e^{+j\pi/2}]^\top = [1, +j]^\top$ （相对麦 1，麦 2 的频域相位为  $+90^\circ$ ）。

##### 第 2 步：构造噪声协方差矩阵 $\mathbf{R}_{nn}$

噪声模型 = 定向干扰 + 各麦独立白噪（功率归一化为 1）：

$$\mathbf{R}_{nn} = 10 \cdot \vec{a}_i \vec{a}_i^H + \mathbf{I}$$

先算外积  $\vec{a}_i \vec{a}_i^H = \begin{bmatrix} 1 \\ +j \end{bmatrix} [1, -j] = \begin{bmatrix} 1 & -j \\ +j & 1 \end{bmatrix}$ （注意  $(\vec{a}_i \vec{a}_i^H)_{12} = 1 \cdot (+j)^* = -j$ ），于是

$$\mathbf{R}_{nn} = \begin{bmatrix} 11 & -10j \\ +10j & 11 \end{bmatrix}$$

读法：对角元  $11 = \text{干扰功率 } 10 + \text{白噪功率 } 1$ （每个麦收到的总噪声功率）；非对角元  $\pm 10j$  记录两麦噪声的相关性和相位差。对本例的单个定向干扰，方向信息体现在这对非对角元中；一般 MVDR 还同时依赖整个协方差矩阵、导向矢量和无失真约束，不能把零陷归因于所有非对角元的某个通用模式。

### 第 3 步：求逆 $\mathbf{R}_{nn}^{-1}$

$2 \times 2$  矩阵求逆公式  $\begin{bmatrix} p & q \\ r & s \end{bmatrix}^{-1} = \frac{1}{ps - qr} \begin{bmatrix} s & -q \\ -r & p \end{bmatrix}$ 。行列式：

$$\det \mathbf{R}_{nn} = 11 \times 11 - (-10j)(10j) = 121 - 100 = 21$$

注意  $(-10j)(10j) = -100j^2 = +100$ 。 $2 \times 2$  行列式为  $ps - qr$ ，所以这里得到  $121 - 100 = 21$ 。

该矩阵的特征值为 21 和 1，2-范数条件数为 21；算例 5-1 的  $\mathbf{\Gamma}$  特征值约为 1.9836 和 0.0164，条件数约为 121。条件数而不是未归一化的行列式可直接比较求逆敏感度。于是

$$\mathbf{R}_{nn}^{-1} = \frac{1}{21} \begin{bmatrix} 11 & +10j \\ -10j & 11 \end{bmatrix} \approx \begin{bmatrix} 0.5238 & +0.4762j \\ -0.4762j & 0.5238 \end{bmatrix}$$

### 第 4 步：算权重

$$\text{分子：} \mathbf{R}_{nn}^{-1} \vec{a}_0 = \frac{1}{21} \begin{bmatrix} 11 + 10j \\ 11 - 10j \end{bmatrix} \approx \begin{bmatrix} 0.5238 + 0.4762j \\ 0.5238 - 0.4762j \end{bmatrix};$$

$$\text{分母：} \vec{a}_0^H \mathbf{R}_{nn}^{-1} \vec{a}_0 = \frac{1}{21} [(11 + 10j) + (11 - 10j)] = \frac{22}{21} \approx 1.0476 \text{（正实数，与 § 5.4 推导第 3 步的论断一致）；}$$

相除：

$$\vec{w}_{MVDR} = \frac{1}{22} \begin{bmatrix} 11 + 10j \\ 11 - 10j \end{bmatrix} = \begin{bmatrix} 0.5000 + 0.4545j \\ 0.5000 - 0.4545j \end{bmatrix}$$

两个权重模长相同（ $\approx 0.676$ ）、虚部符号相反，不再是 DSB 的  $[0.5, 0.5]$ 。这组反号的相位分量使干扰方向的两路加权响应接近相消。

### 第 5 步：验证两个承诺

① 目标无失真： $\vec{w}^H \vec{a}_0 = (0.5 - 0.4545j) \cdot 1 + (0.5 + 0.4545j) \cdot 1 = 1 \checkmark$ （两个虚部恰好抵消）；

② 干扰方向零陷：

$$\vec{w}^H \vec{a}_i = (0.5 - \frac{5}{11}j) \cdot 1 + (0.5 + \frac{5}{11}j)(+j) = \frac{1}{22}(1 + j) \approx 0.0455 + 0.0455j$$



$|\vec{w}^H \vec{a}_i| = \frac{\sqrt{2}}{22} \approx 0.0643$ ，即  $-23.8$  dB。干扰幅度约为输入阵元响应的  $1/15.6$ ，输出干扰功率  $10 \times 0.0643^2 \approx 0.041$ ，低于输出白噪声功率  $\|\vec{w}\|^2 \approx 0.913$ 。

为什么不是精确的 0？MVDR 只显式约束目标方向，不强制干扰方向响应为零。干扰的空间相关信息包含在  $\mathbf{R}_{nn}$  的非对角元中；本例 INR 为 10，优化得到约  $-24$  dB 的残余响应，INR 增大时该响应继续降低并趋近零。若必须在已知方向形成精确零陷，应使用 § 5.5 的 LCMV 约束。


第 6 步：检查波束图的五个方向 ( $|B(\theta)| = |\vec{w}^H \vec{a}(\theta)|$ ，完整曲线见图16)：

| 角度   | 增益 (dB) | 含义              |
|------|---------|-----------------|
| 0°   | 0.00    | 无失真约束保持单位响应     |
| +30° | -23.84  | 干扰方向受到抑制，但响应不为零 |
| +15° | -5.05   | 过渡带，被连带压低       |
| -30° | +2.61   | 无干扰一侧被抬高        |
| +45° | -8.62   | 离开最深抑制方向后响应回升   |

读图：0° 处因无失真约束保持 0 dB，30° 干扰方向的响应为  $-23.8$  dB；波束图不再左右对称。干扰一侧 ( $+\theta$ ) 整体降低，而  $-30^\circ$  附近增益升高 2.6 dB。该权重是在本例协方差与单位目标响应约束下使输出功率最小的解；协方差或干扰方向改变后，曲线也会改变。

WNG 代价：这组权重的  $G_{\text{WNG}} = 1/\|\vec{w}\|^2 = 1/0.9133$ ，所以  $\text{WNG}_{\text{dB}} \approx +0.39$  dB，比同一双麦阵的 DSB 低约 2.6 dB。该差值与干扰抑制量都只对应本算例的 INR、几何和噪声模型。

图16 8元ULA 0°指向波束图：DSB/MVDR 用  $d=\lambda/2$ ，超指向用  $d=0.2\lambda$   
 (各曲线保持目标方向单位响应；MVDR 干扰=20°；超指向相对对角加载= $10^{-6}$ ；模拟)



图示说明：图 16 的三组权重都满足目标方向单位响应。线性幅度图保留这一绝对响应，dB 图以目标响应为 0 dB 参考，并截断到 -40 dB。

DSB 与 MVDR 使用 8 元、 $d = \lambda/2$ ，MVDR 协方差模型含 20° 定向干扰。超指向使用另一个  $d = 0.2\lambda$  的紧凑阵列和相对对角加载  $10^{-6}$ 。

由于阵元间距和噪声模型不同，超指向曲线不能作为与前两条曲线的同几何性能排名；该图也不能直接给出 WNG 或 DI。图中参数与算例 5-2 的 2 元阵、30° 干扰不同，零陷深度不能直接互比。

实现中的三个问题：

1.  $\mathbf{R}_{nn}$  从哪来：无目标帧估计（语音活动检测即 VAD 辅助）；语音场景经典做法是时频掩码（Time-Frequency mask，简称 TF-mask）——神经网络预测每个时频点是语音还是噪声，分别加权估出目标/噪声协方差（在 CHiME 系列远场语音识别挑战赛中验证有效的主流做法；这类掩码做法在完整系统里的效果证据见 § 8.4）；
2. 病态与对角加载：小快拍下  $\hat{\mathbf{R}}$  可能病态，可改用  $\hat{\mathbf{R}} + \epsilon \mathbf{I}$ 。它抬高小特征值并限制权重范数；与显式 WNG 约束的关系见下文，二者不能不加条件地写成同一个问题；
3. 混响中的约束对象：自由场导向矢量只描述直达传播。混响房间中的目标通道还包含早期反射，因此实际目标传递向量可能与自由场模型不一致。可估计相对传递函数（Relative

Transfer Function，简称 RTF），用各麦相对参考麦的目标传递函数作为约束向量；RTF 估计误差仍需通过失配仿真评估。

**对角加载、WNG 约束与正则化的关系：**绝对加载写成  $\hat{\mathbf{R}} + \epsilon \mathbf{I}$ ，其中  $\epsilon$  与协方差矩阵的元素具有相同量纲；它等于在目标函数中加入  $\epsilon \|\vec{w}\|^2$ 。

为使输入整体缩放后加载强度不变，本节比较表改用无量纲相对加载量  $\alpha$ ：

$$\hat{\mathbf{R}}_{\text{load}} = \hat{\mathbf{R}} + \alpha \frac{\text{tr}(\hat{\mathbf{R}})}{M} \mathbf{I}。$$

在无失真约束下，显式约束  $\|\vec{w}\|^2 \leq \delta$  就是在设置 WNG 下限。若该约束在最优点处有效，其拉格朗日乘子会产生同形的对角加载。

给定  $\delta$  对应的  $\alpha$  依赖  $\hat{\mathbf{R}}$ 、 $\vec{a}$  和频点，不能把任意加载量与任意 WNG 门限视为相同。 $\alpha$  应按协方差条件数、器件失配仿真和所需 WNG 扫描选择。Li, Stoica & Wang, IEEE TSP 2003

**对角加载的代价表（相对加载量  $\alpha$  从小到大）：**

| $\alpha$ 取值 | 加载相对平均特征值的大小           | 白噪声增益     | 指向性/零陷深度 | 稳健性          | 适用场合            |
|-------------|------------------------|-----------|----------|--------------|-----------------|
| 较小          | 只轻微抬高特征值               | 接近未加载解    | 接近未加载解   | 小快拍下求逆仍可能病态  | 快拍充足、标定较好的离线处理  |
| 中等（由验证集确定）  | 小特征值被抬高                | 通常回升      | 通常变浅     | 对估计误差和轻微失配较稳 | 按 WNG 与目标失真联合调参 |
| 较大          | 加载项主导小特征值，继续增大时可主导整个矩阵 | 趋近 DSB 上限 | 深零陷逐渐变浅  | 解逐渐接近固定波束    | 稳健模式或诊断对照       |

读法： $\alpha$  增大时，条件数通常改善、权重范数减小，零陷和指向性也可能减弱。变化多少由协方差特征值、导向矢量与加载归一化口径共同决定，不能预先保证若干 dB。应画出 WNG、目标失真和噪声输出随归一化加载量的曲线，再按系统预算选点。

### 5.4.1 稳健波束形成方法

对角加载主要限制协方差求逆的敏感度和权重范数，不能覆盖所有失配来源。下面按四类误差分别说明可选方法、假设和代价：

- A：导向矢量失配：DOA 误差、通道增益/相位不一致或阵列标定误差使约束向量偏离真实目标传递向量；

- B: 协方差估计误差: 快拍不足、噪声非平稳或目标泄漏使  $\hat{\mathbf{R}}_{nn}$  偏离真实噪声协方差, 求逆会放大其中的小特征值误差;
- C: 相干干扰或混响: 早期反射与直达声相干, 可能降低信号子空间秩并改变零陷位置;
- D: 目标自消: 含目标的协方差与失配约束共同作用, 使自适应权重抑制真实目标。

方法 1: 最差情况优化 (Worst-Case Optimization)。若把真实导向矢量限制在球形不确定集  $\|\vec{a}_{true} - \vec{a}_0\| \leq \epsilon$  中, 可要求集合内所有导向矢量都满足最低响应。对常见球形、范数有界模型, 其 KKT 条件常导出对角加载形式, 但加载量需由不确定集半径和数据共同求得; 任意固定加载并不等同于完整的鲁棒 Capon 问题。 $\epsilon$  应由 DOA 误差和通道标定统计确定, 取大时会牺牲 DI 与零陷深度。[Vorobyov, Gershman & Luo, IEEE TSP, 2003](#)

方法 2: 特征空间波束形成 (Eigenspace Beamforming)。对含目标的采样协方差做特征分解, 把权重投影到由主要特征向量张成的子空间中, 可减小小特征值估计误差造成的权重偏差。代价是必须选择子空间维数; 低信噪比或弱目标条件下, 信号与噪声特征值难以分开, 投影也可能删除有用成分。[Chang & Yeh, IEEE Transactions on Antennas and Propagation, 1992](#)

方法 3: 协方差重构 (Covariance Reconstruction)。MVDR 需要干扰加噪声协方差, 但 VAD 选出的噪声段可能含目标残留和混响尾音。以 Capon 谱积分重构为例, 可在非目标角度区域估计空间谱, 再积分重建  $\hat{\mathbf{R}}_{nn}$ 。代价是增加谱估计与积分计算; 目标区域或积分区域设错时, 也会删除干扰信息或保留目标泄漏。[Gu & Leshem, IEEE TSP, 2012](#)

方法 4: 前后向空间平滑 (Forward-Backward Spatial Smoothing)。均匀线阵可切成重叠子阵, 先平均前向子阵协方差, 再加入共轭反转的后向项。该处理可恢复部分相干源条件下的协方差秩。代价是子阵长度小于原阵列, 因而有效孔径和剩余自由度下降; 子阵数量必须同时满足去相关与可分辨性要求。[Shan, Wax & Kailath, IEEE TASSP, 1985](#) (空间平滑)、[Pillai & Kwon, IEEE TASSP, 1989](#) (前后向扩展)

方法选择表 (对角加载主要处理病态求逆和权重范数, 其他误差还需针对性处理):

| 现象                           | 主要误差来源  | 首选                             | 备选/联合                           | 验证重点                            |
|------------------------------|---------|--------------------------------|---------------------------------|---------------------------------|
| DOA 偏差达到设备验证集中的高分位值时, 目标响应下降 | A 导向失配  | 最差情况优化 ( $\epsilon$ 按 DOA 误差定) | 导数约束 (LCMV, § 5.5)<br>降低主瓣内响应起伏 | 先测 DOA 误差分布和目标响应, 再定 $\epsilon$ |
| 更换麦克风批次后结果变化明显               | A 通道不一致 | 通道标定 + 最差情况优化                  | 对角加载                            | 用批次间标定残差设置不确定集                  |
| 噪声段含目标, 自适应后目标衰减             | D 目标自消  | 改善 VAD/SPP 与协方差估计              | 特征空间投影                          | 同时报目标响应和噪声降低量                   |

| 现象               | 主要误差来源 | 首选                | 备选/联合   | 验证重点            |
|------------------|--------|-------------------|---------|-----------------|
| 快拍少、噪声时变，求逆病态    | B 估计误差 | 对角加载 + 协方差重构      | 减少约束或降阶 | 扫描加载量、WNG 与目标失真 |
| 强早期反射或相干干扰造成零陷偏移 | C 相干   | 适用阵列上的空间平滑        | RTF 约束  | 检查子阵结构和剩余孔径     |
| 低频 WNG 很低、权重范数很大 | 超指向固有  | WNG 约束/对角加载，分频段设计 | 降阶 DMA  | 见算例 5-1 第 7 步   |

使用该表时，应先用 § 5.3 的四项诊断量确定主要误差来源，再分别验证候选方法。每次改变稳健化参数，都应重新测量 WNG、目标响应、噪声输出和任务指标。

MVDR 的闭式解依赖准确的协方差和约束向量。对角加载、最差情况优化、特征空间投影、协方差重构与空间平滑分别针对不同误差来源，选择前应先确定失配模型。

### 5.5 线性约束最小方差 (Linearly Constrained Minimum Variance, 简称 LCMV)：多约束推广

多个线性约束写成矩阵形式  $\mathbf{C}^H \vec{w} = \vec{f}$  ( $\mathbf{C}$ : 约束矩阵，每列是一个约束方向/约束向量;  $\vec{f}$ : 对应的约束值向量)，LCMV 闭式解为：

$$\vec{w}_{LCMV} = \mathbf{R}^{-1} \mathbf{C} (\mathbf{C}^H \mathbf{R}^{-1} \mathbf{C})^{-1} \vec{f} \tag{5-4}$$

注意约束的共轭方向：若第  $k$  列为  $\vec{c}_k$ ，式(5-4)约束的是  $\vec{c}_k^H \vec{w} = f_k$ ，而输出响应为  $\vec{w}^H \vec{c}_k = f_k^*$ 。希望输出复响应为  $g_k$  时，应传入  $f_k = g_k^*$ 。只用实数 0 和 1 做测试看不出这个差别，E05-04 用纯虚响应单独检查它。

( $\mathbf{R}$  可以是噪声协方差  $\mathbf{R}_{nn}$ ；目标缺席样本不可得时也会使用含目标的  $\mathbf{R}_{xx}$ ，但目标泄漏会带来自消风险。快拍少会使两种采样协方差都不稳定，仍需对角加载、收缩估计或降阶，不能把  $\mathbf{R}_{xx}$  当作小快拍问题的自动解法；见 § 5.4 工程要点。)

推导：与式(5-3)使用相同的拉格朗日乘子法，只是标量乘子改为  $K_c \times 1$  向量  $\vec{\lambda}$ 。要保证对  $\vec{w}^*$  求导时约束项确实产生  $\mathbf{C} \vec{\lambda}$ ，完整写法为

$$L = \vec{w}^H \mathbf{R} \vec{w} + \vec{\lambda}^H (\vec{f} - \mathbf{C}^H \vec{w}) + (\vec{f}^H - \vec{w}^H \mathbf{C}) \vec{\lambda}。$$

对  $\vec{w}^*$  求导并置零： $\mathbf{R} \vec{w} - \mathbf{C} \vec{\lambda} = \vec{0}$ ，因此  $\vec{w} = \mathbf{R}^{-1} \mathbf{C} \vec{\lambda}$ 。代入  $\mathbf{C}^H \vec{w} = \vec{f}$  得

$$\vec{\lambda} = (\mathbf{C}^H \mathbf{R}^{-1} \mathbf{C})^{-1} \vec{f}。$$



再代回就得到式(5-4)。拉格朗日函数必须保留成对的共轭约束项，才能保持为实数，并在对  $\vec{w}^*$  求导时得到正确的约束贡献。除  $M \times M$  的  $\mathbf{R}$  外，还要对  $K_c \times K_c$  的约束矩阵求逆。

**维度核对：**约束有  $K_c$  条， $\vec{f}$  和  $\vec{\lambda}$  都是  $K_c \times 1$  向量； $\mathbf{C}$  是  $M \times K_c$ ，所以  $\mathbf{C}^H \vec{w}$  与  $\vec{f}$  维度一致。矩阵  $\mathbf{C}^H \mathbf{R}^{-1} \mathbf{C}$  为  $K_c \times K_c$ 。若  $\mathbf{C}$  满列秩， $K_c$  条独立复线性约束把可调子空间的复维数从  $M$  降为  $M - K_c$ ； $K_c = M$  时，权重通常由约束唯一确定。

解的结构由两部分组成： $\mathbf{R}^{-1}$  按噪声与干扰的空间相关结构加权，后半部分把结果投影并归一化到满足全部约束的可行集合。常用约束包括：

1. 期望方向无失真，即  $f = 1$ ；
2. 已知干扰方向响应为零，即  $\vec{a}^H(\theta_i) \vec{w} = 0$ ；
3. 导数约束：令波束图在期望方向处对角度的一阶导数为零，以展宽目标方向附近的低失真区域。

导数约束可降低小幅 DOA 失配的影响，但会占用自由度并改变 WNG。

**约束不是免费的：**若  $\mathbf{C}$  满列秩，数学上可有  $K_c \leq M$  条独立约束。 $K_c = M$  时权重通常被约束唯一确定，没有剩余自由度用于根据  $\mathbf{R}$  压噪；若希望保留至少一个自适应自由度，则需  $K_c < M$ 。约束增多不必然使 WNG 单调恶化，但会缩小可行集合，必须逐频点检查 WNG 与目标响应。

### 算例 5-2 补充：LCMV 双约束

**题设：**沿用算例 5-2 的 2 麦阵 ( $d = \lambda/2$ ，目标  $0^\circ$ ，干扰  $30^\circ$ )，但这次干扰方向已知，要求同时满足两条约束：目标方向增益为 1、干扰方向增益为 0。约束矩阵  $\mathbf{C} = [\vec{a}_0, \vec{a}_i]$  ( $2 \times 2$ )，约束值  $\vec{f} = [1, 0]^\top$ ，噪声取白噪  $\mathbf{R} = \mathbf{I}$ （先看约束本身的效果，不掺自适应）。

**求解：** $\mathbf{R} = \mathbf{I}$  时  $\mathbf{C}^H \mathbf{R}^{-1} \mathbf{C} = \mathbf{C}^H \mathbf{C}$ 。 $\vec{a}_0 = [1, 1]^\top$ ， $\vec{a}_i = [1, +j]^\top$ ，所以

$$\mathbf{C}^H \mathbf{C} = \begin{bmatrix} 2 & 1+j \\ 1-j & 2 \end{bmatrix}。$$

该矩阵的行列式为  $4 - |1+j|^2 = 2$ ，逆为  $\frac{1}{2} \begin{bmatrix} 2 & -(1+j) \\ -(1-j) & 2 \end{bmatrix}。$

$\vec{w} = \mathbf{C}(\mathbf{C}^H \mathbf{C})^{-1} \vec{f}$  取逆矩阵第一列： $\vec{w} = \frac{1}{2} (2\vec{a}_0 - (1-j)\vec{a}_i)$ 。展开得  $\vec{w} = [0.5 + 0.5j, 0.5 - 0.5j]^\top$ 。

**验证约束：** $\vec{w}^H \vec{a}_0 = (0.5 - 0.5j) + (0.5 + 0.5j) = 1 \checkmark$ ； $\vec{w}^H \vec{a}_i = (0.5 - 0.5j) + (0.5 + 0.5j)(+j) = 0 \checkmark$ 。干扰方向满足精确零响应约束。



此时  $\|\vec{w}\|^2 = 1$ ,  $\text{WNG}_{\text{dB}} = 0 \text{ dB}$ , 比 DSB 的  $+3 \text{ dB}$  低  $3 \text{ dB}$ 。2 个麦和 2 条独立约束使权重由约束唯一确定, 没有剩余自由度再根据  $\mathbf{R}$  调整白噪声输出。

相比之下, 算例 5-2 的 MVDR 只约束目标, 得到  $\text{WNG}_{\text{dB}} = +0.39 \text{ dB}$  和干扰方向  $-23.8 \text{ dB}$ 。LCMV 适合方向先验可靠且需要硬约束的情形; MVDR 根据估计协方差自适应抑制干扰。两者的选择还取决于方向误差和协方差估计质量。

多通道维纳滤波 (Multichannel Wiener Filter, 简称 MWF) 直接在均方误差准则下权衡目标失真与残余噪声; MVDR 则施加硬的无失真约束, 两者不能一般性地视为同一个解。语音失真加权多通道维纳滤波 (Speech Distortion Weighted MWF, 简称 SDW-MWF) 写成

$$\begin{aligned} J(\vec{w}) &= E\{|n_{out}|^2\} + \frac{1}{\mu} E\{|s_{out} - s_{ref}|^2\}, \\ \Rightarrow \vec{w}_{SDW} &= (\mathbf{R}_{ss} + \mu \mathbf{R}_{nn})^{-1} \mathbf{R}_{ss} \vec{e}_r. \end{aligned} \quad (5-5)$$

- $\mathbf{R}_{ss}, \mathbf{R}_{nn}$ : 目标与噪声协方差矩阵;  $\vec{e}_r$ : 参考麦选择向量 (第  $r$  位为 1 的单位向量, 即 “以第  $r$  个麦收到的目标为基准”);
- $\mu = 1$  是普通 MWF;  $\mu > 1$  更重视噪声项, 抑制增强而目标失真通常增大;  $\mu < 1$  更重视目标保真。令  $\mu \rightarrow \infty$  时权重趋近零, 并不趋近 MVDR。只有秩一目标模型  $\mathbf{R}_{ss} = \phi_s \vec{a} \vec{a}^H$  且参考麦归一化  $a_r = 1$  时, 才有

$$\vec{w}_{SDW} = \frac{\phi_s q}{\mu + \phi_s q} \vec{w}_{MVDR}, \quad q = \vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a}.$$

此时 SDW-MWF 是 MVDR 输出再乘一个标量 Wiener 增益, 并在  $\mu \rightarrow 0^+$  时趋近 MVDR。目标协方差满秩时没有这个简单关系。Doclo, Spriet, Wouters & Moonen, *Speech Communication*, vol.49, p.636, 2007

前文给出的是 LCMV 的频域闭式解。Frost 算法是它的一种经典时域在线实现; 下面给出更新式, 并与 GSC 的结构对照。

Frost 波束形成器 (1972): LCMV 的时域在线版。§ 5.1 末提过它是滤波求和的自适应代表, 这里把更新式写出来: 每路麦接一段  $J$  抽头 FIR, 第  $m$  路第  $j$  抽头权重记  $w_{m,j}$ , 全权重向量  $\vec{w}$  共  $MJ$  个系数。约束是“看目标方向”的线性约束  $\mathbf{C}^H \vec{w} = \vec{f}$  (比如每列约束钉住一个抽头时刻的目标响应), 更新分两步走:

$$\vec{w}(l+1) = \mathbf{P} [\vec{w}(l) - \mu \vec{x}(l) y^*(l)] + \vec{w}_q. \quad (5-6)$$

方括号中是复数 LMS 的瞬时负梯度步：对  $|y(l)|^2$  求导得到与  $\vec{x}(l)y^*(l)$  同向的梯度。投影矩阵  $\mathbf{P} = \mathbf{I} - \mathbf{C}(\mathbf{C}^H\mathbf{C})^{-1}\mathbf{C}^H$  把更新限制在约束零空间， $\vec{w}_q = \mathbf{C}(\mathbf{C}^H\mathbf{C})^{-1}\vec{f}$  是满足约束的最小范数特解。约束模型匹配时，更新不改变受约束的目标响应；指向或传递函数失配时，真实目标仍可能失真。步长太大会发散，太小则跟不上非平稳干扰。

Frost 与 GSC 对照表（同一类 LCMV 约束的两种实现结构）：

|       | Frost (1972)                                | GSC                                        |
|-------|---------------------------------------------|--------------------------------------------|
| 域     | 时域 FIR 抽头                                   | 频域逐频点（TF-GSC）或时域皆可                         |
| 约束怎么装 | 投影矩阵 $\mathbf{P}$ ，每步拽回约束平面                 | 结构吸收：固定上支路 + 阻塞矩阵，下支路无约束自适应                |
| 自适应算法 | 原始 Frost 使用带投影的 LMS；也可研究其他受约束更新             | 下支路可使用 LMS、NLMS、RLS 等无约束更新                 |
| 收敛与跟踪 | 由自适应算法、输入协方差特征值分布、步长和约束实现共同决定               | 还受阻塞矩阵、下支路输入统计和所选自适应算法影响；结构本身不保证比 Frost 更快 |
| 失配症状  | 目标泄漏进 LMS，实际目标不再满足设计约束                      | 目标泄漏进阻塞矩阵下支路，被当作干扰对消                       |
| 延迟    | 不含 STFT 分帧等待，但仍有滤波器群时延、约束对齐延迟、输入输出缓冲和硬件分块延迟 | 频域版另有窗、帧移、重叠相加和前瞻造成的等待；时域版仍有滤波与缓冲延迟        |
| 约束实现  | 每次更新后投影回约束子空间                               | 固定支路与阻塞矩阵从结构上满足约束                          |


Frost 用投影更新实现时域 LCMV；下一节的 GSC 用固定支路和阻塞矩阵实现同一类约束。

### 5.6 广义旁瓣对消器（Generalized Sidelobe Canceller，简称 GSC）：把约束改装成“噪声对消器”

广义旁瓣对消器把 LCMV 约束吸收进结构，分两条支路。[Griffiths & Jim, \*IEEE Transactions on Antennas and Propagation\*, 1982](#)

图17 GSC（广义旁瓣对消器）结构框图

上支路（设计目标：期望方向单位响应）



模型匹配且滤波器收敛时：保持目标响应，对消相关干扰

图示说明：上支路固定波束形成器输出目标与残留噪声  $d$ ；下支路的阻塞矩阵在模型匹配时消除目标，得到近似不含目标的干扰参考  $u$ ；自适应滤波器由  $u$  估计上支路中与它相关的残留干扰  $y$ ，最后相减得到  $e = d - y$ 。图中的“目标无失真”和“干扰/噪声被自适应对消”表示设计目标，只有固定支路满足约束、阻塞矩阵模型匹配且自适应滤波器收敛时才成立。数值过程见算例 5-3。

- 上支路：固定波束形成器的设计目标是在期望方向保持规定响应，输出  $d$  包含目标与残留噪声；
- 下支路：阻塞矩阵  $\mathbf{B}$ （设计条件为  $\mathbf{B}^H \vec{a}(\theta_0) = \vec{0}$ ）在模型匹配时消除目标，产生干扰与噪声参考；多通道自适应滤波器再估计上支路中与该参考相关的分量  $y$ ；
- 相减  $e = d - y$ ：在上支路满足目标约束、阻塞矩阵精确消除目标且自适应滤波器收敛时，对消与下支路相关的噪声，同时保持设计目标响应。任一条件失配都可能造成目标衰减。

算例 5-3：GSC 数字走一遍——干扰是怎么被“减掉”的。 `scripts/make_figures.py::fig_gsc` 只生成图17的结构框图；本例直接求给定单快拍模型下的最优系数，不模拟有限步自适应收敛。

题设：2 麦， $d = \lambda/2$ ；目标  $0^\circ$ ，即正横方向；干扰  $60^\circ$ 。

上支路使用延迟求和。下支路使用阻塞矩阵  $\mathbf{B} = [1, -1]^T$ ，其维度为  $2 \times 1$ ，两路相减。这是 2 麦特例； $M$  麦时  $\mathbf{B}$  为  $M \times (M - 1)$ ，常用相邻通道相减或取  $\vec{a}(\theta_0)$  的正交补基。

2 麦阻塞后只剩 1 路噪声参考，因此自适应滤波器退化为 1 个复数抽头  $h$ 。

预备数字：  $\psi_{60} = \pi \sin 60^\circ = 2.7207 \text{ rad } (155.9^\circ)$  ,  $\vec{a}(0^\circ) = [1, 1]^\top$  ,  
 $\vec{a}(60^\circ) = [1, e^{+j2.7207}]^\top = [1, -0.9127 + 0.4086j]^\top$  。

### 第 1 步：上支路（延迟求和）漏进多少干扰

上支路权重  $\vec{w}_u = [0.5, 0.5]^\top$ 。目标方向增益  $\vec{w}_u^H \vec{a}(0^\circ) = 1 \checkmark$ （无失真）；  $60^\circ$  方向的泄漏增益：

$$\begin{aligned} g_u &= \vec{w}_u^H \vec{a}(60^\circ) = \frac{1}{2} (1 + e^{+j2.7207}) \\ &= 0.0436 + 0.2043j, \\ |g_u| &= |\cos \frac{\psi}{2}| = 0.2089 \text{ } (-13.6 \text{ dB}). \end{aligned}$$

干扰在目标支路里还残留约 21% 的幅度——这就是图 17 中 “ $d = \text{目标} + \text{漏入噪声}$ ” 里那部分 “漏入噪声” 。

### 第 2 步：下支路把目标陷掉、只留干扰

验证阻塞：  $\mathbf{B}^H \vec{a}(0^\circ) = 1 \times 1 + (-1) \times 1 = 0 \checkmark$ 。目标方向被精确陷掉，下支路里没有目标。这是整个结构的关键前提； § 5.6 所说的 “阻塞矩阵失配” ，就是指这个 0 在实际中保不住。

干扰在下支路的增益为

$$\begin{aligned} g_\ell &= \mathbf{B}^H \vec{a}(60^\circ) = 1 - e^{+j2.7207} \\ &= 1.9127 - 0.4086j, \\ |g_\ell| &= 2 |\sin \frac{\psi}{2}| = 1.9559. \end{aligned}$$

两路相减反而把干扰放大了近 2 倍（因为  $60^\circ$  方向上两麦相位差  $155.9^\circ$  ，接近反相，相减近乎同相叠加）——没关系，它只是一份 “干扰参考样本” 。

### 第 3 步：拿一个具体快拍走一遍

设该频点目标谱  $s = 1$ 、干扰谱  $i = 1$ （都是标量复数），则阵列快拍：

$$\vec{x} = \vec{a}(0^\circ) \cdot 1 + \vec{a}(60^\circ) \cdot 1 = \begin{bmatrix} 2.0000 \\ 0.0873 + 0.4086j \end{bmatrix}$$

上支路输出：

$$\begin{aligned} d &= \vec{w}_u^H \vec{x} = \frac{2.0000 + 0.0873 + 0.4086j}{2} \\ &= 1.0436 + 0.2043j \\ &= \underbrace{1}_s + \underbrace{(0.0436 + 0.2043j)}_{g_u \cdot i}. \end{aligned}$$

花括号下第二项即泄漏项  $g_u \cdot i$ 。

下支路输出： $u = \mathbf{B}^H \vec{x} = 2.0000 - (0.0873 + 0.4086j) = 1.9127 - 0.4086j$  ( $= g_\ell \cdot i$ ，纯干扰，目标分量为 0)。

#### 第 4 步：自适应滤波器学出的那个系数

对消器要减掉的正是泄漏项  $g_u \cdot i$ ，而它手里只有  $u = g_\ell \cdot i$ ，所以最优系数：

$$h^* = \frac{g_u}{g_\ell} = +0.1068j, \quad h = -0.1068j$$

(直接乘子  $h^*$  是纯虚数：把下支路的干扰副本旋转  $+90^\circ$ ，再缩放到 0.107 倍。) 验证：

$$h^* \cdot u = +0.1068j \times (1.9127 - 0.4086j) = 0.0436 + 0.2043j.$$

(在给定舍入精度内与泄漏项一致。)

$$e = d - h^* u = (1.0436 + 0.2043j) - (0.0436 + 0.2043j) = 1.0000 = s \checkmark$$

在本例的单个相干干扰、精确阵列模型和最优系数下，输出只剩目标。把同一路径上的干扰标量换成  $i = 0.5j$ 、 $-2$ 、 $0.3 + 0.7j$  再算， $e$  仍等于 1，因为上下支路的干扰都按同一标量缩放。加入不相关噪声、第二个独立干扰、阻塞泄漏或有限步自适应后，这个结论不再成立。

#### 第 5 步：实际系统怎样估计 $h$

实际系统不知道  $g_u$ 、 $g_\ell$ 。按  $e(l) = d(l) - h^*(l)u(l)$  的复数约定，使用先验残差和旧权重作一次 NLMS 更新：

$$h(l+1) = h(l) + \mu \frac{u(l)e^*(l)}{|u(l)|^2 + \varepsilon}. \quad (5-7)$$

若阻塞支路中只有与目标不相关的干扰，式(5-7)会学习上支路中与  $u$  相关的分量。本例的理想收敛目标是  $h = -0.1068j$ ，等价的直接乘子  $h^*$  为  $+0.1068j$ ；具体稳定步长和收敛帧数取决于输入统计，不能由这一帧手算固定。

#### 第 6 步：检查阻塞矩阵失配

上述对消依赖  $\mathbf{B}^H \vec{a}(0^\circ) = 0$ 。若目标实际方向偏到  $2^\circ$ ，则

$\mathbf{B}^H \vec{a}(2^\circ) = 1 - e^{+j\pi \sin 2^\circ} \approx 0.0060 - 0.1094j$ ；其模约为 0.1096，功率约为 1.2%。自适应滤波器会把泄漏目标的一部分当作干扰抵消，造成语音衰减或断续。可使用自适应阻塞矩阵 (ABM) 和语音存在门控降低这一风险。

优点：约束由固定支路与阻塞矩阵实现，下支路可用 LMS 等无约束自适应算法。主要边界——阻塞矩阵失配：目标因 DOA 误差或混响泄漏进下支路时，会被当作噪声对消。可使用自适应阻塞 (ABM)、语音存在概率门控步长和泄漏均衡 (CA-GSC)。

LCMV 与 GSC 的等价条件：若固定权重满足 LCMV 约束，阻塞矩阵的列满秩且张成约束矩阵的零空间，无约束支路又达到同一二次目标的最优解，那么 GSC 与 LCMV 给出同一个最优权重。GSC 把“带约束求解”改写成“固定支路 + 零空间内的无约束优化”。有限步自适应、阻塞矩阵失配、秩不足或不同的正则化都会破坏严格等价，因此工程实现仍要分别检查收敛和目标泄漏。[Breed & Strauss, IEEE SPL 2002](#)

LCMV 把 MVDR 的单约束推广为多约束；Frost 用投影更新实现时域 LCMV；GSC 用固定支路和阻塞矩阵实现相同约束。三者都受约束失配影响，GSC 还要单独检查目标向下支路的泄漏。

## 5.7 后置滤波

波束形成后仍可能保留弥散噪声、旁瓣干扰和混响。后置滤波在波束输出上估计残留噪声谱，再按各时频点的统计量计算增益。本节先比较噪声谱估计方法，再讨论语音存在概率（§ 5.7.1）、Wiener 增益（§ 5.7.2）和音乐噪声代价（§ 5.7.3）。

- Zelinski (1988)：先按目标方向做时延/相位对齐，并通常把各通道目标传递幅度归一化。在目标同相同幅、通道噪声互不相关且噪声自谱相同的模型下，自谱均值减去互谱实部均值可估计每个输入通道的噪声功率谱：

$$\hat{\phi}_{n,\text{in}}(k) = \frac{1}{M} \sum_{i=1}^M \Phi_{x_i x_i}(k) - \frac{2}{M(M-1)} \sum_{i < j} \text{Re}\{\Phi_{x_i x_j}(k)\}.$$

$\Phi_{x_i x_i}$  为自功率谱， $\Phi_{x_i x_j}$  为互功率谱。这个输入通道估计不能直接当成任意波束输出的残留噪声。若采用上述独立同功率模型，噪声 SCM 为  $\hat{\phi}_{n,\text{in}} \mathbf{I}$ ，通过权重后的估计为  $\hat{\phi}_{n,\text{in}} \|\vec{w}\|^2$ ；等权平均时才简化为  $\hat{\phi}_{n,\text{in}}/M$ 。

未对齐时，目标互谱带有传播相位，公式会把目标的一部分误判为噪声；噪声相关或目标幅度不一致也会造成偏差。输出 PSD 必须与所用波束权重对应，相关结构与后滤位置的区别见 [Li 与 Akagi 2005](#)，§ 2、式(1)、(5)、(8)。

- McCowan (2003) 的改进：Zelinski 的“各麦噪声互不相关”假设不适用于弥散混响场；相邻麦噪声具有相干性，直接使用互谱关系可能低估噪声功率，有限样本下还可能得到负估计。McCowan 方法引入弥散噪声场的理论相干函数（sinc 形的  $\mathbf{\Gamma}$ ，§ 5.1）修正互谱项。其效果取决于实际声场与弥散模型的匹配程度（本节算例给出指定输入下的偏差量级）；
- 对数谱幅度（Log-Spectral Amplitude, LSA）/优化修正 LSA（Optimally Modified LSA, OM-LSA）：在对数谱幅度最小均方误差准则下估计增益；OM-LSA 还显式结合语音存在不确定性。[Habets & Cohen, IWAENC 2006](#)



### 5.7.1 逐时频点语音存在概率 (SPP)

SPP (Speech Presence Probability, 语音存在概率) 记为  $p(k, n) \in [0, 1]$ , 表示第  $k$  个频点、第  $n$  帧含语音的后验概率。它不同于 VAD 的帧级 0/1 判决, 可用于在语音保留与噪声更新之间连续加权。

最小值控制递归平均 (Minima-Controlled Recursive Averaging, MCRA) : 算法在每个频点跟踪一段时间内的平滑功率最小值, 并根据当前功率相对该最小值的偏离估计 SPP。SPP 较低时更新噪声谱, SPP 较高时减慢或冻结更新, 以减少语音泄漏对噪声估计的污染。改进最小值控制递归平均 (Improved Minima-Controlled Recursive Averaging, IMCRA) 进一步改进了最小值跟踪和概率估计; 具体窗口与门限应按所用文献版本实现。

对前级自适应模块的门控: GSC 可把 NLMS 步长乘以  $(1 - p)$ , 在语音存在概率高时减慢更新; MVDR 也可主要使用低 SPP 时频点更新噪声协方差。这些门控都依赖 SPP 的校准质量, 错误的高概率会降低跟踪速度, 错误的低概率会增加目标泄漏。

### 5.7.2 Wiener 后滤通用式: SPP 加权与 MWF 级联

构造 Wiener 型后滤时, 先将噪声估计转换到波束输出, 再按同一输出端的信噪比计算增益:

$$G(k, n) = \max\left(1 - \frac{\hat{\Phi}_{nn}(k, n)}{\Phi_{yy}(k, n)}, G_{\min}\right), \quad (5-8)$$
$$\hat{S}(k, n) = G(k, n)Y(k, n)。$$

$Y$  是波束输出,  $\Phi_{yy}$  是其功率谱,  $\hat{\Phi}_{nn}$  是估计的残留噪声谱,  $G_{\min}$  是最小允许增益, 也称增益地板。若这里的  $G$  用作实数非负的幅度增益, 应取  $0 \leq G_{\min} \leq 1$ :  $G_{\min} = 0$  允许完全压低一个时频点,  $G_{\min} = 1$  则不衰减。它限制最大衰减量, 以减轻谱估计误差造成的音乐噪声; 取值应按听感、目标失真和残留噪声共同确定。

SPP 可用于条件更新噪声谱, 也可连续调节增益。优化修正 LSA (OM-LSA) 是在对数谱幅度最小均方误差准则下结合语音存在不确定性的一类方法。

这里  $\hat{\Phi}_{nn} = \vec{w}^H \hat{\mathbf{R}}_{nn} \vec{w}$ , 而不是输入通道自谱。直接从输出估计噪声时也应使用同一个输出端。分母为零表示没有可用输出功率, 此时不能按上式作除法; 实现可跳过该点, 或以功率下限保护除法并单独标记无有效 SNR 证据。若噪声估计超过输出功率, 上式的  $\max$  会把负的原始增益截到非负地板。

与 MWF 的关系：MWF (§ 5.5 末) 在一个均方误差目标中联合权衡残留噪声和目标失真。

MVDR 与单通道 Wiener 后滤级联时，前级施加空间无失真约束，后级再按时频统计抑制残留噪声；两级的估计误差和延迟会累加。两种结构没有无条件的优劣，应在同一目标参考、延迟预算和任务指标下比较。

### 5.7.3 音乐噪声与三项调节参数

音乐噪声表现为随时间和频率随机出现的窄带音调成分。主要原因是噪声谱估计误差使相邻时频点的增益变化不连续，以及  $G_{\min}$  过低导致被强衰减点与残留点之间反差过大。

三项参数分别影响不同误差：

1. 提高增益地板  $G_{\min}$  会减小相邻时频点之间的衰减反差，通常也会保留更多残留噪声。
2. 帧间或频间平滑会减小增益的局部波动，但平滑时间或频带过宽时会模糊语音起止和瞬态。
3. 把增益改为  $1 - \alpha \hat{\Phi}_{nn} / \Phi_{yy}$  且取  $\alpha > 1$ ，会增大估计噪声的扣除量，同时提高目标语音被衰减的风险。 $\alpha$  没有脱离算法版本、噪声估计偏差和数据集的通用范围。

参数选择应在同一组验证片段上做受控扫描，同时报告残留噪声、目标失真和音乐噪声的听评或指标。比较某一参数时保持其余参数不变。

#### 算例 5-4：残留噪声谱估计与逐点增益

题设：3 麦已按目标对齐，目标与噪声不相关。目标功率为 3，各通道噪声功率为 1，两两噪声互谱均为实数 +0.3。所以输入自谱均为 4、互谱均为 3.3。波束明确取等权平均  $\vec{w} = [1, 1, 1]^T / 3$ ，增益地板取 0。

第 1 步：区分输入与输出。自谱平均减互谱实部平均给  $\hat{\phi}_{n,\text{in}} = 4 - 3.3 = 0.7$ ，比每通道真实噪声功率 1 低 0.3。正相关噪声被误计入相干目标；这一步尚未计算波束输出。

真实噪声 SCM 为  $\mathbf{R}_{nn} = 0.7\mathbf{I} + 0.3\mathbf{1}\mathbf{1}^T$ ，其中  $\mathbf{1}$  是三维全 1 向量。三个对角项与六个非对角项共同给出输出噪声：

$$\Phi_{n,\text{out}} = \vec{w}^H \mathbf{R}_{nn} \vec{w} = \frac{3 \times 1 + 6 \times 0.3}{9} = \frac{8}{15} \approx 0.5333。$$

目标响应为 1，故输出总功率为  $3 + 8/15 = 53/15 \approx 3.5333$ ，不是输入自谱 4。使用真实噪声的理想 Wiener 增益为  $G_{\text{true}} = 3/(53/15) = 45/53 \approx 0.8491$ 。

第 2 步：计算错误噪声模型带来的增益偏差。若仍按独立同功率噪声模型使用输入估计 0.7，推到输出得到  $\hat{\Phi}_{n,\text{out}} = 0.7 \|\vec{w}\|^2 = 0.7/3 = 7/30$ 。用同一个输出总功率计算：

$$\hat{G} = 1 - \frac{7/30}{53/15} = \frac{99}{106} \approx 0.9340。$$

该增益高于 0.8491，会少抑制残留噪声；偏差来自独立噪声假设失效。本例是依据给定 SCM 的本书手算，可由 E05-03 复算，不是完整 Zelinski 软件的实测结果。

同一个实数增益会把该时频点的目标和噪声功率都乘以  $G^2$ ，所以单个时频点的 SNR 不变。整段信号的 SNR 改善来自不同点使用不同增益；效果还取决于语音活动、估计偏差和平滑，不能由这个单点推出固定的 dB 收益。

**为什么放在最后、且通常只改幅度：**波束形成先利用空间信息，后置滤波再按时频统计压制残留噪声。实数非负增益保留波束输出相位，但仍会改变目标幅度；降噪量与目标失真必须在同一测试集、同一参考信号和同一统计区间内同时报告，不能脱离条件承诺固定 dB 收益。学习型后置滤波器也要按相同口径检查目标失真、因果延迟和目标硬件上的资源消耗，不能仅凭模型名称推断效果。

## 5.8 球谐域波束形成（球阵专属）

球阵把声场分解为球谐系数：

$$p(\kappa, \Omega) = \sum_{n=0}^N \sum_{m=-n}^n b_n(\kappa r) Y_n^m(\Omega) \varphi_{nm}(\kappa)$$

逐个符号说明如下。式中已省略与方向无关的常数因子。

- $p(\kappa, \Omega)$  是波数  $\kappa = 2\pi f/c$ 、方向  $\Omega$  处的声压；这里改用  $\kappa$ ，避免与前文的 STFT 频点索引  $k$  混淆；
- $Y_n^m(\Omega)$  是球谐函数，阶数  $n$  表示球面上的空间变化快慢，同一阶有  $2n + 1$  个不同的  $m$ ；
- $b_n(\kappa r)$  是径向项，描述半径  $r$  的球阵对第  $n$  阶成分的响应；刚性球与开放球的形式不同；
- $\varphi_{nm}(\kappa)$  是声场在第  $(n, m)$  个空间模式上的系数。

球谐展开与时间傅里叶展开的共同点是都把信号投影到一组正交基。两者的定义域和物理单位不同，不能把波数直接当作频点编号。

在理想球谐表示、相同阶数截断和正确旋转下，波束图可通过旋转系数转向而不改变自身形状。该性质支持高阶立体声（Higher-Order Ambisonics，简称 HOA）录音、最大 DI 波束和相位模式超指向。

表示到  $N$  阶共有  $(N + 1)^2$  个系数：第  $n$  阶的  $m$  从  $-n$  到  $n$ ，共有  $2n + 1$  个；把第 0 阶到第  $N$  阶相加得到  $1 + 3 + \cdots + (2N + 1) = (N + 1)^2$ 。例如截到  $N = 3$  阶，需要表示  $1 + 3 + 5 + 7 = 16$  个模式，因此  $M \geq 16$  只是阵元数量的必要条件。

采样矩阵还必须满列秩，阵元布局要能稳定区分这些模式，径向响应也不能落入未正则化的深零点。即使有 16 支麦克风，几何位置退化或某阶径向响应过小，仍可能无法稳定估计 16 个系数。高阶重建常因径向补偿和采样条件数而放大噪声。

课程讲义引用的特定实验称小球阵可接近大线阵的识别性能，该结论只适用于其阵列、数据和识别器。[Kumatani et al. (出处同 § 5.2 引文) ]

**圆阵的二维对应：相位模式（phase-mode / 圆谐波）处理。**圆阵可把圆环上的声场做方位角傅里叶分解（Jacobi – Anger 展开）。各阶圆谐波系数经模态补偿后，可在模型成立的频带内合成能电子转向的波束。

模态补偿涉及贝塞尔函数  $J_n(\kappa r)$ 。当它接近零时，除法会放大噪声；因此阶数不仅受麦克风数量限制，还要受正则化和 WNG 约束。同心多环圆阵（Concentric Circular Microphone Array, CCMA）提供另一种扩展可控频带和空间自由度的几何结构；具体结果见 Huang、Chen 与 Benesty, *Insights into Frequency-Invariant Beamforming with Concentric Circular Microphone Arrays*, IEEE/ACM TASLP 26(12), 2305 – 2318, DOI [10.1109/TASLP.2018.2862826](https://doi.org/10.1109/TASLP.2018.2862826)。

**球谐域实现步骤：**

1. **设备选型：**先定最高工作频率  $f_{\max}$  与球半径  $r$ ，算  $\kappa r = 2\pi f_{\max} r / c$ 。阵元数要满足  $M \geq (N + 1)^2$ ，还要检查实际采样矩阵的秩和条件数。刚性球与开放球的径向响应不同；选型时应计算目标频带内各阶  $b_n(\kappa r)$  的最小幅度，不能只按麦数定阶。
2. **定阶数：** $N \approx \kappa r$  可作为声场截断的起点，因为远高于  $\kappa r$  的阶成分幅度通常较小。如  $r = 4.2 \text{ cm}$ 、 $f = 4 \text{ kHz}$ ， $\kappa r \approx 3.1$ ，可先评估  $N = 3$ （至少需要 16 个稳定、独立的采样通道）。最终阶数还要受 WNG 和径向条件数约束。
3. **径向补偿：**球谐系数  $\varphi_{nm}$  要从麦克风声压反推，需除以径向项  $b_n(\kappa r)$ 。当  $|b_n|$  很小时，补偿会放大噪声；应对逆径向滤波做正则化或显式限制模态 WNG，并报告阈值的归一化口径。
4. **正则化：**对高阶模态加入特征波束正则。它与 § 5.4 的对角加载都通过限制病态方向上的增益改善数值稳定性，但作用域和参数定义不同。
5. **实现检查：**先用球谐变换把阵列信号转成  $\varphi_{nm}(\kappa)$ ，再在模态域设计权重。固定目标波束可用 Wigner-D 矩阵旋转系数；涉及数据相关 SCM 的 MVDR 仍要更新统计量和权重，不能把所有波束都概括为“一次闭式求解”。

## 5.9 深度神经网络 (Deep Neural Network, 简称 DNN) 波束形成

神经网络最适合先解决解析波束形成中难估计的统计量，而不是把多个模型名称并列成性能等级。以掩码波束形成为例，固定频点  $k$ ，多通道观测为  $\vec{x}(k, n) \in \mathbb{C}^M$ ，网络输出目标掩码  $m_s(k, n)$  和噪声掩码  $m_n(k, n)$ 。一个可复现的处理顺序如下。

### 1. 掩码到空间协方差矩阵 (Spatial Covariance Matrix, SCM) :

$$\hat{\mathbf{R}}_{ss}(k) = \frac{\sum_n m_s(k, n) \vec{x}(k, n) \vec{x}^H(k, n)}{\max\{\sum_n m_s(k, n), \epsilon\}},$$

$$\hat{\mathbf{R}}_{nn}(k) = \frac{\sum_n m_n(k, n) \vec{x}(k, n) \vec{x}^H(k, n)}{\max\{\sum_n m_n(k, n), \epsilon\}}.$$

分母做掩码权重归一化； $\epsilon$  只保护数值，不能使零掩码拥有统计依据。直接调用本书的 `masked_spatial_covariance()` 时，掩码和低于  $\epsilon$  会使协方差随掩码整体缩小。两麦 `mask_mvdr_2x2()` 则先在每个频点分别用目标和干扰掩码的最大值归一化，再估计协方差；因此统一缩小非零掩码不会触发绝对权重和阈值。

掩码全零或统计量、求解不可用时，该函数回退到参考麦；它不检查原始掩码的置信程度。实际系统若要拒绝低可信度频点，须在归一化前定义有效支持量与阈值，并规定保持已验证权重或旁路等策略。协方差是否使用未来帧决定这一步能否在线运行。

### 2. SCM 到约束向量或广义特征向量：在秩一目标近似下，可取 $\hat{\mathbf{R}}_{ss}$ 的主特征向量并按参考麦归一化，得到相对传递函数 $\hat{a}$ 。MVDR 再用式(5-3)求权重。另一条路线直接解

$$\hat{\mathbf{R}}_{ss} \vec{w}_{GEV} = \lambda_{\max} \hat{\mathbf{R}}_{nn} \vec{w}_{GEV},$$

最大化估计输出 SNR。GEV 没有无失真约束， $c\vec{w}_{GEV}$  对任意非零复数  $c$  都表示同一广义特征向量，因此必须注明参考麦归一化、盲解析归一化 (Blind Analytic Normalization, BAN) 或后置滤波的尺度规则。Warsitz & Haeb-Umbach 2007

### 3. 滤波与检查：输出 $Y = \vec{w}^H \vec{x}$ 。除信号指标外，还要检查 $\hat{\mathbf{R}}_{nn}$ 条件数、目标响应、WNG、掩码泄漏和通道置换。网络训练集未覆盖的阵列几何或混响条件可能使 SCM 估计偏离真实统计量；解析求解并不会自动消除这种误差。Erdogan et al., Interspeech 2016、Heymann et al., ICASSP 2017

两麦小例子：设掩码估得  $\hat{\mathbf{R}}_{nn} = \text{diag}(2, 1)$ ，目标 RTF 为  $\hat{a} = [1, 1]^T$ 。则  $\hat{\mathbf{R}}_{nn}^{-1} \hat{a} = [0.5, 1]^T$ ，归一化分母为 1.5，所以  $\vec{w}_{MVDR} = [1/3, 2/3]^T$ 。

可直接验证  $\vec{w}^H \hat{a} = 1$ ，输出噪声功率为  $\vec{w}^H \hat{\mathbf{R}}_{nn} \vec{w} = 2/3$ 。

若目标掩码把干扰大量计入  $\hat{\mathbf{R}}_{ss}$ ，RTF 会偏移，上述无失真条件只对错误的  $\hat{a}$  成立。



掩码尺度与空掩码的边界例子：取四帧两麦复谱  $\vec{x}_1 = \vec{x}_2 = [1, 1]^\top$ 、 $\vec{x}_3 = \vec{x}_4 = [1, -1]^\top$ ，目标掩码为  $[1, 1, 0, 0]$ ，干扰掩码为  $[0, 0, 1, 1]$ 。目标方向  $[1, 1]^\top$  与干扰方向  $[1, -1]^\top$  正交；采用默认正对角加载  $10^{-6}$  的两麦基线得到  $\vec{w} = [1/2, 1/2]^\top$ ，输出为  $[1, 1, 0, 0]$ 。把非零目标掩码的 1 全部改成  $10^{-300}$ ，峰值归一化后权重和输出不变；把目标掩码改成全零，则退回参考麦，输出变成  $[1, 1, 1, 1]$ 。

这是本书代码的确定性算例，不表明极小网络概率具有可信统计量；两组掩码只由两帧构成，也不能推断真实语音分离性能。

端到端网络也可以直接估计复数权重、时域滤波器或输出波形。它不再自动满足无失真、WNG 或因果约束，必须把阵列泛化、前瞻帧数、目标失真和目标硬件上的资源消耗列入评测。若与 ASR 联合训练，还应固定后端识别器和评分脚本，同时报告前端信号指标与词错误率（Word Error Rate, WER）。Gu et al., IEEE/ACM TASLP 2023

### 5.9.1 可执行基线与上线检查

`beamforming.py` 提供 DSB、弥散场相干矩阵、加载超指向/MVDR、LCMV、GSC 阻塞矩阵和 Wiener 增益的原创 NumPy 基线。权重约定统一为输出  $Y = \vec{w}^H \vec{x}$ ，多通道谱形状统一为 通道 × 频点 × 帧；逐频点权重为 频点 × 通道。

函数用线性方程求解代替显式求逆；未加载协方差病态、LCMV 约束不独立或空统计量都会报错。正文算例的 DSB 单位响应、Capon 数值、MVDR 权重、LCMV 双约束、GSC 阻塞和 Wiener 增益由 `test_codes_doa_beam.py` 独立回归，串联示例见 `ch02_05_baselines.py`。

DSB 对非零导向矢量计算  $\vec{a}/(\vec{a}^H \vec{a})$ ；实现先按最大分量缩放，再归一化，以免极大或极小的有限输入在平方时溢出或下溢。若结果本身超出浮点范围则报错，而不是返回貌似有效的零权重。Wiener 增益中的功率必须为有限非负实数，不能把复数功率的虚部丢掉后继续运行；相关边界回归见 `test_codes_spatial_round3.py`。

这些函数是公式基线，不是完整设备状态机。实时实现还要记录 STFT 窗长和帧移、分数延时滤波器、固定传播补偿、参考通道、SCM 遗忘因子、VAD/SPP 门控、权值更新周期和输出限幅。每次更新后检查条件数、 $|\vec{w}^H \vec{a} - 1|$ 、WNG 和输出峰值；空掩码或病态矩阵出现时，应在“保持上一组已验证权值、增加已标明口径的加载、退回 DSB”之间预先规定顺序。目标泄漏时应冻结噪声 SCM 或 GSC 自适应支路，并记录触发原因，不能只在输出失真后重新初始化。



外部波束实现按完整提交号保存在 `codes/upstream/_downloads/`，取得源码后的构建、数值回归和设备测试分别记录。版本与许可可见 [SOURCES.lock.json](#)，扩展实验和源码阅读顺序见[空间处理与追踪研究](#)。TorchAudio 的 `examples/tutorials/mvdr_tutorial.py`、ESPnet 的 `espnet2/enh/layers/beamformer.py` 分别连接掩码、协方差、参考通道与输出波形；复现应使用锁定源码及相容依赖，不能把浮动 nightly 文档当作稳定发行版契约。

持续自适应 GSC 可读 BTK2.0 的 `btk20_src/lib/pybeamformer.py::SubbandGSCLMSBeamformer` 和 `SubbandGSCRLSBeamformer`，由 `unit_test/test_online_beamforming.py` 连接逐通道音频、滤波器组、方向控制和输出。这些类保留跨帧更新状态，补充了本书只生成阻塞矩阵的教学基线；其子带实现不能直接当作 § 5.5 的时域 Frost。固定 BTK 作者源码。

BTK 示例声速取 `343740.0`，与毫米坐标配套；本书米制阵列不能直接代入。构建默认 Python 2.7，并要求 SWIG、GSL、NumPy 和 libsndfile，不能仅凭根目录 MIT 许可或示例存在便认为可在现代环境直接运行。研究文档分别列出构建前提和目标偏移、更新冻结的最小实验；这些上游数值实验尚未执行。

球阵还多了一层编码误差。`sound_field_analysis/process.py::spatFT` 计算球谐系数，`gen.py::radial_filter` 控制径向补偿；Politis 的 `arraySHTfiltersMeas_regLS.m` 用实测响应设计编码滤波器，`sphMVDR.m`、`sphLCMV.m` 在球谐域求权重。[sfa 官方接口](#)；[Politis 作者实现](#)。

先用已知平面波检查实/复球谐、归一化、通道排列和余纬角，再增加阶数测量每阶噪声放大。只检查旋转后的图形，没有检查径向滤波后的 WNG，仍可能在低频得到不可用的输出。

需要 C/C++ 实现时，可沿 SAF 的 `saf_sh`、`array2sh`、`beamformer`、`powermap` 阅读从球谐计算到块处理的过程。CBLAS/LAPACK、FFT 后端、SIMD 与编译器浮点选项都应记录，随后在目标硬件上测最慢帧耗时和内存。SAF 核心模块为 ISC，可选 `saf_tracker` 和 `saf_hades` 为 GPLv2，不能把整个仓库概括成同一宽松许可证。[SAF 官方模块与许可说明](#)。以上源码核实于 2026-09-22。

工业声源成像的目标也要与语音增强分开。Acoular 的 `BeamformerDamas`、`BeamformerCleansc` 和 `BeamformerCMF` 处理点扩散函数或互谱矩阵，输出声源功率分布；它们不直接产生保持目标语音的波形。[Acoular 官方接口](#)。

成像评测重点包括校准、区域积分、流场和运动模型。研究文档给出了相同数据下比较常规成像、反卷积与协方差拟合的最小实验，不能仅以图中峰更尖判定方法更好。

GEV、BAN、RTF 和 MWF 的函数不能只按名称替换。pb\_bss 的 `get_gev_vector` 给最大信噪比方向，`blind_analytic_normalization` 再确定功率尺度；BAN 不需要真实目标导向，也不普遍保证目标单位响应。[pb\\_bss 固定提交的波束实现](#)。

ESPnet 的 `get_rtf` 明确没有在函数内部完成参考通道归一化，后续调用者应检查参考响应接近零时的行为。[ESPnet 固定提交的波束实现](#)。

一般 SDW-MWF 与秩一化简尤其需要区分。取噪声 SCM 为单位阵，目标 SCM 为 `diag(2,1)`，噪声权重为 1，参考麦为第一通道：一般线性方程的首项解为  $2/(2+1)=2/3$ 。pb\_bss `get_wmwf_vector` 使用目标秩一条件下的迹化简，此输入得到  $2/(1+2+1)=1/2$ 。若把目标 SCM 改为 `diag(2,0)`，两者才在此例同为  $2/3$ 。

这是本书依据源码作的手算边界例，不是外部包运行报告；全秩模型可阅读 ESPnet `get_sdw_mwf_vector`，并显式决定是否启用低秩近似。

§ 5.7 的噪声估计也需要同样的区分。MCRA 用局部最小值控制递归更新，IMCRA 进一步引入两阶段平滑与最小值搜索，OM-LSA 根据语音存在不确定性形成对数谱幅度增益。

Cohen 的[官方软件页](#)介绍了 MATLAB OM-LSA/IMCRA，但本次未取得可核验版本与许可的下载包。已下载的 WebRTC 则可从 `quantile_noise_estimator.cc`、`noise_estimator.cc`、`speech_probability_estimator.cc` 阅读分位数跟踪和语音概率控制；它们不是 IMCRA 或 OM-LSA 的逐式实现。研究文档为这些算法分别给出噪声阶跃、持续弱语音、启动和零输入的检查方案。

## 5.10 波束形成算法总对比

不同方法的混响抑制量不能脱离阵列、数据、因果性和指标压成星级。下表只比较可由定义确定的目标、输入与失败条件；运算量仍要按通道数、频点数、滤波长度和实现测量。

| 方法   | 优化目标或固定规则     | 需要的统计量/先验        | 目标保持条件                   | 主要失败模式           | 主要计算        |
|------|---------------|------------------|--------------------------|------------------|-------------|
| DSB  | 导向后等权平均       | 导向矢量或时延          | 导向匹配                     | 空间分辨率有限；混叠或导向误差  | 延迟/相位补偿与求和  |
| 超指向  | 在弥散场模型下最大化 DI | 阵列几何、弥散相干矩阵      | 精确模型与单位响应约束              | 低频 WNG、阵元失配、矩阵病态 | 每频点线性方程求解   |
| DMA  | 小间距差分形成目标图形   | 间距、内部延迟、均衡器      | $\kappa d \ll 1$ 近似及标定成立 | 自噪声和失配经差分、均衡放大   | 延迟、FIR 与求和  |
| MVDR | 无失真约束下最小输出噪声  | 噪声 SCM、导向矢量或 RTF | 约束向量等于真实目标传递向量           | SCM 误差、目标泄漏、导向失配 | SCM 估计与矩阵求解 |

| 方法            | 优化目标或固定规则       | 需要的统计量/先验      | 目标保持条件                 | 主要失败模式           | 主要计算            |
|---------------|-----------------|----------------|------------------------|------------------|-----------------|
| LCMV          | 多个线性约束下最小输出功率   | SCM、全部约束向量与响应  | 约束模型匹配且可行              | 约束占用自由度、约束失配     | MVDR 外加小型约束矩阵求解 |
| GSC           | 在约束零空间内自适应抵消    | 固定支路、阻塞矩阵、噪声参考 | 精确阻塞且自适应支路收敛           | 目标泄漏到阻塞支路        | 阻塞变换与自适应滤波      |
| MWF/SDW-MWF   | 最小化目标估计均方误差     | 目标与噪声 SCM、参考麦  | 不保证严格无失真               | 统计失配和目标—噪声权衡设置错误 | SCM 估计与矩阵求解     |
| 掩码 + MVDR/GEV | 网络估计 SCM，解析层求权重 | 多通道谱、训练得到的掩码   | MVDR 还需正确 RTF；GEV 需定尺度 | 掩码泄漏、训练分布和阵列变化   | 网络推理、SCM 与矩阵求解  |
| 端到端滤波         | 按训练损失直接估计权重或输出  | 训练数据与固定输入定义    | 由损失和结构决定，通常无硬保证        | 域外阵列、未知设备、目标失真   | 由模型、上下文和硬件决定    |

**贯穿全章的约束：**在单位幅度导向矢量和精确无失真约束下， $G_{\text{WNG}} \leq M$ ，等价地  $\text{WNG}_{\text{dB}} \leq 10 \log_{10} M \text{ dB}$ 。DI 同时受阵列几何、频率、噪声场模型和白噪声增益预算限制。紧凑端射阵在理想弥散场模型下可能获得高于 DSB 的 DI，但逼近强相消解通常伴随很低的  $\text{WNG}_{\text{dB}}$ ；脱离阵列几何、频率、噪声场和稳健性约束，不应给出统一的 DI 上限。

上表“目标保持条件”列只说明算法约束，并不是目标失真的数值。若要量化目标损伤，必须先固定基线。以参考麦选择向量  $\vec{e}_r$  为基线，噪声降低量定义为

$$\text{NR}_{\text{ref}} = 10 \log_{10} \frac{\vec{e}_r^H \mathbf{R}_{nn} \vec{e}_r}{\vec{w}^H \mathbf{R}_{nn} \vec{w}}. \tag{5-9}$$

分子、分母要用同一频带和统计窗口。若以 DSB 为基线，就把分子换成 DSB 的输出噪声功率并明确标注。存在导向失配时，只报 NR 会掩盖目标衰减，还应同时报告  $|\vec{w}^H \vec{a}_{\text{true}} - 1|$ ，或报告相对同一参考麦的输出 SNR 改善。

**同输入算例：**零陷、WNG 与目标损伤一起看。取四麦 ULA，横坐标为  $[0, 0.04, 0.08, 0.12] \text{ m}$ ，方位角从正横  $+y$  起算。声速为  $343 \text{ m/s}$ ，只在  $2 \text{ kHz}$  这一频点比较。设计目标在  $0^\circ$ ，实际目标在  $10^\circ$ ，干扰在  $40^\circ$ ；目标功率为 1、干扰功率为 10，各麦独立白噪声功率为 1，并假定目标、干扰与噪声两两不相关。

设计使用精确的干扰加噪声协方差  $\mathbf{R}_{in} = 10 \vec{a}_{40} \vec{a}_{40}^H + \mathbf{I}$ ，不混入目标；这里没有随机快拍、混响或语音波形。各方法使用同一  $\mathbf{R}_{in}$  与设计导向  $\vec{a}_0$ 。LCMV 额外要求  $\vec{w}^H \vec{a}_{40} = 0$ ；“加载 MVDR”的相对加载量为 1，即设计时对角线上加  $11\mathbf{I}$ ，评分时仍使用原来的声场协方差  $\mathbf{R}_{in}$ 。

参考麦的输入信干噪比为  $10 \log_{10}(1/11) \approx -10.41 \text{ dB}$ 。表中真实目标幅度增益为  $20 \log_{10} |\vec{w}^H \vec{a}_{10}|$ ，WNG 为  $10 \log_{10}(1/\|\vec{w}\|^2)$ 。真实目标输出信干噪比按同一功率口径计算：

$$\text{SINR}_{out} = 10 \log_{10} \frac{1 \cdot |\vec{w}^H \vec{a}_{10}|^2}{10|\vec{w}^H \vec{a}_{40}|^2 + \|\vec{w}\|^2} \quad (5-10)$$

| 方法      | 真实目标增益<br>(dB) | 干扰幅度响应<br>$ \vec{w}^H \vec{a}_{40} $ | WNG (dB) | 输出 SINR (dB) |
|---------|----------------|--------------------------------------|----------|--------------|
| DSB     | -0.35          | 0.5241                               | 6.02     | -5.12        |
| MVDR    | -1.90          | 0.0175                               | 4.70     | 2.76         |
| 加载 MVDR | -1.46          | 0.1534                               | 5.27     | 1.28         |
| LCMV    | -1.96          | 0（解析约束）                              | 4.63     | 2.66         |

可先独立核对 DSB 行：正横设计使四个权重均为 1/4；干扰方向相邻麦的相位步进为  $\psi = 2\pi(2000)(0.04) \sin 40^\circ / 343$ ，所以干扰幅度响应为  $|\sum_{m=0}^3 e^{jm\psi} / 4| \approx 0.5241$ 。输出干扰加噪声功率为  $10(0.5241)^2 + 1/4 \approx 2.9973$ ，再代入式(5-10)得到表中 SINR。

在这一组精确协方差、单频、固定几何条件下，LCMV 的干扰响应被硬约束为零，但输出 SINR 略低于 MVDR；加载使 WNG 和真实目标幅度增益回升，同时放松了干扰抑制。目标方向变化后，四种方法对设计方向的响应仍为 1，却不保证对真实方向无失真。表中数字不代表语音可懂度、统计平均或实机性能，也不能推广为固定排名。完整参数、未舍入结果和可运行计算见[同输入波束对照](#)。

5.10.1 延伸阅读：Kumatani 等的 CMU 课程讲义

本章 § 5.2、§ 5.3、§ 5.8 引用的是同一份 [Kumatani et al. (出处同 § 5.2 引文)] CMU 远场语音识别课程讲义，其中讨论球阵、圆阵上的波束形成与识别实验。该材料是课程讲义而非期刊论文，适合用来比较算法结构与识别评测；公式与适用条件仍需回到相应原始论文核对。阅读时可围绕以下三点整理记录。

第一，GEV 与 MVDR 的约束差异。GEV 最大化输出信噪比，没有无失真约束，输出尺度由后续归一化确定；MVDR 对设计导向矢量施加单位响应。阅读讲义的对比表时，应同时记录噪声抑制、目标失真、归一化方法和最终识别率，不能只比较单一分数。

第二，特征波束 (eigen-beam) 的结构。球谐或圆谐波域中的各阶模态可分别正则化。高阶模态通常提供更细的空间变化，也更容易放大噪声；应按 WNG 预算限制其增益。该处理与阵元域对角加载都用于限制病态逆问题，但作用矩阵和参数口径不同。

第三，与识别联合的评估视角。讲义同时报告前端波束形成和后端词错误率（WER）。前端 SNR 改善不能保证 WER 同步改善，因为目标失真、相位变化和谱空洞也会影响识别器。复现实验时应在固定后端、数据划分和评分脚本下同时报告信号指标与任务指标。

这份讲义适合作为阵列算法与远场语音识别评估之间的补充材料；公式与适用条件仍应回到本章相应小节及原始论文核对。

**本章小结：**DSB 提供固定波束基线；超指向在弥散场 DI 与 WNG 之间权衡；MVDR、LCMV、Frost 和 GSC 用不同形式实现协方差驱动的约束优化；后滤波处理残留噪声；球谐域方法适用于球阵；神经网络可估计掩码、协方差或滤波器。选型时应同时报告目标响应、WNG、噪声降低量、延迟和任务指标。

## 5.11 本章练习

1. DSB 增益与 WNG 上限：4 麦均匀线阵、DSB 指向目标，白噪声增益是多少 dB？再用柯西-施瓦茨不等式说明：任何满足无失真约束 ( $\vec{w}^H \vec{a} = 1$ ) 的权重， $G_{\text{WNG}}$  都不超过 4。

参考答案：

$$\text{WNG}_{\text{dB}} = 10 \log_{10} 4 \approx 6 \text{ dB}.$$

柯西-施瓦茨不等式给出

$$1 = |\vec{w}^H \vec{a}| \leq \|\vec{w}\| \|\vec{a}\| = \|\vec{w}\| \sqrt{4}, \\ G_{\text{WNG}} = 1/\|\vec{w}\|^2 \leq 4.$$

等号在  $\vec{w} \propto \vec{a}$  即 DSB 时成立，完整两步见 § 5.2 的上限推导。

2. GSC 阻塞失配：沿用算例 5-3 的 2 麦阵，若目标实际偏到  $2^\circ$ （DOA 估计差  $2^\circ$ ），下支路会漏进多少目标功率？自适应对消器会如何处理这部分泄漏，输出会出现什么变化？

参考答案：采用该算例的阻塞矩阵归一化， $\mathbf{B}^H \vec{a}(2^\circ) \approx 0.0060 - 0.1094j$ ，模约为 0.1096，功率比为  $0.1096^2 \approx 0.012$ ，即约 1.2%（见算例第 6 步）。换用单位范数阻塞向量时，必须重新计算支路功率，不能照搬这个百分比。

泄漏目标与固定支路输出相关，自适应对消器可能将这部分目标一并消除，造成目标衰减；实际程度还取决于自适应滤波器和更新门控。保护措施见 § 5.6 末。

下面五题由 `exercises_spatial.py` 输出权重、响应或功率，用来检查实现所需的模型条件。



E05-01：一般 MWF 为什么不能总用秩一公式？噪声协方差为  $\mathbf{I}$ ，参考麦选择向量为  $[1, 0]^\top$ ，噪声权重为 1。分别取目标协方差  $\text{diag}(2, 1)$  和  $\text{diag}(2, 0)$ ，比较一般 MWF 线性方程与目标秩一时的迹化简。

参考答案：一般解为  $(\mathbf{R}_{ss} + \mathbf{I})^{-1} \mathbf{R}_{ss} \vec{e}_1$ 。两种目标协方差都得到  $[2/3, 0]^\top$ ，因为参考通道对应的对角项是  $2/(2 + 1)$ 。

在噪声为单位阵、噪声权重为 1 的条件下，秩一迹化简写成  $\mathbf{R}_{ss} \vec{e}_1 / (1 + \text{tr} \mathbf{R}_{ss})$ 。全秩输入得到  $[1/2, 0]^\top$ ，与一般解不同；秩一输入才得到  $[2/3, 0]^\top$ 。全秩反例说明的是化简前提不成立，不代表一般 MWF 线性方程有误。

E05-02：加载增强稳健性时，哪项抑制能力会改变？取目标导向  $[1, 1]^\top$ 、干扰导向  $[1, j]^\top$ ，噪声协方差为

$$\mathbf{R}_{nn} = \begin{bmatrix} 11 & -10j \\ 10j & 11 \end{bmatrix}.$$

分别使用相对加载量 0 和 1 求 MVDR。这里相对加载量 1 表示增加  $(\text{tr} \mathbf{R}_{nn}/2)\mathbf{I} = 11\mathbf{I}$ 。比较目标响应、干扰响应幅度和 WNG。

参考答案：未加载时，权重为  $[1/2 + 5j/11, 1/2 - 5j/11]^\top$ ；目标响应为 1，干扰复响应为  $(1 + j)/22$ ，幅度约为 0.06428。

权重平方范数为  $1/2 + 50/121 = 221/242$ ，所以线性 WNG 为  $242/221 \approx 1.09502$ 。增加  $11\mathbf{I}$  后，权重虚部减半为  $\pm 5/22$ ，目标响应仍为 1，WNG 变为  $242/146 \approx 1.65753$ ；干扰响应幅度则增至  $3\sqrt{2}/11 \approx 0.38569$ 。

本例中，加载减小权重范数，改善白噪声增益，却使该方向的干扰抑制减弱。两个指标针对不同噪声模型，不应合并成一个“效果更好”的判断。这里只作单频理想协方差手算，不给出语音质量或设备实时性能结论。

E05-03：后滤波器需要输入噪声还是输出噪声？沿用算例 5-4：三路目标已对齐，每路目标功率为 3，噪声协方差为  $\mathbf{R}_{nn} = 0.7\mathbf{I} + 0.3\vec{1}\vec{1}^\top$ ，波束权重为  $\vec{1}/3$ 。已知噪声模型时，求波束输出噪声与 Wiener 增益。若把非对角互谱都误认为目标，并假定残留通道噪声互不相关，所得增益又是多少？

参考答案：真实输出噪声是  $\vec{w}^H \mathbf{R}_{nn} \vec{w} = 0.7/3 + 0.3 = 8/15$ ，而不是输入每路噪声功率 1。总输出功率为  $3 + 8/15 = 53/15$ ，所以已知真实功率时的 Wiener 增益为  $3/(53/15) = 45/53 \approx 0.8491$ 。



本例的输入自谱为 4，互谱实部为 3.3，错误的独立噪声模型得到每路噪声估计 0.7。先换算到等权平均的输出端，得到  $0.7/3 = 7/30$ ，再计算  $1 - (7/30)/(53/15) = 99/106 \approx 0.9340$ 。不能省掉除以 3，也不能认为这一步消除了噪声相关性的偏差：模型仍漏掉了共同噪声。数值越接近 1 只表示衰减越少，不表示估计越准。

E05-04：复数约束为何要先取共轭？取  $\mathbf{R} = \mathbf{I}_2$ 、 $\mathbf{C} = \mathbf{I}_2$ ，希望两个约束向量的输出响应为  $[1, j]^\top$ 。分别把该向量原样传给 LCMV 与先取共轭再传入，计算权重和实际响应。

参考答案：因为  $\mathbf{C} = \mathbf{I}_2$ ，约束直接给出  $\vec{w} = \vec{f}$ 。原样传入得到  $\vec{w} = [1, j]^\top$ ，实际输出响应却是  $\vec{w}^H \mathbf{C} = [1, -j]$ 。正确输入应为  $\vec{f} = [1, -j]^\top$ ，此时  $\vec{w}^H \mathbf{C} = [1, j]$ ，与要求一致。

这里的两列是坐标基向量，用来隔离接口的共轭问题，不是某个阵列的两个物理方向。一般约束矩阵仍需检查列独立性和可行性；复数响应检查也不能代替几何、时延和通道顺序检查。

E05-05：干扰方向的抑制为何不等于精确零陷？沿用算例 5-2 的半波长双麦，目标为  $0^\circ$ ，干扰为  $30^\circ$ ，独立白噪声方差为 1。令线性干扰噪声比为  $\beta$ ，因此  $\mathbf{R}_{nn} = \beta \vec{a}_i \vec{a}_i^H + \mathbf{I}$ 。分别取  $\beta = 1, 10, 100$ ，计算干扰方向复响应，以及  $-90^\circ$  至  $90^\circ$  内真正的零点位置。

参考答案：将该协方差代入 MVDR 并约去公共因子，得到

$$\vec{w} = \left[ \frac{1}{2} + \frac{j\beta}{2(\beta+1)}, \frac{1}{2} - \frac{j\beta}{2(\beta+1)} \right]^\top, \quad B(30^\circ) = \frac{1+j}{2(\beta+1)}.$$

对任意有限  $\beta$ ，该复响应都不为零。再记相位差为  $\psi = \pi \sin \theta$ ，由  $w_1^* + w_2^* e^{j\psi} = 0$  得  $e^{j\psi} = -w_1^*/w_2^*$ 。两权重模相等，所以本例确有单位圆上的解；其相位为  $\psi_0 = \pi - 2 \arctan[\beta/(\beta+1)]$ ，于是  $\theta_0 = \arcsin(\psi_0/\pi)$ 。

| 线性 INR $\beta$ | $30^\circ$ 方向幅度响应 (dB) | 精确零点 $\theta_0$ |
|----------------|------------------------|-----------------|
| 1              | -9.03                  | 44.82°          |
| 10             | -23.84                 | 32.03°          |
| 100            | -43.10                 | 30.21°          |

这些是本书单频模型的计算结果，脚本使用未舍入权重再求零点，最后保留两位小数。增大 INR 时，零点向  $30^\circ$  靠近，干扰方向响应趋于零；有限白噪声下，MVDR 仍在干扰抑制与权重范数之间折中。这里存在精确零点依赖双麦权重的等模结构，不能外推为任意阵列、任意噪声模型必有零点。若要在指定方向强制为零，应直接施加 LCMV 约束。

从单频权重走到波形还需要逐频点处理与 iSTFT。可先用[音频实验总览](#)中的对齐平均样本检查通道、增益和参考时延，再搭建自适应波束实验。总览中的对齐平均不是 MVDR 输出，不能把它的听感或误差写成 E05-02 或 E05-05 的实验结果。

## 第 6 章 · 声学回声消除 (AEC)

---

第 4、5 章和第 9 章讨论声源方向、波束和轨迹。本章转向设备播放声返回麦克风所形成的回声。混响拖尾和多说话人混合分别见第 7、8 章。

### 6.1 回声模型与基础自适应滤波

---

**问题：**音箱放音乐时，扬声器的声音经房间反射回到自己的麦克风。回声相对近端语音的强弱取决于播放音量、距离、房间和器件耦合；当回声占优时，唤醒和通话都会受到影响。

回声有一个可利用的条件：设备保存着播放信号  $x(n)$ 。未知的是播放信号经过扬声器、房间和麦克风之后形成的回声路径。本节先建立线性近似，再讨论非线性、双讲、残余抑制以及它与波束形成的顺序。

#### 线性模型与自适应滤波（§ 6.1.1 ~ § 6.2）

##### 6.1.1 回声从哪来：系统模型与四种场景

**信号模型。**先把播放链路近似成有限长、线性、时不变系统。麦克风录到的信号可以写成三项之和：

$$\begin{aligned} d(n) &= s(n) + (x * h)(n) + v(n), \\ (x * h)(n) &= \sum_{\ell=0}^{L-1} h[\ell]x[n - \ell]. \end{aligned} \tag{6-1}$$

其中， $d(n)$  是第  $n$  个采样时刻的麦克风样本； $s(n)$  是需要保留的近端语音； $x(n)$  是设备保存的远端播放参考； $h[\ell]$  是长度为  $L$  的线性回声路径冲激响应， $\ell$  是抽头索引； $v(n)$  是环境噪声， $*$  表示卷积。


短时间内采用固定的  $h[\ell]$ ；若要显式描述路径随时间变化，可写成  $h_n[\ell]$ 。AEC 要估计并减去  $x * h$ ，同时尽量保留  $s$ 。

这个模型不是完整的扬声器—房间—麦克风模型。它只覆盖参考抽头之后、在分析时间内可近似为线性且缓慢变化的部分。扬声器削顶、功放压缩和结构振动不能由单个线性卷积准确表示；人移动、设备转动和温度变化又会使  $h$  随时间改变。


实际系统因此把  $h$  当作短时间内有效的近似，并用持续自适应跟踪变化；非线性残余另由 § 6.3 和 § 6.5 的模块处理。

图26 回声形成:  $d(n) = s(n) + x(n)*h[\ell] + v(n)$

(a) 用脉冲响应  $h[\ell]$  表示房间回声路径



(b) 卷积把声音拖长:  $x \rightarrow$  回声



(c) 麦克风里三者相加得  $d(n)$




图26 (a) 的合成路径显式放置直达分量和若干早期反射，再叠加逐渐衰减的晚期尾声；这些成分只用于说明卷积结构，不代表某个实测房间。

图26 (b) 给出远端参考、卷积后的回声和 0.8~1.2 s 加入的合成近端干扰。该干扰取自白高斯随机样本，不是语音录音；图26 (c) 显示它们在麦克风信号  $d(n)$  中叠加。AEC 根据参考估计回声分量，再从  $d(n)$  中减去该估计。

$h[\ell]$  表示从参考抽头到麦克风之间的线性等效路径，包括转换器、扬声器的小信号响应、声学传播和麦克风响应。它与 § 2.4 的纯声学房间冲激响应有关，但还包含电声器件的线性响应，二者不能完全等同。滤波器所需覆盖时间应由目标设备的实测回声路径确定；16 kHz 下 1 ms 对应 16 个抽头，64 ms 对应 1024 个抽头。滤波器没有覆盖的晚期部分会留在残差中，再由残余回声抑制器处理。

四种工作场景（谈论任何 AEC 指标前先声明场景，否则数字没有意义）：

1. 远端单讲 (Single-Talk Far-End, STFE)：只有扬声器在响， $s(n) = 0$ ，适合检查回声衰减；

2. 近端单讲 (Single-Talk Near-End, STNE) : 只有用户在说话, 回声路径没有激励, AEC 不应改变近端通道;
3. 双讲 (Double-Talk, DT) : 两者同时存在。残差  $e$  中含近端语音, 继续更新会使路径估计偏离, 残余抑制也可能损伤近端语音, 控制方法见 § 6.4;
4. 双方沉默 (idle) : 回声与语音都没有。滤波器不应在纯噪声激励下持续漂移, 残余抑制也不应把背景压成突兀的静音。测试矩阵应覆盖沉默期路径变化以及重新播放后的恢复过程 (§ 6.8、§ 6.11)。

免提通话需要同时控制远端单讲时的残余回声和双讲时的近端语音损伤。远端单讲可用输入、输出功率近似回声返回损失增强 (Echo Return Loss Enhancement, ERLE) ; 双讲的回声分量真值例外和统计口径见 § 6.7。具体验收阈值应由目标场景、适用标准和主观听测确定。

主要难点 (Breining et al. 1999 年的综述系统讨论了以下四项) :

1. 冲激响应长: 回声路径覆盖时间增加时, 时域滤波器需要更多抽头, 计算量增加, 收敛也可能变慢; § 6.2 说明分区频域方案怎样降低长滤波器的计算量;
2. 非线性: 微型扬声器与功放在大音量下可能产生线性卷积无法表示的分量, 具体模型和参考点见 § 6.3;
3. 双讲: 参考与目标同时存在, 近端语音会使自适应更新产生偏差, 见 § 6.4;
4. 路径时变: 人走动、门开关、设备被挪动都会改变等效路径  $h_n[\ell]$ ; 参考具有足够激励时, 滤波器需要更新以跟踪这些变化。Breining et al., IEEE Signal Processing Magazine 1999

边栏: 温度如何搬动回声。

声速随温度变化  $v \approx 331 + 0.61 T$  m/s,  $T$  为摄氏温度。温度每变化  $1^\circ \text{C}$ , 声速改变约 0.18%; 变化  $10^\circ \text{C}$ , 就是约 1.8%。对固定 1 m 路径, 传播时延从  $20^\circ \text{C}$  的  $1/343.2 \approx 2.914$  ms 变为  $30^\circ \text{C}$  的  $1/349.3 \approx 2.863$  ms, 缩短约  $51 \mu\text{s}$ , 在 16 kHz 下约 0.82 个采样。

反射路径长度各不相同, 所以每条路径按自身长度产生不同的时延变化, 并非整条冲激响应统一平移  $50 \mu\text{s}$ 。

Elko、Diethorn 与 Gänslér (IWAENC 2003) 的实测表明, 缓慢的热漂移会侵蚀已收敛 AEC 的性能。这是“路径时变”比较隐蔽、也无法靠出厂标定消除的一种形式。Elko, Diethorn & Gänslér, IWAENC 2003、Frontiers in Signal Processing 2024 (温度对 AEC 影响的实测研究)

减法与乘法两类处理。AEC 有已知参考，可以估计回声的幅度和相位后做减法；相位估计错误时，减法也可能放大残余。降噪（§ 5.7）通常没有噪声波形参考，只能估计能量并施加 0~1 的增益。§ 6.8 的非线性处理（Nonlinear Processing, NLP）残余抑制和第 5 章的后置滤波都属于后一类方法。

图27 AEC 结构：根据播放参考估计回声，再从麦克风信号中相减




图27显示基本信号流：播放参考一支经过扬声器和房间进入麦克风，另一支进入自适应滤波器以估计回声路径。估计回声从麦克风信号中减去，双讲检测控制滤波器是否更新。

### 6.1.2 线性自适应滤波：NLMS 回顾

做法：用一个自适应滤波器  $\hat{w}(n)$  去模仿这条回声路径  $h[l]$ ，把参考信号过滤一遍得到“回声副本”  $\hat{y}(n)$ ，再从麦克风信号里减掉：

先固定抽头顺序： $\vec{x}(n) = [x(n), x(n-1), \dots, x(n-L+1)]^\top$  是最近  $L$  个参考样本， $\hat{\vec{w}}(n) = [\hat{w}_0(n), \dots, \hat{w}_{L-1}(n)]^\top$  是同样长度的实数系数向量，当前位置的样本对应第 0 个抽头。二者的内积才与式(6-1)的卷积索引一致。

$$e(n) = d(n) - \hat{\vec{w}}^\top(n) \vec{x}(n)$$

滤波器当前的路径估计作用于播放参考，产生估计回声； $e(n)$  是麦克风样本  $d(n)$  与估计回声之差。远端单讲、参考充分激励且线性模型匹配时，残差功率下降可以支持路径估计改善；单个样本或高度相关参考上的低残差，并不保证系数接近真实路径。抽头数须结合采样率、参考到麦克风的纯延迟、实测路径覆盖时间和可接受残余确定。



经典更新算法是归一化最小均方（Normalized Least Mean Squares, NLMS）：

$$\hat{\vec{w}}(n+1) = \hat{\vec{w}}(n) + \mu \frac{e(n) \vec{x}(n)}{\|\vec{x}(n)\|^2 + \varepsilon} \quad (6-2)$$

更新量与残差和输入向量成正比，并由输入能量归一化。 $\varepsilon$  防止静默时分母接近零。若实现为了手算或节省运算而省略  $\varepsilon$ ，必须另设零能量保护： $\|\vec{x}(n)\|^2 = 0$  时跳过更新，不能计算未定义的  $0/0$ 。

这个更新式怎么来的（三步）：

1. 定目标：想让残差功率最小。最直接的瞬时目标  $J(n) = e(n)^2$ ，对  $\hat{\vec{w}}$  求梯度：
$$\frac{\partial J}{\partial \hat{\vec{w}}} = -2e(n) \vec{x}(n)$$
（因为  $e = d - \hat{\vec{w}}^\top \vec{x}$ ，链式法则一步得出）；
2. 最速下降：沿负梯度方向走一小步  $\hat{\vec{w}} \leftarrow \hat{\vec{w}} + \mu' e(n) \vec{x}(n)$ ，得到最小均方（Least Mean Squares, LMS）算法；
3. 归一化步长：固定步长  $\mu'$  对输入幅度敏感，幅度较大时可能发散，较小时又会减慢收敛。NLMS 用  $\|\vec{x}(n)\|^2 + \varepsilon$  对更新归一化， $\varepsilon$  是防止静音时除以零的小正数。

当线性路径在观察期固定、参考充分激励、没有近端干扰，并忽略正则项时，同一样本的后验误差缩放为  $1 - \mu$ ；因此  $0 < \mu < 2$  使这个单步误差幅度减小。

它不是任意有色参考、噪声、双讲和时变路径下的统一均方稳定保证。 $\mu = 1$  只对应同一帧给定输入下的瞬时最优，并非统计最优。实际步长要在目标参考信号、双讲控制和路径变化条件下扫描；图 18（b）的本书仿真使用  $\mu = 0.5$ 。

#### 算例 6-1：NLMS 的一步手算

题设：3 抽头滤波器，参考向量  $\vec{x}(n) = [1, 0.5, -0.5]^\top$ （最近 3 个播放样本），当前滤波器  $\hat{\vec{w}}(n) = [0, 0, 0]^\top$ （零初值），麦克风信号  $d(n) = 0.8$ ，步长  $\mu = 0.5$ ， $\varepsilon$  很小先忽略。按式(6-2)更新一步。

第 1 步：算回声副本与残差。 $\hat{y}(n) = \hat{\vec{w}}^\top(n) \vec{x}(n) = 0 \times 1 + 0 \times 0.5 + 0 \times (-0.5) = 0$ ——滤波器还是零，回声一点没被减掉，残差  $e(n) = d(n) - \hat{y}(n) = 0.8$  就是全部。

第 2 步：算归一化因子。 $\|\vec{x}(n)\|^2 = 1^2 + 0.5^2 + (-0.5)^2 = 1.5$ 。用输入能量归一化后，播放幅度增大时分母也随之增大，可降低固定步长对输入幅度变化的敏感性。



第 3 步：算更新量、更新滤波器。

$$\mu \frac{e(n)}{\|\vec{x}(n)\|^2} \vec{x}(n) = \frac{0.5 \times 0.8}{1.5} \begin{bmatrix} 1 \\ 0.5 \\ -0.5 \end{bmatrix} = \frac{0.4}{1.5} \begin{bmatrix} 1 \\ 0.5 \\ -0.5 \end{bmatrix} \approx \begin{bmatrix} 0.267 \\ 0.133 \\ -0.133 \end{bmatrix}$$

$$\hat{\vec{w}}(n+1) = [0, 0, 0]^\top + \Delta \vec{w} \approx [0.267, 0.133, -0.133]^\top$$

这里  $\Delta \vec{w}$  就是上式算出的更新向量。

这一步只修正了当前输入方向上的误差；其他方向需要后续不同的输入向量提供梯度信息。更新方向与  $\vec{x}(n)$  平行。

第 4 步：用更新后的系数重算回声副本。

$$\begin{aligned} \hat{y}'(n) &= \hat{\vec{w}}^\top(n+1) \vec{x}(n) \\ &= 0.267 \times 1 + 0.133 \times 0.5 + (-0.133) \times (-0.5) \\ &\approx 0.267 + 0.067 + 0.067 \approx 0.4 \end{aligned}$$

新残差  $e'(n) = 0.8 - 0.4 = 0.4$ 。把更新式代回残差可得  $e'(n) \approx (1 - \mu)e(n)$ ，因此  $\mu = 0.5$  时同一帧的后验残差减半； $\mu = 1$  时到达该帧的瞬时最优。连续输入上的多次更新使滤波器逐步收敛。

$e' \approx (1 - \mu)e$  的推导。把更新式代回同一帧的残差：

$$\begin{aligned} e'(n) &= d - \hat{\vec{w}}^\top(n+1) \vec{x} \\ &= [d - \hat{\vec{w}}^\top(n) \vec{x}] - \mu e(n) \frac{\vec{x}^\top \vec{x}}{\|\vec{x}\|^2 + \varepsilon} \\ &= e(n) \left[ 1 - \mu \frac{\|\vec{x}\|^2}{\|\vec{x}\|^2 + \varepsilon} \right] \end{aligned}$$

$\varepsilon \ll \|\vec{x}\|^2$  时方括号约等于  $(1 - \mu)$ ，即  $e'(n) \approx (1 - \mu)e(n)$ 。 $\mu = 1$  时  $e' \approx 0$ ，只表示本帧给定  $\vec{x}$  下的瞬时最优；下一帧输入变化后仍需继续更新。 $\mu = 0.5$  时本帧残差减半。 $\mu = 1.8$  时  $e' \approx -0.8e$ ，残差变号且幅度仍为原来的 80%； $\mu = 2$  对应幅度不减的临界情况。

第二个手算例（换一组数，验证“减半”不是巧合）： $\vec{x} = [0.8, -0.4, 0.4]^\top$ ， $d = 0.6$ ， $\hat{\vec{w}}(n) = 0$ ， $\mu = 0.5$ 。

$\|\vec{x}\|^2 = 0.64 + 0.16 + 0.16 = 0.96$ ，更新量  $= 0.5 \times 0.6/0.96 \times \vec{x} = [0.25, -0.125, 0.125]^\top$ 。重算得到

$$\begin{aligned} \hat{y}' &= 0.25 \times 0.8 + (-0.125) \times (-0.4) + 0.125 \times 0.4 \\ &= 0.2 + 0.05 + 0.05 = 0.3, \end{aligned}$$

新残差为  $0.6 - 0.3 = 0.3$ 。

残差同样减半，说明规律  $e' \approx (1 - \mu)e$  与这组具体数字无关。

图18 声学回声消除 (AEC) 原理






图18 (a) 给出整体结构； (b) 给出 NLMS 在模拟回声路径上的收敛曲线。仿真取  $\mu = 0.5$ ，回归向量按  $\vec{x}(n) = [x(n), x(n-1), \dots, x(n-L+1)]^\top$  排列，与生成回声的卷积索引一致，不额外引入一拍延迟。图中标注的是固定随机种子下  $0.45 < t < 0.8$  s 远端单讲窗口的 ERLE 均值；粉色区域表示双讲期间冻结更新，该区间不统计 ERLE。

图28 NLMS 自适应：路径估计逐步逼近真实响应

(a)  $\hat{w}$  逐步逼近  $h$



(b) 失配下降, ERLE 上升



(c) 步长  $\mu$ : 无噪声模型中的有限时段收敛




图28 (a) 显示  $\hat{w}$  从零开始逐步逼近真实路径  $h$ 。(b) 显示本次仿真中, 系数欧氏失配下降时 ERLE 总体上升; 两者不是互为相反数, 因为有色输入下的残余功率还由输入协方差加权, 纵轴也使用不同统计口径。(c) 比较不同步长在有限观察时段内的收敛轨迹。

本图使用固定、完全可表示的线性路径, 没有近端语音或噪声, 因此不能从曲线起伏推出含噪系统的稳态失调。较大步长在含噪时可能增加稳态误差, 须另在固定噪声和统计窗口下测试;  $\mu \in (0, 2)$  也不是实际系统的无条件稳定范围。

图29 NLMS 收敛与合成近端干扰时的冻结




图29上方三行使用共同尺度的均方根包络，分别显示参考  $x$ 、麦克风信号  $d$  和残差  $e$ 。粉色区域加入合成近端干扰，所用白高斯随机样本不是语音录音；此时残差含干扰，不能用输入/输出总功率评价回声抵消量，因此 ERLE 曲线在该区间不绘制。

滤波器在该区间冻结更新，之后继续沿原路径工作。图28中的“0步”曲线表示更新前的全零初值；后续编号表示已完成的更新次数。

**步长与正则项。** 较大的  $\mu$  通常使初期收敛较快；在有观测噪声、近端干扰或路径变化时，也可能增大稳态失调和误更新。图28的无噪声仿真不能单独证明后一项。

$\varepsilon$  防止静默时分母趋近于零。固定下限与随参考功率缩放的正则项使用不同量纲和归一化口径，不能照搬同一个数值。可扫描静音、低电平参考和正常播放三类输入，选择既不在静音时产生大更新、又不过度减慢小信号收敛的取值。

收敛还需要充分激励。NLMS 每步只能沿当前输入方向  $\vec{x}(n)$  修正（见算例 6-1 第 3 步）。纯音或窄带参考不能充分激励所有滤波器系数，未被激励的方向会收敛得很慢。调试时可用已知宽带测试信号检查滤波器是否能辨识目标路径；这项测试不能代替真实节目内容上的收敛与双讲验证。

单位脉冲是一个容易混淆的边界例子。对  $L$  抽头回归器，单个单位脉冲会依次产生  $L$  个标准基向量，因此方向并不缺失；但每个方向只更新一次。

若  $\mu = 0.5$ 、初值为零且忽略非零  $\varepsilon$  的微小影响，每个抽头只走到真实值的一半。要继续逼近真实路径，需要重复脉冲或其他持续激励；输入归零后应按上面的零能量规则跳过更新。

## 6.2 工程化自适应：频域、子带、比例、RLS 与卡尔曼

时域实现的计算量。若每个样本重新计算长度  $L$  的参考能量，时域 NLMS 的滤波、更新和能量求和各约需  $L$  次乘法，即朴素实现约  $3L$  次。参考窗口每次只移入、移出一个样本时，也可递推能量  $p_n = p_{n-1} + x[n]^2 - x[n-L]^2$ ，使这一项每样本只需常数运算；滤波与更新仍约需  $2L$  次乘法。

$L = 1024$ 、8 kHz 时，朴素口径约为 2500 万次乘法/秒，能量递推口径的主要项约为 1600 万次/秒；两者都不含内存访问和控制开销。能量递推需按启动零填充初始化，并在长时浮点运行中定期核对直接求和，避免累计舍入误差。

48 kHz、4096 抽头时主要项达到每秒数亿次；抽头越多、输入频谱越不均匀，收敛通常越慢。常见改进包括频域分块、子带处理、比例步长和卡尔曼估计。

以  $L = 3$ 、参考样本依次为 1, 2, 3, 4 为例，前一窗口能量  $1^2 + 2^2 + 3^2 = 14$ ；移入 4、移出 1 后得到  $14 + 4^2 - 1^2 = 29$ ，与直接计算  $2^2 + 3^2 + 4^2 = 29$  一致。递推只减少分母的重复求和，不减少回声估计和系数更新的  $L$  个抽头运算。

### 6.2.1 PBFDAF：从长回声路径到逐块更新

分区块频域自适应滤波（Partitioned-Block Frequency-Domain Adaptive Filtering, PBFDAF）沿用多延迟块频域（Multidelay Block Frequency-Domain, MDF）方法的思路，把  $L$  个抽头分成  $P = \lceil L/N \rceil$  个长度为  $N$  的分区，并用长度  $2N$  的快速傅里叶变换（Fast Fourier Transform, FFT）完成重叠保存卷积。最后一个分区若不足  $N$  个真实抽头，缺少的位置补零；补零不是新增可学习的声学路径。

先固定索引：第  $m$  块新到的  $N$  个参考样本是  $b_m = [x[mN], \dots, x[mN + N - 1]]$ ，负时间样本为零。将上一块和本块接起来， $u_m = [b_{m-1}, b_m]$ ，它长  $2N$ ；令  $X(k, m) = \text{FFT}_{2N}(u_m)$ 。

把真实路径的第  $p$  段  $h_p = [h[pN], \dots, h[pN + N - 1]]$  补成  $[h_p, 0_N]$ ，其频谱记为  $W_p(k, m)$ 。  $m$  是块号，  $p$  是路径分区号，  $k = 0, \dots, 2N - 1$  是频点号；  $X$ 、  $W$ 、 下文的  $E$  都是复数。实际算法的  $W_p$  是随块更新的估计，不预先知道  $h_p$ 。

| 时域路径的位置                        | 使用的参考谱            | 它在本块输出中代表什么   |
|--------------------------------|-------------------|---------------|
| $p = 0$ ，抽头 $0, \dots, N - 1$  | $X(k, m)$         | 当前及紧邻的参考样本    |
| $p = 1$ ，抽头 $N, \dots, 2N - 1$ | $X(k, m - 1)$     | 再早一个分区的参考历史   |
| $p = P - 1$ ，最后 $N$ 个位置        | $X(k, m - P + 1)$ | 长回声尾部；末分区可能补零 |

所以“第  $p$  个频域抽头”不是一个额外的物理麦克风或单个时域抽头，而是一整段时域路径与延迟  $p$  块的参考谱配对。每来一个新块只需变换一次  $u_m$ ，旧谱移入历史；即使冻结权重更新，参考历史也不能冻结，否则下一块的回声预测就会错位。

预测先于更新。用本块开始时的旧权重计算  $Q_m(k) = \sum_{p=0}^{P-1} W_p(k, m) X(k, m - p)$ ，再作  $q_m = \text{IFFT}_{2N}(Q_m)$ 。这里只取  $q_m$  的后  $N$  点作为本块回声预测  $\hat{y}_m$ ；令有效麦克风块为  $d_m$ ，先验残差是  $e_m = d_m - \hat{y}_m$ 。

前  $N$  点含循环折回，不是本块的另一组有效输出。只要每段权重的逆变换后  $N$  点为零，这一有效区预测就与长度  $L$  的直接时域 FIR 卷积相同。算例 6-3 会逐项复算。

误差放在哪里也有讲究。把有效误差排成  $[0_N, e_m]$ ，再作  $E(k, m) = \text{FFT}_{2N}([0_N, e_m])$ 。若直接用整块循环输出谱与观测谱相减，前半块的循环折回会混入梯度。

以固定的、没有逐频归一化的情形看，  $\text{IFFT}_{2N}(X^*(k, m - p)E(k, m))$  的前  $N$  点，就是该分区合法抽头的块误差相关方向；后  $N$  点是循环相关形成的非法位置，不能当作同一条长度  $L$  的 FIR 抽头。

这里的“相关方向”还不是逐样本时域 NLMS 的更新：它汇合一块的  $N$  个误差，归一化和更新时机也不同。Shynk 1992，§ IV、图 5 和式(24)、(30)区分了有效区选择与约束。

有时同一更新被称为“频域多抽头 NLMS”：固定一个频点，抽头是当前及过去  $P - 1$  个参考块的频谱值，分别对应长时域滤波器的  $P$  个分区。它不是本节前面那个每来一个时域样本就更新一次的  $L$  抽头 NLMS；也不能仅凭“频域多抽头”四个字断定使用了哪种分块、窗函数和误差约束。

每块的频域滤波和梯度相关都要遍历  $P$  个分区，因此不能只写成  $O((L/N) \log N)$ 。忽略实现常数时，无梯度约束版本每个新样本约为  $O(\log N + L/N)$ ；若每个分区都做时域梯度约束，还会增加约  $O((L/N) \log N)$ 。FFT 的固定成本随块长对数增长，分区乘法则随  $L/N$  线性增长。



具体倍数还取决于实数或复数 FFT、频谱共轭对称复用、功率估计、约束频率以及一次乘加如何计数，不能脱离这些约定比较。[KU Leuven DSP-CIS 讲义第 13 章](#)

算例 6-2: PBFDAF 选定核心算子的乘法计数 ( $L = 1024$ 、 $N = 128$ 、8 kHz; 这是理论分项账，不是完整程序计时)

时域 NLMS 的账: 每样本滤波  $L$  次乘法、更新  $L$  次; 朴素重算功率再加  $L$  次, 共约  $3L = 3072$  次乘法/样本。若按上文滑动窗口递推参考能量, 主要项是  $2L = 2048$  次, 另有常数次标量运算; 递推版本与下面的朴素版本应分别比较。

PBFDAF 的账: 块长  $N = 128$ , FFT 长度取  $2N = 256$  (overlap-save 结构, 防循环卷积混叠), 分区数  $P = L/N = 8$ 。每来一块 128 个新样本, 要做的活是:

1. 新参考块算 1 次 FFT——旧分区的频谱整体平移复用, 不必重算, 这是“分区”省钱的根源;
2. 8 个分区各做一次长度 256 的复数相乘 (滤波 = 频域相乘), 合起来做 1 次逆快速傅里叶变换 (Inverse Fast Fourier Transform, IFFT) 得到输出块;
3. 误差块 1 次 FFT, 8 个分区各做一次共轭相关复乘 (梯度方向);
4. 若对每个分区施加时域梯度约束, 要把该分区的频域梯度做 IFFT、把无效的后半段清零, 再 FFT 回频域, 因此每个分区增加一对变换; 无约束版可省掉这一步, 间歇约束版则按实际约束频率折算。

为使下面的算术可逐项复算, 只统计变换与预测、相关中的复乘: 不利用实信号频谱的共轭对称, 把每次  $2N$  点变换按完整复 FFT 估计为  $4N \log_2(2N) = 4 \times 128 \times 8 = 4096$  次实乘法, 长度 256 的逐点复乘按  $256 \times 4 = 1024$  次实乘法计。这是选定算子的部分计数, 不是全算法实乘法上界。实际实 FFT 只需保存  $N + 1 = 129$  个独立频点, 若复用共轭对称, FFT 和逐点乘法都应按具体库重新计数, 不能沿用下面的 4096 和 1024:

- 无约束版:  $3 \times 4096 + 2 \times 8 \times 1024 = 12288 + 16384 = 28672$  次/块  $\rightarrow$  每样本  $28672/128 \approx 224$  次;
- 逐分区约束版: 再加  $2 \times 8 \times 4096 = 65536$ , 共 94208 次/块  $\rightarrow$  每样本约 736 次。

如果像本书教学代码那样每块对全部  $P$  个复频谱重新求  $|X|^2 = (\Re X)^2 + (\Im X)^2$ , 至少还要  $2 \times 256 \times 8 = 4096$  次实乘法/块, 即 32 次/样本。把这一项加进同一全复频点口径, 以上两项分别成为 256 和 768 次/样本; 仍未计功率求和、分母除法、步长缩放、加法、缓存读写和控制逻辑。平滑功率或递推功率的成本又不同。本书教学代码即使关闭约束, 也会为输出“约束前候选系数”做逐分区 IFFT, 故这里的无约束算子账尤其不能当作该 Python 程序的实际运算量。

仅就共同列出的主要乘法项，224/736 与朴素时域 NLMS 的 3072 相比分别约差 14 倍和 4.2 倍；与递推能量版本的  $2L = 2048$  次主要项相比，约差 9.1 倍和 2.8 倍。补入上述重算功率项后，这些部分计数比值还会变化。时域与频域两边都未计全套操作，更未测缓存、向量化和处理器行为，不能把这些比值称为产品加速比。

这些数不能当作实 FFT 库的操作数或实测速度。若约束不是每块、每分区都执行，平均开销会降低，报告时要注明约束周期；但不能把“少约束”误写成“少更新分区”。

以上倍数只针对本算例的逐样本时域 NLMS。若比较对象已经采用相同块长、分区数、FFT 长度、归一化和约束策略的频域多抽头 NLMS，它与这里的 PBFDAF 执行同类运算，不能因为名称不同而宣称 PBFDAF 另有计算量或延迟收益。短分区可能减少未分区长块频域方法等待输入成块的时间；端到端延迟仍要计入缓冲和调度。[MathWorks 频域自适应滤波算法说明](#)分别列出分区与非分区、约束与非约束实现。

块长  $N = 128$ 、采样率 8 kHz 时，每块含 16 ms 新数据。第  $m$  块的最后一个参考样本到齐后，才可形成这一块的完整输入、预测与先验误差； $2N = 256$  点 FFT 包含上一块的历史，不表示还要等待 32 ms 的新参考。输出本块  $N$  点的调用时机、播放—采集对齐、设备缓冲与调度决定端到端延迟，单凭块长或 FFT 长度不能报固定值。滤波器加长时，时域主要成本按  $L$  增长，分区频域的核心项按  $L/N$  增长，但很短的路径和小块可能被变换与缓冲成本抵消。[Soo & Pang 1990](#)

例如固定  $L = 4096$ 、采样率 16 kHz，改变块长只改变分区与变换的折中，不改变要表示的 4096 抽头路径：

| 新块 $N$ (样本) | 分区 $P$ | FFT 点数 $2N$ | 每块新数据时长 | 状态/延迟解释           |
|-------------|--------|-------------|---------|-------------------|
| 64          | 64     | 128         | 4 ms    | 较短积累，更多分区乘法与状态    |
| 128         | 32     | 256         | 8 ms    | 两种成本之间的一个候选点      |
| 256         | 16     | 512         | 16 ms   | 较少分区，单次变换和新数据积累更长 |

这只是精确的样本数换算和方向性取舍，不是三种配置在某台设备上的测时，也不表示  $N$  越大必然更省总算力。若改变分区约束频率、功率估计和缓存布局，最佳块长也可能改变；实际选择须连同播放/采集缓冲和端到端延迟一起测量。

算例 6-3: 两个样本一块, 为什么要丢掉前半块。本书取  $N = 2$ 、 $P = 2$ 、路径  $h = [1, 2 \mid 3, 4]$ 、参考  $x = [1, 2, 3, 4]$ , 负时间样本为零。直接按式(6-1)卷积, 前四个回声样本依次为  $[1, 4, 10, 20]$ 。竖线只标示两段抽头的分区边界, 不表示时域路径在这里中断。

第 0 块把两点新参考  $[1, 2]$  接在两点历史零之后, 形成四点输入  $[0, 0, 1, 2]$ 。它与首分区  $[1, 2, 0, 0]$  作四点循环卷积, 只保留后两点  $[1, 4]$ ; 更早的分区历史为零。

第 1 块的四点输入是  $[1, 2, 3, 4]$ 。它与首分区的四点循环卷积为  $[9, 4, 7, 10]$ , 其中前两点已受到循环折回影响, 必须丢弃。

后两点  $[7, 10]$  加上上一参考块  $[0, 0, 1, 2]$  与第二分区  $[3, 4, 0, 0]$  的有效后两点  $[3, 10]$ , 得到  $[10, 20]$ 。若第二分区错用当前块, 或把前两点当作线性卷积结果, 答案都会错。配套代码只复算这一段分区卷积, 不冒充完整自适应 PBFDAF; 误差反馈还须按下式另行处理。

PBFDFAF 更新式。记第  $m$  块、第  $k$  个频点的参考谱为  $X(k, m)$ ，第  $p$  个分区的滤波器谱为  $W_p(k, m)$ ，误差谱为  $E(k, m)$ ，其中  $p = 0, \dots, P-1$ 。 $\mu$  是块更新步长， $\delta > 0$  是防止参考功率为零时除零的归一化地板。一种按全部分区参考功率归一化的候选更新写成

$$\widetilde{W}_p(k, m+1) = W_p(k, m) + \mu \frac{E(k, m) X^*(k, m-p)}{\sum_{q=0}^{P-1} |X(k, m-q)|^2 + \delta} \quad (6-3)$$

分区  $p$  使用延迟了  $p$  个块的参考  $X(k, m-p)$ ；若省略该下标，公式就只描述单分区 FDAF。与时域 NLMS 相比，分子仍是“误差  $\times$  参考共轭”，分母仍做参考功率归一。

实际重叠保存实现只把每块线性卷积的后  $N$  个输出作为有效残差。以上面  $N=2$  的第 1 块为例，若两个有效先验误差为  $[e_2, e_3]$ ，构造四点误差谱时先排成  $[0, 0, e_2, e_3]$  再做 FFT；不能把循环污染区的输出当成新观测。这里的  $E(k, m)$  是用旧滤波器产生的这类先验误差谱。文献和代码也会为每个分区维护独立平滑功率，比较实现时必须核对归一化定义。

为什么是共轭与功率和？对固定频点，预测谱是  $\sum_p W_p X_{m-p}$ ；改变复权重时，减小平方残差的相关方向含  $X_{m-p}^* E$ 。各分区同时作用于同一频点的预测，所以分母汇总它们的参考功率，而不是每个分区单独拿自己的  $|X_{m-p}|^2$  去除。 $\delta$  和  $\mu$  的数值依赖 FFT 缩放与功率定义；式(6-3)是本书选定的瞬时逐频预条件候选式，并非所有名为 PBFDFAF 的论文、库都原样使用它，也不能把常用的  $0 < \mu < 2$  当作任意有色输入、双讲和控制器下的稳定性定理。


无梯度约束时，式(6-3)的候选值就是下一块权重  $W_p(k, m+1)$ 。若执行时域梯度约束，须对同一分区全部  $2N$  个频点的候选权重做 IFFT、清零无效的后  $N$  个时域抽头，再 FFT 回频域，才得到下一块权重；末分区若只有  $r < N$  个真实抽头，连第  $r$  到  $N-1$  个补零位置也须清零。此投影跨频点耦合，不能靠单个频点独立完成。完全不约束的版本可能有不同的稳态权重和误差，也不再有唯一的长度  $L$  FIR 系数解释。以  $N=128$ 、8 kHz 为例，每秒更新约  $8000/128 \approx 62.5$  次；每次更新同时利用 128 个新样本，核心算子乘法账见算例 6-2。Shynk, *IEEE Signal Processing Magazine* 1992, § IV 讨论频域更新的循环相关与梯度约束。

把一块完整处理写成执行顺序，有助于调试：

1. 拼接上一块和当前块，计算并移入  $X_m$ ；
2. 用旧权重和当前至过去  $P-1$  个参考谱预测；
3. 仅取 IFFT 后半块，与  $d_m$  相减；
4. 对  $[0_N, e_m]$  做 FFT，求每频点的参考功率和式(6-3)候选；
5. 按需投影每个分区，再提交新权重；
6. 保存当前块供下一块使用。


冻结时跳过第 4、5 步的权重更新，不能跳过参考谱历史移位；静音时分母有地板也不意味着必须更新。

图39 PBFDAF：参考历史、有效输出与受控权重更新  
(a) 旧权重先预测；仅循环卷积的后 N 点是本块有效输出



频点  $k$  省略；前  $N$  点因循环折回而弃用。 $h$  含器件的小信号响应。

(b) 有效误差驱动下一块的候选权重；冻结只阻止更新



冻结时保留旧权重，参考历史仍移位；未分区的补位也清零。

图39（a）把播放参考经线性等效声学路径形成真实回声、与近端和噪声合成麦克风输入的物理通路，和同一参考进入算法预测的数字通路分开。路径  $h$  包括参考抽头之后可由线性 FIR 表示的器件及空间作用，不单指房间。预测支路的  $X_m, \dots, X_{m-P+1}$  是持续移位的参考谱历史，当前预测使用更新前的  $W_p(m)$ 。

图39（b）从有效误差产生候选，再选择投影或无约束旁路。紫色虚线冻结控制只阻止更新，不能停止预测与历史移位。



“预测输出前  $N$  点弃用”和“候选权重后  $N$  点清零”位于不同支路、服务于不同目的；末短分区的填充位置另须清零。这是结构示意图，不表示实测消除量或端到端延迟。

### 6.2.2 频域多抽头 NLMS：抽头是什么，何时等于 PBFDAF

“频域多抽头 NLMS”是描述性叫法，先问抽头沿哪个维度排列，才能判断它指的是哪种算法。

“多抽头”可能是多个参考块、多个 STFT 帧，也可能被用来泛指原先的时域 FIR 抽头；单靠名称不能确定预测、误差和更新。原始 MDF 与 PBFDAF 论文讨论分区结构，Shynk 1992, § IV 区分频域块滤波的有效区与约束；这几项是比较实现的依据，而不是给一个含糊名称硬指定唯一公式。

第一种明确含义：每频点有  $P$  个参考块延迟。固定频点  $k$ ，把参考历史排成复数列向量  $\mathbf{X}_m(k) = [X(k, m), X(k, m-1), \dots, X(k, m-P+1)]^T$ ，把分区权重排成同为  $P \times 1$  的  $\mathbf{W}_m(k) = [W_0(k, m), \dots, W_{P-1}(k, m)]^T$ 。取有效输出前的原始块预测谱是  $\mathbf{W}_m(k)^T \mathbf{X}_m(k)$ ；还须经 IFFT、舍弃前  $N$  点，才得到本块的有效预测输出。式(6-3)逐分区合起来可写为

$$\widehat{\mathbf{W}}_{m+1}(k) = \mathbf{W}_m(k) + \mu \frac{\mathbf{X}_m^*(k) E(k, m)}{\|\mathbf{X}_m(k)\|_2^2 + \delta}。$$

这里  $*$  对向量逐元素取共轭，预测采用转置而非共轭转置，因此更新中的参考要取共轭。这只是式(6-3)的候选向量重写，不是另一种算法。例如某一频点有  $P=2$ 、 $\mathbf{X} = [1, 2]^T$ 、先验误差谱  $E = 0.3$ 、 $\mu = 0.5$ 、 $\delta = 1$ ，分母为  $1^2 + 2^2 + 1 = 6$ ，两个分区的更新量分别为  $0.5 \times 0.3 \times 1/6 = 0.025$  和  $0.5 \times 0.3 \times 2/6 = 0.05$ 。这些无量纲数只是核对式(6-3)的单频点算术，不代表由真实块信号形成的完整共轭对称频谱；约束后的更新也不等于  $2N$  条互不影响的复 NLMS。

把“看起来像 NLMS”与“真的优化了什么”分开，可避免误用。令  $F$  为  $2N \times 2N$  的正向 DFT 矩阵， $F^{-1}$  为带  $1/(2N)$  缩放的逆变换； $S = [0_{N \times N} \ I_N]$  取时域后半块， $U = [I_N \ 0_{N \times N}]^T$  把每段  $N$  抽头补零。设  $Q_m = \sum_p W_{p,m} \odot X_{m-p}$ ， $\odot$  表示逐频相乘，那么本块预测为  $\hat{y}_m = SF^{-1}Q_m$ 。零填充后的正确误差谱是

$$E_m = FS^T(d_m - SF^{-1}Q_m) = D_m - CQ_m, \quad D_m = FS^T d_m, \quad C = FS^T SF^{-1}。$$

$S^T$  在前  $N$  点补零； $C$  是从完整循环块取有效区、再补零回频域的投影，通常不是频点逐个独立的对角矩阵。所以  $E_m$  一般不是  $D_m - Q_m$ 。这不是实现细节：若把前半块污染也放入谱误差，真实路径已完全匹配时仍可能产生假梯度。



再令  $w_p \in \mathbb{R}^N$  是第  $p$  段合法时域抽头。固定本块旧权重时，该段从  $w_p$  到有效输出的线性算子是  $A_{p,m} = SF^{-1} \text{diag}(X_{m-p})FU$ ，形状为  $N \times N$ 。对本块目标  $J_m = \frac{1}{2} \|d_m - \sum_p A_{p,m} w_p\|_2^2$ ，真实的块梯度方向为  $-\nabla_{w_p} J_m = A_{p,m}^H e_m$ ；按上面的 DFT 缩放化简，就是  $\text{IFFT}(X_{m-p}^* \odot E_m)$  的前  $N$  点。

这里  $H$  是共轭转置；输入为实时域信号时，合法部分的虚部仅应有浮点舍入量。读者可用  $N = 2$  的算例 6-3 核对索引和共轭。[Shynk 1992, § IV, 式\(20\)~\(24\)、\(30\)](#)给出这一类有效区与梯度约束结构。

如果不作逐频预条件，且每块对全部分区施加合法抽头投影，上述 FFT 只是高效计算块 LMS 梯度；一块内所有误差仍由同一组旧权重产生，不会变成逐样本更新的 NLMS。若再用一个共同标量归一化，得到的是相应的块归一变体。

式(6-3)把各频点分别除以  $R_m(k) = \sum_q |X(k, m - q)|^2 + \delta$ ，即频域对角预条件；它不等于上述有效区目标的精确 Hessian 逆，也没有消除同一频点内  $P$  个历史参考之间的全部相关性。

投影  $G = FUU^T F^{-1}$  还把频点重新混合； $G$  与逐频  $R_m(k)^{-1}$  一般不能交换。因此“每频点的  $P$  抽头复 NLMS”只说明候选式的代数形状，不是完整受约束 PBFDAF 由  $2N$  套独立 NLMS 构成。[MathWorks 频域自适应滤波算法说明](#)也把分区、非分区及约束选择分别列出。

同一个具体实现需要的条件。两种叫法都用  $N$  点新样本、 $2N$  点重叠保存变换，历史频谱抽头对应同一条  $L$  抽头时域 FIR 的  $P$  个分区，并使用相同的有效误差、功率分母、步长与约束策略时，预测和更新才逐块对应。

固定每个分区只有前  $N$  个有效时域系数时，频域乘积之和经 IFFT、丢掉前  $N$  个受循环折回影响的样本，后  $N$  个输出与直接时域线性卷积相同；算例 6-3 已用  $N = P = 2$  复算输出关系。这里的相同是本书对齐约定下的代数关系，不保证不同 FFT 库的浮点结果逐位一致。[Shynk 1992, § IV](#)给出重叠保存、有效区误差与约束的关系。

同形更新式不保证运行轨迹相同。复现时还须核对 FFT 正反变换的缩放、块边界和初始历史、瞬时或平滑功率、 $\delta$  与  $\mu$  的实际尺度、双讲时的冻结或连续控制，以及梯度约束的时机。

重叠保存先在时域取后  $N$  个有效残差，再将  $[0_N, e_{\text{valid}}]$  变换成  $E$ ；不能用未经有效区选择的整块循环卷积频谱直接作  $D - \hat{Y}$ 。若定义  $D = \text{FFT}([0_N, d_{\text{valid}}])$ 、 $\hat{Y}' = \text{FFT}([0_N, \hat{y}_{\text{valid}}])$ ，其中  $d_{\text{valid}}$  是本块的有效麦克风观测， $\hat{y}_{\text{valid}}$  是有效回声预测，才有  $E = D - \hat{Y}'$ 。无梯度约束仍是合法变体，但其循环相关更新和稳态行为可能不同于约束版。[Shynk 1992, § IV、图 5 及式\(30\)](#)。

已匹配路径却被错误更新的四点检查。取  $N = 2$ 、单分区合法抽头  $[1, 2]$  和重叠输入  $[1, 2, 3, 4]$ 。四点循环卷积是  $q = [9, 4, 7, 10]$ ，有效输出只有  $[7, 10]$ 。若麦克风有效块正好是  $d = [7, 10]$ ，则正确先验误差  $e = [0, 0]$ 、 $E = 0$ ，任何合理的误差驱动更新都应停下。

若错误地计算  $F[0, 0, 7, 10] - Fq = F[-9, -4, 0, 0]$ ，频域误差却非零；这正是漏掉有效区投影  $C$  的后果，不是 FFT 舍入误差。

| 叫法或实现              | “抽头”与更新时刻                              | 与本书 PBFDAF 的关系                            |
|--------------------|----------------------------------------|-------------------------------------------|
| 逐样本时域 NLMS         | $L$ 个样本级时延；每个样本的先验误差后更新                | 同一 FIR 目标，但块内更新轨迹不同                       |
| 时域块 LMS / 共同标量归一变体 | $L$ 个样本级时延；整块误差由旧权重生成，块末更新             | 未逐频预条件的受约束 FFT 实现可计算同一块梯度                 |
| 单分区频域块滤波           | $P = 1$ ；用较长的 FFT 处理整条短路径              | 是分区结构的退化情况；长路径大块可能增加积累时间                  |
| 分区重叠保存的频域多抽头 NLMS  | 每个频点有 $P$ 个参考块历史；式 (6-3) 作候选，按有效区及约束执行 | 输入、FFT、误差、分母、步长与投影均相同时，逐块就是本书 PBFDAF 教学变体 |
| 普通窗函数 STFT 同频跨帧滤波  | 每个频点有多个分析帧历史；分析/合成窗及帧移另定               | 更新形状可相似；一般不能仅据此声称等于同一时域 FIR               |

这张表比较的是模型和更新规则，不按乘法量或收敛速度排名。第一行的  $L$  个时域抽头与第四行的  $P$  个频域块延迟不是不同长度的“同一数组”；前者直接表示各采样时延，后者每项代表一整段  $N$  抽头路径。第四行要精确对应还必须保持块首历史、FFT 标度、末分区补零、冻结与约束时机一致。

SpeexDSP、WebRTC AEC3 虽有分区结构，也有不同的功率估计及更新控制；算法名字相近不推出相同权重轨迹。

算例 6-3 的自适应补充：两块更新怎样处理非法抽头。另取  $N = P = 2$ 、 $L = 4$ 、 $\mu = 0.5$ 、 $\delta = 1$ ，初始权重和负时间参考全零；参考  $x = [1, 0, 0, 0]$ 、麦克风观测  $d = [1, 0, 2, 0]$ 。这是为核对式 (6-3) 设计的无量纲输入，不是声学传播测量；第二块的  $d = [2, 0]$  也不被解释成固定物理回声路径的输出。

第 0 块的重叠保存输入为  $[0, 0, 1, 0]$ ，其四点 FFT 为  $X_0 = [1, -1, 1, -1]$ 。旧权重全零，有效误差为  $[1, 0]$ ，所以  $E_0 = X_0$ ；每频点分母为  $|X_0|^2 + \delta = 2$ 。更新第一分区的四个频点后再 IFFT，时域候选为  $[0.25, 0, 0, 0]$ ；第二分区此时没有历史参考，仍为零。

第 1 块新参考全零，但重叠保存输入是  $[1, 0, 0, 0]$ ，故  $X_1 = [1, 1, 1, 1]$ ，历史  $X_0$  仍须保留。先验预测为零，有效误差  $[2, 0]$  对应  $E_1 = [2, -2, 2, -2]$ ；每频点分母是  $|X_1|^2 + |X_0|^2 + \delta = 3$ 。式 (6-3) 使第一分区的候选时域系数成为  $[0.25, 0, 1/3, 0]$ ，第二分区成为  $[1/3, 0, 0, 0]$ 。

第一分区的第 3 个位置是循环相关带来的非法抽头，逐分区梯度约束把各分区后  $N$  点清零，最终  $L$  抽头路径为  $[0.25, 0 \mid 1/3, 0]$ 。如果不做约束，候选中的  $1/3$  会保留，不能再把这个频域状态直接称为四抽头 FIR。可运行版本和独立手算测试见[分区自适应实验与测试](#)；它只实现式(6-3)的瞬时功率教学变体，不复现 SpeexDSP 的 AUMDF 控制。

这个非法位置的索引是第一分区内的滞后 2，而第二分区的合法首抽头也对应整条路径的滞后 2；若都保留，它们对有效输出可以产生重叠表示。投影要维持“每一分区只含前  $N$  个时域抽头”这一清楚的 FIR 解释。注意这里说的是梯度约束/权重投影；预测时舍弃循环卷积前半块是另一件事，两者都做并不重复。

算例 6-4：逐频归一化为什么不等于时域 NLMS。取更小的单分区问题： $N = 2$ 、 $P = 1$ 、初值全零、 $\mu = \delta = 1$ ，当前重叠保存输入  $u = [0, 0, 1, 2]$ ，有效麦克风块  $d = [1, 0]$ 。旧权重为零，所以有效先验误差也是  $e = [1, 0]$ 。按 NumPy 所用的正变换负指数、逆变换除以 4 的约定，四点谱和候选更新逐项为：

| $k$ | $X(k)$    | $E(k)$ | $ X(k) ^2 + 1$ | 候选更新量        |
|-----|-----------|--------|----------------|--------------|
| 0   | 3         | 1      | 10             | $3/10$       |
| 1   | $-1 + 2j$ | $-1$   | 6              | $(1 + 2j)/6$ |
| 2   | $-1$      | 1      | 2              | $-1/2$       |
| 3   | $-1 - 2j$ | $-1$   | 6              | $(1 - 2j)/6$ |

最后一列逐频计算的是

$$\Delta W(k) = \frac{X^*(k)E(k)}{|X(k)|^2 + 1}。$$

这里的分母按本例  $\delta = 1$  计算；分子中的星号表示对参考谱取复共轭。例如  $k = 1$  时， $X^*(1) = -1 - 2j$ ，乘  $E(1) = -1$  得  $1 + 2j$ ，再除以 6，得到表中的  $(1 + 2j)/6$ 。

对最后一列作四点 IFFT，候选时域系数为  $[1/30, 1/30, -2/15, 11/30]$ ；将后两点清零后，合法的两抽头成为  $[1/30, 1/30]$ 。若先不逐频除以不同的分母， $\text{IFFT}(X^*E) = [1, 0, 0, 2]$ ，合法梯度是  $[1, 0]$ ；无论再除以哪一个共同标量，第二个合法抽头仍为零。

逐频功率预条件改变了更新方向，时域投影又把频点耦合起来。因此本书 PBFDAF 不是逐样本时域 NLMS 的“完全相同结果、只是更快”，也不一般等于单一标量归一化的时域块 NLMS。这个反例只比较一次无量纲更新，不给出哪种方法收敛更快的证据。

算例 6-5：预测残差很小，不一定辨识了路径。固定种子实验以独立的直接时域卷积生成无噪声观测，真实九抽头路径为  $[0, 0, 0.7, -0.2, 0.08, 0, 0, 0, 0.05]$ ；教学 PBFDAF 取  $N = 16$ 、 $L = 9$ 、 $\mu = 0.3$ 、 $\delta = 0.05$ 。一组训练参考是独立标准正态宽带样本，另一组是每 8 点一周期的纯音。两组各训练 4096 点，再冻结权重，用同一段 1024 点独立宽带参考留出测试。

随机种子为 2094；两条件不是随机重复试验，因此下表只描述这一组样本，不附置信区间。

| 训练参考     | 训练未 1024 点先验残差均方       | 训练后相对路径误差<br>$\ \hat{h} - h\ _2 / \ h\ _2$ | 冻结宽带留出残差均方             |
|----------|------------------------|--------------------------------------------|------------------------|
| 宽带白噪声    | $4.03 \times 10^{-27}$ | $3.27 \times 10^{-16}$                     | $7.52 \times 10^{-32}$ |
| 周期 8 点纯音 | $1.11 \times 10^{-8}$  | 0.868                                      | 0.382                  |

三列均为无量纲数；接近机器精度的项只说明此双精度无噪声算例近乎精确，不能解释为设备精度。纯音只激励有限的频率方向，即使训练残差已很小，系数仍可能远离真实路径，换宽带输入后失配才显露。这个例子解释为什么调试要同时看参考激励、路径误差（有真值时）与留出场景，而不能只看一个训练段的输入/输出功率；它不是工业 ERLE、真实录音结果或收敛速度排名。

第二种明确含义：普通 STFT 域的同频跨帧抽头。对一般短时傅里叶变换（Short-Time Fourier Transform, STFT），分析窗、合成窗与帧移决定了每帧频谱。若某频点只使用自己的过去帧，忽略窗函数与下采样带来的跨频带项，更新式仍可能与式(6-3)同形，却未必逐样本表示同一条时域 FIR。Avargel 与 Cohen, *IEEE Transactions on Audio, Speech, and Language Processing* 15(4), 2007, § II、式(7)~(11)给出一般 STFT 卷积的跨频带项。

即使使用可完美重建的两点、无重叠矩形 DFT，反例也很小：令真实路径是一拍延迟  $y[n] = x[n - 1]$ ，记第  $m$  帧两频点输入为  $X_{0,m} = x[2m] + x[2m + 1]$ 、 $X_{1,m} = x[2m] - x[2m + 1]$ 。输出的零频点等于

$$Y_{0,m} = \frac{1}{2} (X_{0,m-1} - X_{1,m-1} + X_{0,m} + X_{1,m})。$$

它同时依赖  $X_1$ ，所以只让零频点使用零频点历史就漏掉了真实时域路径的一部分；下文两带 Haar 的一拍延迟反例从另一组归一化约定给出同样的跨带现象。这个反例不说明 STFT 同频模型永远不精确：在此无重叠矩形配置中，若路径只在整帧延迟  $qN$  处有抽头，同频跨帧关系可以精确成立。使用哪种近似，要看窗、帧移、路径及容许误差，不能由“完美重建”或“多抽头”单独判断。



MDF、PBFDAF 指向分区块频域结构，不保证所有论文或产品都采用式(6-3)这一种功率归一化与步长控制。Páez Borralló 与 García Otero 的 1992 年 PBFDAF 原论文摘要就说明其更新还考虑输入谱均匀度。上述等价判断只针对已明确输入、误差、归一化和控制方式的具体实现，不能扩展成所有同名变体完全一致。

对照固定版本工业源码时，还应把“每个分区是否更新”和“每个分区是否每块投影”拆开看。SpeexDSP `mdf.c` 的 AUMDF 会逐分区计算权重更新，同时交替安排分区约束；这里的“交替”不能解释成其余分区那一块完全不学习。

WebRTC AEC3 固定版自适应滤波源码同样有分区更新与轮流约束，且其更新增益源码还按激励、饱和等条件控制增益，不等同于本书固定  $\mu$ 、瞬时功率分母的式(6-3)。

对应源码入口和复现实验步骤见研究手册 A02~A03；本书演示仅是可复算的教学基线。

### 6.2.3 子带 AEC：分带、交叉项与可辨识性

为什么分带。一条长回声路径若在每个采样点更新，抽头数增加会同时推高计算量和输入相关性。子带方法先用分析滤波器组把播放参考  $x[n]$  和麦克风观测  $d[n]$  变成多个低采样率序列，再在这些序列上估计回声；估计结果经合成滤波器组回到全带。

比较两套实现时不能只看每带滤波器的乘法量。分析、合成、缓冲和对齐都进入总成本与端到端延迟。

先看一个能完整手算的分析—合成器。本书用两点正交 Haar 变换作教学模型，块号为  $m$ ，同一块含  $x[2m]$  与  $x[2m+1]$ ：

$$u_0[m] = \frac{x[2m] + x[2m+1]}{\sqrt{2}}, \quad u_1[m] = \frac{x[2m] - x[2m+1]}{\sqrt{2}}.$$

$u_0$  是两点和， $u_1$  是两点差；两路都按原采样率的一半更新。合成时，

$x[2m] = (u_0[m] + u_1[m])/\sqrt{2}$ ， $x[2m+1] = (u_0[m] - u_1[m])/\sqrt{2}$ 。把两式代回可逐块精确还原原信号。这个可逆的两带小模型便于揭示子带之间的耦合，但它的两点窗并不是长原型滤波器组，不能据此推断实际音频子带 AEC 的混叠抑制、频率选择性或听感。

完美重建仍不保证独立每带滤波足够。令真实回声路径只有一个非零抽头，位于原采样的一拍延迟处： $d[n] = x[n-1]$ ，负时间输入为零。对回声也作同一个 Haar 分析，得到  $v_0[m]$  与  $v_1[m]$ 。

由  $d[2m] = x[2m-1] = (u_0[m-1] - u_1[m-1])/\sqrt{2}$  和  $d[2m+1] = x[2m] = (u_0[m] + u_1[m])/\sqrt{2}$ ，逐项相加、相减得到

$$\begin{aligned} v_0[m] &= \frac{1}{2}\{u_0[m-1] - u_1[m-1] + u_0[m] + u_1[m]\}, \\ v_1[m] &= \frac{1}{2}\{u_0[m-1] - u_1[m-1] - u_0[m] - u_1[m]\}. \end{aligned}$$

两行都含  $u_0$  与  $u_1$ ：即使原路径只有一个非零抽头，延迟跨过两点块边界后，输出高带也可能由输入低带产生。只让  $v_0$  读取  $u_0$ 、 $v_1$  读取  $u_1$  的对角子带模型便无法一般性地表示这条路径；每个输出带读取所有输入带的交叉子带模型可以表示。Gilloire 与 Vetterli 对临界采样子带自适应滤波的分析也指出了交叉滤波的重要性；本书的 Haar 例是独立的最小代数说明，不是他们实验结果的重现。原论文，[IEEE Transactions on Signal Processing 40\(8\), 1992](#)

锚点数例。取  $x = [1, 1 \mid 0, 0]$ ，竖线隔开两点块。输入第 0 块的带值是  $(u_0, u_1) = (\sqrt{2}, 0)$ ，第 1 块为  $(0, 0)$ ；一拍延迟后  $d = [0, 1 \mid 1, 0]$ ，输出高带依次是  $v_1 = [-1/\sqrt{2}, +1/\sqrt{2}]$ 。

如果高带滤波器只看始终为零的  $u_1$ ，任何有限系数都只能输出零，两个高带回声样本均漏掉。交叉模型按上式从低带取得它们。这个反例证明表示能力有差异；它不能证明交叉模型在有限数据、双讲或未知路径变化下总能更好地收敛。

从已知路径走到未知路径。写  $H = 2^{-1/2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$ ，则  $\vec{u}_m = H[x[2m], x[2m+1]]^\top$ ，麦克风两样本分析为  $\vec{v}_m = H[d[2m], d[2m+1]]^\top$ 。一个  $L$  抽头的因果时域 FIR，能精确改写为  $K = \lfloor L/2 \rfloor + 1$  个  $2 \times 2$  块矩阵的映射  $\vec{v}_m = \sum_{k=0}^{K-1} G_k \vec{u}_{m-k}$ ，负块号的参考设为零。矩阵的行号是输出带，列号是输入带， $k=0$  为当前块。

偶数延迟  $h_{2r}$  只在第  $r$  个时间块矩阵的两个相位对角线各加  $h_{2r}$ 。奇数延迟  $h_{2r+1}$  同时把当前块的偶样本送到第  $r$  个矩阵的输出奇相位，以及把上块奇样本送到第  $r+1$  个矩阵的输出偶相位；再对每个相位矩阵左右乘  $H$ ，得到  $G_k$ 。这就是交叉项的来源。[fir\\_crossband\\_matrices\(\)](#) 按此规则计算，测试另用时域 `np.convolve` 核对  $L = 1, 2, 3, 4, 7, 12$  的输出，而不是拿同一子带公式自证。

路径未知时，不预先把  $G_k$  填成真值。令  $U_{j,k}(m) = u_j[m-k]$ ，估计权重  $W_{i,j,k}$  形状为  $2 \times 2 \times K$ ；其中  $i$  是输出带， $j$  是输入带。先用更新前的全部权重形成两个输出带的预测与先验误差，再用同一个包含两输入带历史的能量分母分别更新两行：

$$\begin{aligned} \hat{v}_i[m] &= \sum_{j=0}^1 \sum_{k=0}^{K-1} W_{i,j,k}[m] U_{j,k}(m), & e_i[m] &= v_i[m] - \hat{v}_i[m], \\ W_{i,j,k}[m+1] &= W_{i,j,k}[m] + \mu \frac{e_i[m] U_{j,k}(m)}{\varepsilon + \sum_{a=0}^1 \sum_{b=0}^{K-1} U_{a,b}(m)^2}, & i, j &\in \{0, 1\}. \end{aligned} \quad (6-4)$$

式(6-4)是本书两带、实数、单播放参考的全交叉块 NLMS 教学定义； $0 \leq \mu < 2$ 、 $\varepsilon > 0$ 。残差两带经逆 Haar 合成为两个时域样本。

冻结某块时，只跳过权重更新，仍把该块参考推进历史；这里的冻结标记由调用方提供，没有实现双讲检测。两点成块必须等第二个样本到来，因果流至少有一个采样的成块等待；代码要求调用方对齐播放与麦克风时间轴。



一步手算。仍用  $x = [1, 1 \mid 0, 0]$ 、 $d = [0, 1 \mid 1, 0]$ ，令  $K = 2$ 、 $W = 0$ 、 $\mu = 1$ 、 $\varepsilon = 1$ 。第 0 块只有  $U_{0,0} = \sqrt{2}$  非零， $\vec{v}_0 = [1/\sqrt{2}, -1/\sqrt{2}]^\top$ ；先验预测为零，分母是  $1 + (\sqrt{2})^2 = 3$ 。于是  $W_{0,0,0} = 1/3$ 、 $W_{1,0,0} = -1/3$ ，其余仍零。

第 1 块当前参考为零，但历史  $U_{0,1} = \sqrt{2}$ ：先验预测仍为零，更新后  $W_{0,0,1} = W_{1,0,1} = 1/3$ 。

高输出带确实从低输入带学到系数；这些权重是两块数据后的状态，不能把本轮先验残差误写为训练后的低误差。[完整可运行输出与独立测试](#)复算此例。

结构反例与留出验证。用随机种子 20260923 生成 2000 个独立标准正态块值，每值在时域重复两次；物理路径固定为一拍延迟， $h = [0, 1]$ 。前 1500 块训练，后 500 块冻结权重作留出测试；两模型同取  $K = 2$ 、 $\mu = 0.5$ 、 $\varepsilon = 0.05$ 。

量化前 float64 值上，真实回声均方约 0.989129，全交叉残差均方在该构造中为 0（浮点输出），对角残差均方约 0.489674。重复样本对使输入高带恒零，对角模型无法预测由块边界延迟产生的高带；这验证该输入和该路径的表示能力，不是一般语音收敛速度、设备 ERLE 或双讲质量排名。训练和留出共享同一条固定路径与参考序列，留出块的权重不再更新，参数、随机种子和计算代码都在[演示](#)中。

代价与边界。全交叉状态有  $4K$  个实系数，时域物理路径只有  $L$  个；除结构约束外，额外自由度可能在有限、相关或噪声数据上难以辨识。

四条子带路径每块约有  $4K$  次系数乘积，摊到原采样约  $2K$  次，未计分析、合成与归一化；不能因为采样率减半就推断一定比  $L$  抽头时域滤波省算力。对角状态仅有  $2K$  个系数，却可能漏掉必要交叉项。

两点 Haar 没有工业原型滤波器组的频率选择性；真实设计还需检查抽取混叠、过采样、滤波器组延迟、路径变化、双讲冻结和异步采样。

本书的[两带教学实现](#)保留三种不同用途：已知路径的精确交叉矩阵用于验证代数；未知路径的对角 NLMS 用作受限反例；未知路径的全交叉 NLMS 用于辨识这个两带模型。

第一项使用已知真值，第二、三项必须从数据更新权重，所以不能把第一项的真值输出与后两项的训练后残差直接当成公平性能对比。完美重建只检查不处理时能否还原信号，不检查回声路径是否可由逐带 FIR 表示。

归一化子带自适应滤波（Normalized Subband Adaptive Filter，NSAF）走另一条路线：它用子带误差更新全带抽头，并不等于式(6-4)的“每个输出带一行块 FIR”。[Lee 与 Gan, IEEE Signal Processing Letters 2004](#)及[同作者原始会议全文 § 1~3](#)可核对这一结构差异。

固定版 pyroomacoustics 的 [adaptive/subband\\_lms.py](#) 可作为接口线索，但其示例目标信号由子带模型合成，不能用它验证任意时域房间路径的对角近似。

图37 两带 Haar：完美重建不等于逐带回声路径等价  
(a) 真实一拍延迟在子带域需要同带项和交叉带项




图37(a)沿用一拍延迟与两点 Haar 定义，箭头表示代数依赖，不表示实际房间能量流或工业滤波器组的混叠抑制量。图37(b)另取单位脉冲  $x = [1, 0, 0, 0]$ ：完整四项子带映射合成  $[0, 1, 0, 0]$ ，只保留精确同带项则合成  $[0, 0.5, 0, 0.5]$ 。斜线柱是删去交叉项后的模型输出，不是训练后 AEC 的残差，也不是上文  $x = [1, 1, 0, 0]$  的第二次测量。

想听和复算同一结构，可看[两带 Haar 的四个合成 WAV](#)。其中“缺失交叉项”仅是已知矩阵删去非对角项的差值，不是对角自适应算法训练后的结果。

#### 6.2.4 IPNLMS：均匀更新与比例更新如何混合

回声路径若只有少数明显非零的抽头，给这些抽头更多更新量可能比所有抽头等权更新更快；但初始路径全为零时，算法还不知道哪些位置重要。

比例归一化最小均方（Proportionate Normalized Least-Mean-Square, PNLMS; Duttweiler, *IEEE Transactions on Speech and Audio Processing* 2000）与改进比例归一化最小均方（Improved Proportionate Normalized Least-Mean-Square, IPNLMS; Benesty 与 Gay, *ICASSP* 2002）让抽头更新方向依赖当前权重幅度。这里的“快”只在相同参考、真实路径、步长和评价口径下比较；分散的路径不应沿用稀疏路径的结论。

本书沿用 Benesty 等 *EUSIPCO* 2004 表 1 的一类混合参数化，不把下式冒称为 2002 年原论文的逐字原式。用  $\kappa \in [-1, 1]$  表示混合系数， $\delta > 0$  防止更新分母为零， $\varepsilon_g > 0$  防止比例项分母为零：

$$\begin{aligned} g_l &= \frac{1 - \kappa}{2L} + \frac{(1 + \kappa)|\hat{w}_l|}{2\|\hat{\vec{w}}\|_1 + \varepsilon_g}, \\ \hat{\vec{w}}^+ &= \hat{\vec{w}} + \mu \frac{eG\vec{x}}{\vec{x}^\top G\vec{x} + \delta}. \end{aligned} \quad (6-5)$$

这里  $g_l$  是第  $l$  个抽头的非负权重， $G = \text{diag}(g_0, \dots, g_{L-1})$ ； $G$  调整更新方向和归一化，而不改变回声副本的卷积定义。

逐样本实现的顺序不能颠倒：先用旧权重与当前参考向量计算先验回声和残差；再由旧权重的绝对值计算  $g_l$ ；随后求  $\vec{x}^\top G\vec{x} + \delta$ ；最后一次性更新全部抽头。若先更新一个抽头再计算下一个抽头的  $g_l$ ，就不再是式(6-5)的同时更新。

若双讲控制要求冻结，这一步只推进参考历史，不把含近端语音的残差用于更新。冻结的标记在本书实验中由真值给出，并不是检测器输出。

$\kappa = -1$  时各  $g_l = 1/L$ ，式(6-5)的分子、分母同乘  $L$  后，正则项变成  $L\delta$ ；因此与式(6-2)的 NLMS 逐步等价还要求  $\varepsilon_{\text{NLMS}} = L\delta_{\text{IPNLMS}}$ （或两者都忽略正则项），不能给两个地板相同数值就宣称完全等价。 $\kappa = 1$  时只剩比例项；零初值下它会全部为零而无法起步，实际实现须保留均匀分量或权重下限。不同文献可能使用  $\alpha$  并改变归一化，比较参数前要先核对定义。

**两抽头手算。** 设  $\hat{\vec{w}} = [0.8, 0.2]^\top$ 、 $\vec{x} = [1, 1]^\top$ 、 $d = 1.2$ 、 $\mu = 1$ ，则先验残差  $e = 1.2 - (0.8 + 0.2) = 0.2$ 。忽略极小的正则项， $\kappa = 0$  时  $g = [0.65, 0.35]$ ，更新量为  $[0.13, 0.07]^\top$ ； $\kappa = -1$  时  $g = [0.5, 0.5]$ ，更新量为  $[0.10, 0.10]^\top$ 。

这个单步例子只说明权重如何分配，不证明长期收敛优劣；声学路径是否足够稀疏还需用目标录音检验。

**正则项不容略过的第二例。** 固定同一  $\hat{\vec{w}}, \vec{x}, d, \mu$ ，改取  $\varepsilon_g = 2$ 、 $\delta = 0.25$ 。当  $\kappa = 0$  时，均匀项为 0.25，比例项分别为  $0.8/4 = 0.2$  和  $0.2/4 = 0.05$ ，故  $g = [0.45, 0.30]$ 。两项之和是 0.75，不是 1；分母为  $0.45 + 0.30 + 0.25 = 1$ ，更新量为  $0.2[0.45, 0.30] = [0.09, 0.06]$ 。

当  $\kappa = -1$  时，两项均为  $1/2$ ，分母为  $0.5 + 0.5 + 0.25 = 1.25$ ，更新量为  $0.2[0.5, 0.5]/1.25 = [0.08, 0.08]$ 。对照 NLMS，令其正则项为  $L\delta = 2 \times 0.25 = 0.5$ ，式(6-2)的更新正好也是  $0.2[1, 1]/(2 + 0.5) = [0.08, 0.08]$ 。因此“ $\kappa = -1$  退化为 NLMS”需要连同正则项尺度一起说； $\varepsilon_g$  较大时也不能暗中把  $g$  强行归一成和为 1。

图38 IPNLMS、RLS 与 Kalman：三种不同的更新状态




图38(a)取前述忽略正则项的两抽头例，显示  $\kappa = -1, 0, 1$  时的 IPNLMS 份额；不是紧邻的  $\varepsilon_g = 2$  例。图38(b)画出 RLS 手算中逆相关矩阵两步的对角与非对角元素；图38(c)在  $X = 1$  下单独改变已知的  $P^-$  或  $\Psi$ ，说明 Kalman 增益的条件依赖。三幅图没有共同声学输入，不是性能排名，不能由柱高判断哪种方法抵消更好。

持续更新的可运行边界。IPNLMS 状态代码和子带/IPNLMS 演示把先验残差、抽头状态和冻结掩码分开返回。稀疏路径、稠密路径、路径突变分别需要独立评价；某一次更新把强抽头推得更远，只能说明当前输入方向上的变化，不能替代多个时刻的系数误差或远端单讲残差曲线。

### 6.2.5 RLS：用参考相关矩阵改变更新方向

递归最小二乘（Recursive Least Squares, RLS）为什么与 NLMS 不同。NLMS 在当前误差的梯度方向走一步；RLS 则把先前参考与麦克风观测形成的相关矩阵压缩成持续更新的状态，求指数加权最小二乘解。

以下先限于实数、单播放参考、单麦克风、长度  $L$  的因果 FIR。

$\vec{x}_n = [x[n], x[n-1], \dots, x[n-L+1]]^\top$  已与麦克风  $d_n$  对齐，预测是  $\vec{w}^\top \vec{x}_n$ 。近端语音若包含在  $d_n$  中，会进入拟合目标，RLS 本身并不知道哪一部分是回声。

有限的初始逆相关矩阵需要一个相应的初始约束。设初始权重  $\vec{w}_{-1}$ 、 $R_{-1} = \delta I$ 、

$P_{-1} = R_{-1}^{-1} = \delta^{-1}I$ ，其中  $\delta > 0$ ；若每个已接纳的样本都执行一次更新，则本书采用的目标是

$$J_n(\vec{w}) = \sum_{i=0}^n \lambda^{n-i} (d_i - \vec{w}^\top \vec{x}_i)^2 + \lambda^{n+1} \delta \|\vec{w} - \vec{w}_{-1}\|_2^2, \quad 0 < \lambda \leq 1. \quad (6-6)$$

式(6-6)第二项不是可随意省略的装饰：它使数据不足、参考只激励部分方向时仍有唯一解。若删掉该项而继续用有限  $P_{-1}$  递推，前几个样本的结果就不再是所声称目标的精确解。 $\delta$  越大，初始路径约束越强、初始逆相关矩阵越小；它与 NLMS 分母的  $\varepsilon$  不是同一个参数。[MathWorks dsp.RLSFilter](#) 的 [InitialInverseCovariance](#) 与递推定义给出同类初始化接口。

对式(6-6)求梯度并令其为零，得到  $R_n \vec{w}_n = \vec{p}_n$ 。逐项把旧样本的权重乘  $\lambda$ ，就有

$$\begin{aligned} R_n &= \lambda R_{n-1} + \vec{x}_n \vec{x}_n^\top, & R_{-1} &= \delta I, \\ \vec{p}_n &= \lambda \vec{p}_{n-1} + \vec{x}_n d_n, & \vec{p}_{-1} &= \delta \vec{w}_{-1}, \\ P_n &= R_n^{-1}, & \vec{w}_n &= P_n \vec{p}_n. \end{aligned} \quad (6-7)$$

不必每个样本重新求逆。令  $q_n = P_{n-1} \vec{x}_n$ ，对  $R_n = \lambda R_{n-1} + \vec{x}_n \vec{x}_n^\top$  使用矩阵求逆引理，并把式(6-7)的  $\vec{p}_n$  代回，可得到等价递推：

$$\begin{aligned} q_n &= P_{n-1} \vec{x}_n, \\ K_n &= \frac{q_n}{\lambda + \vec{x}_n^\top q_n}, \\ \hat{y}_n^- &= \vec{w}_{n-1}^\top \vec{x}_n, \\ e_n^- &= d_n - \hat{y}_n^-, \\ \vec{w}_n &= \vec{w}_{n-1} + K_n e_n^-, \\ P_n &= \lambda^{-1} (P_{n-1} - K_n \vec{x}_n^\top P_{n-1}). \end{aligned} \quad (6-8)$$

这里  $K_n$  是  $L \times 1$  更新增益， $P_n$  是  $L \times L$  逆相关矩阵； $e_n^-$  是用更新前权重计算的先验残差。只算  $q_n$ 、外积和权重更新时，每样本主要成本为  $O(L^2)$ 、仅存  $P$  就需  $O(L^2)$  空间。



本书教学代码为拒绝已经失去正定性的有限精度状态，每次更新另做一次 Cholesky 检查，故这份代码的检查成本为  $O(L^3)$ ；不能把其运行时间当成工业  $O(L^2)$  RLS 的实测表现。

式(6-8)的实数转置约定不能未经检查就套到复数频域：要先固定预测采用  $\vec{w}^H \vec{x}$  还是  $\vec{w}^\top \vec{x}$ ，再处理增益和误差的共轭。[MathWorks 官方算法式](#)可用于核对常规 RLS 更新；本书式(6-6)的初始化项和以下数字由本书推导。

两抽头锚点手算。取  $L = 2$ 、 $\lambda = 1/2$ 、 $\delta = 1$ 、 $\vec{w}_{-1} = 0$ ，故  $P_{-1} = I$ 。顺序输入  $\vec{x}_0 = [1, 0]^\top$ 、 $d_0 = 1$  与  $\vec{x}_1 = [1, 1]^\top$ 、 $d_1 = 2$ ；第二个回归向量可由连续参考  $x[0] = x[1] = 1$  产生。这是无量纲算术例，不是实录回声或收敛性能结果。

第 0 步有  $q_0 = [1, 0]^\top$ 、分母  $1/2 + 1 = 3/2$ 、 $K_0 = [2/3, 0]^\top$ 。先验预测为零、 $e_0^- = 1$ ，所以  $\vec{w}_0 = [2/3, 0]^\top$ 、 $P_0 = \text{diag}(2/3, 2)$ 。第二个对角元从 1 变为 2，是未受参考激励方向的旧信息被遗忘，不表示那里已量到新的路径。

第 1 步  $q_1 = P_0 \vec{x}_1 = [2/3, 2]^\top$ ，分母  $1/2 + 2/3 + 2 = 19/6$ ，因此  $K_1 = [4/19, 12/19]^\top$ 。先验预测  $2/3$ 、残差  $4/3$ ，得到  $\vec{w}_1 = [18/19, 16/19]^\top$  与  $P_1 = \begin{bmatrix} 20 & -16 \\ -16 & 28 \end{bmatrix} / 19$ ；中途保持分数，最后才按需舍入。

再走一条独立的批量路线：式(6-6)在第 1 步给  $R_1 = \begin{bmatrix} 7/4 & 1 \\ 1 & 5/4 \end{bmatrix}$ 、 $\vec{p}_1 = [5/2, 2]^\top$ 。直接解  $R_1 \vec{w} = \vec{p}_1$  得  $[18/19, 16/19]^\top$ ，其逆也等于上段的  $P_1$ 。这验证两步递推与指定的含初始约束目标一致；换遗忘因子、删去初始项、加入近端语音或让参考秩亏，不能沿用这两个系数。[可运行逐样本示例](#)和[批量独立测试](#)复算此例。

遗忘、双讲与工程边界。对无限长、每步都接纳的序列，指数权重总和趋近  $1/(1 - \lambda)$ ； $\lambda = 0.99$  时约为 100 个单位权重的总量，不是 100 个统计独立样本。若输入独立同分布，权重平方和给出的等效样本数趋近  $(1 + \lambda)/(1 - \lambda) \approx 199$ ；两种数量的定义不同。

时间跨度还须乘每次更新的实际采样或块间隔。减小  $\lambda$  能更快淡忘旧路径，也放大噪声和近端干扰的影响。[MathWorks 在线估计文档](#)给出遗忘因子的时间尺度解释；这里的权重和及等效样本数是本书求和。

双讲时， $d_n$  中的近端语音进入  $e_n^-$ ，式(6-8)仍会更新；已知双讲区间可以冻结更新作受控对照，但实际设备须另测检测器、更新恢复及近端损伤。

参考为零时  $K_n = 0$ ，常规递推仍会把  $P$  除以  $\lambda$ ；长静音可能使逆相关状态膨胀，需要限幅、重置或按实现定义暂停遗忘。

浮点舍入还可能让  $P$  失去对称性或正定性；Householder、QR 或平方根实现是数值方案，不能与普通 RLS 混为“更快”的同义词。



对  $L = 4096$ ，单个 float64 的  $P$  已有  $4096^2 \times 8 = 128$  MiB，尚未计多通道、历史和工作缓冲。长路径通常先考虑分区、子带或其他结构化近似，再测实际设备资源。[MathWorks dsp.RLSFilter 的方法选项](#)列出常规、Householder、滑动窗与 QR；选择这些方法不等于 MathWorks 的 AEC 示例本身用了 RLS。

#### 6.2.6 Kalman：同时描述路径变化与观测不确定度

卡尔曼路径估计与频域卡尔曼滤波（Frequency-Domain Kalman Filter, FDKF）。卡尔曼模型区分两种不确定性：回声路径自身怎样变化，以及麦克风观测里有多少路径不能解释的近端语音和噪声。增益像自适应步长，但“最小均方误差”只在选定的线性状态、二阶统计量和估计类别下成立，不能保证任意双讲或扬声器非线性下最优。

FDKF 将这类状态递推放到块频域。“每频点一个系数”只是后面的标量对角近似；完整分区结构还含分区、参考通道及其协方差。[Enzner 与 Vary 2006 原论文与作者对状态空间 FDAF 的说明](#)均不支持把一般频域 NLMS 直接改名为精确 Kalman。

为先看清状态含义，取已对齐、实数、长度  $L$  的时域 FIR 作模型； $\vec{h}_n$  是当前真实回声路径， $a$  是标量状态转移因子， $\Delta\vec{h}_n$  是零均值过程扰动， $s_n$  是近端语音， $v_n$  是其他加性观测噪声：

$$\begin{aligned}\vec{h}_n &= a\vec{h}_{n-1} + \Delta\vec{h}_n, \\ d_n &= \vec{x}_n^\top \vec{h}_n + s_n + v_n.\end{aligned}\tag{6-9}$$

第一行描述路径的漂移或突变；第二行指出麦克风为何不等于回声副本。过程协方差  $Q = \text{Cov}(\Delta\vec{h}_n)$  与观测方差  $\Psi = \text{Var}(s_n + v_n)$  不是同一种噪声； $\Psi$  也不要与上面 RLS 的参考相关矩阵  $R_n$  混淆。

同写为  $P$  的两个状态也不同：式(6-7)中它是样本相关矩阵的逆，式(6-10)与式(6-11)中它是路径估计误差协方差；只有下文限定条件成立时，两套递推才可作代数对应。

增大  $Q$  表示更不信任旧路径，增大  $\Psi$  表示更不信任这次麦克风观测。实际近端语音有时间相关性，路径突变也未必符合平稳随机模型；式(6-9)只是估计器的工作假设，不是真实声场的完整生成式。[两抽头矩阵 Kalman 教学实现](#)使用此实数约定，而不是把它冒称为完整 FDKF。

双讲时，若观测噪声估计  $\Psi_m$  随近端语音能量增大，卡尔曼增益会减小。路径变化后，先验残差  $E_m$  可能增大，但下文式(6-10)中的增益并不直接依赖  $E_m$ ；只有过程噪声、误差协方差或状态重置策略相应调整时，增益才可能上升并加快重新收敛。每个频点还需维护误差方差或协方差，因此同等频域卷积结构之外另有统计量的计算与存储；不能不指定近似形式就报一个统一复杂度。

下式是便于复算的逐频点标量近似，不是完整分区 FDKF 的跨频点、跨分区协方差递推。假设已对齐的参考  $X_m$  已知，状态扰动与观测扰动为零均值、彼此及与先验状态误差不相关； $P_{m-1} \geq 0$ 、过程方差  $\Phi_m \geq 0$ 、观测方差  $\Psi_m > 0$ ，且所用二阶矩与该模型相符。

在这些条件下，增益是只用当前复数创新、不另用其共轭的最小均方误差复线性增益。若相关复数变量进一步联合为圆对称（proper）复高斯，或全部变量是实数高斯，它也是相应条件均方误差意义下的最优增益。非圆对称复高斯可能需要同时利用创新及其共轭，不能套用这一最优性结论；Dini 与 Mandic 2010 的广义复卡尔曼分析给出这一边界。下面省略频点下标， $W_{m-1}$  是上一块的路径系数， $P_{m-1}$  是其误差方差， $a$  是状态转移因子：

$$\begin{aligned} \hat{W}_m^- &= aW_{m-1}, & P_m^- &= |a|^2 P_{m-1} + \Phi_m, \\ E_m &= D_m - X_m \hat{W}_m^-, & K_m &= \frac{P_m^- X_m^*}{|X_m|^2 P_m^- + \Psi_m}, \\ W_m &= \hat{W}_m^- + K_m E_m, & P_m &= (1 - K_m X_m) P_m^-. \end{aligned} \quad (6-10)$$

前两式先预测路径和不确定度；协方差传播使用  $|a|^2$ ，因为复数状态模型的一般形式是  $APA^H + Q$ 。中间两式根据先验残差计算增益；最后两式更新系数和误差方差。标量复数模型中  $K_m X_m$  为实数且位于 0 与 1 之间。

实际分区频域实现还要处理矩阵协方差、块卷积约束和频点平滑，不能把上面的标量递推直接复制成完整系统。Enzner 与 Vary 2006

观测方差不是残差平方。若假定路径  $W$  精确已知，且残差完全由零均值圆对称复高斯观测噪声产生，单帧负对数似然的相关项才是  $|E|^2/\Psi + \log \Psi$ ，其单帧极大似然解为  $\hat{\Psi} = |E|^2$ 。这组假设恰恰排除了需要估计的路径不确定度，不能直接用于式(6-10)的 Kalman 创新。

在式(6-10)的模型下，创新方差是  $S = |X|^2 P^- + \Psi$ 。若把  $P^-$  和  $X$  当作已知，且仍只用一帧圆对称复高斯创新，则对  $\Psi \geq 0$  的受限极大似然解为  $\max(0, |E|^2 - |X|^2 P^-)$ ；它仍会把路径失配、双讲、噪声和单帧随机波动混在一起。工程实现需另估计或控制  $Q$ 、 $\Psi$ ，并检查双讲和路径突变的不同征兆；不能把当前  $|E|^2$  宣称为测得的近端语音功率。

最小数例取  $X = 1$ 、 $P^- = 1$ 。远端单讲时若  $\Psi = 0.01$ ， $K = 1/1.01 \approx 0.990$ ，残差的大部分用于更新；双讲时若  $\Psi = 10$ ， $K = 1/11 \approx 0.091$ ，同一残差下的更新量约为前者的 9.2%。这说明软门控会缩小更新，但并没有严格冻结。

另固定  $X = 1$ 、 $P^- = 1$ 、 $\Psi = 1$ ，无论先验残差为 0 还是 10，增益都为  $K = 1/2$ 。若路径突变检测后把预测方差调整为  $P^- = 4$ ，在其余条件不变时才得到  $K = 4/5$ 。这是式(6-10)的代入，不表示实际检测器一定能正确区分路径突变与双讲；两者都可能增大残差，却需要不同的更新控制。

完整的一轮标量递推。取实数特例  $W_{m-1} = 0.2$ 、 $P_{m-1} = 0.5$ 、 $a = 1$ 、 $\Phi_m = 0.1$ 、 $X_m = 2$ 、 $D_m = 1.4$ 、 $\Psi_m = 0.4$ 。预测得到  $\hat{W}_m^- = 0.2$ 、 $P_m^- = 0.6$ ；先验残差  $E_m = 1.4 - 2 \times 0.2 = 1.0$ 。于是

$$K_m = \frac{0.6 \times 2}{2^2 \times 0.6 + 0.4} = \frac{1.2}{2.8} \approx 0.4286,$$

$$W_m = 0.2 + 0.4286 \times 1.0 \approx 0.6286,$$

$$P_m = (1 - 0.4286 \times 2)0.6 \approx 0.0857.$$

用更新后的系数回看该观测，残差为  $1.4 - 2 \times 0.6286 \approx 0.1429$ ；它是后验检查，不应代替式(6-10)中用于更新的先验残差。若  $\Psi_m \rightarrow \infty$ ，则  $K_m \rightarrow 0$ ，路径几乎不更新；若理想化地令  $\Psi_m \rightarrow 0$  且  $X_m \neq 0$ ，标量模型会令  $K_m \rightarrow 1/X_m$ 、 $P_m \rightarrow 0$ 。实际系统存在模型失配和数值误差，需要为方差设置正下限，不能把  $P_m = 0$  当作永久确定。

不提前舍入时，上例的精确分数是  $P^- = 3/5$ 、 $E^- = 1$ 、创新方差  $S = 14/5$ 、 $K = 3/7$ 、 $W = 22/35$ 、 $P = 3/35$ 、后验残差  $1/7$ 。[标量递推代码](#)逐项输出这些量，并用相同  $X$  与先验把  $\Psi$  从 0.4 改为 4：增益由  $3/7$  降到  $3/16$ ，后验权重从  $22/35$  变为  $31/80$ 。这只验证假定观测方差已知时的代数响应，不是程序成功检测到了双讲。

另取复数  $X = i$ 、 $P^- = \Psi = 1$ ，式(6-10)给  $K = -i/2$ ；若漏掉共轭，会得到错误的  $+i/2$ 。上述三项有[独立分数与边界测试](#)，仍不能代替完整 FDKF 或 PBFDKF 的协方差、分区和声学验证。

矩阵状态说明标量近似舍掉了什么。对实数路径状态，令  $A$  是  $L \times L$  转移矩阵、 $Q$  是过程协方差，观测仍为标量  $d_n$ 。先预测，再用先验创新更新：

$$\begin{aligned}\hat{h}_n^- &= A\hat{h}_{n-1}, \\ P_n^- &= AP_{n-1}A^\top + Q, \\ S_n &= \vec{x}_n^\top P_n^- \vec{x}_n + \Psi, \\ K_n &= P_n^- \vec{x}_n / S_n, \\ \hat{h}_n &= \hat{h}_n^- + K_n(d_n - \vec{x}_n^\top \hat{h}_n^-), \\ P_n &= (I - K_n \vec{x}_n^\top) P_n^- (I - K_n \vec{x}_n^\top)^\top \\ &\quad + K_n \Psi K_n^\top.\end{aligned}\tag{6-11}$$

最后一行是 Joseph 协方差形式；当增益精确且计算无舍入时，它与简写的  $(I - K_n \vec{x}_n^\top) P_n^-$  等价。近似增益或有限精度下，Joseph 形式更明确保留非负协方差结构；这不保证所有错误的  $Q$ 、 $\Psi$  或增益都能被修复。[矩阵教学代码](#)和[独立测试](#)仅实现短实数 FIR，不含 FFT、分区约束或统计量在线估计。

两维协方差手算。取  $A = I$ 、 $Q = 0$ 、 $\Psi = 1$ 、 $\hat{h}^- = 0$ 、 $P^- = \text{diag}(1, 4)$ 、 $\vec{x} = [1, 1]^\top$ 、 $d = 3$ 。式(6-11)给  $S = 1 + 4 + 1 = 6$ 、 $K = [1/6, 2/3]^\top$ 、 $\hat{h} = [1/2, 2]^\top$ ，Joseph 更新得到  $P = \begin{bmatrix} 5/6 & -2/3 \\ -2/3 & 4/3 \end{bmatrix}$ 。虽然先验是对角矩阵，同一次观测同时约束两个抽头，后验立刻出现非零交叉协方差。

下一次若参考回归向量是  $[-1, 1]^\top$ 、其余预测条件不变，完整创新方差为  $[-1, 1]P[-1, 1]^\top + 1 = 9/2$ ；把  $P$  的非对角项直接丢掉则只得  $19/6$ 。这证明对角近似会改变下一次增益的分母，不证明完整矩阵算法在任意录音上必优。数例与[逐步输出](#)采用同一抽头顺序和无量纲值；实际频域分区还需有效区投影、复数共轭和频点/分区结构。

RLS 与 Kalman 何时同式。在式(6-11)取静态路径  $A = I$ 、 $\Psi = 1$ ，并人为令每次预测协方差  $P_n^- = P_{n-1}/\lambda$ ，则  $K_n = P_{n-1}\vec{x}_n/(\lambda + \vec{x}_n^\top P_{n-1}\vec{x}_n)$ ，恰是式(6-8)的增益。这相当于每次使用依赖当前后验协方差的  $Q_n = (\lambda^{-1} - 1)P_{n-1}$ ； $\lambda = 1$  时  $Q_n = 0$ 。

这是本书在指定归一化下的代数对应，不表示任意固定  $Q$  的 Kalman、FDKF 或 PBFDKF 只是 RLS 改名；两者还可能采用不同的观测模型、变换约束和双讲控制。

分区块频域卡尔曼滤波 (Partitioned-Block Frequency-Domain Kalman Filter, PBFDKF) 把长回声路径分区，状态和协方差还要考虑分区及多播放通道。Kuech、Mabande 与 Enzner 的 ICASSP 2014 状态空间架构是分区方法的原始依据之一；不能把本书单频点、单状态演示直接当作该完整算法。[原论文 DOI 10.1109/ICASSP.2014.6853806](#)。

Zhu 等的 Interspeech 2021 双声道推导分别讨论精确分区递推与两种协方差简化：VD-PBFDKF 只保留同播放声道、同分区的块；SD-PBFDKF 在同分区还保留跨播放声道的块，两者都舍去某些跨分区相关。保留项不同，矩阵乘法和统计近似就不同。论文图 4~5 的结果只属于其给定双声道、块长、路径及双讲条件。[Zhu 等, § 2~3、图 4~5](#)。

公开的第三方短代码可辅助读递推，但其后滤、启发式门控和许可必须分别核对，见[研究手册 A04](#)。

从标量数例走到分区频域模型，究竟多出什么。式(6-10)每频点只保留一个权重和一个非负方差，因而无法表达“上一块的另一分区权重也能解释本块观测”。完整状态必须把若干分区、频点以及多播放通道的系数排成一个向量  $\mathbf{w}_m$ 。对长度  $N$  的有效麦克风块  $\mathbf{d}_m$ ，先建立一条由当前和历史参考块决定的线性观测算子  $H_m$ ；它包括频域相乘、逆变换和只取后  $N$  个有效样本，不能把循环卷积前半块也当成独立的真实观测。



在零均值、互不相关且二阶统计量已知的线性状态模型下，完整矩阵增益可写成

$$\begin{aligned}
 \hat{\mathbf{w}}_m^- &= A\hat{\mathbf{w}}_{m-1}, \\
 P_m^- &= AP_{m-1}A^H + Q, \\
 \mathbf{e}_m^- &= \mathbf{d}_m - H_m\hat{\mathbf{w}}_m^-, \\
 K_m &= P_m^-H_m^H(H_mP_m^-H_m^H + \Psi_m)^{-1}, \\
 \hat{\mathbf{w}}_m &= \hat{\mathbf{w}}_m^- + K_m\mathbf{e}_m^-.
 \end{aligned} \tag{6-12}$$

这里  $A$  是状态转移矩阵； $P_m^-$ 、 $Q$  分别是状态误差与过程扰动的协方差； $\Psi_m$  是有效时域观测块的干扰协方差； $H$  上标表示共轭转置。

若状态有  $M$  个复数系数、有效块含  $N$  个样本， $P_m^-$  是  $M \times M$ 、 $H_m$  是  $N \times M$ 、括号内是  $N \times N$ ，故  $K_m$  是  $M \times N$ 。这组维度检查也说明把所有分区都写成一个标量  $K$  会漏掉相关结构。

式(6-12)是本书按线性观测模型写出的未简化母式，并非声称能直接用密集矩阵实时处理长路径。频域系数还需服从有限长时域 FIR 的有效抽头约束；若按频点、分区或播放通道丢弃协方差块，就从母式走向不同的 FDKF/PBFDKF 近似。

哪一层“对角”被保留必须写清楚，不能仅把式(6-10)复制  $P$  次便称为论文完整分区算法。Zhu 等，Interspeech 2021，§ 2~3 给出双声道分区实现中的具体观测约束与 VD/SD 简化；本书式(6-12)只用于解释这些结构的维度。

已知真值的双讲反例。先取一个实数抽头， $P^- = 1$ 、 $w^- = 0$ 、 $x = 1$ 、观测方差  $\Psi = 0.1$ ，且首个观测  $d = 1$ 。卡尔曼增益为  $1/(1 + 0.1) = 10/11$ ，后验  $w = 10/11$ 、 $P = 1/11$ 。下一次真实路径仍是 1，但加入近端成分 2，使  $d = 3$ ；这时先验残差是  $3 - 10/11 = 23/11$ ，其中大部分并非路径突变。

若仍误设  $\Psi = 0.1$ ，第二次增益为  $(1/11)/(1/11 + 1/10) = 10/21$ ，新权重为  $10/11 + (10/21)(23/11) = 440/231 \approx 1.905$ 。若已知双讲而把  $\Psi$  调成 10，增益变为  $1/111$ ，新权重为  $10/11 + 23/1221 \approx 0.928$ ；若理想冻结观测更新，权重保持  $10/11 \approx 0.909$ 。

三种结果只说明观测方差和真值控制改变了更新；它们都没有提供从实际麦克风信号自动识别双讲的方法。路径若恰在双讲时突变，冻结也会延迟跟踪。

同输入 RLS/Kalman 受控实验把 512 个无量纲样本分成远端单讲、已知近端注入、远端恢复与路径突变四段。固定种子为 20260923，使用两抽头、名义 8 kHz；同一播放参考和真实路径供各算法使用。实验分别报告先验回声估计与已知回声真值的均方误差、后验路径均方根误差，以及 Kalman 增益范数。

双讲段中，固定低  $\Psi$  的 Kalman 回声估计误差均方约为 0.1341；在真值已知的区间提高  $\Psi$  后约为  $1.57 \times 10^{-5}$ ，理想冻结约为  $9.83 \times 10^{-6}$ 。

这些是本书一组短合成序列的算术输出，不是双讲 ERLE、自动检测成绩、自然语音质量或 RLS/FDKF 的一般性能排名。RLS 的遗忘因子与 Kalman 的  $Q, \Psi$  描述不同先验，也不能把参数数值设成相同就称为“公平调参”。

另一组合成音频用 16 kHz、四抽头已知路径和同一麦克风输入导出 NLMS、IPNLMS、RLS、短实数矩阵 Kalman 的先验线性残差；中途人为改变路径，另存真值回声与背景噪声。音频只对应这四种时域教学实现，不含完整子带 AEC、FDKF/PBFDKF、真实语音或实机结果。四法的参数并非等效调优，表格中的单次均方误差也不是普适优劣顺序。

方法对比。下表比较模型和资源依赖，不给没有共同输入、路径、收敛目标与实现条件支撑的“快、中、慢”排名。若要比较实际收敛，需在同一播放参考、回声路径、双讲安排和统计窗口上运行各实现，并分别报告初始收敛、突变恢复与稳态误差。图32给出排障流程，而不是算法性能排序。

| 算法         | 每样本主要计算                                                       | 收敛受什么影响              | 双讲更新控制           | 适用条件            |
|------------|---------------------------------------------------------------|----------------------|------------------|-----------------|
| 时域 NLMS    | $O(L)$ ；朴素约 $3L$ ，<br>能量递推主要项约 $2L$                           | 输入谱、步长、路径变化          | 需外部冻结或连续步长控制     | 路径较短，或资源允许逐样本更新 |
| 比例更新       | IPNLMS: $O(L)$ ，另有比例权重计算                                      | 稀疏路径可能更快；稠密尾声不能照搬该趋势 | 仍需双讲控制           | 有明显强抽头且已测得收益    |
| 分区频域       | PBFDAP: 无约束约 $O(\log N + L/N)$ ；<br>逐分区约束另加 $O((L/N) \log N)$ | 频点归一化、块长和梯度约束        | 需二值或连续控制         | 长路径且可接受分块处理     |
| 子带自适应      | 分带、降采样与每带短滤波                                                  | 带内谱、分析/合成混叠          | 仍需双讲控制           | 已核对带间混叠和系统延迟    |
| RLS        | 标准全矩阵实现 $O(L^2)$                                              | 遗忘因子、参考条件数和噪声        | 干扰会影响更新，不能只调遗忘因子 | 短滤波器或研究对照       |
| 频域卡尔曼 FDKF | 频域滤波外另维护状态统计量                                                 | 过程/观测噪声估计与状态模型       | 增益可软门控，但不自动识别双讲  | 路径变化且统计模型可校验    |

§ 6.1.1 ~ § 6.2 建立了线性回声模型，并比较了 NLMS、分区频域方法、比例步长和频域卡尔曼滤波。常用的输入/输出功率近似 ERLE 应在远端单讲统计；线性滤波只能处理参考可表示的线性回声，参考抽头位置和双讲控制还需另行设计。

非线性回声与双讲控制（§ 6.3 ~ § 6.4）



## 6.3 非线性回声：模型失配与处理方法

---

非线性从哪来。微型扬声器的悬边与磁路在大振幅下不再线性（悬边变硬、音圈跑出匀强磁场区），功放或数字播放链在大音量下可能削顶（clipping），机壳与结构件也可能随声压振动产生二次辐射。Birkett & Goubran (WASPAA 1995) 实测讨论了免提终端中的非线性回声，Klippel (JAES 2006) 从扬声器物理模型分析了相关机制。这里不作“最早提出”的优先权判断。


平台从哪里来。线性滤波器只能估计播放参考历史样本的线性组合。扬声器失真若产生该组合无法表示的谐波或互调分量，即使线性路径估计已收敛，这些分量仍会留在残差；E06-06 的单频输入和三次项给出一个可复算例子。

这不是“凡有非线性必有残余”的定理：若参考样本只取  $\{-1, 1\}$ ，则  $x^3 = x$ ，该输入上的三次映射也能由线性增益表示。能否抵消取决于实际参考集合、路径长度和失真模型。


图 19 (a) 用一组独立定量仿真展示这项能力边界，图 31 则用另一组受控仿真和静态映射检查同一机制。两图都取 3 s 输入、256 抽头、步长 0.3 和驱动系数 1.1。

两图的随机种子、参考序列边界成形方式、具体输入和路径实现不同，属于两次独立单次仿真，ERLE 数值不能横向比较。每个平台高度只属于各自图示配置，不能外推为某类设备固定的 ERLE 上限。

图19 AEC 的模型失配与方法分类



(b) 按模型假设和处理对象区分 AEC 方法



这些模块按路径长度、变化速度、非线性程度和资源约束选择; 横向位置不表示年代或性能排名。

图19 (a) 是独立定量仿真, 只支持其图示配置下“非线性失配使线性 AEC 出现残差平台”这一结论; 它与图31不是同一实验, 不能比较两图的平台高低。(b) 按模型假设和处理对象区分逐样本时域 LMS/NLMS、分区块频域 MDF/PBFDAF、状态空间频域卡尔曼滤波和残余抑制。横向位置不表示年代或性能排名; 选择方法时要结合路径长度、变化速度、非线性程度和资源约束。

tanh 的最小手算。

图 31 使用归一化映射  $y = \tanh(1.1x) / \tanh(1.1)$ ，使  $x = 1$  时  $y = 1$ 。取  $x = 0.3$ ，得到  $y \approx 0.398$ ；取  $x = 1.5$ ，得到  $y \approx 1.160$ 。相对参考直线  $y = x$ ，两点的偏差分别约为  $+0.098$  和  $-0.340$ 。

该映射在零点附近的斜率为  $1.1 / \tanh(1.1) \approx 1.37$ ，所以  $y = x$  只是图中的参考线，不是它的小信号切线。

这两个采样点只说明映射具有曲率，不能推出整段语音的失真功率或 ERLE。平台数值还取决于输入分布、路径、最佳线性拟合和统计窗口。

图31 本仿真中的线性匹配与非线性失配




图31 (a) 在当前仿真参数下比较线性路径与  $\tanh(1.1x) / \tanh(1.1)$  非线性路径，后段均值由脚本按图示窗口计算，不是设备性能上限。(b) 显示同一映射相对参考直线  $y = x$  的曲率。图31的唯一职责是把“映射曲率—线性模型残差平台”对应起来；线性滤波器无法精确表示由此产生的非线性分量，因此只增加抽头或调整步长不能消除该模型失配。

显式建模非线性。二阶 Volterra（沃尔泰拉）模型在线性核之外加入历史样本的两两乘积。对实数输入，令对称的二阶核只保留  $0 \leq i \leq j < L$ ，可写成

$$\hat{y}(n) = \sum_{i=0}^{L-1} w_i x(n-i) + \sum_{0 \leq i \leq j < L} q_{ij} x(n-i)x(n-j). \quad (6-13)$$

线性部分有  $L$  个系数，二阶部分有  $L(L+1)/2$  个； $L = 256$  时仅二阶部分就有 32,896 个。式(6-13)直接把  $q_{ij}$  定义为独立的上三角系数；若从完整对称核  $H$  改写，非对角项应取  $q_{ij} = H_{ij} + H_{ji} = 2H_{ij}$ ，对角项仍是  $q_{ii} = H_{ii}$ ，不能简单删除下三角而不合并交叉项。

限制核的跨度、秩或保留的交互项可降低资源需求，却也改变可表达的失真。二阶模型不能自动处理所有非线性：纯单频输入的平方只有直流和二次谐波，不能生成练习 E06-06 中三次项的三次谐波。[Stenger 与 Rabenstein, NSIP 1999, § 3.1 式\(1\) – \(2\)](#)

级联模型要按处理顺序区分：Hammerstein 是静态非线性后接线性动态 ( $N \rightarrow L$ )，Wiener 是线性动态后接静态非线性 ( $L \rightarrow N$ )，Wiener – Hammerstein 则是  $L \rightarrow N \rightarrow L$ 。如果失真发生在扬声器前、声学传播在后， $N \rightarrow L$  可以作为候选；实际扬声器和播放链可能更复杂，不能仅凭框图确定结构。Nollett 与 Jones (NSIP 1997, § 2) 研究的是 Wiener – Hammerstein 结构，而不是上述两段模型；其摘要报告在论文测得的扬声器信号条件下，相对线性基线改善 8.4 dB。

[Nollett 与 Jones 1997](#)

这个数值与论文中的输入、失真模型、路径和统计口径绑定。当真实失真偏离模型假设时，需要重新测量收益。

改变参考取点。非线性发生在播放链路里，可以把参考取在更接近扬声器的一端，使参考包含更多已经发生的失真。这样减少了需要由自适应模型解释的链路，但并不消除参考点之后的机电或结构非线性。

- **电信号参考**直接采样扬声器端子的电压或电流。Shah 等 (*IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2015) 的作者机构摘要报告，真实设备实验相对其比较基线的 ERLE 改善最高为 6 dB，不是对所有设备的保证；该参考仍不能捕捉其取点之后的全部机电或结构失真。[作者机构论文页](#)
- **机械振动参考**用加速度计采集振膜或机壳振动，需增加传感器和采集通道。

两种做法都要比较新增参考带来的收益、噪声、同步误差和硬件代价。

学习型残余抑制。深度神经网络 (Deep Neural Network, DNN) 可以从数据学习残余抑制, 适用条件和验证方法见 § 6.5。它与改变参考取点、显式建模并非互斥; 评估时要分别报告线性副本和最终输出。

## 6.4 双讲检测与自适应控制

双讲时, 残差同时包含路径失配和近端语音。若仍按普通 NLMS 更新, 近端语音会进入梯度并使路径估计偏离。双讲检测 (Double-Talk Detection, DTD) 用于降低步长或冻结更新。门限过于敏感会延迟路径跟踪, 门限过于迟钝则可能导致误更新。

常见 DTD 方法 (DTD = 双讲检测, double-talk detection; NCC = 归一化互相关, normalized cross-correlation) :

1. Geigel 幅度比较: 设  $x_a$  为已经补偿纯延迟、送入长度  $L$  自适应滤波器的参考。先检查  $M(n) = \max_{0 \leq j < L} |x_a(n-j)|$  是否大于参考活动门限; 只有活动时才计算  $\xi(n) = |d(n)|/M(n)$ , 高于判决阈值时判为双讲。 $M(n) = 0$  时不能做除法, 也不能把本次观测当成可靠双讲判决。

经典示例阈值  $T = 0.5$  来自线路回声中混合器至少衰减 6 dB 的假设 ( $20 \log_{10} 2 \approx 6$  dB), 不是任意声学回声路径的固定阈值。多抽头路径的若干项还会在同一样本叠加, 单个参考峰值与麦克风回声峰值之间没有通用的 0.5 上界。

两抽头反例令  $x_a(n) = x_a(n-1) = 1$ 、真实路径  $h = [0.4, 0.4]$ 、 $s = 0$ , 则  $d = 0.8$ 、 $M = 1$ 、 $\xi = 0.8 > 0.5$ ; 明明没有近端讲话, 仍被判为双讲。反过来, 回声很弱时小声近端也可能漏检。因此它适合低成本初筛, 不宜单独承担声学双讲检测。Duttweiler, *IEEE Transactions on Communications*, 1978;

2. 互相关 / 归一化互相关 (NCC) (Benesty、Morgan 与 Cho) : 原方法用播放参考向量与麦克风观测  $d$  的归一化互相关构造双讲统计量, 不是把残差  $e$  与参考  $x$  去相关后直接判双讲。简化为单抽头、零均值且近端  $s$  与参考  $x$  不相关的  $d = hx + s$ , 有  $|\rho_{xd}| = |h|\sigma_x / \sqrt{h^2\sigma_x^2 + \sigma_s^2}$ : 只有远端回声时为 1, 近端语音功率增加时下降。例如  $h = 0.5$ 、 $\sigma_x^2 = 1$ 、 $\sigma_s^2 = 0.25$  时为  $0.5/\sqrt{0.5} \approx 0.707$ 。实际多抽头检测用参考向量和协方差归一化, 不能把这个单抽头值当通用门限。 $x$  与  $e$  的相关性更适合提示回声路径失配; 单凭它低或高都不能可靠区分双讲和路径变化。Benesty、Morgan 与 Cho, *IEEE Transactions on Speech and Audio Processing* 2000、Benesty 与 Gänslér, *IWAENC* 2001, § 3;
3. 频域 NCC (Gänslér & Benesty, *Signal Processing* 2001) : 在频域逐频点估计相关性, 可与 PBFDAF 复用部分频域表示; 额外计算量取决于平滑、频带汇总和判决实现;
4. 相干函数法: 用  $d$  与  $x$  的幅度平方相干判别, 与 NCC 同族;

5. 双滤波器法：前台滤波器负责输出，后台滤波器用更大的步长寻找新路径。后台并不是“不怕双讲”；双讲时照常大步更新同样会偏离真实路径，所以它也要根据双讲置信度缩小步长或冻结。

只有当后台滤波器在一段保持时间内持续得到更小的远端单讲残差，才把系数复制到前台。切换判决需要门限和迟滞，避免两套滤波器来回切换。

WebRTC AEC3 的 refined/coarse 结构采用了相近的快慢滤波思路，但具体更新和切换规则以对应版本源码为准。

Geigel 判决的数字例子。只为复算经典线路回声假设，设参考历史窗的峰值为 1.0，并把回声简化为单个衰减 6 dB 的副本，则远端单讲时  $|d| \approx 0.5$ ，阈值 0.5 位于边界。这个数字没有包含声学多径叠加、背景噪声或参考失配，不能据此为声学 AEC 固定阈值。实际强回声可能在远端单讲时误判，弱回声叠加小声近端语音又可能漏检。

从二值冻结到连续步长。冻结是 0/1 开关，也可以根据残余回声与近端干扰的相对功率连续调整步长。Mäder、Puder & Schmidt (*Signal Processing* 2000) 推导的最优步长  $\alpha(k)$  在  $[0, 1]$  内变化：回声占优时增大，双讲占优时减小。连续控制可减少硬切换造成的跟踪迟滞。



图30 延迟对齐与合成近端干扰时的冻结




图 30 属于本节的时序控制例。图 30 (a) 在前 4000 个样本上计算参考与麦克风信号的有符号互相关，最大正相关峰位于约 331 个采样。仿真设置的纯延迟是 300 个采样；参考是有色信号，路径又含多个正负抽头，因此相关峰是输入自相关与整条路径共同作用的结果，不能解释成“300 加某个主抽头位置”。若改取互相关绝对值、使用广义互相关（Generalized Cross-Correlation, GCC）加权或改变参考频谱，峰值也可能改变。

图 30 (b) 中，对齐后的远端单讲 ERLE 约为 28 dB，不对齐时约为 2 dB。本例的纯延迟超过 128 抽头滤波器的覆盖范围，因此差异较大。

**覆盖长度的硬边界。** 设纯延迟为  $D$  个样本，随后真实路径仍有从索引 0 到  $R$  的非零尾声。若不先对齐，长度  $L$  的因果 FIR 要覆盖整个路径，至少需要  $L \geq D + R + 1$ ；对齐后才只需覆盖尾声。

若参考到达处理器的时间晚于麦克风回声所对应的播放内容，增加因果抽头无法预测尚未拿到的样本，必须修正参考取点、缓冲或时序。此式是支持集长度条件，不保证满足后一定能在有噪声和双讲时收敛。

单次相关峰只提供候选延迟。负极性回声可使最大正相关峰选错位置，工程上需同时检查绝对峰或更合适的加权估计，并结合播放、采集时间戳。

固定偏移表现为滞后长期近似常数；采样时钟偏移（SRO）通常表现为随时间渐变的斜率；设备切换或缓冲欠载则可能表现为突跳。三者要分别记录和处置，不应全靠调大滤波器长度。[排障与源码核对](#)

图 30（c）比较合成近端干扰期间冻结和继续更新；后者会使路径估计偏离，干扰结束后需要重新收敛。该段是白高斯随机样本，不是语音双讲录音；排查时应分别检查延迟估计方法和双讲控制。

6.4.1 自动双讲检测的四状态实验

前面的冻结例使用已知双讲区间。要检验检测器本身，必须把输入给检测器的两路波形与只用于评分的活动真值分开。本书的 `ncc_activity_states()` 把已对齐的参考  $x$  和麦克风观测  $d$  分成互不重叠的 160 点帧：参考和麦克风都静音、只有参考活动、只有麦克风活动、两者都有活动而绝对归一化互相关低于门限，分别判为静音、远端单讲、近端单讲和双讲。参考静音时不做双讲比值判决。

[可复算脚本](#)以 16 kHz、种子 20260924 生成两条独立高斯波形，已知回声路径为  $[0.6, 0.25]$ ；五个连续阶段各含 20 帧，依次为静音、远端单讲、近端单讲、双讲、远端恢复。参考和近端波形幅度系数分别为 0.3 和 0.22，参考活动门限为帧内去均值均方根 0.02，绝对互相关门限为 0.85。这些门限只为此确定性教学输入给定，没有在独立录音上标定。

| 真值状态       | 预测静音 | 预测远端单讲 | 预测近端单讲 | 预测双讲 |
|------------|------|--------|--------|------|
| 静音         | 20   | 0      | 0      | 0    |
| 远端单讲（含恢复段） | 0    | 40     | 0      | 0    |
| 近端单讲       | 0    | 0      | 20     | 0    |
| 双讲         | 0    | 0      | 0      | 20   |

表中数字是单次合成运行的逐帧计数，分母为 100 帧；没有抽样区间，也不是设备检出率。检测器只读取  $x, d$ ，不读取生成器的真值状态。

把预测双讲帧展开为逐样本冻结掩码后，用相同 NLMS 参数处理，双讲区间已知回声分量的残余均方根为 0.0812；若不断更新为 0.1492。这两个数字只比较同一合成回声真值，不把含近端波形的总输出当作 ERLE，也不评价语音听感。

两种控制在随后的远端恢复段均收敛到所给路径，最终抽头误差都接近浮点舍入级，不能据最终抽头推断双讲期没有损害。

反例同样重要：另给 20 帧没有近端输入的远端单讲，把路径改成 [0.1, 0.75]，同一单帧互相关检测器把 20 帧全误判为双讲，平均绝对互相关约 0.1105。路径变化与近端语音都可能降低这个统计量；实际系统要结合延迟、路径变化估计和跨帧证据，并在独立设备数据上标定误报、漏报及冻结代价。这里实现的是可检查的自动判决基线，不是 WebRTC AEC3 或 SpeexDSP 的内部控制逻辑。[Benesty、Morgan 与 Cho 的互相关 DTD 原论文](#)。

神经 DTD。Ivry et al. 的深度变步长（Deep Variable Step-Size, DVSS, ICASSP 2022）用 DNN 预测逐帧步长。在该论文的数据、路径突变定义、成功判据和基线实现下，DVSS 的重收敛时间为 3.4 s、成功率为 95%，NLMS 加经典 DTD 基线分别为 7.9 s 和 58%。

这些是论文实验结果，不是产品验收阈值；复现时要沿用论文的判据，部署时则按目标设备另定恢复条件。[Ivry et al., ICASSP 2022](#)

§ 6.3～§ 6.4 分别说明了非线性失配和双讲误更新。非线性残余可通过显式建模、改变参考位置或学习型抑制处理；双讲期间应根据检测置信度冻结或减小步长。由于输出含近端语音，双讲区间不能用普通 ERLE 评价。

学习型残余抑制、阵列顺序与评测（§ 6.5～§ 6.7）

## 6.5 学习型 AEC

微软 AEC Challenge 的评测变化。以下只摘录 ICASSP 2021 会议报告和介绍 2023 年挑战的 IEEE OJSP 2024 期刊报告中可直接定位的信息。挑战赛年份与论文出版年份不同；挑战赛的届次名称、任务、排名指标和延迟约束也会改变，不能由仓库更新时间推断后续赛事状态。

| 报告                         | 可复核的设置                              | 读取时的限定                       |
|----------------------------|-------------------------------------|------------------------------|
| ICASSP 2021 报告             | 发布真实设备录音并引入 ITU-T P.808 众包主观评价      | 数据数量、系统排名和分数应直接查报告的数据与结果表    |
| 2023 挑战（IEEE OJSP 2024 报告） | 包含一般 AEC 和个性化 AEC 任务，并同时考查主观质量与语音识别 | 注册语音、延迟和排名条件只属于该届规则，不是通用产品规范 |

[Sridhar et al. \(ICASSP 2021 AEC Challenge 报告\)](#)、[Cutler et al. \(2023 AEC Challenge, IEEE OJSP, vol. 5, pp. 675 – 685, 2024\)](#)

这些报告说明，ERLE 不能单独表示双讲质量或近端语音损伤，因此评测还需主观质量和下游识别指标。参赛系统同时包含线性 AEC 加学习型后滤波的混合方案和端到端方案。两类方法应按延迟、算力、泛化和故障诊断要求分别评估。

后续报告继续加入全频带、个性化和下游识别等条件。复现时应从对应年份的规则和论文表格读取采样率、延迟、注册语音与排名指标，不把某届数字写成后续系统的通用限值。

**混合式结构：线性估计加学习型残余抑制。**自适应滤波器利用已知参考估计线性回声，不需要训练数据；神经网络则处理线性模型未覆盖的残余回声、环境噪声和部分晚期混响。两者分工可以减少网络需要学习的动态范围，同时保留线性段的路径与收敛诊断。

可以用 SER（信号回声比，signal-to-echo ratio）为 -20 dB 的时频点说明两类方法的差别：此时回声能量是近端语音的 100 倍。

只考虑相位完全正确的标量幅度误差，令真实回声为  $y$ 、副本为  $\hat{y} = 0.9y$ ，则残差为  $0.1y$ ，残余能量是原回声的  $|0.1|^2 = 1\%$ ，相当于降低 20 dB。若副本还有相位误差，残余比应按  $|1 - \alpha e^{j\phi}|^2$  计算，不能沿用 1%。

若只对混合信号施加同一个增益  $g$ ，回声和近端语音会同比缩放，该时频点的 SER 不变。混合结构因此先用参考完成线性减法，再对无法建模的残余施加增益抑制。

图32 线性回声消除与残余抑制：按系统条件选择模块  
混合处理流程：线性前级与残余后处理各有适用前提




图32只画一类混合流程，不含 (a) (b) (c) 子图。参考  $x$  经延迟估计得到对齐参考  $x_a$ ，线性 AEC 用  $x_a$  估计回声并输出残差  $e$ ；图中的控制框从  $x_a$  和  $e$  提取统计量来调整更新，不表示所有双讲检测器都只用这两个输入。学习型残余抑制可使用残差与可选参考，最终输出须同时检查回声泄漏和近端语音损伤。此图说明信号依赖，不是 NLMS、PBFDAF、FDKF 的性能排序。

**后滤波器的输入与输出：**输入可以包括残差  $e$ 、参考  $x$  的逐帧谱，以及滤波器系数范数、当前步长和各频带相干性等线性 AEC 内部量。网络输出逐频带增益或其他滤波参数。频带划分、特征维度和训练目标属于具体模型版本，不能在不同实现之间直接套用。

代表方案如下：

- PercepNet：在传统线性 AEC 之后，用网络估计 Bark 频带增益和周期性滤波参数，联合抑制残余回声与噪声。这个结构说明了解析路径估计与学习型后处理的功能分工；论文中的实时性只适用于所述模型、处理器和计时口径，换设备后仍需重测双讲近端保护与资源占用。[Valin et al., ICASSP 2021](#)；
- Ma et al. 2020：自适应滤波器加 RNN 后处理的公开实现展示了同一混合思路；该来源是 arXiv 预印本，结果应按文中的数据与基线解读。[Ma et al., arXiv:2005.09237](#)；
- DeepVQE (Interspeech 2023)：单模型联合 AEC、降噪和去混响，用交叉注意力在参考与麦克风信号之间做软对齐。论文报告了作者实现面向 Teams 场景的实时测试；这一结论只适用于论文所述模型、硬件和软件配置，不能据此推断其他实现的实时性。[DeepVQE, DOI 10.21437/Interspeech.2023-1028](#)

**端到端神经 AEC**把问题写成条件语音分离：输入麦克风信号和播放参考，直接估计近端语音。它能联合建模非线性与残余噪声，但低 SER 下的近端保护、未见设备上的泛化、因果延迟和故障诊断都需要单独验证。深度滤波不只输出 0~1 掩码，而是估计复数时频滤波器，可以同时调整幅度和相位。不同方案的 MOS 与 ERLE 只有在数据、场景、延迟和统计区间相同的条件下才能比较。

**训练数据。**回声路径可以用 § 2.4 的镜像法生成不同房间尺寸和  $T_{60}$ ，非线性失真可以用随机 Wiener – Hammerstein 级联参数化，SER 和 SNR 也可按区间采样。真实设备录音仍用于覆盖仿真中缺少的扬声器、结构振动和系统链路特性。常见做法是先用合成数据训练，再用目标设备录音微调并验证。

**神经卡尔曼滤波：**保留递推结构，学习难以建模的部分。“神经卡尔曼”并不是单一网络接口，不能把所有论文概括为直接预测卡尔曼增益。例如 NeuralKalman (ASRU 2023, § 2.2、图 1(b)) 用网络学习非线性参考变换  $g$ 、状态转移因子  $A$  和非线性状态转移  $t$ ，其余递推仍须结合论文方程理解。另有直接估计频域卡尔曼增益的 NKF 方案；两者改变的变量不同，不宜合并成一行实验结果。[NeuralKalman 原论文](#)、[NKF 原论文](#)



NeuralKalman 已发表于 ASRU 2023；引用性能结果时需同时给出论文中的数据集、基线和表格位置。NeuralKalman, DOI 10.1109/ASRU57964.2023.10389780

Deep Adaptive AEC 把自适应滤波器写成可微分层，并由网络估计参考变换和时变学习因子。这种联合训练仍需在目标设备上验证路径突变与双讲时的稳定性。Zhang et al., ICASSP 2022

Seidel et al. 的综述发表于 *IEEE Signal Processing Magazine*, vol. 41, no. 6, pp. 24 – 38, 2024。各方法的收敛、双讲保护和计算量应按该文的具体实验设置解读。Seidel et al., DOI 10.1109/MSP.2024.3449557

把混合式方案按功能拆开，可分为自适应控制、线性路径估计和残余抑制。网络可以估计步长、卡尔曼统计量或残余增益；PBFDAF/FDKF 等解析结构仍提供可检查的路径估计和收敛状态。具体分工取决于延迟、算力和训练数据，不能写成固定的行业结论。

个性化 AEC (personalized AEC, pAEC)：2023 年 AEC Challenge 报告描述了个性化任务，系统要消除回声并保留注册用户的近端语音。Cutler et al., IEEE OJSP 2024

注册语音时长、延迟和评分条件应按该报告的对应规则复现，不能写成所有 pAEC 产品的通用标准。

系统从注册语音提取声纹嵌入，并把它作为网络条件。这一思路与目标说话人提取 (Target Speaker Extraction, TSE；见 § 13.3) 相近。GTCNN, Interspeech 2022 合规与验收细节见 § 6.13。

pAEC 门限例子。设注册嵌入为  $\vec{e}_{\text{enroll}}$ ，逐帧近端嵌入为  $\vec{e}_t$ ，余弦相似度  $c = \cos(\vec{e}_t, \vec{e}_{\text{enroll}})$ 。阈值不能从通用经验直接照搬，应在目标设备、注册时长、距离和噪声条件下，用目标用户和非目标用户验证集标定。可以设置放行、抑制和不确定三个区间。若优先保护目标用户，不确定区间应减弱或旁路身份条件的抑制，但非目标语音泄漏可能增加；若提高抑制强度，则必须接受目标用户被误压的风险。普通线性回声抵消仍可独立工作。验收时分别报告目标用户误抑制率、非目标用户泄漏率和普通双讲质量，而不是只报一个相似度阈值。

多通道扩展：网络的输入通道数由训练时的结构决定，不能把任意数量的麦克风或播放参考直接拼接给固定模型。常见做法有三种：

1. 固定阵列几何和通道数训练；
2. 先用共享编码器逐通道提取特征，再用池化或注意力聚合可变通道；
3. 先做逐通道线性 AEC 和波束形成，只让单通道网络处理波束输出。



第二种能适应缺失通道，但仍需在训练中覆盖通道数、阵列几何和通道置换。多通道网络还要保持跨通道相位一致性，否则会损害后续波束形成。

对实时语音交互，设备播放语音时仍要检测用户插话。通常先用线性 AEC 降低设备自身播放，再把残差送入语音活动检测和识别；残余抑制的工作点要同时检查回声泄漏、近端语音失真和下游识别。若参考信号只能在远端获得，模块顺序需要按实际接口重新设计。

三类神经方案对比（定性；需要在相同数据、延迟和硬件下实测）：

| 路线    | 代表方案                | 可检查的内部量        | 主要风险             | 资源验证             |
|-------|---------------------|----------------|------------------|------------------|
| 混合式   | 线性 AEC 加学习型残余抑制     | 线性段路径、残差和 ERLE | 后滤波可能损伤近端语音      | 按频带数、模型版本和目标硬件测量 |
| 端到端   | 以麦克风信号和播放参考直接估计近端语音 | 通常缺少显式路径估计     | 域外设备、低 SER 和故障定位 | 按模型、上下文和目标硬件测量   |
| 神经卡尔曼 | 保留状态递推并学习增益或统计量     | 递推增益、状态估计和残差   | 统计量估计失配、模型计算量    | 同时报递推部分与网络部分     |

按设备条件选型：

- 耳机和手表受算力、内存与功耗限制，可比较端侧小模型与传统频域方案；
- 音箱和会议终端可评估 PBFDAF 或 FDKF 加神经后滤波；
- 双讲条件复杂且需要保留递推诊断量时，可进一步评估神经卡尔曼；
- 需要只保留注册用户时再评估 pAEC。

语音助手还要单独验证用户插话（barge-in）时的近端保护。无论采用哪条路线，系统设计仍需处理 § 6.8 所列的参考、延迟、双讲和残余回声问题。

## 6.6 阵列中的 AEC：与波束形成的三种顺序

多麦克风设备里，AEC 与波束形成（第 5 章）谁先做，是系统级的架构决策，教科书上三种排法：

1. AEC→BF（每通道独立 AEC）：每个麦克风通道各配一套 AEC，波束形成在回声消除之后进行。优点是各通道回声路径  $h_m(n)$  不受波束权重变化影响；代价是线性 AEC 的计算与状态量随麦克风数  $M$  增加，量化见本节算力表。

当波束权重持续变化且计算资源允许时，这是优先评估的结构；

2. BF→AEC (波束后单 AEC) : 线性 AEC 从每个麦克风一路减少为波束输出的一路; 实际节省量还要扣除波束处理和共享计算。

在忽略跨频带耦合的同频带窄带近似下, 频域波束权重变化时可写

$H_{\text{eff}}(k, n) \approx \sum_m w_m^*(k, n) H_m(k, n)$ 。一般 STFT 分析、合成窗未必允许把整条时域回声路径精确写成逐频点乘法, 时变权重也不对应一条固定的线性时不变路径; [Avargel 与 Cohen 2007](#), § II 给出跨频带项的来源。若采用固定时域 FIR 波束器, 则相应的精确线性时不变形式是各路波束 FIR 与  $h_m$  卷积后求和。

权重变化会使等效路径变化, AEC 需要重新跟踪, 暂态可能出现回声泄漏。暂时保持波束权重可以减小该变化, 但会降低追踪灵活性;

3. 联合优化 (GEIC, 广义回声与干扰对消, Generalized Echo and Interference Canceller) : Herbordt 与 Kellermann 把回声路径与波束权重放进同一个约束优化框架联合求解。在相应模型和目标函数下可得到联合最优解, 但实现需要维护更多统计量和滤波系数。经典出处为 Kellermann (ICASSP 1997) 与 Springer 《Microphone Arrays》(2001) 第 13 章。

联合分析: Schwartz et al. (Interspeech 2024) 在论文所述的多通道维纳滤波 (Multichannel Wiener Filter, MCWF) 模型下分析了 AEC 与波束形成的顺序。结论依赖其统计模型和目标函数; 实际系统若采用波束后 AEC, 需要验证权重变化期间的回声泄漏, 也可评估在重收敛期间暂时保持波束权重。 [Schwartz et al., Interspeech 2024](#)

边栏: 立体声 AEC 的非唯一性问题。两个扬声器的参考完全线性相关时, 参考相关矩阵秩亏, 正常方程奇异: 除了真实回声路径, 还存在无穷多组解能拟合当前数据。参考只是高度相关而非完全相关时, 矩阵通常不是严格奇异, 但可能病态, 对噪声和节目内容变化很敏感 (Sondhi, Morgan & Hall, *IEEE Signal Processing Letters* 1995) 。去相关方法给各路参考加轻微且互不相同的处理, 以改善条件数; 非线性处理的可闻影响和改善程度要另行测量 (Benesty et al., ICASSP 1997) 。 [Benesty et al. 1997](#) 完整选型见 § 6.9。

立体声非唯一性的数字例子。若  $x_1 = x_2 = x$ , 真实路径  $h_1 = 0.8$ 、 $h_2 = 0.2$  与另一组  $h'_1 = 1.3$ 、 $h'_2 = -0.3$  都产生  $(h_1 + h_2)x = x$ , 仅凭当前参考无法区分。相关系数  $\rho = 0.99$  时, 归一化相关矩阵的特征值为  $1 \pm \rho$ , 条件数约为 199, 说明估计对噪声和信号变化很敏感。去相关的目标是改善条件数, 但改善程度仍应由实际节目内容和处理强度测量。

排序理由见本节, 参考链路见 § 10.1 和图23。波束权重变化会使波束后 AEC 看到的等效路径变化, 因此不能只按麦克风数量决定顺序。选型时应同时测量逐通道 AEC 的资源开销, 以及波束后 AEC 在权重切换、目标移动和双讲条件下的恢复过程。

多通道计算量手算。下面只比较能够从本章计数规则复算的选定核心算子乘法量。共同条件为 16 kHz、 $L = 2048$ 、PBFDAF 块长  $N = 128$ ；不是全算法乘法上界或设备计时。

时域 NLMS 每样本按  $3L = 6144$  次实乘法计。PBFDAF 沿算例 6-2 的同一口径，16 个分区时无约束版约 352 次/样本。若每块对每个分区执行“IFFT、清零、FFT”梯度约束，再加  $2 \times 16 \times 4096/128 = 1024$  次/样本，总计约 1376 次/样本。

若与算例 6-2 一样逐块、逐分区、逐复频点重算  $|X|^2$ ，还须加  $2 \times 256 \times 16/128 = 64$  次实乘法/样本，使两项成为至少 416 和 1440 次/样本，仍未计功率求和、除法与步长缩放。下表保留 352/1376 的原始核心算子口径以便复算，不可把它当作完整计算量。结果也不含延迟搜索、双讲检测、残余抑制、内存访问和硬件并行。

| 算法               | 单通道本书手算                                   | $M$ 通道关系                                 | 仍需实测的资源                  |
|------------------|-------------------------------------------|------------------------------------------|--------------------------|
| 时域 NLMS          | $6144 \times 16000 \approx 98.3$ 百万次实乘法/s | 约为 $M_{\text{mic}} \times 98.3$ 百万次实乘法/s | 指令数、内存带宽、系数与历史缓冲         |
| PBFDAF，无逐分区梯度约束  | $352 \times 16000 \approx 5.6$ 百万次实乘法/s   | 约为 $M_{\text{mic}} \times 5.6$ 百万次实乘法/s  | FFT 实现、功率估计、约束频率与缓冲      |
| PBFDAF，每块逐分区梯度约束 | $1376 \times 16000 \approx 22.0$ 百万次实乘法/s | 约为 $M_{\text{mic}} \times 22.0$ 百万次实乘法/s | 同上，并计入每个分区的一对约束变换；间歇约束另算 |
| FDKF 或神经后滤波      | 不给固定倍数                                    | 由状态维度或模型结构决定                             | 目标实现的算子、线程、内存和实时因子       |

逐通道线性 AEC 的主要计算量随麦克风数  $M$  近似线性增长；放在波束后的单通道处理只运行一路，但会面对等效路径随波束权重变化的问题。两种结构应分别在目标实现上测量资源，并检查波束切换期间的回声泄漏。

## 6.7 评测体系与工程验收清单

客观指标与适用边界。ERLE (echo return loss enhancement，回声返回损失增强) 应在远端单讲的同一统计窗口内计算：

$$\text{ERLE} = 10 \log_{10} \frac{\sum_n |y(n)|^2}{\sum_n |e_{\text{echo}}(n)|^2} \tag{6-14}$$

其中  $y$  是进入消除器前的真实回声分量， $e_{\text{echo}}$  是消除后的回声分量；在线性路径模型下才有  $y = x * h$ 。

真实录音通常不能直接分离这两项。测试时可用远端单讲录音，以 AEC 输入和输出功率近似，但背景噪声会给分母设置下限。报告中应注明采样率、统计窗口、是否去除初始收敛段，以及输出是否包含残余抑制。

双讲时若只有混合输入和最终输出，二者总功率之比不再表示回声衰减；应改用双讲回声和近端语音质量指标。若合成数据另有干净回声及残余回声分量真值，式(6-14)仍可对这些分量单独计算，但必须说明取得真值的办法。图 18、图 19 (a)、图 29 和图 31 来自不同仿真配置，数值不能横向比较。

ERLE 换算。若残余回声能量与输入回声能量之比为 0.0063，ERLE 为  $10 \log_{10}(1/0.0063) \approx 22$  dB；比值为 0.0001 时，ERLE 为 40 dB。双讲段的输出还含近端语音，不能把总输出能量直接代入 ERLE 分母。

主观与自动感知指标。ERLE 只度量能量衰减，不能反映残余回声的音色或近端语音损伤。

AECMOS (Purin et al., ICASSP 2022) 分别预测回声感知分和 “Other” 维度；后者表示回声之外的其他可闻退化，例如语音失真和噪声。AECMOS

自动感知模型会受到训练域、版本和输入处理影响，不能替代双盲听测；报告时应固定模型版本，并与真人听测和下游任务一起使用。

系统验收的三类结果：

1. 收敛后残余回声：在远端单讲稳定期分别报告线性滤波输出和最终输出。前者用于检查路径估计，后者还包含残余抑制；两者不能共用一个 ERLE 名称而不说明取点。
2. 重收敛过程：规定路径突变方式，并报告从突变发生到恢复到项目基线的时间及成功比例。  
§ 6.4 的 DVSS 数字只适用于论文实验，不能作为产品验收阈值。
3. 双讲期质量：同时评估近端语音损伤和残余回声。阈值要绑定具体标准版本、测试序列和目标设备基线；自动指标可用于固定版本的回归测试，不能替代真人听测。

§ 6.5～§ 6.7 比较了混合式、端到端和神经卡尔曼方案，并说明了阵列中的模块顺序和评测口径。线性 ERLE、最终输出质量和近端语音损伤应分别报告；AEC 放在波束形成之后时，还需验证波束权重变化造成的路径突变。

系统实现与验收 ( § 6.8～§ 6.17)

## 6.8 WebRTC AEC3 的结构与排障

---

完整 AEC 的通用系统功能（图20（a）给出部分信号流；下列功能不表示 WebRTC AEC3 为每项都设置独立的二值模块）：


1. 参考—麦克风延迟对齐：播放缓冲、采集缓冲和声学传播共同决定总延迟，其大小应在目标音频路径上测量。若参考与麦克风信号里的回声没有对齐，滤波器会用部分抽头覆盖纯延迟，延迟超出覆盖范围时则无法表示完整路径（抽头点细节见 § 6.10）；
2. 双讲期的更新控制：双讲期的  $e$  含近端语音，更新不受控会使路径估计偏离。二值 DTD 冻结和连续减小学习率是两类实现策略；图18（b）、图29和图30（c）使用的是本书已知真值的冻结示例，不表示 AEC3 内部有同样的显式冻结开关；
3. 非线性处理器（Nonlinear Processor, NLP）残余回声抑制：频域进一步衰减线性滤波器未建模的回声分量，工作点设置见 § 6.12；
4. 舒适噪声生成（Comfort Noise Generation, CNG）：强抑制可能使背景噪声突然消失，听感上形成不连续的静音。CNG 可按真实底噪的频谱和电平合成背景；频谱或电平失配时，合成噪声本身会变得可辨认。

NLP 可以处理扬声器失真和路径时变留下的一部分残余回声，但采集端麦克风或模数转换器削波还会破坏近端语音；已丢失的幅度不能由 NLP 恢复。设备应优先用模拟/数字增益控制避免削波，并用饱和和检测触发冻结更新或降级处理。



图20 AEC 信号处理链：自适应滤波与混合式结构（示意）

(a) 经典 AEC 信号流：已知参考学出回声副本再相减（示意）



(b) 混合式处理链：线性回声估计 + 学习型残余抑制（示意）




图20 (a) 显示参考输入、延迟估计与自适应滤波的基本信号流；该子图没有绘出本节所述的 NLP 和 CNG。(b) 显示混合式结构，橙色框表示可采用学习型残余抑制的部分。完整产品还需按前述顺序接入 NLP、CNG 和对应的双讲保护。

WebRTC AEC3 架构示例。AEC3 的内部模块和参数会随源码版本及构建配置变化，下面依据 WebRTC 官方源码提交 [0467d2b91cc20b9b001c2bbb73d43ea6b2491f3e](#) 说明一种开源实现的分工，不把内部常数当作产品规格：

- 分块流水处理：采集和参考按内部子块推进。子块大小、采样率转换和缓冲共同决定延迟，需针对所用源码版本实测；
- Render Buffer：保存远端参考历史，为延迟估计和路径滤波提供候选数据。所需覆盖范围由播放、采集和传输链路的实测延迟及抖动确定；
- 降采样参考—采集延迟估计：锁定版本的 `echo_path_delay_estimator.cc` 对降采样的播放与采集数据运行匹配滤波，再由 lag 聚合器选择延迟；`block_processor.cc` 据此调整参考缓冲。它不是比较下述 refined/coarse 两个消除滤波器的残差来搜索延迟；路径或输出设备切换后还要检查缓冲和重新对齐过程；
- refined/coarse 双滤波器：两组滤波器使用不同更新增益。该版本的 `echo_remover.cc` 比较 refined/coarse 残差功率、回声功率等量来选择线性输出并平滑切换；`subtractor.cc` 在 coarse 连续较差时还会用 refined 系数重置它。这是线性回声抵消和更新控制，不是上条的延迟候选搜索，也不能概括成检测到双讲就统一冻结；
- 频域抑制器和舒适噪声：线性部分之后按频带控制残余回声，并在需要时生成与背景相符的舒适噪声。具体增益规则应以所用版本源码和目标设备测试为准。[WebRTC](#) `echo_path_delay_estimator.cc`、`block_processor.cc`、`subtractor.cc`、`echo_remover.cc`。

线性输出不是只能靠内部日志取得。在上述锁定版本，公开配置

`EchoCanceller::export_linear_aec_output` 默认关闭；启用后，经 APM 处理可调用 `GetLinearAecOutput()` 并检查其布尔返回值。该接口导出约 10 ms、16 kHz、单声道的线性段数据，比较最终输出前须按采样率、通道及处理延迟对齐。失败返回不能用全零代替成功输出。

`set_stream_delay_ms()` 的请求值在该版本会被截到 0~500 ms，越界给警告；调试时应检查返回状态、实际设置值和播放/采集时间戳，而不是只记录请求参数。[锁定版本 APM 公开头文件](#)

接口故障的反例。SpeexDSP 的异步 `playback / capture` 队列在启动或参考欠载时可能把原始麦克风帧直接送出；这段输出不说明自适应算法已经收敛或失败。先检查参考帧是否在采集帧前进入、首帧是否被丢弃、欠载次数及通道交织顺序。多麦或多扬声器测试应给各物理通道注入不同位置的脉冲，不能给所有通道同一脉冲后宣称顺序正确。[SpeexDSP mdf.c](#) [锁定源码](#)、[工业接口核对](#)

排障清单（回声消不掉，按顺序查）：

1. 检查参考抽头位置：优先选择包含混音、音量、均衡和限幅等已知数字处理的最晚可用参考。抽头后的时变或非线性变换可能留下线性滤波器无法表示的残余；见 § 6.10；

2. 检查延迟估计：逐步注入已知延迟并记录 ERLE 和路径估计。失配仍在滤波器覆盖范围内时，影响取决于剩余可用抽头和路径能量分布；失配超过滤波器跨度时，滤波器无法覆盖完整路径。图30（b）只展示本书仿真的一个越界例子；
3. 检查双讲冻结或步长缩减：否则近端语音会使路径估计偏离（见图30（c））；
4. 比较算法前先排除接口问题：确认参考内容、取点、延迟覆盖、削波和双讲控制，再在同一录音与统计窗口上比较算法。收敛时间和稳态 ERLE 应相对项目基线判断，不使用通用秒数或 dB 阈值。

## 6.9 多参考 AEC 模型与去相关选型

单参考 AEC 假设只有一路播放；立体声外放、双扬声器和多分区播放属于多参考问题。模型是否可辨识取决于参考声道之间的相关性和各条回声路径，不能用固定 ERLE 损失概括。

三种多参考实现组织。前两行都估计单个麦克风的多路播放回声，差别在系数怎样更新，不能把它们当作两种不同的物理传播模型：

| 模型                                           | 结构                                                                                    | 可辨识性                     | 资源关系                   | 适用条件                    |
|----------------------------------------------|---------------------------------------------------------------------------------------|--------------------------|------------------------|-------------------------|
| 逐参考分支、共享总残差                                  | 各分支预测先相加，再以同一个 $e = d - \sum_r \hat{y}_r$ 更新各分支；可用各路自己的归一化分母                          | 忽略跨参考统计量时，强相关输入仍会使路径估计病态 | 滤波与状态近似随参考路数增加         | 单个麦克风接收多路播放，需核对总残差与更新控制 |
| 联合 MISO（多输入单输出，Multiple-Input Single-Output） | 拼接多路参考回归向量，以总预测与共同残差联合估计多条路径                                                          | 仍受拼接参考相关矩阵条件数限制          | 同时维护多组路径；全矩阵方法还维护交叉统计量 | 需要显式处理参考间相关性时           |
| MIMO 阵列联合                                    | 多参考和多麦克风联合估计，例如广义回声与干扰抵消（GEIC）和扩展多通道维纳滤波（extended Multichannel Wiener Filter, MWText） | 可联合利用跨通道统计量，但仍需满秩激励      | 随参考数、麦克风数和状态维度增加       | 需要联合回声与空间干扰处理           |

参考声道越多，待估参数越多；声道内容越相关，正常方程越接近奇异。去相关用于改善相关矩阵的条件数。

为什么不能把两个单参考输出直接相加。本书取无噪声、单抽头、同一参考  $x_1 = x_2 = x$ ，麦克风观测  $d = x$ 。若让两个单参考滤波器各自用完整的  $d$  当目标，它们都可能得到系数 1；合成预测为  $x + x = 2x$ ，总残差反而是  $-x$ 。

正确的多参考误差先减去两路预测之和，即  $e = d - \hat{h}_1x_1 - \hat{h}_2x_2$ ；此例只要求  $\hat{h}_1 + \hat{h}_2 = 1$ ，能完全抵消当前回声，却无法由完全相同的两路参考唯一辨识各自路径。参考内容后来若改变，这种非唯一性还会影响预测。Gilloire, IWAENC 1997, § 2给出共同残差与立体声相关性的原始模型。

去相关方法对照（以立体声 AEC 为例）：

| 方法                             | 做法                | 可能的副作用        | 验证方法                     |
|--------------------------------|-------------------|---------------|--------------------------|
| 半波整流 (half-wave rectification) | 各声道施加不同的轻微非线性     | 谐波失真、声像变化     | 同时测参考相关矩阵条件数、远端单讲残余和主观音质 |
| 时变相位调制                         | 各声道施加独立的慢变全通相位    | 瞬态或声像可能变化     | 在语音与音乐材料上分别盲听，并检查路径跟踪    |
| 独立小频移                          | 各声道施加方向或大小不同的微小频移 | 音乐可能出现拍频或音高扰动 | 扫描移频量，比较可辨识性与可闻失真        |
| 低电平去相关噪声注入                     | 各声道叠加独立、整形后的低电平噪声 | 底噪升高          | 按目标播放电平测条件数、底噪和听感        |

是否启用去相关，应根据目标节目材料在工作频带内的相干函数、相关矩阵条件数和路径估计稳定性判断。确定候选方法后，逐步增加处理强度，并同时复测远端单讲残余、近端单讲失真、双讲质量和主观音质；处理强度的上限由项目听测与任务指标共同决定。

多参考相关性的数字例子。两路等功率参考的归一化相关矩阵为  $\begin{bmatrix} 1 & \rho \\ \rho^* & 1 \end{bmatrix}$ 。本书由其特征方程得到特征值  $1 \pm |\rho|$ ；当  $|\rho| < 1$  时，二范数条件数为  $(1 + |\rho|)/(1 - |\rho|)$ 。 $\rho = 0.95$  和  $\rho = -0.95$  都得到 39， $|\rho| = 0.6$  时降为 4； $|\rho| = 1$  时矩阵奇异。

反相参考与同相参考一样可能缺少独立信息，不能因相关系数为负就判断容易辨识。去相关能改善条件数，但不能直接换算成固定的 ERLE 增益；实际收益还取决于声道内容、回声路径、去相关失真和估计器。

## 6.10 播放链参考抽头位置及其对 ERLE 的影响

播放链路是一串变换：应用音源 → 混音 → 音效/均衡（Equalization，EQ）→ 自动增益控制（Automatic Gain Control，AGC）/动态范围压缩（Dynamic Range Compression，DRC）→ 限幅 → 重采样 → 编解码 → 数模转换器（Digital-to-Analog Converter，DAC）→ 功放 → 扬声器。

参考抽头越早，抽头之后未反映在参考中的处理越多。固定、线性时不变、因果且能在已对齐的同一采样时钟上用有限长 FIR 表示的处理，可以并入式(6-1)的等效路径；跨独立时钟的重采样或持续采样率偏移不能直接并入同一固定 FIR，需检查 § 6.12 的 SRO 诊断。时变增益、削波、丢帧和编解码伪影也可能造成难以稳定建模的残余。

抽头点对照表（T1 最早、T5 最晚；实际系统可能只能访问其中一部分）：

| 抽头点          | 位置          | 抽头之后的变换              | 主要风险              | 检查方法                   |
|--------------|-------------|----------------------|-------------------|------------------------|
| T1 应用层原始音源   | 应用输出        | 混音、系统音量及全部后处理        | 参考可能缺少其他应用声音和时变处理 | 切换音源、通知音和音量，观察参考是否同步变化 |
| T2 混音后、音效前   | 混音器输出       | EQ、AGC/DRC、限幅及后续处理   | 时变增益或限幅造成失配       | 分别旁路后处理，比较残余与路径估计      |
| T3 音效后、AGC 前 | 均衡后         | AGC/DRC 增益包络、限幅及后续处理 | 增益变化和削波未进入参考      | 扫描播放电平并记录残余、削波和恢复过程    |
| T4 限幅后、编解码前  | 限幅器输出       | 重采样、编解码和传输链路         | 延迟抖动、丢帧或编码伪影      | 注入已知信号并记录端到端延迟分布和残余    |
| T5 最晚可用数字参考  | DAC 前的可访问节点 | DAC、功放、扬声器和声学路径      | 模拟与声学非线性仍不在参考中    | 作为候选基线，与电压/电流参考及更早抽头对照 |

在可访问的节点中，通常优先评估包含更多数字处理且时间戳可靠的较晚参考。

若音量增益发生在抽头之后，线性区内播放增益变化会等比例改变等效路径增益；收敛时间和 ERLE 变化量需在目标实现上测量。抽头位于时变增益之前时，可以比较包络补偿与改取较晚参考两种方案。



无线或外接播放链路还要实测延迟分布、突变和丢帧，并让延迟搜索与缓冲覆盖所需分位数，而不是采用固定抖动范围。

云端若拿不到与麦克风时钟对齐、且能代表实际播放链路的参考，就不能直接运行依赖该参考的线性 AEC；此时可在端侧完成 AEC，云端再做无参考或弱参考的声学回声抑制（Acoustic Echo Suppression，AES）。另一种方案是上传对齐后的参考波形或特征，但会增加上行带宽、同步、隐私和故障恢复负担。选择哪种划分应同时记录参考取点、时间戳精度、传输抖动与端云总延迟，不能把“云端只做 AES”当作架构定律。

### 6.11 测试覆盖与验收矩阵

下面的矩阵用于组织测试，不给出通用认证阈值。若项目受某项通信、车载或主观听测标准约束，应记录标准号、版本、测试序列、设备配置和适用 profile，并直接采用该版本规定的判据。

| #  | 测试项                 | 条件                | 记录结果                  | 阈值来源        |
|----|---------------------|-------------------|-----------------------|-------------|
| C1 | STFE 收敛后线性段<br>ERLE | 远端单讲，排除初始收敛段      | 均值或分位数、统计窗口、输入与线性输出取点 | 目标设备线性段基线   |
| C2 | STFE 最终输出           | 与 C1 使用同一录音       | 最终残余、AECMOS 回声维和听测结果  | 目标应用的可闻回声要求 |
| C3 | 初始收敛                | 规定冷启动状态和播放材料      | 从播放开始到达到项目基线的时间分布     | 交互延迟与任务要求   |
| C4 | 路径突变重收敛             | 规定移动、遮挡或设备切换动作    | 恢复时间、成功比例和暂态最大残余      | 目标场景允许的中断时间 |
| C5 | 双讲语音质量              | 规定 SER、说话人和双讲序列   | 近端质量、内容保持与残余回声        | 选定标准或项目听测基线 |
| C6 | 双讲回声泄漏              | 与 C5 同一批样本        | AECMOS 回声维及真人听测       | 固定模型版本和听测协议 |
| C7 | STNE 近端损伤           | 近端单讲，AEC 开关对照     | 频谱、客观质量、下游任务与听测差异     | 旁路基线和允许损伤   |
| C8 | 沉默期稳定性              | 覆盖项目最长空闲段并在期间改变路径 | 系数漂移及重新播放后的恢复过程       | 最长会话和使用状态   |

| #   | 测试项     | 条件                  | 记录结果            | 阈值来源         |
|-----|---------|---------------------|-----------------|--------------|
| C9  | 非线性播放   | 覆盖目标播放电平和材料，并含双讲    | 线性段残余、最终残余和近端损伤 | 设备声学过载与音质要求  |
| C10 | 时钟偏移    | 覆盖实际播放与采集时钟域及最长会话   | 延迟漂移、重采样状态和残余趋势 | 时钟规格和最长运行时间  |
| C11 | 输出切换与丢帧 | 执行目标系统支持的切换和故障注入    | 延迟重搜、恢复时间和音频连续性 | 交互与通话连续性要求   |
| C12 | 适用的认证指标 | 按所选标准及 profile 生成条件 | 标准要求的指标和统计过程    | 所选标准的明确版本与条款 |
| C13 | 下游任务    | AEC 旁路与启用使用同一批输入    | 唤醒、识别或通信任务的差异   | 任务基线与允许退化    |

发布或产线回归可以从上述矩阵抽取一组稳定测试，但抽样长度、重复次数和验收判据要来自项目的历史分布、器件公差和故障成本，不能从本教程复制固定数值：

| #  | 回归项      | 快速方法                  | 判定依据                       |
|----|----------|-----------------------|----------------------------|
| A1 | 参考内容与取点  | 查信号图，并改变音源、通知音、音量和后处理 | 参考包含预期播放内容；未覆盖的处理已有补偿或风险记录 |
| A2 | 延迟覆盖     | 读取延迟估计日志，并注入链路抖动和切换   | 搜索范围与滤波器跨度覆盖目标延迟分布并留有设计余量  |
| A3 | STFE 双取点 | 固定远端单讲样本，分别记录线性段和最终输出 | 两个取点分别达到对应项目基线，口径见 § 6.7   |
| A4 | 双讲       | 使用固定且版本化的双讲测试集        | 近端损伤、残余回声和滤波器稳定性均满足项目基线    |
| A5 | 路径突变     | 执行可重复的移动、遮挡或切换动作      | 在规定时间内恢复到项目基线，并报告失败比例      |
| A6 | 真人听测     | 按预先定义的样本量、随机化和播放协议盲听  | 使用所选协议的统计判据，不以单个听众意见代替结果   |
| A7 | 自动多指标复核  | 固定模型、软件版本和输入集         | 只用于回归；阈值由版本基线和人工复核结果确定     |

## 6.12 AEC 诊断方法与 NLP 工作点

诊断表（按“征兆 → 量测 → 工具 → 判据”排列）：

| #  | 征兆             | 量测                                   | 工具/信号                                                                                                        | 判断依据                         |
|----|----------------|--------------------------------------|--------------------------------------------------------------------------------------------------------------|------------------------------|
| D1 | ERLE 低于项目基线    | 参考与真实播放是否一致                          | 对比参考与实际播放内容；查抽头点                                                                                             | 改变音源、音量或后处理时，参考应包含相同变化或有明确补偿 |
| D2 | ERLE 不再上升      | 延迟失配                                 | 互相关峰、图30 (a) 和延迟日志                                                                                           | 峰位置应落入滤波器覆盖范围；多峰时检查多路径与周期信号  |
| D3 | 双讲后恢复慢         | 自适应控制                                | DTD 判决、步长和路径失配日志                                                                                             | 恢复过程相对同一设备的远端单讲基线无异常停滞       |
| D4 | ERLE 随播放电平出现平台 | 非线性占比                                | 多个播放电平的 ERLE 与失真对比                                                                                           | 电平降低后残余非线性同步减小，见图31的仿真机制     |
| D5 | 断续/闷罐/背景声突然消失  | NLP 过度抑制                             | 旁路 NLP；有独立、时间匹配的干净近端参考且满足标准适用条件时才评估 ITU-T P.863；无此真值时看 AECMOS Other 维、盲听和任务指标。历史回归若保留 PESQ，须固定 P.862 实现与带宽口径 | 旁路后语音改善 → 检查近端损伤并减小过强抑制      |
| D6 | 沉默段背景突变        | CNG 频谱与电平                            | 沉默段频谱与真实底噪对照                                                                                                 | 以盲听和频带差异共同调节，不使用统一 dB 阈值     |
| D7 | 长通话逐渐变差        | 采样率偏移 (Sample Rate Offset, SRO) 累积漂移 | 覆盖最长目标会话的延迟估计曲线                                                                                              | 残余速率差应满足相干性和任务指标要求           |

| #  | 征兆        | 量测   | 工具/信号            | 判断依据                    |
|----|-----------|------|------------------|-------------------------|
| D8 | 切歌或切设备后失效 | 延迟突变 | 对齐切换事件的ERLE与延迟轨迹 | 在项目规定时间内恢复，并检查搜窗是否覆盖新路径 |

D1~D3检查参考、延迟和双讲控制；D4用于判断非线性残余；D5~D6检查近端语音和舒适噪声；D7~D8检查长时漂移和链路切换。

ITU-T 已于 2024 年 1 月 5 日删除 P.862、P.862.1、P.862.2 和 P.862.3，并指向 P.863、P.863.1 与 P.863.2；因此 PESQ 只宜用于需要延续既有 P.862 基线的历史回归，新测试应先确认 P.863 的带宽、预处理和适用条件。[ITU-T P.862 状态页](#)、[ITU-T P.863](#)

本书使用的真实 AEC Challenge 播放环回与麦克风配对录音没有独立干净近端语音真值，不能直接对它们计算 P.863 的近端语音质量。[ITU-T P.863.1](#)要求按参考语音与退化语音的规定条件使用该指标；AECMOS 自动分数也不能代替真人听测。

采样率偏移（Sample Rate Offset, SRO）。播放与采集时钟相差 10 ppm 时，16 kHz 下每秒相差  $16000 \times 10^{-5} = 0.16$  个采样；1 小时累积 576 个采样，即 36 ms。延迟重搜只能重新选择整数或分数延迟，不能消除持续增长的速率差；长通话通常要估计 SRO 并对参考做重采样补偿。若硬件允许，共用时钟可以从源头消除该偏移。

NLP 工作点（NLP = 非线性处理器，nonlinear processor）。NLP 对各频带施加增益；抑制增强时，残余回声可能降低，但近端语音损伤、背景抽动和断续风险会上升。工作点不能只用一个最大抑制深度定义：

| 调节方向   | 需要控制的量                 | 同时观察            | 回退条件                     |
|--------|------------------------|-----------------|--------------------------|
| 近端保护优先 | 提高增益地板，减慢或限制双讲期抑制      | 近端频谱、下游识别、双讲听感  | 仍有回声时再逐步增强抑制，而不是一次设置固定档位 |
| 回声抑制优先 | 在远端单讲置信度高的频带降低增益       | 残余回声、音乐噪声和背景连续性 | 出现近端内容丢失、抽动或背景突变         |
| 状态自适应  | 用远端活动、双讲置信度和残余估计连续控制增益 | 状态切换时的暂态和恢复时间   | 置信度不足或切换产生可闻伪影           |
| 舒适噪声配合 | 根据真实底噪估计 CNG 频谱与电平     | 沉默段的连续性与噪声颜色    | CNG 可单独辨认或掩盖近端弱语音        |

设置时先固定测试集和取点，从旁路 NLP 开始逐步增加抑制，绘制残余回声、近端质量、下游任务和听测结果之间的曲线。增益地板由曲线的折中点和双讲保护要求确定，不存在通用的 -20 dB 下限。

### 6.13 个性化 AEC 的合规检查

pAEC（个性化 AEC，personalized AEC）在 § 6.5 定义。注册语音和算法延迟的具体限制应从采用的挑战赛规则、论文实验设置或产品需求中逐项读取，不能把某一届任务条件直接当作通用产品规格。实现时还要检查以下隐私、访问控制与体验问题：

| #  | 检查项      | 需要明确的设计                              | 不满足的后果           |
|----|----------|--------------------------------------|------------------|
| P1 | 注册数据量与质量 | 在目标距离、噪声和说话变化下绘制注册数据量与错误率曲线          | 嵌入不可靠，双讲时误压目标用户  |
| P2 | 告知与授权    | 按适用法律和产品政策说明用途、处理位置、保留期与删除方式         | 用户无法判断数据怎样使用     |
| P3 | 嵌入存储     | 明确端侧或云侧位置、访问控制、加密和备份范围               | 未授权访问或数据范围扩张     |
| P4 | 首帧可用性    | 若要求从开头保护目标用户，应在首个处理帧前准备嵌入；延迟计入系统关键路径 | 开场语音可能未受个性化条件保护  |
| P5 | 删除与退出    | 定义删除入口、传播范围、完成时间和退出后的普通 AEC 行为       | 用户无法撤回个性化处理      |
| P6 | 低置信度处理   | 规定无注册、低置信度和多人混淆时的旁路、回退或提示            | 误抑制非注册说话人或目标用户   |
| P7 | 共享设备     | 明确多用户配置、权限、切换和未成年人场景的授权流程            | 配置串用或家庭成员被误抑制    |
| P8 | 验收加测     | 在 C5/C6 基础上加入目标用户、非目标用户及多人双讲组合       | 普通双讲测试无法覆盖身份条件错误 |



## 6.14 研究方向

---

当前研究主要沿四条路线展开：学习自适应步长或卡尔曼统计量、在多通道上联合处理回声与干扰、把声纹条件加入个性化 AEC，以及用感知模型评价残余回声。阅读新工作时要先检查因果性、总延迟、通道数、参考抽头位置、双讲数据构成和指标口径。预印本或挑战赛结果只有在版本、测试集和基线一致时才能比较，因此本章不列无法按这些条件复核的近期性能数字。

## 图表对照。

| 图   | 内容                                                            | 对应正文            | 口径提醒                                              |
|-----|---------------------------------------------------------------|-----------------|---------------------------------------------------|
| 图27 | 播放参考、路径估计与相减结构                                                | § 6.1.1         | 顶部 DTD 控制自适应滤波器更新                                 |
| 图18 | (a) 结构 + DTD 开关； (b) NLMS 收敛 + 双讲冻结                           | § 6.1.2         | current-first 回归向量与回声卷积索引一致；图中均值来自固定种子和标示窗口       |
| 图28 | (a) $\hat{w}$ 逼近 $h$ ； (b) 失配与 ERLE 的关系； (c) 不同 $\mu$ 的有限时段轨迹 | § 6.1.2         | 无噪声仿真不能证明稳态失调；“0步”是更新前初值                          |
| 图19 | (a) 独立仿真线性/非线性场景； (b) 按模型假设和处理对象分类                            | § 6.3、§ 6.5     | (a) 支持自身配置下的定量结论；与图31配置不同，ERLE 数值不可横向比较           |
| 图20 | (a) 系统信号流； (b) 混合结构                                           | § 6.8、§ 6.5     | 橙色模块表示可选的学习型残余抑制                                  |
| 图29 | 三路均方根包络与远端单讲 ERLE                                             | § 6.1.2 末、§ 6.4 | 粉色区是合成近端干扰，非语音；双讲区不绘制 ERLE                        |
| 图30 | (a) 有符号互相关的最大正峰约 331 采样； (b) 对齐约 28 dB、不对齐约 2 dB； (c) 冻结与继续更新 | § 6.4、§ 6.8     | 设置的纯延迟为 300 个采样；相关峰还受有色参考和多径影响，且该延迟超过 128 抽头滤波器跨度 |
| 图31 | (a) 线性与归一化 tanh 非线性路径； (b) 同一映射                               | § 6.3           | 唯一职责是量化映射速率与线性模型残差平台；后段均值由图示配置计算                  |
| 图32 | 混合处理信号与控制流程                                                   | § 6.5、§ 6.2     | $x_a, e$ 进入控制框是图示方案，不给固定性能档次                      |

## 6.15 可执行基线与开源实现边界

### 6.15.1 教学 NLMS、PBFDAF 与状态边界

本书提供只依赖 NumPy 的时域 NLMS 与 ERLE 基线，源码见 [codes/array\\_tutorial/aec.py](#)，四章联合示例见 [codes/examples/ch06\\_09\\_baselines.py](#)。在仓库根目录运行：

```
.venv/bin/python -m codes.examples.ch06_09_baselines
```

`nlms(reference, microphone, filter_length, ...)` 接收两个等长一维实数数组，返回残差、估计回声和最终抽头。`freeze[n]=True` 时仍产生当前样本输出，但不更新抽头；参考回归向量能量为零时也跳过更新。

信号、初始抽头和正则项必须有限，抽头长度必须是正整数；掩码必须为布尔数组，不能用数值或字符串隐式转换。非法输入会明确报错，不继续产生 NaN 残差。

跨块续算的状态不能只存抽头。在线性卷积中，块首样本仍需要前一块末尾的  $L - 1$  个参考样本。教学类 `NLMSState` 同时保留当前抽头和这段历史，`process()` 接受任意长度的连续块；`reset()` 同时恢复构造时的抽头与历史。状态的 `history` 按旧到新存放，参与点积的回归向量则按当前到过去排列。

它仍不检测双讲、不搜索参考延迟，也不提供实时线程安全保证。

可运行的[流式边界实验](#)用  $h = [0.5, 0.25]$ 、 $x = [1, 2, 3, 4]$  和  $\mu = 0$  验证：完整或是在第 2 个样本后切块，已知真值抽头给出的残差都是  $[0, 0, 0, 0]$ ；若仅续接抽头而把参考历史归零，第二块的首个残差变成 0.5。这不是算法收敛失败，而是上一块的  $x[1] = 2$  未参与当前卷积。运行：

```
.venv/bin/python -m codes.examples.aec_streaming_demo
```

[AEC 算法小实验](#)把四个易误解的边界写成可运行、可与手算逐项比对的 JSON： $N = 2, P = 2$  的分区卷积有效半块、两抽头 IPNLMS 的一步权重分配、Geigel 多径误判与零参考门控，以及负极性路径使最大正相关峰选错延迟。运行：

```
.venv/bin/python -m codes.examples.aec_algorithm_minicases
```

这些输出是无量纲固定算例，不是完整自适应 PBFDAF、真实录音实验或工业性能测试；相应独立测试在 [test\\_codes\\_aec\\_minicases.py](#)。

分区自适应教学实现另把式(6-3)接成有状态的预测—有效区残差—逐频归一化更新—可选时域梯度约束。它只接收完整的  $N$  样本块，`freeze` 是调用方给定的每块布尔控制；没有双讲检测、延迟搜索、残余抑制或实时设备接口。运行下面的命令可同时输出两块手算和算例 6-5 的固定种子训练/冻结留出结果：

```
.venv/bin/python -m codes.examples.aec_partitioned_demo
```

手算部分同时保留更新前回声预测与残差、约束前候选系数和约束后路径，便于核对非法抽头；留出部分报告两种训练参考下的残差均方和路径误差。测试还检查已知 FIR 的直接时域卷积、短末分区补零、跨调用状态、冻结更新与算例 6-4 的四点 DFT；这不是在真实语音上测出的 ERLE、延迟或收敛速度。教学实现测试与外部 AUMDF 源码须按不同证据级别阅读。

逐样本全矩阵 RLS 保存抽头、逆相关矩阵与跨块参考历史；它返回更新前的回声估计和残差。调用方给定的 `freeze` 会跳过该样本的拟合与遗忘，却继续推进参考历史；未冻结的零参考仍按式(6-8)遗忘。两抽头演示同时输出递推值和独立批量求解，测试还核对切块等价、冻结、重置与非法输入：

```
.venv/bin/python -m codes.examples.aec_rls_demo
```

实数短 FIR 全矩阵 Kalman 另维护完整路径误差协方差，以 Joseph 形式执行式(6-11)。其 `freeze` 仍作状态预测和参考历史推进，只跳过麦克风观测更新；若状态转移系数不为 1，冻结并不意味着权重按位保持。两抽头演示输出非对角协方差及丢弃它后的下一步创新方差；这只是已知  $Q, \Psi$  的算术验证，不是频域分区 AEC：

```
.venv/bin/python -m codes.examples.aec_kalman_matrix_demo
```

式(6-10)的单频点卡尔曼数例另可运行：

```
.venv/bin/python -m codes.examples.aec_kalman_scalar_demo
```

它固定已知状态和噪声方差，展示实数、复数与较大观测方差三种代入；不包含完整频域滤波器的分区状态、方差估计或双讲判决。独立测试核对分数结果，不把这一个标量更新列为已复现的 FDKF 工业算法。

`erle_db()` 用 `double_talk_mask` 明确排除双讲样本；调用者还需用 `valid_mask` 排除初始收敛段、近端单讲和静音段。函数在输入、输出平均功率上都加上正的 `epsilon` 地板，因此完美抵消也会报告有限的、随地板而变的 dB 数值，不能把这个上限解释成设备噪声底。该实现用于核对式(6-2)的抽头顺序、冻结语义和指标窗口，不包含延迟搜索、非线性处理、舒适噪声或实时音频接口。

自动测试见 [tests/test\\_codes\\_aec\\_wpe\\_sep\\_track.py](#) 和[流式边界测试](#)，覆盖零能量参考、已知路径、路径突变、冻结更新、跨块一致性、空块与复位以及双讲样本不进入 ERLE。接入设备时还必须增加参考断流、纯延迟超过滤波器覆盖范围、削波、多参考高度相关和长时路径漂移测试；异常时的安全回退是冻结自适应更新或旁路线性抵消，而不是继续用不可信残差更新。

外部源码按完整提交保存在 `codes/upstream/_downloads/` 的相应项目目录中，具体获取状态见[代码获取说明](#)。该目录是按需取得的参考源码，教学算法与第三方代码各自保留来源和许可。研究细节见 [AEC 源码研究](#)，其中逐项列出信号接口、读码顺序、状态参数、最小实验与失效实验。

| 方法或组件              | 应从哪段源码读起                                                                                                                                                         | 它实际解决什么               | 复现时单独检查                         |
|--------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------|---------------------------------|
| MDF/PBFDAP 与 AUMDF | SpeexDSP<br><code>libspeexdsp/mdf.c</code> ,<br>从<br><code>speex_echo_state_init_mc()</code> 到<br><code>speex_echo_cancellation()</code>                         | 把长路径拆成频域分区，并调度约束和更新   | 重叠保存有效区、FFT 归一化、分区历史、块尾         |
| 连续自适应控制            | 同文件的学习率与比例更新段                                                                                                                                                    | 根据残余回声、双讲和噪声调节学习率     | Speex 此处不使用独立的二值 DTD，不能套用固定冻结语义 |
| AEC3 线性路径与延迟       | WebRTC<br><code>aec3/echo_canceller3.cc</code> 、<br><code>block_processor.cc</code> 、<br><code>subtractor.cc</code> 、<br><code>render_delay_controller.cc</code> | 组织参考、时间对齐和线性回声抵消      | 渲染/采集调用顺序、断流、路径变化与重置            |
| AEC3 残余抑制          | <code>residual_echo_estimator.cc</code> 、<br><code>suppression_gain.cc</code> 、<br><code>comfort_noise_generator.cc</code>                                       | 估计未抵消回声、施加增益并控制输出噪声表现 | 同时保存线性残差和最终输出，避免抑制掩盖失配          |



| 方法或组件                               | 应从哪段源码读起                                                                                              | 它实际解决什么                              | 复现时单独检查                                                                 |
|-------------------------------------|-------------------------------------------------------------------------------------------------------|--------------------------------------|-------------------------------------------------------------------------|
| DTLN-aec                            | 作者仓库 <code>run_aec.py</code> 与两阶段模型输入/输出                                                              | 用麦克风和播放参考联合估计近端语音                    | 采样率、循环状态、块拼接、TFLite 与权重许可                                               |
| NKF-AEC                             | 作者仓库 <code>src/nkf.py</code> , 仅作来源索引                                                                 | 学习卡尔曼更新增益, 仍是线性 AEC                  | 16 kHz、参考延迟补偿; 未确认再分发许可                                                 |
| Meta-AF                             | <code>metaaf/filter.py</code> 、 <code>core.py</code> 与更新器                                             | 学习滤波器更新规则并管理分块状态                     | 核心库与 <code>zoo/</code> 、权重采用不同许可证                                       |
| 学习步长控制 CTF-AEC                      | <code>main_train.py</code> → <code>libPython/class_frontend.py</code> → <code>class_aec_ctf.py</code> | 保留线性 CTF 回声模型, 由 DNN 控制频率选择性步长与误差归一化 | 无预训练 checkpoint; 序列边界重置状态, <code>center_stft=True</code> , 不能直接当作跨块流式接口 |
| Integrated AEC/NR                   | <code>Main.m</code> → <code>Util/Process/process.m</code> → 各 AEC、NR、MWF 与后滤模块                        | 在多麦、多扬声器模型中比较联合设计和 AEC/NR 顺序         | MATLAB R2024a; 原实验用干净语音与干净回声生成预言活动判决                                    |
| 原始 FDKF/PBFDKF、NeuralKalman、DeepVQE | 本章原论文与研究文档的结构对应说明                                                                                     | 分别改变状态统计、学习递推或联合增强                   | 未确认的作者官方完整软件不能由同名第三方复现替代                                                |

6.15.2 外部 AEC 接口及输出取点

SpeexDSP 的 `mdf.c` 文件头直接说明 AUMDF 与连续学习率控制, 并引用 Soo – Pang 的 MDF 和 Valin 的双讲学习率论文; 因此 MDF、DTD 控制与残余抑制应分别检查。FDKF 则需要显式核对应状态转移、过程噪声、观测噪声和增益递推, 不能因为某库含频域 AEC, 就把它列为 FDKF 的实现。[SpeexDSP 官方源码](#)、[WebRTC AEC3 固定版本](#)

三类实现不能只按“消得更干净”排序。本书 `NLMSSState` 接受连续的等长参考与麦克风数组, 需要调用者提供冻结掩码和已对齐参考, 适合核对抽头、块边界与算法算术。

锁定版 WebRTC 通过音频处理模块 (Audio Processing Module, APM) 接入: 应用约每 10 ms 交付播放与采集帧, 先调用 `ProcessReverseStream()` 交播放参考, 在处理对应采集帧前按缓冲时间设置 `set_stream_delay_ms()` , 再调用 `ProcessStream()` 。APM 外部帧长与 AEC3 内部的 64 样本处理块是不同层级; `set_stream_delay_ms()` 也不是房间传播时延或回声滤波器长度。[WebRTC APM 固定版本接口](#)。

SpeexDSP 的同步 `speex_echo_cancellation()` 由应用提供已对应的播放帧，不再额外放入两帧播放缓冲；异步 `speex_echo_playback()` / `speex_echo_capture()` 自带两帧缓冲，但实际声卡延迟不一定等于该假设。锁定版异步辅助函数只按单通道 `frame_size` 复制和排队，不能直接作为多通道交织帧的安全接口；多通道应显式配对后使用同步接口，或自行按完整通道跨度管理缓冲。

SpeexDSP 固定版 `mdf.c` 异步函数。

`speex_echo_cancellation()` 给出核心 MDF 输出；如需预处理器利用残余回声估计，须用 `SPEEX_PREPROCESS_SET_ECHO_STATE` 绑定回声状态，并把预处理后的输出另存为第二个取点。

SpeexDSP 固定版接口、官方手册 § 6。

教学 NLMS 提供可解释的线性基线，WebRTC AEC3 与 SpeexDSP 还包含各自的延迟缓冲、更新控制与可选或内置后处理。若只拿 AEC3 最终输出与教学 NLMS 的线性残差计算输入/输出能量比，前者更安静也不能单独证明其线性回声路径估计更准。

同条件实验应锁定播放参考抽头、输入 PCM、采样率、增益、有效采样窗口和状态重置，分别记录远端单讲回声泄漏、双讲近端损伤、路径突变恢复、参考丢块、资源消耗及端到端延迟。取得不到的内部线性取点要标为“未取得”，不能用最终输出冒名顶替。

### 6.15.3 真实配对录音及双讲控制组

真实配对录音的一次接口验证。本书从 Microsoft AEC Challenge 固定版本按同一 GUID 取得一对远端单讲录音：Windows 播放环回 `lpb` 与麦克风 `mic`，均为 16 kHz、单声道 PCM16。

将共同的 11.77 s 原样交给锁定版 SpeexDSP 的同步 `speex_echo_cancellation()`；每帧 160 样本，滤波覆盖 4096 样本，并显式设置、读回 16 kHz。用前 3 s 收敛，余下 [3,11.77) s 计算同一窗口的麦克风输入/输出数字功率比。

正确配对参考时功率下降 5.57 dB，全零参考控制仍下降 3.95 dB，故意把参考推迟 1 s 时则为 -0.23 dB。本片段的输出对参考条件敏感，但不能把 5.57 dB 全部归因于回声路径估计。

原录音没有独立的干净回声或近端真值，输出还可能受 Speex 核心处理的其他作用影响。这些是输入/输出功率变化，不是真值 ERLE，更不能证明双讲时保留了近端语音。文件 SHA-256、半开样本区间、构建配置、零参考控制与复做命令见[真实配对实验记录](#)及[可运行脚本](#)。录音留在 Git 忽略缓存，不随本书再分发。

真实双讲的控制组。本书又在 Microsoft AEC Challenge 固定版本中取同一 GUID 的真实 `doubletalk_lpb` / `doubletalk_mic` 配对录音，按与上段相同的 16 kHz、160 点帧和 4096 点滤波覆盖运行 SpeexDSP，同样设置正确、全零和晚 1 秒的错误参考。两路原录音分别约 12.26 s 和 12.27 s；共同裁成 196160 点完整帧，[0,3) s 供适应，预先固定 [3,8) s 计量。

在这 5 s 中，麦克风输入对三种输出的总数字功率变化分别是 2.234、2.204、2.200 dB。正确参考的输出功率只比零参考低 0.029 dB。

输入包含近端语音、回声与噪声，却没有对应的干净分量；因此这些数字既不是双讲 ERLE，也不说明近端语音保留或回声泄漏的大小。此处尚未作盲听或逐帧语音标注。

原文件摘要、满幅样本检查、计算口径和[可运行脚本](#)见[研究记录](#)。录音只放在 Git 忽略缓存，不随教程分发。

同一真实配对输入上的教学 PBFDAF。为检查式(6-3)的实现离开合成输入后会怎样，本书将上述远端单讲和真实双讲的 `lpb / mic` 原样交给[离线脚本](#)。16 kHz PCM16 除以 32768 后以 float64 处理；块长 160 点、26 个分区（覆盖 4160 点）、步长 0.3、归一化地板 0.05，每块投影合法梯度。参数沿用先前合成教学例，没有针对这两段实录调参。

正确、全零、晚 1 s 三种参考各从零状态运行；没有延迟搜索、双讲冻结或残余后滤。Speex 的 4096 点请求在固定版内部上取整到 26 个 160 点分区；相同的抽头容量并不意味着相同的更新和输出链。

在相同的远端单讲 [3.11.77] s 评分区，正确参考、全零参考、晚 1 s 参考的麦克风输入/教学残差总数字功率变化分别为 -6.700、0、-18.017 dB；在真实双讲 [3.8] s 分别为 -6.363、0、-1.665 dB。负号表示输出总功率反而更大，不应删除不利结果或把零参考的 0 dB 当作算法有效的证据。晚参考条件的部分 float64 样本还超出了 PCM16 可表示幅度，因此脚本不剪裁、不保存这些输出为音频。

这次对照说明当前无延迟补偿、瞬时功率归一化的教学配置对这两条录音不稳健；它不证明 PBFDAF 这一类方法不适用。输入没有分离的干净回声或近端真值，三个 dB 数字不是 ERLE，也不是近端保留率。Speex 核心输出经过其他处理且量化成 PCM16，不能把它与这里的 float64 线性残差按大小排产品名次。原文件 SHA-256、每个 1 s 区间结果和运行命令见[研究记录](#)。

#### 6.15.4 已知近端注入的受控检查

为了把“输出变小”和“近端信号通过处理器”分开，本书对同一播放参考  $x$ 、基线麦克风  $d_0$ ，分别从新状态运行处理器  $A$ ：一次输入  $d_0$ ，一次输入  $d_0 + s$ 。这里  $s$  是逐样本已知的外加近端波形， $W$  是预先固定的注入区间。定义输出增量、原样投影增益和不拟合时延或增益的相对平方误差为

$$\begin{aligned}\Delta[n] &= A(x, d_0 + s)[n] - A(x, d_0)[n], \\ g_\Delta &= \frac{\sum_{n \in W} \Delta[n] s[n]}{\sum_{n \in W} s[n]^2}, \\ E_\Delta &= \frac{\sum_{n \in W} (\Delta[n] - s[n])^2}{\sum_{n \in W} s[n]^2}.\end{aligned}\tag{6-15}$$

$g_{\Delta} = 1$  且  $E_{\Delta} = 0$  表示这两个输出之差在该区间逐样本等于注入波形；只看  $g_{\Delta}$  不能发现额外失真。若算法状态随  $s$  改变， $\Delta$  还包含状态变化造成的回声残余差异，不能叫“分离出的近端语音”，也不能把  $E_{\Delta}$  叫作双讲 ERLE。

两个比值都要求评分区间内  $\sum_{n \in W} s[n]^2 > 0$ ；若已知注入信号在该区间全为零，实验应报无效，而不是把分母加一个小数后继续评分。

第一组使用本书 2 s 合成样本：已量化麦克风减去已量化近端，再把近端原样加回，PCM 域相加严格成立且无削波。近端只在 [1.2,1.8) s 非零。

教学 NLMS 两次都按已知掩码冻结时，式(6-15)给出  $g_{\Delta} = 1$ 、 $E_{\Delta} = 0$ ；继续更新则为 0.936 和 0.322。相同夹具交给 SpeexDSP 同步核心，正确参考下为 0.878 和 0.208；零参考对照为 0.879 和 0.204。

后两项接近，不能把增量偏差全归于回声滤波：Speex 核心自身还执行 DC 陷波、预加重、去加重和 PCM 量化。这组近端是合成谐波，不是真人语音或实测房间。

第二组把 Microsoft AEC Challenge 同一 GUID 的另一次真实近端单讲麦克风录音，按 PCM 原样叠加到真实远端单讲麦克风的 [3,8) s；播放参考不变，叠加前后都从新状态运行。它是半合成双讲，不是官方同时录制的真实双讲，也不具备干净近端语音真值。

注入在 3 s 和 8 s 处直接切入、切出，没有淡入淡出；两个边界附近可能产生拼接瞬态。因此这一组用于检验固定波形的输出增量，不把它当作自然双讲的听感样本或泛化性能。

Speex 正确参考下  $g_{\Delta} = 0.922$ 、 $E_{\Delta} = 0.140$ ；零参考对照为 0.923、0.128。这里只能说已知外加波形经过两次运行后的输出增量与原波形有差异，不能据此断定真实近端语音的主观保真。

原始录音摘要、无削波检查、恢复区间和[可运行脚本](#)见[研究记录](#)。

### 6.15.5 WebRTC AEC3 的取点与同输入真值实验

固定版本的官方 `audioproc_f` 可分别输出 AEC3 的线性段和最终段。其 WAV 模拟器默认先处理采集帧再处理播放帧；对同帧 Speex 同步接口作比较时，需要显式改为先播放参考、后采集。

两者还要核对流延迟设置、额外高通、取点和输出采样率，不能把 AEC3 最终输出与 Speex 核心输出的功率差解释成线性滤波器优劣。本机已从固定提交构建官方 `audioproc_f`，按同帧先参考后采集、0 ms 报告流延迟，在上述两对真实录音上分别保存线性和最终输出；详细构建参数与输出摘要见[研究记录](#)。



同一评分区间内，AEC3 的远端单讲线性/最终输出相对麦克风输入分别下降 7.685/15.731 dB；真实双讲分别下降 3.384/3.851 dB。这些是总数字功率变化，不是真值 ERLE；双讲没有独立干净近端真值，因而也不能由“更安静”推断近端保真。

同输入合成真值实验。独立脚本以种子 20260924 生成一条 16 kHz、6 s 的 PCM16 播放参考；其量化样本通过已知 5 抽头路径 [0.70, 0, -0.25, 0, 0.12] 形成回声，并再次量化。麦克风底稿只含这条已知回声，不加背景噪声；另在 [3,4) s 原样注入独立生成的已知近端波形，先用 32 位整数检查 PCM 相加无削波。

两次运行分别输入“底稿”和“底稿加近端”，播放参考、采样率、PCM 增益与样本索引保持一致；每次重建处理状态。[0,2) s 留作适应，[2,3) s 是远端单讲评分区。

教学 NLMS 使用 32 抽头、步长 0.4，并凭合成真值在 [3,4) s 冻结更新；这是一种理想控制，不是检测器。SpeexDSP 使用锁定版同步核心、160 点帧和 4096 点请求滤波长度，不接外部残余抑制预处理器。AEC3 使用锁定构建的 audioproc\_f，同帧先送参考再送麦克风，设置报告流延迟为 0 ms，并分别导出线性段与最终段。

四个输出取点及更新控制不相同，因此下表只呈现各自条件下可复核的观测量，不给统一性能排名。

评价前还用一条独立的全零参考、单个 10000 PCM 计数脉冲检查输出时间位置。本机固定构建中，Speex 核心首个非零与峰值样本都和输入同位；AEC3 线性段晚 64 个采样（4 ms），最终段晚 128 个采样（8 ms）。

下表先按这些单独测得的固定延迟配对输出和参考，再用式(6-15)计算注入增量；没有在评分区拟合延迟或增益。远端单讲列是已知量化回声功率与总输出功率之比；只在教学 NLMS 的纯线性残差中，才可把它按该无噪声模型解释为线性回声消除量。

| 处理输出          | 脉冲测得固定延迟 | [2,3) s 回声功率／<br>对齐后总输出功率 | [3,4) s $g_{\Delta}$ | [3,4) s $E_{\Delta}$ |
|---------------|----------|---------------------------|----------------------|----------------------|
| 教学 NLMS，真值冻结  | 0 样本     | 79.27 dB                  | 1.000                | 约 0                  |
| SpeexDSP 同步核心 | 0 样本     | 37.12 dB                  | 0.982                | 0.027                |
| AEC3 导出线性段    | 64 样本    | 60.58 dB                  | 0.964                | 0.241                |
| AEC3 导出最终段    | 128 样本   | 30.63 dB                  | 0.193                | 0.763                |

若不补偿 AEC3 的固定输出延迟，同采样点计算的线性段  $g_{\Delta}$  只有 0.199，不能据此直接说近端幅度只保留两成；补偿后为 0.964。最终段补偿后仍与已知注入相差较大，但这包含 AEC3 输出处理和两次运行状态的差异，不能把  $E_{\Delta}$  当作独立近端语音的失真度或双讲 ERLE。NLMS 的约 79 dB 由精确匹配、无噪声线性路径和真值冻结产生，不能外推到实录。

脚本输出输入、二进制和 PCM 输出摘要、未舍入数字与未经延迟补偿的对照；合成输入和第三方处理输出只在运行时的临时目录中创建，不充当新的真实录音或发布音频。固定二进制与接口来源分别见 [SpeexDSP mdf.c](#) 及 [WebRTC APM 接口](#)。

上述实验完成了同一合成输入上的接口及指标对照，尚无三者相同内部线性取点与相同自适应控制的性能比较。前述真实配对录音仍缺独立干净回声和近端真值；无播放参考的 DEMAND 环境录音也不是 AEC 实录。

### 6.15.6 工业源码与设备验证边界

设备链路方面，目前只枚举到本机内置麦克风与扬声器；端点存在不等于已经测过声学回路、实际参考抽头或独立设备时钟漂移。实机验收须另记录播放和录制的时间戳、参考位置、缓冲事件与听测条件。

学习步长控制的[官方固定版本](#)适合回答“网络究竟替换了什么”：线性回声估计仍由 CTF 自适应滤波器完成，网络输出用于调节更新。源码逐帧运行，不等于部署接口已经支持任意分块续算；前端使用居中 STFT，并在每个序列重新初始化滤波器。没有匹配训练数据和权重时，只能核对结构与状态，不能把论文结果写成本仓库实测。

[Integrated\\_AEC\\_NR 固定版本](#)可用于比较 AEC→NR、NR→AEC 和联合扩展结构，但 [Util/Process/process.m](#) 直接由分解后的干净期望语音与干净回声生成活动判决。这是受控研究条件，不是设备输入。源码采用 MIT；仓库的 [ReadMe.md](#) 另列示例音频来源，代码许可不能替代音频许可。

最小的工业对照实验可以保持输入录音不变，依次检查参考正常、固定延迟、参考丢块和路径突变四种情况。每种情况同时记录线性段回声、线性残差、抑制后输出、更新控制与恢复时间。双讲段另看近端语音损伤；只看最终能量降低，不能区分成功抵消和过度抑制。外部系统还应固定源码、构建选项、帧长、参考抽头、允许延迟和状态重置规则，不能用本节教学 NLMS 的测试代替这些验收。

### 6.16 常见误区与自测题

---

常见误区：



- 参考抽头过早；
- 双讲段仍计算 ERLE；
- 双讲时加大步长；
- 静音时继续更新；
- 把 AEC 固定放在时变波束之后；
- 靠增加线性抽头处理扬声器非线性；
- 只看自动分数而不听双讲语音。

各项对应的模型和检查方法见 § 6.3、§ 6.4、§ 6.6、§ 6.7 和 § 6.10。

自测题（按下方相同编号核对答案）：

1. 默写三项模型并说出每个符号的含义。
2. 换算 16 kHz 下 64 ms 与 128 ms 对应的抽头数。
3. 在播放链路上标出抽头点 T1 – T5，并说明怎样用参考完整性、延迟和残余测量选择抽头。
4. 手推 LMS 到 NLMS 的归一化三步。
5. 复算算例 6-1，验证残差关系  $e' \approx (1 - \mu)e$ 。
6. 说出步长  $\mu$  的大小取舍，并设计目标信号上的扫描方法。
7. 已知残余能量比 0.0063 与 0.0001，分别算出 ERLE。
8. 写出 Geigel 判决的参考历史窗，并解释阈值 0.5 对应的线路回声假设为什么不能直接当作声学 AEC 的固定阈值。
9. 对着图31 说清非线性平台从哪来。
10. 按算例 6-2 的计数规则比较时域 NLMS、无约束 PBFDAF 和逐分区约束 PBFDAF；再说明为什么这些比值不能用于比较同配置的频域多抽头 NLMS 与 PBFDAF。
11. 在 SER=-20 dB 下算一笔减法与乘法的账。
12. 为 A3、A4 和 A6 分别写出测试输入、取点、统计量与项目阈值来源。
13. 说清双讲冻结与连续小步长的取舍。
14. 对三种阵列方案各说一句选型话。
15. 画出 AEC3 示例中的参考缓冲、延迟估计、自适应滤波、残余抑制与舒适噪声关系。
16. 说出客观 ERLE、主观 MOS 和自动 AECMOS 各自评价什么，并说明双讲时为什么不能用 ERLE。
17. 令  $L = 4096$ 、采样率 16 kHz，分别取  $N = 64, 128, 256$ ，算出分区数、FFT 长度和一块新输入的时长。哪一列不等于端到端算法延迟？

18. 按算例 6-4 重算四点 IFFT 的第 2 个合法抽头。解释为什么固定频点的复 NLMS 类比不足以描述投影后的完整更新。
19. 运行算例 6-5 的代码；若纯音训练段残差已很小，为什么还要冻结并换宽带参考测留出残差？本例能否证明真实语音 AEC 的 ERLE？
20. 取单分区  $N = 2$ 、四点重叠输入  $[1, 2, 3, 4]$ 、合法抽头  $[1, 2]$ ，麦克风有效块等于真实输出。分别算正确有效误差和错误的“零填充观测谱减完整循环输出谱”，说明哪一种会误更新。
21. 对两点、无重叠 DFT，令输入前后两帧为  $[1, 2]$  与  $[3, 5]$ 、真实路径为一拍延迟。计算后一帧输出零频点，并检验只使用输入零频点是否足够。

## 自测题答案

1. 式(6-1)为  $d = s + x * h + v$ 。 $d$  是麦克风观测， $s$  是近端目标， $x$  是已知播放参考， $h$  是回声路径， $v$  是背景噪声。要减去的是  $x * h$ ，不是整个  $d$ 。
2.  $16000 \times 0.064 = 1024$  抽头； $16000 \times 0.128 = 2048$  抽头。纯延迟也会占用抽头跨度，因此不能只按混响拖尾配置长度。
3. T1 为应用音源；T2 为混音后音效前；T3 为音效后 AGC 前；T4 为限幅后编解码前；T5 为最晚可访问数字参考。逐点改变音量、音效和输出设备，检查参考是否包含实际播放内容、时间戳是否可靠、延迟能否覆盖，再比较同一远端单讲窗口的残差。位置图和限制见 § 6.10。
4. 对  $J = e^2$  求梯度得  $-2e\vec{x}$ ；沿负梯度得到  $\Delta\vec{w} = \mu'e\vec{x}$ ，其中系数 2 并入步长；令  $\mu' = \mu/(\|\vec{x}\|^2 + \varepsilon)$  得式(6-2)。零参考能量时跳过更新。
5.  $\|\vec{x}\|^2 = 1.5$ ，更新量是  $[0.4/1.5, 0.2/1.5, -0.2/1.5]^\top$ ；重算估计回声为 0.4，后验残差为 0.4。式中的“减半”针对同一输入的后验检查，不是下一样本的输出保证。
6. 较大步长可加快适应，也会提高稳态波动和双讲误更新风险。保持输入、路径变化、噪声、初值和评价窗口不变，扫描步长；同时比较收敛过程、稳态残差和双讲近端损伤，不只选 ERLE 最大者。
7.  $10 \log_{10}(1/0.0063) = 22.0066 \dots \text{dB}$ ，约 22.0 dB； $10 \log_{10}(1/0.0001) = 40 \text{ dB}$ 。两个比值必须来自远端单讲回声能量。
8. 参考窗为  $x_a(n), \dots, x_a(n - L + 1)$ ，取其中绝对值最大者。线路中的约 6 dB 衰减给出约 0.5 幅度比；声学多径可叠加，路径增益也不同，不能沿用同一阈值，见 § 6.4。
9. 图31的非线性映射产生线性参考组合无法完全表示的分量；路径估计收敛后这些分量仍留在残差。平台随输入、非线性强度、路径及统计窗口而变，不是设备类别的固定上限。

10. 在算例 6-2 的核心变换与复乘口径下，逐样本时域 NLMS 的朴素分项为 3072 次实乘法/样本。无约束 PBFDAF 的对应部分为  $28672/128 = 224$  次/样本；逐分区约束为  $94208/128 = 736$  次/样本。因此，仅对这些已计入分项求比，分别约为  $3072/224 = 13.7$  和  $3072/736 = 4.17$ 。
- 若按教学代码逐块重算全部复频点的  $|X|^2$ ，PBFDAF 两项至少分别增加 32 次/样本，成为 256 和 768；这仍不是总量。相同分区、变换、归一化与约束的频域多抽头 NLMS 就是这里的 PBFDAF 更新，不能因改名再计一次加速收益。两边未计的操作、FFT 优化和硬件成本不同，部分乘法计数比不能当作实测加速比。
11. SER 为 -20 dB 意味着回声能量是近端的 100 倍。相位正确的  $0.9y$  副本留下  $0.1y$ ，残余回声能量变为原来的 0.01，理想残余 SER 到 0 dB；统一乘增益会同时缩放近端和回声，SER 不变。存在相位误差时要重新计算复数差。
12. A3 用固定远端单讲数据，在线性段和最终段分别取点并报告同窗口残余；A4 用规定 SER 与双讲区间的数据，同时报告近端损伤、回声和系数稳定性；A6 使用随机化、盲听的样本和播放协议，报告所选主观统计量。阈值来自明确版本的标准或目标设备历史基线，本题没有通用合格数字。
13. 冻结可以阻止检测到的双讲进入梯度，但期间路径变化也不能跟踪；小步长保留跟踪能力，也保留误更新风险。两者都需要检查检测滞后、错误判决和双讲结束后的恢复。
14. 逐通道 AEC 保持每路声学路径与波束权重解耦，但需要更多状态和计算；波束后 AEC 只运行一路，但要跟踪等效路径变化；联合方法利用共同统计模型，代价是更复杂的统计量和约束。按 § 6.6 的输入条件选择并测试。
15. 播放参考先进入历史缓冲和延迟搜索，对齐参考参与自适应滤波，麦克风减去回声估计形成线性残差；残余估计控制后续抑制，舒适噪声用于缓和背景突变。refined/coarse 更新和输出选择必须按固定版本源码检查，见 § 6.8。
16. ERLE 度量规定远端单讲窗口的回声能量衰减；平均意见分（Mean Opinion Score，MOS）来自规定协议下的真人评分；AECMOS 是模型预测的回声和其他可闻退化分。双讲输出包含应保留的近端语音，直接拿总输出功率计算 ERLE 会混淆回声泄漏与近端保留。
17.  $N = 64, 128, 256$  分别给出  $P = 64, 32, 16$ ， $2N = 128, 256, 512$  点，以及  $N/16000 = 4, 8, 16$  ms 的新输入积累时间。FFT 长度是“历史加当前”的运算长度，不是新输入等待时间；积累时间也不是含设备缓冲与调度的端到端延迟。
18. 四个候选频点为  $3/10, (1 + 2j)/6, -1/2, (1 - 2j)/6$ 。对四点 IFFT 的第 1 个时域位置（从 0 起），相位因子依次为  $1, j, -1, -j$ ，因此该位置的值为

$$\frac{1}{4} \left[ \frac{3}{10} + \frac{-2 + j}{6} + \frac{1}{2} + \frac{-2 - j}{6} \right] = \frac{1}{30}。$$

虚部相消后，实部为  $(3/10 - 2/6 + 1/2 - 2/6)/4 = 1/30$ 。逐频分母不同，随后清零后半时域位置又跨频点混合，因此单频点向量式只描述投影前候选，不能替代时域投影。

19. 单一纯音只覆盖有限的输入方向；训练段低残差可能来自只拟合了这条纯音，换宽带输入后才暴露未辨识的路径方向。冻结留出测试阻止算法利用测试块继续修正权重。合成无噪声 FIR、有真值系数和人为冻结均不等于真实设备录音，不能据此报告真实语音 ERLE。

20. 用合法抽头  $[1, 2, 0, 0]$  对四点输入  $[1, 2, 3, 4]$  做循环卷积，逐点得

$[1 + 2 \times 4, 2 + 2 \times 1, 3 + 2 \times 2, 4 + 2 \times 3] = [9, 4, 7, 10]$ 。重叠保存只取后半块，所以麦克风有效块  $[7, 10]$  与预测相同，正确有效误差为  $[0, 0]$ ，误差谱为零。

错误写法先把观测补成  $[0, 0, 7, 10]$ ，却从中减去完整循环输出。其逆变换结果为

$[0, 0, 7, 10] - [9, 4, 7, 10] = [-9, -4, 0, 0]$ 。非零项全来自本应丢弃的前半块；若用它更新权重，已经正确的合法抽头也会被误改。

21. 两点 DFT 的零频点是两样本之和，另一个频点是首样本减末样本。于是前帧  $[1, 2]$  给出

$(X_{0,m-1}, X_{1,m-1}) = (3, -1)$ ；本帧  $[3, 5]$  给出  $(X_{0,m}, X_{1,m}) = (8, -2)$ 。

一拍延迟的真实输出本帧为  $[2, 3]$ ，零频点是 5。按跨帧、跨频表达式复算，

$(3 - (-1) + 8 + (-2))/2 = 5$ 。若只保留两个输入零频点，则得到  $(3 + 8)/2 = 5.5$ ；缺掉的非零频点改变了实际结果，所以这种无重叠两点变换不能把一拍延迟简化为各频点互不相干的单频乘法。

## 可运行练习 E06-01~E06-06

下面六题由 `exercises_enhancement.py` 的 `run_exercises()` 复算。在仓库根目录运行

`.venv/bin/python -m codes.examples.exercises_enhancement`，按稳定 ID 查 JSON 结果。音频与共同播放增益见[练习及音频手册](#)。这些数例不替代设备收敛或听感评测。

- E06-01：脉冲是否能让全部抽头收敛？取  $x = [1, 0, 0]$ 、 $d = [0.8, -0.2, 0.1]$ ，3 抽头、零初值、 $\mu = 0.5$ 、 $\varepsilon = 0$ 。逐样本写回归向量、先验残差和最终抽头。

解答：回归向量依次是三个标准基；各方向只有一次更新，先验残差仍依次是  $0.8, -0.2, 0.1$ 。最终抽头为  $[0.4, -0.1, 0.05]$ ，恰为路径一半。

完整参考回归向量归零后才停止更新；当前参考样本为零时，历史样本仍可能触发更新。单次方向覆盖不等于持续激励或完全收敛。

- E06-02：两点延迟能由两抽头表示吗？取  $x = [1, 0, 0, 0]$ ，纯延迟回声  $d = [0, 0, 1, 0]$ ， $\mu = 1$ 。比较 2 抽头和 3 抽头的最终权重。均使用最近样本在前的回归向量。

解答：2 抽头只包含时延 0 和 1，回声出现时参考回归向量已为零，因此残差仍为  $[0, 0, 1, 0]$ 。3 抽头覆盖时延 2，更新后得到  $[0, 0, 1]$ 。首次回声样本仍先输出再更新；最终权重正确不代表已经消掉过去的样本。参考对齐和长度的关系也见 [Speex 官方排障说明](#)。



- E06-03: 双讲冻结保护了什么? 令  $x = [1, 1, 1, 1]$ 、 $d = [1, 1, 2, 2]$ , 单抽头初值 0.9,  $\mu = 0.5$ 、 $\varepsilon = 0$ ; 后两样本是已知双讲。比较后两样本冻结与持续更新, 并只在前两样本计算 ERLE。

解答: 前两次权重更新为 0.95、0.975。冻结后的残差为  $[0.1, 0.05, 1.025, 1.025]$ ; 继续更新会得到 1.4875、1.74375, 把近端成分错误计入路径。前两样本残差均方为  $(0.1^2 + 0.05^2)/2 = 0.00625$ , ERLE 约为 22.04 dB。

本题真值双讲标记是人为给定的控制输入, 不是双讲检测器; 这两个启动样本只用于检验算术, 不能作为稳态 ERLE。

- E06-04: 相减为什么反而更响? 在单频点上, 真实回声为非零  $y$ , 副本为  $e^{j\phi}y$ , 两者幅度相同。分别取相位误差  $0^\circ$ 、 $60^\circ$ 、 $180^\circ$ , 计算残余能量与原回声能量之比及理想 ERLE。

解答: 本书从复数减法得到  $|y - e^{j\phi}y|^2/|y|^2 = 2 - 2\cos\phi$ 。三个能量比分别是 0、1、4; 理想 ERLE 分别为正无穷、0 dB、约 -6.02 dB。 $180^\circ$  副本其实是  $-y$ , 相减得到  $2y$ , 所以能量翻为四倍。

这是已知副本的代数检查, 不是自适应器收敛结果。代码用 `null` 表示零残差对应的无限理想分数, 避免在 JSON 中写非有限数字; 真实系统还受噪声、量化和模型误差限制。

- E06-05: 噪声底能否掩盖继续改善的回声抵消? 取  $y = [1, 1, -1, -1]/2$ 、 $v = [1, -1, 1, -1]/20$ , 麦克风为  $d = y + v$ 。理想抵消后只剩  $e = v$ , 计算麦克风输入/输出能量比。

解答:  $y^\top v = 0$ ,  $\|y\|^2 = 1$ 、 $\|v\|^2 = 0.01$ , 故输入能量为 1.01、输出为 0.01,  $10\log_{10}(101) \approx 20.04$  dB。此时真实回声残余为零, 但含背景噪声的输入/输出测量仍为有限值。

本书使用正交序列使交叉项精确为零; 普通短录音不保证该条件。这个数字是含噪取点的测量结果, 不是回声分量 ERLE 的理论上限, 也不是设备只能抵消约 20 dB 的证据。

- E06-06: 纯单频参考经过三次非线性后, 最佳线性副本还剩什么? 采样率为 16 kHz, 取 32000 点、500 Hz、幅度 0.4 的参考  $x[n] = 0.4\sin\theta_n$ , 其中  $\theta_n = 2\pi(500)n/16000$ 。令麦克风中的纯远端回声为  $d[n] = x[n] + 2x^3[n]$ , 没有传播滤波、近端语音或噪声。用整段最小二乘标量  $g = \langle x, d \rangle / \langle x, x \rangle$  构造线性副本  $\hat{d} = gx$ , 求残差和 ERLE。

解答: 由  $\sin^3\theta = (3\sin\theta - \sin 3\theta)/4$ , 有

$$d[n] = 0.496\sin\theta_n - 0.032\sin 3\theta_n。$$

两秒记录恰含 1000 个 500 Hz 周期, 500 Hz 与 1500 Hz 正弦在这个窗口内正交。因此  $g = 0.496/0.4 = 1.24$ ,  $\hat{d}[n] = 0.496\sin\theta_n$ , 残差为  $e[n] = -0.032\sin 3\theta_n$ 。理论功率为  $P_d = (0.496^2 + 0.032^2)/2 = 0.12352$ 、 $P_e = 0.032^2/2 = 0.000512$ , 所以

$$\text{ERLE} = 10\log_{10}(P_d/P_e) = 10\log_{10}(241.25) \approx 23.8247 \text{ dB}。$$



图36 三次非线性留下线性估计无法表示的谐波（合成反例）




图36(a)比较回声、共同最小二乘增益得到的线性副本与残差；图36(b)读取配套 PCM 后显示 500 Hz 和 1500 Hz 的离散周期幅度。上面的功率和 ERLE 来自未量化解析序列，PCM 读回值会有量化误差。本题的标量估计不是在线自适应器，但它给出了所有线性时不变滤波器都无法跨频率产生 1500 Hz 分量的稳态反例；改变输入频谱、非线性或统计窗口后，数值不会保持不变。

边界练习 E06-07~E06-10。下面四题可用 `aec_algorithm_minicases.py` 的 JSON 字段逐项核对：E06-07 对应 `overlap_save`，E06-08 对应 `ipnlms`，E06-09 对应 `geigel`，E06-10 对应 `delay_polarity`。先独立手算，再运行程序；这些题只检验运算和判决边界，不是工业算法性能实验。

- E06-07：循环卷积的哪半块能用？取  $N = 2, P = 2, h = [1, 2 \mid 3, 4], x = [1, 2, 3, 4]$ ，负时刻输入为零。写出第 1 块  $[1, 2, 3, 4]$  与第一分区  $[1, 2, 0, 0]$  的四点循环卷积，再加上延迟一个块的第二分区，指出哪些样本可用。

解答：第一分区循环结果为  $[9, 4, 7, 10]$ ，第二分区从上一块  $[0, 0, 1, 2]$  得到  $[8, 0, 3, 10]$ 。各自前半块含循环折返，不用于当前块；后半块相加为  $[7 + 3, 10 + 10] = [10, 20]$ 。连同第 0 块的  $[1, 4]$ ，与直接时域卷积一致。这只检查固定路径的分区卷积，不含自适应系数更新。

- E06-08：IPNLMS 的混合系数如何改变一步更新？取  $\hat{w} = [0.8, 0.2], x = [1, 1], d = 1.2, \mu = 1$ ，忽略本题非零分母上的极小正则项。分别取式(6-5)的  $\kappa = -1, 0, 1$ ，求  $g$  与  $\Delta w$ 。

解答：先验误差为 0.2，三组  $g$  依次为  $[0.5, 0.5]$ 、 $[0.65, 0.35]$ 、 $[0.8, 0.2]$ ；分母均为 1，因此  $\Delta w$  依次为  $[0.1, 0.1]$ 、 $[0.13, 0.07]$ 、 $[0.16, 0.04]$ 。 $\kappa = 1$  且权重全零时比例项也全零，需要均匀分量或抽头下限才可启动；单步数字不能推出长期性能排名。

- E06-09：没有近端语音，Geigel 为什么报双讲？两抽头  $h = [0.4, 0.4]$ 、参考窗  $[1, 1]$ 、近端为零，门限为 0.5。算判决比；再令参考窗全零，判断能否沿用同一公式。

解答：远端单讲时  $d = 0.8$ ，参考峰值为 1，比值为  $0.8 > 0.5$ ，故裸判据误报。全零参考使分母为零，应先门控参考活动，不形成数值判决；把零参考强行除以小数会改变判据含义。

- E06-10：负极性回声怎样骗过最大正峰？令  $x = [1, 0, 0, 0]$ 、 $d = [0, 0, -1, 0]$ ，定义非负滞后相关  $r_{xd}[k] = \sum_n x[n]d[n+k]$ ， $k = 0, 1, 2, 3$ 。分别用最大有符号值、最大绝对值选延迟。

解答：相关序列为  $[0, 0, -1, 0]$ ；只取最大有符号值会在并列零峰中按首个位置选  $k = 0$ ，而最大绝对值选  $k = 2$ ，与真实纯延迟一致。多径或周期参考仍可能使绝对峰有歧义，设备测试还要结合时间戳与宽带激励。

子带、IPNLMS、RLS 与 Kalman 练习 E06-11~E06-20。先按式(6-4)~式(6-12)及本节 Haar 定义手算，再运行 `aec_advanced_exercises.py` 的 `run_exercises()` 对照稳定 ID；**独立测试**用分数与解析边界核对答案。这十题是无量纲模型题，不把合成样本或人为提供的双讲真值当成设备检测结果。

- E06-11：低带输入能否产生高带回声？两点 Haar 分析下，取  $x = [1, 1 \mid 0, 0]$ 、 $d[n] = x[n-1]$ 。写出两个块的输入高带  $u_1[m]$ 、输出高带  $v_1[m]$ ；解释只用独立同带滤波器为何不能精确表示。

解答：输入两块高带均为零。延迟后  $d = [0, 1 \mid 1, 0]$ ，所以  $v_1 = [-1/\sqrt{2}, +1/\sqrt{2}]$ 。任意只读  $u_1$  的线性滤波器输出仍为零；缺的是  $u_0 \rightarrow v_1$  交叉项。这不是实际滤波器组在噪声下的收敛测量。

- E06-12：删掉交叉项会改变什么？对图37(b)的  $x = [1, 0, 0, 0]$  和一拍延迟，分别写出完整两带映射与只保留其精确同带项时合成的四个时域样本，求两输出之差。

解答：完整映射为  $[0, 1, 0, 0]$ ；只保留同带项为  $[0, 0.5, 0, 0.5]$ ；缺失项为  $[0, 0.5, 0, -0.5]$ 。这是已知路径的系统表示对照，不能把两输出之差当作训练后的 AEC 残差或 ERLE。

- E06-13：正则项没有省略时如何更新 IPNLMS？取  $\hat{w} = [0.8, 0.2]$ 、 $x = [1, 1]$ 、 $d = 1.2$ 、 $\mu = 1$ 、 $\kappa = 0$ 、 $\varepsilon_g = 2$ 、 $\delta = 0.25$ 。求先验误差、 $g$ 、分母和  $\Delta w$ ；再取  $\kappa = -1$ ，指出与哪一个 NLMS 正则项相等。

解答： $e = 0.2$ ， $g = [0.45, 0.30]$ ， $\sum g = 0.75$ ，更新分母  $0.75 + 0.25 = 1$ ， $\Delta w = [0.09, 0.06]$ 。 $\kappa = -1$  给  $g = [0.5, 0.5]$ 、分母 1.25、 $\Delta w = [0.08, 0.08]$ ；NLMS 取  $\varepsilon = L\delta = 0.5$  时同样得到  $0.2[1, 1]/2.5$ 。若把  $g$  错误地重新归一成和为 1，第一组答案会改变。

- E06-14: 为什么不能直接从纯比例零权重起步?  $L = 2$ 、 $\hat{w} = [0, 0]$ 、 $\kappa = 1$ 、 $\varepsilon_g > 0$ , 任取非零参考和残差。按式(6-5)计算更新方向。

解答: 均匀项为零, 比例项的分子也都为零, 因此  $G = 0$ 、 $Gx = 0$ , 两个抽头都不更新。 $\varepsilon_g$  和  $\delta$  防止除零, 却不能凭空产生方向; 保留  $\kappa < 1$  的均匀项或明确的权重下限才能启动。这个零初值反例不代表所有 PNLMS 初始化策略都会停住。

- E06-15: RLS 的“记忆长度”换成秒是多少? 忽略冻结, 取  $\lambda = 0.99$ , 求一个旧观测经过 100 次更新后的相对权重; 分别假定每次更新间隔为  $1/16000$  s 和 10 ms, 求历时。

解答: 相对权重是  $0.99^{100} \approx 0.3660$ 。逐采样更新 100 次历时  $100/16000 = 0.00625$  s; 每 10 ms 更新一次则历时 1 s。同一个  $\lambda$  不能脱离更新间隔解释为固定秒数, 也不能把 100 次更新直接称为 100 个独立样本。

- E06-16: 双讲若误当路径变化会怎样? 依本节已知真值反例, 首个观测后  $w = 10/11$ 、 $P = 1/11$ 。第二次  $x = 1, d = 3$  中真实路径仍为 1、近端成分为 2。分别求固定  $\Psi = 0.1$ 、已知双讲时设  $\Psi = 10$ 、理想冻结的第二次权重。

解答: 先验残差为  $23/11$ 。低方差增益  $10/21$ , 权重  $440/231 \approx 1.905$ ; 高方差增益  $1/111$ , 权重  $10/11 + 23/1221 \approx 0.928$ ; 冻结保持  $10/11 \approx 0.909$ 。

后两种控制依赖外部真值, 不能由该数例推断设备上的双讲检测正确率。若路径同时变化, 冻结也会推迟跟踪。

- E06-17: RLS 递推是否真等于目标函数的解? 取算例中的  $R_1 = \begin{bmatrix} 7/4 & 1 \\ 1 & 5/4 \end{bmatrix}$ 、 $p_1 = [5/2, 2]^T$ 。不用式(6-8)的增益, 直接求行列式并解正规方程。

解答:  $\det R_1 = (7/4)(5/4) - 1 = 19/16 > 0$ 。二阶矩阵求逆或消元得  $w_1 = [18/19, 16/19]^T$ , 与递推一致。这个一致性依赖式(6-6)的初始约束和两次观测; 换目标或初始矩阵时不能沿用答案。

- E06-18: 舍去 Kalman 非对角协方差会怎样? 取本节第一次观测后的  $P = \begin{bmatrix} 5/6 & -2/3 \\ -2/3 & 4/3 \end{bmatrix}$ , 第二个参考向量  $x = [-1, 1]^T$ 、 $\Psi = 1$ 。分别用完整  $P$  和只保留对角元素的  $P$  求创新方差  $S = x^T P x + \Psi$ 。

解答: 完整交叉项给  $S = 9/2 = 4.5$ ; 丢掉交叉项仅得  $S = 19/6 \approx 3.167$ 。前一观测把两个抽头联系起来, 下一次不能无条件当作独立。此题只证明递推值不同, 不证明完整矩阵在任意录音上胜过对角近似。

- E06-19: 未知一拍路径的交叉带第一步怎样更新? 取  $x = [1, 1 | 0, 0]$ 、 $d = [0, 1 | 1, 0]$ 、 $K = 2$ 、初始  $W = 0$ 、 $\mu = 1$ 、 $\varepsilon = 1$ 。只处理第 0 块, 求式(6-4)的两个先验误差、分母及四路当前块权重; 指出哪个系数证明高输出带可以读取低输入带。

解答：输入带为  $[\sqrt{2}, 0]$ ，输出带为  $[1/\sqrt{2}, -1/\sqrt{2}]$ ，先验预测为零；分母  $1 + 2 = 3$ 。更新后  $W_{0,0,0} = 1/3$ 、 $W_{1,0,0} = -1/3$ ，两个以高输入带  $j = 1$  为源的权重仍零。 $W_{1,0,0}$  是低输入带到高输出带的交叉项。它是一步权重，不是当前块的后验回声抵消分数。

- E06-20：两带模型是否必然省抽头、省等待？时域物理路径有  $L = 4$  个非零抽头，采用本节两点 Haar 全交叉状态，不施加时域 FIR 结构约束。求精确表示需要的最小块阶数  $K$ 、独立权重数，以及至少需要等多少个后续样本才可输出当前两点块。

解答： $K = \lfloor 4/2 \rfloor + 1 = 3$ ，四条输入—输出带路径各有 3 个权重，共  $4K = 12$  个，而物理 FIR 只有 4 个抽头。收到块内第一个样本后，还须等第二个样本，因此至少有 1 个原采样的成块等待；滤波器组和设备链路可能再增加延迟。这个抽头与等待计数不能代替设备上的乘法、内存或端到端时延测量。

## 6.17 延伸阅读

---

1. Hänsler & Schmidt, *Acoustic Echo and Noise Control* (Wiley 2004) ——AEC 领域的经典大部头，从自适应理论到免提终端工程全覆盖。[Wiley 在线版](#)
2. Benesty, Gansler, Morgan, Sondhi & Gay, *Advances in Network and Acoustic Echo Cancellation* (Springer 2001) ——可用于阅读频域自适应与立体声 AEC 的背景；IPNLMS 参见前文所列的 2002 年方法与 2004 年参数化，不能把 2001 年著作当成它的原始出处。
3. Enzner、Buchner、Favrot 与 Kuech, *Acoustic Echo Control* (Elsevier 2014) ——载于 *Academic Press Library in Signal Processing* 第 4 卷、第 30 章，807~877 页；该书 4.30.2~4.30.6 小节分别讨论抵消与后滤、多通道、非线性和真实系统应用。[出版社章节页](#)
4. Breining et al., IEEE SPM 1999——四大难点的经典出处，一节一引，入门必读（链接见 § 6.1.1）。
5. 中文参考：《语音识别服务实战》第 3.4 节，侧重工程实现。

§ 6.8~§ 6.17 讨论了 AEC3 的信号流、多参考相关性、参考抽头、验收、诊断、个性化处理、代码基线和研究方向。部署时应先确认参考信号与延迟对齐，再检查自适应控制和残余抑制。



## 第 7 章 · 去混响 (WPE)

---

第 6 章处理设备播放声返回麦克风形成的回声。本章讨论房间混响的晚期拖尾及 WPE 去混响。多说话人分离、掩码估计和完整处理顺序见第 8 章。

### 7.1 问题、模型与直觉算例

---

声学回声消除 (Acoustic Echo Cancellation, AEC) 处理已知播放参考产生的回声；加权预测误差法 (Weighted Prediction Error, WPE) 利用语音跨帧预测结构估计晚期混响。保护延迟用来减少对直达声和早期反射的损伤，但不能保证它们完全不受影响；估计误差、过小的保护延迟和模型失配都可能产生语音失真。

去混响有三条常见路线：**波束形成**（第 5 章，利用空间选择性压低弥散混响）、**盲逆滤波或线性预测**，以及神经网络谱增强。本节重点介绍 WPE。WPE 既指它采用的加权预测误差准则，也常用来指基于该准则的去混响算法。

**WPE 之前的三类方法**。多通道逆滤波、倒谱分离和谱方差抑制分别依赖已知路径、倒谱域可分性或晚期混响功率估计。它们的假设和局限有助于理解 WPE 的设计。

**多通道逆滤波定理** (Multiple-input/output INverse Theorem, MINT; Miyoshi & Kaneda 1988)。它假设房间冲激响应 (Room Impulse Response, RIR) 已知，且各通道传递函数没有公共零点，再用有限冲激响应 (Finite Impulse Response, FIR) 逆滤波器抵消房间响应。条件满足时可作为理想逆滤波的参考，但它对 RIR 估计误差、公共零点和加性噪声敏感，滤波器长度也随混响时间增加。因此实际系统很少依赖预先精确测得的 RIR。

**倒谱 liftering**。这类单通道方法假设声门激励与声道、房间响应在倒谱域占据不同区域。对数功率谱经逆傅里叶变换进入倒谱域后，用窗函数保留指定倒谱区间。计算量较低，但重混响和强谐波会使两类成分重叠，窗口选择不当会同时损伤语音。

**谱方差抑制**。该方法假设晚期混响与直达声统计独立，并从历史帧递推晚期混响功率谱，再用维纳增益或谱减法抑制。它可以按帧因果运行，但会受到功率估计滞后、非平稳噪声和音乐噪声影响。现代学习型谱增强仍沿用“估计干扰功率或增益，再施加频带增益”的基本形式。

MINT 说明已知房间响应时的逆滤波条件；倒谱方法说明单通道频谱分解的局限；谱方差方法提供了逐帧功率估计与增益抑制思路。WPE 不要求预先测量 RIR，并可扩展到多通道，同时通过保护延迟只预测晚期成分。

**三路线对照表**。不同论文使用的阵列、数据集、识别器和因果条件不同，不能把词错率改善幅度横向拼成统一范围。表中只比较处理对象与实现条件；需要性能数字时，应引用同一数据集上的原始实验。



| 路线    | 代表                                                                                                                      | 主要处理对象         | 所需输入或假设                                                    | 因果性与计算                    | 主要限制                 |
|-------|-------------------------------------------------------------------------------------------------------------------------|----------------|------------------------------------------------------------|---------------------------|----------------------|
| 空间选择  | 最小方差无失真响应<br>(Minimum Variance Distortionless Response, MVDR)、广义特征值<br>(Generalized Eigenvalue, GEV) 波束形成, 见第 5 章 § 5.4 | 弥散混响与定向干扰      | 多通道信号, 以及目标方向或掩码                                           | 可按帧流式处理; 计算随通道数和频点数增加     | 混响占优且方向线索弱时, 空间选择性有限 |
| 延迟预测  | WPE、在线 WPE                                                                                                              | 可由历史帧预测的晚期混响   | 短时傅里叶变换 (Short-Time Fourier Transform, STFT) 复谱、保护延迟与足够统计量 | 批处理版迭代整段数据; 在线版递推统计量      | 短语音、模型失配或预测阶数过大时不稳定  |
| 谱增益估计 | 深度神经网络 (Deep Neural Network, DNN) 去混响、谱方差抑制                                                                             | 全带混响, 也可联合处理噪声 | 训练数据或可靠的晚期混响功率估计                                           | 是否因果取决于网络前瞻与特征窗; 计算量依模型而定 | 跨房间、跨设备泛化和语音失真需单独验证  |

长混响可先评估 WPE; 存在定向干扰时再结合波束形成; 学习型后滤波还需满足算力和训练数据条件。多通道 WPE、波束形成与单通道后滤波可以组成一条候选链路, 但实际顺序取决于统计量和通道数, 见第 10 章 § 10.1。

REVERB 挑战赛中的 WPE: REVERB 包含 8 通道、2 通道和单通道设置, 仿真数据的混响时间约为 0.25~0.7 s, 另含真实房间录音。

Kinoshita 等在 *EURASIP Journal on Advances in Signal Processing* 2016 的挑战总结表明, WPE 对远场识别的改善与通道数和数据条件有关; 引用结果时必须注明通道数与测试集。

[REVERB Challenge 官方任务说明](#)、Kinoshita et al., 2016, § 2、§ 4.1.1 与图5

图21 (b) 中音节结束后的横向能量拖尾, 在 (c) 中得到减弱。

WPE 的直觉：晚期混响在所选时频模型中被近似为可由历史观测线性预测的成分，再从当前帧减去该预测。这不要语音或混响全程平稳；算法用随帧变化的功率  $\lambda(n, f)$  表示语音非平稳性。保护延迟  $\Delta$  隔开当前帧与预测历史，跳过最近的  $\Delta - 1$  帧，以降低直达声和早期反射进入预测项的程度。

WPE 的预测式只引用当前帧之前的观测，这使它可以改造成流式算法。但经典批处理 WPE 会用整段录音反复估计滤波器和时变功率，仍然是非因果处理。只有把统计量、滤波器和功率估计都改为只使用当前及历史数据，并计入 STFT 分帧带来的等待时间，才能称为因果在线 WPE。

模型（每个频点  $f$  独立处理；本节  $X$ 、 $E$ 、 $G$  都是逐时频点的复数标量，多通道版才升级为向量）：

$$X(n, f) = E(n, f) + \sum_{k=\Delta}^{\Delta+K-1} G^*(k, f) X(n - k, f) \tag{7-1}$$

这里  $E(n, f)$  表示希望保留的直达声与早期反射。

式(7-1)把当前观测分成早期成分  $E$  和由历史帧线性预测的晚期成分。不同频点的混响衰减不同，因此每个频点分别估计一组  $G$ ，实现时可并行计算。 $\Delta$  将当前帧与预测历史隔开，避免使用最近几帧预测直达声和早期反射。其中：

- $X(n, f)$ ：第  $n$  帧、频点  $f$  的观测谱（拿到的数据）； $E(n, f)$ ：想恢复的干净早期成分；
- $G(k, f)$ ：预测滤波器系数； $\Delta$ ：保护延迟，求和的  $k$  从  $\Delta$  起算，因此跳过最近  $\Delta - 1$  帧； $K$ ：预测阶数，决定使用多少个历史帧。 $\Delta$  和  $K$  没有脱离帧移、数据量和目标失真指标的通用默认值。

图24 WPE 延迟预测： $\Delta=3$  时保护  $t-1$ 、 $t-2$ ， $K=5$  使用  $t-3 \dots t-7$




图24 使用与 `nara_wpe 0.0.11` 离线 `build_y_tilde()` 一致的索引： $\Delta = 3$ 、 $K = 5$  时，受保护而不参与预测的是  $t - 1$ 、 $t - 2$ ；五个预测帧依次为  $t - 3$  到  $t - 7$ 。统一写成

$$\hat{r}(t) = \sum_{q=0}^{K-1} G_q^* X(t - \Delta - q).$$

因此  $q = 0$  对应  $t - \Delta$ ，不是保护区的一部分。该预测式只含历史样本；批处理还是在线处理，则取决于  $G_q$  和功率统计是否使用未来帧。

#### 算例 7-1：WPE 的一步直觉数值例（单通道、单频点）

WPE 用历史观测预测晚期混响，再从当前帧中减去预测值。完整算法要交替估计系数  $G$  和时变功率；本例将  $G$  视为已知，只计算一次预测与相减。

取单通道、单频点、预测阶数  $K = 2$ 、保护延迟  $\Delta = 2$ 。预测使用第  $n - 2$ 、 $n - 3$  帧，跳过最近的第  $n - 1$  帧。已知：

- 过去帧观测： $X(n - 2) = 0.8 + 0.1j$ ， $X(n - 3) = 0.5 - 0.2j$ （都是复数标量，实部虚部分别携带该时频点的幅度与相位信息）；
- 预测系数： $G(2) = 0.5 + 0.1j$ ， $G(3) = 0.3 - 0.05j$ ；
- 当前帧观测： $X(n) = 0.9 + 0.4j$ 。

用到的唯一工具是复数乘法： $(a + bj)(c + dj) = (ac - bd) + (ad + bc)j$ 。

教程模型里出现的是共轭  $G^*$ （共轭 = 虚部变号），所以  $G^*(2) = 0.5 - 0.1j$ ， $G^*(3) = 0.3 + 0.05j$ 。

#### 第 1 步：用 $n - 2$ 帧预测一份拖尾

$$G^*(2) X(n - 2) = (0.5 - 0.1j)(0.8 + 0.1j)$$

实部  $= ac - bd = 0.5 \times 0.8 - (-0.1) \times 0.1 = 0.40 + 0.01 = 0.41$ ；

虚部  $= ad + bc = 0.5 \times 0.1 + (-0.1) \times 0.8 = 0.05 - 0.08 = -0.03$ 。

所以  $G^*(2) X(n - 2) = 0.41 - 0.03j$ 。

#### 第 2 步：用 $n - 3$ 帧再预测一份拖尾

$$G^*(3) X(n - 3) = (0.3 + 0.05j)(0.5 - 0.2j)$$

实部  $= 0.3 \times 0.5 - 0.05 \times (-0.2) = 0.15 + 0.01 = 0.16$ ；

虚部  $= 0.3 \times (-0.2) + 0.05 \times 0.5 = -0.06 + 0.025 = -0.035$ 。

所以  $G^*(3)X(n-3) = 0.16 - 0.035j$ 。

第 3 步：两份拖尾相加，得到当前帧里“可预测的陈旧成分”

$$\hat{r}(n) = 0.41 - 0.03j + 0.16 - 0.035j = 0.57 - 0.065j$$

这个  $\hat{r}(n)$  是当前帧晚期混响拖尾的估计。

第 4 步：从当前帧观测中减掉它

$$E(n) = X(n) - \hat{r}(n) = (0.9 + 0.4j) - (0.57 - 0.065j) = 0.33 + 0.465j$$

$E(n) = 0.33 + 0.465j$  就是去混响后的输出：实部  $0.9 - 0.57 = 0.33$ ，虚部  $0.4 - (-0.065) = 0.465$ 。

观测幅度为  $|X(n)| \approx 0.985$ ，相减后的幅度为  $|E(n)| \approx 0.570$ ；对应能量从约 0.97 降到约 0.325，相差约 4.7 dB。

这个数例只检查复数乘法、共轭和帧索引。系数  $G$  是人为给定的，因此能量下降不能作为去混响效果证据，也不能据此断言剩余量恰好等于直达声与早期反射。

真实 WPE 还要从多帧数据估计  $G$  与功率  $\lambda(n, f)$ ，并用独立的干净参考或识别指标评价失真。

算例 7-2：保护期加宽一帧 ( $\Delta = 3$ 、 $K = 2$ )

题设为单通道、单频点， $\Delta = 3$ 、 $K = 2$ 。已知：

- 过去帧为  $X(n-3) = 0.6 + 0.2j$ 、 $X(n-4) = 0.4 + 0.3j$ ；
- 预测系数为  $G(3) = 0.4 - 0.2j$ 、 $G(4) = 0.2 + 0.1j$ ；
- 当前帧为  $X(n) = 1.0 + 0.5j$ 。

要求去混响输出  $E(n)$ 。

求和下标为  $k = 3, 4$ ，因此使用第  $n-3$ 、 $n-4$  帧；第  $n-1$ 、 $n-2$  帧位于保护区，不参与预测。若当前帧  $n = 10$ ，预测使用第 7、6 帧，跳过第 9、8 帧。相较算例 7-1，保护期增加一帧。

第 1 步：计算第一个预测项。先取  $G^*(3) = 0.4 + 0.2j$ ，再计算

$$\begin{aligned} G^*(3)X(n-3) &= (0.4 + 0.2j)(0.6 + 0.2j) \\ &= (0.4 \times 0.6 - 0.2 \times 0.2) + (0.4 \times 0.2 + 0.2 \times 0.6)j \\ &= 0.20 + 0.20j. \end{aligned}$$

第 2 步：计算第二个预测项。取  $G^*(4) = 0.2 - 0.1j$ ，得到

$$\begin{aligned} G^*(4)X(n-4) &= (0.2 - 0.1j)(0.4 + 0.3j) \\ &= (0.2 \times 0.4 + 0.1 \times 0.3) + (0.2 \times 0.3 - 0.1 \times 0.4)j \\ &= 0.11 + 0.02j. \end{aligned}$$

第 3 步：相加预测项并从当前观测中减去。拖尾估计为

$$\hat{r} = 0.20 + 0.20j + 0.11 + 0.02j = 0.31 + 0.22j,$$

因此

$$E = (1.0 - 0.31) + (0.5 - 0.22)j = 0.69 + 0.28j.$$

输入与输出的幅度分别为  $|X| = \sqrt{1.25} \approx 1.118$ 、 $|E| = \sqrt{0.4761 + 0.0784} \approx 0.745$ ；能量从 1.25 降到约 0.55，相差约 3.5 dB。

本例的能量变化约为 3.5 dB，小于算例 7-1 的约 4.7 dB。两组系数为人为设定，差异不能作为一般性能结论。

固定  $K = 2$  时， $\Delta$  从 2 增至 3 并没有减少预测帧数量，仍使用两帧；它只是排除更多靠近当前帧的样本，并把长度相同的历史窗整体移远。 $\Delta$  的选择见 § 7.8。

## 7.2 离线 WPE：交替估计预测器与语音功率

交替估计  $G$  与  $\lambda$  (Nakatani et al., 2010)。假设早期成分  $E$  服从零均值复高斯分布，方差  $\lambda(n, f)$  随时间变化；这里的  $\lambda$  表示第  $n$  帧的功率谱。时变方差使不同能量的语音帧获得不同权重，减少高能量帧对估计的支配。下面在固定频点  $f$  上写出从最大似然到加权最小二乘的推导。

[Nakatani et al., IEEE TASLP 2010](#)

中间行 1——写出条件似然：当前帧的预测值使用过去帧，因此这里不能把整段观测直接说成无条件独立。固定起始历史帧，只对历史窗完整的有效帧  $n \in \mathcal{V}$  计算：给定历史回归向量  $\vec{x}(n)$ 、 $G$  和  $\lambda(n)$ ，把创新  $E(n) = X(n) - \sum_k G^*(k)X(n-k)$  建模为零均值、方差为  $\lambda(n)$  的复高斯。再假定这些创新在给定历史时按时间条件独立，链式法则给出有效帧的条件似然：

$$p(X_{\mathcal{V}} | X_{\text{history}}, G, \lambda) = \prod_{n \in \mathcal{V}} \frac{1}{\pi \lambda(n)} \exp \left( - \frac{|X(n) - \sum_k G^*(k)X(n-k)|^2}{\lambda(n)} \right)$$

。



中间行 2——取负对数：最大化似然等价于最小化负对数似然。去掉与  $G$  无关的常数后，权重  $1/\lambda(n)$  直接来自高斯密度指数项的分母：

$$-\log p = \sum_{n \in \mathcal{V}} \frac{|X(n) - \sum_k G^*(k)X(n-k)|^2}{\lambda(n)} + \sum_{n \in \mathcal{V}} \log \lambda(n) + \text{const}$$

。

固定  $\lambda$  时第二项是常数，最小化第一项就是加权最小二乘。用后文的历史向量  $\vec{x}(n)$  和系数向量  $\vec{g}$  可写成

$$\hat{\vec{g}} = \arg \min_{\vec{g}} \sum_{n \in \mathcal{V}} \frac{|X(n) - \vec{g}^H \vec{x}(n)|^2}{\lambda(n)}. \quad (7-2)$$

中间行 3——对  $G$  求导得正规方程：把历史帧排成向量

$\vec{x}(n) = [X(n-\Delta), \dots, X(n-\Delta-K+1)]^\top$ ，记  $\vec{g} = [G(\Delta), \dots, G(\Delta+K-1)]^\top$ 。求和式可写成  $E(n) = X(n) - \vec{g}^H \vec{x}(n)$ ，其中上标  $H$  表示共轭转置。

对  $\vec{g}^*$  使用 Wirtinger 导数并令其为零，得到  $K \times K$  加权正规方程：

$$\begin{aligned} \mathbf{R} &= \sum_n \frac{\vec{x}(n) \vec{x}^H(n)}{\lambda(n)}, \\ \vec{r} &= \sum_n \frac{\vec{x}(n) X^*(n)}{\lambda(n)}, \\ \mathbf{R} \vec{g} &= \vec{r}. \end{aligned} \quad (7-3)$$

$\mathbf{R}$  是加权自相关矩阵， $\vec{r}$  是加权互相关向量；解式(7-3)即可得到式(7-2)的预测系数  $\vec{g}$ 。

$R$  是  $K \times K$  共轭对称矩阵；当正则化后的  $R$  为正定矩阵时，可用 Cholesky 分解求解。

$K$  应根据可用帧数、拖尾覆盖范围、通道数和矩阵条件数在目标数据上选择，不能只凭固定区间设定。

算法交替固定  $\lambda$  求  $G$ 、固定  $G$  更新  $\lambda$ ；第一次迭代的  $\lambda$  可用观测能量初始化。在线版改用递推统计量，并需要单独处理样本不足和矩阵病态。

固定  $G$  后再更新逐帧功率；在未平滑的标量模型中有  $\lambda(n, f) = |E(n, f)|^2$ 。

固定  $G$  后，对  $\lambda(n) > 0$  求导：

$$\frac{\partial}{\partial \lambda(n)} \left( \frac{|E(n)|^2}{\lambda(n)} + \log \lambda(n) \right) = -\frac{|E(n)|^2}{\lambda^2(n)} + \frac{1}{\lambda(n)}.$$

令导数为零得到  $\hat{\lambda}(n) = |E(n)|^2$ 。实际实现通常会在频率或时间上平滑并设置正数下限，避免单个近零残差造成权重过大。

离线单通道 WPE 的完整一轮：下面把散落的公式按实现顺序连起来。每个频点独立执行，所有下限和正则化强度都要随信号尺度定义。

1. 由观测功率初始化  $\lambda^{(0)}(n, f)$ ，并设相对功率下限，避免静音帧产生过大的  $1/\lambda$ ；
2. 对有效帧构造  $\vec{x}(n) = [X(n - \Delta), \dots, X(n - \Delta - K + 1)]^\top$ 。最早有效帧为  $n = \Delta + K - 1$ ；
3. 用当前  $\lambda^{(i)}$  累加  $\mathbf{R}$  和  $\vec{r}$ 。为保持输入整体缩放时的相对正则化强度，可解

$$\left[ \mathbf{R} + \epsilon \frac{\text{tr}(\mathbf{R})}{K} \mathbf{I} \right] \vec{g}^{(i+1)} = \vec{r},$$

其中无量纲  $\epsilon$  是相对对角加载量；若  $\text{tr}(\mathbf{R}) = 0$ ，该频点应旁路或使用单独定义的正数下限；

4. 更新  $E^{(i+1)}(n) = X(n) - [\vec{g}^{(i+1)}]^\top \vec{x}(n)$ ，再由平滑后的  $|E^{(i+1)}(n)|^2$  更新  $\lambda^{(i+1)}$ ；
5. 达到预设迭代次数，或目标函数相对变化低于预先声明的阈值时停止。报告结果时同时给出迭代次数/停止阈值、功率下限、平滑方式和  $\epsilon$ 。

边界检查包括： $K = 0$  时输出应退化为输入；全零频点不应求逆；把输入整体乘以常数时，采用上述相对加载的滤波器形状不应因绝对幅度而改变。

### 算例 7-3：加权最小二乘求解器的手算（单抽头 $K = 1$ 、3 个有效帧）

取单频点、 $K = 1$ 、保护延迟  $\Delta = 3$ ，只估计一个抽头  $g = G(3)$ 。从零开始计帧，完整六帧观测依次为  $X(0:5) = [0.8, 0.5, 0.4, 1.0, 0.6, 0.2]$ 。最早有效帧是  $n = 3$ ；在  $n = 3, 4, 5$ ，当前观测  $X(n) = [1.0, 0.6, 0.2]$ ，历史样本  $x(n) = X(n - 3) = [0.8, 0.5, 0.4]$ ，权重  $w(n) = 1/\lambda(n) = [1, 4, 1]$ 。前三帧只提供历史，不进入本例的三个正规方程求和项。

为简化运算，本例使用实数。要求闭式解  $\hat{g}$ 。

标量正规方程为  $Rg = r$ ，其中  $R = \sum wx^2$ 、 $r = \sum wxX$ 。代入可得

$$R = 1 \times 0.64 + 4 \times 0.25 + 1 \times 0.16 = 1.80,$$

$$r = 1 \times 0.8 \times 1.0 + 4 \times 0.5 \times 0.6 + 1 \times 0.4 \times 0.2 = 2.08,$$

因此  $\hat{g} = 2.08/1.80 \approx 1.156$ 。该人为数例中的  $\hat{g}$  大于 1，不代表一般路径系数范围。

若所有权重都为 1，则  $R = 1.05$ 、 $r = 1.18$ 、 $\hat{g} \approx 1.124$ 。较大的第二帧权重使估计更接近该帧对应的比值。 $K > 1$  时，同样的加权关系写成矩阵正规方程。

### 7.3 多通道 WPE

多通道版 (MIMO-WPE, Yoshioka & Nakatani 2012) : 预测第  $m$  个通道的当前帧时, 使用所有  $M$  个通道的历史帧:

$$X_m(n, f) = E_m(n, f) + \sum_{m'=1}^M \sum_{k=\Delta}^{\Delta+K-1} G_{m,m'}^*(k, f) X_{m'}(n-k, f). \quad (7-4)$$

每个滞后  $k$  对应一个  $M \times M$  系数矩阵。把  $K$  个滞后的所有通道历史堆叠后, 回归向量长度为  $MK$ , 联合系数可写成  $MK \times M$ 。因此每个频点的正规方程矩阵是  $MK \times MK$ , 而不是单通道的  $K \times K$ 。

例如  $M = 8, K = 10$  时矩阵为  $80 \times 80$ 。有效帧数若只接近 80, 样本协方差很容易病态, 还要为非平稳性、掩码和相关帧留出余量。

晚期混响会同时出现在多个麦克风上, 但幅度和相位不同, 多通道观测因此提供额外空间信息。相对收益取决于混响、阵列和数据长度, 具体数字应查原论文的实验条件。Yoshioka & Nakatani 2012

图21 的仿真输入与读图口径。本书仿真使用 16 kHz、1.4 s 的合成输入和随机种子 21001。房间脉冲响应的直达延迟为 10 ms, 晚期随机尾设  $T_{60} = 0.6$  s、直达混响比 (Direct-to-Reverberant Ratio, DRR) 为 6 dB。


分析采用 512 点 Hann 窗、128 点帧移; 单通道 WPE 取  $\Delta = 6$ 、 $K = 10$ , 迭代 3 次。三图使用同一个谱幅参考。

三幅语谱图在显示前都已补偿合成路径的 10 ms 直达传播时延, 因此横轴表示同一对齐时间基准。横轴约为 0~1400 ms, 纵轴约为 0~2.5 kHz, 颜色表示相对能量的 dB 值。


(a) 给出无混响参考; (b) 加入合成混响后, 音节结束处出现横向拖尾; (c) 经本书单通道 WPE 示例处理后, 拖尾减弱但仍有残留。

图21 WPE 去混响效果（本书单通道仿真）


(a) 按 10 ms 传播时延对齐的干净参考



(b) 混响语音：能量沿时间拖尾、边界变模糊



(c) WPE 去混响后：拖尾被抑制



配置：16 kHz、1.4 s、种子 21001；RIR 直达延迟 10 ms、 $T_{60}=0.6$  s、 $DRR=6$  dB；  
Hann 512 点、帧移 128 点；WPE  $\Delta=6$ 、 $K=10$ 、3 次迭代；三图共用对齐时间与谱幅参考。

脚本按对齐后的无混响参考帧功率定义活动帧和安静帧，随后报告安静帧能量占比，以及活动帧相对该对齐参考、经复增益校准后的谱域归一化均方误差（Normalized Mean Square Error, NMSE）。前者下降而后者增大时，说明去拖尾与语音损伤之间存在权衡。

功率  $\lambda$  使用居中的 5 帧移动平均，因此会读取左右各 2 帧，图中实现是离线而非因果；功率下限为该频点峰值的  $10^{-5}$ 。正规方程使用  $\epsilon \text{tr}(R)\mathbf{I}/K$  的相对对角加载， $\epsilon = 10^{-6}$ 。

合成混响的全卷积尾部被裁到 1.4 s 记录长度，图中指标只统计保留的对齐窗口，不覆盖被裁掉的尾部。这些量来自同一个固定随机种子的合成例，不代表公开数据集上的平均性能。

与其他模块的组合：WPE 可先减弱晚期混响，掩码 MVDR 再抑制噪声与定向干扰。Drude et al. (Interspeech 2018) 在其测试条件下报告了联合系统相对单模块的改善。[Interspeech 2018 论文](#)

WPE  $\rightarrow$  GSS  $\rightarrow$  MVDR/GEV 也可不使用神经分离网络，见第 8 章。Raj et al. (Interspeech 2023) 展示了 GSS 的 GPU 并行实现；速度比较只能按其论文的硬件、数据、代码版本和计时范围解读，不将加速倍数外推到其他实现。

开源实现 `nara_wpe` 的离线与在线接口需要分开选择。

## 7.4 在线 WPE 的因果更新

在线版分为按块更新和逐帧递推两类。块在线 WPE 在最近一段历史上估计统计量；递推 WPE 用遗忘因子逐帧更新相关矩阵和滤波器。[在线 WPE](#)

短块提供的有效样本较少， $\lambda$  和相关矩阵的方差更大；块过长又会增加等待时间，并使旧房间统计占比过高。

在线实现还要处理初始化、矩阵正则化、静音冻结和路径突变，不能只把批处理迭代次数改成 1。DNN-WPE 可以用网络估计  $\lambda$ ，但是否优于传统估计取决于训练数据与测试房间是否匹配。

三帧因果递推小例。对单频点、单抽头实数特例，令  $\Delta = 3$ ，连续观测

$X_0, \dots, X_5 = [1, 2, 1, 0.8, 1.6, 1.0]$ 。从实际帧  $t = 3$  开始，历史回归量为  $x_t = X_{t-3}$ ；待更新的三组  $(x_t, X_t)$  依次为  $(1, 0.8), (2, 1.6), (1, 1.0)$ 。固定遗忘因子  $\alpha = 0.5$ 、 $\lambda_t = 1$ ，按式(7-5)递推：

$$\begin{aligned} R_t &= \alpha R_{t-1} + x_t^2 / \lambda_t, \\ r_t &= \alpha r_{t-1} + x_t X_t / \lambda_t, \\ g_t &= r_t / (R_t + \delta). \end{aligned} \tag{7-5}$$

式中  $R_t$  是累计的加权历史能量， $r_t$  是历史与当前观测的加权互相关， $g_t$  是供下一帧使用的实数预测系数； $\alpha \in [0, 1]$  是遗忘因子， $\delta \geq 0$  是与  $R_t$  同量纲的正则项。式(7-5)仅针对本例的单频点、单抽头实数模型；复数和多通道版须按式(7-3)、式(7-4)处理共轭与矩阵维度。

本例为便于手算取  $\delta = 0$ ，在首个有效帧前初始化  $R_2 = r_2 = 0$ ：



1. 第 1 次更新 ( $t = 3$ ) :  $R_3 = 1$ ,  $r_3 = 0.8$ ,  $g_3 = 0.8$ ;
2. 第 2 次更新 ( $t = 4$ ) :  $R_4 = 0.5 \times 1 + 4 = 4.5$ ,  $r_4 = 0.5 \times 0.8 + 3.2 = 3.6$ ,  $g_4 = 0.8$ ;
3. 第 3 次更新 ( $t = 5$ ) :  $R_5 = 0.5 \times 4.5 + 1 = 3.25$ ,  $r_5 = 0.5 \times 3.6 + 1 = 2.8$ ,  $g_5 \approx 0.8615$ 。

流式输出应先用上一帧已有的  $g_{t-1}$  预测当前拖尾，再用当前  $(x_t, X_t)$  更新出  $g_t$  供下一帧使用；初始化阶段可旁路。

按此顺序，第一个有效帧  $t = 3$  尚无估计器，旁路输出  $E_3 = X_3 = 0.8$ ；更新后  $g_3 = 0.8$ 。第  $t = 4$  帧先输出  $E_4 = X_4 - g_3 x_4 = 1.6 - 0.8 \times 2 = 0$ ，随后得到  $g_4 = 0.8$ 。第  $t = 5$  帧先输出  $E_5 = X_5 - g_4 x_5 = 1.0 - 0.8 \times 1 = 0.2$ ，再更新到  $g_5 \approx 0.8615$ 。

若反过来使用当帧刚算出的  $g_t$  评分，会把当前观测同时用于拟合和输出，便不是这里定义的先输出、后更新流程。

这个例子只演示因果统计量顺序，不包含交替更新的功率估计。 $\lambda_t$  也必须只用当前与历史信息，不能沿用图21的居中平滑。

$\alpha \rightarrow 1$  记忆更长但跟踪更慢， $\alpha \rightarrow 0$  跟踪更快但估计方差增大，实际实现还需  $\delta > 0$  和静音冻结。[Drude et al., 2018](#), § 4.2~§ 4.3、[Kinoshita et al., Interspeech 2017](#)

帧移为 8 ms 时，0.25 s 约含 31 帧，2 s 含 250 帧。这个换算可以用来估计统计样本量和块等待时间，但不能单独决定参数。起始值应在目标数据上同时检查拖尾衰减、语音失真、计算量和端到端延迟，再调整块长、遗忘因子、预测阶数和正则化强度。

## 7.5 `nara_wpe` 的接口与时间索引

开源实现 `nara_wpe` 是常用的 MIMO-WPE 参考实现。下面固定 PyPI 0.0.11 版；其他版本的轴序和在线接口应重新检查。

```
pip install nara-wpe==0.0.11
```

```
from nara_wpe.wpe import wpe
Z = wpe(Y, taps=10, delay=3, # taps=K (预测阶数), delay=Δ (保护延迟)
        iterations=3)      # 离线交替迭代次数；改成 1 仍是离线调用
```

其中  $Y$  是复数 STFT。后两轴为通道  $D$ 、帧  $T$ ，其余前轴可用于频点等维度；0.0.11 版 `help(wpe)` 标注为 `(..., D, T)`。

上述 `wpe()` 会在已给整段数据上交替估计，属于离线调用。

逐帧递推可从 `nara_wpe/wpe.py` 的 `OnlineWPE.step_frame()` 阅读：输入一帧（频点, 通道），对象跨调用保存逆相关矩阵、预测抽头、功率和历史缓冲。它先产生当前输出，再更新状态；若每个音频块重新创建对象，就会反复经历启动阶段。

这里必须把“更新顺序”和“`delay` 参数对应哪个历史帧”分开核对。0.0.11 版三个接口的同名参数并不对应同一时间戳：取帧 `[10,20,30,40]`，在零起始  $t = 3$  令 `taps=1`、`delay=1`、固定预测抽头为 1，离线 `build_y_tilde()` 取 30，即  $X_{t-1}$ ；无状态 `online_wpe_step()` 取 20，即  $X_{t-2}$ ；有状态 `OnlineWPE.step_frame()` 在写入 40 前从旧缓冲取 10，即  $X_{t-3}$ 。

三者残差依次为 10、20、30。图24和本章公式对应第一种离线索引，不能把逐帧接口的 `delay=1` 直接改写成书中的  $\Delta = 1$ 。

同一文件的 `OnlineWPE.step_block()` 要求包含指定历史长度的缓冲形状；锁定版本 `_get_prediction()` 还注明只支持 `block_shift=1`。它不能被当作任意帧移的块处理器。TensorFlow 路线在 `tf_wpe.py` 中另有 `block_wpe_step()` 和 `recursive_wpe()`，依赖、状态和接口也不同。  
[nara\\_wpe](#) [NumPy 源码](#)、[TensorFlow 源码](#)

## 7.6 与其他模块组合及失效边界

DNN 与 WPE 的位置。神经网络可以预测干净复谱、时频掩码或 WPE 所需的功率  $\lambda$ 。常见位置取决于网络输出：

- 网络若对每个通道独立做波形或复谱映射，可能改变跨通道相位关系，通常放在多通道 WPE 和波束形成之后；
- 网络若只估计共享掩码、空间协方差或  $\lambda$ ，而多通道复谱仍由解析滤波器处理，可以放在 WPE 或波束形成内部；
- 联合训练的多通道模型可以同时完成去混响与波束形成。

模块位置应由输入输出是否保留空间相位、是否使用未来帧和训练目标决定，不能简单规定所有 DNN 都在链尾。

局限与处理办法：WPE 的模型目标是抑制可由延迟历史预测的晚期混响，而不是主动消除直达声与早期反射；保护延迟、功率估计或预测模型失配时，输出仍可能改变这些希望保留的成分。下列条件会使估计不稳定、早期成分失真或收益有限：

| 场景            | 现象                              | 对策                                                                    |
|---------------|---------------------------------|-----------------------------------------------------------------------|
| 可用帧数与待估参数数量接近 | 二阶统计量方差增大，相关矩阵可能病态              | 降低预测阶数、增加正则化；流式实现另行调节遗忘因子                                             |
| 弱混响或高信噪比近讲    | 可预测拖尾较弱，处理收益可能小于失真              | 先测混响时间、直混比和旁路差异，再决定是否启用                                               |
| 强加性噪声         | 模型里没有独立噪声项， $G$ 与 $\lambda$ 被污染 | 采用显式含噪模型或联合卷积波束形成；不能把单独去噪器的收益算作 WPE 本身                                |
| 大间距分布式阵列      | 统一 $\Delta$ 让参考与预测仍相关，输出失真      | 麦克风相关延迟：按到达时延给各通道定各自延迟（ <a href="#">Lohmann et al., ICASSP 2023</a> ） |

启用 WPE 前应检查可用帧数、混响强度、加性噪声和通道时延。任一条件不满足时，应调整块长、模型或旁路策略。

卷积功率最小无失真响应（Weighted Power minimization Distortionless response, WPD）把多帧、多通道滤波写进同一个无失真最小功率问题，可同时处理去混响与波束形成。它不是简单串联两个现成模块，也不能用条件不同的 WPE、MPDR 数字相加预测收益。

把当前多通道帧及延迟历史堆成  $\bar{\vec{x}}_t = [\vec{x}_t^\top, \vec{x}_{t-\Delta}^\top, \dots]^\top$ ，并把目标导向约束扩展为  $\bar{\vec{v}} = [\vec{v}^\top, \vec{0}^\top, \dots]^\top$ 。令  $\lambda_t > 0$ ，用同一组时帧构造加权协方差  $\bar{\mathbf{R}} = \sum_t \bar{\vec{x}}_t \bar{\vec{x}}_t^H / \lambda_t$ 。WPD 的目标是

$$\min_{\bar{\vec{w}}} \bar{\vec{w}}^H \bar{\mathbf{R}} \bar{\vec{w}} \quad \text{s.t.} \quad \bar{\vec{w}}^H \bar{\vec{v}} = 1. \quad (7-6)$$

当  $\bar{\mathbf{R}}$  正定时，对式(7-6)作与 § 5.4 相同的复数拉格朗日求导，先得到  $\bar{\mathbf{R}} \bar{\vec{w}} = \eta \bar{\vec{v}}$ ；再代入约束求出  $\eta = 1/(\bar{\vec{v}}^H \bar{\mathbf{R}}^{-1} \bar{\vec{v}})$ ，于是

$$\bar{\vec{w}}_{\text{WPD}} = \frac{\bar{\mathbf{R}}^{-1} \bar{\vec{v}}}{\bar{\vec{v}}^H \bar{\mathbf{R}}^{-1} \bar{\vec{v}}}. \quad (7-7)$$

最小维度检查：2 麦、1 个历史块时， $\bar{\vec{x}}$  和  $\bar{\vec{w}}$  都有 4 个元素。若  $\bar{\mathbf{R}} = \text{diag}(2, 1, 4, 4)$ 、 $\bar{\vec{v}} = [1, 1]^\top$ ，则扩展约束向量为  $\bar{\vec{v}} = [1, 1, 0, 0]^\top$ 。

此时  $\bar{\mathbf{R}}^{-1} \bar{\vec{v}} = [0.5, 1, 0, 0]^\top$ ，分母为 1.5，故

$$\bar{\vec{w}} = [1/3, 2/3, 0, 0]^\top,$$

并可直接验证  $\bar{\vec{w}}^H \bar{\vec{v}} = 1$ 。

这里当前帧与历史块没有互相关，历史权重退化为零，WPD 退化到当前帧的加权 MPDR

(weighted minimum power distortionless response, 加权最小功率无失真响应)。 $\bar{\mathbf{R}}$  仍是用  $1/\lambda_t$  加权的观测协方差，不是噪声协方差。只有把优化中的矩阵明确取为目标缺席时的噪声协方差  $\mathbf{R}_{nn}$ ，同形闭式解才对应 MVDR。

延迟历史与当前晚期混响之间存在可利用相关性时，历史权重才会参与去混响。

该模型还假设希望保留的早期目标可由当前块的导向向量描述、 $\lambda_t > 0$  且加载后的协方差可逆；若  $\lambda_t$  或协方差使用未来帧，所得实现仍是离线的。

原始 WPD 工作见 Nakatani 与 Kinoshita 2019，后续因式分解工作说明了它与 WPE、波束形成的关系。Nakatani & Kinoshita, EUSIPCO 2019、Boeddeker et al., ICASSP 2020

## 7.7 可执行教学基线与复现实验

可执行 WPE 基线。 `codes/array_tutorial/dereverberation.py` 提供只依赖 NumPy 的最小离线 WPE。 `offline_wpe()` 接收复数 STFT，单通道轴序为 (频点, 帧)，多通道轴序为 (频点, 通道, 帧)，输出保持相同形状；它实现保护延迟、按滞后堆叠多通道历史、共享功率权重、相对对角加载和复共轭预测。计算前逐频点以共同幅度归一化各通道和各帧，输出再恢复原幅度，以免极小或极大但有限的输入在平方时下溢或上溢。

`taps=0`、迭代次数为零、记录短于首个有效回归帧或整个频点为零时直接旁路。输入各维不能为空、数值必须有限；阶数、延迟和迭代次数必须为整数，功率下限必须是有限正数。输入必须是复谱，不能把幅度谱传入后再补相位。

默认调用仍只返回谱数组。设 `return_diagnostics=True` 时另返回逐频点诊断：加载后正规矩阵在各轮中的最小数值秩、最大条件数、进入最小范数最小二乘回退的次数，以及未求解时的旁路原因。数值秩依赖浮点精度和矩阵尺度，不是语音质量或混响强度评分。

当前基线在 `np.linalg.solve` 抛出奇异矩阵错误后用 `np.linalg.lstsq` 求最小范数解；它不会自行增加加载、减小  $K$  或根据音质旁路。调用方应检查诊断和参考信号，在需要时调整加载、阶数或旁路策略；求得有限残差不等于保住了直达声。

可预测目标的反例：取一个频点、单通道六帧全为  $1 + 0j$ ，设  $K = 2$ 、 $\Delta = 1$ 、迭代一次、对角加载为零。有效帧  $n = 2, 3, 4, 5$  的历史向量全为  $[1, 1]^\top$ ，所以  $\mathbf{R} = 4 \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ 、 $\vec{r} = [4, 4]^\top$ ； $\mathbf{R}$  的秩为 1。最小范数解  $\vec{g} = [1/2, 1/2]^\top$  把这些帧预测为 1，残差为零（双精度实现中约在  $10^{-16}$  量级）。前两帧因缺少完整历史而原样保留。

该输入没有给出晚期混响真值，却会使可预测的目标分量几乎消失，故不能把残差小解读为去混响成功。若为改善数值条件而加对角加载，也仍须检查目标失真；正则化不能单独证明模型的声学假设成立。

联合示例用 `.venv/bin/python -m codes.examples.ch06_09_baselines` 运行，边界测试见 `tests/test_codes_aec_wpe_sep_track.py` 和 `tests/test_codes_wpe_mask_diagnostics.py`。测试固定检查  $K = 0$ 、短输入、全零频点、单抽头复共轭方向、多通道形状、整体幅度缩放等变性、秩亏诊断与非零微小掩码。实际音频管线还要自行固定 STFT 的窗、帧移、`center` / 补零约定与 ISTFT 长度，并测试短语音、静音权重、病态矩阵、通道交换及块边界。

该基线是整段离线估计，不宣称因果或实时。离线、在线、学习功率与联合滤波的源代码入口分别如下，完整读码顺序和失效实验见 [WPE 源码研究](#)。

| 实现                       | 主要源码                                                                                              | 与教学基线的差别                                             | 最小核对实验                                          |
|--------------------------|---------------------------------------------------------------------------------------------------|------------------------------------------------------|-------------------------------------------------|
| nara_wpe 离线/MIMO         | <code>nara_wpe/wpe.py</code> 的 <code>build_y_tilde()</code> 、 <code>wpe_v6()</code> 等             | 更多求解与统计区间实现                                          | 单抽头手算、多通道历史排列、零功率与短输入                           |
| nara_wpe 逐帧              | 同文件 <code>OnlineWPE</code>                                                                        | 保留递推状态，每次处理一帧；0.0.11 的 <code>delay</code> 时间戳与离线接口不同 | 固定抽头手算实际历史帧；同一帧流按不同外层批次输入，检查是否误重置               |
| nara_wpe 块/递推 TensorFlow | <code>nara_wpe/tf_wpe.py</code>                                                                   | 显式块统计与递推接口                                           | 对照帧时间戳，检查历史窗口和新输入是否混淆                           |
| ESPnet DNN-WPE           | <code>espnet2/enh/layers/dnn_wpe.py</code> 、 <code>wpe.py</code> 、 <code>mask_estimator.py</code> | 网络估计掩码/功率，解析层解预测滤波                                   | 先用固定正数功率核对求解，再接 <code>checkpoint</code> ；测未来帧依赖 |
| ESPnet WPD               | <code>espnet2/enh/layers/beamformer.py</code> 、 <code>dnn_beamformer.py</code> 的 WPD 分支           | 在当前通道和历史联合做无失真滤波                                     | 复算正文历史权重为零的退化例，再加入当前一历史相关                       |
| CuPy WPE/GPU-GSS         | <code>desh2608/wpe</code> 与 <code>gss/wpe/</code>                                                 | 以 GPU 批处理服务会议增强                                      | 同参数核对 CPU/GPU 输出、精度与峰值显存                        |

ESPnet 的 DNN-WPE 外层输入为 `(批, 帧, 通道, 频点)`，内部才转成 `(批, 频点, 通道, 帧)`；换库时必须显式转换，不能仅凭数组同为四维就直接传入。DNN-WPE 中只做一次解析更新，也不表示网络或功率估计没有使用未来帧。[ESPnet DNN-WPE 源码](#)



工程比较应固定通道数、上下文长度、硬件、计时范围和实际因果条件。训练权重、语料和 CUDA 环境是独立前提；取得源代码并不表示训练或设备实时性已经验证。

本书另提供[独立实现数值对照](#)：把教学版 `offline_wpe()` 与未经修改的 `nara-wpe 0.0.11` 的 `wpe_v6()` 比较。固定复数随机输入、预测阶数 2、保护延迟 3，检查单通道、双通道、通道置换和整体缩放，每种分别迭代 1 次和 3 次。两种实现对启动帧的处理不同，因此只比较零起始索引  $t = 4$  起的有效预测区间；本次 8 组检查的最大绝对误差约为  $3.2 \times 10^{-15}$ 。

[完整参数与误差口径](#)说明为何要对齐统计区间和功率下限。该检查验证复数代数、维度和迭代口径，不是语音质量、流式延迟或论文全量实验的复现。

[在线接口与状态对照](#)先手算上述三个固定索引，再以保留上游缓冲顺序的精简 NumPy 适配参考逐帧对照锁定源码。适配部分随附原始版权与 MIT 声明；独立期望另由实数、复数启动例的分数手算给出，不用两个相关实现彼此一致代替独立验证。

固定种子、48 帧、2 个频点、1 个通道、2 抽头、`delay=2`、遗忘因子 0.95 时，NumPy 与上游连续输出的最大绝对误差为  $2.4 \times 10^{-15}$ 。同一对象在第 24 帧外层分块不改变输出；若第 24 帧重建对象，差异从该帧开始，最大绝对差约为 2.56。后一个数值只说明状态丢失会改变这组合成复谱，不表示 2.56 是任何语音指标。

[未来帧与多种外层分块实验](#)进一步固定种子 20260924，构造 48 帧、2 频点、1 通道的合成复谱；只在零起始第 30 帧的两个频点各加  $5 + 2j$ 。锁定的 `nara-wpe 0.0.11` 逐帧接口保持同一个状态对象，使用 2 抽头、`delay=2`、遗忘因子 0.95。

两组输出在第 30 帧之前逐样本相同；第 30 帧的最大差为  $|5 + 2j| = \sqrt{29} \approx 5.385$ ，之后的最大差约为 1.261。当前帧计算时两次运行的旧状态和历史回归量相同，所以当帧输出差由输入改变量直接给出；后续差异还包含状态更新的影响。

将原始 48 帧分成 48 个单帧块、`7+13+5+23` 帧四块或 `30+18` 帧两块，调用同一对象的 `step_frame()`，与整段逐帧调用逐样本完全相同。这些“块”只是外层调用分组，不是 `OnlineWPE.step_block()` 所要求的历史窗口。

作为相反对照，锁定版离线 `wpe_v6()` 用全段统计、一次迭代处理同一对输入时，第 30 帧以前的输出最大差约为 0.210。实验只验证固定复谱和固定实现的时间依赖；它没有 STFT 波形分帧、端到端延迟或去混响音质数据。[逐帧接口源码](#)与 [Kinoshita 等 2017 年论文 § 3](#)分别给出此版本接口和在线短数据统计问题。

## 7.8 保护延迟与预测抽头数的参数换算

---

先把帧数换成物理时间。若帧移为  $H$  ms，最近的预测帧是  $t - \Delta$ ，其时延为  $\Delta H$ ； $K$  个预测帧从  $t - \Delta$  到  $t - (\Delta + K - 1)$ ，最远时延为  $(\Delta + K - 1)H$ 。这个索引关系比“ $\Delta + K$  帧”少一帧，因为起点已算入  $K$  个样本。

以图 21 的本书仿真为例：采样率 16 kHz，短时傅里叶变换（Short-Time Fourier Transform, STFT）窗长 512 点（32 ms），帧移 128 点（8 ms）， $\Delta = 6$ 、 $K = 10$ 、交替迭代 3 次。因此使用  $t - 6$  到  $t - 15$  的十帧：最近预测帧延迟  $6 \times 8 = 48$  ms，最远为  $15 \times 8 = 120$  ms。这些数值只是图 21 的可复现配置，不是会议室、教室或其他房间的通用起点。

选参时，先对  $\Delta$  扫描并检查直达声和早期成分的失真；再在数据量足够的条件下增大  $K$ ，检查晚期拖尾、矩阵条件数、计算量和下游任务指标。增大  $K$  会增加参数量，在短语音或强噪声下反而可能使估计不稳定。 $T_{60}$  只描述整体衰减时间，不能单独决定  $\Delta$ 、 $K$  或迭代次数。

## 7.9 常见错误与练习

---

五项常见错误：

1. 取  $\Delta = 0$ ，使回归器包含当前帧，允许恒等或近恒等的退化预测，而不只是“多减一点直达声”；
2. 无条件增大  $K$ ，导致数据不足时过拟合；
3. 用 WPE 处理本应保留的早期反射；
4. 把 WPE 当作加性噪声抑制器，忽略模型中没有独立噪声项；
5. 在弱混响条件下仍强制启用 WPE。

对应的检查量分别是当前帧泄漏与早期语音损伤、有效样本数、直混比、噪声强度和混响时间。

### 练习 7-1（自测九题）

1. 默写单通道 WPE 模型并解释  $\Delta$ 、 $K$ 。

答案：式(7-1)为当前早期成分加上延迟历史的预测。 $\Delta$  是最近预测帧的时延，跳过最近  $\Delta - 1$  帧； $K$  是参与预测的历史帧数。

2.  $\Delta = 2$ 、 $K = 2$ 、 $n = 10$  时用哪几帧、跳过哪几帧？

答案：用第 8、7 帧；跳过第 9 帧，不使用当前第 10 帧作为回归量。

3. 复算算例 7-1 第 1 步的复数乘法。

答案：先取共轭，实部是  $0.5 \times 0.8 + 0.1 \times 0.1 = 0.41$ ，虚部是  $0.5 \times 0.1 - 0.1 \times 0.8 = -0.03$ ，结果  $0.41 - 0.03j$ 。

4. 独立完成算例 7-2 并算出 dB 数。

答案：预测项相加为  $0.31 + 0.22j$ ，输出  $E = 0.69 + 0.28j$ ；输出能量为 0.5545， $10 \log_{10}(1.25/0.5545) \approx 3.53$  dB。这里只计算能量变化，不评价语音失真。

5. 写出最大似然交替的两步，以及固定  $\lambda$  时的正规方程。

答案：固定  $\lambda$ ，按式(7-3)计算加权自相关  $R$ 、互相关  $\vec{r}$ ，解  $R\vec{g} = \vec{r}$ ；固定  $G$ ，用未平滑标量模型的  $\lambda = |E|^2$  更新功率。实际平滑、下限、对角加载和停止条件均要随实现报告。

6. 手算算例 7-3，并解释权重如何改变估计。

答案：按三帧输入累加得  $R = 0.64 + 4 \times 0.25 + 0.16 = 1.80$ 、 $r = 0.8 + 4 \times 0.3 + 0.08 = 2.08$ ， $\hat{g} = 2.08/1.80 \approx 1.156$ 。第二帧权重较大，因此对估计影响更大；权重全为 1 时结果约为 1.124。

7. 图21的帧移为 8 ms， $\Delta = 6$ 、 $K = 10$ 。写出最近和最远预测帧及物理时延。

答案：用  $t - 6$  到  $t - 15$ ；最近 48 ms，最远 120 ms。该配置属于本书仿真，不能仅由  $T_{60}$  推为通用参数。

8. 在线版面临哪两种统计困难？可以怎样验证改进？

答案：短历史会使功率与相关矩阵估计波动；长历史又会保留旧路径信息。应在相同录音上扫描统计窗、遗忘因子、阶数与加载，同时测拖尾和目标失真。DNN 功率估计是需训练和域外验证的候选，不保证比传统估计好；在线与离线的收益也不必处处按同一方向排序。

9. 神经网络可以放在 WPE 前、后或内部吗？

答案：独立改写各通道复谱的网络通常放在多通道处理之后；只估计共享掩码、协方差或  $\lambda$  的网络可以放在解析算法内部。还要检查是否使用未来帧，单次解析更新不证明整体因果。

## 可运行练习 E07-01~E07-05

运行 `.venv/bin/python -m codes.examples.exercises_enhancement`，源码见

`exercises_enhancement.py`。可听的混响前后样本及其固定处理参数见[练习及音频手册](#)；下面的复数序列只用于数学核对。

- E07-01：有效帧与矩阵尺寸。2 通道、12 帧、 $\Delta = 3$ 、 $K = 2$ 、帧移 8 ms，采用零起始帧号。首个有效帧、有效帧数、回归向量维数分别是多少？

解答：首帧为  $3 + 2 - 1 = 4$ ，使用历史帧 1、0，每个历史帧含两通道。共有  $12 - 4 = 8$  个有效帧，向量有  $MK = 4$  项，正规矩阵为  $4 \times 4$ 。最近/最远历史分别延迟 24/32 ms。8 个样本多于 4 个参数不保证独立或良态。

- E07-02: 复共轭写反会怎样? 令  $G = 0.5 + 0.25j$ ,  $X_0 = 1$ , 之后  $X_t = G^* X_{t-1}$ 。取 12 帧、单抽头、延迟 1、一次离线更新且不加载, 检查有效帧输出。

解答:  $X_1 = 0.5 - 0.25j$ 。正规方程恢复共轭预测关系, 有效帧残差应在浮点误差内接近零, 首帧仍为 1。若预测误用  $GX_0$ , 第一有效帧残差为  $-0.5j$ 。完全可预测的序列被消掉, 不表示真实语音应该被消掉, 也不证明去混响质量。

- E07-03: 加载修复了什么? 给定  $R = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ 、 $r = [1, 1]^T$ , 按  $R + 0.1 \text{tr}(R)I/2$  加载, 求特征值、条件数和解。

解答: 原特征值为 0、2, 不能唯一求逆; 加载矩阵对角元素增加 0.1, 特征值变为 0.1、2.1, 条件数为 21。解的两项均为  $1/2.1 \approx 0.47619$ 。加载选出稳定的正则化解, 但不会补回缺失的独立观测, 也会改变无加载目标。

- E07-04: 预测只用历史, 为什么仍会读到未来? 单频点记录 A 为  $[1, 1, 1, 1]$ , 记录 B 为  $[1, 1, 1, 2]$ , 均作为复谱输入。取单抽头、延迟 1、一次离线迭代、零对角加载; 初始功率为观测能量。前 3 帧相同, 只改最后一帧, 比较第 1 帧的输出 (零起始编号)。

解答: 有效帧为 1、2、3, 历史均为  $[1, 1, 1]$ 。A 的功率权重为  $[1, 1, 1]$ ,  $R = 3, r = 3, g = 1$ , 有效帧输出全为零。B 的权重为  $[1, 1, 1/4]$ ,  $R = 9/4, r = 1 + 1 + 2/4 = 5/2$ , 故  $g = 10/9$ ; 第 1 帧输出由 0 变成  $1 - 10/9 = -1/9$ , 第 3 帧输出为  $8/9$ 。

本书的这个反例直接运行 `offline_wpe()`, 各功率均高于下限。第 1 帧的回归量没有未来样本, 但它使用的系数由整段录音估计, 因此整个处理不是因果的。这里没有采用图 21 的居中平滑, 单靠全段统计已经会产生未来依赖; 单个输入未发现变化, 也不能证明另一实现一定因果。

- E07-05: WPD 的历史权重什么时候不为零? 按式(7-6)、式(7-7), 取当前两麦及一个历史块组成四维向量, 扩展导向为  $\bar{v} = [1, 1, 0, 0]^T$ 。给定加权协方差

$$\bar{R} = \begin{bmatrix} 2 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 2 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix},$$

求满足  $\bar{w}^T \bar{v} = 1$  的最小功率权重, 并与强制历史权重为零比较。

解答: 解  $\bar{R}u = \bar{v}$ 。第 1、3 行给出  $2u_1 + u_3 = 1$ 、 $u_1 + 2u_3 = 0$ , 所以  $u_1 = 2/3, u_3 = -1/3$ ; 另两项为  $u_2 = 1, u_4 = 0$ 。分母  $\bar{v}^T u = 5/3$ , 得到  $\bar{w} = [0.4, 0.6, -0.2, 0]^T$ 。约束为  $0.4 + 0.6 = 1$ , 目标值为  $\bar{w}^T \bar{R} \bar{w} = 0.6$ 。

历史权重强制为零时, 当前块协方差为  $\text{diag}(2, 1)$ , 最优权重为  $[1/3, 2/3, 0, 0]^T$ , 目标值为  $2/3$ 。非零当前一历史相关使第三项能够参与抵消; 若把两处互相关 1 改为 0, 历史权重又回到零。

该矩阵特征值为 1、1、1、3，正定性和约束都可独立检查。这是本书给定协方差的优化手算，不是语音质量实验，也不将目标值下降当作普遍去混响收益。模型出处见 [Nakatani 与 Kinoshita](#)，§ II、§ IV。

## 7.10 研究方向

---

WPE 的改进主要围绕四个限制展开：

- 分布式阵列需要按通道到达时延调整预测延迟；
- 麦克风很多时需要参考通道或子集选择；
- 短块和强噪声下需要更稳健的功率估计；
- 系统级方法尝试把去混响与波束形成联合求解。

神经网络可以为这些解析结构估计功率、掩码或先验，但比较结果时要对齐数据集、通道数、因果性和延迟。本章不列无法按这些条件复核的近期性能数字。

参数设置应先在目标数据上把直达声和早期反射的损伤控制在声明的指标阈值内，再根据晚期拖尾长度和可用帧数选择  $K$ 。保护延迟不能保证早期成分完全不变；弱混响时可以旁路 WPE。多说话人分离见第 8 章。



## 第 8 章 · 语音分离

第 7 章讨论单个声源的混响拖尾，本章讨论多个说话人同时发声时的混合与分离。主要方法包括免训练盲源分离（Blind Source Separation, BSS）、导引源分离（Guided Source Separation, GSS）和深度分离；§ 8.2再说明这些方法在前端系统中的顺序。

### 8.1 多说话人语音分离：鸡尾酒会问题

去混响处理单个声源的时间拖尾，语音分离处理多个声源在同一观测中的叠加。本节依次介绍免训练 BSS、GSS 和深度分离。时频掩码既可用于分离，也可用于 § 5.4 的空间协方差估计。

卷积混合模型。第  $m$  个麦克风接收各说话人经过相应房间冲激响应后的叠加，再加上噪声：

$$x_m(t) = \sum_{n=1}^N \sum_{\tau} h_{mn}(\tau) s_n(t - \tau) + v_m(t). \quad (8-1)$$

$h_{mn}$  是第  $n$  个声源到第  $m$  个麦克风的房间冲激响应， $s_n$  是第  $n$  个源信号。源数  $N$  与麦克风数  $M$  有三种关系：

- $N = M$  是确定混合；
- $N < M$  是超定混合，可保留冗余通道、先降维或使用超定扩展；
- $N > M$  是欠定混合，不能只靠一个方阵解混器恢复全部源，还要利用时频稀疏性、源谱模型或满秩空间协方差等结构。

标准方阵辅助函数型独立向量分析（Auxiliary-function-based Independent Vector Analysis, AuxIVA）和独立低秩矩阵分析（Independent Low-Rank Matrix Analysis, ILRMA）通常针对  $N = M$ 。多通道非负矩阵分解（Multichannel Nonnegative Matrix Factorization, MNMF）能表示  $N > M$ ，但可靠性仍取决于源数、数据长度、初始化和模型匹配。

单麦  $M = 1$  时没有跨通道方向信息。此时多说话人分离只能依赖源信号先验或监督学习，不能使用后文的多通道方向聚类作为证据。

短时傅里叶变换（Short-Time Fourier Transform, STFT）常把卷积近似为每个频点上的瞬时混合：

$$X_m(f, k) \approx \sum_{n=1}^N A_{mn}(f) S_n(f, k) + V_m(f, k). \quad (8-2)$$

其中  $k$  是帧号， $A_{mn}(f)$  是  $h_{mn}$  在频率  $f$  处的近似频响。写成向量形式为

$\mathbf{X}(f, k) = \mathbf{A}(f)\mathbf{S}(f, k) + \mathbf{V}(f, k)$ ：  $\mathbf{X} \in \mathbb{C}^{M \times 1}$ 、 $\mathbf{A} \in \mathbb{C}^{M \times N}$ 、 $\mathbf{S} \in \mathbb{C}^{N \times 1}$ 、 $\mathbf{V} \in \mathbb{C}^{M \times 1}$ 。

这个窄带近似要求分析窗相对通道冲激响应的有效长度足够长，并且源与通道在窗内变化不快。 $T_{60}$  不能单独给出一个“超过多少就失效”的通用阈值；窗长、早晚期能量分布、帧移和允许误差都会影响近似质量。

远场平面波条件下， $\mathbf{A}$  的每一列对应一个导向矢量 (steering vector)，表示给定方向在各麦克风上的相位差：

$$\mathbf{a}(f, \theta) = [1, e^{+j2\pi f d \sin \theta / c}, e^{+j2\pi f 2d \sin \theta / c}, \dots, e^{+j2\pi f (M-1)d \sin \theta / c}]^\top$$

例如麦间距  $d = 4\text{ cm}$ 、声速  $c = 343\text{ m/s}$ 、目标方向  $\theta = 30^\circ$ 。按第 5 章约定，麦 1 在左端，正角声源位于  $+x$  一侧， $\tau_{21} = t_2 - t_1 = -d \sin \theta / c \approx -58.3\text{ }\mu\text{s}$ 。在  $f = 2\text{ kHz}$  时，相位差的绝对值为  $2\pi f |\tau_{21}| \approx 0.733\text{ rad}$ ，即约  $42^\circ$ ；以麦 1 为参考的 4 麦导向矢量约为  $[1, e^{+j42^\circ}, e^{+j84^\circ}, e^{+j126^\circ}]^\top$ 。

频率升到  $4\text{ kHz}$  时，相位差绝对值增至约  $84^\circ$ 。 $2\text{ kHz}$  的波长约  $17\text{ cm}$ ， $4\text{ cm}$  间距小于半波长； $8\text{ kHz}$  的波长约  $4.3\text{ cm}$ ，此间距会产生空间混叠和栅瓣。

最小方差无失真响应 (Minimum Variance Distortionless Response, MVDR) 和广义特征值 (Generalized Eigenvalue, GEV) 波束形成直接使用空间协方差矩阵 (Spatial Covariance Matrix, SCM)；MNMF 也以源相关的 SCM 描述传播。观测 SCM 可写成

$$\mathbf{R}(f, k) = E[\mathbf{X}\mathbf{X}^H] \approx \mathbf{A}\mathbf{R}_s\mathbf{A}^H + \mathbf{R}_v。$$

复角中心高斯混合模型 (Complex Angular Central Gaussian Mixture Model, cACGMM) 先把每个观测归一化到复单位球面，拟合只描述方向分布的形状矩阵。它不把未归一化的观测功率 SCM 直接当作概率密度。

GSS 和部分深度方法先由 cACGMM 或网络估计时频掩码，再用原始  $\mathbf{X}\mathbf{X}^H$  加权计算目标与干扰 SCM，做法见 § 5.4。

波束形成一次输出通常针对一个目标，但可以用不同导向或掩码构造多组权重，分别输出多个人的信号。因此“波束形成”和“语音分离”不是互斥方法：GSS 正是先估掩码，再为每个目标计算一组波束权重。下面按解混矩阵、空间聚类 and 监督学习三条路线比较。

| 路线           | 代表                                                                                             | 思想                                                         | 局限                |
|--------------|------------------------------------------------------------------------------------------------|------------------------------------------------------------|-------------------|
| 经典盲源分离 (BSS) | 独立成分分析<br>(Independent Component Analysis, ICA) / 独立向量分析<br>(Independent Vector Analysis, IVA) | 假设各说话人统计独立，找一组解混矩阵让输出互相独立；IVA 用“同一声源跨频点相关”解决逐频点排列混乱 (置换问题) | 需要源数不多于麦克风数、对混响敏感 |

| 路线          | 代表                                                                                                                                                   | 思想               | 局限                                                            |
|-------------|------------------------------------------------------------------------------------------------------------------------------------------------------|------------------|---------------------------------------------------------------|
| 空间混合模型（免训练） | cACGMM $\rightarrow$ GSS                                                                                                                             | 见下文展开            | 依赖较长的上下文，计算量随通道数、源数、时频点数和迭代次数增加；GPU 并行化的适用边界见本节“GSS 的源数与计算规模” |
| 深度学习分离      | 时频掩码估计、深度聚类（deep clustering：把每个时频点映射成嵌入向量再按说话人聚类）、置换不变训练（Permutation Invariant Training, PIT：对输出与参考说话人的所有对应关系分别计算损失，取最小者反向传播）、Conv-TasNet（全卷积时域分离网络） | 直接学习从混合信号到各声源的映射 | 依赖训练数据，跨场景泛化需验证                                               |

置换不变训练（Permutation Invariant Training, PIT）在所有输出一参考排列中选择总损失最小者。对  $N$  个输出，其定义为

$$\mathcal{L}_{\text{PIT}} = \min_{\pi \in \mathcal{S}_N} \sum_{n=1}^N \mathcal{L}(\hat{s}_n, s_{\pi(n)}), \tag{8-3}$$

其中  $\mathcal{S}_N$  是  $N$  个对象的排列集合。

PIT 的  $2 \times 2$  手算例。分离器输出为  $\hat{s}_1, \hat{s}_2$ ，参考为  $s_1, s_2$ 。假设某种失真损失的矩阵为

$$\mathbf{L} = \begin{bmatrix} L(\hat{s}_1, s_1) & L(\hat{s}_1, s_2) \\ L(\hat{s}_2, s_1) & L(\hat{s}_2, s_2) \end{bmatrix} = \begin{bmatrix} 0.4 & 3.1 \\ 2.8 & 0.6 \end{bmatrix}.$$

保持对应关系时总损失是  $0.4 + 0.6 = 1.0$ ；交换参考时是  $3.1 + 2.8 = 5.9$ ，所以本次更新使用前一种对应关系。

这个例子说明 PIT 解决的是“输出槽位没有固定说话人标签”，并不自动解决未知人数或跨长录音的身份保持。逐帧独立选择排列会让同一输出在相邻帧换人；整句级置换不变训练（utterance-level PIT, uPIT）在整句上只选一次排列，可减少这种帧间交换。

只有当总目标确实分解成式(8-3)这种“每个输出一参考对各贡献一个代价，再把所选代价相加”的形式时，才能把  $N \times N$  成对损失矩阵交给线性指派算法求最小总代价。若损失含有跨输出耦合项、集合级正则项或共同解码约束，就不能直接用匈牙利算法代替全排列目标。[PIT 正式论文](#)、[uPIT 正式论文](#)。

教学函数 `pit_permutation()` 为了让读者直接核对每种排列，采用全排列枚举并把源数上限设为 8；其计算量随  $N!$  增长。超过 8 个源时，该函数明确拒绝运行。若目标确实满足上一段的成对可加条件，应改用线性指派求解器，而不是放宽枚举上限。

## 8.2 处理模块的顺序

回声、混响和多说话人混合对应不同的信号模型。以下顺序由参考可用性、空间相位保持和统计量依赖关系决定，接口定义见 § 10.1。

一种较完整的音频主链见[第 10 章 § 10.1](#)：采集 → AEC → WPE → 解析波束形成 → 单通道增强。定位/追踪、说话人分割/GSS/SCM 是为解析波束提供条件的支路；神经或 CSS 分离则是从多通道特征到单通道/多流输出的替代音频路径，不与 GSS 掩码或解析波束合并成一个黑箱。项目只启用满足输入条件且能改善目标指标的模块。

1. 启用声学回声消除（Acoustic Echo Cancellation, AEC）时先处理回声：回声参考与麦克风回声之间的线性关系可能被后续自适应波束、非线性增益或单通道增强改变，见[第 10 章 § 10.1](#)；
2. 多通道 WPE 通常在波束之前：晚期混响会污染波束形成所需的协方差估计。WPE 是线性处理，但各通道的预测滤波器不同，不能笼统保证所有跨通道相位关系完全不变。应验证处理后的目标相对传递函数和协方差是否仍适用于后续波束；
3. 导向或掩码给解析波束提供目标统计量：DSB 和导向型 MVDR 可由定位/追踪提供方向或相对传递函数；掩码 MVDR 可从目标 SCM 提取相对传递函数，GEV 则直接由目标/干扰 SCM 求广义特征向量，二者都不必先得到显式 DOA。定位仍可作为稳定的方向先验或控制支路（见[第 5 章](#)与[第 9 章](#)）；
4. diarization 在 GSS 聚类之前、掩码在 MVDR 之前：diarization 提供“谁在何时说话”的标注，用于约束 cACGMM 的跨频点置换；掩码随后用于估计目标和噪声协方差，再计算波束权重（见 § 5.4 和 § 8.4）；
5. DNN 的位置由输出决定：逐通道改写复谱或波形的网络可能破坏跨通道相位，通常放在波束形成后的单通道链路；只输出共享掩码、协方差或 WPE 功率先验的网络可以放在多通道算法内部；联合多通道网络则可能同时完成分离和波束形成。还要单独检查网络是否使用未来帧。

对于“逐通道线性前端—波束形成—单通道增强”这类实现，逐通道处理通常位于前端，单通道增强位于波束形成之后。若神经网络只估计解析算法所需的统计量，或本身联合建模多通道相位，则不受这个顺序限制。

AEC 与降噪的顺序也不是脱离统计假设的固定结论。[Integrated\\_AEC\\_NR 固定实现](#)同时提供 AEC→NR、NR→AEC 与联合扩展结构，适合在相同输入下比较顺序；但其 `process.m` 用干净期望语音和干净回声产生预言活动判决。把结论移到实际设备前，必须改用可取得的活动估计，并重新测试参考相关、非平稳噪声、双讲和路径变化。

本章模块与图 23 的对应关系（图的信号取点与启用条件见第 10 章 § 10.1）：

| 本章模块                                                                                                         | 图 23 中的位置                                              | 作用                                                                |
|--------------------------------------------------------------------------------------------------------------|--------------------------------------------------------|-------------------------------------------------------------------|
| diarization / GSS                                                                                            | “说话人分割 → GSS/cACGMM 掩码”支路                              | diarization 约束活动时间与跨频点置换；它不直接输出 SCM 或音频                           |
| 目标/干扰 SCM 与解析波束                                                                                              | “GSS 掩码 + 同阶段 WPE 输出未方向归一 STFT → SCM → DSB/MVDR/GEV”支路 | 掩码只给权重，SCM 仍由 $\mathbf{Y}\mathbf{Y}^H$ 加权计算；不能改用单位向量 $\mathbf{z}$ |
| 神经分离 / CSS                                                                                                   | WPE 后的替代音频路径，可绕过解析波束后接单通道增强                            | 是否输出固定多流、使用未来上下文和跨块排列，都要单独说明                                      |
| DNN 后滤波 / DNN 后端                                                                                             | 波束形成或分离后的单通道增强或后端                                      | 独立改写复谱的网络通常放在多通道 WPE/MVDR 之后，以免破坏空间相位                             |
| 降噪（Noise Suppression, NS） / 自动增益控制（Automatic Gain Control, AGC） / 语音活动检测（VAD） / 关键词检出（Keyword Spotting, KWS） | 单通道增强与可选 KWS 旁路；VAD 属控制面                               | 各模块按目标任务启用，不在本章展开                                                 |

回声、混响和分离使用不同的参考与统计假设，模块顺序需要服从这些条件。下一章讨论如何把逐帧定位结果连接成连续轨迹。

### 8.3 经典盲源分离：AuxIVA、ILRMA、MNMF 与 TRINICON

以下按模型假设、计算代价和失效条件比较四类 BSS 方法。



AuxIVA（辅助函数型独立向量分析，Auxiliary-function IVA，Ono 2011）。它假设不同说话人统计独立，并联合建模同一说话人在各频点的分量。频域 ICA 在各频点独立求解，可能得到不同的输出排列；IVA 利用跨频点包络相关性缓解该置换问题。AuxIVA 使用辅助函数进行闭式更新，不需要设置梯度步长，目标函数在理论条件下单调下降。

标准实现仍是整段迭代，在线版本需要递推改写；强混响、说话人包络高度相关和短语音都会削弱统计独立性或估计稳定性。它常作为免训练分离基线。

ILRMA（独立低秩矩阵分析，Independent Low-rank Matrix Analysis）。ILRMA 在独立性假设之外，再用非负矩阵分解（Nonnegative Matrix Factorization，NMF）表示每个源的低秩功率谱，并联合优化解混矩阵与谱模型。它增加了基数、迭代次数等超参数，计算量和初始化敏感性也高于 AuxIVA。复杂音乐、重叠笑声和强混响可能不满足低秩或独立性假设，需用目标数据验证。

MNMF（多通道 NMF，Multichannel NMF）。MNMF 同样使用低秩源谱模型，但以满秩空间协方差描述传播，不要求方阵解混矩阵可逆，因此可以表示欠定混合。谱基、激活和空间协方差需要联合做最大似然估计，参数较多、迭代较慢且对初值敏感。实践中可用 AuxIVA 或 ILRMA 结果初始化。其计算量通常更适合离线分析或伪标签生成。

TRINICON（三重 N 卷积混合盲分离，TRiple-N ICA for CONvolute mixtures）直接优化时域解混滤波器，用二阶去相关和高阶独立性处理卷积混合，因此不依赖逐频点瞬时混合近似。代价是滤波器与统计窗口较长、优化量大，声源或房间变化时还要重新适应。滤波器长度决定能表示多长的卷积逆，但不等于端到端延迟：因果 FIR 可逐样本输出，块实现的额外等待由分块、缓冲、FFT 和是否使用未来样本决定。

AuxIVA 适合确定混合的免训练基线；ILRMA 进一步利用源谱低秩结构；MNMF 用满秩空间协方差表示欠定混合；TRINICON 直接处理时域卷积混合。选择时需同时检查源数与麦克风数、混响强度、数据长度和实时预算。

BSS 的排列与尺度歧义。若  $\mathbf{W}(f)$  能把混合信号分开，交换  $\mathbf{W}$  的两行只会交换两个输出；把某一行乘非零复数，也不会破坏输出间的统计独立性。因此 BSS 只能在排列和复尺度因子意义下恢复声源。IVA、ILRMA 用跨频点结构缓解频点间排列错乱，但仍要固定输出尺度。方阵情形可令  $\hat{\mathbf{A}}(f) = \mathbf{W}^{-1}(f)$ ，选参考麦克风  $r$ ，再做

$$\tilde{Y}_n(f, k) = \hat{A}_{rn}(f) Y_n(f, k).$$

这一步称为回投影（projection back）：它把第  $n$  个分离输出恢复到参考通道上的幅度和相位尺度。回投影不能修复分离错误，也不能保证不同时间块中的说话人编号一致；连续录音仍要做跨块排列对齐。

两频点的排列小例。假设每个频点已经各自分出槽位 1、槽位 2 两路，但槽位编号在不同频点之间没有说话人身份含义。取两帧，频点  $f_1$  的槽位 1、2 幅度序列分别为  $[2, 0.5]$ 、 $[0.5, 2]$ ；频点  $f_2$  也出现这两条序列。这里的数字是人为给出的非负幅度，不是语音录音或 AuxIVA 的运行输出。

用一个说明跨频点耦合的球对称源先验作检查：设两频点的联合复谱向量满足示意密度  $p(\vec{y}) \propto \exp(-\|\vec{y}\|_2)$ ，其负对数中与排列有关的部分就是范数。把候选的同一路输出在一帧的两频点组成  $\vec{y}_n(k)$ ，计算局部代价  $C = \sum_{k=1}^2 \sum_{n=1}^2 \|\vec{y}_n(k)\|_2$ 。这项代价只用候选输出自身，不读取说话人身份或干净参考。

两频点保持槽位 1 对 1、2 对 2 时，每帧的两个范数是  $\sqrt{2^2 + 2^2} = 2\sqrt{2}$  与  $\sqrt{0.5^2 + 0.5^2} = 1/\sqrt{2}$ ，两帧合计  $C = 5\sqrt{2} \approx 7.071$ 。

若只交换  $f_2$  的两个槽位，每帧两路都变成  $[2, 0.5]$  或  $[0.5, 2]$ ，各有范数  $\sqrt{4.25}$ ；合计  $C = 4\sqrt{4.25} \approx 8.246$ 。因此这个选定的联合代价偏好前一种跨频点排列。对固定的逐频解混矩阵做行交换不会改变行列式的绝对值，所以在这种只比较排列的演示中，其行列式项也不能区分两种方案。

完整 AuxIVA 也不能预先拿到这两条已分离的幅度序列；它要从混合复谱迭代估计逐频解混矩阵，并同时处理复尺度、初始化和局部最优。两人的跨频包络若高度相似，本例的差异可能消失。该数例只展示 IVA 利用跨频点结构缓解排列歧义的一个机制，不是一次 AuxIVA 参数更新或分离性能实验。[AuxIVA 原始论文](#)给出完整辅助函数更新。

BSS 方法的规模例子。以下计算用于说明参数量和迭代规模；性能数字必须以各论文的测试集和评测脚本为准。

AuxIVA 的规模例子：2 源 2 麦、8 kHz、3 s 语音，STFT 取 256 点窗和 64 点帧移。名义帧率为  $8000/64 = 125$  帧/s，3 s 约为 375 帧。

若不补零、从首样本开始取完整窗，精确帧数是  $\lfloor (24000 - 256)/64 \rfloor + 1 = 372$ 。非负频点数为  $256/2 + 1 = 129$ ；每个频点维护一个  $2 \times 2$  解混矩阵，所以参数数目为  $129 \times 2 \times 2 = 516$  个复数。

辅助函数迭代不需要学习率。帧数还取决于是否居中、边界补零和丢弃尾部不完整窗。算法见 [AuxIVA 原始论文](#) (Ono, WASPAA 2011, pp. 189 – 192；公开实现见 [piva](#))。

ILRMA 在同一 2 源 2 麦例子中，还要为每个源维护 NMF 基矩阵和激活矩阵。若每源取 2 个基，沿用上述不补零的 372 帧，则矩阵尺寸分别为  $129 \times 2$  和  $2 \times 372$ ，并与解混矩阵交替更新。

基数、迭代次数和初值都会影响计算量与结果。语音与音乐是否满足同样的低秩假设，需要分别验证。见 [ILRMA 原始论文](#) (Kitamura et al., IEEE/ACM TASLP 24(9), 2016, pp. 1626 – 1641)。

MNMF 可以表示 3 个说话人、2 个麦克风的欠定混合。每个频点、每个源对应一个  $2 \times 2$  Hermitian 空间协方差；129 个频点和 3 个源共需  $129 \times 3 = 387$  个协方差矩阵，还要联合估计谱基和激活。

计算量和局部最优问题使初始化十分重要，AuxIVA 或 ILRMA 结果可作为初值。见 [MNMF 原始论文](#) (Sawada et al., IEEE TASP 21(5), 2013, pp. 971 – 982)。

TRINICON 的长度换算可以这样看：8 kHz 下，0.5 s 对应  $8000 \times 0.5 = 4000$  个采样，但这不表示解混滤波器必须取 4000 点，也不表示算法延迟就是 0.5 s。实际长度是在可表示的卷积范围、估计方差、计算量和块实现之间折中。

例如 1024 点与 2048 点分别覆盖  $1024/8000 = 128$  ms 和  $2048/8000 = 256$  ms 的滤波器记忆；系统仍要单独报告块大小、帧移、前视和输入输出缓冲，才能得到算法延迟。见 [TRINICON 原始论文](#) (Buchner et al., 2005)。

## 8.4 GSS：活动导引、空间聚类与波束形成

### 8.4.1 输入、空间模型与完整处理链

GSS（导引源分离，guided source separation）在 CHiME-5/6 的真实晚宴多通道任务中得到广泛使用 (Boeddeker et al., CHiME-5 2018；CHiME-8 任务设置已经变化，引用时应按当届规则)。先说明原论文的活动标注来源，再写聚类与波束的依赖关系：

1. cACGMM 空间聚类：记 WPE 输出、尚未做方向归一化的多通道 STFT 为  $\mathbf{Y}(f, k)$ 。先剔除  $\|\mathbf{Y}(f, k)\|_2 \leq \varepsilon_E$  的低能量点，再对保留点严格归一化为  $\mathbf{z} = \mathbf{Y}/\|\mathbf{Y}\|_2$ ，主要保留通道间的复数比例。第  $n$  个分量的密度满足

$$p(\mathbf{z} | \mathbf{B}_n) \propto \frac{1}{\det(\mathbf{B}_n)} (\mathbf{z}^H \mathbf{B}_n^{-1} \mathbf{z})^{-M}, \quad \|\mathbf{z}\|_2 = 1. \quad (8-4)$$

其中  $\mathbf{B}_n$  是正定的形状矩阵。cAC 密度对  $\mathbf{B}_n$  的正比例缩放不变，所以每次更新后必须固定尺度，例如令  $\text{tr}(\mathbf{B}_n) = M$ 。式(8-4)建模的是归一化方向  $\mathbf{z}$  的密度，不是  $\mathbf{Y}$  的功率 SCM。

混合模型的后验概率  $\gamma_n(f, k)$  用作软时频掩码。“免训练”只表示聚类参数在当前录音上用期望最大化 (Expectation-Maximization, EM) 估计，不需要预先训练分离网络；完整系统仍需活动标注。

2. 导引 (Guided) : 各频点独立聚类会产生簇标签置换。GSS 使用说话人活动时间标注限制每个说话人可出现的帧, 从而减少不同频点的簇标签置换。Boeddeker 等的 CHiME-5 2018 原实验使用挑战组织者提供的说话人时间标注; 部署时若改用自动说话人分割 (diarization) 输出, 其漏标和错标必须作为新误差来源测试。原系统还增加一个始终允许活动的背景噪声分量, 使所有说话人静音时仍有可归一化的分量;
3. 级联: WPE 去混响  $\rightarrow$  GSS 得到掩码  $\rightarrow$  掩码估计目标/非目标协方差  $\rightarrow$  MVDR/GEV 波束形成。MVDR 是最小方差无失真响应, GEV 是广义特征值波束形成, 见 § 5.4。GSS 论文在 CHiME-5 的特定阵列、赛方时间标注和开发集上报告了识别结果; 引用数字时必须同时给出原文表号、阵列配置、标注来源、打分集和基线, 不能把它当成自动 diarization 的整链成绩。GSS 原始论文 § 3.2、式(5)~(8)和表1~2

#### 8.4.2 活动约束下的 EM 迭代

紧凑实现顺序。下面的伪代码强调依赖关系, 不替代具体实现中的复数矩阵更新式。

1. 从 WPE 输出  $\mathbf{Y}$  中剔除  $\|\mathbf{Y}\|_2 \leq \varepsilon_E$  的点; 对其余点计算严格单位向量  $\mathbf{z} = \mathbf{Y}/\|\mathbf{Y}\|_2$ 。给  $J$  位说话人各设一个分量, 并增加背景噪声分量  $j = 0$ ; 说话人的活动指示  $a_j(k)$  由时间标注给出, 噪声始终取  $a_0(k) = 1$ 。活动标注约束混合权重,  $\mathbf{B}_j$  另用单位阵或空间统计量初始化, 不能把活动标注当作形状矩阵。
2. E 步对保留的时频点先计算非负分数  $q_j(f, k) = a_j(k)\pi_j(f)p(\mathbf{z}(f, k) | \mathbf{B}_j(f))$ , 再令  $\gamma_j(f, k) = q_j(f, k) / \sum_{\ell=0}^J q_\ell(f, k)$ 。这里  $\pi_j$  为混合权重; 若噪声权重和密度为正, 即使所有说话人都静音, 分母仍为正, 此时频点的噪声后验为 1。实际实现宜在对数域计算, 并明确处理非有限值; 若去掉噪声分量, 全员静音时分母为零, 不能强行归一化。
3. M 步按 cACG 的固定点更新形状矩阵: 每个  $\mathbf{z}\mathbf{z}^H$  外积除以当前二次型  $\mathbf{z}^H \mathbf{B}_j^{-1} \mathbf{z}$ , 再用  $\gamma_j$  加权求和。对更新矩阵施加保持正定的正则化后, 固定尺度, 例如令  $\text{tr}(\mathbf{B}_j) = M$ 。有效权重接近零或条件数过大时, 重置该分量, 不能继续求逆。
4. 重复 E/M 步, 直到对数似然相对变化小于预设阈值, 或达到最大迭代次数; 报告实际迭代数、停止条件和重置次数。
5. 将后验作为掩码, 但用同一 WPE 阶段、未做方向归一化的  $\mathbf{Y}\mathbf{Y}^H$  按式(8-5)估计目标/非目标 SCM, 再计算每个目标的 MVDR 或 GEV 权重。对于一个目标, 非目标掩码包含其余说话人与背景噪声; 这里不能把单位向量  $\mathbf{z}$  的外积误当成带功率信息的 SCM。



### 8.4.3 活动门控手算与错误标注反例

活动门控的最小算例：只看一个频点的相邻两帧，并按“说话人 1、说话人 2、背景噪声”排列。假设混合权重为  $[0.5, 0.3, 0.2]$ ，三个分量在这两帧观测上的相对密度都为  $[2, 1, 1]$ 。第一帧的活动指示为  $[1, 0, 1]$ ，E 步的未归一化分数为  $[1, 0, 0.2]$ ，总和为 1.2，后验为  $[5/6, 0, 1/6]$ 。第二帧两位说话人都静音，活动指示为  $[0, 0, 1]$ ，分数为  $[0, 0, 0.2]$ ，后验为  $[0, 0, 1]$ 。

这些密度是题目给定的相对数值，只检验 E 步归一化；它们不是从录音拟合出的 cACG 密度，也不构成分离性能实验。完整手算及代码见练习 E08-07。

活动错误的三帧反例。再固定  $\pi = [0.4, 0.4, 0.2]$ ，顺序仍为“说话人 1、说话人 2、背景噪声”。三帧的相对空间密度依次是  $[8, 1, 1]$ 、 $[1, 8, 1]$ 、 $[1, 1, 1]$ ；真实说话人活动依次是“仅说话人 1、仅说话人 2、两人都静音”。正确标注下，首帧说话人 1 的分数为  $0.4 \times 8 = 3.2$ ，背景分数为 0.2，故其后验为  $3.2/(3.2 + 0.2) = 16/17 \approx 0.9412$ 。

若漏标首帧的说话人 1，门控会把其后验强制置零，无论该分量的固定空间密度多高。若把第三帧的说话人 1 错标为活动，其后验会从 0 变成  $0.4/(0.4 + 0.2) = 2/3$ ，本应占 1 的背景后验变为  $1/3$ 。

这组数字由 [gss\\_activity\\_error\\_demo.py](#) 和独立分数测试复算，只描述固定密度、固定权重时的 E 步。完整 GSS 还会让错误活动参与参数更新，并经 SCM、波束形成影响音频；上述后验变化不能直接换算成 SI-SDR 或 WER 的变化。原论文的活动门控见 [Boeddeker 等 § 3.2、式\(5\)~\(8\)](#)。

活动标注只限制允许的簇，不会自动修复错误分割。如果目标说话人在所选片段内始终活动，目标与恒活动噪声类仍可能交换标签；原论文通过扩展目标片段前后的上下文，让目标类出现静音帧来降低这种置换风险，不能保证完全消除。短活动段、空分量或近奇异形状矩阵还需要正则化和失败检测。[原始论文 § 3.2、图 3、式\(5\)~\(8\)](#)

### 8.4.4 协方差、波束权重与适用边界

GSS 的源数与计算规模：输入通常是一段包含重叠语音的会议录音。cACGMM 的分量数通常由日志或系统配置预先给定；它不会仅凭式(8-4)可靠推断未知说话人数。

$M \geq 2$  才有跨通道方向信息。当  $N \leq M$  时，掩码波束形成通常还有空间自由度；当  $N > M$  时，仍可为每个已知目标估计掩码和 SCM，但分离依赖时频占优、活动标注与数据量，不能获得方阵解混的可逆性保证。

WPE 先减弱晚期混响；cACGMM 在目标段附近的上下文上做 EM 聚类，为每个时频点输出说话人后验掩码；目标和非目标掩码分别用于估计 SCM，再计算 MVDR 或 GEV 权重。



上下文长度和 EM 迭代次数会共同影响估计方差、延迟与计算量。GPU 并行化的收益必须绑定硬件、数据、代码版本和计时范围，不能作为跨实现的通用加速倍数。

以 16 kHz 采样、512 点窗、128 点帧移为例，每秒有 125 帧，30 s 上下文含 3750 帧和 257 个非负频点，约 96 万个时频点。这个换算只给出待处理样本数，不能保证 EM 在固定次数内收敛。实现应监测对数似然相对变化，并设置最大迭代次数；空分量、近奇异  $\mathbf{B}_n$  和低能量时频点还需要正则化或重置。

掩码换成目标协方差时，用

$$\mathbf{R}_{\text{tar}}(f) = \frac{\sum_k \gamma(f, k) \mathbf{Y}(f, k) \mathbf{Y}^H(f, k)}{\sum_k \gamma(f, k) + \varepsilon}. \quad (8-5)$$

式(8-5)展示分母加正数的稳定化写法；无稳定项且权重和非零时，它是加权平均。教学函数 `masked_spatial_covariance()` 采用另一种明确口径：分母为  $\max(\sum_k \gamma, \varepsilon)$ ，只在权重和低于地板时改变归一化。两种写法不能在极小权重下当成数值相同，练习 E08-05 给出差别；空掩码在教学代码中返回零矩阵，不能解释为可靠的噪声估计。

噪声协方差可用相应的非目标掩码估计。软权重的有效样本数不是“ $\gamma > 0.8$  的帧数”，而可用 Kish 公式近似：

$$N_{\text{eff}}(f) = \frac{(\sum_k \gamma(f, k))^2}{\sum_k \gamma^2(f, k)}.$$

例如 900 帧权重全为 1 时  $N_{\text{eff}} = 900$ ；若权重集中在少数帧，有效样本数会明显更小。

由  $N$  个秩一外积相加得到的  $M \times M$  协方差，其秩至多为  $\min(N, M)$ 。满秩估计至少需要  $M$  个线性独立的非零快照； $N \geq M$  只是必要条件，不是充分条件。Kish  $N_{\text{eff}}$  只是软权重集中程度的近似， $N_{\text{eff}} \geq M$  也不能保证快照张成  $\mathbb{C}^M$ 。

高度相关的连续帧不能当作同等数量的独立空间状态；工程上还应检查矩阵秩或条件数，并在必要时做对角加载。

说话人活动标注用于限制各簇可出现的时间区间，从而减少跨频点置换。见 [cACGMM 原始工作](#) (Ito et al., EUSIPCO 2016, pp. 1153 – 1157) 与 [GSS 原始论文](#)。

掩码到波束权重的小例子。以下实数向量只是 WPE 输出复数 STFT 的简化手算。两个时频快照取  $\mathbf{Y}_1 = [1, 1]^\top$ 、 $\mathbf{Y}_2 = [1, -1]^\top$ ，目标掩码为  $\gamma = [0.9, 0.1]$ 。因为权重和为 1，目标协方差为

$$\mathbf{R}_{\text{tar}} = 0.9 \mathbf{Y}_1 \mathbf{Y}_1^H + 0.1 \mathbf{Y}_2 \mathbf{Y}_2^H = \begin{bmatrix} 1 & 0.8 \\ 0.8 & 1 \end{bmatrix}.$$

若这个二分类例子中用  $1 - \gamma = [0.1, 0.9]$  估计干扰协方差，则  $\mathbf{R}_{\text{int}} = \begin{bmatrix} 1 & -0.8 \\ -0.8 & 1 \end{bmatrix}$ 。正的非对角项表示目标快照中两通道同相成分占优，负的非对角项表示干扰快照中反相成分占优。

随后可从  $\mathbf{R}_{\text{tar}}$  估计目标相对传递函数，并与  $\mathbf{R}_{\text{int}}$  一起计算 MVDR。GEV 则直接求矩阵对  $(\mathbf{R}_{\text{tar}}, \mathbf{R}_{\text{int}})$  的主广义特征向量，并需另做尺度归一化。

真实的“目标 + 多个说话人 + 环境噪声”并非二分类， $1 - \gamma$  会把所有非目标成分合在一起，不能解释成纯噪声掩码。实际实现还要检查有效样本数、条件数和对角加载。[掩码波束形成实例](#)。

定位结果可以给分离提供方向先验；分离网络输出的掩码又能用于估计 MVDR 的目标与干扰协方差。

### 8.4.5 可运行的 cACGMM—SCM—MVDR 受控链

前面的三帧例子只计算固定密度的 E 步。本书另提供原创 NumPy [教学整链](#)：逐频点把两麦复谱严格归一化为单位向量，使用说话人活动和恒活动背景类对复角中心高斯混合模型

(cACGMM) 进行 8 轮 E/M 迭代；各类形状矩阵采用迹归一化与正定加载，空类显式重置。然后用未做方向归一化的原始复谱和后验掩码计算目标/非目标 SCM，最终使用两麦 MVDR 输出目标复谱。

低能量点归入背景；代码同时返回掩码、SCM、权重、低能量点数和重置次数，便于核查每一步。

[固定脚本](#)用种子 20260924 合成 16 kHz、2 s 的两条独立高斯测试波形，并给它们设置已知活动区间。第一路在麦 0 直接到达、麦 1 晚 2 个采样；第二路相反，另加每麦独立均方根约 0.003 的高斯噪声。STFT 窗长 256 点、帧移 128 点，活动按帧中心给出。

这个合成阵列没有房间混响，因此演示时旁路 WPE；代码可显式调用本书的离线 WPE 实现，但本实验没有据此验证 WPE。说话人活动作为外部输入提供，不是从混合录音自动识别。

| 同一目标、同一评分区间 [0.2, 1.45) s | 去均值 SI-SDR (dB) | 说明                  |
|---------------------------|-----------------|---------------------|
| 参考麦 0 的混合输入               | 1.28            | 含另一合成源和独立噪声         |
| 正确活动标注的输出                 | 13.76           | 受控单次合成运行；不代表真实会议录音  |
| 目标活动全部漏标的输出               | 1.28            | 目标后验被门控为零，教学波束后退参考麦 |

这一组数字只说明在给定模型、固定输入和已知活动下，整条教学链能产生可复核音频；不能推断在其他说话人、房间或活动标注上必有 12.48 dB 的改善。

所有说话人静音的帧上，背景后验为 1；错误标注条件下目标后验为 0。正确条件下本次形状矩阵重置次数为 0，后验每点求和与 1 的最大差约为  $2.22 \times 10^{-16}$ 。这些数值可由[独立测试](#)和[完整状态文件](#)复算。

[第一路源](#)、[第二路源](#)、[混合双麦](#)、[正确活动输出](#)及[漏标输出](#)都按同一增益导出，文件摘要和精确参数见[独立清单](#)。这五个 WAV 不并入本书主清单的 60 个样本。

官方 [GPU-GSS 固定源码](#)还包含 CuPy、Lhotse/RTTM、分段上下文及完整会议处理；本机未运行其官方整链，也没有使用 CHiME 语料或计算 WER。本段的教学结果不能充当 Boeddeker 等论文的复现成绩。[GSS 原论文 § 3.1~§ 3.3](#)。

## 8.5 分离指标与数据集口径

常用的尺度不变信号失真比（scale-invariant signal-to-distortion ratio, SI-SDR）把等长实数估计信号  $\hat{s}$  投影到非零参考  $s$  上，再比较投影能量与正交残差能量。采用去均值口径时，应先分别去掉两信号的均值：

$$\alpha = \frac{\langle \hat{s}, s \rangle}{\|s\|^2}, \quad s_{\text{tar}} = \alpha s, \quad (8-6)$$
$$\text{SISDR} = 10 \log_{10} \frac{\|s_{\text{tar}}\|^2}{\|\hat{s} - s_{\text{tar}}\|^2}.$$

投影会把估计中与参考平行的部分全部归入  $s_{\text{tar}}$ ，不能把任何人工加入的“噪声”都直接当作分母。若该噪声含与  $s$  同方向的分量，必须先做投影。该指标不自动消除时间偏移、频率响应差异或跨块换人。[Le Roux et al., ICASSP 2019, § 2.3、式\(3\)~\(5\)](#)。

SI-SDR 提升量（SI-SDRi）是输出 SI-SDR 减去混合输入的 SI-SDR，两项必须使用同一预处理和实现。精确数学中，非零完美估计对应正无穷，非零且与参考正交的估计对应负无穷；零参考或零估计不能给出有效分数。实现通常另设数值边界，必须在报告中说明。

分离指标的最小报告模板：

- 写明目标信号定义（无混响干声、带混响参考或参考麦克风图像）、参考通道、采样率与截断长度；
- 说明是否去均值，以及固定传播时延、算法时延和整体增益怎样对齐；
- 给出活动区间、静音段处理、输出一参考排列规则和输入混合基线；
- 固定指标实现及版本，并对多次随机实验报告种子、次数和离散程度。

若其中任一项不同，SI-SDRi、SI-SNRi 或 WER 数字不能直接横向排名。

数据集口径速查：下表先回答“选择哪个数据集”。它们的录音来源、通道和任务不同，没有可横向排名的统一性能数字。随后逐个列出复现实验必须交代的口径。

| 数据集               | 首要用途             | 录音类型             |
|-------------------|------------------|------------------|
| REVERB            | 去混响与识别           | 仿真混响及另行录制的真实房间语音 |
| CHiME-5 / CHiME-6 | 真实晚宴多说话人识别       | 同一批家庭场景录音的不同数据版本 |
| WHAMR             | 噪声、混响与重叠同时存在时的分离 | 合成混合及房间响应        |
| WSJ0-2mix / 3mix  | 干净两人或三人重叠分离      | 干声合成混合           |
| LibriMix          | 跨语料干净或含噪重叠分离     | 干声或加环境噪声的合成混合    |
| LibriCSS          | 连续会议重叠与长录音识别     | 真实会议室中的扬声器回放录音   |

REVERB。仿真部分的混响时间约分 0.25 / 0.5 / 0.7 s 三档，另有以 MC-WSJ-AV 为基础的真实房间录音；基线语音来自 WSJCAM0。存在 8 通道、2 通道及单通道设置。比较 WPE 时，应同时写通道数、识别器、测试子集，以及 WER 的绝对值或相对变化。

CHiME-5。录音来自真实家庭的厨房、餐厅和客厅，包含自然混响和生活噪声。每场有 6 台 Kinect，每台 4 个同步麦克风；每位参与者还佩戴双耳麦。6 台设备不能缩写成“6 麦阵列”，双耳录音用于辅助转写和时间对齐，不是干净评分参考。[CHiME-5 官方数据说明](#)

CHiME-6。该版本重新对齐了 CHiME-5 的部分录音，必须写明具体版本和划分。总计 32 个物理通道，其中 6 台四麦阵列给出 24 通道，4 套双耳设备给出 8 通道。Track 2 中双耳通道只允许用于同步，不能用于分割、增强或识别；报告 GSS 还须注明实际选用哪些阵列、日志输入、打分集和原论文表号。[CHiME-6 Track 2 官方数据规则](#)

WHAMR。使用合成房间冲激响应， $T_{60}$  的低、中、高混响档分别从 0.1~0.3 s、0.2~0.6 s、0.4~1.0 s 均匀采样；这三档表示混响程度，不表示房间大小。

数据以 WSJ0-2mix 加 WHAM 噪声为基础，提供 8 kHz / 16 kHz、min（截短对齐）/ max（全长）版本。报告时写清源数、目标是无混响还是带混响语音，以及 SI-SDRi 实现。[WHAMR 正式论文 §2 与表 1](#)

WSJ0-2mix / 3mix。近场干声直接叠加，无另加噪声或混响。具有 8 kHz / 16 kHz、min（按最短源截断）/ max（全长补零）版本，常用划分为 30 小时训练、10 小时验证、5 小时测试。引用时写清源数、静态还是动态混合、min/max 和指标实现。

LibriMix。clean 版无额外污染，noisy 版叠加 WHAM 环境噪声；提供 8 kHz / 16 kHz、train-100/train-360、min/max 等版本。SparseLibriMix 是另行发布的稀疏重叠测试集。跨语料实验须同时注明训练集、测试集、噪声版本及是否使用 SparseLibriMix。[LibriMix 论文](#)与[官方生成仓库](#)

LibriCSS。将 LibriSpeech 语音从扬声器在真实会议室回放，用 7 通道圆阵列录制。共 10 个约 1 h 会话，每个分为 6 个约 10 min 小会话；0S、0L、10%、20%、30%、40% 表示不同重叠条件，0S 与 0L 虽都无重叠，句间静音长度却不同。报告连续分离或识别时须写明条件、分块、跨块排列、输出流数和说话人分配规则。[LibriCSS 正式论文](#)

REVERB 主要用于去混响与识别，CHiME-5/6 用于真实重叠语音的分离与识别，WHAMR 同时包含噪声、混响和重叠，WSJ0-2mix/3mix 是干净混合基准，LibriMix 还可检查跨数据集泛化，LibriCSS 则把问题扩展到连续会议。CHiME-6 重新对齐了 CHiME-5 的部分录音，引用结果时不能把两个版本混为同一数据版本。[CHiME-6 官方说明](#)。不同数据集的数字不能直接比较。

## 8.6 连续语音分离与深度模型

---

连续语音分离（Continuous Speech Separation, CSS）不能把整句分离器机械地逐块调用。长录音中的活动人数会变化，同一输出槽位还可能在相邻块交换说话人。

实现需明确四件事：

1. 每块使用多少左、右上下文；
2. 重叠块怎样加权拼接；
3. 跨块排列依据声纹、波形相关性还是联合优化；
4. 输出流数固定还是随活动人数变化。

连续识别的指标也要写清分配规则。连接最小排列词错误率（Concatenated Minimum-Permutation WER, cpWER）、最优参考组合词错误率（Optimal Reference Combination WER, ORC-WER）和说话人归属词错误率（Speaker-Attributed WER, sa-WER）处理说话人对应的方式不同，不能只写“WER”。

CSS 解决长录音的分块与输出一致性，不保证身份永久不交换；需要稳定身份时还要结合分割或说话人跟踪。



VarArray 的正式论文发表于 ICASSP 2022 (pp. 6027 – 6031, DOI [10.1109/ICASSP43922.2022.9746876](https://doi.org/10.1109/ICASSP43922.2022.9746876))，通过通道置换/数量不变的聚合结构适配不同麦克风数量和论文评测中的多种同步阵列几何。“阵列几何无关”不表示对任意未见孔径、异步时钟、通道失配或设备频响都有保证；这些条件仍需在目标设备上验证。

**时频稀疏性与掩码：**在某些语音混合中，同一时频点往往由一个声源占优，文献将这种近似称为 W-不重叠正交性 (W-disjoint orthogonality, WDO)。掩码方法可以据此估计每个时频点属于各声源的权重。说话人在同一时频区域强烈重叠时，WDO 近似变差。波束形成的区别不是“对整个频带统一加权”：宽带 STFT 波束形成通常在每个频点使用一组复权重，利用通道间的幅度和相位关系做空间选择。

**深度分离的几类结构。**下表只比较建模方式。原论文的指标、数据生成和评测代码并不完全相同，不在表中按单个 dB 数排名。

| 结构     | 代表                                  | 主要结构                                                                                 | 结果复现要求                        | 优点与限制                                                  |
|--------|-------------------------------------|--------------------------------------------------------------------------------------|-------------------------------|--------------------------------------------------------|
| 时域卷积   | Conv-TasNet (Luo & Mesgarani, 2019) | 可学习的短窗编码器代替 STFT，时序卷积网络 (Temporal Convolutional Network, TCN) 的空洞卷积建模长上下文，再对编码系数施加掩码 | 核对数据版本、采样率、因果设置和 SI-SNRi 实现   | 端到端延迟取决于编码窗、感受野和缓冲。见 <a href="#">Conv-TasNet 正式论文</a>  |
| 双路径循环  | DPRNN (Luo et al., 2020)            | 长序列分块，块内 RNN 建模局部，块间 RNN 建模较长时间关系                                                    | 核对模型规模、块长、静态/动态混合和 SI-SNRi 实现 | RNN 顺序计算会限制并行度，块长影响内存与上下文。见 <a href="#">DPRNN 正式论文</a> |
| 双路径注意力 | SepFormer (Subakan et al., 2021)    | 在双路径结构中用 Transformer 替换 RNN                                                          | 核对源数、数据生成、模型版本和 SI-SNRi 实现    | 注意力内存随序列长度增长，长句通常需分块。见 <a href="#">SepFormer 正式论文</a>  |

| 结构        | 代表                                  | 主要结构                                                                 | 结果复现要求                                                            | 优点与限制                                                                                                              |
|-----------|-------------------------------------|----------------------------------------------------------------------|-------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------|
| 状态空间      | S4M (Chen et al., 2023)             | 用多尺度编码和结构化状态空间块替换分离骨干中的循环或注意力时序建模                                    | 原文使用固定两源的 WSJ0-2Mix、LibriMix 与 LRS2-Mix; 核对 8/16 kHz 数据版本、源数和官方配置 | 状态递推提供长程建模的另一种实现, 但原论文未验证严格因果的前瞻量与端到端延迟。见 <a href="#">Interspeech 2023 正式论文</a> 与 <a href="#">官方复现仓库</a>           |
| 时频网格      | TF-GridNet (Wang et al., 2023)      | 在时频域分别建模时间、频率与跨帧关系, 并结合子带长短期记忆网络 (Long Short-Term Memory, LSTM) 和注意力 | 会议版是单通道分离, 原文主表使用 SI-SDRi; 多通道混响扩展是另一模型与实验设置                      | 整句注意力需要改造后才能流式运行。见 <a href="#">单通道会议正式论文</a> 与 <a href="#">多通道混响期刊扩展</a>                                           |
| 长时多通道因果网络 | Online SpatialNet (Quan & Li, 2024) | 用在线掩码注意力、Retention 或 Mamba 沿时间建模, 同时保留多通道空间特征                        | 核对静止/移动源、麦数、训练配置、CUDA/Mamba 依赖和跨调用状态接口                            | 源码附有固定配置的因果前缀自测, 但顶层 <code>forward()</code> 不暴露跨调用状态, 不能直接推定任意块续算等价。见 <a href="#">论文预印本</a> 与 <a href="#">固定源码</a> |

比较分离数字时要对齐采样率、`min / max` 混合方式、静态或动态混合、源数、评测脚本和指标名称。分离文献中的 SI-SNR 常采用与 SI-SDR 相同的正交投影公式, 二者在相同去均值与数值实现下可以相等; 也有代码把均值处理、截断长度或稳定项写得不同。不能笼统地说两者固定相差若干 dB。引用 SI-SNRi 或 SI-SDRi 时, 应给出实现或至少说明是否去均值, 并始终用同一指标计算输入基线和输出结果。

深度分离的结构选择。卷积、循环网络、注意力和状态空间模型都可以作为分离骨干。S4M 改变的是编码器—分离器—解码器中的时序建模骨干: 多尺度表示送入结构化状态空间块, 而不是仅更换损失函数。

论文实验使用已知的两个输出源和监督干净参考。核实至 2026-09-22，官方仓库提供 `S4M.py`、`s4.py` 等模型结构文件，但没有完整的数据准备、训练入口和配套 checkpoint，不能把可读的骨干代码写成已经可复现整套训练。未知源数、无监督会议录音或任意麦克风阵列不属于这项结果的直接覆盖范围。论文把该结构称为流式分离的潜在方案，但没有报告严格因果实现的前瞻样本数、首帧延迟或端到端延迟。[S4M 固定版本](#)

部署前仍需检查双向上下文与缓冲。选择时不要只看单个榜单分数，还要检查模型是否使用整句上下文、块边界如何处理、状态能否在流式推理中延续，以及计算量和内存怎样随语句长度变化。生成式方法还要检查采样步数和语音幻觉。

因果性也不能替代状态接口检查。Online SpatialNet 的固定源码末尾写有“前 1000 帧输入”和“同一输入再附加 24 帧”的前缀一致性自测，但本书当前环境没有 PyTorch、Mamba 与 CUDA，未实际运行这项检查。顶层 `forward()` 调用子层时传入 `state=None`，没有把卷积或 Retention 状态作为顶层输入输出返回；所以即使固定配置的前缀自测通过，也只能说明该次整段计算没有读取未来帧，不能说明应用把录音任意切块并分别调用时会得到相同结果。部署测试要另做整段、跨块保留状态和逐块重置三路比较。[NBSS 固定版本](#)

近期模型若没有在相同数据、采样率、混合方式和评测脚本下比较，本章不按论文年份或模型名称给出性能排序。

目标说话人提取（target speaker extraction, TSE）不要求输出所有声源，而是用注册语音、视觉或方向等与目标说话人绑定的条件提取一条音轨。声纹网络可把注册语音变成定长嵌入，再将其广播到混合语音的各帧；嵌入可在编码器入口拼接，也可用逐层缩放与偏置调制（FiLM）或交叉注意力注入。

嵌入维度、注册时长和余弦阈值由具体模型和训练数据决定，不存在跨模型通用的“同人区间”。部署时要验证注册信道失配、非目标泄漏、目标误抑制和首帧延迟。

§ 6.5 的 pAEC 也使用声纹条件，但训练目标还包含回声消除。见 [SpeakerBeam/TSE 系列](#)；声纹嵌入的端侧存储、加密和删除要求见 § 6.13。

文本查询通用声音分离是另一项任务：查询词描述“警报声”“狗叫”等声音类别，不保证对应某个可注册的说话人。对比语言—音频预训练（Contrastive Language-Audio Pretraining, CLAP）可提供文本与音频嵌入，但 CLAP 本身不是分离器；实际系统还需要用查询嵌入控制掩码或波形生成模块。

见 [CLAP](#) 与使用语言查询的 AudioSep。AudioSep 已正式发表于 *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 33, pp. 458 – 471, DOI [10.1109/TASLP.2024.3520017](#)；官方仓库提供模型与推理入口。

TSE 的身份泄漏、注册信道和声纹保护测试，不能由文本查询分离的类别级结果替代。

## 8.7 教学代码与源码复现

[codes/array\\_tutorial/separation.py](#) 提供五个只依赖 NumPy 的小模块：

- `si_sdr()` 接收等长一维估计与参考。先各自按峰值缩放再去均值，避免绝对幅度引起溢出；能量下限是估计能量乘 `epsilon`，而不是固定绝对能量。默认 `epsilon=1e-12` 时，完美和正交样本分别返回约 +120/-120 dB 的有限边界值；这些上限不是测量精度。零信号及去均值后为零的信号明确报错。
- `pit_permutation()` 接收 (源, 样本) 数组并枚举排列，返回“第几个输出对应第几个参考”的元组和平均 SI-SDR。这是已知参考下的评价，不是在线说话人身份恢复。
- `masked_spatial_covariance()` 接收 (频点, 通道, 帧) 复谱与 (频点, 帧) 非负掩码；`epsilon` 必须是有限正数，空掩码返回零矩阵而不是 NaN。
- `mask_mvdr_2x2()` 用目标 SCM 的主特征向量估计相对传递函数，再以干扰 SCM 求两麦 MVDR，返回 (频点, 帧) 输出和 (频点, 2) 权重。
- `guided_activity_posterior()` 对已给定的空间相对密度和混合权重执行说话人活动门控，背景分量恒活动；它不估计 cACG 形状矩阵。

两麦 MVDR 先按每频点所有通道共同的实部/虚部峰值缩放观测，再计算统计量；两组非空掩码还分别按自身峰值归一化，然后估计 SCM。这样共同正比例缩放掩码不会仅因落到一个绝对分母地板以下而误触发旁路。解方程前再按干扰 SCM 的平均对角元素归一化；共同信号尺度在 MVDR 权重的分子、分母中抵消，输出恢复原尺度。

掩码全空、有效目标或干扰统计为零，以及求解失败时仍退回参考麦；不把这些情形计为成功分离。这里的掩码归一化只属于 `mask_mvdr_2x2()`，不能反推上一节直接调用 `masked_spatial_covariance()` 时也具有相同的极小掩码行为。

联合示例用 `.venv/bin/python -m codes.examples.ch06_09_baselines` 运行，测试见 [tests/test\\_codes\\_aec\\_wpe\\_sep\\_track.py](#)。测试覆盖输出交换、静音参考和静音估计拒绝、SCM 厄米性、MVDR 无失真约束，以及目标或干扰掩码为空时回退参考麦。实际评测还必须固定去均值、时延/增益对齐、静音段、截断长度和输入基线；秩亏 SCM、单通道输入、 $N > M$ 、跨块换人及 STFT 重构均需单独测试。教学版 MVDR 在目标或干扰统计不可用时退回参考麦克风，不应把这一回退的输出解释成成功分离。

本章的外部实现已经按具体算法定位，不能把“正文尚未实现”写成“没有可用源码”。[盲分离与 GSS 研究](#)和[神经分离研究](#)进一步列出读码顺序、状态、最小实验与失败条件。

| 方法                       | 已定位的源码入口                                                                                          | 复现与工业使用的主要限制                            |
|--------------------------|---------------------------------------------------------------------------------------------------|-----------------------------------------|
| AuxIVA、ILRMA             | pyroomacoustics<br>bss/auxiva.py 、 ilrma.py ;<br>ssspy bss/iva.py 、 ilrma.py                      | 区分 IP/ISS 更新、源数条件、功率下限和 projection-back |
| MNMF、FastMNMF/FastMNMF2  | ssspy bss/mnmf.py ;<br>pyroomacoustics<br>bss/fastmnmf.py 、<br>fastmnmf2.py                       | 固定初值、NMF 基数、空间模型、参考麦与重构尺度               |
| TRINICON                 | pyroomacoustics<br>bss/trinicon.py                                                                | 此实现固定两个输出，不能当作任意源数版本；块长和滤波器长度分开         |
| cACGMM                   | pb_bss<br>distribution/cacgmm.py                                                                  | 方向归一、空分量、密度数值稳定与功率 SCM 分开检查             |
| GPU-GSS                  | gss/core/enhancer.py →<br>gss/wpe/ → gss/cacgmm/ →<br>gss/beamformer/                             | 需活动标注、同步多通道音频及匹配的 CUDA/CuPy；活动错误会传播     |
| Conv-TasNet、DPRNN        | Asteroid<br>models/conv_tasnet.py 、<br>dprnn_tasnet.py                                            | 配套 recipe、编码窗、归一化、源数、循环方向和权重            |
| SepFormer                | SpeechBrain<br>lobes/models/dual_path.py 与<br>WSJ0Mix 分离 recipe                                   | 双路径注意力和整句上下文不能直接当作流式状态                  |
| TF-GridNet               | ESPnet<br>enh/separator/tfgridnet_separa<br>tor.py                                                | 此类明确为离线，固定输入麦数；单/多通道版本分别核对              |
| S4M、SPMamba、Mamba-TasNet | 各作者模型/训练目录，详见研究文档                                                                                 | 三者不是同一算法；S4M 训练资产不完整，双向模型使用未来上下文        |
| Online SpatialNet        | NBSS<br>models/arch/OnlineSpatialNet.<br>py 、 SharedTrainer.py 与<br>configs/onlineSpatialNet.yaml | 依赖 PyTorch/Mamba/CUDA；因果前缀与跨调用状态连续性分别检查 |
| SpeakerBeam、AudioSep     | 注册语音条件模型、 pipeline.py<br>等各自入口                                                                    | 身份条件与文本类别条件不同；代码、权重和数据许可分别核对            |



FastMNMF 的可用实现还体现了许可需要逐来源检查：作者 [SoundSourceSeparation](#) 整库限定学术研究，而 pyroomacoustics 的 [fastnmf.py](#) 文件有独立 MIT 许可。SpeakerBeam 作者仓库采用内部评估协议，限制修改与再分发，不能把它与 MIT/Apache-2.0 项目统一称为可自由纳入产品的开源代码。[FastMNMF 文件许可](#)、[作者仓库许可](#)、[SpeakerBeam 评估协议](#)

已运行的 AuxIVA 盲估计最小实验。本书的 [reproduce\\_auxiva\\_reference.py](#) 直接从锁定的 [ssspy bss/iva.py](#) 调用 [AuxLaplaceIVA](#) 的 IP 更新。混合矩阵只用于合成两麦观测和制作参考，未传给估计器；它接收的只有混合 STFT，自己估计逐频解混矩阵。输出经参考麦 0 回投影和 iSTFT 后才评分。

测试运行命令为 `.venv/bin/python -m codes.examples.reproduce_auxiva_reference`；源码必须先按[锁表](#)取得到隔离目录。

本书仿真采用两路独立高斯随机载波乘不同的八段固定包络，各路按自身标准差归一；随机种子 2468、采样率 8 kHz、每路 32000 点，观测为  $\begin{bmatrix} 1 & 0.9 \\ 0.8 & 1 \end{bmatrix} \mathbf{s}$ ，矩阵条件数约 12.24。无噪声、无混响。周期 Hann 窗长 256 点、帧移 64 点、中心补零，整段运行 30 次 IP 迭代。

评分参考是两路在麦克风 0 上的源图像  $s_1$  与  $0.9s_2$ ，并非统一干声；使用整段去均值、无时延对齐的 SI-SDR。输入基线为同一麦克风 0 混合波形分别对两个源图像评分，输出用真实参考只做离线 PIT 评分。

| 数学合成输入       | 输入两路 SI-SDR / dB | 输出两路 SI-SDR / dB | 平均 SI-SDR <sub>i</sub> / dB |
|--------------|------------------|------------------|-----------------------------|
| 随机包络，8 kHz   | 0.90、-0.94       | 37.70、36.80      | 37.27                       |
| 原有双谐波，16 kHz | 6.02、-6.02       | 2.38、-2.10       | 0.14                        |

第二行沿用本书原有合成音频，其瞬时混合矩阵为  $\begin{bmatrix} 1 & 0.5 \\ 0.2 & 1 \end{bmatrix}$ 。两行各只有一次确定输入，采样率、源统计和混合矩阵都不同，不能按行比较算法优劣。

第一行输出的参考麦 RMS 比为 0.999、0.999；单看尺度不变 SI-SDR 无法验证回投影，故另做这个增益检查。第一行的 [ssspy](#) 目标值从 568.99 降到 -8.69，但不同输入的目标值不可横比，也不能据此推断分离质量必然提高。第二行虽使用相同 IP 配置，输出平均 SI-SDR 仅 0.14 dB，且回投影后的两路 RMS 比约 0.536、1.674，不能称为成功恢复源图像。

把随机包络例子的混合矩阵第二行改成与第一行相同，会使观测秩从 2 降为 1；锁定实现本机在该输入上以 [LinAlgError: Singular matrix](#) 失败。即使某实现返回两路数值输出，只有一路独立观测也不足以凭这套方阵盲解混模型辨识两个任意独立源。

该脚本没有语音语料、房间卷积或设备录音；它证明了一次数学输入上的盲估计链，没有复现 Ono 论文的语音指标或任何工业实时性。[原始 AuxIVA 论文](#)。

后续完整实验还应分别改变混响、初始化及片段长度，在相同统计口径下记录失败次数。CSS 还需测试跨块换人和静音后重新出现，不能让每块用真实答案独立排列后再拼接。cACGMM 的正文伪代码仅解释依赖关系；完整实现中的空分量处理、对数域计算与收敛检查仍须核对。

## 8.8 练习与可复算答案

### 练习 8-1（自测三题）

#### 1. 说明 WDO 假设及其失效条件。

答案要点：时频不交叠（W-disjoint Orthogonality, WDO）近似认为，不同说话人在同一时频点很少同时有显著能量。于是可按某个时频点的主导说话人分配掩码。若两人的谐波、共振峰或瞬态落在同一点，硬分配会丢失弱者或留下串音；重叠越重，近似通常越差。这是分离假设，不能仅凭两人总体能量相近或不同就断定某个点是否满足。

#### 2. GSS 三步顺序是什么？

答案要点：先用 WPE 的延迟线性预测减少晚期混响，降低混响对后续统计量的污染；再由 cACGMM 利用空间特征估计各类后验掩码；随后按掩码汇总目标和干扰的 SCM，最后以这些 SCM 计算 MVDR 或 GEV 权重并输出波束。活动信息可约束聚类，但不能直接代替空间观测。

#### 3. 掩码换协方差要写哪两个矩阵？

答案要点：至少要明确目标协方差  $\mathbf{R}_{\text{tar}}$  与干扰协方差  $\mathbf{R}_{\text{int}}$ 。例如对各帧复数观测  $\vec{x}_n$ ，目标 SCM 可取  $\sum_n \gamma_n \vec{x}_n \vec{x}_n^H / \sum_n \gamma_n$ ；干扰 SCM 则用本模型定义的非目标权重同样求和。分母为零时要跳过或正则化，不能除零。

二分类例子可分别用  $\gamma$  与  $1 - \gamma$  加权；多说话人加环境噪声时应按模型分别定义非目标掩码，不能把  $1 - \gamma$  一律解释成纯噪声。两种 SCM 还须使用同一观测尺度和明确的参考通道。

### 可运行练习 E08-01~E08-07

运行 `.venv/bin/python -m codes.examples.exercises_enhancement` 复算以下七题。逐题结果和代码见 `exercises_enhancement.py`，GSS 活动门控函数见 `guided_activity_posterior()`，合成混合与已知矩阵解混音频见[练习及音频手册](#)。

- E08-01：尺度不变是否意味着时移不变？取零均值  $s = [1, 0, -1, 0]$ 、 $u = [0, 1, 0, -1]$ ， $\hat{s} = s + 0.1u$ 。分别计算原幅度、两信号同乘  $10^{-5}$ 、把干净  $s$  循环右移一采样后的 SI-SDR。

解答： $\langle s, u \rangle = 0$ 、两者能量均为 2，故  $\alpha = 1$ ，能量比  $2/(0.01 \times 2) = 100$ ，原幅度与低幅度都为 20 dB。循环右移一采样恰好得到  $u$ ，与  $s$  正交，数学分数为负无穷，教学实现报 -120 dB 边界。

循环移位只是四点数组反例；真实延迟应补零、对齐并固定共同窗口，不能用 `roll` 把尾部声波移回开头。该题说明 SI-SDR 忽略整体增益，不忽略时间轴。

- E08-02: PIT 分数高是否证明身份连续？沿用上题  $s, u$ 。参考顺序为  $[s, u]$ ，输出为  $[u + 0.1s, s + 0.1u]$ ；比较固定顺序评分与最优排列评分。

解答：固定顺序时每个输出的目标幅度是 0.1、正交干扰幅度是 1，分数为 -20 dB。交换对应关系后每路均为 20 dB，输出到参考的零起始索引为 `[1,0]`。

PIT 利用真实参考选取评价排列；若相邻块不断交换输出而每块各自评分，仍可能得到高分。连续系统必须另外检查跨块对应和身份切换，不能用这个最优排列作为实际可用的身份标签。

- E08-03: 已知混合矩阵为何仍可能不稳？令两源组成  $S$ ，两麦观测  $X = AS$ ，其中  $A = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}$ 。用线性方程求解恢复  $S$ ，再给单个观测列加上  $[0.01, -0.01]^T$ 。将两个非对角元素改成 0.99 后重复。

解答：第一种矩阵特征值为 1.5、0.5，二范数条件数为 3；观测误差恢复为  $[0.02, -0.02]^T$ 。第二种特征值为 1.99、0.01，条件数为 199，同一误差恢复为  $[1, -1]^T$ 。无噪声且矩阵准确时，两者都可在浮点误差内恢复源；噪声和矩阵误差会暴露病态风险。

这里直接给定了  $A$ ，因此只是已知瞬时混合的代数实验，不是 ICA、IVA 或其他盲分离算法，也不代表实际卷积房间中的性能。

- E08-04: 分开了是否就恢复了参考麦的幅度？沿用 E08-03 的  $A$  和 E08-01 的两源  $s, u$ 。人为指定解混矩阵  $W = \text{diag}(2, -3)A^{-1}$ ，计算原始输出和以第一支麦克风为参考的回投影。

解答： $WA = \text{diag}(2, -3)$ ，所以原输出为  $[2s, -3u]^T$ 。逆解混矩阵为  $W^{-1} = A \text{diag}(1/2, -1/3)$ ，第一行为  $[1/2, -1/6]$ 。逐路相乘后恢复  $[s, 0.5u]^T$ ，二者之和恰为第一支麦克风的无噪混合  $s + 0.5u$ 。

回投影恢复的是参考麦上的各源图像，不是把每个源都归一成干声。原输出虽然增益和极性不同，对各自非零参考的理想 SI-SDR 都可为正无穷；尺度不敏感的评分不能验证绝对增益。该题给定  $W$ ，只检验回投影代数，不宣称实现了盲分离。

- E08-05: 所有掩码乘同一个数，SCM 一定不变吗？单通道两帧复谱简化为  $[2, 4]$ ，两帧权重相同，取教学函数分母地板  $\epsilon = 10^{-12}$ 。分别令每个权重为 1、2、 $\epsilon/2$ 、 $\epsilon/4$ 。

解答：每个权重为  $a$  时，分子为  $a(2^2 + 4^2) = 20a$ ，分母为  $\max(2a, \epsilon)$ 。四种结果依次是 10、10、10、5；前两项的共同尺度被分母抵消，最后一项已经进入地板区。

若改用式(8-5)的加性稳定项,  $a = \varepsilon/2$  时分母为  $2\varepsilon$ , 结果是 5, 而非教学地板实现的 10。这是本书针对数值约定的手算。最后两项只说明共同缩放已经触及本函数的绝对分母地板, 不能仅凭权重的绝对尺度断定统计支持是否充足; 统计支持还要结合归一化权重的分布、非零快照数量、 $N_{\text{eff}}$ 、矩阵秩与条件数判断。

- E08-06: 每块 PIT 都是 20 dB, 直接拼接为何仍会换人? 沿用 E08-01 的  $s, u$ 。第一块输出为  $[s + 0.1u, u + 0.1s]$ , 第二块把两个槽位交换为  $[u + 0.1s, s + 0.1u]$ 。分别对两块独立做 PIT, 再把原始固定槽位直接拼接; 最后使用每块的真实参考排列对齐后再拼接。

解答: 两块的最优“输出到参考”排列分别为  $[0,1]$  和  $[1,0]$ , 每块的平均 SI-SDR 都是 20 dB。若把固定的输出槽 0 和槽 1 直接跨块拼接, 各自前半段属于一个说话人、后半段属于另一个说话人; 对整段固定参考评分时, 两路均约为 -3.6900 dB。按每块真实参考排列重排后, 两条长流都回到 20 dB。

这里的重排使用了真实参考, 是评分用的预言信息, 不是部署算法。可用系统还要从重叠区、说话人嵌入、活动状态或其他连续性线索估计跨块对应, 并在静音后重新出现和三人以上重叠时检查误连。本题只证明“逐块最优 PIT 分数”不能证明长录音身份连续。

- E08-07: 所有说话人静音时, GSS 后验怎样归一化? 只算一个频点的相邻两帧, 分量顺序为说话人 1、说话人 2、背景噪声。给定混合权重  $\pi = [0.5, 0.3, 0.2]$ , 两帧各分量的相对密度均为  $L = [2, 1, 1]$ 。

两帧的说话人活动分别是  $[1, 0]$ 、 $[0, 0]$ , 背景噪声始终活动。用  $q_j = a_j \pi_j L_j$  算未归一化分数及后验, 再说明删除背景噪声类后第二帧会发生什么。

解答第 1 步: 补背景活动。函数把两帧的说话人活动补上恒为 1 的背景活动, 得到  $[1, 0, 1]$  和  $[0, 0, 1]$ 。

第 2 步: 逐项相乘并归一化。第一帧的未归一化分数为

$[1 \times 0.5 \times 2, 0 \times 0.3 \times 1, 1 \times 0.2 \times 1] = [1, 0, 0.2]$ 。分母是 1.2, 故后验为  $[5/6, 0, 1/6]$ 。第二帧的分数为  $[0, 0, 0.2]$ , 分母是 0.2, 后验为  $[0, 0, 1]$ 。

第 3 步: 检查失效边界。若删去背景类, 第二帧的两个分数和为零, 后验无定义。该结果说明背景类在全体说话人静音时提供了可归一化的候选; 它不表示这一帧已被正确分离。

本题给的是固定相对密度, 只检验式(8-4)之后的活动门控与 E 步归一化。它没有估计 cACG 形状矩阵、执行 M 步或输出分离音频; 后验属于背景类也不证明目标语音已被正确分离。代码中 `speaker_activity` 只输入两位说话人的标记, 背景活动由函数自动补上。见 `exercises_enhancement.py` 中的 E08-07。



## 第 9 章 · 声源追踪

### 9.1 问题与声学特殊性

声源追踪把含噪且可能间断的逐帧定位结果融合成连续轨迹，再为波束形成提供抖动较小的因果方向估计。状态要随观测和任务选择：只跟踪方位时可用  $[\theta_t, \dot{\theta}_t]^\top$ ；需要描述加速可加入  $\ddot{\theta}_t$ ；要跟踪平面位置则可用  $[x_t, y_t, \dot{x}_t, \dot{y}_t]^\top$ 。角度状态的分量分别以角度、角速度和角加速度为单位，位置状态则要另定坐标系和速度单位。

**LOCATA 声源定位与追踪挑战**包含静止或运动的声源与阵列录音，并提供光学动捕真值；使用时要按任务编号区分单源/多源、静止/运动和阵列配置，数据选择的一般原则见 § 10.6。

声学追踪有四个特点：

- 说话人停顿会造成间歇观测，需要语音活动检测（Voice Activity Detection, VAD）门控和轨迹维持；
- 混响会产生非高斯误差和野点；
- 声源数会随时间变化；
- 到达方向（Direction of Arrival, DOA）与笛卡尔位置之间是非线性关系。

若状态为平面位置与速度  $[x, y, \dot{x}, \dot{y}]$ ，阵列中心为  $(x_0, y_0)$ ，沿用第 2~5 章从  $+y$  轴向  $+x$  轴为正的方位角约定，则观测函数为  $\theta = \text{atan2}(x - x_0, y - y_0)$ 。这里 `atan2` 的第一个参数是正弦分量，第二个是余弦分量；不能直接照搬以  $+x$  轴为零点的数学极角顺序。

例如阵列中心在原点，声源在 (1 m, 2 m) 时，本书方位角是  $\text{atan2}(1, 2) \approx 26.565^\circ$ ；交换参数得到  $\text{atan2}(2, 1) \approx 63.435^\circ$ ，那是另一套零点约定。两者都能描述位置，但定位、追踪与波束控制必须先统一约定，不能直接互传。

单个固定阵列的一次方位观测不能确定距离。令阵列中心为 (0, 0)，声源在 (1 m, 1 m) 与 (2 m, 2 m) 时都得到  $45^\circ$ ；沿同一射线缩放位置不会改变 `atan2` 的结果。

连续仅测方位观测只有在已知运动约束和足够的阵列—声源相对运动使系统可观测时，才可能逐步估计距离。否则，即使用扩展卡尔曼滤波（Extended Kalman Filter, EKF）或无迹卡尔曼滤波（Unscented Kalman Filter, UKF），径向位置仍不能由滤波器自行产生。

位置级追踪通常还要引入已知中心不同的多个阵列、到达时间差（Time Difference of Arrival, TDOA）或距离观测，或利用满足可观测条件的移动阵列轨迹。**仅测方位可观测性分析**。



EKF 用该观测函数的雅可比做一阶线性化。标准对称或缩放无迹变换的 UKF 通常传播  $2L + 1$  个 sigma 点；对位置—速度状态  $[x, y, \dot{x}, \dot{y}]^\top$ ，状态维数  $L = 4$ ，因此是 9 个点。单纯方位—角速度状态只有  $L = 2$ ，对应 5 个点。也有单纯形、球面径向等减少点数的变体，不能把  $2L + 1$  写成所有 UKF 的定义。

近距离或声源越过阵列附近时非线性更强，应比较 UKF、粒子滤波或其他非线性方法，而不是直接套用线性卡尔曼滤波（Kalman Filter, KF）。

## 9.2 单目标追踪

### 9.2.1 卡尔曼预测、观测更新与角度边界

状态与观测模型写为

$$\vec{s}_t = \mathbf{F}\vec{s}_{t-1} + \vec{v}_t, \quad \vec{z}_t = \mathbf{H}\vec{s}_t + \vec{w}_t. \quad (9-1)$$

其中  $\mathbf{F}$  描述匀速或匀加速运动， $\vec{v}_t$  是未建模运动造成的过程噪声。若状态维数为  $d$ 、观测维数为  $p$ ，则过程噪声协方差  $\mathbf{Q} = E[\vec{v}_t\vec{v}_t^\top] \in \mathbb{R}^{d \times d}$ ，观测噪声协方差  $\mathbf{R} = E[\vec{w}_t\vec{w}_t^\top] \in \mathbb{R}^{p \times p}$ 。

协方差元素的单位由对应状态分量相乘决定。例如  $[\theta, \dot{\theta}]^\top$  的对角线单位分别是  $\text{deg}^2$  和  $(\text{deg/frame})^2$ 。若定位器只输出角度， $\vec{z}_t$  退化为标量  $\theta_t^{obs}$ ， $\vec{w}_t$  是观测噪声， $\mathbf{R}$  也退化为角度方差。

三维状态时  $\mathbf{H} = [1, 0, 0]$ ；下文二维简化状态  $[\theta, \dot{\theta}]^\top$  使用  $\mathbf{H} = [1, 0]$ 。

贝叶斯递推包含预测和更新。预测阶段依据运动模型外推状态，并增加因过程噪声带来的不确定度；更新阶段用观测与预测之差，即新息，修正状态和协方差。在线性高斯假设下，卡尔曼滤波给出这两个阶段的闭式递推。

卡尔曼滤波（KF）的五步递推（状态取 [角度, 角速度]）：

1. 预测状态：

$$\hat{\vec{s}}_t^- = \mathbf{F}\hat{\vec{s}}_{t-1}. \quad (9-2)$$

2. 预测协方差：

$$\mathbf{P}_t^- = \mathbf{F}\mathbf{P}_{t-1}\mathbf{F}^\top + \mathbf{Q}. \quad (9-3)$$

$\mathbf{F}$  先把上一帧协方差传播到当前状态， $\mathbf{Q}$  再加入未建模运动的过程噪声。不能据此断言任意  $\mathbf{F}$  下每个协方差元素都必然增大；本章的无观测匀速数例中，角度方差会增大。

### 3. 计算卡尔曼增益：

$$\mathbf{K}_t = \mathbf{P}_t^- \mathbf{H}^\top (\mathbf{H} \mathbf{P}_t^- \mathbf{H}^\top + \mathbf{R})^{-1}. \quad (9-4)$$

$\mathbf{R}$  是式(9-1)定义的观测噪声协方差。观测噪声较小时增益增大，更新更依赖观测；预测协方差较小时增益减小，更新更依赖运动模型。

### 4. 更新状态：

$$\hat{\mathbf{s}}_t = \hat{\mathbf{s}}_t^- + \mathbf{K}_t (\theta_t^{obs} - \mathbf{H} \hat{\mathbf{s}}_t^-). \quad (9-5)$$

括号里的差称为新息 (innovation)，即观测与预测之差。

### 5. 更新协方差：

$$\mathbf{P}_t = (\mathbf{I} - \mathbf{K}_t \mathbf{H}) \mathbf{P}_t^-. \quad (9-6)$$

方位角跨越表示区间边界时，新息不能直接相减。若角度约定为  $[-180^\circ, 180^\circ)$ ，定义

$$\text{wrap}_{180}(\alpha) = ((\alpha + 180^\circ) \bmod 360^\circ) - 180^\circ. \quad (9-7)$$

并在第 4 步使用  $\text{wrap}_{180}(\theta_t^{obs} - \mathbf{H} \hat{\mathbf{s}}_t^-)$ 。预测和更新完成后，还应把状态中的角度分量按式(9-7)映射回同一表示区间；角速度等非角度分量不做环绕。

例如预测为  $+179^\circ$ 、观测为  $-179^\circ$ ，直接相减得到  $-358^\circ$ ，最短圆周角差却是  $+2^\circ$ 。不做环绕会让滤波器沿错误方向大幅更新，门控也可能把正确观测判成野点。

若设备只搜索一个不跨边界的有限扇区，则应使用该扇区的边界模型，不能把  $-180^\circ$  与  $+180^\circ$  自动视为相邻。

式(9-6)便于手算；浮点实现可使用数值上更稳健的 Joseph 形式

$$\mathbf{P}_t = (\mathbf{I} - \mathbf{K}_t \mathbf{H}) \mathbf{P}_t^- (\mathbf{I} - \mathbf{K}_t \mathbf{H})^\top + \mathbf{K}_t \mathbf{R} \mathbf{K}_t^\top. \quad (9-8)$$

式(9-6)与式(9-8)在精确算术和标准卡尔曼增益下等价。Joseph 形式把两个半正定项相加，更不容易因舍入误差得到不对称或负方差；实现中仍应检查  $\mathbf{P}_t$  的对称性和最小特征值。

## 9.2.2 算例 9-1：卡尔曼滤波单步复算

以下数字描述一个正在转头的说话人。

下面用一组数值复算式(9-2)至式(9-6)。状态向量取 § 9.1 三维状态的二维简化版  $\vec{s} = [\theta, \dot{\theta}]^\top$ ，单位分别为度和度/帧。该模型省略加速度，适合运动较平缓的示例；频繁机动时可改用含加速度的模型或后文的 IMM。已知：

- 上一帧估计： $\hat{\mathbf{s}}_{t-1} = [30, 0.5]^\top$ （目标在  $30^\circ$ ，每帧向右走  $0.5^\circ$ ）；

- 上一帧不确定度：  $\mathbf{P}_{t-1} = \begin{bmatrix} 4 & 0 \\ 0 & 0.25 \end{bmatrix}$  （角度方差  $4^\circ^2$ ，即标准差  $2^\circ$ ；角速度方差 0.25）；
- 状态转移矩阵（匀速模型）：  $\mathbf{F} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$  （“新角度 = 旧角度 + 1 帧  $\times$  角速度，角速度不变”的矩阵写法）；
- 过程噪声：  $\mathbf{Q} = \begin{bmatrix} 0.1 & 0 \\ 0 & 0.01 \end{bmatrix}$  （“目标其实会乱动”的程度， $\mathbf{Q}$  越大滤波器越不敢信自己的预测）；
- 观测矩阵：  $\mathbf{H} = [1, 0]$  （DOA 算法只报角度，不报角速度）；
- 本帧观测：  $\theta_t^{obs} = 32^\circ$ ；观测噪声  $\mathbf{R} = 25$  （标准差  $5^\circ$ ，反映单帧 DOA 估计相当粗糙）。

第 1 步：预测  $\hat{\mathbf{s}}_t^- = \mathbf{F}\hat{\mathbf{s}}_{t-1}$

$$\hat{\mathbf{s}}_t^- = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 30 \\ 0.5 \end{bmatrix} = \begin{bmatrix} 1 \times 30 + 1 \times 0.5 \\ 0 \times 30 + 1 \times 0.5 \end{bmatrix} = \begin{bmatrix} 30.5 \\ 0.5 \end{bmatrix}$$

“他上一帧在  $30^\circ$ 、每帧走  $0.5^\circ$ ，这帧大概到  $30.5^\circ$ 。”

第 2 步：预测的不确定度  $\mathbf{P}_t^- = \mathbf{F}\mathbf{P}_{t-1}\mathbf{F}^\top + \mathbf{Q}$

先算  $\mathbf{F}\mathbf{P}_{t-1} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 0.25 \end{bmatrix} = \begin{bmatrix} 4 & 0.25 \\ 0 & 0.25 \end{bmatrix}$  （第一行：  $1 \times 4 + 1 \times 0 = 4$ ，  
  $1 \times 0 + 1 \times 0.25 = 0.25$ ；第二行照算）。

再乘  $\mathbf{F}^\top = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$ ：

$$\begin{aligned} \mathbf{F}\mathbf{P}_{t-1}\mathbf{F}^\top &= \begin{bmatrix} 4 & 0.25 \\ 0 & 0.25 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 4 \times 1 + 0.25 \times 1 & 4 \times 0 + 0.25 \times 1 \\ 0 \times 1 + 0.25 \times 1 & 0 \times 0 + 0.25 \times 1 \end{bmatrix} \\ &= \begin{bmatrix} 4.25 & 0.25 \\ 0.25 & 0.25 \end{bmatrix}. \end{aligned}$$

左上角从 4 增加到 4.25，因为角速度的不确定度会在预测后传播到角度。再加上  $\mathbf{Q}$ ：

$$\mathbf{P}_t^- = \begin{bmatrix} 4.25 & 0.25 \\ 0.25 & 0.25 \end{bmatrix} + \begin{bmatrix} 0.1 & 0 \\ 0 & 0.01 \end{bmatrix} = \begin{bmatrix} 4.35 & 0.25 \\ 0.25 & 0.26 \end{bmatrix}$$

即预测的角度不确定度为标准差  $\sqrt{4.35} \approx 2.09^\circ$ 。

第 3 步：卡尔曼增益  $\mathbf{K}_t = \mathbf{P}_t^- \mathbf{H}^\top (\mathbf{H}\mathbf{P}_t^- \mathbf{H}^\top + \mathbf{R})^{-1}$

$\mathbf{H}\mathbf{P}_t^- \mathbf{H}^\top$  只是取出  $\mathbf{P}_t^-$  的左上角元素 4.35（因为  $\mathbf{H} = [1, 0]$  起到“挑出角度分量”的作用），于是分母是标量：

$$\mathbf{H}\mathbf{P}_t^- \mathbf{H}^\top + \mathbf{R} = 4.35 + 25 = 29.35$$

分子  $\mathbf{P}_t^- \mathbf{H}^\top = \begin{bmatrix} 4.35 & 0.25 \\ 0.25 & 0.26 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 4.35 \\ 0.25 \end{bmatrix}$ （取  $\mathbf{P}_t^-$  的第一列）。

$$\mathbf{K}_t = \frac{1}{29.35} \begin{bmatrix} 4.35 \\ 0.25 \end{bmatrix} = \begin{bmatrix} 0.148 \\ 0.0085 \end{bmatrix}$$

中间值分别为 0.1482 和 0.00852，这里保留三位和两位有效数字。

增益是  $2 \times 1$  向量： $K_1 = 0.148$ （角度分量信观测的比例）、 $K_2 = 0.0085$ （角速度分量分到的一点残差信息——观测虽只报角度，但角度残差里也藏着“速度估偏了”的线索）。

$K_1 \approx 0.148$  表示角度更新量取新息的约 14.8%。观测噪声方差 25 大于预测角度方差 4.35，因此估计更接近预测值。若  $\mathbf{R}$  减小， $K_1$  会增大，观测对更新的影响也会增加。

第 4 步：更新  $\hat{\mathbf{s}}_t = \hat{\mathbf{s}}_t^- + \mathbf{K}_t(\theta_t^{obs} - \mathbf{H}\hat{\mathbf{s}}_t^-)$

新息（innovation，观测与预测之差）为  $\theta_t^{obs} - \mathbf{H}\hat{\mathbf{s}}_t^- = 32 - 30.5 = 1.5^\circ$ 。

$$\hat{\mathbf{s}}_t = \begin{bmatrix} 30.5 \\ 0.5 \end{bmatrix} + \begin{bmatrix} 0.148 \\ 0.0085 \end{bmatrix} \times 1.5 = \begin{bmatrix} 30.5 + 0.222 \\ 0.5 + 0.0128 \end{bmatrix} = \begin{bmatrix} 30.72 \\ 0.513 \end{bmatrix}$$

角度由预测值向观测值修正约  $0.22^\circ$ ，角速度更新为  $0.513^\circ/\text{帧}$ 。最终角度  $30.72^\circ$  位于预测值  $30.5^\circ$  与观测值  $32^\circ$  之间，并因  $K_1$  较小而更接近预测值。

第 5 步：更新的不确定度  $\mathbf{P}_t = (\mathbf{I} - \mathbf{K}_t \mathbf{H}) \mathbf{P}_t^-$

计算协方差时保留未舍入的增益  $\mathbf{K} = [4.35, 0.25]^\top / 29.35$ 。前面显示的 0.148 和 0.0085 只用于展示，不能再当成精确数代入。于是

$$\mathbf{I} - \mathbf{K}_t \mathbf{H} = \begin{bmatrix} 25/29.35 & 0 \\ -0.25/29.35 & 1 \end{bmatrix}$$

$$\mathbf{P}_t = \begin{bmatrix} 25/29.35 & 0 \\ -0.25/29.35 & 1 \end{bmatrix} \begin{bmatrix} 4.35 & 0.25 \\ 0.25 & 0.26 \end{bmatrix} \approx \begin{bmatrix} 3.705 & 0.213 \\ 0.213 & 0.258 \end{bmatrix}$$

逐项计算得到  $P_{11} = 25 \times 4.35/29.35 \approx 3.705281$ ， $P_{12} = P_{21} = 25 \times 0.25/29.35 \approx 0.212947$ ， $P_{22} = 0.26 - 0.25^2/29.35 \approx 0.257871$ ；上面的矩阵最后才舍入到三位小数。若提前用 0.852 计算， $0.852 \times 4.35 = 3.7062$ ，会改变显示的末位，且两条路径计算的非对角项可能不再相等。

角度方差从 4.35 降到 3.71（标准差约  $1.93^\circ$ ）。在线性模型、协方差和卡尔曼增益满足本节条件时，观测更新降低或保持估计协方差；错误观测或错误噪声模型仍可能让真实误差增大。

若下一帧说话人停顿没有观测，就只做第 1、2 步：本例角度方差再次增大，波束指向维持外推，这就是“静默保持”（§ 9.4）。

算例 9-1 说明了单步卡尔曼递推。下表比较常见单目标追踪方法的假设、计算量和适用条件。

$\alpha$ - $\beta$  /  $\alpha$ - $\beta$ - $\gamma$  滤波器采用固定更新增益，因而在线更新可以不反复求解 Riccati 递推。如果模型、采样周期和噪声统计恒定，且固定增益取为对应卡尔曼滤波的稳态增益，它可以等价于该模型下的稳态卡尔曼滤波。

经验选取的固定增益不保证这种最优性；模型或噪声条件变化时，固定增益也不会自行重新适配。 $\alpha$ - $\beta$  的稳态关系见 [Ekstrand, Some Aspects on Filter Design for Target Tracking, § 9.1](#)； $\alpha$ - $\beta$ - $\gamma$  的增益稳定性和优化条件见 [Kosuge 与 Ito, Stability of an  \$\alpha\$ - \$\beta\$ - \$\gamma\$  Filter and Optimal Gains, 2002](#)。

| 方法                                                 | 原理                                | 优点                   | 缺点                                                                             | 适用                      |
|----------------------------------------------------|-----------------------------------|----------------------|--------------------------------------------------------------------------------|-------------------------|
| 滑动平均/中值/直方图众数                                      | 对 DOA 序列低通                        | 结构简单，不需递推协方差         | 隐含局部平稳假设；延迟大、跟不上机动、多源混杂                                                        | 目标缓慢、观测较密时的基线           |
| $\alpha$ - $\beta$ / $\alpha$ - $\beta$ - $\gamma$ | 用固定增益修正位置、速度（及加速度）预测              | 在线不必反复求 Riccati 递推   | 经验增益未必最优；统计条件变化时不能自行适配                                                         | 采样周期和运动条件较稳定、资源受限的单目标追踪 |
| 卡尔曼滤波 KF                                           | 高斯线性贝叶斯递推（预测+新息加权更新）              | 在线性高斯模型正确时得到最小均方误差估计 | 稠密实现随状态维数 $d$ 、观测维数 $p$ 约为 $O(d^3 + p^3)$ ；标量 DOA 更新可更低，但仍需在目标硬件计时；抗野点差、需调 Q/R | 观测质量较好且模型近似成立           |
| EKF（扩展卡尔曼滤波）/UKF（无迹卡尔曼滤波）                          | 一阶线性化/无迹变换处理非线性                   | 可处理位置到角度的非线性观测       | EKF 对线性化误差敏感；标准对称/缩放 UKF 常传播 $2L + 1$ 个 sigma 点，其他变体点数不同                       | 分布式阵列位置级追踪              |
| IMM 交互多模型                                          | 静止、匀速、加速等多个运动模型各自运行 KF，再按新息似然加权融合 | 可在多个预设运动模式之间平滑切换     | 计算量随模型数增加；未包含的运动模式仍会失配，且需标定模型转移概率                                              | 包含启动、停止和匀速段的机动场景        |



| 方法                                                                           | 原理                   | 优点              | 缺点                       | 适用             |
|------------------------------------------------------------------------------|----------------------|-----------------|--------------------------|----------------|
| 粒子滤波 (Particle Filter, PF) /序贯重要性重采样 (Sequential Importance Resampling, SIR) | 带权粒子近似后验；预测、加权、按需重采样 | 能表示非线性、非高斯和多峰后验 | 鲁棒性取决于似然与杂波模型；会权重退化和样本贫化 | 观测多峰或运动模型明显非线性 |

9.2.3 运动模型切换与非线性观测

IMM 的模型切换：IMM 并行运行静止、匀速或加速等运动模型，再根据各模型的新息似然更新权重。它适合包含启动、停止和匀速段的轨迹。

两模型例子可使用静止与匀速模型；转移矩阵的对角元素表示保持当前运动模式的概率。IMM 的转移概率和各模型过程噪声需要用目标运动数据标定。0.95 或 0.9 只能作为示例，实际数值不能脱离帧率和目标运动数据直接照搬。

EKF 与 UKF：EKF 对  $\theta = \text{atan2}(x - x_0, y - y_0)$  求雅可比，并在当前估计附近做一阶线性化；估计偏离真实状态较大时，线性化误差可能导致发散。标准对称或缩放 UKF 不显式求导，而是将  $2L + 1$  个 sigma 点通过原始非线性观测函数，再重构均值与协方差；减少 sigma 点的变体使用不同构造。计算量要按状态维数、sigma 点数、观测维数和矩阵实现估算，不能只按“UKF”名称排序。

9.2.4 算例 9-2：粒子加权与重采样

卡尔曼滤波用均值和协方差表示单峰高斯后验。粒子滤波 (particle filter, PF) 用  $N$  个带权样本近似后验，可以表达偏斜或多峰分布。它并不会自动抵抗观测野点：若似然模型把野点当成高置信观测，粒子权重仍会被错误观测拉偏。鲁棒性来自观测门控、重尾似然或“目标加均匀杂波”的混合似然。下面用 10 个粒子演示加权与重采样。

设本帧 10 个粒子的角度猜测（单位：度）为：

$$x_1, \dots, x_{10} = [25, 27, 28, 30, 30, 31, 32, 33, 35, 40]$$

本帧观测  $\theta^{obs} = 31^\circ$ ，观测噪声标准差  $\sigma = 5^\circ$ （方差  $\sigma^2 = 25$ ）。

第 1 步：根据观测似然计算权重

每个粒子的权重用高斯似然：离观测越近分越高，

$$w_i = \exp\left(-\frac{(x_i - \theta^{obs})^2}{2\sigma^2}\right) = \exp\left(-\frac{(x_i - 31)^2}{50}\right)$$

逐个计算  $((x_i - 31)^2$  先列出来)：

| 粒子 $x_i$ | $(x_i - 31)^2$ | $w_i = \exp(-(x_i - 31)^2/50)$ |
|----------|----------------|--------------------------------|
| 25       | 36             | $\exp(-0.72) = 0.4868$         |
| 27       | 16             | $\exp(-0.32) = 0.7261$         |
| 28       | 9              | $\exp(-0.18) = 0.8353$         |
| 30       | 1              | $\exp(-0.02) = 0.9802$         |
| 30       | 1              | $\exp(-0.02) = 0.9802$         |
| 31       | 0              | $\exp(0) = 1.0000$             |
| 32       | 1              | $\exp(-0.02) = 0.9802$         |
| 33       | 4              | $\exp(-0.08) = 0.9231$         |
| 35       | 16             | $\exp(-0.32) = 0.7261$         |
| 40       | 81             | $\exp(-1.62) = 0.1979$         |

权重和为

$$\begin{aligned} \sum_{i=1}^{10} w_i &= 0.4868 + 0.7261 + 0.8353 + 0.9802 + 0.9802 \\ &\quad + 1.0000 + 0.9802 + 0.9231 + 0.7261 + 0.1979 \\ &= 7.8359. \end{aligned}$$

第 2 步：归一化权重

$$\tilde{w}_i = \frac{w_i}{7.8359}$$

逐项归一化后得到：

| 粒子序号 $i$ | 角度 $x_i$ (度) | 归一化权重 $\tilde{w}_i$ |
|----------|--------------|---------------------|
| 1        | 25           | 0.0621              |
| 2        | 27           | 0.0927              |
| 3        | 28           | 0.1066              |
| 4        | 30           | 0.1251              |

| 粒子序号 $i$ | 角度 $x_i$ (度) | 归一化权重 $\tilde{w}_i$ |
|----------|--------------|---------------------|
| 5        | 30           | 0.1251              |
| 6        | 31           | 0.1276              |
| 7        | 32           | 0.1251              |
| 8        | 33           | 0.1178              |
| 9        | 35           | 0.0927              |
| 10       | 40           | 0.0253              |

校验：归一化权重之和为 1。 $40^\circ$  是一个远离当前观测的粒子，不是观测野点；它的权重较小，只说明当前高斯似然会压低不符合观测的候选状态，不能证明粒子滤波对错误观测鲁棒。

### 第 3 步：计算有效粒子数 $N_{eff}$

$$\begin{aligned}
 N_{eff} &= \frac{1}{\sum_{i=1}^{10} \tilde{w}_i^2} \\
 &= \frac{1}{0.0621^2 + 0.0927^2 + 0.1066^2 + 0.1251^2 + \cdots + 0.0253^2} \\
 &= \frac{1}{0.1101} \approx 9.08.
 \end{aligned}$$

若 10 个粒子权重相等， $N_{eff} = 10$ ；若全部权重集中在一个粒子上， $N_{eff} = 1$ ，称为粒子退化。本例得到 9.08。常见实现会在  $N_{eff}$  低于给定阈值时触发重采样，例如  $N/2$ ；阈值需要结合粒子数和任务验证。

### 第 4 步：在重采样前计算本帧估计

$$\begin{aligned}
 \hat{\theta} &= \sum_{i=1}^{10} \tilde{w}_i x_i \\
 &= 0.0621 \times 25 + 0.0927 \times 27 + 0.1066 \times 28 \\
 &\quad + 0.1251 \times 30 + \cdots + 0.0253 \times 40 \\
 &\approx 30.65^\circ.
 \end{aligned}$$

不加权的平均为  $31.1^\circ$ ，加权估计约为  $30.65^\circ$ 。这个后验均值必须用重采样前的粒子和归一化权重计算。重采样后权重重置为  $1/N$ ，不能把旧权重再乘到新粒子上；重采样后取均值只是在有限样本下近似同一后验。

第 5 步：为演示算法，强制执行一次系统重采样。本例  $N_{eff} = 9.08 > N/2 = 5$ ，按上一段的示例阈值本来不会触发重采样。下面只为展示系统重采样的索引过程而人为执行一次，不能把它当作阈值判决结果。

系统重采样按归一化权重重新抽取 10 个粒子，允许高权重粒子重复出现，并把新权重统一重置为 1/10。

先计算归一化权重的累积和：

| 粒子序号 $i$ | 累积和 $\sum_{j=1}^i \tilde{w}_j$ |
|----------|--------------------------------|
| 1        | 0.0621                         |
| 2        | 0.1548                         |
| 3        | 0.2614                         |
| 4        | 0.3865                         |
| 5        | 0.5116                         |
| 6        | 0.6392                         |
| 7        | 0.7643                         |
| 8        | 0.8821                         |
| 9        | 0.9747                         |
| 10       | 1.0000                         |

再从 [0, 0.1) 取起点  $u_0 = 0.0637$ ，以 0.1 为间隔得到 10 个采样点。对应的新粒子群为：

$$[27, 28, 30, 30, 30, 31, 32, 32, 33, 35]$$

30° 和 32° 的粒子被重复抽取，25° 和 40° 的粒子未被抽中。重采样是随机过程，不按单个粒子的权重机械排序；31° 虽有最高单粒子权重，本次仍只保留一份。下一帧先按运动模型传播粒子，再根据新观测重新计算权重。

粒子滤波依次执行状态传播、似然加权、归一化和按需重采样。它能表示多峰后验，但观测野点仍需门控或杂波似然处理。

抗野点技巧包括观测门控、混合似然和辅助粒子滤波（Auxiliary Particle Filter，APF）。门控阈值不能只照搬固定的  $3\sigma$ ，应结合观测误差分布和漏检代价标定。

9.2.5 单目标追踪仿真与缺测边界

图22(a) 为序贯重要性重采样粒子滤波（Sequential Importance Resampling Particle Filter，SIR-PF）递推估计 DOA 的本书仿真。配置如下：

- 真值与观测：真值是  $60^\circ + 40^\circ \sin(2\pi t/120)$  的正弦轨迹；逐帧观测加标准差  $7^\circ$  的高斯噪声，并将约 20% 帧替换为  $0^\circ \sim 120^\circ$  均匀野点；

- 缺测：第 48~57 帧被置为缺测，这 10 帧只执行状态预测；
- 滤波器：使用 200 个粒子和“高斯目标 + 均匀杂波”混合似然，均匀杂波权重为 0.1；
- 初始化与边界：初始角度粒子在允许扇区内均匀采样，不读取未来第一个有效观测。状态只允许落在  $[0^\circ, 120^\circ]$  有限扇区，越界粒子按扇区端点作镜面反射。

镜面反射是便于展示的玩具边界，不是圆周角的  $360^\circ$  环绕，也不代表真实墙面反射。

图22 声源追踪示意（模拟）




图22 (a) 中，灰点为逐帧 DOA 观测，黑线为正弦真值轨迹，红线为粒子滤波估计，紫色阴影标出连续 10 帧缺测，橙色竖线表示有效粒子数低于  $N/2$  后执行了系统重采样。紫色叉号只标出该帧预测后至少 5% 粒子越界并被镜面反射的时刻，避免用“任一粒子越界”放大单个尾部样本。

缺测段没有似然更新，轨迹只由匀速状态模型与过程噪声外推； $0^\circ$  与  $120^\circ$  是采用反射规则的有限扇区边界。

图22 (b) 在  $-25^\circ$  和  $+40^\circ$  附近设置两个强度峰，用于说明多目标强度函数。峰数只能近似用于提取人数，严格定义见 § 9.3。

单目标追踪由预测和观测更新组成。线性高斯条件下可使用卡尔曼滤波；非线性、多峰或重尾观测可考虑 UKF 或粒子滤波。粒子滤波仍需门控或杂波似然处理野点，IMM 用于多运动模型切换，VAD 用于控制无观测时的更新。



## 9.3 多目标追踪

### 9.3.1 数据关联与目标数

多目标追踪需要同时解决观测与轨迹的数据关联，并估计当前的声源数量。

| 方法族                                                                                                                    | 代表                                                                                              | 思想                           | 声学表现                                                         |
|------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------|------------------------------|--------------------------------------------------------------|
| 数据关联+单目标滤波                                                                                                             | 联合概率数据关联 (Joint Probabilistic Data Association, JPDA)、多假设跟踪 (Multiple Hypothesis Tracking, MHT) | 计算观测属于各轨迹的概率或假设树             | 假设数可能随观测和轨迹数快速增加                                             |
| 多目标粒子滤波                                                                                                                | Brutti et al. 2010                                                                              | 每目标一簇粒子 + 数据关联               | 计算量、数据关联和目标数先验都需按实验验证                                        |
| 随机有限集 (Random Finite Set, RFS) / 概率假设密度 (Probability Hypothesis Density, PHD) 滤波                                       | PHD、势概率假设密度 (Cardinalized PHD, CPHD)、序贯蒙特卡洛 PHD (Sequential Monte Carlo PHD, SMC-PHD)           | 传播目标集合的一阶强度；积分给期望目标数，峰用于提取状态 | 避免显式枚举关联，但不保留身份；峰提取和参数设置影响结果 <a href="#">Liu et al. 2018</a> |
| 标记多伯努利 (Labeled Multi-Bernoulli, LMB) / $\delta$ -广义标记多伯努利 (delta-Generalized Labeled Multi-Bernoulli, $\delta$ -GLMB) | 带标签的 RFS                                                                                        | 为目标维护标签、输出带身份轨迹              | 标签管理、假设数和计算量随具体实现而变                                          |
| 检测前追踪 (Track-Before-Detect, TBD)                                                                                       | 对经校准的定位谱或似然场直接递推                                                                                | 不先把弱峰硬切成离散观测，可保留阈值以下的证据      | 输入谱必须有跨帧一致的尺度与杂波模型；未经校准的 DNN 分数不能直接当似然                       |
| 序列神经网络                                                                                                                 | 循环神经网络 (Recurrent Neural Network, RNN) /Transformer 处理定位后验序列                                    | 可学习时间平滑与活动模式                 | 仍需训练数据；是否输出稳定身份取决于标签和损失                                      |

### 9.3.2 三帧关联手算与 PHD 强度

三帧关联辅助例子。设两条匀速轨迹的预测角分别为 A:  $20^\circ, 30^\circ, 40^\circ$ , B:  $60^\circ, 50^\circ, 40^\circ$ ; 三帧观测依次为  $(22^\circ, 58^\circ)$ 、 $(15^\circ, 31^\circ, 48^\circ)$ 、 $(39^\circ, 41^\circ)$ 。假设独立高斯角度误差的标准差  $\sigma = 3^\circ$ 。为先算清最小 JPDA 归一化, 暂时假设第一、三帧没有漏检和杂波, 且两个全局关联事件先验相同。

第一帧“顺接”事件的似然正比于  $\exp[-(2^2 + (-2)^2)/(2 \times 3^2)] = e^{-8/18} \approx 0.641$ ; “交换”事件的残差为  $38^\circ, -38^\circ$ , 似然约为  $e^{-2888/18}$ , 归一化后的顺接概率在所示精度下为 1。

第三帧两条预测都为  $40^\circ$ , 两个交换事件的残差平方和都为  $(-1)^2 + 1^2 = 2$ , 似然都为  $e^{-2/18} \approx 0.895$ 。归一化后两个全局事件各为 0.5, 因此每条轨迹关联到  $39^\circ$  或  $41^\circ$  的边缘概率也各为 0.5。

第二帧多出的  $15^\circ$  只有在给定检测概率、杂波空间密度和漏检模型后才能得到完整概率; 仅比较残差时, 近邻两对的指数代价为  $(1^2 + (-2)^2)/18 = 5/18 \approx 0.278$ , 但这不是完整 JPDA 后验。

为把这一帧也算完, 另设每条轨迹的检测概率  $p_D = 0.9$ , 三个观测处的 Poisson 杂波强度均为  $\kappa = 0.01 \text{ deg}^{-1}$ , 角度似然为  $g(z | \theta) = \exp[-(z - \theta)^2/18]/(3\sqrt{2\pi}) \text{ deg}^{-1}$ 。这组值只是本书算例的输入, 不是设备标定值。相对“全部观测来自杂波”的公共因子, 一个合法联合事件若有  $d$  条轨迹被检出、 $2 - d$  条漏检, 其未归一化权重为  $p_D^d (1 - p_D)^{2-d} \prod_{(i,j) \in A} g(z_j | \theta_i) / \kappa(z_j)$ ;  $A$  必须一对一, 未分配观测按杂波处理。

例如 A 配  $31^\circ$  的似然比为  $g(31 | 30)/\kappa \approx 12.579$ , B 配  $48^\circ$  的比为  $g(48 | 50)/\kappa \approx 10.648$ 。两条都检出的事件权重为  $0.9^2 \times 12.579 \times 10.648 \approx 108.499$ ; “仅 A 配  $31^\circ$ ” 的权重为  $0.9 \times 0.1 \times 12.579 \approx 1.132$ ; “仅 B 配  $48^\circ$ ” 为  $0.1 \times 0.9 \times 10.648 \approx 0.958$ 。

枚举两条轨迹各自漏检或配给三条观测、再排除两轨占用同一观测的情况, 共有  $4^2 - 3 = 13$  个合法事件。全部权重之和约为 110.600; 上述三个事件的归一化概率依次约为 0.9810、0.0102、0.0087, 其余十个事件合计约为 0.0001。

把包含同一轨迹关联的事件概率相加, A 配  $31^\circ$  的边缘概率约为 0.9912, B 配  $48^\circ$  的边缘概率约为 0.9897。  $15^\circ$  观测在本模型中几乎都由杂波解释; 若改变  $p_D$  或  $\kappa$ , 这些概率也会改变。

JPDA 在每帧枚举满足一对一约束、漏检和杂波模型的联合事件, 再把事件概率边缘化到每条轨迹; 交叉处的两条轨迹可能因共享两个观测而向同一均值靠拢。[JPDA 原始论文](#)。

MHT 把第三帧的两种全局历史都暂时保留, 等后续观测拉开后再按累计似然和剪枝规则决策, 因此更能延迟身份决定, 但假设树会增长。[MHT 原始论文](#)。这个例子只比较关联机制; 实际概率还必须包含检测概率、杂波强度和门控归一化。

LMB/ $\delta$ -GLMB 为目标维护标签，可输出带身份的轨迹。检测前追踪直接递推定位谱，保留未越过检测阈值的弱证据。

把连续定位谱接入 TBD 前，应先在独立验证集上校准“谱值—似然或似然比”的映射，并固定角度网格、归一化、温度缩放、声源数先验、信噪比与混响条件。网络 softmax 分数只在其类别集合内归一化，不能自动跨帧比较；出生、存活、漏检和杂波参数也要与同一标定口径匹配。若这些条件变化，应重新标定或把分数仅作为特征输入，而不是直接解释为概率。

活动耦合笛卡尔 DOA (Activity-Coupled Cartesian DOA, ACCDOA) 把向量方向编码为 DOA、向量长度编码为活动强度。它本身是逐帧声事件定位与检测的输出表示，不等同于追踪器；只有结合时序模型、平滑和身份关联后，才形成轨迹。

PHD 强度  $D_t(x)$  也不是“某处有人”的普通概率密度。它在区域  $A$  上的积分表示该区域内目标数的期望，因而总目标数估计来自  $\hat{N}_t = \int D_t(x) dx$ ，再按整数规则取值。目标位置通常从强度峰或聚类中心提取；“峰数就是人数”只是实现近似。PHD 避免显式枚举观测—目标关联，但只传播一阶矩，不保留目标身份，也不能完整描述目标间相关性。

下面的递推针对标准独立点目标模型：各目标独立演化，检测事件相互独立，每个被检测目标每帧至多产生一条观测，杂波是与目标观测独立的 Poisson 随机有限集，并忽略由既有目标衍生新目标 (spawning) 的过程，只用  $\gamma_t$  表示自发出生；为得到下面的标准闭式更新，还采用 Poisson 型预测多目标分布近似。PHD 的预测式为

$$D_{t|t-1}(x) = \int p_S(x') f_t(x | x') D_{t-1}(x') dx' + \gamma_t(x). \quad (9-9)$$

其中  $p_S$  是存活概率， $f_t$  是状态转移密度， $\gamma_t$  是新生目标强度。给定本帧观测集合  $Z_t$ ，标准 PHD 更新为

$$D_t(x) = [1 - p_D(x)] D_{t|t-1}(x) + \sum_{z \in Z_t} \frac{p_D(x) g_t(z | x) D_{t|t-1}(x)}{\kappa_t(z) + \int p_D(\xi) g_t(z | \xi) D_{t|t-1}(\xi) d\xi}. \quad (9-10)$$

$p_D$  是检测概率， $g_t(z | x)$  是目标在状态  $x$  时产生观测  $z$  的似然， $\kappa_t(z)$  是杂波强度。第一项保留可能漏检的目标；求和中的每个分母比较“该观测来自杂波”与“来自任一目标”的解释，因此杂波强度越大，单条观测增加的目标强度越少。

用两个离散角度网格做手算。预测强度质量为  $D^- = [0.8, 0.6]$ ，表示两个网格合计期望目标数 1.4；取  $p_D = 1$ ，本帧只有一个观测，其似然为  $g = [0.9, 0.1]$ ，杂波强度为 0.1。分母是  $0.1 + 0.9 \times 0.8 + 0.1 \times 0.6 = 0.88$ ，更新后两个网格的强度质量分别为  $0.72/0.88 \approx 0.818$  和  $0.06/0.88 \approx 0.068$ ，总和约 0.886。

总和小于 1，是因为这条观测仍有一部分概率由杂波解释；若  $p_D < 1$ ，还要加上第一项的漏检质量。

这个离散例子只解释更新各项，不能替代连续状态中的积分、峰提取和轨迹身份管理。相关混响峰不满足独立杂波假设，扩展目标还可能在一帧产生多条观测；这两类情况需修改似然或杂波模型，或采用相应的扩展目标、多目标滤波模型，不能直接套用上式。

粒子或高斯混合只是表示和计算强度函数的不同方法。目标数由强度积分估计，位置再从峰或聚类中心提取。PHD 原始论文；音频视觉粒子实现见 Liu et al. 2019。

多目标追踪还要估计观测与轨迹的对应关系以及目标数。JPDA 和 MHT 显式处理关联；PHD 传播随机有限集的一阶强度；LMB 保留目标标签；检测前追踪保留未越过检测阈值的弱证据。

最优子模式分配距离（Optimal Subpattern Assignment, OSPA）同时度量定位误差和目标数误差，但不评价身份连续性。

### 9.3.3 可执行基线与双目标交叉实验

可执行单目标基线与高级算法边界。codes/array\_tutorial/tracking.py 提供常速度角度 Kalman 滤波器、 $[-180^\circ, 180^\circ)$  环绕、系统重采样和圆周角 SIR 粒子滤波器。

ConstantVelocityKalman 的状态单位是 [度, 度/秒]；每帧先用实际秒数 dt 调用 predict()，有观测时再以角度方差调用 update()，缺测时不调用更新。协方差使用 Joseph 形式。它与算例9-1的“度/帧”不同，比较前应转换状态、转移矩阵及过程噪声单位。

CircularParticleFilter 用最短圆周角差的高斯目标项与均匀杂波项混合更新权重，按有效粒子数决定是否系统重采样；它只估计单个圆周角，不包含速度粒子、有限扇区反射或轨迹身份。该高斯项是小角度误差模型，不是一般宽分布的严格环绕正态密度。

联合示例用 .venv/bin/python -m codes.examples.ch06\_09\_baselines 运行，测试见 tests/test\_codes\_aec\_wpe\_sep\_track.py。测试覆盖  $179^\circ$  与  $-179^\circ$  的最短新息、缺测时角度方差增长、Joseph 更新后的对称半正定性、远距离高置信观测的对数权重、退化权重的系统重采样，以及对称后验下未定义的圆周均值。

教学 Kalman 类的过程噪声矩阵  $Q$  已按一次预测间隔离散化；若 dt 改变，不能继续照搬同一个  $Q$ 。粒子后验的圆周合向量接近零时，代码会明确报错，而不是返回由浮点残差决定的任意角度。

如何重算  $Q$  取决于过程噪声模型，练习 E09-04 比较两种不同定义。粒子重采样阈值则按有效粒子数的同一尺度指定：resample\_if\_needed() 接受  $[0, N]$  内有限实数，0 表示关闭，默认是  $N/2$ ；布尔值、数组、负数、超过粒子数或非有限值均报错，且不改变粒子和随机数状态。



设备只搜索有限扇区时不得使用圆周环绕；还需测试迟到/乱序观测、长缺测、错误时间戳、野点门控、目标交叉、轨迹出生/确认/删除、ID 重用和消息超时。无有效观测时只预测并传播协方差，超过有效期后回到搜索模式，不能把外推方向当作新观测。

本书合成实验：两目标交叉、短暂缺测与控制限速。 `tracking_crossing_dropout_demo.py` 使用确定的角度观测，不生成语音或设备录音。为便于手算，每步间隔刻意取 1 s；两条轨迹初态分别为  $[20^\circ, +10^\circ/\text{s}]$ 、 $[60^\circ, -10^\circ/\text{s}]$ ，初始协方差都是  $I$ ，每步过程噪声  $Q = \text{diag}(0.1, 0.01)$ ，角度观测方差为  $1 \text{ deg}^2$ 。这些是实验指定的滤波参数，并非从真实定位器标定得到。

示例在  $15^\circ$  门内穷举两轨与最多两条观测的一对一配对，优先关联最多的门内观测，再选择圆周角残差平方和最小者；若代价完全相等，按轨迹和观测输入顺序决定。

这个两轨最小代价关联是全局最近邻（Global Nearest Neighbour，GNN）分配的教学缩例，不实现 JPDA、MHT、轨迹出生或删除。Stone Soup 固定版本的 `neighbour.py` 区分逐次贪心的 `NearestNeighbour` 与联合分配的 `GlobalNearestNeighbour`；本例只复算后一类的两轨分配思想，没有调用该框架的假设器和轨迹管理。[Stone Soup 固定源码](#)。

第 2 s，两轨按匀速模型都预测到  $40^\circ$ ，输入顺序是 B 的  $39^\circ$ 、A 的  $41^\circ$ 。两种一对一配对的残差平方和同为  $1^2 + 1^2 = 2 \text{ deg}^2$ 。示例的并列代价规则于是把 B 的观测给轨迹 A，把 A 的观测给轨迹 B；这一帧有两次标签错配。

去掉标签后，观测位置集合与真值集合都是  $\{39^\circ, 41^\circ\}$ ，按后文式(9-11)取任何正的  $p, c$ ，该集合的 OSPA 仍为 0。这里算的是未滤波的观测集合；滤波后的两条角度还有非零位置误差，不能把两者混称为零误差。

下表逐帧比较最小代价关联结果与“用真值标签做关联”的诊断对照。真值标签只用于评价和对照更新，不进入最小代价关联的代价。角度误差是滤波后轨迹 A、B 各自相对其真值的最短圆周角绝对误差；方差是最小代价关联轨迹 A 的角度方差，数值保留两位小数。运行命令为

`.venv/bin/python -m codes.examples.tracking_crossing_dropout_demo`，独立手算检验见 `test_codes_tracking_crossing_dropout.py`。

| t (s) | 观测与真标签              | 分配至 A/B | 错配数 | 硬关联角误差 A/B (度) | 真值关联角误差 A/B (度) | A 角度方差 (度 <sup>2</sup> ) |
|-------|---------------------|---------|-----|----------------|-----------------|--------------------------|
| 1 s   | 30° (A)、<br>50° (B) | A / B   | 0   | 0.00 / 0.00    | 0.00 / 0.00     | 0.68                     |
| 2 s   | 39° (B)、<br>41° (A) | B / A   | 2   | 1.68 / 1.68    | 0.32 / 0.32     | 0.68                     |



| t (s) | 观测与真标签          | 分配至 A/B | 错配数 | 硬关联角误差 A/B (度) | 真值关联角误差 A/B (度) | A 角度方差 (度 <sup>2</sup> ) |
|-------|-----------------|---------|-----|----------------|-----------------|--------------------------|
| 3 s   | 30° (B), A 静默   | 缺测 / B  | 0   | 1.00 / 0.36    | 1.00 / 0.36     | 1.80                     |
| 4 s   | 60° (A)、20° (B) | A / B   | 0   | 0.28 / 0.18    | 0.28 / 0.18     | 0.79                     |

第 3 s 轨迹 A 只预测，角度方差从上一帧约 0.68 deg<sup>2</sup> 增到 1.80 deg<sup>2</sup>；第 4 s 再得到 A 的观测后下降到约 0.79 deg<sup>2</sup>。这只是预置轨迹的短时维持与重新配对：代码没有判断说话人是否离开房间，也没有实现出生、删除或永久身份确认。第 2 s 的错配由完全并列的角度代价与指定输入顺序造成；它说明单靠这一帧角度无法判定身份，不能据此推出这一关联规则在所有交叉场景都会错，也不能把真值关联诊断当成可部署算法。

脚本另用一条没有观测的轨迹检查控制延迟。初态 [20°, 10°/s]、 $P_0 = I$ ，只按上述  $Q$  预测两次，则角度依次为 30°, 40°；由  $P_1^- = FIF^T + Q$  得角度方差 2.10 deg<sup>2</sup>，第二次预测为  $2.10 + 2(1.00) + 1.01 + 0.10 = 5.21 \text{ deg}^2$ 。

若波束方向从 20° 起，每秒最多转 5°，两次只能走到 25°, 30°，相对预测方向分别滞后 5°, 10°。这个数例量化了限速代价，不包含定位计算、消息传输或实际波束权重切换的延迟；设备应按真实帧间隔、目标运动与可接受滞后重新选限速值。

进一步的实现可按 FilterPy 和 Stone Soup 的固定版本阅读，源码工作目录、许可和入口由 [SOURCES.lock.json](#) 管理。FilterPy 的 [kalman/EKF.py](#)、[UKF.py](#)、[IMM.py](#) 分别定位非线性更新和运动模型切换；Stone Soup 的 [dataassociator/probability.py::JPDA](#) 处理联合关联，[updater/pointprocess.py::PHDUpdater](#) 配合 [mixturereducer/gaussianmixture.py::GaussianMixtureReducer](#) 完成 GM-PHD 更新与分量合并、剪枝。具体阅读顺序、实验输入和失败情况见[空间处理与追踪研究](#)。

把位置追踪例子改成麦克风方向追踪时，至少要重写三处。观测模型应输出方位角或方向单位向量，不能继续使用二维位置残差；门控距离要使用相应协方差与角度环绕；杂波强度必须与观测空间的测度一致，例如每弧度的预期假峰数。检测概率还要反映说话人静默和定位器漏检，不能直接照搬雷达示例。

GM-PHD 的高斯权重和表示期望目标数，不要求归一到 1。出生分布没有覆盖某个方向时，新目标可能一直不能形成足够强的分量；剪枝阈值过高则会删掉弱源，因此应记录每帧删去的总强度质量。

JPDA 也需要明确漏检事件和一对一约束；在两人交叉时，软关联可能混合轨迹，并不自动保持说话人身份。[Stone Soup JPDA 教程源码](#)；[GM-PHD 官方教程](#)，核实于 2026-09-22。

MHT 已有可阅读的受限参考：Stone Soup 的 `docs/examples/dataassociation/mht_example.py` 使用 `MFAHypothesiser` 延续多帧观测历史，再由 `MFADataAssociator` 做滑窗多帧分配和 N-scan 剪枝。该示例需要 OR-Tools，使用三帧窗口、预置三个目标及方位/距离观测，没有出生或消亡，不能直接代表变人数的声学追踪。[固定 MHT 示例](#)。可先用相同观测比较窗口 1 与 3，再检查交叉和缺测；本书未执行这一上游实验。

CPHD、LMB/ $\delta$ -GLMB 可在 [Vo 作者 MATLAB 工具包页面](#)找到研究代码来源，但页面限定 academic/research 使用，不能把它写成已确认通用再分发许可的源码。检测前追踪也仍需匹配具体观测模型。某个库的基类说明提到这些家族，不等于该版本已实现全部算法；给 PHD 分量附加临时标签也不等于实现了 GLMB。正式采用前仍要验证出生/存活/漏检模型、假设截断、身份切换和运行成本。


## 9.4 定位、追踪与波束形成的接口

---

在线追踪器向波束形成器提供因果滤波或预测方向和置信度；只有离线算法显式使用当前帧之后的观测回修过去状态时，才称为平滑（smoothing）。若定位又使用波束形成后的信号，两个模块会相互影响，因此需要限制更新速率并处理静默期。

图23 远场语音前端：播放参考、音频主链与三条条件支路

实线=音频；红/橙=参考、方向或控制；紫点线=GSS统计；绿点划线=神经旁路。



追踪器兼有因果滤波和预测作用：它减小 DOA 抖动，并在目标短时静默时外推方向。图 23 中，定位与追踪只向解析波束形成器提供方向，不直接控制 GSS 掩码；VAD、远端活动和双讲检测通过控制面约束状态更新。

波束方向的变化上限应按帧率、目标最大转速和允许跟随延迟确定。静默超时或唤醒词触发时还需保持或重置状态，避免定位与波束权重相互影响而振荡。

| 追踪输出字段            | 含义与单位                       | 消费方必须检查          |
|-------------------|-----------------------------|------------------|
| frame_id / 坐标系    | 阵列坐标、设备坐标或世界坐标；<br>角度零点与正方向 | 与导向矢量使用同一坐标约定    |
| measurement_time  | 产生定位观测的采样时刻                 | 不可用消息到达时刻替代      |
| publish_time      | 追踪结果发布时刻                    | 用于测量计算与调度延迟      |
| 状态与协方差            | 角度/角速度或位置/速度，以及同维协方差        | 单位、维度、圆周角新息与置信区间 |
| 活动/存在概率           | 当前目标存在或发声的证据                | 阈值、校准集、静默保持策略    |
| track_id 与生命周期    | 出生、确认、维持、删除和重用规则            | ID 不能等同于永久说话人身份  |
| last_update / 有效期 | 最近一次真实观测更新与允许外推时长           | 超时后保持、降置信度或回搜索模式 |

例如目标角速度为  $30^{\circ}/\text{s}$ ，波束形成器收到的状态比采样时间晚 80 ms；若直接使用旧角度，确定性外推误差可达  $30 \times 0.080 = 2.4^{\circ}$ 。消费方应使用 measurement\_time 和角速度外推到实际生效时刻，并把协方差随预测步长增大；超过接口约定的有效期就不能继续把旧方向当作高置信观测。

多目标结果可用最优子模式分配距离（optimal subpattern assignment，OSPA）评价。若真值集  $X$  有  $m$  个目标，估计集  $Y$  有  $n \geq m$  个目标，截断距离为  $c$ ，阶数为  $p$ ，则

$$d_p^{(c)}(X,Y) = \left[ \frac{1}{n} \min_{\pi} \sum_{i=1}^m \min\{c, d(x_i, y_{\pi(i)})\}^p + \frac{c^p(n-m)}{n} \right]^{1/p}。$$

(9-11)

式(9-11)先写  $n \geq m$ ；若  $m > n$ ，交换  $X, Y$  的角色，因此距离保持对称。边界约定是  $d_p^{(c)}(\varnothing, \varnothing) = 0$ ；若仅一侧为空、另一侧非空，则距离为  $c$ 。

第一项是最优配对后的截断定位误差，第二项惩罚目标数不一致，最后还要除以较大的集合大小。

若状态是完整圆周方位，应使用  $d(\theta_1, \theta_2) = \min(|\theta_1 - \theta_2|, 360^{\circ} - |\theta_1 - \theta_2|)$ ；图22的  $0^{\circ} \sim 120^{\circ}$  有限扇区不是圆周，不能套用环绕距离。

OSPA 不保留身份，所以身份切换要另报身份切换次数（Identity Switch，ID switch）等轨迹指标。

这个定义来自 Schuhmacher、Vo 与 Vo 的 OSPA 原始论文 (IEEE TSP 56(8), 2008, pp. 3447 – 3457, DOI 10.1109/TSP.2008.920469)。截断距离  $c$  同时限制单个定位误差并设定漏检/虚警的惩罚尺度, 因此比较系统时必须使用相同的  $p$ 、 $c$ 、坐标和角度环绕约定。

## 9.5 自由场移动声源的双麦音频与传播真值

前文的[声像移动试听](#)只改变左右声道增益, 不包含阵列传播时差。为让读者听到并复算真实传播模型下的两麦差异, 本书另生成一组[独立的自由场合成样本](#): [原始两音调源](#)、[固定在起点的双麦输出](#)、[沿直线运动的双麦输出](#)。它们是数学合成信号, 不是真实语音、房间录音或 LOCATA 数据, 也不计入主清单的 60 个 WAV。

几何与时间口径固定如下: 采样率 16 kHz, 持续 2 s; 两麦坐标分别为  $(-0.05, 0)$  m、 $(0.05, 0)$  m。声源从  $(-0.8, 1.5)$  m 出发, 以  $(0.8, 0)$  m/s 匀速运动, 声速取 343 m/s。

设发射时刻为  $u$ , 麦克风  $m$  的接收时刻为  $t$ , 则本书求解

$$t = u + \frac{\|\vec{p}_0 + \vec{v}u - \vec{m}_m\|}{c}, \quad x_m(t) = \frac{1 \text{ m}}{\|\vec{p}_0 + \vec{v}u - \vec{m}_m\|} s(u). \quad (9-12)$$

每个接收样本都在相应的迟滞发射时刻求源信号, 并用距离倒数表示自由场声压衰减;  $s(u)$  是 220 Hz 和 320 Hz 两个正弦分量加 20 ms 平滑起始的确定性测试波形。这一模型自然包含因运动导致的传播时延变化。生成代码检验了方程残差, 并对三份 WAV 采用同一个导出增益, 没有逐文件峰值匹配。

每 160 点保存一次轨迹真值。方位角从  $+y$  轴向  $+x$  轴为正。起点横坐标为  $-0.8$  m, 故  $\theta_0 = \arctan(-0.8/1.5) \approx -28.07^\circ$ 。

在  $u = 0.99$  s, 横坐标  $-0.8 + 0.8 \times 0.99 = -0.008$  m, 方位角约  $-0.31^\circ$ ; 末段  $u = 1.99$  s 的横坐标是 0.792 m, 方位角约  $+27.83^\circ$ 。这些时刻属于保存的轨迹格点; 声音到达麦克风的接收时刻还要加传播时延。

把同一发射时刻到麦 1、麦 0 的传播时间之差定义为有符号 TDOA:  $\tau_{1-0}(u) = [r_1(u) - r_0(u)]/343$ , 其中  $r_m$  是声源到麦  $m$  的距离。起点声源在左侧, 更靠近麦 0, 所以  $r_1 - r_0 > 0$ , 麦 1 的到达更晚。按上述坐标代入距离公式, 起点约为  $+0.0001372$  s, 乘以 16000 后是  $+2.19$  采样; 末段声源已在右侧, 约为  $-0.0001361$  s, 即  $-2.18$  采样。两侧符号相反, 不能只报 TDOA 的绝对值。

清单中的时间格点按声源轨迹的全局时钟取样; 同一行 TDOA 比较的是该时刻发出的波到两麦的传播时间, 并非两麦在同一采样索引处的波形峰差。逐帧值、坐标、统一增益及各文件摘要保存在清单中。[静止解析极限和符号测试](#)独立核对[生成器](#)。



这里没有墙面反射、空气吸收、声源和麦克风指向性，也没有多人交叉或活动缺测。听到的音高、声像和电平变化不能直接当作某个 DOA 追踪器的准确率；若要评价追踪，还需对输出运行固定定位器，按相同时间戳比较逐帧误差和漏检，并另报波束控制滞后。真实移动录音可另按 [LOCATA 官方任务说明](#) 选择任务 3（静止阵列、单移动说话人），明确使用的录音和真值版本。

## 9.6 本章练习

1. KF 手算 + 静默外推：沿用算例 9-1 的末态（估计  $[30.72, 0.513]^\top$ ，协方差左上角 3.705）。假设接下来两帧说话人静默、无观测，只做预测不做更新：手算两帧后的角度估计与角度方差，并说明波束应使用哪个方向。
- 答案要点：每帧角度  $+0.513^\circ$ ，两帧后约  $31.75^\circ$ ；在本题给定的  $\mathbf{F}$  与  $\mathbf{Q}$  下，角度方差约按  $3.705 \rightarrow 4.49 \rightarrow 5.80$  增长。一次预测和两次预测后的完整协方差依次约为

$$\begin{array}{ll} \text{一次预测:} & \begin{bmatrix} 4.49 & 0.47 \\ 0.47 & 0.27 \end{bmatrix}, \\ \text{两次预测:} & \begin{bmatrix} 5.80 & 0.74 \\ 0.74 & 0.28 \end{bmatrix}. \end{array}$$

波束可暂时使用外推值。

若目标允许的最大角速度为  $\omega_{\max}$ ，帧间隔为  $\Delta t$ ，单帧转角限值应与  $\omega_{\max} \Delta t$  同量级，再根据允许跟随延迟和机械转速标定；不能在无帧率时固定写成  $3 \sim 5^\circ/\text{帧}$ 。

2. 数据关联二选一：两条轨迹（A 在  $20^\circ$ 、B 在  $60^\circ$ ），本帧两个观测（ $22^\circ$ 、 $58^\circ$ ），JPDA 和最近邻分别如何处理？再加入一个  $19^\circ$  的杂波假峰，并假设门内观测至多分给一条轨迹、每条轨迹至多取一个观测，比较两种方法。

答案要点：无杂波时，最近邻把  $22^\circ$  配给 A、 $58^\circ$  配给 B；JPDA 在噪声很小且无其他可行事件时也会让这两对关联概率占优。

加入  $19^\circ$  后，硬最近邻会把距离 A 仅  $1^\circ$  的假峰分给 A，把  $58^\circ$  分给 B， $22^\circ$  留作未分配观测。JPDA 不先固定一组配对，而是枚举满足一对一约束、门控、漏检和杂波模型的联合事件，再求每个“轨迹—观测”对的边缘关联概率；A 的更新会综合  $19^\circ$ 、 $22^\circ$  及漏检事件。

若只使用高斯角度残差且杂波模型过弱，JPDA 也可能偏向  $19^\circ$ ，因此软关联不是自动识别杂波，还要标定检测概率、杂波强度和门限。[JPDA 原始论文](#)。

3. PHD + OSPA：某帧从 PHD 强度中提取出  $30^\circ$  和  $70^\circ$  两个目标，真值是  $32^\circ$  处一人。人数估对了吗？取  $p = 1$ 、 $c = 10^\circ$ ，算出这一帧的 OSPA。

答案要点：人数估计为 2，真值为 1。最优配对把  $30^\circ$  与  $32^\circ$  配在一起，截断定位误差为  $2^\circ$ ；多出的  $70^\circ$  目标产生  $10^\circ$  的基数惩罚。按较大集合大小 2 归一化，OSPA 为  $(2^\circ + 10^\circ)/2 = 6^\circ$ 。若把  $70^\circ$  错配给真值，其定位误差先截断为  $10^\circ$ ，结果不会更小。

4. VAD 门控 + 波束限速：说话人突然静默 5 帧（无观测），追踪只做预测；第 1 问：WPE、噪声协方差和降噪器的噪声功率各应怎样更新？第 2 问：已知目标最大角速度  $\omega_{\max}$  和帧间隔  $\Delta t$ ，5 帧内转角限值如何设定，之后如何处理？

答案要点：静音且参考能量不足时冻结 WPE 系数，避免病态统计；确认无目标语音时，可以更新噪声协方差和降噪器的噪声功率。目标语音活动时则避免把目标泄漏写入噪声统计，WPE 是否更新由其语音活动和矩阵条件共同决定。

单帧转角限值可以  $\omega_{\max} \Delta t$  为物理起点，5 帧累计上限为  $5\omega_{\max} \Delta t$ ；超过保持时间或不确定度阈值后，应降低波束更新置信度或回到搜索模式。

## 可运行练习 E09-01~E09-06

E09-01~E09-05 运行 `.venv/bin/python -m codes.examples.exercises_enhancement`，源码见 [exercises\\_enhancement.py](#)；E09-06 使用本节的交叉实验脚本。这些练习使用方向数值，不通过左右声道音量模拟阵列定位；后者的声像不能代替麦克风传播时延模型。

- E09-01：把“每帧”改为“每秒”。初态  $[30^\circ, 5^\circ/\text{s}]$ ， $P = \text{diag}(4, 1)$ ；每 0.1 s 预测一次，采用已为此间隔离散化的  $Q = \text{diag}(0.1, 0.01)$ 。连续两次缺测，求状态和协方差。

解答：每步角度增加  $5 \times 0.1 = 0.5^\circ$ ，两步状态依次是  $[30.5, 5]^\top$ 、 $[31, 5]^\top$ 。按式(9-3)得到

$$P_1^- = \begin{bmatrix} 4.11 & 0.1 \\ 0.1 & 1.01 \end{bmatrix},$$

$$P_2^- = \begin{bmatrix} 4.2401 & 0.201 \\ 0.201 & 1.02 \end{bmatrix}.$$

若误把 5 当成“度/帧”，两帧会外推到  $40^\circ$ 。若改采样间隔，还要从声明的运动噪声模型重新离散化  $Q$ ；本题没有给出可任意换帧率的连续噪声密度。

- E09-02：跨越  $\pm 180^\circ$  时朝哪边更新？当前预测为  $179^\circ$ ，观测  $-179^\circ$ ，预测角度方差和观测方差都为 1，角速度与角度无互协方差。只做一次观测更新。

解答：原始差为  $-358^\circ$ ，式(9-7)得到最短新息  $+2^\circ$ 。角度增益为  $1/(1+1) = 0.5$ ，更新到  $180^\circ$  后映射为  $-180^\circ$ ；后验角度方差为 0.5。有限搜索扇区的两端不自动相邻，只有完整圆周约定才适用这个操作。

- E09-03：有效粒子数与 CDF 索引。四个粒子的归一化权重为  $[0.1, 0.2, 0.6, 0.1]$ ，阈值取  $N/2 = 2$ 。是否应触发重采样？再为演示人为强制一次，取起点  $u_0 \approx 0.1592404$ 、间隔 0.25，写出零起始祖先索引。

解答：平方和为  $0.01 + 0.04 + 0.36 + 0.01 = 0.42$ ，有效粒子数约 2.381，大于 2，因此阈值判决不触发。CDF 为  $[0.1, 0.3, 0.9, 1]$ ，四个位置约为 0.15924、0.40924、0.65924、0.90924，对应索引  $[1, 2, 2, 3]$ 。代码起点来自 NumPy `default_rng(0)` 的首个随机数除以 4。重采样后四个新粒子权重均为 0.25。该过程重新分配有限计算样本，没有增加观测信息，不能把单次均值变化解释成精度必然提高。[Stone Soup 官方系统重采样教程](#)。

- E09-04：同样叫“白噪声”，为什么  $Q$  不同？状态为  $[\theta, \dot{\theta}]^\top$ ，单位为度、度/秒，间隔  $\Delta t = 0.1$  s。比较连续白角加速度的强度  $q = 2 \text{ deg}^2/\text{s}^3$ ，以及每个间隔内恒定、跨间隔独立的随机角加速度方差  $\sigma_a^2 = 4 \text{ deg}^2/\text{s}^4$ 。

解答：连续模型通过积分传播噪声。令  $u$  表示噪声作用到区间终点的剩余时间，则贡献方向为  $[u, 1]^\top$ ；对  $u \in [0, \Delta t]$  积分，得到

$$\begin{aligned} Q_c &= q \int_0^{\Delta t} \begin{bmatrix} u^2 & u \\ u & 1 \end{bmatrix} du \\ &= q \begin{bmatrix} \Delta t^3/3 & \Delta t^2/2 \\ \Delta t^2/2 & \Delta t \end{bmatrix} \\ &\approx \begin{bmatrix} 0.000666667 & 0.01 \\ 0.01 & 0.2 \end{bmatrix}. \end{aligned}$$

逐段恒定模型中，一次角加速度使角度、角速度分别改变  $a\Delta t^2/2$ 、 $a\Delta t$ ，所以

$G = [\Delta t^2/2, \Delta t]^\top$ ， $Q_d = \sigma_a^2 G G^\top = \begin{bmatrix} 0.0001 & 0.002 \\ 0.002 & 0.04 \end{bmatrix}$ 。各矩阵左上、右上、右下的单位分别为度<sup>2</sup>、度<sup>2</sup>/秒、度<sup>2</sup>/秒<sup>2</sup>。

两个输入参数的单位和随机过程不同，不能用相同数值替换后判断哪个滤波器“更好”。更改帧间隔时，应沿所选模型重新计算；本题使用本书手算，定义和公式可与 [FilterPy 官方 Q\\_continuous\\_white\\_noise\(\)](#)、[Q\\_discrete\\_white\\_noise\(\)](#) 源码核对，核实于 2026-09-22。

- E09-05：环绕新息怎样影响门控？预测角  $179^\circ$ 、观测角  $-179^\circ$ ，新息方差为  $S = 4 \text{ deg}^2$ 。本题规定平方马氏距离门限为 9，比较直接相减和圆周环绕后的判决。

解答：直接相减为  $-358^\circ$ ，平方马氏距离为  $358^2/4 = 32041$ ，被拒绝。环绕后的新息是  $+2^\circ$ ，距离为  $2^2/4 = 1$ ，被接受。这里  $S = H P^- H^\top + R$  包含预测和测量两部分，不能只用测量方差代替。

门限 9 只是本题输入，不是任意 DOA 误差分布下的通用判据。有限搜索扇区不能强行环绕；迟到观测应先按测量时间处理，不能仅靠放宽门限补偿时间戳错误。

- E09-06：交叉时为什么位置对了，身份仍可能错？两轨都预测  $40^\circ$ ，先到的观测是 B 的  $39^\circ$ ，后到的是 A 的  $41^\circ$ 。按本节最小代价关联的并列代价规则分配，求两种一对一配对的平方残差和、错配数，以及无标签观测集对真值集的 OSPA。再从初态  $[20^\circ, 10^\circ/\text{s}]$ 、 $P_0 = I$  出发，只预测两次且每步采用  $Q = \text{diag}(0.1, 0.01)$ 、 $\Delta t = 1$  s；求角度方差和最大  $5^\circ/\text{s}$  的波束控制角度。

解答：两个配对的代价均为  $1^2 + 1^2 = 2 \text{ deg}^2$ ，按给定输入顺序会把 B 的观测配给 A、A 的观测配给 B，产生两次标签错配。观测集与真值集均为  $\{39^\circ, 41^\circ\}$ ，因此无标签观测集 OSPA 为 0；这不表示滤波轨迹无误差或身份正确。

两次无观测预测的角度方差为 2.10, 5.21  $\text{deg}^2$ ；方向预测为  $30^\circ, 40^\circ$ ，限速后的波束方向为  $25^\circ, 30^\circ$ 。本题没有模拟说话人出生、删除、真实声场与设备时延，不能把单次并列代价当作方法的普遍错误率。

# 第 10 章 · 工程实现、评测与产业实践

本章把前九章的算法放进真实系统，讨论模块启用条件、信号取点、资源预算和验收方法。

本章常用缩写如下：

| 缩写        | 中文名与英文全称                                                                    |
|-----------|-----------------------------------------------------------------------------|
| AFE       | 音频前端（Audio Front End）                                                       |
| AEC       | 声学回声消除（Acoustic Echo Cancellation）                                          |
| WPE       | 加权预测误差去混响（Weighted Prediction Error）                                        |
| NS / AGC  | 噪声抑制（Noise Suppression） / 自动增益控制（Automatic Gain Control）                    |
| VAD       | 语音活动检测（Voice Activity Detection）                                            |
| KWS / ASR | 关键词唤醒（Keyword Spotting） / 自动语音识别（Automatic Speech Recognition）              |
| SRO       | 采样率偏移（Sampling Rate Offset）                                                 |
| RTF       | 实时因子（Real-Time Factor）                                                      |
| STFT      | 短时傅里叶变换（Short-Time Fourier Transform）：把波形变成逐帧、逐频点的复系数；多通道时逐通道计算             |
| GSS       | 导引源分离（Guided Source Separation）：用已知说话人活动引导多通道掩码估计                           |
| cACGMM    | 复角中心高斯混合模型（Complex Angular Central Gaussian Mixture Model）：GSS 中估计空间掩码的一种模型 |
| SCM       | 空间协方差矩阵（Spatial Covariance Matrix）：本章的 GSS 支路用多通道复系数及掩码估计，供解析波束计算权重         |

本章中的 RTF 均指实时因子；波束形成中的“目标相对传递函数”（relative transfer function）不缩写为 RTF，以免混淆。

## 10.1 参考链路 with 端到端延迟

音频前端没有适用于所有产品的固定流水顺序。图 23 给出的是一条参考链路，只表达模块间的依赖，不表示每个项目都要启用全部模块。



音频主链是“多通道采集 → AEC → WPE → 解析波束形成 → 单通道 NS/AGC → KWS/ASR”。

定位与追踪读取多通道特征，只向解析波束提供带时间戳的方向状态。说话人分割约束 GSS/cACGMM 掩码；掩码与同一 WPE 阶段输出、未做方向归一化的多通道 STFT 一起形成目标/干扰 SCM，再送入波束形成。

神经或连续语音分离（Continuous Speech Separation, CSS）是 WPE 后绕过解析波束的替代音频路径，不与“GSS 掩码—SCM—波束”合并成一个模块。

若它输出多条语流，后续的单通道 NS/AGC 与识别须按每条输出流分别配置，或先按任务选出一路；不能把多路直接当作一条单声道信号送入后端。若网络本身已完成抑噪或电平处理，还要通过对照决定是否保留相应后处理。

图23 远场语音前端：播放参考、音频主链与三条条件支路

实线=音频；红/橙=参考、方向或控制；紫点线=GSS统计；绿点划线=神经旁路。




图 23 按较完整的语音交互系统绘制。远端音频先经过混音、均衡和音量控制；AEC 的 render tap 取在这些播放处理之后、DAC/功放之前，扬声器经房间和机壳耦合回麦克风形成声学回路。虚线表示活动控制，实线表示音频、特征或统计量依赖。

确定任务后，可按下面条件省去模块或改变控制路径：

- 设备不播放声音，或不需要边播边听时，可以不启用 AEC。
- 晚期混响已不影响目标指标时，可以不启用 WPE。
- 目标方向固定时，波束形成可以直接使用已知方向，不必持续定位和追踪。
- 只有多人重叠且下游确实需要独立语流时，才需要语音分离。
- VAD、远端活动检测和双讲检测是控制信号。它们不应画成主音频流中的串行处理框。

图中 AEC 的“最先处理”是指：启用 AEC 时，应在会破坏播放参考与回声之间线性关系的 NS、AGC 等处理之前消除回声，并不表示任何系统都必须以 AEC 开头。

确定实际模块后，还要重新核对各信号取点。AEC 通常位于会改变回声路径关系的非线性处理之前。参考信号应覆盖实际播放链中的增益、均衡和混音变化。若参考取在这些处理之前，AEC 看到的参考与扬声器实际播放内容不一致。

WPE、波束和 NS 的先后则要结合实现判断：多通道 WPE 需要多通道输入；单通道 WPE 可以放在波束之后；神经网络若联合完成波束与去混响，也不能再套用传统串行顺序。

10.1.1 延迟不能把每个模块的耗时直接相加

端到端延迟应沿实际关键路径测量，并分成五类：


| 类别      | 含义                                             | 常见来源                                             |
|---------|------------------------------------------------|--------------------------------------------------|
| 前瞻或算法等待 | 输出当前样本前必须等待的未来输入                               | 居中窗、双向网络、判决确认窗                                   |
| 缓冲      | 驱动、直接存储器访问（Direct Memory Access, DMA）、网络或帧拼接等待 | 声卡周期、抖动缓冲、整帧推理                                   |
| 计算      | 当前数据到输出完成的执行时间                                 | 快速傅里叶变换（Fast Fourier Transform, FFT）、矩阵分解、神经网络推理 |
| 调度      | 任务虽已就绪但尚未运行                                    | 操作系统抢占、队列拥塞、加速器排队                                |
| 解码与交互   | 前端之后的关键路径                                      | 流式 ASR 解码、网络往返、播报准备                              |

同一帧内有多个模块串行执行时，它们的计算时间要相加；并行分支取耗时最长的关键分支；流水重叠的等待只沿关键路径计一次。在线 WPE 只使用历史帧时，本身不需要未来帧，但其分帧、平滑和实现缓冲仍可能产生延迟。

可把第  $p$  条路径写成

$$\begin{aligned} L_p &= L_{\text{lookahead}} + L_{\text{buffer}} + L_{\text{compute}} + L_{\text{schedule}} + L_{\text{decode}}, \\ L_{\text{e2e}} &= \max_p L_p. \end{aligned} \tag{10-1}$$

图25 端到端延迟关键路径（示例数字非产品指标）



连续音频：统计到可用音频输出；首个判决：另含确认窗；端点 hangover：只延后结束事件。WPE/追踪历史状态不是未来帧等待。

图 25(a) 把“采集/帧就绪等待”示意为 32 ms，再与未来帧前瞻 16 ms、首个判决确认 25 ms、计算 14 ms 和调度 6 ms 组成一条 93 ms 的示例关键路径。这里的 32 ms 是工作表示例，不等同于 STFT 窗长，也不是所有 32 ms 窗都会增加 32 ms 算法等待；窗的左右对齐、声卡周期、帧移和模块何时开始计算都会改变实际值。

图 25(b) 另行区分三条口径：连续增强音频只计其实际前瞻、缓冲、计算与调度；首个 KWS/ASR 判决还可能等待确认窗；端点 hangover 只延后“语音结束”事件，不应自动计入连续音频或首个判决。

WPE 历史帧、追踪状态、递归协方差和因果 AGC 时间常数是历史状态，不能机械当作未来等待。

这些数字只说明记账方法，没有包含图外可能存在的解码和交互延迟。实际系统应在声学输入与最终输出之间记录时间戳或回采脉冲，分别测量冷启动、稳定运行和最不利调度条件。

把 STFT 窗长从 32 ms 改为 16 ms，也不等于必然省下 16 ms：只有依赖完整窗或未来样本的等待发生变化，关键路径才会缩短。

延迟报告不能只有平均值。稳定运行阶段至少给出中位数（p50）与尾延迟（如 p95、p99）、样本数和测量时长；冷启动另报模型加载、内存分配和状态填充所需时间。若系统存在不同设备、网络或调度模式，应分别报告，而不是把所有样本混成一个分位数。

测量点也要写清，例如“音频驱动时间戳 → 第一块可播放增强 PCM”与“音频入口 → 首个 ASR token”是两条不同关键路径。分位数还需固定计算方法；第 11 章 E11-04 比较最近秩与线性插值，两者在小样本下可能相差较大。

### 10.1.2 实时回调的期限与数据搬运

声卡回调线程的首要目标是按时交付下一块音频。回调中临时分配大数组、等待互斥锁、访问磁盘、打印日志或执行时间不确定的模型推理，都可能让驱动错过期限。[PortAudio 官方回调说明](#)列出了分配、输入输出和互斥等可能产生无界等待的操作。

一种便于检查的分工是：

- 回调复制交织或非交织样本，记录设备时间戳和状态位，写入预分配缓冲；
- 工作线程读取数据，执行 AEC、波束及后端；
- 监控线程汇总期限违约、丢样和高水位，不让日志写入阻塞回调。

回调与工作线程的时钟、缓冲单位和丢帧策略必须写清。这是一种参考结构，不表示所有实时 DSP 都只能在回调外执行；有界、预分配且能满足期限的小型处理也可以在回调中完成。

环形缓冲已满时，系统需要事先选择“丢最旧块”“丢新块”或“降级处理”。任何一种策略都会改变输出：丢块破坏连续状态，等待会阻塞采集，积压则增大延迟。本书的 [RingBuffer](#) 采用“丢最旧样本”的可见基线，并累计 `dropped`；它用来说明容量和溢出语义，不是无锁实时队列。

[simulate\\_deadline\\_queue](#) 用一条串行工作队列区分三件事：处理完成晚于本帧期限、队列达到高水位、容量已满而丢帧。平均 RTF 小于 1 仍可能出现其中任何一种。正式设备还要记录驱动报告的 `underrun/overrun`（合称 `xrun`）、线程优先级、CPU 频率策略和并发负载。

Linux 的 ALSA（Advanced Linux Sound Architecture，先进 Linux 声音架构）还区分具体恢复原因：`-EPIPE` 表示上溢或下溢，`-ESTRPIPE` 与挂起有关，`-ENODEV` 可表示设备移除；某些回声参考设备在关联播放未启动时会返回 `-ENODATA`。这些状态不能统一解释为“再读一次”。恢复后要记录丢样，并通知依赖连续历史的 AEC、重采样器及后端。[ALSA PCM 官方接口说明](#)

参考接口可按下表检查：



| 模块           | 启用条件             | 主要输入                                      | 主要输出                                         | 首要检查                                  |
|--------------|------------------|-------------------------------------------|----------------------------------------------|---------------------------------------|
| 采集与同步        | 多通道输入需要保持时序关系    | 麦克风、时钟                                    | 对齐的多通道脉冲编码调制 (Pulse-Code Modulation, PCM) 样本 | 映射、削波、丢帧、相对时延                         |
| AEC          | 本机播放可能进入麦克风      | 麦克风；播放处理之后、DAC/功放之前的 render tap；远端活动/双讲状态 | 回声减弱的麦克风信号、残余回声与适配状态                         | 参考是否覆盖混音/EQ/音量、参考一麦克风整体延迟、削波、双讲稳定性    |
| WPE          | 晚期混响影响任务         | 多通道或单通道 STFT                              | 去混响 STFT                                     | 预测延迟、阶数、语音损伤                          |
| 定位/追踪        | 波束或应用需要方向/轨迹     | 多通道特征、活动状态、测量时间                           | 坐标系、测量/发布时间、状态与协方差、活动/存在概率、轨迹 ID 与有效期        | 坐标变换、过期外推、漏检/虚警、ID 生命周期；接口细节见 § 9.4   |
| GSS 掩码估计     | 已知说话人活动且需要多人空间增强 | 分割活动标注；WPE 后的多通道 STFT                     | 各目标的时频软掩码、有效帧数                               | 活动标注错位、掩码泄漏和目标缺席帧                     |
| 目标/干扰 SCM 估计 | 已得到同一时频网格上的掩码    | 同一 WPE 阶段输出、未做方向归一化的多通道 STFT；对应目标/干扰掩码    | 每频点目标/干扰 SCM、有效样本数和条件数                       | 掩码与 STFT 的时间、频点和通道约定须一致；掩码不是 SCM      |
| 解析波束形成       | 需要将空间统计转换为目标音轨   | 同一阶段的多通道 STFT；目标/干扰 SCM 或导向矢量             | 每目标的增强信号及波束权重                                | 导向失配、协方差病态和目标泄漏；方向状态只控制需要方向的波束        |
| 神经分离/CSS/TSE | 重叠内容需多流，或有可靠目标条件 | 多通道特征；可选注册语音、视觉或方向条件                      | 固定/动态输出流、单目标音轨                               | 左右上下文、首帧延迟、跨块排列、身份泄漏、域外泛化；它是解析波束的替代路径 |
| NS/AGC       | 残余噪声或电平范围影响后端    | 增强信号                                      | 抑噪、稳电平信号                                     | 语音损伤、增益抽动、削波                          |

| 模块      | 启用条件           | 主要输入  | 主要输出  | 首要检查        |
|---------|----------------|-------|-------|-------------|
| KWS/ASR | 应用需要关键词检测或语音识别 | 音频或特征 | 事件或文本 | 取点、缓存、误报与漏报 |

表中的 GSS 三行是一条有先后依赖的教学子链：活动标注约束掩码，掩码与多通道复系数形成 SCM，解析波束再用 SCM 或导向信息计算权重。若实现直接从网络预测 SCM，第二行的输入会改变；仍须记录实际取点，不能把三个中间量统称为“增强结果”。

## 10.2 拾音、同步与增益

麦克风选型至少要看自噪声、声学过载点、灵敏度、频响和通道一致性。单个器件的典型值不能代替整机测试：声孔、密封、挡板、电源噪声和装配偏差都会改变阵列响应。

脉冲密度调制（Pulse-Density Modulation, PDM）、芯片间音频总线（Inter-IC Sound, I<sup>2</sup>S）和时分复用（Time-Division Multiplexing, TDM）是常见数字接口，但一根数据线能承载多少通道取决于器件、时钟和控制器配置，不能只按接口名称判断。阵列处理还要确认通道是否共享采样时钟、帧同步是否一致，以及驱动是否会独立丢样。

16 位、24 位和 32 位浮点描述的是数字样本格式。32 位浮点便于保留中间动态范围，不能提高麦克风的声学过载点，也不能消除模拟前端的底噪或削波。某些录音设备以浮点文件保存多增益通路合成后的信号，但这仍不等于“无需增益设计”。

### 10.2.1 SRO：先区分初始时差和采样率偏移

设参考设备采样率为  $f_s$ ，另一设备满足  $f_{\text{device}} = f_s(1 + \epsilon)$ 。经过  $T$  秒后，两路时间轴的相对漂移一阶近似为

$$\Delta t(T) = \epsilon T. \tag{10-2}$$

100 ppm (parts per million, 百万分之一) 即  $\epsilon = 100 \times 10^{-6}$ 。若不校正，1 秒累积 100  $\mu\text{s}$ ，10 分钟累积 60 ms。这里的 60 ms 是时间轴长期累积的错位，不能直接当成每一秒都存在的到达时间差（Time Difference of Arrival, TDOA），也不能据此直接换算成固定的波达方向（Direction of Arrival, DOA）偏差。定位退化取决于重对齐周期、分析窗、频带、阵列孔径和估计器。

工程处理分三步：

- 1. 估计相对速率；
- 2. 按估计值重采样；

### 3. 持续跟踪温漂。

互相关峰漂移、相位漂移或专用导频都可用于估计。更新周期和允许残差应由最长连续运行时间、相干性要求及任务指标反推，不宜照搬固定 ppm 门限。

能够共享硬件时钟时，应优先消除 SRO 来源；不能共享时钟时，再评估在线补偿。

初始时差表现为整条“延迟—时间”曲线的截距，稳定 SRO 表现为斜率，偶发丢样则表现为阶跃。三者不能只靠首尾两个点可靠区分。工程上可分块估计互相关峰，先检查峰值置信度，再对可信的“时间—相对延迟”点做直线拟合；残差中若出现近似一个或多个采样间隔的突跳，应先查丢样和时间戳，而不是把所有变化都拟合成 ppm。

`estimate_sro_ppm` 把相对延迟定义为“参考时间减设备时间”，再拟合截距和斜率；正斜率表示设备采样率较高，与 `resample_sro_to_reference` 的符号一致。

若横轴使用参考时间，精确斜率为  $\varepsilon/(1 + \varepsilon)$ ；函数按小偏移的一阶近似把斜率乘  $10^6$  报为 ppm。要求更高时应反解  $\varepsilon = s/(1 - s)$ ，其中  $s$  是拟合斜率。例如  $s = 0.0001$  的一阶报告是 100 ppm，精确反解约为 100.010 ppm。截距描述初始错位，不进入这个速率换算。

重采样函数用线性插值演示长度和方向；线性插值没有足够的带外抑制，只适合教学检查。设备实现要换成有抗混叠滤波和跨块状态的异步采样率转换器，并测量补偿后的相位残差。

#### 专题：有状态重采样的比率、余量与时间标记

连续流可对照 `libsamplerate` 的 `src_process` 或 SpeexDSP 的重采样接口。以 `libsamplerate` 为例，比例定义为“输出速率/输入速率”；设备快 100 ppm 时，转到参考时钟的比例约为  $1/1.0001 = 0.99990001$ 。每次调用还会返回实际消耗的输入帧数和生成的输出帧数，调用方必须保留未消耗输入，不能假设一进一出或每块重新创建转换器。[libsamplerate Full API](#)

本书的[libsamplerate 两段已知时钟实验](#)实际调用锁定的 C 接口：前 5 s 为 +100 ppm，后 5 s 为 +150 ppm。未校正组在 1~9 s 的标记偏移增加 16 帧，按真值更新比例后该段残余增加 0 帧；每次输入消费量及结束排空也逐调用核对。这里的时钟速率是预先给定的，不能把结果写成“已自动估计漂移”，也没有测抗混叠或真实设备。

为把“估计—补偿—残余核查”连起来，本书另有[固定真值的合成时间戳实验](#)。参考时钟为 2 000 Hz，设备时钟快 150 ppm，首样本晚到 2 ms，并故意删去设备索引 12 000 的一个样本。前 2 s 的 9 个时间戳锚点满足  $t_n = 0.002 + n/2000.3$  s；相对延迟  $n/2000 - t_n$  的截距是 -2 ms，斜率应为  $150 \times 10^{-6}/(1 + 150 \times 10^{-6})$ ，即一阶报告 149.9775 ppm，反解得到 150 ppm。时间戳间隔还单独识别出一个缺样，不能把这个阶跃并入斜率。

校准结束后，示例从参考索引 4 500 开始，以 257 样本块保持插值相位。缺样附近的参考索引 12 002、12 003 被标为无效，而不是跨缺口插值。

按解析生成的参考波形逐段比较，缺样前的 6 000 个有效样本均方误差从未校正的 0.02869 降到 0.000002773；缺样后的 9 000 个有效样本从 0.02131 降到 0.000002477。这些是本书合成数据的无量纲幅值平方误差，未校正组按相同序号直接比较，包含起始错位、长期速率偏差和缺样造成的错位；已校正组只统计有效输出。

结果说明在精确时间戳、恒定时钟和已知缺口下，估计值能驱动跨块补偿，且可分别检查缺口两侧。线性插值没有充分抗混叠能力，本例也没有测设备时间戳噪声、音频盲估计、时钟温漂或在线比例更新；这些仍须在目标设备验证。[实验口径与运行方法](#)

换用另一库时要重新检查比例方向。libsoxr 的 `soxr_set_io_ratio` 使用“输入/输出”比，同一 100 ppm 算例应设为 1.0001，而非 0.99990001。其渐变长度以输出样本数计，滤波延迟也应从输出样本换算到时间；创建状态、切换比率与排空尾部是不同操作。[libsoxr 固定可变比率示例](#)

本书另用锁定的 libsoxr 0.1.3 做了已知时钟真值的受控变比率探针：48 kHz 名义输入前 5 s 快 100 ppm、后 5 s 快 150 ppm，输入共 480060 帧；输出 16 kHz，在输出帧 80000 切到新比率，用 160 个输出帧（10 ms）渐变。

持续使用旧比率得到 160004 帧；更新比率并排空后为 160000 帧。每秒脉冲标记的前五个位置相同，9 s 标记在旧比率输出为 144005、在更新后的输出为 144002。两者都有约 2 帧的共同插值器偏移，所以判断漂移要比较相对首个标记的变化，不能把 144002 当作绝对时间误差。

127 输入帧分块与整段渐变输出逐点相同；立即阶跃和 160/320 输出帧渐变的最大逐点差分别约  $6.25 \times 10^{-4}$ 、 $1.25 \times 10^{-3}$ 。这些差值只证明固定实现按不同控制长度产生不同波形，并非设备时钟估计精度。协议、调用消费量及独立验收见[工业接口研究 I22](#)。

## 10.2.2 增益变化与 AEC

AEC 前的时变增益会改变它要辨识的等效回声路径。设计时应记录每一级增益位于参考取点之前还是之后，并确保 AEC 能获知或跟踪这些变化。常见做法是：AEC 收敛和双讲期间保持前置增益稳定；发生削波风险时允许保护性衰减，同时重置或减小自适应步长。锁定时间、解锁条件和允许步进都应通过本机回声路径和双讲集确定，不存在通用的秒数或 dB 阈值。

阵列标定应覆盖相对增益、相位/时延和麦克风坐标。沿用 § 2.3 的远场导向约定，令  $\Delta \vec{r}$  是某麦相对参考麦的实际位置减标称位置（m）， $\vec{u}$  是指向声源的单位向量。将实际位置代入导向相位，再减去标称相位，本书得到

$$\Delta \phi = \frac{2\pi f}{c} \Delta \vec{r}^\top \vec{u}, \quad |\Delta \phi| \leq \frac{2\pi f}{c} \|\Delta \vec{r}\|. \quad (10-3)$$

式(10-3)中的相位以 rad 计；真正改变相位的是沿声源方向的位移投影，不是任意方向的位移长度。位移与  $\vec{u}$  垂直时，平面波模型中的相位变化为零；近场还需重算传播距离与幅度。

例如  $\|\Delta\vec{r}\| = 0.5\text{ mm}$ 、 $f = 4\text{ kHz}$ 、 $c = 343\text{ m/s}$  时，最大绝对相位误差约为  $2.1^\circ$ ，在位移平行于入射方向时达到。高频和深零陷波束因此更敏感，但 0.5 mm 不是所有产品的统一公差，见 E10-11。

标定不能止于得到一组系数。可执行流程应包含以下步骤：

- 1. 确认通道编号和设备时间戳，在多个已知方向播放宽带信号。
- 2. 估计相对增益、固定时延和随频率变化的相位，同时核对实际麦克风坐标与坐标系。
- 3. 把系数连同设备序列、采样率、温度和标定日期保存。
- 4. 在未参与拟合的方向复测波束图和 DOA。

更换声孔、密封件、麦克风或采集板后，要重新判断旧系数是否仍适用。

### 10.3 NS、控制信号与唤醒分支

#### 10.3.1 单通道 NS 的方法和边界

单通道 NS 常放在波束输出之后，因为此处计算量较小，也不会反过来破坏传统 AEC 的线性关系。但联合增强网络、多通道掩码估计或为定位专设的增强支路可能采用不同顺序。应依据训练输入和模块假设决定取点。

| 方法                                                                                    | 基本思想           | 主要风险          |
|---------------------------------------------------------------------------------------|----------------|---------------|
| 谱减                                                                                    | 从带噪功率谱中减去噪声估计  | 谱下限过低会产生音乐噪声  |
| 维纳滤波                                                                                  | 按估计信噪比设置频点增益   | 噪声和先验信噪比估计滞后  |
| 子空间法                                                                                  | 分离语音主子空间与噪声子空间 | 阶数估计和矩阵分解成本   |
| 最小均方误差短时谱幅度估计<br>(Minimum Mean-Square Error Short-Time Spectral Amplitude, MMSE-STSA) | 最小化短时谱幅度的均方误差  | 分布假设与参数估计失配   |
| 最小均方误差对数谱幅度估计<br>(Minimum Mean-Square Error Log-Spectral Amplitude, MMSE-LSA)         | 最小化对数谱幅度的均方误差  | 低信噪比下仍可能有语音损伤 |
| 神经网络掩码/映射                                                                             | 从数据学习谱或波形映射    | 域外噪声、伪影和内容改变  |



MMSE-STSA 和 MMSE-LSA 不是同一目标：前者估计短时谱幅度，后者在对数谱幅度域定义误差。噪声估计也不必“只在 VAD 判无话时更新”。最小统计量、软语音存在概率和神经网络软掩码都能在语音段缓慢更新；关键是避免把语音持续吸收到噪声模型中。

### 10.3.2 功率谱减：一个频点怎样算到输出

先固定模型：单通道观测  $y[n] = s[n] + v[n]$ ，噪声在一小段时间内近似平稳；已经知道开头哪些帧只有噪声。对周期 Hann 窗、512 点短时傅里叶变换（STFT）和 128 点帧移，记频点  $f$ 、帧  $t$  的复系数为  $Y_{f,t}$ 。本书在完整落入噪声段的帧集合  $\mathcal{N}$  上，按同一窗和 FFT 归一化口径平均  $|Y|^2$ ，得到固定的逐频点噪声功率估计  $D_f$ 。这是已知噪声段的教学条件，不是自动检测无语音帧。

本书演示的功率谱减、相对观测功率的谱地板和复系数重建定义为

$$\begin{aligned} D_f &= \frac{1}{|\mathcal{N}|} \sum_{t \in \mathcal{N}} |Y_{f,t}|^2, \\ \hat{P}_{f,t} &= \max(|Y_{f,t}|^2 - \alpha D_f, \beta |Y_{f,t}|^2), \\ \hat{X}_{f,t} &= \begin{cases} \sqrt{\hat{P}_{f,t}/|Y_{f,t}|^2} Y_{f,t}, & |Y_{f,t}|^2 > 0, \\ 0, & |Y_{f,t}|^2 = 0. \end{cases} \end{aligned} \quad (10-4)$$

这里  $\alpha \geq 0$  是过减系数， $0 \leq \beta \leq 1$  是相对带噪频点功率的地板比例； $\beta = 0.04$  意味着正功率频点的最小幅度增益为  $\sqrt{0.04} = 0.2$ 。重建保留带噪相位；零系数没有相位，因此保持为零，不能凭谱地板捏造一个任意相位。逐帧逆变换后，按窗平方权重重叠相加。

Boll 的[原始谱减论文](#)讨论从无语音段估计噪声；Berouti、Schwartz 与 Makhoul 的[功率过减与谱地板论文](#)讨论残余音乐噪声。本书选择  $\beta|Y|^2$  作为容易复算的地板口径；引用论文的其他地板定义或数值不能直接当作本实现的参数。

锚点手算。某频点的已知噪声帧系数为 2，故  $D = |2|^2 = 4$ 。另两帧的带噪系数为 3 和 1，取  $\alpha = 1$ 、 $\beta = 0.04$ 。

前一帧功率是 9，相减得  $9 - 4 = 5$ ，地板为  $0.04 \times 9 = 0.36$ ，故输出功率 5、幅度  $\sqrt{5} \approx 2.2361$ ；后一帧功率是 1，相减得  $-3$ ，地板为 0.04，故输出功率 0.04、幅度 0.2。

两帧原相位均为零；若原系数改成  $3j$  和  $1j$ ，输出相应为  $\sqrt{5}j$  和  $0.2j$ 。不能把功率相减误写成幅度  $3 - 2 = 1$ 。这个手算只证明式(10-4)的数值约定；若噪声统计随时间改变或噪声段混入目标， $D$  就会失配。

运行[谱减练习代码](#)可复算同一频点的两个带噪帧；另运行[统一音频生成器](#)可重建[五个试听文件及参数清单](#)：合成谐波目标、独立高斯噪声、带噪输入、 $\beta = 0.04$  输出和  $\beta = 0$  输出。16 kHz、2 s 输入的前 0.4 s 仅有噪声，47 个完整落在该段的 STFT 帧估计  $D_f$ ；两种处理使用同一输入、同一固定噪声估计和同组共同导出增益。

先降低播放音量，再比较[带噪输入](#)、[有地板输出](#)与[零地板输出](#)。离散随机残余频点可能听成短促的调性噪声，但这组数学合成信号没有经过人耳听测，不能据此报告语音可懂度、MOS 或产品降噪性能。

在生成器的浮点波形上计算前 6400 个样本的均方根值，得到下表；三者的共同 WAV 导出增益为 1，表内按四位小数舍入。输入只有噪声，所以这里没有“语音保真”可比。 $\beta = 0$  的前奏数值比  $\beta = 0.04$  更低，只说明这个固定输入的平均剩余幅度较低，不能推出音乐噪声更少。

| 前奏版本              | 均方根幅度（数字满幅为 1） |
|-------------------|----------------|
| 带噪输入              | 0.0697         |
| $\beta = 0.04$ 输出 | 0.0404         |
| $\beta = 0$ 输出    | 0.0381         |

谱减的关键边界是估计误差：噪声上升时旧  $D_f$  偏低，会留下残余；目标误入估计段时  $D_f$  偏高，会损伤目标。较大的  $\alpha$  或较小的  $\beta$  可能减少持续噪声却造成时频斑点；地板也会保留噪声，不能称为无失真解。此实现没有自适应噪声追踪、语音存在概率或 Ephraim – Malah 的 MMSE-STSA/LSA 统计估计器。它是可复算的谱减基线，不能用其输出冒充这些方法。

### 10.3.3 控制状态不能只看一个 VAD 比特

控制状态需要涵盖近端语音、远端播放和双讲。下表列出这些状态下的更新条件；具体实现可以使用离散状态，也可以使用连续的活动概率。

| 状态    | AEC 自适应          | NS 噪声估计         | 波束/空间统计         | WPE 更新       | ASR/KWS                  |
|-------|------------------|-----------------|-----------------|--------------|--------------------------|
| 仅远端播放 | 参考有效且无削波时可更新     | 残余回声未污染噪声估计时可更新 | 避免把回声当目标        | 视残余回声而定      | 需要播放时唤醒时，KWS 可监听 AEC 后信号 |
| 仅近端语音 | 保持；没有有效远端参考可供辨识  | 软更新或保持          | 更新目标统计，谨慎更新噪声统计 | 可按功率加权更新     | 送入后端                     |
| 双讲    | 由双讲检测降低步长或采用鲁棒更新 | 软更新或保持          | 分离目标与干扰统计       | 不应仅因“有语音”而冻结 | 保留近端语音                   |

| 状态      | AEC 自适应 | NS 噪声估计 | 波束/空间统计 | WPE 更新     | ASR/KWS               |
|---------|---------|---------|---------|------------|-----------------------|
| 无近端、无远端 | 保持      | 更新背景模型  | 更新噪声统计  | 按实现选择保持或更新 | 后端可休眠，KWS 是否常开由应用需求决定 |

WPE 正是利用语音及其晚期混响的统计关系估计预测滤波器，不能用“VAD 有话就冻结”作为通用规则。AEC 的控制则必须结合远端活动和双讲检测；仅用近端 VAD 无法判断滤波器是否有可学习的回声参考。

VAD 的迟滞、挂起和预卷缓存应由语料中的短词、停顿和噪声脉冲调节。

KWS 是否绕过 VAD、是否持续运行、从 AEC 后还是增强后取信号，取决于功耗和训练域。设置 KWS 阈值时，还要在指定误唤醒率下报告漏唤醒率，不能只给一个孤立分数。

#### 10.3.4 VAD 与 AGC 的最小可运行基线

能量 VAD 虽然简单，却能把控制逻辑讲清。启动阈值应高于继续阈值，避免能量在单一阈值附近来回切换；hangover 在能量下降后继续保持若干帧，减少词尾被截断。预卷缓存解决的是词首：VAD 刚触发时，把触发前保留的短时音频一并送给后端。三个时间量都要换算成帧数，并在短词、长停顿和脉冲噪声上分别验证。

[HysteresisVAD](#) 输入线性均方能量，不接受 dB 阈值；把 dBFS 门限传给它会造成口径错误。

`hangover_frames=2` 表示首次跌破继续阈值的两帧仍保持活动，第三帧才关闭。该基线没有噪声自适应、频带特征和神经网络，也不自行保存预卷；预卷可用 [RingBuffer](#) 保留触发前的固定帧数，并在 VAD 由假变真时先取出缓存。

AGC 要区分“把正常语音逐渐推向目标电平”和“立刻避免削波”。增益上升可以缓慢释放，增益下降需要更快；即使平滑状态来不及下降，当前块也要受安全上限约束。[PeakProtectAGC](#) 给出这种峰值保护基线。

它不估计响度，也不能修复模拟前端已经发生的削波。验收时要同时画输入电平、增益、输出峰值和削波比例，并在 AEC 双讲期间检查增益变化是否破坏回声路径模型。

需要比较输出响度时，可以另用 `libebur128` 测量响度与真峰值。响度按频率加权和时间统计得到，不等于当前块的最大样本；真峰值估计重建波形的幅度，也可能高于采样峰值。测量模式、通道角色、门控和无有效能量的处理须固定，数字域响度与峰值都不能未经播放校准就换成声压级。[libebur128 固定 API](#)

一个容易手算的反例是 48 kHz 采样的 12 kHz 正弦，幅度 0.95、初相  $\pi/4$ 。平台段每个离散样本的绝对值都是  $0.95/\sqrt{2} \approx 0.67175$ ，而连续正弦可在两个采样点之间达到 0.95。

对 10 s 信号的两端各加 100 ms 平滑渐变后，锁定 libebur128 的 4 倍插值器实际返回采样峰 0.671751、估计真峰 0.946371；后者是该库有限长滤波器的估计值，不是把解析上界精确重建成 0.95。若让正弦从第一点突起，滤波起始瞬态可能抬高库估计，不适合用来检验纯正弦的采样间峰值。输入与独立手算见[工业接口研究 I23](#)。

实际 VAD 接口有不同的输入协议。WebRTC 传统 VAD 使用合法采样率下的 16 位单声道 PCM 和 10、20、30 ms 帧；Silerio 核实的 ONNX 包装器使用 16 kHz/512 点或 8 kHz/256 点，均为 32 ms，并保留跨块状态。[WebRTC VAD 接口](#)、[Silerio 包装器源码](#)

因此，10 ms 的声卡回调不能直接当成任意模型的一次输入。接入前要按所选接口缓冲到合法块长，并记录判决对应的采集时间；否则 32 ms 块的输出可能被错误标成最后一次 10 ms 回调的即时结果。

跨块状态要与会话绑定。每块重置会改变模型行为，多条独立会话共享状态会相互干扰。阈值、最短语音、静音等待和前后填充也要分开调节；降低语音概率阈值并不能自动补回已经丢失的词首音频。工业 VAD、WebRTC AGC2 和 DeepFilterNet 的源码阅读顺序及故障试验见[工业实现研究中的控制与增强部分](#)。

## 10.4 定点化、算力与功耗预算

---

### 10.4.1 从浮点实现到目标芯片

定点化要检查四件事：

- 数值范围；
- 累加位宽；
- 非线性函数近似；
- 模块间缩放。

协方差矩阵求解与 WPE 线性方程组尤其要观察条件数；对角加载能改善数值稳定性，但加载量应相对矩阵尺度定义。32 位或更宽的累加器可以减少乘加溢出，不能保证病态矩阵求解正确。

训练后量化（Post-Training Quantization, PTQ）不一定需要同一种校准流程。以 ONNX Runtime 的激活量化为例，静态量化用代表性校准输入预先确定尺度与零点；动态量化在推理时根据当前激活计算这些参数，因此增加了运行时工作。量化感知训练（Quantization-Aware Training, QAT）则在训练阶段模拟量化误差。[官方量化文档的 Dynamic/Static Quantization 与 Method selection 小节](#)，核实于 2026-09-22。



选择哪一种方法，应依据目标芯片支持的算子、代表性数据上的任务指标和最不利输入测试。权重与激活是否同时量化、逐张量还是逐通道定标也要写清，不能仅用“int8”推断统一的校准方法、精度下降量或加速倍数。

定点格式还要明确舍入和饱和规则。本书的 `q15_quantize` 把  $[-1, 1)$  映射到有符号 Q1.15：乘 32768、按最近偶数舍入，再饱和到  $[-32768, 32767]$ 。因此 -1 可以精确表示，+1 只能饱和为 32767/32768。

`q15_dot` 用 64 位整数累加乘积，只在输出时除以  $2^{15}$ 、按最近偶数舍入并饱和；目标 DSP 若使用不同累加位宽或逐乘积舍入，就不应期待 bit-exact 相同。测试既要覆盖正常小数，也要覆盖  $\pm 1$ 、超范围输入和累加器极值；不能只比较平均误差。实数 PCM 接口还应在类型转换前拒绝意外的复数输入，不能把丢弃虚部后的数组当作原始信号。

两抽头手算。两个输入向量均取 Q1.15 整数 [16384, 16384]，每个码字表示 0.5。逐项整数乘积都是  $16384^2 = 268435456$ ，按  $2^{30}$  缩放各表示实数 0.25。

64 位累加值为  $268435456 + 268435456 = 536870912$ ，表示实数 0.5。只在末尾除以  $2^{15}$  得 16384，故 `q15_dot` 返回 Q1.15 码字 16384，反量化为 0.5。

饱和边界。若两个向量都只含一个 -32768，乘积表示实数 1，换回 Q1.15 原本需码字 32768，超过正端上限，所以饱和为 32767。这些整数可由本书函数复核；采用窄累加器或逐项舍入的 DSP 必须另行比对。

SIMD（单指令多数据）优化从数据布局开始。连续的频点、通道或抽头便于向量加载，跨步访问和频繁转置会抵消乘加加速。报告 SIMD 收益时要写明标量基线、指令集、编译选项、数组对齐、块尺寸、线程数和是否包含格式转换。运行时派发还要保留标量回退，并让两条路径通过同一组数值容差或 bit-exact 测试；“编译器打开了向量化”不能代替这些检查。

CMSIS-DSP 的 `arm_fir_q15` 是具体对照：源码说明了 1.15 乘法、64 位累加和输出截位/饱和，而本书 `q15_dot` 采用最近偶数舍入。两者都称 Q15，却不应默认逐位相同；快速版、标量版和向量版也要绑定内核及编译宏分别检查。先用脉冲、满幅和余数块长验证，再报告目标芯片周期数。

[CMSIS-DSP FIR 源码](#)

#### 10.4.2 不混用指令数、乘加次数和实时因子

- 每秒乘加次数（Multiply-Accumulate Operations per Second, MAC/s）或每秒百万次乘加（Million MAC/s, MMAC/s）适合描述已经明确算子图和计数规则的算法计算量。
- 每秒百万条指令（Millions of Instructions per Second, MIPS）依赖指令集、并行宽度、存储访问和编译器。同一算法在不同处理器上的 MIPS 不可直接比较。



- RTF 定义为处理时长除以音频时长。RTF 小于 1 只说明平均速度足够；还要检查单帧最坏耗时、调度抖动和队列增长。

“帧耗时/帧长”得到的是 RTF，不是等效 MIPS。预算表应记录测量平台和版本：

| 模块   | 配置与输入尺寸        | MAC/s 或分析复杂度 | 最坏帧耗时   | RTF     | 峰值内存  | 平均/峰值功率 |
|------|----------------|--------------|---------|---------|-------|---------|
| 示例模块 | 麦数、采样率、帧长、模型版本 | 在同一计数规则下统计   | 在目标芯片实测 | 同一段音频实测 | 高水位实测 | 功率仪实测   |

电池容量应换算为能量。若标称电压为  $V$ 、容量为  $C_{Ah}$ ，标称能量近似为  $E = VC_{Ah}$  Wh，其中 Wh (watt-hour) 表示瓦时。续航估算为

$$t \approx \frac{E\eta}{P_{avg}}, \tag{10-5}$$

式(10-5)约定  $P_{avg}$  是各工作状态按占空比加权后、在稳压与转换电路输出端测得的整机负载平均功率； $\eta$  才可同时计入电池可用容量比例、从电池到负载的转换效率及老化裕量。若功率仪测的是电池端输入功率，转换损耗已经包含在  $P_{avg}$  中， $\eta$  不应再次计入转换效率。应记录电压、测点、各状态功率与占空比；只给毫安时 (mAh) 而不给这些条件，无法推出可验收的续航。

### 10.4.3 把吞吐、排队、内存和功率放进同一预算

单看一列可能漏掉真正的失败条件。下面是本书构造的六帧教学调度，不是目标芯片实测：四路 16 kHz 浮点音频每 10 ms 到来一帧，一条串行处理线程的六次服务耗时依次为 [4, 4, 25, 4, 4, 4] ms。队列最多容纳三个未完成帧，包含正在计算的一帧；处理不能抢占，每帧应在下一帧到达前完成。下表的到达、开始和完成时间均从第一帧到达的  $t = 0$  起算。

| 帧号 | 到达 ms | 开始 ms | 完成 ms | 响应 ms | 是否超过 10 ms 期限 |
|----|-------|-------|-------|-------|---------------|
| 0  | 0     | 0     | 4     | 4     | 否             |
| 1  | 10    | 10    | 14    | 4     | 否             |
| 2  | 20    | 20    | 45    | 25    | 是             |
| 3  | 30    | 45    | 49    | 19    | 是             |
| 4  | 40    | 49    | 53    | 13    | 是             |
| 5  | 50    | 53    | 57    | 7     | 否             |

计算量之和为 45 ms，观测的六帧音频长 60 ms，因而示意平均 RTF 为  $45/60 = 0.75$ 。帧 2 的 25 ms 服务使帧 3、4 等待； $t = 40$  ms 时在途帧最多为 3，最大等待为 15 ms，六帧虽全被接收，却有 3 帧错过期限。

六个响应样本中的最大值为 25 ms；不能把这么短的构造序列说成已测得稳定 p99。增加队列容量只能减少溢出，不能让已逾期的帧重新准时。

若常驻状态分别占 400、200、60 KiB，且每个在途帧使用四通道  $\times 160$  样本  $\times 4$  B = 2560 B = 2.5 KiB，三个在途帧共 7.5 KiB。这里明确假设三块状态同时驻留且帧内存彼此独立，峰值为  $400 + 200 + 60 + 7.5 = 667.5$  KiB，低于示意 700 KiB 上限；真实程序还要计入线程栈、对齐、库工作区及共享缓冲区的实际生命周期。

只有假设这六帧模式长期重复且线程服务时间等于高功耗时间，才可用  $45/60 = 75\%$  作功率占空比。若负载端活动/空闲功率为 1.2/0.2 W，则平均为  $1.2 \times 0.75 + 0.2 \times 0.25 = 0.95$  W；3.7 V、2 Ah、可交付比例 0.8 给出  $5.92/0.95 \approx 6.23$  h。功率假设与帧截止期假设彼此独立，续航估算合格也不能抵消三次逾期。完整输入和逐帧结果见 E10-14，复算入口为 [exercises\\_engineering.py](#)。

## 10.5 评测体系

每项指标只能回答一部分问题。面向完整系统的评测通常还需覆盖任务效果、语音质量、稳定性、资源占用和长时间运行。

| 对象    | 可用指标                                                                                            | 不能单独说明什么                                      |
|-------|-------------------------------------------------------------------------------------------------|-----------------------------------------------|
| AEC   | 回声返回损失增强 (Echo Return Loss Enhancement, ERLE)、双讲恢复、残余回声主观分                                      | ERLE 高不等于近端语音无损                               |
| 定位    | 角误差、漏检率、虚警率、均方根误差 (Root Mean Square Error, RMSE)                                                | 单源 RMSE 不代表多人追踪稳定                             |
| 波束/分离 | 尺度不变信号失真比 (Scale-Invariant Signal-to-Distortion Ratio, SI-SDR)、串扰；多输出转写用 cpWER、ORC-WER 或 sa-WER | 单个客观分不代表听感或内容正确；多输出指标的排列/身份口径见第 11 章“多人重叠”决策表 |
| 说话人分割 | 分割错误率 (Diarization Error Rate, DER)、Jaccard 错误率 (Jaccard Error Rate, JER)                       | 必须固定 collar、重叠计分、参考区域和评分工具版本；分割正确不等于分离内容正确    |

| 对象 | 可用指标                                                                                                                                                                                          | 不能单独说明什么                                |
|----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------|
| 增强 | 短时客观可懂度 (Short-Time Objective Intelligibility, STOI)、旧研究复现中的感知语音质量评估 (Perceptual Evaluation of Speech Quality, PESQ)、感知客观听音质量分析 (Perceptual Objective Listening Quality Analysis, POLQA)、主观听测 | 客观模型可能在新失真上失准                           |
| 追踪 | 最优子模式分配距离 (Optimal Sub-Pattern Assignment, OSPA)、轨迹完整度、轨迹中断/碎片数、轨迹身份切换 (ID switch)                                                                                                            | 位置准确不等于身份连续; OSPA 的 $p, c$ 和角度距离见 § 9.4 |
| 系统 | 端到端延迟、RTF、功耗、崩溃/丢帧                                                                                                                                                                            | 平均值不代表尾延迟和最坏状态                          |

OSPA 把定位误差与目标数量错误合成一个集合距离；经典 OSPA 本身不保留身份标签，因此不能用它代替轨迹身份切换指标。报告还应给出轨迹中断/碎片数、ID 切换和关联规则，而不是用一个集合距离覆盖全部时序失败。

ITU-T 已于 2024 年 1 月 5 日撤销 [P.862 \(PESQ\)](#)，并在官方页面指向 [P.863 \(POLQA\)](#)。因此，PESQ 适合在必须对照旧论文时按原条件复现；新的标准合规性表述不应把 P.862 写成现行建议书。P.863 是现行的客观语音质量建议书，但其适用范围和版本仍需随正式报告记录。

[ITU-T P.835 \(07/2026\)](#) 用于对含噪语音处理系统做主观听测，分别评价语音信号 (Signal, SIG)、背景噪声 (Background, BAK) 和总体效果 (Overall, OVRL)。截至 2026-09-22，官方条目状态为“生效，预发布” (in force, prepublished)；三维评分的用途可见[官方工作项目说明](#)。

它适合区分“噪声是否减弱”和“语音是否受损”，但不能直接评价 DOA、轨迹身份或空间位置。正式报告应写明标准版本、听测材料、听众筛选、播放设备和统计区间。

[ITU-T P.566 \(07/2026\)](#) 的官方条目将其列为“已生效，待发布” (in force / to be published) 的单端机器学习多维语音质量模型。在正式文本发布前，本书不从二手资料扩写输出维度或评分细则。P.566 的单端客观预测不能代替 P.835 主观听测，也不评价 DOA、轨迹或空间位置。

公开评分代码可帮助固定执行口径。DNS Challenge 的 [DNMOS/dnsmos\\_local.py](#) 提供本地质量预测，AEC Challenge 的 [AECMOS/AECMOS\\_local/](#) 提供回声相关评分；前者还区分普通和个性化模式。需要同时锁定模型摘要、采样率、裁段、短文件处理与聚合方式。模型预测分不是实际听众 MOS，也不能代替任务识别指标。[DNMOS 本地说明](#)、[AECMOS 本地说明](#)

AECMOS 官方为 2021/2022 测试集规定了收敛段后的评分范围，近端单讲、远端单讲和双讲的裁取方式不同。使用别的测试集时，应按该测试集规则定义区间，不能直接沿用旧届剪裁。逐文件失败、静音输出和缺失场景也要计入报告，避免只汇总成功评分的子集。

全参考指标还要求干净参考与处理后信号的采样率、时间轴和评分区域一致。pystoi 提供普通 STOI 与扩展 STOI（Extended Short-Time Objective Intelligibility，ESTOI），两种模式应分别报告。锁定实现对去静音后不足 30 个 STFT 帧的输入发出警告并返回  $1e-5$ ；这是无效评分的返回值，不能当成有效低分加入平均。[pystoi 固定实现，第 64~70 行](#)

ViSQOL（Virtual Speech Quality Objective Listener）则比较参考与退化信号的时频结构，输出客观听音质量预测分（Mean Opinion Score—Listening Quality Objective，MOS-LQO）。该实现区分 48 kHz 的 audio 模式与 16 kHz 的 speech 模式，并将多通道下混单声道；因此不能用它证明阵列方向或双耳线索保持。它不是 POLQA 实现，模型预测也不能代替受试者评分；模式、映射模型和适用失真范围都要记录。[ViSQOL 固定说明的 Guidelines 与 FAQ](#)

本书的音频示例用于辨认时延、拖尾、削波和增益等现象，不是标准主观评分材料。试听前先降低播放音量，确认没有异常峰值，再比较同一输入的参考、受扰和处理后版本。对同组文件施加共同线性增益，可以保留它们的相对电平；各文件分别峰值归一化会抹去衰减或增益差异。若为了比较音色而另做响度匹配，应把该版本和原始测量版本分开保存，并记录匹配方法。

数值评分应使用规定的原始数据、对齐和增益规则，不能直接把试听归一化后的文件当作评分输入。合成谐波或噪声只检验信号处理现象，不包含自然语言内容，不能由此报告语音 MOS、可懂度或 WER。材料来源、参数及章节练习见[练习与音频实验手册](#)。

## 10.6 数据、仿真与复现

---

公开数据集适合建立可复现基线，不能代替目标设备录音。选择数据时要核对采样率、麦克风几何、房间、说话人数、重叠率、参考真值和许可证。训练、调参、最终测试应按房间或说话人隔离，避免相邻片段泄漏。

录音和声纹还要有数据治理清单：

- 记录采集目的与用户同意范围；
- 区分原始音频、转写文本、声纹嵌入和调试日志；

- 说明数据在端侧还是云侧处理，传输与静态存储怎样加密，哪些角色可以访问；
- 规定保留期限、删除与撤回流程；
- 导出故障样本前做身份信息检查；
- 第三方数据集按许可证限制保存和再分发。

目标说话人提取使用的注册声纹可能比普通缓存更敏感，不能因为只保存嵌入而默认无法关联个人。

具体法律和认证要求取决于部署地区与产品用途，应由相应合规审查确认。

房间冲激响应仿真也要写全条件。以下代码按 [pyroomacoustics 0.10.0](#) 编写，说明 `max_order` 与混响时间的关系；安装命令见项目 README：

```
import pyroomacoustics as pra

room_dim = [6.0, 5.0, 3.0]
target_rt60 = 0.45
absorption, max_order = pra.inverse_sabine(target_rt60, room_dim)
room = pra.ShoeBox(
    room_dim,
    fs=16000,
    materials=pra.Material(absorption),
    max_order=max_order,
)
```

`inverse_sabine` 根据目标混响时间  $T_{60}$  和房间尺寸给出吸收参数及建议的镜像源截断阶数； $T_{60}$  表示声能衰减 60 dB 所需的时间。

这里的 `target_rt60=0.45` 是设计目标，不是已经测得的仿真结果。生成房间冲激响应（Room Impulse Response, RIR）后，还应由 RIR 的 Schroeder 能量衰减曲线估计实际  $T_{60}$ ，并报告拟合区间。衰减动态范围不足时，不应把短区间外推值写成直接测得的 60 dB 衰减时间。

`max_order` 控制镜像反射的截断深度，不能单独决定  $T_{60}$ 。可逐步增加 `max_order`，直到测得  $T_{60}$ 、RIR 总能量和目标任务结果在预定容差内不再明显变化。若始终不收敛，应调整房间或仿真方法，而不是只抬高阶数。

论文或报告还应记录：

- 目标与实测  $T_{60}$ ；



- 声源和麦克风坐标；
- 材料模型、随机种子与噪声生成方法；
- pyroomacoustics 版本和拟合方法。

## 10.7 分布式阵列

分布式系统要分别解决三类问题：

1. 时间轴：初始时差、SRO、丢包和网络抖动要分开估计。长录音首尾对齐只能发现累计误差，不能代替运行时监测。
2. 坐标与增益：节点位置、朝向、通道增益和频响决定导向矢量能否共用。节点移动后要更新几何。
3. 融合：集中式波束需要传多通道信号或统计量，对同步和带宽要求高；通道选择和识别结果融合要求较低，但损失空间信息。应把弱节点加入后的退化列为测试项。

验收阈值应由网络带宽、最长会话和目标任务确定。例如，要求一小时内相位相干的系统与只做句级识别的系统，对残余 SRO 的要求不会相同。

## 10.8 阵列形态与场景约束

公开产品的麦克风数量、位置和算法会随硬件版本及地区型号变化。若没有可追溯的一手资料，不应从拆解照片推断算法链。本教程因此只讨论可迁移的设计条件：

| 场景           | 先确认的约束              | 可能启用的模块                  | 必测状态                |
|--------------|---------------------|--------------------------|---------------------|
| 带扬声器的音箱/会议终端 | 播放声压、参考取点、覆盖角       | AEC；按混响决定 WPE；按覆盖决定定位/波束 | 远端单讲、近端单讲、双讲、音乐播放   |
| 会议室          | 房间混响、座位分布、重叠说话比例    | 多波束或分离；晚期混响明显时用 WPE      | 单人、抢话、键盘/空调、不同座位    |
| 车载           | 舱位、车速相关噪声、多个时钟域     | 分区波束、SRO 补偿、参考完整的 AEC    | 怠速、行驶、开窗、空调、音乐与通话并发 |
| 耳机/助听设备      | 上下行路径、佩戴泄漏、低延迟和电池约束 | 固定/自适应双麦波束、NS、反馈抑制       | 不同佩戴、风噪、自己说话、最坏增益   |

| 场景      | 先确认的约束                                               | 可能启用的模块         | 必测状态             |
|---------|------------------------------------------------------|-----------------|------------------|
| 机器人     | 运动自噪声、阵列姿态、惯性测量单元（Inertial Measurement Unit, IMU）时间戳 | 运动前馈、姿态补偿、定位/追踪 | 静止、转头、行驶、风扇/电机变速 |
| 手机/手持设备 | 握持、遮挡、横竖屏、通话模式                                       | 通道选择、波束/NS、模式切换 | 手指挡孔、风噪、贴脸、免提、录像 |

球阵的可用球谐阶数同时受空间采样、阵列半径、频率和模态噪声放大限制。这里  $k = 2\pi f/c$  是波数， $r$  是球阵半径， $kr$  是无量纲频率。

表示到  $N$  阶的完整球谐系数共有  $(N + 1)^2$  个，因此离散阵元数至少要能支撑相应的空间采样；实际还要留出几何和数值稳定性余量。

可用阶数在高频受阵元空间混叠限制，在低频又受  $kr$  较小和径向滤波噪声放大限制。不能用  $N = \lceil kr \rceil + 1$  一条式子替代完整设计，也不能把“某阶需要多少系数”直接等同于任意摆放的同数麦克风一定可用。

三个非共点麦克风已经构成阵列。若几何非共线，它们能提供二维空间信息；若接近共线，则某些方向存在镜像或条件数问题。手机的主要限制通常是孔径小、结构遮挡和工作模式变化，而不是“三麦构不成阵列”。

## 10.9 从模型到设备

部署前先固定输入尺寸、算子版本、量化方式和线程配置，再测算力与内存。模型参数从 32 位浮点量化到 8 位整数时，参数存储在理想情况下约缩小四倍；端到端速度取决于硬件是否有相应整数内核、访存和算子融合，不能据此承诺“快四倍”。

低功耗常驻任务和高算力按需任务可以分开：例如 KWS 在低功耗处理器上运行，唤醒后再启动 ASR 或分离网络。但 AEC、波束、WPE 是否常驻取决于是否需要持续边播边听、录音或通话，不应把“唤醒前关闭完整前端”写成固定方案。

端侧、云侧或混合部署要比较隐私、断网可用性、网络尾延迟、更新能力和能耗。对品牌产品的实现方式没有公开证据时，只能写成候选架构，不能当作产品事实。

10.9.1 开源实现怎样用作工程对照

开源项目解决的是链路中的不同部分，不能因为都能处理音频就横向替换。下面只列本书正文能够说明用途和边界的项目；固定来源、提交、许可证和核实日期统一记录在 `codes/SOURCES.lock.json`，代码、模型权重和数据集许可证分别检查。

| 官方项目                                        | 可以对照什么                                               | 不能由它证明什么                           |
|---------------------------------------------|------------------------------------------------------|------------------------------------|
| <a href="#">WebRTC AEC3 固定提交</a>            | 实时 AEC 的延迟估计、线性消除和残余回声抑制分工，详见 § 6.8                  | 不能把内部常数当成本产品阈值，也不覆盖阵列定位和 WPE       |
| <a href="#">PortAudio 19.7.0 固定提交</a>       | 跨平台设备枚举、阻塞与回调式音频输入输出；该提交按官方 Release Notes 定位         | 不负责跨设备同步、重采样、AEC 或波束形成             |
| <a href="#">pyroomacoustics 0.10.0 发布记录</a> | 房间、RIR、DOA 与波束的 Python 原型                            | 仿真通过不等于目标设备达到实时性或实录效果              |
| <a href="#">nara_wpe 0.0.11 发布记录</a>        | 离线、块在线和递归 WPE 的接口对照                                  | 安装命令不能证明所选接口因果，也不能证明当前 Python 环境兼容 |
| <a href="#">ONNX Runtime 固定源码快照</a>         | 模型执行、执行提供程序和量化后的设备部署；链接固定到 2026-09-22 核实的完整提交，属于源码快照 | 它是运行时，不定义 NS、分离或波束算法的训练目标          |

更多可直接阅读的工业实现包括以下几组，完整提交、许可和获取状态由 `codes/` 统一记录。

| 实现层              | 官方项目与源码入口                                                                                                                                               | 接入时要固定的条件                                                 |
|------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------|
| Linux 音频与 AEC 路由 | ALSA <code>src/pcm/</code> ；PipeWire <code>src/modules/module-echo-cancel.c</code>                                                                      | 设备、period/buffer、时间戳；capture/source/sink/playback 四流与播放参考 |
| 文件输入输出           | libsndfile <code>include/sndfile.h</code> 、 <code>src/sndfile.c</code>                                                                                  | 时间帧/标量项、PCM 编码与数组类型、浮点归一化、末块短读                            |
| 流式重采样            | libsamplerate <code>src/samplerate.c</code> ；SpeexDSP <code>libspeexdsp/resample.c</code> ；libsoxr <code>src/soxr.h</code>                              | 速率比例方向、滤波质量、跨块状态、消费/输出量、排空与延迟                             |
| VAD、AGC 与神经 NS   | WebRTC <code>common_audio/vad/</code> 、 <code>agc2/</code> ；Silerio <code>utils_vad.py</code> ；DeepFilterNet <code>libDF/</code> 、 <code>ladspa/</code> | PCM 幅度、合法块长、会话状态、前瞻、模型和取点                                 |

| 实现层     | 官方项目与源码入口                                                                                                                    | 接入时要固定的条件                                                     |
|---------|------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------|
| DSP 固件  | XMOS <code>lib_voice</code> 的<br>AEC/ADEC、IC/VNR、<br>NS/AGC；SOF <code>src/audio/tdfb/</code>                                 | 几何、系数、通道、调度、工具<br>链、固件拓扑与硬件适用范围                               |
| MCU 推理  | CMSIS-NN <code>Source/</code> ；<br>TensorFlow Lite Micro<br><code>micro_speech/</code>                                       | 整数量化、算子、临时内存、<br>tensor arena、特征前端                            |
| 块浮点内核   | XMOS <code>lib_xcore_math</code> 的<br><code>src/bfp/</code> 、 <code>src/fft/</code> 、<br><code>src/arch/ref/</code>          | 尾数与共享指数、headroom、目<br>标架构；版本按 <code>lib_voice</code> 依赖固<br>定 |
| 电平与质量测量 | <code>libebur128</code> <code>ebur128/</code> ； <code>pystoi</code><br><code>pystoi/stoi.py</code> ；ViSQOL <code>src/</code> | 响度/真峰值与质量分分开；参考、<br>模式、模型、有效帧与失败记录                            |

[工业实现研究文档](#)逐项给出 27 个实现主题的源码入口、状态和参数、故障注入及验收方法，核实日期为 2026-09-22。XMOS 的旧 `fwk_voice` 已迁移到 `lib_voice`；该库使用 XMOS Public Licence v1，商用硬件范围和特殊用途条款应按原许可判断，不能把可获取源码等同于跨平台宽松许可。[XMOS 官方迁移说明](#)、[lib\\_voice 许可](#)

文件和评分接口也可能改变结论。例如 `libsndfile` 的 `sf_readf_*` 返回时间帧数，`sf_read_*` 返回通道展开后的标量项数；最后一块不足请求长度时，只能按实际返回量更新录音时长与算法状态。评分器则要同时保留失败数和模型资产状态，不能把“源码可以导入”写成“已经能评分”。这些独立对照的输入与建议试验见研究文档，不表示本书已完成对应设备验收。[libsndfile 官方读写接口](#)

本书已运行三库的[工业接口实验](#)：48 kHz 双通道输入重采样到 16 kHz，保留同一状态并排空尾部后，整段与 127/509 帧分块输出相同；中途清状态且不排空则少了 434 个输出帧。另以七帧双通道 PCM16 检查短读，按帧请求三帧时返回 3、3、1、0，按标量项请求六项时返回 6、6、2、0。程序与原始报告均可重跑，这些结果不代表设备回调期限或断连恢复已经通过。

上游源码按锁定清单独立获取到被 Git 忽略的 `codes/upstream/_downloads/`，保留原许可证和版本；是否已下载以本机获取记录为准。代码、权重和数据分别管理。`codes/array_tutorial/` 中的程序是本书教学基线，作用是复算约定和边界；下载上游源码本身也不意味着已经完成依赖安装、编译和目标设备验证。

模型落地时还要固定输入采样率、通道顺序、块长、动态轴、归一化、状态张量、算子集、运行时版本和线程配置。冷启动测量包含模型读取、图优化、权重上传和首轮内核准备；稳定运行延迟要在 warm-up 后另测。更新模型前保存可回滚版本，并用同一硬件、同一数据和同一计时范围比较。

在 ONNX Runtime 中，算子内部线程数与图节点之间的并行是两个参数；线程自旋也会影响功耗。多模型并发时，应测各会话线程池的竞争和音频期限，不能直接复制单模型离线计时的最佳设置。对于 TensorFlow Lite Micro，模型文件大小也不等于内存占用：tensor arena 中的持久、临时和可复用张量之外，还可能有音频缓存和栈。[ONNX Runtime 线程说明](#)、[TFLM 内存说明](#)

## 10.10 联调与验收

联调应按依赖关系排查，不必强行把所有模块串成一个固定顺序。

| 阶段      | 检查内容                           | 验收口径怎样确定                     |
|---------|--------------------------------|------------------------------|
| 采集      | 通道映射、时间戳、削波、丢帧、自噪声、SRO         | 由器件规格、最长运行时间和下游容差确定          |
| AEC     | 参考对齐、路径覆盖、单讲收敛、双讲稳定、路径变化恢复     | 分别报告 ERLE、近端损伤和恢复时间；覆盖目标播放状态 |
| WPE     | 晚期混响衰减、直达声损伤、长时稳定              | 在目标房间和说话距离上与关闭 WPE 对照        |
| 定位/追踪   | 角误差、漏检、虚警、人数、轨迹身份切换、轨迹中断       | 按覆盖区和应用允许误差设线，包含交叉与遮挡        |
| 波束/分离   | 目标保持、干扰抑制、失配鲁棒性、串扰             | 同时报任务指标与语音损伤，不只报 SI-SDR      |
| NS/AGC  | 噪声残留、语音损伤、抽动、削波                | 覆盖噪声类型和输入电平，补 P.835 主观听测     |
| KWS/ASR | 指定误报率下的漏报率、WER/CER、首尾截断        | 使用目标语言、距离、噪声、说话人和播放状态        |
| 系统      | 关键路径延迟、RTF、峰值内存、平均/峰值功耗、长时间稳定性 | 在目标硬件、发布配置和最不利并发状态实测         |

每个验收阈值都应包含测量条件、统计量和样本量。例如“角误差小于 5°”还要说明声源角度分布、距离、房间、信噪比，以及该数值是均值还是某个分位数。教程中的算例只能用于验证计算，不能直接作为产品验收阈值。

在线监控应记录足以定位故障、但不默认保存原始语音的字段。本书给出的

`telemetry_schema.json` 采用以下口径；它是最小示例，不含用户身份、转写文本或原始音频。



| 字段组                          | 单位与统计口径                     |
|------------------------------|-----------------------------|
| timestamp_ns 、 frame_index   | 单调采集时钟域；时间戳指本帧首样本，不是墙上时间    |
| queue_depth                  | 发布该条记录时仍在等待的帧数，不含正在执行的帧     |
| xrun_count 、 dropped_samples | 从流启动起的累计值；丢样按时间样本计，不按通道展开   |
| clipping_fraction            | 本帧所有通道标量样本中的削波比例            |
| sro_ppm                      | 相对指定参考设备、在已配置估计窗内得到的采样率偏移   |
| rtf 、 deadline_miss          | 本帧关键路径处理时长除以音频时长，以及是否越过本帧期限 |
| agc_gain 、 model_version     | 本帧线性幅度增益；完整有序模型链的稳定版本标识     |

simulate\_deadline\_queue 的 queue\_high\_water 包含正在处理的帧，故不能直接写进上表的等待队列深度。实际产品若要记录敏感内容，应按 § 10.6 的同意、访问、保留和删除规则另行设计。

故障注入要对应恢复动作：

- 固定延迟跳变用于检查 AEC 重对齐；
- 单通道增益或相位扰动用于检查标定和波束鲁棒性；
- 插入或删除样本用于区分丢样与 SRO；
- CPU 负载脉冲用于检查队列、尾延迟和降级；
- 截断或 NaN 模型输出用于检查旁路和重置。

每次试验都要记录注入位置、持续时间、期望状态转换和恢复时间，不能只确认进程没有崩溃。教学接口会拒绝非有限阈值、非整数容量和非有限输入，不将这些输入静默转成有效音频；设备上的旁路或停流策略则要由系统接口另行定义。

常见故障可按依赖关系缩小范围：

| 现象          | 先查                    | 再查         |
|-------------|-----------------------|------------|
| 播放时残余回声突然增大 | 参考取点、整体延迟、削波、前置增益变化   | 滤波器长度和双讲控制 |
| 语音发闷或辅音丢失   | NS 增益、WPE 预测延迟、AGC 抽动 | 波束指向失配和标定  |
| 定位随时间缓慢漂移   | 时钟域、SRO、丢样            | 几何和温漂后的标定  |

| 现象          | 先查                 | 再查                |
|-------------|--------------------|-------------------|
| 唤醒差但 ASR 正常 | KWS 取点、缓存、训练域和阈值曲线 | VAD 是否错误截断 KWS 输入 |
| 平均实时但偶尔爆音   | 最坏帧耗时、调度抖动、缓冲下溢    | 平均 RTF 和内存带宽      |

### 10.11 本章练习

以下十四题的输入均为本书构造的教学数据。先手算，再运行 E10-01~12 与 E10-14 的 `exercises_engineering.py`：

```
.venv/bin/python -m codes.examples.exercises_engineering
```

E10-13 运行独立的 `spectral_subtraction_demo.py`。两种程序按稳定编号输出中间量和结果；它们不访问声卡，也不代表硬件性能测量。

E10-01：把初始错位与 SRO 分开。在参考时间  $[0, 10, 20]$  s 测得相对延迟  $[2, 3, 4]$  ms。按 § 10.2 的一阶模型求截距、ppm、600 s 累积漂移，及设备转到参考速率所需的“输出/输入”比例。

答案：斜率为  $(4 - 2) \text{ ms} / 20 \text{ s} = 10^{-4}$ ，即 100 ppm；截距为 2 ms。累计漂移约  $10^{-4} \times 600 = 0.06 \text{ s}$ ，即 60 ms，不含初始的 2 ms；比例约  $1 / 1.0001 = 0.99990001$ 。这组点恰好共线，不能据此认为实录估计也没有噪声，或首尾两点足以识别丢样。

E10-02：VAD 的迟滞与两帧挂起。帧长 160 点、采样率 16 kHz，启动/继续能量阈值为 0.08/0.03，挂起为 2 帧，初始不活动。六帧均方能量依次为  $[0, 0.09, 0.04, 0, 0, 0]$ 。写出六个活动标志及挂起时间。

答案：`[False, True, True, True, True, False]`。第 2 帧越过启动阈值；第 3 帧虽低于启动阈值，却高于继续阈值，因此继续活动并补满挂起计数。第 4、5 帧消耗两个计数，第 6 帧关闭。每帧  $160 / 16000 = 10 \text{ ms}$ ，两帧为 20 ms；这不包含预卷，也不保证真实辅音都能保留。

E10-03：环形缓冲满了以后留下什么。容量为 4 个时间样本，依次写入  $[1, 2, 3]$  和  $[4, 5]$ ，中间不读取；溢出策略为丢最旧样本。求读取结果、累计丢样数。若这些数来自连续 FIR 输入，应如何处理历史？

答案：保留  $[2, 3, 4, 5]$ ，丢 1 个样本。不能把新数据直接标成与旧数据连续而不记录缺口；应将丢样事件和时间戳通知下游，再按协议重置、重新对齐或做明示的缺口填充。环形缓冲只实现容量语义，不会自行修复 AEC 历史。

E10-04：平均处理量够，为什么还会丢帧。每 10 ms 到一帧，六帧处理耗时为 [2, 18, 18, 2, 2, 2] ms。一条串行线程，容量为 2 帧，包含正在执行者；满时丢新帧。各帧期限为自身到达时间加 10 ms。计算接纳、结束、违约及丢帧情况。

| 帧号（从 0 开始） | 到达（ms） | 开始（ms） | 结束（ms） | 结果      |
|------------|--------|--------|--------|---------|
| 0          | 0      | 0      | 2      | 按期      |
| 1          | 10     | 10     | 28     | 违约      |
| 2          | 20     | 28     | 46     | 违约      |
| 3          | 30     | 46     | 48     | 违约      |
| 4          | 40     | —      | —      | 容量已满，丢弃 |
| 5          | 50     | 50     | 52     | 按期      |

答案：总输入工作量比为  $44/60 \approx 0.733$ ，但 3 帧违约、1 帧丢失，高水位为 2，最大等待为 16 ms。这里的 0.733 是全部输入的拟处理工作量比；不是把已经丢弃的任务从分子删掉后得到的“设备 RTF”。模拟不含线程抢占和驱动下溢。

E10-05：半个量化级怎样取整。把  $[-1, -0.5/32768, 0.5/32768, 1.5/32768, 1]$  转成 Q1.15。使用最近偶数舍入和有符号饱和，写出整数编码。

答案：乘 32768 后为  $[-32768, -0.5, 0.5, 1.5, 32768]$ ；舍入和饱和后为  $[-32768, 0, 0, 2, 32767]$ 。恰好位于半级处时选偶整数；正满幅不能精确表示。若目标内核采用截位，这道题应有不同答案，不能将两种实现混称为逐位一致。

E10-06：峰值保护与目标电平不是一回事。初始增益 1，目标峰值 0.8，最大增益 4，增益下降/上升平滑系数均为 0.5。连续两块是  $[-0.2, 0.2]$  和  $[-2, 2]$ 。按 PeakProtectAGC 计算平滑增益、安全限幅和输出峰值。

答案：第一块期望增益为 4，平滑后  $1 + 0.5(4 - 1) = 2.5$ ，输出峰值 0.5。第二块期望增益为 0.4，平滑后  $2.5 + 0.5(0.4 - 2.5) = 1.45$ ，但不削波上限为  $1/2 = 0.5$ ，最终增益 0.5、输出峰值 1。安全保护避免超出满幅，并不保证每块恰好达到目标 0.8，也不能修复输入中已有的模拟削波。

E10-07：一帧音频占多少字节。16 kHz、4 通道、PCM16 的采集接口每次交付 160 个时间帧，各通道交织排列。求一块中的标量样本数、字节数、音频时长及连续一秒的字节数，不计文件头和传输协议开销。

答案：一个时间帧包含同一时刻的 4 个通道值，所以有  $160 \times 4 = 640$  个标量样本；PCM16 每个值占 2 B，共  $640 \times 2 = 1280$  B。时长按每通道计，为  $160/16000 = 10$  ms，不是  $640/16000$  s。连续一秒为  $16000 \times 4 \times 2 = 128000$  B。

这是数组与传输量计算，不含驱动缓冲、对齐填充或文件封装。PortAudio 的 `frameCount` 和重采样接口的帧数均应与通道标量数分开，不能用“帧”同时表示两种单位。

E10-08：块长不同要等到最小公倍数吗。从  $t = 0$  开始采集，每 10 ms 完整交付 160 点。两条独立消费者各需要连续的 240 点、512 点；已有足够样本时立即调用并保留余量。假设计算耗时为零，不把一条消费者的输出串到另一条。求首次调用时间、480 ms 内调用次数及最后余量。

240 点消费者在 10 ms 时只有 160 点；20 ms 收到 320 点，消费 `[0,240)` 后剩 80 点。30 ms 又收到 160 点，恰可消费 `[240,480)`。512 点消费者在 30 ms 时只有 480 点，要到 40 ms 收到 640 点后才能首次消费，剩 128 点。区间使用从 0 开始的左闭右开样本编号。

480 ms 共收到  $48 \times 160 = 7680$  点，两者分别完成  $7680/240 = 32$  次和  $7680/512 = 15$  次调用，最后余量均为零。7680 点是三个块长的最小公倍数，只决定这次余量同时归零的时刻，不是首次启动的必要等待。

代码输出每次消费的起止索引、发生在哪次回调及每轮余量。应检查相邻消费区间首尾相接，不能只核对总长度。真实设备还要计入非零计算耗时、线程队列和输出时间戳；本题没有证明系统实时。

E10-09：通道极性接反能否靠平均修好。目标信号已对齐，无噪声，两路分别为  $s$  与  $0.9s$ 。比较正常平均和第二路极性反转后的平均，求目标幅度增益与两种输出之间的电平差。

正常平均为  $(s + 0.9s)/2 = 0.95s$ ；反转后为  $(s - 0.9s)/2 = 0.05s$ 。后者相对前者为  $20 \log_{10}(0.05/0.95) \approx -25.575$  dB。若两路幅度完全一致，反转后目标会完全抵消；这不是噪声被压低的证据。

题目只展示符号错误，未加入时延或频率相关响应。对照[音频实验手册](#)中的极性样本时，不要分别归一化输出峰值，否则目标衰减会被隐藏。

E10-10：同一个平滑系数为何不能跨块长照搬。期望增益固定为  $g_*$ ，不触发峰值保护，增益按一阶平滑更新。时间常数  $\tau_g = 100$  ms，希望经过相同实际时间后保留相同误差比例。分别计算 10 ms 和 32 ms 更新间隔的系数，并比较 320 ms 后的误差。

令更新间隔为  $\Delta t$ ，本书按连续指数衰减在每个更新时间取样，得到

$$\begin{aligned} g_{k+1} &= g_k + \alpha_g(g_* - g_k), \\ \alpha_g &= 1 - e^{-\Delta t/\tau_g}, \quad g_k - g_* = e^{-k\Delta t/\tau_g}(g_0 - g_*). \end{aligned} \tag{10-6}$$

这是因为一次更新后误差乘  $1 - \alpha_g$ ，连续  $k$  次则乘  $(1 - \alpha_g)^k$ 。因此两种系数分别为  $1 - e^{-0.1} \approx 0.095163$ 、 $1 - e^{-0.32} \approx 0.273851$ ；经过 32 次和 10 次更新后，都保留  $e^{-3.2} \approx 0.040762$ ，即约 4.0762% 的初始误差。

PeakProtectAGC 接受的 attack/release 是每次调用的平滑比例，不是秒数。输入电平变化、攻击与释放切换或安全限幅触发时，固定  $g_*$  的推导不再描述全部过程，不能因此要求任意分块的 AGC 波形完全相同。

E10-11：同样的麦位误差为何有不同相位误差。频率 4 kHz、声速 343 m/s，声源方向  $\vec{u} = [1, 0, 0]^T$ 。相对麦位误差分别为  $[0.0005, 0, 0]^T$  m 和  $[0, 0.0005, 0]^T$  m。按式(10-3)求相位误差。

两次位移长度都是 0.5 mm，但投影分别为 0.0005 m 与 0。换成角度后，第一种为  $360 \times 4000 \times 0.0005 / 343 \approx 2.099^\circ$ ，第二种为  $0^\circ$ 。最大位移约束给出相位误差上界，不代表每个入射方向都达到它；近场与机壳散射不在本题模型内。

E10-12：把一次跳变拟合成 SRO 会怎样。在参考时间  $[0, 1, 2, 3, 4, 5]$  s 观察到延迟  $[0, 0.1, 0.2, 1.3, 1.4, 1.5]$  ms。已知真实漂移斜率为 100 ppm，而 3 s 起额外出现 1 ms 阶跃。先直接拟合全部点，再减去已知阶跃拟合；比较结果。

时间均值为 2.5 s，延迟均值为 0.75 ms。中心化时间平方和为  $17.5 \text{ s}^2$ ，时间与延迟乘积和为  $6.25 \text{ ms} \cdot \text{s}$ ，直接拟合斜率为  $6.25 / 17.5 \approx 0.357143 \text{ ms/s}$ ，即约 357.143 ppm；截距为  $0.75 - 0.357143 \times 2.5 \approx -0.142857 \text{ ms}$ 。

减去后半段已知的 1 ms 阶跃，六点恢复到每秒增加 0.1 ms，拟合得到 100 ppm 和零截距。这里人为提供了阶跃时刻与大小，不是一个自动丢样检测算法。实际阶跃也可能来自时间戳或重新对齐，必须结合采集事件记录判断原因。

E10-13：功率谱减与地板。一个频点的噪声专用帧复系数是 2，后续两帧带噪系数分别是 3、1。按式(10-4)取  $\alpha = 1$ 、 $\beta = 0.04$ ，求噪声功率估计、两个输出功率和幅度；再把  $\beta$  改为零，求第二个输出。说明零观测系数应怎样处理，及为什么这个计算不等于 MMSE-STSA。

答案： $D = 4$ ；带噪功率依次为 9、1，扣噪值为 5、-3，地板为 0.36、0.04，所以输出功率为 5、0.04，输出幅度为  $\sqrt{5} \approx 2.2361$ 、0.2。零地板时第二个输出为零；若原带噪复系数本身为零，直接输出零，因为相位未定义。

代码还给出同一合成输入在三个版本的噪声专用前奏中的均方根值；它们是单次有种子的波形数值，不能拿来证明自然语音的质量排序。MMSE-STSA 要基于语音与噪声的概率模型最小化谱幅度误差，本题没有这些步骤。



E10-14: 平均算得过来，六帧为何仍错过期限？按 § 10.4.3 的到达时间、服务耗时、在途容量、状态内存和功率假设，先逐帧写出开始与完成时间，再求平均 RTF、最大响应、错过期限数、队列高水位、峰值内存及重复工作模式下的续航。若把在途容量缩成两帧，哪些新风险必须重新计算？

参考答案：逐帧开始时间为 [0, 10, 20, 45, 49, 53] ms，完成时间为 [4, 14, 45, 49, 53, 57] ms；服务总计 45 ms，六帧音频长 60 ms，RTF 为 0.75，但最大响应 25 ms、三帧超过 10 ms 期限。 $t = 40$  ms 时有三帧在途，容量 3 恰够；峰值内存为 667.5 KiB，示意续航约 6.23 h。

容量缩为 2 后， $t = 40$  ms 的新到达帧可能被丢弃；不能沿用容量 3 的完成时间、功率占空比和丢帧数，应重新模拟队列。示例代码输出容量 3 的完整时间线，不把六帧最大值称作稳定 p99，也不把预算数字称作芯片测量。

## 10.12 本章小结

---

1. 图 23 是参考依赖图，不是所有设备必须执行的固定流水线。
2. 延迟、算力和续航必须在目标硬件上按明确口径测量；窗口长度、MIPS 和 mAh 不能互相替代。
3. 门控至少要区分近端语音、远端播放和双讲；单个 VAD 比特不足以控制 AEC、WPE 和全部后端。
4. 固定阈值和品牌案例不能替代项目条件。每个验收数字都要带场景、统计口径和来源。

# 第 11 章 · 总结与选型指南

选型应从任务和约束开始。同一个四麦阵列用于固定座位通话、多人会议或机器人跟随时，合适的处理链可能完全不同。本章先确定目标，再选择几何和模块，最后按第 10 章的方法验证。

本章常用缩写如下：

| 缩写       | 中文名与英文全称                                                   |
|----------|------------------------------------------------------------|
| DOA      | 波达方向（Direction of Arrival）                                 |
| AEC      | 声学回声消除（Acoustic Echo Cancellation）                         |
| WPE      | 加权预测误差去混响（Weighted Prediction Error）                       |
| NS / VAD | 噪声抑制（Noise Suppression） / 语音活动检测（Voice Activity Detection） |
| RTF      | 实时因子（Real-Time Factor）                                     |
| SRO      | 采样率偏移（Sampling Rate Offset）                                |
| CSS      | 连续语音分离（Continuous Speech Separation）：连续输出少量语流，并处理跨块拼接      |
| TSE      | 目标说话人提取（Target Speaker Extraction）：按注册语音、视觉或方向条件提取指定目标     |

各定位、波束和追踪算法的全称在首次出现处给出。

## 11.1 先回答六个问题

1. 系统要输出什么？ 输出一个方向、连续轨迹、增强语音、彼此独立的多人语流、指定目标的一条语流，还是识别文本？ 多人输出还要说明人数固定还是随时间变化、整句处理还是连续流、是否需要保持说话人身份。输出不同，所需模块不同。只做固定方向录音时，不需要在线定位；只做方向显示时，也未必需要波束形成和 NS。
2. 覆盖区域和声源距离是什么？ 线阵适合重点覆盖阵列轴所在平面或扇区，但会有前后或镜像歧义；圆阵适合水平面环绕覆盖；平面阵与球阵可提供俯仰信息，但需要更多通道和更严格的标定。形态不是按“几只麦”直接决定的。
3. 空间分辨率和最高工作频率是什么？ 孔径影响角分辨率，阵元间距限制无空间混叠频带。增大孔径有利于低频方向信息，减小间距有利于高频无混叠。两者冲突时，可以增加阵元、限制工作频带或采用非均匀几何；不能只报一个间距就宣称覆盖全频带。

4. 有哪些干扰？ 本机播放造成回声时才需要 AEC；晚期混响妨碍任务时再考虑 WPE；多人重叠且要输出独立语流时才考虑分离；稳定背景噪声可能用解析 NS 即可，复杂域外噪声则要验证神经网络的泛化。
5. 目标是否移动、人数是否变化？ 单个慢速目标可从简单平滑或卡尔曼滤波开始。人数变化、交叉和遮挡要求显式处理轨迹出生、消失和数据关联。概率假设密度（Probability Hypothesis Density, PHD）滤波、带标签多伯努利（Labeled Multi-Bernoulli, LMB）滤波或其他随机有限集方法不会因“人数多”自动成为合适方案；还要考虑观测模型、身份连续性要求和实现成本。
6. 硬件和合规边界是什么？ 写明采样率、麦数、时钟域、算力、峰值内存、功耗、关键路径延迟、隐私和认证要求。使用注册声纹或云端录音时，还要写明同意、访问、保留和删除方式，见第 10 章 § 10.6。每秒百万条指令（Millions of Instructions per Second, MIPS）不能脱离处理器型号比较，电池续航要用瓦时（Wh）与整机平均功耗估算，见第 10 章 § 10.4。

## 11.2 按条件选择模块

先把表中常用方法名与任务对应起来：

- 广义互相关相位变换（Generalized Cross-Correlation with Phase Transform, GCC-PHAT）从麦克风对估计相对时延；导向响应功率相位变换（Steered Response Power with Phase Transform, SRP-PHAT）在候选方向或位置上汇总多麦克风对的证据。
- 多重信号分类（Multiple Signal Classification, MUSIC）用噪声子空间与候选方向导向矢量的正交关系搜索谱峰；旋转不变子空间法（Estimation of Signal Parameters via Rotational Invariance Techniques, ESPRIT）用信号子空间及平移不变子阵解算方向。两者都要检查源数、快拍数和阵列模型。
- 最小方差无失真响应（Minimum Variance Distortionless Response, MVDR）在目标无失真约束下减小输出功率；线性约束最小方差（Linearly Constrained Minimum Variance, LCMV）可同时施加多条方向或响应约束。协方差估计和导向失配会影响两者。

| 决策对象   | 适合先尝试的方案               | 何时换方案                                           | 同时检查的风险         |
|--------|------------------------|-------------------------------------------------|-----------------|
| 单源 DOA | GCC-PHAT 或 SRP-PHAT 基线 | 需要更高分辨率且协方差条件满足时，评估 MUSIC 或 ESPRIT；复杂混响下可评估学习方法 | 阵列歧义、混响、宽带融合、虚警 |

| 决策对象   | 适合先尝试的方案                                                    | 何时换方案                                                        | 同时检查的风险                                             |
|--------|-------------------------------------------------------------|--------------------------------------------------------------|-----------------------------------------------------|
| 固定方向增强 | 延时求和或固定超指向<br>(superdirective) 波束                           | 噪声场变化且统计量可估<br>计时，评估 MVDR 或<br>LCMV 波束形成                     | 白噪声增益、方向失配、<br>标定                                   |
| 自适应波束  | MVDR 或 LCMV 加稳健<br>化                                        | 目标相对传递函数或导向<br>矢量难以估计时，评估掩<br>码辅助或联合模型                       | 协方差秩、对角加载、目<br>标泄漏                                  |
| 晚期混响   | 先用关闭 WPE 的基线                                                | 晚期混响确实限制词错误<br>率 (Word Error Rate,<br>WER)、可懂度或听感时<br>启用 WPE | 预测延迟、阶数、直达声<br>损伤                                   |
| 本机回声   | 有播放泄漏时启用 AEC                                                | 非线性扬声器、路径变化<br>或多扬声器时增加相应建<br>模                              | 参考取点、整体延迟、双<br>讲                                    |
| 多人重叠   | 只需一路增强时先试多波<br>束选择或掩码波束                                     | 需要保留重叠中的全部语<br>音内容时评估分<br>离/CSS；只需指定一人<br>且有可靠目标条件时评估<br>TSE | 最大同时说话数、固定/<br>变化总人数、整句/连续<br>流、跨块排列、身份、内<br>容改变、算力 |
| 轨迹平滑   | $\alpha$ - $\beta$ 或卡尔曼滤波                                   | 多目标交叉、漏检和虚警<br>明显时换多目标滤波                                     | 坐标系、时间戳、轨迹身<br>份切换、轨迹中断                             |
| 残余噪声   | 维纳或最小均方误差<br>(Minimum Mean-<br>Square Error, MMSE)<br>等解析基线 | 非平稳噪声下基线不足时<br>评估神经 NS                                       | 语音损伤、域外噪声、下<br>游 WER                                |

算法名只确定了方法类别，还没有确定参数。WPE 的预测延迟和阶数、MVDR 的加载量、AEC 的滤波器覆盖范围、VAD 的挂起时间都应由目标数据和硬件测量得到，不应作为通用默认值从别的产品复制。

多人重叠场景可按下面的决策维度缩小范围：

下表使用三种不同的识别口径：

- 拼接最小排列词错误率 (Concatenated minimum-Permutation Word Error Rate, cpWER) 先按说话人拼接参考与假设，再寻找一个全局最优的说话人排列；
- 最优参考组合词错误率 (Optimal Reference Combination Word Error Rate, ORC-WER) 允许参考语句在输出流之间做最优组合，不要求一条输出流全程对应同一个人；

- 说话人归属词错误率 (Speaker-Attributed Word Error Rate, sa-WER) 把词转写与说话人标签一起评价，归属错误会影响结果。

三者不能互换：ORC-WER 偏向检查内容是否被完整识别，cpWER 还要求全局输出流一致，sa-WER 用于确实需要身份归属的任务。

**四词手算：**两条流在第二段交换。下表每个“某词”都是一个独立词元；每段中甲、乙同时说话，分离器第二段把两人放进了相反的输出槽位。本例只比较词内容与流分配，不涉及分词歧义或时间容差。

| 时间段 | 甲的参考 | 乙的参考 | 输出流 1 | 输出流 2 |
|-----|------|------|-------|-------|
| 1   | 甲词   | 乙词   | 甲词    | 乙词    |
| 2   | 丙词   | 丁词   | 丁词    | 丙词    |

按说话人拼接的参考是甲流“甲词 丙词”和乙流“乙词 丁词”；实际输出分别是流 1“甲词 丁词”、流 2“乙词 丙词”。四个词的内容都在输出中，但第二段换了流。

cpWER 只能为整条输出流选择一次全局排列。不交换流时，甲流的“丙词→丁词”和乙流的“丁词→丙词”各产生一次替换；交换两条流也各有一次替换，因此最小编辑数为 2，参考总词数为 4，cpWER 为  $2/4 = 50\%$ 。

ORC-WER 按参考语句选择输出流：第一段的“甲词”给流 1、“乙词”给流 2，第二段的“丙词”给流 2、“丁词”给流 1。两条重组参考流于是分别等于两条输出流，编辑数为 0，ORC-WER 为  $0/4 = 0\%$ 。

这个零分只说明按该语句分配口径内容齐全，不能证明流 1 始终属于甲。sa-WER 还需要明确每个输出词的说话人标签及其评分定义，本例没有给出这些标签，故不计算 sa-WER。以上小例遵循下方固定版 MeetEval 对 cpWER 全局排列与 ORC-WER 逐语句分配的定义，不把二者当成同一个评分器的不同阈值。

实现时还要记录分段与重叠处理、标记规则，以及固定的评分工具版本或提交。本文核实于 2026-09-22，并将 MeetEval 对 cpWER、ORC-WER、MIMO-WER 和 DI-cpWER 的算法说明钉在提交 [6e3dc81284f2d6928f7ef9e620fd3b6906daa429](#)；该锁定文档没有把 sa-WER 列作同一工具的实现，使用 sa-WER 时应另行固定定义与评分器。复现实验还应记录实际安装包版本或完整提交号，不能只写会移动的 main。



| 任务条件  | 一路波束/掩码波束            | 连续语音分离（CSS）                        | 目标说话人提取（TSE）            |
|-------|----------------------|------------------------------------|-------------------------|
| 需要的输出 | 一路增强音频               | 固定或少量无重叠输出流；同一路可在不同时段承载不同说话人       | 被注册语音、视觉或方向指定的一人        |
| 人数变化  | 可跟随一个选中目标；不负责完整输出所有人 | 总参会人数可多于输出流数；流数由最大同时说话数和系统设计决定     | 非目标人数可变化，但目标条件必须持续有效    |
| 时间范围  | 可逐帧或分块在线处理           | 连续长录音；必须说明分块、上下文和拼接                | 可整句或流式；需报告注册和首帧延迟       |
| 身份连续  | 由追踪/分割模块提供           | 分离槽位不等于永久身份，通常还需分割或声纹关联            | 目标条件提供身份线索，但会受注册信道和冒用影响 |
| 主要验收  | 目标保持、串扰、语音损伤、WER     | 重叠段遗漏、跨块换人、cpWER/ORC-WER/sq-WER、延迟 | 目标遗漏、非目标泄漏、错误目标、隐私与删除   |

这张表比较的是任务条件，不表示 CSS 或 TSE 一定优于解析波束。若应用只消费一路音频，多输出分离会增加排列和资源问题；若应用要完整转写未知参会者，要求预先注册每个人的 TSE 又会成为功能性限制。

### 11.3 几何与算法要一起选

阵列几何决定观测中有哪些空间信息，算法决定如何使用这些信息。

- **双麦或近似线阵**：可以估计沿阵列轴投影的时差并形成方向性，但某些方向会有镜像歧义。适合已知目标扇区、孔径和外形受限的设备。
- **非共线三麦及平面阵**：能提供二维几何约束。精度仍受孔径、频带、遮挡和标定影响，不能把“三麦”简单归为单麦处理。
- **圆阵**：便于覆盖水平面。阵元数和半径应由所需角分辨率、最高频率与结构尺寸共同确定，不存在“全向必须至少四麦、六麦最好”的通用答案。
- **球阵或三维阵**：适合需要俯仰角、声场分析或多方向波束的任务。可用球谐阶数受阵元采样、无量纲频率  $kr$  ( $k = 2\pi f/c$  为波数， $r$  为球阵半径)、径向滤波噪声放大和标定误差共同限制，详见 § 10.8。
- **稀疏阵**：差分共阵可增加二阶统计中的虚拟滞后数，但不会凭空增加独立物理通道，也不保证宽带、相干声源和有限快拍下都能得到同样的自由度。应按第 3 章的适用条件验证。

白噪声增益（White Noise Gain，WNG）和指向性指数（Directivity Index，DI）之间常有取舍。更窄的波束或更深的零陷可能放大传感器自噪声和标定误差。对角加载、WNG 约束和限制工作频带都能改善鲁棒性，但通常会牺牲一部分空间选择性。

## 11.4 四个场景怎样推导方案

下表给的是推导方法，不是产品清单。

| 场景        | 条件变化             | 方案怎样变化                                                          |
|-----------|------------------|-----------------------------------------------------------------|
| 带扬声器的语音终端 | 若要求播放时仍能唤醒或通话    | AEC 成为必要候选；参考取在实际播放处理之后。圆阵、线阵或平面阵由覆盖区域和外形决定。无明显晚期混响时不必默认加 WPE。  |
| 会议室       | 若多人重叠较少，只需一路会议音频 | 先比较多波束选择和自适应波束。只有重叠说话造成任务失败，且需要独立语流时，再增加分离。远距离和长混响房间要用实测决定 WPE。 |
| 车载        | 若麦克风跨多个时钟域       | 先解决 SRO 和时间戳，再谈分区波束。播放参考需覆盖音乐、导航和通话混音。算法要在急速、行驶、开窗和空调状态分别测试。    |
| 耳机或助听设备   | 若监听路径对延迟和电池很敏感   | 监听与通话上行可采用不同链路。固定双麦波束和轻量 NS 是候选基线，不是必选答案；法规、反馈路径、佩戴变化和听觉安全优先。   |

同一场景也可能得出不同答案。例如会议设备安装在墙边时，覆盖区域可能只有半空间；放在桌中央时则要覆盖周向。前者可能适合线阵或弧形阵，后者可能适合圆阵。覆盖区域确定后，才能据此选择阵列形态和麦克风数量。

## 11.5 把候选方案写成可验证的规格

### 11.5.1 先写规格和证据口径

为了复现实验并比较方案，候选方案的规格应覆盖以下内容：

| 项目   | 应写内容                          |
|------|-------------------------------|
| 任务   | 输入、输出、目标声源数、是否需要身份连续          |
| 几何   | 坐标、尺寸公差、声孔和遮挡、工作频带            |
| 场景   | 距离、角度、房间、噪声、播放和运动状态           |
| 链路   | 每个模块的启用条件、取点、旁路和控制信号          |
| 资源   | 目标硬件上的 RTF、最坏帧耗时、峰值内存、平均/峰值功耗 |
| 延迟   | 前瞻、缓冲、计算、调度和解码关键路径            |
| 指标   | 任务指标、语音损伤、稳定性、置信区间和样本量        |
| 异常处理 | 通道失效、方向低置信度、网络断开和算力过载时的行为     |

可以先建立最小基线，再一次增加一个模块。增加模块后要同时检查收益、语音损伤、延迟、功耗和失败样例。

如果 WPE 没有改善目标房间的结果，或分离网络虽然提高了尺度不变信号失真比（Scale-Invariant Signal-to-Distortion Ratio, SI-SDR）却增加了内容错误，就不应因为流程图里画了它而保留。

开源实现也要按任务筛选。项目名称不能代替算法条件：

- PortAudio 解决设备输入输出，不解决跨设备同步。
- ONNX Runtime 执行模型，不规定模型训练目标。
- pyroomacoustics 适合房间与阵列原型，不证明目标设备实时。
- WebRTC AEC3 可以对照实时回声链路，但其内部参数不是其他产品的默认值。

选择开源项目时应把规范仓库、固定提交或发布、许可证、支持平台、输入输出契约、维护状态和最小测试一起写入方案，详见 § 10.9.1 与 [codes/SOURCES.lock.json](#)。

本书按 [codes/COVERAGE.md](#) 将算法分为“本仓库可运行基线、外部参考实现、原理索引、明确排除”四种状态。适配器只是调用外部实现的一种方式，不是第五种覆盖状态。教学实现通过单元测试，只能说明约定和边界算例正确；它没有经过目标设备的实时、长稳和主观听测，不能直接标成工业实现。

工程选型还要把“源码能获取”与“接口能接入、平台能编译、设备能通过验收”分开。Linux 会议终端可研究 ALSA/PipeWire 的设备和参考路由；Cortex-M 端侧模型可研究 TFLM/CMSIS-NN 的算子与内存；XMOSS 或 SOF 固件则需要对应硬件、工具链及拓扑。每条候选都应补一项故障试验，例如拔插后恢复、参考切换、跨块状态清零、缓冲不足或线程过载，具体入口见[工业部署研究](#)。

候选的输入输出与评分工具同样需要筛选。libsoxr、libsamplerate 的比例协议不能照搬；libsndfile 的时间帧数不能当成通道标量数；libebur128 的响度与真峰值也不是语音质量分。

有干净参考时才可按相应条件使用 STOI/ESTOI 或 ViSQOL，静音过多、有效帧不足、参考错配及模型缺失必须进入失败记录。各接口的固定版本与边界见[第 10 章工程对照](#)。

11.5.2 完整决策例：未知参会者的连续转写

假设会议中共有 2~6 名未注册说话人，人数随时间变化，但任一时刻最多两人同时说话。系统要连续输出全部内容给 ASR，并要求端到端延迟可测但尚未给定阈值。先用硬约束筛选，再进入实测：

| 条件或证据              | 一路掩码波束              | 两路 CSS                               | 注册声纹 TSE                  | 决定                |
|--------------------|---------------------|--------------------------------------|---------------------------|-------------------|
| 必须保留重叠双方内容         | 单路输出可能丢失其中一人，未通过硬约束 | 两路分别承载同一时刻最多两人的语音，设计目标与要求一致          | 每次只提取已指定目标，未通过“全部未知说话人”约束 | 保留两路 CSS 候选       |
| 总参会人数为 2~6 人且随时间变化 | 可选择当前目标，但不输出完整集合    | 不同说话人可在不同时段复用两路输出；需验证静默流和跨块排列        | 需事先获得每位目标条件，本场景没有         | 记录 CSS 的人数与槽位管理风险 |
| 连续长录音              | 可流式                 | 必须报告块长、左右上下文、拼接和状态重置                 | 模型若支持可流式，但功能约束已淘汰         | 对 CSS 设置延迟测试项     |
| 身份与识别评测            | 单路 WER 不能评价重叠双方     | 报 ORC-WER 或 cpWER；若要求身份再报 sa-WER     | 需另测错误目标和声纹冒用              | 先按无注册转写口径验收       |
| 资源与质量证据            | 作为低成本基线保留           | 在目标硬件测 p50/p95/p99 延迟、RTF、内存、遗漏和内容错误 | 功能约束不满足，不参加性能比较           | CSS 只有实测净收益后才采用   |

这个例子中，2~6 是整场会议的总参会人数，两路输出由“最多同时两人重叠”决定，二者并不冲突；输出槽位也不代表永久说话人身份。例子没有填写性能分数，因为算力和准确率必须在目标硬件与目标会议数据上测量。

若需求改成“始终只听主持人，且主持人可注册”，硬约束会改变，TSE 才重新成为候选。

## 11.6 练习

### 题 1：带播放的周向语音终端 (E11-05)

需求是水平面周向覆盖，设备会播放音乐，主要任务是唤醒和单人指令。两种示意圆阵半径都为 4 cm，分别放 4 麦和 6 麦；声速取 343 m/s，需求频率上限 4 kHz。先以相邻麦弦长  $2r \sin(\pi/M)$  与  $c/(2d_{\text{adjacent}})$  作单对筛查，再写出必要模块和两个关键对照实验。这个筛查不保证整个圆阵流形没有其他歧义。

答案要点：四麦相邻弦长为  $0.08 \sin 45^\circ \approx 0.05657$  m，对应筛查界约 3032 Hz，低于 4 kHz；六麦相邻弦长为  $0.08 \sin 30^\circ = 0.04$  m，对应 4287.5 Hz，高于 4 kHz。按本题相邻单对条件，只保留六麦候选继续研究，仍需用完整阵列几何和工作频带核对歧义与波束质量。

播放时仍需拾音，因此两方案都要评估 AEC，并确保参考覆盖播放处理。定位或多方向固定波束可用于周向选择；WPE 和分离不是默认必选。

关键对照至少包括“静音播放与音乐播放下的唤醒曲线”和“AEC 开关下的近端语音损伤及残余回声”。本题的几何数字是本书构造的筛查输入，不是任何产品的性能。运行

`exercises_engineering.py` 的 E11-05 可复算两行候选。

### 题 2：多人会议 (E11-06)

房间混响明显，偶尔有人抢话，系统只接受一路输出，端到端延迟不得超过 150 ms。三条链路分别为单路波束、波束加 WPE、两路分离器；其延迟依次为 90、115、180 ms。

前两种单路方案按同一份 100 个参考词、同一分词规则评分，分别有 25 和 20 个词错误。两路分离器尚无规定的流与参考匹配、合并评分协议，因此本题不给它单路 WER。先用输出路数和延迟两个硬条件筛选，再比较具有相同口径的词错误率。什么时候值得进一步验证 WPE，什么时候才需要重新考虑分离？



答案要点：两路分离器输出两路且延迟 180 ms，先被题设硬条件淘汰；不能给它填一个未定义评分口径的单路 WER。两种合格的单路方案在同一参考与分词规则下，示意 WER 分别为  $25/100 = 25\%$ 、 $20/100 = 20\%$ ，相差 5 个词错误，即 5 个百分点。还需在目标房间的独立会话上比较 WER、可懂度、语音损伤和资源，再决定是否启用 WPE；这一份示意数据不能给出统计显著性或一般优劣结论。

若需求改为必须完整保留重叠双方内容，应重定输出路数与延迟约束，并为所有候选固定同一目标内容、分词和多人评分协议；可按任务选用 ORC-WER 或 cpWER，不能把两路输出的未知错误数与上述单路 WER 排序。E11-06 的代码只执行题设筛选，不产生识别结果。

### 题 3：跨时钟车载阵列 (E11-07)

四只麦克风分属两个时钟域。示意初始错位为 2 ms，相对 SRO 恒定为 80 ppm，允许重对齐间的新增错位不超过 0.1 ms。比较每 10 s 和每 1 s 重对齐两种候选。为什么不能先调波束权重？还应先测什么？

答案要点：10 s 新增漂移是  $80 \times 10^{-6} \times 10 = 0.8 \text{ ms}$ ，失败；1 s 是 0.08 ms，通过题设的漂移条件。只靠周期性重对齐，理论最长间隔为  $0.0001 \text{ s} / (80 \times 10^{-6}) = 1.25 \text{ s}$ 。

初始 2 ms 必须另行对齐，不能把它误当成 SRO 斜率；丢样会产生阶跃，也不能靠改变斜率解释。应先测初始时差、累计漂移、丢样和时间戳稳定性，完成重采样或时钟同步后再标定几何与增益，最后调波束。

E11-07 只复算已知恒定 SRO；温漂、时间戳噪声和行驶状态仍要在设备上验收。

### 题 4：把空间带宽、同步与延迟放进同一张选型表

候选四麦均匀线阵间距为 4 cm，声速取 343 m/s，需求频带上限为 4 kHz。两个采集设备的最坏相对 SRO 为 80 ppm，目前每 5 min 才重新对齐一次，而允许的通道错位不超过 0.1 ms。

连续处理路径的采集/分帧、前瞻、计算、调度和解码分别为 16、8、22、5、70 ms；候选分离器若串行加入，还会增加 48 ms 前瞻和 18 ms 计算。要求端到端延迟小于 150 ms。判断阵元间距、同步周期、基础路径和分离器是否满足硬约束。

答案要点：

1. 阵元间距：空间混叠边界为  $f_{\text{alias}} = c/(2d) = 343/(2 \times 0.04) \approx 4288 \text{ Hz}$ ，因此 4 kHz 仍低于该理想远场边界，但余量只有约 288 Hz，实际还要考虑麦位误差与宽带过渡。
2. 同步周期：80 ppm 经过 300 s 的漂移为  $80 \times 10^{-6} \times 300 = 0.024 \text{ s}$ ，即 24 ms，远超 0.1 ms；若只靠周期性重对齐，最大间隔应不超过  $0.1 \text{ ms} / (80 \times 10^{-6}) = 1.25 \text{ s}$ 。

3. 基础路径：总延迟为  $16 + 8 + 22 + 5 + 70 = 121 \text{ ms}$ ，满足  $150 \text{ ms}$ ，但只剩  $29 \text{ ms}$  裕量。
4. 加入分离器：串行加入后为  $121 + 48 + 18 = 187 \text{ ms}$ ，不满足约束；除非通过并行、流水、减少前瞻或更换后端重新测得关键路径低于  $150 \text{ ms}$ ，否则不应启用该候选。

代码复算 E11-01：运行 `.venv/bin/python -m codes.examples.exercises_engineering`，核对 `alias_boundary_hz=4287.5`、`drift_300s_ms=24`、`maximum_alignment_interval_s=1.25` 和两条延迟。只要其中一个硬约束不满足，就不能用另一个指标的收益抵消。该练习验证算术和筛选逻辑，没有测量设备延迟。

### 题 5：评分覆盖与电池预算 (E11-02)

候选模型计划评测 10 个文件，只有 8 个成功评分，成功文件的平均分为 3.8。能否直接报告“完整测试集得分 3.8”？应同时给出哪些数量？

同一设备示意电池为  $3.7 \text{ V}$ 、 $2000 \text{ mAh}$ ，电池可用容量、老化裕量及电池至负载的转换效率合计系数为 0.8；在转换电路输出端测得的整机负载功率，低功耗状态为  $0.2 \text{ W}$ 、占时间 10%，处理状态为  $1.2 \text{ W}$ 、占时间 90%。估计负载平均功率和续航。这里的输入是预算示意，不是某产品规格；若改在电池端测功率，转换效率不能再计入系数。

答案要点：评分覆盖为  $8/10 = 80\%$ ，3.8 只能标成成功子集的平均分；应保留总数 10、成功数 8、失败数 2、失败原因和各场景分布。缺失项不能擅自填 0 分，也不能悄悄从完整测试集删除；是否判整次评测无效应遵守预先规定的规则。

容量先换成  $2 \text{ Ah}$ ，标称能量为  $3.7 \times 2 = 7.4 \text{ Wh}$ ；按题设综合系数，可交付负载的估算能量为  $7.4 \times 0.8 = 5.92 \text{ Wh}$ 。负载平均功率为  $0.2 \times 0.1 + 1.2 \times 0.9 = 1.10 \text{ W}$ ，续航约  $5.92/1.10 = 5.38 \text{ h}$ 。E11-02 输出这组中间值；温度、各因素随电流的变化和状态转换消耗没有单独建模，所以它是估计，不是续航验收。

### 题 6：平均文件分数与合并计数 (E11-03)

两个文件分别有 10、90 个参考词，替换、删除和插入的错误数之和分别为 1、45。先计算各文件 WER，再比较“每个文件等权平均”和“先合并错误数与参考词数”的结果。假设两文件都成功评分，分词与文本规范化完全一致。

答案要点：两文件的 WER 为  $1/10 = 10\%$  和  $45/90 = 50\%$ 。文件等权的宏平均为  $(10\% + 50\%)/2 = 30\%$ ；合并计数为  $(1 + 45)/(10 + 90) = 46\%$ ，相当于按参考词数加权。

两个值回答不同问题：前者给每个文件同样权重，后者给每个参考词同样权重。不能把宏平均写成合并计数 WER，也不能在比较模型时临时更换聚合方式。实际评测还要按任务固定说话人/会话归属、空参考文件与失败文件的处理方式；本题没有计算语音转写或多人排列。

## 题 7: p99 为什么还需要注明计算方法 (E11-04)

20 个示意延迟按升序为  $[1, 2, \dots, 19, 100]$  ms。采用最近秩定义：对分位数比例  $q > 0$ ，取升序数组中从 1 开始数的第  $\lceil nq \rceil$  项。计算 p50、p95、p99，再与 NumPy 的 `method="linear"` 比较。

答案要点：最近秩为  $\lceil 20 \times 0.50 \rceil = 10$ 、 $\lceil 20 \times 0.95 \rceil = 19$ 、 $\lceil 20 \times 0.99 \rceil = 20$ ，得到 10、19、100 ms。

线性插值则在从 0 开始的位置  $q(n - 1)$  取值：p50 位于 9.5，得到 10.5 ms；p95 位于 18.05，在 19 与 100 ms 间插值，得到  $19 + 0.05 \times 81 = 23.05$  ms；p99 位于 18.81，得到  $19 + 0.81 \times 81 = 84.61$  ms。NumPy 分位数文档的 Notes 小节给出该插值定义，核实于 2026-09-22。

两组结果来自不同的报告约定。预先选定方法，连同样本数、测量时长与测点一起记录；不要用仅 20 个样本宣称已经稳定估计实际系统的 99% 尾部。两种计算都不能补回未观测到的罕见卡顿。

## 11.7 后续阅读

---

要实现算法，可回到第 4~9 章查看定位、波束、AEC、WPE、分离和追踪。要制定整机预算和验收计划，见第 10 章。附录 A 汇总符号与数学工具，附录 B 给出进一步阅读、练习和排错入口。

# 附录 A · 符号术语数学

本附录的 12.1~12.3 汇总符号、术语和数学工具，12.4 用小矩阵与短序列练习复算；下一篇是附录 B。

## 12.1 符号表

约定同 § 2.3：斜体 = 标量，头顶箭头 = 向量，加粗大写 = 矩阵； $H$  表示共轭转置， $\top$  表示转置， $\hat{\phantom{x}}$  表示估计值。 $X(f)$ 、 $X(f_k, \ell)$  这类大写字母按语音文献惯例表示逐频点复数标量。

本书采用前向傅里叶核  $e^{-j2\pi ft}$ 。

阵列坐标约定为：麦 1 位于  $x = 0$ ，麦 2 位于  $+x$ ；正横为  $0^\circ$ ，正角朝麦 2； $\vec{u}$  从阵列指向声源，传播方向为  $-\vec{u}$ 。

字母复用（与 § 2.3 一致）：受文献惯例所限， $k$  可表示频点索引、波数或 WPE 的滞后帧号； $D$  可表示阵列孔径或 PHD 强度函数； $\lambda$  可表示波长、WPE 功率谱或矩阵特征值； $K$  可表示声源数或 WPE 预测阶数； $s$  可表示源信号或追踪状态。具体含义以所在公式的定义为准。

需要区分 STFT 网格时，本书用  $k$  表示频点索引、 $f_k = kf_s/N$  表示对应的 Hz 频率、 $\ell$  表示帧索引；连续时间仍用  $t$ ，离散采样索引用  $n$ 。

| 符号                                                   | 含义                                                                               |
|------------------------------------------------------|----------------------------------------------------------------------------------|
| $M, d, D$                                            | 麦数、阵元间距、阵列孔径                                                                     |
| $c, \lambda, f, f_k$                                 | 声速 ( $\approx 343$ m/s)、波长、连续物理频率 (Hz)、第 $k$ 个 DFT/STFT 频点对应的物理频率 $f_k = kf_s/N$ |
| $\theta, \theta_0$                                   | 正横方向起算的入射角、波束指向角；端射为 $\pm 90^\circ$                                              |
| $\vec{u}(\theta)$                                    | 从阵列指向声源的单位向量；声波传播方向为 $-\vec{u}$                                                  |
| $\vec{r}_m, \vec{p}$                                 | 第 $m$ 个麦克风的位置向量、声源位置向量                                                           |
| $t, n, k, \ell, T$                                   | 连续时间、离散采样索引、频点索引、帧索引、用于统计的快拍数；WPE 等局部公式若复用 $k$ 作滞后号，会在公式旁重新定义                    |
| $\psi$                                               | 相邻两麦在指向补偿后的残余相位差 (§ 2.6、§ 5.2)                                                   |
| $\vec{a}(\theta), \vec{w}$                           | 导向矢量、波束权重                                                                        |
| $\hat{\mathbf{R}}, \mathbf{R}_{nn}, \mathbf{R}_{ss}$ | 空间协方差矩阵、噪声协方差矩阵、目标协方差矩阵                                                          |
| $\mathbf{\Gamma}$                                    | 球面各向同性弥散噪声场的相干矩阵；水平面入射模型另见 § 5.1                                                 |

| 符号                                                           | 含义                                                                                                                                                        |
|--------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| $\mathbf{E}_n$ ( $\mathbf{E}_s$ )                            | 噪声（信号）子空间的特征向量基（§ 4.6）                                                                                                                                    |
| $\sigma^2$                                                   | 噪声方差/功率（白噪声下协方差为 $\sigma^2 \mathbf{I}$ ）                                                                                                                  |
| $\mathbf{C}, \vec{f}$                                        | LCMV 约束矩阵与约束值向量, $\mathbf{C}^H \vec{w} = \vec{f}$ （§ 5.5）                                                                                                 |
| $\vec{e}_r$                                                  | 参考麦选择向量（第 $r$ 位为 1 的单位向量，见 § 5.5 参考麦选择，MWF/SDW 用）                                                                                                         |
| $\mathbf{B}$                                                 | GSC 阻塞矩阵，满足 $\mathbf{B}^H \vec{a}(\theta_0) = \vec{0}$ （§ 5.6）                                                                                            |
| $\Phi(f)$                                                    | GCC 加权函数（§ 4.2） vs 功率谱（§ 5.7），语境区分                                                                                                                        |
| $\mathbf{P}, \mathbf{K}, \mathbf{Q}, \mathbf{F}, \mathbf{H}$ | 卡尔曼滤波：误差协方差、卡尔曼增益、过程噪声协方差、状态转移、观测矩阵（§ 9.2）                                                                                                                |
| $V, A, S, \bar{\alpha}$                                      | 房间体积、等效吸声面积、总表面积、平均吸声系数（§ 2.4）                                                                                                                            |
| $\mu_{\text{NLMS}}$                                          | 归一化最小均方（Normalized Least Mean Squares, NLMS）步长（§ 6.1）；理想化独立性假设下常讨论 $0 < \mu < 2$ ，实际取值还受输入相关性、正则项和时变路径影响                                                  |
| $\mu_{\text{SDW}}$                                           | 语音失真加权多通道维纳滤波（Speech-Distortion-Weighted Multichannel Wiener Filter, SDW-MWF）的失真—降噪折中系数（§ 5.5）；与上一行的 NLMS 步长不是同一物理量                                       |
| $\varepsilon_{\text{NLMS}}$                                  | 归一化最小均方（Normalized Least Mean Squares, NLMS）更新分母中的小正数，用于防止输入能量接近零时除零（§ 6.1）                                                                               |
| $\delta, \eta$                                               | 绝对对角加载 $\mathbf{R} + \delta \mathbf{I}$ 中的 $\delta$ 与 $\mathbf{R}$ 同量纲；相对加载 $\mathbf{R} + \eta \text{tr}(\mathbf{R}) \mathbf{I} / M$ 中的 $\eta$ 无量纲（§ 5.4） |
| $\tau_{ij}$ , TDOA                                           | $\tau_{ij} = t_i - t_j$ ；到达时间差（Time Difference of Arrival, TDOA）。远场下 $\tau_{m1} = -(\vec{r}_m - \vec{r}_1)^\top \vec{u} / c$                              |
| $T_{60}$ , DRR, $d_c$                                        | 混响时间、直达混响比（Direct-to-Reverberant Ratio, DRR；dB 域读数）、临界距离                                                                                                  |
| WNG, DI, HPBW, SLL                                           | 白噪声增益（White Noise Gain, WNG）、指向性指数（Directivity Index, DI）、半功率波束宽度（Half-Power Beamwidth, HPBW）、旁瓣电平（Side-Lobe Level, SLL）                                  |



| 符号                         | 含义                                                                                                     |
|----------------------------|--------------------------------------------------------------------------------------------------------|
| RTF                        | 波束与空间模型中指相对传递函数（Relative Transfer Function）；工程与选型中指实时因子（Real-Time Factor），即处理耗时/音频时长。两者同缩写、不同量，按章节语境区分 |
| $h(n)$ , $\hat{w}$ , ERLE  | 回声路径、AEC 自适应滤波器、回声返回损失增强（Echo Return Loss Enhancement, ERLE）                                           |
| $G(k, f)$ , $\Delta$ , $K$ | WPE 预测系数（本书为滞后 $k$ 、频点 $f$ 的系数）、保护延迟、预测阶数                                                              |
| PHD/RFS                    | 概率假设密度（Probability Hypothesis Density, PHD）/随机有限集（Random Finite Set, RFS）                              |

表中  $\psi$  的“残余”是相对于目标指向  $\theta_0$  而言：来自  $\theta$  的波先按  $\theta_0$  补偿，之后相邻两麦还相差

$$\psi = \frac{2\pi d}{\lambda}(\sin \theta - \sin \theta_0)。$$

这里  $d/\lambda$  和正弦差都无量纲，所以  $\psi$  的单位是弧度。 $\theta = \theta_0$  时残余相位为零，各通道在目标方向对齐；偏离目标方向时，残余相位决定主瓣、零点和旁瓣的位置（§ 5.2）。

球面各向同性弥散噪声模型下，第  $i, j$  个麦克风的相干系数写成

$$[\mathbf{\Gamma}]_{ij} = \text{sinc}\left(\frac{2fd_{ij}}{c}\right), \quad \text{sinc}(x) = \frac{\sin(\pi x)}{\pi x}。$$

$d_{ij}$  是两麦间距， $f$  是 Hz 频率， $c$  是声速；当  $i = j$  或  $f = 0$  时取极限值 1。这一形状依赖声源从三维球面各方向入射的假设。若声源只从水平面各方向入射，相应形状为零阶贝塞尔函数  $J_0(2\pi fd_{ij}/c)$ ；两种声场不能混为同一个矩阵模型（§ 5.1）。

3 分钟手算（12.1）：在无失真归一化、各通道自噪声独立且等功率时， $M = 6$  的 DSB WNG 是多少 dB？ $2 \times 2$  对角协方差  $\text{diag}(4, 1)$  的特征值是哪两个数？

答案： $10\log_{10} 6 \approx 7.8$  dB；对角阵的特征值就是对角元 4 和 1。这里的特征向量是两条传感器空间坐标轴，不一定对应真实空间中的两个入射方向。

## 12.2 术语词典

下表按主题解释正文和相关文献中常见的术语。

信号与数学基础

| 术语                         | 解释                                                                                                  |
|----------------------------|-----------------------------------------------------------------------------------------------------|
| STFT（短时傅里叶变换）              | 把波形分成重叠短帧，并对每帧计算频谱，得到时间—频率复数表示。窗长与帧移按频率分辨率、时变性和延迟要求选择；逐频点处理可把宽带问题近似拆成多个窄带问题（§ 2.5）                  |
| 快拍（snapshot）               | 某一帧、某一频点上， $M$ 个麦克风复数谱排成的列向量——阵列的一张“空间照片”（§ 2.5）                                                    |
| 空间协方差矩阵 $\hat{\mathbf{R}}$ | 阵列文献常把快拍外积的时间平均称为空间协方差。若未减均值，它严格说是未中心化二阶矩；零均值或已经中心化时才等于样本协方差。它是 Capon/MVDR/MUSIC 的共同输入（§ 2.5）       |
| 特征分解 / 子空间                 | 把厄米矩阵拆成特征值与特征向量。在源协方差满秩、 $K < M$ 、空间白噪声、模型正确且快拍充足时，较大特征值对应的特征向量张成信号子空间，噪声底对应的特征向量张成噪声子空间（图6d、§ 4.6） |
| 超定方程组                      | 方程比未知数多，通常无精确解、只可求最小二乘解——TDOA 定位的麦对多于未知数时就是这样（见 § 4.4）                                              |
| 双曲线定位                      | 一对麦测出时延差 $\Leftrightarrow$ 声源在“到两麦距离差为常数”的双曲线上；多对麦的双曲线交点即声源（见 § 4.4）                                |
| 常规波束分辨率 / 超分辨              | 常规波束主瓣宽度的量级约为 $\lambda/D$ ；子空间方法在模型正确、信噪比和快拍数足够时可形成更窄谱峰，因此称为超分辨（§ 2.6、§ 4.6）                        |
| 波束图（beampattern）           | 波束形成器对各个方向的增益图，主瓣/旁瓣/零陷都在上面读（图7a）                                                                   |
| 自由度（DOF）                   | 可调参数的个数。 $M$ 麦波束形成器有 $M$ 个复数自由度，每条约束消耗一个（§ 5.5）；稀疏阵用协同阵（见本组“差分协同阵”行）增加虚拟自由度（§ 3.3）                  |
| 抽头（tap）                    | FIR 滤波器的一个系数。“128 个抽头”表示 128 个系数；按多项式阶数定义时对应 127 阶，阅读文献时需核对作者采用的口径（§ 6.1）                           |

| 术语                               | 解释                                                                                                                                                                                                                          |
|----------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 优先效应 (precedence effect)         | 直达声之后短时间内到达的反射，会与直达声共同影响听觉事件，但方向判断通常更偏向先到声。延迟、声级差和信号类型改变时，反射仍可能改变音色、清晰度或定位结果（§ 2.4）                                                                                                                                         |
| 拉格朗日乘子法                          | 带约束求极值的标准工具：“约束写成等式加到目标里，再求导令零”，MVDR 的闭式解就是这么推的（§ 5.4）                                                                                                                                                                      |
| GCC-PHAT 频谱相位加权                  | 每个频点把非零互功率谱 $G_{12}(f)$ 除以 $ G_{12}(f) $ ，使其模为 1、保留相位；零模频点须跳过或作数值保护。它改变时延估计中的频率权重，不能据此声称麦克风间噪声已被空间白化（§ 4.2）。 <a href="#">Knapp 与 Carter 的 GCC 原始论文</a>                                                                      |
| 空间噪声白化 (spatial noise whitening) | 在同一频点、正定噪声协方差 $\mathbf{R}_{nn}$ 已知时，对通道快拍施加矩阵 $\mathbf{W}$ ，使 $\mathbf{W}\mathbf{R}_{nn}\mathbf{W}^H = \mathbf{I}$ ；导向矢量也须改为 $\mathbf{W}\tilde{\mathbf{a}}$ 。它处理的是通道间的噪声协方差，不能与 GCC-PHAT 的逐频点标量加权混用。估计误差或病态矩阵需另行处理（E12-04）。 |
| sinc 函数                          | 本书定义 $\text{sinc}(x) = \sin(\pi x)/(\pi x)$ 。球面各向同性弥散场中的两麦相干系数具有 sinc 形式；若声源只在水平面各向同性分布，则对应零阶贝塞尔函数 $J_0(2\pi fd/c)$ （§ 5.1）。另一些文献把 sinc 定义为 $\sin x/x$ ，代入公式前必须先核对定义                                                        |
| SNR（信噪比）                         | 信号功率与噪声功率之比，常以 dB 表示。输出 SNR 减去输入 SNR 得到 SNR 增益。SER 在 AEC 语境中比较近端目标与回声功率，使用时应明确分子、分母和测量时段（§ 5.1、§ 6.1）                                                                                                                       |
| dB（分贝）                           | 比值的对数表示；功率比使用 $10\log_{10}$ ，幅度比使用 $20\log_{10}$ 。两种写法只有在功率与幅度平方成正比且参考阻抗一致时才对应同一物理变化（详见 § 12.3 ②）                                                                                                                           |
| FFT（快速傅里叶变换）                     | 离散傅里叶变换的高效算法，把一帧时域样本转换为各频点的复数谱；STFT 对连续短帧重复这一运算（§ 2.5）                                                                                                                                                                      |
| DNN（深度神经网络）                      | 由多层参数化变换组成、通过数据优化的模型。本教程主要用于估计时频掩码、方向概率或增强信号（§ 4.7、§ 5.9）                                                                                                                                                                   |

| 术语      | 解释                                                                                                                                  |
|---------|-------------------------------------------------------------------------------------------------------------------------------------|
| 远场 / 近场 | 远场中波前可近似为平面，导向模型主要由方向决定；近场采用球面波模型，还要考虑距离和通道幅度差。 $2D^2/\lambda$ 可作为检查波前相位曲率的距离尺度，但不是单独决定远近场的硬边界；还要检查 $r \gg D$ 、允许的相位误差和通道幅度差（§ 2.2） |

## 房间声学

| 术语                                      | 解释                                                                                                                                                          |
|-----------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|
| RIR（房间脉冲响应）                             | 在指定声源、接收位置和系统近似线性时，RIR 描述从声源到麦克风的声学传递路径；干净信号与 RIR 卷积可得到该路径下的接收信号（§ 2.4）                                                                                     |
| $T_{60}$                                | 混响时间：房间声能衰减 60 dB 所需时间。具体数值取决于房间体积、表面吸声和测量频带                                                                                                                |
| 直达混响比（Direct-to-Reverberant Ratio, DRR） | 直达声能量 ÷ 混响声能量，dB 域读数：DRR (dB) >0 直达占优，DRR (dB) <0 混响占优；负值绝对值越大，混响能量相对越高                                                                                     |
| 临界距离 $d_c$                              | 在给定声源指向性与扩散场假设下，直达声和混响声能量相等、即 DRR=0 的距离；Sabine 近似下常写成 $d_c \approx 0.057\sqrt{QV/T_{60}}$ ，其中 $Q$ 是声源指向因子。取全向声源 $Q = 1$ 时才化为 $0.057\sqrt{V/T_{60}}$ （§ 2.4） |
| 镜像法                                     | 把墙面反射等效成墙后镜像声源的仿真方法（Allen & Berkley 1979），pyroomacoustics 的核心                                                                                               |
| 弥散噪声场                                   | 来自大量方向、没有单一主导入射方向的声场模型。晚期混响常用这一模型近似；麦克风附近的湍流风噪通常不满足各向同性弥散场假设                                                                                                |

## 自适应滤波、增强与分离

| 术语               | 解释                                                                                                                                                                                |
|------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| LMS / NLMS / RLS | 最小均方（Least Mean Squares, LMS）结构简单；归一化最小均方（Normalized LMS, NLMS）按输入功率归一化步长；递归最小二乘（Recursive Least Squares, RLS）利用输入相关矩阵的递推逆，通常收敛更快，但计算量和存储量也更大。实际差距取决于输入相关性、滤波长度和参数设置（§ 5.6、§ 6.1） |

| 术语              | 解释                                                                                               |
|-----------------|--------------------------------------------------------------------------------------------------|
| 音乐噪声            | 谱减类方法过度估计噪声后残留的随机孤立谱峰，听起来像叮咚作响的流水声（§ 5.7）                                                        |
| ICA / IVA / PIT | ICA 利用源间统计独立性估计解混矩阵；IVA 把同一输出在各频点的分量组成向量联合估计，以降低频点间排列不一致；PIT（排列不变训练）在训练时选择与参考源匹配代价最小的输出排列（§ 8.1） |

### 波束形成与阵列度量

| 术语                                                              | 解释                                                                             |
|-----------------------------------------------------------------|--------------------------------------------------------------------------------|
| 导向矢量 $\vec{a}(\theta)$                                          | “如果声音从 $\theta$ 来，各麦应该是什么相位”的标准答案向量（§ 2.3）                                     |
| 转向（steering）                                                    | 把波束对准某个方向：按导向矢量补偿各通道时延/相位                                                      |
| 主瓣 / 旁瓣 / 零陷                                                    | 波束图中目标指向附近的主要响应区、主瓣外的局部峰，以及响应接近零的方向（图 7a）                                      |
| 栅瓣                                                              | 空间采样混叠产生的高旁瓣；均匀线阵在特定间距和转向下可出现与主瓣等高的方向歧义（§ 2.6、图 7b）                            |
| 白噪声增益（White Noise Gain, WNG）                                    | 衡量波束权重对各通道独立等功率白噪声的放大或抑制；在目标方向无失真归一化下， $M$ 元 DSB 达到 $10 \log_{10} M$ dB（§ 2.6） |
| 指向性指数（Directivity Index, DI）                                    | 指定各向同性弥散场与归一化口径下的方向性收益（§ 2.6）                                                  |
| 半功率波束宽度（Half-Power Beamwidth, HPBW）/ 旁瓣电平（Side-Lobe Level, SLL） | HPBW 是主瓣两个 $-3$ dB 点间的角宽；SLL 是最高旁瓣相对主瓣的电平（§ 2.6、§ 5.2）                         |
| CRLB / CRB（克拉美 – 罗下界，Cramér – Rao Lower Bound）                  | 给定概率模型和正则条件下，无偏估计器方差的下界；模型、参数化或偏差条件改变，下界也改变（§ 2.6）                             |
| MVDR（最小方差无失真响应）                                                 | 在 $\vec{w}^H \vec{a} = 1$ 的约束下最小化输出噪声功率。它保护目标方向或 RTF，同时压低噪声（§ 5.4）             |



| 术语                                      | 解释                                                                                                                                                                                                                                                          |
|-----------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| MWF（多通道维纳滤波）                            | 直接最小化参考目标与输出之间的均方误差，允许目标缩放来换取更小总误差。秩一目标模型下，MWF 可分解成 MVDR 空间滤波器乘一个标量维纳后滤波器，但两者不是简单的“加不加约束”关系。对本书 $\vec{w}_{\text{SDW}} = (\mathbf{R}_{ss} + \mu\mathbf{R}_{nn})^{-1}\mathbf{R}_{ss}\vec{e}_r$ 的定义， $\mu = 1$ 是标准 MWF； $\mu$ 增大时更重视降噪并趋向零输出，而不是趋向 MVDR（§ 5.5） |
| 相对传递函数（Relative Transfer Function, RTF） | 各通道相对参考通道的声学传递响应；是否包含早期反射取决于估计目标和时间窗，混响中 MVDR 常保护 RTF 而不是自由场导向矢量（§ 5.4）                                                                                                                                                                                     |
| 对角加载                                    | 求逆前在协方差矩阵上增加对角项，以改善条件数并降低对失配的敏感性。绝对加载写成 $\mathbf{R} + \delta\mathbf{I}$ ，相对加载写成 $\mathbf{R} + \eta\text{tr}(\mathbf{R})\mathbf{I}/M$ ；两种参数的量纲和缩放行为不同（§ 5.4、§ 12.3）                                                                                          |
| 相干源                                     | 内容高度相关的多个源（直达声 + 强反射）。MUSIC 遇相干源会失效（§ 4.6）                                                                                                                                                                                                                  |
| 空间平滑                                    | 把线阵切成重叠子阵分别估协方差再平均，牺牲孔径换去相干（§ 4.6）                                                                                                                                                                                                                          |
| 差分协同阵                                   | 由全部阵元位置差组成的虚拟位置集合；结合二阶统计重构，可在条件满足时获得长于物理阵列的连续虚拟孔径（§ 3.3）                                                                                                                                                                                                    |
| GEV 波束形成器                               | 最大化输出信噪比的波束形成器（广义特征值问题的解），与 MVDR（见本组 MVDR 行）并列的掩码后处理选项（§ 5.9）                                                                                                                                                                                               |
| GSS（导引源分离）                              | 利用方向或说话人活动信息引导空间聚类与波束形成的分离方法；常用 cACGMM 估计时频掩码，并用活动标注约束输出排列（§ 8.4）                                                                                                                                                                                           |
| WDO（W-不重叠正交性，W-disjoint orthogonality）  | 近似认为不同源在时频平面的非零支撑较少重叠，从而可逐时频点选取主导声源；它强于“互不相关”。例如两组系数 $[1, 1]$ 与 $[1, -1]$ 的内积为 0，但两个位置都同时非零，故不能由正交或零互协方差推出 WDO。强混响或多人同时发声会削弱这一近似（§ 8.1）。<br><a href="#">Yilmaz 与 Rickard 原始论文</a>                                                                           |

定位与追踪

| 术语                                       | 解释                                                                                                                                                      |
|------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------|
| 到达时间差 (Time Difference of Arrival, TDOA) | 本书定义 $\tau_{ij} = t_i - t_j$ ；同一声源到达一对麦克风的带符号时间差，是远场和近场定位的重要观测量（§ 2.1）                                                                                  |
| DOA（波达方向）                                | 声从哪个方向来，一般指角度。TDOA 是两路麦克风信号的到达时间差；紧凑阵列中常为几十到几百微秒。远场模型下，可结合麦克风间距和声速把 TDOA 换算成入射角（§ 4.1、§ 4.4）                                                            |
| ITD / ILD                                | 双耳时间差 (Interaural Time Difference, ITD) / 双耳声级差 (Interaural Level Difference, ILD)。双重理论把低频细结构 ITD 与高频 ILD 视为主要线索，但不是硬分界：低频可有 ILD，调制高频声也可提供包络 ITD（§ 1.1） |
| HRTF                                     | 头相关传递函数：头、耳廓和躯干对声音的方向相关滤波；其谱形是判断俯仰和减少前后混淆的重要线索之一，并非唯一线索（§ 1.1）                                                                                          |
| 鸡尾酒会效应                                   | 人类在多人嘈杂环境中选择性聆听的能力；对应机器的波束形成 + 语音分离（§ 1.1、§ 8.1）                                                                                                        |
| GCC-PHAT                                 | 广义互相关 + 相位加权：把两路信号错位到最像，峰值位置即时间差（§ 4.2）                                                                                                                 |
| SRP-PHAT                                 | 遍历候选位置并汇总各麦对 PHAT 相关值的定位方法，是常用的稳健基线之一（§ 4.3）                                                                                                            |
| Capon / MUSIC / ESPRIT                   | Capon 逐方向计算最小方差谱；MUSIC 利用导向矢量与噪声子空间的正交性形成伪谱；ESPRIT 利用阵列的平移不变结构直接估计参数。三者的协方差、源数和几何条件不同（§ 4.5、§ 4.6）                                                      |
| GDOP（几何精度因子）                             | 同样的时延误差经过不同几何布局会产生不同的位置误差。阵列孔径较小、麦对基线方向单一或目标位于不利方位时，几何误差放大通常更明显（§ 4.4）                                                                                  |
| VAD（语音活动检测）                              | 判断“当前帧有没有人在说话”，给定位/更新做门控                                                                                                                                |

| 术语                                              | 解释                                                                                                                    |
|-------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------|
| 时频掩码 (Time-Frequency Mask, TF-mask)             | 定义在时频网格上的权重或选择函数，用于加权目标、干扰或噪声统计量。二值掩码和理想比值掩码常限制在 $[0, 1]$ ，但复值掩码、幅度比掩码及某些网络输出可以超出该区间；使用时必须写明类型、取值域和作用对象（§ 5.4、§ 5.9）  |
| 新息 (innovation)                                 | 卡尔曼滤波里“观测 - 预测”的差，用它修正状态估计（§ 9.2）                                                                                     |
| EKF（扩展卡尔曼滤波） / UKF（无迹卡尔曼滤波）                     | 两种非线性卡尔曼滤波。EKF 用雅可比做局部线性化；UKF 让一组 sigma 点通过非线性函数。UKF 可减小某些非线性变换的近似误差，但不保证总比 EKF 稳或准，仍取决于模型、调参和数值实现（§ 9.2）             |
| JPDA / MHT                                      | 多目标追踪中解决“观测属于谁”的两类经典方法：联合概率数据关联 / 多假设跟踪（§ 9.3）                                                                        |
| 锥面模糊                                            | 线阵只观测方向在阵列轴上的投影，同一时延可对应绕阵列轴的一圈方向；平面阵的两侧则是法向镜像歧义，二者不要混为一种（§ 3.1）                                                       |
| FIR 滤波器                                         | 有限长冲激响应滤波器：输出 = 输入最近若干样本的加权和，抽头数（抽头见本表“信号与数学基础”组）就是加权长度（§ 5.1、§ 6.1）                                                  |
| 重采样（粒子滤波）                                       | 把权重小的粒子删掉、权重大的复制，防粒子退化（§ 9.2 算例 9-2 下集）                                                                               |
| 概率假设密度 (Probability Hypothesis Density, PHD) 滤波 | 传播随机有限集 (Random Finite Set, RFS) 的一阶矩（强度函数）。某一区域上 $D(\vec{x})$ 的积分给出该区域内目标数的期望值；实际目标状态常从强度峰或高斯分量提取，峰的个数本身不等于人数（§ 9.3） |
| OSPA（最优子模式分配距离）                                 | 多目标追踪误差度量，同时罚定位误差和人数错误（§ 10.5 评测指标表）                                                                                  |

## 系统与硬件

| 术语  | 解释                                                                    |
|-----|-----------------------------------------------------------------------|
| AEC | 声学回声消除 (Acoustic Echo Cancellation, AEC)：用已知的播放信号做参考，估计回声副本再相减（§ 6.1） |

| 术语                                           | 解释                                                                                         |
|----------------------------------------------|--------------------------------------------------------------------------------------------|
| DTD（双讲检测）                                    | 检测近端语音与远端播放同时活动的状态，用于冻结、减小步长或切换到稳健的 AEC 更新策略（§ 6.1）                                        |
| 回声返回损失增强（Echo Return Loss Enhancement, ERLE） | 衡量远端单讲时回声功率被降低多少；目标值取决于设备、声学路径、非线性和测量窗口，不能用一个通用区间代替验收条件（§ 6.1）                             |
| WPE                                          | 加权预测误差去混响：用过去帧预测晚期混响拖尾再减掉（§ 7.1）                                                           |
| SI-SDR / STOI / PESQ / WER                   | 分离增强失真比 / 可懂度 / 主观质量预测 / 识别错误率（§ 10.5 评测指标表）                                               |
| SDR / SIR / SAR                              | BSS_eval 三件套：总失真 / 干扰残留 / 算法伪影的分解指标（语音分离论文常用）                                              |
| MEMS 麦克风                                     | 使用微机电工艺制造的微型麦克风，是小型阵列中的常见器件（§ 10.2）                                                        |
| PDM / I2S / TDM                              | 常见数字音频接口。单线承载的通道数、时隙和位宽由具体控制器及协议配置决定；阵列通道应共享或校准采样时钟（§ 10.2）                                |
| dBa                                          | A 计权声级：按规定的 A 计权频率响应处理后得到的声级。它不是未加权 dB，比较数据时要核对参考量和计权方式（§ 10.2）                            |
| AOP（声学过载点）                                   | 在数据手册规定的失真阈值和测试条件下，麦克风可承受的最大声压级；比较器件时必须同时核对阈值、频率和供电条件（§ 10.2）                              |
| 孔径（aperture）                                 | 阵列的最大跨度 $D$ ；分辨率 $\approx$ 波长/孔径                                                           |
| 阵列流形（manifold）                               | 全体候选方向或位置的导向矢量集合，即阵列的方向响应模型；几何定义见 § 2.3，实测标定见 § 3.4 与 § 10.2                               |
| AFE（音频前端）                                    | Audio Front End：位于采集与识别、通信或交互后端之间的音频处理部分，可包含 AEC、去混响、波束、降噪和电平控制；实际模块由任务决定（§ 10.1）          |
| 双讲（double-talk）                              | 远端播放与近端用户同时发声。近端语音出现在麦克风或误差信号中，不应出现在理想的远端参考信号中；它会使 AEC 的误差不再只含路径失配，因此需用 DTD 控制自适应更新（§ 6.1） |

| 术语         | 解释                                                                                                                                |
|------------|-----------------------------------------------------------------------------------------------------------------------------------|
| MOS（平均意见分） | 按规定听测流程收集受试者评分并取统计量。量表、问题、材料和受试者筛选由具体标准规定；客观模型只能在其验证范围内近似预测主观质量（§ 10.5）                                                           |
| CHiME      | 面向复杂声学场景的公开挑战系列，不同届次覆盖远场识别、会议转写、分离或增强等不同任务；数据生成方式和指标应按当届说明读取（附录 B 13.2）                                                           |
| KWS（关键词唤醒） | Keyword Spotting：检测预设关键词的模型。可作为低功耗常驻任务，也可与 VAD、AEC 或增强共享前端；取点和运行方式由功耗及训练数据决定（§ 10.3、§ 10.9）                                       |
| BOM（物料成本）  | Bill of Materials：设备所用元器件的采购成本总和。增加麦克风还可能增加接口、结构、标定和计算成本（§ 11.1）                                                                  |
| HATS（人工头）  | Head and Torso Simulator：带耳廓与躯干声学模型的测量假人，麦克风置于鼓膜位置，用于模拟“人听到的效果”的客观测量（§ 10.5）                                                      |
| NLP（非线性处理） | Non-Linear Processing：AEC 里接在线性滤波器之后的残余回声抑制（谱减式/神经式），对付扬声器非线性失真等线性滤波器消不掉的部分（§ 6.1）；注意与自然语言处理（Natural Language Processing）同缩写，语境区分 |
| PBFDaf     | 分区块频域自适应滤波：把长回声路径分块并用 FFT 计算卷积与更新。第 6 章式(6-3)与同配置的频域多抽头 NLMS 更新逐分量相同；相对逐样本时域实现能节省多少计算取决于滤波长度、分块、FFT 库和硬件（§ 6.2）                   |
| IPNLMS     | 改进比例 NLMS：按抽头幅度分配各系数的更新量。常见定义中，混合系数 $\alpha = -1$ 退化为 NLMS， $\alpha = 1$ 接近纯比例更新， $\alpha = 0$ 是两部分的折中；具体取值要与所用公式和数据一同验证（§ 6.2）   |
| CNG（舒适噪声）  | Comfort Noise Generation：残余抑制压得太狠时补回的轻微背景噪声，避免通话“死寂”听感（§ 6.8）                                                                     |
| pAEC       | 个性化 AEC：把目标说话人的声纹嵌入作为条件，在双讲中增强目标说话人；定义和隐私要求见 § 6.5、§ 6.13                                                                         |



| 术语            | 解释                                                                            |
|---------------|-------------------------------------------------------------------------------|
| barge-in (打断) | 设备播放 TTS 或音乐时用户直接说话的交互状态。系统需在自发声期间保留近端语音或唤醒词，并让 VAD/KWS 使用合适的 AEC 后取点 (§ 6.5) |
| TCLw          | 加权终端耦合损耗：免提终端回声衰减的测试指标。阈值、信号和收敛窗口必须按产品适用的标准版本及测试条款核对，不能跨标准套用一个固定数值 (§ 6.7)    |

3 分钟手算 (12.2)：幅度减半是多少 dB？功率减半又是多少 dB？这是两个不同的物理变化；§ 12.3 还会说明同一物理变化怎样用幅度比或功率比等价表示。

答案：幅度减半为  $20 \log_{10} 0.5 \approx -6 \text{ dB}$ ；功率减半为  $10 \log_{10} 0.5 \approx -3 \text{ dB}$ 。前者对应功率变为四分之一，后者对应幅度变为  $1/\sqrt{2}$ 。

## 12.3 预备知识速览

本节为零基础读者准备，只讲“够用”的程度。

### 12.3.1 复数与相位：时延的符号

本书用  $e^{+j2\pi ft}$  表示正频率复正弦，并采用前向傅里叶变换  $X(f) = \int x(t)e^{-j2\pi ft} dt$ 。复数可写成  $z = Ae^{j\phi}$ ，且  $e^{j\phi} = \cos \phi + j \sin \phi$ 。

在此约定下，延迟  $\tau$  对应乘子  $e^{-j2\pi f\tau}$ 。对麦 1 参考的远场导向矢量， $\tau_{m1} = -(\vec{r}_m - \vec{r}_1)^\top \vec{u}/c$ ，所以

$$a_m = e^{-j2\pi f\tau_{m1}} = e^{+j2\pi f(\vec{r}_m - \vec{r}_1)^\top \vec{u}/c}。$$

若采用相反傅里叶约定，相关公式的相位符号也要整体改变，不能只改其中一式 (§ 2.3、§ 4.2)。

### 12.3.2 分贝：幅度比与功率比

能量比用  $10 \log_{10}(\cdot)$ ，幅度比用  $20 \log_{10}(\cdot)$ 。系数相差一倍，是因为相同阻抗下功率与幅度平方成正比。

因此，同一物理变化用两种比值表示时，dB 数相同：幅度变为 0.5 时功率变为 0.25， $20 \log_{10} 0.5 = 10 \log_{10} 0.25 \approx -6 \text{ dB}$ 。

| dB     | 幅度比                         | 功率比                 |
|--------|-----------------------------|---------------------|
| +6 dB  | $\times 2$                  | $\times 4$          |
| +3 dB  | $\times 1.41 (\sqrt{2})$    | $\times 2$          |
| 0 dB   | $\times 1$                  | $\times 1$          |
| -3 dB  | $\times 0.707 (1/\sqrt{2})$ | $\times 1/2$ (半功率点) |
| -6 dB  | $\times 1/2$ (幅度减半)         | $\times 1/4$        |
| -20 dB | $\times 0.1$                | $\times 0.01$       |

对数把连乘转为相加，便于表示跨越多个数量级的增益、信噪比和衰减。

dB 练习：① 功率先乘 4 再乘 2，总增益是多少 dB？② 电压增益为 -6 dB 时，幅度比约为多少？

答案：①  $10 \log_{10}(4 \times 2) \approx 9 \text{ dB}$ ；② 幅度约减半，功率约为原来的四分之一。

SNR 换算例。目标功率为 3、噪声功率为 1 时，线性 SNR 为 3，对应  $10 \log_{10} 3 \approx 4.8 \text{ dB}$ 。若处理后输出 SNR 为 12 dB，则 SNR 增益约为  $12 - 4.8 = 7.2 \text{ dB}$ 。输入 SNR、输出 SNR 和 SNR 增益是三个不同的量（§ 5.1）。

### 12.3.3 卷积与相关

卷积  $y = x * h$  表示信号  $x$  经过线性时不变系统  $h$  后的输出；在固定声源和接收位置的近似下， $h$  可以取房间脉冲响应（§ 2.4）。

对离散时间序列， $y[n] = \sum_k h[k]x[n-k]$ 。先选定输出时刻  $n$ ，再把各个过去输入  $x[n-k]$  乘上对应路径系数  $h[k]$  并相加；附录练习 E12-01 用两个抽头逐项计算。

相关  $R(\tau)$  衡量两段信号在相对位移  $\tau$  下的相似度；峰值位置可作为时延候选（§ 4.2）。

对于实值录音，本书的时延次序是  $R_{12}[\tau] = \sum_n x_1[n]x_2[n-\tau]$ 。第一路比第二路晚到时，峰在正  $\tau$ ；交换两个通道，峰位的符号随之交换。频域相关式须对第二路的复谱取共轭，不能只凭“相关”一词猜测符号。

傅里叶变换把线性卷积转成频域乘法，配合快速傅里叶变换可降低长卷积的计算量，但分帧、补零和重叠相加仍要按实现条件处理。

### 12.3.4 期望、方差与协方差矩阵

期望  $E[\cdot]$  表示统计平均；方差描述变量偏离均值的平方平均；协方差描述两个中心化变量共同变化的程度。把  $M$  个麦克风两两协方差排成矩阵，就是空间协方差矩阵。

§ 2.5 的常用估计式未显式减均值，因此在零均值假设下才与协方差相同；否则应称未中心化二阶矩。

### 12.3.5 最小二乘

方程比未知数多时通常没有精确解。最小二乘求使总残差平方最小的  $\hat{\vec{x}}$ ：

$$\min_{\vec{x}} \|\mathbf{A}\vec{x} - \vec{b}\|^2.$$

把残差平方展开为  $(\mathbf{A}\vec{x} - \vec{b})^H(\mathbf{A}\vec{x} - \vec{b})$ ，对  $\vec{x}^*$  求驻点得到正规方程  $\mathbf{A}^H\mathbf{A}\hat{\vec{x}} = \mathbf{A}^H\vec{b}$ 。当  $\mathbf{A}$  满列秩时， $\hat{\vec{x}} = (\mathbf{A}^H\mathbf{A})^{-1}\mathbf{A}^H\vec{b}$ 。

这是闭式表达式，不是要求程序显式求逆；即使满列秩，形成  $\mathbf{A}^H\mathbf{A}$  也会把二范数条件数平方，因而 QR/SVD 通常更适合作为数值求解入口。

秩不足时最小二乘解可能不唯一，Moore – Penrose 伪逆给出其中范数最小的一解。

`numpy.linalg.lstsq` 同时返回秩与奇异值，便于检查可辨识性；不能只看到残差很小就认定参数唯一。NumPy 最小二乘接口说明。12.4 的 E12-03 给出两列完全相关的例子。

TDOA 几何解算（§ 4.4）和 WPE 系数估计（§ 7.2）都会用到这一思想。

### 12.3.6 带约束的最小化：MVDR 拉格朗日推导

第 1 步：写拉格朗日函数。复约束必须同时包含约束及其共轭，常写成实值函数

$$L = \vec{w}^H \mathbf{R} \vec{w} + 2 \operatorname{Re}\{\lambda^* (\vec{w}^H \vec{a} - 1)\}.$$

第 2 步：求驻点。对  $\vec{w}^*$  做 Wirtinger 求导并令零，得到  $\mathbf{R} \vec{w} + \lambda^* \vec{a} = 0$ 。

第 3 步：写出比例关系。乘子的命名可吸收共轭与负号，因此得到  $\vec{w} \propto \mathbf{R}^{-1} \vec{a}$ 。

第 4 步：代回约束。写  $\vec{w} = \kappa \mathbf{R}^{-1} \vec{a}$ ，则  $\vec{w}^H \vec{a} = \kappa^* \vec{a}^H \mathbf{R}^{-1} \vec{a} = 1$ 。若  $\mathbf{R}$  厄米正定，分母  $q = \vec{a}^H \mathbf{R}^{-1} \vec{a}$  是正实数，所以  $\kappa = 1/q$ ，得到  $\vec{w} = \mathbf{R}^{-1} \vec{a} / (\vec{a}^H \mathbf{R}^{-1} \vec{a})$ ，即 § 5.4 式(5-3)。

若协方差奇异，不能直接使用这一逆矩阵形式；需另行处理秩或加载。LCMV 把标量约束和乘子换成向量形式（§ 5.5）。

Wirtinger 求导。对实值目标函数，可在 Wirtinger 微积分中把  $\vec{w}$  和  $\vec{w}^*$  视为形式上独立的变量，对  $\vec{w}^*$  求偏导并令其为零。§ 5.4 给出了与实部、虚部分别求导等价的完整推导。

### 12.3.7 特征值分解

对 Hermitian 协方差矩阵可写  $\mathbf{R} = \mathbf{E}\mathbf{A}\mathbf{E}^H$ 。特征向量是传感器观测空间中的正交主轴，特征值表示沿这些主轴的能量；它们通常不等于真实空间中的 DOA。

MUSIC (§ 4.6) 在独立源、白噪声和模型正确等条件下，把较大的特征值所张成的空间解释为信号子空间，把噪声底对应的空间解释为噪声子空间。

3 分钟手算 (12.3)：协方差  $\begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}$  的特征值和特征向量各是什么？若两个共轭对称的非对角元都变成 0.5，哪个特征值变大？

答案：特征值为 4 和 1，对应特征向量可取  $[1, 0]^T$  和  $[0, 1]^T$ 。非对角元都变为 0.5 后，两个特征值为  $(5 \pm \sqrt{10})/2$ ，约 4.08 和 0.92；通道相关性使特征值间隔增大。

### 12.3.8 病态矩阵与对角加载

当最大、最小奇异值相差很大时，矩阵条件数高，求逆会放大数据和舍入误差。低频小间距的超指向设计 (§ 5.3) 是常见例子。

- 绝对加载写作  $\mathbf{R} + \delta \mathbf{I}$ ， $\delta$  与协方差元素同量纲；
- 相对加载写作  $\mathbf{R} + \eta \text{tr}(\mathbf{R})\mathbf{I}/M$ ， $\eta$  无量纲，整体缩放  $\mathbf{R}$  时加载也同比缩放。

两者都可抬高小特征值，但会改变最优权重和指向性。报告参数时必须说明采用哪一种口径，不能只写一个无单位的 “ $\varepsilon$ ”。

附录 B 第 8 题可比较加载前后的 WNG、DI 与条件数；数值由脚本参数决定，不预设固定区间。

## 12.4 计算练习

四题都可通过 `.venv/bin/python -m codes.examples.exercises_engineering` 复算。代码中的数组是本书构造的输入，答案先由短序列求和或代数得到，再与实现比较。

E12-01：FFT 乘法为什么需要补零。取  $x = [1, 2]$ 、 $h = [1, 0.5]$ ，下标都从 0 开始。求完整线性卷积，再比较 FFT 长度为 2 和 3 时的结果。

线性卷积逐点为  $y_0 = 1 \times 1 = 1$ 、 $y_1 = 1 \times 0.5 + 2 \times 1 = 2.5$ 、 $y_2 = 2 \times 0.5 = 1$ ，共  $2 + 2 - 1 = 3$  点。

FFT 长度为 2 时，频域相乘给出的是 2 点循环卷积，第三点绕回第零点，结果为  $[1 + 1, 2.5] = [2, 2.5]$ 。补零到 3 点或更长，才可容纳这次完整线性卷积；FFT 长度不必是 2 的幂，但不同长度的执行效率可能不同。

这道题只检查一次有限卷积。连续音频还需要正确保留重叠与历史，不能对每个短块独立补零、丢掉尾部，再假定拼接结果等于整段卷积。

E12-02：未中心化二阶矩为什么不总等于协方差。一个频点上有两路麦克风、两个快拍，列向量为  $\vec{x}_1 = [1, j]^\top$ 、 $\vec{x}_2 = [1, -j]^\top$ 。分别计算以快拍数 2 为分母的二阶矩，以及先减样本均值的协方差。本题不使用无偏估计的  $T - 1$  分母。

两个外积为

$$\vec{x}_1 \vec{x}_1^H = \begin{bmatrix} 1 & -j \\ j & 1 \end{bmatrix}, \quad \vec{x}_2 \vec{x}_2^H = \begin{bmatrix} 1 & j \\ -j & 1 \end{bmatrix}.$$

相加除以 2 得  $\mathbf{I}$ 。均值是  $\bar{\vec{x}} = [1, 0]^\top$ ；减均值后的两列为  $[0, j]^\top$  和  $[0, -j]^\top$ ，所以中心化结果为  $\text{diag}(0, 1)$ 。

第一路始终为 1，有二阶矩能量，却没有相对样本均值的波动。这个例子说明减均值会改变秩，不能把两种估计混着解释。复外积还必须使用共轭转置： $j j^* = 1$ ，若误写成  $j^2 = -1$ ，会把非负功率算成负数。

E12-03：零残差是否意味着参数唯一。给定

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix}, \quad \vec{b} = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

求所有满足  $\mathbf{A}\vec{x} = \vec{b}$  的解，并找出范数最小者。 `numpy.linalg.lstsq` 应报告多大的秩？

第二行是第一行的两倍，只有  $x_1 + x_2 = 2$  这一条独立约束，所以所有解可写成  $[t, 2 - t]^\top$ 。范数平方为  $t^2 + (2 - t)^2 = 2(t - 1)^2 + 2$ ，在  $t = 1$  取最小值；最小范数解为  $[1, 1]^\top$ ，秩为 1。奇异值理论上为  $\sqrt{10}$  和 0，浮点运算可能把后者算成接近零的数，因此还要记录判秩容差。

残差为零只说明输入方程被满足，没有说明两个参数可分别辨认。增加重复行不会改变这一点，需要新增独立观测或明确的先验约束。

E12-04：频谱相位加权能使空间噪声白化吗？在一个固定频点，设两麦噪声零均值，协方差为  $\mathbf{R}_{nn} = \text{diag}(4, 1)$ ，两个通道的噪声功率单位相同。求一个对角白化矩阵  $\mathbf{W}$ ，算出白化后的噪声协方差；若目标导向矢量原为  $\vec{a} = [1, 1]^\top$ ，处理后应使用哪一个导向矢量？最后判断只对互功率谱作 PHAT 加权能否得到同样的结果。



第一路噪声功率是第二路的 4 倍，所以把第一路幅度乘 1/2，第二路保持原样：

$$\mathbf{W} = \begin{bmatrix} 1/2 & 0 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{W}\mathbf{R}_{nn}\mathbf{W}^H = \begin{bmatrix} (1/2)^2 \times 4 & 0 \\ 0 & 1^2 \times 1 \end{bmatrix} = \mathbf{I}, \quad \mathbf{W}\vec{a} = \begin{bmatrix} 1/2 \\ 1 \end{bmatrix}.$$

这里两个特征值由 4, 1 变为 1, 1，但目标导向矢量也改变了。若用白化后的数据与原导向矢量  $[1, 1]^T$  匹配，空间模型就不一致。这个矩阵例子由本书构造，并非实测噪声。

PHAT 的运算对象却是一个频点的一对通道的互功率谱：当  $G_{12}(f) \neq 0$  时， $G_{12}(f)/|G_{12}(f)|$  是一个模为 1 的复数，不会把两路快拍分别乘上 1/2 和 1。例如两路确定的复频谱值为  $X_1 = 2$ 、 $X_2 = 1$  时，互谱为 2，PHAT 后为 1，但这不是把噪声协方差变成单位阵。

本题两路噪声互不相关，理论噪声互功率谱为 0；此时 PHAT 还须跳过或保护分母，更不能从零互谱推得  $\mathbf{W}$ 。这反驳了“PHAT 等于空间白化”的说法，但不否定 PHAT 在时延估计中抑制源谱幅度影响的用途。复算入口为 [exercises\\_engineering.py](#) 的 E12-04。

## 附录 B · 路径地图与练习

---

### 13.1 研究生学习路径

---

下面的阅读与实验顺序从经典模型开始，再过渡到公开基线、数据集和硬件实验。

1. 基础阅读：Van Veen & Buckley, *Beamforming: A Versatile Approach to Spatial Filtering* (IEEE ASSP Mag. 1988) ; Krim & Viberg, *Two Decades of Array Signal Processing* (IEEE SPM 1996) 。
2. 语音场景：Kumatani、McDonough 与 Raj, *Microphone Array Processing for Distant Speech Recognition: From Close-Talking Microphones to Far-Field Sensors* (IEEE Signal Processing Magazine 29(6):127 – 140, 2012) ; Gannot et al., *A Consolidated Perspective on Multimicrophone Speech Enhancement and Source Separation* (IEEE/ACM TASLP 2017) 。Kumatani 等另有题名前半段相同的 *Towards Real-World Deployment*, 查找时不能省略副标题。
3. 原始论文：Capon (1969) 、Griffiths & Jim GSC (1982, *An Alternative Approach to Linearly Constrained Adaptive Beamforming*, IEEE Trans. Antennas Propag. 30(1):27 – 34) 、Schmidt MUSIC (1986) 、Roy & Kailath ESPRIT (1989) 、Allen & Berkley 镜像法 (1979) 、Nakatani et al. WPE (IEEE TASLP 2010) 、Pal & Vaidyanathan 嵌套阵 (IEEE TSP 2010) 。
4. 回声消除：Hänsler & Schmidt, *Acoustic Echo and Noise Control* (Wiley 2004) ; 近年进展看 ICASSP AEC Challenge 系列报告。
5. DNN 方向：Chakrabarty 与 Habets, *Multi-Speaker DOA Estimation Using Deep Convolutional Networks Trained With Noise Signals* (IEEE JSTSP 13(1):8 – 21, 2019) ; Gu et al. 全神经波束形成 (IEEE/ACM TASLP, vol.31, pp.849 – 862, DOI 10.1109/TASLP.2022.3229261) 。
6. 实验顺序：每一步增加一种新的验证条件，前一步的可复算结果应留作后一步的对照。
  1. 运行 `codes/` 中只依赖 NumPy 的教学实现，核对手算结果、数组维度和退化边界。
  2. 在隔离环境中用 pyroomacoustics 验证 DSB、MVDR、MUSIC 和 SRP-PHAT 基线，记录房间、阵列和随机种子。
  3. 运行 `scripts/` 中的两个绘图脚本，按当前参数复现 39 张编号图，并逐图核对正文条件。
  4. 按研究任务选择公开数据和固定版本参考系统，分别核对代码、模型与数据的许可和评测口径。
  5. 在可用的多通道硬件上测实时性、同步和标定；仿真结果不能代替设备测量。

## 13.2 领域地图：教材、会议、期刊与挑战赛

本节按教材、会议、期刊、挑战赛和历史脉络组织，可按需要查阅。

教材与专著（由浅到深）：

| 书                                                                                                                                                                  | 特点                        |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------|
| Benesty, Chen & Huang, <i>Microphone Array Signal Processing</i> (Springer 2008)                                                                                   | 覆盖阵列模型、定位、波束形成与多通道增强      |
| Brandstein & Ward (eds.), <i>Microphone Arrays: Signal Processing Techniques and Applications</i> (Springer 2001)                                                  | 经典论文式合集，各章由领域奠基人撰写        |
| Tashev, <i>Sound Capture and Processing: Practical Approaches</i> (Wiley 2009)                                                                                     | 从工程视角讨论捕获链路、器件和实现权衡       |
| Johnson & Dudgeon, <i>Array Signal Processing: Concepts and Techniques</i> (Prentice Hall 1993)                                                                    | 通用阵列信号处理经典（雷达/声呐同源理论）     |
| Van Trees, <i>Optimum Array Processing</i> (Wiley 2002)                                                                                                            | 系统推导最优阵列处理，适合查阅数学细节       |
| Vincent, Virtanen & Gannot (eds.), <i>Audio Source Separation and Speech Enhancement</i> (Wiley 2018)                                                              | 分离与增强方向的现代合集              |
| Rafaely, <i>Fundamentals of Spherical Array Processing</i> (Springer, 一版2015, DOI 10.1007/978-3-662-45664-4; 二版 online 2018、版权2019, DOI 10.1007/978-3-319-99561-8) | 系统介绍球阵与球谐域处理，可配合 § 5.8 阅读 |

会议：ICASSP（信号处理旗舰会）、Interspeech（语音领域旗舰会）、WASPAA（音频与声学信号处理研讨会，两年一届）、IWAENC（声学信号增强研讨会）、HSCMA（免提语音通信与麦克风阵列研讨会）、DCASE Workshop（声事件与场景）。

期刊：IEEE/ACM Transactions on Audio, Speech, and Language Processing (TASLP，本领域主刊)、IEEE JSTSP（信号处理选题特刊）、JASA（美国声学学会刊）、Speech Communication。

挑战赛用于了解公开任务和评测口径。

CHiME 覆盖远场、多说话人和多通道语音处理；CHiME-9 设置 MCoRec 多会话鸡尾酒会转写与会话聚类、ECHI 低延迟助听对话增强。[CHiME 官方](#)于 2026 年 7 月公布 CHiME-10 的 ECHI-2、URGENT、SG-TSE 三项任务；挑战计划于 2027 年 2 月 4 日开放，提交期暂定为 2027 年 8~9 月。日程可能调整，参赛时应以官方页面为准。

DCASE 2026 已于 2026 年 6 月 15 日结束，并在 7 月 1 日公布结果；Task 3 是 Semantic Acoustic Imaging SELD，与 DCASE 2024 Task 3 的距离估计设置不同。以上状态核实于 2026 年 9 月，任务定义与结果见 [DCASE 2026 官方页面](#)和[结果公告](#)。

其他公开评测包括 REVERB 去混响评测、ICASSP DNS/AEC Challenge，以及已结束的 [SPEAR Challenge 2023](#)。SPEAR 使用头戴式 6 通道设备研究 AR 语音增强；它的年份、阵列和任务条件不应外推为当前持续榜单。

历史脉络（本领域是雷达/声呐技术向语音的迁移史）：

| 年代          | 里程碑                                                           |
|-------------|---------------------------------------------------------------|
| 1940s – 60s | 雷达/声呐阵列处理奠基（Bartlett 波束扫描）                                    |
| 1969        | Capon 最小方差谱估计（为地震学阵列而做）                                       |
| 1972        | Frost 时域约束自适应波束形成                                             |
| 1979 – 82   | Allen & Berkley 镜像法房间仿真；Griffiths & Jim 提出 GSC                |
| 1985        | Flanagan 等报告了可计算转向的大孔径会议室麦克风阵列                                |
| 1986 – 89   | MUSIC（1986）与 ESPRIT（1989）用子空间结构估计到达方向；分辨能力仍受孔径、信噪比、快拍数和模型失配限制 |
| 1990s       | Elko 差分麦克风阵列进入助听器与桌面会议设备                                      |
| 2001 – 08   | Brandstein & Ward、Benesty 等教材出版，语音阵列知识体系化                     |
| 2010        | Nakatani 提出 WPE 去混响；Pal & Vaidyanathan 提出嵌套阵                  |
| 2011        | 首届 CHiME 挑战赛，远场语音成为公开评测对象                                     |
| 2014        | Amazon Echo 把多麦克风远场语音带入一类消费设备；具体阵列规格随硬件代次而变                   |

| 年代        | 里程碑                                                                                                                                 |
|-----------|-------------------------------------------------------------------------------------------------------------------------------------|
| 2015 – 18 | CHiME-3/4/5 的公开任务推动了掩码辅助波束与 GSS 等方法的可复现比较                                                                                           |
| 2019 – 24 | DNN 定位/追踪（ACCDOA：声源活动与方向联合输出，Shimada et al., ICASSP 2021）、端到端一体化；CHiME-7/8 大模型后端；STARSS23（DCASE 2024 Task 3 使用的开发与评测数据集）支持声源距离估计子任务 |
| 2025 – 26 | CHiME-9 设置 MCoRec 与 ECHI；2026 年 7 月公布 CHiME-10 三项任务；DCASE 2026 Task 3 转为 Semantic Acoustic Imaging SELD，并于 2026 年 7 月公布挑战结果         |

DCASE 2024 Task 3 的官方任务页明确将开发集和评测集称为 STARSS23，数据集名中的年份不应随挑战年份改写。[DCASE 2024 Task 3 官方说明](#)

### 13.3 研究前沿速览（2024—）

本节把正文中的经典方法与 2024 年以来若干公开研究方向相连。具体成绩只在原论文的数据、实现和评测条件下成立；带日程的内容以对应挑战赛官方页面为准。

#### 研究方向一：预训练模型用作远场识别后端

CHiME-7/8（2023/2024）部分参赛系统使用 Whisper、WavLM 等预训练模型作为识别后端，也有系统保留 GSS（导引源分离，详见 § 8.4）和解析波束。这些参赛系统只能说明相应架构在该届数据和评测中被实现，不能据此断言整个领域已转向某一种架构。[CHiME-7/8 综述预印本](#)，[arXiv:2507.18161](#)

#### 研究方向二：阵列无关系统

CHiME-8 的 DASR 系统报告描述了不固定阵列拓扑的设计。其泛化范围只能以报告中的训练阵列、测试设备、任务和打分脚本为边界。[CHiME-8 DASR](#)

#### 研究方向三：目标说话人提取

目标说话人提取（Target Speaker Extraction，TSE）用注册语音、视觉或方向提示描述目标，再从混合语音中提取相应音轨。AR 眼镜阵列和手机结构辅助方向提取提供了不同的条件输入形式。



TEA-PSE (ICASSP 2022, DOI 10.1109/ICASSP43922.2022.9747765; 后续版本 arXiv:2303.07704) 和 [CIENet](#) 使用注册语音提供说话人条件, 再通过条件注入或帧级对齐提取目标。

SonicSieve 采用另一种线索: 被动声学微结构改变方向相关响应, 让神经网络利用方向特征提取语音, 不是由注册声纹指定身份。它依赖对应的声学结构与训练数据, 不能当作任意手机加软件即可获得的效果。原论文为 CHI 2026; 本书仅说明方法条件, 不转引摘要中的性能数字。[作者机构项目页](#)、[作者论文 v3, 2026-02-11](#), [摘要与方法部分](#) (核实: 2026-09-22)。

§ 6.5 的个性化 AEC 与这类条件提取方法相关, 但训练目标和回声参考结构仍需分别定义。

#### 研究方向四: 生成式语音增强与推理加速

SGMSE+ (Richter et al., IEEE/ACM TASLP 2023) 在复数 STFT 域使用基于随机微分方程的扩散模型; StoRM (Lemercier et al., IEEE/ACM TASLP 2023) 把判别式回归与生成过程结合, 以减少采样负担。[SGMSE+ 代码与论文](#)、[StoRM 代码与论文](#)。

这类方法可能改善特定数据上的感知质量, 也可能生成参考中不存在的语音细节, 因此要同时评估听感、内容一致性和下游 WER。流匹配、蒸馏和一致性模型试图减少采样步数。

FlowSep (ICASSP 2025) 把整流流用于 VAE 隐空间中的文本查询通用音频分离, 其结论不能直接外推到多通道语音增强。[FlowSep, DOI 10.1109/ICASSP49660.2025.10890129](#)

多通道生成模型还需显式处理跨通道相位、空间协方差和实时性, 目前与 § 5.9 的掩码加解析波束属于不同成熟度的技术路线。

#### 研究方向五: TF-GridNet 与复数谱映射骨干

TF-GridNet 的单通道会议版 (Wang et al., ICASSP 2023) 研究单通道说话人分离; 期刊扩展 (IEEE/ACM TASLP 2023) 进一步覆盖噪声、混响和多通道条件。具体 SI-SDRi 必须按原文的数据版本、混合方式和表号引用, 不能把两版结果混在一起。[ICASSP 2023 单通道会议版](#)、[TASLP 2023 期刊扩展](#)。

#### 研究方向六: 几何无关前端的期刊研究

Kamo et al. 在 *Computer Speech & Language* 95:101820 (2026) 中整理了几何无关的多说话人远场识别系统, 并在真实会议数据上评估。[Kamo et al., Computer Speech & Language](#) 它与 CHiME-8 的系统共同说明, 不固定阵列拓扑可以作为明确的系统设计目标; 泛化范围仍以论文的训练阵列、测试设备和数据为边界。

## 研究方向七：CHiME-9 与大模型后端

CHiME-9 设置 MCoRec 和 ECHI 两项任务；前者涉及多会话转写与会话聚类，后者研究低延迟助听对话增强。[CHiME-9 官网](#)

DiCoW (Polok et al., *Computer Speech & Language* 95:101841, 2026) 把分割信息作为条件注入 Whisper，用于目标说话人识别。这个实例说明前端的分割、增强结果可以作为大模型后端的显式条件，而不只是输出单路音频。[DiCoW, DOI 10.1016/j.csl.2025.101841](#)

## 研究方向八：扩散先验用于无监督盲分离

ArrayDPS (Xu et al., ICML 2025) 处理“没有阵列几何、房间冲激响应和配对分离标签”的多通道盲分离问题。AuxIVA 通过源独立性直接迭代解混矩阵；ArrayDPS 改为从单说话人扩散先验采样，并在每个采样步骤内估计相对房间冲激响应，用该近似混合模型计算似然梯度。

它仍假设说话人数已知、各通道同步、混合可由卷积模型近似，而且单说话人先验要覆盖测试语音域；扩散先验不能替代源数估计、同步或域外验证。

最小复现可沿用官方 SMS-WSJ 配置：两名说话人、3 通道、8 kHz，先下载作者提供的单说话人扩散模型，再运行 `separate.py`，设置 `num_speakers=2`、`n_channels=3`、`num_steps=400`，将输出与其 IVA 初始化按同一 SI-SDR 实现比较，同时记录总耗时和峰值显存。官方说明要求显存大于 7 GB；400 步扩散采样还嵌套相对 RIR 优化，因此它是离线研究候选，不应直接列入低延迟流式基线。[ArrayDPS 论文 \(PMLR 267\)](#)、[官方实现与复现命令](#)。

### 13.3.1 神经网络前端的泛化失配与四类对策

本专栏解释阵列或房间改变后性能下降的原因，并展开上面“阵列无系统”与“几何无关前端的期刊研究”涉及的四类对策。

神经网络前端可能在训练阵列和房间上表现良好，换到新的几何、声学条件或任务后却明显退化，这就是泛化失配。下面把失配分为阵列、声学、任务与数据三类，再从数据、表示、训练和部署四方面讨论缓解方法。

失配三源：

1. **阵列失配**：训练与部署的几何、通道数、麦克风一致性或采样时钟不同。若网络依赖固定通道编号及其相位关系，更换阵列后这些特征不再成立，端到端波束尤其容易受影响（§ 5.9 第 2 条）。
2. **声学失配**：混响时间、噪声类型和说话人距离改变。训练数据未覆盖相应混响尾部或噪声结构时，掩码估计误差会传递到协方差和 MVDR 权重。

3. 任务与数据失配：仿真未包含麦位误差、挡板散射或非平坦频响；训练与测试的语言不同；面向听感训练的增强模型被直接用于 ASR。最后一种情况还要检查生成式模型是否改变语音内容（见上面的“生成式语音增强与推理加速”）。

#### 四类对策：

1. 数据：混合多种阵列几何、房间、采样率和噪声进行训练，并用少量目标设备录音适配。目标是覆盖可能变化的相位和幅度关系，而不是穷举设备。
2. 表示：让网络输出掩码、协方差或说话人活动等中间量，再由 MVDR 或 GSS 等解析方法施加无失真约束（§ 5.9 第 1 条）。这种分工仍需验证中间量是否真正跨几何泛化。
3. 训练：随机丢弃通道、置换通道顺序并扰动麦克风坐标，分别模拟通道失效、可变麦数和标定误差；网络结构还要满足相应的置换不变或等变性质。
4. 部署：先做通道一致性和几何标定，再根据置信度、资源和失败模式选择模型或解析基线。模型分级只是候选架构，是否有净收益要在目标硬件上测量。

阵列无关系统的常见结构：各通道先独立提取特征，再用注意力或池化聚合成对通道顺序不敏感、可接受可变通道数的表示。中间量可选掩码、协方差或说话人活动；分离与波束部分采用 GSS 等解析方法，或使用满足几何无关要求的神经前端。后端再用预训练识别模型吸收残余失配。

CHiME-8 DASR 与上面的“几何无关前端的期刊研究”给出了两类公开实例。复现时应画出实际流程图，并逐项标明训练数据、通道聚合方式、解析约束和测试阵列范围。

TAC 与 VarArray。TAC (Transform-Average-Concatenate) 先对各通道独立变换，再跨通道平均并把聚合结果拼回各通道，从结构上支持可变通道数和通道置换。

VarArray 把 TAC、Conformer 分离和通道间相位差特征用于几何无关的连续语音分离，并在 AMI 会议转写上报告端到端 sa-WER 结果。它们为后续跨设备系统提供了结构基础。[VarArray, ICASSP 2022, DOI 10.1109/ICASSP43922.2022.9746876](#)

## 13.4 常见问题与调试指南

下面按“现象 → 优先检查项”列出八类常见问题。

1. MUSIC 没有峰 / 峰位置不稳定 → 先看样本协方差的秩与条件数。若直接用  $T$  个  $M$  维快照计算未中心二阶矩，矩阵秩不超过  $T$ ，所以  $T < M$  时必然奇异；若先估计并减去样本均值，中心化后的  $T$  个向量线性和为零，秩上限通常降为  $T - 1$ ，所以  $T \leq M$  时必然奇异。快照数超过这一最低门槛也不代表估计已经稳定。

再检查源数  $K$  和噪声底是否可分，最后检查直达声与反射是否强相干。空间平滑只适用于具有可分重叠子阵的几何，而且会缩短有效孔径；它不是所有混响场景的必选项（§ 2.5、§ 4.6）。

2. GCC-PHAT 峰位置在离散时延格点间跳变 → 没有做亚采样时延估计，或原始时延网格太粗；也可能是强反射峰超过直达峰（图13）。图12采用 16 倍互谱补零插值，不是三点抛物线拟合；其他实现也可采用相关峰插值或相位斜率拟合（§ 4.2）。

3. 波束形成后目标语音反而失真 → 先查 DOA、RTF 和通道标定是否一致，再检查噪声协方差的估计方式。

噪声协方差既可由目标缺席帧估计，也可由时频掩码加权估计；关键是尽量排除目标泄漏，同时保留足够有效快拍。混响中还要确认约束对象是否应改用 RTF（§ 5.4、§ 5.9）。

4. 超指向输出噪声很大 → 检查 WNG、协方差条件数、通道增益相位和阵列流形误差。容许的失配没有统一 dB 门槛，应从目标 WNG、最高工作频率和实测波束图反推；可用对角加载或显式 WNG 约束改善稳健性（§ 5.3、§ 5.4）。

5. AEC 残余回声较大 → 优先检查参考取点、参考与麦克风的整体延迟、扬声器削波以及滤波器覆盖时间。参考不同步是需要排查的原因之一，不是所有设备的固定首因。

若线性路径已收敛而仍有与播放相关的非线性残余，再评估非线性处理（NLP）或学习型 AEC（§ 6.1）。

6. SRP-PHAT 出现镜像假峰：先区分三种原因，不能把所有对称峰都归于麦间距。

- 几何不可辨识：线阵可能存在前后或锥面歧义，平面阵可能存在上下镜像；增加频带未必能消除相同 TDOA，见 § 3.1。
- 空间混叠：检查工作频率、间距与转向；超过半波长失去全视场无混叠保证，但并非每个方向必然出现等高栅瓣，见 § 2.6 和本附录练习 2。
- 多径反射：强反射可能形成镜像声源峰，应结合直达声可见性、搜索区域与房间条件判断。限制搜索空间需要明确的场景先验，不能仅为删除不喜欢的峰。

7. 多麦录音各通道逐渐错位 → 先区分固定的初始时差、独立丢样和 SRO。单设备可让通道共享采样时钟；分布式设备无法共享时钟时，要估计相对采样率并重采样。PDM/TDM 是接口形式，不自动保证跨设备同步（§ 10.2）。

8. 仿真很好、实测很差 → 逐项加入麦位误差、通道增益相位误差、壳体散射、频响差异、时钟偏移和扬声器非线性，寻找哪一项能复现实测退化。

位置容差应按最高频率允许的相位误差换算，不存在对所有阵列通用的毫米阈值。完成标定后，再在容差范围和多个位置上复测。

## 13.5 核心公式速查卡

下表汇总正文中的关键公式，便于复习和查阅。公式成立条件仍以对应章节为准。

| 公式                                                           | 含义                                                                                                 | 章节          |
|--------------------------------------------------------------|----------------------------------------------------------------------------------------------------|-------------|
| $10 \log_{10} M$                                             | 无失真归一化、各通道独立等功率白噪声下， $M$ 元 DSB 的 WNG (dB)                                                          | § 1、§ 5.2   |
| $r_F = 2D^2/\lambda$                                         | Fraunhofer 相位曲率检查尺度；不是远近场硬分界。使用平面波模型还要检查 $r \gg D$ 、阵元幅度差和允许的相位误差                                  | § 2.2       |
| $T_{60} = 0.161V/A$                                          | 赛宾公式：房间混响时间                                                                                        | § 2.4       |
| $d_c = 0.057\sqrt{QV/T_{60}}$                                | 临界距离：直达/混响相等处； $Q$ 为声源指向因子， $Q = 1$ 时才化为原来的全向式                                                     | § 2.4       |
| $\vec{x} = \vec{a}(\theta)s + \vec{n}$                       | 远场窄带阵列信号模型                                                                                         | § 2.3       |
| $\hat{\mathbf{R}} = \frac{1}{T} \sum_t \vec{x}\vec{x}^H$     | 空间协方差矩阵估计                                                                                          | § 2.5       |
| $d < \lambda/2$                                              | ULA 在整个闭可视角域内避免端点歧义的充分条件； $d = \lambda/2$ 时两个端火方向 $-90^\circ$ 与 $+90^\circ$ 可产生相同阵元采样，限定转向范围时可另行分析 | § 2.6       |
| HPBW、DI、WNG                                                  | 分别按主瓣两个半功率点、全空间方向响应平均、独立等功率通道噪声定义；见式(2-3)~式(2-5)                                                   | § 2.6       |
| CRB 公式                                                       | 给定统计模型与正则条件下，无偏 DOA 估计方差的下界；见式(2-6)                                                                | § 2.6       |
| $\hat{\theta} = \arcsin(c\hat{\tau}_{12}/d)$                 | 双麦时延差 $\rightarrow$ 角度；本书定义 $\tau_{12} = t_1 - t_2$ ，并以 $X_1 X_2^*$ 的 GCC 峰估计它                     | § 2.1、§ 4.2 |
| $R(\tau) = \int \Phi X_1 X_2^* e^{j2\pi f\tau} df$           | GCC 加权互相关                                                                                          | § 4.2       |
| $\hat{p} = \arg \max_{\vec{r}} \sum R^{PHAT}$                | SRP-PHAT 全阵列投票                                                                                     | § 4.3       |
| $P_C = 1/(\vec{a}^H \hat{\mathbf{R}}^{-1} \vec{a})$          | Capon 谱                                                                                            | § 4.5       |
| $P_{MU} = 1/(\vec{a}^H \mathbf{E}_n \mathbf{E}_n^H \vec{a})$ | MUSIC 伪谱                                                                                           | § 4.6       |



| 公式                                                                                          | 含义                                                                      | 章节    |
|---------------------------------------------------------------------------------------------|-------------------------------------------------------------------------|-------|
| $\vec{w}_{DSB} = \vec{a}/M$                                                                 | 延迟求和波束                                                                  | § 5.2 |
| $ B(\theta)  = \left  \frac{\sin(M\psi/2)}{M \sin(\psi/2)} \right $                         | 等权 ULA 的归一化阵因子，<br>$\psi = 2\pi d(\sin \theta - \sin \theta_0)/\lambda$ | § 5.2 |
| $\vec{w}_{SD} = \frac{\mathbf{\Gamma}^{-1}\vec{a}}{\vec{a}^H \mathbf{\Gamma}^{-1} \vec{a}}$ | 超指向：在无失真约束下最小化弥散噪声输出                                                    | § 5.3 |
| $\vec{w}_{MVDR} = \mathbf{R}_{nn}^{-1}\vec{a}/(\vec{a}^H \mathbf{R}_{nn}^{-1} \vec{a})$     | 最小方差无失真                                                                 | § 5.4 |
| LCMV 权重，见式(5-4)                                                                             | 多约束最小方差解；完整表达式和符号在表后单列                                                  | § 5.5 |
| SDW-MWF 权重，见式(5-5)                                                                          | 失真可调维纳滤波；完整表达式和符号在表后单列                                                  | § 5.5 |
| $e = d - y$                                                                                 | GSC 中固定波束输出 $d$ 减去自适应抵消输出 $y$ ；在阻塞矩阵理想、支路自由度足够且优化收敛时与相应 LCMV 等价         | § 5.6 |
| NLMS 更新式                                                                                    | AEC 自适应滤波                                                               | § 6.1 |
| $ERLE = 10 \log_{10} \frac{\sum_n  y(n) ^2}{\sum_n  e_{\text{echo}}(n) ^2}$                 | 同一远端单讲窗口内的回声返回损失增强； $y = x * h$ 为消除前回声， $e_{\text{echo}}$ 为消除后回声分量      | § 6.1 |
| WPE 预测模型，见式(7-1)                                                                            | 当前观测分成预测残响和早期成分；完整表达式在表后单列                                              | § 7.1 |
| KF 五步                                                                                       | 预测-更新-增益循环；圆周角新息先做 wrap，浮点实现可用 Joseph 协方差更新                             | § 9.2 |

表中三个较长的表达式单独列出，以便在网页和 A4 页面上读清上下标。这里沿用对应章节的定义与成立条件，没有重新给公式编号。

LCMV 权重，见式(5-4)： $\mathbf{R}$  为用于最小化输出功率的协方差矩阵； $\mathbf{C}$  的列是各约束导向向量， $\vec{f}$  给出对应响应。若所需逆矩阵不存在，须回到 § 5.5 检查约束是否独立及正则化条件。

$$\vec{w}_{LCMV} = \mathbf{R}^{-1} \mathbf{C} (\mathbf{C}^H \mathbf{R}^{-1} \mathbf{C})^{-1} \vec{f}.$$

SDW-MWF 权重，见式(5-5)： $\mathbf{R}_{ss}$ 、 $\mathbf{R}_{nn}$  分别是目标与噪声协方差矩阵， $\vec{e}_r$  选出参考麦； $\mu > 0$  调节噪声惩罚与目标失真。它不是一般条件下的 MVDR 解，具体目标函数和秩一特例见 § 5.5。

$$\vec{w}_{SDW} = (\mathbf{R}_{ss} + \mu \mathbf{R}_{nn})^{-1} \mathbf{R}_{ss} \vec{e}_r.$$

WPE 预测模型，见式(7-1)： $X(n, f)$  是当前帧第  $f$  个频点的观测； $G^*(k, f)X(n - k, f)$  用过去帧预测晚期混响， $E(n, f)$  是保留的早期成分。 $\Delta$  为预测延迟， $K$  为抽头数；多通道时系数和历史观测改为向量，见 § 7.1。

$$X(n, f) = E(n, f) + \sum_{k=\Delta}^{\Delta+K-1} G^*(k, f)X(n - k, f).$$

PHD 预测，见式(9-9)：新生目标强度加存活目标的状态转移。

$$D_{t|t-1}(\vec{x}) = \gamma_t(\vec{x}) + \int p_S(\vec{\xi}) f_{t|t-1}(\vec{x} | \vec{\xi}) D_{t-1}(\vec{\xi}) d\vec{\xi}.$$

PHD 更新，见式(9-10)：漏检项加每条观测的“目标/杂波”归一化贡献。

$$D_t = (1 - p_D)D^- + \sum_{z \in Z_t} \frac{p_D g(z | x) D^-}{\kappa(z) + \int p_D g(z | \xi) D^-(\xi) d\xi}.$$

预测式中， $D_{t-1}(\vec{\xi})$  是上一时刻在状态  $\vec{\xi}$  处的目标强度， $p_S$  是存活概率， $f_{t|t-1}$  是状态转移密度， $\gamma_t$  是新生目标强度。预测把“存活并移动的旧目标”和“新生目标”相加。

更新式中， $D^- = D_{t|t-1}$  是更新前强度， $Z_t$  是本帧观测集合， $p_D$  是检测概率， $g(z | x)$  是目标在状态  $x$  时产生观测  $z$  的似然， $\kappa(z)$  是该观测处的杂波强度。分母把杂波与所有可能目标来源放在同一观测口径下比较；这些量的连续状态积分及多观测含义见 § 9.3。

单状态格演示。假设上一时刻此格的强度为 0.6，存活概率 0.9，转移仍留在本格，新生强度 0.26。预测强度为  $D^- = 0.26 + 0.9 \times 0.6 = 0.8$ 。

若本帧只有一个观测，令  $p_D = 0.75$ 、该格观测似然  $g = 0.5$ 、同单位杂波强度  $\kappa = 0.1$ 。漏检项为  $(1 - 0.75) \times 0.8 = 0.2$ ；观测项为  $(0.75 \times 0.5 \times 0.8) / (0.1 + 0.75 \times 0.5 \times 0.8) = 0.75$ ；更新强度为 0.95。

这是把积分退化为单格求和的本书手算，不是“该观测有 95% 概率属于目标”，也不能替代多目标、多观测的关联计算。

## 13.6 思考与练习

练习按章节排列。修改脚本参数时，应同时记录随机种子、实验条件和输出指标。数值题附参考答案，综合题附思路提示。

练习涉及的绘图函数：先阅读参数与生成模型。需要改参数时，在个人实验副本中运行并保存到独立输出目录，不直接覆盖本书的出版插图。

| 函数名                           | 它画的是什么      | 用在哪道题 |
|-------------------------------|-------------|-------|
| <code>fig_geometries</code>   | 阵列形态布局      | 题4    |
| <code>fig_gcc_phat</code>     | GCC-PHAT 原理 | 题5    |
| <code>fig_doa_spectrum</code> | DOA 空间谱     | 题6    |
| <code>fig_wng_di</code>       | WNG – DI 权衡 | 题8    |
| <code>fig_wpe</code>          | WPE 去混响     | 题9    |
| <code>fig_tracking</code>     | 粒子滤波追踪      | 题13   |

动手题用的绘图函数都在 `scripts/` 里，具体对应关系见上表。第 16 题还要安装 `pyroomacoustics 0.10.0`；它是房间声学仿真的扩展依赖，命令见该题和项目 README。

章内还有带稳定编号 `E01-01` 等的计算练习，由[练习与音频实验手册](#)统一索引。附录原有题号仍用于下面的 1~17 题；不要把两个编号系统按顺序相加。工程练习 E10、选型练习 E11 和数学练习 E12 的运行入口是 `codes/examples/exercises_engineering.py`，可先手算再比对输出。

13.6.1 基础与几何：第 1~3 章的题 1~4

第 1 章（问题定义）

1. 思考题：为什么“双耳 + 自由转头”通常比静止双耳更容易消除前后混淆？
- 提示：静止时并非只有两个数；ITD、ILD 和 HRTF 的频谱线索都随频率变化。某些镜像方向仍会产生相近线索，转头后这些线索按不同轨迹变化，动态观测可打破歧义。联系 § 1.1 与 § 3.1 的几何对称性。

第 2 章（基础）

2. 手算：3 麦线阵、间距 3 cm、声源 45°、频率 2 kHz，写出导向矢量；该频率是否满足全视场无混叠条件？6 kHz 呢？
- 参考答案：2 kHz 时  $\lambda = 17.15\text{ cm}$ ， $\psi = \frac{2\pi d}{\lambda} \sin 45^\circ \approx 0.777\text{ rad}$ ， $\vec{a} = [1, e^{+j0.777}, e^{+j1.554}]^\top$ ；正角声源先到达  $+x$  侧的后续阵元，按本书的傅里叶变换约定对应正的相对相位。  
 $d < \lambda/2$ ，满足全视场安全条件。
- 6 kHz 时  $\lambda \approx 5.72\text{ cm}$ ， $d > \lambda/2$ ，不再保证所有方向无混叠。但对本题  $\theta_0 = 45^\circ$ ，候选歧义满足  $\sin \theta = \sin 45^\circ \pm \lambda/d \approx 0.707 \pm 1.91$ ，两解都落在  $[-1, 1]$  外，因此该转向本身没有可见等高栅瓣。条件被突破不等于每个转向都必然出现栅瓣。

3. 用赛宾公式估算你所在房间的  $T_{60}$  与临界距离  $d_c$ ，判断 3 m 对话处在直达占优还是混响占优区。

参考示例：取  $5\text{ m} \times 4\text{ m} \times 2.8\text{ m}$  客厅，体积  $V = 5 \times 4 \times 2.8 = 56\text{ m}^3$ ，六面总面积  $S = 2(5 \times 4 + 5 \times 2.8 + 4 \times 2.8) = 90.4\text{ m}^2$ 。若把各面简化为相同的平均吸声系数 0.2，等效吸声面积为  $A = 0.2S = 18.08\text{ m}^2$ ，所以赛宾估计  $T_{60} = 0.161 \times 56/18.08 \approx 0.499\text{ s}$ 。

若声源指向因子  $Q = 1$ ，临界距离  $d_c = 0.057\sqrt{1 \times 56/0.499} \approx 0.604\text{ m}$ 。3 m 大于此值，在该均匀吸声、近似扩散声场模型下属于混响占优区；改变  $Q$  会按  $\sqrt{Q}$  改变临界距离。真实房间的材料并不均匀，直接声可能被遮挡，不能把这道算例的  $T_{60}$  或  $d_c$  当作该客厅的实测值。

### 第 3 章（几何）

4. 打开 `fig_geometries` 按题面改：把 6+1 圆环改成 8 麦；改麦数时坐标、标题、图注要一起改。思考：中心麦能提供什么新信息？

提示：它可作为参考通道，并新增从中心到各环麦的基线；“到各环麦距离相等”描述的是几何布局，不表示任意入射方向下都与环麦等相位。固定半径时增加环上麦数会缩短相邻间距，但不会增加最大孔径。

#### 13.6.2 定位与波束：第 4、5 章的题 5~8

### 第 4 章（定位）

5. 打开 `fig_gcc_phat`，逐步增加噪声并比较 PHAT 与普通互相关。记录每个随机种子、信号谱和混响条件下的峰值误差，不预设固定 SNR 崩溃点。

提示：PHAT 去掉幅度谱着色，可能让峰变尖，也可能在低信噪比频带放大相位噪声。它的优势取决于源谱、噪声谱和反射结构。

6. 在 `fig_doa_spectrum()` 中把两源间隔从  $50^\circ$  缩到  $15^\circ$ 、 $8^\circ$ ，观察 Bartlett、Capon、MUSIC 的谱峰。

比较基准：8 元半波 ULA 的离散阵因子 HPBW 近似为  $0.886\lambda/(Md) \approx 12.7^\circ$ ；用物理跨度  $D = (M-1)d = 3.5\lambda$  得到的  $\lambda/D \approx 16.4^\circ$  只是孔径尺度。

不要预先规定谁在某个角度必然失败。实际结果取决于 SNR、快拍数、源相关性、加载和峰值判据。MUSIC 在理想独立源条件下可能分辨小于常规主瓣宽度的两源，但不保证在失配或相干源下保持这一能力。

### 第 5 章（波束形成）

7. 从拉格朗日函数推出 MVDR 闭式解，再回 § 5.4 对答案。

提示：构造实值函数  $L = \vec{w}^H \mathbf{R}_{nn} \vec{w} + 2 \operatorname{Re}\{\lambda^* (\vec{w}^H \vec{a} - 1)\}$ ，对  $\vec{w}^*$  求导，得到  $\vec{w} \propto \mathbf{R}_{nn}^{-1} \vec{a}$ ，再代入约束定比例系数。

8. 在 `fig_wng_di()` 中把麦距从 4 cm 改成 2 cm 与 8 cm，画出 WNG、DI 和协方差条件数，再比较有无对角加载。记录脚本实际输出，不预设某个频率的固定 dB 数。

解释重点：低频  $kd$  很小时，各阵元观测接近相同，弥散噪声相干矩阵容易病态；超指向解需要大幅度、相互抵消的权重，因而 WNG 下降。增大间距可能改善低频条件数，也可能在高频引入空间混叠，不能只看一端。

### 13.6.3 增强、分离与追踪：第 6~9 章的题 9~13

#### 第 7 章（去混响）

9. 打开 `fig_wpe` 按题面修改：把  $T_{60}$  从 0.6 s 改为 0.3 s 与 1.0 s，再把 `prediction_delay` 从 6 改为 1，其他参数保持 `prediction_order=10`、`iters=3`。记录每次试验的参数，比较图中拖尾与语音谱结构的变化。

提示：当前 `wpe_past_frames` 要求 `delay>=1`，因此 `delay=0` 会报错，不是可比较的算法配置。8 ms 帧移时，`delay=6` 从 48 ms 历史开始预测，`delay=1` 则从 8 ms 开始，更容易将需保留的早期成分纳入预测。

#### 第 6 章（AEC）

10. 手算（AEC，接算例 6-1）：回声路径  $\vec{h} = [0.8, 0.3, 0.1]^T$ ，参考为单位脉冲  $x(0) = 1$ 、其余时刻为 0；3 抽头 NLMS， $\hat{\vec{w}}(0) = \vec{0}$ ， $\mu = 0.5$ 。在  $\|\vec{x}\|^2 > 0$  时为便于手算取  $\epsilon = 0$ ；零能量时按 § 6.1.2 的规则跳过更新。手算  $n = 0, 1, 2, 3$  的  $d(n)$ 、 $e(n)$  与  $\hat{\vec{w}}(n+1)$ ，并解释为什么 3 步之后滤波器恰好停在  $0.5\vec{h}$ 。

参考答案： $d = [0.8, 0.3, 0.1, 0]$ ，因为单位脉冲卷上  $\vec{h}$  就是  $\vec{h}$  本身。

- $n = 0$ :  $\vec{x} = [1, 0, 0]^T$ ， $\hat{y} = 0$ ， $e = 0.8$ ， $\|\vec{x}\|^2 = 1$ ， $\hat{\vec{w}} \leftarrow [0.4, 0, 0]^T$ ；
- $n = 1$ :  $\vec{x} = [0, 1, 0]^T$ ， $\hat{y} = 0$ ， $e = 0.3$ ， $\hat{\vec{w}} \leftarrow [0.4, 0.15, 0]^T$ ；
- $n = 2$ :  $\vec{x} = [0, 0, 1]^T$ ， $e = 0.1$ ， $\hat{\vec{w}} \leftarrow [0.4, 0.15, 0.05]^T$ ；
- $n = 3$ :  $\vec{x} = \vec{0}$ ，按零能量规则跳过更新。

前三个回归向量已经依次覆盖三个正交方向，但每个方向只更新一次； $\mu = 0.5$  使每个抽头只走完一半误差，所以终点恰为  $0.5\vec{h}$ 。若要继续收敛到  $\vec{h}$ ，需要在这些方向上获得更多非零更新；持续的白噪声或语音通常同时提供重复观测和多方向激励。

11. 论述题：为什么多数时变波束系统把 AEC 放在波束形成之前？有没有例外？



思路提示：若权重随追踪变化，波束后的等效回声路径  $h_{\text{eff}}(t) = \vec{w}(t)^H \vec{h}(t)$  也随时间变化，单路 AEC 更难跟踪。若波束固定或采用联合多通道回声模型，波束后 AEC 并非数学上不可能，只是路径变化、双讲控制和多波束复用要重新设计。

## 第 8 章（语音分离）

### 12. 手算与设计题：

1. 某两输出分离器对两条参考语音的损失矩阵为  $\begin{bmatrix} 1.2 & 0.3 \\ 0.4 & 1.5 \end{bmatrix}$ ，求 PIT 选择的排列与总损失。
2. 取两个双通道时频快照  $\mathbf{X}_1 = [1, 1]^\top$ 、 $\mathbf{X}_2 = [1, -1]^\top$ ，目标掩码  $\gamma = [0.75, 0.25]$ ，计算目标协方差和互补掩码协方差。
3. 若把模型用于连续会议，还要增加哪三类处理？

参考答案：

1. 保持排列的损失为  $1.2 + 1.5 = 2.7$ ，交换排列为  $0.3 + 0.4 = 0.7$ ，故选择交换。
2. 两组权重和都为 1， $\mathbf{R}_{\text{tar}} = 0.75\mathbf{X}_1\mathbf{X}_1^H + 0.25\mathbf{X}_2\mathbf{X}_2^H = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}$ ，互补掩码得到  $\mathbf{R}_{\text{int}} = \begin{bmatrix} 1 & -0.5 \\ -0.5 & 1 \end{bmatrix}$ 。
3. 连续会议至少要定义分块与上下文、重叠块拼接、跨块排列/输出流管理；需要身份时还要增加分割或说话人关联。

互补掩码在这个二分类题中成立，不能据此把多说话人加噪声场景中的  $1 - \gamma$  一律称为纯噪声。

## 第 9 章（追踪）

### 13. 打开 `fig_tracking`，按下面的条件修改：

- 当前基线：200 个粒子、 $7^\circ$  观测噪声、“高斯目标 + 均匀杂波”混合似然（杂波权重 0.1）、第 48~57 帧连续缺测、 $0^\circ \sim 120^\circ$  有限搜索扇区的镜面反射边界，以及有效粒子数低于  $N/2$  时的系统重采样；
- 实验变量：把生成观测的标准差和 `particle_filter_doa(..., observation_std=...)` 同时从  $7^\circ$  改为  $20^\circ$ ，分别用  $N = 200, 500, 1000$  运行；
- 其余保持不变：杂波权重、缺测区间、有限扇区边界和系统重采样阈值沿用当前基线；
- 要记录：轨迹 RMSE、`n_eff` 的最小值/中位数、`resampled` 为真的帧数、`reflection_fraction` 的最大值/中位数与不低于 5% 的帧数，并单独报告缺测段 RMSE。

提示：当前图用橙色竖线标出重采样帧，用紫色叉号标出反射粒子比例不低于 5% 的帧，但没有绘制 `n_eff` 或反射比例曲线；需要曲线时应增加子图。只改一处噪声参数是观测模型失配实验。粒子数增加是否改善结果，应由这些记录判断。

### 13.6.4 工程预算与方案选型：题 14~15

## 第 10 章（工程实现）

14. 思考题：一台 6 麦音箱的项目需求规定“唤醒到应答 < 300 ms”。按 § 10.1 的延迟分类和关键路径公式拆分预算，并指出三处优先优化项。

提示：分别列出前瞻、缓冲、计算、调度和解码/交互。把 STFT 窗长从 32 ms 改为 16 ms 只会改变依赖完整窗的等待，不会自动把端到端延迟减半；WPE 流式化和后端分级也要以实测关键路径验收。

运行 `.venv/bin/python -m codes.examples.ch10_engineering_baselines`，再把调度示例中的两个 18 ms 处理帧逐步增大。记录 deadline miss、队列高水位和丢帧数。该模拟器只有一条串行工作线程，不含操作系统抢占；它验证记账方式，不是目标硬件性能测试。

## 第 11 章（选型）

15. 思考题：给“车载 4 麦分布式 + 强发动机噪声 + 免唤醒连续对话”场景写一段选型论证，分别说明几何、定位、波束和 AEC。

提示：按 § 11.1 的六个问题补齐条件；检查分布式 SRO 风险（§ 10.2）、低频噪声下超指向的 WNG、AEC 参考是否覆盖车机实际播放处理，以及连续对话期间哪些模块需要保持运行。功耗预算见 § 10.4 和 § 10.9。

### 13.6.5 房间仿真：第 16 题的输入、测量和结果

16. 确定性房间仿真：距离、DRR 与定位误差。用 `pyroomacoustics 0.10.0` 生成目标  $T_{60} = 0.6$  s 的房间冲激响应（RIR），再用本书的 SRP-PHAT 教学实现估计单声源方向。先运行 `.venv/bin/python -m codes.examples.room_srp_exercise --check`：这一步只检查配置，不需要安装 `pyroomacoustics`，也没有运行房间仿真。

输入与口径。房间为  $12 \times 10 \times 6$  m 的长方体，阵列中心在 (6, 5, 3) m，四麦位于该中心的水平面上，偏移分别为  $(\pm 0.03, \pm 0.03)$  m。声速 343 m/s，采样率 16 kHz。角度以  $+y$  为  $0^\circ$ ，朝  $+x$  为正。

声源与阵列同高：四个固定条件为距离 1 m、2.5 m 各配  $-30^\circ$ 、 $+30^\circ$ ；另有两个用 PCG64 种子 20260924 从距离 1~2.5 m、方向  $-60^\circ \sim +60^\circ$  分别均匀抽取的位置。每个条件用独立、固定种子的 1 s 白高斯噪声作激励，不叠加环境噪声；这是一间理想合成房间中的六个位置，不是六次独立房间实测。

从目标到 RIR。对三维房间体积  $V$ 、总表面积  $S$ ，脚本按 pyroomacoustics 0.10.0 的 `inverse_sabine` 口径计算均匀墙面能量吸收系数  $\alpha = 24 \ln(10) V / (c S T_{60})$ ，并核对该函数给出的建议镜像阶数。本题  $V = 720 \text{ m}^3$ ， $S = 2(12 \cdot 10 + 12 \cdot 6 + 10 \cdot 6) = 504 \text{ m}^2$ ，故  $\alpha = 24 \ln(10) \cdot 720 / (343 \cdot 504 \cdot 0.6) \approx 0.38360$ 。

按该版本源码的镜像覆盖口径，最小的两边组合尺度为  $60 / \sqrt{136} \approx 5.145 \text{ m}$ ，建议阶数  $\lceil 343 \cdot 0.6 / (60 / \sqrt{136}) - 1 \rceil = 40$ ；由于天花板函数会受舍入影响，运行时仍以未舍入数计算。镜像法关闭随机扰动、射线追踪和空气吸收；实际使用的阶数单独写进结果。

这里的  $\alpha$  和“目标 0.6 s”都只是建模输入，不能写成已实现的衰减时间。公式口径可对照 [固定版本源码清单](#) 中锁定的 pyroomacoustics `acoustics.py` 的 `inverse_sabine`。

运行与作图。在单独的虚拟环境安装 `pyroomacoustics==0.10.0` 和绘图依赖，再从仓库根目录用该环境的 Python 运行 `python -m codes.examples.room_srp_exercise --run --plot /tmp/room_srp_exercise.png`；这里的 `python` 指隔离环境的解释器，不要求改变仓库 `.venv`。`--run` 输出逐位置 JSON，图按六个位置分别画四麦 DRR 中位数、由  $T_{20}$  外推的  $T_{60}$  与 DOA 绝对误差；每个位置标明距离和角度，避免相同距离、近乎相同 DRR 的左右对称点在散点图中重叠。

定位脚本用 512 点 Hann 窗、128 点帧移、300~2000 Hz 频带，在  $-80^\circ$  到  $+80^\circ$  的  $1^\circ$  网格扫描；报告  $|\hat{\theta} - \theta|$ ，故网格量化与近场/远场模型差异均计入误差。四麦最远间距为  $0.06\sqrt{2} \approx 0.0849 \text{ m}$ ，低于 2 kHz 对应的半波长  $343 / (2 \cdot 2000) = 0.08575 \text{ m}$ ，这控制了所用频带内的空间混叠。

DRR 怎样算。每个位置、每只麦分别生成完整 RIR 与“墙面能量吸收率设为 1、仍保留相同镜像阶数”的直达声 RIR。两者的几何、采样率、RIR 长度与 pyroomacoustics 默认的 10 Hz 零相位高通边界一致；完全吸收的墙面使非零阶镜像声能为零。然后以  $h_{\text{full}} - h_{\text{direct}}$  得到反射分量，计算  $\text{DRR} = 10 \log_{10}(\sum h_{\text{direct}}^2 / \sum (h_{\text{full}} - h_{\text{direct}})^2)$ 。


只用零阶镜像生成较短的 RIR 再补零，会使两条 RIR 在不同长度下分别经历零相位滤波，差中可能混入滤波边界效应；处理位置与默认参数见 [固定版 room.py](#) 的 RIR 构建代码及默认参数。四麦 DRR 先各自计算，再取中位数；中位数并非把四麦能量先合并后计算的 DRR。

混响时间怎样算。从完整 RIR 的 Schroeder 倒向能量积分曲线，在  $-5$  到  $-25 \text{ dB}$  区间拟合 dB 对时间的直线，按斜率外推至  $-60 \text{ dB}$ ；本题将它称为“ $T_{20}$  外推的  $T_{60}$ ”，不是实测房间混响时间。逐麦值与中位数都保留，区间不够时脚本报错。

以 1 m、 $-30^\circ$  条件的第 1 只麦为例，本书仿真的直达 RIR 能量约为 0.96774，反射 RIR 能量约为 0.24448，因而该麦 DRR 为  $10\log_{10}(0.96774/0.24448) \approx 5.975$  dB；四麦 DRR 的中位数为 5.755 dB。同一只麦的  $-5 \sim -25$  dB 拟合斜率约为  $-109.682$  dB/s，故外推  $T_{60} = -60/(-109.682) \approx 0.547$  s。计算先用未舍入值，下面仅展示约数。

本书仿真结果。2026 年 9 月 24 日用 pyroomacoustics 0.10.0、Python 3.13.12、NumPy 2.5.3、SciPy 1.18.1 实际运行脚本；镜像阶数为 40，声学和定位条件均如上，PRA\_NUM\_THREADS=2。表中的  $T_{60}$ 、DRR 都是四麦逐麦指标的中位数；方位估计按  $1^\circ$  网格输出。为免把近似值当作精确值，下表距离、真方位、 $T_{60}$ 、DRR 和绝对误差均保留三位小数。

| 声源位置   | 距离 (m) | 真方位 ( $^\circ$ ) | $T_{20}$ 外推 $T_{60}$<br>(s) | DRR (dB) | SRP 方位<br>( $^\circ$ ) | 绝对误差<br>( $^\circ$ ) |
|--------|--------|------------------|-----------------------------|----------|------------------------|----------------------|
| 固定近左   | 1.000  | -30.000          | 0.546                       | 5.755    | -29                    | 1.000                |
| 固定近右   | 1.000  | +30.000          | 0.546                       | 5.755    | +29                    | 1.000                |
| 固定远左   | 2.500  | -30.000          | 0.553                       | -2.113   | -32                    | 2.000                |
| 固定远右   | 2.500  | +30.000          | 0.553                       | -2.113   | +32                    | 2.000                |
| 种子位置 1 | 1.099  | -41.244          | 0.555                       | 4.866    | -40                    | 1.244                |
| 种子位置 2 | 1.973  | +2.396           | 0.563                       | -0.003   | +3                     | 0.604                |



这张本题补充图的上、中、下栏分别用 dB、s、角度表示四麦 DRR 中位数、 $T_{20}$  外推的  $T_{60}$  中位数和 SRP-PHAT 方位绝对误差。横轴标明六个已经固定的声源位置、距离与真方位；中栏虚线是 0.6 s 建模目标。图仅表示这一间合成房间的六个源位，不代表跨房间的统计分布。

最后一行 DRR 的未舍入值为  $-0.00304$  dB，接近零。六个由仿真 RIR 估得的  $T_{60}$  在约  $0.546 \sim 0.563$  s，低于 Sabine 反推时设定的 0.6 s；目标参数不能替代实际 RIR 的衰减估计。

**镜像阶数检查。** 默认脚本对固定近左位置另算 32 阶结果，并与 40 阶比较：四麦  $T_{60}$  中位数相差约  $2.08 \times 10^{-6}$  s，DRR 中位数相差约  $7.55 \times 10^{-7}$  dB，低于本题自定的 0.02 s 与 0.5 dB 判据。本书还实际以 `--max-order 48` 重跑六个位置：与 40 阶相比，六个位置的  $T_{60}$  中位数变化都小于  $10^{-6}$  s，DRR 中位数变化都小于  $10^{-6}$  dB， $1^\circ$  网格的方位估计不变。这些比较说明所列指标对 40~48 阶的截断不敏感，不证明频谱细节或其他几何设置也已收敛；改变房间、源位或指标后须重新检查。



本题试听样本。仓库已将六组源信号、四麦完整房间输出和四麦仅直达输出，共 18 个 PCM WAV 单独保存在 `codes/room_audio/`，参数、共同增益、种子和逐文件摘要见[房间音频清单](#)；[逐组试听入口](#)列出全部文件。

每组使用与定位估计相同的固定白高斯噪声输入；全部文件采用同一个显式增益，不逐文件峰值归一化，保留传播时延和增益差异。文件是数学合成白噪声，不是真实语音或实测房间录音；试听前先降低播放音量。它们与主清单的 60 个 `codes/audio/` 样本分别管理。

若要重新生成到个人实验目录，先在装有锁定版 pyroomacoustics 0.10.0 的隔离环境中运行 `python -m codes.examples.room_srp_exercise --run --audio-dir /tmp/room-srp-audio-new`；为防止覆盖，该目录必须尚不存在。

解读边界。固定的  $\pm 30^\circ$  条件分别在 1 m 与 2.5 m 比较；这间合成房间中，远位置的 DRR 较低，绝对 DOA 误差由  $1^\circ$  变成  $2^\circ$ 。

距离变化也改变了声源相对墙面的位置和反射路径，这两个成对条件不足以估计跨房间、跨方向的平均因果效应。另两个随机位置同时改变距离与方向，更不能凭六点的总体相关性归因于距离。临界距离只给 DRR 量级参考，定位误差不保证在那里出现拐点。

脚本未加入麦克风失配、加性噪声、声源高度变化或真实房间扩散结构；讨论这些因素时须另做控制实验。`--check` 的输出只有配置，没有上述仿真指标。

### 13.6.6 公开系统复核：题 17

17.（研究拓展）读一篇 CHiME-8 参赛系统报告（见 § 13.3 引用），按报告实际结构画出前端流程图，与本书图23 对照。

逐项标出定位、分割、GSS/波束、增强和 ASR 后端是否存在，不先假定高排名系统都采用同一架构；再说明其阵列无关设计依赖哪些训练数据或解析模块。

### 13.6.7 补充计算：试听归一化

E13-01：试听归一化会隐藏什么。两段四点信号分别为  $a = [0, 0.4, -0.4, 0]$ 、 $b = [0, 0.2, -0.2, 0]$ ，仅用于手算，不当作可听语料。求两者电平差，再比较“共同乘 2”和“各自除以自身峰值”两种处理。

答案： $b$  的幅度是  $a$  的一半，电平低  $20 \log_{10} 2 \approx 6.0206$  dB。共同乘 2 后，两者峰值是 0.8 和 0.4，原来的比例保留。各自除以自身峰值后，都变成  $[0, 1, -1, 0]$ ，差值为零，衰减被归一化消除了。

运行 `.venv/bin/python -m codes.examples.exercises_engineering` 中的 E13-01 可复核这组数字。实际试听使用音频实验手册列出的较长素材。比较残余回声电平或 AGC 行为时，不能先分别拉到同一峰值再宣称电平没有变化；若只比较音色，可另建等响度试听版本，但仍保留未经该处理的评分输入。

图35 三种合成反例：相关噪声、极性错误与病态求逆




图 35 读取 16 kHz、PCM16 导出文件，每组使用共同增益，随机种子 20260923，时长 2 s。

- (a) 两路目标已对齐，噪声标准差均为 0.07；独立噪声平均后误差 RMS 下降，复制相同噪声则不下降。
- (b) 输入目标增益为 1 与 -0.9；极性未纠正时平均只保留 0.05 倍目标，已知纠正后为 0.95 倍。波形展示 500~510 ms。

(c) 两个已知混合矩阵的二范数条件数分别为 3、199，同一输入噪声标准差为 0.003。每一路恢复结果与对应源参考逐样本相减，统计全段 RMS，不拟合额外时延或增益。柱形表示同一固定随机样本，不代表统计均值；不同子图条件不同，不能跨组排名。模型、矩阵及 13 个对照文件见[音频手册第 9~11 节](#)。

## 13.7 复现说明

先运行代码基线的单元测试和第 10 章示例，核对确定性输出：

```
.venv/bin/python -m unittest tests.test_codes_engineering -v
.venv/bin/python -m codes.examples.ch10_engineering_baselines
.venv/bin/python -m codes.examples.exercises_engineering
```

第 10 章示例使用确定性输入，覆盖 SRO 直线拟合与线性重采样、VAD 迟滞与 hangover、峰值保护 AGC、固定容量环形缓冲、deadline/队列模拟和 Q1.15 饱和量化。线性重采样、Python 环形缓冲和调度模拟都是教学基线，不应替换带抗混叠滤波的流式重采样器、无锁实时队列或目标系统测量。

继续做设备实验时，可按[工业实现研究](#)的 I01~I27 选择一个主题，例如采集与路由、连续重采样、VAD/AGC/NS、DSP 固件、模型运行时或评分。先固定源码提交，再记录依赖、编译、模型、声学输入和故障状态；“已下载”只能说明源码在本机，不能代替“已编译、已运行、已测量”。

会议识别复现还要固定数据准备与文本规范化。CHiME-8 的官方 [chime-utils](#) 提供 SegLST 转写格式、该届规范化及 cpWER/tcpWER 评分；其中缺失场景的忽略选项会改变实际计分范围。应保留每个场景的输入文件数、失败数和最终参与评分的清单，并先用正确转写、说话人交换、漏词和时间戳偏移的小夹具检查评分口径。[CHiME-8 官方评分实现](#)

绘图脚本都在 `scripts/` 里。图 34~36 和图 37~38 读取或复算指定教学数据，图 39 是算法流程图；先生成音频，再运行两个绘图脚本。图片写入 `figures/`，共 39 张：

```
.venv/bin/python codes/examples/generate_audio_samples.py
.venv/bin/python scripts/make_figures.py    # 图 1~25、图 33~36
.venv/bin/python scripts/make_aec_figures.py # 图 26~32、37~39（回声消除专题）
```

Windows 上把 `.venv/bin/python` 换成 `.venv\Scripts\python`，其余不变。

运行时间随硬件、软件版本和负载变化。报告耗时时应同时记录这些条件、运行次数和统计方式。

代码基线只依赖 `numpy`；绘图脚本依赖 `numpy` 和 `matplotlib`，并使用固定随机种子，因此相同环境和参数下应得到相同结果。每个脚本生成哪些图、练习需要哪些扩展依赖，见

`scripts/README.md`；代码覆盖范围、上游来源和许可证见 `codes/README.md`、`codes/COVERAGE.md` 与 `codes/SOURCES.lock.json`。

全书完